



Melhorando a precisão de previsão de dados de séries temporais usando um novo Método híbrido ARIMA-ANN e decomposição do modo empírico



Umit Chavuo ° Grande irmão a, *, Seyda Ertekin a, b

^a Departamento de Engenharia da Computação, Universidade Técnica do Oriente Médio (METU), Üniversiteler Mh., No:1, Ankara 06800, Turquia ^b MIT Sloan School of Management, Massachusetts Institute of Technology, 77 Massachusetts Ave, Cambridge, MA 02139, EUA

artilleinfo

Histórico do artigo:

Recebido em 17 de julho de 2018
Revisado em 1 de fevereiro de 2019
Aceito em 3 de maio de 2019
Disponível online em 16 de julho de 2019

comunicado pelo Prof. A. Prieto

Keywords:

Previsão da série temporal
ANN
ARIMA
EMD
Métodos híbridos

abstract

Muitas aplicações em diferentes domínios produzem grande quantidade de dados de séries temporais. Fazer um fundição preciso é fundamental para muitos tomadores de decisão. Existem vários métodos de previsão de séries temporais que usam modelos lineares e não lineares separadamente ou combinação de ambos. Estudos mostram que a combinação de modelos lineares e não lineares pode ser eficaz para melhorar o desempenho de previsão. No entanto, algumas suposições que esses métodos existentes fazem podem restringir seu desempenho em determinadas situações. Fornecemos um novo método híbrido autoregressivo Integrated Moving Average (ARIMA)-Artificial Neural Network (ANN) que funciona em uma estrutura mais geral. Os resultados experimentais mostram que as estratégias de decomposição dos dados originais e para a combinação de modelos lineares e não lineares ao longo do processo de hibridização são fundamentais fatores no desempenho de previsão dos métodos. Usando esses achados, o método híbrido proposto é combinado com a técnica empírica de decomposição do modo empírico (EMD), que gera componentes mais pré-dicáveis. Mostramos que nosso método híbrido com EMD pode ser uma maneira eficaz de melhorar a precisão de previsão obtida pelos métodos híbridos tradicionais e também qualquer dos métodos individuais que usamos separadamente.

© 2019 Elsevier B.V. Todos os direitos reservados.

1. Introdução e trabalho relacionado

Séries temporais de dados listados em ordem de tempo. É geralmente uma sequência de dados de tempo discreto que consiste em pontos igualmente espaçados no tempo. Na previsão da série temporal, tentamos prever os pontos futuros analisando pontos observados na série. Tem sido amplamente utilizado em várias aplicações das áreas de ciência, engenharia e negócios. No entanto, os dados da série temporal podem mostrar características diferentes e mostrar tendências crescentes ou decrescentes. Alguns dados da série temporal têm tendências sazonais em que as variações são específicas para uma determinada faixa de tempo, por exemplo, vendas de casacos e inicializadores em vinhos na temporada de inverno enquanto diminuir na temporada de verão. Por outro lado, alguns dados da série time não são sazonais, como dados do mercado de ações. Além disso, os dados da série temporal podem mostrar um nível diferente de volatilidade. Por exemplo, a taxa de câmbio USD/EUR (Dólar dos Estados Unidos/Euro) mostra alta volatilidade, por outro lado, o crescimento de um ser animal, vegetal ou humano mostra uma mudança linear. Ao longo das últimas décadas, um esforço considerável tem sido dedicado para desenvolver e melhorar os modelos de previsão de séries temporais [1]. Na literatura, vários métodos de previsão foram propostos que usam lineares

* Autor Correspondente.

Endereços de e-mail: umit.buyuksahin@ceng.metu.edu.tr (U.Ç. Grande canela), seyda@ceng.metu.edu.tr (S. Ertekin).

<https://doi.org/10.1016/j.neucom.2019.05.099> 0925-2312/© 2019 Elsevier B.V. Todos os direitos reservados.

e modelos não lineares separadamente ou combinação de ambos. Neste artigo, propomos um algoritmo híbrido de métodos lineares e não lineares onde escolhemos a Auto-borracha integrada Autoregressiva (ARIMA) como método linear e Artificial Redes Neurais (ANNs) como um método não linear. Além disso, o desempenho do método proposto é aprimorado usando uma técnica de decomposição em várias escalas, como a Decomposição do Modo Empírico (EMD).

ARIMA é amplamente utilizado método de previsão de séries de tempo linear que é usado em inúmeras aplicações, incluindo finanças [2], engenharia [3], ciências sociais [4] e agricultura [5]. Os modelos ARIMA são integração dos modelos Autoregressivo (AR) e Moving Average (MA). Os modelos ARIMA dão boa precisão na previsão de dados de séries temporais relativamente estacionárias. No entanto, faz uma forte suposição de que os valores de dados futuros são linearmente dependentes dos valores de dados atuais e passados. Portanto, muitos dados da série tempo real apresentam padrões complexos não lineares que podem não ser modelados pela ARIMA efetivamente.

Para a modelagem de séries temporais não lineares, a Rede Neural Artificial (ANNs) é um dos algoritmos mais utilizados [6] em muitos campos, como finanças [7], energia [8], hidrologia [9], e comunicações de rede [10]. As ANNs têm várias vantagens sobre a ARIMA e outros modelos de previsão. Em primeiro lugar, as ANNs são capazes de encaixar uma função complexa não linear. Essa capacidade ajuda as ANNs a aproximar qualquer função mensurável contínua com precisão arbitrariamente desejada [11,12]. Além disso, as ANNs são adaptativamente de natureza, o que significa que os modelos ANN podem ser adaptados com base nos recursos de dados de séries temporais [13].

Na literatura, há estudos que mostram o sucesso de métodos lineares e não lineares uns sobre os outros. Por exemplo, [14–16] relatam que modelos estatísticos e lineares dão melhores resultados do que as ANNs. Por outro lado, [17–19] relatam que a ANN tem um desempenho melhor do que os modelos lineares quando os dados apresentam alta volatilidade e multicolinearidade.

Em suma, cada tipo de modelo pode não ter um bom desempenho em todas as circunstâncias. Para superar essa limitação, foram propostas diversas técnicas híbridas que visam aproveitar a força única de cada tipo diferente de modelos.

A prática comum em técnicas híbridas é decompor a série temporal data em suas formas lineares e não lineares, em seguida, usar apropriado tipo de modelos sobre eles separadamente. Um modelo híbrido ANN-ARIMA proposto por Zhang [13] alcança resultados de previsão mais precisos em dados de séries temporais em comparação com o uso de modelos individuais, em aplicações como previsão de preços de eletricidade [20] e previsão de qualidade da água [21]. Outra técnica híbrida de sucesso ARIMA-ANN é apresentada por Khashei e Bijari [22] que define a relação funcional entre os componentes. Além disso, Babu e Reddy [23] oferecem uma solução para o problema de volatilidade em dados de séries temporais, suavizando o conjunto de dados com filtro médio móvel.

Cada método híbrido na literatura traz diferentes per-espectros para o problema de previsão de séries temporais. No entanto, fortes suposições que esses métodos fazem podem degenerar suas performances se as situações contrárias ocorrerem. A força dos métodos híbridos vem do tratamento dos componentes lineares e não lineares da série temporal de diferentes maneiras. Portanto, a decomposição adequada da série é crítica. No entanto [13] e [22] não decompõem dados da série temporal em componentes lineares e não lineares. Em vez disso, eles assumem que o componente linear dos dados é a saída do modelo ARIMA. Além disso, [13] e [23] assumem que a saída de seus métodos híbridos é uma combinação linear dos componentes. No entanto, diferentes conjuntos de dados podem sugerir diferentes tipos de relações entre a saída e os componentes.

Neste estudo, propomos um novo método híbrido para previsão de séries temporais que visa superar as limitações dos métodos híbridos tradicionais, eliminando a necessidade de fazer suposições fortes. Neste método, a natureza da não linearidade é primeiro caracterizada pela ajuda do filtro de média móvel (MA), em seguida, a ARIMA é aplicada ao componente linear. Na etapa final, a ANN é usada para combinar a saída de ARIMA, o componente não linear e os dados originais. Por isso, não fazemos quaisquer suposições na extração de componentes e na modelagem de componentes. Três conjuntos de dados de referência, os dados da mancha solar do Wolf, os dados canadenses de linco, e os dados de taxa de câmbio libra/dólar britânico e um conjunto de dados público adicional, Os dados de preços do mercado de eletricidade intradiário da Turquia são usados para mostrar a eficácia do método proposto na previsão de séries temporais.

Além disso, propomos uma melhoria em todos os métodos híbridos mencionados neste artigo, incluindo o nosso, adicionando técnica de Decomposição do Modo Empírico (EMD) [24] aos modelos. Quando os resultados de precisão dos métodos híbridos com diferentes tipos de conjuntos de dados são comparados, observamos que o desempenho da precisão melhora com o aumento do nível de linearidade em séries temporais. Em seguida, os dados da série temporal podem ser considerados como uma mistura de sub-séries que cada uma delas demonstra mais linearidade. Para isso, uma técnica de decomposição multiescala bem conhecida, a EMD é usada no método híbrido proposto. Os componentes obtidos pelo EMD são relativamente estacionários e têm faixa de frequência mais simples que os tornam fortemente

correlacionados em si mesmos. Assim, previsões mais precisas podem ser obtidas através dos modelos [25,26].

O resto do jornal é organizado da seguinte forma. No próximo seção, apresentamos diferentes métodos de previsão da série Time.

Na Seção 3 apresentamos nosso modelo proposto. Na Seção 4, mostramos os resultados de avaliação do nosso modelo e apresentamos resultados de comparação com os demais métodos. Na Seção 5, fornecemos discussões e apresentamos o efeito positivo do uso da técnica EMD com os métodos híbridos e nosso novo método. Mostramos que nosso método supera consistentemente outros métodos lineares, não lineares e até híbridos.

2. Métodos de previsão da série temporal

A fim de dar revisão geral antes de apresentar nosso método, queremos dar uma breve informação sobre outros métodos de fundição de séries temporais, como ARIMA, ANN e o métodos híbridos bem conhecidos. Escolhemos três métodos híbridos sucessivos onde cada um tomou os anteriores como estudo de referência. Como os conjuntos de dados de referência são utilizados na avaliação desses métodos híbridos, pudemos repetir seus estudos para nossas comparações.

2.1. Método médio móvel integrado autoregressivo

ARIMA é um método linear que significa que o valor futuro de uma variável a ser prevista é assumido como função linear das observações passadas. Como consequência, espera-se que os dados da série temporal que são alimentados com a ARIMA sejam lineares e estacionários.

ARIMA realiza verificação de estacionariedade em determinados dados da série temporal para verificar se os padrões médios e de correção automática são constantes ao longo do tempo. Se a propriedade estacionária não estiver satisfeita, a ARIMA aplica-se método de diferenciamento d vezes até que a propriedade não estacionária seja descartada. Como consequência, a ordem de integração do modelo ARIMA está definida para ser d . Depois disso, uma média móvel autoregressiva (ARMA) é aplicada nos dados resultantes da seguinte forma:

Deixe que o valor real dos dados seja y_t e erro aleatório ϵ_t em qualquer momento t . Este valor real y_t é considerado como uma função linear dos valores de observação p passados, digamos $y_{t-1}, y_{t-2}, \dots, y_{t-p}$ e q erros aleatórios, digamos $\epsilon_t, \epsilon_{t-1}, \dots, \epsilon_{t-q}$. A equação ARMA correspondente é dada na seguinte equação:

$$y_t = \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \dots + \alpha_p y_{t-p} + \epsilon_t - \theta_1 \epsilon_{t-1} - \theta_2 \epsilon_{t-2} - \dots - \theta_q \epsilon_{t-q} \quad (1)$$

Em Eq. (1) Os coeficientes de α_1 a α_p são coeficientes de autoregressão, θ_1 a θ_q são coeficientes da média móvel. Observe que erros aleatórios ϵ_t são distribuídos de forma idêntica com uma média de zero e uma variância constante.

Semelhantes ao parâmetro d , os coeficientes p e q são referidos como as ordens do modelo. Quando q equivale a zero, o modelo é reduzido ao modelo AR de ordem p (AR(p)). Se p for igual a zero, o modelo torna-se ma modelo de ordem q (MA(q)).

2.2. Método de redes neurais artificiais

A ANN fornece uma estrutura de computação flexível para modelagem não linear em ampla gama de aplicações. Devido ao seu arqueoflexo flexível, o número de camadas e os neurônios em cada camada podem ser facilmente variados. Além disso, a ANN não requer nenhuma assumption prévia, como a estacionalidade de dados de entrada. A configuração da rede ANN é determinada em grande parte pelas características dos dados.

A arquitetura dos modelos ANN mais amplamente utilizados na previsão de séries temporais contém três camadas. Os neurônios das camadas estão aciclicamente ligados. A fim de modelar dados de séries temporais usando

uma rede de três camadas, função não linear f de y_t , sequência de y_{t-1} a y_{t-N} é construída como mostrado na seguinte equação:

$$y_t = w_0 + \sum_{j=1}^H w_j \left(\sum_{i=1}^N f(w_{ij} y_{t-i} + e_t \right) \quad (2)$$

onde, a qualquer momento t , w_{ij} e w_j são pesos modelo e H e N são o número de nós ocultos e de entrada, respectivamente. Nesta equação, e_t corresponde a um termo de ruído ou erro. A função de transferência das camadas ocultas f na arquitetura ANN pode ser funções como sigmoid, ReLu, tanh, etc.

2.3. Método híbrido de Zhang

Para a previsão da série temporal, Zhang propôs um ARIMA híbrido. Modelo ANN [13]. De acordo com este modelo, supõe-se que os dados da série temporal são uma soma de componentes lineares e não lineares, dado na forma de:

$$y_t = L_t + N_t \quad (3)$$

onde L_t denota o linear e N_t denota o componente não linear. Em primeiro lugar, a ARIMA é usada com os dados da série temporal e as previsões lineares são obtidas. Presume-se que os resíduos do componente linear contenham apenas uma relação não linear. Este método usa ARIMA para fazer previsão a partir do componente linear e ANN a partir do componente não linear. Então, esses modelos são combinados para melhorar o desempenho geral de previsão. Este método dá melhor precisão de previsão do que o uso de métodos ARIMA e ANN individualmente, como visto nos resultados experimentais em três conjuntos de dados reais bem conhecidos - os dados da mancha solar do Wolf, os dados canadenses de lince e os dados da taxa de câmbio libra/dólar britânico.

2.4. Método híbrido de Khashei e Bijari

Para previsão de séries temporais, Khashei e Bijari propuseram outro híbrido ARIMA-ANN [22]. Semelhante ao modelo de Zhang, este modelo também assume que qualquer dado da série temporal é composto de componentes lineares e não lineares. Da mesma forma, a ARIMA é usada para extrair componentes lineares e fazer previsão sobre ele e os resíduos, que são componentes não lineares, são alimentados em ANN juntamente com os dados originais, e previsão linear da saída ARIMA. A diferença do modelo de Zhang é evitar a suposição de que a relação entre componentes lineares e não lineares é aditiva. Em vez disso, este método constrói uma relação funcional entre os componentes, como mostrado na seguinte equação:

$$y_t = f(L_t, N_t) \quad (4)$$

onde L_t é o linear e N_t é o componente não linear.

Além disso, não se pode garantir que os resíduos do componente linear possam incluir padrões não lineares válidos. Khashei e Bijari sugerem que os resíduos não devem ser colocados em ANN apenas como uma entrada.

2.5. Método híbrido de Babu e Reddy

O método híbrido ARIMA-ANN proposto por Babu e Reddy [23] integra filtro médio móvel no modelo HÍBRIDO ANN-ARIMA. Como outros métodos, este modelo também assume que qualquer dado de série temporal é composto de componentes lineares e não lineares. No entanto, este estudo enfatiza que nem os métodos de Zhang nem Khashei e Bijari decompõem dados originais da série temporal em seus componentes

lineares e não lineares; em vez disso, eles usam um modelo ARIMA linear para extrair o componente linear e as sequências de erro são assumidas como componente não linear. Por outro lado, este estudo separa os componentes lineares e não lineares e, em seguida, alimenta-os em métodos apropriados.

Este método tenta fixar o comprimento do filtro Moving Average (MA) até que o valor da kurtose dos dados se torne aproximadamente 3. Kurtose é uma forma de distribuição de probabilidades que mede a espessura ou o peso das caudas de uma distribuição. O valor da kurtose é 3 se os dados têm distribuição normal. Em breve, o método visa descobrir o componente distribuído normal, que mostra baixa volatilidade, em dados de séries temporais usando o valor da kurtose. Quando o componente baixo volátil é separado dos dados originais, o alto-volátil componente, que se supõe ser não linear, é alcançado. Na etapa final, como no método de Zhang, os componentes decompostos são alimentados em ARIMA e ANN de acordo e os resultados de previsão são resumidos para alcançar previsão final.

3. Método proposto

Muitos processos de decisão precisam de altas precisão de previsão em aplicações de séries temporais. Embora existam inúmeros modelos de séries temporais disponíveis, nenhum deles consistentemente dá os melhores resultados em várias situações. Há dois desafios principais para fazer uma previsão precisa. O primeiro desafio é que o processo de geração de dados subjacente de séries temporais não pode facilmente identificar [27]. A segunda é que modelos individuais não híbridos são geralmente insuficientes para determinar todas as características da série temporal [13]. Muitas pesquisas em séries temporais que preveem a literatura mostram que os modelos híbridos melhoram a previsão performances [28]. Ao tirar vantagem de cada método individual em um modelo combinado, o risco de erro de usar um método inadequado é reduzido e resultados mais precisos são obtidos.

Cada método híbrido mencionado neste artigo traz diferentes perspectivas para o problema de previsão de séries temporais. No entanto, fortes suposições que esses métodos fazem podem degenerar suas formas em determinadas circunstâncias. Neste estudo, propomos um novo método híbrido para previsão de séries temporais que visa superar as limitações dos métodos híbridos tradicionais, eliminando premissas fortes. A arquitetura do método híbrido proposto é mostrada em Fig. 1.

O algoritmo começa com a decomposição de dados. Neste método, os dados da série temporal y_t são considerados como uma função dos componentes lineares L_t e N_t não lineares da mesma forma que dado no Eq. (4).

Estes dois componentes são separados dos dados originais usando filtro de média móvel (MA) com o comprimento de m , conforme dado no Eq. (5). Enquanto o componente linear L_t tem baixa volatilidade, o residual r_t , que é a diferença entre os dados originais e os dados lineares decompostos em Eq. (6), mostra alta flutuação.

$$L_t = \frac{1}{m} \sum_{i=t-m+1}^t y_i \quad (5)$$

$$r_t = y_t - L_t \quad (6)$$

Para uma decomposição adequada, o comprimento do filtro MA m deve ser ajustado. O teste de Dickey Fuller (ADF) aumentado, que é teste raiz da unidade, pode ser realizado para determinar se uma determinada série de dados está parada ou não. A existência de uma raiz de unidade em um determinado conjunto de dados indica que há um padrão sistemático imprevisível.

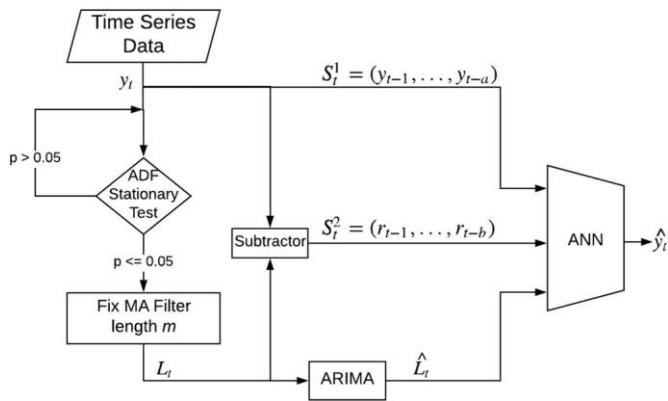


Fig. 1. Método híbrido proposto .

O resultado mais negativo do teste ADF significa a rejeição mais forte da existência de raiz unitária para uma determinada série temporal. Portanto, um resultado ADF negativo implica que o conjunto de dados dado está parado. O limiar bem aceito é 0,05, que também é usado neste estudo para ajustar o comprimento do filtro MA.

Depois que o componente linear é alcançado com filtro MA, um modelo linear é construído como mostrado no Eq. (7). O componente aryl é modelado como uma função linear dos valores passados da série de dados $lt-1, lt-2, \dots, lt-p$ e série de erros aleatórios

$-1, \epsilon_{t-2}, \dots, \epsilon_{t-q}$ em Eq. (1) utilizando o modelo ARIMA.

$$L_{\dots}t = g(lt-1, lt-2, \dots, lt-p, \epsilon_{t-2}, \dots, \epsilon_{t-q}) \quad (7)$$

onde g é uma função linear de ARIMA.

Por fim, a modelagem não linear ANN é usada para implementar a relação funcional entre componentes conforme indicado no Eq. (4).

Daí o passado de observados os dados decompostos $yt-1$ stationary, $yt-2, \dots$, dados $yt-a, L_{\dots}$ presentt, e residualsARIMA previsão do

decomposição de dados $rt-1, rt-2, \dots, rt-b$ são alimentados para ANN como indicado no Eq. (8):

$$\begin{aligned} S_t^1 &= (y_{t-1}, y_{t-2}, \dots, y_{t-a}) \\ S_t^2 &= (r_{t-1}, r_{t-2}, \dots, r_{t-b}) \\ y_{\dots}t &= f(S_t^1, L_{\dots}t, S_t^2) \\ y_{\dots}t &= f(y_{t-1}, y_{t-2}, y_{t-a}, L_{\dots}t, r_{t-1}, r_{t-2}, \dots, r_{t-b}) \end{aligned} \quad (8)$$

onde f é a função não linear de ANN, a e b são parâmetros do modelo que mostram o quanto voltaremos no tempo para usar como recursos para ANN. Os dados da série time determinam quantas dessas características no caminho residual e no caminho de dados observados serão usadas no modelo não linear. Por exemplo, se os dados determinados não mostrarem volatilidade, então a variável residual b no Eq. (8) pode sair até mesmo como zero no processo de ajuste. Da mesma forma, uma variável em Eq. (8) também é empiricamente determinado no processo de sintonia.

O modelo proposto não explora apenas a força única dos modelos únicos, mas também elimina as três premissas fortes realizadas por outros métodos híbridos. Portanto, o risco de baixo desempenho de fundição em situações inesperadas é altamente evitado. O desempenho competitivo do nosso algoritmo proposto é mostrado em nossos resultados experimentais usando vários tipos de conjuntos de dados.

4. Resultados empíricos

Os resultados de desempenho do método híbrido proposto juntamente com os outros métodos discutidos neste artigo são avaliados em quatro conjuntos de dados diferentes. Três deles são conjuntos de dados de referência bem conhecidos - os dados da mancha solar do Wolf, os dados canadenses de linco e os dados de taxa de câmbio libra/dólar britânico - que têm sido amplamente utilizados nas estatísticas e na rede neural litera-ture [13,22,23,25]. O outro conjunto de dados é o preço de eletricidade disponível publicamente do Turkey Intraday Market [29]. Esses quatro dados de séries temporais diferentes são originados de diferentes disciplinas e mostram características diferentes. Enquanto um conjunto de dados (por exemplo, GbpUsd) é altamente não estacionário e volátil, outro (por exemplo, Lynx) mostra comportamentos de orelhas lin. Da mesma forma, enquanto um deles inclui sazonalidade (por exemplo, Sunspot), o conjunto de dados restante (por exemplo, Intraday) não. Essa diversidade nos permitiu fazer nossos experimentos com um amplo espectro de conjuntos de dados.

Nos experimentos, apenas uma previsão de um passo à frente é considerada. Para comparar os desempenhos de precisão, são utilizadas três métricas de avaliação: Erro Absoluto Médio (MAE), Erro Quadrado Médio (MSE) e Erro De Escala Absoluta Média (MASE), cujas formulações são indicado da seguinte forma:

$$\begin{aligned} AED &= \sum_{t=1}^n e_t \\ \overline{|e|} &= \frac{1}{n} \sum_{t=1}^n |e_t| \\ \frac{n-1}{n} \frac{\sum_{t=2}^n |e_t|}{\sum_{t=2}^n |e_t - e_{t-1}|} \\ MSE &= \frac{1}{n} \sum_{t=1}^n e_t^2 \\ MASSES &= \frac{1}{n} \sum_{t=1}^n |e_t| \end{aligned} \quad (9)$$

onde $e_t = y_t - \hat{y}_t$ e y_t é o valor real dos dados, \hat{y}_t é o valor lançado em determinado momento t . Enquanto o MAE especifica a média dos erros absolutos sobre a previsão realizada, o MSE mede a média do erro quadrado. Uma vez que os erros de previsão são quadrados na métrica MSE, isso dá uma influência relativamente maior para erros maiores. Portanto, esta propriedade torna o MSE útil quando grandes erros não são desejados. Por outro lado, o MAE não penaliza outliers como o MSE, uma vez que igualmente pondera erros de previsão na média. Ambas as métricas são boas quando comparamos algoritmos para um conjunto de dados. No entanto, ao comparar um algoritmo para séries temporais que têm escalas diferentes, eles podem não ser confiáveis, uma vez que os resultados mae e MSE dependem a escala dos dados dados. Portanto, um MASE métrico de erro sem escala pode ser usado para comparar a precisão de previsão entre séries dimensionadas.

Para avaliar o desempenho de previsão dos diferentes métodos, cada conjunto de dados é dividido em conjuntos de treinamento e testes. Enquanto os dados de treinamento são usados para o desenvolvimento do modelo, os dados de teste são usados para avaliar o modelo estabelecido. Para ajustar os hiper parâmetros dos métodos, os últimos 20% do conjunto de dados de treinamento são usados como conjunto de validação. Ao escolher o modelo ANN certo, uma vez que não há um método aceito para configuração de rede, uma abordagem empírica é realizada. Nesta abordagem, ANN é metodicamente construída para cada combinação de parâmetros de algoritmo

e avaliada no conjunto de validação. A melhor configuração alcançada é usada como modelo final.

Além disso, devido ao fato de que a ANN realiza uma inicialização aleatória e produz resultados diferentes em cada execução, os métodos que incluem o algoritmo ANN são executados 50 vezes e resultados médios são relatados. Este número não é um hiperparâmetro para sintonizar, mas alto o suficiente para obter resultados confiáveis e robustos. A Tabela 1 dá os resultados de previsão de todos os métodos examinados nesses quatro conjuntos de dados. A tabela também apresenta os resultados do método ingênuo para ter uma comparação de linha de base. Este método ($y_t = y_{t-1}$) usa o valor na etapa anterior $t - 1$ para prever o resultado esperado no atual passo do tempo t .

Para avaliar se os resultados médios dos ods de metanfetamina são estatisticamente diferentes entre si, é utilizada a análise t-test [30]. Como resultado do teste, os valores p são obtidos para comparação par-wise entre o nosso método e as métricas de erro dos outros métodos. Se p -valor for inferior a 0,05, pode ser aceito, pois nosso método é estatisticamente diferente do método comparado no teste [30]. A Tabela 2 apresenta os valores p para quatro comparações em pares para todos os conjuntos de dados. Como o MASE é o aumento do MAE, os resultados dos testes em duas métricas são os mesmos. Para evitar a repetição em vez de dois deles, os resultados para apenas MAE são relatados. A Tabela 2 mostra que o método proposto é significativamente diferente de todos os métodos examinados para todos os conjuntos de dados experimentados na métrica MSE. Na métrica mae, os métodos propostos são estatisticamente significativos do que pelo menos três dos métodos examinados.

4.1. Previsões para o conjunto de dados de manchas solares

A série de manchas solares do Lobo, que contém atividade anual de manchas visíveis na face do sol, tem sido amplamente utilizada em inúmeros modelos lineares e não lineares [22]. Os dados incluem a contagem anual de manchas solares de 1700 a 1987 (ver Fig. 2) totalizando 288 observações. Resultado do teste de stationaridade da ADF

Datasets	Métricas de métodos	Método ingênuo	ANN	ARIMA	Método de Zhang	Método K-B	Método de B-R	Método proposto
Sunspot	MAE	22.96		13.37				
	MSE	920.73		306.97				
	MASE	1.01		0.59				
Lince	MAE	0.2308		0.1198				
	MSE	0.0687		0.0231				
	MASE	1.1425		0.5932				
Gbp/Usd	MAE	512.41		435.72		10.62 ± 0.26	11.39 ± 0.22	10.48 ± 0.27
						205.08 ± 15.06	239.90 ± 22.89	194.29 ± 13.36
						0.47 ± 0.01	0.50 ± 0.01	0.46 ± 0.01
						0.1025 ± 0.0025	0.1102 ± 0.0028	0.1013 ± 0.0031
						0.0175 ± 0.0016	0.0189 ± 0.0019	0.0162 ± 0.0018
						0.50757 ± 0.0127	0.5457 ± 0.0138	0.5016 ± 0.0157
						406.22 ± 24.65	436.34 ± 36.87	404.90 ± 23.43
						3.10 ± 0.22	3.50 ± 0.33	2.95 ± 0.26
						1.028 ± 0.062	1.104 ± 0.145	1.025 ± 0.059
						19.79 ± 1.708	19.50 ± 0.981	18.81 ± 0.972
						600.93 ± 46.75	619.67 ± 37.07	581.38 ± 34.77
						1.03 ± 0.08	1.01 ± 0.05	0.98 ± 0.05

* o método de Khashei-Bijari é mostrado como método K-B. ** o método de Babu-Reddy é mostrado como método de B-R. *** os resultados do MAE e do MSE são multiplicados com 10⁻⁵ em Gbp/Usd dataset **** Os valores mostrados com ± dão os valores de desvio padrão.

Tabela 2 p -valor de comparação do resultado do teste do método proposto.

Datasets	Métricas de métodos	ANN	Método de Zhang	Método de Khashei-Bijari	Método de Babu-Reddy
Mancha solar	MAE	0.001	0.001	0.007	0.001
	MSE	0.001	0.001	0.001	0.001
Lince	MAE	0.001	0.135	0.038	0.001
	MSE	0.001	0.002	0.011	0.001
Gbp/Usd	MAE	0.017	0.022	0.124	0.037
	MSE	0.001	0.001	0.036	0.001
Intraday	MAE	0.001	0.012	0.001	0.001
	MSE	0.001	0.049	0.017	0.001




Fig. 2. Série Sunspot (1700-1987).

o conjunto de dados é de 0,083, que é maior que o limiar 0,05. Isso implica que há uma raiz de unidade no conjunto de dados, portanto, o conjunto de dados pode ser considerado como uma série temporal não estacionária. 288 observações no conjunto de dados são divididas em duas amostras: 221 observações entre 1700-1920 anos são consideradas como dados de treinamento para desenvolver o modelo, as últimas 67 observações entre 1921 e 1987 anos são consideradas como dados de teste e usados para avaliar o desempenho do modelo.

No conjunto de dados sunspot, quando o ARIMA é usado individualmente como método de previsão, também definimos a ordem de ARIMA para 9 (AR(9)) como as outras muitas pesquisas [13,22,23]. Quando é usado individualmente como um método de previsão, semelhante a estes estudos, três camadas $4 \times 4 \times 1$ ARQUITETURA ANN é usada que é composta de quatro nós de entrada, quatro nós ocultos e um nó de saída.

No método proposto, o componente linear sai quando o comprimento do filtro MA é de 15. Após o uso do filtro, o componente linear alcançado tem resultado de teste estacionário de 0,006, o que indica sua stationaridade, uma vez que é um valor inferior ao limiar, 0,05. A rede neural mais bem encaixada na etapa final do método híbrido proposto tem 7 nós na camada de entrada onde 4 deles são valores observados, 2 de são resíduos, e um nó é atribuído para o resultado da previsão de componentes lineares. De acordo com nossos experimentos, quando o número de nós ocultos são ajustados para o mesmo número de nós que na camada de entrada, o modelo ANN mais bem equipado é alcançado.

Quando são analisados os resultados numéricos do conjunto de dados

4.2. Previsões para o conjunto de dados lynx

O conjunto de dados lynx, que contém o número de linces presos por ano no distrito do rio Mackenzie, no norte do Canadá, é outro dados da série temporal amplamente analisados na literatura [13,22]. Os dados mostram uma periodicidade de aproximadamente 10 anos, como visto na Fig. 4. Além disso, os resultados dos testes estacionários ADF do conjunto de dados são 0,056, o que implica que o conjunto de dados está quase estacionário. Há 114 observações nos dados, correspondendo ao período de 1821 a 1934. As primeiras 100 observações entre 1821 e 1920 anos são consideradas como dados de treinamento para desenvolver o modelo, as últimas 14 observações entre 1921 e 1934 anos são usadas como teste dados para avaliar o desempenho do modelo. Além disso, como em outros estudos [13,22], os logaritmos (até a base 10) dos dados são utilizados na análise.

Quando o ARIMA é usado como modelo individual, utilizamos o modelo AR de ordem 12 (AR(12)) para conjunto de dados Lynx que também é usado por [13,22]. Semelhante a esses estudos, três camadas $7 \times$ arquitetura 5×1 ANN são usadas quando ANN é usada individualmente como método de previsão.

No método proposto, o componente linear é extraído do conjunto de dados Lynx quando o comprimento do filtro MA é 5. O comprimento relativamente curto do filtro MA era esperado, uma vez que o resultado do teste ADF mostra um certo nível de stationaridade nos dados. Como resultado do filtro MA, o componente linear alcançado tem resultado de teste estacionário de 0,006, o que indica ainda mais stationaridade a ser devidamente modelado pela ARIMA. A rede neural mais bem encaixada na etapa final do método híbrido proposto tem

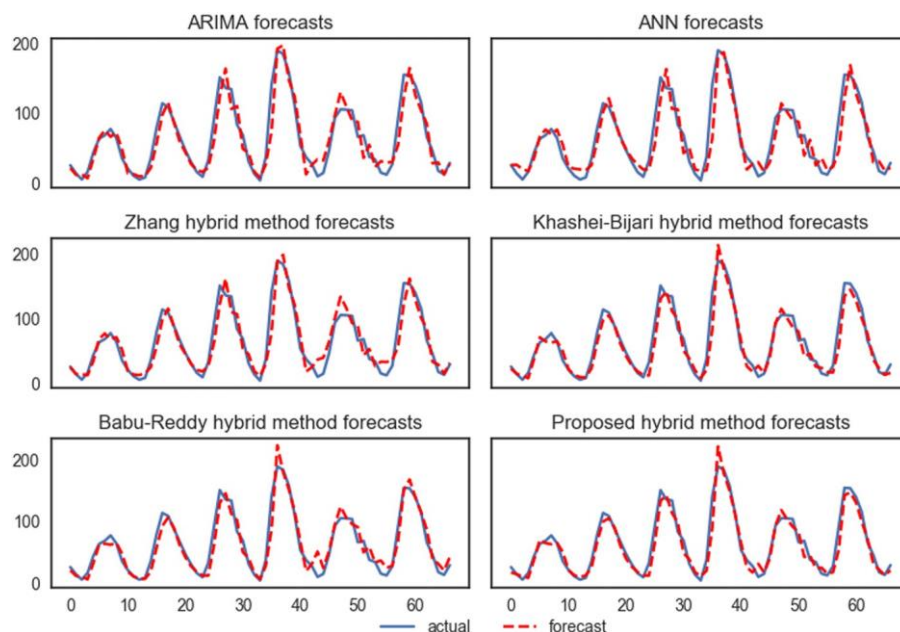


Fig. 3. Previsões de dados da Mancha Solar usando vários métodos.

sunspot dado na Tabela 1, métodos individuais como ARIMA, ANN têm desempenho aparentemente menor em comparação com métodos híbridos. Isso sugere que arima ou ANN, quando usado individualmente, não capturam todos os padrões da série de dados. Portanto, combinar dois métodos aproveitando cada um deles pode ser uma maneira eficaz de superar essa limitação. Observamos na Tabela 1 que os métodos híbridos Zhang, Khashei-Bijari e Babu-Reddy produzem melhores resultados em comparação com os individuais. No entanto, eles produzem um desempenho de previsão menor do que o nosso método híbrido proposto. As suposições que esses métodos híbridos fazem podem ser restringidas em muitas situações como mencionado na Seção 3. Nosso método híbrido proposto elimina essas suposições e produz melhor desempenho de generalização. A comparação dos valores reais e de previsão para todos os métodos examinados são dadas em Fig. 3.

9 nós na camada de entrada onde 5 deles são valores observados, 3 de são resíduos, e um nó é atribuído para o resultado da previsão de componentes lineares. De acordo com nossos experimentos de ajuste, quando o número de nós ocultos são ajustados para o mesmo número de nós que na camada de entrada, o melhor modelo ANN equipado é alcançado.

Neste conjunto de dados, entre os métodos utilizados individualmente, o ARIMA dá melhor precisão em comparação com ANN em contraste com o conjunto de dados sunspot (ver na Tabela 1).. Isso é mais provável devido ao fato de que o conjunto de dados lynx é mais estacionário em comparação com o conjunto de dados sunspot. Devido a essa estacionariedade relativa, o efeito dos métodos híbridos pode não ser facilmente observado. Embora tenhamos circunstâncias que não necessariamente favorecem a decomposição de dados e a combinação de modelos, os métodos híbridos não dão um desempenho menor do que o indivíduo modelos lineares, e eles até fornecem melhores resultados. O melhor desempenho é alcançado principalmente pelo nosso

método híbrido proposto. **Fig. 5** compara os valores reais e de previsão para todos os métodos examinados.

treinamento para desenvolver o modelo, as últimas 52 observações entre 1992-1993 anos são usados como dados de teste para avaliar o desempenho do




Fig. 4. Série de dados canadense lynx (1821-1934).

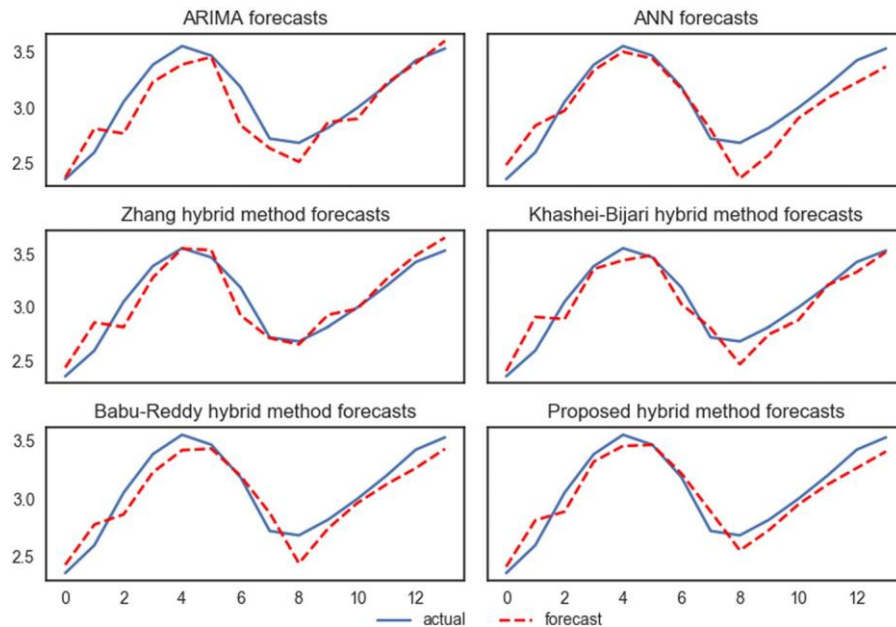


Fig. 5. Os dados do Lynx são previsões usando vários métodos.

4.3. Previsões para conjunto de dados Gbp/Usd

O outro conjunto de dados de referência é a taxa de câmbio entre libra britânica e dólar americano que contém observação semanal de 1980 a 1993, dando 731 pontos de dados na série temporal. A taxa de câmbio pré-dicting é uma tarefa importante, mas difícil, devido à alta volatilidade. O resultado do teste estacionário ADF do conjunto de dados é de 0,58, que é altamente maior que o limiar 0,05. Isso implica que o conjunto de dados é altamente volátil e não está parado. Essa não-estação pode até ser vista na trama, dada em **Fig. 6**, que mostra numerosos mudando pontos de virada na série. Semelhante a outros conjuntos de dados, a configuração experimental é a mesma de estudos híbridos anteriores [13,22] onde os dados são transformados usando função logarítmica natural e separados em duas amostras. Os 679 anos de 1980 a 1992 são considerados como dados de

modelo.

Neste conjunto de dados, quando o ARIMA é usado individualmente, em vez de usar o tipo de modelo de regressão no próprio ARIMA, o modelo de caminhada aleatória é escolhido como o modelo ARIMA mais bem equipado. Essa abordagem tem sido usada por Zhang [13] e também foi sugerida por muitos estudos na literatura cambial [31]. Neste modelo, a observação mais recente é o melhor guia para a próxima previsão. Quando ANN é usado individualmente como um método de previsão, o ANN mais bem equipado é definido como três camadas $7 \times 6 \times 1$ arquitetura.

No método proposto, a fim de decompor esses dados altamente voláteis, o comprimento do filtro MA sai para 40. Como resultado dessa decomposição, o resultado do teste ADF do componente obtido é 0,007, o que indica a stationariedade do componente. Para calcular a melhor previsão final no modelo proposto, a ANN é construída como três camadas $9 \times 9 \times 1$




Fig. 6. Semanalmente, a libra britânica/dólar americano (1980-1993).

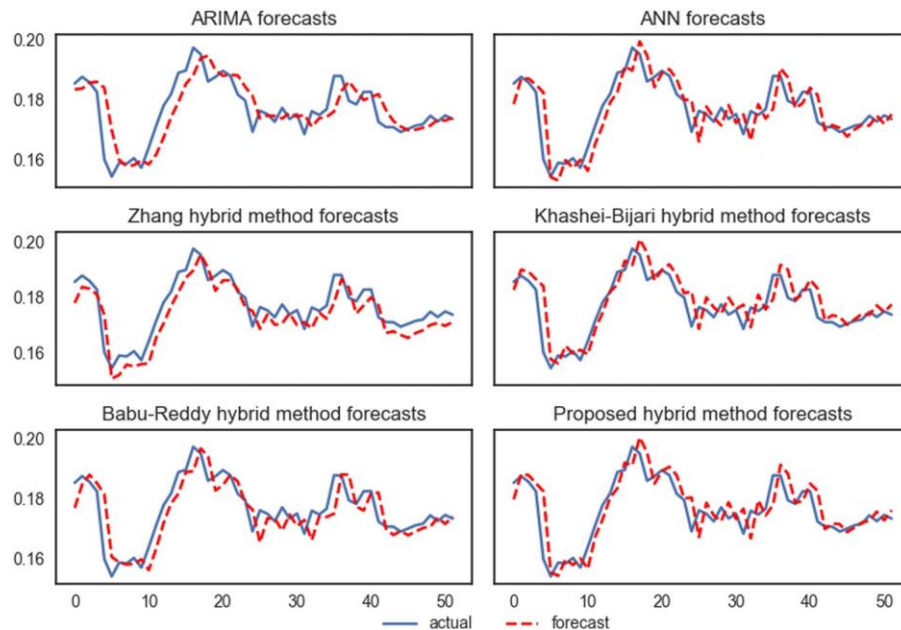


Fig. 7. Previsões de dados gbp/Usd usando vários métodos.

arquitetura. Nesta tectura arquii-ecture, a camada de entrada é composta dos últimos 5 valores observados, os últimos 3 de resíduos e o resultado da previsão de componentes lineares. Os resultados das previsões do conjunto de dados Gbp/Usd são comparados na Fig. 7. Tanto os métodos ANN quanto os híbridos têm um desempenho muito melhor do que o método ARIMA individual para um horizonte de previsão altamente flutuante. O método híbrido proposto é capaz de capturar este padrão volátil muito melhor e supera os outros métodos em todas as métricas de erro.

4.4. Previsões para o conjunto de dados intradiário

O último conjunto de dados analisados são os dados de preços intradiários do mercado de eletricidade da Turquia, que estão disponíveis publicamente [29]. O conjunto de dados contém 581 observações que consistem em preços médios diários de julho de 2015 a dezembro de 2017. Em comparação com conjuntos de dados como Sunspot e Lynx, o padrão de dados neste conjunto de dados também é altamente flutuante (ver Fig. 8). O resultado do teste

estacionário ADF do conjunto de dados mostra um valor de 0,27, que é altamente superior ao limiar de 0,05. A transformação natural do logarto-mic é aplicada no conjunto de dados para fins de dimensionamento.

Neste conjunto de dados, quando o ARIMA é usado individualmente como método de previsão, encontramos modelo autoregressivo da ordem 9 (AR(9)) para ser o mais parcimonioso entre todos os modelos ARIMA. O modelo ANN individual mais bem equipado é alcançado em três camadas $3 \times 6 \times 1$ arquitetura, após nosso processo de ajuste.

Neste conjunto de dados, o comprimento do filtro MA que usamos no método híbrido proposto sai como 6. O componente linear obtido após o filtro MA tem 0,004 resultado de teste estacionário ADF; isso implica que o componente pode ser devidamente modelado pelo método ARIMA em nossa arquitetura. A ANN mais bem encaixada na etapa final do método proposto tem $17 \times 17 \times 1$ arquitetura. A camada de entrada é composta pelos últimos 8

dados originais, os últimos 8 de resíduos e o resultado da previsão de componentes lineares.

Semelhante ao conjunto de dados Gbp/Usd, o conjunto de dados Intraday é altamente volátil e não estacionário que não pode ser efetivamente modelado usando apenas um modelo linear. Como pode ser visto na [Tabela 1](#), ANN e métodos híbridos superam significativamente o modelo linear individual de ARIMA. Além disso, o método proposto dá uma precisão notavelmente superior em comparação com outros métodos híbridos em todas as métricas de erro. A comparação dos valores reais e de previsão para todos os métodos examinados são dadas em [Fig. 9](#).

5. Discussão e melhoria

Existem vários resultados importantes obtidos em nossos experimentos. Em primeiro lugar, quando os resultados dos métodos individuais são comparados entre si, vemos que a ARIMA supera ANN para os conjuntos de dados que apresentar mais linearidade e vice-versa (ver [Tabela 1](#)). Além disso, os métodos híbridos têm melhor desempenho em comparação com os individuais, especialmente em conjuntos de dados mais flutuantes. Além disso, as suposições feitas por outros métodos híbridos degeneram o desempenho de previsão quando ocorrem situações inesperadas nos dados. Por exemplo, os métodos de Zhang e Babu-Reddy assumem que a relação

entre componentes lineares e não lineares é aditiva. Se os componentes lineares e não lineares não estiverem associados aditivamente e a relação for diferente (ou seja, pode ser multiplicativa), a possível relação complexa entre componentes podem ser negligenciados e o desempenho de previsão pode ser degenerado. Outra suposição que nem sempre é que os resíduos podem não mostrar propriedade padrão não linear. Além disso, os métodos de Zhang e Khashei-Bijari não atuam dados em componentes lineares e não lineares, mas assumem que o componente linear pode ser extraídos por ARIMA e sequências de erro mostram padrão não linear. Como resultado; tais suposições podem levar a baixos desempenhos de previsão quando cenários inesperados acontecem. Nosso método híbrido proposto evita fazer essas suposições e cria modelos mais gerais e supera os outros métodos examinados.

[Fig. 10](#) compara a distribuição dos resultados de MASE dos conjuntos de dados com os resultados dos testes ADF do conjunto de dados correspondente. Nesta figura, as tabelas são sorteadas utilizando-se valores de MASE de todas as metas examinadas para cada conjunto de dados, apresentados na [Tabela 1](#). Quando comparamos os resultados de erro entre os dados da série temporal usando um MASE métrico de erro invariante de escala, observa-se que quanto mais não-stationaridade em um conjunto de dados leva a um valor de erro mais alto. Por exemplo, o conjunto de dados Lynx, que acaba por ser o mais linear entre todos os conjuntos de dados de acordo com os resultados dos testes da ADF, tem os resultados de MASE mais baixos. Por outro lado, o conjunto de dados Gbp/Usd, que mostra a




Fig. 8. Preço da eletricidade do mercado intradiário na Turquia (Jul. 2015-Dez. 2017).

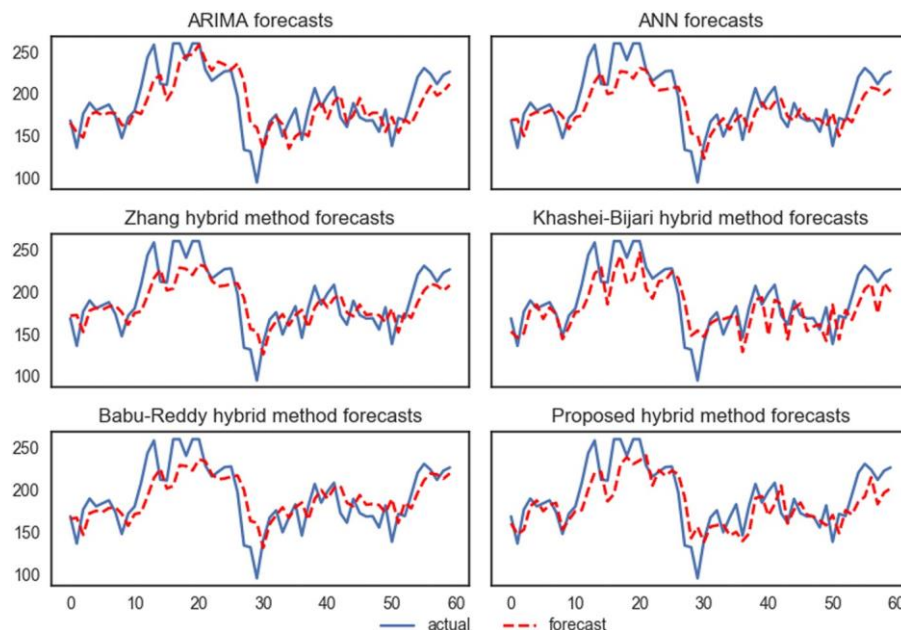


Fig. 9. Previsões de dados intradiários usando vários métodos.

maior não linearidade de acordo com os resultados dos testes da ADF, tem os maiores resultados de MASE. Como resultado disso, podemos concluir que ter uma distribuição de dados mais regular em uma série temporal leva a resultados mais precisos na previsão. Essa conclusão nos motiva a propor uma melhoria no nosso método híbrido já mais bem-apresentado. Este método aprimorado visa produzir subséries mais estacionárias a partir de determinadas séries temporais, usando uma técnica de decomposição em várias escalas. Em seguida, essas subséries lineares alcançadas podem ser modeladas com maior precisão usando o método híbrido proposto.




Fig. 10. Comparação da distribuição de MASE com os resultados dos testes ADF para todos os conjuntos de dados.

Na literatura existem vários métodos de decomposição em várias escalas, como Decomposição do Modo Empírico (EMD), Decomposição de Pacotes de Ondas (WPD), Fourier Transform (FT) e etc. [32]. Uma vez que o EMD não faz uma suposição priori sobre a determinada série temporal e preserva a escala de tempo dos dados ao longo da decomposição, é mais preferível técnica do que os outros para séries temporais em decomposição [24]. Além disso, mostra-se que a combinação de EMD e métodos híbridos tradicionais dão resultados promissores [25].

O princípio principal do EMD é decompor dados de uma determinada série temporal em uma soma de várias subséries. Essas subséries são chamadas de *Funções de Modo Intrínseco (IMFs)* e o componente restante após subtrair a soma dos IMFs dos dados originais é chamado de *resíduo*. Essas subséries têm duas propriedades importantes que permitem que sejam facilmente modeladas: cada subsérie tem sua própria escala de tempo característica local e são relativamente estacionárias subsérie. Que $y(t)$ seja um dado dados de série temporal e, em seguida, o cálculo EMD pode ser descrito da seguinte forma:

$$yIMF^{(t)} = \sum_{i=1}^n (t) + R_n(t) \quad (10)$$

onde $FMI_i(t)$ ($i = 1, 2, \dots, n$) representa as diferentes subséries, e $R_n(t)$ é o resíduo após a soma dos IMFs n serem subtraídos dos dados originais.

Os métodos baseados em EMD incluem três etapas principais, como visto na Fig. 11: Na primeira etapa, os dados originais da série temporal são decompostos em IMFs. Na segunda etapa, a previsão é realizada usando nosso método híbrido em cada FMI. Na última etapa, os resultados previstos de cada modelo individual são somados para alcançar a previsão final da série temporal original. Usamos uma função aditiva no final para capturar a relação aditiva dos IMFs com os dados originais.

Os métodos baseados em EMD são avaliados nos mesmos conjuntos de dados usando a configuração experimental em Fig. 11. Para avaliar o efeito do EMD, todos os métodos examinados são executados na segunda etapa do algoritmo (ver Fig. 11). A Tabela 3 fornece os resultados de previsão de todos os métodos examinados com EMD em quatro conjuntos de dados. Quando esses

resultados são comparados com os anteriores apresentados na Tabela 1, os métodos com EMD dão precisão significativamente maior. A melhoria percentual para todos os conjuntos de dados é apresentada na Tabela 5. As melhorias em cada conjunto de dados variam entre 23% e 89% para todas as métricas de erro. Também fornecemos um gráfico de barras (ver Fig. 12) que mostra os resultados do MASE para cada método que

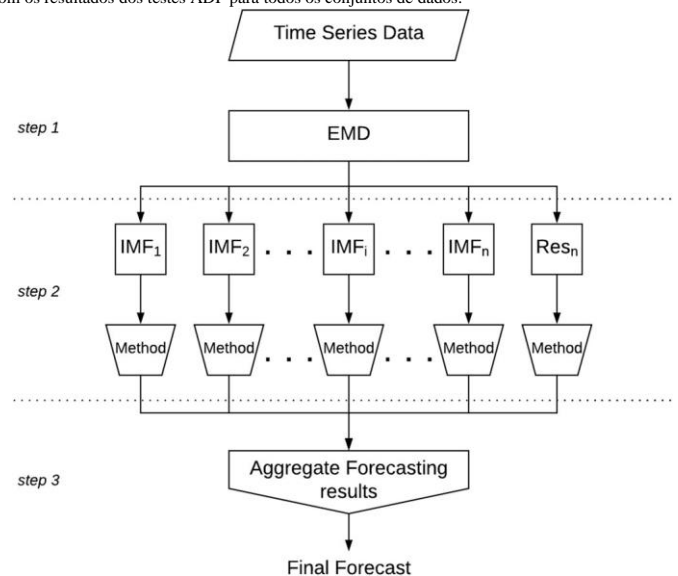


Fig. 11. A arquitetura híbrida usando EMD.

são mediados acima dos resultados de todos os conjuntos de dados. O gráfico indica que os métodos com EMD alcançam um erro notavelmente menor em suas previsões. Uma análise mais aprofundada mostra que os métodos baseados em EMD dão melhorias ainda maiores na precisão dos conjuntos de dados não estacionários. Isso se deve ao fato de que o EMD é capaz de resolver a não-estação e aliviar o problema de alta volatilidade nos dados da série temporal [25]. Por exemplo, enquanto nosso método híbrido com im EMD prova resultados de MASE de conjuntos de dados relativamente estacionários Sunspot e Lynx 30% e 28% respectivamente, essa melhoria salta 50% em conjuntos de dados Gbp/Usd e Intraday que são altamente não

estacionários (ver [Tabela 5](#)). Outra indicação da capacidade da EMD de resolver problemas de volatilidade é que o ARIMA é capaz de alcançar melhores resultados do que o ANN para todos os conjuntos de dados (ver [Tabela 5](#)), embora ANN sem o uso do EMD tenha sido melhor em conjuntos de dados não estacionários (ver [Tabela 1](#)).

As anlaysis *t*-test dos resultados experimentais relatados na [Tabela 3](#) são apresentadas na [Tabela 4](#) para todos os conjuntos de dados e métricas de erro. Como sugere a [Tabela 4](#), o método proposto usando EMD é estatisticamente significativo do que pelo menos três dos métodos examinados para todos os conjuntos de dados experimentados.

Tabela 3

Comparação de desempenho de métodos usando EMD para todos os conjuntos de dados.

Datasets	Métricas de métodos	ANN	ARIMA	Método de Zhang	Método K-B	Método de B-R	Método proposto
Mancha solar	MAE		7.72				
	MSE		99.07				
	MASE		0.341				
Lince	MAE		0.0772				
	MSE		0.0099				
	MASE		0.3822				
Gbp/Usd	MAE		146.03	7.76 ± 0.48	7.92 ± 0.52	7.28 ± 0.47	
				99.17 ± 11.5	100.64 ± 9.20	87.86 ± 9.11	
				0.343 ± 0.014	0.350 ± 0.023	0.322 ± 0.020	
				0.0782 ± 0.0043	0.0788 ± 0.0045	0.0760 ± 0.0035	
				0.0099 ± 0.0010	0.0101 ± 0.0008	0.0092 ± 0.0008	
				0.3872 ± 0.0213	0.3902 ± 0.0226	0.3763 ± 0.0176	
				146.11 ± 7.66	147.18 ± 9.87	141.38 ± 6.87	
				0.3581 ± 0.0319	0.3633 ± 0.0292	0.3285 ± 0.0280	
				0.3699 ± 0.0194	0.3726 ± 0.0250	0.3579 ± 0.0174	
				9.88 ± 1.03	10.05 ± 1.20	8.93 ± 1.04	
				162.55 ± 15.24	165.41 ± 16.33	130.79 ± 14.91	
				0.51 ± 0.05	0.52 ± 0.06	0.45 ± 0.05	
	MSE		0.3578				
	MASE		0.3697				
Intraday	MAE		10.79				
	MSE		158.64				
	MASE		0.56				

* o método de Khashei-Bijari é mostrado como método K-B. ** o método de Babu-Reddy é mostrado como método de B-R. *** os resultados do MAE e do MSE são multiplicados com 10^{-5} em Gbp/Usd dataset **** Os valores mostrados com ± dão os valores de desvio padrão.

Tabela 4 *p*-valor de comparação do resultado do teste do método proposto usando EMD.

Datasets	Métricas de métodos	ANN	Método de Zhang	Método de Khashei-Bijari	Método de Babu-Reddy
Mancha solar	MAE	0.001	0.016	0.001	0.001
	MSE	0.001	0.233	0.001	0.001
Lince	MAE	0.001	0.136	0.001	0.002
	MSE	0.001	0.001	0.001	0.001
Gbp/Usd	MAE	0.001	0.328	0.011	0.001
	MSE	0.001	0.004	0.003	0.001
Intraday	MAE	0.001	0.001	0.001	0.001
	MSE	0.001	0.001	0.001	0.001

Tabela 5

Melhoria percentual nos métodos quando o EMD é usado.

Datasets	Métricas de métodos	ANN (%)	ARIMA (%)	Método de Zhang (%)	Método de Khashei-Bijari (%)	Método de Babu-Reddy (%)	Método proposto (%)
Mancha solar	MAE	41.1	42.2	43.2	26.9	30.4	30.5
	MSE	65.9	67.7	68.8	51.6	58.0	54.7
	MASE	41.1	42.2	43.2	26.9	30.4	30.5
Lince	MAE	26.9	35.5	25.1	23.7	28.4	28.4

	MSE	45.6	57.1	42.7	43.4	46.5	43.2
	MASE	26.9	35.5	25.1	23.7	28.4	28.4
Gbp/Usd	MAE	55.6	66.4	62.3	64.0	66.2	65.0
	MSE	83.8	90.0	90.1	88.7	89.7	89.1
	MASE	55.6	66.4	62.3	64.0	66.2	65.0
Intraday	MAE	45.4	46.6	44.4	50.0	48.4	52.5
	MSE	70.3	75.6	73.2	72.9	73.3	77.5
	MASE	45.4	46.6	44.4	50.0	48.4	52.5

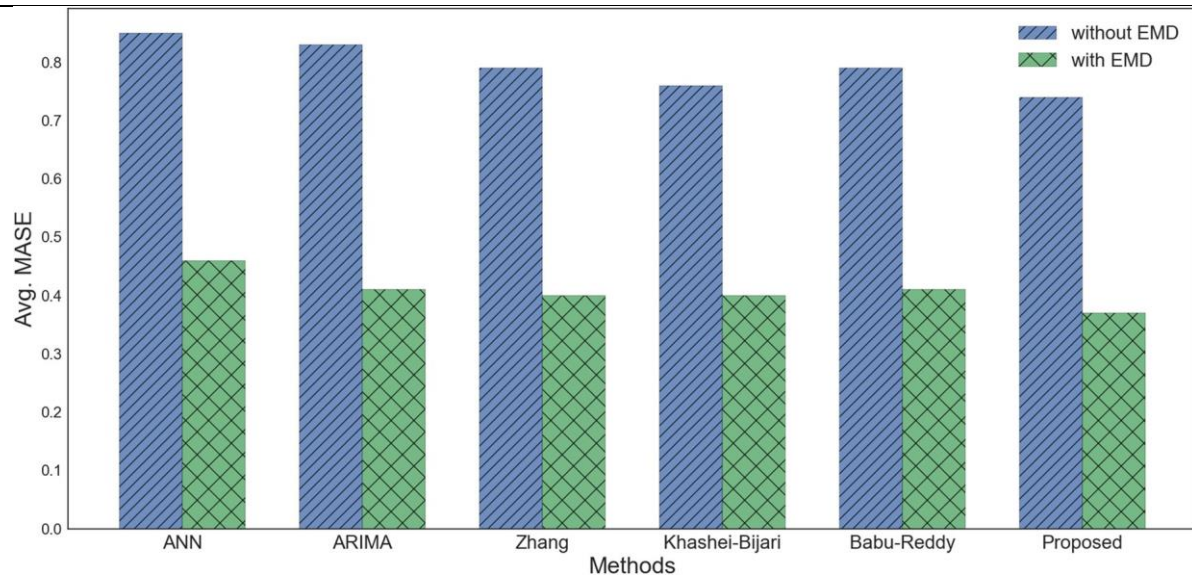


Fig. 12. Resultados médios de MASE dos métodos para todos os conjuntos de dados com/sem o uso de EMD.

Em final, queremos salientar que nosso método híbrido proposto com EMD dá os melhores resultados em comparação com outros dius (ver [Tabela 5](#)). As subséries obtidas do EMD são relativamente estacionárias em comparação com os dados originais, no entanto, elas ainda mostram flutuações em sua faixa de frequência. Realizar mais uma decomposição nestas subséries usando filtro MA e constituindo relação funcional entre a parte estacionária, os resíduos e os valores de dados originais supera todos os outros métodos restantes.

6. Conclusões

A previsão de séries temporais é uma tarefa importante, mas muitas vezes desafiadora, usada em muitos domínios de aplicativos diferentes. Os estudos na literatura focam principalmente em modelagens lineares ou não lineares individualmente ou em uma combinação delas. Embora modelos lineares como o ARIMA dê melhor precisão de previsão com dados de séries temporais estacionárias, métodos não lineares como ANN são mais apropriados para conjuntos de dados não estacionários. Para aproveitar a força única de cada tipo diferente de métodos em um ambiente mais geral, são propostos métodos híbridos. Os métodos híbridos basicamente utilizam modelagem linear e não linear, ARIMA e ANN, respectivamente, nos componentes decompimento correspondentes e, em seguida, combinam os resultados. Os métodos híbridos ARIMA-ANN dão melhores resultados em geral em comparação com os casos em que são utilizados individ- uly. No entanto, eles geralmente sofrem com as suposições que fazem durante a construção de seu modelo. Essas suposições

levam a produzir resultados inconsistentes e dar baixa precisão no geral se ocorrerem situações inesperadas.

Neste estudo, propõe-se um novo modelo híbrido ARIMA-ANN baseado em fundição para superar três premissas principais feitas pelos modelos tradicionais híbridos ARIMA-ANN. Firstly, o método pró-posed remove a suposição de que o componente linear é a saída do modelo ARIMA dos dados determinados. Em vez disso, extrai o componente linear usando filtro MA. Sabe-se que os dados que mostram características lineares podem ser modelados com mais precisão por métodos lineares. Portanto, dados devidamente decompostos produzem previsões lineares mais precisas e, consequentemente, resultados finais mais precisos nos métodos híbridos. Em segundo lugar, o método proposto não modela diretamente os resíduos através de um método não linear ANN, uma vez que a suposição de que os resíduos podem incluir padrões não lineares válidos, nem sempre segura. Em terceiro lugar, o método proposto não restringe a modelagem de componentes lineares e não lineares e também combina os resultados deles. Em vez disso, pode capturar estruturas dos componentes lineares e não lineares de uma maneira melhor, e produz modelos mais gerais do que os modelos híbridos existentes.

À luz de nossos resultados experimentais, podemos concluir que o desempenho de previsão fica melhor se mais dados de séries temporais forem fornecidos. Esse resultado nos motiva a tornar os dados originais da série temporal mais estacionários, a fim de melhorar os resultados de precisão. Mostramos que quando a decomposição de dados em várias escalas é combinada com todos os métodos examinados, os resultados de precisão podem ser notavelmente melhorados. Nossos resultados experimentais indicam que nosso método híbrido com EMD dá uma precisão notavelmente superior em comparação com todos os outros métodos examinados.

Como um trabalho futuro, outros métodos de análise de séries temporais podem ser aplicados a cada componente EMD como uma etapa de pré-processamento para escolher o método mais adequado para aplicar. Além disso, em vez de uma previsão de um passo à frente que visamos neste estudo, o método pró-posed poderia ser adotado e aprimorado para previsões de vários passos adiante.

Declaração de interesses

Nenhum.

Referências

- [1] J.C. Brocklebank, D.A. Dickey, B. Choi, SAS para Previsão de Séries Tempoas, 3º Ed., Instituto SAS, 2018.
- [2] J. Contreras, R. Espinola, F. Nogales, A. J. Conejo, modelos ARIMA para prever os preços da eletricidade no dia seguinte, IEEE Power Eng. Rev. 22 (2002) 57, doi: 10.1109/MPER.2002.4312577.
- [3] E. Gonzalez-Romera, M.A. Jaramillo-Moran, D. Carmona-Fernandez, Previsão mensal de demanda de energia elétrica com base na extração de trend, IEEE Trans. Power Syst. 21 (4) (2006) 1946-1953, doi: 10.1109/TPWRS.2006.883666.
- [4] K.P. Vishwajith, P.K. Sahu, B.S. Dhekale, P. Mishra, Modelagem e previsão de produção de cana-de-açúcar e açúcar na Índia, Indian J. O Econ. Dev. 12 (2016) 71, doi: 10.5958/2322-0430.2016.00009.3.
- [5] Wang, K.-w. Chau, D.-M. Xu, X.-Y. Chen, melhorando a precisão de previsão da série anual de tempo de escoamento usando ARIMA com base na decomposição EEMD, Water Resour. O Manag. 29 (2015) 2655-2675, doi: 10.1007/s11269-015-0962-6.
- [6] A. Lapedes, R. Farber, Processamento de sinal não linear usando redes neurais: predição e modelagem do sistema, in: Proceedings of the IEEE International Conference on Neural Networks, San Diego, 1987.
- [7] W.-S. Chen, Y.-K. Du, Usando redes neurais e técnicas de mineração de dados para o modelo de previsão de sofrimento financeiro, Expert Syst. Appl. 36 (2) (2009) 4075-4086, doi: 10.1016/j.eswa.2008.03.020.
- [8] D. Singhal, K.S. Swarup, previsão de preço de eletricidade usando rede neural artificial, Int. J. Electr. Power Energy Syst. 33 (3) (2011) 550-555, doi: 10.1016/j.ijepes.2010.12.009.
- [9] S.F. Ardabili, B. Najafi, S. Shamshirband, B.M. Bidgoli, R.C. Deo, K. asa Chau, abordagem de inteligência computacional para modelagem da produção de hidrogênio: uma re-visão, Eng. Appl. Computação. Mech fluído. 12 (1) (2018) 438-458.
- [10] B.R. Chang, H.F. Tsai, nova abordagem híbrida para a previsão de fluxo de pacotes de dados para melhorar a análise de tráfego de rede, Appl. Soft Comput. 9 (3) (2009) 1177-1183, doi: 10.1016/j.asoc.20.09.03.
- [11] G. Cybenko, Aproximação por superposições de uma função sigmoide, Matemática. Sinais de controle Syst. 5 (4) (1992) 455, doi: 10.1007/BF02134016.
- [12] Hornik, M. Stinchcombe, H. Redes de alimentação brancas e multicamadas são aproximadores universais, Neural Netw. 2 (5) (1989) 359-366, doi: 10.1016/0893-6080(89)90020-8.
- [13] P. Zhang, Série time previsão usando um modelo de trabalho híbrido ARIMA e rede neural, Neurocomputing 50 (2003) 159-175, doi: 10.1016/S0925-2312(01)00702-0.
- [14] W.R. Foster, F. Collopy, Ungar, Previsão de rede neural de séries temporais curtas e ruidosas, Computers & Chemical Engineering 16 (4) (1992) 293-297, doi: 10.1016/0098-1354(92)80049-F.
- [15] M.C. Brace, J. Schmidt, M. Hadlin, Comparison da precisão de previsão de redes neurais com outras técnicas estabelecidas, em: Proceedings of the First International Forum on Applications of Neural Networks to Sistemas de Energia, 1991, pp. 31-35, doi: 10.1109/ANN.1991.213493.
- [16] S. Aras, A.D. Kocako, Uma nova estratégia de seleção de modelos em séries temporais com redes neurais artificiais: IHTS, Neurocomputing 174 (2016) 974-987, doi: 10.1016/j.neucom.2015.10.036.
- [17] J.W. Denton, Quão boas são as redes neurais para previsão causal, The Journal of Business Forecasting Methods and Systems 14 (2) (1995) 17-20.
- [18] T.H. Hann, E. Steurer, muito burburinho sobre nada? previsão cambial: neu-ral redes vs. modelos lineares utilizando dados mensais e semanais, Neurocomputing 10 (4) (1996) 323-339, doi: 10.1016/0925-2312(95)00137-9.
- [19] J.L. Callen, C.C.Y. Kwan, P.C.Y. Yip, Y. Yuan, Previsão de rede neural de ganhos contábeis quar-terly, International Journal of Forecasting 12 (4) (1996) 475-482, doi: 10.1016/S0169-2070(96)00706-6.
- [20] R. Adhikari, R. K. Agrawal, uma combinação de rede neural artificial e modelos random walk para previsão de séries de tempo financeiro, Computação Neural e Aplicações Aceitas (2013), doi: 10.1007/s00521-013-1386-y.
- [21] D. Omer Faruk, uma rede neural híbrida e modelo ARIMA para previsão da série tempo quality of água, Aplicações de Engenharia de Inteligência Artificial 23 (4) (2010) 586-594, doi: 10.1016/j.engappai.2009.09.015.
- [22] Khashei, M. Bijari, Uma hibridização novel de redes neurais artificiais e modelos ARIMA para previsão de séries temporais, Appl. Soft Comput. 11 (2) (2011) 2664-2675, doi: 10.1016/j.asoc.2010.10.015.
- [23] C.N. Babu, B.E. Reddy, um modelo híbrido ARIMA-ANN baseado em filtro móvel para prever dados de séries temporentas, Appl. Soft Comput. 23 (2014) 27-38, doi: 10.1016/j.asoc.2014.05.028.
- [24] N.E. Huang, Z. Shen, S.R. Longo, M.C. Wu, H.H. Shih, Q. Zheng, N.-C. Yen, C.C. Tung, H.H. Liu, A decomposição do modo empírico e a especificação hilbert-trum para análise de séries tempomais e não estacionárias, Proceedings of the Royal Society of London A: Ciências Matemáticas, Físicas e De Engenharia 454 (1971) (1998) 903-995, doi: 10.1098/rspa.1998.0193.
- [25] U.C. Buyuksahin, S. Ertekin, Previsão da série time usando modo empírico de composição e método híbrido, 26ª Conferência de Processamento de Sinais e Aplicação de Comunicação (SIU), IEEE, maio de 2018, Izmir Turkey (2018).
- [26] J. Wang, W. Zhang, Y. Li, J. Wang, Z. Dang, Previsão da velocidade do vento usando decomposição do modo empírico e rede neural elman, Applied Soft Computing 23 (2014) 452-459, doi: 10.1016/j.asoc.2014.06.027.
- [27] Hibon, T. Evgeniou, Para combinar ou não combinar: selecionando entre moldes de fore e suas combinações. jornal internacional de previsão, Diário Interno de Previsão 21 (2005) 15-24.
- [28] T. Taskaya-Temizel, M.C. Casey, Um estudo comparativo de híbridos de rede neural autoregressiva, Redes Neurais: O Diário Oficial da Sociedade Internacional da Rede Neural 18 (5-6) (2005) 781-789, doi: 10.1016/j.neunet.2005.06.003.
- [29] EPIAS intradiário, (https://www.epias.com.tr/en/intra-day-market/introduction). 2018, (acessado 2018-05-14).
- [30] P. Baldi, A.D. Longo, Uma estrutura bayesiana para a análise de dados de microarray expression: regularizado t-test e inferências estatísticas de alterações genéticas, Bioinformática (Oxford, Inglaterra) 17 (6) (2001) 509-519.
- [31] Moosa, K. Burns, A caminhada aleatória imbatível na previsão cambial: realidade ou mito? Journal of Macroeconomics 40 (2014) 69-81, doi: 10.1016/j.jmacro.2014.03.003.
- [32] N.E. Huang, M.-L. Wu, W. Qu, S.R. Longo, S.S.P. Shen, Aplicações de hilbert huang transformam-se em análise de séries de tempo financeiro não estacionária, Modelos Estocásticos Aplicados em Negócios e Indústria 19 (3) (2003) 245-268, doi: 10.1002/asmb.501.



Ümit Çavuş s İ Büyük s İ ahin é recebido o B.Sc. in computer engenharia da Univer-sity Técnica do Oriente Médio (METU), Ancara, Turquia, em 2011 e possui o Mestre Europeu em Computação Distribuída pela KTH Royal Institute de Tecnologia em Estocolmo, Suécia e UPC, Universidade Poli-tecnica da Catalunha em Barcelona, Espanha. Ele continua o doutorado. estudos na METU. Ele está trabalhando como cientista de dados e foco em design, analy-sis e implementação de algoritmos de aprendizagem de máquina para resolver problemas de séries de tempo real, como renováveis previsão de produção de energia.

assistente em Depart-ment Middle East Tech-nical ingressar na METU, Massachusetts Institute of na MIT Sloan School of Ciência da Computação e longo de seu Ph.D. estudos, pesquisadora no Ma-chine Laboratories. Ela recebeu o Engenharia pela



Dr. S İ eyda Ertekin é professor de Engenharia da Computação na University (METU). Antes de trabalhou como pesquisadora no Technology (MIT) com nomeações Management e na Laboratório de Inteligência Artificial (CSAIL). Ao ela também trabalhou como Learning Group no NEC Research ph.D. em Ciência da Computação e Universidade Estadual da Pensilvânia, sua M.Sc na Uni-versity da Louisiana em Lafayette e seu B.Sc em Elétrica e Eletrônica Engenharia da METU. Sua pesquisa em...

os terests se concentram principalmente no design, análise e implementação de algoritmos e abordagens de aprendizagem de máquinas para análises de Big Data para resolver problemas do mundo real em vários domínios industriais como energia & energia, fabricação e saúde.