

Manuscrito Aceito

Previsão da Série tempo de consumo de energia usando aprendizado de máquina
Técnicas baseadas em Padrões de Uso de Moradores Residenciais

Jui-Sheng Chou, Duc-Son Tran

PII: S0360-5442(18)31914-5

DOIS: 10.1016/j.energy.2018.09.144

Referência: UM 13838


Para aparecer em: Energia

Data recebida: 15 de junho de 2018

Data aceita: 20 de setembro de 2018

Por favor, cite este artigo como: Jui-Sheng Chou, Duc-Son Tran, Forecasting Energy Consumption Time
Série utilizando Técnicas de Machine Learning baseadas em Padrões de Uso de Residências Residenciais,
Energia (2018), doi: 10.1016/j.energy.2018.09.144

Este é um arquivo PDF de um manuscrito não publicado que foi aceito para publicação. Como um serviço para nossos clientes estamos fornecendo esta versão inicial do manuscrito. O manuscrito passará por cópia, digitação e revisão da prova resultante antes de ser published em sua forma final. Observe que durante o processo de produção podem ser descobertos erros que podem afetar o conteúdo e todas as isenções legais que se aplicam ao diário.



Previsão da Série tempo de consumo de energia usando aprendizado de máquina

Técnicas baseadas em Padrões de Uso de Moradores Residenciais

Jui-Sheng Chou, P.E., Ph.D. ^{1,*}

Distinto Professor, Departamento de Engenharia Civil e Da Construção Civil

Universidade Nacional de Ciência e Tecnologia de Taiwan

43, Sec. 4, Keelung Rd., Taipei, 106, Taiwan

E-mail: jschou@mail.ntust.edu.tw

Telefone: +886-2-2737-6321

Fax: +886-2-2737-6606

** Autor correspondente*

Duc-Son Tran ²

² Assistente de Pós-Graduação em Pesquisa, Departamento de Engenharia Civil e De Construção

Universidade Nacional de Ciência e Tecnologia de Taiwan

43, Sec. 4, Keelung Rd., Taipei, 106, Taiwan

E-mail: son.neutron@gmail.com

Previsão da Série de Tempo de Consumo de Energia usando técnicas de aprendizagem de máquina baseadas em padrões de uso de moradores residenciais

ABSTRACT

O consumo de energia nas buildings está aumentando por causa do desenvolvimento social e da urbanização. Prever o consumo de energia em edifícios é essencial para melhorar a eficiência energética e desenvolvimento sustentável e, assim, redução dos custos de energia e impacto ambiental. Esta investigação apresenta uma revisão abrangente de técnicas de aprendizado de máquina para previsão de série temporal de consumo de energia usando dados reais. Dados em tempo real coletados de uma grade inteligente que foi instalado em um edifício experimental e usado para avaliar a eficácia e eficácia de técnicas estatísticas e de aprendizagem de máquina. Técnicas de inteligência artificial bem conhecidas foram usadas para analisar o consumo de energia em cenários individuais e conjuntos. Uma revisão aprofundada e a análise do "modelo híbrido" que combina técnicas de previsão e otimização é apresentada. A comparação abrangente demonstra que o modelo híbrido é mais preciso do que os modelos individuais e de conjunto. Tanto a precisão da previsão quanto a adequação para o uso destes modelos são considerados para apoiar os usuários no planejamento de gestão de energia.

Keywords: consumo de energia; edifícios residenciais; previsão de séries temporais previstas; previsão padrão; inteligência artificial; aprendizado de máquina.

1.Introdução

A taxa de desenvolvimento de países ao redor do mundo está crescendo tremendamente e é inevitável, levando a um aumento da demanda por energia. Além disso, a rápida expansão das áreas residenciais e comerciais contribui para o aumento do consumo de energia predial. A previsão do consumo de energia tornou-se crucial para estimar o uso de energia. Além de proporcionar benefícios ambientais, a eficiência energética predial pode proporcionar grandes benefícios econômicos. Edifícios com sistemas de energia eficientes e estratégias de gestão têm custos operacionais muito menores. Vários países aceleraram a implementação de regulamentos e códigos de energia para vários tipos de construção. Muitos pacotes de software de computador também foram desenvolvidos e estão sendo amplamente utilizados para projetar edifícios com eficiência energética.

Estima-se que o consumo global de energia aumente 53% de 505 trilhões de btu em 2008 para 700 quadrilhões de Btu em 2035 [1]. Vários países aceleraram a implementação de códigos de energia e regulamentos para vários tipos de edifícios. Essas regulamentações impõem requisitos básicos para garantir que os novos projetos de edifícios sejam eficientes em termos de energia, a que visam reduzir o consumo de energia e as emissões de CO₂ relacionadas [2]. Estudos revelam que a eficiência energética de uso final pode reduzir significativamente o consumo total de energia global [3, 4]. Mesmo pequenas mudanças no pico de demanda podem gerar grandes economias tanto para os consumidores quanto para os serviços públicos [5]. Portanto, melhorar a eficiência energética dos edifícios é necessário para diminuir o impacto ambiental e controlar a influência dos custos de energia.

Para otimizar o desempenho energético dos edifícios, devem ser aplicadas estratégias operacionais adequadas aos sistemas de gestão de energia. Os gestores devem monitorar e

gerenciar continuamente a série temporal de energia, juntamente com fatores que influenciam o desempenho energético de seus edifícios. A previsão é parte do monitoramento contínuo e gestão do consumo de energia. Prever com precisão o consumo de energia é fundamental para melhorar a energia predial



eficiência [6]. Como um modelo de previsão de séries tempoescos aprende com os padrões anteriores de consumo de energia, um consumo de energia ligeiramente superior ao previsto durante um período pode fazer com que os gerentes de instalações e sistemas de energia sejam notificados da mudança.

Nas últimas duas décadas, várias técnicas de previsão têm sido utilizadas para prever o consumo de energia de edifícios [7-14]; eles se enquadram em três categorias, que são métodos de engenharia, métodos estatísticos e métodos de inteligência artificial. Destes, os mais amplamente implementados são os métodos de inteligência artificial (IA), que incluem Redes Neurais Artificiais (ANNs) [9, 15], o Classificação e Regressão (CART) [16], a Máquina vetorial de suporte (SVM) [7], a Regressão Linear (LR) [17], a média móvel integrada autoregressiva (ARIMA) [9, 18-21], e os métodos de média móvel integrada autoregressiva (SARIMA) sazonalmente .. A não linearidade e a volatilidade do uso de energia em tempo real criam as dificuldades na previsão do consumo de energia em edifícios residenciais.

Revisões recentes da previsão de energia fornecem detalhes dos modelos de previsão existentes e sua classificação. Chirag *et al.* (2017) compilou os resultados de pesquisadores anteriores [23]. Eles analisaram as nove técnicas de previsão mais populares que são baseadas na plataforma de machine learning. Zhao e Magoules (2012) revisaram modelos recentemente desenvolvidos para prever o consumo de energia, incluindo métodos estatísticos complicados e simplificados, métodos de engenharia e métodos de inteligência artificial [2]. No entanto, as avaliações anteriores são baseadas em resultados de pesquisa anteriores, mas não no mesmo banco de dados. Portanto, as avaliações dos modelos não possuem padrões de comparação. Esta investigação apresenta, portanto, uma revisão abrangente e análise da previsão de séries

temporidades utilizando técnicas de aprendizado de máquina baseadas no padrão de consumo de energia em um edifício residencial.

Para preencher a lacuna de pesquisa acima mencionada, o presente estudo apresenta uma revisão abrangente da previsão de consumo de energia utilizando técnicas de aprendizado de máquina, com base no padrão de consumo de energia em um edifício residencial. O objetivo é facilitar a eficiente previsão de um dia de antecedência do consumo de energia para usuários finais e gestores em edifícios residenciais. Previsões de um dia podem ser aplicadas para aumentar a produtividade do uso de energia controlando equipamentos elétricos em edifícios. A consumação de energia é prevista usando técnicas básicas de IA - ANNs, SVR, CART, LR e SARIMA - usando duas plataformas de análise de dados (RapidMiner Studio e IBM SPSS Modeler). Além disso, dois modelos de conjunto, que são gerados pela combinação dessas técnicas de IA, utilizam métodos de ensacamento de votação. Dois modelos metaheurísticos híbridos de IA são usados com três componentes metaheurísticos que são integrados com o ARIMA.

Os objetivos desta pesquisa são os seguintes.

- Para fornecer uma revisão exaustiva e abrangente das técnicas para a série de tempo de previsão de carga de curto prazo de consumo de energia para edifícios.
- Implantar modelos de previsão de consumo de energia único, conjunto e híbrido.
- Tanto a precisão da previsão quanto a adequação ao uso são considerados para avaliar até que ponto os modelos apresentados apoiam os usuários no planejamento da gestão de energia.

O resto deste trabalho é organizado da seguinte forma. A Seção 2 revisa a literatura sobre métodos de previsão de séries temporais, métodos ML, métodos híbridos e revisões existentes de métodos para prever o consumo de energia de edifícios. A Seção 3 descreve métodos que atualmente são usados para prever o consumo de energia. A seção 4 elucida o conjunto de dados

de consumo de energia e os parâmetros que são inseridos nos modelos de IA. A Seção 5 compara o desempenho dos modelos implementados. Finalmente, a Seção 6 tira conclusões e oferece sugestões para usuários finais de edifícios e gerentes de energia.

2.Revisão de Literatura

2.1. Consumption de energia em edifícios

O rápido aumento do uso de energia em todo o mundo já levantou preocupações sobre o esgotamento dos recursos energéticos, o excesso de capacidades de abastecimento e os graves impactos ambientais (aquecimento global, esgotamento da camada de ozônio, change climático e outros) [24]. O tamanho e a localização de um edifício residencial são fatores-chave para determinar seu consumo de energia. A quantidade de energia que é utilizada em edifícios residenciais está relacionada principalmente ao clima, projeto arquitetônico, systems energéticos e renda dos moradores. O uso de energia no ambiente construído crescerá 34% nos próximos 20 anos, a uma taxa média de 1,5% ao ano. Em 2030, as moradias consumirão 67% de toda a energia e o setor não doméstico consumirá 33% [24]. A consumpção energética representa uma grande fração do gasto total de consumo da sociedade.

Recentemente, os sistemas de gerenciamento de energia de construção têm visto um rápido desenvolvimento e os usuários finais foram, portanto, habilitados a usar eletricidade em seus edifícios de forma mais eficaz [25-35]. Por exemplo, Agheno *et al.* (2014) apresentou um estudo de caso das performances energéticas e ambientais de um sistema de controle de iluminação em escritórios [25]. Eles avaliaram os resultados de dez escritórios em Torino (Itália) relativos à economia potencial de energia (de 17% para 32%), levando em conta tanto o consumo anual de energia elétrica monitorado quanto o consumo de energia parasitária. Zhou *et al.* (2014) propôs um método de controle do consumo de energia em tempo real para residências no Reino Unido [27]. Seus resultados de simulização indicaram que a abordagem de controle proposta pode

otimizar o cronograma de uso de eletrodomésticos e comportamentos de carga/descarga de bateria, mesmo que as informações previstas sejam imprecisas.

Além disso, Valor *et al.* (2001) analisou o relacionamento entre a carga elétrica predial e a temperatura diária ao ar livre na Espanha, usando um índice de temperatura ponderado pela população [36]. O estudo indicou que a sensibilidade da carga elétrica à temperatura diária ao ar livre aumentou ao longo do tempo, em um grau de higher para o verão do que para o inverno, embora a sensibilidade na estação fria seja sempre mais significativa do que na estação quente. A associação entre dados de eletricidade e temperatura externa define as funções de demanda de aquecimento e resfriamento, que mostram coeficientes de correlação de 0,79 e 0,87, e previsão de carga elétrica com erros padrão de estimativa de 4% e 2%, respectivamente.

A otimização de energia em edifícios tem sido amplamente investigada na última década. Inúmeras investigações têm sido realizadas para abordar a eficiência energética dos edifícios [29, 37-39] e vários projetos de pesquisa foram realizados para identificar os edifícios de melhor desempenho no que diz respeito à eficiência energética. Monfet *et al.* (2014) apresentou uma nova abordagem para prever a demanda energética de edifícios comerciais usando raciocínio baseado em casos. Seu método pode ser usado para prever a demanda de energia e pode ser implementado em sistemas de operação de construção [29].

Costa *et al.* (2012) apresentou a metodologia de fatores-chave para apoiar os gestores da energia na determinação da estratégia ideal de operação predial no que diz respeito tanto ao consumo de energia quanto ao conforto térmico [40]. Chou e Ngo (2016) apresentaram uma estrutura para análise de big data em rede inteligente e os componentes necessários de um sistema de suporte à decisão que salvaguarda a energia [41]. Esses estudos têm se concentrado no

desenvolvimento de plataformas e métodos de previsão para aumentar a eficiência e a confiabilidade dos sistemas de gestão de energia.

2.2. AI técnicas para prever o consumo de energia em série temporal

A análise do consumption energético envolve métodos para análise de dados de séries temporais para extrair estatísticas significativas e outras características dos dados. A previsão da série temporal é o uso de um modelo para prever valores futuros com base em valores previamente observados [42]. Uma série temporal é uma sequência ordenada de valores que são registrados em intervalos iguais de tempo. A análise de uma série temporal compreende duas partes [23]. Na primeira parte, a estrutura e o padrão subjacente dos dados observados são obtidos. Na segunda parte, um modelo é instalado nos dados para suportar previsões futuras. A análise de séries temporais é usada em vários campos, incluindo estatísticas, previsão de energia, processamento de sinais, reconhecimento de padrões, econometria, previsão meteorológica, previsão de terremotos, astronomia e em qualquer domínio da ciência aplicada e engenharia que envolva medições temporais.

A análise da série temporal é amplamente utilizada para prever o consumo de energia, uma vez que os edifícios estão sendo cada vez mais monitorados em tempo real. Esse monitoramento pode fornecer dados históricos que podem ser utilizados para análise crítica e na previsão do consumo de energia de edifícios. Muitas investigações examinaram o desempenho energético dos edifícios [43-51]. Vários modelos de séries temporais foram desenvolvidos para prever o consumo de energia em edifícios [52-58]. Este estudo considera algumas das técnicas de previsão de séries temporais mais populares que podem ser aplicadas ao consumo de energia de edifícios.

Redes Neurais Artificiais são tipicamente técnicas de modelagem que são baseadas em uma coleção de unidades conectadas ou nós, chamados neurônios artificiais. Os modelos de ANNs têm sido amplamente utilizados para prever o consumo de energia de edifícios [59, 60]. Adya e

Collopy (1998) revisaram a eficácia das ANNs na previsão [61]. Ekici e Aksoy (2009) propuseram um modelo para prever os requisitos energéticos dos edifícios, e sua relação com a orientação de um edifício, espessura de isolamento e razão de transparência, utilizando ANNs [53]. Os resultados da simulação revelaram que a ANN fornece resultados satisfatórios com desvio de 3,43% e previsão de precisão de 94,8 a 98,5%. Hamzacebi (2007) desenvolveu modelos usando ANNs para prever o consumo líquido de eletricidade na Turquia [62]. Os resultados demonstraram que a técnica ANN dá resultados better do que a técnica Modelo de Análise da Demanda Energética (MAED).

As máquinas vetoriais de suporte são usadas em muitas tarefas de aprendizado de máquina, como reconhecimento de padrões, classificação de objetos e previsão de séries temporidades, incluindo especialmente a previsão de consumo de energia. Dong *et al.* (2005) aplicou a SVM para prever o consumo de energia de edifícios em uma região tropical [63]. Eles coletaram contas médias mensais de serviços públicos para desenvolver e testar modelos. Suas previsões tinham coeficientes de variância de less superior a 3% e um erro percentual inferior a 4%. Bozic *et al.* (2010) propôs uma máquina vetorial de suporte de pelo menos quadrados (LSSVM) para previsão de carga de curto prazo [64]. Eles usaram uma semana de dados por hora para fazer previsões de carga horária e diária. Os resultados renderam valores percentuais absolutos entre 0,93% e 3,04% para as previsões diárias.

Modelos de Regressão Linear (LR) têm sido usados para prever o consumo de energia dos edifícios devido à sua facilidade de uso. Catalina *et al.* (2008) desenvolveu models de regressão para prever a demanda mensal de aquecimento no setor residencial unifamiliar em climas temperados, a serem utilizados por arquitetos ou engenheiros de design na fase inicial de seus projetos para encontrar soluções eficientemente energéticas em relação à energia performática

[65]. Hygh *et al.* (2012) apresentou um novo método de modelagem que utilizou um modelo de regressão multivariada para quantificar o desempenho energético dos edifícios em seus estágios iniciais de projeto [66]. A facilidade de uso é considerada a principal vantagem do método LR, pois nenhum parâmetro foi ajustado. No entanto, o método LR tem uma limitação maior, que é sua inaplicabilidade a problemas não lineares [67].

Os modelos autoregressivos da Média Móvel Integrada (ARIMA) são ferramentas estatísticas eficazes e fornecem o trabalho mais geral para técnicas de previsão de séries temporais [18, 19, 21, 22, 68]. Tais modelos são amplamente utilizados modelos lineares de séries temporais univariadas. Newsham e Birt (2010) propuseram um modelo ARIMA com entrada eXternal (ARIMAX) para prever a demanda de energia por um edifício de escritórios [69]. Eles usaram dados de ocupação como um preditor externo para melhorar o modelo. Chujai *et al.* (2013) apresentaram modelos ARIMA e ARMA para análise de séries temporais de dados de consumo elétrico doméstico [18]. Seus resultados revelaram que o modelo ARIMA foi o melhor modelo para encontrar o período de previsão mais adequado. Mohamed *et al.* (2011) realizou previsão de carga de curto prazo usando um modelo ARIMA sazonal duplo [70] e dados de demanda de carga de meia hora para a Malásia ao longo de um ano. O MAPE estimado foi de 0,99%.

Modelos de conjunto combinam metaheuristicamente as saídas de muitos modelos AI-based individuais gerados, de tal forma que a combinação supera cada um dos modelos únicos [71-74]. Técnicas de conjunto para prever séries temporais são indispensáveis para muitas aplicações de mineração de dados práticas [75]. Soares *et al.* (2018) descreveu uma variação do método inteligente baseado em nuvem de dados conhecido como o método baseado em tipicidade e excentricidade para análise de dados (TEDA), que usa modelos de conjunto [76]. Eles

desenvolveram um ensemble de modelos de nuvem e fuzzy, bem como operadores de agregação para dar previsões de séries temporestrais de valor único e granular. O conjunto forneceu a melhor precisão geral com um em cada quatro conjuntos de dados, e o TEDA forneceu as melhores previsões com os conjuntos de dados de remainagem.

Modelos híbridos lineares e não lineares foram desenvolvidos recentemente para a previsão de dados de séries temporais, e especialmente para o consumo de energia em edifícios [77-80]. Tan *et al.* (2010) propôs um novo método de previsão de preços que combinava a transformação de ondas com arima e os modelos de heteroesquecidade condicional autoregressiva generalizada (GARCH) [20]. Eles avaliaram a precisão do método híbrido proposto, que capturou as características complexas dos preços da eletricidade. Chou e Ngo (2016) desenvolveram um novo sistema de aprendizado de máquina baseado em otimização metaheurística de janela para prever o consumo de energia para edifícios em tempo real, coletado usando uma grade inteligente [6]. Seu sistema de previsão teve alta e confiável precisão na realização de pré-idades de 1 dia de antecedência do consumo de energia em um edifício, com uma taxa de erro total de 1,181% e um erro absoluto médio de 0,026 kWh.

Azadeh *et al.* (2010) apresentou uma regressão difusa integrada e uma estrutura de séries temporândias para estimar e prever mudanças estacionárias e mensais no consumo de eletricidade, especialmente países em desenvolvimento, como China e Irã, utilizando dados não estacionários [49]. Seus resultados indicam que o algoritmo proposto é superior a outros modelos e algoritmos disponíveis. Lee e Tong (2012) descreveram uma nova abordagem dinâmica híbrida que combina um modelo cinza dinâmico com programação genética para prever o consumo de energia [78]. Eles o usaram para prever o consumo de energia devido à sua excelente precisão,

aplicabilidade aos casos de conjuntos de dados limitados e facilidade de computação usando software matemático.

Esta seção também resume os artigos de revisão que se concentram na previsão baseada em IA do consumo de energia em edifícios [43, 46, 67, 81-83]. Para cada artigo de revisão, o objetivo do estudo, as técnicas de previsão de séries temporais revisadas e os modelos comparados, são todos fornecidos. Martínez-Álvarez *et al.* (2015) apresentou um levantamento das técnicas de mineração de dados utilizadas na previsão de séries temporais de eletricidade [72]. Eles concluíram que a mineração de dados supera as técnicas clássicas. Deb *et al.* (2017) revisou abrangentemente as técnicas de aprendizado de máquina para prever séries temporais de consumo de energia [23]. Eles analisaram as nove técnicas de previsão mais populares que são baseadas na plataforma de machine learning. Eles também forneceram uma revisão aprofundada e análise de "modelos híbridos" que combinam pelo menos duas técnicas de previsão.

Zhao e Magoulès (2012) revisaram modelos recentemente desenvolvidos para prever o consumo de energia de edifícios, diluindo métodos de engenharia elaborados e simplificados, métodos estatísticos e métodos de inteligência artificial [2]. Eles se concentraram na aplicação desses modelos a novos problemas de previsão, otimizando os parâmetros do modelo ou amostras de entrada para melhorar o desempenho e comparando modelos sob determinadas condições. Raza e Khosravi (2015) forneceram uma revisão abrangente e sistemática da literatura de técnicas de previsão de carga de curto prazo baseadas em inteligência artificial para redes inteligentes e edifícios [84]. O principal objetivo de sua investigação foi revisar, identificar, avaliar e analisar o desempenho dos modelos de previsão de carga baseados em IA e identificar lacunas na pesquisa relevante.

Ahmad *et al.* (2014) revisou métodos baseados em IA, como os métodos SVM and ANN, para prever o consumo de energia elétrica de edifícios [7]. Combinar modelos pode melhorar o desempenho de previsão. Eles afirmaram que um modelo híbrido de método de grupo de manipulação de dados (GMDH) e LSSVM tem grande potencial para previsões em séries temporais em diversos campos, como estoque, consumo de energia, entre outros. Wang e Srinivasan (2017) [67] realizaram uma revisão aprofundada de métodos únicos baseados em IA, como MLR, ANNs e SVR, e métodos de previsão de conjuntos que combinam modelos de predição baseados em IA para melhorar a precisão preditiva por um grande fator. Eles elaboraram os princípios, aplicações, vantagens e limitações dos métodos de previsão baseados em IA e discutiram o futuro da pesquisa sobre métodos baseados em IA para prever o uso de energia de edifícios.

Amasyali e El-Gohary (2018) [85] revisaram trabalhos sobre o desenvolvimento de modelos baseados em dados para prever o consumo de energia de edifícios, com foco no escopo da previsão, nos métodos de pré-processamento dos dados e nas propriedades dos dados, algoritmos ML que são utilizados para previsões e métricas de desempenho. Revisões recentes da previsão do consumo de energia fornecem detalhes das técnicas de séries temporentas, modelos de previsão e sua classificação. Os trabalhos acima mencionados são baseados nos resultados de estudos anteriores, mas estes não são baseados no mesmo banco de dados. Portanto, não existe base para comparação e verificação. Este estudo realiza uma revisão abrangente da previsão de séries temporâneas utilizando técnicas de aprendizado de máquina que se baseiam em um padrão de consumo de energia em um edifício residencial.

3. Metodologia

Modelos de previsão baseados em 3.1.AI

Um método típico de previsão baseado em IA consiste em quatro etapas principais, que são coleta de dados, pré-processamento de dados, treinamento de modelos, teste de modelo de anúncio [67]. Muitos algoritmos de aprendizagem baseados em IA e modelos de previsão com essas etapas são usados para prever o consumo de energia de edifícios. Os modelos de previsão baseados em IA podem ser classificados em três categorias, que são single, ensemble e hybrid com base em seus componentes de previsão. Modelos de predição simples usam um algoritmo de aprendizagem; os modelos de conjunto compreendem múltiplos modelos de predição, que são integrados de forma a determinar os dados de saída. Modelos híbridos combinam duas ou mais técnicas de aprendizagem de máquinas. Esses modelos são mais robustos do que os outros, pois frequentemente exibem as vantagens das técnicas incorporadas e proporcionam uma melhor precisão de previsão. A Figura 1 mostra a estrutura geral das técnicas de previsão de séries temporais. As seguintes subseções introduzem essas três principais categorias de modelo.

<<Figure 1>>

3.1.1. Modelos únicos

Neste estudo, os métodos de previsão única incluem todas as técnicas de previsão disponíveis baseadas em IA.

Tais métodos podem ser categorizados em vários tipos pelos fenômenos que são usados para prever. Esta investigação se concentra em técnicas de ML que são usadas para prever o consumo de energia em edifícios. Alguns modelos populares são apresentados para proporcionar uma ampla compreensão dos modelos preditivos únicos; estes incluem ANNs, C&R TREE, SVR e LR. A Figura 2 apresenta a estrutura geral dos modelos de previsão única.

<<Figure 2>>

Redes Neurais Artificiais

Redes neurais artificiais são os modelos de IA mais utilizados; eles simulam a capacidade dos neurônios cerebrais para processar informações. O uso de ANNs para resolver problemas de previsão recentemente atraiu considerável atenção da pesquisa, pois eles superaram substancialmente técnicas implementadas anteriormente para previsão baseadas em variáveis de entrada não lineares [15, 47, 48, 53, 84]. A função da sinapse, que é a estrutura responsável por armazenar informações no cérebro, é modelada como articulações entre unidades neurais que estão localizadas em camadas adjacentes, cada uma com um peso modificável.

Um modelo de previsão de carga baseado em ANN é desenvolvido usando uma rede neural multicamadas com um algoritmo de aprendizagem de propagação de costas adequadamente modificado. O treinamento é feito de forma supervisionada que é para cada vetor de entrada, a saída desejada é dada e os pesos são adaptados para minimizar uma função de erro que mede a discrepância entre a saída desejada e a saída real calculada pela rede.

Máquina vetorial de suporte para classificação e regressão

A abordagem de Máquina vetorial de suporte (SVM), desenvolvida pela Vapnik em 1995 [86], baseia-se na teoria da aprendizagem estatística e no princípio da minimização de riscos estruturais. O Vetor de Suporte para Regressão (SVR) é uma conversão do SVM que é usado para resolver problemas de regressão não linear. Para problemas de regressão não linear, os dados são transformados usando uma função de kernel não linear que mapeia as entradas para um espaço de características de alta dimensão. Assim, o desempenho geral do modelo de regressão SVM depende da seleção satisfatória dos parâmetros do kernel [23]. O conceito básico de SVM para aproximação da função é mapear os dados em um espaço de características de alta dimensão por um mapeamento do kernel não linear e, em seguida, realizar uma regressão linear no espaço de características.

Árvore de Classificação e Regressão

Breiman *et al.* (1984) cunhou o termo "Classificação e Regressão de Árvores (CARTs)" para se referir a algoritmos de árvore de decisão que podem ser usados para problemas de modelagem de classificação ou regressão [87]. O algoritmo CART fornece uma base para algoritmos importantes, como árvore de decisão ensacada, floresta aleatória e algoritmos de árvore de decisão impulsionados. A representação de um modelo CART é uma árvore binária. Cada nó raiz representa uma única variável de entrada e um ponto dividido no *that* (que se supõe ser numérico). Cada um dos nódulos de folha da árvore contém uma variável de saída, que é usada para fazer previsões.

Regressão Linear

A regressão linear (LR) foi desenvolvida para modelar a relação entre uma variável dependente escalar e uma ou mais variáveis independentes. Esta investigação utilizou a técnica de regressão linear multivariada (MLR), que é uma das múltiplas versões dos modelos LR. Devido à sua facilidade de uso, os modelos MLR têm sido amplamente utilizados para prever as cargas de energia dos buildings. Este estudo aplica a propriedade estatística de quadrados mínimos comuns (OLS) ao modelo de regressão da série temporal linear, exigindo a especificação das propriedades dos dados e o termo de erro. Vários importantes resultados de amostra assintótica e finita são apresentados e esses resultados são comparados com as propriedades estatísticas da regressão da série temporal.

Média móvel integrada automática

Os modelos autoregressivos da Média Móvel Integrada (ARIMA) são, em teoria, a classe mais geral de modelos para prever uma série de dados temporestos. Eles são baseados na transformação de uma série temporal em uma série estacionária por um processo diferente. Uma variável aleatória que é uma série temporal está parada se suas propriedades estatísticas são todas

constantes sobre time. Portanto, a equação ARIMA para uma série temporal é uma equação linear na qual os preditores compreendem atrasos da variável dependente e do erro de previsão.

O problema com o uso de erros defasados como preditores é que as previsões do modelo não são funções lineares dos coeficientes, embora sejam funções lineares de dados passados. Assim, os coeficientes em modelos ARIMA que incluem erros defasados devem ser estimados por métodos de otimização não lineares, em vez de apenas resolver um sistema de equações. O modelo de média móvel integrada (SARIMA) é uma extensão simples do modelo ARIMA. Como mencionado, os modelos SARIMA são amplamente aplicados para prever dados sazonais de séries temporais devido à sua eficácia na previsão linear.

3.1.2. Modelos de Conjunto

Os métodos de conjunto ganharam atenção substancial das comunidades de aprendizado de máquina e computação suave nos últimos anos. Os métodos de aprendizagem de conjuntos são amplamente utilizados hoje em dia devido à sua previsão favorável de performance preditiva [73-76, 88]. O aprendizado do conjunto combina múltiplas previsões feitas usando múltiplos métodos para obter melhor precisão do que a simples previsão e evitar possíveis excessos. Sua combinação supera cada modelo em casos de linha de base. Portanto, os seguintes métodos de conjunto são utilizados aqui para obter saídas previstas melhoradas. A Figura 3 apresenta a estrutura dos modelos de conjunto.

<<Figure 3>>

Votação

A votação é o método de conjunto mais simples porque é fácil de entender e implementar [89]. O voto é um meio de metaclassificação para combinar classificadores conceitualmente semelhantes ou diferentes de aprendizagem de máquina através do voto majoritário ou pluralidade. Neste estudo, utilizou-se o método de votação para gerar 11 conjuntos de duas, três ou quatro

técnicas. Os conjuntos de duas tecnologias foram ANNs+CART, ANNs+SVR, ANNs+LR, CART+SVR, CART+LR e SVR+LR. Os três conjuntos técnicos foram ANNs+CART+SVR, ANNs+CART+LR, CART+SVR+LR e ANNs+SVR+LR. O conjunto de quatro técnicas foi ANNs+CART+SVR+LR.

Ensacamento

Ensacar é um simples método de conjunto muito poderoso. Ensacar aplica o procedimento Bootstrap a um algoritmo de aprendizagem de máquina de alta variância, que normalmente envolve árvores de decisão. No método de ensacamento, bootstrapping é realizado para treinar vários modelos de forma independente e with diferentes conjuntos de treinamento. O único parâmetro no ensacamento das árvores de decisão é o número de amostras. Esse número pode ser definido aumentando o número de árvores a cada corrida até que a precisão pare de melhorar significativamente. Um número muito grande de modelos pode ganhar muito tempo para se preparar, mas não vai se encaixar demais nos dados de treinamento. Este trabalho desenvolve quatro modelos de conjunto de ensacamento de uniformidade utilizando técnicas de aprendizagem; eles são um conjunto SVR, um conjunto ANN, um conjunto CART, e um conjunto LR.

3.1.3. Modelos Híbridos

Modelos híbridos combinam técnicas de aprendizado de máquina com algoritmos de otimização. Eles são mais poderosos do que modelos únicos, pois comumente incorporam as vantagens e compensam as fraquezas das técnicas individuais envolvidas, melhorando a precisão da forragem. Modelos híbridos podem ser criados com uma ou mais fases, correspondendo a diferentes metas de resolução de problemas. As seções a seguir discutem métodos híbridos e apresentam dois modelos híbridos representativos para prever o consumo de energia.

Models de uma fase

Os sistemas híbridos tornaram-se essenciais para a inteligência computacional e a computação suave, pois podem lidar com componentes complexos. O modelo híbrido mais simples é a simulação em fase única. Um grande número de modelos em fase única foram desenvolvidos para análise da série time nos últimos anos [20, 90, 91]. Na fase de treinamento, duas ou mais técnicas de aprendizado de máquina são combinadas, como no modelo ARIMA-GARCH. As técnicas combinadas funcionam juntas para resolver todos os problemas preditivos. Em alguns casos, esses modelos combinados estão associados a um algoritmo de otimização para gerar um modelo de previsão afinado, como o modelo PSO-ANN. A Figura 4 exibe a estrutura geral de modelos híbridos de uma fase para a previsão de séries temporais.

<<Figure 4>>

Modelos de várias fases

Modelos de aprendizagem em várias fases têm sido mostrados teoricamente e empiricamente para superar modelos de fase única, especialmente para problemas de regressão e classificação de alta dimensão, complexos. Inúmeras aplicações acadêmicas e industriais de modelos de múltiplas fases foram desenvolvidas [6, 9, 22, 23, 92]. Modelos de várias fases consistem em dois ou mais componentes, cada um dos quais implementa várias técnicas de aprendizado de máquina. Cada componente funciona independentemente dos outros para resolver um problema específico. Por exemplo, o modelo híbrido SARIMA-ANN tem um componente SARIMA que resolve dados de padrão linear e um componente ANN que resolve dados de padrões não lineares. Modelos combinados serão associados a um algoritmo de otimização para gerar um modelo de pré-disseção afinado. A Figura 5 mostra a estrutura geral dos modelos híbridos de múltiplas fases.

<<Figure 5>>

Modelos Híbridos Propostos

Como mencionado acima, modelos híbridos de muitos tipos existem para prever séries temporais. Este trabalho apresenta dois modelos metaheurísticos de otimização de aprendizagem de máquina para prever o consumo de energia de um edifício. Eles são um modelo SARIMA-PSO-LSSVR e um modelo SARIMAMetaFA-LSSVR. Estes modelos são modelos de predição híbrida de várias fases que possuem dois componentes – modeling linear univariado e modelagem não linear multivariada – no processo de treinamento. Chou e Ngo (2016) [6] desenvolveram um modelo de aprendizado de máquina baseado em otimização metaheurística, SARIMA-MetaFA-LSSVR, para fazer previsões de um dia antes do consumo de energia de um edifício. Este modelo superou de destaque modelos individuais como SARIMA, LSSVR e modelos híbridos, como MetaFA-LSSVR, na previsão do consumo de energia versus. Esta investigação desenvolve o SARIMA-PSO-LSSVR e compara seu desempenho com o de SARIMA-MetaFA-LSSVR e os outros modelos.

Os modelos SARIMA são amplamente utilizados para prever dados sazonais de séries temporais devido à sua eficácia na previsão do componente linear dos dados. No entanto, sua maior limitação é sua suposição de que os valores da série temporal estão linearmente correlacionados [6]. Portanto, o modelo SARIMA não pode elucidar adequadamente padrões não lineares em uma estrutura de dados complexa, como a dos dados de consumo de energia. A combinação do modelo SARIMA com outros modelos de previsão não linear elimina essa limitação. Nos modelos híbridos propostos, as saídas do modelo LINEAR SARIMA univariado na fase 1 fazem parte das entradas de modelos não lineares multivariados que aplicam aprendizado de máquina baseado em otimização metaheurística, como o de MetaFA-LSSVR e PSOLSSVR, na fase 2.

O modelo SVR é uma técnica de ML que se baseia na teoria da aprendizagem estatística. Suykens *et al.* (2002) apresentou o método LSSVR para melhorar a velocidade computacional do modelo SVR [93]. Embora o modelo LSSVR resolva efetivamente problemas de previsão, sua precisão depende de seus hiperparâmetros, e especialmente dos parâmetros constantes de regularização e kernel. Para melhorar a precisão preditiva do modelo, a otimização automática integrada ao LSSVR deve envolver o parâmetro de regularização (C) e o sigma do kernel RBF (σ). Detalhes do LSSVR podem ser encontrados em outros lugares [6].

A otimização do enxame de partículas (PSO) é uma técnica de otimização estocástica de base populacional que foi desenvolvida por Kennedy e Eberhart em 1995 [94], inspirada no comportamento de forrageamento social de alguns animais, incluindo o rebanho de aves e a escolaridade dos peixes. O algoritmo PSO envolve uma coleção de partículas que se movem em torno de um espaço de busca, afetado por sua própria melhor localização passada e a melhor localização passada de qualquer partícula no enxame ou um vizinho próximo. Em cada iteração, a velocidade de cada partícula é atualizada.

O algoritmo PSO no modelo proposto – SARIMA-PSO-LSSVR usa um mapa caótico de tendas. O mapa da tenda fornece uma população inicial altamente diversa devido à sua sensibilidade às condições iniciais. O mapa da tenda é linear, tornando o mapa da tenda mais fácil de analisar do que o mapa logístico. No entanto, embora a forma do mapa da tenda seja simples e as equações sejam lineares, para certos valores de parâmetros, o mapa pode produzir comportamentos complexos e caóticos. Além de ser sensível às condições iniciais, o mapa da tenda também depende do seu valor de parâmetro, segundo o qual apresenta comportamentos previsíveis a caóticos. Este mapa da tenda pode ser combinado com PSO para criar um algoritmo de otimização substancial. A Figura 6 mostra o fluxograma do algoritmo metaheurístico PSO.

<<Figure 6>>

O algoritmo metaheurístico firefly (MetaFA) é um algoritmo de otimização que foi desenvolvido por Chou e Ngo em 2016 [6]. O MetaFA tem três componentes metaheurísticos, que são mapas caóticos, os voos Adaptive Inércia Weight (AIW) e Lévy. A FA convencional é combinada com esses componentes para melhorar seus recursos de pesquisa e otimização. Um mapa caótico logístico é usado para gerar uma população inicial altamente diversificada no estágio inicial do MetaFA. Em seguida, um mapa caótico Gauss/mouse é usado para redefinir os parâmetros aleatórios que são usados na FA convencional. Para determinar a convergência, a AIW é ajustada dinamicamente no processo de otimização para controlar as capacidades de exploração locais e globais da FA. Finalmente, os voos da Lévy são usados para acelerar a busca local, gerando novos bairros ideais:

em torno da solução ideal derivada. Os detalhes do MetaFA são fornecidos em outros lugares [6].

3.2. Software de Machine Learning

Esta investigação avalia tanto a precisão preditiva dos modelos quanto sua capacidade de atender às demandas dos praticantes. Portanto, é necessário software que forneça uma interface fácil de usar e um aplicativo preditivo poderoso. Para obter previsões precisas dos modelos, os pacotes de mineração de dados comumente usados RapidMiner Studio, IBM SPSS Modeler, IBM SPSS

Estatística e WEKA são usados para fácil aprendizado de máquina. O modelo híbrido foi desenvolvido no MATLAB, que tem poder comprovado para análise rápida e processamento de dados devido à biblioteca de funções, caixas de ferramentas e flexibilidade.

3.3. Avaliação de desempenho

Medidas de R, RMSE, MAE, MAPE, MaxAE e SI foram utilizadas para avaliar as medidas preditivas precisão dos modelos propostos; Eqs. (6) a (10) são as respectivas fórmulas.

$$\frac{n \sum (e - e')^2}{\sqrt{n \sum e^2} \sqrt{n \sum e'^2}}$$

onde e' é o valor previsto ; e é o valor real, e n é o número de amostras de dados.

$$\frac{1}{n} \sum_{i=1}^n \left| \frac{e - e'}{e} \right|$$

$$\frac{1}{n} \sum_{i=1}^n |e - e'|$$

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (e' - e)^2}$$

$$\text{MexEE} = \max(|e - e'|)$$

$$\frac{1}{m} \sum_{i=1}^m \left(\frac{P_i - P_{m,h,1}}{P_{mex,1} - P_{m,h,1}} \right)$$

onde m é o número de medidas de desempenho, e $P_i = T^{és}$ medida de desempenho. A gama de Si é de 0 a 1; um valor SI próximo a 0 indica um modelo preditivo extremamente preciso.

$$R = \frac{1}{n} \sum_{i=1}^n \left(\frac{P_i - P_{m,h,1}}{P_{mex,1} - P_{m,h,1}} \right) \quad (1)$$

$$\text{MAP} = \frac{1}{n} \sum_{i=1}^n \left(\frac{P_i - P_{m,h,1}}{P_{mex,1} - P_{m,h,1}} \right) \quad (2)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |e - e'| \quad (3)$$

RMSE □ (4)

(5)

SIM □ (6)

4. Consumo de energia de edifícios e desenvolvimento do modelo do mesmo

4.1. Descrição dos dados

Foram utilizados dados de consumo de energia em tempo real de uma rede de rede inteligente instalada em um prédio típico de três andares no distrito de Xindian, Cidade de Nova Taipei, Taiwan. Os dados foram utilizados para avaliar a aplicabilidade dos modelos preditivos propostos na previsão de padrões de consumo de energia em edifícios. O prédio residencial de interesse foi ocupado por uma família de cinco (três filhos e seus pais). O prédio tinha uma área total de 350 m². Detalhes do layout do prédio e dos aparelhos e equipamentos elétricos do prédio podem ser encontrados em outros lugares [6].

Os dados de consumo de energia foram convertidos a partir de dados com intervalos de 1min em dados com intervalos de 15 minutos, executando um procedimento de conversão no MySQL, com base na demanda real de informações de eletricidade das companhias de eletricidade. Consequentemente, foram obtidos 96 pontos de dados para o consumo de energia predial com intervalos de 15 minutos por dia. A base de dados incluiu informações sobre quatro variáveis que afetam diretamente o consumo total de energia no prédio; são temperatura ao ar livre (°C), dia da semana (segunda, terça, quarta, quinta, sexta, sábado e domingo), e hora do dia (0, 1, 2,... (23). Os tempos em que esses valores também foram registrados.

Foram coletados sete conjuntos de dados, correspondentes aos dias da semana. Este artigo apresenta modelos de previsão de carga de curto prazo usando técnicas de IA. Com base em uma sugestão de Chou e Telaga (2014) [57], os dados de aprendizagem utilizados neste estudo foram

coletados dentro de uma janela deslizante de quatro semanas e os dados para o dia seguinte ao aprendizado foram os utilizados para testes. Por exemplo, os primeiros dados de aprendizagem foram de 23 de junho a 20 de julho e os dados de teste correspondentes foram referentes a 21 de julho. Os detalhes da coleta e pré-processamento de dados são fornecidos em outros lugares [6].

4.2. Desenvolvimento de modelos

Modelos Únicos

O software RapidMiner Studio fornece interfaces fáceis de usar para o desenvolvimento de técnicas de IA em todos os modelos únicos mencionados, mas eles têm vários campos de parâmetros com diferentes

Configurações. Para uma operação eficiente e facilidade de uso, os settings padrão dos principais parâmetros foram usados em cada modelo no pacote de software. A Tabela 1 mostra as configurações abrangentes destes modelos individuais no RapidMiner Studio. O SPSS Modeler fornece um modelo SARIMA para prever dados de séries. A tabela 2 reconhece as configurações padrão do modelo único no SPSS Modeler.

<<Tabela 1>

<<Tabela 2>

O RapidMiner Studio e o SPSS Modeler permitem que os usuários ajustem a estrutura de um único modelo manualmente usando módulos integrados na plataforma. As figuras 7 e 8 exibem a implementação dos procedimentos para modelos únicos no RapidMiner Studio e IBM SPSS Modelador.

<<Figura 7>

<<Figura 8>

Como no cenário de modo único, um usuário pode construir fluxos analíticos de conjunto organizando e personalização dos módulos de técnicas de IA. O melhor software para implementar o single cenário foi o RapidMiner Studio, que é, portanto, utilizado para aumentar a precisão preditiva no cenário do conjunto. No RapidMiner Studio, os modelos de conjunto de votação e ensacamento foram implementados. As figuras 9 e 10 apresentam streams de conjuntos no RapidMiner Studio.

<<Figura 9>

<<Figura 10>

Modelos de Conjunto

Modelos Híbridos

Estudos anteriores demonstraram que um modelo híbrido que exibe habilidades de modelagem linear e não linear é adequado para prever o consumo de energia. Os modelos SARIMA e LSSVR podem resolver componentes lineares e não lineares nos dados, respectivamente. Desde que os modelos híbridos propostos combinem os pontos fortes de todos os modelos constituintes, eles podem efetivamente capturar padrões de dados de séries temporais. Os modelos propostos (SARIMA-PSO-LSSVR, SARIMAMetaFA-LSSVR) possuem duas etapas; estágio 1 envolve modelagem linear univariada e estágio 2

envolve modelagem não linear multivariada. Os modelos híbridos metaheurísticos otimizados aqui foram implementado no software MATLAB. Detalhes do desenvolvimento do modelo de previsão foram fornecidos em outros [6]. As tabelas 3 e 4 fornecem as configurações dos parâmetros para os modelos de previsão propostos. A Figura 11 mostra os processos pelos quais os modelos híbridos propostos são construídos.

<<Tabela 3>

<<Tabela 4>

<<Figura 11>

Resultados experimentais e discussão

5.1. Desempenho em cenário único

Na primeira etapa do processo analítico, modelos únicos foram implementados utilizando dois pacotes de software - RapidMiner Studio e IBM SPSS Modeler. Suas medidas de desempenho são usado para comparar esses modelos únicos em termos de R, RMSE, MAE, MAPE, MaxAE e SI. Tabelas 5 e 6 apresentam o desempenho de modelos únicos no SPSS Modeler e RapidMiner Studio,

<<Tabela 5>

<<Tabela 6>

O desempenho de previsão do modelo único no SPSS Modeler foi comparado com aqueles de modelos únicos no RapidMiner Studio. Tabelas 5 e 6 confirmam que o modelo DES em RapidMiner Studio é o modelo único mais eficaz para fazer previsões de using os dados. Ela

5.

respectivamen

te.

produziram os menores valores da RMSE (0,092), MAE (0,057) e MAPE (36,834%); o segundo menor valor do MaxAE (0,353) e o maior valor R (0,556).

5.2. Desempenho no Cenário do Conjunto

A Tabela 7 apresenta as medidas performáticas dos modelos de conjunto no RapidMiner Studio. O conjunto de ensacamento ANN alcançou os melhores resultados entre os quatro modelos conjuntos no RapidMiner Studio, com os melhores valores de todas as medidas de avaliação - RMSE (0,094), MAE (0,049), MAPE (42,31%), MaxAE (0,338) e R (0,607). Com relação à votação, o melhor desempenho foi obtido utilizando o modelo de conjunto baseado em ANNs+LR, que rendeu os melhores valores de R, RMSE, MAE, MAPE e MaxAE (0,512, 0,164, 0,104, 42,75% e 0,564, respectivamente).

<<Table 7>>

5.3. Desempenho em Cenário Híbrido

Para demonstrar a eficácia e a confiabilidade dos modelos híbridos propostos SARIMAMetaFA-LSSVR e SARIMA-PSO-LSSVR no MATLAB, seus desempenhos preditivos foram comparados como mostrado na Tabela 8. O model híbrido SARIMA-MetaFA-LSSVR obteve melhores resultados do que o modelo híbrido SARIMA-PSO-LSSVR, com os melhores valores de todas as medidas de avaliação - R (0,796), RMSE (0,164), MAE (0,028), MAPE (15,657%) e MaxAE (0,179). O

O modelo SARIMA-PSO-LSSVR teve um tempo de CPU mais curto (0,729s).

<<Table 8>>

5.4. Comparação e Discussão Abrangentes

Esta investigação identificou o melhor dos modelos único, conjunto e híbrido com dados em diferentes intervalos. Com dados de 15 minutos intervalados, o melhor modelo único de IA foi ANNs no RapidMiner Studio, enquanto o melhor modelo de conjunto foi o modelo de ensacado baseado em ANN, cuja precisão foi 9% melhor que a do modelo único no mesmo pacote de software. O modelo híbrido mais eficaz foi o SARIMA-MetaFA-LSSVR, cuja precisão foi 64% melhor que a do modelo único. A Tabela 9 compara de forma abrangente esses modelos.

<<Table 9>>

Nos estudos existentes sobre os modelos de conjunto para previsão de energia em edifícios e instalações, por exemplo, Jovanović *et al.* (2015) apresentou o conjunto de várias redes neurais para previsão de aquecimento do consumo de energia em uma universidade [95]. Alcançaram altos resultados com dados diários para analisar o aquecimento do consumo de energia. No entanto, isso é difícil de superar de perto o consumo de energia em uma escala diária. Com base nos resultados analíticos, este estudo sugere que os dados de intervalos de 15 minutos são bastante adequados para prever o consumo de energia em edifícios residenciais.

Candanedo *et al.* (2017) apresentou modelos de previsão de dados para o uso de energia de aparelhos em uma casa de baixa energia [96]. O melhor modelo - modelo de conjunto de máquinas de aumento de gradiente (GBM) foi capaz de explicar 57% da variância (R^2) e atingir 38,29% do MAPE no processo de teste ao usar todos os preditores. Em comparação com seu trabalho, este estudo alcança melhores resultados do que o modelo GBM com R^2 (63,4%) e MAPE (15,657%) no processo de teste.

Da mesma forma, Wang *et al.* (2018) aplicou o modelo de ensacamento de árvores de conjunto (EBT) para prever a consumação energética de um anfiteatro em uma universidade [97]. Em comparação com o modelo convencional de previsão única (ou seja, CART), eles concluíram que o modelo de conjunto homogêneo (ou seja, EBT) é superior na precisão da previsão, enquanto requer mais tempo de computação e é uma variedade de interpretabilidade devido à sua estrutura de modelo sofisticada.

Os modelos híbridos são geralmente mais precisos do que os modelos single e ensemble. Os modelos únicos são os mais fáceis de usar porque podem ser implementados em pacotes de software que integram técnicas de IA. Os usuários só têm que selecionar modelos e parâmetros usando as interfaces nos pacotes de software, que estão aqui no RapidMiner Studio e no IBM SPSS Modeler. No entanto, sua precisão e eficiência são muito baixas. Portanto, modelos únicos são a escolha para usuários que primeiro usam um modelo de IA para resolver o problema do consumo de energia.

Usuários que conhecem o básico das técnicas de aprendizado de máquina devem ser capazes de usar modelos mais eficazes do que modelos individuais. Os modelos de conjunto são favoráveis porque têm um desempenho satisfatório na análise de séries temporáticas. Para construir modelos de conjunto, os usuários devem conhecer seus procedimentos associados e combinar os pontos

fortes dos modelos constituintes. Alguns modelos de conjunto são integrados em pacotes de software, cujos usuários podem implementá-los tão facilmente quanto implementar modelos únicos. Um modelo de conjunto é uma combinação de modelos únicos que compensa os erros cometidos usando os modelos individuais, de modo que eles superam em casos de linha de base.

A eficácia e eficiência dos modelos híbridos propostos demonstraram a análise dos dados de consumo de energia em tempo real. Os modelos SARIMA-MetaFA-LSSVR propostos e SARIMA-PSOLSSVR foram altamente precisos e confiáveis na realização de previsões de um dia antes do consumo de energia na construção de juro. Esses modelos são mais poderosos do que modelos individuais e conjuntos porque normalmente incorporam as vantagens e compensam as fraquezas dos modelos constituintes individuais, e melhoram a precisão de previsão otimizando algoritmos.

No entanto, os modelos híbridos propostos são construídos em plataformas (MATLAB) que não são fáceis de usar.

Portanto, seus usuários são obrigados a ter um profundo conhecimento das técnicas de aprendizado de máquina.

6. Conclusão e Recomendação

A gestão da energia é essencial para reduzir o consumo de energia dos edifícios. A importância da economia de energia deriva da necessidade global de reduzir o gasto energético e os impactos ambientais e da legislação pertinente. Este trabalho apresenta uma revisão abrangente e análise de várias técnicas de previsão de séries temporais para prever o consumo de energia de edifícios com um único de antecedência. Recentemente, muitos experimentos têm sido realizados utilizando essas técnicas, que têm sido e utilizadas com dados sobre o consumo de energia de edifícios. Cada uma das técnicas aqui mencionadas tem vantagens e desvantagens. Este estudo

analisa as vantagens e desvantagens de cada método de previsão e fornece sugestões sobre seu uso efetivo.

As técnicas de IA utilizadas neste estudo são técnicas únicas, de conjunto e híbridas para prever o consumo de energia de edifícios. Especificamente, cinco técnicas de IA (ou seja, ANNs, SVR, CART, LR e SARIMA) foram aplicadas em modelos únicos, enquanto suas combinações foram usadas para gerar dois modelos de conjunto, envolvendo votação e ensacamento. O

modelos propostos (SARIMA-MetaFA-LSSVR e SARIMA-PSO-LSSVR) foram ambos

implementados como componentes de modelos híbridos. Uma comparação abrangente demonstrou que o modelo híbrido é mais preciso do que modelos individuais e conjuntos. Tanto a precisão da predição quanto sua usabilidade no planejamento da gestão de energia são consideradas.

Quatro plataformas analíticas - RapidMiner Studio, IBM SPSS Modeler, IBM SPSS Statistics e WEKA - foram usados para implementar os modelos individuais de IA. Com dados em intervalos de 15 minutos, o modelo único de AI best foi ANNs no RapidMiner Studio, enquanto o melhor modelo de conjunto foi o modelo de ensacamento annbado no mesmo pacote de software. O modelo híbrido mais eficaz foi SARIMA-MetaFA-LSSVR no MATLAB. Os modelos conjunto e híbrido foram 2,7% e 72% mais preciso do que o melhor modelo único, respectivamente.

A novidade deste estudo é a sua disposição de uma abordagem abrangente para o uso de modelos de IA para o consumo de energia de curto prazo que prevê o consumo de energia em edifícios. Esta pesquisa se concentra em encontrar o modelo eficaz most para vários usuários que têm que desenvolver modelos preditivos rapidamente. Os resultados desta pesquisa revelam que os modelos únicos são a melhor escolha para os usuários que primeiro usariam o modelo de IA na

previsão do consumo de energia de edifícios. Modelos ensemble são melhores para usuários que conhecem o básico das técnicas de aprendizado de máquina. Usar que tenham um profundo conhecimento das técnicas de IA e exijam modelos altamente precisos e eficazes devem usar modelos híbridos baseados em IA.

Esta investigação fornece uma revisão abrangente da previsão de energia usando técnicas de IA e alguns modelos típicos. Os usuários podem explorar este estudo para melhorar a eficiência energética de aparelhos e equipamentos elétricos em seus edifícios. Este estudo envolveu uma análise preditiva utilizando quatro variáveis que foram coletados da infraestrutura de rede inteligente em um edifício selecionado. A influência de fatores como umidade, intensidade de radiação solar e tempos de eventos climáticos extremos não foram consideradas na previsão do consumo energético do edifício aqui. Um novo estudo deve ser realizado para coletar tais dados potenciais para melhorar o desempenho preditivo. Estudos futuros, desenvolverão uma plataforma de previsão inteligente com autoanálise abrangente e visualizações de insights useful.

Referências

- [1] AIE. Panorama executivo da Perspectiva Mundial da Energia 2011: Agência Internacional de Energia, 2011.
- [2] Zhao H-x, Magoulès F. Uma revisão sobre a previsão de construção do consumo de energia. *Revisões de Energia Renovável e Sustentável*. 2012;16(6):3586-92.
- [3] Lee YM, An L, Liu F, Horesh R, Chae YT, Zhang R. Aplicando ciência e matemática a big data para edifícios mais inteligentes. *Anais da Academia de Ciências de Nova York*. 2013;1295(1):18-25.
- [4] Reinisch C, Kofler M, Iglesias F, Kastner W. ThinkHome Energy Efficiency in Future Smart Homes. *Jornal EURASIP sobre Sistemas Embarcados*. 2011;2011(1):104617.
- [5] Spees K, Lave L. Impacts of Responsive Load in PJM - Load Shifting e Real Time Pricing. *O Jornal da Energia*. 2008;29:101-22.
- [6] Chou J-S, Ngo N-T. Analíticos da série temporal usando otimização metaheurística de janela deslizante baseou sistema de aprendizado de máquina para identificar padrões de consumo de energia de construção. *Energia Aplicada*. 2016;177:751-70.
- [7] Ahmad AS, Hassan MY, Abdullah MP, Rahman HA, Hussin F, Abdullah H, et al. Uma revisão sobre as aplicações da ANN e da SVM para a construção de previsão de consumo de energia elétrica. *Revisões de Energia Renovável e Sustentável*. 2014;33:102-9.
- [8] Biswas MAR, Robinson MD, Fumo N. Previsão do consumo de energia de edifícios residenciais: uma abordagem de rede neural. *Energia*. 2016;117:84-92.

- [9] Khandelwal I, Adhikari R, Verma G. Time Series Forecasting Using Hybrid ARIMA e ANN Models Based on DWT Decomposition. *Procedia Ciência da Computação*. 2015;48:173-9.
- [10] Zhang W, Liu S, Li N, Xie H, Li X. Previsão de desenvolvimento e análise de roteiro de tecnologia de energia renovável em edifícios na China. *Revisões de Energia Renovável e Sustentável*. 2015;49:395-402.
- [11] Lim Y-D, Kim S-C, Park J-O, Choo Y-G. Uma demanda preditiva da energia elétrica máxima usando o caos. *A 10ª Conferência Internacional do IEEE: Fuzzy Systems*; 2001. p. 1511-4.
- [12] Lü X, Lu T, Kibert CJ, Viljanen M. Modelagem e previsão de consumação de energia para edifícios heterogêneos usando uma abordagem físico-estatística. *Energia Aplicada*. 2015;144:261-75. [13] Monfet, Arkhipova, Choiniere. Avaliação de uma ferramenta de previsão de energia baseada em casos para edifícios comerciais. Os procedimentos da 13ª conferência internacional reforçam a construção de oper. Montreal, Quebec, Canadá 2013. p. 1-7.
- [14] Mousavi A, Vyatkin V. Energy Efficient Agent Function Block: Uma abordagem semântica de agente para blocos de funções IEC 61499 em sistemas de automação predial eficientes em energia. *Automação em Construction*. 2015;54:127-42.
- [15] Kandanand K. Previsão de Demanda de Eletricidade na Tailândia com uma Abordagem de Rede Neural Artificial. *Energias*. 2011;4(12):1246-57.
- [16] Hu Y, Peng L, Li X, Yao X, Lin H, Chi T. Uma nova árvore de evolução para analisar a estrutura global de consumo de energia. *Energia*. 2018;147:1177-87.
- [17] Yip S-C, Wong K, Hew W-P, Gan M-T, Phan RCW, Tan S-W. Detecção de roubo de energia e medidores inteligentes defeituosos em redes inteligentes usando regressão linear. *International Journal of Electric Power & Energy Systems*. 2017;91:230-40.
- [18] Chujai P, Kerdprasop N, Kerdprasop K. Time Series Análise do Consumo Elétrico Doméstico com Modelos ARIMA e ARMA. *Multiconferência Internacional de Engenheiros e Cientistas da Computação*. Hong Kong: IMECS 2013; 2013.
- [19] Khashei M, Bijari M. Uma nova hibridização de redes neurais artificiais e modelos ARIMA para previsão de séries temporais. *Aplicou a Computação Suave*. 2011;11(2):2664-75.
- [20] Tan Z, Zhang J, Wang J, Xu J. Day-ahead preço de eletricidade prevendo usando wavelet transform combinado com modelos ARIMA e GARCH. *Energia Aplicada*. 2010;87(11):3606-10.
- [21] Gp de Zhang. Previsão de séries temporais usando um modelo híbrido de ARIMA e rede neural. *Neurocomus*. 2003;50:159-75.
- [22] Chen K-Y, Wang C-H. Um SARIMA híbrido e máquinas vetoriais de suporte na previsão dos valores de produção da indústria de máquinas em Taiwan. *Sistemas especializados com Aplicações*. 2007;32(1):254-64.
- [23] Deb C, Zhang F, Yang J, Lee SE, Shah KW. Uma revisão sobre técnicas de previsão de séries temporais para a construção do consumo de energia. *Revisões Energy renováveis e sustentáveis*. 2017;74:902-24.
- [24] Pérez-Lombard L, Ortiz J, Pout C. Uma revisão sobre informações sobre consumo de energia em edifícios. *Energia e Edifícios*. 2008;40(3):394-8.
- [25] Aghemo C, Blaso L, Pellegrino A. Sistemas de automação e controle predial: Estudo de caso para avaliar o desempenho energético e ambiental de um sistema de controle de iluminação nos escritórios. *Automação em Construção*. 2014;43:10-22.

- [26] Corry E, Pauwels P, Hu S, Keane M, O'Donnell J. Uma ontologia de avaliação de desempenho para o manejo ambiental e energético dos buildings. *Automação em Construção*. 2015;57:249-59.
- [27] Zhou S, Wu Z, Li J, Zhang X-p. Abordagem de controle de energia em tempo real para o sistema inteligente de gerenciamento de energia doméstica. *Componentes e Sistemas de Energia Elétrica*. 2014;42(3-4):315-26.
- [28] Lee Y-S, Tong L-I. A previsão do consumo de energia usando um modelo cinza melhorou incorporando a programação genética. *Conversão e Gestão de Energia*. 2011;52(1):147-52. [29] Monfet D, Corsi M, Choinière D, Arkhipova E. Desenvolvimento de uma ferramenta de previsão de energia para edifícios comerciais usando raciocínio baseado em barril. *Energia e Edifícios*. 2014;81:152-60.
- [30] Allouhi A, El Fouih Y, Kousksou T, Jamil A, Zeraouli Y, Mourad Y. Consumo de energia e eficiência em edifícios: status atual e tendências futuras. *Journal of Cleaner Production*. 2015;109:118-30.
- [31] Faria P, Vale Z. Resposta à demanda no fornecimento de energia elétrica: Uma abordagem ideal de preços em tempo real. *Energia*. 2011;36(8):5374-84.
- [32] Guo JJ, Wu JY, Wang RZ. Uma nova abordagem para a previsão de consumo de energia do aquecedor de água da bomba de calor doméstico com base no sistema cinza theory. *Energia e Edifícios*. 2011;43(6):1273-9. [33] Hsu D. Comparação de métodos integrados de clustering para previsão precisa e estável de dados de consumo de energia de construção. *Energia Aplicada*. 2015;160:153-63.
- [34] Radulovic F, Poveda-Villalón M, Vila-Suero D, Rodríguez-Doncel V, García-Castro R, Gómez-Pérez A. Diretrizes para geração e publicação de dados vinculados: Um exemplo na construção do consumo de energia. *Automação em Construção*. 2015;57:178-87.
- [35] Sandels C, Widén J, Nordström L, Andersson E. Previsões antecipadas de consumo de eletricidade em um edifício de escritórios sueco a partir de dados meteorológicos, de ocupação e temporais. *Energia e Edifícios*. 2015;108:279-90.
- [36] Valor E, Meneu V, Caselles V. Temperatura diária do Ar e Carga Elétrica na Espanha. *Meteorologia aplicada*. 2001;40(8):1413-2.
- [37] Yang J, Santamouris M, Lee SE, Deb C. Desenvolvimento do modelo de desempenho energético e identificação do número de ocupação de edifícios institucionais. *Energia e Edifícios*. 2016;123:192204.
- [38] Mat Daut MA, Hassan MY, Abdullah H, Rahman HA, Abdullah MP, Hussin F. Construindo análises de previsão de consumo de energia elétrica usando métodos convencionais e de inteligência artificial: Uma revisão. *Revisões de Energia Renovável e Sustentável*. 2017;70:1108-18.
- [39] Fumo N, Rafe Biswas MA. Análise de regressão para previsão de consumo de energia residencial. *Revisões de Energia Renovável e Sustentável*. 2015;47:332-43.
- [40] Costa A, Keane MM, Raftery P, O'Donnell J. Key factors methodology — Um novo apoio ao processo de tomada de decisão do gerente de energia predial na definição de estratégias de operação ideais. *Energia e Edifícios*. 2012;49:158-63.
- [41] Chou J-S, Ngo N-T. Estrutura de análise de data de grade inteligente para aumentar a economia de energia em edifícios residenciais. *Automação em Construção*. 2016;72:247-57.

- [42] Brockwell PJ, Davis RA. *Série de Tempo de Introdução e Previsão*. Nova Iorque: SpringerVerlag Nova Iorque, 1996.
- [43] De Boeck L, Verbeke S, Audenaert A, De Mesmaeker L. Melhorando o desempenho energético dos edifícios residenciais: Uma revisão da literatura. *Revisões de Energia Renovável e Sustentável*. 2015;52:960-75.
- [44] Fan C, Xiao F, Wang S. Desenvolvimento de modelos de previsão para a construção de energia no dia seguinte e pico de demanda de energia usando técnicas de mineração de dados. *Energia Aplicada*. 2014;127:110.
- [45] Fouquier A, Robert S, Suard F, Stéphan L, Jay A. State of the art in building modelling and energy performances forecast: A review. *Revisões de Energia Renovável e Sustentável*. 2013;23:272-88.
- [46] Fumo N. Fumo Uma revisão sobre o básico da estimativa de energia de construção. *Revisões de Energia Renovável e Sustentável*. 2014;31:53-60.
- [47] Li K, Hu C, Liu G, Xue W. Building's electricity consumption forecast using optimized artificial neural networks and principal component analysis. *Energia e Edifícios*. 2015;108:10613.
- [48] Mena R, Rodríguez F, Castilla M, Arahal MR. Um modelo de previsão baseado em redes neurais para o consumo de energia de um edifício bioclimático. *Energia e Edifícios*. 2014;82:142-55.
- [49] Azadeh A, Saberi M, Seraj O. Um algoritmo de regressão difusa integrada para estimativa de consumo de energia com dados não estacionários: Um estudo de caso do Irã. *Energia*. 2010;35(6):235166.
- [50] Azadeh A, Seraja O, Saberib M. Um algoritmo de regressão difusa total para estimativa de consumo de Energy. *Procedimentos da 6ª Conferência Internacional do IEEE em informática*. Daejeon, Coreia2008. p. 1562-8.
- [51] Naji S, Shamshirband S, Bassar H, Keivani A, Alengaram UJ, Jumaat MZ, et al. Aplicação de metodologia adaptativa neuro-fuzzy for estimando o consumo de energia predial. *Revisões de Energia Renovável e Sustentável*. 2016;53:1520-8.
- [52] Arghira N, Hawarah L, Ploix S, Jacomino M. Previsão do uso de energia de aparelhos em casas inteligentes. *Energia*. 2012;48(1):128-34.
- [53] Ekici BB, Aksoy UT. Previsão de construção do consumo de energia usando redes neurais artificiais. *Avanços em Software de Engenharia*. 2009;40(5):356-62.
- [54] Hamzacebi C, Es HA. Prever o consumo anual de eletricidade da Turquia usando um modelo cinza otimizado. *Energia*. 2014;70:165-71.
- [55] Jung HC, Kim JS, Heo H. Previsão do consumo de energia de construção usando um algoritmo genético codificado real melhorado baseado em pelo menos quadrados de suporte à abordagem da máquina vetorial. *Energia e Edifícios*. 2015;90:76-84.
- [56] Yang C, Li H, Rezgui Y, Petri I, Yuce B, Chen B, et al. High através de algoritmo genético distribuído baseado em computação para a otimização do consumo de energia. *Energia e Edifícios*. 2014;76:92-101.
- [57] Chou J-S, Telaga AS. Detecção em tempo real do consumo de energia anômeos. *Revisões de Energia Renovável e Sustentável*. 2014;33:400-11.
- [58] Pereira CM, Almeida NNd, Velloso MLF. Modelagem difusa para prever uma série de tempo de carga elétrica. *Procedia Ciência da Computação*. 2015;55:395-404.

- [59] D'Andrea E, Lazzerini B, Rosario SLd. Previsão de consumo de energia baseada em rede neural devido à iluminação elétrica em edifícios de escritórios. Internet Sustentável e TIC para Sustentabilidade (SustainIT) Pisa, Itália: IEEE; 2012.
- [60] Mehdi, Shahrookh, Hirad, Masih, Singh. A temperatura do ar por hora é impulsionada usando rede de função de perceptron e base radial de várias camadas em regiões áridas e semiáridas. *Climatologia Teórica e Aplicada*. 2012;109(3-4):519-28.
- [61] Adya M, Collopy F. Quão eficazes são as redes neurais na previsão e previsão? Uma revisão e avaliação. *Previsão*. 1998;17:481-95.
- [62] Hamzaçebi C. Previsão do consumo líquido de energia elétrica da Turquia em bases setoriais. *Política energética*. 2007;35(3):2009-16.
- [63] Dong B, Cao C, Lee SE. Aplicando máquinas vetoriais de suporte para prever o consumo de energia na região tropical. *Energia e Edifícios*. 2005;37(5):545-53.
- [64] Božić M, Stojanović M, Stajić Z. Previsão de carga elétrica de curto prazo usando máquinas vetoriais de suporte mínimo quadrado. *Controle Automático e Robótica*. 2010;9:141-50.
- [65] Catalina T, Virgone J, Blanco E. Desenvolvimento e validação de modelos de regressão para prever a demanda mensal de aquecimento para edifícios residenciais. *Energia e Edifícios*. 2008;40(10):1825-32. [66] Hygh JS, DeCarolis JF, Hill DB, Ranji Ranjithan S. Multivariate regression como uma ferramenta de avaliação de energia no design de edifícios precoces. *Construção e Meio Ambiente*. 2012;57:165-75.
- [67] Wang Z, Srinivasan RS. Uma revisão da previsão de uso de energia de construção baseada em inteligência artificial : Contrastando as capacidades de modelos de predição single e ensemble. *Revisões de Energia Renovável e Sustentável*. 2017;75:796-808.
- [68] Zhang P. Análise de séries de tempo com redes neurais e híbridos de rede neural ARIMA. *Neurocomus*. 2001;50:159-75.
- [69] Newsham GR, Birt BJ. Dados de ocupação em nível de construção para melhorar as previsões de uso de eletricidade baseadas em ARIMA. Zurique, Suíça: BuildSys, 2010.
- [70] Mohamed N, Ahmad M, Ismail Z. Previsão de carga de curto prazo usando o modelo Arima sazonal duplo. *Ciência Aplicada*. 2011;15:223-31.
- [71] Chou J-S, Ho C-C, Hoang H-S. Determinando a qualidade da água no reservatório utilizando aprendizado de máquina. *Informática Ecológica*. 2018;44:57-75.
- [72] Martínez-Álvarez F, Troncoso A, Asencio-Cortés G, Riquelme J. Uma pesquisa sobre técnicas de mineração de dados aplicadas à previsão da série temporal relacionada à eletricidade. *Energias*. 2015;8(12):1316293.
- [73] Chou J-S, Lin C. Previsão de Disputas em Projects de Parceria Público-Privada: Classificação e Modelos de Conjunto. *Revista de Computação em Engenharia Civil*. 2013;27(1):51-60.
- [74] Qiu X, Zhang L, Ren Y, Suganthan PN. Ensemble Deep Learning for Regression and Time Series Forecasting. 2014.
- [75] Allende H, Valle C. Ensemble Métodos para Previsão da Série Do Tempo. 2017;349:217-32. [76] Soares E, Costa P, Costa B, Leite D. Conjunto de nuvens de dados em evolução e modelos nebulosos para previsão de séries meteorológicas. *Aplicou a Computação Suave*. 2018;64:445-53.
- [77] Sallehuddin R, Shamsuddin M, Abraham A. Forecasting time series dados usando rede neural artificial cinza híbrido e modelo médio móvel integrado auto regressivo. *Neural Network World*. 2007;17(6):573-605.

- [78] Lee Y-S, Tong L-I. Previsão de séries temporelas não lineares de consumo de energia usando um modelo dinâmico híbrido. *Energia Aplicada*. 2012;94:251-6.
- [79] Chen J, Yang J, Zhao J, Xu F, Shen Z, Zhang L. Previsão de demanda de energia das estufas usando modelos não lineares baseados no método de previsão otimizado do modelo. *Neurocomus*. 2016;174:1087-100.
- [80] Chou J-S, Cheng M-Y, Wu Y-W. Melhorando a precisão de classificação da resolução de disputas de projetos usando inteligência artificial híbrida e suportando modelos de máquinas vetoriais. *Expert Systems with Applications*. 2013;40(6):2263-74.
- [81] Coakley D, Raftery P, Keane M. Uma revisão dos métodos para combinar modelos de simulação de energia de construção com dados medidos. *Revisões de Energia Renovável e Sustentável*. 2014;37:123-41. [82] Sapankevych N, Sankar R. Time Series Prediction Using Support Vector Machines: A Survey. *Revista de Inteligência Computacional IEEE*. 2009;4(2):24-38.
- [83] Suganthi L, Samuel AA. Modelos de energia para previsão de demanda — uma revisão. *Revisões de Energia Renovável e Sustentável*. 2012;16(2):1223-40.
- [84] Raza MQ, Khosravi A. Uma revisão sobre técnicas de previsão de demanda de carga baseada em inteligência artificial para redes inteligentes e edifícios. *Revisões de Energia Renovável e Sustentável*. 2015;50:1352-72.
- [85] Amasyali K, El-Gohary NM. Uma revisão dos estudos de previsão de consumo de energia orientados por dados. *Revisões de Energia Renovável e Sustentável*. 2018;81:1192-205.
- [86] Vapnik VN. A natureza da teoria da aprendizagem estatística. Nova Iorque, Estados Unidos: SpringerVerlag, 1995.
- [87] Breiman L, Friedman J, Stone CJ, Olshen RA. Classificação e Regressão de Árvores. Nova Iorque, Estados Unidos: Taylor & Francis, 1984.
- [88] Lin L, Wang F, Xie X, Zhong S. Random forests-based extreme learning machine ensemble para previsão de séries temporáticas multi-regime. *Sistemas especializados com Aplicações*. 2017;83:164-76. [89] Kittler J, Hatef M, Duin RPW, Matas J. Na combinação de classificadores. *Transações IEEE sobre Análise de Padrões e Inteligência de Máquina: IEEE*; 1998. p. 226-39.
- [90] Bashir ZA, El-Hawary ME. Aplicando wavelets à previsão de carga de curto prazo usando redes neurais psobased. *IEEE Transactions on Power Systems*. 2009;24(1):20-7.
- [91] Pradeepkumar D, Ravi V. Prever a volatilidade da série de tempo financeiro usando a Otimização do Enxame de Partículas treinou rede neural de regressão quântica. *Aplicou a Computação Suave*. 2017;58:3552.
- [92] Hansen JV, Nelson RD. Análise da série temporal com redes neurais e híbridos de rede neural ARIMA. *Inteligência Artificial Experimental & Teórica*. 2003;15(3):315-30. [93] Suykens JAK, Gestel TV, Brabanter JD, Moor BD, Vandewalle J. Least Squares Suportam Vetores Máquinas. Cingapura: World Scientific, Cingapura, 2002.
- [94] Kennedy J, Eberhart R. Particle Swarm Optimization. *IEEE*. Perth, WA, Austrália 1995. [95] Jovanović RŽ, Sretenović AA, Živković BD. Conjunto de várias redes neurais para previsão de aquecimento do consumo de energia. *Energia e Construções*. 2015;94:189-99.
- [96] Candanedo LM, Feldheim V, Deramaix D. Modelos de previsão de dados de uso de energia de aparelhos em uma casa de baixa energia. *Energia e Edifícios*. 2017;140:81-97.

[97] Wang Z, Wang Y, Srinivasan RS. Uma nova abordagem de aprendizado de conjunto para apoiar a previsão de uso de energia. *Energia e Edifícios*. 2018;159:109-22.



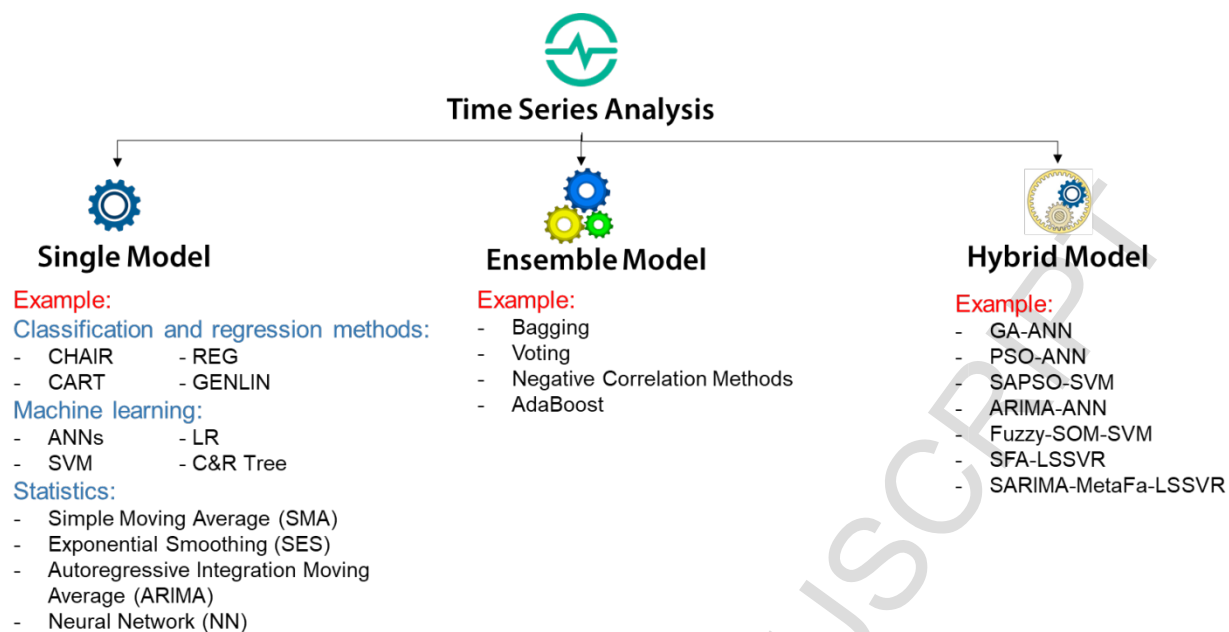


Figura 1: Fluxo de técnicas de previsão de séries temporentas.




Figura 2: Quadro de modelos de previsão única.

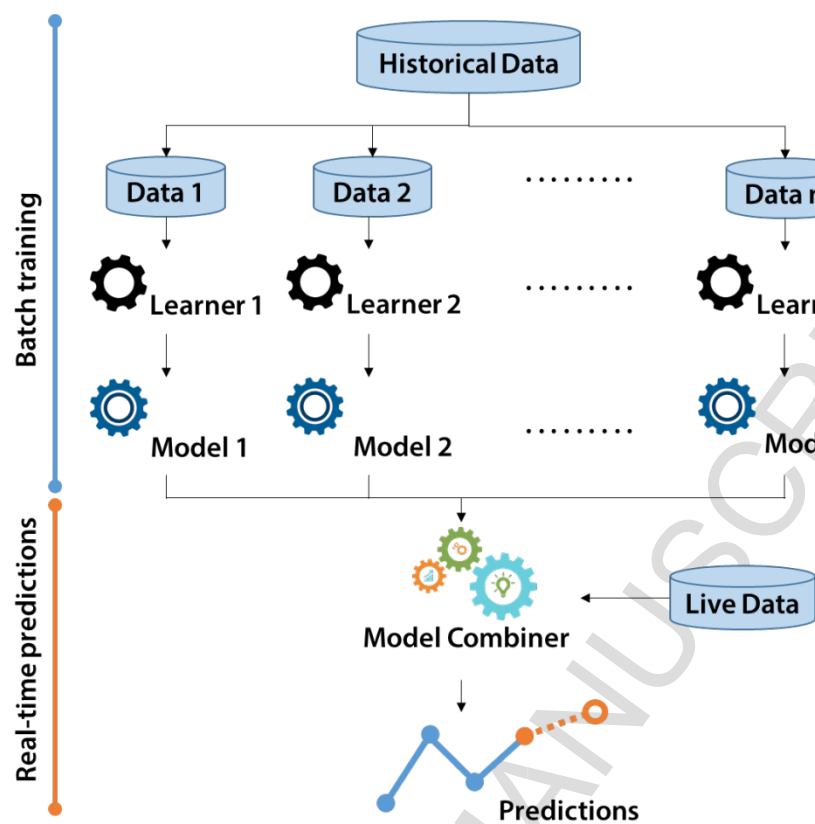


Figura 3: Estrutura de modelos de conjunto.

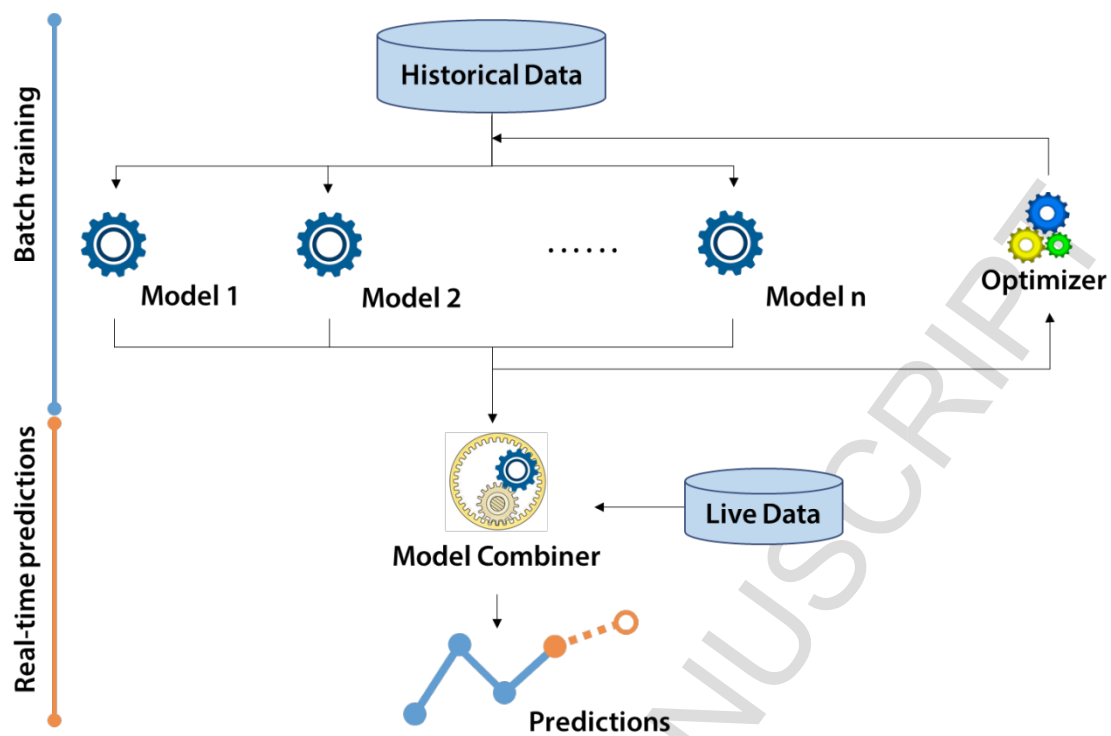


Figura 4: Fluxo de modelos híbridos de uma fase.

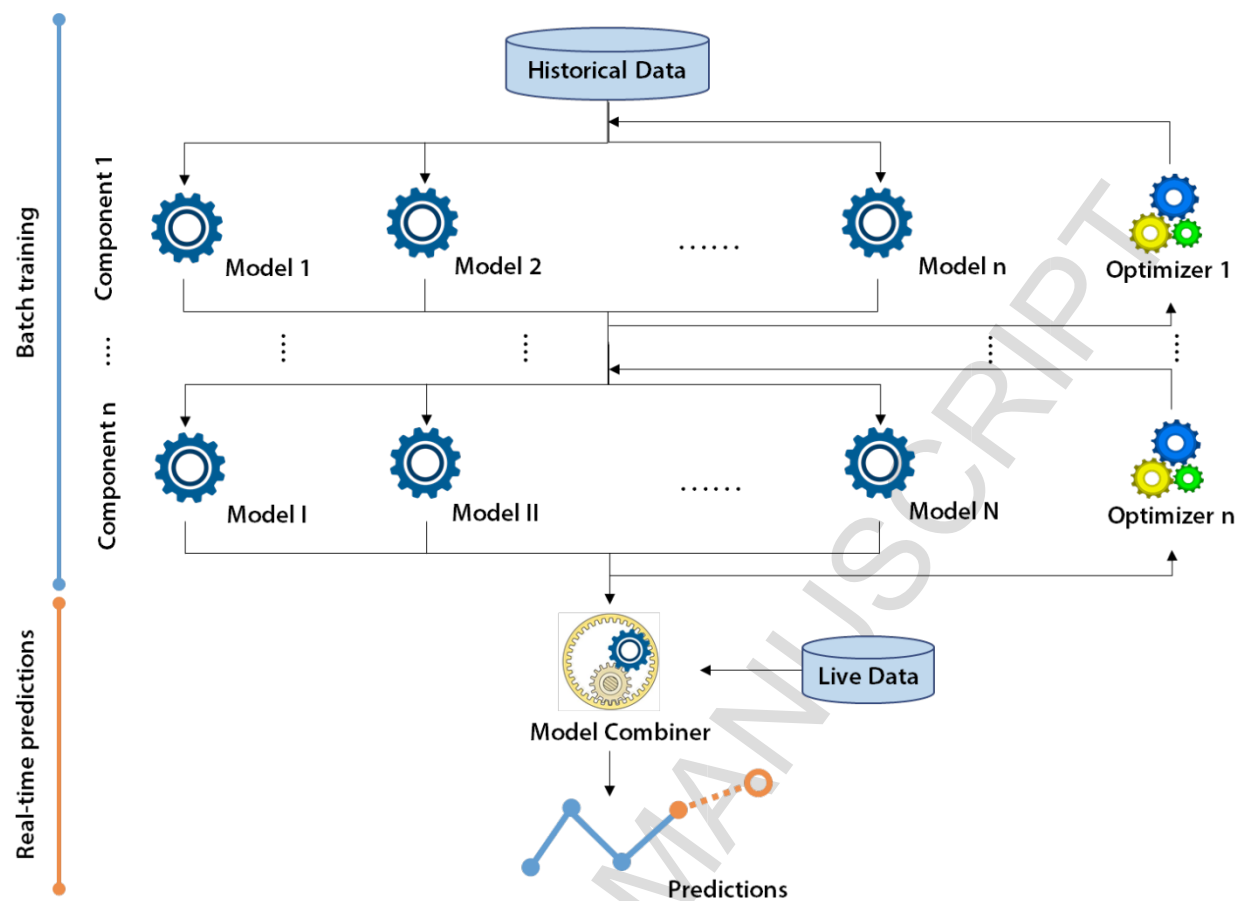


Figura 5: Fluxo de modelo híbrido de várias fases.

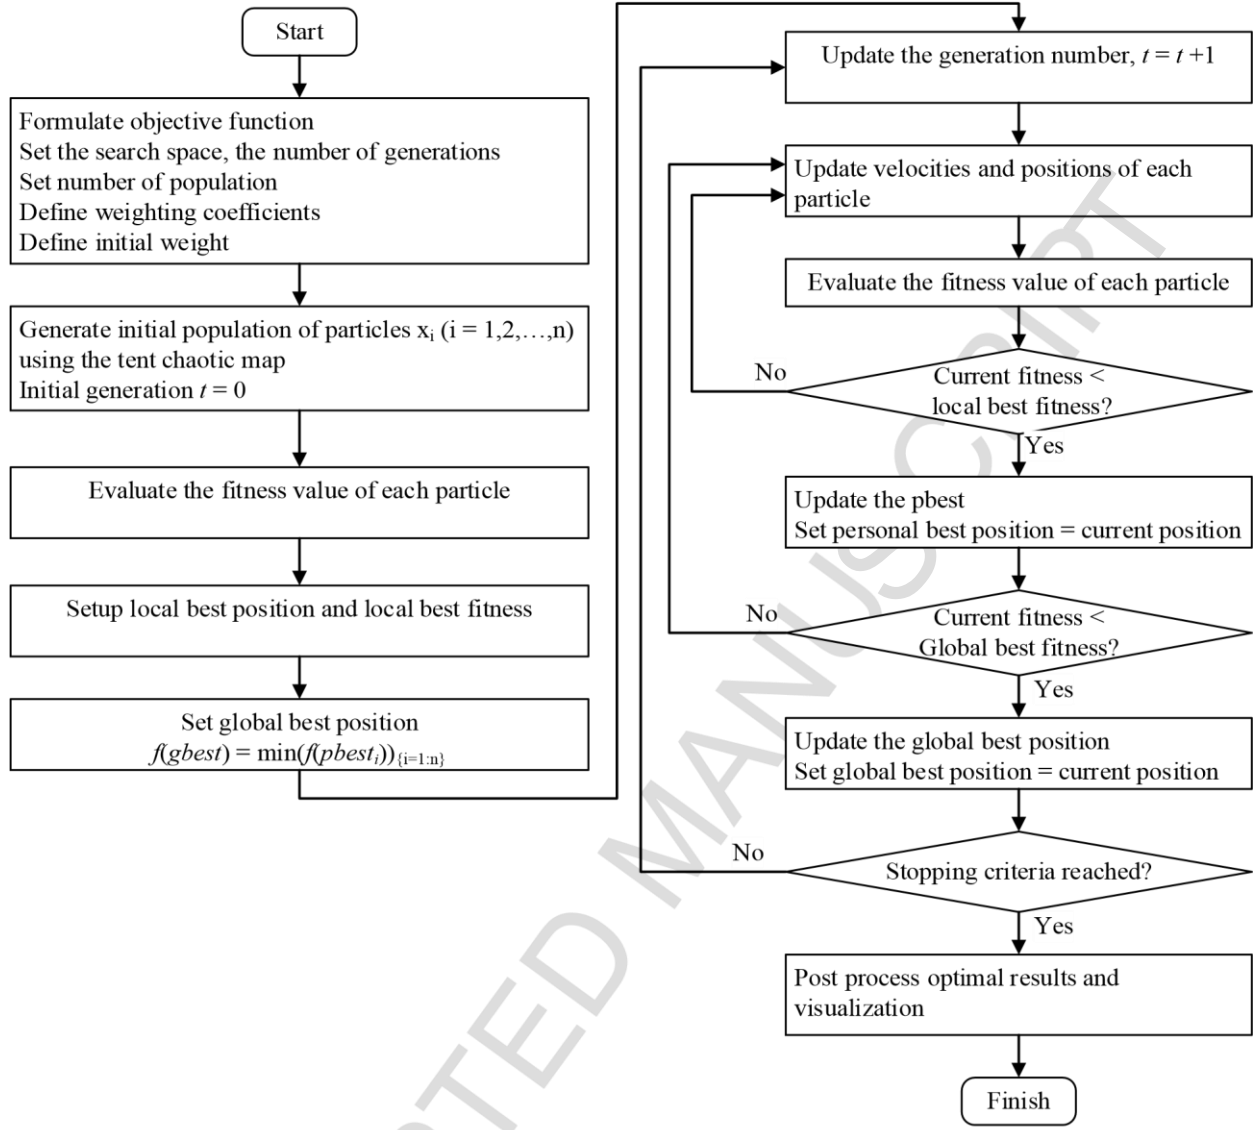


Figure 6: Flowchart of metaheuristic PSO algorithm.

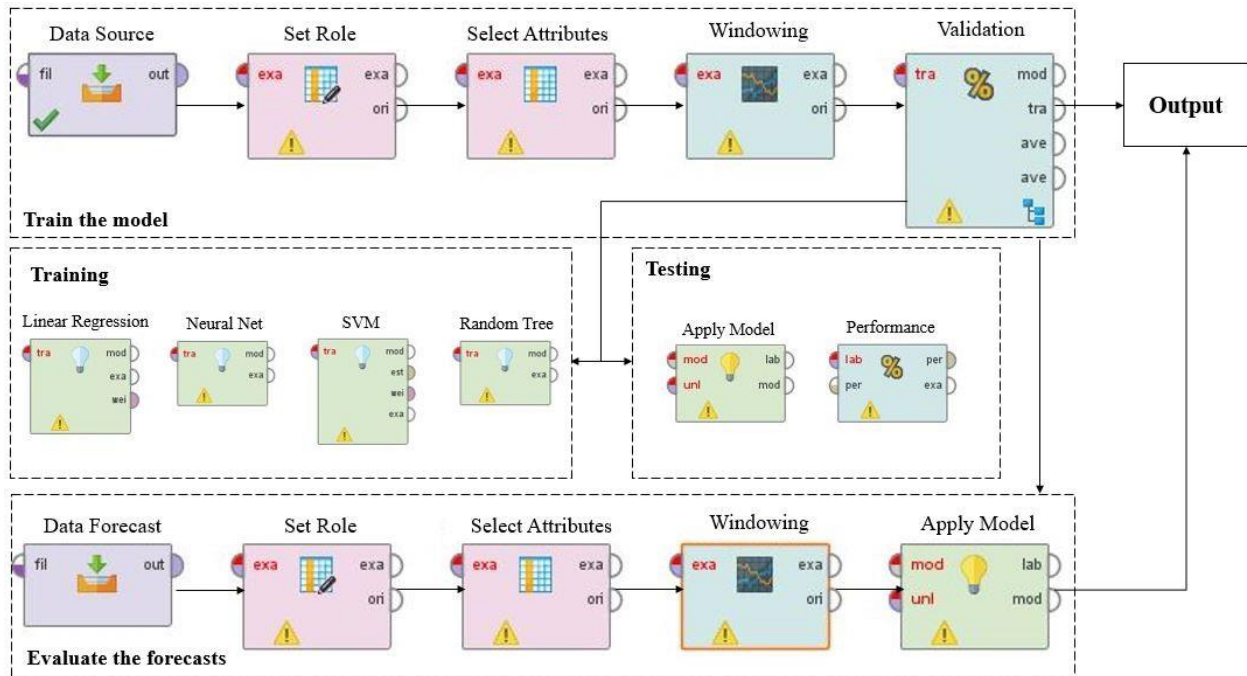


Figura 7: Fluxo de modelo único no RapidMiner Studio.

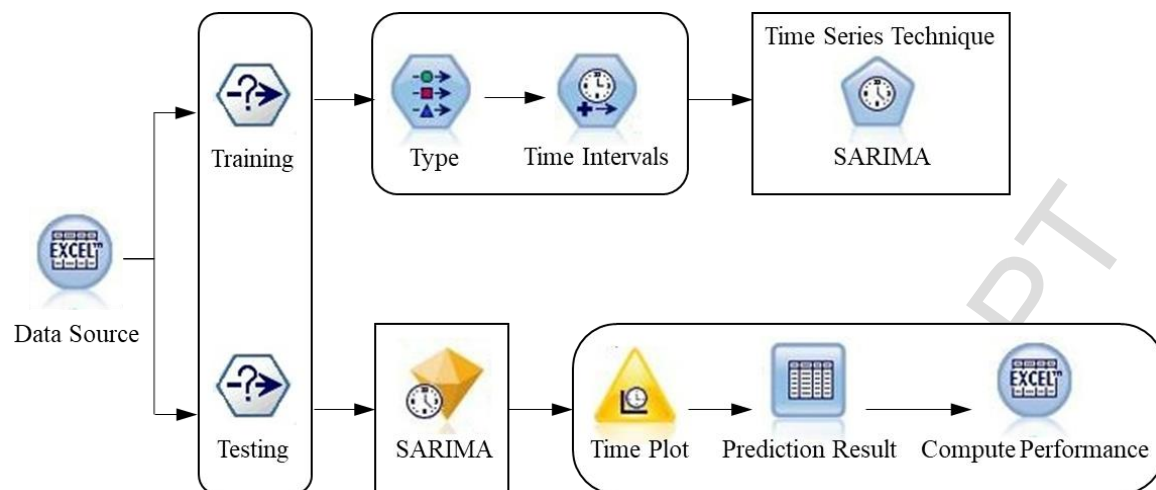


Figura 8: Fluxo de modelo único no IBM SPSS Modeler.

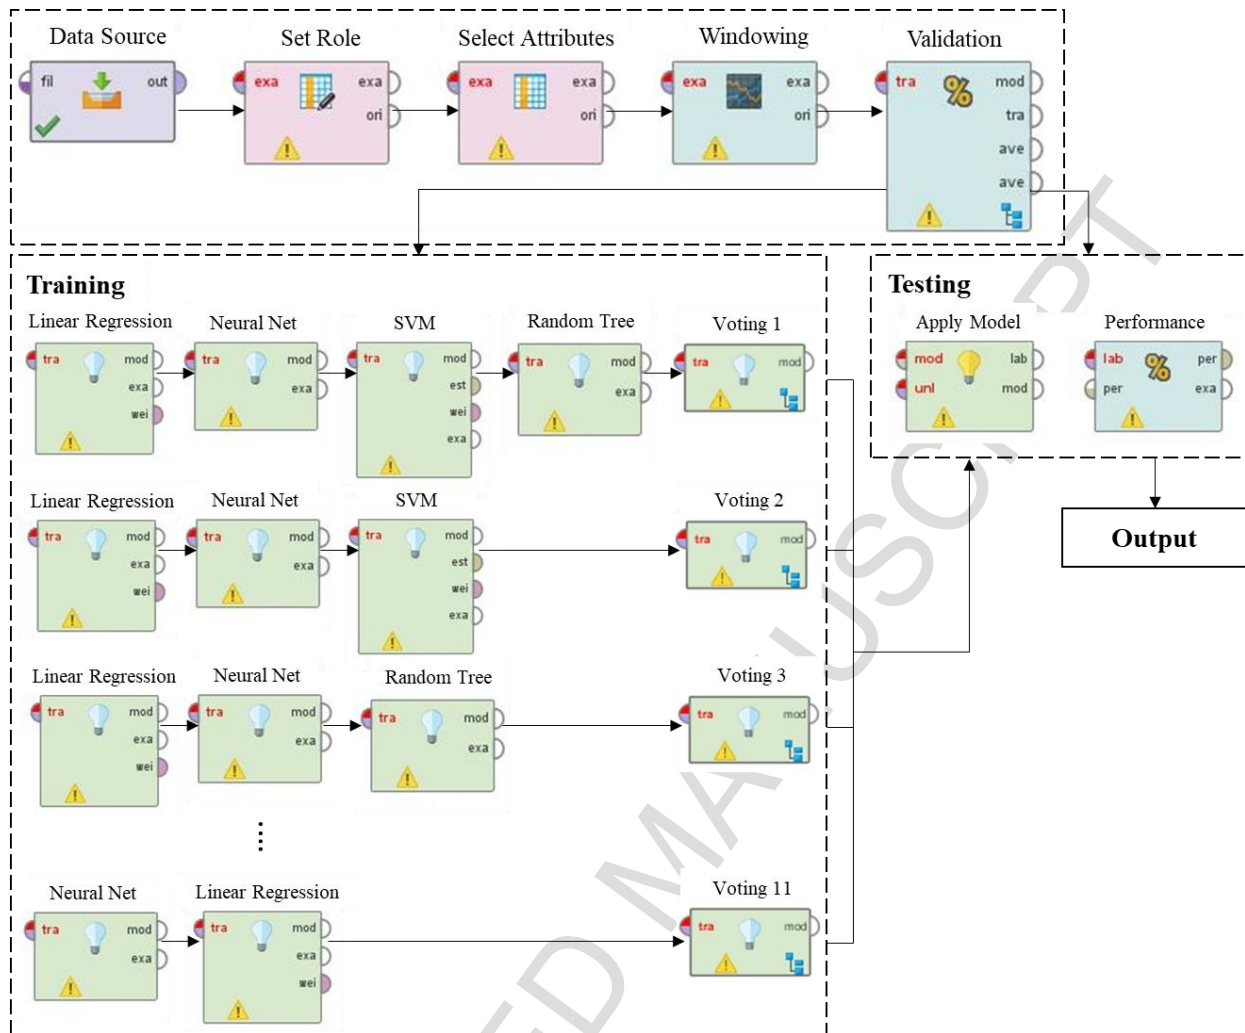


Figura 9: Fluxo de modelo de votação no RapidMiner Studio.

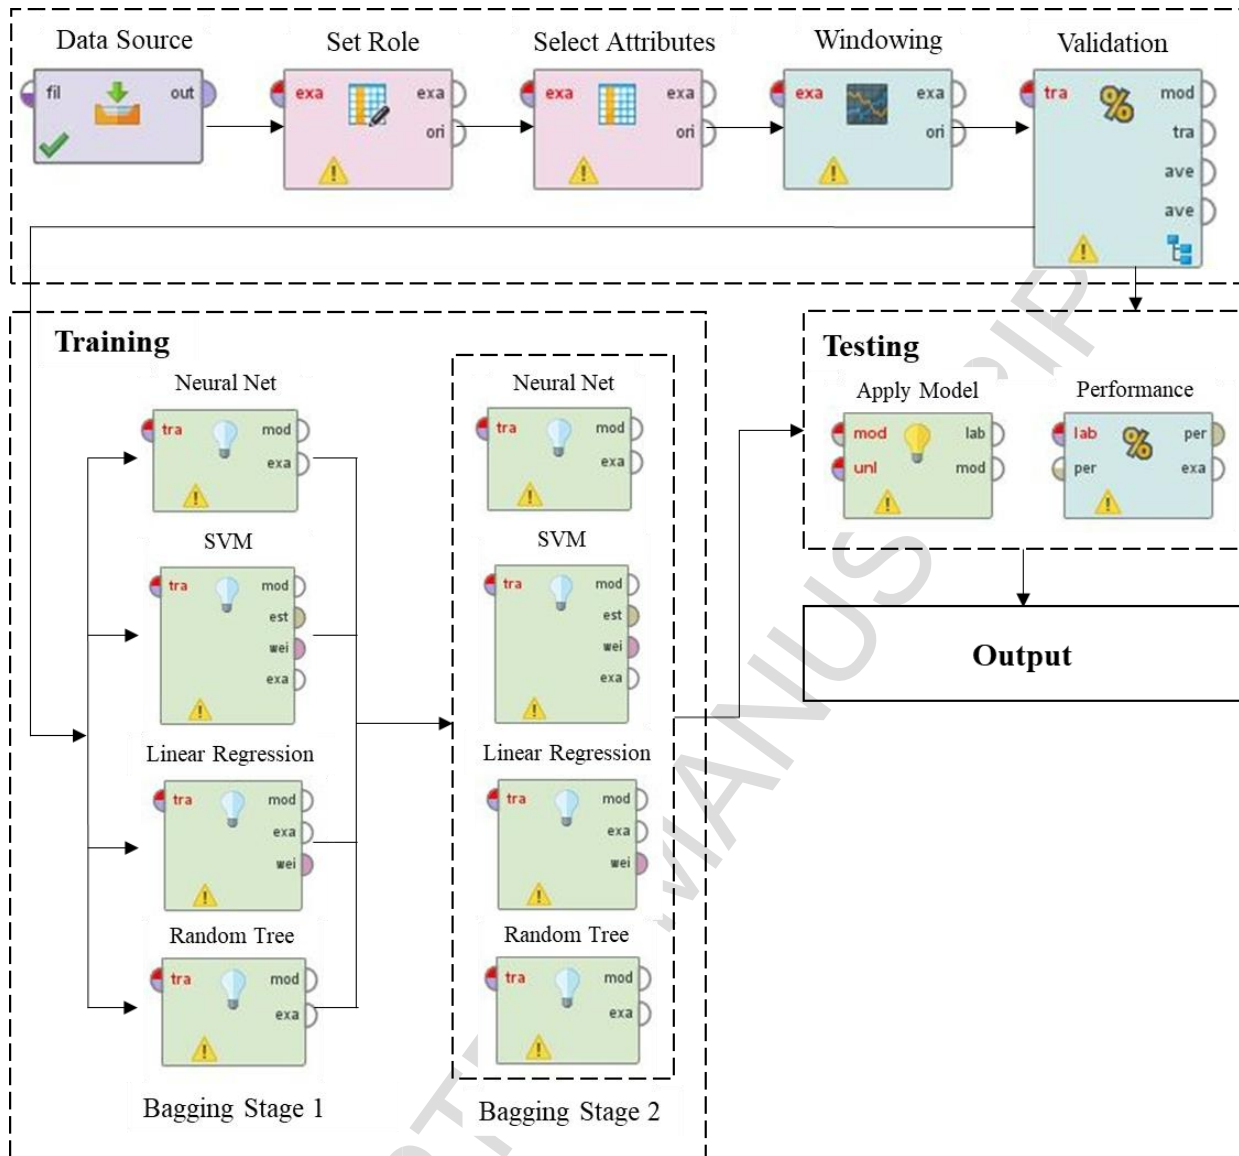


Figura 10: Fluxo de modelo de ensacamento no RapidMiner Studio.

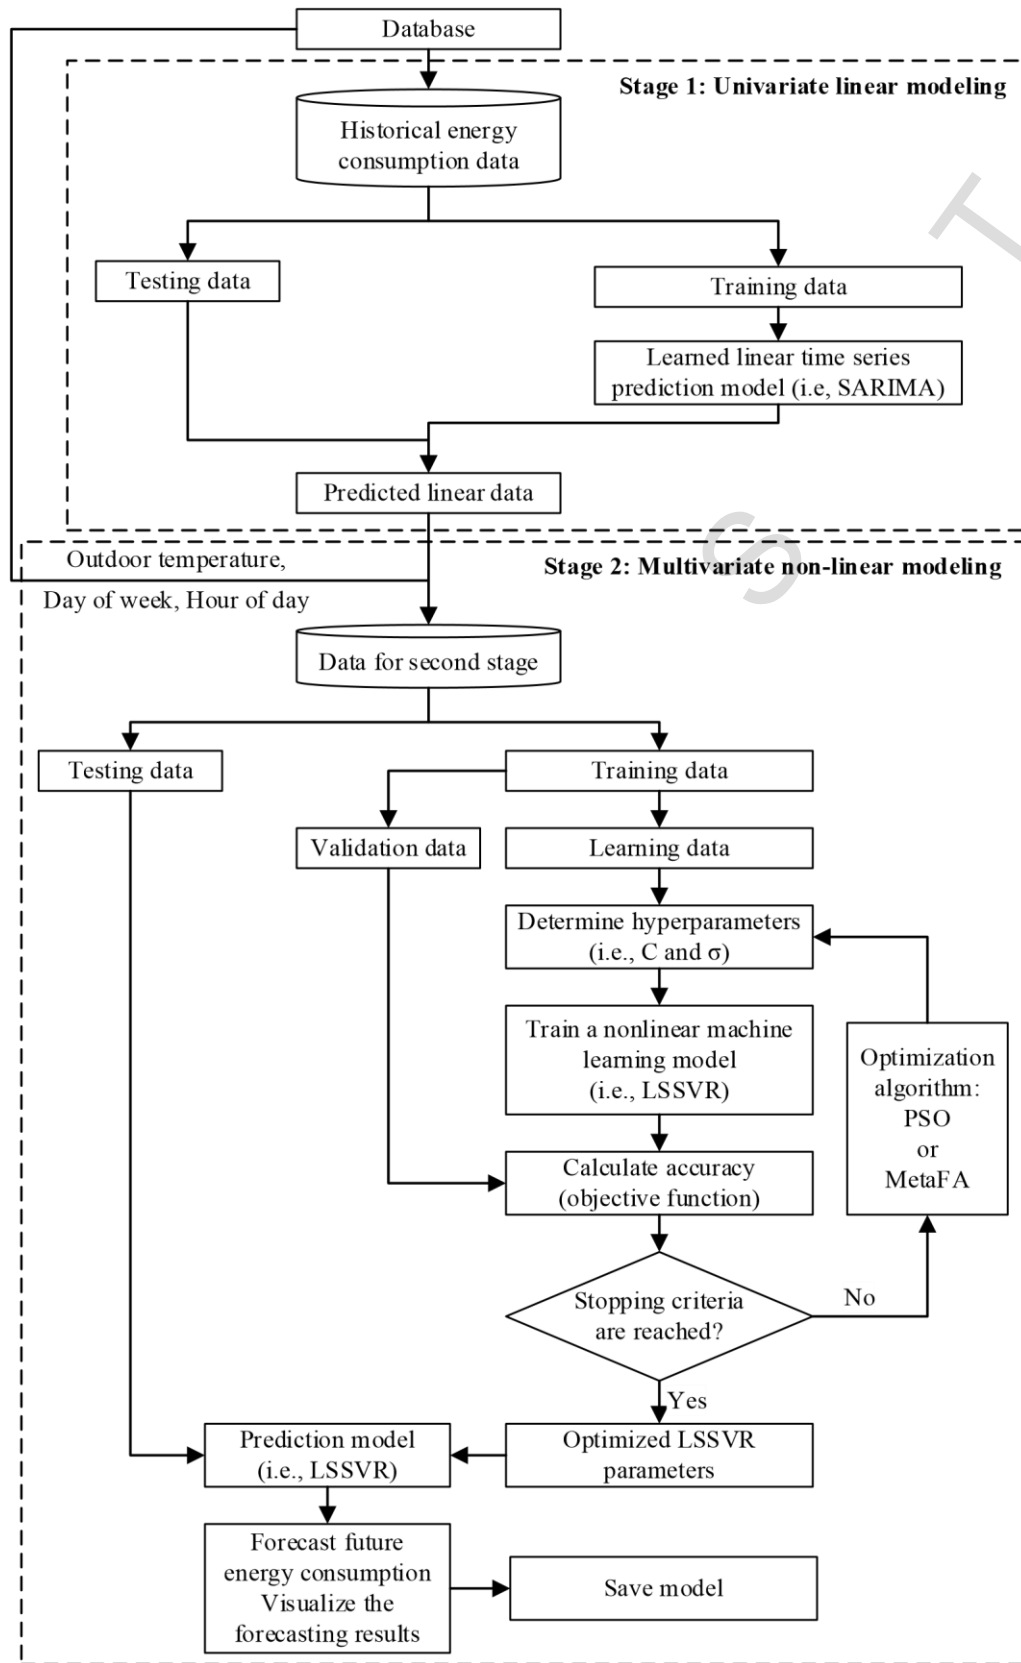


Figura 11: Modelos de aprendizado de máquina baseados em otimização metaheurística no MATLAB.

Tabela 1: Configurações padrão dos parâmetros do modelo no RapidMiner Studio.

Modelo	Parâmetros	Valor padrão
		Estúdio RapidMiner
		NameNeural Net

Artificial Neural Rede	Especificação de camada oculta	
	Número de camadas ocultas	1
	Número de nódulos ocultos	$1 + \frac{\text{atts} + \text{Classes}}{2}$
	Número de iterações de aprendizagem	500
	Ímpeto	0.2
	Tipo de normalização	[-1,1]
	Exemplos dados	Verda
Apoio Vetor Máquina	Taxa de	0.3
	Nome	SVM
	Tipo de kernel	RBF
	Parâmetro de regularização (C)	0
	E(epsilon)	0.001
	RBF C(gama)	1.0
	Crítérios de parada	N/A
Classificação e Regressão Árvor	Nome	W-REPTree
	Profundidade	Infinito
	Número de splits aleatórios / nó de folha	N/A
	Número mínimo de amostras / nó de folha	2
	Criar modo de treinador	Único parâmetro
	Variância mínima para split (V)	1.0E-3
	Número de dobras para poda de erro reduzida (N)	3
	Sementes para embaralhar dados aleatórios	1
Linear Regressão	Poda (P)	Verda
	Nome	Linear Regressão
	Método de linha de regressão de	Mínimo comum Quadrado
	Peso de regularização L2	1.0E-8
	Seleção de recursos	M5-prime
	Use viés	Verda
	Excluir recursos collineares	Verda
	Tolerância	0.05
		N/A

Tabela 2: Configurações padrão dos parâmetros do modelo no Modelador SPSS.

Modelo	Parâmetros	Modelador SPSS
	Intervalo de	confiança de 95%
	Considere sazonal	Sim
	SarimaIntervals	dados15-min
	Periodicidade	96
	Número máximo de lags	96

Tabela 3: Configurações do parâmetro para o modelo de previsão SARIMA-PSO-LSSVR.

Parametrionssetting

Primeira etapa: Modelo SARIMA

		1
		0
		1
		96
		0
		96
		96
Escopo de C	Parâmetro de regularização do LSSVR	$[10^{-3} \ 10^{12}]$
Escopo de \square	Função sigma do kernel RBF em LSSVR	$[10^{-3} \ 10^3]$
Não. de partículas	Tamanho populacional do PSO	50
Critérios de	Geração máxima	25
	Três taxas consecutivas de variação em valores de função objetiva	$< 10^{-8}$
Mapa logístico caótico	Gerar população inicial com alta diversidade	Geração aleatória
E_o	Valor inicial da aleatoriedade parâmetro	0.5
c_1, c_2	Parâmetros de	$c_1 = 2,05$ $c_2 = 2,05$

p Não-sazonal ordem autoregressiva

d Diferença não sazonal q Ordem

autoregressiva sazonal

D Diferença sazonal

Q Ordem média móvel sazonal

S Tempo de repetição sazonal
padrão
Segunda etapa: Modelo PSO-LSSVR

T

S

Tabela 4: Configurações do parâmetro para o modelo de previsão SARIMA-MetaFA-LSSVR.

Parametrionssetting		
Primeira etapa: Modelo SARIMA		
		1
		0
		1
		96
		0
		96
		96
		$[10^{-3} \ 10^{12}]$
Escopo de	Função sigma do kernel RBF em LSSVR	$[10^{-3} \ 10^3]$
Não. de vagalumes	Tamanho populacional do MetaFA	50
Critérios de	Geração máxima	25
	Três taxas consecutivas de variação em valores de função objetiva	$< 10^{-8}$
Mapa logístico caótico	Gerar população inicial com alta diversidade	Geração aleatória
B_{Min}	Valor mínimo de atratividade parâmetro B	0.1
C	Coefficiente de absorção	1
Gauss/mouse caótico	Ajuste automaticamente o parâmetro	Parâmetro atraente
E	Aleatoriedade do movimento do vagalume	$\alpha = 0,2$
AIW	Controle a exploração local e global capacidades do algoritmo enxame	$T = 0,9$
Voo Levy	Acelere a busca local por gerando novas soluções em torno do solução ideal	$T = 1,5$

p

Não-sazonal ordem autoregressiva

d Diferença não sazonal q Ordem

autoregressiva sazonal

D Diferença sazonal

Q Ordem média móvel sazonal

S Tempo de repetição sazonal
padrão

Segunda etapa: Modelo MetaFA-LSSVR

Intervalo de *parâmetro de* CRegularization de LSSVR

Tabela 5: Medidas de desempenho de modelos únicos no Modelador SPSS.

ModelMeasure	Mon.	Tue.	Wed.	Thur.	Sex.	Sat.	Sun.	Ave.	Max	Min
R	0.192	0.519	0.332	0.602	0.733	0.527	0.138	0.435	0.733	0.138
RMSE (kWh)	0.146	0.081	0.176	0.109	0.074	0.129	0.098	0.116	0.176	0.074
SARIMA MAE (kWh)										
MAPA (%)										
MaxAE (kWh)										
	0.103	0.058	0.161	0.073	0.055	0.102	0.085	0.091	0.161	0.055

49.79126.226103.247.5234.0180.3582.5360.518103.226.226

0.180.2260.9830.2650.1780.2040.2130.3210.9830.178



Tabela 6: Medidas de desempenho de modelos únicos no RapidMiner Studio.

Model	Measure	Mon.	Tue.	Wed.	Thur.	Fri.	Sat.	Sun.	Ave.	Max	Min
		0.373	0.729	0.518	0.697	0.645	0.651	0.276	0.556	0.729	0.276
		0.097	0.068	0.116	0.105	0.073	0.068	0.116	0.092	0.116	0.068
		0.058	0.045	0.068	0.083	0.051	0.052	0.044	0.057	0.083	0.044
		35.06	19.04	34.95	56.69	29.29	40.82	41.99	36.834	56.69	19.04
		0.34	0.36	0.529	0.375	0.226	0.177	0.464	0.353	0.529	0.177
SVM	R	0.339	0.371	0.345	0.725	0.535	0.584	0.19	0.441	0.725	0.19
	RMSE (kWh)	0.094	0.109	0.134	0.089	0.077	0.095	0.108	0.101	0.134	0.077
	MAE (kWh)	0.064	0.082	0.085	0.062	0.058	0.065	0.072	0.070	0.085	0.058
	MAPE (%)	34.78	37.25	34.53	36.96	34.76	49.67	74.62	43.224	74.62	34.53
	MaxAE (kWh)	0.308	0.371	0.526	0.335	0.215	0.279	0.276	0.330	0.526	0.215
LR	R	0.296	0.326	0.525	0.593	0.57	0.563	0.239	0.445	0.593	0.239
	RMSE (kWh)	0.099	0.103	0.109	0.111	0.105	0.063	0.119	0.101	0.119	0.063
	MAE (kWh)	0.069	0.068	0.069	0.064	0.076	0.039	0.046	0.062	0.076	0.039
	MAPE (%)	42.62	28.15	37.32	42.89	51.92	22.79	43.93	38.517	51.92	22.79
	MaxAE (kWh)	0.348	0.363	0.39	0.39	0.355	0.264	0.655	0.395	0.655	0.264
C&R Tree	R	0.392	0.519	0.381	0.355	0.425	0.512	0.08	0.381	0.519	0.08
	RMSE (kWh)	0.097	0.103	0.125	0.116	0.099	0.124	0.087	0.107	0.125	0.087
	MAE (kWh)	0.058	0.083	0.068	0.089	0.078	0.085	0.056	0.074	0.089	0.056
	MAPE (%)	35.06	40.41	26.47	65.49	48.96	63.43	57.61	48.204	65.49	26.47
	MaxAE (kWh)	0.409	0.262	0.538	0.347	0.327	0.346	0.305	0.362	0.538	0.262

Note: Bold value denotes the best performance for each model.

R
RMSE (kWh)
ANNsMAE (kWh)
MAPE (%)

MaxAE (kWh)

T

S

Tabela 7: Medidas de desempenho de modelos de conjunto no RapidMiner Studio.

Modelo	Medir	Meu.	Ter.	Casar.	Thur.	Sex	Sáb.	Chão.	De.	Max	Min
Ensacame	R	0.545	0.573	0.528	0.363	0.535	0.658	0.384	0.512	0.658	0.363
		0.087	0.131	0.126	0.167	0.362	0.101	0.174	0.164	0.362	0.087
		0.048	0.064	0.058	0.056	0.178	0.171	0.153	0.104	0.178	0.048
		38.76	45.89	34.65	35.36	47.25	43.58	53.74	42.75	53.74	34.65
		0.215	0.391	0.429	0.534	0.641	0.486	1.253	0.564	1.253	0.215
ANNs	R	0.551	0.616	0.658	0.623	0.734	0.651	0.416	0.607	0.734	0.416
	RMSE (kWh)	0.058	0.016	0.072	0.171	0.125	0.149	0.067	0.094	0.171	0.016
	MAE (kWh)	0.042	0.068	0.031	0.061	0.034	0.039	0.069	0.049	0.069	0.031
	MAPA (%)	34.82	54.95	38.19	35.31	28.07	42.62	62.19	42.31	62.19	28.07
	MaxAE (kWh)	0.277	0.549	0.157	0.232	0.451	0.381	0.319	0.338	0.549	0.157

Nota: O valor em negrito denota o melhor desempenho para cada modelo.

RMSE (kWh)
VotaçãoSVR+LRMAE (kWh)
MAPA (%)
MaxAE (kWh)

Tabela 8: Comparação de desempenho dos modelos híbridos propostos no MATLAB.

Modelo	Medir	Meu.	Ter.	Casar.	Thur.	Sex	Sáb.	Chão.	De.	Max	Min
SARIMA- PSO- LSSVR			0.855	0.910	0.813	0.867	0.82	0.492	0.796	0.91	0.492
			0.18	0.18	0.17	0.172	0.168	0.1	0.164	0.18	0.1
			0.032	0.032	0.029	0.03	0.028	0.01	0.028	0.032	0.01
			13.98	14.93	16.55	18.42	18.97	10.19	15.657	18.97	10.19
	MaxAE (kWh)	0.182	0.213	0.249	0.261	0.151	0.166	0.033	0.179	0.261	0.033
	Tempo de CPU	0.733	0.815	0.705	0.797	0.772	0.784	0.821	0.775	0.821	0.705
	R	0.731	0.632	0.845	0.908	0.867	0.825	0.493	0.757	0.908	0.493
	RMSE (kWh)	0.24	0.239	0.182	0.18	0.171	0.162	0.1	0.182	0.24	0.1
	MAE (kWh)	0.057	0.057	0.033	0.032	0.029	0.026	0.01	0.035	0.057	0.01
	MAPA (%)	33.85	22.45	14.28	14.95	0.184	17.4	10.2	16.188	33.85	0.184
	MaxAE (kWh)	0.24	0.458	0.234	0.244	0.151	0.182	0.033	0.220	0.458	0.033
	Tempo de CPU	0.767	0.724	0.736	0.729	0.724	0.714	0.71	0.729	0.767	0.71

Nota: O valor em negrito denota o melhor desempenho para cada modelo.

R 0.817
RMSE (kWh) 0.179
SARIMA-MAE (kWh) 0.032
MetaFA-

MAPA LSSVR (%) 16,56

T

S

Tabela 9: Comparação de desempenho entre os melhores modelos em cada cenário.

Cenário	Melhor	Medida de desempenho					
		R	RMSE	MAE	MAPA (%)	SI	Aperfeiçoamento
Único	RapidMiner: ANNs	0.556	0.092	0.057	36.834	0.70 (3)	-
Junto	RapidMiner: Ensacado (ANNs)	0.607	0.094	0.049	42.31	0.64 (2)	9%
Híbrido	MATLAB: SARIMA-MetaFA-LSSVR	0.796	0.164	0.028	15.657	0.25 (1)	64%

Nota: O valor em negrito denota o melhor desempenho para cada medida; o ranking.

Destaques

- Este estudo apresenta técnicas de IA para prever dados de consumo de energia em edifícios.
- As vantagens e desvantagens de cada método de aprendizagem de máquina são analisadas.
- Demonstra que o modelo híbrido é mais preciso do que os modelos single e ensemble.
- A precisão da previsão e a adequação para o uso da IA são consideradas nesta investigação.
- As observações finais apoiam os usuários no planejamento da gestão de energia.