




Conteúdo Listado disponível em ScienceDirect

Elétrico Poder Sistemas Investigaç

Disponível em Eumepage: www.elsevier.com/locate/epsr

Previsão da série temporal desacoplada baseada em ARIMA da demanda de carregamento de veículos elétricos para operação do sistema de energia estocástica

Hadi Aminia,b,c,d, Amin Kargariane,*, Orkun Karabasoglu,b,c,d,*

^a Sun Yat-Sen University-Carnegie Mellon University Joint Institute of Engineering, Guangzhou, Guangdong 510006, China ^bDepartamento de Engenharia Elétrica e de Computação, Universidade Carnegie Mellon, Pittsburgh, PA 15213, EUA ^c SYSU-CMU Shunde International Joint Research Institute, Shunde, China ^d School of Electronics and Information Technology, SYSU, Guangzhou, China^e Departamento de Engenharia Elétrica e de Computação, Universidade Estadual de Louisiana, Baton Rouge, EUA

artigo info

Histórico do artigo:

Recebido em 9 de fevereiro de 2016

Recebido em formulário revisado em 6 de maio de 2016

Aceito em 1 de junho de 2016

Disponível online xxx

Keywords:

Previsão de demanda

Demanda de carregamento

Estacionamentos de veículos elétricos

Média móvel integrada autoregressiva (ARIMA)

Compromisso de unidade com restrição de segurança com restrição de chance

abstract

A utilização em larga escala de veículos elétricos (EVs) afeta consideravelmente a demanda total de eletricidade. A previsão de demanda é geralmente projetada para os padrões de carga que mudam sazonalmente. No entanto, com a alta penetração de EVs, a demanda diária de carregamento torna os métodos tradicionais de previsão menos precisos. Este artigo apresenta um método autoregressivo de média móvel integrada (ARIMA) para previsão de demanda de carga elétrica convencional (CEL) e demanda de carregamento de estacionamentos EV (CDE) simultaneamente. Nosso modelo de previsão de demanda de carregamento EV toma padrões e distâncias diárias de condução como uma entrada para determinar os perfis de carga de carregamento esperados. Os parâmetros do modelo ARIMA são ajustados para que o erro quadrado médio (MSE) do preditor seja minimizado. Melhoramos a precisão do preditor ARIMA otimizando os parâmetros de pedidos integrados e autoregressivos. Além disso, devido ao diferente padrão sazonal e diário do CEL e CDE, o método de previsão de demanda dissociado proposto proporciona uma melhoria significativa em termos de redução de erros. O impacto da demanda de carregamento de EV na precisão do preditor de carga proposto também é analisado em duas abordagens: (1) predito integrado para CEL + CDE, e (2) desacoplou a previsão que visa cel e CDE de forma independente. As saídas de previsão são usadas para formular um problema de agendamento de dia antes. Os resultados numéricos mostram a eficácia do preditor proposto e sua influência na operação do sistema de energia estocástica.

© 2016 Elsevier B.V. Todos os direitos reservados.

1. Introdução

A utilização em larga escala de veículos elétricos (EVs) afeta significativamente o perfil geral de carga em sistemas de energia futuros. Os EVs estão emergindo como alternativas mais econômicas e ecológicas aos carros convencionais baseados em combustíveis fósseis. De acordo com o anúncio da Casa Branca e dos EUA. Departamento de Energia, a redução do custo das tecnologias de bateria acelerará a tendência crescente de vendas de EVs [1]. Recursos de energia renovável,

exigir cargas responsivas, e unidades de geração distribuída, como Os EVs pavimentam o caminho para futuros sistemas de energia para melhorar o ativo.

* Autor correspondente em: Sun Yat-sen University-Carnegie Mellon University Joint Institute of Engineering (JIE), School of Electronics and Information Technology, SYSU, Guangzhou, Guangdong, China; Scott Institute for Energy Innovation, Carnegie Mellon University, Pittsburgh, PA, EUA; SYSU-CMU Shunde International Joint Research Institute, Guangdong, China. Tel.: +86 13226996631. ** autor correspondente em: Departamento de Engenharia Elétrica e de Computação, Louisiana State University, Baton Rouge, EUA.

Endereços de e-mail : amini@cmu.edu (M.H. Amini), kargarian@lsu.edu (A. Kargarian), karabasoglu@cmu.edu (O. Karabasoglu).

<http://dx.doi.org/10.1016/j.epsr.2016.06.003> 0378-7796/© 2016 Elsevier B.V. Todos os direitos reservados.

lização e preservar um nível aceitável de confiabilidade [2,3]. Na literatura, os EVs têm sido considerados como recursos vantajosos para melhorar a operação do sistema de energia [4]. Eles podem atuar como recursos flexíveis de armazenamento de energia e participar de aquisição de serviços auxiliares [5]. Consequentemente, os veículos elétricos plug-in podem fornecer armazenamentos de energia despachadas distribuídos para redes inteligentes [6]. Nesse contexto, analisa-se o impacto do controle ideal dos sistemas de armazenamento de energia distribuída na demanda de eletricidade para redes inteligentes [7]. Com maior uso de veículos elétricos (EVs) entre os condutores urbanos, a rede de distribuição será submetida a maior estresse devido a aumentos na demanda de energia elétrica cobrando necessidades de EVs [8].

Nomenclatura		ARTIGO NA IMPRENSA		
Índices, conjuntos e parâmetros b Índice para índice de barramento i para unidade geradora l Índice para linha l Índice para período de tempo Índice para veículos elétricos (EV) classe CbMaximum capacidade de carga chr Taxa de carregamento ϕv Mersem ação do mercado da ordem l EV classe d Integrated (I) da ARIMA Consumo de EmEnergy por milha impulscionada $f_i(\cdot)$ Função de custo de produção da unidade i no tempo t – 1, em hora M Constante suficientemente grande ϵ kDemand previsão erro de barra b no horário t no dia k b,t MD Distância máxima de drivable (com uma bateria totalmente carregada) dProbabilistic tempo de partida N Ordem auto regressiva (AR) de ARIMA Valor de carga L_r Real na décima hora i do EV , também existem alguns problemas causados pelos EVs. As próximas vantagens e		M.H.Aminiepara p./ElétricoPoderSistemasInvestigaçãoXxx(2016)xxx-xxx		3
Modelo G				
EPSR-4723: Não de Páginas 16				
Índice para período de tempo				
Índice para veículos elétricos (EV)				
classe CbMaximum capacidade de carga chr				
Taxa de carregamento				
ϕv Mersem ação do mercado da				
ordem l EV classe d Integrated (I) da				
ARIMA				
Consumo de EmEnergy por milha impulscionada				
$f_i(\cdot)$ Função de custo de produção da unidade i no tempo t – 1, em hora				
M Constante suficientemente grande				
ϵ kDemand previsão erro de barra b no horário t no dia k b,t				
MD Distância máxima de drivable (com uma bateria totalmente carregada)				
dProbabilistic tempo de partida				
N Ordem auto regressiva (AR) de ARIMA				
Valor de carga L_r Real na décima hora				
i				
Valor de carga LForecast na décima hora				
eu				
Pr{· } Medida de probabilidade				
Fator SF Shift				
R_{UI} , RDMaximum ramp up/down rate of unit i, in MW/h				
T_{on} , ToffMinimum ON/OFF time da unidade i, em hora				
I_i				
Z_{x100} $\times (1 - x)$ th percentil da distribuição normal padrão				
ar Valor médio do tempo de chegada sendo usado para carregar modelagem demanda				
ar Desvio padrão do tempo de chegada sendo usado para carregar modelagem de demanda				
b,t Desvio padrão da demanda no ônibus b no momento t que é fornecido pelo preditor ARIMA				
d Valor médio do tempo de partida sendo usado para a modelagem da demanda de carregamento				
d Desvio padrão do tempo de partida dos EVs sendo usado para carregar modelagem de demanda				
m Valor médio da distribuição lognormal para distância probabilística diária impulscionada				
mOrdor de desvio de lognormal de distribuição para a distância diária impulscionada probabilística sendo usada para a modelagem da demanda de carregamento				
md Valor médio da distância probabilística diária impulscionada sendo usado para modelagem de estacionamento				
mdO desvio padrão da distância probabilística diária impulscionada sendo usado para modelagem de estacionamento $\epsilon_{t,i}$				
nível de confiança de restrições de chance no momento t x_{-},x				
ÍMinimum e máximo de $x \times \dots$ Valor esperado de x				
Variáveis				
DkDemand de ônibus b no horário t no dia k				
b,t				
D... kExpressa demanda de ônibus b no horário t no dia k				
b,t				
E... dExpressa demanda energética de EV				
$I_{i,t}$ Commitment estado de unidade i no momento t				
MD Distância diária probabilística				
$P_{i,t}$ Geração da unidade térmica i no momento t				
$P_{LL,t}$ Poder fluxo na linha l no tempo t				
$R_{i,t}$ Reserve de unidade térmica i no momento t				
RVR Variável aleatória normal padrão, ou seja, uma variável aleatória				
SOC Para o estado de carga de um veículo elétrico				
estacionamento				
Para o estado de carga de um veículo elétrico				
estacionamento				

desvantagens da alta penetração de EVs em sistemas de energia são investigadas em [9,10]. Em [11], um problema de otimização multiprofissional é modelado para a alocação de estações de carregamento de EV nas redes de distribuição. Além disso, os autores em [12] levam um passo adiante e apresentam um modelo de duas etapas para alocar estacionamentos de EV nos sistemas de distribuição considerando perda de energia, confiabilidade da rede e desvio de tensão. Em [13], criar instalações inovadoras de carregamento inteligente com redes de comunicação eficazes entre as concessionárias escoltadas por infraestruturas de controle bem desenvolvidas para a obtenção de estabilidade de grade adequada e utilização adequada de energia. O impacto de diferentes tipos de contrato entre agregadores de EV e seus clientes sobre o comportamento do mercado de energia elétrica e o bem-estar social também são apresentados em [14]. Este artigo analisou os critérios das redes de distribuição, incluindo a melhoria do índice de confiabilidade, a redução de perdas e a otimização de custos. No entanto, o erro de previsão de carga não é considerado nem no modelo de otimização nem na solução de fluxo de energia. Em [3], o agregador de veículos elétricos plug-in (PEV) colaborou com a DISCO para melhorar a confiabilidade do sistema e participou de transações no mercado de energia, considerando os comportamentos de PEVs em relação aos incentivos introduzidos. Em [15], foi fornecida uma revisão abrangente das questões relacionadas à integração em larga escala dos EVs. Aghaei et al. também estudou as capacidades dos EVs como um meio eficaz para facilitar a integração de programas de resposta à demanda e fontes de energia renováveis em sistemas de energia [15]. Em [4], a coordenação horária dos EVs e da geração de energia eólica são levadas em conta para formular um problema de compromisso unitário (SCUC) restrito à segurança. Este artigo utilizou EVs como cargas diferíveis distribuídas para reduzir a volatilidade das gerações de energia eólica. No entanto, os tempos de partida e chegada de EVs são modelados de forma mas também melhora o desempenho dos sistemas de energia, por exemplo, melhoria da confiabilidade por ações preventivas. Uma revisão abrangente da abordagem de séries temporais para previsão de curto prazo é fornecida em [22]. Em [23,24], foram utilizados modelos de rede neural artificial (ANN) e híbridos ARIMA/ANN para prever eficientemente a carga elétrica. De acordo com [25], a avaliação de cinco tipos diferentes de previsão de carga de curto prazo, que utilizaram dados de demanda de dez países europeus, métodos ARIMA e análise de componentes principais (PCA) realizado suficientemente. Uma única previsão de demanda de carregamento de EV baseada em séries temporais esparsas foi proposta em [26]. Este método utilizou aplicativo móvel para a comunicação entre EVs e estações de carregamento. Em [27], abordagens de previsão de carga e seu papel na gestão do lado da demanda foi revisto de forma abrangente. Além disso, o efeito das estações de carregamento rápido na previsão de carga foi estudado em [28]. Korolko et al. utiliza um modelo ARIMA fracionado (fARIMA) para previsão de demanda.

Os EVs que cobram a demanda têm um impacto considerável nos mercados de agendamento de sistemas e eletricidade. O operador do sistema deve considerar a demanda de carregamento de EVs, e sua incerteza para fornecer energia e reserva adequadas para o sistema [4]. Modelo mais preciso e previsão de demanda dos EVs podem potencialmente beneficiar o mercado e diminuir custos reduzindo incompatibilidades entre agendamento diário e operação em tempo real. Os EVs que cobram a incerteza, que é modelada pela função de distribuição neste papel, podem ser usados para agendamento do sistema de energia estocástica.

Este artigo apresenta um modelo autoregressivo de média móvel integrada (ARIMA) para prever o consumo de energia elétrica, incluindo carga elétrica convencional (CEL) e demanda de carregamento de EVs (CDE). No modelo de estacionamento EV proposto, utilizamos a função de densidade de probabilidade (PDF) dos horários de chegada e partida com base nos dados históricos. Para considerar o padrão de condução de diferentes drivers, calcula-se os valores de distância impulsionados esperados utilizando o PDF

determinística. Vale ressaltar que o modelo probabilístico de EV cobrando a demanda e a incerteza da previsão de demanda pode não apenas afetar os procedimentos de tomada de decisão para a operação de sistemas de energia, mas também influenciar problemas de planejamento de sistemas de energia.

A modelagem e o agendamento de demanda de cobrança têm sido investigados na literatura. Em [16], um modelo estocástico de demanda de carregamento de EV foi desenvolvido com base na teoria da fila. Darabi e Ferdowsi propuseram um modelo agregado de EV para prever a demanda total de eletricidade [17]. Este estudo considerou quatro fatores influentes na agregação, ou seja, tipos de EV, distância orientada, nível de carregamento e tempo de partida de carregamento; a natureza estocástica da demanda de carregamento de EV e a incerteza de previsão de demanda são negligenciadas. O impacto da demanda de carregamento dos EVs na rede de distribuição é investigado em [18]. Os dados da Pesquisa Nacional de Viagens Domiciliares (NHTS) são usados para modelar os EVs que cobram demand. Perfis determinísticos de carga elétrica são usados para avaliar o efeito dos EVs em rede de distribuição. Um esquema de gerenciamento de carga inteligente é abordado para coordenação de EVs plug-in em [19]. Este estudo baseia-se na priorização dos fusos horários de sobrecarga e considera os problemas operacionais da rede de energia, por exemplo, os limites de tensão. Os estudos supracitados têm sido focados apenas em EVs cobrando demanda, mas a incerteza da previsão de demanda não foi levada em conta, ou seja, a demanda é assumiu ser determinista.

A utilização dos EVs aumentará a incerteza da demanda de eletricidade, portanto, precisamos de métodos de previsão mais precisos para melhorar a operação e o desempenho do sistema [20]. A média móvel integrada autoregressiva (ARIMA) tem sido amplamente utilizada para fins de previsão de carga [21-25]. Um método preciso de previsão de demanda de curto prazo não só reduz os custos de operação,

dos dados diários de distância. Os parâmetros do modelo ARIMA proposto são ajustados com base nos dados históricos do ponto de carga para manter o erro quadrado médio raiz ideal (RMS). Em relação ao teste χ^2 , o erro RMS permanece constante

para grandes encomendas de modelos Autoregressive (AR). , portanto, concluímos que os valores de erro em dias diferentes não são corrigidos e o erro é um ruído branco. Como o CEL e o CDE podem ter padrões sazonais diferentes, o impacto da demanda de carregamento dos EVs sobre a precisão do preditor de carga proposto é investigado considerando duas estratégias: um preditor cel + CDE agregado e um preditor CEL/CDE dissociado. A saída do preditor proposto, que representa o PDF da demanda prevista, é usada para formular um problema de agendamento baseado no dia-a-dia com restrições à oportunidade em relação às incertezas associadas com CEL e CDE. Nosso foco principal neste artigo é a previsão de demanda para o agendamento de sistemas de transmissão, enquanto temos penetração em larga escala de EVs nos sistemas de distribuição. Assim, modelamos o sistema de distribuição como uma carga e não consideramos seu modelo detalhado. O fluxograma da série temporal baseada em ARIMA, que prevê a operação do sistema de energia estocástica, é ilustrado em Fig. 1. Observe que o quadro detalhado do preditor proposto está fornecido na Fig. 2.

Dois sistemas de teste (sistemas de teste de 6 barramentos e IEEE de 24 barras) são usados para mostrar a eficácia do preditor proposto para o agendamento do sistema de energia. Para validar a proficiência do preditor para o agendamento do dia anterior, o sistema de energia é reagendado em operação em tempo real utilizando os dados históricos (reais) e o custo de reagendamento é avaliado.

O resto deste trabalho é organizado da seguinte forma. O modelo de previsão de demanda baseado em ARIMA proposto é apresentado na Seção

2. A Seção 3 formula um agendamento estocástico no mercado. Os resultados numéricos são ilustrados na Seção 4, seguidos de conclusões.

2. A metodologia de previsão de demanda proposta

O preditor de demanda baseado em ARIMA é apresentado nesta seção que é capaz de alcançar uma previsão de demanda altamente precisa.

2.1. Média móvel integrada autoregressiva

Para introduzir o preditor ARIMA, precisamos formular a série temporal com base na resolução de tempo dos dados históricos. De acordo com a disponibilidade dos dados históricos, podemos formular o preditor ARIMA para várias etapas do tempo. Suponha que o valor médio da demanda no k th day para o b th bus é mostrado pela D_k .

b, t

A série temporal é construída para o décimo dia usando $ARIMA(N, d, 0)$ como mostrado em (1).

$$\left(1 - \sum_{q=1}^N a_q(L)^q\right) (1-L)^d D_k = \varepsilon_t \quad \forall t = N+d, N+d+1, \dots, b, t, b, t \quad (1)$$

onde N e D são as ordens auto-regressivas e integradas do modelo ARIMA, respectivamente. a_q representa os parâmetros da parte autoregressiva do modelo. L é o operador de lag em séries temporais. f tais que $L^q f = f_{t-q}$. Based on (1), we can represent the demand D_k for the t th time period

$$D_k = \sum_{i=1}^D \varepsilon_{t-i} + \varepsilon_t, \quad \text{onde}$$

D_k is the demand expected of bus b at hour t on day k , and ε_t represents the error of prediction corresponding.

Como aplicação do preditor baseado em ARIMA proposto, planejamos usar a demanda prevista para problemas de agendamento estocásticos para que, neste artigo, o prazo e o tempo passo são um dia e uma hora, respectivamente. Observe que nosso preditor proposto não se limita a um passo específico.

2.2. Previsão da demanda de eletricidade

Fig. 2 mostra a estrutura de três etapas da previsão de demanda baseada em ARIMA. Uma vez que o erro de quadrado-médio raiz (rms) permanece constante para grandes ordens auto-regressivas, em relação ao teste t , nós

concluir que os valores de erro em dias diferentes não são corrigidos e, portanto, o erro é um ruído branco. Portanto, se $ARIMA(N, d, 0)$ for usado para fins de previsão, então o erro de previsão é o ruído branco gaussiano (GWN). Em outras palavras, o processo aleatório f_t é um GWN de variância σ^2 , ou seja, $f_t \sim GWN(\sigma^2)$. Equivalentemente podemos dizer

$f_t \sim N(0, \sigma^2)$ para cada t . Observe que o erro mínimo obtido de RMS

é o desvio padrão.

A abordagem proposta ajusta os parâmetros do modelo ARIMA com base nos dados históricos nas três etapas seguintes:

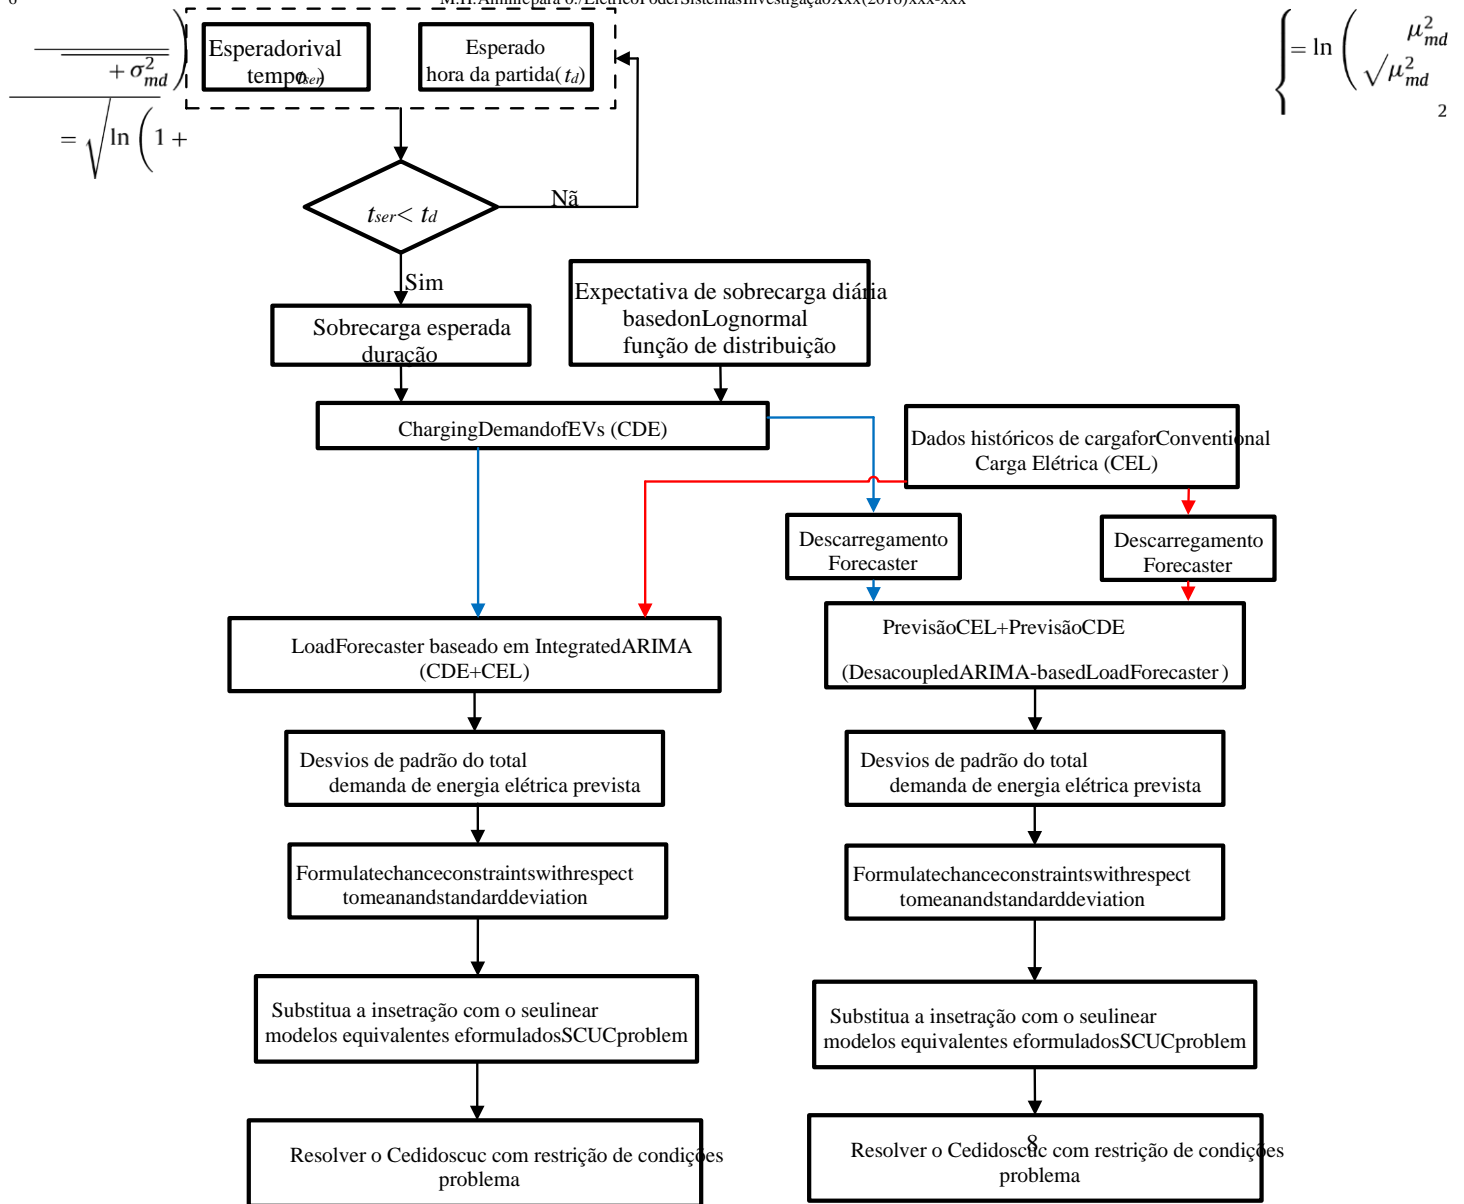
- Encontrar a ordem de integração ideal entre três valores, 1, 2 e 3. Na previsão de carga para a maioria dos casos $d = 1$ é a ordem de integração ideal.
- Determinação da ordem auto-regressiva adequada com base no número total de dias disponíveis a partir dos dados históricos.
- Cálculo do erro quadrado médio para obter o desvio padrão do ruído gaussiano branco.

2.3. Veículo elétrico (EV) modelo de demanda de carregamento

2.3.1. Modelagem de estacionamentos EV probabilísticos

A demanda de carregamento de EVs é obtida utilizando-se dois parâmetros probabilísticos: (1) distância esperada e (2) duração esperada do carregamento.

- Distância esperada: Neste estudo, nosso objetivo é estimar a carga elétrica do dia a dia, considerando a integração em larga escala dos EVs. Para estimar o consumo de energia



O 1. Fluxograma do proposto método. de EVs, nós usar reportado combustível economia Valores e histórico diariamente impulsionado distância De [29]. Lognormal distribuição função é utilizado Paragerar probabilístico diário impulsionado distância denotado como MD [29].

(3)

$$MD = \mu_m + \sigma_m RVR \quad (2)$$

onde o RVR é um valor normal normal (um RV normal com média de zero e uma variância de um), μ_m e σ_m são os parâmetros de distribuição lognormal e são obtidos com base na variação média e padrão do Md utilizando os dados históricos, denotados como μ_{md} e σ_{md} , respectivamente [30,31].

$$MD = \mu_m + \sigma_m RVR$$

Com base nos dados históricos de distância de condução em [31], μ_{md} e σ_{md} são considerados de 40 milhas e 20 milhas, respectivamente. Distância máxima de condução com uma bateria totalmente carregada,

denotado por MD, é calculado em (4).

$$= \frac{MD}{C_b} \quad (4)$$

Eme

onde E_m é o consumo de energia por milhas dirigida, e C_b denota a capacidade máxima da bateria. A demanda energética esperada do EV é calculada como mostrado em (5) [31]. E... CMD_b ; $\cdot E$; $MDMD <=$

$$(5) d = \frac{MDMD}{m}$$

- (2) Também consideramos a duração de carregamento esperada como um parâmetro eficaz que depende da taxa de carregamento (chr), da capacidade da bateria (C_b), bem como da chegada probabilística (a_r) e horários de partida (a_d). Para obter o tempo de chegada e o horário de partida, as distribuições gaussianas são usadas como a melhor estimativa

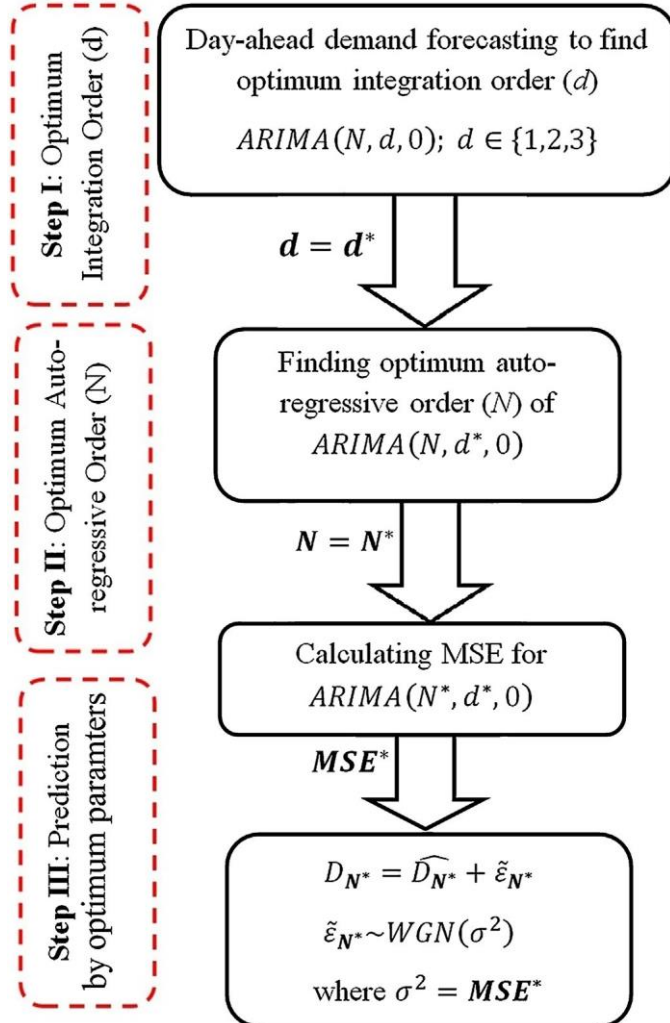


Fig. 2. Quadro de três etapas da previsão de demanda baseada em ARIMA.

de comportamento aleatório do consumidor residencial. Os horários probabilísticos de chegada e partida são determinados como:

$$\tau_{ar} = \mu_{ar} + \sigma_{ar} \cdot RV_1$$

$$\tau_d = \mu_d + \sigma_d \cdot RV_2 \quad (6)$$

onde RV_1 e RV_2 representam duas variáveis aleatórias normalmente distribuídas, μ_{ar} e μ_d mostram o desvio médio e padrão do a_r com base nos dados históricos, σ_{ar} e σ_d são médias e variação padrão do tempo de partida, respectivamente. Os horários de chegada e partida precisam satisfazer a seguinte desigualdade: $\tau_d > \tau_{ar}$. Se essa restrição não estiver satisfeita, outro conjunto de horários de partida e chegada deve ser gerado. Após a geração dos tempos de chegada e partida probabilísticos viáveis, a duração de carregamento probabilístico de cada EV pode ser calculada como:

$$d_{duro} = d - \tau_{ar} \quad (7)$$

Eventualmente, a demanda de carregamento de each EV pode ser calculada em termos de estado de carga esperado (SOC) usando (8).

$$SOC = \frac{\min(SOC_0, C_b - E_d) + \tau_{ar} \cdot chr}{C_b} \quad (8)$$

bb

Tabela 1

Especificações das classes EV.

Classe EV	C_b (kWh)	E_m (kWh/milha)	Market share, ϕ_v (%)
1	10	0.3790	20
2	12	0.4288	30
3	16	0.5740	30
4	21	0.8180	20

Tabela 2

Taxas de carregamento.

Modo de carregamento	Taxa de carregamento (chr)a
Carregamento lento	0.1
Carregamento médio	0.3
Carregamento rápido	1.0

a) taxa de carregamento são dadas na capacidade da bateria por hora.

2.3.2. Exemplo ilustrativo

As Tabelas 1 e 2 representam as características de diferentes tipos de EVs e diferentes taxas de carregamento disponíveis, respectivamente. Os parâmetros fornecidos na Tabela 1 são extraídos de [31]. As classes EV 1, 2, 3 e 4 referem-se a micro carro, carro econômico, carro de médio porte e caminhão leve/SUV, respectivamente.

Aqui, consideramos dois casos para avaliar o efeito da taxa de carregamento e diferentes tipos de EV sobre a demanda de carregamento.

Caso 1: Para um estacionamento com capacidade de 100 EVs, avaliamos o efeito de diferentes taxas de carregamento sobre a demanda total de carregamento. Observe que a participação de mercado de diferentes tipos de EVs é usada com base na Tabela 1. O efeito de diferentes taxas de carregamento sobre a demanda total de carregamento é apresentado na Fig. 3.

Caso 2: Para uma taxa de carregamento fixa de 0,3, e capacidade fixa do estacionamento de 100 EVs, comparamos o efeito da capacidade da bateria na demanda total de carregamento utilizando nossa Modelo de estacionamento EV. Quatro taxas de penetração em comparação com as ações reais do mercado representadas na Tabela 1, e são mostradas na Tabela 3.

Fig. 4 mostra a demanda de carregamento para os cinco cenários especificados na Tabela 3.




Fig. 3. O efeito da taxa de carregamento sobre a demanda de energia de carregamento de EV.

Tabela 3
Especificações detalhadas dos cinco cenários avaliados.

Cenário índice	Mercadoações deCA Tipos(%)				Total diárioCarregame procuraçã(Kwh)
	92	93	94	91	
Cenário base 20 30 30 20 982					
S-I 80 10 5 829 S-II 10 80 5 857 S-III 5 5 80 10 1091					
S-IV	5	5	10	80	1361




Fig. 4. Cobrando demanda por diferentes taxas de penetração de tipos de EV.

3. Aplicação da abordagem de previsão proposta no agendamento estocástico do dia-a-dia

As funções de distribuição de probabilidades fornecidas pelo preditor ARIMA proposto são usadas no problema de agendamento do dia-a-dia. As

saídas da abordagem de previsão proposta também podem ser utilizadas em muitos problemas de operação/planejamento de sistemas de energia. Neste artigo, utilizamos uma formulação estocástica de SCUC para mostrar como as saídas do preditor proposto são utilizadas. Pode-se facilmente seguir um procedimento semelhante e usar as saídas da abordagem de previsão proposta para outros fins de operação/planejamento. O compromisso unitário com restrição de segurança (SCUC) é um dos processos de tomada de decisão mais importantes no agendamento diário [32,33]. Nesta seção, um problema estocástico de SCUC é formulado usando as saídas de previsão ARIMA. A função objetiva é minimizar o custo de produção e os custos de inicialidade/desligamento das unidades geradoras da seguinte forma:

$$\text{Min} \sum_t \sum_i F_{i,t} \quad \forall t, \forall i$$

O primeiro termo da função objetiva é o custo de produção das unidades geradoras, e o segundo prazo é o custo inicial/desligamento da unidade ao longo do agendamento horizonte (por exemplo, 24 h).

Além da incerteza das cargas convencionais que é considerada em [33-35], também levamos em conta o comportamento estocástico dos veículos elétricos, ou seja, consideramos o seguinte parâmetros: (1) distância diária esperada com base nos dados históricos e (2) tempo probabilístico de chegada/partida. Em [34,35], a simulação de Monte Carlo é implantada para modelar os cenários e, em seguida, o problema de comprometimento da unidade estocástica de segurança é resolvido. Neste artigo, utilizamos otimização com risco para resolver o problema do SCUC. Utilizando as funções de distribuição de probabilidades determinadas pelo preditor ARIMA para demanda de eletricidade e consumo de energia EV, as restrições de otimização são formuladas como em (10)–(18). As restrições (10)–(16) são deterministas, e (17) e (18) são restrições estocásticas sendo modeladas como restrições por acaso.

$$(X_{i,t-1}^{on} -$$

$$\left(I_{i,t} - I_{i,t-1} \right) \geq \forall i, \forall t \quad (10)$$

$$R_{i,t} = I_{i,t} - I_{i,t-1} \quad \forall i, \forall t \quad (11)$$

$$P_{i,t} - P_{i,t-1} \leq R_{i,t} + M(2 - I_{i,t-1} - I_{i,t}) \quad \forall i \quad (12)$$

$$P_{i,t-1} - P_{i,t} \leq R_{i,t} + M(2 - I_{i,t-1} - I_{i,t}) \quad \forall i \quad (13)$$

$$T_{i,t} (14) \quad I_{i,t-1} - I_{i,t} \geq 0 \quad \forall i, \forall t \quad (15) \quad \text{off}$$

$$\left(X_{i,t-1}^{off} - \sum_b P_{i,t} = \sum_b D_{i,t} \right) \quad \forall i, \forall b \quad (16)$$

$$\Pr \left\{ \sum_{\forall i} (P_{i,t} + R_{i,t}) \geq \sum_{\forall b} (D_{b,t} \geq_t \forall t \right\} \quad (17)$$

$$- \left\{ -PL_l \leq \sum_{\forall i} PrSFL_{i,l} \cdot P_{i,t} - \sum_{\forall b} SFL_{b,l} \cdot D_{b,t} \leq \overline{PL}_l \right\} \geq \quad \forall l, \forall t \quad (18)$$

onde (10) representa faixa superior e inferior de saída de energia das

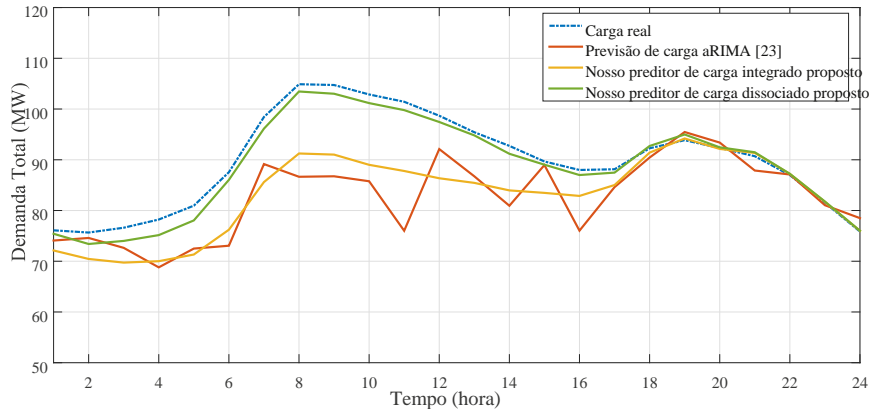


Fig. 5. Comparação dos métodos integrados e dissociados [23].

unidades geradoras; restrição de igualdade (11) é a reserva fornecida pelas unidades geradoras; unidades que aumentam e descem os tempos são impostas por (12) e (13); as restrições mínimas de tempo para cima/para baixo são formuladas por (14) e (15). A restrição da igualdade (16) é a restrição do equilíbrio de poder. Observe que o valor esperado das variáveis estocásticas determinadas pelo preditor de carga baseado em ARIMA proposto, a demanda de eletricidade e o consumo de energia dos EVs, são utilizados nesta restrição. Como pode haver desvio dos valores esperados na operação do sistema em tempo real, a restrição de chance (17) é formulada para garantir a disponibilidade da reserva giratória adequada durante o despacho em tempo real. O nível de confiança dessa restrição de chance no momento é denotado por α_t . A segurança da rede é levada em conta pela restrição por acaso (18). Essa restrição garante que o fluxo de energia na linha l no momento t esteja dentro do seu limite com um nível de confiança pré-especificado.

Deve-se notar que α_t e l_t precisam ser adequadamente definidos pelo operador para fazer uma troca entre economia e confiabilidade de a operação do sistema [36].

3.1. Modelo determinístico das restrições de chance

Para resolver o problema de agendamento acima mencionado, as restrições de chance precisam ser substituídas pelo seu modelo determinístico equivalente. O operador do sistema precisa conhecer os PDFs dos parâmetros/variáveis estocásticos para formular o modelo equivalente determinístico de restrições de chance. O preditor os PDFs de EVs cobrando energia elétrica da seguinte forma:

$$D_{b,t} = D_{\dots b,t} + \varepsilon_{b,t} \quad \forall b, \forall t \quad (19) \quad \left. \begin{matrix} 2 \\ 0.5 \end{matrix} \right\}$$

onde:

$$\varepsilon_{b,t} \sim N(0, \sigma_{b,t}^2) \quad \forall b, \forall t$$

Em (19), $D_{\dots b,t}$ é o valor esperado da demanda de energia elétrica, incluindo o valor esperado do consumo de energia dos EVs, no ônibus b , a hora t .

Variância $\sigma_{b,t}^2$ 2modelos os erros de previsão. Usando valores esperados e

variâncias, as restrições de chance (17) e (18) podem ser convertidas para a seguinte restrição de desigualdade linear [36-38].

0. 5

$$\sum_{\forall i} (P_{i,t} + R_{i,t}) \geq \sum_{\forall b} D_{b,t} + Z_{t,l} \quad \forall t \quad (20)$$

$$SFL_{i,l} \cdot P_{i,t} - \sum_{\forall b} P_{i,t} SFL_{b,l} \cdot \left[\sum_{\forall b} D_{b,t} + Z_{t,l} \right] \leq PL_l \quad \forall l, \forall t \quad (21)$$

Observe que os desvios padrão das funções de distribuição de probabilidades influenciam diretamente o agendamento ideal para o dia-a-dia. Um desvio padrão maior resulta em ter um conjunto de restrições mais restritas, (20) e (21), e, como consequência, aumenta o custo operacional total. Quanto menores forem os desvios padrão, menor será o custo operacional. Além disso, ter previsões mais precisas reduz os custos de reagendamento, que são necessários para compensar os desvios entre

Tabela 4

Valores MAPE e MAE para três diferentes abordagens de previsão.

Método	MAPA	MAE (MW)
CDE, método de previsão de [23] (CEL + carga baseado em ARIMA)	8.04%	7.553
Nosso método integrado de previsão de carga (CEL + CDE)	7.25%	6.078
Nosso (CDE + CEL) método de previsão de carga dissociado proposto	1.44%	1.277

os valores pré-programados (potência produzida por unidades geradoras) no mercado futuro e na operação em tempo real. Portanto, o preditor ARIMA (que define o valor médio e o desvio padrão) desempenha um papel importante no custo operacional total no problema de agendamento diário.

Deve-se notar que os valores esperados fornecidos pelo modelo ARIMA são utilizados na restrição de equilíbrio de energia (16).

4. Resultados numéricos

Em primeiro lugar, fornecemos as métricas de desempenho para medir a precisão da abordagem de previsão proposta. Os resultados são comparados com o preditor ARIMA usado em [23]. Em seguida, a eficácia do preditor ARIMA proposto e seu impacto no agendamento do sistema que vem no dia seguinte são estudados em um sistema de seis ônibus e no IEEE 24-bus test systems. Em um primeiro momento, são definidos os estacionamentos EV cobrando parâmetros de demanda. Um conjunto de demanda de carregamento é gerado com base nos parâmetros históricos. Com base nos dados gerados e nos dados históricos de carga medidos da PJM, a carga é prevista utilizando duas estratégias diferentes como explicado acima: o CEL + CDE agregado e o dissociado CEL/CDE. Em seguida, o agendamento diurno estocástico é implementado utilizando os dados previstos dessas duas estratégias de previsão. Note-se que, para enfatizar e destacar as diferenças entre os preditores integrados e dissociados, consideramos uma penetração de demanda de carregamento de energia de 10% EV. Além disso, a operação do sistema em tempo real é realizada com os dados históricos reais. Avalia-se os custos de reagendamento tanto das estratégias de previsão dissociadas quanto integradas. O código de software é escrito no MATLAB, e os cálculos são realizados usando caixa de ferramentas YALMIP [39] e ILOG CPLEX 12.4s MIQP solver em um solucionador de 3,1 GHz computador pessoal.

Tabela 5 Dados do gerador .

Unidade	p _{max} (MW)	p _{min} (MW)	a (MBtu)	b (MBtu/MWh)	c (MBtu/(MW2 h))	T _{off} (h)	T _{on} (h)	RU (MW/h)	RD (MW/h)
1	220	40	100	7	0.03	4	4	100	100
2	100	10	104	10	0.07	2	3	50	50
3	100	0	110	8	0.05	2	2	50	50

4.1. Avaliação de desempenho da abordagem de previsão proposta

Para validar a precisão do preditor proposto, utilizamos duas métricas amplamente utilizadas na literatura, erro percentual absoluto (MAPE) e erro absoluto médio (MAE). Essas métricas são definidas respectivamente em (22) e (23).

$$= \sum_{i=1}^{N_f} \text{MAPE}_i$$

(22)

MAEwhere

$$eN= \left\| L^r - L^f \right\|_1 = \sum_{i=1}^N \left| L^r_i - L^f_i \right|$$

/ L Li , e N denotaram o período de previsão. (23)

$$= \frac{1}{N} \sum_{i=1}^N \left| L^r_i - L^f_i \right|$$

Utilizamos os dados de carga PJM para destacar a melhoria de desempenho do preditor utilizado, e comparamos com os preditores apresentados em [23]. O número de EVs integrados é de 12.000, com uma taxa de carregamento de 0,3 da capacidade da bateria por hora. A demanda média de carga é de 80 MW. O perfil de carga é extraído dos dados de carga medidos por hora da PJM, reduzindo a carga total para obter a demanda média mencionada. Em nosso estudo, o período de previsão é de 24 h (Nf = 24).

A Tabela 4 representa os valores MAPE e MAE para os três casos para validar a eficácia da abordagem dissociada proposta em comparação com nossa abordagem integrada e a previsão baseada em ARIMA método apresentado em [23].

De acordo com os resultados, a precisão do preditor integrado proposto é melhorada. Além disso, observa-se uma redução considerável de erros para o prognóstico de carga dissociado. Os perfis de carga previstos dos três casos comparados são apresentados na Fig. 5.

4.2. Caso 1: o sistema de teste de 6 barramentos

O sistema de teste de 6 barramentos tem 3 unidades de geração, 7 linhas e 3 pontos de carga, como mostrado na Fig. 6. As características das unidades de geração e as informações da rede são dadas nas Tabelas 5 e 6, respectivamente. As cargas 3, 4 e 5 consomem 20%, 40% e 40% da demanda total de energia do sistema, respectivamente. Neste estudo de caso, assumimos que temos estacionamentos EV nos ônibus 3, 4 e 5. O número de




Fig. 6. Topologia do sistema de teste de 6 ônibus.

Tabela 6 Informações da rede .

De ônibus	Para ônibus	X (pu)	Limite de fluxo (MW)
1	2	0.170	200
1	4	0.258	200

2	3	0.037	190
2	4	0.197	200
3	6	0.018	180
4	5	0.037	190
5	6	0.140	180

Tabela 7				
Padrão de condução		parâmetros [31].		
Parâmetro	seria	seria	d	d
Valor	7	1.73	18	1.73

Os EVs no barramento 3 são de 10.000 EVs com a taxa de carregamento de 0,3 capacidade de bateria por hora. O número de EVs nos ônibus 4 e 5 é de 12.000 com taxa de carregamento de 0,3 capacidade de bateria por hora.

4.2.1. Previsão da demanda de eletricidade

A Tabela 7 representa os valores típicos para parâmetros da função de distribuição de probabilidade de padrão de condução com base em dados históricos do padrão de condução [31,40,41].

Os valores típicos desses parâmetros estatísticos são extraídos de [31], como mostrado na Tabela 7. Figs. 7 e 8 representam os resultados da previsão de demanda tanto para CEL quanto para CDE no primeiro ponto de carga

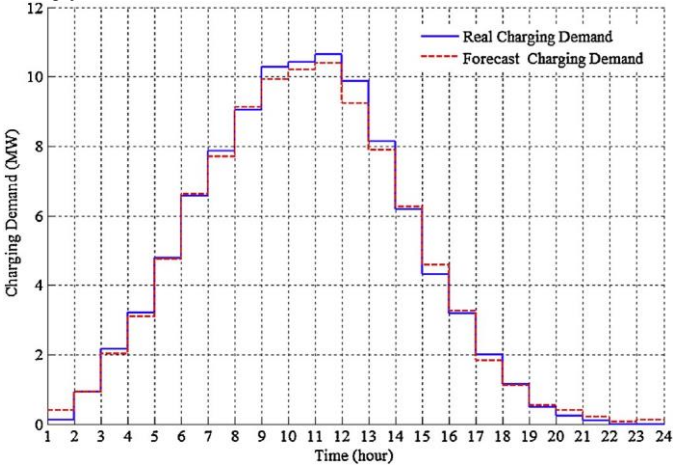


Fig. 8. CDE previsto para o ônibus 3.

(ônibus 3). Note-se que a carga total no sistema de teste de 6 ônibus analisado é de 210 MW que é alocado para os ônibus. Note-se que, para enfatizar e destacar as diferenças entre os preditores integrados e dissociados, consideramos 10% de penetração da demanda de carregamento de energia EV, ou seja, a área abaixo da demanda de carga convencional ao longo de um dia é de 10% da área abaixo da curva de demanda de carregamento EV durante o mesmo período de tempo.

De acordo com figs. 7 e 8, a demanda prevista antes da integração de EV (CEL) e dos estacionamentos que cobram demanda (CDE) são representadas, respectivamente. Para encontrar a carga prevista integrada, adicionamos \widehat{CDE} o \widehat{CEL} para cada slot de tempo. Fig. 9 mostra os resultados da previsão de demanda dissociada obtida adicionando o CDE

$$\widehat{CDE} + \widehat{CEL}$$

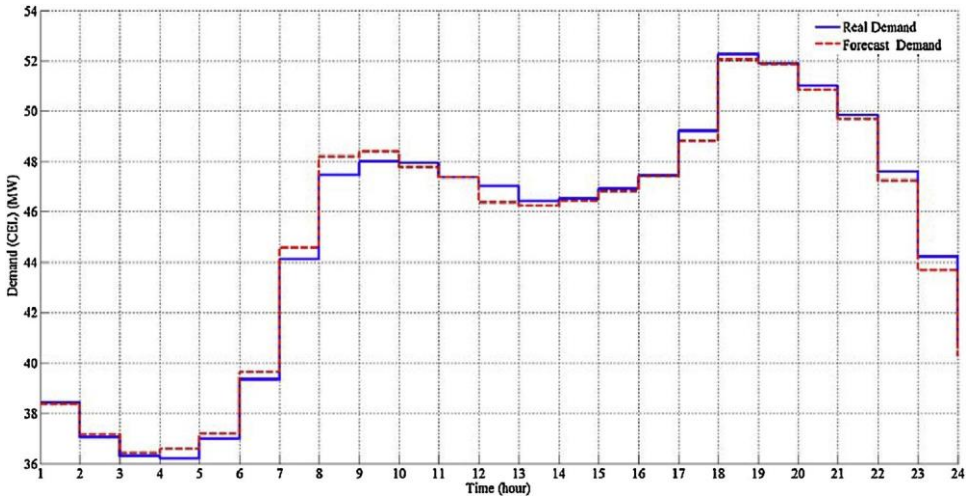


Fig. 7. Precisão CEL para ônibus 3.

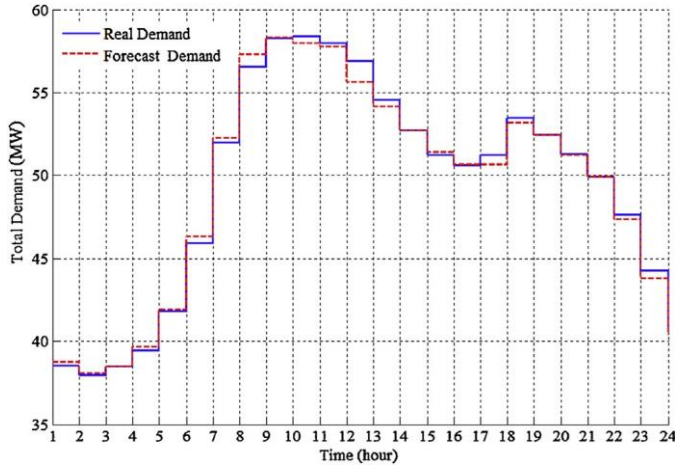
previsto ao CEL previsto, ou seja,

No entanto, a previsão dissociada do CEL e do CDE leva a valores aceitáveis de desvio padrão, e a previsão integrada também foi implementada para destacar o desempenho superior ao desacoplado proposto previsão.

Fig. 10 demonstra os resultados da previsão integrada de CEL e CDE, ou seja, CEL CDE para o ônibus 3. De acordo

com esse número, a abordagem de previsão integrada aumentará

dissociados foi plotado para número diferente de EVs. **Fig. 11** representa



consideravelmente o erro. A natureza diferente da demanda de carregamento de EV e da demanda convencional de eletricidade é a importante razão para essa diferença notável, ou seja, o CDE tem padrão de carga diário enquanto o CEL segue um padrão sazonal.

Fig. 9. Previsão CEL + CDE previsto para o ônibus 3.

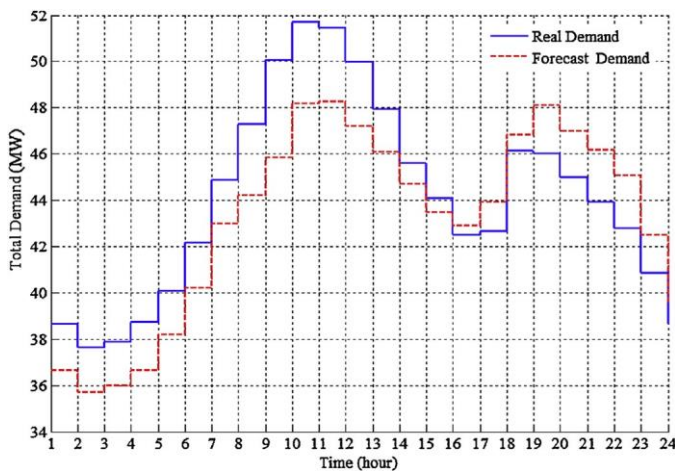



Fig. 10. Previsão CEL + CDE (+ CELCDE) para o ônibus 3.

Para investigar o efeito do número de EVs utilizados no erro quadrado médio de previsão (MSE), o erro MSE para métodos integrados e



O 12. Avaliar o efeito de integração ordenemo previsão exatidão.

EVs e termos do MSE ValoresDaqui De o procuraçãorevisão os resultados no ônibus 1.

Segundo Para este figura o Dissociados previsão abordagem supera o integrado previsão durante todo Analisados Números de ponto de vista o Dissociados previsão método É mais preciso. Doravante nós avaliar o efeito de estesDoisestratégias de previsão em o estocástico operação de poderSistemas pordadoDoisdiferentetesteSistemas.

Aqui avaliamos o efeito da sintonia de parâmetros na precisão do preditor ARIMA. Para isso, realizamos análises de sensibilidade nos parâmetros de ordem autoregressiva e de integração e fornecemos os resultados. O modelo ARIMA utilizado é diferente dos modelos ARIMA anteriores em termos de ajuste dos parâmetros para melhorar o desempenho do nosso preditor que é aplicável ao carregamento de EV previsão de demanda. A principal razão para melhorar a precisão da previsão é utilizar a estratégia de previsão dissociada.

Como foi mostrado em **Fig. 2**, ajustamos a ordem autoregressiva e a ordem de integração como duas etapas para a sintonia dos parâmetros para melhorar a precisão do modelo ARIMA. **Fig. 12** mostra o efeito do ajuste da ordem de integração, d , na precisão de previsão. Os valores do MSE para $d = 1$, $d = 2$ e $d = 3$ são 0,037, 0,043 e 0,138, respectivamente. Observe que esses resultados são baseados em dados de carga normalizados na escala unitária, ou seja, a média do conjunto de dados utilizados é dimensionada para um, a fim de facilitar a comparação entre casos diferentes.

Como este número mostra, diferentes valores de ordem de integração levarão a diferentes níveis de precisão de previsão. Assim, ajustamos d avaliando os três valores mencionados e escolhemos aquele com menos erro. Também avaliamos o efeito da ordem autoregressiva na precisão de força, alterando o valor de N de 20 para 90. **Fig. 13** representa os resultados.

Dos resultados de **Figs. 8 e 9**, pode-se ver utilizando parâmetros sintonizados para a previsão de ARIMA aumentará significativamente a precisão.

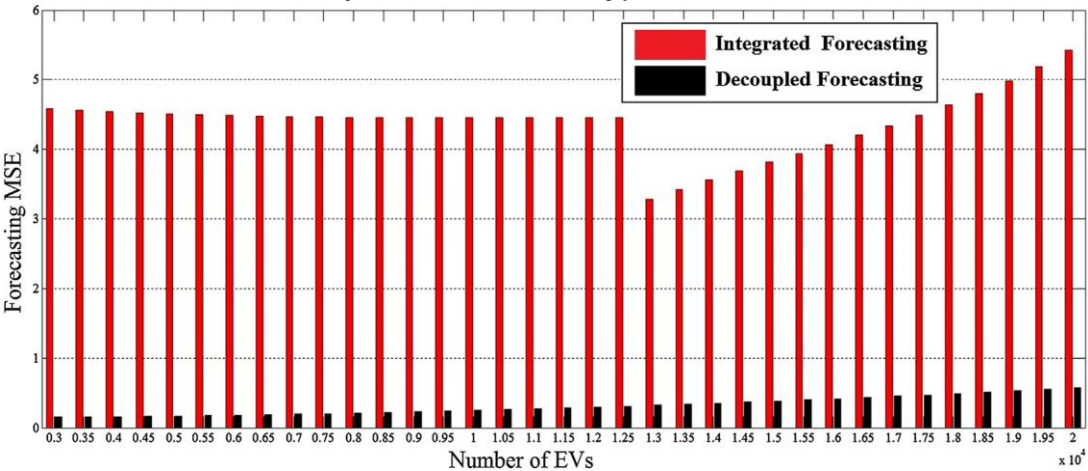


Fig. 11. Previsão de MSE para métodos integrados e dissociados.

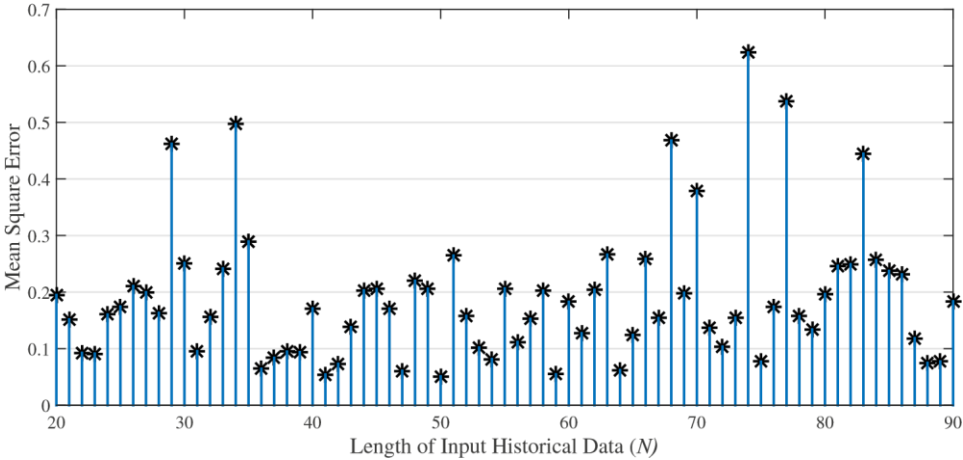


Fig. 13. Avaliando o efeito da ordem autoregressiva na precisão da previsão.

Tabela 8
Solução uc para a estratégia de previsão agregada CEL + CDE.

Unidades	Horas (1-24)																							
1	11		1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	
2	0	0	0	0	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	0	0	
3	11		1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	

Tabela 9 Despacho de geração day-ahead (MW) para a estratégia agregada CEL + CDE.			
Hora	Unidade1	Unidade2	Unidade3
1	130.60	0	68.36
2	129.69	0	67.81
3	130.94	0	68.56
4	137.71	0	72.62
5	142.79	0	75.68
6	133.96	35.98	70.38
7	153.57	44.39	82.14
8	161.13	47.63	86.68
9	160.12	47.19	86.07
10	149.81	42.78	79.89
11	150.04	42.87	80.02
12	141.91	39.39	75.15
13	139.74	38.46	73.84
14	137.58	37.54	72.55

15	132.49	35.35	69.50
16	130.98	34.71	68.59
17	132.81	35.49	69.69
18	136.94	37.26	72.16
19	138.36	37.87	73.01
20	133.65	35.85	70.19
21	133.92	35.97	70.35
22	130.74	34.60	68.44
23	136.41	0	71.85
24	132.31	0	69.39

4.2.2. Agendamento diário

O problema de agendamento estocástico é resolvido utilizando-se a demanda de carga elétrica convencional prevista e de carregamento de EVs, ou seja, funções de distribuição de probabilidades obtidas pelo modelo ARIMA proposto em a seção anterior. Os níveis de confiança (α e 21) de ambas as restrições de chance (20) e (21) estão definidos para 99%

Tabela 10

Solução de UC para a estratégia de previsão cel/CDE dissociada.

Unidades	Horas (1-24)																						
1	11	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
2	0	0	0	0	0	1	1	1	1	1	1	1	1	1	1	1	1	1	1	0	0	0	0
3	11	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1

(99% e 95% são geralmente utilizados na literatura para o nível de confiança).

Estratégia um: SCUC com os dados agregados de previsão cel + CDE

(+ CEL CDE). Os resultados de compromisso unitário e despacho de geração para a estratégia de previsão agregada CEL + CDE são mostrados nas Tabelas 8 e 9. O gerador 2, que é uma unidade cara, está desligado durante o horário de carga fora do pico. Este gerador está comprometido a ficar desligado em 7 horas (horas 1, 2, 3, 4, 5, 23, 24). Os outros dois geradores estão empenhados em estar sempre ligados para suportar a demanda de energia no horizonte de agendamento (ou seja, 24 h). O custo total de agendamento do dia anterior é de US\$ 73.244.

Estratégia dois: SCUC com os dados de previsão cel/CDE dissociados

Resolvemos o SCUC usando a estratégia de previsão cel/CDE dissociada. Os resultados do status da unidade e da expedição de geração estão representados na Tabela 10 e na Tabela 11, respectivamente. Semelhante ao Caso A, as unidades geradoras 1 e 3 estão sempre ON, e a unidade 2 está ON quando a demanda de energia está próxima dos horários de pico. No entanto, a unidade geradora 2 está comprometida a estar off na hora 22 ao contrário do Caso A onde esta unidade está ON. Além disso, os resultados de expedição de geração do Caso B são diferentes dos que determinaram no Caso A. O custo total de agendamento diário neste caso é de US\$ 71.819, us\$ 1.425 a menos do que o obtido no Caso A. Essas observações ilustram a diferença entre a carga horária prevista pelo CEL/CDE dissociado e os preditores agregados baseados em CEL + CDE ARIMA.

4.2.3. Reagendamento do sistema em tempo real

Devido ao erro entre a previsão de carga diária e o consumo real de energia em tempo real, o operador precisa reagendar o sistema (modificar a saída das unidades geradoras determinada no dia seguinte agendamento) para equilibrar a geração e o consumo de energia. Nós usamos o verdadeiro horário convencional elétrico

Tabela 11

Despacho de geração day-ahead (MW) para a estratégia de previsão cel/CDE dissociada.

Hora	Unidade1	Unidade2	Unidade3
1	126.87	0	66.12
2	127.76	0	66.66
3	130.45	0	68.27
4	133.98	0	70.39
5	140.05	0	74.03
6	131.41	34.89	68.85
7	146.06	41.17	77.63
8	157.26	45.97	84.35
9	153.64	44.42	82.18
10	150.89	43.24	80.53
11	148.74	42.32	79.24
12	143.18	39.93	75.91
13	138.60	37.97	73.16
14	137.79	37.63	72.68
15	132.12	35.19	69.27
16	131.33	34.85	68.80
17	130.14	34.35	68.08
18	135.24	36.53	71.14
19	138.11	37.76	72.87
20	134.00	36.00	70.40
21	131.14	34.78	68.69
22	149.94	0	79.96

23	134.75	0	70.85
24	126.24	0	65.74

demanda de carga e carregamento de dados de EVs (dados históricos) para avaliar os requisitos para o reagendamento do sistema. Dois tipos diferentes de agendamento diurno são realizados: (1) utilizando o preditor agregado baseado cel + CDE ARIMA (CEL + CDE) e (2) $\widehat{CEL} + \widehat{CDE}$, usando o is and the reagendamento do sistema realizados para ambas as estratégias, os resultados são mostrados nas Tabelas 12 e 13. O custo total de reagendamento resultante da estratégia de previsão cel + CDE agregada ao longo do horizonte de 24 horas é de \$2100. O custo total de reagendamento da estratégia dissociada sobre o horizonte de 24 horas é de \$1384. Os resultados da reagendamento para rede de testes de 6 ônibus estão representados na Tabela 14.

Os custos totais do agendamento diário e reagendamento do sistema em tempo real usando a estratégia agregada é de US\$ 75.344. São US\$ 73.203 quando o operador usa os dados obtidos pelo dissociado

Tabela 12

Despacho de geração em tempo real (MW) para estratégia de previsão de CEL + CDE agregada.

Hora	Unidade1	Unidade2	Unidade3
1	123.54	0	64.12
2	123.43	0	64.05
3	125.41	0	65.24
4	128.55	0	67.13
5	135.50	0	71.30
6	127.08	33.03	66.24
7	141.41	39.18	74.85
8	149.11	42.48	79.47
9	148.45	42.19	79.07
10	145.73	41.03	77.44
11	143.32	39.99	75.99
12	139.08	38.18	73.45
13	135.64	36.70	71.39
14	131.76	35.04	69.06
15	128.89	33.81	67.33
16	127.13	33.05	66.28
17	128.02	33.43	66.81
18	133.78	35.91	70.27
19	134.66	36.28	70.80
20	132.16	35.21	69.29
21	129.79	34.19	67.87
22	124.32	31.85	64.59
23	134.08	0	70.45
24	124.62	0	64.77

Tabela 13

Despacho de geração em tempo real (MW) para a estratégia de previsão cel/CDE dissociada.

Hora	Unidade1	Unidade2	Unidade3
1	123.54	0	64.12
2	123.43	0	64.05
3	125.41	0	65.24
4	128.56	0	67.13
5	135.50	0	71.30
6	127.08	33.03	66.24
7	141.41	39.18	74.85

M.H.Aminiepara o./ElétricoPoderSistemasInvestigaçãoXxx(2016)xxx-xxx						15
8	149.12	42.48	79.47	Tempo de execução (s)		4
9	148.45	42.19	79.07			
10	145.73	41.03	77.44	Custo diário (\$)	4	2,030,868
11	143.32	39.99	75.99			
12	139.08	38.18	73.45		2,764,262	2,613,868
13	135.65	36.70	71.38	Custo de reagendamento (\$)	150,394	73,836
14	131.77	35.04	69.06	Custo total do sistema = Day-ahead +		2,104,704
15	128.89	33.81	67.33	Custo de reagendamento (\$)		
16	127.13	33.05	66.27	Semelhante ao Caso 1, também realizamos o reagendamento do sistema		
17	128.02	33.43	66.81	Caso 2. Os custos de reagendamento de ambas as estratégias de previsão são		
18	133.78	35.91	70.27	mostrados na Tabela 15. Esta tabela também mostra os custos operacionais		
19	134.67	36.28	70.80	diários totais (custo de agendamento diário + custo de reagendamento por hora)		
20	132.16	35.21	69.29	O custo total da estratégia dissociada é 23,8% menor do que o obtido pela		
21	129.79	34.19	67.87	estratégia integrada. Essa melhoria significativa valida o desempenho mais		
22	144.22	0	76.53	preciso do preditor dissociado em comparação com o preditor integrado.		
23	134.08	0	70.45	De acordo com o caso 1 (sistema de teste de 6 barramentos) e o caso		
24	124.62	0	64.77			

estratégia, que é US \$ 2141 menos do que a estratégia agregada. Consequentemente, o preditor baseado em ARIMA proposto fornece previsões mais precisas da carga elétrica convencional e da demanda de carregamento de EVs, e o uso desses dados ajuda o operador para ter um agendamento de sistema mais preciso e eficiente.

4.3. Caso 2: o sistema de teste IEEE de 24 barramentos

Aplicamos a abordagem de previsão proposta no sistema de teste IEEE 24-bus. O sistema tem 10 unidades de geração e 17 pontos de carga. Neste estudo de caso, assumimos que temos estacionamentos EV nos ônibus 1, 3, 4, 6, 8, 10, 13, 15, 19 e 20. O número de EVs nos ônibus 4, 10, 19 e 20 é de 40.000 EVs com a taxa de carregamento de 0,3 capacidade de bateria por hora. O número de EVs nos ônibus 1 e 6 é de 60.000 com taxa de carregamento de 0,3 capacidade de bateria por hora. O número de EVs nos ônibus 3, 8, 13 e 15 é de 80.000 com taxa de carregamento de 0,3 capacidade de bateria por hora.

As duas estratégias de previsão são aplicadas para prever a carga ao longo das próximas 24 horas. De acordo com os resultados da previsão, o desvio padrão máximo nos cenários de previsão dissociado e integrado são de 54,96628 MW (ônibus 18, hora 7) e 149,6969 MW (ônibus 13, hora 8) respectivamente. O nível de confiança das restrições de chance é definido para 0,95 e o SCUC estocástico é resolvido. [Tabela 11](#)

mostra os custos de agendamento diários da proposta dissociada e das estratégias integradas. Os custos futuros das estratégias de previsão dissociadas e integradas são de US\$ 2.030.868 e US\$ 2.613.868, respectivamente. O preditor baseado em ARIMA proposto acaba com uma redução de custos de US \$ 583.000 em comparação com a estratégia integrada.

Tabela 14

Resultados de simulação para sistema de teste de 6 barramentos.

Sistema de teste	sistema de teste de 6 barramentos	
Cenário	+ CELCDE	
Tempo de execução (s)	1	CDE + CEL
		1
Custo diário (\$)	73,244	71,819
Custo de reagendamento (\$)	2100	1384
Custo total do sistema = Day-ahead + Custo de reagendamento (\$)	75,344	73,203

Tabela 15

Resultados de simulação para sistema de teste IEEE 24-bus.

Sistema de	teste sistema de teste de 24 barramentos	
Cenário	O + CDE	CDE + CI

Semelhante ao Caso 1, também realizamos o reagendamento do sistema no Caso 2. Os custos de reagendamento de ambas as estratégias de previsão são mostrados na [Tabela 15](#). Esta tabela também mostra os custos operacionais diários totais (custo de agendamento diário + custo de reagendamento por hora). O custo total da estratégia dissociada é 23,8% menor do que o obtido pela estratégia integrada. Essa melhoria significativa valida o desempenho mais preciso do preditor dissociado em comparação com o preditor integrado.

De acordo com o caso 1 (sistema de teste de 6 barramentos) e o caso 2 (sistema de teste IEEE 24-bus), utilizamos a abordagem de previsão proposta para prever a demanda de energia de cada ponto de carga com base no dados históricos. Precisamos de uma previsão separada para cada ponto de carga em vez de uma previsão conjunta para todas as cargas. Portanto, o número de pontos de carga não afeta a precisão do preditor proposto, pois lidamos com eles separadamente. Em outras palavras, mesmo que tenhamos um sistema de energia muito grande com muitos pontos de carga, o operador pode usar a abordagem de previsão baseada em ARIMA proposta para prever a energia demanda de cada ponto de carga.

5. Conclusões

Este artigo propõe uma abordagem de previsão baseada em séries temporais para cobrar demanda de estacionamentos de EV. Isso é feito através de (1) melhorar a precisão do preditor ARIMA, afinando os parâmetros de ordem integrado e auto-regressiva e (2) desacoplado o perfil de demanda de carregamento diário de Estacionamentos EV do perfil de carga que muda sazonalmente. O estudo de caso demonstra a melhora considerável do desempenho da previsão da demanda, enquanto estamos usando o preditor dissociado em vez do método integrado de previsão de demanda. Nosso novo modelo de previsão de demanda de carregamento EV leva padrões e distâncias de condução diárias como as entradas para determinar os perfis de carga de carregamento esperados. As saídas de previsão são usadas para formular um problema de agendamento de dia antes para mostrar os benefícios potenciais de redução de custos do preditor proposto na segurança problema de comprometimento unitário (SCUC). Os resultados da simulação certificam que o preditor baseado em CEL/CDE ARIMA proposto leva a previsões de demanda mais precisas em comparação com a estratégia tradicional de previsão integrada. Isso se traduz em um compromisso de unidade mais eficaz, bem como resultados de dispatch de energia, e reduz o custo operacional total resultante, que é o soma do agendamento diário e dos custos de reagendamento em tempo real. De acordo com os resultados numéricos, o preditor proposto com abordagem dissociada reduz os custos operacionais diários em quase 2,9% para o sistema de teste de 6 ônibus e 23% para o sistema de teste de barramento IEEE-24 para o cenário simulado em comparação com a abordagem de previsão integrada. Isso pode potencialmente levar a uma considerável economia anual de custos de US\$ 770 mil para o sistema de 6 barras e US\$ 240 milhões para o sistema de barramento IEEE-24. Assim, quando dimensionada, nossa abordagem de previsão de demanda pode ajudar a obter uma redução significativa de custos nas operações do sistema de energia estocástica.

Mais pesquisas são necessárias para investigar o efeito da cobrança programada no SCUC. Isso pode ser feito considerando a carga programada dentro da formulação de SCUC por acaso.

Reconhecimento

Os autores gostariam de reconhecer os valiosos insumos, comentários frutíferos e discussões da Prof^a Marija D. Ilic' da Universidade Carnegie Mellon para este artigo. A qualidade deste trabalho é substancialmente melhorada por seus comentários. Também gostaríamos de agradecer a Kritika Jain do SYSU-CMU Shunde International Joint Research Institute e Chengkun (George) Li por seu esforço na revisão do manuscrito.

Referências

- [1] <http://www.whitehouse.gov/the-press-office/2014/11/18/fact-sheet-growing-united-states-electric-vehicle-market>.
- [2] C.W. Gellings, The Smart Grid: Enabling Energy Efficiency and Demand Response, Fairmont Press, 2009.
- [3] Rahmani-andebili, G.K. Venayagamoorthy, colocação no SmartPark e operação para melhorar a confiabilidade do sistema e a participação no mercado, Electr. Power Syst. Res. 123 (junho (6)) (2015) 21-30.
- [4] M.E. Khodayar, L. Wu, M. Shahidehpour, coordenação horária da operação de veículos elétricos e geração volátil de energia eólica em SCUC, IEEE Trans. Smart Grid 3 (3) (2012) 1271-1279.
- [5] Kempton, J. Tomic, fundamentos de energia veículo-a-grade : cálculo de capacidade e receita líquida, J. Fontes de energia 144 (2005) 268-279.
- [6] Lund, W. Kempton, Integração de energia renovável nos setores de transporte e eletricidade through V2G, Energy Policy 36 (9) (2008) 3578-3587.
- [7] Yazdani-Damavandi, P.M. Moghaddam, M.-R. Haghifam, M. Shafie-khah, J.P.S. Catalao, Modelando o comportamento operacional do lote de parking de veículos elétricos plug-in em sistemas multi energia, IEEE Trans. Smart Grid 7 (1) (2016) 124-135.
- [8] Rahman, P.M. Vasant, B. Singh, M. Singh, M. Abdullah-Al-Wadud, N. Adnan, Revisão das tendências recentes em técnicas de otimização para infraestruturas de carregamento de veículos elétricos plug-in e veículos elétricos, Renovação. O Sust. Rev. 58 (2016) 1039-1047.
- [9] Kempton, J. Tomic', implementação de energia veículo-rede: desde estabilizar a rede até suportar energia renovável em larga escala, J. Fontes de energia 144 (1) (2005) 280-294.
- [10] J. Tomic', W. Kempton, Usando frotas de veículos elétricos para suporte de rede, J. Fontes de energia 168 (2) (2007) 459-468.
- [11] Moradijoz, P.M. Moghadam, M.-R. Haghifam, E. Alishahi, um problema de otimização multi-objetivo para alocando estacionamentos em uma rede de distribuição, Int. Electr. Power Energy Syst. 46 (2013) 115-122.
- [12] N. Neyestani, Y. Damavandi, M. Shafie-khah, J. Contreras, J.P.S. Catalao, Alocação de estacionamentos de veículos plug-in em sistemas de distribuição considerando objetivos restritos à rede, IEEE Trans. Power Syst. 30 (5) (2015) 2643-2656.
- [13] Rahman, P.M. Vasant, B.S.M. Singh, M. Abdullah-Al-Wadud, à beira da otimização acelerada do enxame de partículas para o carregamento de veículos elétricos híbridos plug-in, Alexandria Eng. J. 55 (1) (2016) 419-426.
- [14] Shafie-khah, P.M. Moghaddam Sheikh-El-Eslami, M. RahmaniAndebili, Modelagem de interações entre regulamentos de mercado e comportamento de agregadores de veículos elétricos plug-in em um ambiente de mercado de energia virtual, Energy 40 (1) (2015) 139-150.
- [15] J. Aghaei, A. Esmael Nezhad, A. Rabiee, E. Rahimi, Contribuição de veículos elétricos híbridos plug-in no sistema de energia incerteza management, Renew. O Sust. Energy Rev. 59 (2016) 450-458.
- [16] Alizadeh, A. Scaglione, J. Davies, K.S. Kurani, um modelo escalável e estocástico para a demanda de eletricidade de veículos híbridos elétricos e plug-in, IEEE Trans. Smart Grid 5 (2 de março) (2014) 848-860.
- [17] Darabi, M. Ferdowsi, impacto agregado de veículos elétricos híbridos plug-in no perfil de demanda de eletricidade, IEEE Trans. Sustentar. Energia 2 (outubro (4)) (2011).
- [18] S. Shafiee, M. Fotuhi-Firuzabad, M. Rastegar, Investigando os impactos dos veículos elétricos híbridos plugin nos sistemas de distribuição de energia, IEEE Trans. Smart Grid 4 (3 de setembro) (2013).
- [19] S. Deilami, A.S. Masoum, P.S. Moisés, M.A.S. Masoum, coordenação em tempo real do carregamento de veículos elétricos plug-in em redes inteligentes para minimizar perdas de energia e melhorar o perfil de tensão, IEEE Trans. Smart Grid 2 (3 de setembro) (2011) 456-467.
- [20] L. Hernandez, et al., Uma pesquisa sobre previsão da demanda de energia elétrica: tendências futuras em redes inteligentes, microgrids e edifícios inteligentes, IEEE Commun. Surv. Surv. Tutor. 16 (3) (2013) 1-36.
- [21] Cho, J.C. Hwang, C.S. Chen, Previsão de carga de curto prazo do cliente usando o modelo de função de transferência ARIMA, em: Proc. da Conferência Internacional sobre Gestão de Energia e Entrega de Energia, 1995.
- [22] Hagan, S.M. Behr, a abordagem da série temporal para a previsão de carga de curto prazo, IEEE Trans. Power Syst. 2 (3) (1987) 785-791.
- [23] A.A. El Desouky, M.M. El Kateb, Técnicas adaptativas híbridas para forecast de carga elétrica usando ANN e ARIMA, IEE Proc. Gerar. Transm. O Distrib. 147 (4) (2000).
- [24] G.P. Zhang, série time previsão usando um modelo híbrido de ARIMA e rede neural, Neurocomputing 50 (2003) 159-175.
- [25] J.W. Taylor, P.E. McSharry, métodos de previsão de carga de curto prazo: uma avaliação baseada em dados europeus, IEEE Trans. Power Syst. 22 (4) (2007) 2213-2219.
- [26] R. Majidpour, C. Qiu Chu, R. Gadh, H.R. Pota, Previsão rápida para séries temporais esparsas: previsão de demanda de estações de carregamento de EV para aplicações de celular, IEEE Trans. Ind. O Informat. (2015).
- [27] A. Raza Khan, et al., Previsão de carga, preços dinâmicos e DSM na smart grid: uma revisão, Renove. O Sust. Rev. 54 (2016) 1311-1322.
- [28] N. Korolko, et al., Modelagem e previsão de carga de energia auto-similar devido a carregadores rápidos EV, IEEE Trans. Smart Grid (2015).
- [29] S. Meliopoulos, Impactos do nível do sistema de energia de veículos híbridos plug-in, Centro de Pesquisa em Engenharia de Sistemas de Energia (PSERC), 2009.
- [30] P. Sharer, R. Leydier, A. Rousseau, Impacto da agressividade do ciclo de condução e velocidade na sensibilidade ao consumo de combustível dos HEVs, Argonne National Lab, 2007 (Online). Disponível <http://www.transporte.Anl.gov/modelagem-de-simulacao/apresentacoes/PSAT/psat-.html>.
- [31] G. Li, X.-P. Zhang, Modelagem da demanda de carregamento de veículos elétricos híbridos plug-in em cálculos probabilísticos de fluxo de energia, IEEE Trans. Smart Grid 3 (março (1)) (2012).
- [32] A. Kargarian, Y. Fu, Z. Li, Compromisso de unidade com restrição de segurança distribuída para systems de energia em larga escala, IEEE Trans. Power Syst. 30 (4) (2015) 1925-1936.
- [33] A. Khodaei, M. Shahidehpour, S. Bahramirad, SCUC com resposta de demanda horária considerando características intertemporais do load, IEEE Trans. Smart Grid 2 (3) (2011) 564-571.
- [34] L. Wu, M. Shahidehpour, T. Li, compromisso de unidade com restrição de segurança estocástica, IEEE Trans. Power Syst. 22 (2) (2007) 800-811.
- [35] M.M.R. Sahebi, S.H. Hosseini, segurança estocástica restringiu o compromisso da unidade incorporando a demanda side reserve, Int. J. Electr. Power Energy Syst. 56 (2014) 175-184.
- [36] H. Wu, M. Shahidehpour, Z. Li, W. Tian, Chance-constrained dia-à-frente scheduling na operação do sistema de energia estocástica, IEEE Trans. Power Syst. 29 (4 de julho) (2014) 1583-1591.
- [37] R. Henrion, Introdução ao programa de acaso. Tutorial Paper para a Página Inicial da Comunidade de Programação Estocástica, 2004.
- [38] A. Prékopa, Programming Estocástico, Kluwer, Dordrecht, Holanda, 1995.
- [39] J. Löfberg, YALMIP: uma caixa de ferramentas para modificação e otimização no MATLAB, em: Proc. IEEE Simpósio Internacional sobre Design de Sistemas de Controle Auxiliado por Computador, setembro de 2004.
- [40] M.H. Amini, P.M. Moghaddam, Modelagem probabilística dos estacionamentos de veículos elétricos cobrando demanda, em: 21st Iranian Conference on Electric Engineering (ICEE), 2013.
- [41] M.H. Amini, A. Islam, Alocação de estacionamentos de veículos elétricos em rede de distribuição, em: IEEE PES 5ª Conferência inovadora de Tecnologias smart grid (ISGT), 2014.