

# Previsão para a frente do preço das ações usando Regressão de aprendizado de máquina otimizada para metaheurística de janela deslizante

Jui-Sheng Chou e Thi-Kha Nguyen

**Resumo** — A forecasting de séries temporais tem sido amplamente utilizada para determinar os preços futuros das ações, e a análise e modelagem das séries de tempo de financiamento importantemente orientam as decisões e negociações dos investidores. Além disso, em um ambiente dinâmico como o mercado de ações, a não-linha da série temporal é pronunciada, afetando imediatamente a eficácia das previsões de preços das ações. Assim, este trabalho propõe um sistema inteligente de previsão de séries temporais que usa otimização metaheurística de janela deslizante com o propósito de prever os preços das empresas de construção de Taiwan um passo à frente. Pode ser de grande interesse para os home brokers que não possuem conhecimento suficiente para investir em tais empresas. O sistema tem uma interface gráfica de usuário e funciona como um application autônomo. O sistema híbrido desenvolvido apresentou excelente desempenho de previsão e melhora o lucro geral para o desempenho dos investimentos. O modelo proposto é uma técnica preditiva promissora para séries temporais altamente não lineares, cujos padrões são difíceis de capturar por modelos tradicionais.

**Termos de Índice** — Empresa de construção, mineração de dados, sistema de previsão, janela deslizante, previsão de preços de ações, séries temporais, aprendizado de máquina, inteligência de enxame e otimização metaheurística.

## INTRODUÇÃO

**F**INANCIAL mercados são altamente voláteis e geram enormes quantidades de dados diariamente. O investimento é um compromisso de dinheiro ou outros recursos para obter benefícios no futuro. Ações são um tipo de títulos. É o instrumento mais popular do mercado financeiro e seu valor muda rapidamente [1]. Pode ser definido como um sinal de participação de capital por uma pessoa ou uma empresa em uma empresa ou uma empresa de responsabilidade limitada.

Este trabalho foi apoiado em parte pelo Ministério da Ciência e Tecnologia, Taiwan, sob o Grant 103-2221-E-011-144-MY3 e em parte pelo Ministério da Educação – Projeto Aim for Top University. Papel não. 17-1416. (Autor correspondente: Jui-Sheng Chou.)

Jui-Sheng Chou é do Departamento de Engenharia Civil e de Construção, Universidade Nacional de Taiwan de Ciência e Tecnologia, Taipei, Taiwan. (e-mail: jschou@mail.ntust.edu.tw).

Thi-Kha Nguyen é da Faculdade de Engenharia e Agricultura da Universidade de Danang – Campus em Kontum, Kontum, Vietnã. (e-mail: nguyengkha130490@gmail.com).

O mercado de ações oferece oportunidades para corretores e empresas fazerem investimentos em terreno neutro [2]. Prevê-se que os preços das ações determinem o valor futuro das ações das empresas ou outros instrumentos financeiros que são comercializados em bolsas financeiras [3]. No entanto, o mercado de ações é caracterizado por não linearidades, descontinuidades e componentes multi-polinômios de alta frequência, pois interage com muitos fatores, como eventos políticos, condições econômicas gerais e expectativas dos comerciantes [4]. Portanto, fazer previsões precisas dos valores das ações são desafiantes.

Os investidores podem comprar ações relacionadas às construtoras que projetam projetos de infraestrutura, contratam empreiteiros e lidam com documentos, e os tomadores de decisão de construtoras podem comprar ações de outras empresas. Quando a direção do mercado for prevista com sucesso, os investidores podem ser melhor guiados e as recompensas monetárias serão substanciais. O desafio no ambiente atual, as más notícias podem ser ouvidas, é prever de forma proativa, e não reativa. Portanto, as construtoras estão tentando prever os preços das ações, o que é importante para ser considerado em uma bolsa financeira, contra quedas bruscas no mercado.

A previsão da série Time consiste em uma área de pesquisa projetada para resolver diversos problemas, principalmente na área financeira [5]. Vale ressaltar que essa área normalmente utiliza ferramentas que auxiliam no planejamento e na tomada de decisões para minimizar os riscos de investimento. Esse objetivo é óbvio quando se quer analisar os mercados financeiros e, por isso, é necessário garantir uma boa precisão na previsão de tarefas.

Segundo Saini (2016), a previsão baseada em uma série temporal representa um meio de providing de informação e conhecimento para apoiar uma decisão subsequente [6]. Assim, a análise de séries temporizantes foca em alcançar relações de dependência entre dados históricos. As duas grandes categorias de modelos de previsão são lineares e não lineares. Para muitos decadas, os modelos tradicionais de previsão estatística em engenharia financeira eram lineares. Alguns modelos estatísticos bem conhecidos podem ser usados em previsões de séries temporâneas [6]. Técnicas convencionais de modelagem, como a média de moving integrado autoregressive da Box-Jenkins, não são adequadas para a previsão de preços no mercado de ações [7].

O aprendizado de máquina (ML) está entrando em sua própria que pode reproduzir uma chave em uma ampla gama de aplicações críticas. No aprendizado de máquina, as máquinas vetoriais de suporte (SVMs) possuem muitos recursos avançados que se refletem em sua boa capacidade de generalização e computação rápida [6]. Eles também não são muito sensíveis a suposições sobre termos de erro e podem tolerar ruídos e componentes caóticos. Notavelmente, os SVMs são cada vez mais utilizados em materiais science [8], o projeto de sistemas de engenharia [9] e a previsão de risco financeiro [10].

A regressão vetorial de suporte (SVR), uma variante do SVM, foi desenvolvida por Vapnik *et al.* (1995) [11]. O SVR é normalmente usado para resolver problemas de regressão não lineares, construindo a função de mapeamento de saída de entrada. O algoritmo de regressão vetorial de menor suporte (LSSVR) é um desenvolvimento adicional de SVR pela Suykens (2001) [12] e envolve igualdade em vez de restrições de desigualdade, e trabalha com uma diversão objetiva de menos quadrados. A abordagem LSSVR reduz consideravelmente a complexidade computacional e aumenta a eficiência em comparação com o SVR padrão.

Recentemente, Lu *et al.* (2009) utilizou análise de componentes independentes para remover o ruído das variáveis de previsão. As variáveis de previsão filtradas, que contêm menos informações de ruído, servem então como as variáveis de entrada do modelo de previsão de SVR [13]. Hao *et al.* (2006) examinou a viabilidade dos métodos na previsão do índice composto de ações e melhorou a precisão do seletor de parâmetros pelo SVR. Eles concluíram que a SVR tem alto desempenho de previsão [14].

Alguns estudos demonstraram a superioridade do LSSVR sobre a regressão vetorial de suporte padrão (SVR) para estimar o custo do produto [15] e a utilização de energia [16]. O LSSVR resolve equações de linear em vez de um problema de programação quadrática. É preferível para problemas de regressão em larga escala que exigem computação rápida [12]. Uma vez que os dados da série temporal podem ser formulados pela análise de regressão, o LSSVR é muito eficiente quando aplicado à emissão em questão. No entanto, a eficácia do LSSVR depende fortemente de seus hiperparâmetros de ajuste,

que são o parâmetro de regularização e a função do kernel. Configurações inadequadas desses parâmetros podem levar a um desempenho significativamente ruim do modelo [17]. Portanto, a avaliação desses hiperparâmetros é um problema de otimização do mundo real.

Uma vez que o desempenho dos modelos baseados em SVR depende fortemente da configuração de seus hiperparâmetros, eles costumavam ser definidos com antecedência com base na experiência de practitioners, por tentativa e erro, ou usando um algoritmo de pesquisa de grade [18]. Assim, encontrar os valores ideais de regularização e parâmetros de função do kernel para modelos baseados em SVR é uma etapa importante e demorada. Portanto, é necessário encontrar automaticamente os hiperparâmetros do SVR, garantindo seu desempenho de generalização.

A otimização é um dos pilares da ciência e da engenharia. Recentemente, o campo de algoritmos de otimização inspirados na natureza cresceu incrivelmente rápido. Os algoritmos são geralmente de uso geral e de base populacional. Eles são normalmente referidos como algoritmos evolutivos porque muitos deles são motivados pela evolução biológica. Em um sentido amplo, algoritmos evolutivos cobrem aqueles que eleerativamente variam um grupo de soluções baseadas em algumas operações inspiradas na natureza.

Muitos algoritmos evolutivos, such como colônia de abelhas artificiais e algoritmos de pesquisa de cuco (CS), foram adotados para sintonizar os hiperparâmetros de SVR [19, 20]. Por exemplo, Jianzhou *et al.* (2014) propôs modelos híbridos de previsão inteligente que foram baseados em CS, a análise de espectro singular, séries tempoesas e métodos de aprendizado de máquina para realizar a previsão de carga de energia de curto prazo [20]. Hsieh *et al.* (2011) demonstrou que o modelo SVR baseado em enxame particle (PSO) foi superior ao SVR tradicional na previsão do índice diário de ações ponderadas de capitalização da Bolsa de Taiwan (TAIEX) [19].

O algoritmo firefly (FA) [21], que é um método metaheurístico inspirado na natureza, has recentemente teve um desempenho extremamente bem na resolução de vários problemas de otimização, como previsão de preço das ações [18] e previsão de preços de eletricidade [22]. A FA padrão foi desenvolvida modelando o comportamento dos vagalumes tropicais. Notavelmente, o LSSVR baseado em algoritmos de firefly inteligente tem sido demonstrado ser muito eficaz na resolução de problemas complexos na engenharia civil [23, 24].

Fa e suas variantes são usadas para resolver muitos problemas de otimização, classificação e engenharia. Gandomi *et al.* (2011) em [25] utilizou FA para resolver problemas de otimização estrutural contínua/discreta mista no projeto de vigas soldadas, vasos de pressão, molas de compressão helicoidal, vigas de concreto armado, vigas de cantilever pisadas e design de impacto lateral do carro. Os resultados de otimização indicaram que a FA é mais eficiente do que outros algoritmos meta-heurísticos, como PSO, algoritmo genético, annealing simulado e evolução diferencial.



Em uma estimativa de função do LSSVR, o problema de otimização é formulado como

$$\min_{\alpha, b, e} J(\alpha, b, e) = \frac{1}{2} \sum_{k=1}^N \alpha_k^2 + \frac{1}{2} \sum_{k=1}^N \alpha_k^2 + \frac{1}{2} \sum_{k=1}^N \alpha_k^2 \quad (2)$$

Uma vez que este é um problema típico de otimização de uma função diferente com restrições, pode ser resolvido usando multiplicadores Lagrange. Equação (3) é o modelo LSSVR resultante para previsão de função.

$$f(x) = \sum_{k=1}^N \alpha_k K(x, x_k) + b \quad (3)$$

onde  $\alpha_k$  e  $b$  são multiplicadores Lagrange e o termo viés, respectivamente; e  $K(x, x_k)$  é a função do kernel. Neste estudo, é utilizado um núcleo de função radial (RBF). Para uma explicação técnica detalhada desta abordagem aplicada neste estudo, os leitores interessados podem se referir ao trabalho de Chou *et al.* (2016) [24].

No entanto, a precisão de previsão do LSSVR é altamente dependente da determinação de seus hiperparâmetros. Portanto, como parte deste study, o algoritmo FA aprimorado foi desenvolvido para hiperparâmetros LSSVR otimizados, ou seja, o parâmetro de regularização ( $C$ ) e o sigma do kernel RBF ( $\sigma$ ).

## 2) Sintonizar hiperparâmetros: enxame e algoritmo de otimização metaheurística

A FA, desenvolvida por Yang [21], está entre os métodos de inteligência de enxame mais bem sucedidos. Este algoritmo foi inspirado pelos padrões piscando e comportamento de vagalumes tropicais. Para um problema de maximização, o brilho é simplesmente definido para ser proporcional ao valor da função objectiva. Uma vez que a atratividade de um vagalume é proporcional à intensidade de sua luz visível aos vagalumes adjacentes, a atratividade  $a_i$  de um vagalume satisfaz (4).

$a_i = \frac{p_i}{r_i + 1} e^{-\frac{r_i}{2}}$  (4) onde  $a_i$  é a atratividade do vagalume;  $p_i$  é a atratividade do vagalume em  $r=0$ ;  $r$  é a distância entre o vagalume de interesse e qualquer outro;  $e$  é um coeficiente constante; e  $\frac{1}{2}$  é o coeficiente de absorção. O procedimento detalhado da FA foi resumido em [8].

Embora a FA seja altamente eficiente em muitas aplicações, muitas vezes fica presa em um ideal local [31]. Além disso, definir parâmetros de ajuste que melhorem a convergência da FA é outro desafio. Os parâmetros da FA devem ser otimizados para equilibrar a exploração e a exploração. Portanto, o MetaFA incorpora três componentes metaheurísticos, ou seja, mapa caótico, o peso da inércia adaptativa e o voo Lévy, na FA convencional para melhorar suas capacidades de busca e otimização [32]. Fig. 2 descreve os pseudocódigos para o modelo MetaFA-LSSVR.

## Mapa caótico logístico para melhorar a população inicial

A FA usa uma abordagem típica para gerar uma solução inicial aleatoriamente. As duas principais desvantagens dessa abordagem são sua lenta convergência e sua tendência a ficar presa em optima local devido à redução da diversidade populacional. Para melhorar a diversidade inicial de soluções e a qualidade da população inicial, um mapa caótico logístico é usado para gerar uma população altamente diversificada de vagalumes na fase inicial.

## Mapa caótico gauss/mouse para sintonizar atratividade

O mapa Gauss/mouse fornece o melhor meio de sintonizar o parâmetro de atratividade ( $a_i$ ) da FA. Para uma explicação técnica detalhada desta abordagem aplicada neste estudo, os leitores interessados podem consultar o trabalho de He *et al.* (2001) [33]. **Peso de inércia adaptável para ajuste da randomização**

Reduzir a aleatoriedade à medida que as iterações prosseguem melhora a eficiência convergente de um algoritmo baseado em enxame. Nos estágios iniciais do processo de busca, um grande peso de inércia pode impulsionar o desempenho de exploração global (busca de uma nova área). Em cada uma das etapas finais, a redução do peso da inércia aumenta a exploração local (ajuste fino da área de busca atual). O peso da inércia é essencial na convergência das soluções conhecidas ideais para o valor globalmente ideal; o peso da inércia melhora o tempo de execução da simulação.

## Voo Lévy para controlar o movimento

A teoria da caminhada aleatória desempenha um papel crítico na inteligência moderna do enxame e algoritmos de otimização evolutiva [34]. Os voos lévy são uma caminhada aleatória na qual o comprimento do passo é uma distribuição Lévy. Os comprimentos do passo não têm escala característica, pois o segundo momento ou mesmo o primeiro momento podem divergir, e a distribuição exibe propriedades auto-afim. Os voos lévy são usados para gerar números aleatórios em duas etapas: seleção random de uma direção e geração de passos que obedecem à distribuição lévy selecionada. Neste trabalho, foram geradas direções com distribuições uniformes. O algoritmo de Mantegna, que é o mais popular, é usado para gerar passos a partir de uma distribuição estável symmetric Lévy.


## C. Sistema inteligente de previsão de séries temporal usando otimização metaheurística de janela deslizante

As ferramentas de desenvolvimento que são utilizadas neste estudo são MATLAB GUIDE, MATLAB compiler e matlab compiler runtime, todos baseados em software MATLAB e desenvolvidos em um ambiente window em uma máquina com um Intel Core i5 e 4GB de RAM. O MATLAB GUIDE foi usado para projetar uma interface fácil de usar.

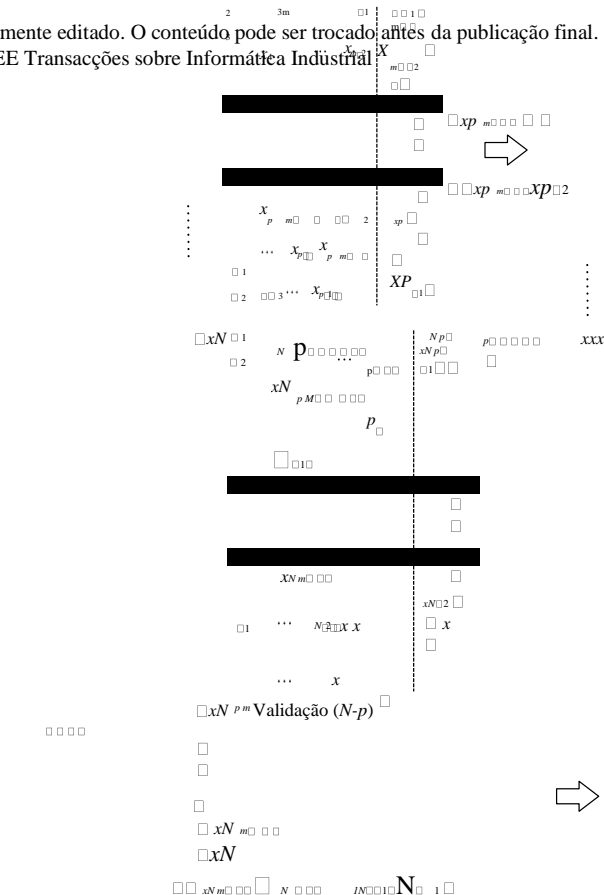

O modelo de previsão proposed tem dois estágios principais. Na primeira etapa, são determinados os valores dos parâmetros da série temporal, lag e o tamanho da janela deslizante. Os dados de aprendizagem na janela deslizante são incorporados em

matrizes de entrada e saída. Na segunda etapa, o modelo MetaFA-LSSVR é usado para executar uma previsão de um passo à frente. Cada validação envolve uma etapa de antecedência, de modo que o número de dados de teste equivale ao número de validações. A janela continua avançando e as validações são conduzidas. O processo é repetido até que todas as validações sejam realizadas.

Existem dois módulos, Avaliação e Previsão, fornecidos no sistema de interface. O módulo de Avaliação examina o desempenho dos modelos MetaFA-LSSVR e LSSVR de janela deslizante. Para avaliação, o usuário pode escolher entre várias opções, que são usar o arquivo de dados aberto, usar o arquivo de teste, hold-out e validação de janela deslizante. O módulo Previsão realiza uma ou multi-dias de antecedência. O sistema retorna uma avaliação de desempenho ou valores previstos, conforme necessário. O sistema também fornece um recurso que permite ao usuário salvar o modelo após sua execução, permitindo que o usuário o reutilize para outro propósito.



a Representação da janela deslizante



b Reconstrução do espaço de fase para análise da série temporal Fig. 1. Reconstrução de janela deslizante e espaço de fase para análise de séries temporais.

Fig. 3 exibe a arquitetura do sistema de previsão de séries temporais inteligentes proposto com otimização metaheurística de janela deslizante. O usuário do sistema envolve as seguintes etapas simples - configuração do parâmetro, normalização, otimização e propósito com o componente MetaFA-LSSVR. Os resultados são mostrados na interface. O usuário também pode ler o relatório de análise ou salvar resultados em um arquivo eletrônico para análise posterior.

Equação (5) é a função fitness do MetaFA-LSSVR.

$f_m()$  objetivo\_ função Dados de avaliação (5) em que a função objetiva pode ser designada como erro quadrado médio, erro médio absoluto, erro percentual absoluto médio, coeficiente de correlação múltipla de regressão não linear ou quadrado médio erro. No entanto, se o conjunto de dados contiver valores zero reais, então o erro percentual absoluto médio não poderá ser usado como função objetiva.

Executar função objetiva  $f(x) = (x_1, \dots, x_d)^T$

Definir espaço de busca e número de gerações

Gerar população inicial de vagalumes  $x_i$  ( $i = 1, 2, \dots, n$ ) utilizando caótico logístico

mapa

Determine a intensidade da luz  $i$  at  $X_i$  por  $f(x)_i$

Defina o coeficiente de absorção de luz  $\square$

Gerar população inicial,  $k = 0$

1. Enquanto ( $t$ ) MaxGeneration) fazer
  - (1) Atualize o número de geração,  $k = k + 1$
  - (2) Parâmetro de randomização de sintonia  $\square$  pelo peso da inércia adaptativa ( $\square \square \square 00,9$ )'
  - (3) Parâmetro de atratividade de sintonia  $\square$  usando mapa caótico gauss/mouse para  $i = 1$ : Não. Pirilampus

```

for  $j = 1$ : No. fireflies
    if ( $I_j > I_i$ )
        Move firefly  $i$  toward  $j$  in  $d$ -dimension by Lévy flight;
    end if
    Vary attractiveness with distance  $r$  via  $\exp[-\gamma * r]$ 
    Evaluate new solutions and update light intensity
end for  $j$ 
end for  $i$ 
Rank the fireflies and find the current best
end while

```

2. MetaFA-LSSVR function validation
  - Set kernel (rbf) and loss-function (least-square) parameters
  - Train model with hyperparameters ( $C, \sigma$ )
  - Evaluate trained LSSVR model
  - Evaluate fitness function  $f(m)$ , and go to step 1
3. Has the stopping criterion been met?
  - If the criterion has been met, Go to step 4
  - else go to step 1
- End
4. Optimized LSSVR model
5. Postprocess results and visualization

Fig. 2. Pseudo code for MetaFA-LSSVR model.

#### D. Performance evaluation methods

As medidas de desempenho utilizadas to avaliam a precisão preditiva do sistema proposto incluíram o erro quadrado da média raiz (RMSE), o erro absoluto médio (MAE), o erro percentual absoluto médio (MAPE), o erro quadrado médio (MSE), o coeficiente de correlação (R), o coeficiente de correlação não linear ( $R^2$ ), e o índice de síntese (SI). Esses índices são usados para medir se os valores previstos estão próximos aos valores reais. Tabela I resume as fórmulas para esses índices, onde  $y$  é o valor real;  $y'$ is o valor previsto;  $-\bar{y}_i$  é a média entre amostras de dados;  $n$  é o número de amostras de dados;  $m$  é o número de medidas de desempenho; e  $P_i$  é a

décima medida de desempenho. O SI varia de 0 a 1 e um valor SI de perto de 0 indica um modelo preditivo altamente preciso.

### III. APLICAÇÕES DO SISTEMA

#### A. Coleta de dados

Os preços diários históricos foram retirados do Yahoo! Finance, um site de acesso público, como eram de Xiong *et al.* (2014) [18]. Seis anos (5 de outubro de 2011 a 31 de maio de 2017) de dados diários sobre cinco ações - Yuanta/P-shares Taiwan Top 50 ETF (0050.TW) Highwealth Construction Corp. (2542.TW), Huang Hsiang Construction Corporation (2545.TW), Ruentex

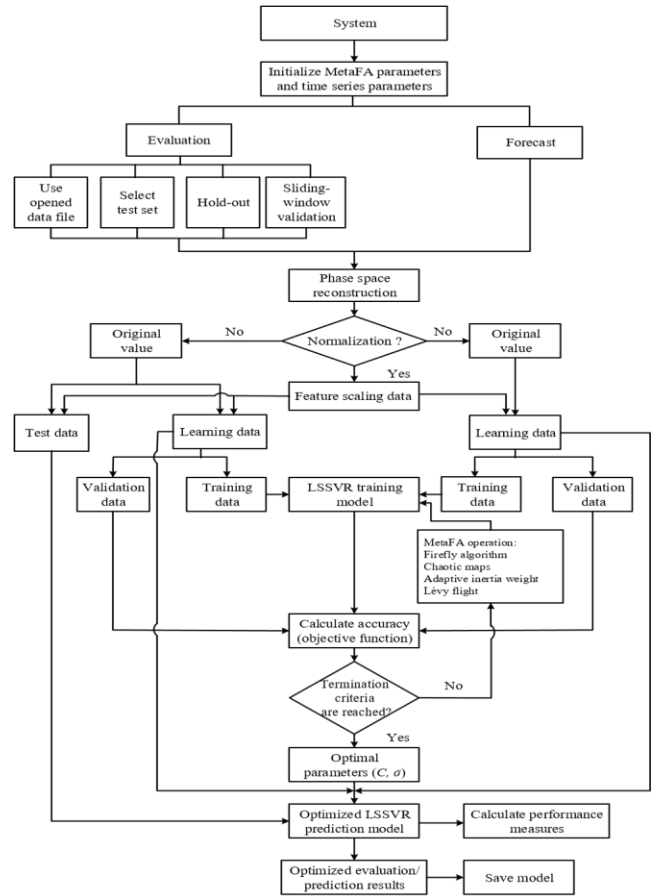


Fig. 3. System flowchart.

Engineering & Construction Co., Ltd. (2597.TW) e Chong Hong Construction Co., Ltd. (5534.TW) – foram baixados do Yahoo! Finance. Os dados estavam fechando os preços de Stock. O conjunto de dados de ações 0050.TW inclui as 50 principais ações por capitalização de mercado em Taiwan. 2542.TW, 2545.TW, 2597.TW e 5534.TW ações fornecem indicadores importantes do desempenho geral do mercado de construção em Taiwan. A Tabela II apresenta details sobre as ações e o número de instâncias de dados para cada estoque.

## B. Configuração de entrada

O desempenho do modelo proposto na previsão de curto prazo ao longo dos próximos 1, 10 e 15 dias e na previsão de longo prazo nos próximos 30, 60, 90, 180 e 360 dias é avaliado usando cinco conjuntos de dados de ações. Seu desempenho é comparado com o de modelos previamente relatados. Em seguida, seu desempenho é testado usando outros conjuntos de dados de ações populares que estão disponíveis na literatura. Embora esta investigação se concentre principalmente na previsão de preços de curto prazo, foram realizadas previsões de preços de longo prazo. Parte das configurações padrão do sistema foram as seguintes em [8]. O número de dados de aprendizagem/treinamento foi definido igual ao tamanho da janela deslizante. O tamanho do vento deslizante foi definido para 840. Com base em vários ensaios e experimentos, o *lag* ideal foi 2.

## C. Análise dos resultados experimentais 1) Resultados do sistema de predição híbrida proposto

Foram comparados oito cenários (ou seja, 1, 10, 15, 30, 60, 90, 180 e 360 dias antes do tempo). A Tabela III apresenta resultados para o estoque 0050.TW. Fig. 4 exibe os preços de fechamento previstos do conjunto de dados de ações 0050.TW para os próximos dias especificados. Este número indica que os valores que foram previstos um dia à frente pelo sistema estavam mais próximos dos valores reais do que os outros. Tabela IV a VII apresenta resultados semelhantes para 2542.TW, 2545.TW, 2597.TW e 5534.TW ações.

TABELA I

Medir	Fórmula
Erro quadrado médio raiz (RMSE)	$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (A_t - \hat{A}_t)^2}$
Média absolutaerro (MAE)	$MAE = \frac{1}{n} \sum_{t=1}^n  A_t - \hat{A}_t $
Erro percentual absoluto médio (MAPE)	$MAPA = \frac{1}{n} \sum_{t=1}^n \left  \frac{e_t}{e} \right $
Erro quadrado médio (MSE)	$MSE = \frac{1}{n} \sum_{t=1}^n (A_t - \hat{A}_t)^2$

MESA III

DESEMPENHO DE PREDICTION DO MODELO PROPOSTO PARA AÇÕES 0050.TW

		RMSE	MAE	MAPA (%)	R	$R^2$	MSE		
<b>11</b>		<b>0.644</b>	<b>0.474</b>	<b>0.713</b>	<b>0.992</b>	<b>0.969</b>	<b>0.414</b>	<b>0.000</b>	<b>1</b>
2	10	1.863	1.515	2.302	0.930	0.848	3.472	0.239	2
3	15	2.368	1.909	2.906	0.885	0.765	5.609	0.341	3
	430	3.135	2.557	3.884	0.789	0.401	9.829	0.513	4
5	60	4.416	3.777	5.628	0.536	0.220	19.498	0.850	5
6	90	4.757	4.145	6.131	0.458	0.100	22.624	0.948	7
7	180	4.940	4.062	5.974	0.353	0.032	24.400	0.987	8
8	360	4.763	4.086	5.936	0.605	0.092	22.690	0.878	6

O coeficiente de correlação (R)	$R = \frac{\sum_{t=1}^n (e_t - \bar{e})(e_t' - \bar{e}')}{\sqrt{\sum_{t=1}^n (e_t - \bar{e})^2} \sqrt{\sum_{t=1}^n (e_t' - \bar{e}')^2}}$
Não-regressão linear múltipla coeficiente de ação ( $R^2$ )	$R^2 = \frac{\sum_{t=1}^n (e_t - \bar{e})^2}{\sum_{t=1}^n (A_t - \bar{A})^2}$
Índice de síntese (SI)	$SI = \frac{1}{m} \left( \frac{PP_{\min,i}}{PP_{\max,i}} \right)$
FÓRMULAS MATEMÁTICAS PARA MEDIDAS DE DESEMPENHO	
$m = P_{\min,i} \dots P_{\max,i}$	

TABELA II

DESCRIÇÃO DE ESTOQUES E CONJUNTOS DE DADOS ANALISADOS

Dataset	Total N°. de pontos de dados	Duração
0050.TW	1357	5 de outubro de 2011 a 31 de maio de 2017
2542.TW	1457	5 de outubro de 2011 a 31 de maio de 2017
2545.TW	1457	5 de outubro de 2011 a 31 de maio de 2017
2597.TW	1457	5 de outubro de 2011 a 31 de maio de 2017
5534.TW	1457	5 de outubro de 2011 a 31 de maio de 2017

Os resultados acima revelam claramente que o erro aumenta com o número de dias de antecedência para o qual a previsão é feita. Isso pode ser óbvio para qualquer sistema de previsão. Acima de tudo, o sistema proposto rendeu melhores previsões para o 0050.TW

conjunto de dados de estoque do que os outros conjuntos de dados de ações. Por exemplo, uma previsão de um dia antes usando o conjunto de dados de ações 0050.TW produziu medidas de desempenho globais favoráveis. No entanto, os valores RMSE, MAE, MAPE e MSE da previsão de 360 dias de antecedência foram menoresum da previsão de 90 dias de antecedência e a previsão de 180 dias de antecedência (com um RMSE de 4.763, um MAE de 4.086, um MAPE de 5.936 % e um MSE de 22.690). Isso motivará pesquisas futuras para investimentos de longo prazo.

Nota: Valores ousados denotam as melhores medidas de desempenho entre as demais.

TABELA IV  
DESEMPENHO DE PREDICTION DO MODELO PROPOSTO PARA AÇÕES 1542.TW

Cenário	Para a frente	Medida média de desempenho em dados de teste						SI	Rank
		RMSE	MAE	MAPA (%)	R	$R^2$	MSE		
<b>11</b>		<b>2.308</b>	<b>0.863</b>	<b>1.745</b>	<b>0.982</b>	<b>0.957</b>	<b>5.239</b>	<b>0.000</b>	<b>1</b>
2	10	4.729	4.177	5.446	0.942	0.877	17.445	0.070	2
3	15	5.041	3.347	6.809	0.915	0.823	25.414	0.100	3
	430	8.572	5.420	10.874	0.766	0.508	73.483	0.209	4
5	60	11.066	9.043	18.703	0.583	0.185	122.453	0.337	5
6	90	11.993	9.424	19.655	0.424	0.048	143.821	0.433	7
7	180	11.686	9.503	20.583	0.541	0.105	136.555	0.410	6
8	360	122.047	16.919	34.821	0.011	-96.350	14895.569	1.000	8

Cenário Para a frente Medida média de desempenho em dados de teste SI Rank

Nota: Valores ousados denotam as melhores medidas de desempenho entre as demais.

TABELA V  
DESEMPENHO DE PREDICTION DO MODELO PROPOSTO PARA AÇÕES 2545.TW

Cenário	Para a frente	Medida média de desempenho em dados de teste						SI	Rank
		RMSE	MAE	MAPA (%)	R	$R^2$	MSE		
<b>11</b>		<b>1.372</b>	<b>0.558</b>	<b>1.701</b>	<b>0.984</b>	<b>0.959</b>	<b>1.883</b>	<b>0.000</b>	<b>1</b>
2	10	2.707	1.756	5.345	0.866	7.329	0.866	0.123	2
3	15	3.212	2.166	6.631	0.810	10.314	0.810	0.169	3
	430	4.541	3.256	9.821	0.639	20.625	0.639	0.301	4
5	60	5.740	4.624	13.865	0.423	32.943	0.423	0.449	5
6	90	6.972	5.773	17.740	0.569	0.150	48.612	0.616	6
7	180	10.963	9.017	28.170	0.351	-1.074	120.191	1.000	8
8	360	8.434	7.130	20.460	0.637	-0.236	71.139	0.693	7

Nota: Valores ousados denotam as melhores medidas de desempenho entre as demais.

TABELA VI  
DESEMPENHO DE PREDICTION DO MODELO PROPOSTO PARA AÇÕES 1597.TW

Cenário	Para a frente	Medida média de desempenho em dados de teste						SI	Rank
		RMSE	MAE	MAPE (%)	R	$R^2$	MSE		
<b>11</b>		<b>1.548</b>	<b>0.617</b>	<b>1.372</b>	<b>0.990</b>	<b>0.973</b>	<b>2.396</b>	<b>0.000</b>	<b>1</b>
2	10	3.075	1.792	3.963	0.962	0.916	9.459	0.082	2
3	15	5.169	2.823	6.319	0.902	0.770	26.717	0.178	3
	430	5.569	3.668	8.367	0.882	0.735	31.011	0.229	4
5	60	8.396	5.684	13.754	0.764	0.410	70.494	0.406	5
6	90	9.870	7.050	17.262	0.718	0.190	97.417	0.507	6
7	180	19.444	11.600	28.536	0.295	-2.110	378.059	1.000	8
8	360	16.333	8.608	19.948	0.443	-1.198	266.769	0.756	7



Nota: Valores ousados denotam as melhores medidas de desempenho entre as demais.

Para o conjunto de dados de ações 2597.TW, a previsão de um dia antes do preço das ações foi a melhor com uma RMSE de 1,548, um MAE de 0,617, um MAPE de 1,372%, um R de 0,990, um  $R^2$  de 0,973 e um MSE de 2.396. A Tabela VI também revela que os valores RMSE, MAE, MAPE e MSE da previsão de 360 dias de antecedência foram mais baixos do que os da previsão de 180 dias de antecedência (com um RMSE de 16.333, um MAE de 8.608, um MAPE de 19,948 % e um MSE de 266.769). Resultados semelhantes foram obtidos utilizando-se os outros conjuntos de dados.

## 2) Novos testes do sistema híbrido de previsão


Para verificar a robustez do sistema inteligente de previsão de séries temporais que usa otimização metaheurística de janela deslizante, experimentos numéricos são realizados com mais estoques. Os preços diários de fechamento de três ações populares de 5 de outubro de 2011 a 31 de maio de 2017 foram obtidos do Yahoo! Finance. A Tabela VIII apresenta os detalhes dos conjuntos de dados. Um dia antes foram feitas previsões utilizando-se os oito conjuntos de dados de ações e obtidas pelo sistema proposto. A Tabela IX compara ainda mais os desempenhos com as técnicas existentes na literatura.

## VII

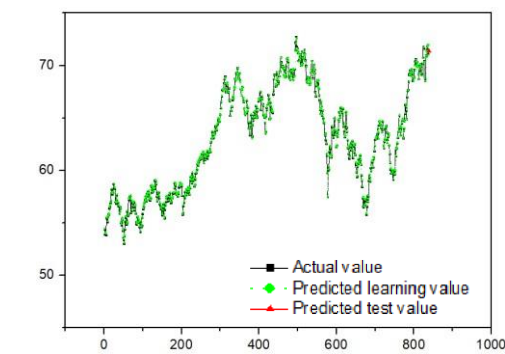
PREDICTION DE MESA PERFORMANCIELO PROPOSTO PARA AÇÕES 5534.TW

PREDIÇÃO DE MESA PERFORMANCE ELOS PROPOSTO PARA AÇÚCAR 5554-1W									
Cenário	Para a frente	Medida média de desempenho em dados de teste						SI	Rank
		RMSE	MAE	MAPA (%)	R	<sup>2</sup> R	MSE		
11		1.728	0.823	1.494	0.985	0.956	2.986	0.000	1
2	10	3.760	2.709	4.855	0.930	0.842	14.135	0.101	2
3	15	7.701	5.591	10.188	0.851	0.379	59.309	0.266	4
	430	6.298	4.786	8.722	0.821	0.571	39.671	0.231	3
5	60	9.698	7.840	14.325	0.608	0.003	94.049	0.434	5
6	90	13.301	10.643	19.774	0.442	-0.857	176.920	0.621	6
7	180	20.026	16.997	31.787	0.137	-3.194	401.023	1.000	8
8	360	13.888	10.903	21.392	0.379	-1.030	192.878	0.665	7


Nota: Valores ousados denotam as melhores medidas de desempenho entre as demais.




(a) Valores reais e previstos de 1 dia antes da validação.



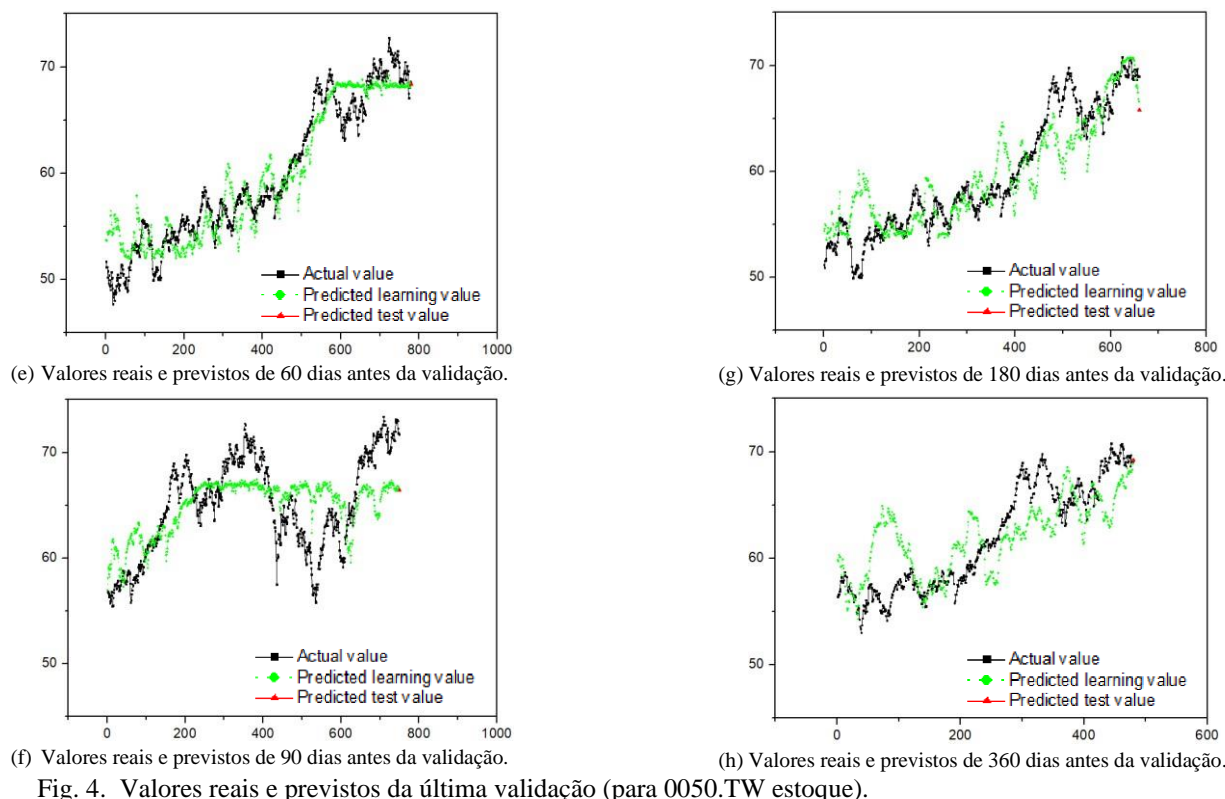
(c) Valores reais e previstos de 15 dias antes da validação.



(b) Valores reais e previstos de 10 dias antes da validação.



(d) Valores reais e previstos de 30 dias antes da validação.



exemplo, a Tabela IX mostra os valores RMSE, MAE, MAPE e MSE das ações da NASDAQ de 0,712, 0,536, 0,901% e 0,507, respectivamente. Como esperado, as previsões de um dia antes do conjunto de dados de ações 0050.TW que foram feitas usando o modelo proposto foram muito melhores do que aquelas baseadas nas ações do THE BIST 100 e NASDAQ. Para o 2597.TW ações, os valores RMSE, MAE, MAPE e MSE foram de 1.548, 0,617, 1.372% e 2.396, respectivamente. A previsão de um dia antes do preço do 2597.TW ações foi melhor do que a do preço das ações de qualquer uma das outras construtoras da MAPE. O melhor desempenho de previsão foi alcançado para o preço das ações do S&P 500.

A Tabela IX também revisa a literatura-chave que é relevante para o presente trabalho e fornece detalhes sobre as escolhas dos conjuntos de dados e medidas de performance nesses artigos. A Tabela IX lista os valores médios das medidas de desempenho obtidas em trabalhos anteriores [4, 22, 35-39], nos quais diferentes conjuntos de dados e algoritmos de aprendizagem foram usados para prever os preços de fechamento das ações no dia seguinte. Claramente, as previsões de um dia antes dos valores nos oito estoques alcançaram MAPEs superiores em comparação com os modelos relatados anteriormente.

Neste estudo, a "taxa de acerto" também é usada como medida de desempenho para prever se as ações irão ou para baixo em um determinado período de tempo. A taxa de acerto indica com que frequência um modelo dá uma previsão correta

em termos da direção do preço [40]. A Tabela X mostra uma comparação de taxa de acerto do modelo proposto usando os oito conjuntos de dados de ações. A predição de um dia antes da direção de preço para o 2542.TW e 2597.TW ações foi melhor do que as outras que utilizam o sistema proposto, como pode ser visto facilmente.

### 3) Comparação do lucro

As medições estatísticas de desempenho e a direção do preço das ações não têm muito significado para investidores práticos. O desempenho financeiro de um modelo de previsão também deve ser examinado para avaliar um modelo de previsão. Os comportamentos de compra e venda de um investidor típico podem ser simulados. Um investidor comprará ações do mercado se esperar um aumento nos preços e venderá seus ativos financeiros para evitar uma perda potencial se esperar uma queda nos preços. Esta simples lógica de negociação foi simplificada usando as previsões feitas usando o modelo proposto. Para simplificar, nenhum imposto ou taxas foram associados a qualquer transação.

TABELA VIII

CONJUNTOS DE DADOS DE AÇÕES THREE

Dataset	Total N°. de pontos de dados	Duração de dados
Borsa Istanbul 100 (BIST 100)	1395	5 de outubro de 2011 a 31 de maio de 2017

Associação Nacional de Revendedores de Valores Mobiliários Cotação Automatizada Sistema (NASDAQ)	1421	5 de outubro de 2011 a 31 de maio de 2017
Standard's & Poor's 500 (S & P 500)	1421	5 de outubro de 2011 a 31 de maio de 2017

De acordo com pesquisas anteriores, o lucro que foi obtido nas oito ações durante 300 dias de negociação, quando os investimentos foram gerenciados de acordo com as previsões feitas utilizando o sistema proposto. A Tabela XI compara os resultados da negociação utilizando o sistema de híbrida proposto com os obtidos utilizando o método BUY e HOLD. Nesse método, um investidor compra ações desde o início do período de negociação e vende todos os seus ativos a partir do fim do período de negociação, preço de fechamento. O sistema proposto supera com as ações do BIST 100. Mais lucro foi feito na 2542.TW ações do que nas ações de outras construtoras. A Tabela XI também revela que o sistema proposto com as oito ações gera lucros maiores do que o método tradicional BUY e HOLD.

#### IV. CONCLUSÕES E RECOMENDAÇÕES

A decisão de comprar ou vender uma ação é muito complicada, pois muitos fatores podem afetar o preço das ações. Este trabalho apresenta uma nova abordagem, baseada em um algoritmo metaheurístico firefly e menos quadrados suportam a regressão vetorial (MetaFA-LSSVR), para a construção de um sistema de especialistas em previsão de preços de ações, com o objetivo de melhorar a precisão da previsão. O sistema inteligente de previsão de séries temporal que usa otimização metaheurística de janela deslizante é uma interface gráfica de usuário que pode ser executada como um aplicativo autônomo. O sistema torna mais simples a previsão de valores do mercado de ações, envolvendo menos cálculos, do que o que utiliza o outro método que foi mencionado acima.

A FA original é complementada com três componentes metaheurísticos – mapas caóticos, peso de inércia adaptável e voo Lévy – para construir um algoritmo de otimização metaheurística (MetaFA). O desempenho superior do MetaFA foi verificado por meio da validação das funções de benchmark. Assim, o MetaFA foi adotado para sintonizar automaticamente os hiperparâmetros  $C$  e  $\gamma$  do LSSVR. O modelo de previsão LSSVR otimizado foi utilizado com a abordagem de janela deslizante para avaliar e prever o preço das ações. As configurações padrão do sistema, incluindo parâmetros pré-definidos, economizam tempo dos usuários.

Para avaliar a abordagem proposta, foi aplicado a cinco conjuntos de dados para ações em Taiwan, e três outros conjuntos de dados de ações que foram usados em outros artigos. Medidas estatísticas foram obtidas quando aplicadas ao desempenho da abordagem proposta. Os conjuntos de estoque da empresa de construção de Taiwan alcançados na previsão 1, 15 e 30 dias antes do tempo nos níveis de significância

estatística desejados. Em particular, a previsão de um dia de 2597.TW preços das ações foi melhor que a de qualquer valor das ações da construtora com um MAPE de 1,372%, um R de 0,990, e um  $R^2$  de 0,973. Ao final do estudo, o desempenho financeiro do sistema proposto foi examinado com resultados animadores. Portanto, o sistema proposto pode ser usado como uma ferramenta decisiva para prever preços das ações para investimentos de curto prazo.

Este estudo se concentra no mercado de preços das ações em Taiwan. Para generalizar a aplicação do sistema proposto, o trabalho futuro deve usar o sistema proposto para estimar outras ações em mercados emergentes semelhantes e mercados maduros, como Vietnã, Indonésia, China, Japão, Hong Kong, Coreia, Cingapura, Europa e EUA. Em segundo lugar, o sistema pode ser estendido para analisar dados de séries temporais multivariadas e importar diretamente o conjunto de dados brutos. Em terceiro lugar, o lucro pode ser maximizado mesmo quando o mercado de ações corporativos de construção está em alta. Finalmente, o desenvolvimento de um aplicativo baseado na Web deve ser considerado para melhorar a simpatia do usuário e a usabilidade do sistema especializado.

A limitação do sistema proposto é sua velocidade computacional, especialmente no que diz respeito à validação da janela deslizante, devido à complexidade da resolução de grandes loops matemáticos no programa MATLAB. O custo computacional aumenta com o número de validações. Outra fraqueza é a necessidade de definir muitos parâmetros do sistema (MetaFA e parâmetros da série temporal), embora as configurações padrão sejam fornecidas. Além disso, o sistema não alcança excelentes resultados para investimentos de longo prazo – um achado que motivará pesquisas futuras.

TABELA IX  
COMPARAÇÃO DE DESEMPENHO DE PREVISÃO DO DIA ANTERIOR ENTRE O MÉTODO PROPOSTO E OS MÉTODOS EXISTENTES

Método	Dataset	Medidas de desempenho			
		RMSE	MAE	MAPA (%)	MSE
O sistema de previsão de séries temporal inteligente proposto usando otimização metaheurística de janela deslizante	2542.TW	2.308	0.863	1.745	5.239
	2545.TW	1.372	0.558	1.701	1.883
	2597.TW	1.548	0.617	1.372	2.396
	5534.TW	1.728	0.823	1.494	2.986
	0050.TW	0.644	0.474	0.713	0.414
	BIST 100	1.056	0.782	0.981	1.115
	NASDAQ	0.712	0.536	0.901	0.507
	S&P 500	0.182	0.127	0.613	0.033
Göçken <i>et al.</i> [4] e Hadavandi <i>et al.</i> [35]	BIST 100	2.413	2.833	3.688	12.651
Bhattacharya <i>et al.</i> [38] e Shen <i>et al.</i> [39]	NASDAQ	0.042	-	0.160	5.721
Rout <i>et al.</i> [22], Anish <i>et al.</i> [36] e Dash <i>et al.</i> [37]	S & P 500	0.037	-	9.436	0.003

TABELA X

COMPARAÇÃO NA TAXA DE ACERTO

Dataset	Tempo de previsão correto	Taxa de acerto
2542.TW	160 de 299	53.511%
2545.TW	143 de 299	47.826%
2597.TW	162 de 299	54.180%
5534.TW	136 de 299	45.484%
0050.TW	146 de 299	48.829%
BIST 100	139 de 299	46.488%
NASDAQ	143 de 299	47.826%
S & P 500	136 de 299	45.484%

TABELA XI

ANÁLISES COMPARATIVE DE VÁRIAS NEGOCIAÇÕES RESULTADOS

Estoque	Preço no início de o investimento período (1000 USD)	Preço no final do investimento período (1000 USD)	Lucro por ação aplicando a proposta sistema (1000 USD)	Lucro usando o método BUY and HOLD (1000 USD)
2542.TW	48.25	48.20	37.40	-0.05
2545.TW	29.35	39.20	32.00	9.85
2597.TW	44.50	37.20	27.35	-7.3
5534.TW	55.7	52.90	35.43	-2.8
0050.TW	60.35	71.75	30.20	11.4
BIST 100	71.34	79.76	39.48	8.42
NASDAQ	50.99	68.44	20.22	17.45
S&P 500	19.14	21.60	26.11	2.46

REFERÊNCIAS

- [1] J. P. He, L. Cai, P. Cheng, e J. L. Fan, "Investimento ideal para Empresa varejista no Mercado de Eletricidade", *Ieee Transactions on Industrial Informatics*, vol. 11, nº 5, pp. 1210-1219, out, 2015.
- [2] Y. Perwej, A. Perwej, e "Forecast of the Bombay Stock Exchange (BSE) retorna usando rede neural artificial e algoritmo genético", *Journal of Intelligent Learning Systems and Applications*, vol. 4, pp. 108-119, 2012.
- [3] A. A. Arafah, e I. Mukhlash, "The Application of Fuzzy Association Rule on Co-movement Analyze of Indonesian Stock Price", *Procedia Computer Science*, vol. 59, pp. 235-243, 2015/01/01, 2015.
- [4] M. Göçken, M. Özçalıcı, A. Boru e A. T. Dosdoğru, "Integrando metaheurísticas e Redes Neurais Artificiais para melhor previsão de preço das ações", *Expert Systems with Applications*, vol. 44, pp. 320-331, 2016.
- [5] Y. Bao, Y. Lu e J. Zhang, "Previsão de Preço de Stock por SVMs Regressão", *Inteligência Artificial: Metodologia, Sistemas e Aplicações*, C. Bussler e D. Fensel, eds., pp. 295-303, Berlim, Heidelberg: Springer Berlin Heidelberg, 2004.
- [6] D. Saini, A. Saxena e R.C. Bansal, "Preço da eletricidade forecasting por regressão linear e SVM." pp. 1-7.
- [7] J. Wang, R. Hou, C. Wang e L. Shen, "Modelo de regressão vetorial v-Support melhorado com base na seleção variável e otimização da tempestade cerebral para previsão de preços de ações", *Applied Soft Computing*, vol. 49, pp. 164-178, 2016.
- [8] J.-S. Chou, e N.-T. ONG, "Força de engenharia do solo reforçado com fibra estimado pelo sistema de regressão otimizado de inteligência de enxame", *Computação Neural e Aplicações*, 28 de dezembro de 2016.
- [9] A. Jindal, A. Dua, K. Kaur, M. Singh, N. Kumar, e S. Mishra, "Decision Tree e SVM-Based Data Analytics for Theft Detection in Smart Grid", *Ieee Transactions on Industrial Informatics*, vol. 12, nº 3, pp. 1005-1016, Jun, 2016.
- [10] V. Behbood, J. Lu e G. Q. Zhang, "Adaptação do Domínio de Refinamento Difuso para Previsão de Longo Prazo no Ecossistema Bancário", *Ieee Transactions on Industrial Informatics*, vol. 10, nº 2, pp. 1637-1646, maio de 2014.
- [11] V. N. Vapnik, *a natureza da teoria da aprendizagem estatística*: Springer-Verlag New York, Inc., 1995.
- [12] J. A. K. Suykens, "Modelagem não linear e máquinas vetoriais de suporte." pp. 287-294.
- [13] C.-J. Lu, T.-S. Lee e C.-C. Chiu, "Previsão de séries de tempo financeiro utilizando análise de componentes independentes e regressão vector de suporte", *Sistemas de Suporte de Decisão*, vol. 47, nº 2, pp. 115-125, 2009.
- [14] W. Hao, e S. Yu, "Support Vector Regression for Financial Time Series Forecasting", *Knowledge Enterprise: Intelligent Strategies in Product Design, Manufacturing, and Management*, K. Wang, G. L. Kovacs, M. Wozny and M. Fang, eds., pp. 825-830, Boston, MA: Springer US, 2006.
- [15] S.-G. Deng, e T.-H. "Usando máquinas de vetores de suporte menos quadrados para a estimativa de custo do produto", *Journal of Chung Cheng Institute of Technology*, vol. 40, nº 1, pp. 1-16, 2011.
- [16] F. Kaytez, M.C. Taplamacioglu, E. Cam e F. Hardalac, "Previsão do consumo de eletricidade: uma comparação da análise de regressão, redes neurais e menos quadrados suportam máquinas

- vetoriais", *International Journal of Electrical Power and Energy Systems*, vol. 67, pp. 431-438, 2015.
- [17] K. Duan, S. S. Keerthi e A. N. Poo, "Avaliação de medidas simples de desempenho para ajuste de hiperparâmetros SVM", *Neurocomputing*, vol. 51, pp. 41-59, 2003.
- [18] T. Xiong, Y. Bao e Z. Hu, "Regressão vetorial de suporte de produção múltipla com um algoritmo de firefly para previsão de índice de preços de ações com valor de intervalo", *Sistemas Baseados em Conhecimento*, vol. 55, pp. 87-100, 2014.
- [19] H.-I. Hsieh, T.-P. Lee e T.-S. Lee, "Um modelo de otimização de enxame de partículas híbridas e suporte ao modelo de regressão vetorial para financeira Previsão da Série Time", *International Journal of Business Administration*, vol. 2, pp. 48-56, 2011.
- [20] W. Jianzhou, J. Shiqiang, Q. Shanshan e J. Haiyan, "Modelos Híbridos Baseados em Inteligência swarm para previsão de carga de curto prazo", *Problemas Matemáticos em Engenharia*, vol. 2014, pp. 17, 2014.
- [21] X.-S. Yang, *Algoritmos Metaheurísticos Inspirados na Natureza*: Luniver Press, 2008.
- [22] A. K. Rout, R. Bisoi e P. K. Dash, "Uma rede neural de link funcional recorrente de baixa complexidade e eficiente para a previsão de séries temporais", *2015 IEEE Power, Communication and Information Technology Conference, PCITC 2015 - Proceedings*, pp. 576-582.
- [23] J.-S. Chou, e A.-D. Pham, "Vetor de suporte baseado em algoritmo artificial inteligente da colônia de fogos de fogo para previsão aprimorada em engenharia civil", *engenharia civil e de infraestrutura auxiliada por computador*, vol. 30, nº 9, pp. 715-732, 2015.
- [24] J.-S. Chou, W. K. Chong e D.-K. Bui, "Inspirado na Natureza Sistema de Regressão Metaheurística: Programação e Implementação para Aplicações de Engenharia Civil", *Revista de Computação em Engenharia Civil*, vol. 30, nº 5, 2016.
- [25] A. H. Gandomi, X. S. Yang e A. H. Alavi, "Otimização estrutural variável mista usando algoritmo firefly", *Computadores e Estruturas*, vol. 89, nº 23-24, pp. 2325-2336, 2011.
- [26] J.-S. Chou, K.-H. Yang, J. P. Pampang e A.-D. Pham, "Inteligência metaheurística evolutiva para simular cargas de tração em reforço para estruturas de solo reforçadas por geossintéticos", *Computadores e Geotecnia*, vol. 66, pp. 1-15, 2015.
- [27] R. S. T. Lee, "consultor de ações do iJADE: Um sistema inteligente de previsão de ações baseado em agente usando rede recorrente RBF híbrida", *IEEE Transactions on Systems, Man, and Cybernetics Part A: Systems and Humans*, vol. 34, no. 3, pp. 421-427, 2004.
- [28] N.D. Hoang, A.-D. Pham, e a.M.-T. Cao, "Uma nova abordagem de previsão da série time baseada em uma hibridização de menos praças suportam a regressão vetorial e a inteligência do enxame", *Inteligência Computacional E Soft Computing*, vol. 2014, nº 2014, pp. 8, 2014.
- [29] J.-S. Chou, e N.-T. ONG, "Análise da série time usando sistema de aprendizado de máquina baseado em otimização metaheurística de janela deslizante para identificar padrões de consumo de energia de construção", *Applied Energy*, vol. 177, pp. 751-770, 2016.
- [30] J. A. K. Suykens, T. V. Gestel, J. D. Brabanter, B. D. Moor e J. Vandewalle, *Least quadrados suportam máquinas vetoriais*: World Scientific, Singapura, 2002.
- [31] I. Fister, I. Fister Jr, X.-S. Yang e J. Brest, "Uma revisão abrangente dos algoritmos do firefly", *Swarm e Evolutionary Computação*, vol. 13, pp. 34-46, 2013.
- [32] J.-S. Chou, e A.-D. Pham, "Otimização metaheurística inspirada na natureza em pelo menos praças apoiam a regressão vetorial para a obtenção de informações de varredura de pontes", *Ciências da Informação*, vol. 399, pp. 64-80, 2017.
- [33] D. He, C. He, L.-g. Jiang, H.-w. Zhu, e G.-r. Hu, "Características caóticas de um mapa iterativo unidimensional com colapsos infinitos", *IEEE Transactions on Circuits and Systems I: Fundamental Theory and Applications* vol. 48, no. 7, pp. 900 - 906, 2001.
- [34] T. Geisel, J. Nierwetberg, e A. Zacherl, "Difusão Acelerada em Josephson Junctions e Sistemas Caóticos Relacionados", *Physical Review Letters*, vol. 54, nº 7, pp. 616-619, 1985.
- [35] E. Hadavandi, H. Shavandi e A. Ghanbari, "Integração de sistemas genéticos difusos e redes neurais artificiais para previsão de preços de estoque", *Sistemas baseados em conhecimento*, vol. 23, nº 8, pp. 800-808, 2010.
- [36] C.M. Anish, e B. Majhi, "Esquema adaptativo híbrido não linear para previsão do mercado de ações usando feedback FLANN e análise de fatores", *Journal of the Korean Statistical Society*, vol. 45, no. 1, pp. 64-76, 2016.
- [37] R. Dash e P. Dash, "Previsão eficiente do preço das ações usando um sistema de inferência neuro-fuzzy recorrente auto-evoluído otimizado através de uma técnica de pesquisa de harmonia diferencial modificada", *Sistemas especializados com aplicações*, vol. 52, pp. 75-90, 2016.
- [38] D. Bhattacharya, A. Konar e P. Das, "Fator secundário induziu previsão de séries temporais do índice de ações induzidas por índice de ações usando Conjuntos Difusos tipo-2 de intervalo auto-adaptativo", *Neurocomputus*, vol. 171, pp. 551-568, 2016. [39] Shunrong Shen, Haomiao Jiang e T. Zhang, "Mercado de Ações Previsão usando algoritmos de aprendizagem de máquina", *IEEE Transações em Redes Neurais*, vol. 84, nº 4, pp. 21, 2015.
- [40] Huaguang Zhang, Jiuzhen Liang e Z. Chai, "Previsão de Estoque Baseada na Reconstrução espacial de fase e redes estaduais echo", *Journal of Algorithms & Computational Technology*, vol. 7, no. 1, pp. 87-100, 2012.



**Jui-Sheng (Rayson) Chou** é especialista em análise de projetos e gerenciamento de engenharia. Atualmente, é Professor Titular no Departamento de Engenharia Civil e Construtiva da Universidade Nacional de Taiwan de Ciência e Tecnologia (Taiwan Tech). Dr. Chou recebeu seu BS e MS da National Taiwan

Universidade and seu PhD em Engenharia de Construção e Projeto Management at o Departamento de

Civil,

Engenharia Arquitetônica e Ambiental - Universidade do Texas em Austin. Possui carteiras de engenheiro profissional registradas e atua em diversos comitês profissionais. Prestou serviços de consultoria a diversos setores privados e públicos de engenharia. É autor ou coautor de centenas de artigos de revistas, capítulos de livros, artigos de conferência e relatórios técnicos relacionados à gestão de engineering e é membro de vários conselhos editoriais internacionais.



**Thi-Kha Nguyen** recebeu o bacharelado em Gestão de Projetos de Construção pela Danang University of Science and Technology, Vietnã, em 2013. Ela recebeu o mestrado em Ms pelo Departamento de Engenharia Civil e Construtiva da Universidade Nacional de Ciência e Tecnologia de Taiwan (Taiwan Tech), Taiwan, em 2017.

Atualmente, é professora da Faculdade de Engenharia e Agricultura da Universidade de Danang – Campus em Kontum, Vietnã. Seus interesses de pesquisa current são economia da construção e gerenciamento de projetos.