

Manuscrito Aceito

Uma abordagem de decomposição do modo variacional para análise e
Previsão da Série Tempo Econômico-Financeiro

Salim Lahmiri

PII:S0957-4174(16)30056-2

DOI: [10.1016/j.eswa.2016.02.025](https://doi.org/10.1016/j.eswa.2016.02.025)

Referência: ESWA 10542


Para aparecer em: *Sistemas especializados com
aplicações*

Data recebida: 10 de junho de 2014

Data revisada: 30 de setembro de 2015

Data aceita: 12 de fevereiro de 2016

Por favor, cite este artigo como: Salim Lahmiri , A Variational Mode Decomposition Approach for Analysis and Forecasting of Economic and Financial Time Series, *Expert Systems With Applications* (2016), doi: [10.1016/j.eswa.2016.02.025](https://doi.org/10.1016/j.eswa.2016.02.025)



Este é um arquivo PDF de um manuscrito não publicado que foi aceito para publicação. Como um serviço para nossos clientes estamos fornecendo esta versão inicial do manuscrito. O manuscrito passará por cópiação, digitação e revisão da prova resultante antes de ser publicado em sua forma final. Observe que durante o processo de produção podem ser descobertos erros que podem afetar o conteúdo e todas as isenções legais que se aplicam ao diário pertinem.

Uma abordagem de decomposição do modo variacional para análise e previsão de Série tempo econômico e financeira

Salim Lahmiri

Escola de Gestão do ESCA
Rua Abou Youssef El Kindy, BD Moulay Youssef
Casablanca slahmiri@esca.ma

Abstrair.

A decomposição do modo empírico (EMD) foi aplicada com sucesso para decompor adaptativamente séries tempoeconômicas e financeiras com o propósito de previsão. Recentemente, a decomposição do modo variacional (VMD) foi proposta como uma alternativa ao EMD para separar facilmente tons de frequências semelhantes em dados onde o EMD falha. O objetivo deste estudo é apresentar uma nova série temporal paramodelo de ecasting que integra VMD e rede neural de regressão geral (GRNN). O desempenho do modelo proposto é avaliado comparando os resultados de previsão da VMD-GRNN com três modelos de previsão concorrentes; ou seja, o modelo EMD-GRNN, alimentadoredes neurais de ala (FFNN) e processo de média móvel autoregressiva (ARMA) no West Texas Intermediate (WTI), taxa de câmbio canadense/norte-americana (CANUS), produção industrial dos EUA (IP) e o Chicago Board Options Exchange NASDAQ 100 Volatility Index (VIX) tempo series são usados para experimentações. Com base no erro absoluto médio (MAE), erro percentual absoluto médio (MAPE) e na média raiz de erros quadrados (RMSE), os resultados da análise demonstram a superioridade do método baseado em VMD sobre o three abordagens de previsão concorrente. Os resultados da análise prática sugerem que a VMD é uma técnica eficaz e promissora para análise e previsão de séries temporais econômicas e financeiras.

Keywords. Decomposição do modo empírico, decomposição do modo variacional, séries temporais, regressão, rede neural, previsão.

1. Introdução

Huang et al. (1998) introduziram uma técnica adaptativa chamada decomposição do modo empírico (EMD) para representar sinais não estacionários não lineares como somas de componentes com parâmetros modulados de amplitude e frequência. Em particular, é uma técnica de multiresolução para realizar a decomposição de frequência espacial conjunta de um sinal empiricamente pela remoção sucessiva de sinais elementais, as funções de modo intrínseco ou FMI, que representam os modos oscilatórios do sinal original indo de faixas de alta a baixa frequência. Os IMFs obtidos podem então servir para representar o sinal. A função do modo intrínseco é completa, adaptativa e quase ortogonal. A principal vantagem do uso da técnica EMD é que o sinal de entrada é analisado sem a necessidade de envolvê-lo com uma função base como feito para fourier e wavelet transforma. Além disso, o método é baseado em dados e, thus, auto-adaptável. Esses recursos tornam o EMD adequado para análise de dados não lineares e não estacionários. Devido às suas características atraentes, foi aplicado em diversas áreas científicas de processamento de sinais; incluindo engenharia mecânica (Ricci & Pennacchi, 2011), descansagem de sinal (Li et al., 2011, Lahmiri e Boukadoum, 2014a, 2015a), identificação de alto-falantes (Wu et al, 2011), análise biomédica de imagem (Ai et al., 2011, Lahmiri e Boukadoum, 2014b, 2015b), análise de sequência de DNA (Zhang et al, 2012) e diagnóstico de falha de máquina (Cheng et al, 2012).

O EMD também recebeu uma grande atenção na análise de dados econômicos e financeiros para fins de previsão. Por exemplo, foi empregado na modelagem e previsão do preço do petróleo bruto (Zhang et al, 2008; Zhang et al, 2009), bolsa de valores (Cheng et al, 2014), preço da eletricidade (An et al, 2013, Lisi e Nan, 2014) e taxa de câmbio (Lin et al, 2012, Premanode e Toumazou, 2013).

Mais recentemente, uma nova multiresolução chamada variação decomposição do modo (VMD) foi introduzido por Dragomiretskiy e Zosso (2014) como uma alternativa ao algoritmo EMD para superar seus limites. Por exemplo, desvantagens do EMD incluem falta de modelo matemático exato, escolha de interpolação e sensibilidade para tanto ruído quanto

amostragem (Dragomiretskiy & Zosso, 2014). O VMD é um modelo variacional totalmente não recursivo onde os modos são extraídos simultaneamente (Dragomiretskiy & Zosso, 2014). Em particular, o modelo VMD busca por um número de modos e seus respectivas frequências centrais, de modo que os modos de banda limitadas reproduzem o sinal de entrada exatamente ou no sentido de menos quadrados (Dragomiretskiy & Zosso, 2014). Em suma, o VMD tem a capacidade de tons separados de frequências semelhantes contrárias ao EMD (Arrastaromiretskiy & Zosso, 2014). Usando funções harmônicas simuladas, Dragomiretskiy e Zosso (2014) descobriu que o VMD como uma abordagem denoizante supera o EMD. A VMD foi considerada eficaz na denoização de sinais biomédicos (Lahmiri e Boukadoum, 2014c, 2015c) e também foi aplicado na análise dos mercados acionários internacionais (Lahmiri, 2015d). No entanto, é necessário explorar a eficácia do VMD contra o EMD na modelagem e previsão de dados econômicos e financeiros. De fato, modelagem e previsão Os dados econômicos e financeiros são cruciais para que o governo estabeleça política econômica e que as empresas gerenciem carteiras e controlem riscos.

O objetivo deste estudo é explorar a utilidade do VMD na extração de características da série tempo econômico-financeira (componentes) para fins de previsão. Em particular, comparamos o desempenho da abordagem baseada em EMD e VMD em termos de precisão de previsão de quatro dados econômicos e financeiros: West Texas Intermediate (WTI) (petróleo bruto), taxa de câmbio canadense/norte-americana, produção industrial dos EUA (IP) e o Chicago Board Options Exchange NASDAQ 100 Volatility Index (VIX).

Por fim, o desempenho de cada abordagem será avaliado em virtude de medidas de desempenho estatísticos que são o erro absoluto médio (MAE), erro percentual absoluto médio (MAPE) e a média raiz dos erros quadrados (RMSE). A rede neural de regressão geral (GRNN) (Specht, 1991) será usada para treinamento e teste dos padrões extraídos em EMD e VMD. O GRNN é escolhido, pois fornece aprendizado rápido e convergências para a superfície de regressão ideal à medida que o número de amostras se torna muito grande (Polat & Yildirim, 2008). Neste trabalho, uma rede neural de alimentação (FFNN) (Haykin, 2008) treinada com observações passadas e o conhecido processo autoregressivo de média móvel (ARMA) também serão considerados como modelos de linha de base para fins de comparação.

O restante do papel é organizado da seguinte forma. Na Seção 2 introduz brevemente a decomposição do modo empírico, a decomposição do modo variacional e a rede neural de regressão geral. Os resultados da simulação obtida são fornecidos na Seção 3, enquanto a Seção 4 conclui.

2. Métodos

Dois sistemas principais de previsão são projetados, avaliados e comparados. No primeiro sistema, o EMD é aplicado aos dados originais (sinal) para obter suas funções de modo intrínseco (IMFs). Em seguida, eles serão alimentados com a GRNN para fins de previsão. Da mesma forma, eu.n o segundo sistema, o VMD é aplicado aos dados originais (sinal) para obter seus modos de variação. Em seguida, este último será alimentado com o GRNN para fins de previsão. Os dois sistemas de previsão são descritos em Fig. 1 e em Fig. 2 respectivamente. O EMD, As medidas de VMD, GRNN e desempenho estatístico são descritas a seguir.






Fig. 1. Sistema baseado em EMD.




Fig. 2. Sistema baseado em VMD.

2.1 Decomposição do modo empírico

A principal característica do EMD é decompor um sinal em uma soma de funções de tal forma que cada uma delas tenha os mesmos números de cruzamentos zero e extrema, and é simétrica em relação à sua média local (Huang et al., 1998). Estas são as chamadas Funções de Modo Intrínseco (IMFs). Os IMFs são encontrados em cada escala indo de multa a grosseira por um procedimento iterativo chamado algoritmo de peneiração. Para um sinal $s(t)$, a decomposição do EMD é realizada da seguinte forma (Liu et al., 2007):

- Encontre todas as máximas locais, $M_{i,i} \in 1,2,\dots$, e mínima, $m_{k,k} \in 1,2,\dots$, em $s(t)$.
- Calcular por interpolação - por exemplo, um Spline cúbico - os envelopes superior e inferior do sinal: $M_{i,t} \in f_M \in M_{i,t}$ e $m_{k,t} \in f_m \in m_{k,t}$.
- Calcular o envelope significa $e(t)$ como a média dos envelopes superior e inferior: $e_{i,t} = (M_{i,t} + m_{k,t}) / 2$.
- Calcule os detalhes como: $d_{i,t} = s_{i,t} - e_{i,t}$.
- Verifique as propriedades de $d(t)$:
 - Se $d(t)$ atender às condições sobre o número de extrema e simetria declaradas anteriormente, calcule o i th FMI como $FMI_{i,t} = d_{i,t}$ e substitua $s(t)$ pelo $s_{i,t} = s_{i,t} - FMI_{i,t}$.
 - Se $d(t)$ não for um FMI, substitua $s(t)$ pelo detalhe: $s_{i,t} = d_{i,t}$.
- Etapas iteradas (a) para (e) até que o $r(t)$ residual satisfaça um determinado critério de parada. No final, $s(t)$ é expresso da seguinte forma:

$$N s_{i,t} = \sum_{j=1}^N IMF_j + r_N \quad (1)$$

onde N é o número de FMI que são quase ortogonais uns aos outros e todos têm meios quase zero; e $r_N(t)$ é o resíduo final que é a tendência de baixa frequência do sinal $s(t)$. Normalmente, o desvio padrão (SD) computado a partir de dois resultados consecutivos de peneiração é usado como critério para parar o processo de peneiração limitando o tamanho do SD (Huang et al., 1998; Chen et al., 2009) como:

$$\frac{1}{d} \int_0^T s(t) e^{j2\pi f_k t} dt \quad (2)$$

onde k é o índice da décima diferença entre o sinal $s(t)$ e o envelope significa $e(t)$. O termo $\frac{1}{d}$ é um valor de parada pré-determinado. Por exemplo, seu valor é definido para 0,001.

2.2 Decomposição do modo variacional

O objetivo do VMD é decompor um sinal de entrada em k número discreto de subassinões (modos), onde cada modo tem largura de banda limitada no domínio espectral (Dragomiretskiy e Zosso, 2014). Assim, cada modo k é necessário para ser principalmente compacto em torno de uma pulsação central f_k determinado junto com a decomposição (Dragomiretskiy e Zosso, 2014). O algoritmo VMD para avaliar a largura de banda de um sinal de uma dimensão é a seguinte (Dragomiretskiy e Zosso, 2014): (1) para cada modalidade u_k , calcular o sinal analítico associado por meio da transformação hilbert para obter um espectro de frequência unilateral, (2) para cada modo, shift the o espectro de frequência do modo à banda base misturando-se com uma frequência central exponencial, (3) estimar a largura de banda através da suavidade gaussiana do sinal desmodulado; por exemplo, a norma L2 quadrada do gradiente. Ésimoen, o problema variacional restrito é dado por (Dragomiretskiy e Zosso, 2014):

$$\min_{\{u_k\}} \sum_{k=1}^K \int_0^T \left| \frac{d}{dt} \left(u_k(t) e^{j2\pi f_k t} \right) \right|^2 dt \quad (3)$$

Sujeito a,

$$\sum_{k=1}^K u_k(t) = f(t) \quad (4)$$

onde f é o sinal, u é o seu modo, f_k é a frequência, δ é a distribuição Dirac, t é script de tempo, k é número de modos, e $*$ denota convolução. O modo u com k de alta ordem representa componentes de baixa frequência.

2.3 Rede neural de regressão geral

O GRNN (Specht, 1991) é um sistema paralelo e baseado em memória que estima o surf de regressãoace de uma variável contínua. É um algoritmo de aprendizagem de um passe; assim fornece aprendizado rápido e convergências para a superfície de regressão ideal quando o tamanho da amostra é grande (Specht, 1991). Suponha que a entrada do sistema seja o vetor X , e a estimativa desejada da saída do sistema é o vetor Y . Suponha que a função de densidade de probabilidade contínua conjunta de X e Y é representado por uma função desconhecida $f(x,y)$. Então, a regressão de y em x é representado por:

$$\hat{y} = \frac{\sum_{j=1}^N \frac{y_j}{\|x - x_j\|}}{\sum_{j=1}^N \frac{1}{\|x - x_j\|}}$$

$$E[y|X=x] = \int_{-\infty}^{\infty} y f(x,y) dy \quad (5)$$

A função de densidade contínua de probabilidade contínua de articulação *desconhecida* $f(x,y)$ é estimada da seguinte forma:

$$f(x,y) = \frac{1}{(2\pi)^{p/2}} \exp\left\{-\frac{1}{2} \sum_{i=1}^p \frac{(y_i - \mu_i)^2}{\sigma_i^2}\right\} \exp\left\{-\frac{1}{2} \sum_{i=1}^p \frac{(x_i - \mu_i)^2}{\sigma_i^2}\right\}$$

onde $\sigma < 1$ é a largura do kernel gaussiano, p é a dimensão de X , e n é o tamanho da amostra. Quando $f(x,y)$ é substituído em $E[y|X=x]$, então a função de saída $Y(X)$ é dada por:

$$Y(X) = \frac{\sum_{i=1}^n \frac{1}{D_{i2}} \exp\left\{-\frac{1}{2} \sum_{j=1}^p \frac{(y_{ij} - \mu_j)^2}{\sigma_j^2}\right\} \exp\left\{-\frac{1}{2} \sum_{j=1}^p \frac{(x_{ij} - \mu_j)^2}{\sigma_j^2}\right\}}{\sum_{i=1}^n \frac{1}{D_{i2}} \exp\left\{-\frac{1}{2} \sum_{j=1}^p \frac{(x_{ij} - \mu_j)^2}{\sigma_j^2}\right\}} \quad (7)$$

onde D_{i2} é expresso da seguinte forma:

$$D_{i2} = \sum_{e=1}^T X_{ie} X_{ie}^T \quad (8)$$

O GRNN consiste em quatro camadas, incluindo a camada de entrada, camada de padrão, camada de somação e camada de saída. A camada de entrada é totalmente connected para a camada padrão, onde cada unidade representa um padrão de treinamento. Por exemplo, cada neurônio na camada de entrada representa uma determinada função de variação quando o VMD é empregado (modelo VMD-GRNN) ou uma função de modo intrínseco quando o EMD (modelo EMD-GRNN) é empregado. A camada padrão consiste em unidades padrão que representam todas as amostras de treinamento. As saídas da camada padrão são transmitidas para a camada de somação onde um produto de ponto entre um vetor de peso composto pelos sinais do padrão units é realizado. Finalmente, a camada de saída produz o valor previsto correspondente a um vetor de entrada desconhecido; por exemplo, o valor previsto da série temporal. Lembre-se que, para efeito de comparação, uma rede neural de alimentação (FFNN) (Haykin, 2008) trained com as cinco observações passadas e o conhecido processo autoregressivo da média móvel (ARMA) também serão empregados para avaliar a eficácia do modelo VMD-GRNN apresentado.

2.4. Medidas de desempenho

O desempenho de previsão é avaliado utilizando as seguintes medidas de desempenho: o erro absoluto médio (MAE), erro percentual absoluto médio (MAPE) e a média raiz dos erros quadrados (RMSE). Eles medem o desvio entre valores reais e previstos. Os valores menores de MAE, MAPE e RMSE, mais próximos são os valores de séries temporais aos do valor real. Assim, eles podem ser usados para avaliar o erro de previsão. As definições desses critérios são dadas da seguinte forma:

$$MAE = \frac{1}{n} \sum_{i=1}^n |A_i - P_i| \quad (9)$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|A_i - P_i|}{|A_i|} \times 100\% \quad (10)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (A_i - P_i)^2} \quad (11)$$

onde A e P representam, respectivamente, o valor real e previsto; e n é o número total de pontos de dados fora da amostra.

3. Resultados

Dados diários do West Texas Intermediate (WTI), canadian/us exchange rate (CANUS) e chicao board options exchange NASDAQ 100 Volatility Index (VIX), dados mensais da produção industrial dos EUA (IP) a partir de 2 de janeiroNd 2008 para December 16^{ésimo} 2013 foram utilizados para a realização de experimentos. Eles foram obtidos do Banco Federal de Saint Louis, EUA. Os primeiros 80% das amostras são utilizadas para o treinamento do GRNN e os 20% restantes são usados para testes. Fig. 3 a Fig. 6 exibem WTI, CANUS, IP e Série temporal VIX, onde x -eixo é número de observação e y -eixo são valores observados. Exemplos de IMFs e modos obtidos respectivamente por EMD e VMD para séries temporais IP são ilustrados em Fig. 7 e Fig. 8.




Fig. 3. Série tempoeial wti.

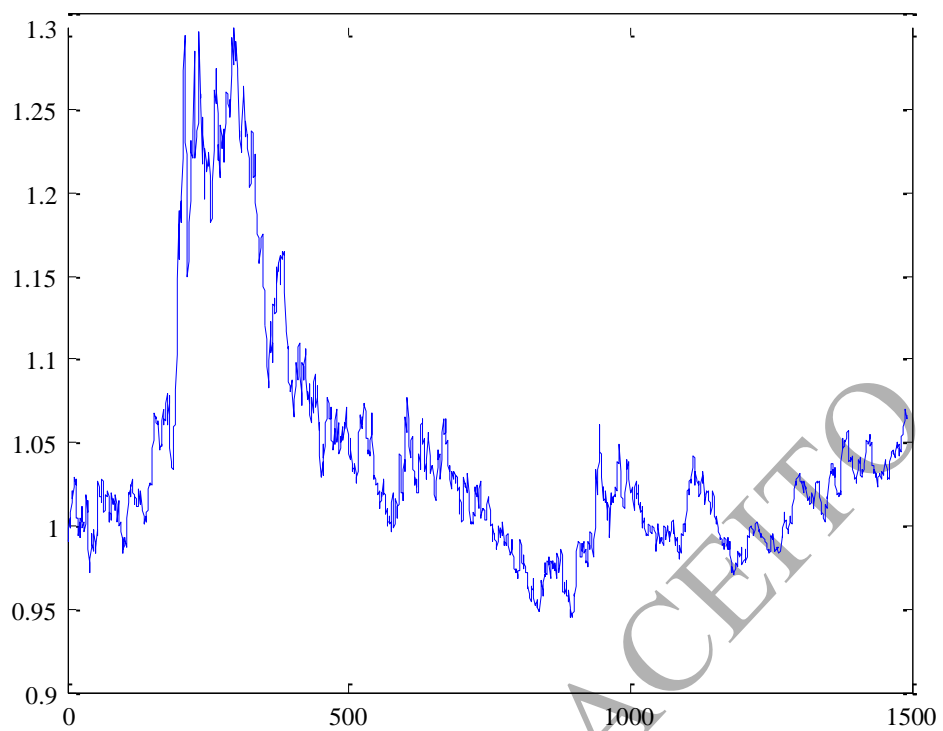


Fig. 4. Série de tempo de taxa de câmbio canadense/norte-

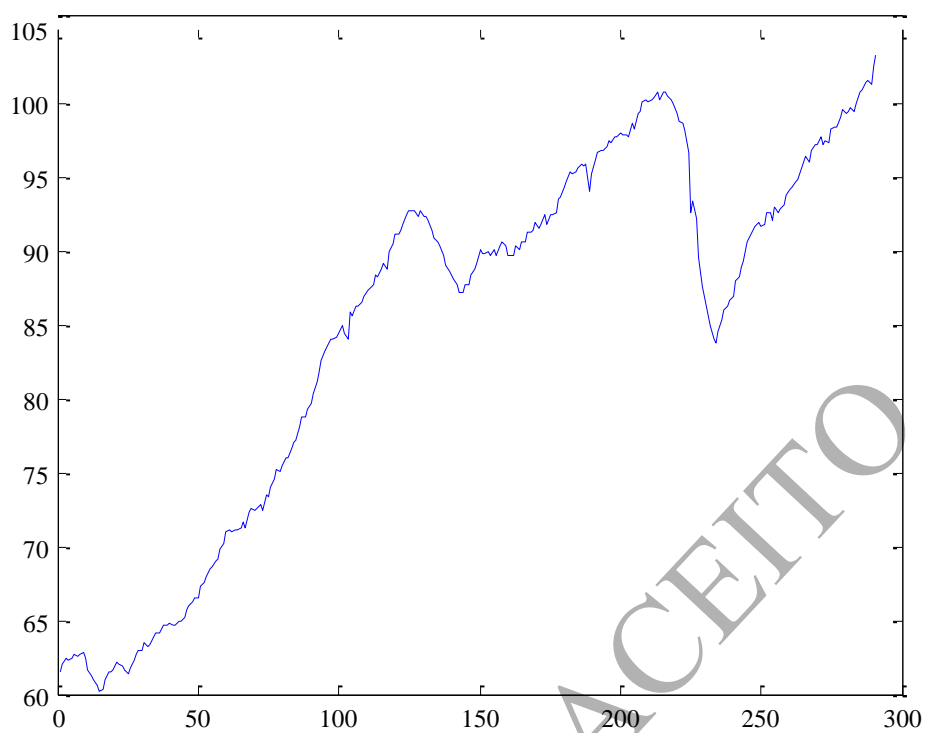


Fig. 5. IP série temporal

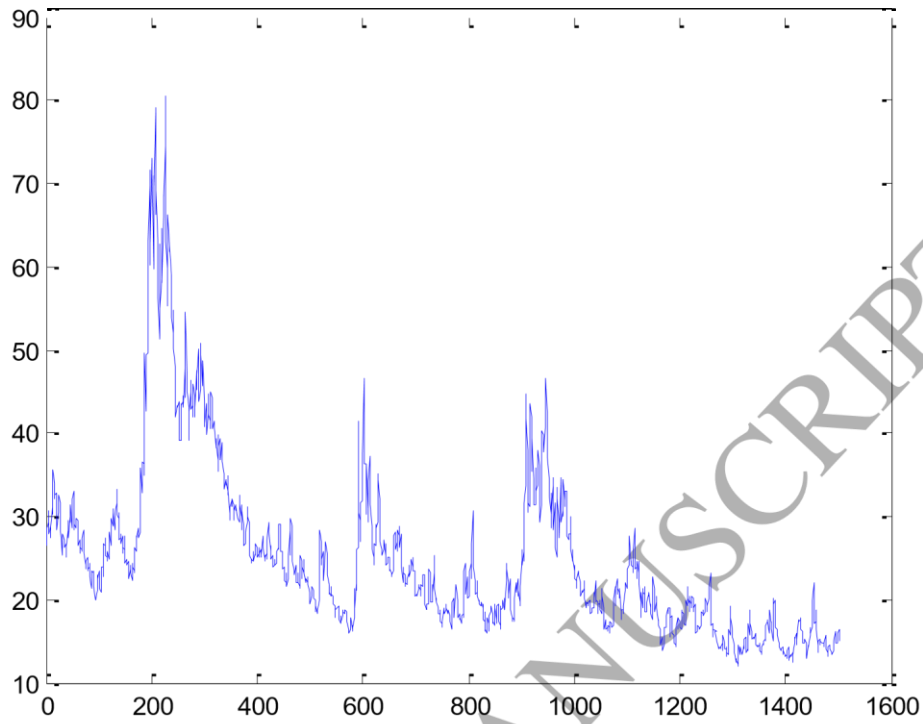


Fig. 6. VIX time series.

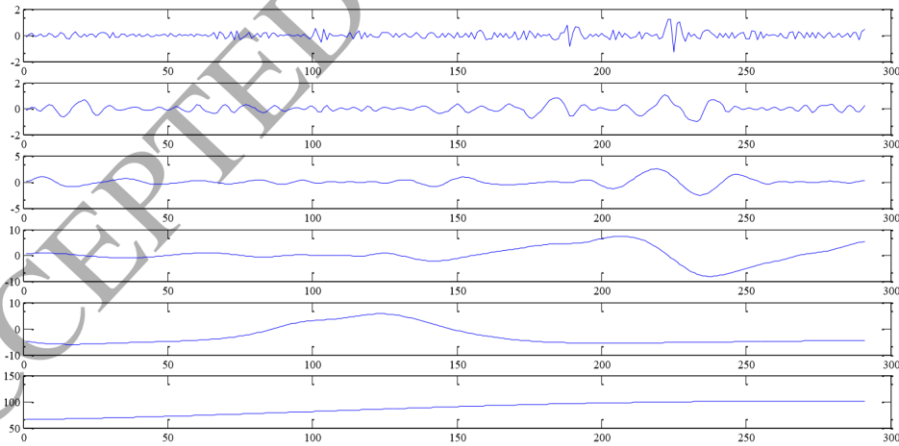


Fig. 7. EMD decomposition results for IP time series. From top to bottom: first IMF to residue.




Fig. 8. Resultados de decomposição de VMD para séries temporais IP. De cima para baixo: primeiro modo para sexto.

Uma vez que o VMD requer um número predeterminado de decomposição k , este último é variado dependendo do número de IMFs obtidos pela EMD. Por exemplo, se o número de IMFs for d , então o parâmetro k usado para determinar o número de decomposição a ser obtido pelo EMD é $d-3$, $d-2$, $d-1$, d , $d+1$, $d+2$ e $d+3$. Os resultados da simulação para o WTI, a taxa de câmbio canadense/norte-americana, a produção industrial e o Índice de Volatilidade NASDAQ 100 são respectivamente mostrados na Tabela 1 à Tabela 4. De acordo com os valores MAE, MAPE e RMSE mostrados na Tabela 1, a abordagem de previsão baseada em VMD superou a abordagem baseada em EMD na previsão dos preços futuros do petróleo bruto. Isso é verdade para todos os valores de k . Da mesma forma, a abordagem de previsão baseada em VMD superou a abordagem baseada em EMD na previsão da taxa de câmbio canadense/norte-americana para todos os valores de k de acordo com os valores MAE, MAPE e RMSE mostrados na Tabela 2. Para a produção industrial dos EUA, a abordagem baseada em EMD tem um desempenho melhor do que a VMD com $k=7$ em termos de MAE e MAPE.

Como mostrado na Tabela 3. Ele também tem um desempenho melhor que o VMD em termos de RMSE com $k=4, 5, 6, 7$. Em suma, os valores mais baixos do MAE, MAPE e RMSE estão com $k=8$ quando a abordagem VMD é adotada; como resultado, supera a abordagem baseada em EMD para prever a produção industrial dos EUA. Finalmente, a Tabela 4 mostra que a abordagem de previsão baseada em VMD superou a abordagem baseada em EMD na previsão do Índice de Volatilidade NASDAQ 100, conforme indicado pelos valores MAE, MAPE e RMSE para todos os valores de k . Finalmente, as Tabelas 1 a 4 demonstram que o sistema de previsão VMD-GRNN apresentado superou o FFNN treinado com observações históricas e também o processo arma clássico em termos de todas as medidas de desempenho na previsão da taxa de câmbio West Texas Intermediate, Canadian/US, produção industrial dos EUA e o Chicago Board Options Exchange NASDAQ 100 Volatility Index.

Em resumo, os resultados experimentais ilustram totalmente a vantagem do modelo baseado em VMD para a previsão de dados econômicos e financeiros. De fato, a vantagem da filtragem baseada em EMD é aparente com base em quatro conjuntos de dados e medidas de desempenho estatístico utilizadas neste estudo.

As possíveis razões pelas quais a decomposição do EMD impacta o desempenho da previsão podem ser duplamente. Por um lado, o modelo VMD busca uma série de modos e suas respectivas frequências centrais, de modo que os modos limitados de banda reproduzem o sinal de entrada exatamente ou no sentido de menos quadrados. Em particular, ele tem a capacidade de separar tons de frequências semelhantes contrárias ao EMD. Por outro lado, a VMD é mais robusta para dados barulhentos, como o WTI, a taxa de câmbio

	MAE	MAPE	RMSE
EMD	11.4755	12.7085	25.2435
VMD (K=6)	1.6032	1.6183	2.1201
VMD (K=7)	1.5997	1.6143	2.1210
VMD (K=8)	1.5795	1.5933	2.1094
VMD (K=9)	1.7255	1.7439	2.2550
VMD (K=10)	1.7232	1.7427	2.2475
VMD (K=11)	1.7826	1.8105	2.3055
VMD (K=12)	1.8786	1.9291	2.3961
FFNN	61.9352	64.3726	62.2902
ARMA	96.9726	97.1308	116.7510

canadense/norte-americana, a produção industrial e o Índice de Volatilidade NASDAQ 100. De fato, como cada modo é atualizado pela filtragem de Wiener em fourier domain durante o processo de otimização, o modo atualizado é menos afetado por distúrbios barulhentos. A este respeito, o VMD pode capturar adequadamente o sinal de variações curtas e longas melhor do que o EMD.

Mesa 1. Desempenho para a série de tempo WTI

Table 2. Performance for CANUS time series

	MAE	MAPE	RMSE
EMD	0.0294	2.9286	0.0358
VMD (K=6)	0.0289	2.8773	0.0352
VMD (K=7)	0.0289	2.8774	0.0352
VMD (K=8)	0.0289	2.8781	0.0352
VMD (K=9)	0.0289	2.8811	0.0353
VMD (K=10)	0.0289	2.8813	0.0353
VMD (K=11)	0.0291	2.9016	0.0355
VMD (K=12)	0.0292	2.9030	0.0355
FFNN	0.2524	24.7592	0.2535
ARMA	0.8979	8.7801	1.1152

Table 3. Performance for IP time series

	MAE	MAPE	RMSE
EMD	1.3583	1.4646	1.6289
VMD (K=6)	1.0881	1.1791	1.4771
VMD (K=7)	1.2513	1.3546	1.7439
VMD (K=8)	1.2709	1.3755	1.7670
VMD (K=9)	1.2832	1.3884	1.7834
VMD (K=10)	1.4067	1.5203	1.8818
VMD (K=11)	0.9144	0.9627	1.0959
VMD (K=12)	0.9241	0.9733	1.1070
FFNN	14.1580	14.5833	16.2013
ARMA	53.4600	57.7455	66.3919

Mesa 4. Desempenho para séries temporais VIX

	MAE	MAPA	RMSE
EMD	3.8437	25.5625	4.3238
VMD (K=6)	1.6735	11.3780	1.9330
VMD (K=7)	1.6727	11.3716	1.9322
VMD (K=8)	1.6919	11.4742	1.9407
VMD (K=9)	1.6939	11.4883	1.9428
VMD (K=10)	1.6922	11.4732	1.9422
VMD (K=11)	1.6916	11.4667	1.9419
VMD (K=12)	1.6932	11.4766	1.9434
FFNN	37.2400	25.1600	38.3200
ARMA	9.3023	62.3786	10.0399

4. Conclusão

O objetivo do artigo era apresentar um sistema preditivo para dados econômicos e financeiros utilizando VMD; que é uma nova técnica de multiresolução adaptativa; em conjunto com o modelo GRNN. Nesse sentido, comparamos a previsão accuracy de quatro conjuntos de dados econômicos e financeiros usando o modelo GRNN baseado em VMD contra a abordagem baseada em EMD, feedforward rede neural e processo ARMA. Experimentos com diferentes critérios estatísticos (MAE, MAPE, RMSE), demonstram claramente que o mod GRNN baseado em VMD alcançou significativamente o menor erro de previsão para todos os conjuntos de dados. Isso indica que o paradigma de previsão da rede neural de regressão geral baseada em VMD pode ser usado como uma metodologia muito promissora para a previsão econômica e financeira mundial. Em suma, este trabalho é um passo importante na modelagem e previsão de séries temporais, pois destaca o uso de VMD em uma estrutura inteligente de sistemas especializados para prever dados econômicos e financeiros.

As principais vantagens de adotar a abordagem VMD-GRNN são duplas. Primeiro, como uma nova técnica de multiresolução adaptativa, o VMD é mais robusto para analisar sinais barulhentos, como dados econômicos e financeiros do que EMD. Em segundo lugar, o GRNN é um algoritmo de aprendizagem de um passe; assim, proporciona aprendizado e convergência rápidas quando o tamanho da amostra é grande. Como resultado, a abordagem VMD-GRNN é adequada para analisar dados barulhentos e processamento e convergência rápidos ao lidar com um grande conjunto de dados. De fato, o sistema preditivo proposto não é complicado, simples de implementar e fácil de desapegar. Tudo isso o torna muito atraente para os usuários.

No entanto, o algoritmo VMD requer a predeterminação do número de modos variacionais a serem extraídos em contrário ao EMD. Não é fácil definir uma regra para determinar um número apropriado de modos variacionais. Para simplificar, podemos sugerir corrigi-lo igual ao número de funções de modo intrínseco extraídas pelo EMD. No entanto, uma metodologia formal deve ser desenvolvida nesse sentido em trabalhos futuros.

De fato, no que diz respeito às futuras direções de pesquisa, vamos estender este estudo aplicando o modelo apresentado à previsão de preços intradiários das ações, previsão de volatilidade de ativos e classificação de séries temporais econômicas e financeiras. Por exemplo, a validade do VMD-GRNN pode ser testada na previsão de movimentos futuros para cima e para baixo. Finalmente, um estudo comparativo da precisão do VMD combinado com outros modelos de mineração de dados, como máquinas vetoriais de suporte e redes neurais de função radial poderia ser considerado para trabalhos futuros para examinar a eficácia do modelo VMD-GRNN.

Referências

- Ai, L., Wang, J., & Yao, R. (2011). Classificação de tremor parkinsoniano e essencial utilizando decomposição do modo empírico e máquina vetorial de suporte. *Processamento de sinal digital*, 21, 543-550.
- An, N., Zhao, W., Wang, J., Shang, D., & Zhao, E. (2013). Usando rede neural de alimentação de várias saídas com filtragem de sinal baseada em decomposição do modo empírico para previsão de demanda de eletricidade. *Energia*, 49, 279-288.
- Cheng, C.-H., e Wei, L.-Y. (2014). Um novo modelo de série temporal baseado na decomposição do modo empírico para a previsão do TAIEX. *Modelagem Econômica*, 36, 136-141.
- Cheng, J., Yang, Y., & Yang, Y. (2012). Um método de diagnóstico de falha de máquina rotativa baseado na decomposição média local. *Processamento de sinal digital*, 22, 356-366.
- Dragomiretskiy, K., & Zosso, D. (2014). Decomposição do modo variacional. *Transações IEEE no Processamento de Sinais*, 62, 531-544.
- Haykin, S.O. (2008). *Redes Neurais e Máquinas de Aprendizagem*. Prentice Hall; 3ª Edição.
- Huang, N.E., Shen, Z., Long, S.R., Wu, M.C., Shih, H.H., Zheng, Q., Yen, N.-C., Tung, C.C., & Liu, H.H. (1998). A decomposição do modo empírico e o espectro Hilbert para análise de séries temporais não lineares e não estacionárias," *In: Proc. R. Soc. Rio Lond.*, 454, 903-995.
- Lahmiri, S. (2014a). Um estudo comparativo do sinal ECG denoizando por limiar de onda em domínios de decomposição empírica e variacional. *Cartas de Tecnologia de Saúde IET*, 1, 104-109.

- Lahmiri, S., & Boukadoum, M. (2015a). Uma abordagem desnoizante de bio-sinal ponderada usando decomposição do modo empírico. *Cartas de Engenharia Biomédica*, 5, 131-139.
- Lahmiri, S., & Boukadoum, M. (2014b). Detecção automatizada de exsudatos circinate em imagens digitais de retina usando decomposição do modo empírico e a entropia e uniformidade das funções do modo intrínseco. *Biomedizinische Technik/Engenharia Biomédica*, 59, 357-366.
- Lahmiri, S., & Boukadoum, M. (2015b). Classificação patológica em imagens digitais de retina usando decomposição do modo empírico ajustado pelo aluno e estatísticas de direito de poder. *IEEE LASCAS*, 1-4, 2015.
- Lahmiri, S., & Boukadoum, M. (2014c). Imagem biomédica denoizando a decomposição do modo variacional using. *IEEE BIOCAS*, 340-343.
- Lahmiri, S., & Boukadoum, M. (2015c). Denoização do sinal fisiológico com decomposição do modo variacional e reconstrução ponderada após o limiar do DWT. *IEEE ISCAS*, 806-809.
- Lahmiri, S. (2015d). Memória longa nas tendências dos mercados financeiros internacionais e movimentos curtos durante a crise financeira de 2008 com base na decomposição do modo variacional e na análise de flutuação destrericada. *Física A*, 437, 130-138.
- Li, C., Wang, X., Tao, Z., Wang, Q., & Du, S. (2011). Extração de tempo variando informações de sinais barulhentos: Uma abordagem baseada na decomposição do modo empírico. *Sistemas Mecânicos e Processamento de Sinais*, 25, 812-820.
- Lin, C.-S., Chiu, S.-H., & Lin, T.-Y. (2012). Decomposição do modo empírico com base em quadrados menos quadrados suportam regressão vetorial para previsão cambial. *Modelagem Econômica*, 29, 2583-2590.
- Lisi, F., & Nan, F. (2014). Estimativa de componentes para preços de eletricidade: Procedimentos e comparações. *Economia de Energia*, 44, 143-159.
- Liu, W., Xu, W., & Li, L. (2007). Recuperação de imagem médica com base na decomposição do modo empírico bidimensional. Conferência *Internacional do IEEE sobre Bioinformática e Bioengenharia*, 641-646.
- Polat, O., & Yildirim, T. (2008). Identificação de geometria manual sem extração de características por rede neural de regressão geral. *Sistemas Especializados com Aplicações*, 34, 845-849.

- Premanode, B., & Toumazou, C. (2013). Melhorando a previsão das taxas de câmbio usando o DIFERENCIAL EMD. *Sistemas Especializados com Aplicações*, 40, 377-384.
- Ricci, R.R., & Pennacchi, P. (2011). Diagnósticos de falhas de engrenagem baseadas em EMD e seleção automática de funções de modo intrínseco. *Sistemas Mecânicos e Processamento de Sinais*, 25, 821-838.
- Specht, D.F. (1991). Uma rede neural de regressão geral. *IEEE Transactions on Neural Networks*, 6, 568-576.
- Wu, J.-D., e Tsai, Y.-J. (2011). Sistema de identificação de alto-falantes using decomposição do modo empírico e uma rede neural artificial. *Expert Systems with Applications*, 38, 6112-6117.
- Zhang, W.-F., & Yan, H. (2012). Previsão de exon usando decomposição do modo empírico e transformação de Fourier de perfis estruturais de sequências de DNA. *Reconhecimento de padrões*, 45, 947-955.

Zhang, X., Lai, K.K., Wang, S., & Wang, S. (2008). Uma nova abordagem para o preço do petróleo: análise baseada na Decomposição do Modo Empírico. *Economia energética*, 30, 905-918.

Zhang, X., Yu, L., Wang, S., & Lai, K.K. (2009). Estimando o impacto do extremo eventos sobre o preço do petróleo bruto: um método de análise de eventos baseado em *Economia energética*, 31, 768-778.