

# Um modelo híbrido para previsão de séries temporais previstas

Yi Xiaoa,c, Jin Xiaob,c e Shouyang Wangc,\*

*a*Department of Information Management, Central China Normal University, Wuhan, China

*b*Business School, Sichuan University, Chengdu, China *c*Academy of Mathematics and

*Systems Science, Chinese Academy of Sciences, Pequim, China*

**Abstract.** Para séries temporais, o problema que muitas vezes encontramos é como extrair os padrões escondidos nos dados do mundo real para prever seus valores futuros. Um único modelo linear ou não linear é inadequado na modelagem e previsão da série temporal, porque a maioria deles geralmente contém padrões lineares e não lineares. Este estudo constrói um modelo de previsão híbrido que combina a média móvel integrada autoregressiva (ARIMA) com a rede neural artificial Elman (ANN) para previsão de curto prazo de séries temporais. O approach proposto considera os padrões lineares e não lineares nos dados reais simultaneamente para que possa minerar características mais precisas para descrever melhor a série temporal. Por fim, os resultados de previsão do modelo híbrido são ajustados com o conhecimento da mineração de texto e sistema especializado. Os resultados empíricos na previsão de throughput de contêineres do Porto de Tianjin mostram que as previsões do modelo híbrido são superiores às do modelo ARIMA e da rede Elman.

**Palavras-chave:** metodologia TEI@I, rede neural artificial elman, média móvel integrada autoregressiva, modelo híbrido, previsão de séries temporais



**Yi Xiao** é professor associado na Jin Xiao Department of Information Management pela professor assistente na Universidade De da Universidade de Sichuan e da Academia de pesquisa de interesse chinês inclui business gestão de conhecimento e a economia de de dados de inteligência de negócios. mineração, cliente-

ment, e gestão do conhecimento.



recebeu seu ph.D. Universidade de Sichuan em 2010. Ele é Negócios da Universidade de Chi-School Ciências da Nese. Seu pesquisador de intelligence, Academy of Sciences. A his research inter incluem a previsão gerenciamento de relacionamento com o



**Shouyang Wang** is currently a Bairen distinct professor of Systems Management at Academy of Mathematics and Systems Science, Chinese Academy of Sciences. He is the editor-in-chief and co-editor of 12 leading journals and the president of the Sociedade Internacional de Conhecimentos e Sistemas Descendentes. Seus o interesse da pesquisa inclui a economia fundamento, gestão de conhecimentos e sistemas de apoio a decisões.

---

\* Autor correspondente: Shouyang Wang, Academia de Minas. ics and Systems Science, Chinese Academy of Sciences, Pequim 100190, China. Tel.: +861062651375; Fax: +861062541829; E-mail: sywang@amss.ac.cn.

---

0167-2533/12/\$27,50 © 2012 – IOS Press e os autores. Todos os direitos reservados.

## 1. Introdução

A análise e previsão de séries temporais é uma área de pesquisa ativa que tem chamado considerável atenção para aplicações em diversas áreas, incluindo negócios, economia, governo, ciências sociais, ciências ambientais, medicina, política, finanças, etc. O forecasting é um problema importante porque a previsão de eventos futuros é um insumo crítico para muitos tipos de processos de planejamento e tomada de decisão. Ao longo das últimas décadas, vários tipos de modelos de previsão foram desenvolvidos e melhoraram a abordagem da previsão de séries temporais.

Na previsão da série temporal, os dados históricos da variável critério podem ser utilizados para construir um modelo que reflita sua característica subjacente. Em seguida, o modelo estabelecido será usado para especular o desenvolvimento futuro da série temporal. Este método de análise é particularmente útil quando pouco conhecimento está disponível no processo gerador subjacente dos dados ou quando não há um modelo explicativo satisfatório que descreva a relação entre a variável critério e outras variáveis de previsão. Em geral, existem dois tipos de métodos para previsão de séries temporais: qualitativo e quantitativo. Métodos qualitativos, por exemplo, método Delfos e encontro de especialistas, prevêm o desenvolvimento futuro do objeto dependendo principalmente da experiência dos especialistas, knowledge e habilidades analíticas. Métodos quantitativos geralmente estabelecem modelos matemáticos de previsão com base em dados estatísticos históricos. Como estes últimos são mais objetivos e precisos, eles têm recebido cada vez mais atenção. De acordo com a diferença dos métodos, eles podem ser divididos em três categorias: estatísticos, análise causal e previsão de combinação. Métodos estatísticos, como modelo médio móvel integrado autoregressivo (ARIMA), suavização exponencial, método de sistema cinza, seasonal adjustment method and Kalman filtering,

constroem um modelo matemático apenas por dados históricos [7]. Os métodos de análise causal examinam a correlação entre a variável critério e uma série de indicadores econômicos, e constroem um modelo de previsão abordando os indicadores relevantes, incluindo análise de regressão, método de coeficiente de elasticidade e dinâmica do sistema [19]. Na verdade, não há uma tecnologia ou método que seja capaz de superar consistentemente todos os outros métodos em qualquer caso. Por isso, os métodos de previsão da combinação obtêm os resultados finais da previsão integrando os resultados de alguns modelos individuais. Nesse contexto, Wang et al. [25] propuseram a metodologia TEI@I integrando a análise qualitativa e quantitativa, que tem sido aplicada com sucesso a um número cada vez maior de áreas devido à sua alta eficácia de previsão.

No monitoramento das mudanças nos padrões sazonais e nos ciclos de negócios, as previsões de curto prazo muitas vezes produzem resultados melhores do que as previsões de longo prazo [12]. No entanto, não é fácil prever a volatilidade de curto prazo devido à sua típica não linearidade e irregularidade. A dificuldade em prever séries temporais geralmente é atribuída à limitação de muitos modelos tradicionais de previsão, o que tem incentivado pesquisadores e profissionais de negócios a desenvolver modelos de previsão mais eficazes. Neste caso, os modelos de inteligência artificial, como a rede neural artificial (ANN), têm sido reconhecidos como mais úteis do que os modelos tradicionais de previsão estatística. A maior vantagem da ANN é sua capacidade flexível de modelagem não linear, que pode aproximar qualquer função mensurável contínua com precisão arbitrariamente desejada [8]. Como uma espécie de modelo não paramétrico e orientado a dados, a ANN precisa de poucos processos de absorção de assumptionantes anteriores dos quais são gerados dados, portanto, é adequado para muitos conjuntos

de dados empíricos onde nenhuma orientação teórica está disponível para entender o processo de geração de dados. Por exemplo, Lametal.[ 16] developedtheneuralnetworkmodeland previu37typesoffreightmovementsofHongKong Port,anditissownthattheforecastingresultsaremore preciso em comparação com os da análise de regressão. Embora ann tenha as vantagens de prever precisa, seu desempenho em algumas circunstâncias específicas é inconsistente. Foster et al. [11] fizeram comparações entre rede neural e modelo linear na previsão cambial. Seus resultados mostram que a regressão linear e uma simples média de métodos de suavização exponencial são significativamente superiores à ANN. Further, TaskayaandCasey[23], descobriram que o modelo lineararautoregressivo poderia superar a rede neural em alguns casos. A razão pode ser que os dados são aproximadamente lineares sem muita perturbação, assim, modelos lineares são mais adequados para relações lineares than ANN.

Em todas as abordagens de previsão de séries de tempo linear, um dos modelos mais importantes é o ARIMA, que tem sido amplamente utilizado para prever problemas sociais, econômicos, de engenharia e financeiros. A popularidade do modelo ARIMA deve-se principalmente às suas propriedades estatísticas e à conhecida metodologia Box-Jenkins no processo de modelagem. Além disso, vários modelos de suavização exponencial podem ser implementados pelos modelos ARIMA [18]. No entanto, uma estrutura de correlação linear é assumida entre os dados no modelo ARIMA, ând portanto, não pode capturar os padrões não lineares. A aproximação de modeloslineartostocomplexproblema no mundo real nem sempre é satisfatória porque os sistemas do mundo real são muitas vezes não lineares [30].

Como todos sabemos, é difícil saber completamente a característica dos dados no mundo real. Portanto, o modelo híbrido tornou-se uma prática comum para melhorar a precisão de previsão. A ideia básica das combinações de modelosinforecastingistoutilize o recurso único de cada modelo para capturar diferentes formas de relacionamento na série temporal. Na verdade, a abordagem híbrida não é uma ideia nova. Como o trabalho pioneiro de previsão de combinação, Reid

[21], Bates e Granger [5] mostraram que uma combinação linear de previsões alcançaria uma variância de erro menor do que qualquer um dos métodos individuais. Desde então, os estudos sobre a previsão da combinação se expandiram dramaticamente. Entre esses estudos, a decomposição de uma série temporal em suas formas lineares e não lineares é um dos modelos híbridos mais populares [29], que tem sido usado para melhorar o desempenho da previsão em muitos casos com sucesso [4].

Este artigo propõe um modelo híbrido baseado em TEI@I integrando a rede neural ARIMA e Elman para previsão de séries temporais econômicas. Para verificar a eficácia do modelo de previsão proposed, a série mensal de tempo de transferência de contêineres do Porto de Tianjin é usada para estudo empírico. Os resultados experimentais mostram que as previsões com o modelo proposto são superiores ao modelo ARIMA, bem como à rede neural elman.

O remainder deste estudo é organizado da seguinte

forma:theframeworkofTEI@Ibasedhybridforecasting modelo que propusemos é apresentado na Seção 2; os conceitos básicos da rede neural ARIMA e Elman são introduzidos na Seção 3; o processo de modelagem do modelo híbrido de forecasting integrando a rede neural ARIMA e Elman é descrito na Seção 4; um estudo empírico é realizado sobre a previsão de throughput de contêineres do Porto de Tianjin com séries temporais mensais em Seções5; Finalmente, algumas marcas de consumo são retiradas na Seção 6.

## 2. Estrutura do modelo de previsão de híbridos baseado em TEI@I

TEI@I metodologia, proposta por Wang [25], é uma nova metodologia e pode ser aplicada para analisar os sistemas complicados que são emergentes, instáveis, não lineares e incertos. Nesta metodologia, os modelos econometricais são usados para modelar o padrão linear das séries tempores (ou seja, principais tendências) enquanto não lineares

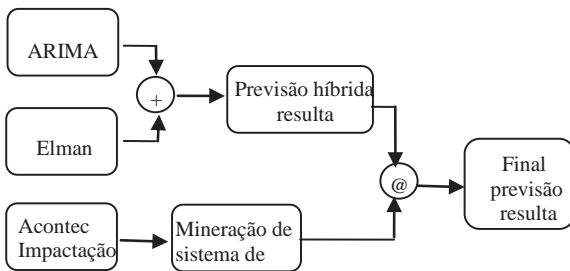


Fig. 1. Estrutura do modelo de previsão híbrida baseada em TEI@I.

padrão da série temporal (ou seja, termos de erro) é modelado por um modelo de rede neural artificial (ANN). Além disso, as efeitos da série temporal são exploradas pela técnica de minagem de texto e pela técnica de tecnologia de sistemas de especialistas. Assim, dentro da estrutura de TEI@I metodologia, um modelo integrado de previsão com correção de erros e ajuste julgador é formulado para gerar previsões mais precisas. Uma descrição mais detalhada da metodologia TEI@I pode ser encontrada em referência [25].

A Figura 1 mostra o quadro de TEI@I modelo de previsão híbrida baseado em séries temporômicas propostas neste estudo. Inclui três passos. Na primeira etapa, o modelo ARIMA é empregado para explorar o componente linear da série temporal econômica. Na segunda etapa, os resíduos de previsão do modelo ARIMA são analisados por uma rede neural elman ainda mais. Os resultados da previsão híbrida podem ser obtidos integrando as previsões do modelo ARIMA e do network neural elman. Na terceira etapa, utiliza-se a técnica de mineração de texto e o sistema especializado para analisar os efeitos do sistema de irregularidades, e o sistema de especialistas. O processo de análise dos effects de eventos irregulares é basicamente o mesmo que Wang et al. [25], e não damos os detalhes aqui. Os processos de modelagem detalhados da primeira etapa e a segunda etapa do modelo proposto estão descritos na Seção 4.

### 3. Modelos de previsão de séries tempos

Há um grande número de abordagens para modelagem de séries temporizais. Os modelos estatísticos tradicionais, como a média móvel (MA), a suavização exponencial e a ARIMA pertencem à previsão linear, ou seja, as previsões dos valores futuros são restritas à

função linear de observações passadas. Nas últimas décadas, alguns tipos de modelos de previsão não linear foram propostos para superar a limitação de modelos lineares de séries temporáticas, incluindo modelo bilinear [13], modelo de autoregressive limiar (TAR) [24], autoregressivo modelo heteroscedástico (ARCH) [10], heteroscedante condicional geral (GARCH) [2], dinâmica caótica [3], etc. Embora alguma melhoria tenha sido notada com esses modelos não lineares, o ganho de usá-los para problemas gerais de forecasting é limitado [1]. Recentemente, alguns modelos ANN como perceptron multicamadas (MLP), rede de função radial (RBF), rede neural de regressão geral (GRNN) têm been suggested as an alternative to time series forecasting. The main advantage of the ANN is their flexible nonlinear modeling capability. Nesta seção, os princípios básicos e os processos de modelagem dos modelos ARIMA e ANN são brevemente introduzidos.

#### 3.1. Modelo ARIMA

Suponha que essa é a observação de uma série de tempo, e sua média é  $\mu$ . Uma média móvel mista de autoregressive (ARMA) modelo é expresso como

$$\phi(B) \hat{I}z_t = \theta(B)a_t, \quad (1) \text{ onde } \hat{I}z_t = z_t - \mu, \text{ at e } B \text{ são}$$

o erro aleatório da série de tempo no momento  $t$  e o oper shift para trás-

ator , respectivamente.

$$\phi(B) = 1 - \sum_{i=1}^p \phi_i B^i \text{ and } \theta(B) = 1 -$$

$\sum_{j=1}^q \theta_j B^j$  are polynomial of degree  $p$  and  $q$  respectively,  $\phi_i (i = 1, 2, \dots, p)$  e  $\theta_j (j = 1, 2, \dots, q)$  são parâmetros de modelo,  $p$  e  $q$  são inteiros e muitas vezes se referem às ordens do modelo. Além disso, os erros aleatórios  $a_t$  são assumidos independentemente e identicálmente distribuídos com uma média de zero e uma variância constante de  $\sigma^2$ .

O processo ARMA está parado se as raízes de  $\phi(B) = 0$  lie outside the unit circle and it exhibit explosive behavior se eles estiverem dentro do círculo da unidade. Se  $\phi(B)$  é um operador autoregressivo estacionário, então o processo autoregressivo de modelo médio móvel integrado (ARIMA) é derivado como

$$\varphi(B)(1 - B)d\hat{I}t = \varphi(B)at, \quad (2)$$

onde  $d$  é um inteiro e muitas vezes referido à ordem da diferença. Introduzindo os operadores de diferença retrógrada  $\nabla = 1 - B$  e  $\nabla dz_{It} = \nabla dz_t$ , a equação acima se torna

$$\varphi(B)\nabla dz_t = \varphi(B)at, \quad (3)$$

onde considerando os vários valores de  $p$ ,  $d$  e  $q$ , o modelo ARIMA é escrito como ARIMA( $p, d, q$ ). Em ARIMA, o valor futuro de uma variável é assumido como uma função linear de várias observações passadas e erros aleatórios.

Box e Jenkins [6] desenvolveram uma abordagem prática para construir modelos ARIMA, que tem um impacto fundamental nas aplicações da análise e previsão da série time. Sua metodologia envolve as seguintes três etapas iterativas: identificação do modelo, estimativa de parâmetros e verificação de diagnóstico. A função de autocorrelação (ACF) e a ACF parcial (PACF) dos dados amostrais são computadas como as ferramentas básicas para identificar a ordem do melhor modelo ARIMA. A transformação de dados é muitas vezes necessária para tornar a série temporal estacionária. Uma série temporal estacionária é caracterizada por características estatísticas como a média e a estrutura de autocorreção sendo constante ao longo do tempo. Quando a série temporal observada apresenta tendência e heteroscedasticidade, diferença e transformação de poder são aplicadas aos dados para remover a tendência e estabilizar a variância antes que um modelo ARIMA possa ser montado.

Após a especificação da função do modelo ARIMA, os parâmetros da função precisam ser estimados mais adiante. Os parâmetros são estimados para que uma medida geral de erros seja minimizada. Isso geralmente envolve o uso de um processo de estimativa de menos quadrados. A última etapa da construção do modelo é a verificação diagnóstica da adequação do modelo, que verifica principalmente se as suposições do modelo sobre o theerrorsat estão satisfeitas. Várias estatísticas diagnósticas e parcelas dos resíduos podem ser usadas para examinar a bondade do ajuste do modelo provisoriamente entretido aos dados históricos. Se o modelo não for adequado, deve-se

identificar um novo modelo provisório, que é novamente seguido pelas etapas de estimativa de parâmetros e verificação do modelo. As informações de diagnóstico nos ajudam a encontrar alguns modelos alternativos. Este processo de construção de modelos de três etapas é normalmente repetido várias vezes até que um modelo satisfatório seja selecionado finalmente. O modelo final selecionado pode então ser usado para previsão.

### 3.2. Rede neural artificial

A rede neural artificial (ANN), proposta pela primeira vez em 1943 [17], é derivada através da neuropsicologia. A ideia básica da ANN é imitar o sistema biológico do cérebro humano para aprender e identificar padrões. Diferentes modelos ANN foram propostos, nos quais a rede neural feedforward (FNN) é a mais utilizada. Normalmente, o mecanismo de aprendizagem da FNN consiste em duas fases: treinamento e testes. Durante a fase de treinamento, o inputandoutlaylayersaresettorepresenta um par de treinamento  $(x, y)$  onde  $x$  é o vetor variável independente e  $y$  é o vetor variável dependente. O objetivo é construir uma equação a seguir:

$$y = f(x) = fa(x) = f(x; a), \quad \text{um} \in A, \quad (4)$$

onde  $f=fa$  é definido especificando parâmetros  $a$  de uma família explicitamente parametrizada  $A$  dos modelos. Usually, o algoritmo de treinamento da FNN ajusta repetidamente as matrizes de peso de conexão minimizando o erro para cada par de treinamento. Quando o erro quadrado médio sobre todos os pares de treinamento é aceitável, o procedimento de treinamento pára e as matrizes finais de peso de connection são armazenadas como conhecimento para uso na fase de teste.

Durante a fase de teste, a camada de entrada do FNN é ativada pelos novos vetores de entrada. Esta ativação do FNN se espalha da camada de entrada para a camada de saída através das matrizes de peso-conection armazenadas na fase de treinamento. Ou seja,  $f=fa$ , determinado pela fase de treinamento, é aplicado a novos vetores de característica  $x$  não used em fase de treinamento e a saída de previsão  $y=f(x')$  de FNNisproduced. Weusuallymeasuretheefnessness

of the model em um conjunto de teste, que é distintamente diferente do conjunto de treinamento.

O FNN é amplamente utilizado para previsão de séries temporais [15, 22, 31] porque sua capacidade de modelagem não linear pode capturar bem as características não lineares das séries temporais. Ao aplicar FNN à previsão de séries temporais, a saída final pode ser representada como

$$y_t = a_0 + \sum_{j=1}^n w_j f(a_j + \sum_{i=1}^m w_{ij} y_{t-i}) + \xi_t, \quad (5)$$

where  $a_j (j = 0, 1, 2, \dots, n)$  is a bias on the  $j$ -th unit, and  $w_{ij} (i = 1, 2, \dots, m; j = 1, 2, \dots, n)$  is the weight of connection between layers of the model,  $f(\cdot)$  is the transfer function of the hidden layer, and  $m$  is the number of input nodes and  $n$  is the number of hidden nodes. In fact, the FNN model in Equation (4) performs a non-linear mapping from the observed values ( $y_{t-1}, y_{t-2}, \dots, y_{t-m}$ ) to the future value  $y_t$ , or

$$y_t = \varphi(y_{t-1}, y_{t-2}, \dots, y_{t-m}, v) + \varphi_t, \quad (6)$$

where  $\varphi$  is a function determined by the network structure and connection weights. Assim, em alguns sentidos, o modelo FNN é equivalente a um modelo autoregressivo não linear [28].

Uma grande vantagem da FNN é sua capacidade de fornecer mapeamento flexível entre as entradas e saídas. Além disso, Hornik et al. [14] e White [26] provaram teoricamente que uma rede neural de três camadas (FNN) com uma função de transferência de identidade nos nós de saída e funções logísticas nos nós intermediários pode aproximar qualquer função contínua a qualquer precisão de desejo bem dada um número suficiente de nós de camada média. Portanto, um modelo FNN de três camadas é usado como um paradigma básico de aprendizagem neste estudo. 3.3. Rede neural Elman

A rede neural elman pertence à classe de arquitetura de redes neurais recorrentes. É uma conexão de três camadas de alimentação para a rede neural com a conexão corrente da saída da camada oculta para sua entrada. A rede é aumentada no nível de entrada por unidades

adicionais, chamadas unidades de contexto. O número de unidades contextualizadas é igual ao número de unidades ocultas. As unidades de entrada aumentada, incluindo as unidades de entrada e as unidades de contexto, ativam as unidades ocultas [9]. As entradas para as unidades de contexto são as saídas dos neurônios ocultos formando a segunda ou oculta camada. As saídas das unidades de contexto e os neurônios de entrada externa são alimentados com os neurônios ocultos. Os valores unitários de contexto no passo  $t+1$  são exatamente os mesmos que os valores unitários ocultos no passo  $t$  de tempo. Portanto, as unidades atuais que transferem o estado anterior das unidades ocultas para a camada de entrada são reconhecidas como um atraso de um passo. Unidades de contexto também são conhecidas como unidades de memória, pois armazenam a saída anterior dos neurônios ocultos.

Durante a operação da rede neural elman, os valores de ativação das unidades de entrada são definidos como um padrão de entrada desejado. O valor de ativação de cada unidade oculta é calculado multiplicando cada valor de ativação de entrada e contexto pelo valor do peso da unidade para a unidade oculta. Esses valores são então somados, o viés da unidade oculta é adicionado, e a soma é passada através de uma função de esmagamento  $f$ . O valor do resultado é então considerado como o valor de saída da unidade oculta. Na rede neural elman, a função de esmagamento utilizada é a logística  $f$ . Em seguida, as ativações das unidades de saída são calculadas com base nas unidades ocultas de forma análoga. Isso representa um passo. Em seguida, a ativação de cada unidade oculta é copiada em uma unidade de contexto correspondente em uma base um por um com pesos fixos de 1 e, em seguida, o próximo passo é realizado. Isso equivale a uma conexão recorrente de cada unidade oculta para si mesma e é mais restritivo do que as conexões arbitrárias recorrentes permitidas pela reivindicação de Minsky [20]. Suponha que  $n, l, m$  são o número das unidades de entrada, unidades ocultas e unidades de saída, respectivamente. A entrada primária é  $x_i (i=1, 2, \dots, n)$ , e a saída da rede é  $y_k (k=1, 2, \dots, m)$ .  $w_{ji} (i=1, 2, \dots, n; j=1, 2, \dots, l)$ ,  $w_{kj} (j=1, 2, \dots, l; k=1, 2, \dots, m)$  são os pesos das conexões entre as unidades de entrada e ocultas, as unidades recorrentes e ocultas, e as unidades ocultas e de saída, respectivamente.  $b_j$  e  $b_k$  são vieses de unidades ocultas e unidades de saída,  $eff(\cdot)$  and  $g(\cdot)$  are hidden and output functions, respectively. A

arquitetura da rede neural elman pode ser escrita matematicamente da seguinte forma. A saída da unidade oculta:

$$y'_j(t) = f \left( \sum_{i=1}^n w_{ji}x_i + \sum_{r=1}^l w_{jr}y'_r(t-1) + b_j \right). \quad (7)$$

A saída da unidade de saída:

$$y_k(t) = g \left( \sum_{j=1}^l w_{kj}y'_j(t) + b_k \right). \quad (8)$$

A rede neural convencional não é adequada para os padrões que variam ao longo do tempo. No entanto, os dados históricos da série econômica como os insumos da rede neural são que variam de tempo. Portanto, deve-se considerar uma rede com capacidade de processamento temporal. Neste estudo, uma rede neural recorrente de Elman foi treinada para prever a série residual de séries temporais econômicas.

#### 4. O método híbrido que integra a rede neural ARIMacom Elman

No mundo real, a previsão da série temporal está longe de ser simples devido à alta volatilidade, complexidade, irregularidade e ruído. Moreover, séries temporalhais práticas raramente são puras lineares ou não lineares. Eles geralmente contêm padrões lineares e não lineares. Embora ambos os modelos de rede neural ARIMA e Elman tenham tido sucesso em seus próprios domínios lineares ou não lineares, nem a rede neural ARIMA nem Elman podem modelar adequadamente e prever séries temporais, uma vez que os modelos lineares não podem lidar bem com relações não lineares enquanto a rede neural Elman não é capaz de lidar com padrões lineares e não lineares igualmente bem. Portanto, não há nenhum modelo universal adequado para todos os tipos de séries temporísticas. Por outro lado, como mencionado anteriormente, para séries temporidades prevendo a relação entre ARIMA e ANN é complementar. ARIMA é um dos modelos lineares que podem capturar as características lineares de uma série temporal, enquanto a rede neural elman treinada pela propagação traseira com uma camada oculta é uma das aproximações da função geral com forte capacidade de modelar a não linearidade e eles podem capturar padrões não lineares em séries temporais. Não é sábio aplicar apenas a rede neural ARIMA ou Elman cegamente a qualquer série

temporal porque é difícil saber as características da série temporal completamente nos problemas reais. Portanto, neste estudo propomos um modelo híbrido integrando a rede neural ARIMA e Elman de forma adaptativa para a previsão de séries temporais econômicas. Combinando os dois modelos, diferentes aspectos dos padrões subjacentes podem ser capturados. O objetivo do método híbrido é integrar aspabilidades de delineamento e ononline e melhorar ainda mais o poder de previsão em aplicações práticas.

Uma vez que as séries de tempo econômico real geralmente contêm muitos padrões complexos, não basta apenas modelar o componente linear para uma série temporal. Portanto, a relação não linear da série temporal deve ser considerada para refletir melhor as circunstâncias reais. Pode ser razoável supor que uma série temporal é composta de uma estrutura linear de correção automática e um componente não linear:

$$y_t = L_t + N_t, \quad (9)$$

onde  $y_t$  é valor actual, componente linear  $L_t$  e  $N_t$  denotam e o componente não linear , respectivamente.

De acordo com a Equação (9), os dois componentes devem ser estimados a partir dos dados para obter o resultado final da previsão. Na primeira fase, um modelo ARIMA é usado para extract o componente linear da série temporal. Comparando o valor real da série temporal e o valor de previsão  $L_{t-1}$  de componente linear, podemos obter uma série de resíduos, que é definido como  $e_t$ :

$$e_t = y_t - L_{t-1}. \quad (10)$$

Os resíduos são importantes no diagnóstico da suficiência dos modelos lineares. Um modelo linear não é suficiente se ainda houver estruturas de correlação lineares nos resíduos. Neste estudo, assumimos que o modelo ARIMA construído na primeira fase é suficiente. Portanto, não é mais capaz de lidar com isso. Qualquer padrão não linear significativo nos resíduos indicará a limitação da ARIMA. A fase secand é como se encaixar nos componentes não lineares da série. Inthisphase, um modelo de rede ineural é usado para modelar a série temporal acima não linear. A série temporal não

linear gerada anteriormente é considerada como as entradas do modelo Elman, e, em seguida, os treinados Elman modelis used to generate series of forecasts de componentes não lineares de séries temporais. Com os nódulos de entrada  $m$ , o modelo de rede neural Elman para os resíduos será descrito como

$$e_t = \varphi(e_{t-1}, e_{t-2}, \dots, e_{t-m}, v) + s_{ut}, \quad (11)$$

onde  $v$  é o vetor do parâmetro,  $\varphi$  é uma diversão determinada pela estrutura de rede Elman e pesos de conexão, e  $s_{ut}$  é o erro aleatório.

Para obter os resultados de previsão sinérgica, basta integrar as previsões de componentes lineares e não lineares das séries temporeas. Assim, a previsão final pode ser calculada da seguinte forma:

$$y_{t+1} = L_{t+1} + N_{t+1}, \quad (12)$$

onde  $L_{t+1}$  é o resultado de previsão de componente linear e  $N_{t+1}$  é o valor de previsão do componente não linear. Em resumo, o método híbrido proposto consiste

de três fases. Na primeira fase, um modelo ARIMA deve ser construído para analisar o padrão linear da série temporal. O procedimento de construção do modelo ARIMA pode ser resumido da seguinte forma.

1. Identificar a ordem do modelo ARIMA com gráficos, estatísticas, função de correção automática (ACF), função de autocorrelação parcial (PACF), critério de informação de Akaike (AIC), o comprimento mínimo de descrição (MDL), bem como abordagens inteligentes como redes neurais, algoritmos genéticos ou sistema difuso ;
2. Estimar os parâmetros dos modelos identificados pelo método de mínimos quadrados, métodos de máxima probabilidade, etc.;
3. A verificação diagnóstica da adequação do modelo.

Na segunda fase, um modelo de rede neural Elman é introduzido para modelar o padrão não linear. Uma vez que o modelo ARIMA não pode capturar o componente não linear da série temporal

econômica, os resíduos do modelo linear conterão informações sobre o padrão não linear. Portanto, os resultados da rede neural Elman podem ser usados como previsões do termo de erro para o modelo ARIMA.

Na terceira fase, os resultados combinados de previsão são obtidos a partir da Equação (12). O modelo híbrido pode explorar a característica única e a força do modelo ARIMA, bem como o modelo ANN na determinação de diferentes padrões. Teoricamente falando, o modelo híbrido apresentado neste estudo ainda é uma classe de modelo de previsão única. No entanto, é útil e eficaz em padrões separadamente usando diferentes modelos, e pode melhorar ainda mais o desempenho de previsão.

## 5. Estudo empírico

### 5.1. Preparação e pré-processamento de dados

A série mensal de tempo de transferência de contêineres do Porto de Tianjin no período de janeiro de 2001 a dezembro de 2011 tem abelha usada em nossos experimentos. Os dados são baixados do banco de dados do CEIC (ver Fig. 2). Os dados mensais de janeiro de 2001 a dezembro de 2010 são utilizados como conjunto de treinamento para modelagem, incluindo os modelos de rede neural ARIMA e Elman, e o restante data de janeiro de 2011 a dezembro de 2011 como o conjunto de testes para verificação e comparação de modelos.

Os dados precisam ser normalizados antes do treinamento dos modelos, que podem ser descritos como a seguinte fórmula:

$$x_n(i) = \frac{x(i) - \min(X)}{\max(X) - \min(X)} \quad (13)$$

onde  $x_n(i) \in [0,1]$  são os dados normalizados,  $x(i)$  é que os dados originais,  $\min(X)$  e  $\max(X)$  representam o mínimo e o máximo da série temporal original, respectivamente.

### 5.2. Medidas de desempenho

Para avaliar o desempenho do modelo de previsão híbrida, são utilizadas três medidas de desempenho de previsão difusa.

O primeiro é o erro absoluto médio (abreviado como MAE), que é descrito como



$$MAE = \frac{1}{N} \sum_{i=1}^N |T_i - T'_i| \quad (14)$$

A segunda é o erro percentual absoluto médio (MAPE) que pode ser escrito como

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left| \frac{T_i - T'_i}{T_i} \right| \quad (15)$$

O terceiro é o erro quadrado médio raiz (RMSE), que pode ser apresentado como

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (T_i - T'_i)^2} \quad (16)$$

onde  $N$  é o número total de dados observados.  $T_i$  e  $T'_i$  representam os valores reais e de pré-moldagem, respectivamente.

MAE, MAPE e RMSE são as métricas que são usadas para estimar o erro de previsão do modelo.




Fig. 2. Dados mensais de transferência de contêineres do Porto de Tianjin de janeiro de 2001 a dezembro de 2011.

Valores menores dessa métrica indicam maior precisão na previsão.

### 5.3. Modelagem ARIMA

O modelo ARIMA é usado para modelar o componente linear da série de tempo de transferência de contêineres. Para a construção do modelo ARIMA com os dados disponíveis da série tempo de transferência de contêineres, foi utilizado um procedimento three-estágio

de identificação do modelo, estimativa dos parâmetros do modelo e verificação diagnóstica dos parâmetros estimados. Descobrimos que o modelo mais bem equipado era um modelo autoregressivo de ordem 2, ou seja, AR(2) pelo




Fig. 3. Os

resultados de fornecção do throughput de contêiner com base no modelo ARIMA.

Software Eviews. Além disso, utilizou-se o modelo ARIMA treinado para prever os dados mensais de throughput de contêineres de janeiro de 2011 a dezembro de 2011. Como é mostrado na Fig. 3 que os resultados de previsão de AR(2) têm alguns vieses em comparação com os valores reais. Esses vieses se devem principalmente às limitações da modelagem linear do modelo ARIMA. Assim,

podemos concluir que o modelo ARIMA geralmente não é adequado para identificar e explorar o pattern não linear da série de tempo de throughput de contêiner.

#### 5.4. Modelagem da rede neural de Elman

A rede neural Elman é usada para modelar o componente não linear da série de tempo de throughput de contêiner por descida gradiente com impulso e algoritmo de treinamento de retropropagação otimizado. A rede Elman é uma rede de alimentação com a adição de uma conexão recorrente desde a saída da camada oculta até sua entrada. O atraso nessa conexão armazena os valores da etapa anterior, que podem ser usados na etapa de tempo atual. Thus, a rede neural elman pode aprender a reconhecer e gerar padrões temporais, bem como padrões espaciais com o caminho de feedback. Nesta seção, uma rede Elman foi treinada em software MATLAB de acordo com os resíduos do modelo linear. Finalmente, a arquitetura de rede elman ideal composta por três entradas, quatro neurônios ocultos e um de saída, chamada E(3-4-1), foi obtida pela tecnologia de poda. Os resultados de previsão dos resíduos para o conjunto de testes são mostrados em Fig. 4. Os resultados indicam que

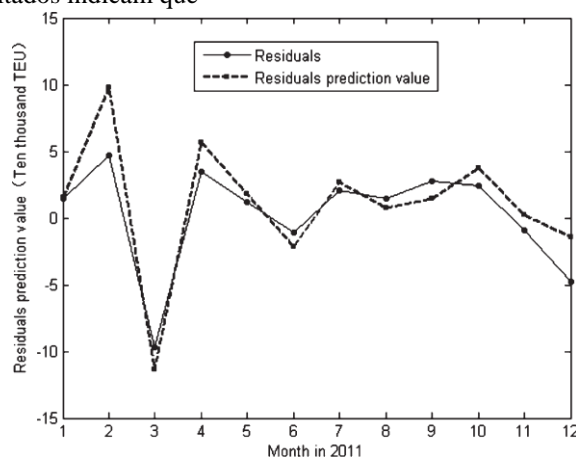


Fig. 4. Os resultados de previsão dos resíduos com base na rede Elman.




Fig. 5. Os resultados de previsão do modelo híbrido para rendimento de contêineres.

A rede Elman é capaz de capturar o padrão não linear da série de tempo de throughput do contêiner para provide bons desempenhos de previsão da flutuação mensal do throughput do contêiner.

#### 5.5. Integração da previsão com base no modelo ARIMA e rede neural Elman

Depois de obter os resultados de previsão do componente linear da série de tempo de throughput de contêiner por AR(2) e os resultados do componente não linear pela rede neural Elman, só precisamos integrar as duas séries temporais de previsão para obter os resultados finais de previsão. Os valores de previsão do modelo híbrido no conjunto de testes são mostrados em Fig. 5. Os resultados de verificação sugerem que os resultados da previsão do modelo híbrido proposto podem coincidir com as observações de forma mais razoável.

#### 5.6. Comparação do desempenho do modelo

A Tabela 1 mostra os resultados da simulação do modelo ARIMA, rede Elman e modelo híbrido em conjunto de testes, onde cada valor é o desempenho médio de 10 experimentos.

Pode-se ver a partir da Tabela 1 que: (a) de acordo com todos os índices, o desempenho de previsão do modelo ARIMA é melhor do que o da rede Elman. A razão pode ser que na série de tempo de throughput de contêineres

que consideramos, o fator dominante são os componentes lineares; b O desempenho de previsão do modelo híbrido é melhor do que o do modelo ARIMA e da rede Elman, o que demonstra que a série de tempo de throughput do contêiner inclui componentes não lineares e componentes lineares. Portanto, não é adequado para a rede de throughputforecastingtoutilizeonlyARIMAorElman; c O modelo híbrido é superior ao modelo proposto por Xiao et al. em outro estudo [27]. Finalmente, podemos concluir que o model híbrido proposto neste estudo é mais favorável ao modelo de séries temporais de throughput de contêineres.

Como pode ser visto na Fig. 2, devido à crise financeira global originada dos Estados Unidos, o crescimento do transporte de contêineres do Porto de Tianjin desacelerou de 2009 para 2010. Mas com a rápida recuperação da economia chinesa da crise financeira e o rápido desenvolvimento da Nova Área Costeira de Tianjin, a produção de contêineres do Porto de Tianjin começou a crescer rapidamente a partir de 2010. Como fator causal, a crise financeira não se reflete em modelos baseados nos dados históricos, de modo que o

Tabela 1

Comparação do desempenho médio de diferentes modelos acima de 10

Experiências

ModelMAEOrderMAPEOrdermseOrder

Rede Elman6.648230.074338.06813

Modelo ARIMA2.722720.028623.80182

TEI@I

based2.236210.023413.6181

modelo híbrido

Tabela 2

Previsões de throughput de contêineres do Porto de Tianjin por TEI@I modelo híbrido baseado em TEI@I (Dez milhares de TEU)

Mês2012.1 2012.2 2012.3 2012.4 2012.5 2012.6

Valores de previsão 106.05 101.53 104.74 113.82 108.67 109.62

os erros de previsão do modelo ARIMA ou elman network são relativamente grandes. No entanto, o desempenho de previsão do modelo híbrido baseado em

TEI@I é significativamente melhor do que o dos outros dois modelos, ajustando-se com o conhecimento do sistema de tecnologia e tecnologia. Por isso, utilizamos o model híbrido baseado em TEI@I para prever a produção de contêineres do Porto de Tianjin nos próximos 6 meses. Os resultados de previsão estão listados na Tabela 2 e prontos para validação futura.

## 6. Conclusões

Na previsão de séries temporais, o problema que muitas vezes encontramos é como aumentar a precisão da pré-venda tanto quanto possível com a não-estacionária enoisedata. Neste estudo esperamos projetar um modelo híbrido baseado em TEI@I que possa melhorar efetivamente o desempenho da previsão de throughput de contêineres. No modelo híbrido proposto, a capacidade única do modelo ARIMA na modelagem linear é usada para extrair o padrão linear existente em dados, e então uma rede Elman é adotada para capturar padrão não linear dos resíduos do modelo linear. Experimentamos o modelo ARIMA, rede Elman e oproposedhybridmodelinmonthlycontainer série de tempo de rendimento do Porto de Tianjin, comparamos o resultado anteriorresultsbasedonthemeanabsoluteerror, erro de porcentagem absoluta e erro de média raiz ao quadrado, e descobrimos que o desempenho de previsão do híbrido proposto modelo é melhor do que o modelo ARIMA e rede Elman em geral. O modelo híbrido proposto pode ser usado como uma ferramenta alternativa de previsão e útil para a previsão de séries de tempo de curto prazo.

## Confirmações

Esta pesquisa foi apoiada pela Fundação jovem de Ciências Humanas e Sociais do Ministério da Educação da China sob o Grant nº 11YJC870028, o Fundo Especial de Pesquisa Científica Básica das Faculdades Centrais sob o Grant No. CCNU10A01031, Fundação de Ciências Naturais da China sob Grant No. 71101100, Fundo de Novos Professores para Estações Médicas, Ministério da Educação sob Grant No. 20110181120047, China Pós-Doutorado Ciência

Fundação sob o Grant No. 2011M500418, Centro de Previsão de Ciências da Academia Chinesa de Ciências e do Centro Nacional de Matemática e Ciências Interdisciplinares. Este artigo foi concluído durante a

visita do autor correspondente ao Departamento de Ciências gerenciais da City University of Hong Kong. He is grateful to the department and the university for a financial support to his visit.

## Referências

- [1] C.H. Aladag, E. Egrioglu and C. Kadilar, Forecasting nonlinear series temporais with a hybrid methodology, *Letras matemáticas aplicadas* **22** (2009), 1467-1470.
- [2] Modelos G. Ali, ARCH, GARCH e ARMAX para previsão de patógenos eadvisoriesatmarinerecreationalsites, *Marine Resource Economics* **26** (2011), 211-224.
- [3] Ardalani-Farsa e S. Zolfaghari, análise residual e combinação de incorporação de teorema e inteligência artificial na caótica previsão de séries temporais, *Inteligência Artificial Aplicada* **25** (2011), 45-73.
- [4] P. Areekul, T. Senjyu, H. Toyama e A. Yona, um ARIMA híbrido e modelo de rede neural para previsão de preços de curto prazo no mercado desregulamentado, *IEEE Transactions on Power Systems* **25** (2010), 524-530.
- [5] J.M. Bates e C.W.J. Granger, A combinação de previsões, *Operations Research Quarterly* **20** (1969), 451-468.
- [6] G.E.P. Box and G.M. Jenkins, *Timeseriesanalysis*, previsão e controle, holden-day, 1970.
- [7] S.H. Chen and J.N. Chen, Forecasting container throughput at ports using genetic programming, *Expert Systems with Applications* **37** (2010), 2054-2058.
- [8] G. Cybenko, Aproximações por superposições de uma função sigmoide, *Matemática de Controle, Sinais e Sistemas* **2** (1989), 303-314.
- [9] J.L. Elman, Encontrando estrutura no tempo, *Ciência Cognitiva* **14** (1990), 179-211.
- [10] R.F. Engle, Heteroscedasticidade condicional Autoregressiva com estimativas da variância do Reino Unido. *Econometrica* **50** (1982), 987-1008.
- [11] W.R. Foster, F. Collopy e L.H. Ungar, previsão de rede neural de séries temporais curtas e ruidosas, *Computadores e Engenharia Química* **16** (1992), 293-297.
- [12] P.H. Franses e D. Van Dijk, A previsão de desempenho de vários modelos para sazonalidade e não linearidade para a produção industrial trimestral, *International Journal of Forecasting* **21** (2005), 87-102.
- [13] C.W.J. Granger and A.P. Anderson, *An Introduction to Bilinear Time Series Models*, Vandenhoek-Ruprecht, 1978, pp. 1-8.
- [14] K. Hornik, M. Stinchcombe and H. White, Multilayer feedforward redes são aproximadores universais, *Redes Neurais* **2** (1989), 359-366.
- [15] H.B. Hwang, Insights sobre a rede neural previsão série tempo coring para estruturas ARMA (p, q), *Ômega* **29** (2001), 273-289.
- [16] W.H.K. Lam, P.L.P. Ng, W. Seabrooke e E.C.M. Hui, Previsões e análise de confiabilidade da produção de carga portuária em Hong Kong, *Journal of Urban Planning and Development* **130** (2004), 133-144.
- [17] W.S. McCulloch e W.A. Pitts, Cálculo lógico das ideias iminentes em atividade nervosa, *Boletim e Biofísica Matemática* **5** (1943), 115-133.
- [18] E.D. McKenzie, General exponential smoothing e o processo ARMA equivalente, *Journal of Forecasting* **3** (1984), 333-344.
- [19] W.Y. Peng e C.W. Chu, Uma comparação dos métodos univariados para previsão de volumes de throughput de contêineres, *Modelagem Matemática e Computador* **50** (2009), 1045-1057.
- [20] D.T. Pham e X. Liu, identificação dinâmica do sistema usando redes neurais parcialmente recorrentes, *Journal of Systems Engineering* **2** (1992), 90-97.
- [21] D.J. Reid, Combinando três estimativas do produto interno bruto, *Economica* **35** (1968), 431-444.
- [22] Z. Tang, C. Almeida e P.A. Fishwick, série time que prevê o uso de redes neurais vs. Box-Jenkins metodologia, *Simulação* **57** (1991), 303-310.
- [23] T. Taskaya e M.C. Casey, Um estudo comparativo de híbridos de rede neural autoregressiva, *Redes Neurais* **18** (2005), 781-789.
- [24] H. Tong, *Modelos limiares em análise de séries tempore não lineares*, Springer-Verlag, 1983, pp. 3-9.
- [25] S.Y. Wang, L. Yu e K.K. Lai, Previsão de preços do petróleo bruto com metodologia TEI@I, *International Journal of Systems Science e Complexity* **18** (2005), 145-166.
- [26] H. White, regressão não paramétrica connectionista: redes de alimentação multicamadas podem aprender mapeamentos arbitrários, *Redes Neurais* **3** (1990), 535-549.
- [27] Y. Xiao, J. Xiao e S.Y. Wang, um modelo de previsão híbrida para séries temporentas não estacionárias: Uma aplicação para a previsão de throughput de contêineres, *International Journal of Knowledge and Systems Sciences* **3** (2012), em imprensa.
- [28] L. Yu, S.Y. Wang e K.K. Lai, um novo modelo de previsão de conjunto não linear incorporando GLAR e ANN para taxas de câmbio, *Computadores e Operações Research* **32** (2005), 2523-2541.
- [29] G.P. Zhang, TimeseriesforecastingusingahybridARIMAand modelo de rede neural, *Neurocomputing* **50** (2003), 159-175.
- [30] G. Zhang, B.E. Patuwo and M.Y. Hu, Forecasting with artificial neural networks: The state of the art, *International Journal of Forecasting* **14** (1998), 35-62.
- [31] G.P. Zhang, E.B. Patuwo e M.Y. Hu, Um estudo de simulação de redes neurais artificiais para previsão de séries temporais não lineares, *Pesquisa de Computadores e Operações* **28** (2001), 381-396.