

# Sistema híbrido de previsão e análise de energia eólica baseado no esquema de divisão e conquista: Um estudo de caso na China

Wendong Yang <sup>a, b</sup>, Jianzhou Wang <sup>a, b, \*</sup>, Haiyan Lu <sup>b</sup>, Tong Niu <sup>a, b</sup>, Pei Du <sup>a</sup>

<sup>a</sup>School of Statistics, Dongbei University of Finance and Economics, Dalian, 116025, China <sup>b</sup>School of Software, Faculty of Engineering and Information Technology, University of Technology, Sydney, Australia

## artículo info

Histórico do artigo:

Recebido em 16 de outubro de 2018

Recebido em forma revisada

2 de março de 2019

Aceito 4 março 2019 Disponível

online 5 março 2019

Keywords:

Sistema híbrido

Previsão determinística

Análise de incerteza

Optimização

Energia eólica

## abstract

A energia eólica, reconhecida como uma forma promissora de energia renovável e o método limpo de crescimento mais rápido para a geração de eletricidade, tem atraído considerável atenção de muitos cientistas e pesquisadores nas últimas décadas. No entanto, a previsão de energia eólica ainda é uma tarefa desafiadora devido às suas características inerentes à não linearidade e à aleatoriedade. Portanto, este estudo desenvolve um sistema híbrido de previsão e análise de energia eólica, incluindo um módulo de previsão determinista e um módulo de análise de incerteza para mitigar os desafios nos estudos existentes. Em particular, esses desafios são os seguintes: (1) É difícil garantir que as características de dados subjacentes à série temporal sejam efetivamente extraídas; (2) na modelagem de cada subsérie, ou seja, quando os dados originais são decompostos em alguma série temporal, a precisão e a estabilidade da previsão não são consideradas simultaneamente e, portanto, não são devidamente modeladas; e (3) a melhor função para realizar uma previsão determinística e a análise de incerteza com base na previsão de cada subsérie é desconhecida. O sistema híbrido desenvolvido consiste em três etapas: Primeiro, o pré-processamento de dados é realizado para capturar e minerar a principal característica da série temporal de energia eólica e enfraquecer os efeitos negativos dos ruídos; segundo, a otimização multi-objetiva é proposta para alcançar a previsão de cada subsérie com melhorias na precisão e estabilidade; finalmente, a busca pela melhor função, que obtém a previsão determinística e a análise da incerteza, utilizando uma máquina de aprendizagem extrema otimizada baseada em diferentes objetivos de modelagem. Simulações experimentais são realizadas utilizando dados de três locais em um parque eólico real, o que indica que o sistema desenvolvido tem um melhor desempenho em aplicações de engenharia do que os de outros métodos. Além disso, esse sistema poderia não apenas ser utilizado como uma ferramenta eficaz para a previsão determinística da energia eólica e análise da incerteza, mas também para outras áreas de aplicação de engenharia no futuro.

© 2019 Elsevier Ltd. Todos os direitos reservados.

## 1. Introdução

Nos últimos anos, a China enfrentou enormes desafios ambientais e energéticos, que têm uma instabilidade significativa no crescimento econômico, saúde pública e bem-estar (Li et al., 2018a). Com o declínio das fontes de energia convencionais e o aumento da poluição ambiental, a estrutura energética baseada em combustíveis fósseis será substituída por uma estrutura energética mais limpa (Zendejboudi et al., 2018). A energia eólica tornou-se cada vez mais popular em todo o mundo, e pode contribuir muito para reduzir as emissões de CO<sub>2</sub> (Wang et al., 2008; Wang e Li, 2019). Pelo que sabemos, vento

a energia, como fonte renovável com maior potencial em todo o mundo, tem a maior taxa de crescimento no sistema elétrico (EPS) devido à sua simpatia ambiental e ecológica e porque é facilmente extraível com o rápido desenvolvimento da tecnologia de energia eólica (Wang et al., 2018a, 2018b; Liang et al., 2016). De acordo com o Global Wind Report 2017 (Global Wind Energy Council, 2018), o mercado global de energia eólica permaneceu acima de 50 GW em 2017, e o total de instalações em 2017 foi de 52.492 MW, elevando o total global para 539.123 MW. O mercado anual caiu 3,8% em relação a 2016, e o total acumulado aumentou 11% em relação aos 487.279 MW no final de 2016. Com uma nova capacidade adicional para a rede elétrica de 19.660 MW, a China voltou a liderar os mercados globais em 2017. Caiu 15,9% em relação a 2016, mas a China ainda representa 37% das instalações globais. Além disso, representa um aumento de 11,7% em relação ao ano anterior e instalações acumuladas de 188.392 MW. Portanto, para acelerar o desenvolvimento da energia eólica, os dados de energia eólica são reconhecidos como uma série temporal complexa do mundo real de grande importância para o EPS, e sua previsão é atualmente uma das questões mais importantes na produção limpa.

\* Autor correspondente. Escola de Estatística, Universidade do Ngbei de Finanças e Economia, Dalian, Liaoning, 116025, China.

Endereço de e-mail: [wangjz@dufe.edu.cn](mailto:wangjz@dufe.edu.cn) (J. Wang).

No entanto, a integração em larga escala da energia eólica poderia ameaçar a operação e o planejamento de sistemas de energia convencionais devido às características de não linearidade e aleatoriedade inerentes à energia eólica, que dificultam severamente o desenvolvimento da energia eólica (Zhao et al., 2016a). Uma das soluções que podem ajudar a resolver os problemas acima mencionados é o desenvolvimento de uma técnica de previsão eficaz, que poderia desempenhar um papel significant nas usinas para controlar o equilíbrio, operação e segurança da rede (Li et al., 2018b). Uma previsão geral e ação de energia eólica pode reduzir os riscos financeiros e técnicos da incerteza da energia eólica para todos os participantes do mercado de eletricidade (Foley et al., 2012). No entanto, devido à natureza da energia eólica, não é possível garantir sua disponibilidade quando necessário e, portanto, a previsão de energia eólica é uma questão desafiadora para o desenvolvimento de energia eólica (Zhao et al., 2016b). Para isso, propor uma técnica de previsão eficaz para a energia eólica que considere as questões relevantes associadas à integração em larga escala da energia eólica na rede elétrica tornou-se particularmente desejável e não deve ser adiada (Ma et al., 2009).

Nas últimas décadas, muitos métodos de previsão para a energia eólica foram propostos, que incluem principalmente três famílias, ou seja, as abordagens de previsão física, convencional e inteligente (Zhang et al., 2017; Jiang et al., 2019; Hao e Tian, 2019a). As abordagens físicas são desenvolvidas de acordo com alguns fatores meteorológicos, como temperatura, umidade, rugosidade superficial e pressão, e têm melhor desempenho para previsão de energia eólica a longo prazo (Su et al., 2014). Além disso, eles não são adequados para a condução de pequenas áreas e previsão de energia eólica de curto prazo porque precisam de tempo e recursos de simulação extensos (Sun e Liu, 2016). Em contraste, as abordagens estatísticas convencionais, como a média móvel autoregressiva (ARMA) (Torres et al., 2005) e o modelo autoregressivo de média móvel integrada (ARIMA) (Sfetsos, 2002), visam prever as mudanças futuras por dados históricos, e embora sejam mais adequados para a previsão de curto prazo da energia eólica do que os modelos físicos, eles não conseguem se desarmar com condições não lineares (Xiao et al., 2017). Com o rápido desenvolvimento da inteligência artificial, modelos inteligentes de previsão foram desenvolvidos e empregados com sucesso na previsão de energia eólica (Jiang e Ma, 2016) e, entre eles, as redes neurais artificiais (ANNs) (Wang et al., 2018c; Tian et al., 2018), máquinas vetoriais de suporte (SVMs) (Hu et al., 2015) e métodos lógicos difusos (Hong et al., 2010) são discutidos principalmente. Com base nos vários métodos de previsão, muitos sistemas de previsão foram desenvolvidos em todo o mundo. Por exemplo, o sistema e Wind™ desenvolvido pela AWS TruePower, EUA, cujas localizações geográficas de aplicações incluem os EUA; o sistema WPPT desenvolvido pela Eltra/Elsam em colaboração com a Informatics and Mathematical Modeling no Danmarks Tekniske Universitet (DTU), Dinamarca, com localizações geográficas de aplicações que incluem Dinamarca, Austrália, Canadá, República da Irlanda, Holanda, Suécia, Grécia e Irlanda do Norte; o sistema Sipreolico desenvolvido pela Universidad Carlos III, Madrid, Espanha e Red Electrica de Espana, cujos locais geográficos correspondentes de aplicações incluem Espanha (Foley et al., 2012).

Além disso, Ma et al. (2019a) apontam que apenas os modelos não lineares podem obter o desempenho de pré-moldagem desejável porque os dados de energia eólica geralmente apresentam fenômenos não lineares fortes. No entanto, devido às desvantagens inerentes aos métodos únicos, eles nem sempre podem obter os resultados de previsão desejados (Du et al., 2018; Ma et al., 2017a). Além disso, devido à crescente penetração da energia eólica nas redes elétricas, é necessário ter uma melhor compreensão do erro de previsão e tentar reduzi-lo o máximo possível (Bludszuweit et al., 2008).

Portanto, para remediar essas fraquezas que são inerentes aos métodos únicos, muitos sistemas híbridos têm sido propostos para a previsão de energia eólica, que alcançam melhor desempenho de previsão (Tian et al., 2018). Em geral, de acordo com a estratégia de pré-processamento de dados, o sistema híbrido poderia ser desenvolvido pelas duas estratégias seguintes (Yang et al., 2017). (1) A estratégia de decomposição e reconstrução (Yang et al., 2017), que é um esquema simples de pré-processamento de dados que decompõe os dados

originais em algumas subséries em diferentes frequências e remove os sinais de alta frequência para obter a série reconstruída. Em seguida, os dados reconstruídos são usados para desenvolver o modelo de previsão. Ma et al. (2017b) desenvolveram um sistema de previsão de energia eólica baseado na análise de espectro de espectro singular (SSA) para obter uma sequência mais suave com base na série original. Da mesma forma, Niu et al. (2018) também propuseram um sistema híbrido de previsão de energia eólica baseado na SSA. Seu estudo de caso comprovou que o sistema desenvolvido, baseado na estratégia de decomposição e reconstrução, não só supera outros métodos, mas também poderia ser empregado como uma técnica eficaz em aplicações de engenharia. (2) A estratégia de divisão e conquista (Xu et al., 2017), outra estratégia de pré-processamento de dados, é o esquema mais utilizado na modelagem de previsão híbrida. Ele emprega certas técnicas de pré-processamento de dados para decompor os dados originais em algumas subséries e, em seguida, constrói um preditor para cada subsérie. Os resultados de previsão final podem ser obtidos agregando todas as subséries previstas. Por exemplo, Wang et al. (2017) desenvolveram um sistema de previsão baseado no pré-processamento de dados e otimização para energia eólica. Da mesma forma, Meng et al. (2016) desenvolveram um modelo híbrido para a previsão de energia eólica de curto prazo que prevê que combine pré-processamento de dados, ANNs e a abordagem de otimização. De acordo com a avaliação do desempenho do sistema desenvolvido, este método aumenta significativamente a precisão de previsão em comparação com a de todos os modelos de benchmark. Os resultados dos sistemas híbridos acima mencionados com base nesses dois esquemas verificaram a capacidade de previsão dos sistemas híbridos.

Com base na análise e revisão da literatura acima mencionada, pode-se constatar que, na maioria dos casos, os modelos baseados em divisão e conquista são superiores aos modelos utilizando a estratégia de decomposição e reconstrução. Os métodos anteriores melhoram o desempenho de previsão final até certo ponto e agora são empregados em aplicações tradicionais. No entanto, a maioria dos estudos anteriores enfatizando a contribuição da fase de divisão só melhoram a eficácia da previsão até certo ponto. Mais importante, ignoram a sinalização da fase de conquista para o desempenho de previsão final, que inclui dois aspectos. Por um lado, a maioria deles adotou um algoritmo tradicional de otimização para otimizar o modelo de previsão para a previsão de cada subsérie, o que geralmente resulta em baixa estabilidade de previsão. Por outro lado, e igualmente importante, a maioria deles emprega uma forma de integração amplamente utilizada, denominada método de integração direta, para obter os resultados de previsão final, enquanto poucos deles consideraram outras formas de integração na fase de conquista, o que deixa uma área de potencial de melhoria para estudos futuros. Portanto, vale a pena realizar mais pesquisas e estudos sobre novos métodos para a fase de conquista.

Outra questão da previsão de energia eólica é o período limitado de direções de pesquisa. Especificamente, a maioria das análises anteriores se concentrou apenas na previsão de energia eólica diminuída, que é insuficiente para aplicações de engenharia e não pode garantir a confiabilidade e a controlabilidade do EPS. Felizmente, a previsão do intervalo probabilístico pode fornecer mais informações, e seus resultados irão facilitar os tomadores de decisão para realizar análise e avaliação de riscos. No entanto, as pesquisas e aplicações da previsão de intervalos não obtiveram atenção suficiente dos pesquisadores relevantes, que estão centrados principalmente na realização de análises baseadas no modelo estatístico, como os métodos bootstrap (Errouissi et al., 2015), método de regressão quântica (Nielsen et al., 2006; Wang et al., 2016), e método de estimativa de densidade de kernel (Juban et al., 2007). Além disso, foram desenvolvidos modelos de previsão com base em ANNs, a estimativa de limite superior inferior (LUBE) e a teoria não paramétrica para a previsão de intervalos (Khosravi et al., 2011). Com base na revisão e análise dos métodos de forquesting de intervalo acima mencionados, pode-se constatar que: (1) o método bootstrap é adaptado a uma pequena amostra, o que pode evitar possíveis descartes em uma regressão quântica, mas com uma carga computacional pesada; (2) com exceção da carga computacional pesada, o método de regressão quântica precisa de uma amostra de treinamento específico para previsão de intervalo, com a probabilidade de os resultados serem descartados no processo de resampling; (3) embora o método de estimativa de densidade do kernel seja facilmente realizado para a previsão de intervalos, ele precisa de premissas de strict na distribuição; (4) o

método LUBE não só evita as suposições sobre distribuição, mas também tem alta eficiência computacional, embora sua complexa função objetiva não possa ser resolvida usando o método matemático tradicional. Em suma, não há um único método uniforme para previsão de intervalos, e novos estudos e investigações precisam ser conduzidos com base no conhecimento atualmente disponível para obtenção de resultados mais eficazes (Moghran e Rahman, 1989). Mais especificamente, poucos dos estudos anteriores realizaram análises aprofundadas da incerteza da energia eólica e eles apenas enfatizaram a modelagem da energia eólica centrada na previsão determinística. Mais importante, eles ignoraram as melhorias potenciais and significance de obter previsão de intervalo de alta qualidade. Portanto, com o objetivo de fornecer mais informações aos tomadores de decisão em EPS, novos estudos de intervalo determinístico e probabilístico previstos na previsão de energia eólica são especialmente necessários devido à sua sinalização.

A principal contribuição deste estudo é que desenvolvemos um sistema híbrido de previsão e análise para realizar a previsão de intervalos determinísticos e probabilísticos de energia eólica, o que compensa a insuficiência dos estudos existentes. Este sistema consiste em um módulo de previsão determinístico e um módulo de análise de incerteza, que pode fornecer mais informações para os tomadores de decisão no EPS e melhorar o gerenciamento e o agendamento do EPS. Simulações experimentais são realizadas usando dados de três locais em um parque eólico real, o que indica que o sistema desenvolvido tem melhor desempenho em aplicações de engenharia do que os outros modelos comparados.

Em particular, as principais diferenças entre os atuais trabalhos de pesquisa envolvem quatro pontos, o que pode ser considerado como uma forte contribuição para o domínio de previsão de energia eólica. Os detalhes podem ser resumidos da seguinte forma: (1) Diferentes alvos de previsão: Esta pesquisa se concentra em melhorar a precisão e estabilidade do modelo em vez de apenas o alvo de precisão. Por isso, é desenvolvido um modelo otimizado de máquina de aprendizagem extrema (ELM), que combina um algoritmo de otimização multi-objetivo com dois alvos (precisão e estabilidade) para fornecer uma garantia para o desempenho de previsão final. (2) Método de integração diferente: Focando na fase de conquista e não na fase de divisão ao utilizar a estratégia de divisão e conquista superior. Neste estudo, outro ELM otimizado é desenvolvido como um novo method de integração para substituir o método simples de integração direta, que pode obter os resultados de previsão final pelas mudanças futuras previstas de cada subsérie. Devido à sua excelente capacidade de previsão, a eficácia do estágio de conquista e o desempenho de forcação final podem ser ainda mais aprimorados. (3) Diferentes direções de pesquisa: O foco é fornecer informações de previsão determinística e análise de incerteza. Além de um módulo de previsão determinístico com dois objetivos, desenvolve-se um modelo de ramcasting de intervalo probabilístico com três objetivos para quantificar os riscos potenciais para os tomadores de decisão no EPS. Os três objetivos da função fitness são desafiados da seguinte forma: um é maximizar a probabilidade de cobertura do intervalo de previsão; o segundo é minimizar o intervalo de previsão normalizado largura média; e o terceiro é minimizar o desvio de largura acumulado. (4) Além das três diferenças acima mencionadas, esta pesquisa também fornece um estudo comparativo mais abrangente. A família de decomposição do modo empírico (EMD) é usada para desenvolver métodos de previsão semelhantes para estudos comparativos que fornecem sugestões para futuras direções potenciais de pesquisa dos métodos baseados em EMD. Além disso, são fornecidas algumas discussões perspicazes, como a superioridade do sistema desenvolvido e uma análise de sensibilidade e assim por diante.

O restante do artigo é organizado da seguinte forma: a Seção 2 fornece os métodos necessários para o sistema concebido. A Seção 3 constrói o sistema de previsão e análise proposto. A seção 4 priver os dados e analisa os resultados. Outras discussões são conduzidas na Seção 5. Finalmente, a conclusão é resumida na Seção 6.

## 2. Metodologia

Esta seção fornece a introdução dos métodos necessários para o sistema desenvolvido, que incluem a decomposição do modo variacional (VMD), máquina de aprendizagem extrema (ELM) e algoritmo de enxame de salp multi-objetivo (MSSA).

### 2.1. Decomposição do modo variacional (VMD)

VMD, desenvolvido por Dragomiretskiy e Zosso (2014), é um novo método de decomposição que tem sido frequentemente utilizado em muitos fields, como a denoização da imagem biomédica (Lahmiri e Boukadoum, 2014), diagnóstico de falha mecânica (Huang et al., 2016) e análise de tempoequência sísmica (Xue et al., 2016). Muitos estudos anteriores provaram que o método VMD é superior a outras abordagens de decomposição, como a transformação de ondas e o EMD para denoização de sinais (Lin et al., 2017). Os detalhes do VMD são apresentados como Algoritmo 1.

#### Algoritmo 1: VMD

```

1 /*Defina os parâmetros de VMD.
2 /*Inicializar o  $\{N_k\}, \{e_k\}, \lambda^1$  e  $n, *$ 
3
4  $n = n + 1$ 
5 DURA = 1 ;  $k$  DO
6     /*  $N_k$  para  $e > 0$  */
7      $N_k^{n+1}(y) = \frac{F(y) - \sum_{m=1}^{n+1} N_m^{n+1}(y) - \sum_{m=1}^n N_m^n(y) + \lambda^n / 2}{1 + 2(e - e_k)^2}$ 
8     /*  $e_k$  */
9      $e_k^{n+1} = \int_0^\infty W_k^{n+1}(w) |y|_w^2 / \int_0^\infty |N_k^{n+1}(w)|_w^2$ 
10 FIM PARA
11 /*Dupla ascensão para  $\lambda > 0$ . */
12  $\lambda^{n+1}(y) = \lambda^n(y) + \tau((\frac{1}{k}W - \sum_k N_k^{n+1}(y))$ 
13 FIM ATÉ CUMPRIR CONDIÇÃO DE RESCISÃO
14 RETURN a série de modos limitados de banda

```

#### REPITA A ITERAÇÃO

### 2.2. Máquina de aprendizagem extrema (ELM)

ELM, desenvolvido por Huang et al. (2004) é um tipo de rede neural de alimentação de camada oculta única (Jiang et al., 2017), which tem uma estrutura simples, alta precisão de previsão, velocidades de cálculo rápidas e menos requisitos de amostra de treinamento. Em comparação com algumas redes neurais bem conhecidas, ela tem uma boa capacidade de previsão e capacidade de aprendizagem em tempo real (Huang et al., 2012, 2015; Zhang et al., 2012).

O preditor ELM entre  $x_i$  e  $y_i$  pode ser apresentado da seguinte forma:

$$y_i = \sum_{j=1}^L x_{ij} w_j + b_j, \quad i = 1, 2, \dots, N(1)$$

onde  $a_i$  é o vetor de peso do nó oculto  $i$ ,  $b_i$  é polarização de nó  $i$ ,  $G$  é a função excitação,  $b$  denota o vetor de peso do nó de entrada e nó de saída,  $L$  é o número de camada oculta, e  $N$  é o número de amostras de treinamento.

Para simplificar, Eq. (1) é transformado da seguinte forma:

$$H B_{1/4} Y \quad (2)$$

$$Deus1; b1; x1TH / G\delta aL; bL; x1This$$

4

$$H\delta a1; aL; b1; bL; x1; xN^{1/2} Ged.a1; b1; xN^{1/2} Voc\hat{e}/G\delta aL; bL; xN^{1/2} 5N.L$$

(3)

$$(b \ 1/4 \ hbY1; /; bYL \ iL_m \quad (4) \quad cif1; 2;::; kg;1/2Fx \ Thom\Lambda1/2i21; 2;::; k : i\delta xi\delta \quad (10)$$

$$Y \ 1/4 \ _{hyY1}; /; yYNiN, m$$

onde H é a matriz de saída da camada oculta, e o peso de saída pode ser obtido da seguinte forma:

$$kHb \ Yk \ 1/4 \ HHpY \ Y \ 1/4 \ minb \ kHb \ Yk \quad (5)$$

$$b \ 1/4 \ HpY \quad (6)$$

onde Hp é a matriz inversa generalizada de Moore-Penros da camada oculta.

### 2.3. Algoritmo de enxame de salp multi-objetivo (MSSA)

O SSA, desenvolvido por Mirjalili et al. (2017) é um novo algoritmo de otimização bioinspirado que é inspirado no comportamento de salps.

Semelhante a outros algoritmos de otimização de inteligência de enxame, a posição dos salps é desafiada como uma matriz bidimensional x. Além disso, a fonte de alimento chamada F é desafiada como o alvo no espaço de busca.

A posição do líder é atualizada da seguinte forma:  $x_{lj}^{1/4} FF_{jj} p_{cc1ubjj}$

$$l b l b j j c c 22 \ p \ l b l b j j \ c c 33 < 00 \quad (7)$$

onde  $x_{lj}$  denota a posição do líder na dimensão  $jth$ , Fj é a posição da fonte de alimento na dimensão  $jth$ , ubj e lbj são os limites superior e inferior, respectivamente,  $c1$ ,  $c2$ , e  $c3$  são números aleatórios.  $c1$  é usado para equilibrar exploração e exploração e é calculado da seguinte forma:

$$c1 \ 1/4 \ 2or4l=LTH2(8)$$

onde L é o número máximo de iterações e l é o número de iteração atual.

A posição dos seguidores é atualizada de acordo com a seguinte equação:

$$x_{ij} \ 1/4 \ 12x_{ij} \_p \ x_{ij}l \quad (9)$$

Definição 2. Idealidade de Pareto

! x 2X é o Pareto ideal se

$$e! \ y \ 2XJJD! \ y \ Y\_F\delta! \ x \ Th \quad (11)$$

Definição 3. Conjunto ideal de Pareto

O conjunto ideal pareto consiste em todas as soluções não dominadas:

$$p_s : 1/4 \ fx; \ y2XjdF\delta y p\_F\delta xPg(12)$$

Definição 4. Frente ideal de Pareto

A frente ideal do Pareto consiste nas soluções ideais do Pareto:

$$pr : 1/4 \ fFxPjx2Psg(13)$$

A versão multi-objetiva da SSA é desenvolvida para resolver problemas multi-objetivos, e é nomeada SSA multi-objetiva (MSSA). Em primeiro lugar, de forma semelhante com os arquivos em otimização multi-objetiva de enxames de partículas (MOPSO), o repositório de alimentos é equipado para o algoritmo SSA. Em segundo lugar, a fonte de alimento é escolhida a partir de um conjunto de soluções não dominadas com o bairro menos lotado. Finalmente, o pseudo-código do algoritmo MSSA é apresentado no Algoritmo 2.

#### Algoritmo 2: Parâmetros MSSA:

$L$  - iterações máximas  $n$  - número

de salps

$F_i$  - fitness do  $i$ -th salp

$[lb_j, ub_j]$  — limites da dimensão  $j$ -th  $xi$  —

posição do  $i$ -th salp  $l$  — iterações atuais

1 /\*Defina os parâmetros básicos do MSSA. \*/

2 /\*Inicialize a população salp  $x_i$  ( $i = 1, 2, \dots, n$ ) aleatoriamente. \*/

3 **WHILE** ( $l < L$ ) **DO**

onde  $i \ 2$  e  $x_{ij}$  mostra a posição do primeiro seguidor salp na dimensão  $jth$ .

Diferente de resolver o único problema objetivo, não se pode comparar diferentes soluções pelos operadores relacionais aritméticos para o problema de otimização multiprofissional. Para este objetivo, as desfigurações incluem o domínio Pareto, a idealidade de Pareto, o conjunto ideal de Pareto e o pareto para frente ideal (Coello Coello, 2009).

Definição 1. Domínio de Pareto

Vetor! x 1/4  $\delta x1$ ;  $x2;::;$   $x_{kTh}$  domina ! y 1/4  $\delta y1$ ;  $y2;::;$   $y_{kP}$ , denotado por  $x\_y$ , se

```

4  /*Calcule os valores objetivos de cada salp . */
5  /*Encontre salps dominados por você. */
6  /*Atualize o repositório em relação aos salps não dominados obtidos. */
7  SE o repositório está cheio
8      /* Remova um residente do repositório usando manutenção do repositório. */
9      /* Adicione o salp não dominado ao repositório. */
10 FIM SE
11 /* Escolha uma fonte de alimento no repositório  $Food = SelectFood (repositório)$  */
12 /*Atualize  $a$ . */
13  $c_1 = 2e^{-(4/l)^2}$ 
14 PARA CADA SALP(X)
15     SE  $i == DO$ 
16         /*Atualize a posição do salp líder . */
17          $x_i^j = \begin{cases} F_j + c_1((Ub_j - lb_j) \cdot r_2 + L_j) & c_3 \geq \\ F_j - c_1((Ub_j - lb_j) \cdot r_2 + L_j) & c_3 < 0 \end{cases}$ 
18     ELSE SE
19         /*Atualize a posição do seguidor salp . */
20          $x_i^j = \frac{1}{2}(x_i^j + x_{i-1}^j)$ 
21     FIM SE
22 FIM PARA

21 FIM SE
22 FIM PARA
23 /* Alterar os salps com base nos limites  $[L, Ub]$ . */
24  $l = l + 1$ 
25 FIM ----- 0
26 Repositório DE RETORNO
27 /* Obter  $X^*$  com base no repositório devolvido */

```

### 3.1. Projeto do sistema

Nesta seção, a estrutura geral do sistema concebido neste estudo é apresentada na Fig. 1, que consiste em dois módulos: módulo de previsão determinística e módulo de análise de incerteza.

#### 3.1.1. Módulo de previsão determinista

O flowchart do módulo de previsão determinístico do sistema concebido é mostrado na Fig. 1, que é composta de três fases, e as informações detalhadas de cada fase são as seguintes:

A Fase I: Devido às características inerentes aos dados de energia eólica de não linearidade e aleatoriedade, a utilização da energia eólica é restrita pelo desempenho de previsão de energia eólica. Para diminuir os efeitos negativos do ruído nos dados originais de energia eólica e melhorar ainda mais o desempenho da previsão final, o pré-processamento de dados é realizado para decompor os dados originais em uma série de subséries para captura e mineração da principal característica da série de tempo de energia eólica, que tem feito contribuições importantes para o desempenho de previsão do sistema.

A Fase II: Como discutido acima, a precisão e estabilidade da previsão são indispensáveis para um modelo de previsão eficaz e robusto em aplicações de engenharia. Para este objetivo, dois objetivos (precisão e estabilidade) são desafiados para previsão determinística. Mais especificamente, a precisão de previsão é representada pelo erro quadrado médio dos resultados de previsão, que é uma das funções de fitness mais utilizadas para melhorar a precisão do modelo. Além disso, é sabido que os erros de previsão são um dos indicadores mais importantes para avaliar o desempenho de um modelo. Portanto, neste estudo, a estabilidade dos erros de previsão é representada pelo desvio padrão dos erros de previsão, que é desafiado como outra função fitness para melhorar a estabilidade de previsão determinística. Com base nisso, um ELM otimizado é desenvolvido para prever mudanças futuras de cada subseries, que envolve otimização multiobjetiva e garante precisão e estabilidade dos resultados de previsão final. Em particular, a previsão é feita usando os dados anteriores para um passo à frente.

O algoritmo 2 mostra que o procedimento principal é o seguinte: o algoritmo MSSA primeiro inicializa a população de salp aleatoriamente, então calcula os valores objetivos de cada salps e, em seguida, os salps nomeados são obtidos. Se o repositório não estiver cheio, as soluções não dominadas são adicionadas a ele; pelo contrário, se estiver cheio, a manutenção do repositório é realizada para remover as soluções com bairro lotado. Uma fonte de alimento é escolhida a partir das soluções nomeadas no repositório com a vizinhança menos lotada após a atualização do repositório. Em seguida,  $c_1$  é atualizado por Eq. (8). Em seguida, as posições dos salps líder e seguidor são atualizadas pela Eqs. (7) e (9), respectivamente. E o algoritmo vai alterar os salps com base nos limites para evitar que um salp saia dos limites. Finalmente, o MSSA é encerrado quando atende satisfatoriamente à condição final.

Deve-se notar que existem dois métodos (ou seja, a priori versus a posteriori) para resolver problemas multiprofissionais (Branke et al., 2001).

Tradicionalmente, o problema multi-objetivo é transformado em um único problema objetivo, combinando os objectives no método anterior. Além disso, ambas as abordagens têm vantagens e desvantagens. E, felizmente, em comparação com abordagens a priori, as vantagens de uma otimização posteriori são mais do que suas desvantagens. Portanto, o foco do algoritmo

MSSA está em uma otimização multi-objetiva posteriori para resolver problemas multiobjetivos. E neste método, o problema multi-objetivo não é convertido em um único objetivo, combinando os objetivos.

### 3. Construção da previsão de energia eólica e sistema de análise

Esta seção descreve o desenvolvimento do sistema de previsão e análise, que inclui projeto do sistema e avaliação do sistema.



A Fase III: A maioria dos estudos anteriores baseados na estratégia de divisão e conquista apenas utilizaram o método de integração direta amplamente utilizado para obter os resultados de previsão final na terceira fase, poucos deles consideraram outras formas de integração na fase de conquista. Isso oferece potencial para melhorias no

determinista para conduzir a análise de incerteza da energia eólica como intervalos de desenvolvimento e quantificar os riscos potenciais para os tomadores de decisão no EPS. Além disso, para obter os resultados de previsão de intervalo de alta qualidade, o algoritmo de otimização multi-objetivo também é incorporado no módulo de análise de incerteza. Portanto,

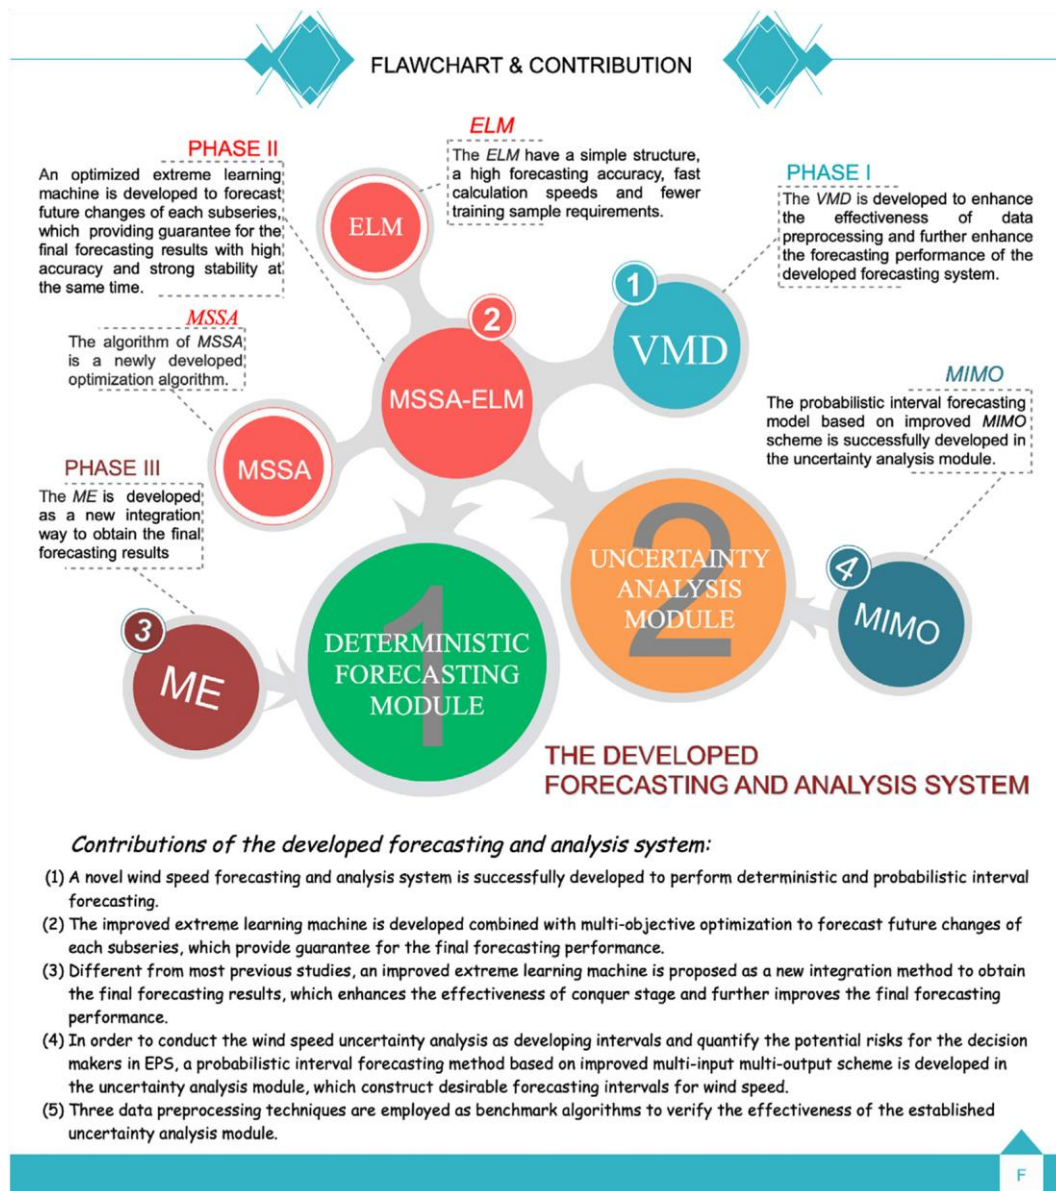


Fig. 1. Fluxograma e contribuição do sistema criado.

desempenho de previsão final. Portanto, neste estudo, diferente da maioria dos estudos anteriores, outro ELM otimizado é desenvolvido como um novo método de integração, em vez de um método de integração direta. Em particular, o passo à frente da previsão de resultados de cada subsérie é inserto ao novo método de integração desenvolvido para obter o final um passo à frente dos resultados previstos em energia eólica, o que aumenta a eficácia da etapa de conquista e melhora ainda mais o desempenho de previsão final.

### 3.1.2. Módulo de análise de incerteza

O quadro do módulo de análise de incerteza do sistema concebido é mostrado no Fig.1, que é established com base no módulo de previsão

o objetivo de otimização, denominado função fitness, é desafiado neste estudo.

A probabilidade de cobertura de intervalo de previsão (FICP) e o intervalo de previsão normalizada de largura média (FINAW) são duas métricas amplamente empregadas para avaliar a qualidade de previsão de intervalo. No entanto, apenas considerando o FICP e o FINAW não é suficiente para algumas condições special. Em detalhes, se o valor real estiver fora do intervalo previsto, e quando os valores de FICP e FINAW forem aproximados ao modelo de referência, o efeito de dois intervalos previstos com diferentes níveis de limites superiores e inferiores do valor-alvo real do THE desviando-se do intervalo de previsão não pode ser razoavelmente avaliado. Para resolver esse problema, uma nova métrica, chamada de desvio de largura acumulada (AWD), também é empregada para validar o desempenho do módulo de análise de incertezas. Estes três objetivos devem ser considerados simultaneamente e aplicados no desenvolvimento do

módulo de análise de incertezas. Mais especificamente, diferente dos dois

3.2.1.2. Análise relacional cinza (GRA).

Metric	Definition	Equation
MAE	Mean absolute error of $N$ forecasting results	$MAE = \frac{1}{N} \sum_{i=1}^N  F_i - A_i $
RMSE	Square root of average of the error squares	$RMSE = \sqrt{\frac{1}{N} \times \sum_{i=1}^N (F_i - A_i)^2}$
MAPE	Average of $N$ absolute percentage error	$MAPE = \frac{1}{N} \sum_{i=1}^N \left  \frac{A_i - F_i}{A_i} \right  \times 100\%$
MdAPE	Median of $N$ absolute percentage error	$MdAPE = median\left(\left  \frac{A_i - F_i}{A_i} \right  \times 100\%\right)$
U1	Theil U statistic 1 of forecasting results	$U1 = \sqrt{\frac{1}{N} \times \sum_{i=1}^N (F_i - A_i)^2} / \left( \sqrt{\frac{1}{N} \times \sum_{i=1}^N A_i^2} + \sqrt{\frac{1}{N} \times \sum_{i=1}^N F_i^2} \right)$
U2	Theil U statistic 2 of forecasting results	$U2 = \sqrt{\frac{1}{N} \times \sum_{i=1}^N ((A_{i+1} - F_{i+1})/A_i)^2} / \sqrt{\frac{1}{N} \times \sum_{i=1}^N ((A_{i+1} - F_i)/A_i)^2}$

objetivos (precisão e estabilidade) do processo de previsão determinística, a função de fiabilidade com três objetivos é projetada no módulo de análise de incerteza. O primeiro objetivo é maximizar o FICP (ou seja, min 1 a FICP), o segundo é minimizar o FINAW (ou seja, min FINAW), e o terceiro é minimizar o desvio de largura acumulado (ou seja, min AWD).

Nesta seção, com base no algoritmo de otimização multi-objetivo com os três objetivos acima mencionados, um modelo de previsão de intervalo probabilístico baseado no ELM multi-entrada otimizado é desenvolvido com sucesso para prever o futuro intervalo de energia eólica com base nas mudanças futuras previstas de cada subsérie. Em particular, os resultados de previsão de um passo à frente de cada subsérie são inseridos no ELM multi-entrada otimizado para obter os resultados de previsão do intervalo de energia eólica, que fornecem intervalos de previsão desejáveis para a energia eólica.

### 3.2. Avaliação do sistema

Esta seção introduz uma avaliação abrangente do sistema concebido, que compreende oito métricas para a previsão determinística e três métricas para a análise de incerteza.

#### 3.2.1. Avaliação de previsão determinística

Para testar o desempenho do módulo de previsão determinística, os critérios de erro múltiplo (MEC), análise relacional cinza (GRA) e teste de Pearson são utilizados a partir de diferentes perspectivas, e os detalhes de cada perspectiva são os seguintes.

3.2.1.1. Múltiplos critérios de erro. Muitas métricas de erro têm sido amplamente empregadas em estudos recentes, mas não há um padrão universal para avaliação de modelos. Portanto, os pesquisadores geralmente adotam múltiplos critérios de erro para comparar o desempenho dos métodos desenvolvidos e de outros modelos comparados (Xu et al., 2017). Referindo-se à literatura relevante na previsão de fields (Ma et al., 2019b; Xiao et al., 2016a, 2016b; Wang et al., 2018d), seis critérios de erro comuns, incluindo o erro absoluto médio (MAE), erro quadrado de média raiz (RMSE), erro percentual absoluto médio (MAPE), erro percentual absoluto mediano (MdAPE), estatística de Theil U 1 (U1) e estatística theil U 2 (U2), são adotados como critérios de erro múltiplo neste estudo e apresentados na Tabela 1. Valores menores para essas métricas revelam um melhor desempenho de previsão (Jiang, 2018).

Considera-se que o GRA testa se a curva dos valores previstos tem maior semelhança com a curva dos valores observados. O procedimento principal é desafiado da seguinte forma (Yang et al., 2019):

A série de referência:

Tabela 1

Regras de métrica de desempenho para o módulo de previsão determinística.

X0 1/4 0X001Th; X0d2Th;::; X0thatth(14)

A série de comparação:

Xi 1/4 0Xied1Th; Xið2Th;::; Xiðnth(15)

As séries são padronizadas da seguinte forma:

n

xiðtTh \_\_\_\_\_ 1/4Xedth 1n tP1/41Xiðnth (16)

vuutn11 tP1/41 XiðtTH 1n tP1/41Xidth!ffi

O coefficient de correlação é calculado da seguinte forma:

xiðkth 1/4miniminjx0ðkðjxxkkðj x0dkThis jx0dxk Thjkkj;

r2d0;∞Que

(17)

O grau de relação cinza (GRD) entre x0 e xi é dado da seguinte forma:

1 n

ri 1/4 1n Xxiðkð (18)

k1/41

Se  $r_a < r_b$ , a série B tem uma semelhança maior com a curva de referência do que a série A.

3.2.1.3. Teste de Pearson. O teste de Pearson, desenvolvido por Karl Pearson, pode ser usado para apresentar a força de associação dos valores observados e previstos (Wang et al., 2018b). Neste estudo, a avaliação da força da associação é realizada com base no teste de Pearson para elaborar ainda mais a superioridade do módulo de previsão determinística proposto. O resultado do teste de Pearson pode ser apresentado pela métrica chamada coefficient de

correlação de Pearson (PCC). Se o PCC  $\geq 1$ , significa que há uma relação linear entre os valores observados e forçados e, pelo contrário, se o PCC  $\leq 0$ , não há relação entre essas duas séries temporais.

### 3.2.2. Avaliação da análise de incerteza

Conforme discutido na Seção 3.1.2, três métricas, incluindo a probabilidade de cobertura de intervalo de previsão (FICP), o intervalo de previsão de largura média normalizada (FINAW) e o desvio de largura

Tabela 2

Regras Métrica de desempenho durante o módulo de análise de incerteza.

Métrica	Definição	Equação
FICP	Probabilidade de cobertura de intervalo de previsão do conjunto de	$\frac{1}{N} \sum_{i=1}^N c_i \quad 100\%$
FINAW	Intervalo de previsão normalizou largura média do conjunto de dados de	$FINAW = \frac{1}{N} \sum_{i=1}^N \frac{E_{iV} - L_{iV}}{E_{iU} - E_{iL}} \quad 100\%$
AWD <sub>1</sub>	Desvio de largura Acumulado da amostra de teste	$AWD_1 = \frac{1}{N} \sum_{i=1}^N \frac{E_{iV} - L_{iV}}{E_{iU} - E_{iL}} \quad 100\%$
Desvio	de largura AWD Acumulado do conjunto de dados de teste	$AWD_1 / 4 \times AWD$

Aqui,  $u_i$  e  $l_i$ , respectivamente, denotam os limites superior e inferior do intervalo previsto; se o valor real  $A_i \in [l_i, u_i]$ ,  $c_i = 1$ , caso contrário  $c_i = 0$ ; e  $N$  é o comprimento do testando conjunto de dados.

## 4. Dados e resultados

Para verificar o desempenho do sistema de previsão e análise elaborado, os conjuntos de dados de energia eólica coletados de um determinado parque eólico situado em Chengde, província de Hebei, na China, são usados neste estudo.

### 4.1. Descrição dos dados

Os dados de medição do vento foram colhidos pela torre de observação meteorológica. Os dispositivos de medição de vento atuais geralmente registram dados em intervalos de amostragem de 2 s e 3 s. Alguns parâmetros foram considerados durante o processo de coleta, como data de tempo, velocidade do vento, direção do vento, temperatura e pressão. A torre de observação pode calcular automaticamente e registrar a velocidade média do vento a cada 10 minutos. Neste estudo, dados de energia eólica de três locais no parque eólico de Chengde, na província de Hebei, China, com um período de 10 minutos são aleatoriamente afetados para propor um sistema de previsão e análise de energia eólica para parques eólicos. No total, são selecionados 5040 pontos de dados que cobrem 35 dias para o estudo de comparação de cada conjunto de dados, que são denotados como conjunto de dados A, dataset B e conjunto de dados C neste estudo, e the first 4032 pontos que cobrem 28 dias são adotados como conjunto de treinamento, e os outros dados de 1008 cobrindo 7 dias são usados como conjunto de testes. A proporção dos conjuntos de dados de treinamento e teste é de 4:1 neste estudo. Os detalhes dos dados experimentais utilizados no estudo de caso estão listados na Tabela 3. Os desvios padrão são todos acima de 3 m/s, que indicam flutuações significantes

acumulado (AWD), são estudadas simultaneamente e implementadas no desenvolvimento do módulo de análise de incerteza. Devido à sinalização desses três índices para a qualidade da previsão interval, essas três métricas também são adotadas para avaliação de análise de incerteza, e são desafiadas na Tabela 2.

## 4.2. Análise dos resultados de decomposição por técnica de VMD

Na fase I, de acordo com o esquema de construção do sistema desenvolvido de previsão e análise de energia eólica, para diminuir a influência negativa de ruído na previsão de energia eólica e melhorar o desempenho de previsão final, a técnica de VMD é empregada para decompor os dados originais em várias subséries. Tendo como exemplo o conjunto de dados A, os resultados de decomposição são apresentados na Fig. 2. Como mostrado na Fig. 2, os dados originais, incluindo os conjuntos de treinamento e testes, são respectivamente decompostos em 8 subséries, que são nomeados como S1, S2, ..., S7, S8. A técnica VMD garante que as principais características de dados subjacentes à série temporal sejam efetivamente extraídas e extraídas. Como mencionado acima, após a decomposição pela técnica VMD, os dois objetivos (accuracy e estabilidade) são desafiados para a previsão determinística, que é combinado com o algoritmo de otimização multi-objetivo MSSA para alcançar esses dois objetivos específico. Com base nisso, um ELM otimizado é desenvolvido com base na otimização multi-objetiva with dois objetivos (precisão e estabilidade) como um preditor, o que garante a precisão e estabilidade dos resultados de previsão final. Para o exemplo anterior mostrado na Fig. 2, cada subsérie pode ser devidamente modelada com base no modelo MSSAeELM desenvolvido, e os resultados de forecasting de cada subsérie são mostrados na Fig. 3. Além dos resultados de previsão de cada subsérie mostrado na Fig. 3, os resultados do conjunto de treinamento correspondente também podem ser obtidos pelo MSSA proposto.



dos dados de energia eólica quando tomados o máximo/mínimo dos conjuntos de dados de A a C, que são 22,40/0,10 m/s, 22,50/0,10 m/s e 23,40/0,10 m/s, respectivamente. Mostra uma evidente Flutuação em frequência e amplitude entre as séries, indicando que estes three as séries têm características diferentes e os experimentos baseados neles são apropriados para validação do sistema concebido.

Tabela 3

Valores estatísticos de cada conjunto de dados utilizado neste estudo.

Grupo de	Número	Valores				
		Máximo	Mínimo	Mediana	Significar	DST.
<hr/>						
Conjunto de dados A						
Todas as amostras	5040	22.4000	0.1000	6.6000	7.4676	3.9102
Conjunto de treinamento	4032	22.4000	0.1000	6.7000	7.6284	3.9150
Conjunto de testes	1008	19.3000	0.2000	5.9000	6.8241	3.8256
Conjunto de dados B						
Todas as amostras	5040	22.5000	0.1000	6.5000	7.3006	3.8739
Conjunto de treinamento	4032	22.5000	0.2000	6.7000	7.3818	3.7512
Conjunto de testes	1008	22.0000	0.1000	5.7000	6.9759	4.3168
Conjunto de dados C						
Todas as amostras	5040	23.4000	0.1000	6.6000	7.2519	3.8179
Conjunto de treinamento	4032	20.6000	0.2000	6.9000	7.3353	3.6348
Conjunto de testes	1008	23.4000	0.1000	5.8000	6.9182	4.4626

Modelo ELM. Com base nos resultados fitted e de previsão de cada subsérie, a previsão determinística final pode ser obtida pela fase III do módulo de previsão determinista. No caso de média, os resultados de previsão do intervalo probabilístico também podem ser obtidos utilizando o módulo de análise de incerteza desenvolvido. Para verificar a eficácia do sistema desenvolvido tanto na previsão determinística quanto na previsão do intervalo, os dois estudos seguintes de validação são conduzidos com mais detalhes.

#### 4.3. Validade do módulo de previsão determinista

Para verificar a validade do módulo de previsão determinístico do sistema concebido, dois casos, denotados como caso 1 e caso 2, são projetados nesta seção. A principal motivação do caso 1 é verificar a superioridade dos componentes do módulo de previsão determinista desenvolvido, como o modelo ELM, o algoritmo de otimização multi-objetivo MSSA e o método de integração recém-proposto, e então a eficácia da modelagem de hibridização desses métodos pode ser comprovada razoavelmente. Outra motivação do caso 1 é comprovar a eficácia e superioridade do módulo determinístico desenvolvido em comparação com o modelo tradicional de previsão. Além disso, a técnica de pré-processamento data desempenha um papel vital e indispensável na previsão de energia eólica, pois contribui muito para melhorar os resultados de previsão. Portanto, escolher uma técnica razoável de pré-processamento de dados é um passo crucial no processo de concepção do modelo de previsão de energia eólica. Para verificar a razoabilidade e superioridade da técnica VMD utilizada neste estudo, o caso 2 é projetado comparando a técnica de VMD com outras técnicas de pré-processamento de

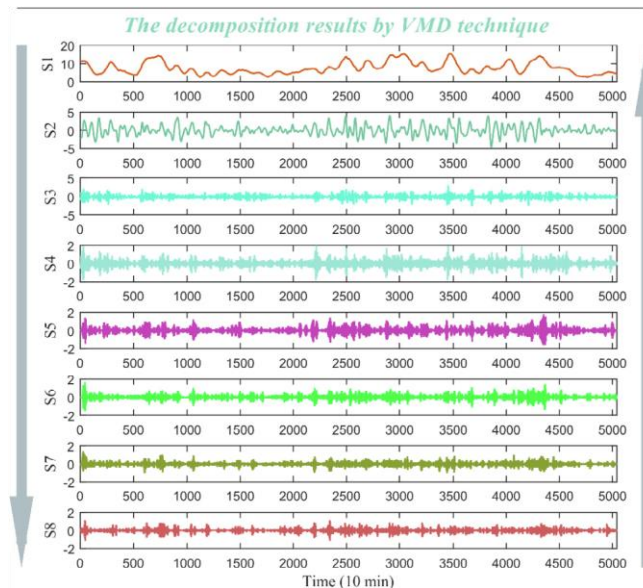


Fig. 2. Resultados de decomposição pela técnica VMD para conjunto de dados A. dados comumente utilizadas. A análise detalhada para cada um dos casos é a seguinte:

##### 4.3.1. Caso 1

Neste caso, todos os conjuntos de dados experimentais, ou seja, conjunto de dados A, conjunto de dados

B, e conjunto de dados C, são usados para avaliar o desempenho do módulo de previsão determinista. Além disso, as quatro comparações seguintes são estabelecidas neste caso, denotadas como comparação I, comparação II, comparação III e comparação IV. Em comparação I, o GRNN, ENN e ELM são usados como comparação do modelo de previsão individual para a previsão de energia eólica, que visa obter o melhor modelo de previsão individual para o desenvolvimento de um sistema eficaz de previsão e análise de energia eólica. Na comparação II, a comparação do modelo baseado em ELM combinado com diferentes métodos multi-objetivos de otimização, ou seja, MODAEELM, MOGOAeELM e MSSAeELM, é considerada como o estudo da versão melhorada do modelo, que é usada para enfatizar a sinalização da otimização para a melhoria da precisão e estabilidade da previsão final. Em comparação III, o ELM e o MSSAeELM são empregados como métodos comparados para validar o desempenho do módulo de previsão determinística. Enquanto isso, para revelar ainda mais a superioridade do módulo de previsão determinista, dois modelos tradicionais, ou seja, o modelo de persistência and ARIMA, são considerados como modelos de referência na comparação IV.

Além disso, os resultados do módulo de previsão determinístico desenvolvido e outros métodos de benchmark são apresentados na Tabela 4, onde os valores arrojados representam os melhores valores de MAE, RMSE, MAPE, MdAPE, U1, U2, GRD e PCC entre todos os modelos. Além disso, os resultados de previsão também são ilustrados na Fig. 4. Da Tabela 4 e Fig. 4, pode-se evidentemente observar que o módulo determinístico proposto é superior a outros métodos, o que significa que este módulo é mais adequado para a previsão de energia eólica do que outros.

Para a previsão determinística da energia eólica no parque eólico de Chengde, os resultados do caso 1 são os seguintes:

- (a) Comparação I é projetado para selecionar o melhor modelo de previsão individual, ou seja, ELM, entre três comumente usados




Fig. 3. Previsão de resultados de cada subsérie para conjunto de dados A.

Tabela 4

Resultados do módulo de previsão determinística proposto e outros modelos comparados no caso 1.

Dados	Modelo	MAE	RMSE	MAPA	MdAPE	U1	U2	GRD	PCC
Site 1	ARIMA	0.8147	1.0891	16.4396	10.3502	0.0696	0.9427	0.7927	0.9590
Conjunto de dados A	Modelo de persistência	0.7934	1.0921	15.1921	10.3195	0.0698	0.9781	0.7996	0.9593
	QUE	0.7766	1.0524	15.9522	9.9005	0.0674	0.9370	0.8011	0.9615
	GRNN	0.8403	1.1124	18.1713	10.6901	0.0713	0.8574	0.7895	0.9569
	OLMO	0.7736	1.0505	15.6789	9.6814	0.0673	0.9573	0.8017	0.9616
	MODAeELM	0.7708	1.0455	15.5108	9.5189	0.0670	0.9640	0.8012	0.9619
	MOGOAeELM	0.7767	1.0524	15.5792	9.6934	0.0674	0.9460	0.7997	0.9614
	MSSAeELM	0.7728	1.0486	15.4527	9.5657	0.0672	0.9698	0.8008	0.9617
	MEeVMDDeMSSAeELM	0.1000	0.1335	2.0195	1.2897	0.0085	0.0709	0.9647	0.9994
Site 2	ARIMA	0.7138	0.9409	14.0369	9.2273	0.0574	1.2640	0.8106	0.9762
Conjunto de dados B	Modelo de persistência	0.7114	0.9483	14.6466	9.0854	0.0583	0.8560	0.8116	0.9757
	QUE	0.6931	0.9204	14.7438	8.9751	0.0564	0.7598	0.8156	0.9770
	GRNN	0.8018	1.0933	17.1262	9.9674	0.0678	0.7684	0.7986	0.9696
	OLMO	0.6973	0.9229	14.5435	8.9272	0.0566	0.7895	0.8149	0.9771
	MODAeELM	0.7013	0.9318	14.6705	8.9084	0.0572	0.7002	0.8137	0.9766
	MOGOAeELM	0.7026	0.9364	14.4187	9.0608	0.0575	0.7405	0.8131	0.9765
	MSSAeELM	0.7004	0.9287	14.2728	9.0610	0.0569	0.7436	0.8138	0.9767
	MEeVMDDeMSSAeELM	0.0895	0.1168	1.8574	1.1623	0.0071	0.0677	0.9683	0.9996
Site 3	MEeVMDDeMSSAeELM	0.0895	0.1168	1.8574	1.1623	0.0071	0.0677	0.9683	0.9996

Conjunto de dados C	ARIMA	0.7942	1.0697	15.9145	10.0000	0.0650	1.0961	0.8060	0.9712
	Modelo de persistência	0.7932	1.0524	16.8574	10.1129	0.0641	1.0956	0.8037	0.9718
	QUE	0.8091	1.0919	17.5684	10.5407	0.0674	1.0582	0.8053	0.9715
	GRNN	0.8822	1.2440	19.5654	11.0462	0.0771	1.0640	0.7931	0.9635
	OLMO	0.7761	1.0410	17.2341	10.2149	0.0639	1.0448	0.8076	0.9730
	MODAeELM	0.7757	1.0325	17.0915	10.1401	0.0632	1.0656	0.8096	0.9732
	MOGOAeELM	0.7983	1.0814	17.0986	10.2821	0.0665	1.1058	0.8054	0.9713
	MSSAeELM	0.7775	1.0453	16.9580	10.2305	0.0640	1.1538	0.8081	0.9726
	MEeVMDeMSSAeELM	0.1026	0.1362	2.0656	1.3872	0.0083	0.0568	0.9657	0.9995

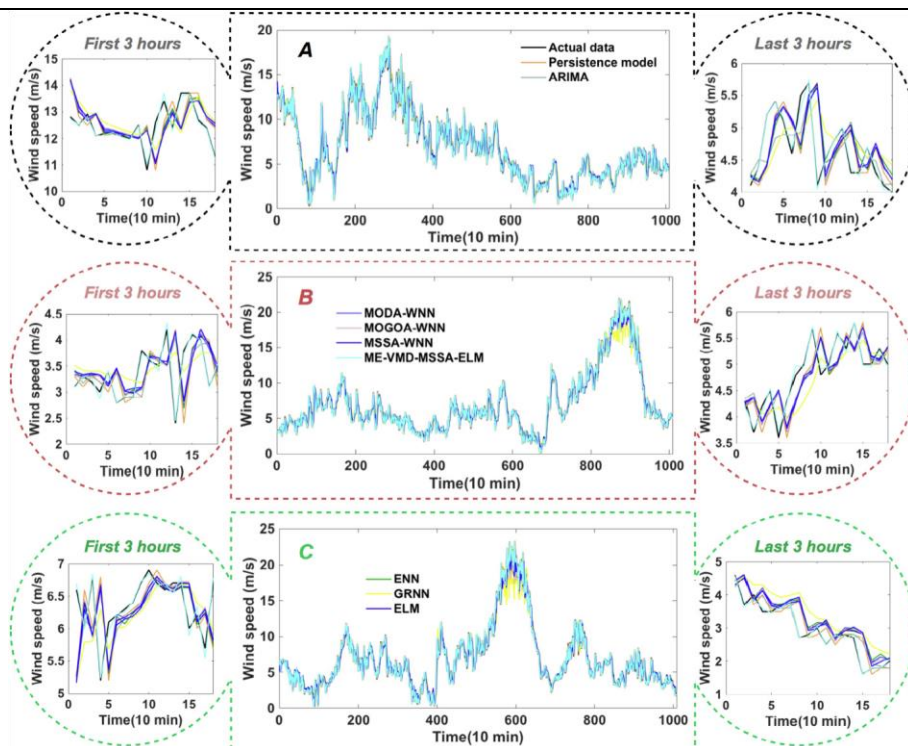


Fig. 4. Previsão de resultados de diferentes modelos considerados no caso 1.

modelos, incluindo o GRNN, ENN e ELM. Por exemplo, o modelo ELM obtém o valor mínimo do MAPE para o conjunto de dados A entre todos os modelos, e os valores MAPE do GRNN, ENN e ELM são de 18,1713%, 15,9522% e 15,6789%, respectivamente.

- (b) A comparação II está prestes a escolher um algoritmo de otimização multi-objetivo eficaz e excelente para desenvolver um modelo de ELM otimizado e melhorar ainda mais o desempenho de previsão. Para o conjunto de dados A, comparado com o MODAeELM e MOGOAeELM, os valores MAPE do MSSAeELM são reduzidos em 0,3746% e 0,8120%, respectivamente. Os resultados mostram que a otimização do ELM tem uma influência positiva para a previsão de energia eólica, e o MSSA é superior ao MODA e mogoa na resolução do problema de otimização do ELM ou outras questões não lineares complexas.
- (c) Em comparação III, os modelos componentes do módulo de previsão desenvolvido, ou seja, ELM e MSSAeELM, são adotados como modelos de referência para outro estudo de comparação. Pode-se constatar que o módulo de previsão proposto obtém resultados melhores do que os obtidos pelo ELM e MSSA-ELM. Comparando o ELM e o MSSAeELM, descobrimos que o MSSA é eficaz para

melhorar a capacidade de previsão do ELM. Além disso, foi comprovada a sinalização da otimização para a previsão de energia eólica. Além disso, comparando o módulo de previsão desenvolvido com o MSSAeELM, podemos confirmar a influência positiva da teoria da divisão e conquista e o novo método de integração para melhorar a execução da previsão. Da mesma forma, comparando o módulo de previsão proposto com o ELM, é possível quantificar claramente as contribuições do VMD, MSSA e forma de integração ao excelente desempenho do módulo. Assim, essas técnicas são capazes de efetivamente enfeitar com o desempenho do ELM, que pode ser amplamente utilizado em outras áreas.

- (d) Em comparação IV, comparando o modelo de previsão elaborado com dois modelos tradicionais, incluindo o modelo de persistência e ARIMA, é óbvio que o modelo proposto é superior aos métodos típicos tradicionais de previsão. Para o conjunto de dados A, os valores MAPE do módulo desenvolvido, modelo de persistência e ARIMA são de 2,0195%, 15,1921%, e 16,4396%, respectivamente.

#### 4.3.2. Caso 2

Este caso tem como objetivo comparar o desempenho do VMD used neste estudo com outras técnicas de decomposição bem conhecidas, incluindo EMD, EEMD e CEEMD. Para este objetivo, os módulos de previsão determinísticos baseados em diferentes abordagens de decomposição, ou seja, MEeEMDeMSSAEELM, MEeEEMDeMSSAEELM, e MEeCEEMDeMSSAEELM, são considerados como os modelos comparados. Sua única diferença é o método de decomposição usado para pré-processamento de dados na fase I. Portanto, através dessas comparações podemos não apenas testar se o módulo de previsão determinístico desenvolvido é eficaz e superior, mas também encontrar a maneira mais eficaz e eficiente de decompor a série temporal original para melhorar o desempenho do sistema. Além disso, este caso pode ser empregado para ilustrar a indispensabilidade do método de pré-processamento de dados para previsão de séries temporais complexas.

Todos os resultados obtidos pelas diferentes técnicas de decomposição de dados consideradas neste estudo são apresentados na *Tabela 5*, onde os valores ousados representam os melhores valores de cada métrica. Os resultados também são mostrados em *Fig. 5* para providing uma comparação clara. Como pode ser observado na *Tabela 5* e *Fig. 5*, o módulo de previsão determinístico desenvolvido, ou seja, MEeVMDDeMSSAEELM, tem um desempenho muito melhor do que os outros três módulos de previsão baseados em decomposição, incluindo MEeEMDeMSSAEELM, MEeEEMDeMSSAEELM e MEeCEEMDeMSSAEELM. Por exemplo, os resultados mostram que os valores MAPE do MEeEMDeMSSAEELM, MEeEEMDeMSSAEELM, MEeCEEMDeMSSAEELM e o módulo desenvolvido para previsão de energia eólica do conjunto de dados A são de 9,1486%, 4,3507%, 2,5275% e 2,0195%, respectivamente. E o modelo MEeEMDeMSSAEELM apresenta o pior desempenho entre todos os modelos de benchmark. Os erros mae do module desenvolvido são reduzidos em 55,2973% em comparação com o MEeEMDeMSSAEELM. Além disso, a precisão e a qualidade da previsão podem ser consempradas por U1 e U2, respectivamente. Por exemplo, os valores mínimos de U1 e U2 são obtidos pelo módulo desenvolvido para conjunto de dados A, which são iguais a 0,0085 e 0,0709, respectivamente. Esses resultados também revelam que a seleção de uma técnica adequada de pré-processamento de dados pode reduzir consideravelmente a dificuldade e a incerteza na previsão de energia eólica e melhorar efetivamente o desempenho do sistema. Além disso, a técnica VMD é proposta para decompor os dados originais de energia eólica com características de aleatoriedade e não linearidade, pois pode efetivamente abordar as dificuldades de previsão através da abordagem adequada de decomposição.

#### Observação para o módulo de previsão determinista

O caso 1 e o caso 2 mantiveram o foco na validação da superioridade do módulo de previsão determinística, tentando prová-lo a partir das perspectivas do modelo básico de previsão individual, otimização, método de integração, método tradicional e decomposição. Os resultados demonstraram que o módulo de previsão determinístico proposto supera todos os modelos comparados considerados nesses dois casos. A razão subjacente é que a hibridização de dados pré-processamento, otimização,

previsão e integração podem efetivamente abordar a incerteza, a difusão e potenciais melhorias na previsão de energia eólica através da abordagem de previsão adequada. Com base no excelente desempenho do módulo de previsão determinística, acreditamos que é uma alternativa promissora para a previsão de energia eólica.

#### 4.4. Validade dos resultados do módulo de análise de incerteza

Diferente da previsão determinística da energia eólica, a previsão do intervalo probabilístico pode fornecer mais informações e seus resultados são propícios à análise e avaliação de riscos para os tomadores de decisão no EPS, garantindo sua confiabilidade e controlabilidade. Nesta seção, foi desenvolvido o módulo de análise de incertezas, que é nomeado como MIMOeVMDDeMSSAEELM, para realizar a previsão de intervalo e foi verificado por três conjuntos de dados com períodos de 10 minutos em diferentes locais. Para verificar a superioridade do sistema concebido para a previsão de intervalos, três modelos baseados em diferentes decompositions e o melhor esquema multi-entrada multi-entrada, incluindo o MIMOeEMDeMSSAEELM, MIMOeEEMDeMSSAEELM e MIMOeCEEMDeMSSAEELM, são desenvolvidos como modelos de benchmark para realizar a mesma previsão de intervalo. Desenvolvemos esses três modelos principalmente como modelos de comparação porque os módulos de previsão determinísticos baseados nessas três diferentes abordagens de decomposição têm um desempenho melhor do que os outros modelos comparados considerados no estudo comparativo de casos de módulos de previsão determinística. Além disso, se o módulo MIMOeVMDDeMSSAEELM desenvolvido superar todos esses três modelos competitivos, podemos acreditar com segurança que o módulo de análise de incerteza desenvolvido é superior a outros modelos de benchmark, o que prova plenamente a eficácia e superioridade do módulo THIS.

Os resultados do módulo MIMOeVMDDeMSSAEELM desenvolvido e dos outros três modelos de referência são apresentados na *Tabela 6*, e compreendem os experimentos baseados em três locais do parque eólico de Chengde. Além disso, a probabilidade de expectativa, ou seja, (1e a) 100%, está definida para 90% e 80%, respectivamente, para avaliação do módulo de análise de incerteza desenvolvido. A partir da *Tabela 6*, observa-se que o módulo de análise de incertezas proposto obtém os melhores valores de todas as métricas entre todos os modelos, o que demonstra que o módulo de análise elaborado é superior a todos os métodos de benchmark. Por exemplo, quanto à probabilidade de expectativa de 90%, o conjunto de dados A como exemplo, os valores FICP oferecidos pela MIMOeEMDeMSSAEELM, MIMOeEEMDeMSSAEELM, MIMOeCEEMDeMSSAEELM, e o módulo desenvolvido de análise de incertezas são 58,4325, 62,2024, 93,9484 e 95,4365, respectivamente, enquanto os valores IFAW são 0,0733, 0,0735, 0,0715 e 0,0712,

*Tabela 5*  
Resultados do módulo de previsão determinística proposto e outros modelos comparados no caso 2.

Dados	Modelo	MAE	RMSE	MAPA	MdAPE	U1	U2	GRD	PCC
Site 1	MEeEMDeMSSAEELM	0.4304	0.5590	9.1486	5.6283	0.0357	0.4388	0.8721	0.9893
Conjunto de dados A	MEeEEMDeMSSAEELM	0.2237	0.3032	4.3507	2.8693	0.0195	0.2507	0.9301	0.9973
	MEeCEEMDeMSSAEELM	0.1314	0.1812	2.5275	1.6722	0.0116	0.1545	0.9547	0.9989
	MEeVMDDeMSSAEELM	0.1000	0.1335	2.0195	1.2897	0.0085	0.0709	0.9647	0.9994
Site 2	MEeEMDeMSSAEELM	0.4078	0.5193	8.2299	5.4140	0.0316	0.5517	0.8775	0.9930
Conjunto de dados B	MEeEEMDeMSSAEELM	0.1779	0.2399	3.4370	2.2452	0.0146	0.2212	0.9401	0.9985
	MEeCEEMDeMSSAEELM	0.1138	0.1513	2.1475	1.5181	0.0092	0.1566	0.9602	0.9994

Site 3 Conjunto de dados C	MEeVMDDeMSSAeELM	0.0895	0.1168	1.8574	1.1623	0.0071	0.0677	0.9683	0.9996
	MEeEMDeMSSAeELM	0.4388	0.6069	9.9914	5.5011	0.0373	0.4627	0.8785	0.9917
	MEeCEEMDeMSSAeELM	0.2079	0.2841	4.6130	2.5956	0.0173	0.1485	0.9361	0.9981
	MEeCEEMDeMSSAeELM	0.1217	0.1697	2.7804	1.5071	0.0103	0.1127	0.9601	0.9993
	MEeVMDDeMSSAeELM	0.1026	0.1362	2.0656	1.3872	0.0083	0.0568	0.9657	0.9995

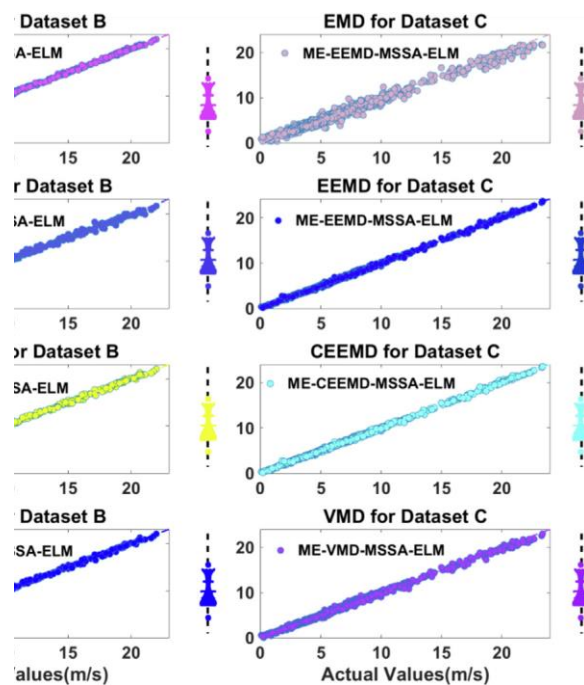


Fig. 5.2 resultados  
Previsão de diff  
modelos erent co

considered no  
aso 2.

Tabela 6  
Análise proposto e outros mc

Site 1 Dataset			Asite 2 Dataset			BSite 3 Dataset C		
AlphaFICP	FINAW	AWD	PICP	PINAW	AWD	PICP	PINAW	AWD
MIMOeEMDeMSSAeELM								
0.158.4325	0.0733	0.0135	57.0437	0.0643	0.0081	51.7857	0.0554	0.0172
0.284.9206	0.1414	0.0034	85.9127	0.1249	0.0014	78.1746	0.1141	0.0030
MIMOeEEMDeMSSAeELM								
0.162.2024	0.0735	0.0096	71.7262	0.0619	0.0053	58.3333	0.0563	0.0124
0.286.1111	0.1511	0.0017	92.2619	0.1286	0.0012	80.0595	0.1047	0.0102
MIMOeCEEMDeMSSAeELM								
0.193.9484	0.0715	0.0020	94.8413	0.0638	0.0013	94.9405	0.0594	0.0085
0.298.1151	0.1430	0.0013	98.6111	0.1274	0.0011	97.6190	0.1185	0.0004
MIMOeVMDDeMSSAeELM								
0.195.4365	0.0712	0.0010	96.9246	0.0637	0.0007	95.8333	0.0589	0.0017
0.299.2063	0.1429	0.0001	99.3056	0.1264	0.0001	99.0079	0.1176	0.0001

respectivamente. Além disso, o módulo de análise proposto leva a reduções de 0,0125, 0,0086 e 0,0010 em AWD quando comparado com os modelos

MIMOeEMDeMSSAeELM, MIMOeEEMDeMSSAeELM e MIMOeCEEMDeMSSAeELM, respectivamente.



Enquanto isso, para apresentar o comparison de forma clara e intuitiva, os resultados do módulo concebido e dos outros métodos comparados são mostrados em Figs. 6e8, que suportam as conclusões obtidas da Tabela 6 e fornecem evidências intuitivas para verificar a superioridade do sistema proposto para análise da incerteza da energia eólica. Como mostrado em Figs. 6e8, o módulo de análise de incerteza desenvolvido obtém resultados de previsão de intervalo mais eficazes quando comparado com os outros métodos, e é claro que seu intervalo previsto não só cobre valores reais de energia eólica com maior probabilidade, mas também se torna mais suave do que os outros modelos comparados, o que significa que a robustez do módulo de análise de incerteza desenvolvido é mais estável do que a dos outros Modelos. Além disso, os resultados dizem que o módulo de análise de incertezas proposto apresenta a mesma superioridade para os três conjuntos de dados de experimentos de diferentes locais, o que demonstra ainda mais a eficácia e robustez do sistema elaborado para análise da incerteza.

#### Observação para o módulo de análise de incerteza

Os estudos comparativos são realizados com base em dados de diferentes locais e três modelos competitivos baseados em diferentes decomposições e no melhor esquema de multi-entradas de multi-saída, e mostram que o módulo de análise não certificou que o módulo de análise desenvolvido supera todos os modelos comparados. Com base no excelente desempenho do módulo de análise de incertezas elaborado, acreditamos que é uma alternativa promissora para a previsão de intervalo probabilístico de energia eólica.

## 5. Discussão

Para verificar melhor o desempenho do sistema elaborado e fornecer sugestões para estudos futuros, algumas questões são discutidas nesta seção.

### 5.1. Discussão da forma de integração adequada

A maioria dos estudos anteriores apenas empregou o método simples de integração direta (DI) para obter os resultados final com base no esquema de divisão e conquista, e poucos deles consideraram outras formas de integração

na fase de conquista, o que oferece potencial de melhorias em estudos futuros. Portanto, neste estudo, propõe-se um ELM otimizado como um novo método de integração para melhorar ainda mais a eficácia da etapa de conquista e o desempenho de previsão final. Para comprovar a superioridade do método de integração desenvolvido e verificar a contribuição deste estudo ao mesmo tempo, o método simples de integração direta é utilizado como modelo de referência, denotado como DieVMDemSSAeELM, para obter os resultados de previsão final. Os resultados, incluindo oito métricas do módulo de previsão determinística proposto e dos outros modelos comparados, estão listados na Tabela 7. De acordo com o estudo comparativo apresentado na Tabela 7, comparamos o MAE, RMSE, MAPE, MdAPE, U1, U2, GRD e PCC, e o módulo desenvolvido tem melhor desempenho na maioria dos testes. Por exemplo, em comparação com o DieVMDemSSAeELM, os erros de MAE do MEeVMDemSSAeELM são reduzidos em 10,9528%, 11,6549% e 10,1576% para a forecasting de energia eólica nos conjuntos de dados A, B e C, respectivamente. Os resultados mostram que a forma de integração adequada desempenha um papel importante na previsão de energia eólica com base na teoria da divisão e conquista, e a forma recém-proposta de integração tem mostrado sua vanguarda significant sobre o método de integração direta na fase de conquista para prever os resultados final com base nas mudanças futuras previstas de cada subsérie. Mais importante, o módulo de previsão determinístico desenvolvido satisfaz satisfatoriamente todos os dados sobre os locais de diferentes e, assim, o módulo pode ser usado como parte de previsão do sistema de previsão e análise de energia eólica.

### 5.2. Discussão da sinalização estatística do sistema

Embora o módulo de previsão determinístico desenvolvido já tenha sido verificado por oito métricas de avaliação, a sinalização estatística precisa ser testada do ponto de vista estatístico

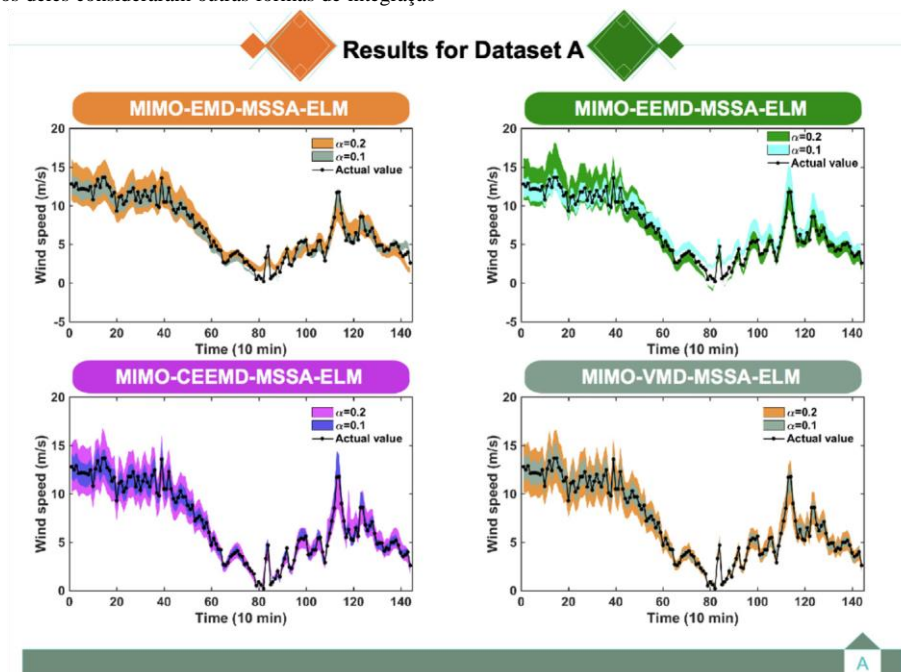


Fig. 6. Previsão de resultados de diferentes modelos para conjunto de dados A.

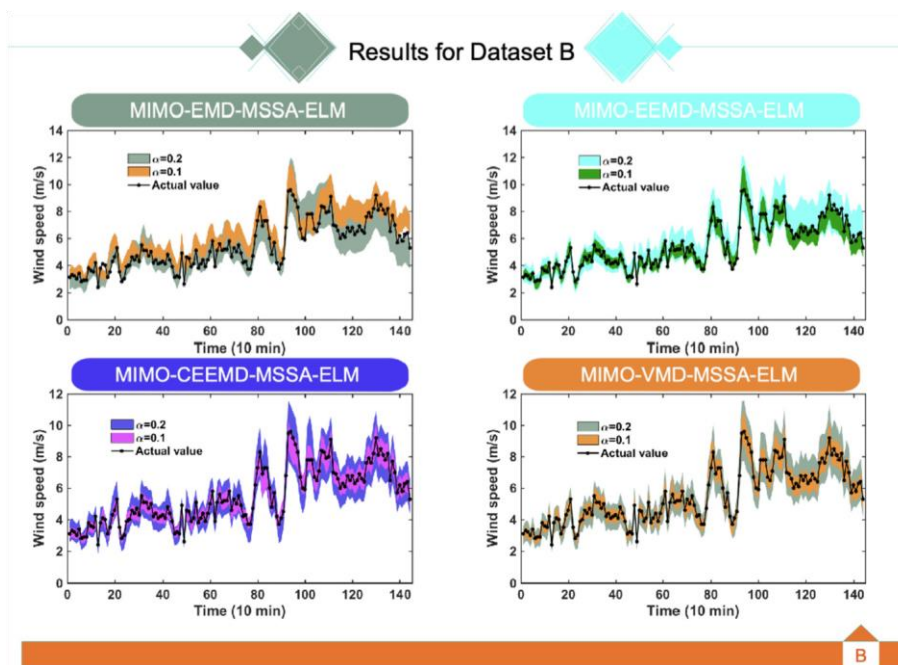


Fig. 7. Previsão de resultados de diferentes modelos para conjunto de dados B.

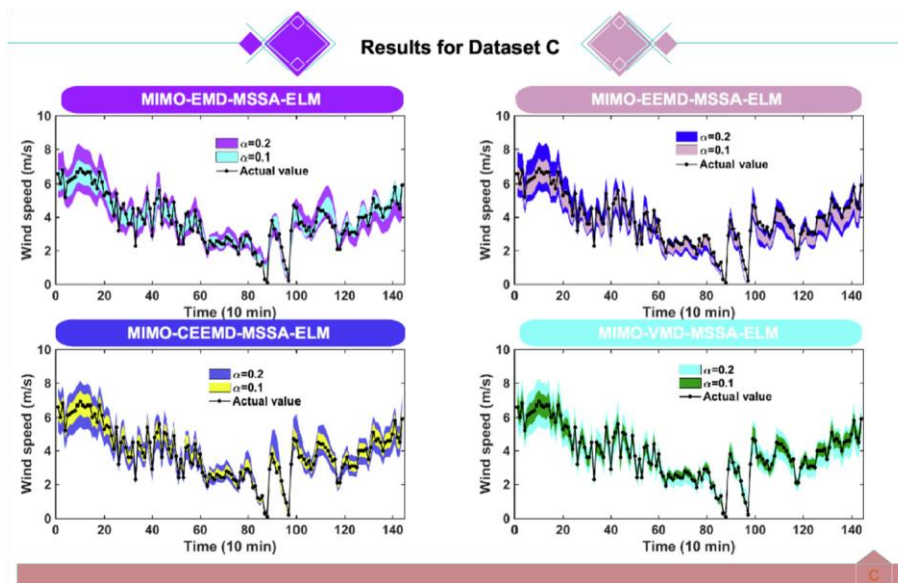


Fig. 8. Previsão de resultados de diferentes modelos para conjunto de dados C.

Tabela 7

Resultados para o módulo de previsão desenvolvido e modelos comparados.

Modelo	MAE	RMSE	MAPA	MdAPE	U1	U2	GRD	PCC
Conjunto de dados do site 1 A								
DleVMDemSSAeELM	0.1123	0.1489	2.2415	1.4267	0.0095	0.0884	0.9607	0.9992
MEeVMDemSSAeELM	0.1000	0.1335	2.0195	1.2897	0.0085	0.0709	0.9647	0.9994
Conjunto de dados do site 2 B								
DleVMDemSSAeELM	0.1013	0.1312	2.1943	1.2967	0.0080	0.0882	0.9645	0.9995
MEeVMDemSSAeELM	0.0895	0.1168	1.8574	1.1623	0.0071	0.0677	0.9683	0.9996
Site 3 Dataset C								
DleVMDemSSAeELM	0.1142	0.1517	2.3773	1.5061	0.0092	0.0637	0.9624	0.9994

Tabela 8

Resultados de testes de DM para o módulo de previsão desenvolvido e modelos comparados.

Modelo	Conjunto de dados do site 1 A	Conjunto de dados do site 2 B	Site 3 Dataset C
ARIMA	17.2217a	17.0170a	17.0194a
Modelo de persistência	15.9187a	16.3703a	17.2768a
QUE	16.2131a	16.9979a	15.8565a
GRNN	17.2339a	14.9825a	12.9364a
OLMO	16.2896a	17.1267a	16.6961a
MODAeELM	16.0098a	16.8541a	16.9938a
MOGOAeELM	16.1020a	16.5049a	15.9114a
MSSAeELM	16.0519a	16.8759a	16.5526a
MEeEMDeMSSAEELM	18.0716a	19.7921a	13.9840a
MEECEEMDeMSSAEELM	13.2885a	11.4929a	11.2910a
	5.9088a	6.4596a	4.5651a
MEECEEMDeMSSAEELM			
DleVMDeMSSAeELM	5.8904a	7.0468a	4.2797a
MEEVMDDeMSSAEELM	-	e	e

a Indica o nível de significância de 1%.

usando testes de hipóteses. Portanto, um método eficaz de teste de hipóteses, ou seja, o teste Diebold-Mariano (DM) (Diebold e Mariano, 1995), é apresentado nesta seção com base na função de perda de erro quadrado. Os valores dos testes DM estão listados na Tabela 8. Furthermore, o menor valor de DM é de 4,2797, que é muito maior que  $z_{0.01/2} = 1/4 \cdot 2.58$ . Com base nisso, no nível de significância de 1%, podemos rejeitar a hipótese nula e considerar que o módulo de previsão determinística concebido faz mais apostas do que os outros modelos de referência. Portanto, acreditamos que o módulo de previsão determinista proposto não só mostra excelente desempenho de previsão, mas também apresenta uma diferença significant no nível de previsão de desempenho, o que verifica ainda mais a superioridade do sistema concebido para a previsão de energia eólica.

### 5.3. Discussão sobre a estabilidade de previsão do sistema

Principalmente devido à sinalização de alcançar precisão e estabilidade ao mesmo tempo para aplicações de engenharia, o algoritmo MSSA é empregado para desenvolver um sistema eficaz neste estudo e prever mudanças futuras com base nas melhorias alcançadas na precisão e estabilidade da previsão. A análise acima mencionada está focada na avaliação da precisão da previsão, que não pode comprovar a melhoria do módulo proposto em termos de estabilidade. No entanto, como discutido acima, a estabilidade é um dos fatores mais importantes no desenvolvimento de um modelo. Portanto, para realizar uma avaliação mais abrangente para o módulo determinístico, além de avaliar o desempenho a partir da perspectiva de precisão de previsão na Seção 4, deve ser realizada uma discussão sobre a estabilidade de previsão do módulo neste estudo. É sabido que o desempenho de previsão pode ser medido pelo erro de pré-moldagem. Além disso, a variância pode representar a estabilidade

Tabela 9

Resultados da variância do erro de previsão para cada modelo.

Modelo	Conjunto de dados do site 1 A	Conjunto de dados do site 2 B	Site 3 Dataset C
ARIMA	1.1855	0.8862	1.1454
Modelo de persistência	1.1937	0.8975	1.1087
QUE	1.1066	0.8479	1.1897
GRNN	1.2348	1.1878	1.5447
OLMO	1.1032	0.8523	1.0838
MODAeELM	1.0930	0.8688	1.0672
MOGOAeELM	1.1070	0.8773	1.1692
MSSAeELM	1.0995	0.8633	1.0937
MEeEMDeMSSAEELM	0.3109	0.2629	0.3583
MEECEEMDeMSSAEELM	0.0850	0.0576	0.0773
	0.0328	0.0229	0.0288
MEECEEMDeMSSAEELM			
DleVMDeMSSAeELM	0.0222	0.0172	0.0230
MEEVMDDeMSSAEELM	0.0178	0.0136	0.0185




Fig. 9. Análise de sensibilidade de diferentes números de agentes de pesquisa com base no MSSA.

de uma série temporal (Tian e Hao, 2018). Portanto, neste estudo, a variância do erro de previsão do modelo é empregada para medir sua estabilidade de previsão. Valores de baixa variância significam que o modelo tem melhor desempenho em termos de estabilidade, enquanto os altos valores de variância indicam que o modelo é mais instável do que outros modelos com valores baixos (Hao e Tian, 2019b). As variâncias dos erros de previsão para diferentes modos estão listadas no Table 9, o que mostra que o módulo de previsão determinística proposto obtém os menores valores de variância entre todos os modelos nos diferentes conjuntos de dados. Os resultados comprovam que o módulo de previsão determinístico proposto é mais estável do que os outros modelos comparados considerados neste estudo e que pode realizar previsão de energia eólica com a estabilidade desejada em um verdadeiro parque eólico.

#### 5.4. Discussão da análise de sensibilidade para o algoritmo de otimização multiprofissional

Devido à sinalização da otimização multi-objetiva no sistema desenvolvido, mais comentários sobre o ajuste dos parâmetros de controle devem ser apresentados. Neste estudo, há um parâmetro-chave, chamado número de agentes de busca, que afetará o desempenho do modelo. Assim, uma discussão sobre a análise de sensibilidade do número dos agentes de busca no algoritmo de otimização multiprofissional é uma questão importante que vale a pena estudar. Nesta seção, a discussão sobre este importante parâmetro é conduzida com base no conjunto de dados C, e os resultados medidos pelo MAPE são mostrados na Fig. 9. Deve-se notar que apenas o número dos agentes de busca na fase III do módulo de previsão determinística é considerado para a discussão da análise de sensibilidade. O objetivo é evitar a influência de outros parâmetros, incluindo os números dos agentes de pesquisa, na fase I. Especificamente, como mostrado na Fig. 9, os resultados comprovam que o número do agente de pesquisa tem impacto no modelo. s previsão. Se o número for muito grande, pode resultar em um fraco desempenho de previsão e um aumento na complexidade da computação, enquanto que se o número for muito pequeno, pode não alcançar o parâmetro do melhor modelo e fornecer resultados de previsão ruins. Moreover, haverá um ponto de virada, que pode ser definido como o parâmetro ideal do modelo para a previsão de energia eólica. Assim, considerando a complexidade de desempenho e computação do modelo, o número dos agentes de busca é desafiado como 40, que é o parâmetro ideal neste estudo.

#### 5.5. Discussão da superioridade do algoritmo de otimização multiprofissional

A comparação entre diferentes modelos com algoritmos de otimização provou que o algoritmo MSSA executa

Tabela 10

Valores estatísticos do IGD para quatro funções de teste.

	Signifi	DST	Mediana	Melh	Pior
<b>ZDT1</b>					
MOGOA	0.015759	0.008718	0.013463	0.005627	0.044987
MODA	0.003673	0.001496	0.003468	0.002064	0.009450
MSSA	0.002284	0.000344	0.002243	0.001751	0.003129
<b>ZDT2</b>					
MOGOA	0.015759	0.008718	0.013463	0.005627	0.044987
MODA	0.003673	0.001496	0.003468	0.002064	0.009450
<b>ZDT3</b>					
MOGOA	0.023466	0.001199	0.023450	0.021290	0.026890
MODA	0.024921	0.000484	0.024821	0.024359	0.026596
MSSA	0.024799	0.000307	0.024793	0.024274	0.025535
<b>ZDT1</b>					
MOGOA	0.019879	0.012171	0.015506	0.007895	0.057791
MODA	0.003993	0.002180	0.003179	0.002013	0.011178
MSSA	0.002474	0.000355	0.002456	0.002001	0.003761

ZDT1is ZDT1 com frente linear.

melhor do que outros dois algoritmos bem conhecidos. A teoria chamada de free lunch (NFL) (Wolpert e Macready, 1997) provou que nenhum algoritmo único pode resolver todos os problemas de otimização. Para obter o melhor desempenho, os pesquisadores devem selecionar adequadamente o algoritmo de otimização para seus estudos. Além disso, os índices de desempenho de otimização multiprofissionais podem servir como padrão de referência. Portanto, neste estudo, são apresentados e discutidos índices multi objetivos de desempenho de otimização, incluindo a métrica amplamente utilizada chamada distância geracional invertida (IGD) (Mirjalili et al., 2016), e são empregados para avaliar o desempenho de otimização do MSSA. Em particular, o IGD é a métrica de desempenho que mostra a convergência de um algoritmo e seus resultados estatísticos podem ser usados para medir a robustez e robustez do algoritmo (Mirjalili et al., 2016, 2017; Kusakci e Can, 2013). Quatro funções de teste, incluindo ZDT1, ZDT2, ZDT3 e ZDT1 com frente linear são usadas. Para cada função de teste, trinta experimentos são realizados com base nos seguintes parâmetros: o número de iteração é igual a 100, o número dos agentes de pesquisa é igual a 40 e o tamanho do arquivo é igual a 100. Os resultados são apresentados na Tabela 10. A partir da Tabela 10, observa-se que o MSSA obtém os melhores valores do IGD para três funções de teste including ZDT1, ZDT2 e ZDT1 com frente linear. Um melhor desempenho é mostrado tanto no desvio médio quanto no padrão, o que prova o quão bom e robusto o MSSA é ao resolver tais problemas. Portanto, o método MSSA é superior ao MOGOA e moda em termos de convergência, estabilidade e robustez, e tem a melhor capacidade potencial para

Tabela 11

Resultados do módulo de previsão determinístico desenvolvido e outros modelos.

dados é realizado para decompor o data original em várias subséries para capturar

Dados	Modelo	MAE	RMSE	MAPA	MdAPE	U1	U2	GRD	PCC
Site 1	ICEEMDANeMODAeENN	0.4132	0.5642	8.3086	5.2374	0.0361	0.3923	0.7857	0.9891
Conjunto de dados A	MCEEMDeMOSCAeWNN	0.1109	0.1591	2.4207	1.3765	0.0102	0.0817	0.9293	0.9992
	CSVeMOSBOeENN	0.1850	0.2648	3.0776	2.2159	0.0170	0.0878	0.8858	0.9977
	MEeVMDeMSSAeELM	0.1000	0.1335	2.0195	1.2897	0.0085	0.0709	0.9302	0.9994
	ICEEMDANeMODAeENN	0.3660	0.4988	7.5334	4.7055	0.0306	0.6786	0.8599	0.9937
Conjunto de dados B	MCEEMDeMOSCAeWNN	0.1030	0.1382	3.0295	1.2627	0.0084	0.4517	0.9533	0.9995
	CSVeMOSBOeENN	0.1708	0.2422	3.9946	2.0818	0.0147	0.4702	0.9273	0.9986
	MEeVMDeMSSAeELM	0.0895	0.1168	1.8574	1.1623	0.0071	0.0677	0.9589	0.9996
	ICEEMDANeMODAeENN	0.4039	0.6245	7.5831	4.6371	0.0377	0.2073	0.8529	0.9907
Conjunto de dados C	MCEEMDeMOSCAeWNN	0.1086	0.1507	3.1613	1.2783	0.0091	0.0711	0.9517	0.9994
	CSVeMOSBOeENN	0.2132	0.3929	3.6605	2.1411	0.0241	0.1057	0.9029	0.9975
	MEeVMDeMSSAeELM	0.1026	0.1362	2.0656	1.3872	0.0083	0.0568	0.9523	0.9995
	ICEEMDANeMODAeENN	0.4039	0.6245	7.5831	4.6371	0.0377	0.2073	0.8529	0.9907

otimização do modelo. Além disso, essa foi a razão por trás da escolha de um MSSA no sistema desenvolvido.

## 5.6. Discussão da superioridade e avanço do sistema desenvolvido

Para comprovar ainda mais a superioridade do sistema desenvolvido e enfatizar o avanço do artigo em relação a outros modelos da literatura, é preciso realizar uma comparação entre o sistema concebido e outros sistemas propostos em estudos anteriores. Portanto, nesta seção, três sistemas de previsão híbrida, chamados ICEEMDANeMODAeENN (Wang et al., 2018c), MCEEMDeMOSCAeWNN (Wang et al., 2018b) e CSVeMOSBOeENN (Tian et al., 2018), são adotados como modelos de referência para comprovar ainda mais a superioridade do sistema desenvolvido para previsão determinística. Os resultados do módulo de previsão dissuadiminística proposto e outros modelos de benchmark são apresentados na Tabela 11, onde os valores arrojados representam os menores valores de MAE, RMSE, MAPE, U1 e U2 e os maiores valores de GRD e PCC entre todos os modelos. A partir da Tabela 11, pode-se, obviamente, evitar que o módulo determinístico proposto tenha um desempenho melhor do que os outros modelos comparados, o que mostra o avanço deste estudo em relação à literatura (Tian et al., 2018; Wang et al., 2018b, 2018c) e valida ainda mais a superioridade do sistema desenvolvido para previsão determinística.

## 6. Conclusão

Uma efetiva previsão determinista de energia eólica e uma análise de incerteza fornecem mais informações para os tomadores de decisão no EPS, o que pode melhorar sua gestão e agendamento. No entanto, devido às características de aleatoriedade e não linearidade associadas à energia eólica, desenvolver um sistema eficaz de previsão e análise de energia eólica não é apenas uma questão particularmente desafiadora, mas também uma tarefa crítica para toda a sociedade. A pesquisa relevante tem deficiências, apesar de sua significância. Apesar disso, neste estudo, um novo sistema de previsão e análise de energia eólica é desenvolvido com sucesso com base na ideia de dividir e conquistar para compensar a insuficiência dos estudos existentes e realizar uma efetiva análise determinística e de incerteza. Os resultados experimentais ilustram que o sistema elaborado pode produzir resultados de previsão determinísticos mais precisos e estáveis e um intervalo previsto de maior qualidade do que outros modelos de benchmark. Assim, podemos concluir que o sistema elaborado supera todos os modelos considerados comparados em aplicações de engenharia.

As razões pelas quais o sistema concebido é superior a outros modelos de benchmark podem ser resumidas da seguinte forma: (1) o pré-processamento de

e minerar as principais características dos dados de energia eólica e eliminar a inflação negativa do ruído, que tem um efeito positivo na melhoria do desempenho do sistema; (2) um ELM otimizado é desenvolvido com base na otimização multi-objective para prever mudanças futuras de cada subsérie, o que garante um desempenho de previsão eficaz com melhor precisão e estabilidade; (3) diferente da maioria dos estudos anteriores, outro ELM otimizado é proposto com sucesso como um método de integração new para obter os resultados de previsão final, o que melhora ainda mais a eficácia da fase de conquista e, em última instância, melhora o desempenho de previsão final; (4) o ELM multi-produção multi-produção otimizado é desenvolvido com três aims, ou seja, para maximizar a probabilidade de cobertura do intervalo de previsão, para minimizar o intervalo de previsão de largura média normalizada, e para minimizar o desvio de largura acumulado, para prever futuros intervalos de energia eólica com base nas mudanças futuras de cada subseries, que constroem intervalos de previsão de alta qualidade para energia eólica.

Os resultados revelam que o sistema concebido é uma ferramenta eficaz para a previsão determinística da energia eólica e a análise da incerteza. Mais especificamente, tomando dataset A como um exame, os estudos comparativos mostram que o sistema desenvolvido para previsão determinística tem um valor MAPE menor de 2,0195% em comparação com os MAPEs de 8,3086%, 2,4207%, e 3,0776% para os modelos da literatura anterior, ou seja, ICEEMDANeMODAeENN, MCEEMDeMOSCAeWNN, e CSVeMOSBOeENN, respectivamente. Isso mostra que o sistema desenvolvido leva a reduções de 6,2891%, 0,4012% e 1,0581% no MAPE quando comparados com esses três modelos, respectivamente. Portanto, podemos razoavelmente chegar à conclusão de que o sistema concebido também pode ser amplamente utilizado em outras áreas de aplicações de engenharia no futuro devido ao seu excelente desempenho, o que pode reduzir o risco financeiro e técnico de incerteza da energia eólica para todos os participantes do mercado de eletricidade e trazer finalmente enorme economia, benefícios sociais e ambientais. Além disso, algumas implicações baseadas no sistema de previsão determinística de energia eólica desenvolvida e no sistema de análise da incerteza, na perspectiva do governo e dos profissionais, podem ser declaradas claramente da seguinte forma. (1) O governo pode estabelecer e melhorar políticas sistemáticas e eficazes de energia eólica e promover a energia eólica para participar da concorrência de mercado, a fim de superar os obstáculos econômicos à aceitação da energia eólica pela rede elétrica. Além disso, os governos podem aumentar o apoio a investimentos relevantes em pesquisa científica e promover o avanço do sistema de previsão determinística de energia eólica e análise da incerteza. (2) Os profissionais relacionados podem aplicar a previsão de energia eólica eficaz para melhorar o desempenho das turbinas eólicas, a capacidade de agendamento da rede elétrica e outras tecnologias, permitindo assim que o EPS aceite mais energia eólica e quebrando as restrições técnicas da rede elétrica para aceitar a capacidade de



energia wind. Os profissionais relacionados podem tomar medidas práticas para realizar uma alocação efetiva dos recursos do sistema de energia e melhorar o benefício econômico sob a condição de garantir a estabilidade do mercado de energia.

## Conflitos de interesse

Os autores do The declaram que não há qualquer conflict de interesse em relação à publicação deste artigo.

## Agradecimentos

Este trabalho foi apoiado pela Fundação Nacional de Ciência Natural da China (Grant No. 71671029) e pelo Conselho de Bolsas da China (CSC) (File No. 201808210272).

## Referências

- Bludszweit, H., Domínguez-Navarro, J.A., Llombart, A., 2008. Análise estatística do erro de previsão de energia eólica. *IEEE Trans. Power Syst.* <https://doi.org/10.1109/TPWRS.2008.922526>.
- Branke, J., Kaußler, T., Schmeck, H., 2001. Orientação em otimização multi-objetiva evolutiva. *Adv. Eng. Software*. [https://doi.org/10.1016/S0965-9978\(00\)00110-1](https://doi.org/10.1016/S0965-9978(00)00110-1).
- Coello Coello, C.A., 2009. Otimização multi-objetiva evolutiva: algumas tendências e tópicos atuais de pesquisa que ainda estão a ser explorados. *Fronte. Computação. Sci. China*. <https://doi.org/10.1007/s11704-009-0005-7>.
- Diebold, F.X., Mariano, R.S., 1995. Comparando a precisão preditiva. *J. Bus. Econ. Stat.* <https://doi.org/10.1080/0735015.1995.10524599>.
- Dragomiretskiy, K., Zosso, D., 2014. Decomposição do modo variacional. *IEEE Trans. Processo de sinal*. <https://doi.org/10.1109/TSP.2013.2288675>.
- Du, P., Wang, J., Yang, W., Niu, T., 2018. Multi-passo à frente previsão no sistema de energia elétrica usando um sistema de previsão híbrida. *Renovar. Energia*. <https://doi.org/10.1016/j.renene.2018.01.113>.
- Errouissi, R., Cardenas-Barrera, J., Meng, J., Castillo-Guerra, E., Gong, X., Chang, L., 2015. Estimativa do intervalo de previsão de bootstrap para previsão de velocidade do vento. In: 2015 IEEE Energy Conversion Congress and Exposition, ECCE 2015. <https://doi.org/10.1109/ECCE.2015.7309931>.
- Foley, A.M., Leahy, P.G., Marvuglia, A., McKeogh, E.J., 2012. Métodos atuais e avanços na previsão da geração de energia eólica. *Renovar. Energia*. <https://doi.org/10.1016/j.neucom.2015.11.010>.
- Conselho Global de Energia Eólica, 2018. Relatório Global de Vento 2017. <http://fi.les.gwec.net/registro/sucesso/?file1/4/files/GWR2017.pdf>.
- Hao, Y., Tian, C., 2019a. Um novo modelo de previsão de duas etapas foi baseado no fator de erro e no método de conjunto para previsão de energia eólica em várias etapas. <https://doi.org/10.1016/j.apenergy.2019.01.063>.
- Hao, Y., Tian, C., 2019b. O estudo e a aplicação de um novo sistema híbrido para a qualidade do ar alerta antecipado. *Appl. Soft Comput. J.* <https://doi.org/10.1016/j.asoc.2018.09.005>.
- Hong, Y.Y., Chang, H.L., Chiu, C.S., 2010. Previsão de energia eólica e velocidade com uma hora de antecedência usando algoritmo de aproximação e aproximação estocástica simultânea (SPSA) e rede neural com entradas difusas. *Energia*. <https://doi.org/10.1016/j.energy.2010.05.041>.
- Hu, J., Wang, J., Ma, K., 2015. Uma técnica híbrida para previsão de velocidade do vento a curto prazo. *Energia*. <https://doi.org/10.1016/j.energy.2014.12.074>.
- Huang, G. Bin, Zhu, Q.Y., Siew, C.K., 2004. Máquina de aprendizagem extrema: um novo esquema de aprendizagem de redes neurais de alimentação. In: IEEE International Conference on Neural Networks - Conference Proceedings. <https://doi.org/10.1109/ICNN.2004.1380068>.
- Huang, G. Bin, Zhou, H., Ding, X., Zhang, R., 2012. Máquina de aprendizagem extrema para regressão e classificação multiclasse. *IEEE Trans. Syst. Man Cybern. B Cybern.* <https://doi.org/10.1109/TSMCB.2011.2168604>.
- Huang, G. Bin, Bai, Z., Kasun, L.L.C., Vong, C.M., 2015. Fields receptivos locais baseados em máquina de aprendizagem extrema. *IEEE Comput. Intell. Mag.* <https://doi.org/10.1109/MCI.2015.2405316>.
- Huang, N., Chen, H., Cai, G., Fang, L., Wang, Y., 2016. Diagnóstico de falha mecânica de disjuntores de alta tensão com base na decomposição do modo variacional e em vários tipos de classe. <https://doi.org/10.3390/s1611887>.
- Jiang, P., Ma, X., 2016. Uma abordagem híbrida de previsão aplicada no sistema de energia elétrica com base em algoritmos de pré-processamento, otimização e inteligência artificial. *Appl. Math. Model.* <https://doi.org/10.1016/j.apm.2016.08.001>.
- Jiang, P., Liu, F., Song, Y., 2017. Um modelo de previsão híbrida baseado na strategy de data-framework e tecnologia de seleção de recursos melhorada para previsão de carga de curto prazo. *Energia*. <https://doi.org/10.1016/j.energy.2016.11.034>.
- Jiang, H., 2018. Previsão de modelo com base em procedimento de seleção de feature em duas etapas usando algoritmo ortogonal ganancioso. *Appl. Soft Comput. J.* <https://doi.org/10.1016/j.asoc.2017.11.047>.
- Jiang, P., Yang, H., Heng, J., 2019. Um sistema de previsão híbrida baseado em séries temporais difusas e otimização multi-objetiva para previsão de velocidade do vento. *Energia*. <https://doi.org/10.1016/j.apenergy.2018.11.012>.
- Juban, J., Siebert, N., Kariniotakis, G.N., 2007. Previsão de energia eólica de curto prazo probabilística para o manejo ideal da geração eólica. In: 2007 IEEE Lausanne POWERTECH, Proceedings. <http://doi.org/10.1109/PCT.2007.4538398>.
- Khosravi, A., Nahavandi, S., Creighton, D., Atiya, A.F., 2011. Método de estimativa de limite superior inferior para construção de intervalos de previsão baseados em rede neural. *IEEE Trans. Neural Netw.* <https://doi.org/10.1109/TNN.2010.2096824>.
- Kusakci, A.O., Can, M., 2013. Avaliação de desempenho de algoritmos inspirados na natureza em otimização restrita. *Sudeste Eur. J. Soft Comput.* <https://doi.org/10.21533/scjournal.v2i1.50>.
- Lahmiri, S., Boukadoum, M., 2014. Denoização de imagem biomédica usando decomposição do modo variacional. In: IEEE 2014 Biomedical Circuits and Systems Conference, BioCAS 2014 - Proceedings. <https://doi.org/10.1109/BioCAS.2014.6981732>.
- Liang, Z., Liang, J., Wang, C., Dong, X., Miao, X., 2016. A energia eólica de curto prazo combinou a previsão com base na correção da previsão de erro. *Convers de energia. O Manag.* <https://doi.org/10.1016/j.enconman.2016.04.036>.
- Li, C., Lin, S., Xu, F., Liu, D., Liu, J., 2018a. Short-term wind power forecast based on data mining technology and improved support vector machine method: a case study in Northwest China. *J. Clean. Prod.* <https://doi.org/10.1016/j.jclepro.2018.09.143>.
- Li, H., Wang, J., Lu, H., Guo, Z., 2018b. Pesquisa e aplicação de um modelo combinado baseado no peso variável para previsão de velocidade do vento de curto prazo. *Renovar. Energia*. <https://doi.org/10.1016/j.renene.2017.09.089>.
- Lin, Y., Luo, H., Wang, D., Guo, H., Zhu, K., 2017. Um modelo de conjunto baseado em métodos de aprendizagem de máquina e pré-processamento de dados para previsão de carga elétrica de curto prazo. *Energias*. <https://doi.org/10.3390/en10081186>.
- Ma, L., Luan, S., Jiang, C., Liu, H., Zhang, Y., 2009. Uma revisão sobre a previsão da velocidade do vento e energia gerada. *Renovar. Sustentar.* <https://doi.org/10.1016/j.rser.2008.02.002>.
- Ma, X., Wang, Y., Wang, C., 2017a. Desenvolvimento de baixo carbono da indústria de energia térmica da China com base em uma comparação internacional: revisão, análise e previsão. *Renovar. Sustentar.* <https://doi.org/10.1016/j.rser.2017.05.102>.
- Ma, X., Jin, Y., Dong, Q., 2017b. Uma rede neural difusa dinâmica generalizada baseada na análise de espectro singular otimizada pela otimização da tempestade cerebral para previsão de velocidade do vento de curto prazo. *Appl. Soft Comput. J.* <https://doi.org/10.1016/j.asoc.2017.01.033>.
- Ma, X., Liu, Z., Wang, Y., 2019a. Aplicação de um novo modelo bernoulli cinza multivariado não linear para prever a renda turística da China. *J. Comput. Appl. Math.* <https://doi.org/10.1016/j.cam.2018.07.044>.
- Ma, X., Xie, M., Wu, W., Zeng, B., Wang, Y., Wu, X., 2019b. O novo modelo de sistema cinza multivariado fracionado e suas aplicações. *Appl. Math. Modelo.* <https://doi.org/10.1016/j.apm.2019.01.039>.
- Meng, A., Ge, J., Yin, H., Chen, S., 2016. Previsão de velocidade do vento com base na decomposição do pacote de ondas e redes neurais artificiais treinadas pelo algoritmo de otimização do cruzamento. *Convers de energia. O Manag.* <https://doi.org/10.1016/j.enconman.2016.02.013>.
- Mirjalili, S., Saremi, S., Mirjalili, S.M., Coelho, L.D.S., 2016. Otimizador multi-objetivo de lobo cinzento: um novo algoritmo para otimização de critério multi. *Especialista Syst. Appl.* <https://doi.org/10.1016/j.eswa.2015.10.039>.
- Mirjalili, S., Gandomi, A.H., Mirjalili, S.Z., Saremi, S., Faris, H., Mirjalili, S.M., 2017. Algoritmo Salp Swarm: um otimizador bioinspirado para problemas de design de engenharia. *Software Adv. Eng.* <https://doi.org/10.1016/j.advengsoft.2017.07.002>.
- Mogham, I., Rahman, S., 1989. Análise e avaliação de técnicas de previsão de carga de curto prazo. *IEEE Trans. Power Syst.* <https://doi.org/10.1109/59.41700>.
- Nielsen, H.A., Madsen, H., Nielsen, T.S., 2006. Usando a regressão quantil para estender um sistema de previsão de energia eólica existente com previsões probabilísticas. In: *Energia Eólica*. <https://doi.org/10.1002/we.180>.
- Niu, T., Wang, J., Zhang, K., Du, P., 2018. Previsão de velocidade do vento de vários passos com base na seleção ideal de recursos e um algoritmo de morcego modificado com a estratégia de cognição. *Renovar. Energia*. <https://doi.org/10.1016/j.renene.2017.07.075>.
- Sfetsos, A., 2002. Uma nova abordagem para a previsão de séries temporais de velocidade do vento médias. *Renovar. Energia*. [https://doi.org/10.1016/S0960-1481\(01\)00193-8](https://doi.org/10.1016/S0960-1481(01)00193-8).
- Su, Z., Wang, J., Lu, H., Zhao, G., 2014. Um novo modelo híbrido otimizado por um algoritmo de otimização inteligente para previsão de velocidade do vento. *Convers de energia. O Manag.* <https://doi.org/10.1016/j.enconman.2014.05.058>.
- Sun, W., Liu, M., 2016. Previsão de velocidade do vento usando redes de estado eco FEEMD com RELM em Hebei, China. *Convers de energia. O Manag.* <https://doi.org/10.1016/j.enconman.2016.02.022>.
- Tian, C., Hao, Y., Hu, J., 2018. Um novo sistema de previsão de velocidade do vento baseado em pré-processamento de dados híbridos e otimização multiprofissione. *Energia*. <https://doi.org/10.1016/j.apenergy.2018.09.012>.
- Tian, C., Hao, Y., 2018. Um novo sistema de previsão combinada não linear para previsão de carga de curto prazo. *Energias*. <https://doi.org/10.3390/en11040712>.

- Torres, J.L., García, A., De Blas, M., De Francisco, A., 2005. Previsão de velocidade média do vento por hora com modelos ARMA em Navarra (Espanha). *Sol. Energia*. <https://doi.org/10.1016/j.solener.2004.09.013>.
- Wang, J., Shahidehpour, M., Li, Z., 2008. Compromisso de unidade com geração volátil de energia eólica. *IEEE Trans. Power Syst.* <https://doi.org/10.1109/TPWRS.2008.926719>.
- Wang, H.Z., Wang, G.B., Li, G.Q., Peng, J.C., Liu, Y.T., 2016. Rede de crenças profundas baseada em abordagem determinística e probabilística de previsão de velocidade do vento. *Energia*. <https://doi.org/10.1016/j.apenergy.2016.08.108>.
- Wang, J., Du, P., Niu, T., Yang, W., 2017. Um novo sistema híbrido baseado em um novo algoritmo proposto algoritmodmulti-Objective Whale Optimization Algorithm para previsão de velocidade do vento. <https://doi.org/10.1016/j.apenergy.2017.10.031>.
- Wang, J., Niu, T., Lu, H., Guo, Z., Yang, W., Du, P., 2018a. Um sistema de previsão de análise para modelagem de incerteza de velocidade wind: um estudo de caso de parques eólicos de grande escala. <https://doi.org/10.1016/j.apenergy.2017.11.071>.
- Wang, J., Yang, W., Du, P., Niu, T., 2018b. Um novo sistema de previsão híbrida de velocidade do vento baseado em um recém-desenvolvido algoritmo multi-objetivo de cosseno. *Convers de energia. O Manag.* <https://doi.org/10.1016/j.enconman.2018.02.012>.
- Wang, J., Yang, W., Du, P., Li, Y., 2018c. Pesquisa e aplicação de uma estrutura de previsão híbrida baseada na otimização multiprofissionais para system de energia elétrica. *Energia*. <https://doi.org/10.1016/j.energy.2018.01.112>.
- Wang, J., Du, P., Lu, H., Yang, W., Niu, T., 2018d. Um modelo cinza aprimorado otimizado pelo algoritmo de otimização multi-objetivo do leão de formigas para a previsão anual de consumo de eletricidade. <https://doi.org/10.1016/j.asoc.2018.07.022>.
- Wang, Z.X., Li, Q., 2019. Modelando a relação não linear entre as emissões de CO2 e o crescimento econômico usando um modelo Verhulst cinza baseado em algoritmo PSO. *Limpe. prod.* <https://doi.org/10.1016/j.jclepro.2018.10.010>.
- Wolpert, D.H., Macready, W.G., 1997. Sem teoremas de almoço gratuitos para otimização. *IEEE Trans. Evol. Computação*. <https://doi.org/10.1109/4235.585893>.
- Xiao, L., Shao, W., Wang, C., Zhang, K., Lu, H., 2016a. Pesquisa e aplicação de um modelo híbrido baseado na otimização multiprofissional para previsão de carga elétrica. *Energia*. <https://doi.org/10.1016/j.apenergy.2016.07.113>.
- Xiao, L., Shao, W., Liang, T., Wang, C., 2016b. Um modelo combinado baseado em múltiplos padrões sazonais e algoritmo de firefly modificado para previsão de load elétrico. <https://doi.org/10.1016/j.apenergy.2016.01.050>.
- Xiao, L., Shao, W., Yu, M., Ma, J., Jin, C., 2017. Pesquisa e aplicação de um modelo de rede neural de wavelet híbrido com o algoritmo de busca de cuco melhorado para previsão do sistema de energia elétrica. *Energia*. <https://doi.org/10.1016/j.apenergy.2017.04.039>.
- Xu, Y., Yang, W., Wang, J., 2017. Sistema de alerta antecipado de qualidade do ar para cidades da China. *Atmos. Environ.* <https://doi.org/10.1016/j.atmosenv.2016.10.046>.
- Xue, Y.J., Cao, J.X., Wang, D.X., Du, H.K., Yao, Y., 2016. Application da variação dedendo decomposição para análise sísmica de frequência de tempo. *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.* <https://doi.org/10.1109/JSTARS.2016.2529702>.
- Yang, W., Wang, J., Wang, R., 2017. Pesquisa e aplicação de um novo modelo híbrido baseado na seleção de dados e algoritmo de inteligência artificial para previsão de carga de curto prazo. *Entropia*. <https://doi.org/10.3390/e19020052>.
- Yang, W., Wang, J., Niu, T., Du, P., 2019. Um sistema de previsão híbrida baseado em uma estratégia de dupla decomposição e otimização multi-objetiva para previsão de preços de eletricidade. <https://doi.org/10.1016/j.apenergy.2018.11.034>.
- Zendehboudi, A., Baseer, M.A., Saidur, R., 2018. Aplicação de modelos de máquina vetorial de suporte para previsão de recursos de energia solar e eólica: uma revisão. *Limpe. Prod.* <https://doi.org/10.1016/j.jclepro.2018.07.164>.
- Zhang, R., Lan, Y., Huang, G. Bin, Xu, Z. Ben, 2012. Aproximação universal da máquina de aprendizagem extrema com crescimento adaptativo de núdulos ocultos. *IEEE Trans. Redes Neurais Aprendem. Syst.* <https://doi.org/10.1109/TNNLS.2011.2178124>.
- Zhang, W., Qu, Z., Zhang, K., Mao, W., Ma, Y., Fan, X., 2017. Um modelo combinado baseado no CEEMDAN e algoritmo de polinização de flower modificado para previsão de velocidade do vento. *Convers de energia. O Manag.* <https://doi.org/10.1016/j.enconman.2017.01.022>.
- Zhao, Y., Ye, L., Li, Z., Song, X., Lang, Y., Su, J., 2016a. Um novo mecanismo bidirecional baseado no modelo de série temporal para previsão de energia eólica. *Energia*. <https://doi.org/10.1016/j.apenergy.2016.03.096>.
- Zhao, J., Guo, Z.H., Su, Z.Y., Zhao, Z.Y., Xiao, X., Liu, F., 2016b. Um modelo de previsão de várias etapas melhorado baseado em conjuntos WRF e sistemas criativos de fuzzy para a velocidade do vento. <https://doi.org/10.1016/j.apenergy.2015.10.145>.