

REVEJA

 Comunicado por Xingjian Shi

Aplicações de Redes Neurais Recorrentes em Meio Ambiente Previsão de fatores: uma revisão

Yingyi Chen

chenyingyi@cau.edu.cn

Qianqian Cheng

2367753738@qq.com

YanJun Cheng

chengyanjun172@163.com

Hao Yang

804727068@qq.com

Huihui Yu

774754053@qq.com

Faculdade de Informação e Engenharia Elétrica, Universidade Agrícola da China, Pequim 10083, China; Laboratório Chave de Aquisição de Informação Agrícola Tecnologia, Ministério da Agricultura Pequim 100125, China; e Pequim Engenharia e Centro de Pesquisa Tecnológica para Internet das Coisas na Agricultura, Pequim 100083, China

Análise e previsão de dados sequenciais, problemas-chave em vários domínios da engenharia e da ciência, têm atraído a atenção de muitos pesquisadores de diversas comunidades. Ao prever o futuro probabilidade de eventos usando séries temporais, redes neurais recorrentes (RNNs) são uma ferramenta eficaz que tem a capacidade de aprendizado de redes neurais feedforward e expande sua capacidade de expressão usando dinâmicas equações. Além disso, RNNs são capazes de modelar diversas estruturas. Os pesquisadores desenvolveram várias RNNs com diferentes arquiteturas e topologias. Resumir o trabalho das RNNs na previsão e fornecer diretrizes para modelagem e novas aplicações no futuro estudos, esta revisão se concentra em aplicações de RNNs para previsão de séries temporais na previsão de fatores ambientais. Apresentamos a estrutura, fluxo de processamento e vantagens das RNNs e analisamos as aplicações de várias RNNs na previsão de séries temporais. Além disso, discutimos limitações e desafios de aplicações baseadas em RNNs e pesquisas futuras instruções. Finalmente, resumimos as aplicações de RNNs na previsão.

1. Introdução

Junto com o rápido desenvolvimento da tecnologia da informação, uma variedade de sistemas de informação são amplamente utilizados no dia a dia das pessoas. Esses sistemas produzir grandes quantidades de dados de séries temporais ruidosas, que são instáveis e

flutuar (Singh, Basant, Malik e Jain, 2009). Além disso, a relação entre variáveis nesses dados é complexo e não linear. O uso eficiente desses dados de séries temporais para extrair informações úteis é um tópico importante em dados em processamento. Até onde sabemos, a previsão de séries temporais desempenha um papel crítico em muitas aplicações científicas e de engenharia (Zhang, 2003). Geralmente, uma melhor previsão é o fator chave para fornecer uma melhor decisão fazer e monitorar a gestão. Além disso, a previsão de séries temporais tem atraído a atenção de pesquisadores de diversas áreas. Recentemente, a literatura sobre pesquisa de previsão tem focado no desenvolvimento de tecnologia da informação e inteligência artificial (Sadaei, Guimarães, Silva, Lee, & Eslami, 2017). Portanto, uma variedade de modelos e metodologias foram fornecidos para previsão de dados sequenciais (Raza & Khosravi, 2015; Tas cikaraoglu & Uzunoglu, 2014).

As metodologias para previsão de séries temporais dependem quase inteiramente de duas diferentes métodos: métodos tradicionais e algoritmos de inteligência artificial (Bontempi, Taieb, & Borgne, 2013). Modelos tradicionais, como múltiplos fontes de regressão linear (Mahmoud, 2008) e métodos de expansão de Fourier (Sanz-Serna, 2009), são simples e fáceis de realizar. A maioria desses métodos são baseadas em teorias matemáticas. No entanto, esses métodos têm pouca adaptabilidade e desempenho imprevisível com o aumento da complexidade do modelo. Nas últimas décadas, algoritmos de inteligência artificial, incluindo redes neurais artificiais (RNAs; Zhang, Patuwo, & Hu, 1998), máquinas (SVM; Tay & Cao, 2007) e redes neurais recorrentes (RNNs; Garcia-Pedrero & Gomez-Gil, 2010), chamaram a atenção e foram usado com sucesso para previsão de séries temporais. Embora esses modelos tenham boa capacidade de aprendizagem e reconhecer a complexidade e não linearidade na padrões de conjuntos de dados, eles têm algumas deficiências. A RNA pode facilmente cair em uma solução ótima local e tem um processo de aprendizagem complexo. O SVM requer um grande espaço de armazenamento e maior tempo de treinamento ao manusear grandes quantidades de dados. Esses métodos ainda precisam ser aprimorados para alcançar melhor precisão de previsão. Felizmente, as RNNs provaram ser adequadas para previsão de séries temporais devido à sua capacidade de capturar relações de dados de sequência no tempo, em contraste com redes neurais feedforward (FFNNs; Bebis & Georgiopoulos, 2009). A RNN (Mandic & Chambers, 2001) também é uma classe de RNA em que as conexões entre as unidades formam um ciclo direcionado. Esse ciclo estabelece um estado interno da rede que permite mostrar um comportamento temporal dinâmico. Devido aos avanços em sua arquitetura e treinamento métodos, várias RNNs com diferentes arquiteturas e topologias têm amplamente e com sucesso aplicado para previsão de séries temporais em vários domínios, como energia elétrica, fatores ambientais, finanças e economia (Motlagh & Khaloozadeh, 2016; Alzahrani, Shamsi, Dagli, & Fer dowsi, 2017; Zheng, Yuan, & Chen, 2017).

As RNNs são consideradas uma categoria extremamente promissora de métodos para previsão de séries temporais e podem ser usadas para compensar as deficiências dos modelos tradicionais de previsão. RNNs foram

desenvolvido a partir da rede Hopfield em 1982 (Hopfield, 1982). RNNs iniciais eram sistemas dinâmicos poderosos que eram capazes de corrigir erros por meio de retropropagação e uso de um algoritmo de gradiente. No entanto, as RNNs foram difíceis de treinar e sofria com o gradiente de fuga ou explosão problema (Le & Zuidema, 2016), que não pode resolver o problema da dependência de longo prazo. Portanto, este método não foi amplamente utilizado até a década de 1990. Para resolver este problema, um grande avanço foi feito através da introdução de uma arquitetura baseada em LSTM amplamente aprimorada que usava um mecanismo de portão para evitar que erros retropropagados desapareçam ou explodam para lembrar entradas por um longo período de tempo. As redes LSTM (Gers, Schmidhuber, & Cummins, 2000) foram posteriormente comprovadas como mais eficazes e precisos do que RNNs convencionais e ajudaram a levar ao renascimento em IA.

Como um dos tipos mais promissores de modelos de previsão de séries temporais, As RNNs têm sido amplamente estudadas na teoria e aplicadas em muitos campos. Lá é uma extensa base de literatura sobre diferentes aplicações de RNNs em previsão de séries temporais, incluindo previsão de energia elétrica, previsão de fatores ambientais e previsão de finanças e economia. No entanto, um resumo único de aplicações em RNNs na previsão de séries temporais não foi publicado. Além disso, muitos campos novos precisam ser explorados para aplicações de RNNs, e mais pesquisas são necessárias para melhorar o desempenho de modelos baseados em RNNs em sistemas dinâmicos de tempo real; esses são problemas importantes e desafiadores. Nos últimos anos, com o surgimento de big data e aprendizado profundo, a previsão de sistemas em larga escala tornou-se viável devido aos dados abundantes e representações hierárquicas em arquiteturas profundas. Portanto, novos modelos de aprendizado profundo baseados em RNNs estão se tornando cada vez mais populares.

Esta revisão resume as aplicações de RNNs na previsão, principalmente considerando a previsão de fatores ambientais. A estrutura, processamento fluxo, e as vantagens de RNNs são introduzidas. Além disso, as limitações e os desafios do estado atual das RNNs são discutidos. Simultaneamente, futuras direções de pesquisa de RNNs e novas áreas são discutidas. Acreditamos que esta revisão pode ser usada como um guia para pesquisadores sobre as aplicações de RNNs na previsão de dados. A revisão está estruturada da seguinte forma. A Seção 2 explica a estrutura, o fluxo de processamento e as vantagens das RNNs em detalhe. Na seção 3, aplicativos para previsão de séries temporais com base em RNNs são resumidos e avaliados, incluindo limitações e desafios. a direção de pesquisa é explorada na seção 4, e a seção 5 resume os principais conclusões.

2 Redes Neurais Recorrentes

Esta seção se concentra na teoria das RNNs e apresenta sua estrutura, fluxo de processamento e vantagens.

2.1 Estrutura das RNNs. A RNN é uma classe de RNA que permite que os nós para ser conectado a loops direcionados; o RNN pode ser facilmente confundido com o rede neural recursiva (Pollack, 1990). A formulação do RNN garante que ele possa apresentar um comportamento temporal dinâmico. O RNN pode gerar estados de memória de dados passados, processar dados sequenciais e estabelecer dependências entre dados de tempos diferentes. Enquanto FFNNs só podem ser usados para estabelecer relações de mapeamento entre dados, eles não podem ser usados para analisar a dependência temporal de sinais passados. Em teoria, RNNs podem lidar com sequências de entrada arbitrárias, e o compartilhamento de peso é adotado de maneira recursiva. As RNNs não apenas podem aprender dependências temporais de longo alcance, mas também podem também simulam eficientemente uma máquina de Turing universal, que pode realizar quase qualquer computação. Em geral, as RNNs fornecem aprendizado de máquina flexível ferramentas que possuem a capacidade de aprendizado das FFNNs e podem expandir sua capacidade de expressão dependendo das equações dinâmicas. Assim, as RNNs podem ser usadas para tarefas como processamento de imagem, reconhecimento de fala ou previsão de séries temporais (Lee, Tseng, Wen, & Tsao, 2017; Sak, Senior, & Beaufays, 2014; Verdejo, Herreros, Luna, Ortuzar, & Ayuso, 1991).

As RNNs foram introduzidas na década de 1980 (Rumelhart, Hinton, & Williams, 1988), e seu uso inclui redes Hopfield, redes Elman e Redes da Jordânia (Chen, 2001; Cao, 2001; Kalinli & Sagioglu, 2006; Turk, Barisci, Ciftci e Ekmekci, 2015). As redes Hopfield foram desenvolvidas por John Hopfield (1982), e todas as conexões em RNNs são simétricas. Além disso, o RNN pode abordar dependências temporais. Posteriormente, em 1990, a rede de Elman foi proposta pela primeira vez (Elman, 1990) para processamento de linguagem, que apresenta vantagens incomparáveis para lidar com entrada inercial e dados de saída. Portanto, a rede Elman tem sido universalmente utilizada para modelagem de sistema, previsão de séries temporais e controle adaptativo. Jordânia redes e redes Elman têm semelhanças (Song, 2011). Seu contexto unidades são alimentadas a partir da camada de saída em vez da camada oculta, o contexto unidades nas redes Jordan aparecem como camadas de estado, e sua saída pode ser passado diretamente para o nó oculto. Essas redes também são chamadas de redes simples redes recorrentes (SRNs; Cruse, 1996). A rede neural autoregressiva não linear com entrada exógena (NARX; Chen, Billings, & Grant, 1990) é um modelo de previsão dinâmico maduro que usa uma arquitetura neural recorrente. O NARX tem arquiteturas de feedback limitadas que vêm apenas de neurônios de saída em vez de neurônios ocultos. Foi verificado que este tipo de arquitetura de aprendizagem com estados ocultos pode produzir resulta no modelo NARX do que em outras arquiteturas recorrentes. Recentemente anos, esses modelos levaram a grandes conquistas no processamento de linguagem natural e rotulagem de sequências (Collobert, Weston, Karlen, Kavukcuoglu, & Kuka, 2011; Mikolov, Karafiát, Burget, Cernocký, & Khudanpur, 2010; Yao, Zweig e Hwang, 2013).

Além dos modelos acima, também existem variantes RNN (Dinarelli & Tellier, 2016), como a rede neural recorrente bidirecional (BRNN; Schuster & Paliwal, 1997). O estado dos SRNs no momento t é apenas

está relacionado ao estado do passado, enquanto o estado das RNNs no momento *está* relacionado não apenas ao estado do passado, mas também ao estado do futuro. A rede de memória de longo prazo (LSTM) é uma variante RNN aprimorada que Hochreiter e Schmidhuber (1997) propuseram. O LSTM é caracterizado por sua unidade básica, que possui uma célula de memória que pode armazenar um estado de tempo e é protegido durante o armazenamento, gravação e leitura de informações. O LSTM também é um sistema de aprendizado profundo que evita eficientemente o gradiente de fuga ou problema de explosão (Gers & Schraudolph, 2003). Com o rápido desenvolvimento do aprendizado profundo, a rede LSTM tem desempenhado um papel cada vez mais importante devido à convergência do processo de aprendizagem (Fernández, Graves, & Schmidhuber, 2007). Assim, gradualmente substituiu o RN clássico.

A estrutura da rede neural recorrente está intimamente relacionada ao desempenho da rede (Awano et al., 2011). Por um lado, a dinâmica interna das RNNs de grande escala é complicada e confusa. No entanto, a dinâmica interna aumentará muito o armazenamento da rede e custo de cálculo do algoritmo de treinamento. Por outro lado, a dinâmica características de RNNs de pequena escala são relativamente singulares. A informação contida em problemas complexos não contém uma capacidade de aprendizado e não pode atender aos requisitos das RNNs para processamento de informações. O desempenho das RNNs é determinado por sua estrutura e algoritmo de treinamento. Portanto, a atividade e o número de neurônios ocultos em RNNs são ajustados de acordo com o objeto de estudo, que altera sua topologia. Melhorando o desempenho de RNNs tornou-se um tema quente de pesquisas recentes (Gil, Cardoso, & Palma, 2009).

2.2 Fluxo de Processamento de RNNs. Uma simples adaptação no padrão FFNNs permite que RNNs simulem dados contínuos. Uma rede neural multicamada só pode mapear vetores de entrada e vetores de saída (Riedmiller, 1994), mas As RNNs podem, teoricamente, mapear um conjunto de dados históricos inteiro. Em cada momento, um nó pode aceitar uma entrada, atualizar o estado da camada oculta e prever um resultado, como mostrado na Figura 1.

A propagação direta de RNNs é semelhante ao modelo perceptron que tem apenas uma camada oculta. A diferença é que a camada oculta em a RNN não apenas recebe uma entrada externa, mas também aceita a valor calculado a partir da função de ativação no último momento. A saída vetor da rede neural multicamada é dado pela função de ativação da camada de saída. O valor de entrada de cada unidade da camada de saída é a saída valor de todas as camadas ocultas conectadas à unidade. O número de camada de saída unidades e a seleção da função de ativação dependem principalmente da aplicação cenários de redes neurais. Deve-se enfatizar que as tangentes sigmóides, hiperbólicas e a ReLU são amplamente utilizadas como funções de ativação em RNNs. Em seguida, é necessário considerar como selecionar o modelo apropriado parâmetros. Em geral, as RNNs são treinadas com um método comum baseado em gradiente.




Figura 1: Rede neural recorrente simples.




Figura 2: O RNN se desdobra ao longo do tempo para o cálculo.

algoritmo, como aprendizado recorrente em tempo real (RTRL) ou retropropagação através do tempo (BPTT), para derivar os parâmetros RNN.

O RNN é mostrado na Figura 2 para se desdobrar ao longo do tempo. A RNN pode ser considerada uma rede neural de feedforward profundo com os mesmos pesos entre todas as suas camadas (LeCun, Bengio, & Hinton, 2015). RNNs incluem unidades de entrada, unidades de saída e unidades ocultas, cujas sequências vetoriais são marcadas como (x_1, \dots, x_T) , (o_1, \dots, o_T) e (s_1, \dots, s_T) , respectivamente. Os estados de saída e oculto podem ser expressos pelas seguintes equações:

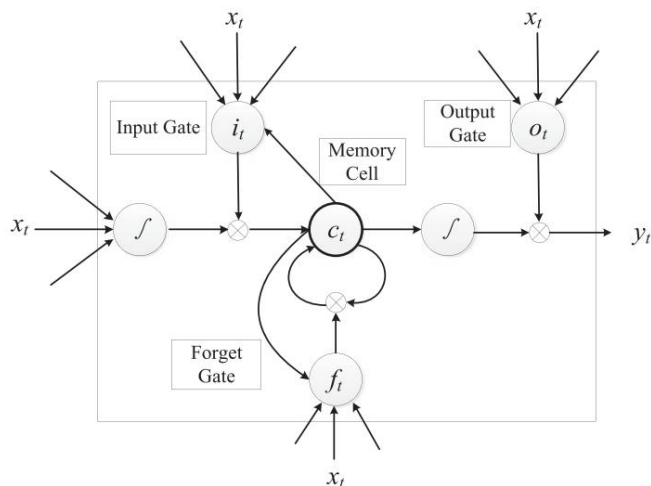


Figura 3: Estrutura da célula LSTM.

$$st = f(wsxt + wssst\ddot{y}1 + bs), \quad (2.1)$$

$$ot = wost + bo. \quad (2.2)$$

Nestas equações, w_{sx} é o vetor de peso de entrada para oculto, w_{ss} é o vetor de peso oculto para oculto, w_{os} é o vetor de peso de saída para oculto, b_o e b_s são os desvios e u , v e w são os parâmetros da rede. os mesmos parâmetros são usados em cada passo de tempo, e f é uma função de ativação como peixinho.

As RNNs podem processar facilmente dados de sequência. No entanto, as RNNs tradicionais sofrem com o desaparecimento ou a exploração de gradientes quando o número de passos de tempo é grande, e eles não conseguem capturar a evolução de longo prazo. LSTMs efetivamente resolvem esses problemas introduzindo um mecanismo de portão para evitar erros retropropagados de desaparecer ou explodir e foram posteriormente mostrados serem mais eficazes do que RNNs tradicionais. A Figura 3 representa a estrutura de uma célula LSTM que é configurada principalmente por três portas e uma célula de memória. O fluxo de dados no bloco é controlado pela porta de entrada, e a decisão de quando redefinir o estado da célula de memória é feita pelo portão do esquecimento. Além disso, o fluxo de dados de saída do bloco é controlado pela porta de saída. A última célula de memória é usada para armazenar o estado de todo o bloco. Todo o cálculo pode ser expresso como uma série de equações do seguinte modo:

$$it = \ddot{y} (wixxt + wihht \ddot{y} 1 + wicct \ddot{y} 1 + bi), \quad (2.3)$$

$$ft = \ddot{y} (wf_{xxt} + wf_{hht}\ddot{y}_1 + wf_{cct}\ddot{y}_1 + b f), \quad (2.4)$$

$$ot = \tilde{y} (wo_{xt} + woh_{ht} \tilde{y} + wo_{ct} \tilde{y} + bo), \quad (2.5)$$

$$ct = fct \tilde{y} + it \tanh(wc_{xt} + wch_{ht} \tilde{y} + bo), \quad (2.6)$$

$$ht = ottanh(ct), \quad (2.7)$$

onde it , ft e ot são os métodos de cálculo da porta de entrada, esqueça a porta e porta de saída, respectivamente, no tempo t : ct é o método de cálculo do célula de memória no tempo t . ht é toda a saída da célula LSTM no tempo t ; \tilde{y} e \tanh são as funções de ativação da tangente sigmóide e hiperbólica, respectivamente; w são as matrizes de peso; e b são os vetores de polarização. O LSTM unidades de memória capturam facilmente os complexos recursos de correlação dentro do tempo séries tanto a curto como a longo prazo, uma melhoria significativa em relação às RNNs tradicionais através da função das diferentes portas.

2.3 Vantagens das Redes Neurais Recorrentes. As RNNs fornecem ferramentas flexíveis de aprendizado de máquina que não apenas possuem as habilidades de aprendizado de FFNNs, mas também expandem suas habilidades de expressão com base em equações dinâmicas. Portanto, RNNs podem lidar diretamente com dados espaço-temporais complexos e construir sistemas dinâmicos complicados. Devido a dados temporais e espaciais sendo usado em muitos campos, como modelagem de energia elétrica, finanças e economia e séries temporais do ambiente de processamento, as RNNs são promissoras candidatos para uma variedade de aplicações (Wu, Wang, Jiang, Ye e Xue, 2015; Giles, Kuhn e Williams, 1994). Além disso, as RNNs passaram por melhorias significativas de desempenho na previsão de séries temporais.

As redes neurais tradicionais aplicadas na previsão de séries temporais afundam facilmente em um ótimo local e têm um processo de aprendizagem complexo, resultando em um velocidade de computação relativamente lenta. RNNs são ferramentas que podem obter alta precisão e bom desempenho ao processar previsões de séries temporais baseado em um grande número de conjuntos de dados. A característica mais fundamental das RNNs é sua memória de curto prazo. O entendimento de curto prazo a memória afeta diretamente o projeto da estrutura RNN e indiretamente influencia os pesos dos métodos de treinamento. RNNs exigem mais virtual conexões e muito mais memória para simulações do que o convencional BPNN. RNNs alcançam um melhor efeito devido à repetição grosseira de padrões presentes em dados de sequência. Essas séries temporais regulares, mas sutis, são importante fazer previsões úteis.

As RNNs são conhecidas por serem redes locais de realimentação, nas quais apenas conexões locais estão ativas. A capacidade de generalização da rede é notavelmente aprimorado por não aprender arquiteturas recorrentes complexas e totalmente conectadas. Além disso, as conexões redundantes são eliminadas (Tsoi, 1998). Isso é Também é importante que diferentes configurações de RNNs escolham parâmetros de aprendizado apropriados, um número apropriado de nós ocultos e funções de ativação apropriadas. Comparado com o multicamada tradicional perceptron, RNNs têm uma conexão de feedback e armazenamento de memória. Elas também pode processar dados de sequência em cada passo de tempo enquanto aceita a entrada,

atualizando o estado oculto e prevendo o próximo valor. Embora RNNs têm a capacidade computacional para processar dados sequenciais, aprender dependências temporais de longo alcance é difícil quando um gradiente estocástico decrescente é usado para treinamento. Para resolver este problema, os LSTMs foram propostos para introduzir unidades de memória para decidir se deve esquecer e atualizar estados. Como resultado, os LSTMs provaram ser mais eficazes do que os RNNs tradicionais (Gers & Schmidhuber, 2001).


As RNNs podem refletir direta e vividamente as características dinâmicas do sistema, bem como representar a direção da modelagem e identificar redes. Eles também contêm informações de feedback no estado interno de as redes. O comportamento dinâmico não linear do sistema é descrito usando o feedback interno da rede. Portanto, o desempenho de previsão de As RNNs são melhores do que as redes feedforward ao lidar com o tempo dados da série. Teoricamente, RNNs podem lidar com qualquer comprimento de dados de sequência (Boden, 2002). Na prática, no entanto, para reduzir a complexidade computacional, assume-se que o estado recorrente está relacionado apenas aos estados anteriores. Semelhante à propagação direta padrão, o BPTT contém importantes regras da cadeia. A diferença das RNNs é que a ativação da camada oculta depende da função de perda e afeta a camada de saída e a camada oculta no momento seguinte. Em resumo, as RNNs têm forte poder de computação e são os modelos de rede neural mais utilizados.

3 Previsão de Fatores Ambientais


O ambiente engloba muitos aspectos, como a atmosfera, a água, o solo e o clima. De acordo com a situação atual e a tendência de desenvolvimento, a qualidade do meio ambiente é prevista cientificamente, o que contribui para a saúde humana e para a produção e vida normais. Como assunto importante, os modelos de previsão ambiental têm recebido cada vez mais atenção por parte dos tomadores de decisão de planejamento ambiental. Nós principalmente introduzir a previsão de fatores ambientais com base em RNNs nesta seção. Dentro Além disso, a Tabela 1 mostra a aplicação de RNNs no fator ambiental previsão e descreve os objetos de previsão, fonte de dados, métodos atuais e resultados.

3.1 Previsão do Fator de Água. Previsão precisa de água, incluindo previsões de nível de água, previsões de escoamento e previsão de inundações são necessárias e desempenham um papel importante na regulação e proteção da qualidade da água. Até o momento, as RNAs, especialmente as RNNs, têm atraído atenção e têm sido aceitos como ferramentas poderosas para a previsão do fator água. Muitos os pesquisadores fizeram grandes progressos na previsão do fator água.

A previsão precisa do escoamento, incluindo rios e águas pluviais, é importante no planejamento e gestão dos recursos hídricos. Ao longo dos anos, considerável pesquisa tem sido realizada nesta área, e numerosos



Aplicações de RNNs na Previsão de Fatores Ambientais



modelos de previsão de escoamento baseados em RNNs têm sido propostos. Zhang (2011) desenvolveram um modelo baseado em RNNs com o algoritmo de treinamento de retropropagação de Levenberg-Marquardt para prever o escoamento de águas pluviais. Os resultados experimentais indicaram que o modelo melhorado foi bem sucedido para fazendo previsões de escoamento de águas pluviais nas quais o melhor número de neurônios e atrasos nas linhas de atraso foram 50 e 11, respectivamente. Saharia e Bhattacharjya (2012) apresentaram o modelo de previsão de escoamento baseado em rede neural recorrente com atraso de tempo distribuído (TRLNN), que teve as vantagens de uma rede neural dinâmica, integração de propriedades morfológicas e adaptação de uma abordagem de modelagem semidistribuída. O TRLNN foi usado em conjunto com informações geomorfológicas para alcançar melhores resultados de previsão, e o TRLNN mostrou-se uma melhoria significativa em relação a todos os outros modelos nesta revisão. Duong, Nguyen, Bui, Nguyen e Snasel (2014) empregaram o RFNN, um híbrido de o RNN e a teoria fuzzy, para prever o escoamento de Srepok no Vietnã com mudanças no clima. O RFNN pode fazer previsões precisas em comparação a um modelo ambiental chamado SWAT no mesmo conjunto de dados porque o erro relativo do RFNN é baixo. Além disso, o RFNN não exige tantos dados quanto o SWAT. Posteriormente, o NARX-RNN foi sugerido para prever a taxa de fluxo de água (WFT); o NARX-RNN é baseado no parâmetros mais relevantes, irradiância solar e temperatura do ar. Os resultados indicou que o modelo apresentado tinha uma precisão aceitável para o dia seguinte previsão, que forneceu informações valiosas para o sistema de bombeamento de água fotovoltaica (Haddad, Mellit, Benghanem, & Daffallah, 2016). No mesmo ano, Shoaib, Shamseldin, Melville e Khan (2016) exploraram o potencial da rede neural recorrente com atraso de tempo acoplada a wavelet (TLRNN) modelos para prever com precisão o escoamento. Modelos TLRNN acoplados a wavelet com grandes profundidades provaram ser insensíveis à seleção da ondaleta função porque todas as funções wavelet têm desempenho semelhante, enquanto o A função wavelet db8 mostrou ter o melhor desempenho com o MLP estático.

A previsão de inundações é necessária e desempenha um papel vital no planejamento de inundações regulamentos e medidas de proteção. Deshmukh e Ghatol (2010) compararam as redes Jordan e Elman para modelagem de chuva-vazão. Elas coletou dados da área superior do rio Wardha na Índia e usou unidades de contexto para expandir o perceptron multicamada, um elemento de processamento que podem se lembrar de eventos passados. Descobrimos que o MSE e o NMSE para a rede da Jordânia foram 0,0187 e 0,0357, respectivamente, que foram menores do que os da rede neural de Elman, demonstrando que a rede de Jordan foi mais versátil e superou a rede neural de Elman. Roy, Choudhury e Saharia (2010) observaram um modelo de previsão de inundação usando uma rede neural recorrente com atraso de tempo (TLRN) com três memórias: TDNN, memória gama e Laguerre. Os resultados do desempenho do modelo indicaram que um TLRN com memória gama teve melhor aplicabilidade, seguido por um TDNN com memória Laguerre.

Posteriormente, Chang, Chen e Chang (2012) propuseram um algoritmo de aprendizado recorrente em tempo real (RTRL) para dois passos à frente (2SA) previsão usando RNNs para investigar dois conjuntos de dados de sequência de referência bem conhecidos e escoamento em eventos de inundação de Taiwan. Para comparação, o algoritmos RTRL originais - o RNN, ESN, BPNN e BPNNII - foram Também usado. Foi demonstrado que o novo ajuste de peso 2SA reforçado técnica teve excelente viabilidade e boa precisão para 2SA em tempo real previsão combinando informações preliminares de previsão com um processo de aprendizado on-line. O trabalho futuro se concentrará no desenvolvimento de novos modelo de previsão em bacias não calibradas. Chen, Chang e Chang (2013) incorporou as mensagens antecedentes mais próximas em um processo de aprendizado on-line, no qual os autores consideraram previsões multistep-ahead (MSA) para a pesquisa do fator água. Um algoritmo RTRL reforçado com MAS para RNNs (R-RTRLNN) foi proposto que ajustou adequadamente os parâmetros do modelo repetidamente de acordo com as informações atuais para melhorar a confiabilidade e precisão da previsão. Os resultados mostraram que o R-PTLNN apresentado teve boa praticabilidade e capacidade muito melhor do que os métodos comparativos para as previsões de cheias da MSA.

Nos últimos anos, ocorreram flutuações significativas do nível da água e pode estar relacionado com as alterações climáticas. Portanto, a previsão do nível da água é um método para garantir o uso sustentável da água. Guldal e Tongal (2010) discutiram e compararam o RNN, abordagem neurofuzzy, sistema de inferência fuzzy baseado em rede adaptativa (ANFIS) e modelos estocásticos clássicos, como como a média móvel autoregressiva (AR) e autoregressiva (ARMA) abordagens. Os resultados mostraram que o uso do RNN gerado e Os modelos ANFIS tiveram uma boa capacidade de aprender e prever mudanças no nível do lago. Posteriormente, Chang, Chen, Lu, Huang e Chen (2014) realizaram um estudo em termos de previsão de cheias usando RNNs reforçados. Eles usaram três modelos - o BPNN, a rede neural Elman e a rede NARX - construir modelos de previsão de nível de água de lagoas de armazenamento de água de inundação (FSP) em dois cenários como entradas do modelo. Um teste gama foi usado para obter fatores que influenciaram notavelmente o nível de água do FSP. O experimental resultados mostraram que a rede NARX teve uma aplicabilidade maior do que a rede BPNN e Elman. O método forneceu coeficientes efetivos dentro de 0,9 a 0,7 (cenário I) e 0,7 a 0,5 (cenário II) na fase de teste. Eles descobriram que os modelos NARX apresentados eram valiosos e benéficos para controle de enchentes urbanas. Concluímos com comentários sobre possíveis direções futuras de pesquisa neste campo.

3.2 Previsão do fator climático. A previsão do tempo tem atraído atenção considerável de várias equipes de pesquisa devido ao seu esforço para sustentar a vida humana global. O principal objetivo da previsão do tempo é prever a temperatura, chuva, vento e desastres climáticos especiais de uma área local. Essas previsões são importantes para muitos campos, incluindo navegação de voo, agricultura, turismo e transporte. Geralmente dependemos do clima

meteorologistas para orientar o planejamento de nossas rotinas diárias. Numerosos desenvolvimentos significativos na previsão do tempo foram propostos que tornam uso de técnicas de modelagem estatística e aprendizado de máquina com sucesso notável.

Para obter a previsão do tempo de 24 horas no sul de Saskatchewan, Maq sood, Khan, Huang e Abdallah (2005) desenvolveram um modelo baseado em uma rede de funções de base radial (RBFN). Comparado com o perceptron multicamadas (MLP), ERNN e modelo Hopfield (HFM), o RBFN foi mais rápido e confiável do que os outros métodos de previsão do tempo, exibiu boa aproximação e capacidade de aprendizado, e foi mais fácil de treinar para uma convergência mais rápida. É importante considerar outros fatores sazonais significativos, como chuvas e nevascas. Posteriormente, esses pesquisadores compararam o desempenho do MLP, ERNN e RBFN usando várias medidas estatísticas para prever o clima de Vancouver, Canadá. Os resultados empíricos demonstraram claramente que a RBFN foi muito mais rápida e mais confiável para previsão do tempo do que outros modelos de rede (Maqsood & Abraão, 2007). Na última década, juntamente com o desenvolvimento de dados e computação acelerada por GPU, o aprendizado profundo tem sido amplamente usado em muitos campos, como em reconhecimento de fala e visão computacional. Salman, Kanigoro, Heryadi e IEEE (2015) investigaram o aprendizado profundo para previsão do tempo. Particularmente, eles compararam o desempenho de previsão da RNN, máquina de Boltzmann restrita condicional (CRBM), e rede convolucional (CN). Os resultados experimentais mostraram que a RNN teve bom desempenho para previsão de chuvas. No futuro, outros profundos algoritmos de aprendizado serão usados para representar, classificar e prever problemas de tempo com precisão.

Recentemente, tem havido muito trabalho na previsão da qualidade do ar usando RNNs. Prakash, Kumar, Kumar e Jain (2011) empregaram um Modelo Elman para prever a poluição do ar. Os resultados do modelo sublinharam que o alta eficiência do RNN foi maior do que os dos modelos de rede usado em estudos anteriores. No mesmo ano, Wu, Feng, Du e Li (2011) descreveram uma rede neural Elman aprimorada com base em uma nova ativação função para prever os valores de pico de poluentes atmosféricos PM10 na área de Wuhan, China. O modelo de Elman melhorado forneceu valores RMSE baixos e Valores MAE comparados com o modelo de Elman. Em seguida, foi realizado um estudo desenvolver e comparar diferentes metodologias de inteligência computacional soft, como o FFNN, NARX, e uma inferência neurofuzzy adaptativa (ANFIS), para prever as emissões de CO2 na cidade de Nis. o conjuntos de dados incluíam temperatura do ar, direção do vento, frequência de tráfego, tempo do dia, estabilidade atmosférica e concentração de CO2. O estudo mostrou que os modelos apresentados ofereceram avaliações mais efetivas e precisas usando o conhecimento especializado disponível. Simultaneamente, a rede NARX teve o melhor desempenho em termos de avaliação porque considerou tanto estados anteriores quanto entradas, mas exigiu um método de treinamento mais avançado, e seu tempo computacional foi significativo. Além disso, computação

metodologias de inteligência podem ser usadas em outras aplicações interessantes em pesquisas futuras (Ciric, Cojbasic, Nikolic, Zivkovic, & Tomic, 2012).

Ong et al. (2014) introduziu uma rede neural recorrente profunda (DRNN) que foi treinado explorando um novo método de pré-treinamento do autoencoder (AE) chamado DynAE que foi desenvolvido especialmente para a concentração de PM_{2,5} previsões no Japão. A principal vantagem deste método era que a profundidade técnicas de aprendizagem em previsões temporais foram melhoradas. Os experimentos demonstraram que o método apresentado realizou previsões de concentração de PM_{2,5} com maior precisão em comparação com o FFNN, RNN, e DFNN. A pesquisa mais recente, de Oprea, Popescu e Mihalache (2016), apresentou um modelo de previsão do ar PM_{2.5} de curto prazo baseado no FFNN e RN. A precisão de cada modelo foi avaliada usando o RMSE, IA, R², e R. A maior contribuição deste trabalho foi verificar se a melhor rede neural possuía uma arquitetura feedforward. Em trabalhos futuros, o modelo preditivo PM_{2.5} pode ser colocado em uso prático, como no monitoramento PM_{2.5} estação.

Além da qualidade do ar, os estudos sobre secas, furacões e outras previsões de desastres naturais também aumentaram gradativamente, como a análise de a superfície da camada de ozônio com base no RNN (Biancofiore et al., 2015). Mohammadinezhad e Jalili (2013) desenvolveram um modelo de previsão usando redes de estado de eco que é uma classe de RNN baseada em dados de sensoriamento remoto para prever condições de seca. Eles usaram o produto Kronecker para reduzir o número de parâmetros a serem otimizados e forneceram três métodos de evolução: um algoritmo genético, recozimento simulado e evolução diferencial. O método baseado em diferentes tecnologias de otimização obteve uma acurácia média de 74,25%, que superou os demais métodos. Futuro O trabalho irá comparar o desempenho deste método com o de outras técnicas clássicas. Fang, Wang, Murphey, Weber e MacNeille (2014) estudaram os algoritmos MLP e ERNN para prever a umidade específica de três estações meteorológicas. Os resultados mostraram que o ERNN é uma alternativa promissora para esta previsão. No futuro, devemos nos concentrar em outros modelos de previsão de séries temporais de última geração.

A previsão precisa da ocorrência de furacões é importante e pode reduzir diretamente as perdas econômicas e salvar vidas humanas. Kordmahalleh, Se fidmazgi, Homaifar e ACM (2016) introduziram um RNN esparsos com uma topologia ágil para previsão de trajetória de furacões no Atlântico. A topologia da RNN foi otimizada através de um algoritmo genético customizado. A abordagem proposta teve um alto grau de correlação e precisão para 6 e 12 horas à frente da previsão de trajetória de quatro catastróficas furacões. No futuro, explorar a abordagem proposta para rastrear outros furacões do Atlântico e comparar os resultados com diferentes técnicas deve ser o foco principal. Em um estudo recente, Le, El-Askary, Allali e Struppa (2017) aplicou RNNs para previsão de seca na Califórnia. Os coeficientes de correlação variaram em aproximadamente 0,7, o que foi bastante semelhante aos atuais níveis de precipitação observados e valores de PZI para 2016 comparados

aos da temporada 1997-1998. O resultado deste estudo contribuiu para a previsão de que as condições de seca continuarão a persistir e mostrou que a precipitação associada à temporada 2015-2016 El Niño continuou para enfraquecer em comparação com a histórica temporada 1997-1998 El Niño.

3.3 Previsão de Fatores de Ambiente Artificial. O alcance do ambiente artificial aumentou gradativamente, juntamente com o desenvolvimento das economias sociais, como instalações de apoio, instalações de serviço público e tráfego. Esta seção discute principalmente a previsão de tráfego com base em RNNs, que tem sido vital e crítico para o controle de tráfego com o rápido aumento de veículos.

Muitos pesquisadores têm usado RNNs para previsão de tráfego, uma área que requer informações altamente precisas sobre gerenciamento de congestionamento de tráfego em sistemas de transporte inteligentes. Um novo atraso dinâmico recorrente O modelo de rede neural wavelet (WNN) foi discutido por Jiang e Adeli (2005) que incorporaram as propriedades auto-similares, singulares e fractais descobertas no fluxo de tráfego e alcançaram alta precisão de previsão. Sheu, Lan, e Huang (2009) apresentaram um novo algoritmo recorrente em tempo real (RTRL) treinar dinâmicas de tráfego não lineares medidas em diferentes aspectos. Assim, o objetivo de previsão precisa que é afetada por intervalos de tempo, defasagens de tempo, e períodos de tempo, podem ser alcançados.

An, Song e Zhao (2011) usaram um modelo para previsão de fluxo de tráfego baseado em redes neurais de estado de eco (ESNs). Os ESNs podem efetivamente evitar o problema problemático de usar a geração de estrutura de rede aleatória e o treinamento usando algoritmos de mínimos quadrados, bem como comparações com o FFNN.

Os resultados experimentais revelaram que o método ESN teve melhor desempenho de previsão, o que comprovou sua validade. Para prever velocidades de tráfego, Ma, Tao, Wang, Yu e Wang (2015) projetaram um esquema baseado no LSTM usando dados do sensor remoto de micro-ondas. O LSTM foi comparado com três tipologias de RNNs (o Elman NN, TDNN e NARX) e outros modelos estatísticos clássicos, como o SVM e um filtro de Kalman baseado no

mesmo conjunto de dados. Os experimentos demonstraram que o LSTM, um A abordagem de aprendizado de séries temporais com longa dependência de tempo e identificação automática das defasagens de tempo ideais superou os outros algoritmos em termos de precisão e estabilidade. Estudos futuros devem considerar inserir informações espaciais e temporais no LSTM e estudar desempenho de previsão com diferentes níveis de agregação de dados. Adicionando várias camadas para o LSTM para melhorar a capacidade de aprendizado de rede é um caminho potencial para melhorar o método. Um estudo semelhante foi realizado por Tian e Pan (2015). Eles usaram o modelo LSTM RNN para prever fluxos de tráfego de curto prazo, e o conjunto de dados foi coletado do Caltrans

Sistema de medição de desempenho. Quatro métodos clássicos de previsão foram selecionado para comparação: o passeio aleatório (RW), SVM, vetor feedforward máquina e autoencoder empilhado (SAE). Três aspectos desses modelos foram testados e comparados: precisão de previsão, capacidade de memória de

dados históricos e capacidade de generalização com diferentes intervalos de previsão. Os resultados experimentais mostraram que tanto o MAPE quanto o RMSE foram menor, com os diferentes intervalos de predição, o que provou que o LSTM foi capaz de capturar efetivamente a não linearidade e aleatoriedade do tráfego fluxo e alcançar uma boa precisão de previsão e generalização.

Outra pesquisa baseada no LSTM NN para previsão de tráfego inclui que por Chen, Lv, Li e Wang (2016), Fu, Zhang e Li (2016) e Zhao, Chen, Wu, Chen e Liu (2017). O trabalho futuro deve se concentrar em previsões de tráfego e outras técnicas de aprendizado de máquina devem ser usadas para melhorar o desempenho, ao inserir mídias sociais, informações meteorológicas, e outros fatores no modelo. Além disso, o LSTM também pode ser usado para prever matrizes dinâmicas de origem-destino (OD) em uma rede de metrô, o que também requer que fatores adicionais sejam inseridos nas matrizes OD de outros sistemas de transporte. Os resultados validaram que o modelo obteve melhor desempenho em comparação com as ferramentas tradicionais, como a metodologia do calendário e a autorregressão vetorial. Futuras investigações serão realizadas para reduzir o tempo computacional e alcançar melhor desempenho (Toque, Come, Mahrsi, & Oukhellou, 2016).

Existem RNNs que usam outros algoritmos de aprendizado profundo, como o rede neural convolucional (CNN), para previsão de séries temporais. Lai, Wei Cheng, Yiming e Hanxiao (2017) apresentaram uma nova estrutura de aprendizado profundo, a rede de séries temporais longas e curtas (LSTNet), que usou a CNN para extrair padrões de dependência de carga de curto prazo entre variáveis e o RNN para descobrir padrões e tendências de longo prazo. Os resultados experimentais mostraram que o LSTNet de fato alcançou desempenho significativo melhorias em relação aos de vários métodos de linha de base. Nesse período, uma abordagem baseada em imagens espaço-temporais foi adotada por Yu, Wu, Wang, Wang, e Ma (2017) para prever o tráfego de rede de transporte em larga escala, no qual a rede neural convolucional profunda (DCNN) foi usada para obter dependências espaciais em diferentes links e o LSTM foi apresentado para aprender as dependências temporais de longo prazo de cada link. Os autores compararam o novo modelo com o LSTM, DCNN, SAE e SVM usando o mesmo conjunto de dados. Os testes numéricos revelaram que o SRCN superou outros métodos no que diz respeito à precisão e estabilidade. No entanto, fatores adicionais, como clima, eventos sociais e controle de tráfego, devem ser considerados, bem como os métodos de pré-treinamento para melhorar o desempenho do modelo. Li, Yu, Shahabi e Yan (2017) projetaram experimentos para apresentar uma estrutura de aprendizado profundo para previsão de fluxo de tráfego, que incluiu dados espaciais e dependências temporais. Os métodos superaram significativamente as abordagens convencionais ao avaliar dois dados de tráfego do mundo real em grande escala conjuntos. No futuro, aplicando o método apresentado a outras tarefas de previsão serão estudadas.

Esta revisão apresenta principalmente aplicações atuais de RNNs no tempo previsão de séries. As RNNs estão sendo aplicadas em vários campos, como a previsão de fatores ambientais. Além disso, os métodos utilizados, incluindo a

RNNs clássicas, RNNs aprimoradas, modelos híbridos de RNNs e outros modelos, melhorar a precisão da previsão e obter bons efeitos de previsão. Numerosos estudos teóricos e implementações práticas foram realizados por pesquisadores de muitas áreas. No futuro, as RNNs podem ser estendidas a outros campos, como aplicações agrícolas, buscando uma melhor otimização algoritmos e usando tecnologia RNN mais avançada.

4 Limitações e Desafios

Em quase todos os campos científicos e industriais, como finanças, economia, hidrologia e telecomunicações e sistemas elétricos, a pesquisa no tempo a previsão de séries tem atraído atenção nos últimos anos (Nogales, Contreras, Conejo, & Espinola, 2002; Kim, 2003; Chen & Chen, 2015). Previsão eventos de séries temporais nesses campos é desafiador devido à alta volatilidade e múltiplos fatores de influência. Também é difícil processar dados que tenham não linearidades, baixa confiabilidade e alta heterogeneidade. No entanto, previsões e avaliações de dados de séries temporais nesses campos são extremamente importante para a tomada de decisão eficaz, monitoramento inteligente, gerenciamento e avaliação de risco para eventos futuros.

Para obter alta precisão, trabalhos amplamente conhecidos em RNNs foram realizados out que propõe novas técnicas e arquiteturas de previsão a partir de vários modelos. O problema das redes tradicionais é que elas têm convergência lenta e baixa estabilidade, o que leva ao overfitting. Em geral, tradicional métodos e técnicas têm baixa precisão de previsão em dados sequenciais. As redes neurais recorrentes são amplamente utilizadas devido às suas poderosas características dinâmicas, excelente arquitetura e métodos de treinamento. RNNs têm muitas vantagens, incluindo memória associativa, aprendizagem adaptativa, otimização rápida e forte robustez. Eles se mostraram viáveis e de obter um bom desempenho preditivo com capacidade generalizada, mas eles precisam ser melhorados em relação às previsões de sequência de tempo.

Algumas deficiências e desafios precisam ser melhorados. No primeiro Por outro lado, os métodos convencionais envolvem poucos fatores de influência e não levar em conta outros fatores complicados, como mídias sociais, eventos e condições meteorológicas. RNNs como uma classe de modelos orientados a dados são diferentes dos modelos tradicionais e requerem um grande número de conjuntos de dados para obter previsões precisas. Por outro lado, é preciso considerar como estabelecer simultaneamente parâmetros e estruturas de modelo ideais, bem como reduzir o tempo computacional para treinamento. As RNNs se concentram principalmente em prognósticos de curto prazo, enquanto as aplicações de RNNs para previsão de longo prazo são relativamente escassas e têm baixa precisão de previsão, como mostrado em a literatura. A maioria das pesquisas compara o desempenho de RNNs apenas com o das redes neurais tradicionais. No entanto, vários estudos têm sido dedicado a combinar RNNs com outros algoritmos de aprendizado profundo (LeCun et al., 2015; Zuo, Fan, Blasch, & Ling, 2017), como a recorrente

máquina restrita de Boltzmann (RTRBM; Sutskever, Hinton, & Taylor, 2008; Wang, Wang, Zhao, & Wang, 2017) e LSTM convolucional (ConvLSTM; Shi et al., 2015; Zhu, Zhang, Shen e Song, 2017). Além disso, a combinação de RNNs e outros métodos de aprendizado profundo aplicados a séries temporais a previsão nos campos mencionados será fundamental em estudos futuros.

Esses problemas não são facilmente resolvidos. Em trabalhos futuros, tomaremos outros fatores complexos em consideração nos modelos para obter uma previsão mais alta precisão. O maior número possível de dados de sequência foi obtido e usado para treinar e testar os modelos. Além disso, mais investigações serão realizadas para aumentar a capacidade de aprendizagem das redes neurais e reduzir tempo computacional, levando a um treinamento mais rápido. Também é importante para RNNs armazenar informações por muito tempo. Além disso, previsões de longo prazo usando RNNs e seus modelos híbridos levarão a novos avanços. São necessários mais pesquisadores para estudar as previsões de longo prazo em vários campos. Tal estudos podem aumentar a precisão científica e de previsão. Simultaneamente, nós esperamos que os métodos de aprendizado profundo sejam combinados com RNNs para fornecer previsões precisas para problemas de séries temporais selecionadas e comparar o desempenho preditivo com os modelos superficiais. Finalmente, expandindo para novas áreas de pesquisa de previsão é de grande valor para resolver problemas do mundo real.

O objetivo desta revisão é descrever as aplicações de RNNs em previsão que possuem grande valor prático e econômico em diversos campos. As áreas de aplicação são principalmente fatores ambientais baseados no trabalho atual.

É claro que muitos campos novos precisam ser explorados. Por exemplo, preciso e previsões eficientes de mudanças na qualidade da água desempenham um papel significativo no planejamento ambiental e pode prevenir a deterioração da água e surtos de doenças na aquicultura, bem como orientar o melhoramento científico. Além disso, previsões de fatores ambientais em estufa solar ou aquaponia também são direções de pesquisa que valem a pena. Com o desenvolvimento da Internet das coisas e da tecnologia computacional, dados de qualidade da água em tempo real, multivariados e de alta dimensão são obtidos com rapidez e precisão. Isso é de grande importância e valor para construir modelos usando essas séries temporais dados para levar ao crescimento saudável de produtos aquáticos e gestão científica de obras aquáticas. Existem alguns métodos convencionais para construir modelos de qualidade da água (Chau, 2006; Faruk, 2010; Chang, Tsai, Chen, Coynel, & Vachaud, 2015; Gazzaz, Yusoff, Aris, Juahir e Ramli, 2012; Najah, El-Shafie, Karim, & El-Shafie, 2013). Liu et al. (2013) apresentou um híbrido abordagem que combina a regressão do vetor de suporte com um algoritmo genético para resolver o problema de previsão da qualidade da água da aquicultura. Liu, Wei e Chen (2013) propôs uma rede neural fuzzy para resolver o problema da previsão de oxigênio dissolvido. Esses modelos tiveram um efeito em ajudar a facilitar o alerta precoce e reduzir as perdas. No entanto, ainda existem muitas desvantagens. Para resolver o problema de baixa robustez e baixa precisão de modelos tradicionais de previsão, as RNNs são uma ferramenta promissora para fazer previsões de alta precisão da qualidade da água. Acreditamos que futuras aplicações de

As RNNs na previsão serão expandidas para outras áreas que poucas pessoas consideraram até o momento, como a aquicultura.

5. Conclusão

Nesta revisão, apresentamos uma série de publicações preliminares sobre as aplicações de RNNs na análise e previsão de séries temporais. Como resumimos, as RNNs foram aplicadas para prever séries temporais dados na maioria dos campos científicos e industriais, mas principalmente em previsão de fatores. Além disso, apresentamos a estrutura, fluxo de processamento, e vantagens de RNNs nesta revisão. Além disso, RNNs, como o Rede neural Elman, rede neural LSTM e modelos de melhoria podem ser alternativas de previsão poderosas para redes neurais tradicionais e pode obter melhores resultados de previsão para alguns problemas. Apresentamos também o limitações e desafios dos modelos de previsão baseados em RNNs e discutir o desenvolvimento futuro de RNNs para fazer previsões de dados. Esta revisão fornece orientação útil para modelagem RNN e novos campos de pesquisa em estudos posteriores.

Agradecimentos

Agradecemos ao American Journal Experts por fornecer a edição em inglês desta revisão. A revisão é apoiada pela Science & Technology Programa de Pesquisa e Demonstração de Tecnologias em Pequim Equipamento Capaz de Controle Inteligente para Cultivo Saudável em Grande Escala de Peixes de Água Doce (Z171100001517016); e a chave da província de Shandong Programa de Pesquisa e Desenvolvimento “Pesquisa e Demonstração de Tecnologias Precisas de Monitoramento e Controle para o Ambiente de Vegetais nas Instalações” (2017CXGC0201).

Referências

- Alzahrani, A., Shamsi, P., Dagli, C., & Ferdowsi, M. (2017). Previsão de irradiância solar usando redes neurais profundas. Em CH Dagli (Ed.), *Sistemas adaptativos complexos conferência com o tema: Engenharia de sistemas físicos cibernéticos*, Cas(vol. 114, pp. 304–313). Amsterdã: Elsevier.
- An, Y., Song, Q., & Zhao, X. (2011). *Previsão de fluxo de tráfego de curto prazo via neural de estado de eco redes*. In *Proceedings of the International Conference on Natural Computation* (pp. 844-847). Piscataway, NJ: IEEE.
- Awano, H., Nishide, S., Arie, H., Tani, J., Takahashi, T., Okuno, HG, & Ogata, T. (2011). *Uso de uma estrutura esparsa para melhorar o desempenho de aprendizagem de neurais recorrentes*. Berlim: Springer.
- Bebis, G., & Georgiopoulos, M. (2009). Redes neurais feed-forward. *Potência IEEE cial*, 13(4), 571-586.

Aplicações de RNNs na Previsão de Fatores Ambientais

21

- Biancofiore, F., Verdecchia, M., Di Carlo, P., Tomassetti, B., Aruffo, E., Busilacchio, M., & Colangeli, C. (2015). Análise do ozônio superficial usando uma rede neural recorrente. *Ciência do Ambiente Total*, 514, 379-387. doi:10.1016/j.scitotenv.2015.01.106
- Boden, M. (2002). *Um guia para redes neurais recorrentes e retropropagação*. Halmstad Suécia: Universidade de Halmstad.
- Bontempi, G., Taieb, SB, & Borgne, YAL (2013). *Estratégias de aprendizado de máquina para o tempo previsão de séries*. Berlin: Springer.
- Cao, JD (2001). Estabilidade exponencial global de redes neurais Hopfield. *International Journal of Systems Science*, 32(2), 233–236. doi:10.1080/00207720117783
- Chang, F.-J., Chen, P.-A., Lu, Y.-R., Huang, E., & Chang, K.-Y. (2014). Previsão de nível de água multi-passo em tempo real por redes neurais recorrentes para inundação urbana ao controle. *Journal of Hydrology*, 517, 836-846. doi: 10.1016/j.jhydrol.2014.06.013
- Chang, FJ, Tsai, YH, Chen, PA, Coynel, A., & Vachaud, G. (2015). Modelagem da qualidade da água em um rio urbano usando fatores hidrológicos: abordagens orientadas por dados. *Journal of Environmental Management*, 151, 87-96. doi: 10.1016/j.jenvman.2014.12.014
- Chang, L.-C., Chen, P.-A., & Chang, F.-J. (2012). Peso reforçado de dois passos à frente técnica de ajuste para treinamento online de redes neurais recorrentes. *IEEE Transactions on Neural Networks and Learning Systems*, 23(8), 1269–1278. doi: 10.1109/tnnls.2012.2200695
- Chau, K.-W. (2006). Uma revisão sobre a integração da inteligência artificial na modelagem da qualidade da água. *Boletim de Poluição Marinha*, 52(7), 726–733. doi:10.1016/j.marpolbul.2006.04.003
- Chen, MY, & Chen, BT (2015). Um modelo híbrido fuzzy de séries temporais baseado em computação granular para previsão de preços de ações. *Ciências da Informação*, 294, 227-241. doi:10.1016/j.ins.2014.09.038
- Chen, P.-A., Chang, L.-C., & Chang, F.-J. (2013). Redes neurais recorrentes reforçadas para previsões de cheias com vários passos à frente. *Jornal de Hidrologia*, 497, 71-79. doi:10.1016/j.jhydrol.2013.05.038
- Chen, S., Billings, SA, & Grant, PM (1990). Identificação de sistemas não lineares usando redes neurais. *International Journal of Control*, 51(6), 1191-1214. doi: 10.1080/00207179008934126
- Chen, TP (2001). Estabilidade exponencial global de redes neurais de Hopfield atrasadas. *Redes Neurais*, 14(8), 977-980. doi:10.1016/s0893-6080(01)00059-4
- Chen, YY, Lv, Y., Li, Z., & Wang, FY (2016). Modelo de memória de curto prazo longo para previsão de congestionamento de tráfego com dados abertos online. Em *Atos do Conferência Internacional IEEE sobre Sistemas Inteligentes de Transporte*. Piscataway, NJ: IEEE.
- Ciric, IT, Cojbasic, ZM, Nikolic, VD, Zivkovic, PM, & Tomic, MA (2012). Ar estimativa de qualidade por metodologias de inteligência computacional. *Ciências Térmicas*, 16, S493-S504. doi:10.2298/tsci120503186c
- Collobert, R., Weston, J., Karlen, M., Kavukcuoglu, K., & Kuksa, P. (2011). Natural processamento de linguagem (quase) do zero. *Journal of Machine Learning Research*, 12(1), 2493-2537.
- Cruse, H. (1996). *Redes neurais como sistemas cibernéticos*. Stuttgart: Thieme Medical Editores.

- Deshmukh, RP, & Ghatol, AA (2010). Estudo comparativo de Jorden e Elman modelo de rede neural para previsão de inundações de curto prazo. Em *Anais de 2010 3ª Conferência Internacional IEEE em Ciência da Computação e Tecnologia da Informação* (vol. 9, 400-404). Piscataway, NJ: IEEE.
- Dinarelli, M., & Tellier, I. (2016). *Melhorando as redes neurais recorrentes para a sequência la campanha*. arXiv: 1606.02555v1.
- Duong, HN, Nguyen, QNT, Bui, LT, Nguyen, HT, & Snasel, V. (2014). Aplicação de rede neural difusa recorrente para prever o escoamento do rio Srepok. Tinta.
- Saeod & V. Snasel (Eds.), *Sistemas de informação informática e gestão industrial* (vol. 8838, pp. 55-66). Berlim: Springer Verlag.
- Elman, JL (1990). Encontrando estrutura no tempo. *Ciência Cognitiva*, 14(2), 179-211.
- Fang, C., Wang, X., Murphey, YL, Weber, D., & MacNeille, P. (2014). Previsão de umidade específica usando rede neural recorrente. Em *Anais da Conferência Conjunta Internacional de 2014 sobre Redes Neurais* (pp. 955-960). Piscataway, NJ: IEEE.
- Faruk, DO (2010). Uma rede neural híbrida e modelo ARIMA para qualidade da água previsão de séries temporais. *Aplicações de Engenharia de Inteligência Artificial*, 23(4), 586–594. doi: 10.1016 / j.engappai.2009.09.015
- Fernández, S., Graves, A., & Schmidhuber, J. (2007). Rotulagem de sequência em estrutura domínios com redes neurais recorrentes hierárquicas. In *Proceedings of the International Joint Conference on Artificial Intelligence*. Nova York: ACM.
- Fu, R., Zhang, Z., & Li, L. (2016). Usando métodos de rede neural LSTM e GRU para previsão de fluxo de tráfego. *Anais do 31º Anual Acadêmico da Juventude de 2016 Conferência da Associação Chinesa de Automação* (pp. 324–328).
- Garcia-Pedrero, A., & Gomez-Gil, P. (2010). Previsão de séries temporais usando recorrente redes neurais e sinais reconstruídos wavelet. In *Proceedings of the International Conference on Electronics, Communications and Computer*. Piscataway, NJ: IEEE.
- Gazzaz, NM, Yusoff, MK, Aris, AZ, Juahir, H., & Ramli, MF (2012). Artificial modelagem de rede neural do índice de qualidade da água para o rio Kinta (Malásia) usando variáveis de qualidade da água como preditores. *Boletim de Poluição Marinha*, 64(11), 2409–2420. doi: 10.1016 / j.marpolbul.2012.08.005
- Gers, FA, Schmidhuber, J., & Cummins, F. (2000). Aprendendo a esquecer: contínuo previsão com LSTM. *Computação Neural*, 12(10), 2451-2471.
- Gers, FA, & Schmidhuber, E. (2001). As redes recorrentes LSTM aprendem linguagens simples, livres de contexto e sensíveis ao contexto. *Trans. IEEE Neural Netw.*, 12(6), 1333-1340.
- Gers, FA, & Schraudolph, NN (2003). *Aprendendo o tempo preciso com LSTM recorrente redes*. JMLR.org.
- Gil, P., Cardoso, A., & Palma, L. (2009). Estimando o número de neurônios ocultos em redes neurais recorrentes para identificação de sistemas não lineares. Em *Processos de o IEEE International Symposium on Industrial Electronics*. Piscataway, NJ: IEEE.
- Giles, CL, Kuhn, GM, & Williams, RJ (1994). Redes neurais recorrentes dinâmicas: Teoria e aplicações. *Transações IEEE em Redes Neurais*, 5(2), 153–156.
- Guldal, V., & Tongal, H. (2010). Comparação de rede neural recorrente, sistema de inferência neuro-fuzzy adaptativo e modelos estocásticos no nível do lago Egirdir previsão. *Gestão de Recursos Hídricos*, 24(1), 105–128. doi:10.1007/s11269-009-9439-9

- Haddad, S., Mellit, A., Benghanem, M., & Daffallah, KO (2016). Previsão de curto prazo baseada em NARX da vazão de água de um sistema de bombeamento fotovoltaico: um estudo de caso. *Journal of Solar Energy Engineering-Transactions of the ASME*, 138(1), 6. doi:10.1115/1.4031970
- Hochreiter, S., & Schmidhuber, J. (1997). Memória de curto prazo longa. *Computação Neural*, 9(8), 1735-1780.
- Hopfield, JJ (1982). Redes neurais e sistemas físicos com coletivos emergentes habilidades computacionais. *Proc. Nacional Acad. Sci. EUA*, 79(8), 2554.
- Jiang, XM, & Adeli, H. (2005). Modelo de rede neural wavelet dinâmica para previsão de fluxo de tráfego. *Journal of Transportation Engineering—ASCE*, 131(10), 771–779. doi:10.1061/(asce)0733-947x(2005)131:10(771)
- Kalinli, A., & Sagiroglu, S. (2006). Rede Elman com memória incorporada para identificação do sistema. *Journal of Information Science and Engineering*, 22(6), 1555–1568.
- Kim, KJ (2003). Previsão de séries temporais financeiras usando máquinas de vetor de suporte. *Neurocomputing*, 55(1-2), 307-319. doi:10.1016/s0925-2312(03)00372-2 Kordmahalleh, MM, Sefidmazgi, MG, Homaiifar, A., & ACM (2016). Uma rede neural recorrente esparsa para previsão de trajetória de furacões no Atlântico. Em *Gecco'16: Anais da Conferência de Computação Genética e Evolutiva de 2016* (pp. 957–964). Nova York: ACM. doi:10.1145/2908812.2908834
- Lai, G., Wei-Cheng, C., Yiming, Y., & Hanxiao, L. (2017). *Modelagem de padrões temporais de longo e curto prazo com redes neurais profundas*. arXiv:1703.07015.
- Le, JA, El-Askary, HM, Allali, M., & Struppa, DC (2017). Aplicação de redes neurais de aluguel recorrente para projeções de seca na Califórnia. *Pesquisa Atmosférica*, 188, 100-106. doi: 10.1016/j.atmosres.2017.01.002
- Le, P., & Zuidema, W. (2016). Quantificando o gradiente de fuga e o problema de dependência de longa distância em redes neurais recursivas e LSTMs recursivas. Em *Workshop sobre Aprendizagem Representativa para PNL* (pp. 87–93).
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Aprendizado profundo. *Natureza*, 521 (7553), 436-444. doi:10.1038/nature14539
- Lee, H.-Y., Tseng, B.-H., Wen, T.-H., & Tsao, Y. (2017). Personalizando o modelo de linguagem baseado em rede neural recorrente por rede social. *IEEE-ACM Transactions on Audio Speech and Language Processing*, 25(3), 519–530. doi:10.1109/taslp.2016.2635445 Liu, S., Tai, H., Ding, Q., Li, D., Xu, L., & Wei, Y. (2013). Uma abordagem híbrida de regressão de vetores de suporte com otimização de algoritmo genético para predição da qualidade da água em aquicultura. *Modelagem Matemática e Computacional*, 58(3–4), 458–465.
- Li, Y., Yu, R., Shahabi, C., & Yan, L. (2017). *Rede neural recorrente convolucional gráfica: previsão de tráfego orientada por dados*. arXiv.
- Liu, Y., Wei, Y., & Chen, Y. (2013). Modelo de previsão de oxigênio dissolvido baseado em rede neural difusa. *IFIP Advances in Information and Communication Technology*, 420(1), 49–54.
- Ma, XL, Tao, ZM, Wang, YH, Yu, HY e Wang, YP (2015). Rede neural de memória de longo prazo para previsão de velocidade de tráfego usando dados de sensores remotos de micro-ondas. *Pesquisa em Transporte Parte C—Tecnologias Emergentes*, 54, 187–197. doi:10.1016/j.trc.2015.03.014
- Mahmoud, MA (2008). Análise fase I de perfis de regressão linear múltipla. *Communications in Statistics—Simulation and Computation*, 37(10), 2106–2130. doi:10.1080/03610910802305017

- Mandic, DP, & Chambers, J. (2001). Redes neurais recorrentes para previsão: Algoritmos de aprendizagem, arquiteturas e estabilidade. Em KS Narendra (Ed.), *Sistemas Adaptativos e de Aprendizagem para Comunicações e Controle de Processamento de Sinais*. Boston: Springer.
- Maqsood, I., & Abraham, A. (2007). Análise do tempo usando um conjunto de paradigmas de aprendizagem de conexão. *Computação Suave Aplicada*, 7(3), 995–1004. doi:10.1016/j.asoc.2006.06.005
- Maqsood, M., Khan, MR, Huang, GH, & Abdallah, R. (2005). Aplicação de modelos de computação suave para análise meteorológica de hora em hora no sul de Saskatchewan, Canadá. *Aplicações de Engenharia de Inteligência Artificial*, 18(1), 115–125. doi:10.1016/j.engappai.2004.08.019
- Mikolov, T., Karafiát, M., Burget, L., Cernocký, J., & Khudanpur, S. (2010). *Recurrente modelo de linguagem baseado em rede neural*. Trabalho apresentado no INTERSPEECH 2010, Conferência da International Speech Communication Association, Makuhari, Chiba, Japão, setembro.
- Mohammadinezhad, A., & Jalili, M. (2013). Otimização de redes de estado de eco para previsão de seca com base em dados de sensoriamento remoto. Nos *Anais do IEEE 2013 8ª Conferência sobre Eletrônica Industrial e Aplicações* (pp. 126–130). Piscataway, NJ: IEEE.
- Motlagh, MT, Khaloozadeh, H., & IEEE. (2016). Uma nova arquitetura para modelagem e previsão de sistemas dinâmicos usando redes neurais: Aplicação em Bolsa de valores de Teerã. Nos *Anais da 4ª Conferência Internacional de 2016 sobre Controle, Instrumentação e Automação (ICCIA)* (pp. 196–201). Piscataway, NJ: IEEE.
- Najah, A., El-Shafie, A., Karim, OA, & El-Shafie, AH (2013). Aplicação de redes neurais artificiais para previsão da qualidade da água. *Computação Neural e Aplicações*, 22, S187–S201. doi:10.1007/s00521-012-0940-3
- Nogales, FJ, Contreras, J., Conejo, AJ, & Espinola, R. (2002). Previsão para o dia seguinte preços de eletricidade por modelos de séries temporais. *Transações IEEE em Sistemas de Energia*, 17(2), 342–348. doi:10.1109/tpwrs.2002.1007902
- Ong, BT, Sugiura, K., & Zettsu, K. (2014). Pré-treinamento dinâmico de profunda recorrente redes neurais para prever dados de monitoramento ambiental. Em *Processos de a Conferência Internacional IEEE 2014 sobre Big Data (Big Data)* (pp. 760–765). Piscat, NJ: IEEE.
- Oprea, M., Popescu, M., & Mihalache, SF (2016). Um modelo baseado em rede neural para a previsão de poluentes atmosféricos PM2.5. Nos *Anais do 20º Congresso Internacional de 2016 Conferência sobre Teoria de Sistemas, Controle e Computação* (pp. 776–781). Piscataway, NJ: IEEE.
- Pollack, JB (1990). Representações distribuídas recursivas. *Inteligência Artificial*, 46(1), 77–105.
- Prakash, A., Kumar, U., Kumar, K., & Jain, VK (2011). Um modelo de rede neural baseado em wavelets para prever a concentração de poluentes do ar ambiente. *Modelagem e Avaliação Ambiental*, 16(5), 503–517.
- Raza, MQ, & Khosravi, A. (2015). Uma revisão sobre carga baseada em inteligência artificial técnicas de previsão de demanda para redes inteligentes e edifícios. *Renewable and Sustainable Energy Reviews*, 50, 1352–1372. doi:10.1016/j.rser.2015.04.065

- Riedmiller, M. (1994). Aprendizado supervisionado avançado em perceptrons multicamadas: Da retropropagação aos algoritmos de aprendizagem adaptativa. *Padrões de Computador e Interfaces*, 16(3), 265–278. doi:10.1016/0920-5489(94)90017-5
- Roy, P., Choudhury, PS, & Saharia, M. (2010). Modelagem ANN dinâmica para inundação previsão em uma rede fluvial. In *Proceedings of the International Conference on Modeling, Optimization, and Computing* (vol. 1298, pp. 219–225). College Park, MD: Instituto Americano de Física.
- Rumelhart, DE, Hinton, GE, & Williams, RJ (1988). *Aprendizagem de representações internas por propagação de erros*. Cambridge, MA: MIT Press.
- Sadaei, H. J., Guimaraes, F. G., da Silva, C. J., Lee, M. H., & Eslami, T. (2017). Método de previsão de carga de curto prazo baseado em séries temporais difusas, sazonalidade e longo processo de memória. *International Journal of Approximate Reasoning*, 83, 196–217. doi: 10.1016 / j.ijar.2017.01.006
- Saharia, M., & Bhattacharjya, RK (2012). Redes neurais recorrentes com atraso temporal baseadas em geomorfologia para previsão de escoamento. *Revista KSCE de Engenharia Civil*, 16(5), 862-869. doi:10.1007/s12205-012-1463-2
- Sak, H., Senior, A., & Beaufays, F. (2014). Longa memória de curto prazo neural recorrente arquiteturas de rede para modelagem acústica em larga escala. *Ciência da Computação*, 24, 338–342.
- Salman, MG, Kanigoro, B., Heryadi, Y., & IEEE. (2015). Previsão do tempo usando técnicas de aprendizado profundo. Em *Anais da Conferência Internacional de 2015 sobre Ciência da Computação Avançada e Sistemas de Informação* (pp. 281–285). Piscataway, NJ: IEEE.
- Sanz-Serna, JM (2009). Expansões de Fourier moduladas e métodos multiescala heterogêneos. *IMA Journal of Numerical Analysis*, 29(3), 595–605. doi: 10.1093 /imanum/dm031
- Schuster, M., & Paliwal, KK (1997). *Redes neurais recorrentes bidirecionais*. Piscat, NJ: IEEE Press.
- Sheu, J.-B., Lan, LW, & Huang, Y.-S. (2009). Previsão de curto prazo da dinâmica do tráfego com algoritmos de aprendizado recorrente em tempo real. *Transportmetrica*, 5(1), 59–83. doi:10.1080/18128600802591681
- Shi, X., Chen, Z., Wang, H., Yeung, DY, Wong, W., & Woo, W. (2015). *Rede LSTM Convolutional: Uma abordagem de aprendizado de máquina para previsão de precipitação*. arXiv: 1506.04214v1
- Shoaib, M., Shamseldin, AY, Melville, BW, & Khan, MM (2016). Uma comparação entre abordagens de redes neurais estáticas e dinâmicas baseadas em wavelets para escoamento predição. *Jornal de Hidrologia*, 535, 211-225. doi:10.1016/j.jhydrol.2016.01.076
- Singh, KP, Basant, A., Malik, A., & Jain, G. (2009). Modelagem de redes neurais artificiais da qualidade da água do rio: Um estudo de caso. *Modelagem Ecológica*, 220 (6), 888-895.
- Canção, Q. (2011). Inicialização robusta de uma rede Jordan com restrições recorrentes Aprendendo. *Transações IEEE em Redes Neurais*, 22(12), 2460–2473.
- Sutskever, I., Hinton, G., & Taylor, G. (2008). A recorrente máquina de Boltzmann com restrição temporal. Em D. Kotter, D. Schuurmans, Y. Bengio, & L. Bottou (Eds.), *Avanços em sistemas de processamento de informação neural*, 21. Red Hook, NY: Curran.
- Tascikaraoglu, A., & Uzunoglu, M. (2014). Uma revisão de abordagens combinadas para previsão da velocidade e potência do vento a curto prazo. *Energia renovável e sustentável Comentários*, 34, 243-254. doi:10.1016/j.rser.2014.03.033

- Tay, FEH, & Cao, L. (2001). Aplicação de máquinas vetoriais de suporte em finanças previsão de séries temporais. *Jornal da Universidade de Ciência e Tecnologia Eletrônica de China*, 29(4), 309-317.
- Tian, YX, & Pan, L. (2015). Previsão do fluxo de tráfego de curto prazo por longo prazo rede neural recorrente de memória. Nos *Anais do IEEE International 2015 Conferência sobre Smart City/ Socialcom/ Sustaincom* (págs. 153–158). Piscataway, NJ: IEEE. doi:10.1109/SmartCity.2015.63
- Toque, F., Come, E., El Mahrsi, MK, & Oukhellou, L. (2016). Dinâmica de previsão matrizes de origem-destino de transporte público com memória de longo prazo redes neurais recorrentes. *Anais da 19ª Conferência Internacional do IEEE 2016 sobre Sistemas Inteligentes de Transporte* (pp. 1071–1076). Piscataway, NJ: IEEE.
- Tsoi, AC (1998). Arquiteturas de redes neurais recorrentes: uma visão geral. In *The Adaptive Processing of Sequences and Data Structures*, International Summer School on Redes Neurais, Palestras Tutoriais Er Caianiello.
- Turk, F., Barisci, N., Ciftci, A., & Ekmekci, Y. (2015). Comparação de redes multicamadas per ceptron e Jordan Elman para diagnóstico de hipertensão. *Intel Ligent Automation and Soft Computing*, 21(1), 123–134. doi: 10.1080/10798587.2014.959312
- Verdejo, JED, Herreros, AP, Luna, JCS, Ortuzar, MCB, & Ayuso, AR (1991). Redes neurais recorrentes para reconhecimento de fala. *Notas de Aula em Ciência da Computação* (pp. 1–26). Berlim-Springer-Verlag.
- Wang, Q., Wang, L., Zhao, J., & Wang, W. (2017). Previsão de séries temporais de longo prazo com base na rede de máquinas Boltzmann restrita temporalmente recorrente de remoção de ruído profunda. In *Proceedings of the Chinese Automation Congress*. Piscataway, NJ: IEEE.
- Wu, S., Feng, Q., Du, Y., & Li, X. (2011). Modelos de redes neurais artificiais para uso diário Previsão do índice de poluição do ar PM10 na área urbana de Wuhan, China. *Ciência da Engenharia Ambiental*, 28(5), 357–363. doi:10.1089/ees.2010.0219
- Wu, Z., Wang, X., Jiang, YG, Ye, H., & Xue, X. (2015). Modelagem espaço-temporal pistas em uma estrutura híbrida de aprendizado profundo para classificação de vídeo. *Em Procedimentos da Conferência Internacional da ACM sobre Multimídia*. Nova York: ACM.
- Yao, K., Zweig, G., & Hwang, M. (2013). Redes neurais recorrentes para linguagem compreensão. In *Proceedings of Interspeech*.
- Yu, H., Wu, Z., Wang, S., Wang, Y., & Ma, X. (2017). Redes convolucionais recorrentes espaço-temporais para previsão de tráfego em redes de transporte. *Sensores (Basileia, Suíça)*, 17(7). doi:10.3390/s17071501
- Zhang, GP (2003). Previsão de séries temporais usando um modelo híbrido ARIMA e rede neural. *Neurocomputing*, 50, 159-175. doi:10.1016/s0925-2312(01)00702-0
- Zhang, GQ, Patuwo, BE, & Hu, MY (1998). Previsão com neural artificial redes: o estado da arte. *International Journal of Forecasting*, 14(1), 35–62. doi: 10.1016 / s0169-2070 (97) 00044-7
- Zhang, N. (2011). Previsão de escoamento de águas pluviais urbanas usando neurais recorrentes redes. *Avanços em Redes Neurais - Isnn 2011, Pt I* (Vol. 6675, pp. 610–619).
- Zhao, Z., Chen, WH, Wu, XM, Chen, PCY e Liu, JM (2017). Rede LSTM: Uma abordagem de aprendizado profundo para previsão de tráfego de curto prazo. *Transporte Inteligente IET Systems*, 11(2), 68-75. doi:10.1049/iet-its.2016.0208

Aplicações de RNNs na Previsão de Fatores Ambientais

27

- Zheng, H., Yuan, J., & Chen, L. (2017). Previsão de carga de curto prazo usando EMD-LSTM redes neurais com um algoritmo xgboost para avaliação de importância de recursos. *Energias*, 10(8). doi: 10.3390/pt10081168
- Zhu, GM, Zhang, L., Shen, PY, & Song, J. (2017). *Reconhecimento de gestos multimodal usando LSTM 3-D e convolucional*. Piscataway, NJ: IEEE.
- Zuo, H., Fan, H., Blasch, E., & Ling, H. (2017). Combinando redes neurais convolucionais e recorrentes para detecção de pele humana. *Cartas de Processamento de Sinal IEEE*, 24(3).

Recebido em 5 de outubro de 2017; Aceito em 18 de julho de 2018.