



Previsão do mercado de ações usando inteligência computacional: uma pesquisa

Gourav Kumar¹ · Sanjeev Jain² · Uday Pratap Singh³

Recebido: 27 de junho de 2019 / Aceito: 10 de fevereiro de 2020
© CIMNE, Barcelona, Espanha 2020

Resumo

O mercado de ações desempenha um papel fundamental na organização econômica e social de um país. A previsão do mercado de ações é uma tarefa altamente exigente e desafiadora para investidores, analistas profissionais e pesquisadores do mercado financeiro devido à natureza altamente barulhenta, não paramétrica, volátil, complexa, não linear, dinâmica e caótica das séries temporais de preços de ações. A previsão do mercado de ações é uma tarefa crucial e uma área de pesquisa de destaque no domínio financeiro, pois investir no mercado de ações envolve maior risco. Porém com o desenvolvimento de métodos computacionais inteligentes é possível reduzir grande parte do risco. Neste trabalho de pesquisa, nosso foco está na aplicação de abordagens computacionais inteligentes, como redes neurais artificiais, lógica fuzzy, algoritmos genéticos e outras técnicas evolutivas para previsão do mercado de ações. Este artigo apresenta um levantamento atualizado da literatura existente sobre previsão do mercado de ações com base em métodos computacionais inteligentes. Neste artigo, os artigos selecionados são organizados e discutidos de acordo com seis pontos de vista principais: (1) o mercado de ações analisado e o conjunto de dados relacionado, (2) o tipo de variáveis de entrada investigadas, (3) as técnicas de pré-processamento utilizadas, (4) as técnicas de seleção de características para escolher as variáveis efetivas, (5) os modelos de previsão para lidar com o problema de previsão de preços de ações e (6) as métricas de desempenho utilizadas para avaliar os modelos. A principal contribuição deste trabalho é fornecer ao pesquisador e analista financeiro uma abordagem sistemática para o desenvolvimento de metodologia inteligente para previsão de mercado de ações. Este artigo também apresenta os contornos do trabalho proposto com o objetivo de melhorar o desempenho das técnicas existentes.

1. Introdução

O mercado de ações é um mercado aberto no qual títulos ou ações de uma empresa são negociados publicamente para arrecadar dinheiro para pesquisa e desenvolvimento, introdução de novos produtos, entrada em novos mercados, crescimento financeiro, aquisição de concorrentes, etc. Uma ação é parte da propriedade da empresa. A economia e a organização social de um país estão fortemente ligadas e fortemente afetadas pelo desempenho do mercado de ações. O mercado de ações desempenha um papel crucial na economia mundial, pois o desenvolvimento econômico de muitos países é influenciado por várias atividades financeiras [1]. O lado positivo do mercado de ações

é que dá lucros mais altos do que outros mercados financeiros e o lado negativo do investimento em ações é que envolve maior risco, mas uma decisão inteligente pode reduzir a maior parte do risco. Portanto, a previsão do mercado de ações é uma tarefa emergente antes de investir nele. A previsão de séries temporais de preços de ações é uma tarefa altamente exigente e desafiadora para os investidores e analistas profissionais na literatura de séries temporais e inteligência computacional [2]. A previsão bem-sucedida e precisa do mercado de ações renderia lucros significativos para os investidores.

Há um número de abordagens que são utilizadas para a previsão do mercado de ações. Essas abordagens foram categorizadas em quatro classes (1) análise fundamental, (2) análise técnica, (3) métodos estatísticos tradicionais, (4) métodos de computação suave. A análise fundamentalista e a análise técnica são as duas abordagens mais comumente usadas para analisar e prever o comportamento do mercado de ações [3]. Na primeira abordagem, os investidores se concentram em várias métricas que refletem a saúde da empresa antes de comprar suas ações. O analista fundamentalista estuda várias métricas como volume de negócios, despesas, relatórios anuais e trimestrais, lucros e perdas, demonstrações de resultados, ativos e passivos, balanço patrimonial etc. A análise fundamentalista é mais favorecida por investidores de longo prazo. A análise técnica é baseada no estudo de

* Uday Pratap Singh
usandohitg@gmail.com

¹ Escola de Ciência da Computação e Engenharia,
Universidade Shri Mata Vaishno Devi, Katra,
Jammu e Caxemira 182320, Índia

² Departamento de Ciência e Engenharia da Computação,
Instituto Indiano de Tecnologia da Informação, Design e
Manufatura, Jabalpur, Madhya Pradesh 482005, Índia

³ Escola de Matemática, Universidade Shri Mata Vaishno Devi,
Katra, Jammu e Caxemira 182320, Índia

estatísticas geradas pelo próprio mercado. O analista técnico acredita que o preço das ações já contempla todos os fundamentos que o afetam e modelam o comportamento histórico de

mercado de ações como uma série temporal. Analisar a forma das séries temporais financeiras permite ao analista técnico prever o comportamento futuro com base nos comportamentos passados das séries temporais acreditando que a história pode se repetir no futuro [4].

As flutuações do mercado de ações são influenciadas por vários fatores macroeconômicos, incluindo condição econômica da empresa ou país, taxa bancária, taxa de câmbio, preço de commodities, preço do ouro, movimento de outro mercado de ações, expectativas dos investidores, eventos políticos, políticas das empresas, psicologia dos investidores etc. [5-7]. Nos últimos anos, muitas outras abordagens diferentes foram sugeridas para prever o mercado de ações e fornecer um sistema inteligente de tomada de decisão. Duas abordagens mais comumente usadas para prever séries temporais de preços de ações são métodos estatísticos e abordagens de computação suave [8]. Métodos tradicionais de previsão estatística, como média móvel autorregressiva (ARMA), suavização exponencial (ES), média móvel integrada autorregressiva (ARIMA), heteroscedasticidade condicional autorregressiva (ARCH) e heteroscedasticidade condicional autorregressiva generalizada (GARCH) prevê os preços futuros das ações com base dos preços das ações anteriores [9]. Esses modelos são baseados na suposição de que as séries temporais financeiras sob investigação são geradas a partir de processos lineares [10] e tentam modelar o processo das séries temporais para prever o valor futuro das séries. No entanto, os dados de séries temporais de estoque são altamente ruidosos, não lineares, complexos, dinâmicos, não paramétricos e caóticos por natureza [11, 12]. Portanto, as técnicas estatísticas tradicionais não podem ser usadas para modelar a complexidade e a natureza não estacionária dos mercados de ações. Assim, várias técnicas de soft computing foram propostas e utilizadas para a previsão de tendências do mercado de ações. Redes neurais artificiais (RNAs) e máquinas de vetores de suporte (SVMs) são os algoritmos amplamente utilizados entre essas técnicas [13, 14].

O objetivo deste trabalho é revisar as abordagens recentes de inteligência computacional aplicadas para resolver o problema de previsão do mercado de ações. Este estudo é útil para orientar acadêmicos de pesquisa, investidores e analistas financeiros na construção de uma metodologia inteligente de previsão do mercado de ações.

2 Trabalhos Relacionados Anteriores

Iniciamos a pesquisa revisando a literatura existente de diversos autores que proporcionaram a revisão da relevância das técnicas de inteligência computacional em problemas do mercado financeiro.

Atsalakis e Valavanis [15] pesquisaram artigos científicos que fazem uso de técnicas neurais e neuro-fuzzy para resolver o problema de previsão do mercado de ações. Nesse estudo, cada artigo foi discutido com respeito a cinco perspectivas-chave

(1) o mercado de ações pesquisado, (2) as variáveis de entrada investigadas em cada modelo, (3) técnicas e parâmetros utilizados para construir o modelo de previsão, (4) diferentes comparações de modelos e (5) as medidas de desempenho usadas para medir a precisão de cada modelo. Embora este artigo forneça a valiosa contribuição na organização da literatura em previsão do mercado de ações usando técnicas de soft computing, ele é limitado a uma determinada classe de soft computing. Em contrapartida, nosso estudo investiga diversas áreas da inteligência computacional aplicadas na previsão do mercado de ações. Estudos primários de 2009 a 2015 examinados por Cavalcante et al. [16], que ilustram o uso de técnicas de inteligência computacional no mercado financeiro. Neste artigo, os estudos primários selecionados foram classificados em cinco aspectos principais (1) aplicação da soft computing no mercado financeiro, (2) o mercado financeiro examinado, (3) as variáveis de entrada utilizadas, (4) a negociação inteligente sistema proposto e (5) se o trabalho discutido auxilia no desenvolvimento do sistema de negociação. Eles investigaram os principais problemas financeiros, como previsão de preço de ações, preço de commodities, taxa de câmbio, preços de eletricidade e previsão de dificuldades financeiras, entre outros. A outra contribuição principal deste trabalho foi a apresentação de conceitos básicos principalmente análise fundamental e técnica, técnicas de pré-processamento, abordagens tradicionais de computação estatística e soft computacional usadas para resolver problemas financeiros, e desafios e escopo futuro da pesquisa relacionada.

Embora esta pesquisa abranja a ampla área de inteligência computacional e mercado financeiro, ela é relativamente antiga e muitos avanços foram feitos desde 2016. Assim, nosso trabalho apresenta um levantamento atualizado de artigo recente em inteligência computacional e previsão do mercado de ações domínio. Também alguns estudos primários que aplicaram abordagens de mineração de texto para extrair informações qualitativas sobre empresas e usar esse conhecimento minerado para prever o comportamento futuro dos preços das ações com base na qualidade das notícias das empresas são apresentados por Nikfarjam et al. [17].

Uma análise comparativa de várias abordagens de mineração de texto propostas neste artigo também discutiu de acordo com algumas características dos estudos primários: (1) os métodos de seleção de recursos, (2) a abordagem de representação de recursos, (3) a fonte de notícias utilizada, (4)) as técnicas de classificação aplicadas, (5) o número de categorias ou classes de alvos e (6) a precisão direcional. Nosso estudo também inclui várias abordagens de mineração de texto para previsão do mercado de ações, mas fornecemos a discussão mais recente em contrato para esta pesquisa de literatura. Li e Ma [18] revisaram a aplicação de redes neurais artificiais em diferentes mercados financeiros.

Eles examinaram alguns trabalhos de pesquisa primários que implementam ANN para prever o valor futuro das taxas de câmbio, mercado de ações e previsão de crises bancárias e financeiras. Nesse pequeno artigo, os autores não forneceram detalhes de quais arquiteturas de RNA ou algoritmos de aprendizado foram usados na literatura pesquisada e têm escopo limitado, pois

investigaram apenas uma classe de classe de inteligência computacional. Em contrato, nossa pesquisa tem um escopo mais amplo. Rivera et al. [19] apresentaram o levantamento da aplicação de abordagens de computação evolucionária para resolver diversos problemas financeiros. As técnicas evolutivas baseadas na abordagem darwiniana como Programação Genética (GP), Learning Classifier Systems (LCSs), Algoritmo Genético (GA), Algoritmos Evolutivos Multiobjetivos (MOEAs), Esquema de Otimização Coevolucionária e Algoritmo Evolucionário Competente foram considerados neste artigo. Esta revisão é mais restrita às abordagens darwinianas, pois apresentou poucos métodos evolutivos. Nosso estudo tem um escopo mais amplo, pois discutimos a maioria das técnicas de otimização inspiradas na natureza usadas na literatura. Agrawal et al. [20] pesquisou as técnicas existentes para previsão do mercado de ações indiano e discutiu os parâmetros relacionados, várias vantagens e limitações desses métodos. Neste artigo, os autores forneceram uma breve introdução da análise fundamental e técnica usada para previsão do mercado de ações. Kumar e Ravi [21] revisaram artigos de pesquisa de 2000 a 2016 que tratam da aplicação de mineração de texto no domínio financeiro e destacam alguns dos problemas, lacunas de pesquisa, principais desafios no domínio financeiro e direção futura em campos relacionados. Soni

[22] também revisaram o uso de RNAs na previsão do mercado de ações. Neste artigo o autor forneceu uma breve introdução da ANN e discutiu a importância da ANN na previsão.

Antes de apresentar o levantamento de estudos anteriores que utilizam RNAs para resolver o problema de previsão do mercado de ações, o autor apresentou alguns conceitos básicos do mercado de ações.

3 Terminologia Básica do Mercado de Ações e Inteligência Computacional (CI)

Esta seção apresenta as terminologias básicas do mercado de ações, como o que é mercado de ações, bolsa de valores, índice de ações, previsão do mercado de ações e abordagens de inteligência computacional que servirão de base para o restante deste artigo.


1. *Mercado de ações* O mercado de ações também chamado de mercado de ações ou mercado de ações é um mercado de propriedade pública para venda e compra de ações da empresa que as emite a um preço acordado [22]. A venda e compra de ações é conhecida como negociação. Uma ação é uma parte da propriedade da empresa e uma ação é uma coleção de ações. Possuir uma ação significa que se pode compartilhar a parte dos lucros e perdas da empresa. Uma ação é um tipo de título que é um instrumento financeiro que tem algum valor monetário e pode ser comprado ou negociado [23]. Os títulos podem ser privados ou públicos. Se apenas um indivíduo selecionado pode investir em ações, é conhecido como títulos privados e se qualquer pessoa pode investir neles, é conhecido como títulos públicos. Indivíduo

s que investem em bolsa de valores devem seguir as regras e regulamentos do órgão regulador que rege investidores e investimentos. Na Índia, as regras para títulos negociados publicamente são definidas e aplicadas pelo Securities and Exchange Board of India (SEBI). É dever do SEBI garantir que os investidores sejam tratados de forma justa e que todos os investimentos tenham sido feitos honestamente e dentro do mercado não haja negociação ilegal. Os preços das ações dependem da oferta e da demanda. Se um estoque tiver alta demanda, seu preço aumentará, enquanto estoque com baixa demanda ou muito vendido resultará em queda no preço. As empresas autorizadas a negociar em bolsa são denominadas empresas cotadas [24].

2. *Bolsa de Valores* Uma bolsa de valores é um local onde as ações da firm são negociadas. A bolsa de valores fornece um mercado que pode ser uma corporação ou organização mútua onde ações ou outros títulos são negociados por membros da organização [22]. As ações são fornecidas diretamente pela empresa por meio de Oferta Pública Inicial (IPO) ou podem ser compradas em bolsa de valores. A maioria das maiores potências econômicas do mundo tem suas próprias bolsas de valores. A Bolsa de Valores de Nova York (NYSE) e a NASDAQ são as duas maiores bolsas de valores do mundo. Na Índia, existem 21 bolsas de valores. Bombay Stock Exchange (BSE) e National Stock Exchange (NSE) são as duas maiores bolsas de valores indianas. Para negociar as ações da empresa em determinadas bolsas de valores, ela deve estar listada em determinada bolsa de valores [24].

3. *Índice de ações* Um índice é uma medida estatística do desempenho de um grupo de empresas. Uma empresa de índice escolhe um número limitado de ações de uma empresa que representa o desempenho de todo o mercado, ou de um setor específico dentro do mercado e calcula a média de seu desempenho para encontrar um número que os investidores possam usar para analisar o desempenho do mercado ou compará-lo com outras unidades populacionais [23]. Dow Jones Industrial Average (DJIA), o Standard & Poor's 500 (S&P 500) e o NASDAQ Composite são os três principais índices de ações dos EUA. Assim como as ações de empresas individuais, cada índice de ações tem seu próprio gráfico que mostra o preço de abertura, preço de fechamento, preço baixo, preço alto, volume médio e número de ações negociadas. S&P BSE Sensex e Nifty 50 são os dois principais índices de ações da BSE e NSE, respectivamente, do mercado de ações indiano. Em vez do índice do mercado de ações, outro índice popular fornecido pela Chicago Board Options Exchange (CBOE) conhecido como índice de volatilidade do mercado Cboe (índice VIX) é um indicador das expectativas do mercado de volatilidade futura no mercado de ações dos EUA [25]. É baseado em opções do índice S&P 500 e é considerado como medida do mercado global de ações dos EUA [25]. A volatilidade é uma medida da frequência e magnitude do movimento de preços, tanto para cima quanto para baixo, de um instrumento financeiro em um determinado intervalo de tempo. O índice VIX é reconhecido como

Fig. 1 Gráfico de co-movimento do índice de volatilidade Nifty 50 e da Índia



os investidores temem a gaze, pois as leituras baixas do VIX indicam que os investidores estão confiantes sobre o mercado futuro, em vez de valores temíveis e altos de VIX implicam que os investidores reconheceram um risco mais alto e perceberam que o mercado flutuaria frequentemente em qualquer direção [26]. A bolsa de valores nacional da Índia (NSE) oferece seu próprio índice de volatilidade com base no preço de opção do índice Nifty, ou seja, India VIX (INDIAVIX ou Nifty VIX), que mede a volatilidade esperada do mercado de Nifty 50 nos próximos 30 dias. figura 1 mostra o co-movimento do índice Nifty 50 e do India VIX para o período de um ano financeiro de 2 de abril de 2018 a 29 de março de 2019.

4. Tipos de ações Existem várias maneiras de classificar ações em

diferentes classes, mas geralmente as ações são classificadas por setor e por valor de mercado. No investimento setorial, os investidores compram ações de um setor, conhecido como setor.

Por exemplo, alguns podem investir em empresas de saúde ou setor de TI, setor automobilístico, setor de telecomunicações e muitos outros. Em capitalização de mercado, as ações de investimento são classificadas de acordo com o tamanho da empresa usando a fórmula chamada de capitalização de mercado (market cap) que é dada pela multiplicação do preço atual de uma única ação pelo número de ações disponíveis no mercado. As empresas são classificadas de acordo com seu valor de mercado usando diferentes números, mas a regra geral é: \$ 50 milhões ou menos: nano cap, \$ 50 milhões a \$ 300 milhões: micro cap, \$ 300 milhões a \$ 2 bilhões: small cap, \$ 2 bilhões a \$ 10 bilhões: mid cap, \$10 bilhões ou mais: large cap (também conhecido como blue chip) [23]. As Figuras 2 e 3 mostram a comparação de desempenho de 9 anos de três setores de NSE e dois setores de BSE do mercado de ações indiano. Os índices setoriais capturam o desempenho das empresas listadas em determinado índice. O índice Nifty IT mede o desempenho de empresas indianas de TI, como TCS Ltd., Wipro Ltd., Infosys Ltd. etc. GAIL, Petronet LNG etc. O retorno total é a quantidade de lucro em porcentagem, ganha pelos investidores de um título durante um determinado período de tempo e é uma medida forte para analisar

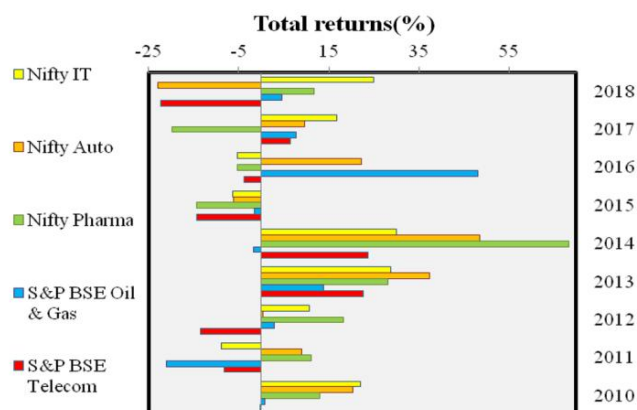


Fig. 2 Comparação de desempenho dos índices setoriais com base nos retornos totais




Fig. 3 Comparação de desempenho dos índices setoriais com base nos retornos médios diários

o desempenho histórico das empresas [27]. O retorno médio diário é o valor médio que um investidor ganha diariamente em um período específico de tempo [28].

5. **Previsão do mercado de ações** A previsão do mercado de ações é o processo de prever os preços futuros do mercado de ações com base em dados históricos anteriores. As séries temporais de preços de ações geralmente são usadas para tarefas de previsão. Prever o mercado de ações é uma tarefa emergente para investidores, profissionais

analistas e pesquisadores sionais, pois investir no mercado de ações envolve maior risco.

6. **Séries Temporais** Uma série temporal é um conjunto de observações geralmente coletadas em pontos sucessivos de tempo tais como: $x_t = \{x_t | t=1, 2, 3, \dots, N\}$ onde t é o índice temporal e N é o total número de observações e essas observações são registradas em intervalos de tempo regulares, como diariamente, mensalmente, trimestralmente e anualmente [29]. Figura 4 mostra a série temporal do preço das ações do preço de fechamento de duas empresas indianas, nomeadamente Tata Consultancy Services Ltd. (TCS) e Reliance Industries Ltd. (RIL) por um período de 10 anos. As séries temporais geralmente são plotadas por gráficos de linhas. Exemplos de séries temporais são preço das ações, preço do ouro, taxa de câmbio, preço das commodities, preço do petróleo, venda mensal da empresa, população do país medida em um ponto regular do tempo etc. As séries temporais são usadas em diversas aplicações, como econometria, clima previsão, processamento de sinais, engenharia de controle, previsão de terremotos, reconhecimento de padrões, estatísticas, previsão do mercado de ações e outras previsões do mercado financeiro [30]. O principal objetivo das técnicas de previsão de séries temporais é prever os valores futuros da série com base no padrão regular presente nas observações passadas da própria série.
7. **Análise Fundamental** A análise fundamental é realizada com base em dados econômicos das empresas e envolve a previsão dos mercados de ações usando dados econômicos das empresas, que são publicados em períodos regulares de tempo, por exemplo, relação preço/lucro (P/L), volume de negócios de empresa, lucros e perdas, relatórios anuais e trimestrais, ativos e passivos, balanço patrimonial, demonstrações de resultados [3, 31]. Envolve simplesmente analisar o desempenho da empresa com base em certos fundamentos da empresa.
8. **Análise Técnica** A análise técnica está de acordo com os dados das séries temporais e envolve a previsão do mercado de ações por meio de gráficos ou indicadores técnicos [3, 31]. Baseia-se na hipótese de que todas as informações sobre o




Fig. 4 Série temporal do preço das ações das empresas indianas

mercado está presente nos preços das ações em tempo real. Os analistas técnicos usam gráficos e técnicas de modelagem para determinar tendências no preço das ações e depende de dados anteriores para prever os preços futuros das ações. Envolve a previsão do preço futuro da ação com base em padrões passados da ação por meio de análise de séries temporais [32].

9. **Inteligência Computacional (IC)** É um conjunto de técnicas que são aplicadas para imitar o poder do pensamento humano para lidar com problemas complexos do mundo real [33]. A taxonomia de CI é dada na Fig. 5. Lógica difusa, redes neurais, algoritmos genéticos e outras técnicas de computação evolucionária são usadas coletivamente em CI para representar conhecimento e para simular a capacidade de tomada de decisão e raciocínio do ser humano [34]. As técnicas de CI têm sido aplicadas em muitas aplicações, como reconhecimento de padrões [35], comunicações [36], sistema de corrente pesada [37], sistema inteligente de reconhecimento de fala [38], área de processamento de sinal [39], design e fabricação [40], previsão e previsão [14] e muitas aplicações diversas.

- 9.1 **Redes Neurais Artificiais (RNAs)** As RNAs são sistemas distribuídos massivamente paralelos inspirados no cérebro humano [41]. É uma rede de unidades conhecidas como neurônio artificial que tem a capacidade de processar e armazenar conhecimento de experimentos. As RNAs imitam o cérebro humano em dois aspectos (1) o conhecimento aprendido pela rede usando a experiência passada (dados históricos) através do processo de aprendizagem e (2) a força (peso sináptico) da conexão entre os neurônios é usada para armazenar o conhecimento adquirido. É um modelo de conexão que consiste em três camadas (1) camada de entrada (2) camada oculta (3) camada de saída. A entrada é transmitida entre as camadas por meio de links. Cada link possui um peso associado (força da conexão) que é multiplicado com a entrada proveniente da camada de entrada para calcular a entrada líquida (soma de todas as entradas em determinado nó). A entrada líquida é fornecida à função de ativação para produzir a saída da rede. Modelos de conexão como ANN são adequados para computação suave onde os pesos de conexão são otimizados para melhorar o desempenho de uma rede. O algoritmo de retropropagação (BP) é usado principalmente em redes neurais artificiais para treinar a rede [42, 43].

- 9.2 **Lógica Fuzzy** A Lógica Fuzzy (FL) é uma expansão da teoria clássica dos conjuntos e foi proposta por Lotfi A. Zadeh e Dieter Klaua em 1965. Lógica difusa é um método de representação do conhecimento humano que é impreciso por natureza em uma determinada área de aplicação e no raciocínio com esse conhecimento para tomar decisões úteis ou fazer inferências [34, 44]. A lógica difusa fornece poder computacional para CI. Em difuso

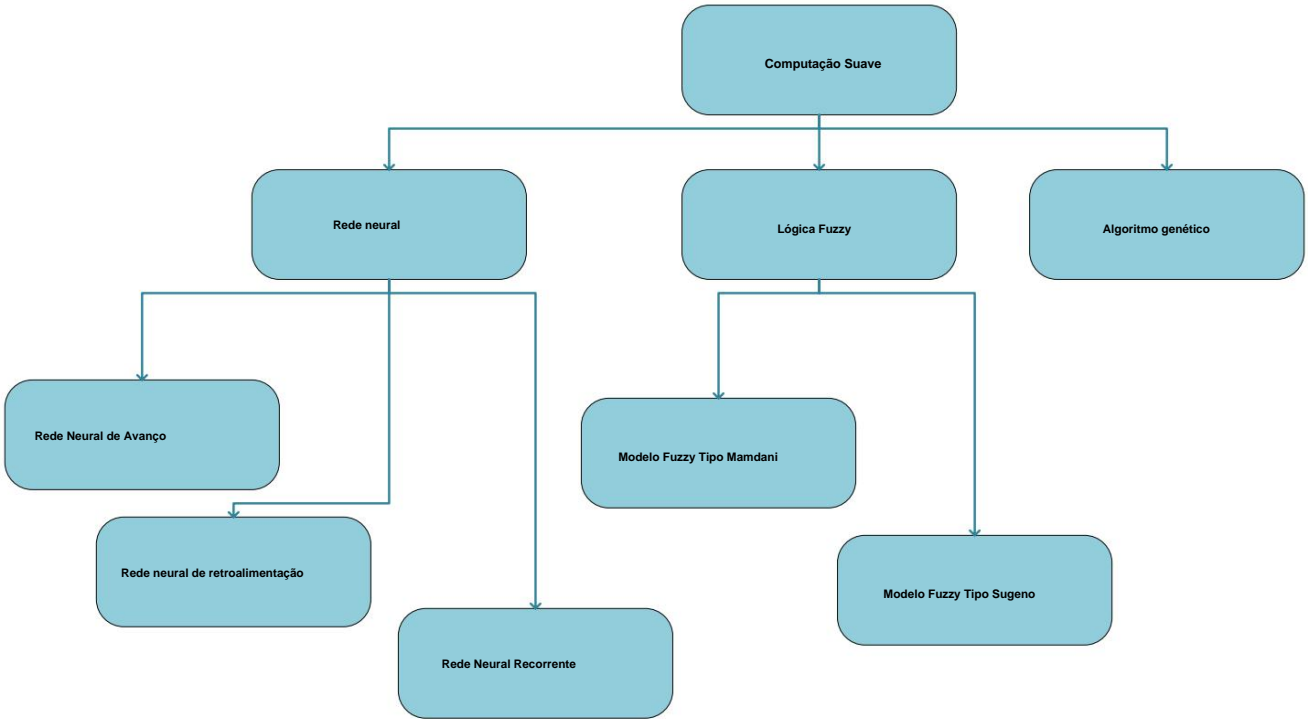


Fig. 5 Principais abordagens de CI para previsão do mercado de ações

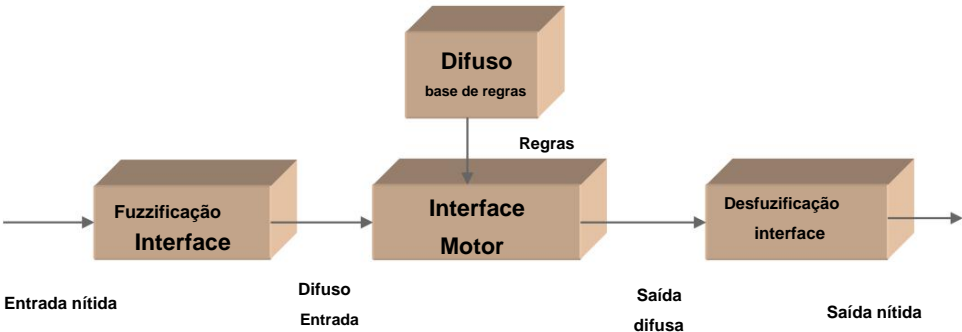
lógica, o conhecimento é representado através de regras if-then envolvendo variáveis linguísticas. A Figura 6 mostra a arquitetura básica do sistema de lógica fuzzy. A interface de fuzzificação traduz os dados de entrada nítidos em dados linguísticos difusos. No sistema de lógica fuzzy, a fuzzificação é necessária porque as fontes de dados existentes fornecem entrada na forma de valores nítidos. O mecanismo de inferência usa a entrada fuzzy e as regras fuzzy para gerar a saída fuzzy. A interface de defuzzificação produz a ação de saída crisp [33].

9.3 *Algoritmo Genético* GA foi inventado por John Holland na década de 1960 [34]. O AG é um método de otimização dinâmico, adaptativo e livre de derivativos, que é inspirado na evolução biológica [33, 45]. Pertence à classe de computação evolucionária. A computação evolucionária tem as três propriedades principais

[34]: (1) é uma técnica de busca estocástica baseada em população, pois é baseada em múltiplos pontos de busca (2) usa operações biológicas como cruzamento e mutação para gerar a solução ótima (3) é baseada em operações probabilísticas. O processo básico do algoritmo genético envolve os seguintes passos:

- 1. Inicialização, onde a busca começa com a população inicial que é criada aleatoriamente.
- 2. Avaliação, onde cada elemento da população é avaliado e a adequação dos membros é calculada usando a função de adequação.
- 3. Seleção, onde os membros que atendem ao requisito desejado são selecionados com base no valor da função de adequação.

Fig. 6 Arquitetura básica do sistema de lógica fuzzy [33]



- 4. Crossover, onde a nova geração conhecida como primavera é gerada pela combinação do melhor dos pais existentes [46].
- 5. Mutação, onde um único bit dentro do indivíduo é alterado para manter a diversidade da população [46].
- 6. Na próxima etapa, a próxima geração é produzida alterando a população atual por novas fontes geradas.

O processo de avaliação-seleção-reprodução é repetido até que uma solução ótima ou quase ótima seja obtida ou a condição de término seja satisfeita.

4 Fluxo de Trabalho de Previsão

A previsão do mercado de ações é uma importante área de pesquisa. Desenvolver um sistema inteligente que possa prever o preço das ações é uma área emergente de pesquisa para investidores e analistas financeiros. A Figura 7 mostra o fluxo de trabalho generalizado para previsão do mercado de ações adotado por diferentes autores na literatura revisada. Cada artigo escolhido é organizado e investigado de acordo com cinco categorias principais, conforme apresentado a seguir.

Uma abordagem sistemática para prever o mercado de ações compreendeu as seguintes etapas operacionais (1) seleção de variáveis de entrada, (2) pré-processamento de dados, (3) seleção e extração de recursos, (4) treinamento usando modelo de previsão/classificação e (5) avaliar o desempenho do modelo proposto. o

O primeiro passo no processo de previsão do mercado de ações consiste na seleção das características de entrada a serem modeladas pelos métodos de CI e saída a ser prevista. No contexto da previsão do mercado de ações, várias variáveis de entrada fundamentais e técnicas estão disponíveis. A seleção de variáveis de entrada é questão principal na previsão do mercado de ações e a decisão de quais variáveis de entrada devem ser utilizadas não é uma tarefa fácil. A próxima etapa do processo é o pré-processamento dos dados selecionados na primeira etapa. Os dados são pré-processados para aumentar a capacidade de previsão dos modelos. O mecanismo de pré-processamento pode ser usado para remoção de ruído, detecção de valores discrepantes, tratamento de valores ausentes e normalização de dados. Na terceira fase, várias técnicas de seleção ou extração de características são aplicadas para obter as melhores variáveis representativas dos dados de entrada, a fim de reduzir as dimensões dos dados de entrada e reduzir a complexidade computacional do modelo. A próxima fase consiste em determinar os métodos de CI a serem utilizados para previsão e treinamento do modelo utilizando dados de treinamento. A avaliação de desempenho da última fase compreende a seleção de métricas de desempenho apropriadas e a medição da precisão do modelo e a tomada de decisão correta. Neste artigo, cada artigo selecionado foi discutido de acordo com a estrutura generalizada para previsão do mercado de ações.

4.1 Mercado de ações pesquisado

Nesta seção, apresentamos uma lista de vários autores do mercado de ações que investigaram e adquiriram dados para avaliar o desempenho de seus modelos, juntamente com os correspondentes

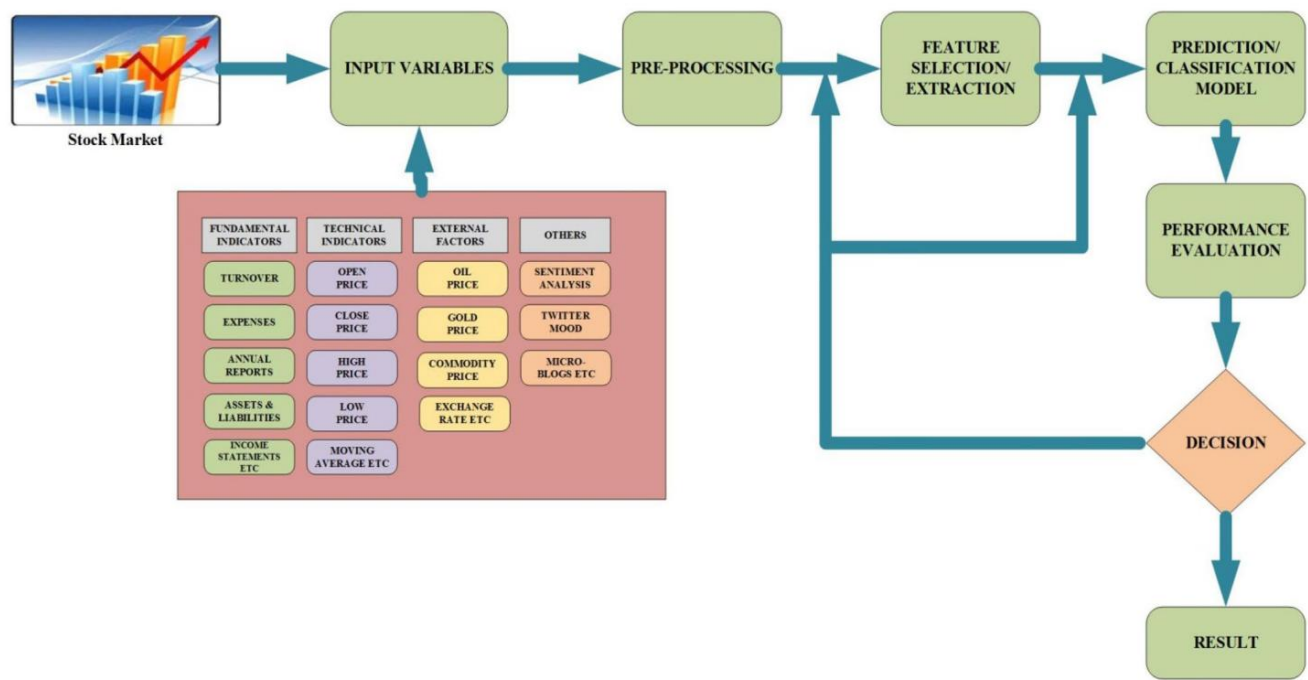


Fig. 7 Estrutura generalizada para previsão do mercado de ações

bolsa de valores, índice de ações e fontes do conjunto de dados conforme Tabela 1. Reza et al. [47], Thakur et al. [48] e Wang e Wang [49] modelam o índice DAX do mercado de ações alemão negociado na bolsa de Frankfurt. Lu [50], Thakur et al.

[48], Asadi et al. [51], Chang e Liu [52] e Esfahanipour e Aghamiri [53] tomaram o índice de ações TAIEX de Taiwan da bolsa de valores para estudo de caso. Dai et al. [54], Qiu e Song [55], Qiu et al. [56], Liu et al. [57], Cheng e Yang [58] e Lei [59] tentaram prever o índice NIKKEI 225 da bolsa de valores de Tóquio. Kara et al. [60], Boyacioglu e Avci [61] e Yolcu e Lam [62] estudaram o índice nacional ISE da bolsa de valores da Turquia. Os índices BSE Sensex e Nifty 50 do mercado de ações indiano são previstos por Thakur et al. [48], Patel et al. [63], Pathak e Shetty [64], Senapati et al. [65], Chopra et al. [66], Em vez et al. [67], Patel et al.

[68], Dash e Dash [69, 70], Rout et al. [71], Pradeepkumar e Ravi [72], Pal e Kar [73] e Rajab e Sharma [74].

Os índices DJIA S&P 500, IXIC e SPDR S&P 500 da bolsa de Nova York (NYSE) e NASDAQ do mercado norte-americano são os índices mais estudados entre os estudos levantados neste artigo por Niall e Madden [75], Asadi et al. [51], Wang e Wang [76], Liu e Wang [77], Chien e Chen [78], Zhang e Wu [79], Niaki e Hoseinzade [80], Hu et al. [81], Kazem et al. [82], Chien e Chen [83], Zhong e Enke [84], Chiang et al. [85], Liu et al. [57], Dash e Dash [69, 70], Sheta et al. [86], Sadaei et al. [87], Jiang et al. [88], Chang et al. [89], Rout et al. [71], Fischer e Krauss [90], Nayak et al. [91], Pradeepkumar e Ravi [72], Xiong et al. [92], Wang e Wang [49], Seo et al.

[93], Lei [59], Rajab e Sharma [74] e Zhou et al. [94]. de Oliveira et al. [95] e Brasileiro et al. [96] examinaram as ações PETR4 da Petrobras, negociadas na BM&FBOVESPA para estudo de caso. Asadi et al. [51], Esfahanipour e Aghamiri [53], Hadavandi et al. [97], Rezaee et al. [98] e Ghasemieh et al. [99] previam a bolsa de valores de Teerã. Os principais índices do mercado de ações da China são previstos por Dai et al. [54], Wang e Wang [76], Liu e Wang [77], Wang et al. [100], Pang et al. [101], Tan et al. [102], Mo et al. [103], Pal e Kar [73], Lei [59], Yang et al. [104], e Zhou et al. [94]. Vanstone et al. [105] e Lei [59] previram o índice ASX200 do mercado de ações australiano. Pullido et al. [106] realizaram a previsão de séries temporais da bolsa de valores mexicana do mercado de ações do México. Inthachot et al. [107, 107] tentam prever a tendência do índice SET50 da bolsa de valores da Tailândia. Gocken et al. [108] modelam o índice BIST100 do mercado de ações turco. Wang et al. [100], Kim et al. [109] e Chung e Shin [110] tentam prever o mercado de ações coreano. O índice Financial Times Stock Exchange (FTSE) do mercado de ações de Londres é previsto por Nayak et al. [91] e Wang e Wang [49]. Do país do centro-sul da Europa, a bolsa de valores de Zagreb, na Croácia, foi examinada por Svalina et al. [111]. O índice geral da bolsa de valores de Atenas (ASE) da Grécia foi estudado por Choumouziadis et al. [112].

A Tabela 2 inclui os artigos que se concentram na previsão de preço de ações individuais em vez de índices de mercado de ações particulares. Ticknor [121] e Chang et al. [89] mostra a capacidade da rede de prever os principais estoques dos EUA. Mabu et al. [122] selecionaram 16 principais empresas com alta capitalização de mercado da bolsa de valores de Tóquio no Japão. Fazel et al. [123] avaliaram a capacidade do modelo proposto aplicando-o em dados diários de preços de ações coletados da IBM e Dell Corporation do setor de TI e British Airways e Ryanair do setor aéreo. Pang et al. [101] previu o preço das ações da Petroleum and Chemical Corporation of China.

Xiong et al. [92], Shynkevich et al. [124], Laboissiere et al. [125], Pimenta et al. [126], Weng et al. [127], Gocken et al. [128], Zhang et al. [129], Shah et al. [130] e Chander [131] tentaram prever os preços das ações de um número variável de empresas em vez de índices de ações.

4.2 Variáveis de Entrada

O primeiro estágio na previsão do mercado de ações é a seleção das variáveis de entrada. Na literatura, diversos autores têm utilizado um número variável de variáveis de entrada. Dois tipos mais comuns de recursos que são amplamente utilizados para prever o mercado de ações são os indicadores fundamentais e os indicadores técnicos.

Benjamin Graham usou a análise fundamental em 1928 e mencionou que os investidores precisam analisar vários fatores fundamentais de uma empresa antes de investir nela, como tamanho da empresa, ativos, passivos, lucro, perda, relação preço/lucro, capitalização, volume de negócios, relatórios anuais e outros fatores financeiros que refletem a saúde geral da empresa [132]. A análise técnica independe dos atributos fundamentais intrínsecos e extrínsecos da empresa no campo da previsão do mercado de ações. Segundo o analista técnico, a maioria dos fundamentos que afetam o mercado de ações se refletem no próprio preço das ações [4].

O analista técnico modela os preços das ações como séries temporais e tenta identificar padrões futuros com base nos valores passados das séries temporais. Teixeira et al. [133] usaram indicadores técnicos que são determinados pela aplicação de fórmulas matemáticas aos preços das ações, como preço de abertura, preço de fechamento, preço baixo e preço alto e tentam encontrar os preços futuros das ações. Tsi naslanidis e Kugiumtzis [134] usaram vários indicadores técnicos viz. médias móveis, índice de força relativa, momentum, taxa de variação, volume de balanço, indicadores de movimento direcional entre outros fatores para previsão do mercado de ações. A Tabela 1 resume a variável de entrada usada por vários autores em seu artigo, juntamente com o período e o número de instâncias do conjunto de dados. Os artigos da Tabela 1 foram divididos em várias classes. A primeira classe inclui

artigos que utilizam preços de ações como dados de entrada, a segunda classe concentra-se em artigos que usam preços de ações e volume de ações negociadas. A terceira categoria inclui artigos que usam preços de ações com tendências do Google, a quarta categoria inclui






Tabela 2 Lista de ações pesquisadas

Artigo	Mercado de ações Bolsa de valores/ações/setor		Estoque	Origem do conjunto de dados
Ticknor [121] e Chang et al. [89]	NÓS	Microsoft Corp., Goldman Sachs Group Inc., Apple Inc., The Boeing Company, Caterpillar Inc., Verizon Communications Inc., Exxon Mobile Corp.	MSFT, GS, MAÇÃ, BA, GATO, VZ, XOM	Apple Inc. (AAPL) e International Business Machines Corp. (IBM)
Mabu et ai. [122]	Japão	Bolsa de Valores de Tóquio	16 empresas	—
Zarandi et ai. [123]	—	setor de TI Setor aéreo	IBM, DELL, British Airlines, Ryanair Airlines	Yahoo Finanças
Pang et ai. [101]	China	Petroleum and Chemical Corp. Sinopec		SINA fnance and economics, RoyalFlush fnance and economics
Xiong et ai. [92]	—	—	30 ações	Yahoo finanças
Shynkevich et ai. [124]	NÓS	NASDAQ e NYSE	50 ações negociadas no S&P 500	Yahoo fnance
Laboissiere et ai. [125]	Brasil	BM&FBOVESPA	3 ações brasileiras de distribuição de energia	Economia
Pimenta et ai. [126]			6 ações de diversos setores	
Weng et ai. [127]	—	Ações do Grupo Citi	19 ações	Yahoo finanças API Rest da Wikimedia API de banco de dados Quandl API de tendências do Google
Gocken et ai. [128]	Peru	Bolsa de valores Borsa Istanbul	3 Ações negociadas no BIST 100	Bloomberg
Zhang et ai. [129]	China	Bolsa de Valores de Xangai	6 títulos	Site da bolsa de valores de Xangai
Shah et ai. [130]	Bolsa de Valores Tadawul da Arábia Saudita		5 ações	Bloomberg
Chandler [131]	Índia	BSE e NSE	4 ações	Yahoo finanças

—, não mencionado no artigo

artigos que utilizam indicadores fundamentais como entrada, a quinta categoria é composta por artigos que utilizam indicadores técnicos como variáveis de entrada, a sexta categoria de artigos utiliza indicadores técnicos com preços de ações e a última categoria inclui artigos que utilizam indicadores fundamentais e técnicos.

Wang e Wang [76], Kazem et al. [82], Senapati et al. [65], Yolchu e Lam [62] e Zhou et al. [94] usaram o preço diário das ações como preço de abertura, preço alto, preço de fechamento e preços baixos como variáveis de entrada para o modelo de previsão proposto. O preço pelo qual uma ação é negociada na abertura de uma bolsa de valores em um determinado dia de negociação é conhecido como preço de abertura. O preço de fechamento é o último preço pelo qual uma ação é negociada no fechamento de uma bolsa em um determinado dia de negociação. Os preços máximo e mínimo são os preços diários mais altos e mais baixos pelos quais uma ação é negociada em um dia de negociação específico. Reza et ai. [47] utilizaram dados trimestrais para um período de 40 anos de abril de 1972 a julho de 2012 contendo 163 instâncias. Lu [50] usaram dados diários para um período de 2 de janeiro de 2003 a 27 de fevereiro de 2006 para o índice TAIEX compreendendo 781 instâncias e de 2 de fevereiro a 29 de fevereiro de 2008 para o índice NIKKEI contendo 1000 instâncias Liu e Wang [77] e Chander [131] selecionaram preços de abertura, fechamento, alta, baixa e volume de ações negociadas como entrada para o modelo. Hu et ai. [81] e Zhou et al. [94] utilizaram a tendência do Google com e


sem preço de abertura, preço alto, preço de fechamento e menor preço e volume de ações negociadas para desenvolver modelo de previsão.

A Figura 8 mostra o gráfico OHLC (open-high-low-close) do S&P BSE sensenx para o período de um ano financeiro de abril de 2018 a março de 2019 e mostra o movimento no preço das ações em um determinado período de tempo. No gráfico OHLC, os preços de abertura-máxima-baixa-fechamento são representados por dois tipos de barra: barra ascendente e barra descendente. Cada barra é composta por duas linhas horizontais e uma linha vertical. O valor inferior e superior na barra superior representa o preço mais baixo e mais alto da ação e a linha horizontal inferior e superior representam o preço diário de abertura e fechamento em um determinado dia de negociação e na barra inferior, o preço de fechamento é inferior ao preço alto.

Vanstone et ai. [105] aplicaram quatro indicadores fundamentais, a saber, relação preço/lucro (P/E), taxa de pagamento de dividendos, retorno sobre o patrimônio líquido (ROE) e valor contábil para a previsão do mercado de ações australiano. Boyacioglu e Avci [61] usaram 6 fatores macroeconômicos, como índice de preços ao consumidor, taxas de juros sobre depósitos, taxas de câmbio do dólar americano, índice de produção industrial, preço de venda do ouro da república, taxas de juros sobre letras do Tesouro e preço de fechamento de 4 índices, a saber DJI, ISE Nacional 100. DAX e BOVESPA e Niaki e Hoseinzade [80] utilizaram

27

Fig. 8 Preço de abertura-alto-baixo-fechamento do índice S&P BSE Sensex



fatores como entrada e selecione 20 fatores que tenham efeito considerável no movimento do índice S&P 500. Rezae et al. [98] usou 7 variáveis fundamentais pertencentes ao mercado da bolsa de valores de Teerã, como dívida total por ativos totais (TDTA), fluxo de caixa dividido por ativos totais (CFTA), passivo circulante dividido por ativos totais (CLTA), capital de giro dividido pelo total ativos (WCTA), lucro antes de juros e impostos dividido pelo ativo total (EBTA) e lucro líquido dividido pelo ativo total (NITA), ativo circulante dividido pelo ativo total (CATA) como entrada para o modelo de previsão proposto por seis anos consecutivos. Qiu et al. [56] utilizaram 71 indicadores financeiros e macroeconômicos para desenvolver um modelo de previsão do índice Nikkei 225. Todo o conjunto de dados compreende 237 observações mensais durante um período de novembro de 1993 a julho de 2013. Kara et al. [60] usam 10 indicadores técnicos viz. Média móvel simples de 10 dias, Momentum, média móvel ponderada de 10 dias, Estocástico K%, Índice de força relativa (RSI), Estocástico D%, Divergência de convergência de média móvel (MACD), A/D (Acumulação/Distribuição) Oscillator, Larry William R% e CCI (Commodity Channel Index) por um período de 11 anos contendo 2733 dias úteis. Thakur et al. [48] usaram uma combinação de cinquenta e cinco indicadores técnicos como variáveis de entrada para prever o movimento futuro dos índices de ações no período de janeiro de 2008 a dezembro de 2013. Niall e Madden [75] investigaram a capacidade de usar indicadores externos como preços de commodities e taxas de câmbio com outros indicadores técnicos para prever os movimentos do índice Dow Jones Industrial Average (DJIA). Patel et al. [63] e Zhang e Wu [79] escolheram dez indicadores técnicos como insumos para os modelos de previsão propostos. Bisoi e Dash [135] no modelo proposto usaram dados normalizados de quatro ações para um período de 3 de janeiro de 2005 a 13 de agosto de 2008. Dai et al. [54] aplicaram quatro indicadores, como preço baixo, preço de fechamento, alta do mercado à vista do dia anterior e índice de caixa de abertura de hoje para prever o índice de fechamento Nikkei 225 e o preço de fechamento do índice de ações B-share. Ticknor [121] usaram

6 indicadores técnicos, ou seja, média móvel exponencial de 5 dias e 10 dias (EMA), estocástico K%, índice de força relativa estocástica D% (RSI) e William R%, juntamente com três preços diários de ações, ou seja, preços abertos, altos e baixos para um período de 2 anos compreendendo 734 instâncias. Chien e Chen et al. [78] fazem uso de 10 indicadores técnicos, incluindo média móvel (MA), índice de força relativa (RSI), oscilador estocástico (K, D), índice de sobrecompra/sobrevenda de Williams (WILLIAM%R), convergência e divergência de médias móveis (MACD), Índice de Movimento Direcional (DMI), Índice de Canal de Commodities (CCI), Taxa de Mudança (ROC) e Índice de Movimento Direcional Médio (ADX). Qiu e Song [55] realizaram a comparação de dois tipos de variáveis de entrada denominadas Tipo I e Tipo II para prever o movimento do índice do mercado de ações. A entrada Tipo I é composta por 12 indicadores técnicos e a entrada Tipo II é composta por 9 indicadores técnicos. Os resultados do experimento mostram que as variáveis de entrada do Tipo II geram maior precisão de previsão em comparação com as variáveis de entrada do Tipo I. Neste artigo, os autores sugeriram que é possível aumentar a precisão do modelo de previsão escolhendo as variáveis de entrada apropriadas.

Inthachot et al. [107] utilizaram 11 indicadores técnicos para encontrar 44 variáveis de entrada, onde cada indicador técnico é representado por 4 indicadores diferentes com base nos últimos 4 períodos de tempo como 3, 5, 10 e 15 dias. Bisoi e Dash [135], Chiang et al. [85], Cheng e Yang [58] e Chung e Shin [110] usaram indicadores técnicos junto com os preços das ações. Reza et al. [47], Niall e Madden [75], Zarandi et al. [136] e Weng et al. [127] empregaram indicadores fundamentais e técnicos para fornecer as entradas para o modelo. de Oliveira et al. [95] combinaram análise técnica, análise de séries temporais e análise fundamentalista e para prever preço e utilizar observações mensais do índice PETR4 contendo um total de 144 observações (Tabela 3).

Neste trabalho de pesquisa, é descrito que os autores usaram diferentes tipos de variáveis de entrada para modelos de previsão. A Figura 9 mostra a distribuição de diferentes variáveis de entrada

Tabela 3 Variáveis de entrada

Artigo	Variáveis de entrada	Período	Nº de instâncias
Wang e Wang [76]	Preços diários das ações	21 de junho de 2006–31 de agosto de 2012	1513
		4 de janeiro de 2005–31 de agosto de 2012	1863
		4 de agosto de 2006–31 de agosto de 2012	1539
		4 de agosto de 2006–31 de agosto de 2012	1532
Kazem et ai. [82]	Preço diário das ações	12 de outubro de 2007–11 de novembro de 2011	800
		12 de outubro de 2007–11 de novembro de 2010	
		27 de junho de 2008–29 de setembro de 2011	
Senapati et ai. [65]	Preços diários das ações	janeiro de 2012 - dezembro de 2014	—
Chopra et ai. [66]	Preços diários das ações	Julho de 2002 a agosto de 2016	—
		novembro de 2007 a agosto de 2016	
		abril de 2008 a agosto de 2016	
Em vez et ai. [67]	Preços diários das ações	2 de janeiro de 2007–22 de março de 2010	—
Chang e Lee [115]	Preços diários das ações	2003–2014	—
Wang et ai. [100]	Preços diários das ações	16 de março de 2006–19 de março de 2014	2000
		9 de fevereiro de 2006–19 de março de 2014	
		20 de fevereiro de 2006–19 de março de 2014	
		27 de janeiro de 2006–19 de março de 2014	
Liu et ai. [57]	Preços diários das ações	janeiro de 1999 - dezembro de 2004	2160
Zarandi et ai. [123]	Preços diários das ações	10 de fevereiro de 2003 - 21 de janeiro de 2005	491
		10 de fevereiro de 2003 - 21 de janeiro de 2005	491
		17 de setembro de 2002–20 de janeiro de 2005	594
		6 de maio de 2003–17 de março de 2005	471
Svalina et ai. [111]	Preços diários das ações	4 de novembro de 2010–24 de janeiro de 2012	—
Passageiro e Lam [62]	Preços diários das ações	2000–2004	1262
		2009–2012	999
Sadei et ai. [87]	Preços diários das ações	1990–1999	—
		2000–2009	
Jiang et ai. [88]	Preços diários das ações	janeiro de 1999 - dezembro de 2004	—
		3 de janeiro de 2007–20 de dezembro de 2010	
Cai et ai. [117]	Preços diários das ações	1990–1999	—
Zang et ai. [118]	Preços diários das ações	1991-1999	—
Rout et ai. [71]	Preços diários das ações	—	1200
		1º de janeiro de 2004 a 31 de dezembro de 2008	653
Fischer e Krauss [90]	Preços diários das ações	4 de janeiro de 2010–12 de dezembro de 2012	
		dezembro de 1989 a setembro de 2015	3800
Mo et ai. [103]	Preços diários das ações	1 de agosto de 2002–27 de setembro de 2012	—
Nayak et ai. [91]	Preços diários das ações	1 de janeiro de 2000–31 de dezembro de 2014	—
Pradeepkumar et ai. [72]	Preços diários das ações	—	7581
			4232
Wang e Wang [49]	Preços diários das ações	2 de janeiro de 2007–19 de março de 2015	—
Pal e Kar [73]	Preços diários das ações	Janeiro de 2014 a março de 2015	301
		11 de abril de 2004 a 3 de dezembro de 2015	593
Yolcu e Alpaslan [119]	Preços diários das ações	janeiro de 2000 - dezembro de 2016	2984
Zhang et ai. [129]	Preços diários das ações	2 de março de 2015 a 29 de dezembro de 2017	—
Shah et ai. [130]	Preços diários das ações	2015–2016	250
Zhou et ai. [94]	Preços diários das ações	4 de janeiro de 2012–30 de dezembro de 2016	1214
		3 de janeiro de 2007–30 de dezembro de 2011	1260
Liu e Wang [77]	Preços diários das ações + volume de ações negociadas	4 de janeiro de 2000–30 de abril de 2010	2495
Chandler [131]	Preços diários das ações + volume de ações negociadas	Janeiro de 2010 a junho de 2015	1414
Hongping et ai. [81]	Preços diários das ações + tendências do Google	1 de janeiro de 2010 a 16 de junho de 2017	1877
Seo et ai. [93]	Preços diários das ações + tendências do Google	3 de janeiro de 2007–30 de dezembro de 2016	—
Vanstone et ai. [105]	4 indicadores fundamentais	Janeiro de 1994 – Janeiro de 2008	—
Boyacioglu e Avci [61]	6 indicadores de fundamentos + 3 índices	janeiro de 1990 - dezembro de 2008	228
Niaki e Hoseinzade [80]	Indicadores fundamentais	1 de março de 1994 a 30 de junho de 2008	3650

Tabela 3 (continuação)


Artigo	Variáveis de entrada	Período	Nº de instâncias
Qiu et al. [56]	71 indicadores fundamentais	Novembro de 1997 a julho de 2013	—
Mustafá et al. [98]	7 indicadores fundamentais	2007–2012	—
Zhong e Enke [84]	60 indicadores fundamentais	1 de junho de 2003–31 de maio de 2013	2518
Sheta et al. [86]	27 Indicadores fundamentais	7 de dezembro de 2009–2 de setembro de 2014	1192
Tan et al. [102]	Indicadores fundamentais	Janeiro de 2006 – julho de 2016	—
Yang et al. [104]	6 indicadores fundamentais	2006–2016	—
Chi Jie Lu [50]	6 indicadores técnicos	2 de janeiro de 2003 - 27 de fevereiro de 2006	781
		2 de fevereiro de 2004 - 29 de fevereiro de 2008	1000
Kara et al. [60]	10 indicadores técnicos	2 de janeiro de 1997 - 31 de dezembro de 2007	2733
Thakur et al. [48]	55 indicadores técnicos	janeiro de 2008 - dezembro de 2013	—
Patell et al. [63]	10 indicadores técnicos	janeiro de 2003 - dezembro de 2012	—
Chang e Liu [52]	8 indicadores técnicos	18 de julho de 2003–31 de dezembro de 2005	614
Esfahanipour e Aghamiri [53]	7 indicadores técnicos	18 de julho de 2003–31 de dezembro de 2005	614
Dai et al. [54]	4 indicadores técnicos	2 de fevereiro de 2004–3 de março de 2009	1000
		14 de dezembro de 2004–23 de fevereiro de –2009	—
Chang et al. [78]	10 indicadores técnicos	1º de janeiro de 2005 a 31 de dezembro de 2008	—
Hsu [114]	16 indicadores técnicos	4 de janeiro de 1996–18 de setembro de 2009	3540
Shahrokh et al. [51]	7 indicadores técnicos	18 de julho de 2003–31 de dezembro de 2005	620
		10 de abril de 2006 - 30 de janeiro de 2009	—
		3 de abril de 2006 - 30 de janeiro de 2009	—
		7 de março de 2001–26 de agosto de 2003	—
		10 de agosto de 2002–28 de junho de 2004	—
Ticknor [121]	9 indicadores técnicos	4 de janeiro de 2010–31 de dezembro de 2012	734
Abdul-Sal et al. [137]	6 indicadores técnicos	setembro de 2004 a setembro de 2007	—
Zhang e Wu [79]	10 indicadores técnicos	23 de outubro de 1998–27 de fevereiro de 2008	2350
Hadavandi et al. [97]	7 indicadores técnicos	20 de abril de 2006 - 31 de janeiro de 2009	863
Feng e chou [113]	20 indicadores técnicos	janeiro de 2000 - dezembro de 2004	—
Qiu e Song [55]	21 indicadores técnicos	janeiro de 2007 - dezembro de 2013	1707
Inthachot et al. [107]	44 indicadores técnicos	5 de janeiro de 2009–30 de dezembro de 2015	1464
Gocken et al. [108]	45 indicadores técnicos	8 de junho de 2005–20 de outubro de 2013	4160
Patell et al. [68]	10 indicadores técnicos	janeiro de 2003 - dezembro de 2012	2474
Cão et al. [83]	10 indicadores técnicos	1º de janeiro de 2005 a 31 de dezembro de 2008	—
Dash et al. [70]	6 indicadores técnicos	4 de janeiro de 2010–31 de dezembro de 2014	1208
		4 de janeiro de 2010–31 de dezembro de 2014	1221
Kim et al. [109]	37 indicadores técnicos	2 de janeiro de 2008–31 de dezembro de 2014	—
Werner e Marcel [120]	7 indicadores técnicos	13 de setembro de 2011–26, agosto de 2017 2110	—
Su e Cheng [116]	13 indicadores técnicos	1998–2006	—
Ghasemieh et al. [99]	44 indicadores técnicos	fevereiro de 2009 - abril de 2016	—
Chouemouziadis et al. [112]	4 indicadores técnicos	15 de novembro de 1996–5, junho de 2012	—
Chang et al. [89]	28 indicadores técnicos	2 de janeiro de 2008–30 de junho de 2009	397
Inthachot et al. [107] 30	44 indicadores técnicos	5 de janeiro de 2009–30 de dezembro de 2014	1464
empresas Gocken et al. [128]	10 indicadores técnicos	29 de janeiro de 2002–23 de dezembro de 2008	2640
	44 indicadores técnicos	17 de abril de 2013–30 de novembro de 2015	1260
Lei [59]	15 indicadores técnicos	10 de abril de 2009–24 de junho de 2014	—
		9 de fevereiro de 2009 - 2 de abril de 2014	—
		21 de abril de 2009–26, março de 2014	—
		15 de março de 2009–24 de junho de 2014	—
		22 de outubro de 2009–18 de julho de 2014	—
Pimenta et al. [126]	12 indicadores técnicos	2 de maio de 2013–2 de fevereiro de 2015	514
Rajab e Sharma [74]	10 indicadores técnicos	31 de janeiro de 2005–30 de dezembro de 2015	2865
		3 de janeiro de 2005–24 de dezembro de 2015	2730

Tabela 3 (continuação)

Artigo	Variáveis de entrada	Período	Nº de instâncias
Dash et al. [69]	3 indicadores técnicos + 3 preços de fechamento anteriores	2 de julho de 2012–11 de julho de 2014	491
		2 de julho de 2012–6 de agosto de 2014	512
Chaing et al. [85]	10 indicadores técnicos + preço de fechamento + volume 4	29 de janeiro de 2004–24 de junho de 2011	—
Pang et al. [101]	indicadores técnicos + 5 preços de ações diários	1 de janeiro de 2006–19 de outubro de 2016	—
Mabu et al. [122]	8 indicadores técnicos + gráfico de velas	4 de janeiro de 2007–30 de dezembro de 2010	—
Cheng e Yang [58]	2 indicadores técnicos + 4 preços de fechamento	1998–2012	—
Chung e Shin [110]	5 indicadores técnicos + 5 cotações diárias de ações 17	Janeiro de 2000 - Dezembro de 2016	4203
Hafzi et al. [47]	indicadores fundamentais e 3 indicadores técnicos abril de 1972 a julho de 2012		162
Niall et al. [75]	20 indicadores fundamentais e 11 técnicos	2 de janeiro de 1986 - 4 de fevereiro de 2005	4818
Oliveira et al. [95]	46 indicadores fundamentais e técnicos	Janeiro de 2000 - Dezembro de 2011	144
Zarandi et al. [136]	18 Indicadores fundamentais e técnicos	—	365
Laboissiere et al. [125]	Fundamentos e indicadores técnicos	Janeiro de 2008 a setembro de 2013	—
Weng et al. [127]	Fundamentos e indicadores técnicos	1 de janeiro de 2013–31 de dezembro de 2016	—

—, não mencionado no artigo

Fig. 9 Variáveis de entrada utilizadas nos artigos pesquisados



utilizados nos artigos pesquisados. Entre as várias variáveis de entrada, os indicadores técnicos são os mais usados, seguidos por preços de ações, indicadores fundamentais, indicadores técnicos e preços de ações, combinação de indicadores técnicos e fundamentais e preços de ações com volume e tendências do Google.

4.3 Pré-processamento de dados

Na previsão do mercado de ações, a qualidade dos dados é o principal fator, porque a precisão e a confiabilidade do modelo de previsão dependem da qualidade dos dados. Em muitas aplicações de computação leve, os dados do mundo real tendem a ser incompletos, ruidosos e contêm valores discrepantes [138]. Quaisquer anomalias indesejadas no conjunto de dados são conhecidas como ruído. Outliers são o conjunto

de observações que não obedecem ao comportamento geral do conjunto de dados [160]. [47] autores usaram vários pré-processamento de dados

A presença de ruído e outliers pode resultar em baixa precisão de previsão dos modelos de previsão. Os dados devem ser preparados de forma que cubram a faixa de entradas para as quais a rede será usada. Técnicas de pré-processamento de dados tentam reduzir erros e remover outliers, melhorando assim a precisão dos modelos de previsão. Uma das técnicas de pré-processamento de dados é a transformação de dados. A transformação de dados de uma escala para outra é útil na maioria das heurísticas.

abordagem especialmente ao resolver problemas de previsão [140].

A transformação ou mapeamento de dados de uma escala para outra é conhecida como normalização de dados. É necessário retransformar os dados pré-processados para a escala original para obter os resultados reais usando técnicas de pós-processamento [51]. Na literatura, os autores têm utilizado vários tipos de técnicas de normalização para transformar dados de uma escala para outra.

técnicas como a normalização min-max para normalizar dados e três critérios de informação baseados em estatísticas (IC), como critérios de informação Bayesian (BIC), critérios de informação Bayesian de Schwarz (SBIC) e critérios de informação Akaike (AIC) para seleção de defasagem porque as características do mercado de ações mostram sua efeitos com defasagem de tempo. Lu [50] apresentou uma análise de componentes independentes (ICA) integrada para remover o ruído contido no conjunto de dados. A saída do ICA contendo menos ruído é usada como entrada da rede neural de retropropagação (BPN) para criar o modelo de previsão. Asadi et al. [51] e Hadavandi et al. [97] usaram a normalização Min–Max para mapear os dados no intervalo $[\bar{y}_9, 0,9]$. A normalização dos dados na rede neural é necessária para evitar o aprendizado de padrões irrelevantes nos dados [51]. Se a entrada para a rede neural artificial (ANN) não for dimensionada em pequena escala, então a rede pode não dar resultados úteis ou não pode convergir no treinamento [141]. Dai et al. [54] a série temporal original é processada pela técnica de suavização de dados logarítmicos para remoção de ruído. Wang e Wang [76], Liu e Wang [77], Qiu et al.

[56], Senapati et al. [65], Chopra et al. [66], Wang et al. [100], Chiang et al. [85], Dash e Dash [69, 70], Pang et al. [101], Chang et al. [89], Rout et al. [71], Wang e Wang [49], Chung e Shin [110] e Chander [131] para minimizar o impacto do ruído nos dados do mercado de ações e aumentar a precisão, normalizaram o conjunto de dados original no intervalo $[0, 1]$ usando técnicas de normalização Min–Max. Wang et al. [8] sugeriram o modelo de previsão híbrido chamado Wavelet De-noising-based Back Propagation (WDBP) combinando a transformada wavelet (WT) para remover ruído como etapa de pré-processamento e rede neural de retropropagação (BPNN). WT é uma técnica para remover ruído do conjunto de dados antes de treinar o modelo. Neste estudo WT decompõe a série temporal do preço de fechamento em componente de baixa frequência e componente de alta frequência. O componente de alta frequência foi descartado, pois representa ruído e o componente de baixa frequência é usado como entrada para o WDBP para prever o preço futuro das ações. Hu et al. [81] e Inthachot et al. [107] mapeou o conjunto de dados original no intervalo $[\bar{y}_1, 1]$ usando técnicas de normalização min-max. Kazem et al. [82] na fase de pré-processamento de seu estudo, a primeira função de informação mútua (MI) aplicada é utilizada para identificar a constante de atraso de tempo, em segundo lugar, falsos vizinhos mais próximos (FNN) são usados para encontrar a dimensão mínima de incorporação e, em seguida, usando o melhor tempo de atraso e dimensão de incorporação, eles reconstróem o espaço de fase da série temporal para mostrar sua dinâmica oculta e, por fim, aplicaram a técnica de normalização min-max para transformar os dados no intervalo $[0, 1]$. Zhong e Enke [84] apresentaram o modelo de previsão de séries temporais de preços de ações empregando técnicas de redução de tridimensionalidade, a saber, análise de componentes principais (PCA), análise de componentes principais baseada em kernel (KPCA) e análise de componentes principais robustos fuzzy (FRPCA) com tecnologia neural artificial. rede (RNA). Neste artigo, os autores primeiro pré-processaram os dados brutos para lidar com

valores ausentes, amostras incompatíveis e valores discrepantes. Eles usaram a média dos valores existentes em ambos os lados da célula da Tabela consistindo em valores omissos para preencher os valores omissos. Para lidar com outliers, os autores definiram um intervalo e um valor que está fora do intervalo é considerado outlier. Nesse estudo, de 60 fatores financeiros e econômicos, 36 variáveis mais influentes e correlacionadas são selecionadas por três versões do PCM. Chiang et al. [85] usaram a transformação wavelet para suavizar os preços das ações e o volume de ações antes de fornecer dados ao modelo proposto. Wavelets são técnicas úteis para mineração de informações de diferentes tipos de dados. Zarandi et al. [123] aplicaram o método de rede neural de mapa auto-organizado como uma etapa de pré-processamento para a formação de cluster de dados de entrada. Ghasemieh et al. [99] usaram dois métodos de normalização, a saber, normalização linear e normalização estocástica para mapear dados no intervalo $[\bar{y}_1, 1]$. Nayak et al. [91] e Gocken et al. [128] aplicaram a função sigmóide para normalizar os dados no intervalo $[0, 1]$. Pimenta et al. [126] empregaram o mecanismo de suavização de gráfico de dispersão ponderado localmente (LOWESS) para detectar e remover valores discrepantes do conjunto de dados do mercado de ações.

Segundo ele, os outliers nas séries temporais de preços das ações são as observações que apresentam variações anormais do preço das ações que indicam a presença de fator extrínseco que não poderia ser modelado sem a disponibilidade de informações restritas e esses outliers precisam ser removidos, pois estes observações podem levar a sérios problemas na fase de treinamento.

4.4 Seleção e Extração de Recursos

A seleção de recursos significa simplesmente escolher recursos importantes e descartar os irrelevantes. A seleção de recursos é aplicada para escolher os recursos mais otimizados e é a questão-chave na tarefa de previsão do mercado de ações [142]. A ênfase das abordagens de seleção de recursos é escolher um subconjunto de recursos do conjunto de dados de entrada que possa representar efetivamente os dados de entrada, minimizando os impactos de ruído ou variáveis irrelevantes e ainda produzir bons resultados de previsão e minimizar a complexidade computacional, como tempo de execução [143].]. A seleção de um recurso irrelevante e incorreto pode resultar em modelo que não pode prever o comportamento real do mercado de ações. Os algoritmos de seleção de recursos determinam um conjunto reduzido de recursos importantes que podem ser usados como entrada no modelo de previsão para minimizar o erro e os recursos selecionados são os melhores representantes dos dados [51]. Esses métodos resultam em menor precisão e envolvem maior escalabilidade computacional. O método de extração de recursos que é diferente do método de seleção de recursos envolve o mapeamento do espaço original de recursos de dimensão superior para um conjunto de recursos de dimensão inferior que é mais informativo em relação à tarefa executada [144]. A vantagem das técnicas de extração de recursos é que as informações ocultas no conjunto de dados original podem ser recuperadas. Com base na operação, tanto o método de seleção de recursos quanto o método de extração de recursos são classificados no método de filtro

e método wrapper [142]. Segundo Lee [143] métodos de filtro são aqueles que realizam a seleção de variáveis-chave independente de qualquer método de classificação ou regressão. Esses métodos simplesmente analisam os dados de entrada com base em algumas estatísticas e determinam alguns recursos-chave.

Por outro lado, os métodos wrapper dependem da medida de precisão de um determinado método de computação suave e envolvem altos custos computacionais, mas apresentam melhor desempenho [145]. Correlação, F-score, regressão stepwise, análise de componentes principais (PCA) e muitos outros têm sido utilizados na literatura para selecionar o conjunto ideal de recursos.

Lee [143] desenvolveu uma abordagem híbrida de seleção de recursos combinando métodos de filtro e wrapper para prever a tendência do mercado de ações em dois estágios. No primeiro estágio, eles usaram as estatísticas do F-score como filtro para determinar o subconjunto ideal de um determinado conjunto de recursos. Na segunda etapa, eles aplicaram a técnica de classificação de máquina de vetor de suporte (SVM) como método de previsão de wrapper para gerar um conjunto de recursos-chave. Kao et al. [146] desenvolveram uma abordagem de previsão de preços de ações aplicando análise de componentes independentes não lineares (NLICA) para extrair os principais recursos conhecidos como componentes independentes (IC) do conjunto de dados de entrada e usando IC extraído como entrada para suportar a regressão vetorial (SVR). NLICA é um método de extração de características que se baseia na suposição de que os dados são agregação não linear de sinal de fonte latente e é usado para encontrar componentes independentes que contêm informações ocultas e são mais adequados para previsão de preços de ações. Reza et al. [47] usaram a técnica de seleção de características de correlação cruzada para escolher características importantes de 20 características e selecionar 13 características que são apropriadas para prever o mercado de ações. Thakur et al. [48] propuseram quatro modelos de predição híbridos combinando quatro abordagens de seleção de características diferentes para selecionar um conjunto ótimo de indicadores, como Correlação Linear (LC), Regressão Relevância (RR), Correlação de Rank (RC) e Random Forest (RF), com classificador de máquina de vetor de suporte proximal (PSVM) para previsão de tendência (alta ou baixa) no mercado de ações.

Eles avaliaram o desempenho do modelo proposto para 12 índices de ações diferentes, com base em certo número de métricas de desempenho. O desempenho obtido num conjunto de índices bolsistas de vários mercados internacionais

mostram que todos os modelos híbridos apresentam desempenho superior ao da técnica de previsão individual PSVM. A comparação entre os modelos propostos mostra que o RF-PSVM supera todas as outras abordagens de previsão. A maior precisão no conjunto de dados S&P BSE Sensex é alcançada quando 48 indicadores técnicos são selecionados. de Oliveira et al. [95] desenvolveram um modelo de rede neural para a previsão do comportamento futuro do preço de fechamento das ações. Eles realizaram uma análise de mercado para encontrar os parâmetros que regem o mercado de ações e encontraram 46 variáveis totais e realizam a correlação cruzada de todas as variáveis com o preço de fechamento para encontrar o subconjunto otimizado de variáveis contendo 18 variáveis. Asadi et al. [51],

Esfahanipour e Aghamiri [53], Hadavandi et al. [147, 97], Hsieh et al. [148] e Chang et al. [89] empregaram a análise de regressão stepwise (SRA) para escolher as variáveis importantes que aumentaram a precisão do modelo de previsão do mercado de ações. A técnica SRA encontra um conjunto de variáveis de entrada que têm mais efeitos nas variáveis de saída. Chang e Liu [52] aplicaram análise de regressão passo a passo e técnicas de agrupamento K-means para melhorar o desempenho do modelo proposto. Dai et al. [54] usaram a análise de componentes independentes não lineares (NLICA) para transformar os dados de séries temporais no espaço de características composto por componentes independentes (ICs) que descrevem as principais informações dos dados originais.

Em seguida, os ICs são usados como entrada da rede neural para construir o modelo de previsão denominado NLICA-BPN. Os resultados da simulação mostram que o modelo de previsão proposto melhorou o desempenho da rede neural e também superou a abordagem PCA-BPN, LICA-BPN e BPN único. Wang e Wang [76] propuseram o uso da análise de componentes principais (PCA) em combinação de rede neural funcional efetiva no tempo estocástico (STNN) para analisar séries temporais de preços de ações. No modelo proposto, eles primeiro implicaram o PCA para retirar os componentes principais (PC) do conjunto de dados de entrada e, em seguida, usar esses componentes como entrada para o STNN. Eles compararam o resultado do modelo PC-STNN com o modelo de rede neural de retropropagação (BPNN), modelo PC-BPNN e STNN e mostraram que o desempenho de previsão do modelo proposto é melhor que outros. Niaki e Hoseinzade [80] empregaram um desenho fatorial e conceito de agrupamento para conduzir um desenho de experimento a fim de determinar os fatores mais influentes entre 27 variáveis financeiras e econômicas. Os fatores estatisticamente significativos selecionados através do planejamento de experimentos são usados como entrada para a rede neural artificial (RNA) para prever a movimentação diária do índice S&P 500. Os resultados do estudo mostram que a metodologia proposta tem um desempenho eficazmente melhor do que a abordagem buy and hold. Qiu et al. [56] utilizaram superfícies fuzzy para extrair um conjunto efetivo de variáveis de entrada do conjunto original de variáveis. Inthachot et al. [107] usaram algoritmo genético para encontrar o subconjunto efetivo de características de um conjunto de 44 características e usaram o conjunto otimizado de características como entrada para a rede neural. Zahedi e Rounaghi [149] realizaram a previsão da bolsa de valores de Teerã aplicando o modelo RNA e análise de componentes principais (PCM). O PCM é usado neste estudo para extrair os principais recursos de 20 variáveis contábeis. Gocken et al. [108] utilizaram algoritmo genético (GA) e busca de harmonia (HS) para selecionar as características mais apropriadas para o modelo de previsão do mercado de ações turco. Neste estudo, eles inicialmente consideraram 45 indicadores técnicos e ao final selecionaram 26 e 23 variáveis por modelo GA e HS respectivamente. Tan et al. [102] e Weng et al. [127] utilizaram o PCA para reduzir a dimensionalidade do conjunto de dados original e obter vários componentes que fornecem informações mais valiosas. Laboissiere et al. [125] propuseram o uso combinado de análise de correlação e

modelo multi-layer perceptron (MLP) para aprender os recursos de entrada que têm maior impacto no mercado de ações para lidar com o problema de previsão de preços máximos e mínimos diários das ações de três empresas de distribuição de energia no Brasil.

Lei [59] propôs um método integrado combinando conjunto bruto (RS) e rede neural wavelet (WNN) para aumentar a precisão na previsão da tendência do mercado de ações. Nesse trabalho, primeiramente o RS é aplicado para reduzir as dimensões do conjunto de recursos de entrada, além de determinar a arquitetura ótima do WNN. Em seguida, os recursos selecionados são fornecidos como entrada para o modelo de previsão WNN otimizado para prever a tendência em cinco índices do mercado de ações. Os resultados da simulação mostram que ao reduzir os atributos por meio de RS a precisão da previsão de WNN pode ser melhorada significativamente para modelar o problema de previsão. Pimenta et al. [126] propôs uma abordagem de seleção de características com base em regras de negociação geradas a partir de indicadores técnicos em seu trabalho de pesquisa usando programação genética.

4.5 Modelos de previsão

A previsão de séries temporais de preços de ações é uma das tarefas desafiadoras em séries temporais e domínio CI [2]. Os modelos de previsão dependem da escolha da tarefa realizada pelos autores, ou seja, se eles desejam prever a tendência (para cima ou para baixo) no mercado de ações que é modelado como tarefa de classificação ou previsão de valor numérico, ou seja, preço da ação ou índice de ações que é modelado como tarefa de regressão. Nos últimos anos, foram propostas várias abordagens que podem ser aplicadas para a previsão de séries temporais do mercado de ações. Neste trabalho de pesquisa, nosso foco está em abordagens centrais de CI, como rede neural, algoritmo genético, lógica difusa e outras abordagens de computação evolucionária.

4.5.1 Redes Neurais Artificiais (RNAs)

A RNA é uma das técnicas eficientes para prever o mercado de ações, pois não compreende fórmulas complexas em comparação com os modelos tradicionais lineares e não lineares [150]. As RNAs tornaram-se uma técnica popular usada para previsão do mercado de ações desde a década passada. O amplo uso de RNAs para previsão de séries temporais do mercado de ações se deve à capacidade das RNAs de lidar com dados que são caracterizados por não linearidade, componentes polinomiais de alta frequência e descontinuidade [77]. As RNAs são técnicas auto-organizadas, orientadas a dados e auto-adaptativas que têm a capacidade de adotar a não linearidade de séries temporais sem considerar qualquer suposição estatística sobre os dados [151]. Muitos tipos de RNAs têm sido empregados na literatura para a previsão de séries temporais do mercado de ações. Kara et al. [60] realizam a previsão de tendência ascendente e descendente no índice ISE National 100 usando rede neural artificial (ANN) e máquina de vetor de suporte (SVM). Ao comparar o desempenho de

essas técnicas e mostraram que a precisão de predição do modelo ANN é maior do que o modelo SVM. Nos experimentos apresentados em Niall et al. [75], a rede neural feed-forward foi usada para prever o preço de fechamento do índice DJIA no dia seguinte. Eles iniciaram o experimento alimentando o trabalho da rede neural com o preço de abertura do dia atual e o preço de abertura anterior de 5 dias do DJIA. Em seguida, eles aumentam gradualmente a entrada introduzindo a média móvel de 10 e 30 dias (MA), gradientes diários de 5 dias anteriores de DJIA, preço do petróleo bruto, preço do petróleo bruto e dados de moeda, petróleo bruto, dados de moeda e gradiente de DJIA. Os resultados do experimento mostram que a rede neural treinada em 31 variáveis, incluindo fatores externos, resultou em um retorno sobre o investimento (ROI) de 23,5% ao ano em um momento em que o índice DJIA aumentou 13,03% ao ano. Dhar et al. [152] usam uma ANN para prever 1 dia antes do preço de fechamento das ações do mercado de ações indiano. Eles usaram o algoritmo de retropropagação para treinar redes neurais de três camadas. Neste artigo, o objetivo dos autores foi encontrar os melhores parâmetros de RNAs realizando vários experimentos com diferentes combinações de parâmetros de RNAs, como número de camadas ocultas, número de nós em cada camada e taxa de aprendizado. Vanstone et al. [105] empregou o Perceptron multicamada (MLP) para desenvolver um sistema de negociação automática para o mercado de ações australiano. Eles usaram quatro indicadores fundamentais, como retorno sobre o patrimônio líquido (ROE), valor contábil, índice de pagamento de dividendos e índice preço/lucro (P/L) como entrada para o MLP. A saída da rede neural é um sinal cuja força dá o retorno esperado em 1 ano. Ticknor [121] implementou uma rede neural feedforward (FFNN) combinada com regularização bayesiana para prever o movimento do mercado de ações. Na rede Bayesiana o peso entre as camadas da rede é considerado como variável aleatória e assim suas funções de densidade são representadas usando a regra de Bayes. Durante o treinamento, os pesos são ajustados encontrando a função densidade de probabilidade de cada peso.

A técnica de previsão proposta minimiza o impacto de overfitting e overtraining e melhora a precisão da previsão e a generalização da rede. Mabu et al. [122] investigaram o uso do paradigma ensemble learning combinando uma técnica evolutiva baseada em regras e uma rede neural artificial para tomar decisões de compra ou venda na negociação de ações. Neste artigo, uma programação de rede genética foi usada para gerar um grande número de conjuntos de regras de ações e o Perceptron multicamada (MLP) é usado para selecionar a melhor regra para tomar uma boa decisão no mercado de ações. Guresen et al. [150] avaliam o desempenho de diferentes modelos de redes neurais para predição de índices do mercado de ações. Nesse estudo, eles usaram perceptron multicamada (MLP), rede neural artificial dinâmica (DAN2) e rede neural híbrida combinando heterocedasticidade condicional autorregressiva (GARCH) e heterocedasticidade condicional autorregressiva exponencial (EGARCH) com MLP. Liu

e Wang [77] apresentaram uma abordagem preditiva para prever a flutuação de preços no mercado de ações que é baseada na rede neural Legendre e na função de força de tempo aleatório (LNNRT). Eles também introduziram o movimento browniano no modelo proposto para modelar o efeito do movimento aleatório. Adebisi et al. [153] compararam a capacidade de previsão da abordagem ANN com a média móvel integrada autorregressiva convencional Box-Jenkins (ARIMA) e o modelo ANN para a previsão da bolsa de valores de Nova York. Os resultados do experimento revelam que o modelo de rede neural tem um desempenho melhor do que o modelo ARIMA. Chopra et al. [66] examinaram a capacidade da ANN de prever o mercado de ações indiano antes e depois da desmonetização. Dentro

Neste artigo, a rede neural de retropropagação (BPNN) é treinada pelo algoritmo de Levenberg-Marquardt. Patel et al. [68] realizam a comparação de quatro técnicas de previsão de tendências, nomeadamente rede neural artificial (RNA), classificador de baías ingênuas, floresta aleatória e máquina de vetores de suporte (SVM) para prever a direção do movimento de duas ações e dois índices do mercado de ações indiano. Neste estudo, eles consideraram dois cenários para entrada. No primeiro cenário, eles usaram dez indicadores técnicos e no segundo cenário eles representam esses indicadores técnicos como dados determinísticos de tendência. Zhong e Enke [84] aplicaram a rede neural artificial (RNA) juntamente com três versões da análise de componentes principais (PCM) como um modelo de classificação para prever o movimento diário de retorno do mercado de ações. Wang et al. [100] desenvolveram um modelo de previsão (ST ERNN) que integra a rede neural recorrente de Elman (ERNN) com função efetiva de tempo estocástico para prever índices do mercado de ações. Neste artigo, eles analisaram o modelo proposto com a distância invariante de complexidade (CID), regressão linear e CID multiescala (MCID) e compararam o resultado do modelo de previsão com a rede neural de retropropagação (BPNN), rede neural recorrente de Elman e a rede neural efetiva de tempo estocástico (STNN). Os resultados do experimento revelam que o modelo proposto apresenta desempenho superior entre outras redes neurais na previsão de séries temporais de preços de ações. Dash e Dash [70] desenvolveram um sistema de apoio à decisão combinando a capacidade de aprendizado de uma rede neural artificial de link funcional eficiente computacional (CEFLANN) com o conjunto de regras criadas a partir de indicadores técnicos para geração de sinais de negociação. Neste artigo, o método Extreme Learning Machine (ELM) é usado para treinar a rede CEFLANN em vez do algoritmo tradicional de retropropagação e a capacidade de previsão do método proposto foi comparada com outras técnicas de aprendizado de máquina. Kristjanpoller e Minutolo [120] desenvolveram um modelo híbrido de previsão de volatilidade combinando rede neural artificial (RNA), heterocedasticidade condicional autorregressiva generalizada (GARCH), análise técnica e análise de componentes principais para prever a volatilidade do preço do bitcoin. Sheta et al.

[86] explorou a aplicação de rede neural artificial (RNA), máquina de vetor de suporte (SVM) e modelo tradicional de regressão linear múltipla (MLR) para construir um modelo de previsão para previsão do índice de ações S&P 500 e compararam o desempenho de três abordagens. Neste estudo, o SVM supera os modelos MLR e ANN. Pang et al. [101] desenvolveram uma abordagem de rede neural inovadora, propondo a rede neural de memória de longo prazo e longa duração profunda (LSTM) com camada incorporada e a rede neural de memória de longa duração com codificador automático para previsão do mercado de ações. Neste artigo, eles introduziram a ideia de vetor de ações em que a entrada não é um único índice de ações, mas um grupo de índices de ações. Nos dois modelos, a camada embutida e o codificador automático são usados para formar o vetor dos dados do mercado de ações. Os resultados da simulação demonstram que o LSTM profundo com camada incorporada fornece melhor precisão de previsão do que o LSTM com codificador automático. Fischer e Krauss [90] implantaram redes de memória de longo prazo (LSTM), uma classe de redes neurais recorrentes cuja estrutura de rede é composta por pelo menos um ciclo e a camada oculta é caracterizada por células de memória para prever o movimento direcional em tempo financeiro Series. Resultados de previsão do método proposto e técnicas de classificação sem memória, como rede neural profunda, floresta aleatória e classificador de regressão logística, revelam que as redes LSTM fornecem precisão superior. Shynkevich et al. [124] utilizaram classes de redes neurais artificiais (RNA), K-nearest neighbor (KNN) e máquinas de vetor de suporte (SVM) para investigar o impacto do comprimento da janela de entrada nas tendências futuras dos preços das ações. O comprimento da janela de entrada é um parâmetro de intervalo de tempo que indica quantos valores passados em séries temporais de preços de ações podem ser utilizados para calcular os indicadores técnicos que são fornecidos como entrada para modelos de previsão para prever. Os resultados mostram que o desempenho máximo de previsão é alcançado quando o comprimento da janela é aproximadamente igual ao horizonte de previsão, ou seja, n dias à frente. Wang e Wang [49] sugeriram o uso do trabalho de rede neural de força de tempo estocástico (STNN) em combinação com a posição empírica de decomposição de modo (EMD) para melhorar a precisão da previsão do movimento do preço das ações. Nesta pesquisa, a EMD, que é uma técnica de processamento, é utilizada para extrair todos os componentes oscilatórios presentes nas séries temporais dos preços das ações, decompondo as séries temporais originais em várias subséries de alta e baixa frequência conhecidas como funções de modo intrínseco (IMFs). O modelo de previsão STNN é aplicado para cada FMI para obter o valor previsto de cada subsérie e o valor previsto de cada subsérie é agregado para obter a previsão da série temporal original do preço das ações. Seo et al. [93] combinaram rede neural artificial com diferentes versões de modelos de dassticidade condicional autorregressiva generalizada (GARCH) e tendências domésticas do Google (GDTs) para prever a volatilidade das séries temporais d

Uma tendência doméstica do Google são os serviços de código aberto fornecidos pelo Google para analisar os diversos setores de finanças e economia. Neste trabalho, os autores primeiro estimaram a volatilidade usando a família do modelo GARCH e, em seguida, usaram a saída da família GARCH e GDTs como entrada para a rede neural para previsão precisa das volatilidades do índice S&P500. Mo et al. [103] introduziu uma conexão do tipo expoente na rede neural de retropropagação (BPNN) para criar uma rede neural de retropropagação de expoente (EBPNN) para prever correlações cruzadas entre os índices compostos da bolsa de valores chinesa de xangai (SSE) e da bolsa de valores de Shenzhen (SZSE) no mercado de ações da China. No EBPNN a informação é processada realizando o produto escalar do expoente do vetor de entrada e do vetor de peso.

Esta pesquisa é motivada pelo conceito de que a função do tipo exponencial captura mais flutuações em dados não estacionários. O resultado dos experimentos revela que a saída EBPNN realiza BPNN. Weng et al. [127] desenvolveram um sistema especialista baseado em um conjunto de métodos de aprendizado de máquina, como rede neural artificial, regressão vetorial de suporte, árvore de regressão impulsionada e regressão florestal aleatória que utiliza os recursos de várias fontes on-line para prever preços de ações de curto prazo. A ideia-chave deste trabalho é incorporar dados de várias fontes, como preços históricos de ações, indicadores técnicos, artigos sobre determinadas ações publicadas em notícias, pesquisa no Google sobre determinadas ações e número de páginas da Wikipedia visitadas para ações relacionadas. Após a coleta e pré-processamento dos dados, os autores aplicaram a análise de componentes principais para obter as características efetivas que são usadas como entrada para o modelo de previsão. Os resultados mostraram que o uso de recursos de fontes online melhorou a precisão dos métodos de ensemble. Gocken et al. [128] combinação de busca de harmonia (HS) com a arquitetura de rede neural artificial (ANN), máquina de aprendizado extremo (ELM), rede neural recorrente Jordan (JRNN), máquina de aprendizado extremo recorrente (RELM), árvore de regressão (RT), generalizada modelo linear (GLM) e regressão de processo gaussiano (GPR) para previsão de preços de ações de curto e médio prazo. Neste trabalho, o HS é utilizado para seleção de características e ajuste dos parâmetros de vários modelos híbridos propostos. Os parâmetros a serem otimizados são função de transferência, número de neurônios ocultos e de contexto em diferentes modelos. Zhou et al. [94] desenvolveram uma nova estratégia de dois estágios baseada na decomposição de modo empírico (EMD) e na rede neural baseada em máquina de faturação (FNN) denominada EMD2FNN para prever a tendência do mercado de ações. No primeiro estágio, um método eficiente para lidar com dados não estacionários, o EMD, é usado para reduzir os dados da série temporal do preço das ações originais em um número de componentes conhecidos como funções de modo intrínseco (IMFs), que contém componentes oscilatórios dentro de um intervalo estreito. Na segunda etapa, cada FMI extraído é fornecido como entrada para FNN para prever

preço futuro das ações. O resultado do experimento do modelo proposto fornece melhor desempenho em relação a outros modelos, como o modelo de rede neural (NN), o modelo de rede neural baseado em máquina de faturação (FNN), o modelo de rede neural de propagação reversa baseada em redução de ruído de wavelet (WDBP), o modelo de rede neural baseada em decomposição em modo empírico (EMD2NN).

4.5.2 Lógica Fuzzy

Abordagens de lógica fuzzy têm sido aplicadas por muitos autores com taxa de sucesso relativamente alta para modelagem e previsão de séries temporais de preços de ações. Hadavandi et al. [147] propuseram uma abordagem combinada integrando sistema fuzzy genético (GFS) e rede neural artificial (RNA) para criar um sistema inteligente para previsão de preços de ações. Eles aplicaram a análise de regressão passo a passo para determinar os principais recursos que têm mais influência no preço das ações e os recursos selecionados são categorizados em vários clusters usando o mapa auto-organizado (SOM). Finalmente, todos os clusters são usados como entrada para o GFS para extração da base de regras. Os resultados mostraram que o modelo proposto apresenta melhor desempenho em comparação com outras abordagens como ARIMA e RNA. Chang e Liu [52] desenvolveram uma abordagem baseada em regras fuzzy do tipo Takagi-Sugeno-Kang (TSK) para previsão do mercado de ações. Eles aplicaram o recozimento simulado (SA) para determinar o conjunto de melhores parâmetros do sistema fuzzy. Para justificar a precisão da previsão, eles mostraram que o sistema de regras fuzzy TSK tem um desempenho melhor do que a rede neural de retropropagação (BPNN) e a técnica de regressão múltipla. Esfahanipour e Aghamiri [53] implementaram o sistema de inferência Neuro-Fuzzy adotado em um sistema de base de regras fuzzy do tipo TSK para previsão do mercado de ações e aplicaram o agrupamento Fuzzy C-Mean para determinar o número de regras. Boyacioglu e Avci [61] examinaram a capacidade do sistema de inferência fuzzy baseado em rede adaptativa (ANFIS) para prever o retorno do mercado de ações. Os resultados dos experimentos mostram que o ANFIS pode ser utilizado de forma eficiente para resolver problemas de previsão do mercado de ações. Pathak e Shetty [64] geraram uma base de regras fuzzy para previsão de fé de ações (alta ou baixa) que é a força de recomendação para compra ou venda de ações. O modelo proposto foi implementado em três módulos. No primeiro módulo, eles usaram algoritmos de aprendizado de máquina para prever o preço de fechamento das ações. No segundo módulo, eles obtêm o valor do sentimento das últimas notícias sobre cada ação. No terceiro módulo, as saídas de ambos os módulos são usadas como entrada para o módulo de lógica fuzzy para geração da base de regras fuzzy. Zarandi et al. [136] aplicaram um sistema fuzzy tipo 2 para previsão de preços de ações usando indicadores fundamentais e técnicos como entrada para o modelo proposto. Neste estudo, os parâmetros da função de pertinência são refinados por algoritmo genético. Liu et al. [57] investigaram o benefício do sistema neuro-fuzzy tipo 2 para modelar o problema de

segmentados em clusters usando o método de clustering de autoconstrução e, em seguida, uma base de regra da regra TSK tipo 2 é gerada a partir de cada cluster. Os parâmetros associados ao modelo neuro fuzzy tipo 2 são ajustados por otimização de enxame de partículas e estimativa de mínimos quadrados. Zarandi et al. [123] apresentaram um sistema multiagente fuzzy de quatro camadas (FMAS) para criar um sistema inteligente híbrido que combina os múltiplos agentes inteligentes para prever o preço das ações no dia seguinte. A primeira camada é usada para coletar informações relevantes sobre o domínio do problema usando conhecimento especializado. A segunda camada é dedicada à seleção de recursos e formação de clusters. O papel de

A terceira camada é construir um modelo para todos os clusters usando o sistema fuzzy genético e otimizar o modelo construído para selecionar o melhor sistema fuzzy para cada cluster. O objetivo da quarta camada é analisar o modelo e a representação do conhecimento. Svalina et al. [111] criaram um modelo de predição que emprega um sistema de inferência neuro-fuzzy adaptativo (ANFIS) para predição do preço de fechamento do mercado de ações, com 5 dias de antecedência, individualmente para cada dia. Dash e Dash [69] propuseram um sistema de inferência fuzzy recorrente auto-evolutivo (SERFIS) para aumentar o poder de predição do sistema neuro-fuzzy tradicional. O modelo é criado usando o sistema fuzzy de primeira ordem Takagi-Sugeno-Kang (TSK) com duas variantes de conexão de realimentação, ou seja, fornecendo a força de franja da regra fuzzy de volta para ele e introduzindo loops de realimentação de atraso de tempo na camada de saída. Neste artigo, os autores propuseram uma busca de harmonia diferencial modificada (MDHS) para otimizar o feedback loop, parâmetros antecedentes e consequentes da abordagem proposta. A fim de comparar o resultado do modelo proposto, outra rede, a rede neural artificial de link funcional recorrente (RCEFLANN), também é apresentada neste artigo. Su e Cheng [116] apresentaram um novo modelo de predição de preços de ações empregando o sistema de inferência neurofuzzy adaptativo (ANFIS) e técnicas de seleção de recursos não lineares integrados (INFS). Este estudo utilizou o método INFS para selecionar os principais indicadores técnicos que são utilizados como entrada para o modelo de previsão ANFIS para obter o valor previsto primário e, por fim, o modelo de expectativa adaptativa é usado para aumentar ainda mais o desempenho do modelo de previsão. Sadei et al. [87] inicialmente usaram lógica de série temporal difusa diferencial para prever tendências nos dados do mercado de ações e, em seguida, introduziram uma nova técnica evolutiva chamada algoritmo competitivo imperialista (ICA) para melhorar ainda mais a precisão da previsão do modelo inicial, otimizando os parâmetros do modelo. Chouemouziadis e Chatzoglou [112] apresentaram um modelo fuzzy de negociação de curto prazo usando o sistema fuzzy Mamdani e uma mistura de indicadores técnicos comumente usados e raramente usados para gerar sinais de negociação no mercado de ações. Jiang et al. [88] apresentaram um sistema de lógica fuzzy de intervalo tipo 2 (IT2FLS) para prever índices de ações com base em séries temporais fuzzy e um mapa de relacionamento de lógica fuzzy (FLRM). Neste artigo, o modelo proposto funciona em cinco etapas.

O primeiro passo envolve encontrar a variação dentro da série temporal.

A segunda etapa inclui a fuzzificação da série temporal e a definição do conjunto fuzzy. Na terceira etapa, são definidos os conjuntos fuzzy de intervalo de entrada tipo 2 (IT2FSs) e os intervalos de saída do sistema de lógica fuzzy de intervalo tipo 2 (IT2FLS). A quarta etapa inclui a criação de relacionamentos lógicos difusos (FLRs) e o mapa de relacionamentos lógicos difusos (FLRM) e, finalmente, prever os valores futuros. Zang et al. [118] sugeriram uma nova abordagem baseada em lógica fuzzy e combinação de gráfico de visibilidade e previsão de link para aumentar a precisão do problema de previsão de séries temporais. No método proposto, a série temporal é primeiramente transformada em gráfico de visibilidade, então a técnica de previsão de link é aplicada para obter a previsão inicial e, finalmente, a lógica fuzzy é utilizada para aumentar ainda mais a precisão da previsão determinando regras fuzzy baseadas na relação entre dados históricos. Com base na comparação entre estudos anteriores, os autores mostraram que o método proposto tem melhor capacidade de predição. Cheng e Yang [58] propuseram o uso do modelo fuzzy de séries temporais e indução de regras de conjunto aproximado para prever o índice de ações. Neste trabalho, os autores aplicaram o algoritmo de indução de regras de conjunto aproximado, LEM2 (Learning from Examples Module version 2) para extrair regras de previsão de venda ou compra de séries temporais para obter a previsão inicial. Depois disso, o modelo de expectativa adaptativa é utilizado para melhorar o desempenho da previsão inicial. O modelo de expectativa adaptativa é um modelo de previsão razoável na previsão de séries temporais. Na previsão de séries temporais de preços de ações, usando o modelo de expectativa adaptativa, os preços futuros das ações são gerados pelo último período do preço das ações e pelo erro de previsão para o último período. Chander [131] formulou o modelo de predição de séries temporais de preços de ações baseado na fusão da transformada wavelet (WT) com o sistema adaptativo de inferência neurofuzzy (ANFIS). Neste trabalho a transformada wavelet de Haar é utilizada para dividir os dados da série temporal normalizada em dois componentes viz. componentes de aproximação e coeficientes de detalhamento para construção do vetor de características que é fornecido como entrada do modelo ANFIS para gerar o preço futuro das ações como resultado do modelo proposto. Os resultados da comparação do modelo proposto com RNA e híbrido de RNA com transformada wavelet mostram a superioridade do modelo.

4.5.3 Algoritmos Genéticos (GA)

O AG tem sido efetivamente utilizado na literatura para aumentar a precisão de previsão de modelos de previsão. Shahrokh et al. [51] sugeriram um paradigma baseado em algoritmo genético (AG) para construir um modelo de classificação que possa encontrar regras de negociação a partir de indicadores técnicos. Eles usaram o GA para otimizar os pesos iniciais das redes neurais e o algoritmo de retropropagação de Levenberg-Marquardt (LMBP) para treinar o feed para a rede neural ward. O resultado mostra que o modelo de previsão proposto tem capacidade para lidar com as flutuações do mercado de ações e fornece bons resultados de previsão.

Chang et al. [78] construir um classificador associativo propondo

abordagem de algoritmo genético (GA) para gerar sinais de venda e compra. O modelo proposto determina a regra de negociação a partir de indicadores técnicos. Lee e Tong [154] desenvolveram um modelo de previsão híbrido combinando a média móvel integrada autorregressiva (ARIMA) com a programação genética (GP) para prever séries temporais não lineares. ARIMA é aplicado para lidar com a parte linear da série temporal e GP é utilizado para lidar com a parte não linear da série temporal para aumentar a precisão. Para testar a precisão do modelo híbrido proposto, os autores usaram três séries temporais e mostram que o modelo híbrido pode ser melhor utilizado para problemas de previsão de séries temporais. Chang et al. [155] desenvolveram um novo modelo usando algoritmo genético para ajustar o peso da conexão da rede neural parcialmente conectada para prever a tendência no mercado de ações. Huang [156] desenvolveu um paradigma para o problema de seleção de ações usando regressão vetorial de suporte (SVR) e algoritmo genético (GA). Neste estudo, o SVR é utilizado para previsão de retorno da coleção de ações e as ações de melhor desempenho são selecionadas para criação de portfólio. O GA é usado para obter os melhores parâmetros de SVR. Chien et al. [83] construir um modelo de classificação de regras de classificação associativa (ACR) baseado em algoritmo genético (GA) para descobrir regras de negociação a partir de indicadores técnicos que geram sinal de compra ou venda. Chang e Lee [115] incorporaram o processo de decisão de Markov e o algoritmo genético para criar um sistema de apoio à decisão para a melhor estratégia de investimento em ações. Neste estudo, o processo de decisão de Markov é usado para ajudar os investidores a escolher o timing certo e as estratégias de negociação para vender ou comprar ações e o algoritmo genético é usado para ajudar os investidores a selecionar as ações de maneira ideal e alocação de capital. Essas duas estratégias são combinadas para lidar com problemas de portfólio e proporcionar alto retorno sobre o investimento aos investidores. Mabu et al. [122] aplicaram um algoritmo evolutivo baseado em grafos denominado programação de rede genética (GNP) para extrair um número significativo de regras de negociação de ações a partir de indicadores técnicos. Essas regras de negociação de ações são usadas para tomar decisões sobre o melhor momento para vender ou comprar ações. Neste artigo, o multi-layer perceptron (MLP) é usado para selecionar os conjuntos de regras eficazes para negociação de ações de vários conjuntos de regras gerados pelo GNP.

Kim et al. [109] desenvolveram um sistema de negociação híbrido inteligente para descobrir as regras de negociação aplicando análise de conjunto aproximado e algoritmo genético (GA). Neste estudo, o conjunto aproximado extrai a regra de negociação de determinados indicadores técnicos e o GA é usado para procurar pontos de corte ótimos para discretização de dados e encontrar um subconjunto de atributos para descobrir a regra de negociação subótima. Essas regras de negociação ideais são utilizadas para gerar o sinal de negociação de compra ou venda. Pimenta et al. [126] formularam um método de investimento automatizado baseado em análise técnica, seleção de recursos, filtragem de outliers, programação genética (GP) e conjunto para tomar três decisões de investimento, como comprar ou vender ou manter ações da empresa. Neste trabalho, primeiramente, a filtragem de outliers é empregada para detectar e remover as observações que não obedecem às características gerais.

de dados do mercado de ações e, em seguida, o GP é usado para gerar regras de compra e regras de venda a partir da associação de indicadores técnicos selecionados e as regras geradas são usadas para criar o conjunto e, finalmente, o conjunto é aplicado para identificar uma das três decisões de negociação.

4.5.4 Modelo de Previsão Híbrida

Em técnicas de previsão híbridas, combinar abordagens centrais de IC tornou-se um procedimento útil para aumentar a precisão do modelo de previsão, combinando vantagens de abordagens individuais e evitando desvantagens de certas técnicas individuais. Cheng et al. [157] recomendaram que os algoritmos híbridos são mais eficientes em melhorar a precisão do aprendiz de base individual. Nesta seção, apresentamos vários modelos de previsão híbridos aplicados ao mercado de ações de previsão.

4.5.4.1 RNA híbrida Nesta seção apresentamos diversos artigos que se baseiam na hibridização da rede neural artificial com outras técnicas. Reza et al. [47] propuseram o sistema multiagente de rede neural de morcego híbrido (BNNMAS) para prever o preço das ações. Neste artigo, o modelo proposto funciona em um cenário multiagente de 4 camadas. Na primeira camada foi realizada a coleta de dados e a tarefa de pré-processamento de dados. Na segunda camada, a técnica de correlação cruzada e a seleção de atraso foram usadas para escolher o recurso relevante e o melhor intervalo de tempo.

Dos 20 indicadores fundamentais e técnicos, 13 características importantes foram selecionadas para a tarefa de previsão. Na terceira camada o algoritmo bat (BA) foi utilizado como algoritmo de aprendizado da rede neural de três camadas e a função de base radial (RBF) como função de ativação para a camada oculta e o quarto agente é usado para testes de validação. O desempenho do BNNMAS foi comparado com outros métodos viz. rede neural de algoritmo genético (GANN) e rede neural de regressão generalizada (GRNN). A estatística de erro percentual absoluto médio (MAPE) mostra superioridade do BNN MAS sobre outros métodos. Patel et al. [63] propuseram abordagens de fusão em dois estágios. No estágio inicial, o Support Vector Regression (SVR) é usado para prever o valor futuro dos indicadores técnicos. Artificial Neural Network (ANN), SVR e Random Forest (RF) são usados no último estágio da fusão resultando em modelos de predição de fusão SVR-ANN, SVR-SVR e SVR-RF para prever o valor futuro do preço de fechamento.

A precisão de previsão dos modelos híbridos propostos foi comparada com os cenários de estágio único onde ANN, SVR e RF são usados individualmente. O resultado dos experimentos mostra que os modelos de previsão de dois estágios superam os modelos de previsão de estágio único. Bisoi e Dash [135] apresentaram uma rede neural dinâmica baseada em resposta ao impulso infinito (IIR) para prever o índice de preços de ações de 1 dia antes a 30 dias antes de quatro ações distintas, a saber Bombay stock exchange (BSE), IBM stock, RIL

estoque de porções. Para treinar a DNN foram utilizados quatro algoritmos de aprendizado diferentes, como algoritmo de aprendizado recorrente em tempo real (RTRL), avaliação diferencial (DE), kalman filter sem cheiro (UKF) e uma abordagem híbrida DEUKF. Do resultado conclui-se que o DEUKF apresenta alto desempenho para todos os índices bolsistas em comparação com DE, UKF e RTRL. A eficácia de DNN e DEUKF foi comparada com outras técnicas de redes neurais modificadas como a rede neural wavelet linear local (LLWNN), a RBFNN linear local (LLRBFNN) e a FLANN de Laguerre. Shen et al. [158] aplicaram a rede neural funcional de base radial (RBFNN) para treinar os dados históricos do mercado de ações da bolsa de valores de Xangai e empregaram o algoritmo artificial fish swarm (AFSA) para otimizar os parâmetros da RBFNN. Neste artigo, para aumentar a precisão da previsão, eles usaram o AFSA para otimizar a largura e o peso do centro do algoritmo de agrupamento K-means durante o treinamento do RBFNN. Para demonstrar a eficácia do modelo proposto, os autores compararam os resultados de previsão com o RBFNN, algoritmo de retropropagação (BP), ARIMA e máquina de vetor de suporte usados individualmente e outros modelos híbridos de algoritmo genético (GA) e otimização de swam de partículas (PSO) com RBFN.

Os resultados mostram que o modelo proposto supera outros modelos. Pullido et al. [106] desenvolveram um método híbrido composto de otimização de enxame de partículas (PSO) e rede neural ensemble com agregação difusa para previsão de séries temporais complexas. Neste artigo, o PSO é empregado para ajustar os parâmetros das redes neurais e para determinar o número otimizado de redes neurais individuais usadas para criar uma rede neural de conjunto. Eles usaram o tipo 2 fuzzy para combinar a saída da rede neural individual que forma o conjunto. Abdul-Sal et al. [137] realizaram as comparações do algoritmo de evolução diferencial (DE) e otimização de enxame de partículas (PSO) na otimização dos parâmetros da rede neural feedforward (FFNN) que é utilizada para prever os preços diários das ações. A comparação entre as duas técnicas de otimização foi feita com base na precisão da previsão, velocidade de convergência e capacidade de generalização. O resultado deste estudo mostra que ambas as técnicas de otimização evitam o problema dos mínimos locais. A técnica DE converge para mínimos globais mais rapidamente do que o PSO e o DE tem um desempenho melhor do que o PSO. Zhang e Wu [79] integraram a rede neural de retropropagação (BPNN) e a otimização da quimiotaxia bacteriana (IBCO) para estabelecer um modelo de previsão que pode prever com eficiência o índice de ações do índice S&P 500. O modelo proposto tem sido usado tanto para previsão de índice de ações de curto prazo (dia seguinte) quanto de longo prazo (15 dias). O erro quadrático médio calculado a partir do experimento revela que o modelo BP-IBCO supera o modelo BPNN tradicional. Feng e Chou [113] desenvolveram uma abordagem de previsão neural artificial combinando análise de regressão passo a passo (SRA), base radial

rede neural funcional (RBFNN) e otimização de enxame de partículas com base recursiva (RPSO). SRA é usado para filtragem de dados, ou seja, para determinar características importantes e RPSO, que é um algoritmo de aprendizado híbrido construído combinando PSO e algoritmo de aprendizado recursivo de mínimos quadrados (RLS) foi aplicado para extrair os parâmetros apropriados da técnica de previsão RBFNN. Hsieh et al. [148] propuseram uma abordagem integrada combinando a transformada wavelet (WT), rede neural recorrente (RNN) e algoritmo de colônia artificial de abelhas (ABC) para previsão do mercado de ações. Neste estudo, eles usaram o WT para eliminar o ruído das séries temporais do mercado de ações e o algoritmo ABC é empregado para ajustar o peso e os vieses do RNN. Hongping et al. [81] apresentaram o algoritmo de seno cosseno melhorado (ISCA) para ajustar os parâmetros da rede neural de retropropagação (BPNN) para prever a direção do preço de abertura das ações de dois índices de ações dos EUA, a saber, S&P 500 e DJIA. Neste artigo, eles realizaram duas variantes de previsão, ou seja, a previsão do Tipo I sem considerar os dados de tendências do Google e a previsão do Tipo II, levando em consideração os dados de tendências do Google. Os resultados do experimento revelam que as tendências do Google podem ser usadas de forma eficiente para prever a tendência do índice do mercado de ações. Senapati et al. [65] apresentaram um modelo híbrido inteligente para previsão de preço de ações aplicando rede neural adalina e otimização de enxame de partículas modificado. Neste artigo, o PSO é empregado para obter os pesos. O desempenho do modelo proposto foi comparado com outros modelos híbridos, como Bayesian-ANN, medição de intervalo e otimização de enxame de partículas multi enxame caótico (CMS-PSO). Os resultados do estudo mostram a superioridade do modelo proposto. Chiang et al. [85] desenvolveram um paradigma adaptativo de suporte à decisão de negociação de índices de ações que integra a otimização de swam de partículas (PSO) com rede neural artificial para prever a direção do movimento do índice de ações. Este modelo é usado para ajustar séries temporais de preços de ações de várias ações em vez de ações específicas, adaptando as entradas e o modelo de previsão. Os resultados da simulação mostram que os comerciantes podem gerar lucros mais altos usando o sistema de apoio à decisão proposto. Rout et al. [71] adotaram várias técnicas de otimização evolutiva, como otimização de enxame de partículas (PSO), evolução diferencial (DE) e PSO baseado em pesquisa aleatória moderada híbrida (HMRPSO) para otimizar o peso de diferentes variantes de rede neural artificial de link funcional (FLANN), como com FLANN putacionalmente eficiente (CEFLANN) e sua versão recorrente FLANN computacionalmente eficiente recorrente (RCEFLANN) para prever os índices do mercado de ações ao longo de diferentes intervalos de tempo que variam de 1 a 30 dias à frente. Neste artigo, os autores compararam o desempenho de várias FLANN treinadas com várias técnicas de aprendizado evolutivo e mostram que FLANN recorrentes treinadas com ED fornecem melhor precisão em relação a outras abordagens de FLANN. Nayak et al. [91] apresentou uma

rede neural de reação química (ACRNN) que usa uma técnica de otimização metaheurística baseada em população, ou seja, otimização de reação química artificial (ACRO) para treinar o modelo perceptron multicamada (MLP) para prever os índices de ações de sete mercados de ações de rápido crescimento para curto prazo, médio e longo prazo. ACRO tem o poder de lidar com o problema de overfitting, convergência e otimização de parâmetros. Pradeepkumar et al. [72] propuseram uma nova abordagem chamada rede neural de regressão quantílica treinada para otimização de enxame de partículas (PSOQRNN) para prever a volatilidade em séries temporais financeiras e a comparou com modelos convencionais de previsão de volatilidade viz. heteroscedasticidade condicional autorregressiva generalizada (GARCH), rede neural de regressão geral (GRNN), floresta aleatória (RF) multicamada perceptron (MLP), método de grupo de manipulação de dados (GMDH) e modelo híbrido baseado em regressão quantílica (QR) ou seja, rede neural de regressão quantílica (QRNN) e floresta aleatória de regressão quantílica (QRFF). O PSO é usado para obter o peso ideal e o viés do QRNN. O erro quadrado médio calculado a partir do resultado mostra que o PSOQRNN proposto superou outros modelos. Xiong et al. [92] desenvolveram um modelo de previsão combinando as redes neurais de função de base radial de valor complexo (FCRBFNNs) e dois métodos de computação evolutiva, PSO e PSO discreto (DPSO) para previsão de intervalo de séries temporais. Neste artigo, o preço máximo diário e o preço mínimo das ações foram usados para obter o intervalo e, em seguida, os limites inferior e superior do intervalo representam a parte real e imaginária do número complexo para formar um intervalo de valor complexo que é modelado pelo FCRBFNN. Para aumentar a precisão do FCRBFNN, a topologia e os parâmetros da rede são otimizados simultaneamente pelo PSO e DPSO. Yang et al. [104] apresentaram um novo método híbrido de seleção de ações composto por duas etapas principais: previsão de ações e pontuação de ações. Na primeira etapa, os retornos das ações para o próximo período de tempo são previstos usando uma técnica emergente de inteligência computacional, chamada Extreme Learning Machine (ELM), que é uma classe especial de redes neurais de feedforward de camada oculta (SLFNs) com base na geração aleatória de neurônios ocultos para resolver o problema de ótimos locais no processo de aprendizado iterativo. Na segunda etapa, os retornos previstos na etapa anterior e vários fatores fundamentais são usados coletivamente para formular um mecanismo de pontuação de ações ponderada linear para avaliar o valor de cada ação e, finalmente, ações de alto valor são escolhidas para enquadrar uma carteira igualmente ponderada como o saída final do modelo proposto. No mecanismo de pontuação de ações, os termos de peso do modelo linear são otimizados utilizando uma técnica de otimização heurística baseada em população viz. evolução diferencial (ED). Shah et al. [130] apresentaram um algoritmo de otimização Quick Gbest Guided Artificial Bee Colony (QGGABC) para ajustar os parâmetros do modelo de rede neural feedforward (FFNN) para prever as tendências no mercado de ações.

ket. Neste trabalho, o modelo proposto é baseado no algoritmo de aprendizado bio-inspirado viz. colônia artificial de abelhas (ABC) que é estendida pelos autores neste trabalho usando várias estratégias, como o melhor processo global de otimização de enxame de partículas (PSO), ou seja, gbest guiado ABC e simulando o comportamento de forrageamento inteligente de abelhas para fornecer ABC rápido para desenvolver o aprendizado QGGABC algoritmo.

4.5.4.2 Algoritmo Genético Híbrido (AG) Nesta seção discutimos os artigos que focam em AG híbrido. Khan e Sahai [159] usaram três técnicas de otimização estocástica baseadas em população, como algoritmo de morcego (BA), algoritmo genético (GA), otimização de enxame de partículas (PSO) e dois algoritmos baseados em gradiente viz. O algoritmo de retropropagação (BP) e Levenberg-Marquardt (LM) para treinamento de redes neurais feedforward e mostrou que o BA tem um desempenho melhor do que outras técnicas de otimização. Hasan et al. [160] propuseram um modelo híbrido combinando Hidden Markov Model (HMM), Genetic Algorithm (GA) e Artificial Neural Network (ANN) para prever o comportamento do mercado de ações. GA é utilizado para ajustar os parâmetros iniciais de HMM e RNA e eles mostraram as vantagens do modelo híbrido sobre os modelos individuais. Ferreira et al. [161] constroem um modelo inteligente híbrido combinando rede neural padrão com algoritmo genético modificado para lidar com o problema de previsão de séries temporais de preços de ações. O modelo proposto busca eficientemente o mínimo de defasagem das séries temporais suficiente para resolver o problema de previsão, a melhor configuração da rede neural e os melhores algoritmos de treinamento. Hadavandi et al. [97] desenvolveram uma rede neural evolutiva incorporando algoritmo genético com rede neural feed forward para previsão de bolsa de valores. Os resultados do experimento demonstram que o paradigma híbrido proposto é capaz de lidar com a flutuação de séries temporais de preços de ações e é eficiente para prever o índice de ações TEPIX. Hsu [114] propôs um modelo híbrido integrando rede neural de mapa auto-organizado (SOM) e programação genética (GP) para prever o preço das ações. A rede neural SOM é aplicada para gerar clusters de dados de entrada e o GP é utilizado para prever o preço de fechamento de cada cluster. Qiu e Song [55] constroem um modelo híbrido GA-BPNN aplicando GA para obter parâmetros otimizados para BPNN para previsão do índice japonês Nikkei 225. Qiu et al. [56] desenvolveram uma técnica híbrida que é baseada em duas abordagens de busca global, ou seja, algoritmo genético (GA) e reconhecimento simulado (SA) para aumentar a precisão da previsão do BPNN para prever o retorno do índice japonês Nikkei 225. Neste estudo, os autores introduziram um novo conjunto de variáveis de entrada para melhorar a precisão do modelo proposto. Inthachot et al. [107] combinou a inteligência de ANN e GA para previsão de tendência do índice de ações SET50 da Tailândia. Neste artigo, eles usaram GA como técnicas de seleção de recursos para determinar o subconjunto efetivo de recursos. Gocken et al. [108] examinaram a correlação subjacente entre os indicadores técnicos

e mercado de ações propondo um modelo híbrido que combina recursos de busca de harmonia (HS) e algoritmo genético (GA) com rede neural artificial (RNA). No modelo proposto, eles utilizaram o HS e o GA para extrair os indicadores técnicos relevantes que servem de entrada para a RNA e para ajustar os parâmetros da RNA. O resultado dos experimentos revela que o modelo ANN baseado em HS supera o modelo ANN baseado em GS para prever o mercado de ações turco. Em vez et al. [67] criaram um modelo híbrido composto por dois modelos lineares viz. modelo de média móvel autorregressiva (ARMA) e suavização exponencial (ES) e um modelo não linear chamado rede neural recorrente (RNN). Neste estudo, o modelo híbrido proposto combina os resultados de previsão desses três modelos de previsão para gerar saída e algoritmo genético (GA) usado para obter os pesos ótimos do modelo híbrido. Os resultados da previsão revelam que o modelo híbrido proposto supera a rede neural recorrente. Ghasemieh et al. [99] propuseram uma rede neural artificial híbrida baseada em algoritmos de otimização metaheurística, nomeadamente busca de cuco (CS), busca de cuco melhorada (ICS), algoritmo genético (GA), algoritmo genético de busca de cuco melhorado (ICSGA) e otimização de enxame de partículas para prever estoque índices e realizou estudo comparativo de diferentes modelos híbridos. Os resultados da simulação revelam que o PSO tem alto desempenho em relação a outro modelo e pode ser utilizado de forma eficiente para a previsão do preço das ações. Inthachot et al. [107] propuseram uma abordagem de inteligência híbrida pelo uso de rede neural artificial e algoritmo genético para prever tendências no índice do mercado de ações da Tailândia. Este estudo aplicou 11 indicadores técnicos para calcular 44 características de entrada com base em diferentes intervalos de tempo viz. 3, 5, 10 e 15 dias. Neste artigo, o algoritmo genético é usado para escolher o subconjunto efetivo de variáveis de entrada para a rede neural artificial para aumentar a precisão da previsão. Ahmadi et al. [162] propuseram dois modelos híbridos para prever sinais de negociação no mercado de ações com base na análise técnica de velas japonesas, empregando máquina de vetor de suporte (SVM) e dois algoritmos de otimização heurística viz. algoritmo de competição imperialista (ICA) e algoritmo genético (AG). No primeiro modelo híbrido, SVM e ICA são combinados para construir o modelo híbrido no qual o ICA é aplicado para obter os parâmetros otimizados do SVM. No segundo modelo híbrido, SVM e GA são integrados onde o GA é utilizado para selecionar recursos eficazes, bem como para otimizar os parâmetros do SVM. Aqui, os dados de entrada para o modelo proposto são gerados com base na abordagem baseada em dados brutos, que se concentra nos dados de entrada brutos do castiçal japonês, incluindo preços de abertura, fechamento, baixo e alto de ações e abordagens baseadas em sinais, onde o foco está nos sinais de reversão do castiçal japonês como Harami, Estrela da Manhã, Martelo Invertido e muitos outros. Os resultados mostraram que o SVM-ICA supera o SVM-GA. Chung e Shin [110] propuseram a aplicação de algoritmo genético (GA) para determinar a melhor topologia de rede e o tamanho da janela de tempo

da rede de memória de longo prazo (LSTM) para melhorar a precisão da previsão do modelo de previsão do mercado de ações. O GA é usado para otimizar vários parâmetros da rede LSTM como número de camada oculta, número de neurônio por camada oculta, número de defasagens de tempo e outros. Como a capacidade de aprendizado do LSTM depende de informações passadas, é importante escolher a janela de tempo ideal neste trabalho.

4.5.4.3 Lógica Fuzzy Híbrida Nesta seção apresentamos artigos que combinam lógica fuzzy com outros modelos para criar uma abordagem híbrida. Mustafá et al. [98] propuseram uma abordagem híbrida reunindo fuzzy C-means (FCM), artificial neural network (ANN) e data envelopment analysis (DEA) para prever o desempenho financeiro de várias corporações no mercado de ações de Teerã quando os dados são coletados em diferentes intervalos de tempo. Neste artigo, o FCM é aplicado para agrupar dados homogêneos usando lógica fuzzy para gerar agrupamentos dinâmicos. Depois disso, o DEA é utilizado para avaliar a eficiência de cada membro do cluster calculando a relação de saída ponderada para entrada ponderada e, em seguida, a rede neural é treinada para prever o desempenho futuro das empresas.

Yolcu e Lam [62] introduziram um modelo robusto de previsão de séries temporais fuzzy que é baseado na integração do modelo de neurônio multiplicativo único (SMNN), otimização de enxame de partículas (PSO) e estimadores M para melhorar a precisão da previsão de séries temporais de preços de ações afetados por outliers. Este modelo não requer defuzzificação, pois a entrada é composta por valores crisp e valores de associação e o treinamento de SMNN é realizado pelo PSO. Chang et al. [89] desenvolveram um novo método híbrido agregando Takagi-

Técnica baseada em regras fuzzy Sugeno (TS) com técnica de regressão de vetor de suporte (SVR) para identificar pontos de virada do sinal de negociação em dados do mercado de ações dos EUA. O SVR é usado para determinar os sinais de negociação dos indicadores técnicos e o modelo baseado em regras difusas TS é usado para identificar com precisão o momento certo para negociar ações, determinando o ponto de virada nos dados do mercado de ações. Neste artigo, para ilustrar a excelência do modelo proposto, os resultados são comparados com regressão linear tradicional e redes neurais artificiais. Yolcu e Alpaslan [119] criaram uma abordagem híbrida de séries temporais fuzzy combinando a capacidade de agrupamento fuzzy c-means (FCM), modelo de neurônio multiplicativo único (SMNN) e otimização de enxame de partículas (PSO) para prever o índice do mercado de ações de Taiwan. Em geral, o modelo de predição de séries temporais fuzzy é composto por três processos distintos: fuzzificação, identificação de relações fuzzy e defuzzificação e erro total no modelo é a soma dos erros que degraus. O foco principal deste artigo é reduzir o erro do modelo ao constituir o processo de solução do modelo fuzzy de séries temporais em um único processo de otimização concorrentemente. Neste artigo, a abordagem FCM é utilizada para fuzzificação e o modelo SMNN é aplicado para identificar a relação fuzzy e não há etapa de defuzzificação como modelo proposto produzido fora-

colocar como observação real de séries temporais. Além disso, os parâmetros relevantes de FCM e SMNM são determinados pelo PSO.

Cai et al. [117] desenvolveram uma abordagem híbrida integrando séries temporais fuzzy (FTS) e algoritmo genético (GA) para prever o mercado de ações. Operações de algoritmos genéticos como seleção, cruzamento e mutação são empregadas para obter uma partição precisa do universo. O resultado dos experimentos do modelo proposto foi comparado com três modelos convencionais de séries temporais fuzzy. Pal e Kar [73] propuseram o uso de algoritmos genéticos duplos: GA1 e GA2 com sistema de previsão de séries temporais fuzzy. GA1 é aplicado para particionamento eficaz de séries temporais fuzzy para determinar os intervalos desiguais, pois a precisão da previsão é sempre afetada pela duração do intervalo e GA2 é empregado para ajustar os parâmetros do modelo de relacionamento de lógica fuzzy e estabelecer a relação entre pontos de dados consecutivos para construir modelo de previsão de séries temporais de preços de ações. Tan et al. [102] criaram um modelo híbrido usando o sistema de inferência fuzzy baseado em rede adaptativa (ANFIS) e uma técnica de otimização de inteligência de enxame, o algoritmo de otimização fruit fly (FOA) para prever a volatilidade do mercado de ações. O FOA é implementado no ANFIS para alterar de forma adaptativa as regras de inferência no sistema fuzzy. Os resultados da comparação do modelo proposto com o ANFIS convencional revelam que o modelo proposto pode ser aplicado com sucesso para prever a volatilidade do mercado de ações.

Rajab e Sharma [74] apresentaram uma abordagem neuro difusa interpretável baseada no coeficiente de correlação de Pearson, agrupamento subtrativo, otimização restrita e técnicas de redução de base de regras para prever o preço das ações com o objetivo de lidar com trocas de precisão interpretável. A capacidade de interpretação do modelo proposto é assegurada pela base de regras compacta e parâmetros ótimos do conjunto fuzzy no modelo de previsão proposto. Neste trabalho, primeiramente o coeficiente de correlação de Pearson é empregado para selecionar os indicadores técnicos efetivos, em segundo lugar gerou a base de regra do sistema neuro-fuzzy usando agrupamento subtrativo e então selecionou as melhores regras fuzzy para gerar base de regra compacta com base na regra alta por e, finalmente, para garantir alto desempenho e base de regras altamente interpretável do modelo proposto, utilizou-se o algoritmo de aprendizado restrito para alcançar os melhores parâmetros do modelo neuro-fuzzy. Os resultados da simulação da comparação revelam que o modelo proposto fornece melhor equilíbrio entre interpretabilidade e precisão em relação ao sistema de inferência neurofuzzy adaptativo (ANFIS), RNA, heterocedasticidade condicional autorregressiva generalizada (GARCH) e análise de regressão múltipla (MRA).

4.5.4.4 Outros Modelos Híbridos Evolutivos Nesta seção apresentamos os artigos que são baseados na hibridização de técnicas de computação evolucionária. Brasileiro e col. [96] desenvolveram um sistema inteligente híbrido combinando uma técnica de otimização inspirada na natureza, chamada colônia artificial de abelhas (ABC) com algoritmo K-nearest neighbor (KNN) e seu

variante denominada Classificação Adaptativa e Vizinho Mais Próximo (AK-NN). Os algoritmos de classificação são aplicados para determinar o momento certo para comprar ou vender ações. ABC foi aplicado para otimizar o parâmetro do classificador KNN e escolher a melhor defasagem de cal. Kazem et al. [82] desenvolveram um modelo baseado em mapeamento caótico, regressão vetorial de suporte (SVR) e algoritmo frefy para prever preços de ações. Neste artigo, o modelo proposto funciona em três fases. Na fase inicial, eles usaram a técnica de incorporação de coordenadas de atraso para restaurar a dinâmica de fase invisível. Na segunda fase, para otimizar os hiperparâmetros do SVR, foi utilizado um algoritmo caótico frefy. Na fase final, o modelo otimizado é usado para prever o preço das ações. Os autores mostram a superioridade do modelo proposto, comparando-o com SVR baseado em algoritmo genético (GA) (SVR-GA), SVR baseado em frefy (SVR-FA), SVR baseado em GA caótico (SVR-

CGA), RNAs e sistemas adaptativos de inferência neuro-fuzzy (ANFIS). Zhang et al. [129] construíram uma técnica híbrida baseada em regressão vetorial de suporte (SVR) e algoritmo frefy modificado (MFA) para resolver o problema de previsão do mercado de ações.

Neste artigo, os autores realizaram o trabalho de pesquisa em duas etapas. Na primeira etapa, um FA modificado foi desenvolvido para melhorar o desempenho do FA. Na segunda etapa, o MFA é combinado com o SVR para criar um modelo híbrido no qual o MFA é usado para otimizar os hiperparâmetros do SVR para a previsão do preço das ações. Por fim, é realizada comparação com outro modelo para demonstrar as vantagens do modelo proposto.


Através desta pesquisa, observa-se que as abordagens de CI podem ser utilizadas de forma eficiente para o problema de previsão do mercado de ações. Com base nessa pesquisa, a Fig. 10 mostra a frequência das abordagens de IC usadas para prever o índice do mercado de ações das principais bolsas de valores do mundo.

No topo e segunda maior bolsa de valores do mundo, como a bolsa de valores de Nova York (NYSE) e NASDAQ e a décima e a décima primeira principais bolsas de valores do mundo, viz. Bolsa de Valores de Bombaim (BSE) e Bolsa de Valores Nacional (NSE), observou-se que as abordagens híbridas de CI são as mais utilizadas. Na terceira e quarta maiores bolsas de valores do mundo, como a bolsa de valores de Tóquio e a bolsa de valores de Xangai, as redes neurais artificiais (RNAs) são as técnicas mais aplicadas para a previsão de índices de mercado de ações.

4.6 Avaliação de Desempenho

Nesta seção apresentamos várias métricas de desempenho que têm sido utilizadas para medir o desempenho do modelo proposto na literatura pesquisada. Para avaliar o desempenho e a robustez do modelo, as métricas de avaliação a serem utilizadas dependem do tipo de problema que está sendo modelado, ou seja, se deve modelar problema de classificação ou problema de regressão. Na tendência do mercado de ações (alta/baixa ou baixa/

Fig. 10 Core CI aborda frequências para previsão das principais bolsas de valores



bullish) problemas de previsão precisão, recall e F-score [68] que são calculados a partir da matriz de confusão são utilizados para avaliar a precisão do modelo de classificação e a estatística de erro de previsão conjunta (JPE) [48] é usada para realizar a comparação de diferentes modelos. Em problemas de previsão de preço ou índice de ações, o desempenho do modelo de previsão é obtido avaliando a extensão da proximidade entre o valor real e o valor previsto e diferentes modelos de previsão são comparados usando o coeficiente U de Theil (TheilU) [95] e a variância relativa média (ARV) métricas [161]. Diversas métricas utilizadas nos artigos pesquisados para medir a proximidade são apresentadas neste artigo. A Figura 11 mostra a taxonomia das métricas de avaliação mais utilizadas. Reza et al. [47], Esfahanipour e Aghamir [95], Le et al. [78]

usaram o erro percentual médio absoluto (MAPE) para avaliar e comparar o desempenho do modelo com outros modelos. Erro quadrático médio (RMSE), precisão direcional (DA) e MAPE foram utilizados por Lu [50] para avaliar o desempenho do modelo proposto. Thakur et al. [48] usaram o recall e o F-score calculados a partir da confusão

matriz para julgar o desempenho do modelo de classificação. Para comparar o resultado entre os diferentes índices de ações, uma nova medida de desempenho denominada erro de previsão conjunta (JPE) é apresentada pelos autores deste estudo. Patel et al. [63] avaliaram o desempenho das técnicas de fusão propostas usando MAPE, RMSE, erro absoluto médio (MAE) e erro quadrático médio (MSE). de Oliveira et al. [95] avaliaram a mudança de direção (POCID) que dá

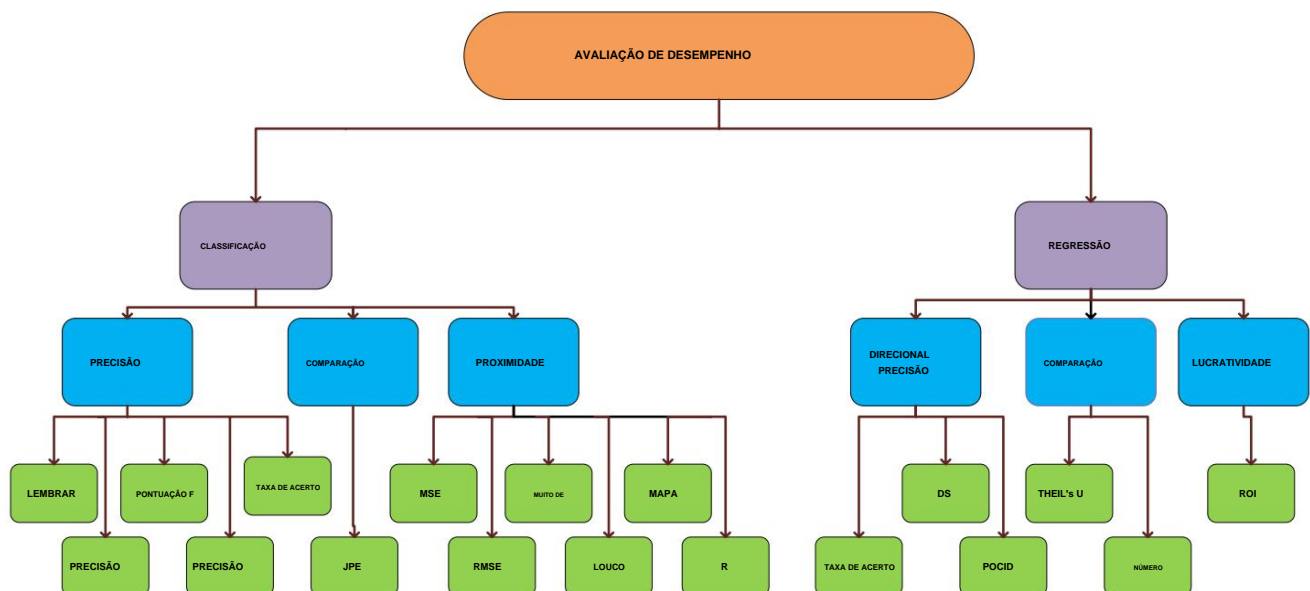


Fig. 11 Taxonomia de métricas de desempenho

a porcentagem de previsões corretas da direção da série de preços, MAPE, RMSE e coeficiente THEIL (Theil' U) para medir o desempenho do modelo. Asadi et al. [51] e Ferreira et al. [161] usaram quatro métricas de avaliação como MAPE, POCID, coeficiente U de Theil e métrica ARV para calcular a capacidade de previsão do modelo proposto e comparar a precisão do modelo com outros modelos. Dai et al. [54] e Feng e Chou [113] avaliaram a acurácia do modelo proposto utilizando métricas como RMSE, MAPE, diferença média absoluta (MAD), simetria direcional (DS) e erro percentual quadrático médio (RMSPE).

Hongping et al. [81], Qiu e Song [55] e Ahmadi et al. [162] usaram a taxa de acerto para avaliar o desempenho do modelo. A taxa de acerto é definida como porcentagem de tentativas quando a tendência prevista (para cima ou para baixo) é igual à tendência real [81]. Qiu et al. [56] e Mustafa et al. [98] utilizaram RMSE e MSE para calcular o desempenho do modelo proposto.

Kazem et al. [82] e Senapati et al. [65] empregaram MSE e MAPE para analisar e comparar o desempenho do modelo de previsão. Gocken et al. [108] avaliaram o desempenho do modelo proposto usando 9 funções de perda, nomeadamente MAE, MAPE, RMSE, MSE, erro relativo absoluto médio (MARE), erro relativo quadrático médio (MSRE), erro relativo quadrático médio (RMSRE), erro médio quadrático erro percentual quadrado (MSPE) e RMSPE. Em vez et al. [67] usaram o MSE médio (A-MSE) e o MAE médio (A-MAE) para julgar o desempenho do modelo híbrido proposto para ações múltiplas do mercado de ações indiano. Patel et al. [68] avaliaram a precisão de previsão do modelo proposto usando métricas de precisão e F-score. As métricas de precisão e pontuação F são computadas usando precisão e chamada que são determinadas a partir de verdadeiro positivo (TP), falso positivo (FP), verdadeiro negativo (TN) e falso negativo (FN) da matriz de confusão. Zarandi et al. [136], Liu et al.

[57], Yolcu e Lam [62], Sadaei et al. [87], Jiang et al. [88], Cai et al. [117] e Yolcu e Alpaslan [119] utilizaram RMSE para julgar o desempenho do modelo. Fazel et al. [123] aplicaram o MAPE para determinar a precisão de previsão do sistema proposto. Svalina et al. [111] empregaram o erro relativo médio (AvRE) e o coeficiente médio de variação (AvCE) do RMSE para avaliar o desempenho do modelo de previsão. Wang et al. [100], Dash e Dash et al. [69], Seo et al. [93], Laboissiere et al. [125], Weng et al. [127], Zhang et al. [129], Chung e Shin [110] e Zhou et al. [94] utilizaram RMSE, MAPE e MAE para analisar e comparar a acurácia do modelo proposto para previsão de preço de ações com outros algoritmos de previsão. Werner e Marcel [120] e Pal e Kar [73] avaliaram a precisão do modelo de previsão usando MSE como função de perda. Sheta et al. [86] e Ghasemieh et al. [99] avaliaram o desempenho do modelo de previsão do mercado de ações usando MAE, RMSE e coeficiente de correlação (R) que dá a força e direção da associação entre variáveis dependentes e independentes.

Su e Cheng [116] usaram o coeficiente U de Theil e RMSE

estatística para medir a precisão do modelo. Pang et al. [101] estimaram a precisão do modelo utilizando MSE e DA. Zang et al. [118] aplicaram MAD, MAPE, Symmetric MAPE (SMAPE) e NRMSE para determinar a precisão e capacidade de previsão da abordagem proposta. Inthachot et al. [107] usaram o valor de precisão para medir o desempenho do sistema híbrido. Rout et al. [71] utilizam RMSE e MAPE para realizar a comparação do desempenho de diferentes modelos. Mo et al. [103] avaliaram o desempenho preditivo do método proposto usando RMSE, MAE, MAPE e coeficiente de correlação (R). Nayak et al. [91] utilizaram métricas de precisão e POCID para avaliar e comparar o desempenho do modelo proposto. Pradeepku mar e Ravi [72] fazem uso do MSE, coeficiente U de Theil e estatística de mudança direcional (Dstat) para calcular o desempenho do modelo proposto. Xiong et al. [92] utilizaram métricas de variância relativa média (ARV) para comparar a capacidade preditiva de vários modelos em diferentes conjuntos de dados.

Wang e Wang [49] e Lei [59] analisaram o desempenho da técnica de previsão utilizando RMSE, MAPE, MAE, DS e mais duas métricas de desempenho de tipo de tendência, a saber, tendência de alta correta (CP) e tendência de baixa correta (CD). que fornece a porcentagem de acerto da tendência de alta e baixa prevista nos índices do mercado de ações. Cheng e Yang [58] avaliaram a precisão do modelo proposto com base na raiz do erro quadrático relativo (RRSE), RMSE e erro absoluto relativo (RAE). Ahmadi et al. [162] considerou a taxa de acerto que é definida como porcentagem de previsão precisa para determinado período. Gocken et al. [128] realizaram a comparação do desempenho de diferentes modelos usando cinco métricas viz. RMSE, MAE, MAPE, TheilU e DS. Yang et al. [104] fazem uso de RMSE, MAPE para precisão de nível e Dstat é usado para precisão direcional. Pimenta et al. [126] compararam diferentes sistemas de negociação com base no retorno financeiro sobre o investimento (ROI) obtido pela aplicação de diferentes métodos. Rajab e Sharma [74] mediram a precisão de previsão do modelo proposto usando RMSE, MAPE e DA. Shah et al. [130] avaliaram o desempenho da abordagem proposta por MSE, desvio padrão de MSE, NMSE, taxa de sucesso e acurácia. Chander [131] avaliou e comparou a acurácia dos modelos de predição por RMSE, MAPE, erro absoluto médio (AAE), coeficiente de variação (CoV) e coeficiente de determinações múltiplas (R²).

5 Trabalho proposto

Modelos híbridos para previsão do mercado de ações são proeminentes e mais precisos do que as abordagens tradicionais. Nosso objetivo é desenvolver um modelo evolutivo híbrido usando técnicas baseadas em inteligência computacional para obter previsões precisas do mercado de ações. As etapas básicas no trabalho da abordagem híbrida proposta foram descritas na Fig. 12

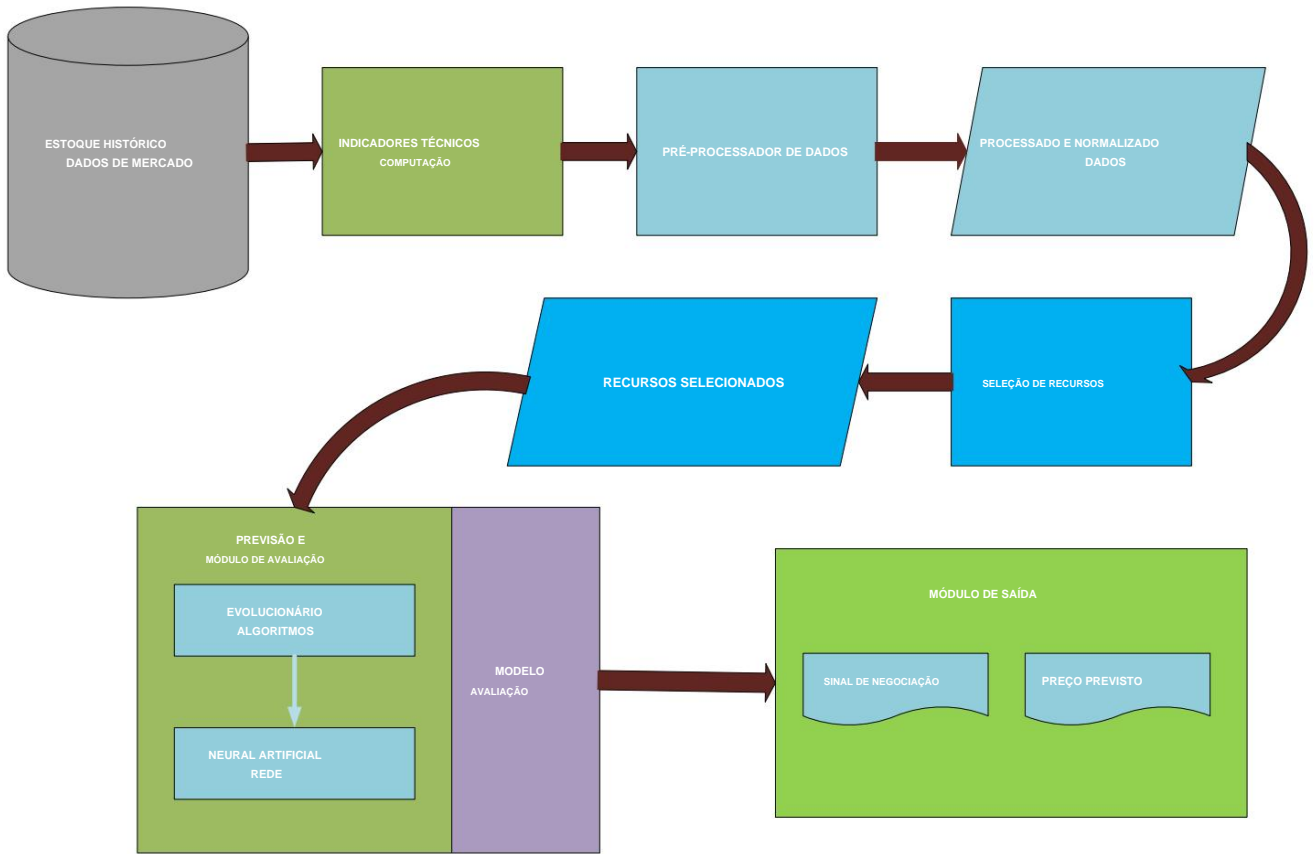


Fig. 12 Funcionamento do sistema proposto

De acordo com a literatura pesquisada; indicadores técnicos têm mostrado excelente resultado para previsão do mercado de ações. Em trabalhos futuros, propusemos usar indicadores técnicos para construir um vetor de características para a previsão do mercado de ações. As várias etapas do trabalho proposto são mencionadas abaixo:

1. Obtenção dos dados históricos do mercado de ações.
2. Calcular os indicadores técnicos usando dados reais do mercado de ações, como preço de abertura, preço de fechamento, preço baixo, preço alto e volume de ações negociadas.
3. Pré-processamento do conjunto de dados para normalizar os dados no intervalo [0 1].
4. Aplicar técnicas de extração de características para determinar os indicadores técnicos que mais influenciam o preço das ações e, portanto, reduzem a dimensionalidade.
5. Desenvolvimento de um modelo de previsão híbrido para previsão do mercado de ações utilizando rede neural artificial (RNA).
6. Aplicar a técnica de otimização evolutiva para ajustar os parâmetros do modelo proposto para melhorar a precisão.
7. Avaliar a capacidade de previsão do modelo proposto usando várias métricas de desempenho.
8. Apresentar o sinal de negociação ou preço das ações previsto valor.

6. Conclusão

Neste artigo, buscamos levantar as contribuições importantes e atuais no domínio da inteligência computacional para resolver o problema de previsão do mercado de ações. A capacidade das abordagens de inteligência computacional para realizar a inteligência artificial imitando o poder de pensamento humano foi investigada para prever o mercado de ações neste trabalho. Este artigo investigou e discutiu os artigos que tratam de pré-processamento, redução de dimensionalidade e previsão de tendência futura ou previsão de preços futuros de ações. Por meio desta pesquisa, observou-se que as abordagens de IC têm mostrado resultados promissores na área de mercado de ações. A primeira grande contribuição deste artigo é auxiliar o pesquisador e analista financeiro a construir uma abordagem sistemática para o desenvolvimento de metodologia inteligente para previsão do mercado de ações. O segundo foco principal deste estudo é a discussão sobre as terminologias básicas do mercado de ações e abordagens de inteligência computacional. A terceira contribuição desta pesquisa é apresentar as fontes de dados para obter os dados históricos do mercado de ações de diversos mercados internacionais e

bolsas de valores nacionais. Até onde sabemos, esta é a primeira pesquisa que apresenta as fontes de dados no domínio do mercado de ações. Em nosso estudo, os principais achados são: (1)

indicadores técnicos desempenham um papel proeminente na previsão do mercado de ações. Portanto, a identificação de um conjunto adequado de indicadores técnicos ainda é um problema em aberto (2) a identificação de técnicas adequadas de pré-processamento e seleção de recursos ajuda a melhorar a precisão dos modelos de previsão do mercado de ações (3) abordagens de inteligência computacional podem ser efetivamente usadas para resolver ações problema de previsão de mercado com alta precisão. Entre eles, os modelos híbridos são técnicas predominantes aplicadas à previsão do mercado de ações devido à capacidade de previsão combinada dos modelos base (4) as métricas de desempenho não são únicas e diferentes autores têm usado diferentes combinações de métricas.

Conformidade com os padrões éticos

Conflito de interesse Os autores declaram não ter conflito de interesse.

Referências

- Lin CS, Chiu SH, Lin TY (2012) Mínimos quadrados baseados em decomposição de modo empírico suportam regressão vetorial para previsão de taxa de câmbio. *Modelo Eco* 29(6):2583–2590
- Tay FE, Cao L (2001) Aplicação de máquinas de vetores de suporte na previsão de séries temporais financeiras. *Omega* 29(4):309–317
- Lam M (2004) Técnicas de redes neurais para previsão de desempenho financeiro: integrando análise fundamental e técnica. *Sistema de Suporte Decis* 37(4):567–581
- Murphy JJ (1999) Análise técnica dos mercados financeiros. Instituto de Finanças de Nova York, Nova York
- Miao K, Chen F, Zhao ZG (2007) Previsão do preço das ações com base na rede neural RBF da colônia bacteriana. *J Qingdao Univ (Nat Sci Ed)* 2(11):2–11
- Nassirtoussi AK, Wah TY, Ling DNC (2011) Uma nova metodologia de previsão FOREX baseada em dados fundamentais. *Afr J Bus Manag* 5(20):8322–8330
- Haleh H, Moghaddam BA, Ebrahimijam S (2011) Uma nova abordagem para prever o preço das ações com fusão de dados EKF. *Int J Trade Econ Finance* 2(2):109–114
- Wang JZ, Wang JJ, Zhang ZG, Guo SP (2011) Previsão de índices de ações com rede neural de retropropagação. *Aplicativo de sistema especialista* 38(11):14346–14355
- Box GE, Jenkins GM, Reinsel GC, Ljung GM (2015) Análise de séries temporais: previsão e controle. Wiley, Nova York
- Kumar D, Murugan S (2013) Análise de desempenho do índice do mercado de ações indiano usando modelo de série temporal de rede neural. In: Conferência internacional sobre reconhecimento de padrões, informática e engenharia móvel. IEEE, pp 72–78
- Si YW, Yin J (2013) Abordagem de segmentação baseada em OBST para séries temporais financeiras. *Eng Appl Artif Intell* 26(10):2581–2596
- Adebiyi AA, Ayo CK, Adebiyi MO, Otokiti SO (2012) Previsão de preço de ações usando rede neural com indicadores de mercado hibridizados. *J Emerg Trends Comput Inf Sci* 3(1):1–9
- Cortes C, Vapnik V (1995) Redes de vetores de suporte. *Mach Learn* 20(3):273–297
- Bone R, Crucianu M (2002) Predição multi-passo à frente com redes neurais: uma revisão. 9º Encontro Internacional: Abordagens Conexistas à Ciência 2:97–106
- Atsalakis S, Valavanis KP (2009) Levantamento de técnicas de previsão do mercado de ações – parte II: métodos de computação suave. *Aplicativo de sistema especialista* 36(3):5932–5941
- Cavalcante RC, Brasileiro RC, Souza VL, Nobrega JP, Oliveira AL (2016) Computational intelligence and financial markets: a survey and future directions. *Expert Syst Appl* 55:194–211
- Nikfarjam A, Emadzadeh E, Muthaiyah S (2010) Abordagens de mineração de texto para previsão do mercado de ações. In: Congresso Internacional de Engenharia de Computação e Automação. IEEE, págs. 256–260
- Li Y, Ma W (2010) Aplicações de redes neurais artificiais em economia financeira: uma pesquisa. In: Simpósio Internacional de Inteligência e Design Computacional. IEEE, pp 211–214
- Rivera RA, Rendón MV, Ortiz JR (2015) Algoritmos genéticos e abordagens darwinianas em aplicações financeiras: uma pesquisa. *Aplicativo de sistema especialista* 42(21):7684–7697
- Agrawal JG, Chourasia VS, Mittra AK (2013) Estado da arte em técnicas de previsão de ações. *Int J Adv Res Electr Electron Instrum Eng* 2(4):1360–1366
- Kumar BS, Ravi V (2016) Um levantamento das aplicações de mineração de texto no domínio financeiro. *Sistema Baseado em Conhecimento* 114:128–147
- Soni S (2011) Aplicações de RNAs na previsão do mercado de ações: uma pesquisa. *Int J Comput Sci Eng Technol* 2(3):71–83
- Border J, Evan JH (2014) Mercado de ações para iniciantes. Plataforma de publicação independente CreateSpace, Scotts Valley
- Setty DV, Rangaswamy TM, Subramanya KN (2010) Uma revisão sobre aplicações de mineração de dados para o desempenho do mercado de ações. *Int J Comput Appl* 1(3):24–34
- Sarwar G (2012) O VIX é um indicador de medo do investidor nos mercados de ações do BRIC? *J Multinatl Finance Manag* 22(3):55–65
- Chandra A, Thenmozhi M (2015) Sobre a relação assimétrica do índice de volatilidade da Índia (Índia VIX) com o retorno do mercado de ações e gestão de risco. *Decisão* 42(1):33–55
- <https://www.investopedia.com/terms/t/totalreturn.asp>
- <https://www.investopedia.com/terms/a/averagereturn.asp>
- Brockwell PJ, Davis RA, Calder MV (2002) Introdução às séries temporais e previsão. Springer, Berlim
- Metcalfe AV, Cowpertwait PS (2009) Série temporal introdutória com R. Springer, Berlim, pp 2–5
- Leigh W, Purvis R, Ragusa JM (2002) Previsão do índice composto NYSE com análise técnica, reconhecedor de padrões, rede neural e algoritmo genético: um estudo de caso em apoio à decisão romântica. *Sistema de Suporte Decis* 32(4):361–377
- Tsinaslanidis PE, Kugiumtzis D (2014) Um esquema de previsão usando pontos perceptualmente importantes e distorção do tempo dinâmico. *Aplicativo de sistema especialista* 41(6):848–860
- Ibrahim D (2016) Uma visão geral da computação suave. *Procedia Comput Sci* 102:34–38
- Karray O, Silva CD (2004) Soft computing e design de sistemas inteligentes: teoria, ferramentas e aplicações. Pearson Education, Londres
- Pedrycz W (1990) Conjuntos fuzzy no reconhecimento de padrões: metodologia e métodos. *Reconhecimento de Padrão* 23(1):121–146
- Yuhua B, Ansari N (2012) Redes neurais em telecomunicações. Springer, Berlim
- Dote Y, Hoft RG (1998) Controle inteligente: eletrônica de potência sistemas. Imprensa da Universidade de Oxford, Oxford
- Komori YA (1992) Abordagem de treinamento nebuloso neural para melhoria contínua do reconhecimento de fala. In: Continuando a conferência internacional IEEE sobre acústica, fala e processamento de sinais, vol 1, pp 405–408
- Cichocki A, Unbehauen R (1993) Redes neurais para otimização e processamento de sinais. Wiley, Hoboken
- Roy R, Furuhashi T, Chawdhry PK (1998) Avanços na computação suave: projeto de engenharia e fabricação. Springer, Berlim

41. Haykin S (1999) Rede neural: uma base abrangente. Prentice Hall, Upper Saddle River
42. Goh AT (1995) Redes neurais de retropropagação para modelagem de sistemas complexos. *Artif Intel Eng* 9(3):143–151
43. Saerens M (2002) Controlador neural baseado em algoritmo de retropropagação. *Processo de sinal de radar IEE Proc* 138(1):55–62
44. Zadeh LA (1994) Lógica difusa, redes neurais e computação suave ing. *Comum ACM* 37(3):77–84
45. Holland JH (1992) Adaptação em sistemas naturais e artificiais: uma análise introdutória com aplicações em biologia, controle e inteligência artificial. MIT Press, Cambridge
46. Coley DA (2003) Uma introdução aos algoritmos genéticos para cientistas e engenheiros. World Scientific Publishing Co, Cingapura
47. Reza H, Shahrazi J, Hadavandi E (2015) Um sistema multi-agente de rede neural de morcegos (BNNMAS) para previsão de preços de ações: estudo de caso do preço de ações DAX. *Appl Soft Comput* 29:196–210
48. Kumar D, Meghwani SS, Thakur M (2016) Modelos híbridos de previsão baseados em máquinas de vetor de suporte proximal para previsão de tendências em mercados financeiros. *J Comput Sci* 17:1–13
49. Wang J, Wang J (2017) Previsão de rede neural estocástica com base na decomposição do modo empírico financeiro. *Rede Neural* 90:8–20
50. Lu CJ (2010) Integrando esquema de denoising baseado em análise de componentes independentes com rede neural para previsão de preços de ações. *Aplicativo de sistema especialista* 37(10):7056–7064
51. Asadi S, Hadavandi E, Mehmanpazir F, Nakhosin MM (2012) Híbridação de redes neurais evolutivas de Levenberg–Marquardt e pré-processamento de dados para previsão do mercado de ações. *Sistema Baseado em Conhecimento* 35:245–258
52. Chang PC, Liu CH (2008) Um sistema baseado em regras fuzzy do tipo TSK para previsão de preços de ações. *Aplicativo de sistema especialista* 34(1):135–144
53. Esfahanipour A, Aghamiri W (2010) Adaptado sistema de inferência neuro-fuzzy na abordagem indireta TSK base de regras fuzzy para análise do mercado de ações. *Aplicativo de sistema especialista* 37(7):4742–4748
54. Dai W, Wu JY, Lu CJ (2012) Combinando análise de componentes independentes não lineares e rede neural para a previsão de índices do mercado de ações asiático. *Aplicativo de sistema especialista* 39(4):4444–4452
55. Qiu MY, Song Y (2016) Prevendo a direção do movimento do índice do mercado de ações usando um modelo de rede neural artificial otimizado. *PLoS ONE* 11(5):1–11
56. Qiu MY, Song Y, Akagi F (2016) Aplicação de rede neural artificial para a previsão de retornos do mercado de ações: o caso do mercado de ações japonês. *Chaos Solitons Fractals* 85:1–7
57. Liu CF, Yeh CY, Lee SJ (2012) Aplicação da modelagem neuro difusa tipo 2 na previsão de preços de ações. *Appl Soft Comput* 12(4):1348–1358
58. Cheng CH, Yang JH (2018) Modelo fuzzy de séries temporais baseado na indução de regras de conjunto aproximado para prever o preço das ações. *Neurocomputação* 302:33–45
59. Lei L (2018) Método de previsão de rede neural Wavelet da tendência do preço das ações com base na redução aproximada de atributos definidos. *Appl Soft Comput* 62:923–932
60. Kara Y, Boyacioglu MA, Baykan OK (2011) Prevendo a direção do movimento do índice de preços de ações usando redes neurais artificiais e máquinas de vetores de suporte: a amostra da Bolsa de Valores de Istambul. *Aplicativo de sistema especialista* 38(5):5311–5319
61. Boyacioglu MA, Avci D (2010) Um sistema de inferência fuzzy baseado em rede adaptável (ANFIS) para a previsão do retorno do mercado de ações: o caso da bolsa de valores de Istambul. *Aplicativo de sistema especialista* 37(12):7908–7912
62. Yolcu OC, Lam HK (2017) Um método de série temporal fuzzy robusto combinado para previsão de séries temporais. *Neurocomputação* 247:87–101
63. Patel J, Shah S, Thakkar P, Kotecha K (2015) Previsão do índice do mercado de ações usando a fusão de técnicas de aprendizado de máquina. *Aplicativo de sistema especialista* 42(4):2162–2172
64. Pathak A, Shetty NP (2019) Previsão do mercado de ações indiano usando aprendizado de máquina e análise de sentimentos. *Computar Dados Intell Min.* 711:595–603
65. Senapati MR, Das S, Mishra S (2018) Um novo modelo para previsão de preços de ações usando rede neural híbrida. *J Inst Eng (Índia)* Sor B 99 (6): 555–563
66. Chopra S, Yadav D, Chopra AN (2019) Redes neurais artificiais com base na previsão de preços do mercado de ações indiano: antes e depois da desmonetização. *Int J Swarm Intell Evol Comput* 8(174):1–7
67. Em vez AM, Agarwal A, Sastry VN (2015) Rede neural recorrente e um modelo híbrido para previsão de retornos de ações. *Aplicativo de sistema especialista* 42(6):3234–3241
68. Patel J, Shah S, Thakkar P, Kotecha K (2015) Previsão do movimento do índice de preços de ações e ações usando preparação de dados determinísticos de tendência e técnicas de aprendizado de máquina. *Aplicativo de sistema especialista* 42(1):259–268
69. Dash R, Dash P (2016) Previsão eficiente de preços de ações usando um sistema de inferência neuro-fuzzy recorrente auto-evolutivo otimizado por meio de uma técnica de busca de harmonia diferencial modificada. *Aplicação de sistema especialista* 52:75–90
70. Dash R, Dash PK (2016) Uma estrutura híbrida de negociação de ações que integra análise técnica com técnicas de aprendizado de máquina. *J Finance Data Sci* 2(1):42–57
71. Rout AK, Dash PK, Dash R, Bisoi R (2017) Previsão de séries temporais financeiras usando uma rede neural recorrente de baixa complexidade e abordagem de aprendizado evolutivo. *J King Saud Univ Comput Inf Sci* 29(4):536–552
72. Pradeepkumar D, Ravi V (2017) Previsão de volatilidade de séries temporais financeiras usando rede neural de regressão quantílica treinada para otimização de enxame de partículas. *Appl Soft Comput* 58:35–52
73. Pal SS, Kar S (2019) Modelo de série temporal difusa para comprimento de intervalo desigual usando algoritmo genético. In: *Tecnologia da informação e matemática aplicada*, vol 699. Springer, pp 205–216
74. Rajab S, Sharma V (2019) Uma abordagem neuro-fuzzy interpretável para a previsão de preços de ações. *Soft Comput* 23(3):921–936
75. Niall O, Madden MG (2006) Uma abordagem de rede neural para prever os movimentos da bolsa de valores usando fatores externos. *Sistema Baseado em Conhecimento* 19:371–378
76. Wang J, Wang J (2015) Previsão de índices do mercado de ações usando análise de componentes principais e redes neurais efetivas em tempo estocástico. *Neurocomputação* 156:68–78
77. Liu F, Wang J (2012) Previsões de flutuação do índice do mercado de ações pela rede neural Legendre com função de força de tempo aleatório. *Neurocomputação* 83:12–21
78. Chien YWC, Chen YL (2010) Regras de classificação associativa de mineração com dados de negociação de ações - Um método baseado em GA. *Sistema Baseado em Conhecimento* 23:605–614
79. Zhang Y, Wu L (2009) Previsão do mercado de ações do S&P 500 através da combinação de abordagem BCO melhorada e rede neural BP. *Aplicativo de sistema especialista* 36:8849–8854
80. Niaki STA, Hoseinzade S (2013) Previsão do índice S&P 500 usando redes neurais artificiais e desenho de experimentos. *J Ind Eng Int* 9(1):1–9
81. Hu H, Tang L, Zhang S, Wang H (2018) Prevendo a direção dos mercados de ações usando redes neurais otimizadas com o Google Trends. *Neurocomputação* 285:188–195
82. Kazem A, Sharif E, Hussain FK, Saberi M, Hussain OK (2013) Suporta regressão vetorial com algoritmo frefy baseado em caos para previsão de preços no mercado de ações. *Appl Soft Comput* 13(2):947–958
83. Chien YWC, Chen YL (2010) Regras de classificação associativa de mineração com dados de negociação de ações - Um método baseado em GA. *Sistema Baseado em Conhecimento* 23(6):605–614
84. Zhong X, Enke D (2017) Previsão de retorno diário do mercado de ações usando redução de dimensionalidade. *Aplicativo de sistema especialista* 67:126–139

85. Chiang WC, Enke D, Wu T, Wang R (2016) Um sistema adaptativo de suporte à decisão de negociação de índices de ações. *Aplicativo de sistema especialista* 59:195–207
86. Sheta AF, Ahmed SEM, Faris H (2015) Uma comparação entre regressão, redes neurais artificiais e máquinas de vetores de suporte para prever o índice do mercado de ações. *Computação Suave* 7:8
87. Sadaei HJ, Enayatifar R, Lee MH, Mahmud M (2016) Um modelo híbrido baseado em relações de lógica difusa diferencial e algoritmo competitivo imperialista para previsão do mercado de ações. *Appl Soft Comput* 40:132–149
88. Jiang JA, Syue CH, Wang CH, Wang JC, Shieh JS (2018) Um sistema de lógica fuzzy de intervalo tipo 2 para previsão de índices de ações com base em séries temporais fuzzy e um mapa de relacionamento lógico fuzzy. *Acesso IEEE* 6:69107–69119
89. Chang PC, Wu JL, Lin JJ (2016) Um modelo fuzzy de Takagi-Sugeno combinado com uma regressão de vetor de suporte para previsão de negociação de ações. *Appl Soft Comput* 38:831–842
90. Fischer T, Krauss C (2018) Aprendizado profundo com redes de memória de longo prazo para previsões do mercado financeiro. *Eur J Opera Res* 270(2):654–669
91. Nayak SC, Misra BB, Behera HS (2017) Otimização de reações químicas artificiais de redes neurais para previsão eficiente de índices do mercado de ações. *Ain Shams Eng J* 8(3):371–390
92. Xiong T, Bao Y, Hu Z, Chiong R (2015) Previsão de séries temporais de intervalo usando uma rede neural RBF de valor totalmente complexo com algoritmos DPSO e PSO. *Inf Sci* 305:77–92
93. Seo M, Lee S, Kim G (2019) Previsão da volatilidade do índice do mercado de ações usando os modelos híbridos com tendências domésticas do google. *Fluct Noise Lett* 18(01):1950006, 1–17
94. Zhou F, Zhou HM, Yang Z, Yang L (2019) Uma estratégia que combina decomposição de modo empírico e rede neural baseada em máquina de fatoração para previsão de tendências do mercado de ações. *Aplicativo de sistema especialista* 115:136–151
95. de Oliveira FA, Nobre CN, Zarate LE (2013) Aplicação de Redes Neurais Artificiais para predição de preço de ações e melhoria do índice de predição direcional – estudo de caso PETR4, Petro bras, Brasil. *Aplicativo de sistema especialista* 40(18):596–7606
96. Brasileiro RC, Souza VL, Fernandes B, Oliveira AL (2013) Método automático de negociação de ações combinando a análise técnica e o Algoritmo Artificial da Colônia de Abelhas. In: *Congresso IEEE sobre Computação Evolutiva*. IEEE, págs. 1810-1817
97. Hadavandi E, Ghanbari A, Abbasian-Naghneh S (2010) Desenvolvendo um modelo de rede neural evolutiva para previsão de índices de ações. In: Huang DS, McGinnity M, Heutte L, Zhang XP (eds) *Teorias e aplicações avançadas de computação inteligente*. ICIC 2010. Comunicações em informática e ciência da informação, vol 93. Springer, Berlim, pp 407–415
98. Rezaee MJ, Jozmaleki M, Valipour M (2018) Integrando dinâmica fuzzy C-means, análise de envoltória de dados e rede neural artificial para previsão on-line de desempenho de empresas em bolsa de valores. *Físico A* 489:78–93
99. Ghasemiyeh R, Moghdani R, Sana SS (2017) Uma rede neural artificial híbrida com algoritmos metaheurísticos para prever o preço das ações. *Sistema Cybern* 48(4):365–392
100. Wang J, Wang J, Fang W, Niu H (2016) Predição de séries temporais financeiras usando redes neurais aleatórias recorrentes elman. *Computar Intell Neurosci* 2016:1–14
101. Pang X, Zhou Y, Wang P, Lin W, Chang V (2018) Uma abordagem inovadora de rede neural para previsão do mercado de ações. *J Supercomputador* 74:1–21
102. Tan L, Wang S, Wang K (2017) Um novo sistema de inferência difusa baseado em rede adaptável com regras de ajuste adaptáveis para previsão de volatilidade do mercado de ações. *Inf Process Lett* 127:32–36
103. Mo H, Wang J, Niu H (2016) Previsão de rede neural de retropropagação de expoente para relação de correlação cruzada financeira. *Aplicativo de sistema especialista* 53:106–116
104. Yang F, Chen Z, Li J, Tang L (2019) Um novo método de seleção de ações híbridas com previsão de ações. *Appl Soft Comput* 80:820–831
105. Vanstone B, Finnie G, Hahn T (2012) Criando sistemas de negociação com variáveis fundamentais e redes neurais: o estudo de caso Aby. *Simulação de computação matemática* 86:78–91
106. Pulido M, Melin P, Castillo O (2014) Otimização de enxame de partículas de redes neurais ensemble com agregação difusa para previsão de séries temporais da Bolsa de Valores Mexicana. *Inf Sci* 280:188–204
107. Inthachot M, Boonjing V, Intakosum S (2016) Rede neural artificial e inteligência híbrida de algoritmo genético para prever a tendência do índice de preços de ações tailandês. *Computar Intell Neurosci* 2016:1–8
108. Gocken M, Ozcalici M, Boru A, Dosdogru AT (2016) Integrando metaheurísticas e redes neurais artificiais para melhorar a previsão de preços de ações. *Aplicativo de sistema especialista* 44:320–331
109. Kim Y, Ahn W, Oh KJ, Enke D (2017) Um sistema de negociação híbrido inteligente para descobrir regras de negociação para o mercado futuro usando conjuntos aproximados e algoritmos genéticos. *Appl Soft Comput* 55:127–140
110. Chung H, Shin KS (2018) Rede de memória de longo prazo otimizada por algoritmo genético para previsão do mercado de ações. *Sustentabilidade* 10(10):1–18
111. Svalina I, Galzina V, Lujic R, Simunovic G (2013) Um sistema de inferência fuzzy baseado em rede adaptável (ANFIS) para a previsão: o caso de índices de preços próximos. *Aplicativo de sistema especialista* 40(15):6055–6063
112. Chourmouziadis K, Chatzoglou PD (2016) Um sistema fuzzy de negociação de ações de curto prazo inteligente para auxiliar os investidores na gestão de carteiras. *Aplicativo de sistema especialista* 43:298–311
113. Feng HM, Chou HC (2011) Geração evolutiva de sistemas de previsão de RBFNs nas aplicações de dados de séries temporais financeiras. *Aplicativo de sistema especialista* 38(7):8285–8292
114. Hsu CM (2011) Um procedimento híbrido para previsão de preços de ações integrando mapa auto-organizado e programação genética. *Aplicativo de sistema especialista* 38(11):14026–14036
115. Chang YH, Lee MS (2017) Incorporando o processo de decisão de Markov em algoritmos genéticos para formular estratégias de negociação para mercados de ações. *Appl Soft Comput* 52:1143–1153
116. Su CH, Cheng CH (2016) Um modelo híbrido fuzzy de séries temporais baseado em ANFIS e método de seleção de características não lineares integradas para previsão de estoque. *Neurocomputação* 205:264-273
117. Cai Q, Zhang D, Wu B, Leung SC (2013) Um novo modelo de previsão de ações baseado em séries temporais difusas e algoritmo genético. *Procedia Comput Sci* 18: 1155–1162
118. Zhang R, Ashuri B, Deng Y (2017) Um novo método para previsão de séries temporais com base em lógica difusa e gráfico de visibilidade. *Classificação Anal de Dados Adv* 11(4):759–783
119. Yolcu OC, Alpaslan F (2018) Previsão de TAIEX com base em modelo de série temporal fuzzy híbrido com processo de otimização simples. *Appl Soft Comput* 66:18–33
120. Kristjanpoller W, Minutolo MC (2018) Uma estrutura de previsão de volatilidade híbrida integrando GARCH, rede neural artificial, análise técnica e análise de componentes principais. *Aplicação de sistema especialista* 109:1–11
121. Ticknor JL (2013) Uma rede neural artificial Bayesiana regularizada para previsão do mercado de ações. *Aplicativo de sistema especialista* 40(14):5501–5506
122. Mabu S, Obayashi M, Kuremoto T (2015) Aprendizagem em conjunto de algoritmo evolucionário baseado em regras usando perceptron multicamada para apoiar decisões em problemas de negociação de ações. *Appl Soft Comput* 36:357–367
123. Zarandi MF, Hadavandi E, Turksen IB (2012) Um sistema baseado em agente híbrido fuzzy inteligente para previsão de preços de ações. *Int J Intell Syst* 27(11):947–969

124. Shynkevich Y, McGinnity TM, Coleman SA, Belatreche A, Li Y (2017) Previsão de movimento de preços usando indicadores técnicos: investindo o impacto de diferentes comprimentos de janela. *Neurocomputação* 264:71-88
125. Laboissiere LA, Fernandes RA, Lage GG (2015) Previsão de preço máximo e mínimo de ações de empresas brasileiras de distribuição de energia com base em redes neurais artificiais. *Appl Soft Comput* 35:66-74
126. Pimenta A, Nametala CA, Guimarães FG, Carrano EG (2018) Um método de investimento automatizado para o mercado de ações baseado em programação genética multiobjetivo. *Calcular Econ* 52(1):125-144
127. Weng B, Lu L, Wang X, Megahed FM, Martinez W (2018) Previsão de preços de ações de curto prazo usando métodos de conjunto e fontes de dados online. *Aplicativo de sistema especialista* 112:258-273
128. Gocken M, Ozcalici M, Boru A, Dosdogru AT (2019) Previsão de preços de ações usando modelos híbridos de computação flexível que incorporam ajuste de parâmetros e seleção de variáveis de entrada. *Aplicativo de Computação Neural* 31(2):577-592
129. Zhang J, Teng YF, Chen W (2019) Suporta regressão vetorial com algoritmo frefy modificado para previsão de preços de ações. *Appl Intel* 49(5):1658-1674
130. Shah H, Tairan N, Garg H, Ghazali R (2018) Um algoritmo de colônia de abelhas artificial guiado rápido para previsão de preços do mercado de ações. *Simetria* 10(7):1-15
131. Chandar SK (2019) Modelo de fusão da transformada wavelet e sistema de inferência neuro fuzzy adaptativo para previsão do mercado de ações. *J Ambiente Intell Humaniz Comput* 10:1-9
132. Vanstone B, Finnie G (2009) Uma metodologia empírica para o desenvolvimento de sistemas de negociação no mercado de ações usando redes neurais artificiais. *Aplicativo de sistema especialista* 36(3):6668-6680
133. Teixeira LA, Oliveira A (2010) Um método para negociação automática de ações combinando análise técnica e classificação do vizinho mais próximo. *Aplicativo de sistema especialista* 37(10):6885-6890
134. Tsinaslanidis PE, Kugiumtzis D (2014) Um esquema de previsão usando pontos perceptualmente importantes e distorção de tempo dinâmica. *Aplicativo de sistema especialista* 41:6848-6860
135. Bisoi R, Dash PK (2014) Uma rede neural dinâmica evolutiva híbrida para análise e previsão de tendências do mercado de ações usando filtro de Kalman sem perfume. *Appl Soft Comput* 19:41-56
136. Zarandi MF, Rezaee B, Turksen IB, Neshat E (2009) Um modelo de sistema especialista baseado em regras difusas tipo 2 para análise de preços de ações. *Aplicativo de sistema especialista* 36(1):139-154
137. Abdul-Sal ME, Abdul-Kade HM, Abdel-Wahed WF (2010) Estudo comparativo entre evolução diferencial e algoritmos de otimização de enxame de partículas no treinamento de redes neurais feed-forward para predição de preços de ações. In: VII Congresso Internacional de Informática e Sistemas. IEEE, pp 1-8
138. Alpaydin E (2009) Introdução ao aprendizado de máquina. MIT Press, Cambridge, p 30
139. Han J, Pei J, Kamber M (2011) Mineração de dados: conceitos e tecnologia níquel. Elsevier, Amsterdã, p 30.
140. Azadeh A, Saberi M, Ghaderi S, Gitiforouz A, Ebrahimpour V (2008) Melhor estimativa da função de demanda de eletricidade pela integração do sistema fuzzy e abordagem de mineração de dados. *Energy Convers Manag* 49(8):2165-2177
141. Azadeh A, Asadzadeh SM, Ghanbari A (2010) Um sistema de inferência fuzzy baseado em rede adaptável para estimativa de demanda de gás natural de curto prazo: ambientes incertos e complexos. *Política de Energia* 38:1529-1536
142. Yu L, Liu H (2003) Seleção de recursos para dados de alta dimensão: uma solução de filtro rápida baseada em correlação. In: Proceedings of the 20th international conference on machine learning, pp 856-863
143. Lee MC (2009) Usando máquina de vetor de suporte com um método híbrido de seleção de recursos para a previsão de tendência de ações. *Aplicativo de sistema especialista* 36(8):10896-10904
144. Webb AR (2003) Reconhecimento de padrões estatísticos. Wiley, Hoboken
145. Lin F, Liang D, Yeh CC, Huang JC (2014) Novos métodos de seleção de recursos para previsão de dificuldades financeiras. *Aplicativo de sistema especialista* 41(5):2472-2483
146. Kao LJ, Chiu CC, Lu CJ, Yang JL (2013) Integração de análise de componentes independentes não lineares e regressão vetorial de suporte para previsão de preços de ações. *Neurocomputação* 99:534-542
147. Hadavandi E, Shavandi H, Ghanbari A (2010) Integração de sistemas fuzzy genéticos e redes neurais artificiais para previsão de preços de ações. *Sistema Baseado em Conhecimento* 23:800-808
148. Hsieh TJ, Hsiao HF, Yeh WC (2011) Previsão de mercados de ações usando transformadas wavelet e redes neurais recorrentes: um sistema integrado baseado no algoritmo de colônia de abelhas artificial. *Appl Softcomput* 11(2):2510-2525
149. Zahedi J, Rounaghi M (2015) Aplicação de modelos de redes neurais artificiais e método de análise de componentes principais na previsão de preços de ações na Bolsa de Valores de Teerã. *Phys A* 438:178-187
150. Guresen E, Gulgun K, Daim TU (2011) Usando modelos de redes neurais artificiais na previsão do índice do mercado de ações. *Aplicativo de sistema especialista* 38(8):10389-10397
151. Lu CJ, Lee TS, Chiu CC (2009) Previsão de séries temporais financeiras usando análise de componentes independentes e regressão vetorial de suporte. *Sistema de Suporte Decis* 47(2):115-125
152. Dhar S, Mukherjee T, Ghoshal AK (2010) Avaliação de desempenho da abordagem de rede neural na previsão financeira: evidências do mercado indiano. In: Conferência Internacional de Comunicação e Inteligência Computacional (INCOCCI). IEEE, págs. 597-602
153. Adebisi AA, Adewumi AO, Ayo CK (2014) Comparação de modelos ARIMA e redes neurais artificiais para previsão de preços de ações. *J Appl Math* 2014:1-7
154. Lee YS, Tong LI (2011) Previsão de séries temporais usando uma metodologia baseada em média móvel integrada autoregressiva e programação genética. *Sistema Baseado em Conhecimento* 24(1):66-72
155. Chang PC, Wang DD, Zhou CL (2012) Um novo modelo por meio da evolução de rede neural parcialmente conectada para previsão de tendência de preço de ações. *Aplicativo de sistema especialista* 39(1):611-620
156. Huang CF (2012) Um modelo híbrido de seleção de ações usando algoritmos genéticos e regressão vetorial de suporte. *Appl Soft Comput* 12(2):807-818
157. Cheng C, Xu W, Wang J (2012) Uma comparação de métodos de conjunto na previsão do mercado financeiro. In: 2012 Quinto Congresso Internacional de Ciências Computacionais e Otimização. IEEE, págs. 755-759
158. Shen W, Guo X, Wu C, Wu D (2011) Previsão de índices de ações usando redes neurais de função de base radial otimizadas pelo algoritmo artificial fish swarm. *Sistema Baseado em Conhecimento* 24:378-385
159. Khan K, Sahai A (2012) Uma comparação de BA, GA, PSO, BP e LM para o treinamento de redes neurais feed forward em contexto de e-learning. *Int J Intell Syst Appl* 4(7):23-29
160. Hassan MR, Nath B, Kirley M (2007) Um modelo de fusão de HMM, ANN e GA para previsão do mercado de ações. *Aplicativo de sistema especialista* 33(1):171-180
161. Ferreira TAE, Germano CV, Adeodato PJL (2008) Uma nova metodologia de sistema inteligente para previsão de séries temporais com redes neurais artificiais. *Processo Neural Lett* 28(2):113-129
162. Ahmadi E, Jasemi M, Monplaisir L, Nabavi MA, Mahmoodi A, Jam PA (2018) Novo modelo de análise técnica de vela híbrida eficiente para temporização do mercado de ações com base na Máquina de vetores de suporte e algoritmos heurísticos de competição imperialista e genética. *Aplicação de sistema especialista* 94:21-31

Nota do editor Springer Nature permanece neutro em relação a reivindicações jurisdicionais em mapas publicados e afiliações institucionais.