

Listas de conteúdo disponíveis em [ScienceDirect](#)

Revista de Hidrologia

página inicial da revista: www.elsevier.com/locate/jhydrol

Revisar papéis

Modelo de previsão híbrido para séries de escoamento diário não estacionário: Um estudo de caso na Bacia do Rio Han, China



Tuo Xiea, Gang Zhanga,b,ÿ, Jinwang Houa, Jiancang Xiea, b, Meng Lva, Fuchao Liuc

^a Laboratório chave do estado de eco-hidráulica na região árida do noroeste da China, Universidade de Tecnologia de Xi'an, Xi'an 710048, China^b Centro de Pesquisa de Eco-hidráulica e Desenvolvimento Sustentável, Universidade de Tecnologia de Xi'an, The New Style Think Tank das Universidades de Shaanxi, Xi'an 710048, China^c State Grid Gansu Electric Power Company, Gansu Electric Power Research Institute, Lanzhou 730050, China

INFORMAÇÕES DO ARTIGO

Este manuscrito foi tratado por A. Bardossy, Editor-Chefe, com a assistência de Fi-John Chang, Editor Associado

Palavras-chave:

Previsão diária de escoamento
Decomposição em modo variacional
Rede de crenças profundas
Algoritmo de otimização de enxame de partículas aprimorado
A bacia do rio Han

RESUMO

A previsão precisa e confiável de escoamento de curto prazo é de grande importância para o gerenciamento da otimização dos recursos hídricos e operação de inundação do reservatório. A fim de melhorar a precisão da previsão de escoamento de curto prazo, foi proposta uma "reconstrução de aprendizado de decomposição de recursos" baseada em modelo híbrido chamado VMD-DBN-IPSO. Neste artigo, a decomposição de modo variacional (VMD) é usada pela primeira vez para decompor a série de escoamento diário original em um conjunto de subsequências para melhorar a resolução de frequência. A função de autocorrelação parcial (PACF) é então aplicada para determinar as variáveis de entrada de cada subsequência. O algoritmo aprimorado de otimização de enxame de partículas (IPSO) é combinado com o modelo de rede de crença profunda (DBN) para prever cada subsequência e, finalmente, reconstruir o resultado da previsão do conjunto. Três indicadores de avaliação quantitativa, erro absoluto médio (MAE), erro quadrático médio (RMSE) e coeficiente de eficiência de Nash-Sutcliffe (NSE), foram usados para avaliar e comparar os modelos estabelecidos usando os dados históricos de escoamento diário (1/1/1988 - 31/12/2017) na estação hidrológica de Yangxian e Ankang na Bacia do Rio Han da China. Enquanto isso, foi realizada uma análise comparativa do desempenho do modelo VMD-DBN-IPSO em diferentes períodos de previsão (lead time de 1, 3, 5 e 7 dias). Além disso, a capacidade de previsão do pico de escoamento do modelo VMD-DBN-IPSO é verificada ainda mais analisando os 10 picos de vazão durante a série de dados de teste. Os resultados indicam que o modelo VMD-DBN-IPSO pode sempre alcançar o melhor desempenho na etapa de treinamento e teste, e possui boa estabilidade e representatividade, o coeficiente NSE permanece acima de 0,8, e o erro de previsão de pico de fluxo está dentro de 20%. É uma ferramenta orientada por dados preferida para prever o escoamento diário.

1. Introdução

A previsão de escoamento, especialmente a previsão de escoamento diário de alta precisão, sempre foi um tópico altamente relevante e difícil na hidrologia. A previsão de escoamento precisa e confiável tem um significado importante para o controle de enchentes e redução de desastres, alocação ótima de recursos hídricos, despacho ótimo de reservatórios (Napolitano et al., 2011) etc. -características estacionárias e estocásticas devido à influência abrangente de eventos meteorológicos, características das bacias hidrográficas e condições geográficas naturais. Garantir a precisão e estabilidade de um método de previsão é a questão chave para os estudiosos relevantes estudarem (Wang et al., 2009; Zhu et al., 2016).

Nas últimas décadas, um grande número de modelos de previsão de escoamento foi proposto. Esses métodos geralmente podem ser divididos em duas categorias: modelos orientados a processos e modelos orientados a dados (Wang et al.,

2013). Geralmente, o método de previsão baseado em um modelo orientado a processos (Bittelli et al., 2010; Partington et al., 2012) requer modelos matemáticos complexos, conhecimento preciso dos processos físicos de formação do escoamento, uma grande quantidade de dados hidrológicos e meteorológicos, e às vezes julgamento humano. Existem muitos fatores limitantes no processo de aplicação, resultando em baixo desempenho de previsão do modelo e incertezas (Yoon et al., 2011). Para a operação e gestão de usinas hidrelétricas e reservatórios, a formulação de planos de despacho de curto prazo (incluindo planos de despacho diário e semanal) baseia-se principalmente na previsão diária de escoamento. No entanto, devido às suas características de curto período de pré-previsão, os modelos orientados a dados são mais utilizados para previsão para atender às necessidades de alta precisão e confiabilidade (Kumar et al., 2015). Muitos pesquisadores têm usado a tecnologia de suavização de séries temporais para prever séries temporais hidrológicas, principalmente incluindo o modelo autorregressivo (Myronidis et al., 2018), modelo de média móvel auto regressiva (ARMA) (Moeeni et al., 2017) e

ÿ Autor correspondente.

Endereços de e-mail: xtxaut6863@aliyun.com (T. Xie), zhanggang3463003@163.com (G. Zhang), liufc8127@sina.com (F. Liu).<https://doi.org/10.1016/j.jhydrol.2019.123915> Recebido em

24 de abril de 2019; Recebido em formulário revisado em 17 de junho de 2019; Aceito em 2 de julho de 2019

Disponível online em 05 de julho de 2019 0022-1694/© 2019 Elsevier BV Todos os direitos reservados.

Nomenclatura	HRB bacia do rio Han
Sistema de inferência neuro-fuzzy adaptativo ANFIS	FMI função de modo intrínseco
Rede neural artificial ANN	Otimização aprimorada de enxame de partículas IPSO
Rede de crença profunda DBN	erro absoluto médio MAE
O modelo digital de elevação	NSE Coeficiente de eficiência de Nash-Sutcliffe
árvore de decisão DT	Função de autocorrelação parcial PACF
Transformação wavelet discreta DWT	Máquina boltzmann restrita RBM
Decomposição de modo empírico do conjunto EEMD	Erro quadrático médio da raiz RMSE
Decomposição de modo empírico EMD	Máquina de vetores de suporte SVM
	Decomposição do modo variacional VMD

modelo de média móvel integrada autoregressiva (ARIMA) (Wen et al., 2019). Esses modelos assumem que a relação entre as séries de entrada e saída é linear, mas sua relação é altamente não linear. Portanto, os modelos negligenciam as características não lineares ocultas nas séries de escoamento, resultando em um desempenho de previsão ruim (Amiri, 2015). Com o desenvolvimento de algoritmos inteligentes (Yaseen et al., 2015), regressão quantílica (Fan et al., 2017), análise de cluster passo a passo (Fan et al., 2016), rede neural artificial (RNA, etc.) (Sharghi et al., 2018), árvore de decisão (DT) (Gan et al., 2014), sistema de inferência neuro-fuzzy adaptativo (ANFIS) (Zhou et al., 2019) e SVM (Aggarwal et al., 2012) têm sido amplamente usado na previsão de escoamento. Em comparação com os métodos tradicionais de regressão, esses métodos fizeram grande progresso na precisão e eficácia da previsão, o que enriqueceu as inferências da teoria da previsão de escoamento. No entanto, esses modelos pertencem à categoria de aprendizagem “superficial” (Sze et al., 2017). Eles têm capacidade limitada para endereçar recursos de entrada. Eles são propensos a cair em ótimo local ou convergência pobre, overfitting e forte dependência de parâmetros (Lee et al., 2012; McInerney et al., 2017), o que restringe a capacidade prática e interpretabilidade dos modelos de previsão até certo ponto.

O aprendizado profundo é inspirado no modo cognitivo do cérebro humano, ou seja, extrair informações de várias camadas de abstração. Por muito tempo, foi difícil otimizar os pesos da arquitetura profunda devido à falta de métodos de treinamento e experiência, o que levou à estagnação de pesquisas e aplicações relacionadas. Não foi até que Hinton propôs um método de rede de crenças profundas não supervisionado ganancioso que esse problema foi resolvido (Hinton, 2002). Desde então, o DBN tem mostrado uma habilidade incomparável na extração de características, classificação e discriminação e previsão de ajuste, derrubando o domínio de métodos de aprendizado superficial em muitos campos. Atualmente, redes de crenças profundas são amplamente utilizadas e frutíferas em reconhecimento de fala (Hinton et al., 2012), visão computacional (Krizhevsky et al., 2017), processamento de texto (Ciresan et al., 2010) e processamento de linguagem natural (Collobert et al., 2011), enquanto ainda há falta de uso em áreas relacionadas à hidrologia. Como um campo interdisciplinar que abrange aprendizado de máquina e hidrologia, a previsão de escoamento se tornará um importante exemplo de avanço na aplicação do aprendizado profundo à hidrologia.

Além disso, a complexidade do próprio processo de escoamento é outra dificuldade do modelo de previsão orientado a dados. É difícil distinguir e reconhecer essas características com precisão apenas por modelos convencionais de previsão (Noori et al., 2011). Mais e mais estudos mostram que, ao escolher a tecnologia de decomposição de tempo-frequência apropriada para pré-processar dados, informações úteis ocultas em séries temporais hidrológicas complexas podem ser extraídas com eficiência e a precisão da previsão de modelos orientados por dados pode ser melhorada (Zhang et al., 2015). Transformada Wavelet Discreta (DWT) (Lahmiri e Boukadoum, 2015), EMD (Huang et al., 2014) e EEMD (Bai et al., 2016) são métodos de decomposição tempo-frequência comumente usados. Entre eles, o DWT possui boas características de localização tempo-frequência, mas o efeito de decomposição depende da escolha da função de base, e sua adaptabilidade é baixa (Hadi e Tombul, 2018). O EMD tem uma forte adaptabilidade, mas existem alguns problemas, como efeitos de ponto final e superenvelopamento (Sankaran e Reddy, 2016). EEMD é um método aprimorado de EMD que pode analisar sinais com assistência de ruído e enfraquecer a influência

de fenômenos de aliasing modal (He et al., 2019). No entanto, o método envolve uma grande quantidade de computação, e o componente modal não pode ser controlado, o que facilmente leva à não convergência da função e afeta a precisão do algoritmo (Yu et al., 2018). Para superar essas deficiências, o VMD é introduzido na questão da previsão como um novo método adaptativo de decomposição tempo-frequência. Comparado com o modo de decomposição de triagem recursiva tradicional, o VMD pode transformar recursivamente sinais não estacionários em uma série de sequências ortogonais de função de modo intrínseco (IMF) com frequências naturais, que é essencialmente um grupo de filtros de Wiener auto-adaptativos, com um fundamentação teórica (Yin e Ren, 2015). Atualmente, a tecnologia VMD tem sido usada em muitos campos de pesquisa, como previsão de nova geração de energia (Liu et al., 2018; Zhang et al., 2019) e análise do mercado de ações internacional (Lahmiri, 2015). No entanto, existem poucos relatos sobre a aplicação do VMD a séries temporais hidrológicas.

Para melhorar ainda mais a precisão da previsão de escoamento diário, um modelo híbrido inovador baseado em “previsão de combinação de aprendizado de extração-otimização de recursos de decomposição modal” chamado VMD IPOS-DBN é proposto neste artigo para previsão de escoamento diário. Primeiro, o VMD é usado para decompor a série diária de escoamento em uma série de sequência IMF com boas características para reduzir a complexidade e a não estacionariedade da série original. Em segundo lugar, a função de autocorrelação parcial (PACF) é empregada para determinar as variáveis de entrada de cada série do FMI. Em seguida, o algoritmo de otimização IPSO é aplicado para otimizar os parâmetros do modelo DBN, e o modelo de rede de previsão ótimo baseado em DBN-IPSO é obtido no processo de treinamento.

Finalmente, cada modelo de previsão de otimização é aplicado à sequência FMI correspondente para obter os resultados finais diários de previsão de escoamento através da reorganização. Especificamente, a estrutura organizacional deste artigo é a seguinte: a Seção 2 apresenta brevemente os métodos mencionados acima, incluindo VMD, PACF, DBN e IPSO; A Seção 3 apresenta modelos de previsão e indicadores de avaliação de desempenho de previsão; A Seção 4 realiza estudos de caso; A seção 5 discute os resultados; e a Seção 6 apresenta as conclusões da pesquisa.

2. Metodologias

2.1. Extração de recursos – VMD

O VMD é um novo método de estimação de decomposição adaptável ao sinal não estacionário. Foi proposto por Dragomiretskiy et al. em 2014 (Dragomiretskiy e Zosso, 2014). O processo principal é decompor sinais não estacionários complexos em sinais K de FM e AM por filtragem de Wiener. A solução ótima do modelo variacional é buscada iterativamente para determinar a frequência angular central $\tilde{\gamma}K$ e o parâmetro de largura de banda finita $\tilde{\gamma}$. Finalmente, a banda de frequência fundamental do sinal é decomposta adaptativamente para obter o IMF sob o número controlável correspondente, K. Comparado com o modelo cíclico recursivo adotado por EMD e EEMD tradicionais, o método VMD usa decomposição de modo não recursivo e variacional para processar o sinal original, que tem melhor robustez para medição de ruído. Além disso, como K pode ser predefinido, a complexidade computacional do modelo pode ser efetivamente reduzida definindo uma convergência razoável

condições.

A estrutura geral do VMD é um problema variacional, que inclui principalmente construir problemas variacionais e resolvê-los (Majumder et al., 2018). A sequência de dados de escoamento original é considerada como um sinal não estacionário f , e o problema variacional é descrito como buscando K funções modais de largura de banda finita $u_k(t)$ ($t_k = K$) com frequência central, de modo que a soma das estimativas de largura de banda de cada modo é minimizado. A condição de restrição é que a soma de cada modal seja

igual ao sinal de entrada f . O problema variacional restrito (Naik et al., 2019) pode ser expresso como:

$$\min_{\{\tilde{y}_k\}} \sum_{k=1}^K \left\| \tilde{y}_k \right\|_{2, \tilde{y}_k}^2 \quad \text{sujeito a} \quad \sum_{k=1}^K \tilde{y}_k = f \quad (1)$$

onde $\{\tilde{y}_k\}$ é o conjunto de funções modais, $\{k\}$ é o conjunto de frequências centrais correspondentes a funções modais, \tilde{y} é a operação de convolução, K é o número total de funções modais, e $\tilde{y}_k(t)$ é a distribuição de Dirac. $\tilde{y}_k(t)$ é o fasor descrição da frequência central da função modal no plano complexo e \tilde{y}_k é a frequência central da função modal. O algoritmo VMD é resumido como Algoritmo 1 (Dragomiretskiy e Zosso, 2014).

Algoritmo 1. A implementação do VMD.

Passo 1: Defina o número de modos K ;

Etapa 2: parâmetro de inicialização $\{u_k\}^1, \{\tilde{y}_k\}^1, \tilde{y}, n \tilde{y} 0$;

Etapa 3: atualize $n \tilde{y} + 1$, repita

para $k = 1$: faça

Atualize u_k para todo $\tilde{y} > 0$, de acordo com a Eq. (2):

$$\tilde{y}_k^{n+1} = \frac{\tilde{y}_k^n - \tilde{y}_k^n \sum_{k=1}^K \tilde{y}_k^n}{1 + 2 \sum_{k=1}^K \tilde{y}_k^n} \quad (2)$$

Atualize \tilde{y}_k , de acordo com a Eq. (3):

$$\tilde{y}_k^{n+1} = \frac{\tilde{y}_k^n | \tilde{y}_k^n |}{\sum_{k=1}^K \tilde{y}_k^n | \tilde{y}_k^n |} \quad (3)$$

fim para

Ascensão dupla para todos $\tilde{y} \tilde{y} 0$:

$$\tilde{y}_k^{n+1} = \tilde{y}_k^n + \frac{K}{K+1} (\tilde{y}_k^n - \tilde{y}_k^{n+1}) \quad (4)$$

até que a seguinte condição de convergência seja alcançada:

$$\frac{\sum_{k=1}^K \left\| \tilde{y}_k^n - \tilde{y}_k^{n+1} \right\|_{2, \tilde{y}_k}^2}{\sum_{k=1}^K \left\| \tilde{y}_k^n \right\|_{2, \tilde{y}_k}^2} < \epsilon \quad (5)$$

onde X é o conjunto desejável de u_k ; $u_k(\cdot)$ é o filtro de Wiener equivalente a

a corrente residual $f(\cdot) - \sum_{k=1}^K \tilde{y}_k$; \tilde{y}_k é o centro de gravidade de $p(\cdot)$; \tilde{y}_k

espectro inferior da função modal atual; e $f \tilde{y}$ representa a forma de Fourier Tr do sinal original $x(t)$.

Passo 4: De acordo com o número modal K , obter os FMIs de subsequência modal correspondentes.

2.2. Processamento preliminar – PACF

Como o escoamento diário flutua de forma diferente em diferentes períodos, a correlação dos componentes modais decompostos pelo VMD também é diferente. Portanto, antes de prever os componentes modais, precisamos analisar a correlação entre os dados em cada FMI de acordo com os resultados da decomposição atual e selecionar o vetor próprio de entrada ótimo de cada modelo de predição através da correlação. O PACF foi usado avaliar a correlação e o resultado de cada componente (Sun et al., 2016).

Assumindo que x_t é a variável de saída, x_{t-k} é uma das variáveis de entrada variáveis se o comprimento de autocorrelação de atraso k exceder 95% de confiança intervalo $[1,96 / \sqrt{n}]$. Se todos os coeficientes do PACF estiverem na faixa de 95% intervalo de confiança, o valor anterior é usado como variável de entrada.

A PACF é descrita da seguinte forma: para séries de escoamento, a covariância na defasagem K (se $k = 0$, é variância), \tilde{y}_k é estimado como:




Fig. 1. Estrutura da rede de crenças profundas.

$$\hat{y}_k = \frac{1}{n} \sum_{t=1}^{n-k} (x_t - \bar{x})(x_{t+k} - \bar{x}) \quad (6)$$

onde \bar{x} é o valor médio da série de escoamento e $M = n/4$ é o coeficiente de histerese máximo, k é o comprimento de atraso da autocorrelação função, \hat{y}_k pode ser estimado como:

$$\hat{y}_k = \hat{y}_k / \hat{y}_0 \quad (7)$$

Com base na covariância, PACF na defasagem k ($M = \bar{y}_1, 2, \dots$), o f_{kk} é apresentado a seguir:

$$f_{kk} = \frac{\hat{f}_{kk} - \hat{f}_{kk}^2}{\hat{f}_{kk} - \hat{f}_{kk}^2} \quad (8)$$

onde $1 \leq k \leq M$.

2.3. Previsão de aprendizagem - DBN

DBN é um algoritmo de rede de aprendizado profundo eficiente proposto por Hinton et al. para lidar com dados de alta dimensão e grande escala

problemas (Hinton e Salakhutdinov, 2006), como

extração e filtragem colaborativa. Em essência, DBN consiste em um Rede restrita de máquina Boltzmann (RBM) e uma rede supervisionada de retropropagação. O nível inferior representa os detalhes dos dados originais, e o nível mais alto representa as categorias ou recursos dos dados. Os dados são abstraídos do nível inferior para o nível superior e a mineração de dados profunda ocorre passo a passo; a estrutura específica é mostrado na Fig. 1.

O processo de treinamento de aprendizado de parâmetros do modelo DBN é dividido em duas etapas: pré-treinamento RBM de pilha direta e reverso aparar.

- (1) Na fase de pré-treinamento, os parâmetros de todo o modelo DBN são inicializados, e cada RBM é treinado pelo não supervisionado aprendizagem da pilha para frente (Geng et al., 2018), e a saída de o RBM inferior é usado como entrada da camada visível do RBM superior. Porque a rede RBM só pode alcançar o ótimo intra-camada mapeamento de recursos e não pode garantir o mapeamento de recursos ideal de todo o modelo DBN, é necessário entrar na fase de ajuste fino para otimizar os parâmetros de toda a rede.
- (2) Na fase de ajuste fino reverso, o DBN usa o método de aprendizagem (Zrira et al., 2018) para otimizar e ajustar ainda mais

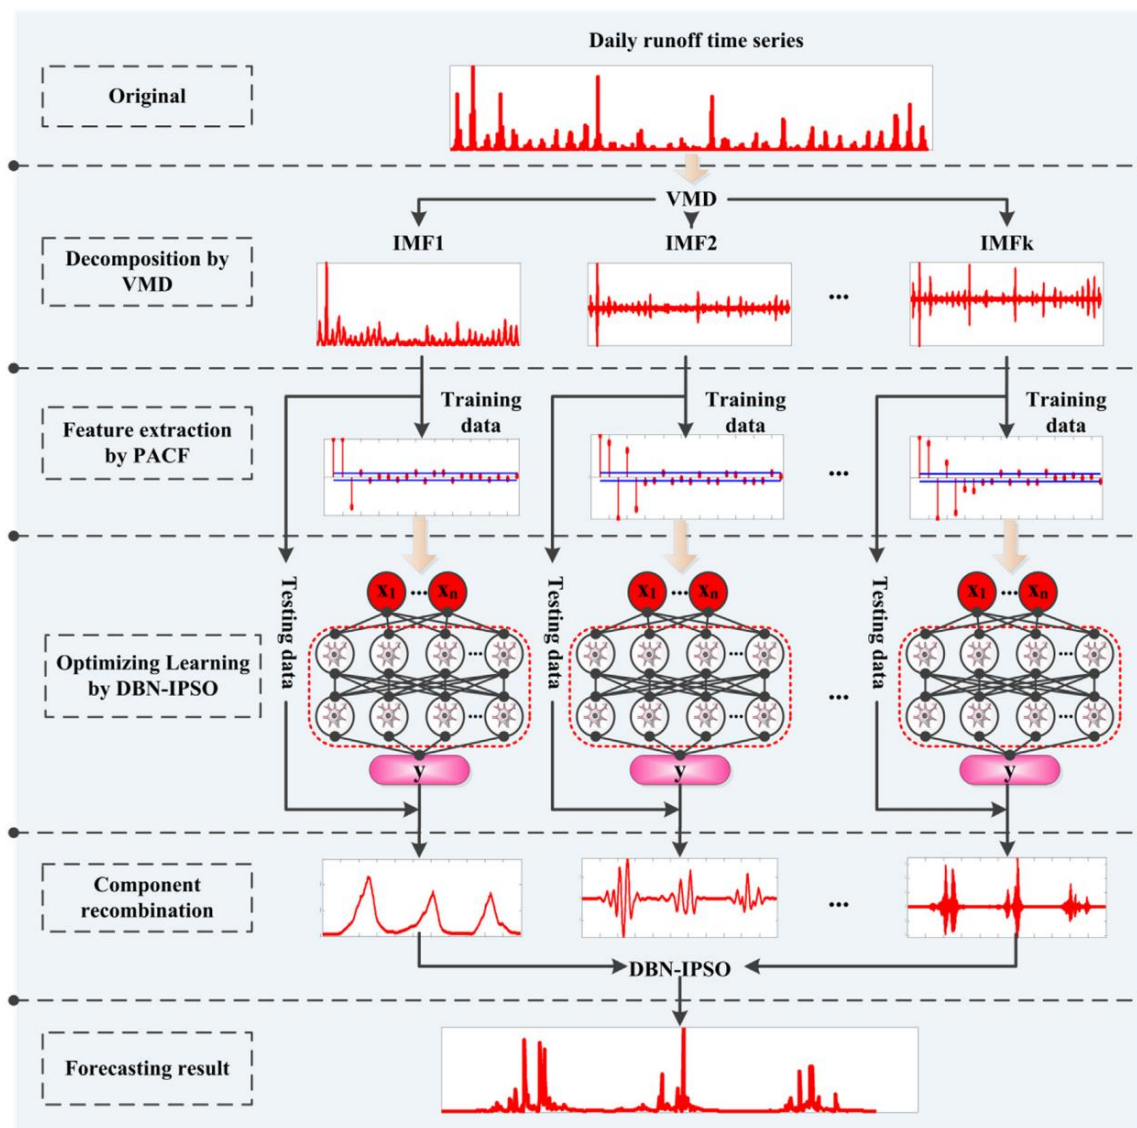


Fig. 2. Aplicação do modelo proposto VMD-DBN-IPSO.

os parâmetros relevantes do espaço de rede, propagar o deslocamento valor entre a saída esperada e os dados reais camada por camada, ajuste o peso de treinamento de cada camada de conexão no todo o modelo e concluir todo o treinamento do modelo DBN.

2.4. Otimização de parâmetros – IPSO

Para superar a desvantagem de que a rede DBN cai facilmente em, o ótimo local no processo de aprendizagem e treinamento, um IPSO algoritmo (Cheng e Jin, 2015), é usado para resolver o peso da conexão do modelo DBN. Eq. (9) aumenta a capacidade de otimização local em o último estágio da evolução. Eq. (10) pode permitir a auto-busca de partículas e a capacidade cognitiva de todos os grupos de partículas.

$$kT_{\text{máximo}}() / \ddot{y} \ddot{y} \ddot{y} = \ddot{y}_{\text{min}} - \ddot{y} \quad (9)$$

$$\ddot{y} = \ddot{y} + C_1 \frac{C_{\text{máximo}} - C_{\text{mínimo}}}{C_{\text{máximo}} - C_{\text{mínimo}}} \quad (10)$$

Na Eq. (10), \ddot{y}_{max} e \ddot{y}_{min} são os valores máximo e mínimo de o peso de inércia inicial, respectivamente; C_{max} e C_{min} são os máximos e valores mínimos do fator de aceleração inicial, respectivamente; \ddot{y} , C_1 e C_2 são o peso de inércia, o fator de aceleração máxima e o fator de aceleração mínimo da k -ª iteração, respectivamente; e T é o número de iterações. As etapas específicas da partícula algoritmo de enxame pode ser referido na literatura (Kang et al., 2018). A função fitness é definida neste artigo como:

$$F_{\text{pt aptidão}} = \sum_{i=1}^N \sum_{j=1}^m (\ddot{y}_{ij} - \ddot{y}_{ij})^2 \quad (11)$$

onde N e m são o número da amostra e o número da dimensão de dados observados, respectivamente; p_{ij} e t_{ij} são o valor reconstruído e o valor verdadeiro da i -ésima amostra em dados de observação de j -ésima dimensão, respectivamente.

3. Modelos de previsão e indicadores de avaliação

3.1. O modelo do conjunto de decomposição VMD-DBN-IPSO

Depois de discutir cada constituinte-chave separadamente, a abordagem do

modelo proposto baseado em 'otimização de extração de características de decomposição modal e previsão de combinação de aprendizado', VMD-DBN-IPSO, pode ser concluído como segue e diagramado na Fig. 2. O processo de o algoritmo do modelo é descrito da seguinte forma:

A primeira parte: decomposição modal. O escoamento instável original sequência é decomposta em vários componentes IMF relativamente estáveis com características óbvias.

A segunda parte: extração de recursos. De acordo com o valor PACF de cada sequência IMF, a análise de histerese de sequência de componentes é realizado para reduzir a influência das interações entre diferentes recursos e extrair as variáveis de entrada ideais.

A terceira parte: otimização e aprendizado. Os parâmetros são otimizados pelo IPSO e os modelos de previsão DBN dos componentes IMFS são determinados reduzindo ou aumentando o número de camadas ocultas e neurônios em cada camada.

A quarta parte: previsão de reconstrução. Na terceira parte, o os resultados da previsão de cada componente IMF são reconstruídos usando DBN IPSO, e os resultados finais da previsão são obtidos.

3.2. Critérios de avaliação do modelo

Para avaliar de forma abrangente o efeito de previsão do modelo, este artigo avalia os resultados de previsão do modelo considerando a três aspectos a seguir:

- (1) Precisão dos resultados da previsão. O MAE é usado para caracterizar o precisão geral da previsão.

$$MAE = \frac{1}{N} \sum_{i=1}^N |\ddot{y}_i - \ddot{y}_i| \quad (12)$$

onde N é o número da amostra; e y_i é o valor medido; \ddot{y}_i é o valor previsto.

- (2) Precisão dos resultados de previsão. O RMSE é usado para caracterizar o precisão geral da previsão (Gopalan et al., 2018).

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (\ddot{y}_i - \ddot{y}_i)^2} \quad (13)$$

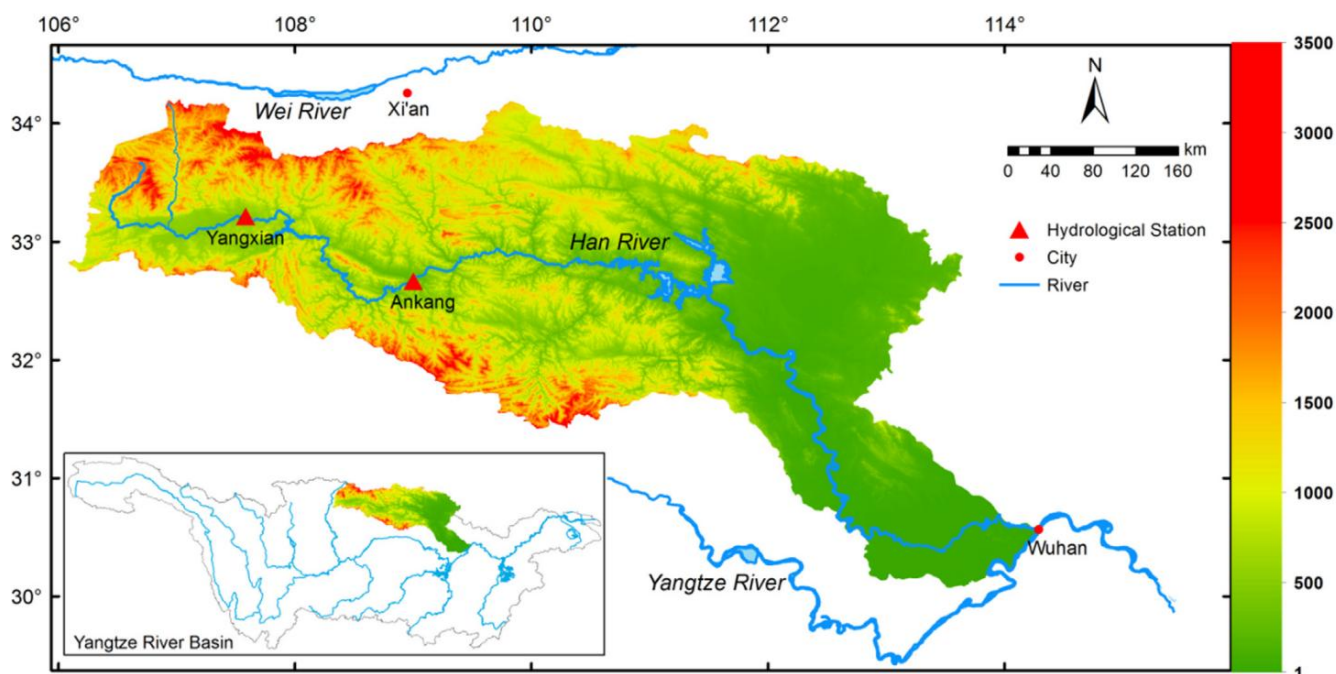


Fig. 3. Área de estudo e localização das estações hidrologicas Yangxian e Ankang na Bacia do Rio Han.

A faixa de valores de RMSE é (0, +∞), e quanto mais próximo o valor estiver de 0, quanto maior a precisão da previsão.

(3) Estabilidade dos resultados da previsão. A precisão da previsão não pode avaliar completamente o desempenho da previsão do modelo. Se o erro de previsão flutuar muito, mesmo que a precisão geral seja alta, o modelo não é confiável. O coeficiente de eficiência de Nash-Sutcliffe (NSE) é sensível à flutuação da série de dados e pode descrever a capacidade de rastreamento do valor previsto para o valor medido. O NSE é usado para avaliar a estabilidade do valor previsto (Naik et al., 2019). O método de cálculo é o seguinte:

$$NSE = 1 - \frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (14)$$

onde \bar{y} é o valor médio da amostra medido. A faixa de valores de NSE é (\bar{y} , 1]. Quanto mais próximo o valor estiver de 1, maior será a precisão e estabilidade dos resultados da previsão. Quanto mais próximos os resultados da previsão estiverem de 0, mais próximo o valor médio das amostras medidas, mais credível é o modelo global, mas maior é o erro do processo. Quando o valor de NSE é inferior a 0, os resultados da previsão do modelo não são credíveis.

4. Estudo de caso

4.1. Área de estudo e dados

O rio Han, o maior afluente do rio Yangtze, origina-se no sopé sul das montanhas Qin, na província de Shaanxi, e flui pelas províncias de Shaanxi e Hubei. Converte para o rio Yangtze em Wuhan com um comprimento total de 1577 km. A área da bacia é de cerca de 159.000 km² (106°25'-114°33'E, 30°17'-34°33'E). Localizada na zona de transição de mudanças hidrológicas e climáticas no Norte e Sul da China, a Bacia do Rio Han (HRB) pertence à zona de clima subtropical de monções do Leste Asiático, com clima quente e úmido e temperatura média anual variando de 12°C a 16°C. °C (Zhou et al., 2017). A topografia da bacia é alta a oeste e baixa a leste, e gradualmente desce das áreas montanhosas médias e baixas a oeste para as áreas montanhosas e planas, formando um sistema de água em forma de veia.

O escoamento médio anual é de 18,7 bilhões de m³ e a precipitação média anual é de aproximadamente 843,1 mm com altas

variabilidade anual. A precipitação máxima por quatro meses consecutivos é responsável por cerca de 55% a 65% da precipitação anual, sendo que a estação das cheias de verão foi do final de junho ao final de julho, e a estação das cheias do outono foi do final de agosto a meados de outubro (Zheng et al., 2013). A Fig. 3 mostra um modelo digital de elevação (DEM) da região e dos rios localizados na bacia. Vale a pena mencionar que o rio Han não é apenas uma importante área de produção de grãos e uma importante zona de desenvolvimento econômico na construção "um cinturão e uma estrada" da China, mas também uma fonte de conservação de água para o "Projeto de Desvio de Água do Sul para o Norte" na China. Considerando o impacto das mudanças climáticas e as atividades humanas, a gestão do despacho de recursos hídricos no rio Han enfrenta grande pressão. Portanto, a bacia é um candidato útil para o desenvolvimento de um modelo de previsão híbrido.

Neste artigo, os dados diários de escoamento foram coletados das estações hidrológicas Yangxian (107°35'E, 33°13'N) e Ankang (109°00'E, 32°40'N) no HRB, que é a principal estação de controle de fluxo do rio Han. Esses valores observados são coletados do Anuário Hidrológico do HRB e da Rede de Informações sobre Recursos Hídricos e Hidrológicos da Província de Shaanxi (<http://www.shxsw.com.cn/7/39/list.aspx>) publicados, e a qualidade dos dados é rigorosamente controlada no processo de publicação. Os dados diários de escoamento das duas estações foram de 01/01/1988 a 31/12/2017, sendo de 01/01/1988 a 31/12/2012 (9132 dias, representando 83,35% do conjunto total de dados) é usado para calibração, enquanto que de 01/01/2013 a 31/12/2017 (1826 dias, representando 16,65% do conjunto total de dados) é usado para validação, conforme mostrado na Fig. 4.

A Tabela 1 mostra os parâmetros característicos dos dados diários de escoamento nas estações hidrológicas de Yangxian e Ankang. De acordo com as propriedades estatísticas, não houve diferença significativa entre a divisão dos dados de treinamento e os dados de teste, o que significa que o conjunto de treinamento contém muitas informações sobre as características hidrológicas e indica que a divisão dos conjuntos de dados é razoável.

4.2. Decomposição de dados com VMD

De acordo com o modelo de previsão estabelecido na Seção 3.1, o modelo VMD é aplicado para decompor a série de escoamento original para reduzir a complexidade da série de escoamento. O número apropriado de modos K pode extrair os recursos de dados originais de forma mais completa. Para evitar a composição excessiva, a maioria dos estudiosos usou o método de frequência central (Huang et al., 2016) para determinar o número de modos K . O VMD é

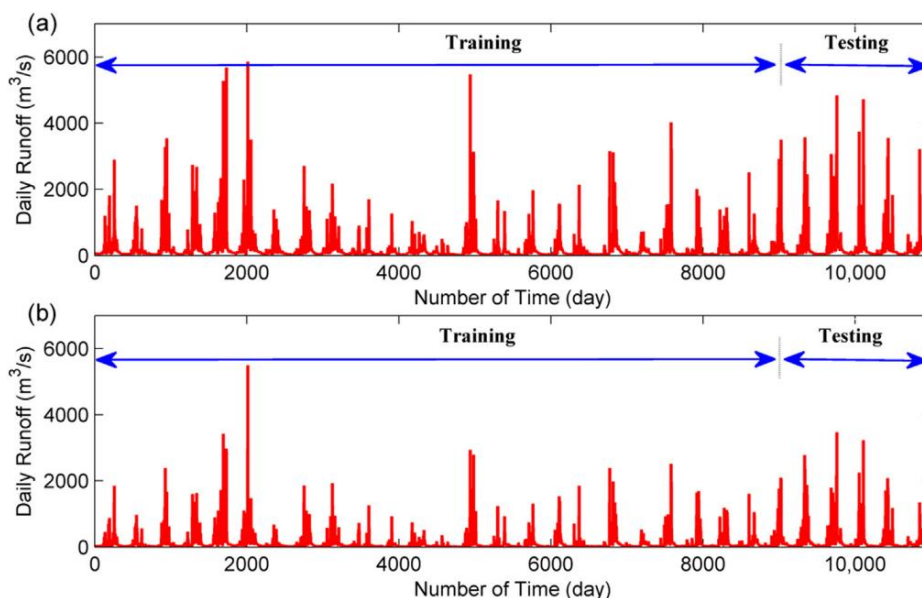


Fig. 4. Os valores observados da série diária de escoamento do conjunto de dados de treinamento e teste variaram de 01/01/1988 a 31/12/2017. (a) Estação Yangxian e; (b) Estação Ankang.

tabela 1

Os parâmetros característicos do escoamento diário nas estações hidrológicas de Yangxian e Ankang (m3 / s).

Estação	Comprimento máximo dos dados do conjunto de dados	M mín.	Cv	C
YangXian Todos	10.958	5860,00 4,94 152,81 1,62 4,16		
	Treinamento 9132	5860,00 4,94 143,78 1,59 4,09		
	Testando 1826	4840,00 18,8 199,63 1,73 4,5		
AnKang	Tudo 10.958	5500,00 1,68 95,95	1,71	4.2
	Treinamento 9132	5500,00 1,68 89,73	1,72	4,24
	Testando 1826	3470,00 8,76 128,19 1,69 4,32		

Max, Min, M, Cv e Cs denotam o valor geral máximo, mínimo e médio de conjunto de dados, desvio padrão e assimetria, respectivamente.

empregado para decompor o conjunto de treinamento de Yangxian Hydrological estação, e as frequências centrais sob diferentes valores de K são determinadas conforme mostrado na [Tabela 2](#). Vale a pena notar que a extração de sequência de características aqui visa apenas treinar dados para evitar potenciais erros nos resultados da previsão devido ao uso de dados futuros.

Da [Tabela 2](#), quando $K = 8$, o valor da frequência central é o maior, ou seja, 4928,54 Hz, e quando o número de K aumentou, o diferença da frequência central do K adjacente é menor e menor, o que indica a aparência do modo de mixagem. Portanto, quando $K = 8$, este ponto crítico é escolhido como o valor ótimo, e o outros parâmetros internos dos algoritmos VMD ([Shi et al., 2018](#)) são mostrado na [Tabela 3](#).

O conjunto de treinamento de séries diárias de escoamento nas estações hidrológicas Yangxian e Ankang são decompostos pelo VMD, respectivamente, e os resultados são mostrados na [Fig. 5](#).

4.3. Determinação de variáveis de entrada pelo PACF

De acordo com a descrição da extração de recursos de dados de séries temporais na [Seção 2.2](#), o PACF é usado para determinar as variáveis de entrada do modelo de treinamento. Quando f está no intervalo de confiança de 95%, a série de escoamento da dimensão t é linearmente independente e pode ser usada como variável de entrada; quando há múltiplos f no intervalo de confiança de 95%, o valor mínimo de $t-1$ é escolhido como o número de atraso, ou seja, o variável de entrada ideal. A [Fig. 6](#) mostra o PACF de cada FMI decomposto pelo VMD na estação hidrológica de Yangxian, e as variáveis de entrada ótimas de cada FMI são apresentadas na [Tabela 4](#).

O primeiro FMI do VMD, ou seja, FMI1, é empregado como exemplo para ilustrar o processo de determinação das variáveis de entrada e saída por PACF da [Fig. 6](#). Quando o intervalo de tempo t é 8d, o PACF é 0,03 em 95% intervalo de confiança, e $t \hat{y} 1 = 7d$ é o tempo de atraso de IMF1. Em outros Em outras palavras, os dados de escoamento diário do FMI1 de $t \hat{y} 7d$ a $t \hat{y} 1d$ por 7 dias consecutivos são usados como variáveis de entrada, e o escoamento diário do período previsto td , $(t + 2)d$, $(t + 4)d$, e $(t + 6)d$ são usados como saída variáveis. A [Fig. 7](#) traça o processo de determinação da entrada e saída

mesa 2

Frequências centrais correspondentes a diferentes valores de K na estação Yangxian.

Número modal	Frequência central/Hz									
	FMI1	FMI2	FMI3	FMI4	FMI5	FMI6	FMI7	FMI8	FMI9	FMI10
K = 1	173,79 — —					—	—	—		
K = 2	70,82	1279,45 — —				—	—	—		
K = 3	53,43	710,15	1804,61	—	—	—	—	—		
K = 4	45,82	596,42	1277,39	2.515,86	—	—	—	—		
K = 5	41.03	531,13	1089,30	2036.06	3450,88	—	—	—		
K = 6	33,40	425,78	915,07	1655,22	2657,94	4121,21	—	—		
K = 7	30.01	379,39	815,97	1399,42	2214,80	3263,56	4560,66	—		
K = 8	28,35	357,13	764,75	1272,46	1976,99	2766,37	3750,21	4928,54	—	—
K = 9	26,72	335,23	719,01	1165,45	1768,27	2448,87	3249,16	4016,36	4650,04	—
K = 10	25,83	323,41	692.11	1095,21	1604,23	2218,83	2938,08	3754,98	4180,46	4428,25

Os valores marcados em negrito denotam os desempenhos das variáveis ótimas.

Tabela 3

Parâmetros de algoritmos VMD usados em nossos experimentos.

Parâmetros	α	β	K	DC	λ	μ
Valor	2000	0	8	0	1	1e-5

variáveis do IMF1 são descritas em.

4.4. Previsão de componentes baseada em DBN-IPSO

Antes de aplicar o modelo híbrido DBN-IPSO para previsão de séries de escoamento, a taxa de aprendizado de cada camada oculta RBM no modelo DBN é definido como 0,01, o número máximo de iterações é 1000, e o peso da conexão é obtido pela otimização IPSO. Entre eles, o parâmetros do modelo de otimização de peso IPSO são definidos da seguinte forma: $\hat{y}max = 0,9$, $\hat{y}min = 0,4$, $Cmax = 2,6$, $Cmin = 0,6$, $T = 1000$ e população tamanho é 50, e a base de cada configuração de parâmetro é encontrada na referência ([Al-Musayih et al., 2018](#)). Ao treinar a estrutura do modelo DBN, o O número de neurônios ocultos é selecionado camada por camada usando o método de erro experimental e os efeitos de previsão de diferentes redes estruturas são comparadas e verificadas.

Porque os pesos e limites correspondentes são otimizados por o modelo IPSO durante cada treinamento, as camadas ocultas são definidas para RBM1, camadas RBM2 e RBM3, por sua vez, e o número de neurônios ocultos em cada camada RBM é definida para 3–24 (o intervalo é 3), um total de 8 níveis. FMI1 é usado como exemplo para descrever a determinação do DBN-IPSO estrutura de rede. O processo específico é o seguinte.

Primeiro, inicialize um único modelo DBN de camada oculta com 7 neurônios de entrada e 1 neurônio de saída, execute dez vezes para diferentes neurônios ocultos, e calcular cada índice de desempenho e tempo médio de execução. o os resultados são mostrados na [Tabela 5](#). O modelo DBN-IPSO tem o melhor aprendizado desempenho quando a camada RBM1 possui 18 neurônios ocultos.

Então, seja 18 o número de neurônios ocultos na camada RBM1, e uma camada oculta (RBM2) é adicionada para conduzir o aprendizado do modelo DBN da dupla camada oculta. O valor ideal do número de unidades na camada RBM2 é determinada por sua vez, e o desempenho da previsão é mostrado na [Tabela 6](#). Quando os neurônios ocultos do RBM2 camada são 12, o MAE é 1,8459, o RMSE é 4,0161, e o NSE é 0,9907, o modelo tem o melhor desempenho de aprendizado e é superior ao o valor de avaliação de desempenho do modelo DBN-IPSO com apenas RBM1. É necessário continuar aumentando o RBM3 para testes.

Por analogia, a otimização e aprendizado do modelo DBN estrutura é realizada, deixando os neurônios ocultos de RBM1 e RBM2 ser 18 e 12, respectivamente, os valores ótimos do número de unidades na camada RBM3 são determinadas por sua vez, e a previsão o desempenho é mostrado na [Tabela 7](#). Quando os neurônios ocultos do RBM3 são 9, o DBN com 3 camadas ocultas tem o valor de desempenho ideal. No entanto, nenhum de seus indicadores de desempenho é mais excelente do que




Fig. 5. Resultados da decomposição por VMD: (a) Estação Yangxian (conjunto de treinamento: o primeiro de 9132 dias) e (b) estação Ankang (conjunto de treinamento: o primeiro de 9132 dias).

Modelos DBN com duas camadas ocultas. Para o conjunto de dados do componente IMF1, com o aumento do número de camadas ocultas, a capacidade de aprendizado otimizado do modelo é gradualmente aprimorada, e o ótimo é obtido quando há 2 camadas RBM, e então o erro é aumentado gradualmente e o aprendizado otimizado habilidade é reduzida. Ou seja, o modelo de previsão DBN-IPSO tem um efeito melhor ao adotar a estrutura de 4 camadas de “7-18-12-1” (camada de entrada: 7 neurônios, camada oculta: RBM1: 18 neurônios, RBM2: 12 neurônios, camada de saída: 1 neurônio).

Através do método acima, a estrutura do modelo DBN do

Os componentes IMF2-IMF8 e o desempenho de previsão são obtidos, conforme mostrado na [Tabela 8](#).

À medida que as séries originais são decompostas camada por camada, as frequências das subséries são reduzidas gradualmente com processos periódicos óbvios (ver [Fig. 5](#)). Correspondentemente, o desempenho da previsão dos FMIs é melhorado gradualmente, resultando em um aumento no valor de NSE e uma diminuição nos valores de MAE e RMSE. Os resultados são consistentes com a motivação que usamos a estrutura do conjunto de decomposição para construir um modelo de previsão. O processo de decomposição pode gerar

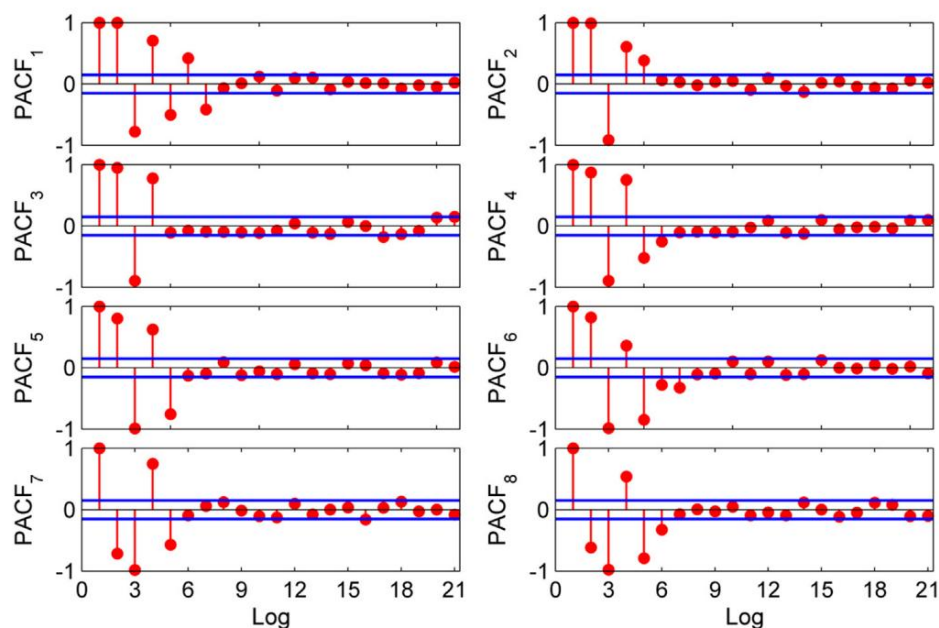


Fig. 6. O PACF de cada FMI decomposto pelo VMD.

Tabela 4
As variáveis de entrada ótimas de cada FMI decompostas pelo VMD.

FMI's decompostos	Números de entrada	Variáveis de entrada	Saída
FMI1	7	$x(t) \quad 2 \times (1) \quad 2 \times (4) \quad 7 \times (5) \quad t \quad 5 \times (t) \quad 6 \times (t)$	$x(t) \quad 1$
FMI2	5	$x(t) \quad y \times (t) \quad t \quad (3) \quad (4) \quad (5) \quad t$	$x(t) \quad 2$
FMI3	4	$x(t) \quad (4) \quad y \times (t) \quad 4 \times (t) \quad 3 \times (t)$	$x(t) \quad 3$
FMI4	6	$x(t) \quad 1 \times (t) \quad 2 \times (8) \quad 5 \times (6) \quad y \times (t) \quad t$	$x(t) \quad 4$
FMI5	5	$t \times (t) \quad (t) \quad 5 \times (t) \quad 6 \times (7) \quad 8 \times (t)$	$x(t) \quad 5$
FMI6	7	$x(t) \quad 2 \times (1) \quad 2 \times (4) \quad 7 \times (5) \quad t \quad 5 \times (t) \quad 6 \times (t)$	$x(t) \quad 6$
FMI7	5	$x(t) \quad y \times (t) \quad t \quad (3) \quad (4) \quad (5) \quad t$	$x(t) \quad 7$
FMI8	6	$x(t) \quad y \times (t) \quad 2 \times (8) \quad 4 \times (5) \quad 6 \times (t) \quad t$	$x(t) \quad 8$

entradas para modelos DBN, melhorando assim o desempenho da previsão.

4.5. Reconstrução dos resultados da previsão

Neste artigo, o modelo de previsão DBN-IPSO é usado para reconstruir os resultados da previsão de cada componente (IMF1–IMF8), levando os FMIs dados de amostra como entrada e escoamento real como saída, o modelo é treinado, e então os valores de previsão de cada componente são usados como entrada para obter os valores finais de previsão de escoamento. As Figs. 8 e 9 mostram o resultados da previsão de escoamento diário usando o modelo VMD-DBN-IPSO em Estações Yangxian e Ankang, respectivamente.

5. Análise e discussão de resultados

Para verificar a precisão e estabilidade da previsão do modelo proposto, cinco tipos de modelos de previsão de escoamento em escala diária, como ARMA, DBN, DBN-IPSO, EEMD-DBN-IPSO e VMD-DBN-IPSO, são estabelecido respectivamente. O modelo único pôde verificar se o modelo DBN IPSO tem melhor capacidade preditiva, o EEMD-DBN-IPSO e Os modelos VMD-DBN-IPSO podem verificar se a integração de decomposição modelo pode melhorar muito a precisão da previsão, e a redução de ruído capacidade de otimização da decomposição VMD é melhor do que a do Decomposição EEMD. Figs. 10 e 11 mostram os resultados do segundo turno previsões da série para as estações Yangxian e Ankang um dia à frente. Figs. 12 e 13 mostram a figura adequada da previsão da série de escoamento resultados para as estações Yangxian e Ankang um dia antes.

Pode ser visto a partir das Figs. 10 e 11 que o conjunto de treinamento e o conjunto de teste resultados de previsão de vários modelos nas estações Yangxian e Ankang estão de acordo com as expectativas, e a precisão da previsão é classificada

de alto para baixo como: VMD-DBN-IPSO > EEMD-DBN-IPSO > DBN IPSO > DBN > ARMA.

Na previsão de modelo único, o ARMA modelo tem baixa capacidade de ajuste e alto erro de previsão. Comparado com Modelo ARMA, modelo DBN possui mecanismo de aprendizado profundo cuja especificidade conteúdo é aprendizagem não supervisionada positiva e supervisão reversa aprendizagem, a precisão de previsão do modelo é melhorada. No entanto, os parâmetros do modelo são mais difíceis de selecionar, o que pode levar a sobreajuste. Usando o algoritmo de otimização IPSO para otimizar a parâmetros do modelo DBN, o desempenho de previsão do modelo pode ser efetivamente melhorado. Comparado com os resultados de previsão de modelo único, o modelo de previsão combinado após processado pelo EEMD e a decomposição modal VMD é sempre melhor do que o modelo único previsão, que pode se ajustar melhor ao fluxo de pico e ter melhor precisão de previsão. Além disso, vale ressaltar que a previsão resultados do modelo VMD-DBN-IPSO proposto neste artigo são sempre melhor do que o modelo EEMD-DBN-IPSO, principalmente porque diferentes métodos de decomposição tem um método de controle diferente no número modal, afetando assim o tamanho do erro de previsão. o frequência central da decomposição modal VMD é controlável, que pode efetivamente evitar alias modal comparando com EEMD modelo de decomposição modal.

A linha de ajuste do modelo VMD-DBN-IPSO nas Figs. 12 e 13 (o linha de montagem vermelha nas Figs. 12 e 13) está mais próximo da linha de ajuste ideal (a linha de encaixe preta nas Figs. 12 e 13), e o erro de previsão de pico é o menor e o efeito de previsão geral é o melhor, seguido por EEMD DBN-IPSO, DBN-IPSO e DBN. O modelo ARMA tem o pior ajuste efeito, e o efeito de ajuste do período de treinamento é melhor do que o período de teste (o ângulo entre a linha ajustada de cada modelo e o linha ajustada ideal durante o período de treinamento é menor do que o teste

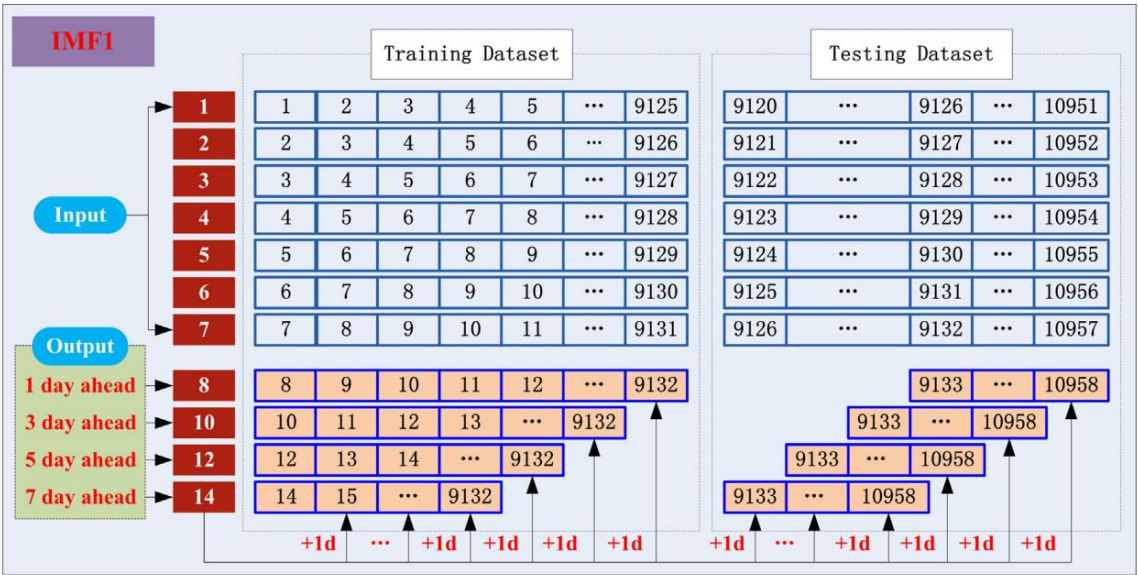


Fig. 7. O processo de determinação das variáveis de entrada e saída do FMI1.

Tabela 5
Resultados de um DBN-IPSO com uma camada oculta para previsão do IMF1.

Estrutura prevista	MUITO DE	RMSE	NSE	Tempo/s de treinamento	Estrutura prevista	MUITO DE	RMSE	NSE	Tempo/s de treinamento
7-3-1	3,2749	5,701964	0,9634	16.831	7-15-1	2,3295	4,9788	0,9858	6.113
7-6-1	2,9914	5,2679	0,9714	11.374	7-18-1	2,1187	4,8988	0,9862	5.737
7-9-1	2,7103	5,1843	0,9783	7.068	7-21-1	2,2362	4,9125	0,9812	14.661
7-12-1	2,4912	5,0016	0,9791	6.663	7-24-1	2,4144	4,9954	0,9807	18.206

Os valores marcados em negrito denotam os desempenhos das variáveis ótimas.

Tabela 6
Resultados de um DBN-IPSO com duas camadas ocultas para previsão do IMF1.

Estrutura prevista	MUITO DE	RMSE	NSE	Tempo/s de treinamento	Estrutura prevista	MUITO DE	RMSE	NSE	Tempo/s de treinamento
7-18-3-1	2,8814	5,2733	0,9799	28.77	18-7-15-1	1,9105	4,2147	0,9811	30.83
7-18-6-1	2,3191	4,8605	0,9854	25.889	18-7-18-1	2,0721	4,3524	0,9809	29.517
7-18-9-1	2,0516	4,2411	0,9899	24.222	18-7-21-1	2,1157	4,3954	0,9789	34.539
7-18-12-1	1,8459	4,0161	0,9907	20.793	18-7-24-1	2,1967	4,5677	0,9754	37.512

Os valores marcados em negrito denotam os desempenhos das variáveis ótimas.

Tabela 7
Resultados de um DBN-IPSO com três camadas ocultas para previsão do IMF1.

Estrutura prevista	MUITO DE	RMSE	NSE	Tempo/s de treinamento	Estrutura prevista	MUITO DE	RMSE	NSE	Tempo/s de treinamento
7-18-12-3-1	2,5651	4,7903	0,9852	45.474	18-7-12-15-1	2,2496	4,5491	0,9816	44.259
7-18-12-6-1	2,2549	4,5217	0,9874	42.062	18-7-12-18-1	2,2755	4,6758	0,9791	65.094
7-18-12-9-1	2,0125	4,3183	0,9899	53.865	18-7-12-21-1	2,3179	4,8125	0,9779	58.117
7-18-12-12-1	2,1914	4,4724	0,9827	54.184	18-7-12-24-1	2,3663	4,9727	0,9761	62,9

Os valores marcados em negrito denotam os desempenhos das variáveis ótimas.

Tabela 8
Estrutura DBN de cada componente IMF após a decomposição VMD.

Componente de decomposição VMD	Estrutura do modelo DBN	Conjunto de dados de treinamento (m3 /s)			Conjunto de dados de teste (m3 /s)		
		MUITO DE	RMSE	NSE	MUITO DE	RMSE	NSE
FMI1	7-18-12-1	1,8459	4,0161	0,9907	2,8134	6,2334	0,9867
FMI2	5-15-9-1	1,6706	4,0916	0,9913	2,7038	6,0813	0,9918
FMI3	4-24-15-6-1	1,6201	3,9350	0,9921	2,5991	5,8090	0,9928
FMI4	6-9-6-1	1,3749	3,3265	0,9961	2,1514	4,9284	0,9969
FMI5	5-12-6-1	1,2499	3,0512	0,9980	2,0416	4,6886	0,9971
FMI6	7-18-12-9-1	1,0501	2,5101	0,9992	1,6182	3,6966	0,9989
FMI7	5-24-18-9-1	0,7572	1,9237	0,9997	1,1810	2,6693	0,9997
FMI8	6-15-12-1	0,4600	1,1812	0,9999	0,7481	1,7599	0,9999

período), não há fenômeno de sobreajuste.

Embora hidrogramas e gráficos de dispersão possam avaliar intuitivamente a correspondência temporal entre os dados observados e a previsão do modelo valor, os indicadores estatísticos podem avaliar com mais precisão a previsão poder de cada conjunto de dados do modelo. As Tabelas 9 e 10 mostram os resultados da avaliação dos modelos ARMA, DBN, DBN-IPSO, EEMD-DBN-IPSO e VMD DBN-IPSO em Yangxian e Ankang durante seus respectivos período de treinamento e período de teste.

A análise mostra que DBN-IPSO tem melhores resultados de previsão de fluxo do que DBN e ARMA. Comparado com DBN-IPSO, usando EEMD e VMD métodos de decomposição melhoram a precisão da previsão, o VMD-DBN IPSO é o melhor modelo de previsão de fluxo diário em HRB. Mais importante, tal conclusão é verdadeira tanto para o conjunto de dados de teste quanto para o treinamento conjunto de dados.

Tomando a Estação Yangxian como exemplo, para o conjunto de dados de escoamento previsto quando o período de previsão é de 1 dia à frente, os valores MAE de cada modelo durante o período de teste são como: 11,72 (VMD-DBN-IPSO) vs. 20,41 (EEMD-DBN-IPSO), 40,95 (DBN-IPSO), 59,19 (DBN), 82,38 (ARMA), o valor MAE do modelo VMD-DBN-IPSO é reduzido por 42,58%, 71,38%, 80,19% e 85,77%, respectivamente, em comparação com outros modelos. Enquanto os valores de RMSE são respectivamente como: 38,57 (VMD-DBN

IPSO) vs. 57,78 (EEMD-DBN-IPSO), 81,82 (DBN-IPSO), 111,07 (DBN), 141.06 (ARMA), os valores RMSE do modelo VMD-DBN-IPSO são reduzidos em 33,25%, 52,86%, 65,27% e 72,66%, respectivamente, em comparação com outros modelos. Este resultado também concorda com um valor NSE relativamente alto (0,9798 para o VMD-DBN-IPSO vs. 0,9236 para o EEMD-DBN-IPSO, 0,8224 para o DBN-IPSO, 0,7617 para o DBN e 0,4836 para o ARMA modelo), os valores NSE do modelo VMD-DBN-IPSO são reduzidos em 6,08%, 19,14%, 28,63% e 102,61% respectivamente em relação a outros modelos. Através do cálculo e comparação de estatísticas (como MAE, RMSE e NSE) do conjunto de dados de treinamento e conjunto de teste de cada modelo, descobriram que o modelo VMD-DBN-IPSO fornece 1- previsões de escoamento para o dia anterior quase para todos os modelos (Tabelas 9 e 10).

Os estudos acima mostram que todos os DBN-IPSO, EEMD-DBN-IPSO e os modelos VMD-DBN-IPSO têm um coeficiente NSE superior a 0,8 quando o tempo de atraso do período de treinamento e período de teste é de 1 dia (ou seja, o período previsto é de 1 dia), e tanto o MAE quanto o RMSE são pequenos, o efeito é satisfatório. Exceto que a previsão hidrológica se concentra na precisão da previsão, a duração do período prospectivo também é de grande importância. importância para orientar a operação e despacho do reservatório. Agora tomando o VMD-DBN-IPSO como exemplo, ilustramos os efeitos da período de previsão de 1d, 3d, 5d e 7d nos resultados da previsão. A Fig. 14 é

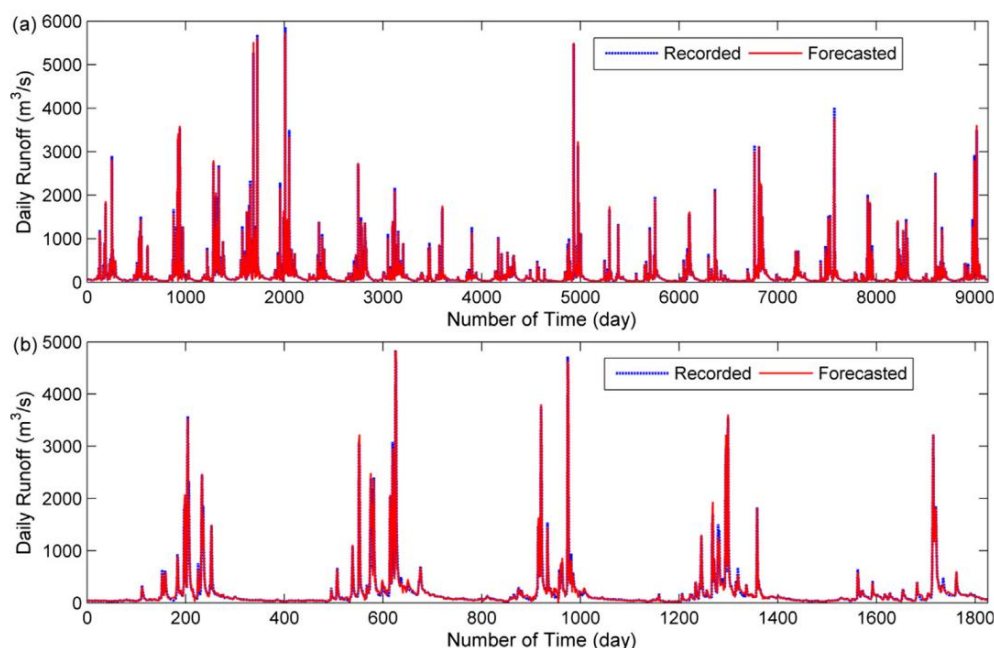


Fig. 8. Resultados da previsão da combinação VMD-DBN-IPSO para a estação Yangxian. (a) Conjunto de treinamento (o primeiro de 9132 dias de 01/01/1988 a 31/12/2012); (b) Conjunto de testes (o restante de 1826 dias de 01/01/2013 a 31/12/2017).

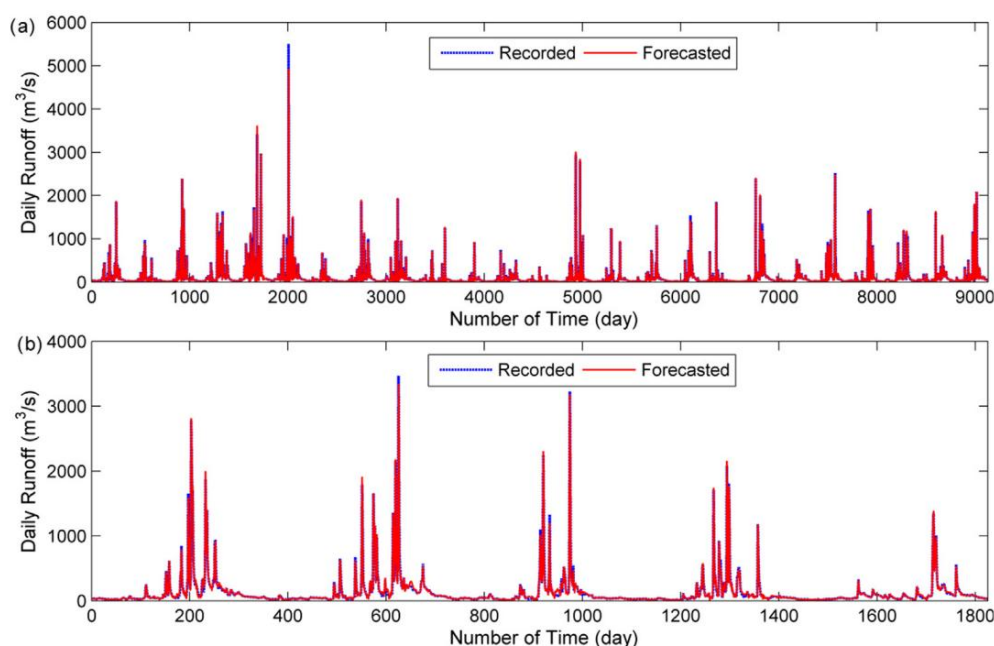


Fig. 9. Resultados da previsão da combinação VMD-DBN-IPSO para a estação Ankang. (a) Conjunto de treinamento (o primeiro de 9132 dias de 01/01/1988 a 31/12/2012); (b) Conjunto de testes (o restante de 1826 dias de 01/01/2013 a 31/12/2017).

uma figura de ajuste de dispersão dos resultados previstos no conjunto de dados de teste da estação Yangxian e Ankang sob diferentes períodos de previsão.

Para explicar esses resultados, cinco linhas de dispersão de ajuste foram incluídas em cada painel na Fig. 14 para avaliar a precisão geral do modelo. Obviamente, o método VMD-DBN-IPSO teve melhor desempenho na previsão de escoamento quando o período de previsão é de 1 dia, o que também é melhor do que o efeito de previsão quando o período de previsão é de 3, 5 e 7 dias, respectivamente. Vale ressaltar que quanto maior o período de previsão, pior o efeito de ajuste (Fig. 14), que é causado pelo acúmulo contínuo de erros. Pode-se ver claramente que o valor de escoamento estimado pelo método VMD-DBN-IPSO é o mais próximo do valor observado e a tendência é consistente. Para comparar ainda mais o impacto do período de previsão nos resultados da previsão, é realizada uma análise estatística

sobre os indicadores de avaliação de previsão em diferentes períodos de previsão.

A Tabela 11 mostra os valores estatísticos dos indicadores de avaliação em Yangxian e Ankang no período de previsão de 1d, 3d, 5d e 7d.

Pode-se observar que os resultados estatísticos da Tabela 11 são consistentes com os resultados da Fig. 14. À medida que o período de previsão aumenta, o MAE e o RMSE aumentam gradualmente, a taxa de aprovação da previsão diminui e o coeficiente NSE diminui, mas permanece acima de 0,8, o que pode satisfazer a formulação do plano diário de operação (como plano diário e plano semanal) do reservatório.

A previsão de picos de vazão por meio de um modelo confiável de escoamento é importante para divulgar informações sobre gestão de recursos hídricos e alertas oportunos de enchentes. A Tabela 12 mostra 10 resultados de previsão de fluxo de pico para

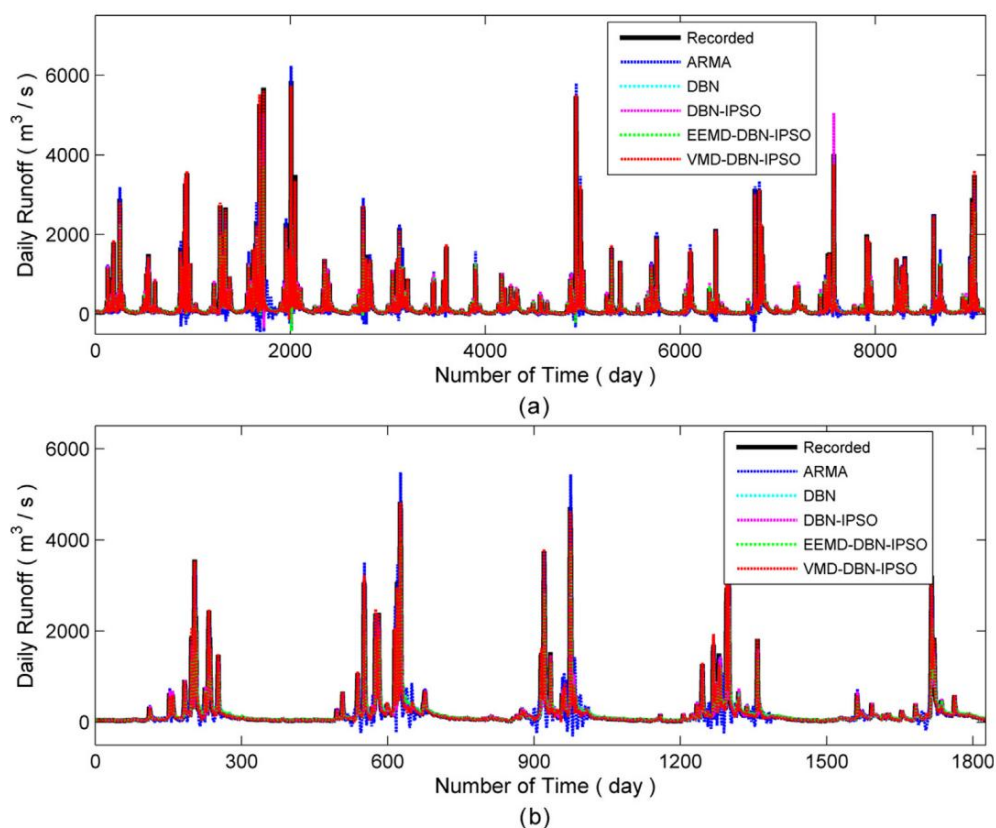


Fig. 10. A comparação dos resultados da previsão na estação Yangxian. (a) Conjunto de treinamento (o primeiro de 9132 dias de 01/01/1988 a 31/12/2012); (b) Conjunto de testes (o restante de 1826 dias de 01/01/2013 a 31/12/2017).




Fig. 11. A comparação dos resultados da previsão na estação Ankang. (a) Conjunto de treinamento (o primeiro de 9132 dias de 01/01/1988 a 31/12/2012); (b) Conjunto de testes (o restante de 1826 dias de 01/01/2013 a 31/12/2017).

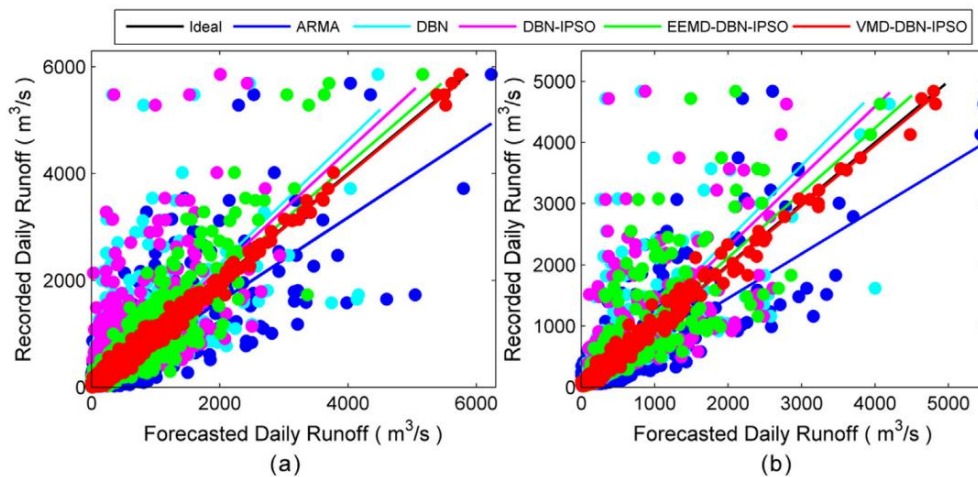


Fig. 12. A comparação dos resultados da previsão na Estação Yangxian. (a) Conjunto de treinamento (o primeiro de 9132 dias de 01/01/1988 a 31/12/2012); (b) Conjunto de teste (o restante 1826 dias de 01/01/2013 a 31/12/2017).

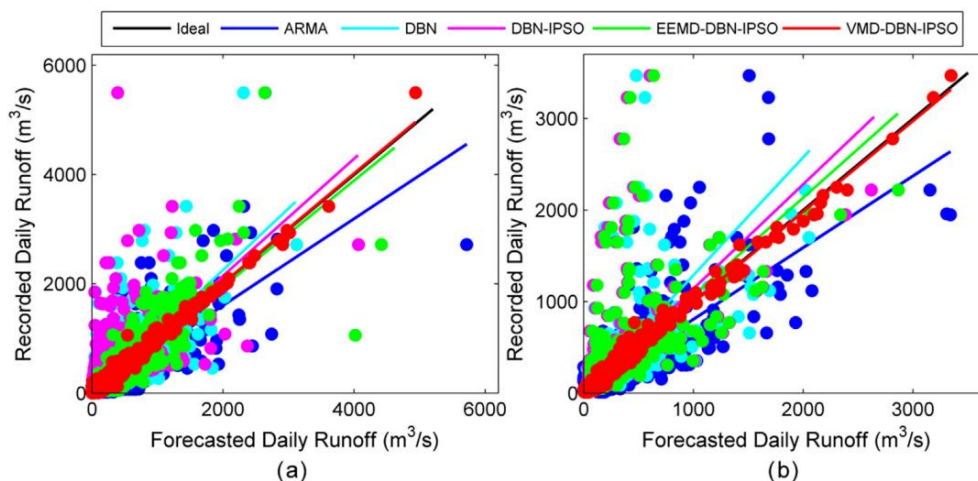


Fig. 13. A comparação dos resultados da previsão na Estação Ankang. (a) Conjunto de treinamento (o primeiro de 9132 dias de 01/01/1988 a 31/12/2012); (b) Conjunto de teste (o restante 1826 dias de 01/01/2013 a 31/12/2017).

Tabela 9

Indicadores de desempenho de previsão de treinamento e teste definidos sob diferentes modelos na estação Yangxian.

Predição Modelo	Conjunto de treinamento			Conjunto de teste		
	MUITO DE (m ³ /s)	RMSE (m ³ /s)	NSE MAE (m ³ /s)	RMSE (m ³ /s)	NSE	
ARMA	77,36	145,06	0,6580 82,38	141,06	0,4836	
DBN	51,26	107,59	0,7823 59,19	111,07	0,7617	
DBN-IPSO	43,13	88,76	0,8533 40,95	81,82	0,8224	
EEMD-DBN	19,29	49,92	0,9295 20,41	57,78	0,9236	
ELE MESMO						
VMD-DBN	9,69	31,72	0,9843 11,72	38,57	0,9798	
ELE MESMO						

diferentes modelos no período de previsão de 1 dia. A Tabela 13 mostra 10 resultados de previsão de fluxo de pico para o modelo VMD-DBN-IPSO para sob o período de previsão de 1, 3, 5 e 7 dias.

O erro relativo absoluto (ARE) proposto neste trabalho é calculado e obtido com base no pico de fluxo observado e previsto. Nós observe que a faixa de valores de previsão ARE para diferentes modelos sob o período de previsão de 1 dia da seguinte forma: ARMA (25,435 a 43,673)%, DBN (18,788 a 35,171)%, DBN-IPSO (13,172 a 21,847)%, EEMD DBN-IPSO (0,302 a 8,243)% e VMD-DBN-IPSO (0,073 a

Tabela 10

Indicadores de desempenho de previsão de treinamento e teste definidos sob diferentes modelos na estação Ankang.

Predição Modelo	Conjunto de treinamento			Conjunto de teste		
	MUITO DE (m ³ /s)	RMSE (m ³ /s)	NSE MAE (m ³ /s)	RMSE (m ³ /s)	NSE	
ARMA	57,49	135,51	0,7439 62,28	138,71	0,5968	
DBN	35,02	94,09	0,8594 41,04	103,81	0,7893	
DBN-IPSO	33,77	87,48	0,9084 38,85	89,9	0,8559	
EEMD-DBN	17,31	45,01	0,9444 19,24	55,86	0,9113	
ELE MESMO						
VMD-DBN	8,58	27,88	0,9896 9,27	27,07	0,9791	
ELE MESMO						

7.766). Os resultados deste estudo mostram que o modelo VMD-DBN-IPSO tem o menor erro de previsão para escoamento de pico. De acordo com o ARE média dos 10 principais pontos de dados de escoamento de pico, o VMD-DBN-IPSO modelo tem, respectivamente, erros de 2,506%, 5,453%, 10,969% e 19,317% no prazo de previsão de 1, 3, 5, 7 dias. Além disso, embora os resultados são ruins em comparação com o modelo VMD-DBN-IPSO, o pico o erro de fluxo do modelo EEMD-DBN-IPSO é relativamente pequeno comparado ao modelo não decomposto, o que novamente prova que a decomposição pode melhorar a precisão de previsão do modelo.

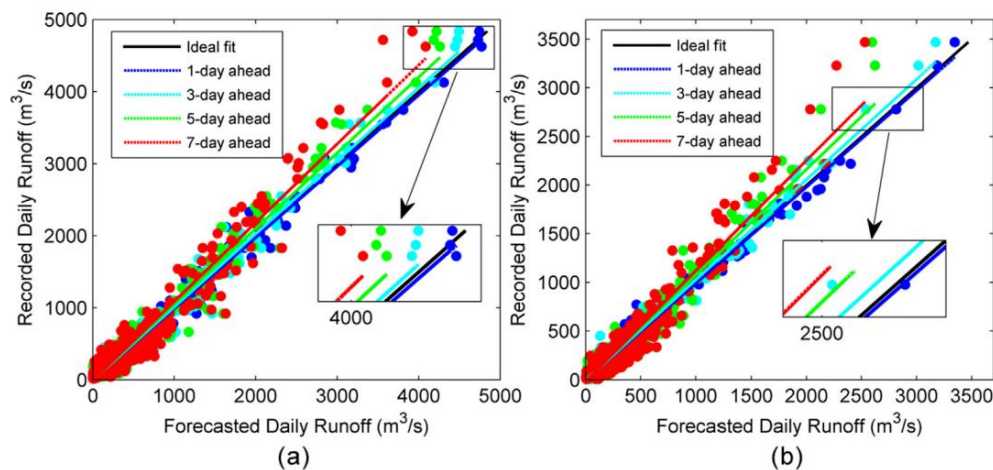


Fig. 14. Gráficos de ajuste de dispersão previstos e observados para conjuntos de teste usando as melhores estimativas para previsão de 1, 3, 5 e 7 dias à frente. (a) Yangxian (o resto da 1826 dia de 01/01/2013 a 31/12/2017); (b) Ankang (o restante de 1826 dias de 01/01/2013 a 31/12/2017).

Tabela 11

Análise multiescala do desempenho de testes para o modelo VMD-DBN-IPSO.

Tempo de execução Yangxian		Ankang		
MUITO DE (m3 /s)	RMSE (m3 /s)	NSE MAE (m3 /s)	RMSE (m3 /s)	NSE
1 dia à frente 11,72 3 dias	38,57	0,9798 9,27	27,07	0,9791
à frente 26,08 5 dias à	59,18	0,9086 18,59	38,45	0,9260
frente 31,45 7 dias à	75,15	0,8625 24,28	57,90	0,9081
frente 43,80	99,54	0,8273 28,28	70,63	0,8976

Tabela 12

As 10 principais previsões de fluxo de pico por diferentes modelos com o respectivo relativo absoluto erro (ARE, %) em comparação com os fluxos observados correspondentes no teste fase para o horizonte de 1 dia à frente.

Observado Fluxo	ARMA DBN	DBN-IPSO	EEMD-DBN	VMD-DBN
		ELE MESMO		ELE MESMO
4840	2793.814 3930.683 4202.483 5484.249			4742.587
4720	2717.922 3800.623 4069.185 5438.138			4727.683
4630	2607.947 3001.588 3937.372 3703.317			4771.024
4130	2567.073 2868.466 2854.815 3604.175			4307.318
3750	2483.957 2579.264 2771.541 3509.37			3809.514
3570	2417.727 2548.116 2683.45	3462.024		3599.767
3550	2411.44 2499.556 2482.876 3339.473			3552.586
3220	2400.995 2482.655 2481.211 3158.566			3185.998
3080	2287.059 2445.506 2461.589 3070.707			2843.589
3070	2274.574 2233.877 2404.814 2960.104			3202.566
Max ARE (%) 43,673 Min	35.171	30.876	20.015	7.676
ARE (%) 25,435 Média ARE	18.788	13.172	0.302	0,073
(%)	34.141	26.415	21.847	2.506

6. conclusões

Para melhorar a precisão da previsão de escoamento diário não estacionário série temporal, um modelo híbrido VMD-DBN-IPSO é proposto de forma inovadora nesse papel. Os conteúdos específicos são os seguintes: (1) Decomposição do séries de escoamento não lineares e não estacionárias baseadas em VMD. O VMD O método é usado para decompor a série de escoamento original em vários componentes de baixa complexidade e forte periodicidade, o que reduz a complexidade da série original. (2) Determinação da entrada variáveis pelo PACF. O PACF é usado para analisar as características de cada subsequência para extrair as variáveis de entrada. (3) Previsão cada uma das subsequências baseadas em DBN-IPSO. As subsequências são previsto pelo modelo DBN com forte capacidade de mapeamento não linear, alta auto-aprendizagem e capacidade de auto-adaptação, os parâmetros de DBN são

Tabela 13

As 10 principais previsões de fluxo de pico pelo VMD-DBN-IPSO com o respectivo relativo absoluto erro (ARE, %) em comparação com os fluxos observados correspondentes no teste fase para o horizonte de 1,3,5,7 dias à frente.

Fluxo Observado	1 dia à frente	3 dias à frente	5 dias à frente	7 dias à frente
4840	4742.587	4493.163	4216.679	3922.348
4720	4727.683	4474.092	4182.827	3561.754
4630	4771.024	4445.598	4259.989	4084.747
4130	4307.318	4195.864	3962.813	3612.507
3750	3809.514	3611.048	3371.935	3026.457
3570	3599.767	3283.703	2985.858	2799.534
3550	3552.586	3147.695	3054.887	2825.67
3220	3185.998	3108.854	2805.327	2582.525
3080	2843.589	2812.896	2796.313	2.397,57
3070	3202.566	3027.173	2735.065	2390.617
Máx. ARE (%)	7.676	11.333	16.363	24.539
ARE mínimo (%)	0,073	1,395	4.048	11.777
Média ARE (%)	2.506	5.453	10.969	19.317

otimizado iterativamente pelo modelo de otimização IPSO, e o resultados de previsão são obtidos por sua combinação. Além disso, usando MAE, RMSE e NSE como índices de avaliação de desempenho, e o resultados de previsão do modelo VMD-DBN-IPSO são comparados com aquele de quatro modelos de previsão, como ARMA, DBN, DBN-IPSO, EEMD-DBN IPSO, etc.

Em geral, o modelo VMD-DBN-IPSO proposto neste artigo pode melhorar significativamente a precisão da previsão de séries de escoamento não estacionário em escala diária. Diferente do escoamento tradicional da série diária previsão, as principais características do método proposto estão no seguinte aspectos: (1) o modelo pode efetivamente distinguir o modolaliasing de a série não estacionária original, reduza os componentes do FMI e melhorar a eficiência da previsão; (2) pode reduzir o erros no processo de extração de características de cada componente; (3) pode melhorar efetivamente a taxa de velocidade de iteração do parâmetro da previsão modelo para evitar que o parâmetro caia em um ótimo local. Os resultados da previsão mostram que entre todos os métodos mencionados, o modelo VMD-DBN IPSO proposto neste artigo é o melhor em precisão de previsão, estacionaridade e previsão de pico extremo. O modelo pode efetivamente prever dados de séries temporais complexas não estacionárias e não lineares. É um novo método promissor para previsão de escoamento diário.

Além disso, deve-se notar que no processo de pesquisa, embora o método de decomposição VMD melhorou o aliasing modal e o fenômeno do componente falso, não foi completamente eliminado esses problemas. O valor K apropriado da frequência central vale a pena de atenção. Especificamente, quando K é muito grande, é fácil causar decomposição de frequência excessiva, o que leva a um aumento no modelo

complexidade de previsão; quando K é muito pequeno, causará alias modal. Para obter os melhores resultados de previsão, otimizamos os parâmetros do modelo DBN por meio do IPso. É necessário treinar o modelo várias vezes, o que aumenta a carga de trabalho, inevitavelmente aumenta o erro incontrolável no processo de previsão e afeta a previsão final. É um problema importante que precisa ser superado na próxima etapa da pesquisa.

Declaração de Interesse Concorrente

Os autores declaram que não conhecem interesses financeiros concorrentes ou relações pessoais que possam ter influenciado o trabalho relatado neste artigo.

Agradecimentos

Esta pesquisa foi financiada pelo Programa Nacional de Pesquisa e Desenvolvimento Chave da China, concessão número 2016YFC0401409, e a Fundação Nacional de Ciências Naturais da China sob concessão 51507141, 51679188, 71774132, e o Plano de Pesquisa e Desenvolvimento Chave da Província de Shaanxi, concessão número 2018- ZDCXL-GY 10-04. Sincera gratidão é estendida ao editor e aos revisores anônimos por seus comentários e correções profissionais.

Referências

Aggarwal, SK, Goel, A., Singh, VP, 2012. Previsão de estágio e descarga por técnicas de SVM e RNA. *Recursos Hídricos. Gerenciar.* 26 (13), 3705-3724.

Al-Musayih, MS, Deo, RC, Li, Y., Adamowski, JF, 2018. Modelo híbrido de regressão vetorial de suporte otimizado de enxame de partículas bifásico integrado com decomposição de modo empírico aprimorado com ruído adaptativo para demanda de eletricidade de vários horizontes previsão. *Aplic. Energia* 217, 422-439.

Amini, E., 2015. Previsão de fluxos diários de rios usando modelos de séries temporais não lineares. *J. Hidráulico.* 527, 1054-1072.

Bai, Y., Chen, Z., Xie, J., Li, C., 2016. Previsão diária de influxo de reservatórios usando aprendizado profundo multiescala com modelos híbridos. *J. Hidrol.* 532, 193-206.

Bittelli, M., et al., 2010. Desenvolvimento e teste de um modelo tridimensional de hidrologia de superfície e subsuperfície com base física. *Av. Recursos Hídricos.* 33 (1), 106-122.

Cheng, R., Jin, Y., 2015. Um algoritmo de otimização de enxame de partículas de aprendizagem social para otimização escalável. *Inf. Sci.* 291, 43-60.

Ciresan, DC, Meier, U., Gambardella, LM, Schmidhuber, J., 2010. Redes neurais profundas, grandes e simples para reconhecimento de dígitos manuscritos. *Computação Neural.* 22 (12), 3207-3220.

Collobert, R., et al., 2011. Processamento de linguagem natural (quase) do zero. *J. Mach. Aprender.* Res. 12, 2493-2537.

Dragomiretskiy, K., Zosso, D., 2014. Decomposição em modo variacional. *Trans. IEEE Sinal Processo.* 62 (3), 531-544.

Fan, YR, Huang, GH, Li, YP, Wang, XQ, Li, Z., 2016. Previsão probabilística para fluxo de fluxo mensal através do acoplamento stepwise cluster analysis e métodos de regressão quantílica. *Recursos Hídricos. Gerenciar.* 30 (14), 5313-5331.

Fan, YR, et al., 2017. Desenvolvimento da estrutura de regressão quantílica de cluster baseada em PCA (PCA-CQR) para previsão de vazão: aplicação à bacia hidrográfica do rio Xiangxi, China. *Aplic. Computação Suave.* 51, 280-293.

Gan, Y., et al., 2014. Uma avaliação abrangente de vários métodos de análise de sensibilidade: um estudo de caso com um modelo hidrológico. *Ambiente. Modelo Software* 51, 269-285.

Geng, Z., Li, Z., Han, Y., 2018. Uma nova rede de crenças profundas baseada em RBM com cadeias gliais. *Inf. Sci.* 463, 294-306.

Gopalan, SP, Kawamura, A., Takasaki, T., Amaguchi, H., Azhikodan, G., 2018. Um modelo de função de armazenamento eficaz para uma bacia hidrográfica urbana em termos de reprodutibilidade hidrográfica e critério de informação de Akaike. *J. Hidrol.* 563, 657-668.

Hadi, SJ, Tombul, M., 2018. Previsão de vazão usando quatro abordagens de combinações de transformação wavelet com modelos orientados por dados: um estudo comparativo. *Recursos Hídricos. Gerenciar.* 32 (14), 4661-4679.

He, XX, Luo, JG, Zhu, GG, Xie, JC, 2019. Previsão de escoamento diário usando um modelo híbrido baseado em decomposição de modo variacional e redes neurais profundas. *Recursos Hídricos. Gerenciar.* 33 (4), 1571-1590.

Hinton, G., et al., 2012. Redes neurais profundas para modelagem acústica em reconhecimento de fala. *Processo de Sinal IEEE Mag.* 29 (6), 82-97.

Hinton, GE, 2002. Produtos de treinamento de especialistas minimizando a divergência contrastiva. *Computação Neural.* 14 (8), 1771-1800.

Hinton, GE, Salakhutdinov, RR, 2006. Reduzindo a dimensionalidade dos dados com redes neurais. *Ciência* 313 (5786), 504-507.

Huang, N., Chen, H., Cai, G., Fang, L., Wang, Y., 2016. Diagnóstico de falhas mecânicas de disjuntores de alta tensão com base na decomposição de modo variacional e classificador multicamadas. *Sensores* 16 (11).

Huang, S., Chang, J., Huang, Q., Chen, Y., 2014. Previsão de vazão mensal usando máquina de vetor de suporte baseada em EMD modificada. *J. Hidrol.* 511, 764-775.

Kang, M.-S., Won, Y.-J., Lim, B.-G., Kim, K.-T., 2018. Síntese eficiente do padrão de antena usando PSO aprimorado para desempenho e imagem de SAR no espaço presença de falha do elemento. *IEEE Sens. J.* 18 (16), 6576-6587.

Krizhevsky, A., Sutskever, I., Hinton, GE, 2017. Classificação ImageNet com profundidade

redes neurais convolucionais. *Comum. ACM* 60 (6), 84-90.

Kumar, S., Tiwari, MK, Chatterjee, C., Mishra, A., 2015. Previsão de afluentes de reservatórios usando modelos ensemble baseados em redes neurais, análise wavelet e método bootstrap. *Recursos Hídricos. Gerenciar.* 29 (13), 4863-4883.

Lahmiri, S., 2015. Longa memória nas tendências dos mercados financeiros internacionais e curta movimentos durante a crise financeira de 2008 com base na decomposição do modo variacional e análise de flutuação destendida. *Física A-Estat. Mec. Aplic.* 437, 130-138.

Lahmiri, S., Boukadoum, M., 2015. Denoising de sinal fisiológico com decomposição de modo variacional e reconstrução ponderada após limiarização de DWT. *Em: 2015 IEEE International Symposium on Circuits And Systems*, pp. 806-809.

Lee, H., et al., 2012. Assimilação variacional de vazão em modelos hidrológicos distribuídos operacionais: efeito de escala espaço-temporal de ajuste. *Hidrol. Sistema Terra. Sci.* 16 (7), 2233-2251.

Liu, H., Mi, X., Li, Y., 2018. Modelo inteligente de aprendizado profundo de várias etapas para previsão de velocidade do vento com base na decomposição de modo variacional, análise de espectro singular, rede LSTM e ELM. *Energia Convers. Gerenciar.* 159, 54-64.

Majumder, I., Dash, PK, Bisoi, R., 2018. Decomposição de modo variacional baseada em máquina de aprendizado extremo de kernel robusto de baixo nível para previsão de irradiação solar. *Energia Convers. Gerenciar.* 171, 787-806.

McInerney, D., Thyer, M., Kavetski, D., Lerat, J., Kuczera, G., 2017. Probabilidade de melhoria previsão abilitada do fluxo diário, identificando abordagens ótimas de Pareto para modelar erros residuais heterocedásticos. *Recursos Hídricos. Res.* 53 (3), 2199-2239.

Moeeni, H., Bonakdari, H., Fatemi, SE, 2017. Estacionarização do modelo estocástico por eliminando o termo periódico e seu efeito na previsão de séries temporais. *J. Hidrol.* 547, 348-364.

Myronidis, D., Ioannou, K., Fotakis, D., Dorfliinger, G., 2018. Fluxo de corrente e análise de tendência de seca hidrológica e previsão em Chipre. *Recursos Hídricos. Gerenciar.* 32 (5), 1759-1776.

Naik, J., Dash, PK, Dhar, S., 2019. Uma previsão multiobjetiva de velocidade do vento e previsão de intervalo de previsão de energia eólica usando a decomposição de modos variacionais baseada em regressão robusta de curme multi-kernel. *Renovar. Energia* 136, 701-731.

Napolitano, G., Serinaldi, F., Veja, L., 2011. Impacto da decomposição EMD e inicialização aleatória de pesos em ANN hindcasting de séries de fluxo diário: um exame empírico. *J. Hidrol.* 406 (3-4), 199-214.

Noori, R., et al., 2011. Avaliação da determinação de variáveis de entrada no desempenho do modelo SVM usando PCA, teste Gamma e técnicas de seleção direta para previsão de vazão mensal. *J. Hidrol.* 401 (3-4), 177-189.

Partington, D., et al., 2012. Avaliação das saídas de métodos automatizados de separação de fluxo de base contra fluxo de base simulado de um modelo de fluxo de água superficial-água subterrânea com base física. *J. Hidrol.* 458, 28-39.

Sankaran, A., Reddy, MJ, 2016. Analisando as teleconexões hidroclimáticas das chuvas de monção de verão em Kerala, Índia, usando decomposição de modo empírico multivariado e correlação intrínseca dependente do tempo. *IEEE Geosci. Detecção Remota Lett.* 13 (9), 1221-1225.

Sharghi, E., Nourani, V., Najafi, H., Molajou, A., 2018. Emotional ANN (EANN) e abordagens wavelet-ANN (WANN) para modelagem baseada em markoviana e sazonal do processo de chuva-vazão. *Recursos Hídricos. Gerenciar.* 32 (10).

Shi, XY, et al., 2018. Previsão horária de energia eólica para o dia seguinte usando o modelo híbrido de decomposição do modelo variacional e memória de longo prazo. *Energias* 11 (11), 20.

Sun, G., et al., 2016. Um modelo de previsão de preços de carbono baseado no modo variacional de composição e spiking de redes neurais. *Energias* 9 (1).

Sze, V., Chen, Y.-H., Yang, T.-J., Emer, JS, 2017. Processamento eficiente de redes neurais profundas: um tutorial e pesquisa. *Proc. IEEE* 105 (12), 2295-2329.

Wang, W.-C., Chau, K.-W., Cheng, C.-T., Qiu, L., 2009. Uma comparação do desempenho de vários métodos de inteligência artificial para previsão de séries temporais de descarga mensal. *J. Hidrol.* 374 (3-4), 294-306.

Wang, W.-C., Xu, D.-M., Chau, K.-W., Chen, S., 2013. Melhorar o escoamento anual da precipitação previsão usando o modelo PSO-SVM baseado em EEMD. *J. Hydrol.* 15 (4), 1377-1390.

Wen, XH, et al., 2019. Máquinas de aprendizado extremo de duas fases integradas com o decomposição de modo empírico de conjunto completo com algoritmo de ruído adaptativo para problemas de previsão de escoamento multi-escala. *J. Hidrol.* 570, 167-184.

Yaseen, ZM, El-Shafie, A., Jaafar, O., Afan, HA, Sayil, MN, 2015. Modelos baseados em inteligência artificial para previsão de fluxo: 2000-2015. *J. Hidrol.* 530, 829-844.

Yin, A., Ren, H., 2015. Um algoritmo de extração de modo de propagação para guia de ondas de microondas usando decomposição de modo variacional. *Medir. Sci. Tecnol.* 26 (9).

Yoon, H., Jun, S.-C., Hyun, Y., Bae, G.-O., Lee, K.-K., 2011. Um estudo comparativo de redes neurais artificiais e máquinas de vetor de suporte para previsão níveis de água subterrânea em um aquífero costeiro. *J. Hidrol.* 396 (1-2), 128-138.

Yu, Y., Zhang, H., Singh, VP, 2018. Previsão antecipada de dados de escoamento em bacias com escassez de dados com um modelo de decomposição de modo empírico (EEMD) aprimorado. *Água* 10 (4).

Zhang, G., et al., 2019. Previsão de energia eólica com base em combinações de múltiplas frequências de decomposição de modo variacional. *J. Modern Power Syst. Energia Limpa* 7 (2), 281-288.

Zhang, X., Peng, Y., Zhang, C., Wang, B., 2015. Os modelos híbridos são integrados com técnicas de pré-processamento de dados adequados para a previsão mensal de vazão? Algumas evidências experimentais. *J. Hidrol.* 530, 137-152.

Zheng, X., Lu, F., Ma, J., 2013. Características de múltiplas escalas de tempo de precipitação da Bacia do Rio Hanjiang e com análise de correlação de fatores de circulação. *Av. Terra Sci.* 28 (5), 618-626.

Zhou, Y., Guo, S., Hong, X., Chang, F.-J., 2019. Avaliação sistemática do impacto em projetos de transferência de água entre bacias hidrográficas da Bacia do Rio Hanjiang na China. *J. Hidrol.* 553, 584-595.

Zhou, YL, Guo, SL, Chang, FJ, 2019. Explore um ANFIS recorrente evolucionário para modelar previsões de cheias com vários passos à frente. *J. Hidrol.* 570, 343-355.

Zhu, S., Zhou, J., Ye, L., Meng, C., 2016. Estimativa de vazão por máquina de vetor de suporte acoplada a diferentes métodos de decomposição de séries temporais no curso superior do rio Yangtze, China. *Ambiente. Terra Sci.* 75 (6).

Zrira, N., Khan, HA, Bouyakhf, EH, 2018. Rede de crenças profundas discriminativas para classificação de ambientes internos usando recursos visuais globais. *Cognição. Computar.* 10 (3), 437-453.