

Previendo a demanda de água: uma revisão dos métodos empregados e possibilidades futuras.

Gustavo de Souza Groppo, Marcelo Azevedo Costa and Marcelo Libânio

RESUMO

O equilíbrio entre oferta e demanda de água requer técnicas eficientes de gestão dos sistemas de abastecimento de água. Esse equilíbrio é alcançado por meio de ações operacionais, muitas das quais requerem a aplicação de conceitos e ferramentas de previsão. Neste artigo, são revisadas pesquisas recentes sobre previsão de demanda de água urbana empregando inteligência artificial, com o objetivo de apresentar o 'estado da arte' sobre o assunto e fornecer algumas orientações sobre métodos e modelos para pesquisadores e empresas profissionais de saneamento. A revisão abrange os modelos desenvolvidos usando técnicas estatísticas padrão, como regressão linear ou análise de séries temporais, ou técnicas baseadas em Soft Computing. Esta revisão mostra que os estudos são, em sua maioria, voltados para o gerenciamento dos sistemas operacionais. Há, portanto, espaço para previsões de longo prazo. Vale ressaltar que não existe um modelo global que supere todos os métodos para todos os casos, sendo necessário estudar cada região separadamente, avaliando os pontos fortes de cada modelo ou a combinação de métodos. A utilização de aplicações estatísticas de metodologias de Machine Learning e Inteligência Artificial tem crescido consideravelmente nos últimos anos. No entanto, ainda há espaço para melhorias no que diz respeito à previsão da demanda de água.

Palavras-chave | inteligência artificial, aprendizado de máquina, computação suave, previsão de demanda de água

Gustavo de Souza Groppo
Economia aplicada,
São Paulo University;
Engenharia Sanitária,
Federal University of Minas Gerais;
The Companhia de Saneamento de Minas Gerais
COPASA-MG
e
Rua Mar de Espanha,
525 CEP: 30.330-900,
Belo Horizonte - MG,
Brazil

Marcelo Azevedo Costa
Engenharia elétrica,
UFMG;
Escola de Medicina de Harvard,
Cuidados de Saúde de Peregrinos de Harvard,
EUA;
Universidade de Linköping,
Suécia
e
Departamento de Engenharia de Produção,
Federal University of Minas Gerais

Marcelo Libânio (corresponding author)
Meio Ambiente e Recursos Hídricos,
UFMG;
Hidráulica e Saneamento,
São Paulo University;
Universidade de Alberta,
Canadá
e
Departamento de Engenharia Sanitária e
Ambiental, Universidade Federal de Minas
Gerais E-mail: marcelo@desa.ufmg.br

ABREVIATURAS

| | | | |
|---------|--|---------|---|
| ACO | Otimização de colônia de formigas | B | Bootstrap |
| ACPSO | Enxame de Partículas do Caos Adaptativo | B-ANN | Redes Neurais Artificiais Bootstrap |
| | Otimização | B-ELM | Bootstrap Extreme Learning Machine |
| AFS | Série Adaptativa de Fourier | BPCA | Análise Bayesiana de Componentes Principais |
| AMALGAM | Multi-Algoritmo Geneticamente Adaptativo | CCNN | Redes Neurais de Correlação em Cascata |
| | Método | CMF | Média de Ponderação Cumulativa Fuzzy |
| ANFIS | Sistema de Inferência Neuro Fuzzy Adaptativo | CNN ou | Rede Neural Convolucional |
| ANN | Redes neurais artificiais | ConvNet | |
| PA | Preço médio | DAN2 | Redes Neurais Artificiais Dinâmicas |
| ARIMA | Movimento Integrado Autoregressivo | DAN2-H | Redes Neurais Artificiais Dinâmicas |
| | Médias | | Híbrido |

| | | | |
|-----------------------|--|------------------|---|
| DFS | Sistema de previsão de demanda | MSE | Erro quadrático médio |
| DMA | Áreas de Medidas Distritais | MS-RVR | Regressor de vetor de relevância multiescala |
| E-ANN | Redes Neurais Artificiais Evolutivas | NC | Computação Neural |
| CE | Computação Evolutiva | NRLM | Múltipla Regressão Não Linear |
| EDBD | Barra Delta Estendida | NSI | Nash-Sutcliffe |
| EFF | Filtro Kalman Estendido | PPR | Regressão de Busca de Projeção |
| EKF PG | Filtro Kalman Estendido com Programação Genética | RP | Razão de Probabilidade |
| | | RBN | Redes Neurais de Base Radial |
| | | RF | Floresta Aleatória |
| OLMO | Máquina de aprendizado extremo | RVR | Regressor de vetor de relevância |
| EMD | Decomposição em Modo Empírico | RW | Caminhada aleatória |
| EMD-ANN Modo Empírico | Decomposição Artificial | RWD | Passeio aleatório com tendência |
| | Redes neurais | SAR | Autoregressivo Espacial |
| ESN | Eco de estado neural | SARMA | Média Móvel Autoregressiva Espacial |
| FFnn | Redes neurais de feedforward | SC | Computação Suave |
| FIS | Sistemas de Inferência Fuzzy | SEM | Erro espacial |
| FL | Lógica Fuzzy | SVD | Decomposição de valor singular |
| FLR | Regressão linear difusa | SVR | Regressão de vetores de suporte |
| FRNN | Rede Neural Totalmente Recorrente | TDNN | Rede Neural Atrasada |
| STF | Fuzzy Takagi Sugeno | TS-GRNN | Regressão Generalizada de Séries Temporais |
| GA | Algoritmos genéticos | | Redes neurais |
| GARCH | Condiciona l Autoregressivo Generalizado | | |
| | Heterocedasticidade | ESTAVA | Vetor Autoregressivo |
| ENTENDER | Randomização adaptativa ágil | Dentro | Wavelet |
| GRNN | Redes Neurais de Regressão Generalizada | W-ANN | Redes Neurais Artificiais Wavelet |
| GSAA | Algoritmo de Recozimento Simulado Genético | WB-ANN | Neural Artificial Bootstrap Wavelet |
| HW | Holt Winters | | Redes |
| FMI | Função Intrínseca | WDF | Módulo de previsão de demanda de água |
| K-NN | K-vizinhos mais próximos | W-ELM | Máquina de Aprendizagem Extrema Wavelet |
| LF-DFNN | Rede Neural Dinâmica de Feedback Local | WPatiGenericName | Padrão ponderado |
| LRGF | Feedforward global recorrente local | WSS | Sistemas de Abastecimento de Água |
| LS-SVM | Máquina Vetorial de Suporte Mínimo Quadrado | TUDO | Zona de Abastecimento de Água |
| LSTM | Memória de curto prazo longa | YWS | Serviços de Água de Yorkshire |
| LTF | Função de transferência linear | RRMSE | Erro Relativo da Raiz Média Quadrada |
| MAPA | Erro de Porcentagem Absoluta Média | R2 | Coefficiente de determinação |
| MARTE | Regressão Adaptativa Multivariada | AREP | Porcentagem Média de Erro Relativo |
| | Splines | NRMSE | Erro de raiz quadrada média normalizada |
| MFIS | Sistemas de Inferência Fuzzy Mandami | EXAUSTÃO | Erro Relativo Absoluto Médio |
| ML | Aprendizado de máquina | max ARE | Erro Relativo Absoluto Máximo |
| MLP | Perceptron multicamadas | R | Coefficiente de correlação |
| MLR | Regressão linear múltipla | ts | Estatística de limite |
| MNLR | Regressão Não Linear Múltipla | Valor p HM | Valor de probabilidade de Henriksson e Merton |
| deputado | Preço marginal | U-Statistic | Coefficiente de Desigualdade de Theil |
| MSE | Erro quadrado médio | SETEMBRO | Erro padrão de previsão |

| | |
|---------|----------------------------|
| PI | Índice de persistência |
| RMS | Medida de erro absoluto |
| NMSE | Erro Quadrado Médio Normal |
| LM | Multiplicador de Lagrange |
| LR | Lagrange Robusto |
| Moran I | Estatística Moran I |
| CUBA | Desvio percentual no pico |

INTRODUÇÃO

Disponibilizar uma quantidade suficiente de água potável representa um grande desafio, principalmente nas grandes cidades. Cidades cresceram sem planejamento adequado, resultando em remoção da cobertura vegetal e impermeabilização do solo. Isso tem causado problemas hidrológicos e meteorológicos como aumento da temperatura do ar, evapotranspiração e risco de inundação. Consequentemente, a água tornou-se menos disponível, devido à poluição ou devastação de áreas protegidas de fontes de água. Assim, a água disponível fontes de abastecimento estão distantes dos centros urbanos, tornando a água exploração cada vez mais cara.

Lidar com esses problemas requer água eficiente Técnicas de gerenciamento de Sistemas de Suprimentos (WSS), para para manter o equilíbrio entre oferta e demanda. A manutenção deste equilíbrio é conseguida através de ações, muitas das quais requerem aplicação de previsão

Ferramentas.

Devido à importância da previsão da demanda de água, muitos pesquisadores e profissionais começaram recentemente para estudá-lo, conforme descrito em Ghalekhondabi et al. (2019). O número de artigos publicados aumentou exponencialmente nos últimos 20 anos, como mostra a Web de Ciência (Thomson Reuters). Esse aumento pode refletir o crescente escassez de recursos hídricos e a crescente importância da gestão da demanda de água.

Portanto, os gestores se preocupam em planejar o WSS para atender a demanda de água com custos operacionais mais baixos. De acordo com para Ghiassi et al. (2019), a otimização das operações pode resultar em economias substanciais de 25% a 30% na operação custos, devido à redução de custos com energia elétrica e insumos de tratamento. Achados semelhantes são apresentados por Odan (2019).

Ao mesmo tempo, tem sido intensificada a avaliação da infraestrutura existente e das estratégias de expansão

(plano mestre e estudo de projeto/projeto de construção). o planos diretores visam o investimento de longo prazo, antecipando o demandas hídricas do crescimento vegetativo esperado, expansão geográfica e as condições socioeconômicas e climáticas variáveis que modificam o comportamento de consumo ao longo do tempo. Inúmeros fatores afetam a quantidade de água demandada. o os mais importantes são: condições climáticas como temperatura; precipitação e umidade relativa; tamanho do população; pressão da água na rede; perdas no sistema; estrutura de preços (residencial, comercial, industrial e público); sistema de abastecimento e medição de água (hidrométrica); renda familiar, tamanho e espaço ao ar livre (Arbués et al. Ts; Tsutiya 2019; Wentz & Gober 2019; Sheikh & Hillenbrand 2019; Nauges & Whittington 2019; Maria André and Carvalho, 2016).

Após extensa revisão da literatura, Donkor et al. (2019) concluiu que a aplicação de um determinado método depende na periodicidade e no horizonte de previsão. De acordo com esses autores, as redes neurais eram mais propensas a serem usado na previsão de curto prazo, enquanto os métodos econométricos e simulações foram mais frequentemente empregadas no previsão de longo prazo. Conclusões semelhantes foram encontradas por Ghalekhondabi et al. (2019). Para esses autores, os métodos Soft Com puting (SC) foram usados principalmente no curto prazo. previsão. De acordo com Brentan et al. (2019), o uso de aplicações estatísticas de Machine Learning e Metodologias de inteligência na previsão de demanda de água cresceu consideravelmente nos últimos anos.

O termo Soft Computing (SC), também conhecido como Inteligência Computacional, é a combinação de tecnologias de resolução de problemas, como Fuzzy Logic (FL), Computação Neural (NC), Algoritmos Genéticos (GA), Computação Evolutiva (EC), Aprendizado de Máquina (ML), Razão de Probabilidade (PR) e híbridos complementares. SC os sistemas híbridos são descritos em Bonissone (2019). Cada uma dessas tecnologias fornece raciocínio complementar e métodos complexos de solução de problemas do mundo real. UMA combinação particularmente eficaz é conhecida como 'neuro-fuzzy sistemas'.

O objetivo deste artigo é apresentar uma extensa revisão de métodos de previsão de demanda de água urbana para profissionais e pesquisadores de saneamento, fornecendo assim orientações para aplicações práticas. A revisão abrange o modelos desenvolvidos usando técnicas estatísticas padrão,

como regressão linear ou análise de séries temporais, ou técnicas baseadas em SC.

Métodos para suportar tarefas de gerenciamento de Sistemas de Distribuição de Água (WDS) em tempo quase real, como programação de bombas online e modelagem hidráulica dinâmica, receberam menos atenção. Embora sistemas dinâmicos sejam aplicados a problemas de previsão de água, sua aplicação é bastante limitada quando comparada a outros métodos SC (Ghaleh khondabi et al. 2019).

Este artigo está organizado da seguinte forma. As publicações relacionadas a cada método investigado são apresentadas na Seção 2. As discussões sobre os resultados da revisão são apresentadas na Seção 3. As considerações finais e sugestões para pesquisas futuras são apresentadas na Seção 4.

MÉTODOS DE PREVISÃO DE DEMANDA

Os métodos de previsão de demanda podem ser amplamente classificados como lineares e não lineares (Zhang 2019). Métodos lineares usam análise de séries temporais univariadas, como suavização exponencial, médias móveis integradas autorregressivas (ARIMA) e métodos de regressão linear (MLR) (por exemplo, Adamowski & Karapataki 2019; Caiado 2019; Adamowski et al. 2019).

Métodos não lineares usam métodos de regressão não linear (MNLR), Redes Neurais Artificiais (RNA) (por exemplo, Ghiassi et al. 2019; Firat et al. 2019b; Firat et al. 2019; Adamowski & Karapataki 2019), FL (por exemplo, Altunkaynak et al. 2019; Firat et al. 2019a), Support Vector Machine (SVM) (Peña Guzmán et al. 2019), AG, sistemas especialistas (por exemplo, Altunkaynak et al. 2019; Nasser et al. 2019) e métodos híbridos.

Redes neurais artificiais

As RNAs são ferramentas de previsão muito úteis, devido a vários fatores. A primeira está relacionada à exigência de um número menor de hipóteses, quando comparado aos métodos estatísticos tradicionais. Um segundo fator diz respeito à generalização dos resultados e à previsão de dados não observados (Zhang et al. 2019). Um terceiro fator diz respeito à capacidade de lidar com diferentes graus de não linearidade presentes nos dados de demanda de água. Ou seja, eles são capazes de modelar relações altamente não lineares entre os dados e estimar funções não lineares com alto grau de precisão. De acordo com Adamowski et al.

(2019), as RNAs permitem o uso de séries históricas para prever valores futuros de séries temporais multivariadas possivelmente ruidosas.

Ghiassi et al. (2019) desenvolveram um método de Rede Neural Artificial Dinâmica (DAN2) para prever a demanda de água em uma cidade da Califórnia. Este método dinâmico é um caso especial da arquitetura Feedforward (FFNN). O método desenvolvido apresentou melhor desempenho que os métodos ARIMA e ANN, mostrando-se assim mais eficaz para prever a demanda de água. Os autores notaram que a inclusão de

informações meteorológicas em modelos de previsão aumentam a precisão. No entanto, mesmo usando apenas dados de demanda de água, os métodos DAN2 fornecem excelentes ajustes. Os resultados obtidos para as previsões mensais, semanais e diárias foram altamente precisos, assim como os modelos horários. Esses resultados demonstram excelente eficácia para DAN2 na previsão da demanda de água urbana para todos os horizontes temporais. Firat et al. (2019b) estimou a previsão mensal para a demanda de água na cidade de Izmir (Turquia) usando várias técnicas de redes neurais, como Redes Neurais de Regressão Generalizada (GRNN), Redes Neurais Feedforward (FFNN) e Redes Neurais de Base Radial (2019b) RBN). Eles usaram vários fatores socioeconômicos e climáticos que afetam

consumo (consumo médio mensal de água, população, número de domicílios, produto nacional bruto, temperatura média mensal, precipitação total mensal, umidade média mensal e inflação). O conjunto de dados foi dividido em dois subconjuntos (treinamento e teste). Os métodos que obtiveram os melhores ajustes também foram comparados ao método de Regressão Linear Múltipla (MLR). Os resultados obtidos indicaram que o GRNN supera todos os outros métodos na modelagem do consumo mensal de água.

Posteriormente, Firat et al. (2019) também estimou a previsão mensal de demanda de água, empregando várias técnicas de RNA, incluindo Rede Neural de Correlação em Cascata (CCNN), GRNN e FFNN. Seis modelos de previsão foram construídos. A melhor estrutura de entrada de ajuste foi investigada pela comparação das técnicas empregadas. O modelo M5-CCNN compreende uma rede CCNN com cinco meses de defasagem se mostrou mais eficiente que os demais modelos. Ao comparar os resultados usando as três técnicas de RNA, o desempenho do modelo M5-CCNN teve um desempenho ligeiramente melhor que os demais.

Adamowski & Karapataki (2019) analisaram a demanda de água empregando dados de pico semanais e o clima

variáveis temperatura máxima semanal e precipitação total para duas regiões distintas na cidade de Nicósia, Chipre. Os autores desenvolveram e compararam a relativa desempenho de 20 modelos MLR e 60 modelos de rede neural Multilayer Perceptron (MLP) usando três algoritmos de aprendizado (Levenberg-Marquardt, propagação reversa resiliente e gradiente conjugado de Powell Beale métodos). Para as duas regiões analisadas, o método que emprega o algoritmo de Levenberg-Marquardt apresentou o previsão precisa do pico de demanda semanal.

Métodos fuzzy e neuro-fuzzy

Altunkaynak et al. (2011) usou o Fuzzy Takagi-Sugeno (FTS) para prever a demanda mensal de água em Istambul (Peru). O método consiste em utilizar os valores de consumo de água dos últimos três meses como variáveis. Ou seja, a demanda atual de água é uma função da flutuações da demanda nos últimos três meses. o Método Adaptativo Neuro Fuzzy Inference System (ANFIS) foi usado para determinar os parâmetros do modelo. O significativo A estatística Square Error (MSE) para diferentes configurações de métodos foi usada para selecionar o método mais eficaz. o autores argumentam que este modelo é amplamente utilizado do que o Métodos de Markov ou ARIMA, comumente disponíveis para modelagem e previsão estocástica. Uma das vantagens de usar o método FTS, em comparação com os métodos ARIMA, é que não se baseia em pressupostos estacionários e de ergodicidade. Finalmente, este método também ajuda a fazer previsões com menos de 10% de erro relativo.

Firat et al. (2012) comparou dois tipos de Sistemas de Inferência Fuzzy (FIS) para prever a série temporal de demanda de água. Os Sistemas de Inferência Fuzzy usados incluem um sistema ANFIS e um Sistema de Inferência Fuzzy Mandami (MFIS). O desempenho dos métodos ANFIS e MFIS foram analisados nas etapas de treinamento e teste. Para avaliar o melhor método de previsão, os desempenhos dos dois métodos, tanto no estágio de treinamento quanto no de teste de demanda, foram comparados com os valores observados. Todos os níveis das estatísticas de limiar empregadas no estudo demonstraram a maior precisão do modelo M5-ANFIS sobre o M5-Modelo MFI. O modelo M5 compreende uma Inferência Fuzzy Sistemas com atrasos de cinco meses. Portanto, os resultados mostrou que o método M5-ANFIS é superior ao

Método M5-MFIS para previsão de séries mensais de demanda, e pode ser aplicado com sucesso para prever água consumo.

Máquinas vetoriais de suporte

Peña-Guzmán et al. (2013) usou o método de aprendizado dos Mínimos Quadrados Método Support Vector Machines (LS-SVM) para prever o demanda mensal de água para as categorias residencial, industrial e comercial em Bogotá, Colômbia. Para fazer isso, eles utilizou os parâmetros de demanda mensal de água, número de usuários e preço, para uso residencial, industrial e comercial categorias. A cidade emprega um sistema de estratificação socioeconômica, de acordo com as leis nacionais de serviços, onde as residências são classificadas em seis estratos. Eles usaram registros mensais de janeiro de 2004 a Dezembro 2014. Conforme proposto por Ghiassi et al. (2011), o pesquisadores empregaram 80% dos dados de treinamento e 20% dos dados. O método LS-SVM mostrou-se superior ao método neural método de redes, usando o método de retropropagação de aprendizado de erros, para todas as categorias e estratos. Isso provou ser uma ferramenta eficaz para o planejamento e gestão da água demanda, pois ajudou a identificar a necessidade de decisões para regular o consumo em diferentes estratos e para diferentes usos.

Herrera et al. (2013) descreveu e comparou vários métodos para prever a demanda de água em uma cidade do sul da Espanha. Os métodos utilizados foram: Vetor de Suporte Regressão (SVR), FFNN empregando o método de aprendizado Error Backpropagation, Projection Pursuit Regression (PPR), Splines de regressão adaptativa multivariada (MARS) e Floresta Aleatória (RF). Além desses métodos, pesquisadores propuseram um método simples baseado na demanda perfil, usando resultados ponderados da análise exploratória de dados (WPA). Os resultados obtidos identificaram o SVR como o mais método preciso, seguido de perto pelo MARS, PPR e métodos de RF.

Métodos estatísticos

O objetivo principal do estudo de Fullerton Jr et al. (2011) foi analisar a dinâmica da demanda de água para o cidade de El Paso (Texas, EUA), utilizando diversas metodologias de previsão, entre as quais a Função de Transferência Linear

(LTF), que é uma extensão da metodologia descrita por Box e Jenkins (1976). O resultado do LTF foi superior quando comparado aos métodos de vetor autorregressivo (VAR), passeio aleatório (RW) e passeio aleatório com tendência (RWD).

Maria André & Carvalho (2019) estimaram a função da demanda de água residencial na cidade de Fortaleza, Brasil, considerando o impacto potencial da inclusão de efeitos espaciais na modelagem, uma vez que a exclusão desses efeitos subestima o impacto da renda e do número de banheiros na demanda de água residencial preços marginais. Primeiro, esses autores estimaram um método econométrico de água demanda sem levar em conta os efeitos espaciais. Este método econométrico foi calculado para as seguintes especificações: preço médio (modelo AP), preço marginal com diferença (modelo MP) e preço marginal com diferença pelo método de McFadden (modelo McFadden). Em seguida, eles calcularam três modelos para verificar a inclusão de efeitos espaciais na demanda de água: Spatial Error Model (SEM), Spatial Autoregressive Model (SAR) e Spatial Autoregressive Moving Average Model (SARMA) foram estimados usando as seguintes variáveis explicativas: média e disparidade marginal de renda, número de moradores masculinos e femininos e número de banheiros, sob diferentes especificações espaciais. Os resultados sugerem que o SARMA fornece os melhores resultados. No entanto, esses resultados contradizem os achados de Chang et al. (2018) e House-Peters et al. (2019), que afirmam que a abordagem espacial fornece resultados mais precisos que o SARMA. Após estimar o SARMA (tanto para o modelo AP quanto para o modelo McFadden), e corrigir os efeitos diretos e indiretos dos parâmetros estimados, concluiu-se que a utilização de uma abordagem espacial é mais vantajosa. A não inclusão dos efeitos espaciais nas variáveis causou uma subestimação do

efeito de todas as variáveis do modelo. Após a inclusão desses componentes espaciais, a elasticidade-preço nos modelos AP e McFadden aumentou 24,66% e 13,32%, respectivamente, afetando a demanda prevista.

Gagliardi et al. (2019), propôs um método de previsão de demanda de água de curto prazo baseado no conceito estatístico da Cadeia de Markov (MC), fornecendo estimativas para demandas futuras e as probabilidades de que a demanda prevista caia dentro da variabilidade esperada. Dois métodos foram propostos, um baseado em Cadeias de Markov Homogêneas

(HMC) e um baseado em Cadeias de Markov Não Homogêneas (NHMC). Esses métodos foram aplicados a três áreas de medição distritais (DMA) localizadas em Yorkshire (Reino Unido), a fim de prever as demandas de água de 1 a 24 horas depois. Posteriormente, os resultados foram comparados com as previsões dos dois métodos utilizados como benchmarks (RNA, Naive Bayes). Os resultados mostram que o método HMC fornece previsões de curto prazo mais precisas do que o NHMC. Ambos os métodos fornecem informações probabilísticas de previsão de demanda estocástica com esforço computacional reduzido, em comparação com a maioria dos métodos existentes. Esta informação não está prontamente disponível nos métodos de benchmark ANN ou Naive Bayes. No entanto, pode ser obtido através de análise pós-processamento usando simulações de Monte Carlo que são computacionalmente mais caras.

Métodos híbridos

Os principais fatores que afetam a demanda de água urbana são muitas vezes difíceis de identificar usando algoritmos tradicionais devido aos muitos fatores que são incertos e difíceis de quantificar. Alguns filtros, wrappers e sistemas embarcados podem ser empregados para lidar com este problema. Cada um tem pontos fortes e fracos. A Tabela 1 apresenta uma visão geral dos principais pontos fortes e fracos dos três tipos de métodos de seleção de variáveis (Freitas 2019).

Os métodos de seleção de variáveis são importantes no aprimoramento dos modelos de previsão, aumentando a eficiência do processo causado pela mitigação da conhecida maldição da dimensionalidade (Guyon & Elisseeff 2003), reduzindo o custo computacional (Piramuthu 2018) e obter uma visão mais profunda dos processos subjacentes que geraram os dados (Sayes et al. 2019). Estratégias de busca eficientes podem ser planejadas sem necessariamente sacrificar

Tabela 1 | Comparação de métodos para seleção de variáveis

| Tipos | Forças | Fraquezas |
|--|---|---|
| Filtro | Execução rápida e robustez ao sobreajuste de dados. | Variáveis redundantes seleção |
| Envoltório de alta precisão | | Execução e dados lentos sobreajuste |
| Combinação incorporada de filtros e invólucros | | Conhecimento preliminar para seleção de variáveis |

desempenho preditivo (Guyon & Elisseeff [2011](#)). Diversas estratégias de seleção estão sendo desenvolvidas para minimizar a carga computacional causada pela busca exaustiva, como o trabalho de Sorjamaa et al. ([2006](#)) e Hsu et al. ([2002](#)).

Recentemente, abordagens híbridas foram propostas para combinar as vantagens de filtros e wrappers (Crone & Kourentzes [2015](#); Stan'czyk [2016](#)).

Outro aspecto da pesquisa diz respeito ao aprendizado usando ensemble, onde os métodos que geram vários modelos são combinados para prever um novo caso. A ideia destes métodos pode ser descrita como a construção de um modelo preditivo através da integração de múltiplos métodos (Dietterich [2000](#)). Uma das vantagens é a melhoria do desempenho da generalização (Hansen & Salamon [1990](#); Sharkey [1987](#); Zhang [1995](#); Melin et al. [2005](#)). No entanto, tal melhoria depende da qualidade de seus componentes e da diversidade do erro apresentado por eles (Granger [1999](#); Perrone & Cooper [1998](#); Krogh & Vedelsby [1997](#); Sollich & Krogh [1998](#); Granitto et al. [2004](#); Gashler et al. [2003](#); Al-Zahrani & Abo-Monasar [2003](#); Ren et al. [2004](#); Wang et al. [2004](#)), ou seja, cada um dos componentes de um conjunto deve ter um bom desempenho e, ao mesmo tempo, deve generalizar de forma diferente. Faz pouco sentido combinar métodos que adotem os mesmos procedimentos e hipóteses para resolver um problema (Perrone & Cooper [1998](#)). Se componentes que possuem o mesmo padrão de erro forem combinados, não haverá desempenho incremental, apenas aumentando o custo computacional, sem resultados práticos de desempenho.

Segundo Mendes-Moreira et al. ([2006](#)), a geração de ensembles homogêneos é a área de aprendizagem com melhor abrangência na literatura. Em conjuntos homogêneos, os modelos são gerados usando o mesmo algoritmo.

Conjuntos heterogêneos são gerados usando mais de um algoritmo de aprendizado de máquina. Espera-se que a abordagem heterogênea possa obter modelos com maior diversidade devido à natureza diferente dos aprendizes básicos (Webb & Zheng [2004](#)). Alguns autores afirmam que esses ensembles apresentam melhor desempenho quando comparados aos ensembles homogêneos (Granger [1999](#); Krogh & Vedelsby [1997](#); Wichard et al. [2004](#)). Outra abordagem, usualmente empregada, é aquela que combina o uso de diferentes algoritmos de indução mesclados com diferentes conjuntos de parâmetros (Rooney et al. [2004](#)).

Os métodos de ensemble mais conhecidos são o Bag ging (Bootstrap Aggregating) introduzido por Breiman ([1996](#)), Boosting (Freund & Schapire [1996](#)) e Random Forest (Breiman [1999](#)).

Filtro

Xu et al. ([2006](#)) utilizou o espectro de energia (Oshima & Kosuda [2000](#)) e o maior coeficiente de Lyapunov (Tsonis [1998](#)) para examinar qualitativamente as características da série temporal de demanda de água. Os resultados indicam que o

as séries temporais de demanda de água apresentam características de caos, ou seja, uma tendência ascendente da série temporal é observável, mas a lei de evolução e as características de variação dos dados não pode ser determinado facilmente. Os resultados são semelhantes aos obtidos por Zhao & Zhang ([2003](#)) e Bai et al. ([2004](#)).

Assim, os problemas de previsão da demanda de água podem ser traduzidos em problemas de previsão de séries caóticas. Portanto, o pré-processamento para melhorar a precisão dos resultados é necessário.

No procedimento de filtragem, a seleção do conjunto é uma etapa de pré-processamento dos dados, independentemente do algoritmo de indução. O filtro geralmente é robusto ao sobreajuste de dados, mas falha em encontrar o subconjunto de variáveis mais promissor (Freitas [2006](#)), em média. A principal fraqueza dessa abordagem é que ela ignora os efeitos dos subconjuntos selecionados no desempenho do algoritmo de indução (John et al. [1994](#); Kohavi & John [1997](#)).

Na literatura, vários tipos de filtros são utilizados: (i) Regressão passo a passo usada para identificar atrasos significativos do componente autorregressivo da variável dependente como entradas para um MLP (Dahl & Hylleberg [1999](#)); (ii) Análise Espectral utilizada para avaliar os padrões de dados cíclicos, decompondo a série temporal nas funções seno e cosseno subjacentes dos comprimentos de onda (Kay & Marple [1981](#)); (iii)

Análise de Espectro Singular (Hassani [1999](#); Du et al. [2004](#)); (iv) Decomposição em Modo Empírico (EMD) onde a resolução de frequência de tempo pela qual o comportamento da série temporal estável e não linear pode ser decomposto (Di et al. [2004](#); Shabri & Samsudin [2004](#)); e (v) filtro de Kalman (Poli & Jones [2004](#); Nasser et al. [2004](#); Arandia et al. [2004](#); Karuna singha & Liong [2004](#)) e filtro Hodrick-Prescott (Li & Huicheng [2004](#)).

Vale ressaltar que segundo Zhang & Qi ([2006](#)), métodos de aprendizado de máquina, sem

processamento, podem se tornar instáveis e gerar resultados abaixo do ideal.

Embalagens

Wrappers, popularizados por John et al. (2013) e Kohavi & John (2001), fornecem uma maneira simples e poderosa de abordar o problema de seleção de variáveis e/ou atributos, independentemente da máquina de aprendizado a ser empregada. Segundo Freitas (2005), o ponto forte desse método é que ele leva em conta o viés do algoritmo de indução e considera as variáveis em contexto. No início, a busca é exponencial, mas é possível implementar buscas estocásticas (ex., algoritmos genéticos (O algoritmo genético é uma metaheurística inspirada no processo de seleção natural, motivada por uma analogia com a evolução biológica. Esses algoritmos, ao invés de busca de hipóteses gerais e específicas, de simples a complexas, geram hipóteses sucessoras, mutando e recombinao repetidamente partes das hipóteses mais conhecidas (Mitchell, 1997).) exclusão para trás).

Portanto, existem inúmeras possibilidades a serem estudadas empiricamente.

Integrado

No modelo embarcado, a tarefa de seleção de atributos é realizada dinamicamente pelo algoritmo de aprendizado de máquina. O processo de seleção de atributos não é distinto do treinamento do modelo, e os resultados são calibrados em relação a um determinado classificador ou regressor específico. Para Zanchettin (2011), um dos pontos fortes dessa abordagem é que ela faz o melhor uso dos dados disponíveis, ou seja, não precisa dividir em dados de treinamento e de teste, e é mais rápida, pois não requer múltiplas treinamentos.

Modelos híbridos com filtros acoplados

Um modelo híbrido que combina Filtro de Kalman Estendido (EKF) e Programação Genética (PG) foi proposto por Nasseri et al. (2011) para prever a demanda mensal de água. De acordo com Nasseri et al. (2011) GP é um método de regressão simbólica baseado em uma abordagem estruturada em árvore apresentada por Koza (1992). Este método pertence a um ramo de

método evolutivo, que imita o processo natural de luta pela existência (Holland 1975). A principal vantagem da abordagem proposta é a possibilidade de alcançar o menor número de fórmulas matemáticas não lineares e determinísticas.

ções para a previsão mensal da demanda de água, pelo método evolutivo. Os resultados obtidos com os modelos híbridos EKF PG e PG mostraram efeito perceptível na precisão da previsão.

Adamowski et al. (2005) realizou previsões diárias de demanda de água para os meses de verão na cidade canadense de Montreal. Eles empregaram um método híbrido baseado em Transformadas Wavelet de acoplamento discreto (W) e Redes Neurais Artificiais. Os modelos híbridos W-ANN foram comparados aos métodos ANN, MLR, Regressão Não Linear Múltipla (MNL) e ARIMA para prever um lead time de um dia. Os resultados indicam que as W-ANN foram mais

robusto do que todos os outros métodos, sugerindo o potencial promissor deste método para prever a demanda de água urbana. Segundo os autores, a precisão da previsão de W ANN pode ser útil na gestão, planejamento e avaliação de sistemas existentes, iniciativas de conservação, análise de condições de seca e políticas de precificação da água.

Odan & Reis (2008) tiveram como objetivo identificar um método que melhor se ajustasse aos dados de consumo horário para uma determinada zona de abastecimento na cidade de Araraquara (Brasil). Antes de utilizar os valores observados, o procedimento de pré-processamento de dados faltantes resultantes de falhas de registro, ou a presença de valores maiores ou menores que duas vezes o valor absoluto do padrão devição, foi usado. O método de pré-processamento utilizado foi a Análise Bayesiana de Componentes Principais (BPCA) desenvolvida por Oba et al. (2005). Este método é baseado em uma regressão de componentes principais, estimativa Bayesiana e um algoritmo repetitivo de maximização de expectativas. O método utiliza um algoritmo Bayesiano variante iterativo para estimar a distribuição posterior dos parâmetros do modelo e dos dados defeituosos, até sua convergência. Segundo os pesquisadores, a técnica de pré-processamento obteve bons resultados, mesmo quando faltam 40% dos dados, superando o desempenho dos modelos baseados em K-Near est Neighbors (K-NN) e Singular Value Decomposition (SVD). . Após a conclusão do pré-processamento, a análise de correlação foi empregada para identificar as variáveis de entrada (temperatura, umidade relativa, tempo de consumo e nível do reservatório). Foi observado que a inclusão de

variáveis climáticas (temperatura e umidade relativa do ar) melhoraram a previsão de demanda. O tempo de consumo foi considerado como variável na correlação análise, devido ao consumo cíclico de água ao longo do dia. Este estudo abordou o problema de previsão de WSS em tempo real usando ANN, DAN2 e os modelos híbridos ANN-H e DAN2-H. Ambos os modelos híbridos ANN-H e DAN2-H utilizam o erro produzido pela predição da série de Fourier como entrada, alcançando resultados promissores. O modelo híbrido DAN2-H apresentou os melhores resultados, tanto para as previsões horárias quanto para as diárias.

De acordo com Liu e cols. (2013), os principais fatores que impactam os padrões de demanda de água urbana são muitas vezes difíceis de identificar, empregando algoritmos tradicionais, devido a inúmeros fatores incertos e dificuldades de quantificação. Para contornar esse problema, pesquisadores propuseram um algoritmo de redução de atributos aprimorado baseado na média de ponderação cumulativa C-Fuzzy (FCM). Este algoritmo foi utilizado para analisar os principais fatores que impactam o padrão de demanda de água diurna na cidade de Hangzhou (China). Os dados utilizados neste estudo incluíram temperatura mínima, média e máxima diária, precipitação diária, dia da semana ou final de semana e padrão de demanda hídrica diurna. Posteriormente, utilizaram o SVR para avaliar a influência dos principais fatores na previsão do padrão diurno da demanda hídrica. O modelo com melhor desempenho incluiu temperatura mínima e máxima diária e dia da semana. Segundo os pesquisadores, esse algoritmo mostrou-se um método eficaz e viável para resolver o problema do agrupamento de curvas consecutivas, como no padrão de demanda diurna de água.

Recentemente, Tiwari & Adamowski (2018) realizaram previsões semanais e mensais de demanda de água na cidade de Calgary (Canadá). O método utilizado em seu estudo foi o híbrido Wavelet-Bootstrap Artificial Neural Network (WB ANN). A utilização deste método teve como objetivo melhorar a precisão e confiabilidade da previsão de demanda, incorporando capacidade de processamento Wavelet e análise Bootstrap (B) utilizando redes neurais artificiais. Este método foi então comparado ao padrão ANN, ANN baseado em Bootstrap (B-ANN) e baseado em W-ANN. Para a previsão de picos semanais e mensais, os métodos híbridos WB-ANN e W-ANN mostraram-se mais precisos quando comparados aos métodos B-ANN e ANN. Os resultados do

as previsões usando os métodos híbridos WB-ANN e W-ANN foram muito eficazes na previsão de picos de demanda de água. Isso indica que a análise Wavelet melhorou significativamente o desempenho do método, enquanto a técnica Bootstrap melhorou a confiabilidade das previsões. Outro ponto destacado pelos pesquisadores é a eficácia da metodologia em situações com disponibilidade limitada de dados.

Devido à dificuldade de modelagem de séries temporais de demanda de água usando métodos estatísticos tradicionais, Shabri & Samsu din (2017) propuseram um modelo híbrido que combina o Empirical Mode Decomposition (EMD), método proposto por Huang et al. (2003), e o método Least Square Support Vector Machine (LS-SVM) para prever o consumo de água. O EMD foi usado para decompor as séries não lineares e não estacionárias de demandas de água em vários componentes de funções de modo intrínseco (FMI) e um componente residual. O algoritmo LS-SVM foi construído para prever individualmente esses componentes intrínsecos e residuais, que posteriormente foram agregados para produzir o valor final esperado. Os resultados empíricos indicam que o método proposto supera o método LS-SVM simples e a RNA, sem pré-processamento EMD, e o método EMD-ANN.

Tiwari et al. (2018) usaram o recém-desenvolvido método Extreme Learning Machines (ELM), sozinho ou em conjunto com os métodos de análise wavelet (W) ou Bootstrap (B), para prever a demanda diária de água na cidade de Calgary, Canadá. Posteriormente, eles foram avaliados e comparados com métodos equivalentes baseados em RNA tradicionais (ie, ANN, W-ANN, B-ANN). Os métodos híbridos B-ELM e B-ANN forneceram precisão semelhante nas previsões em dias de pico. No entanto, os métodos W-ANN e W-ELM proporcionaram maior precisão, com o método W-ELM superando o método W-ANN. A superioridade do método W-ELM sobre os métodos tradicionais (W-ANN ou B-ANN) demonstra a importância da transformação wavelet na modelagem de previsão de demanda de água urbana. Isso destaca a capacidade da transformação wavelet de decompor séries temporais com comportamento não estacionário em componentes discretos, destacando os padrões e tendências cíclicos.

Arandi et al. (2018) apresentou uma metodologia para prever a demanda de água no curto prazo através da combinação de componentes autoregressivos, médias móveis, filtro de integração e termos sazonais adicionados ao

Método ARIMA (SARIMA). Segundo Caiado (2013), esse método não tem recebido muita atenção para prever a demanda de água, apesar de suas qualidades de parcimônia e facilidade de interpretação de seus parâmetros em função explícita de formulações matemáticas. Para Arandi et al. (2013), o modo offline é mais adequado para operações de serviços públicos (como dimensionamento diário da produção de água), enquanto o modo online pode ser mais apropriado para outras operações (como programação de bombas). No modo offline, o método emprega os modelos reestimados usando dados históricos mais recentes. No modo online, o método aplica o filtro de Kalman para atualizar e otimizar os modelos usando dados de 'feed' em tempo real. Três conjuntos de dados qualitativamente diferentes foram modelados. Estruturas e estimativa de tamanho de amostra de dados usados para treinamento foram identificadas. Esses modelos foram aplicados para antecipar demandas com 24 horas de antecedência utilizando os modos offline e online. Posteriormente, os resultados foram analisados, comparados e demonstrados a aplicação do método na previsão da produção diária de água utilizando métodos SARIMA. Ao contrário dos métodos RNA, ou outros métodos conhecidos como 'caixa preta', a metodologia SARIMA pode ser moldada na forma de um modelo de espaço de estados, identificando as estruturas paramétricas mais adequadas para demandas de água com resoluções temporais variando de hora em hora a diária.

Modelos híbridos com vários métodos empregados

Pulido-Calvo & Gutiérrez-Estrada (2003) propuseram um modelo híbrido usando Redes Neurais, Inferência Fuzzy e Algoritmos Genéticos (AG) para prever a demanda diária de água no distrito de irrigação da Andaluzia no sul da Espanha. Os métodos de RNA foram treinados usando o algoritmo Extended-Delta-Bar-Delta (EDBD) (Pulido-Calvo et al. 2003) e, posteriormente, recalibrados com uma variação do algoritmo Error Backpropagation conhecido como Levenberg-Marquardt (Shepherd 2003). Segundo Wilamowski & Yu (2003), o algoritmo de Levenberg-Marquardt é atualmente um dos mais eficientes para o treinamento de redes neurais artificiais, principalmente quando envolvem séries temporais longas. Os resultados obtidos com o modelo híbrido indicaram que ele é superior aos métodos RNA autoregressivo, univariado e multivariado.

Portanto, o modelo híbrido é uma ferramenta muito poderosa para desenvolver políticas apropriadas de consumo de água para irrigação.

Caiado (2013) analisou o desempenho da previsão de demanda na Espanha usando os métodos de suavização exponencial univariada de Holt-Winters (HW), ARIMA e heterocedasticidade condicional autorregressiva generalizada (GARCH), para um a sete passos à frente. Segundo o autor, a combinação fornece previsões mais precisas do que os métodos individuais. As previsões podem ser combinadas usando uma média simples ou ponderada. Foram consideradas todas as combinações possíveis dos métodos de previsão Holt-Winters, ARIMA e GARCH, utilizando a média simples das previsões para 1 a 7 passos (dias) à frente. Para calcular os pesos ideais, o autor considerou duas abordagens. Primeiro, os pesos eram proporcionais ao MSE inverso de cada método individual (Makridakis e Winkler, 1983). Em segundo lugar, os pesos foram proporcionais ao inverso dos erros quadrados de predição (PSE) de cada método individual. Se o desempenho de métodos individuais mudar durante o período de previsão, combinar previsões com o uso de pesos inversos de PSE pode resultar em previsões mais precisas do que o método que usa pesos inversos de MSE. Os resultados indicam que a combinação de previsões pode ser muito útil, principalmente para previsões de curto prazo. No entanto, o desempenho dessa abordagem não é consistente ao longo dos sete dias da semana. Por outro lado, as previsões individuais dos métodos HW e GARCH podem melhorar a precisão da previsão em dias específicos da semana.

Azadeh et al. (2003) apresentaram uma abordagem híbrida, utilizando RNA e Regressão Linear Fuzzy (FLR), para melhorar a previsão de demanda de água. Segundo os pesquisadores, essa abordagem pode ser facilmente aplicada em ambientes incertos ou complexos, dada sua flexibilidade. A abordagem híbrida proposta foi aplicada para prever a demanda diária de água em Teerã (Irã). As variáveis utilizadas foram a temperatura máxima diária, a temperatura máxima prevista para o dia seguinte, o índice de precipitação e a demanda em dias quentes e dias frios. Os resultados indicaram que a RNA superou a FLR formada em dias quentes devido à sua capacidade de lidar com complexidade e não linearidade. No entanto, tanto ANN quanto FLR foram ideais em dias frios.

Segundo Al-Zahrani & Abo-Monasar (2003), os fatores climáticos desempenham um papel fundamental na previsão da demanda hídrica de curto prazo, pois influenciam diretamente no consumo de água. Seu estudo foi realizado na cidade de Al-Khobar, na Arábia Saudita, e empregou o clima

parâmetros de umidade e temperatura (mínimo, médio e máximo), intensidade de chuva, ocorrência de chuva e velocidade do vento associada ao histórico de consumo diário de água. Neste estudo, investigou-se o potencial de modelos híbridos, para a previsão de demanda diária de água, acoplando Séries Temporais a Redes Neurais Artificiais (TS GRNN). Os resultados indicam que os modelos híbridos TS-GRNN fornecem melhores previsões quando comparados aos métodos ANN ou TS sozinhos. Segundo os autores, os resultados indicam que a temperatura é o preditor meteorológico mais importante no treinamento da rede neural. A umidade, a velocidade do vento e a ocorrência de chuva também se mostraram importantes, mas não podem ser utilizadas sem temperatura. Por outro lado, a intensidade da chuva é o parâmetro que menos contribui, para a capacidade do modelo de prever a demanda de água, durante o processo de treinamento da RNA.

Modelos híbridos com processamento de sinal integrado

Bai et al. (2017) propôs uma abordagem Multi-Scale Relevance Vector Regressor (MS-RVR) para prever a demanda diária de água na cidade de Chongqing (China). Este método é um híbrido que combina o RVR e a análise multiescala da wavelet. Os coeficientes da Wavelet, de todas as escalas obtidas, foram usados para treinar um modelo de aprendizado de máquina usando o método Relevance Vector Regression (RVR). Posteriormente, os coeficientes estimados do RVR foram utilizados para gerar os resultados de previsão através da transformada wavelet inversa. A fim de facilitar a predição do MS-RVR, as características do caos da série diária de abastecimento de água foram analisadas usando o algoritmo Adaptive Chaos Particle Swarm Optimization (ACPSO) para determinar a combinação ótima das variáveis de entrada do método RVR. Por fim, os pesquisadores compararam os resultados do melhor método MS-RVR com dois métodos recentes propostos por Firat et al. (2017), denominados GRNN e FFNN, usando o mesmo conjunto de dados e os mesmos critérios de precisão. Os resultados mostram que o método MS-RVR proposto é muito mais preciso.

Modelagem on-line em sistemas de distribuição de água

De acordo com Zapelan (2017), vários métodos matemáticos são usados para descrever o comportamento do WDS. Acordo indo para Gupta et al. (2017), alguns métodos pertencem a um grupo

de problemas intrinsecamente intratáveis comumente referidos como NP-difíceis. Para ter um uso significativo, o modelo matemático WDS deve primeiro ser calibrado (Zapelan 2017). Essa calibração é definida como um processo no qual vários parâmetros do modelo WDS são ajustados até que o modelo imite o comportamento real do WDS o mais próximo possível. A calibração do modelo hidráulico WDS é aprimorada pela aplicação de métodos de otimização apropriados. Recentemente, a aplicação de técnicas de otimização estocástica baseada na natureza, como o Algoritmo Genético (AG), tem se expandido. De acordo com Broad e cols. (2017), o AG demonstrou sua aplicabilidade na otimização das operações de WDS minimizando o custo sujeito a restrições hidráulicas. Além disso, de acordo com Broad et al. (2017), o foco da otimização se expandiu para incluir questões relacionadas à qualidade da água, gerando complexidade adicional e aumentando a sobrecarga computacional. A modelagem em tempo real do WDS, segundo Hutton et al. (2017), muitas vezes negligencia as múltiplas fontes de incerteza do sistema, afetando assim a identificação de soluções operacionais robustas. Para minimizar essa lacuna, esses autores fornecem uma revisão crítica de vários métodos aplicados na quantificação e redução da incerteza em cada etapa da modelagem em cascata, desde a calibração, passando pela assimilação de dados, até a previsão do modelo. Esta revisão também inclui métodos promissores para lidar com a incerteza do modelo aplicado em campos científicos relacionados e considera questões-chave que governam sua aplicação no controle de WDS.

Odan (2017) implementou o Método Multi-Algoritmo Geneticamente Adaptativo (AMALGAM) integrado ao simulador hidráulico (EPANET 2) e o método de Dinâmica de Rede Neural (DAN2-H). O estudo foi realizado na cidade de Araraquara (Brasil). O método foi aplicado em três setores distintos (Eliana, Iguatemi e Martinez) e as estratégias operacionais resultantes proporcionaram reduções de 14%, 13% e 30%, respectivamente, no custo do consumo de energia elétrica. Este método de otimização provou ser uma ferramenta robusta e eficiente.

Xu et al. (2017) usou o espectro de energia (Oshima & Kosuda 2017) e o maior expoente de Lyapunov (Tsonis 2017) para examinar qualitativamente as características da série temporal. Seus resultados indicam que a série temporal de demanda de água apresenta características de caos. Os resultados estão de acordo com os obtidos por Zhao & Zhang

([ȳȳȳȳ](#)); resultados de [Bai et al. \(\[ȳȳȳȳ\]\(#\)\)](#) também foram semelhantes. Portanto, os problemas de previsão da demanda de água podem ser traduzidos em problemas de previsão de séries caóticas.

[Romano & Kapelan \(\[ȳȳȳȳ\]\(#\)\)](#) apresentaram um inovador metodologia para prever a demanda de água por até 24 horas, com o objetivo de apoiar a gestão operacional em sistemas de distribuição de água em tempo quase real. A metodologia é baseada exclusivamente na análise de séries temporais de demanda hídrica (estimada por análise de balanço de massa), usando Redes Neurais Artificiais (E-ANN). As principais características do Sistema de Previsão de Demanda (DFS) incluem adaptabilidade às mudanças nos padrões de demanda de água, aplicabilidade e transparência para diferentes sinais de demandas, redução drástica do necessário, especialista humano esforço na projeção de um método RNA, e, viabilidade de implementar esta metodologia em ambiente online. O DFS consiste em quatro componentes principais: (i) o módulo de pré-processamento de dados; (ii) a otimização da RNA módulo; (iii) o módulo de construção da RNA; e (iv) o Módulo de previsão de demanda de água (WDF). Para o específico sinal de demanda que está sendo analisado, o pré-processamento de dados módulo prepara os dados brutos para facilitar/melhorar o processo de construção do método E-ANN e assim obter um WDF mais preciso. O DFS permite a aplicação de duas abordagens alternativas para sistemas de distribuição de água. O primeiro modelo (pE-ANN) utilizou vários modelos de E-ANN em paralelo para prever as demandas, separadamente, para diferentes tempos de dia. O segundo modelo (rE-ANN) usou uma horizonte de previsão para prever as demandas. Ambas as abordagens foram usados e testados para três medidas distritais Áreas (DMA) e uma Zona de Abastecimento de Água (WSZ) de Yorkshire Serviços de Água (YWS) cobrindo partes significativas de dois cidades do condado de Yorkshire, no Reino Unido. De acordo com pesquisadores, essa nova metodologia permite previsões a serem geradas, demonstrando assim o potencial de proporcionar melhorias substanciais para o estado de a arte na gestão da distribuição inteligente de água sistemas, em tempo quase real. Os desempenhos das previsões foram avaliados em termos de Nash-Sutcliffe (NSI), o erro quadrado médio (MSE) e porcentagem absoluta média erro (MAPE). Os resultados mostraram que, independentemente da abordagem utilizada, os vários modelos E-ANN superam ligeiramente o único modelo E-ANN em termos de precisão na previsão demanda de água.

Segundo [Herrera et al. \(\[ȳȳȳȳ\]\(#\)\)](#), o uso de SVR é um das melhores opções de aprendizado de máquina para demanda de curto prazo previsão. Portanto, [Brentan et al. \(\[ȳȳȳȳ\]\(#\)\)](#) propôs um modelo híbrido online aplicando SVR e Série de Fourier Adaptável (AFS) para melhorar a previsão. O estudo foi realizado em município de Franca (Brasil), onde os dados sobre demanda de água pelos consumidores residenciais, temperatura, umidade, precipitação e velocidade do vento.

A [Tabela 2](#) resume as informações sobre o uso de métodos de previsão de demanda de água.

DISCUSSÃO

A revisão da literatura mostra que no contexto da água previsão de demanda, vários métodos Soft Computing (SC) têm sido estudados e aplicados para lidar com problemas de precisão, estocasticidade e não linearidade ([Bonissone \[ȳȳȳȳ\]\(#\)](#)). Esse torna a previsão da demanda de água uma tarefa muito difícil. Nesse sentido, os métodos SC (Lógica Fuzzy, Computação Neural, Algoritmos Genéticos, Computação Evolutiva, aprendizado de máquina e sistemas híbridos que utilizam tal complementaridade) contribuíram muito para o avanços na previsão da demanda de água urbana. De acordo com [Bates & Granger \(\[ȳȳȳȳ\]\(#\)\)](#), a possibilidade de aumentar a precisão dos prognósticos beneficia da complementaridade das informações contidas em cada previsão individual. Isso resulta da proposição de que a variância esperada dos erros da previsão combinada é menor do que o pequeno para evitar as variações das previsões individuais. Cada um de esses métodos fornecem ferramentas adicionais, tentando resolver problemas complexos do mundo real.

No entanto, um olhar mais atento à literatura revisada e avanços recentes nos métodos SC sugerem que ainda há espaço para melhorias na previsão da demanda de água.

Para redes neurais, elas podem ser divididas em vários tipos de arquitetura. No entanto, existem poucos métodos usado para prever a demanda de água ([Ghalekhondabi et al. \[ȳȳȳȳ\]\(#\)](#)). Uma extensa revisão da literatura revelou que apenas pequeno número de arquiteturas foram empregadas para prever demanda urbana de água. A arquitetura mais utilizada na previsão da demanda hídrica urbana é a FFNN, também conhecida como MLP. Referências à Rede Neural de Base Radial (RBNN) ([Broomhead & Lowe \[ȳȳȳȳ\]\(#\)](#)), Rede Neural Probabilística

Tabela 2 | Métodos de previsão da demanda de água de acordo com a literatura usada

| Autores | Localização | Parâmetros | Frequência | Métricas | Métodos |
|-------------------------|-------------------------|---|------------|-----------------------------|--|
| Nicólas et al. (2017) | Al Kobar/Arábia Saudita | Temperatura, precipitação, relativa umidade, velocidade do vento | Diário | MAPE, NRMSE, R | Regressão (MS-RVR), Artificial Redes Neurais (ANN): GRNN, FFnn |
| Azad et al. (2017) | Teerã/Irã | Temperatura, precipitação, demanda | Diário | MAPE, NRMSE, R | Regressão (MS-RVR), Artificial Redes Neurais (ANN): GRNN, FFnn |
| Bai et al. (2017) | Chongqing/China | Demanda | Diário | MAPE, NRMSE, R | Regressão (MS-RVR), Artificial Redes Neurais (ANN): GRNN, FFnn |
| Brentan et al. (2017) | Francês / Brasil | Temperatura, precipitação, relativa umidade, velocidade do vento | Diário | RMSE, MAE, R2 | Regressão vetorial de suporte (SVR), Regressão de vetor de suporte adaptável Série Fourier (SVR-AFS) |
| Caiado (2017) | Espanha | Demanda | Diário | MSE | Movimento Integrado Autoregressivo Média (ARIMA), Holt Winters, Autoregressivo Generalizado Heteroscedasticidade condicional (GARCH) |
| Firat et al. (2017a) | Izmir/Turquia | Demanda | Por mês | NRMSE, AARE, TS | Inferência Fuzzy: ANFIS, MFIS |
| Firat et al. (2017b) | Izmir/Turquia | População, número de domicílios, produto nacional bruto, temperatura, precipitação, umidade, inflação, exigem | Por mês | NRMSE, R, NSI | Redes Neurais Artificiais (RNA): GRNN, FFNN, RBNN |
| Firat et al. (2017c) | Izmir/Turquia | Demanda | Por mês | NRMSE, R, NSI | Redes Neurais Artificiais (RNA): GRNN, GRNN, FFNN |
| Fullerton et al. (2017) | El Paso/EUA | Demanda de água por cliente, real preço médio da receita, número de clientes por dia, clima > 32 C, taxa de precipitação mensal, não sazonal não agrícola emprego | Por dia | Valor p, HM, U, estatística | Modelos de regressão linear múltipla, Redes Neurais Artificiais (RNA), Modelos de regressão logística, Modelos de regressão logística com Derivada (RW), |

(continuo)



(PNN) ([Specht 1998](#)) e ELM (Huang et al. 2006) também foram encontrados. No entanto, não há estudos utilizando a arquitetura de Redes Neurais Recorrentes como Hopfield ([Hopfield 1982](#)), Jordan ([Jordan 1986](#)), Rede Neural Totalmente Recorrente (FRNN) ([Williams & Zipser 1986](#)), Elman Networks ([Elman 1990](#)), Local Recurrent Global Feedforward (LRGF) ([Tsoi & Back 1994](#)), Long Short-Term Memory (LSTM) (Hochreiter e Schmidhuber, 1997) e Neural State Echo (ESNN) ([Jaeger 1998](#)) foram encontrados para prever a demanda de água.

Avanços recentes em redes neurais, como a Rede Neural Convolutacional (CNN ou ConvNet), não têm sido utilizados para prever a demanda hídrica urbana, abrindo um espaço promissor para esse problema. Recentemente, [Borovykh et al. \(2017\)](#) desenvolveram uma rede neural convolutacional profunda para prever séries temporais multivariadas, com base na recente arquitetura WAVENET desenvolvida por [Oord et al. \(2016\)](#). Além disso, de acordo com [Qiu et al. \(2017\)](#), os métodos de aprendizado profundo provaram ser altamente promissores em várias áreas de previsão.

Além disso, em relação às redes neurais, o número de camadas ocultas e os algoritmos utilizados no treinamento podem afetar o desempenho da RNA. Encontrar a melhor arquitetura pode ser uma tarefa difícil, e o FFNN nem sempre pode ser o melhor método ou fornecer os melhores resultados ([Herrera et al. 2017](#)). Outros algoritmos como Dynamic Gaussian Bayesian Network (DGBN) ([Froelich 2017](#)) e ELM foram pesquisados e desenvolvidos para otimizar previsões baseadas em redes neurais ([Tiwari et al. 2017](#)).

Esta revisão de literatura mostra que os estudos são mais focado no sistema operacional de gestão (curto prazo), segundo a classificação proposta por [Gardiner & Herrington \(2017\)](#) e utilizada por [Donkor et al. \(2017\)](#). Existem pouquíssimos estudos que abordam a previsão de médio e longo prazo. Uma possível explicação pode estar associada à inadequação da arquitetura básica da RNA, como a FFNN, para lidar com dados ruidosos ([Ghalekhondabi et al. 2017](#)), limitando sua aplicação a padrões menos complexos e linearmente inseparáveis. Existem também certos tipos de padrões nas séries temporais de demanda de água, que exigem grande necessidade de pré-processamento. A fim de melhorar a precisão da previsão, os pesquisadores começaram a desenvolver métodos híbridos baseados no acoplamento wavelet e bootstrap ([Adamowski et al. 2017](#); [Tiwari & Adamowski 2017](#); [Tiwari et al. 2017](#); [Altunkaynak & Nigussie 2017](#); [Chen et al. 2017](#); [Du et al.](#)

[2017](#)). Esses métodos foram mais robustos na predição, em comparação com o FFNN, RLM, Nonlinear Regression Multiple (NRLM) e regressão ARIMA, indicando que a transformada wavelet melhorou significativamente o desempenho dos métodos, destacando sua capacidade de processamento em decomposição em estado estacionário de componentes de séries temporais. Também destaca padrões e tendências cíclicos, enquanto a técnica bootstrap melhorou a confiabilidade da previsão, sugerindo um potencial promissor desse método híbrido para prever a demanda urbana de água.

Em relação aos modelos híbridos, destacamos o Time Delayed Neural Network (TDNN) ([Htike & Khalifa 2017](#)), ANN com Fuzzy ([Araujo et al. 2017](#)), Local Feedback Dynamic Neural Network (LF-DFNN) ([Barbounis & Theocharis 2017](#)), Neuro-Fuzzy (ANFIS) ([Jang 2001](#), [2017](#)), ARIMA-ANN ([Zhang 2017](#)), ARIMA-SVR ([Chen 2017](#)) combinação dos métodos ARIMA-HW-GARCH ([Caiado 2017](#)) e Rede Neural de Crença Profunda Contínua (CDBNN)

([Xu et al. 2017](#)).

A linha de pesquisa Metaheurística tem grande potencial de aplicação na previsão de demanda de água. No entanto, existem poucos estudos utilizando programação genética, como [Pulido Calvo & Gutiérrez-Estrada \(2017\)](#) e [Nasseri et al. \(2017\)](#). [Odan \(2017\)](#) já utilizou o método de otimização AMALGAM e, mais recentemente, [Bai et al. \(2017\)](#) usou o ACPSO. Outras metaheurísticas, como o método de otimização de colônias de formigas (ACO) ([Colorni et al. 2017](#)), procedimentos de randomização adaptativa ágil (GRASP) ([Feo & Resende 2017](#)), algoritmo genético de recozimento simulado (GSAA), também pode ser empregado.

CONSIDERAÇÕES FINAIS

Neste trabalho, foi apresentada uma extensa revisão sobre a previsão da demanda urbana de água utilizando inteligência artificial, a fim de fornecer algumas orientações sobre métodos e modelos aos profissionais das empresas de saneamento. Este artigo deve ser utilizado para abordar decisões de planejamento de curto, médio e longo prazo, e por pesquisadores que tenham o objetivo de aprimorar os modelos. Esta revisão mostra que os estudos são, em sua maioria, voltados para a gestão dos sistemas operacionais. Há, portanto, espaço para previsões de longo prazo e apoio ao desenvolvimento de planos diretores.

Vale ressaltar que não existe um modelo global, ou seja, um método soft computing que supera todos os métodos em todos os casos. Cada região deve ser estudada separadamente, buscando somar os pontos fortes de cada modelo, ou combinação de modelos, ou escolhendo um modelo mais adequado para determinada ocasião. Outro ponto diz respeito à robustez do desempenho dos modelos. Os resultados indicam que os modelos híbridos e inovadores apresentaram resultados superiores, quando comparados aos modelos clássicos analisados.

Embora grandes avanços nos métodos de computação suave tenham sido feitos recentemente, nenhum novo método, como redes neurais profundas, entre outros, surgiu como a melhor abordagem de previsão. Portanto, a previsão de demanda de água ainda permanece um problema de pesquisa, o que deixa espaço para pesquisadores desenvolverem métodos híbridos ou específicos para aplicações específicas.

O uso de aplicações estatísticas de metodologias de Machine Learning e Inteligência Artificial na previsão de demanda de água tem crescido consideravelmente nos últimos anos. No entanto, ainda há espaço para melhorias no que diz respeito à previsão da demanda de água.

REFERÊNCIAS

Adamowski, J. & Karapataki, C. [Comparação de regressão multivariada e redes neurais artificiais para previsão de pico de demanda urbana de água: avaliação de diferentes algoritmos de aprendizado de RNA](#) . Journal of Hydrologic Engineering 15 (10), 729–743. doi:10.1061/_ASCE_HE.1943-5584.0000245.

Adamowski, J., Chang, HF, Prascher, SO, Ozga-zielinski, B. & Sliusarieva, A. [Comparação de regressão linear múltipla e não linear, média móvel integrada autoregressiva , rede neural artificial e rede neural artificial wavelet métodos para previsão da demanda de água urbana em Montreal, Canadá](#). Pesquisa de Recursos Hídricos 47, 1–14. doi:10.1029/2010WR009945.

Altunkaynak, A. & Nigussie, TA [Previsão de consumo mensal de água usando algoritmo sazonal e modelos baseados em transformada wavelet](#) . Jornal de Planejamento e Gestão de Recursos Hídricos 143 (6). doi:10.1061/(ASCE)WR.1943-5452.0000761.

Altunkaynak, A., Özger, M. & Çakmakci, M. [Água previsão de consumo da cidade de Istambul usando abordagem de lógica fuzzy](#). Gestão de Recursos Hídricos 19, 641–654. doi:10.1007/s11269-005-7371-1.

Al-Zahrani, MA & Abo-Monasar, A. [Residencial urbano previsão de demanda de água com base em redes neurais artificiais](#)

[e modelos de séries temporais](#). Gestão de Recursos Hídricos 29, 3651–3662. doi:10.1007/s11269-015-1021-z.

Arandia, E., Ba, A., Eck, B. & Mckenna, S. [Adaptação de modelos de séries temporais sazonais para prever a demanda de água de curto prazo](#). Jornal de Planejamento e Gestão de Recursos Hídricos 142 (3). doi:10.1061/(ASCE)WR.1943-5452.0000591.

Araujo, R., Valença, M. & Fernandes, S. [Uma Nova Abordagem de Redes Neurais Fuzzy na Previsão Mensal de Vazão de Água](#). In: Avanços em Inteligência Computacional, vol. 9094 (I. Rojas, G. Joya & A. Catala, eds). IWANN 2015. Notas de Palestra em Ciência da Computação. Springer, Cham. https://doi.org/10.1007/978-3-319-19258-1_47

Arbués, F., Valiñas, M. A. G. & Espiñeira, R. M. [Estimation of residential water demand: a state-of-the-art review](#). The Journal of Socio-Economics 32, 81-102. <http://www.sciencedirect.com/science/article/B6W5H...3ad935b7298f4feb8cdd>

Azadeh, A., Neshat, N. & Hamidipour, H. [Regressão Fuzzy Híbrida – rede neural artificial para melhoria da estimativa e previsão de consumo de água de curto prazo em ambientes incertos e complexos: caso de uma grande cidade metropolitana](#). Journal of Water Resource Planning and Management 138 (1), 71–75. [https://doi.org/10.1061/\(ASCE\)](https://doi.org/10.1061/(ASCE)WR.1943-5452.0000152)

WR.1943-5452.0000152

Bai, Y., Wang, P., Li, C., Xie, J. & Wang, Y. [A multiescala abordagem de regressão vetorial de relevância para a previsão diária da demanda de água urbana](#). Journal of Hydrology 517, 236-245. doi:10.1016/j.jhydrol.2014.05.033.

Barbounis, TG & Theocharis, JB [Uma rede neural difusa localmente recorrente com aplicação à previsão da velocidade do vento usando correlação espacial](#). Neurocomputing 70 (7-9), 1525-1542. <https://doi.org/10.1016/j.neucom.2006.01.032>.

Bates, JM & Granger, CWJ [Combinação de previsões](#). Operations Research Quarterly 20 (4), 451–468. doi: 10.2307/3008764.

Bonissone, PP [Soft computing: convergência de tecnologias de raciocínio emergentes](#). Computação Suave 1, 6–18. <https://doi.org/10.1007/s005000050002>.

Borovykh, A., Bohte, S. & Oosterlee, CW [Previsão Condicional de Séries Temporais com Redes Neurais Convolucionais](#). Biblioteca da Universidade de Cornell de aprendizado de máquina. <https://arxiv.org/pdf/1703.04691.pdf>.

Breiman, L. [Preditores de ensacamento](#). Aprendizado de Máquina 24 (2), 123–140. <https://doi.org/10.1023/A:1018054314350>.

Breiman, L. [Floresta aleatória](#). Aprendizado de Máquina 45 (1), 5–32. doi:10.1023/A:1010933404324.

Brentan, BM, Luziovoto-Jr., E., Herrera, M., Izquierdo, J. & Pérez-Garcia, R. [Modelo de regressão híbrida para previsão de demanda de água urbana em tempo quase real](#). Revista de Matemática Computacional e Aplicada. doi:10.1016/j.cam.2016.02.009.

Broad, DR, Dandy, GC & Maier, HR [Otimização do sistema de distribuição de água usando metamodelos](#). Journal of Water Resources Planning Management 131 (3), 172–180. doi: 10.1061/(ASCE)0733-9496(2005)131:3(172).

Broomhead, DH & Lowe, D. [Interpolação funcional multivariável e redes adaptativas](#). Complex Systems 2, 321–355.

Caiado, J. [Desempenho do combinado duplo sazonal modelos de séries temporais univariadas para previsão de demanda de água](#). Journal of Hydrologic Engineering 15 (3), 215–222. [https://doi.org/10.1061/\(ASCE\)HE.1943-5584.0000182](https://doi.org/10.1061/(ASCE)HE.1943-5584.0000182).

Chang, H., Parandvash, H. & Shandas, V. [Variações espaciais do consumo de água residencial unifamiliar em Portland, Oregon](#). Geografia Urbana 31, 953-972. doi: 10.2747/0272- 3638.31.7.953.

Chen, K.-Y. [Combinando modelo linear e não linear na previsão da demanda turística](#). Sistemas Especialistas com Aplicativos 38 (8), 10368–10376. <https://doi.org/10.1016/j.eswa.2011.02.049>.

Chen, G., Long, T., Xiong, J. & Bai, Y. [Modelagem de floresta aleatória múltipla para previsão de consumo de água urbana](#). Gestão de Recursos Hídricos 31 (5), 4715–4729. <https://doi.org/10.1007/s11269-017-1774-7>.

Colomi, A., Dorigo, M. & Maniezzo, V. [Distribuído otimização por colônias de formigas](#). Na Conferência Europeia de Vida Artificial. Elsevier Publishing, Paris, pp. 134-142.

Crone, SF & Kourentzse, N. [Seleção de recursos por tempo previsão de série – Uma abordagem combinada de filtro e wrapper para redes neurais](#). Neurocomputing 73, 1923-1936. doi: 10.1016/j.neucom.2010.01.017.

Dahl, CM & Hylleberg, S. [Modelos de regressão flexíveis e desempenho de previsão relativa](#). International Journal of Forecasting 20 (2), 201–207. doi:10.1016/j.ijforecast.2003.09.002.

Di, C., Yang, X. & Wang, X. [Um modelo híbrido de quatro estágios para previsão hidrológica de séries temporais](#). PLoS One 9 (8), 1–18. <https://doi.org/10.1371/journal.pone.0104663>.

Dietterich, TG [Métodos de combinação em aprendizado de máquina](#). Múltiplos Sistemas Classificadores Notas de Aula em Ciência da Computação 1857, 1–15. https://doi.org/10.1007/3-540-45014-9_1.

Donkor, EA, Mazzuchi, TA, Soyer, R. & Roberson, JA [Previsão da demanda de água urbana: revisão de métodos e modelos](#). Journal of Water Resources Planning and Management 140 (2), 146–159. [https://doi.org/10.1061/\(ASCE\)WR.1943-5452.0000314](https://doi.org/10.1061/(ASCE)WR.1943-5452.0000314).

Du, K., Zhao, Y. & Lei, J. [O uso incorreto de análise espectral singular e transformada wavelet discreta em modelos híbridos para prever séries temporais hidrológicas](#). Journal of Hydrology 552, 44-51. doi:10.1016/j.jhydrol.2017.06.019.

Elman, JL [Encontrando a estrutura no tempo](#). Ciência Cognitiva 14 (2), 179-211. https://doi.org/10.1207/s15516709cog1402_1.

Feo, TA & Resende, MGC [Uma heurística probabilística para um problema computacionalmente difícil de cobertura de conjuntos](#). Operations Research Letters 8 (2), 67–71. doi:10.1016/0167-6377(89) 90002-3.

Firat, M., Turan, ME & Yurdusev, MA [Análise comparativa de sistemas de inferência fuzzy para previsão de séries temporais de consumo de água](#). Journal of Hydrology 374, 235-241. <https://doi.org/10.1002/wrcr.20517>.

Firat, M., Yurdusev, MA & Turan, ME [Avaliação de técnicas de redes neurais artificiais para modelagem de consumo de água municipal](#). Gestão de Recursos Hídricos 23, 617-632. doi:10.1007/s11269-008-9291-3.

Firat, M., Turan, ME & Yurdusev, MA [Comparativo análise de técnicas de redes neurais para previsão de séries temporais de consumo de água](#). Journal of Hydrology 384, 46-51. <http://dx.doi.org/10.1016/j.jhydrol.2010.01.005>.

Freitas, A. A. C. [Previsão de séries temporais via seleção de variáveis, reconstrução dinâmica, ARMA-GARCH e redes neurais artificiais](#). Tese (Doutorado), Universidade Estadual de Campinas, Campinas. (in Portuguese).

Freund, Y. & Schapire, RE [Experimentos com um novo algoritmo de reforço](#). In: Proceedings of the International Conference on Machine Learning, pp. 148–156. doi: 10.1.1.29.3868.

Froelich, W. [Previsão da Demanda Diária de Água Urbana Usando Rede Bayesiana Gaussiana Dinâmica](#). In: Além de Bancos de Dados, Arquiteturas e Estruturas. BDAS 2015, Vol. 521 (S. Kozielski, D. Mrozek, P. Kasprowski, B. Małysiak, Mrozek & D. Kostrzewa, eds). Comunicação em Ciência da Computação e Informação. Springer, Cham. https://doi.org/10.1007/978-3-319-18422-7_30

Fullerton Jr, TM, Ceballos, A. & Walke, AG [Análise de previsão de curto prazo para a demanda municipal de água](#). Journal American Water Works Association 108 (1), 27–38. <http://dx.doi.org/10.5942/jawwa.2016.108.0003>.

Gagliardi, F., Alvisi, S., Kapelan, Z. & Franchini, M. [Água urbano modelo probabilístico de previsão de demanda de água de curto prazo baseado na Cadeia de Markov](#). Água 9, 507. doi:10.3390/w9070507.

Gardiner, V. & Herrington, P. [Water Demand Forecasting](#). Spon Press, Norwich, Reino Unido

Gashler, M., Giraud-Carrier, C. & Martinez, T. [Conjunto de Árvore de Decisão : Pequeno Heterogêneo é Melhor que Grande Homogêneo](#). In: 7th International Conference on Machine Learning and Applications, 11 a 13 de dezembro, San Diego, EUA. doi:10.1109/ICMLA.2008.154.

Ghalekhondabi, I., Ardjmand, E., Yong II, WA & Weeckman, GR [Previsão de demanda de água: revisão de métodos de computação suave](#). Monitoramento e Avaliação Ambiental 189–313. doi:10.1007/s10661-017-6030-3.

Ghiassi, M., Zimbra, DK & Saidane, H. [Água urbana previsão de demanda com um modelo dinâmico de rede neural artificial](#). Journal of Water Resource Planning and Management 134 (2), 138–146. doi:10.1061/(ASCE)0733-9496(2008) 134:2(138).

Granger, CWJ [Combinando previsão – vinte anos depois](#). Journal of Forecasting 8, 167–173. doi:10.1002/for. 3980080303.

Granitto, PM, Verdes, PF & Ceccatto, HA [Neural ensembles de rede: avaliação de algoritmos de agregação](#). Inteligência Artificial 163, 139-162. <https://doi.org/10.1016/j.artint.2004.09.006>.

Gupta, I., Gupta, A. & Khanna, P. [Algoritmo genético para otimização de sistemas de distribuição de água](#). Ambiental

Modelagem e Software 14, 437–446. [https://doi.org/10.1016/S1364-8152\(98\)00089-9](https://doi.org/10.1016/S1364-8152(98)00089-9).

Guyon, I. & Elisseeff, A. [ȳȳȳ Uma introdução à seleção de variáveis e recursos](#). Journal of Machine Learning Research 3, 1157–1182. <http://dx.doi.org/10.1162/153244403322753616>.

Hansen, LK & Salamon, P. [ȳȳȳ Conjuntos de redes neurais](#). Transações IEEE em Análise de Padrões e Inteligência de Máquina 12 (10), 993–1001. doi: 10.1109/34.58871.

Hassani, H. [ȳȳȳ Análise de espectro singular: metodologia e comparação](#). Journal of Data Science 5, 239–257. doi:RePEc:pra:mprra:4991.

Herrera, M., Torgo, L., Izquierdo, J. & Pérez-García, R. [ȳȳȳ Modelos preditivos para previsão da demanda horária de água urbana](#). Journal of Hydrology 387, 141-150. doi:10.1016/j.jhydrol.2010.04.005.

Holland, JH [ȳȳȳ Adaptação em Sistema Natural e Artificial](#). University of Michigan Press, Ann Arbor, Michigan.

Hopfield, JJ [ȳȳȳ Redes neurais e sistemas físicos com habilidades computacionais coletivas emergentes](#). Proceedings of National Academy of Science 79 (8), 2554–2558. <https://doi.org/10.1073/pnas.79.8.2554>.

House-Peters, L., Pratt, B. & Chang, H. [ȳȳȳ Efeitos da estrutura espacial urbana, sociodemográfica e clima no consumo de água residencial em Hillsboro, Oregon](#). Jornal da Associação Americana de Recursos Hídricos 46 (3), 461–472. doi:10.1111/j.1752-1688.2009.00415.x.

Hsu, HH, Hsieh, CCH & Lu, MD [ȳȳȳ Recurso híbrido seleção combinando filtros e wrappers](#). Sistemas Especialistas com Aplicativos 38, 8144–8150. doi:10.1016/j.eswa.2010.12.156.

Htike, KK & Khalifa, OO [ȳȳȳ Modelos de Previsão de Chuvas Usando Redes Neurais de Atraso de Tempo Focadas](#). In: International Conference on Computer and Communication Engineering (ICCC), Kuala Lumpur, Malásia. doi:10.1109/ICCC.2010.5556806.

Huang, NE, Shen, Z., Long, SR, Wu, MC, Shih, HH, Zheng, Q., Yen, N., Tung, CC & Liu, HH [ȳȳȳ A decomposição de modo empírico e o espectro de Hilbert para análise de séries temporais não lineares e não estacionárias](#). Anais da Royal Society 454, 903-995. doi:10.1098/rspa.1998.0193.

Hutton, CJ, Kapelan, Z., Vamvakieridou-Lyroudia, L. & Savic´, DA [ȳȳȳ Lidando com a incerteza em modelos de sistemas de distribuição de água : uma estrutura para modelagem em tempo real e assimilação de dados](#). Journal of Water Resources Planning and Management 140 (2), 169–183. [https://doi.org/10.1061/\(ASCE\)WR.1943-5452.0000325](https://doi.org/10.1061/(ASCE)WR.1943-5452.0000325).

Jaeger, H. [ȳȳȳ A Abordagem 'Echo State' Analisando e Treinando Redes Neurais Recorrentes](#). Relatório GMD 148, Instituto Nacional Alemão de Pesquisa para Ciência da Computação.

Jang, J.-SR [ȳȳȳ Modelagem Fuzzy Usando Neurais Generalizados Algoritmo de Redes e Filtro de Kalman](#). In: Proceedings of the 9th National Conference on Artificial Intelligence, Anaheim, CA, USA, Vol. 2, pp. 762-767.

Jang, J.-SR [ȳȳȳ ANFIS: sistema de inferência fuzzy baseado em rede adaptável](#). Transações IEEE em Sistemas, Homem e Cibernética 23 (3). doi: 10.1109/21.256541.

John, HG, Kohavi, R. & Pfleger, K. [ȳȳȳ Características irrelevantes e o problema de seleção de subconjunto](#). Aprendizado de Máquina: Anais da Décima Primeira Conferência Internacional 121–129. doi: 10.1.1.30.3875.

Jordan, MI [ȳȳȳ Ordem Serial: Uma Abordagem de Processamento Distribuído Paralelo](#). Relatório Técnico 8604, Instituto de Ciências Cognitivas. Universidade da Califórnia, San Diego.

Karunasingha, DSK & Liong, SY [ȳȳȳ Aprimoramento de predição de séries temporais hidrológicas caóticas com redução de ruído em tempo real usando Filtro de Kalman Estendido](#). Journal of Hydrology 565, 737-746. doi:10.1016/j.jhydrol.2018.08.044.

Kay, SM & Marple, SL [ȳȳȳ Análise de espectro – uma perspectiva moderna](#). Anais do IEEE 69 (11), 1380–1419. doi:10.1109/PROC.1981.12184.

Kohavi, R. & John, GH [ȳȳȳ Wrappers para subconjunto de recursos seleção](#). Inteligência Artificial 7, 273-324. [https://doi.org/10.1016/S0004-3702\(97\)00043-X](https://doi.org/10.1016/S0004-3702(97)00043-X).

Koza, JR [ȳȳȳ Um Paradigma para Procriar Geneticamente Populações de Programas de Computador para Resolver Problemas](#). Departamento de Ciência da Computação, Universidade de Stanford, Margaret Jacks Hall, Stanford, Cali.

Krogh, A. & Vedelsby, J. [ȳȳȳ Conjuntos de redes neurais, validação cruzada e aprendizagem ativa](#). Advances in Neural Information Processing Systems 7, 231–238.

Li, W. & Huicheng, Z. [ȳȳȳ Previsão da demanda de água urbana com base no filtro HP e rede neural difusa](#). Journal of Hydroinformática 12 (2), 172-184.

Liu, JQ, Cheng, WP & Zhang, TQ [ȳȳȳ Fator principal análise para previsão do padrão diurno de demanda de água usando a técnica combinada de Rough-set e Fuzzy-Clustering](#). Journal of Water Resource Planning Management 139 (1), 23–33. [https://doi.org/10.1061/\(ASCE\)WR.1943-5452.0000223](https://doi.org/10.1061/(ASCE)WR.1943-5452.0000223).

Maria André, D. & Carvalho, JR [ȳȳȳ Determinantes espaciais da demanda de água residencial urbana em Fortaleza, Brasil](#). Gestão de Recursos Hídricos 28, 2401–2414. doi:10.1007/s11269-014-0551-0.

Melin, P., Soto, J., Castillo, O. & Soria, J. [ȳȳȳ Uma nova abordagem para predição de séries temporais usando conjuntos de modelos ANFIS](#). Sistemas Especialistas com Aplicativos 39, 3494–3506. <https://doi.org/10.1016/j.eswa.2011.09.040>.

Mendes-Moreira, J., Soares, C., Jorge, A. L. M. & Sousa, J. F. [ȳȳȳ Abordagens ensemble para regressão: uma pesquisa](#). ACM Computing Surveys 45 (1), 40. doi:10.1145/2379776.2379786.

Nasseri, M., Moeini, A. & Tabesh, M. [ȳȳȳ Previsão da demanda mensal de água urbana usando filtro kalman estendido e programação genética](#). Sistemas Especialistas com Aplicativos 38, 7387–7395. doi:10.1016/j.eswa.2010.12.087.

Nauges, C. & Whittington, D. [ȳȳȳ Estimativa da demanda de água em países em desenvolvimento: uma visão geral](#). O Observador de Pesquisa do Banco Mundial 25, 2.

Oba, S., Sato, M., Takemasa, I., Monden, M., Matsubara, K. & Ishii, SA [ȳȳȳ Método Bayesiano de estimação de valores perdidos](#).

Bioinformática 19 (16), 2088-2096. doi:10.1093/bioinformática/btg287.

Odan, F. K. [Estudo de Confiabilidade Aplicado à Otimização da Operação em Tempo Real de Redes de Abastecimento de água](#). Tese (Doutorado), Escola de Engenharia de São Carlos, Universidade de São Paulo, São Carlos. (in Portuguese)

Odan, FK & Reis, LFR [Modelo híbrido de previsão de demanda de água associando rede neural artificial à série de Fourier](#). Journal of Water Resources Planning and Management 138, 245–256. doi:10.1061/(ASCE)WR.1943- 5452.0000177.

Oord, AVD, Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A. & Kavukcuoglu, K. [WaveNet: A Modelo generativo para áudio bruto](#). Sound Cornell University Library.arXiv:1609.03499.

Oshima, N. & Kosuda, T. [Controle de reservatórios de distribuição com previsão de demanda usando o método do caos determinístico](#). Water Science Technology 37 (12), 389-395. [https://doi.org/10.1016/S0273-1223\(98\)00378-3](https://doi.org/10.1016/S0273-1223(98)00378-3).

Peña-Guzmán, C., Melgarejo, J. & Prats, D. [Previsão de demanda de água em zonas residenciais, comerciais e industriais em Bogotá, Colômbia, usando Máquinas Vetoriais de Suporte de Mínimos Quadrados](#). Problemas Matemáticos em Engenharia. <http://dx.doi.org/10.1155/2016/5712347>.

Perrone, MP & Cooper, LN [Quando as redes discordam: Métodos de conjunto para redes neurais híbridas](#). In: Redes neurais para processamento de fala e imagem Capítulo 10 (RJ Mammone, ed.). Chapman-Hall.

Piramuthu, S. [Avaliando métodos de seleção de recursos para aprendizagem em aplicações de mineração de dados](#). Jornal Europeu de Pesquisa Operacional 156 (2), 483-494. [https://doi.org/10.1016/S0377-2217\(02\)00911-6](https://doi.org/10.1016/S0377-2217(02)00911-6).

Poli, I. & Jones, RD [Um modelo de rede neural para previsão](#). Journal of American Statistical Association 89 (425), 117–121. doi:10.1080/01621459.1994.10476451.

Pulido-Calvo, I. & Gutiérrez-Estrada, JC [Melhorado previsão de demanda de água para irrigação usando um modelo híbrido de computação suave](#). Engenharia de Biosistemas 102, 202-218. <https://doi.org/10.1016/j.biosystemseng.2008.09.032>.

Qiu, X., Zhang, L., Ren, Y., Suganthan, PN & Amaratunga, G. [Ensemble deep learning para regressão e previsão de séries temporais](#). In: Trabalho apresentado no Simpósio de Inteligência Computacional em Ensemble Learning (CIEL). doi:10.1109/CIEL.2014.7015739.

Ren, Y., Zhang, L. & Suganthan, PM [Classificação de conjunto e regressão-desenvolvimentos recentes, aplicações e direções futuras](#). Revista de Inteligência Computacional IEEE 11, 41–53. doi:10.1109/MCI.2015.2471235.

Romano, M. & Kapelan, Z. [Demanda de água adaptativa previsão para gerenciamento quase em tempo real de sistemas inteligentes de distribuição de água](#). Modelagem Ambiental e Software 60, 265–276. <https://doi.org/10.1016/j.envsoft.2014.06.016>.

Rooney, N., Patterson, D., Anand, S. & Tsymbal, A. [Dinâmico integração de modelos de regressão](#). Anais do Workshop Internacional sobre Sistemas de Classificadores Múltiplos.

Notas de aula em Ciência da Computação 3181, 164–173. https://doi.org/10.1007/11871842_82.

Sayes, Y., Inza, I. & Larrañga, P. [Uma revisão das técnicas de seleção de características em bioinformática](#). Bioinformática 23 (19), 2507-2517. <https://doi.org/10.1093/bioinformatics/btm344>.

Scheich, J. & Hillenbrand, T. [Determinantes da demanda residencial de água na Alemanha](#). Ecological Economics 68, 1756-1769. <https://doi.org/10.1016/j.ecolecon.2008.11.012>.

Shabri, A. & Samsudin, R. [Decomposição em modo empírico – os mínimos quadrados suportam máquina vetorial baseada na previsão da demanda de água](#). International Journal of Advances in Soft Computing e sua aplicação. 7 (2). ISSN 2074-2827 Sharkey, AJC [Sobre a combinação de redes neurais artificiais](#). Journal Connection Science 8 (3–4), 299–314. <https://doi.org/10.1080/095400996116785>.

Shepherd, AJ [Métodos de Segunda Ordem para Rede Neural: Métodos Rápidos e Confiáveis para Perceptrons Multicamadas](#). Springer, Nova York.

Sollich, P. & Krogh, A. [Aprendendo com conjuntos: como overfitting pode ser útil](#). In: Advances in Neural Information Processing Systems 8 (D. Touretzky, M. Mozer & M. Hasselmo, eds). The MIT Press, pp. 190–196.

Sorjamaa, A., Hao, J., Reyhani, N., Ji, Y. & Lendasse, A. [Metodologia para previsão a longo prazo de séries temporais](#). Neurocomputing 70, 2861-2869. <https://doi.org/10.1016/j.neucom.2006.06.015>.

Specht, DF [Redes neurais probabilísticas](#). Rede Neural 3 (1), 109–118. doi:10.1016/0893-6080(90)90049-Q.

Stan'czyk, U. [Avaliação de recursos por filtro, wrapper e abordagens incorporadas](#). In: Seleção de recursos para reconhecimento de dados e padrões. Estudos em Inteligência Computacional, Vol. 584 (U. Stan'czyk & LC Jain, eds). Springer, pp. 29-44.

Tiwari, M. & Adamowski, J. [Previsão de demanda de água de médio prazo com dados limitados usando uma abordagem de aprendizado de máquina de Bootstrap de Wavelet](#). Revista de Planejamento e Gestão de Recursos Hídricos 141 (2). [https://doi.org/10.1061/\(ASCE\)WR.1943-5452.0000454](https://doi.org/10.1061/(ASCE)WR.1943-5452.0000454).

Tiwari, M., Adamowski, J. & Adamowski, K. [Previsão de demanda de água usando máquinas de aprendizado extremo](#). Journal of Water and Land Development 28, 37–52. doi:10.1515/jwld.2016-0004.

Tsoi, AC & Back, AD [Localmente recorrente globalmente redes feedforward: uma revisão crítica de arquiteturas](#). Rede Neural de Transações IEEE 5 (4), 229–239. doi: 10.1109/72.279187.

Tsonis, AA [Caos: Da Teoria às Aplicações](#). Springer, Nova York.

Tsutiya, MT [Abastecimento de Água, 3ª ed.](#) Departamento de Engenharia Hidráulica e Sanitária da Escola Politécnica da Universidade de São Paulo, São Paulo. (em português)

Waibel, A., Hanazawa, T., Hinton, G., Shikano, K. & Lang, KJ [Reconhecimento de fonemas usando redes neurais de atraso de tempo](#). Transações IEEE em Acústica, Fala e Processamento de Sinais 37 (3), 328–339. doi: 10.1109/29.21701.

Wang, L., Wang, Z., Qu, H. & Liu, S. [Combinção ótima de previsão baseada em rede neural para previsão de séries temporais](#). Computação Suave Aplicada 66, 1–17. <https://doi.org/10.1016/j.asoc.2018.02.004>.

Webb, GI & Zheng, Z. [Aprendizagem de conjunto multi-estratégia: reduzindo o erro combinando técnicas de aprendizagem de conjunto](#). IEEE Transactions on Knowledge and Data Engineering 16 (8), 980–991. doi:10.1109/TKDE.2004.29.

Wentz, EA & Gober, P. [Determinantes do consumo de água em pequenas áreas para a cidade de Phoenix, Arizona](#). Gestão de Recursos Hídricos 21, 1849-1863. doi:10.1007/s11269-006-9133-0.

Wichard, JD, Merkwirth, C. & Ogorzaýek, M. [Construindo conjuntos com modelos heterogêneos](#). Disponível em: www.j-wichard.de/publications/salermo_Incs_2003.pdf (acessado em 22 de agosto de 2018).

Wilamowski, BM & Yu, H. [Aprendizagem de redes neurais sem retropropagação](#). Transações IEEE em Redes Neurais 21 (11), 1793–1803. doi:10.1109/TNN.2010.2073482.

Williams, RJ & Zipser, D. [Um algoritmo de aprendizado para executando continuamente redes neurais totalmente recorrentes](#). Computacional Neural 1 (2), 270–280. <https://doi.org/10.1162/neco.1989.1.2.270>.

Xu, Y., Zhang, J., Long, Z. & Lv, M. [Água urbana diária previsão de demanda com base na teoria caótica e Contínua Rede Neural de Crença Profunda](#). Letras de processamento neural. <https://doi.org/10.1007/s11063-018-9914-5>.

Zanchettin, C. [Otimização Global de Redes Neurais Artificiais](#). Tese (Doutorado), Universidade Federal de Pernambuco, Recife. (In Portuguese).

Zapelan, R. [Calibração do Sistema de Distribuição de Água Modelos Hidráulicos](#). Doutorado (Tese), University of Exeter, Reino Unido.

Zhang, GP [Uma investigação de redes neurais para previsão de séries temporais lineares](#). Computers & Operations Research 28 (12), 1183–1202. [https://doi.org/10.1016/S0305-0548\(00\)00033-2](https://doi.org/10.1016/S0305-0548(00)00033-2).

Zhang, GP [Previsão de séries temporais usando um modelo híbrido ARIMA e rede neural](#). Neurocomputing 50, 159-175. [https://doi.org/10.1016/S0925-2312\(01\)00702-0](https://doi.org/10.1016/S0925-2312(01)00702-0).

Zhang, GP & Qi, M. [Previsão de rede neural para séries temporais sazonais e de tendência](#). Jornal Europeu de Pesquisa Operacional 160 (2), 501-514. doi:10.1016/j.ejor.2003.08.037.

Zhang, GP, Patuwo, BD & Hu, MY [Previsão com redes neurais artificiais: o estado da arte](#). International Journal of Forecasting 14, 35–62. [https://doi.org/10.1016/S0169-2070\(97\)00044-7](https://doi.org/10.1016/S0169-2070(97)00044-7).

Zhao, P. & Zhang, HW [Caracteres caóticos e previsão do consumo urbano de água](#). Água da China Águas Residuais 24 (5), 90–94. <https://doi.org/10.1007/s11063-018-9914-5>.

Recebido pela primeira vez em 3 de março de 2019; aceito em formulário revisado em 12 de agosto de 2019. Disponível on-line em 29 de agosto de 2019