


Listas de conteúdo disponíveis em [ScienceDirect](https://www.sciencedirect.com)

Energia e Edifícios

página inicial da revista: www.elsevier.com/locate/enbuild

Uma visão abrangente sobre as abordagens baseadas em dados e em larga escala para previsão da demanda de energia em edifícios: uma revisão

Tanveer Ahmad, Huanxin Chen[✉], Yabin Guo, Jiangyu Wang

Escola de Energia e Engenharia de Energia, Universidade de Ciência e Tecnologia Huazhong, Wuhan, China

informações do artigo

Historia do artigo:

Recebido em 27 de agosto de 2017
 Revisado em 25 de dezembro de 2017
 Aceito em 14 de janeiro de 2018

Palavras-chave:

Abordagens baseadas em dados
 Modelos de mapeamento de energia
 Modelos de previsão
 avaliação comparativa
 Padrões estatísticos e de aprendizado de máquina

resumo

Os modelos de consumo de energia desempenham um papel fundamental na gestão e conservação de energia, no que diz respeito aos edifícios. Ele pode auxiliar na avaliação da eficiência energética do edifício, na realização do comissionamento do edifício e na identificação e diagnóstico de falhas no sistema do edifício. Esta revisão analisa em profundidade os modelos de previsão de demanda de energia para edifícios, na medida em que investiga os desenvolvimentos recentes nas abordagens de energia de edifícios usadas para prever o uso de energia. Ao listar as abordagens atuais para a modelagem de edifícios, os métodos para simulações de energia de edifícios podem ser categorizados em quatro classes de nível como segue: (i) abordagens orientadas por dados; (ii) abordagens baseadas na física; (iii) abordagens de previsão energética de edifícios em grande escala; e (iv) abordagens híbridas. O foco desta revisão é direcionar a abordagem baseada em dados e abordagens baseadas em previsão de energia de construção em grande escala. Aqui, as abordagens orientadas a dados podem ser categorizadas por (1) abordagens baseadas em redes neurais artificiais; (2) abordagens baseadas em agrupamentos; (3) abordagens estatísticas e baseadas em aprendizado de máquina; e (4) abordagens baseadas em máquinas vetoriais de suporte. A partir daí, o tipo de abordagem baseada em dados é ainda agrupado por (a) modelos de benchmarking; (b) modelos de mapeamento de energia; (c) modelos de previsão de energia; e (d) modelos de perfis energéticos. As técnicas de previsão de energia de construção em larga escala são então categorizadas da seguinte forma: (1) abordagens baseadas em caixa branca; (2) abordagens baseadas em caixa preta e (3) abordagens baseadas em caixa cinza. O estudo atual explora abordagens baseadas em dados de primeira linha sobre análise de energia de edifícios para uso industrial, comercial, doméstico, etc., dentro de um ambiente rural e urbano. Este artigo de revisão baseia-se na necessidade de identificar pontos de partida e oportunidades de pesquisa para análises urbanas e rurais do desempenho energético do edifício. Uma variedade de questões são exploradas, incluindo: métricas de desempenho energético; uso final de diferentes tipos de construção; vários níveis de granularidade; e escalas urbanas e rurais. Cada técnica abrange uma variedade de informações de entrada, bem como cálculos variados ou modelos de simulação, além de fornecer resultados contrastantes que sugerem uma variedade de usos. Uma revisão completa de cada técnica é apresentada neste estudo. Esta revisão destaca os pontos fortes, as deficiências e o propósito dos métodos de várias abordagens baseadas em mineração de dados. Uma revisão abrangente dos modelos de previsão de energia que são especificados na parte da literatura também é fornecida.

© 2018 Elsevier BV Todos os direitos reservados.

1. Introdução

Os modelos de previsão do uso de energia em edifícios desempenham um papel fundamental na gestão e conservação de energia. Esses modelos podem auxiliar na análise da eficiência energética dos edifícios; na construção de atividades de comissão; detectar falhas no sistema predial; e na identificação dessas falhas. De acordo com a sua especificidade, a energia prevista pode ser categorizada nas cinco categorias seguintes: (1) energia/eletricidade do edifício inteiro; (2) energia de aquecimento e resfriamento;

(3) energia de aquecimento; (4) energia de resfriamento; (4) e (5) todos os outros. A Fig. 1, diferencia as porcentagens da energia conforme os tipos mencionados anteriormente [1].

Conforme descrito acima, mais de 50% dos estudos concentram-se na previsão do uso de energia em todo o edifício, que captura o desempenho total do edifício. A quantidade total de todos os estudos para a categoria de aquecimento e resfriamento é de 35%. Isso ocorre porque os edifícios comerciais ou educacionais/de pesquisa são considerados mais frequentemente como sua substância de aquecimento, conforme mencionado anteriormente, e os usos de energia de resfriamento compreendem uma grande parte do consumo de energia do edifício. Destaca-se que, em relação às zonas climáticas e percebidas as necessidades dos estudos, alguns dos estudos selecionaram a energia de aquecimento ou resfriamento [2] como saídas.

[✉] Autor correspondente: Escola de Energia e Engenharia de Energia, Huazhong University of Science and Technology, Wuhan, China.

Endereços de e-mail: ahmad_tanveer@hust.edu.cn (T. Ahmad), chenhuanxin@tsinghua.org.cn (H. Chen).




Fig. 1. A composição do tipo de energia [1].

Os modelos de previsão de energia de edifícios foram categorizados vagamente em as seguintes áreas: (1) engenharia; (2) Inteligência Artificial (IA) -Sediada; (3) abordagens híbridas e (4) abordagens orientadas a dados [1]. Para atingir um nível máximo de desempenho energético, a instalação de sistemas eficientes de eficiência energética poderiam ser implementados, juntamente com seguido por modelos de operação e gestão adequados [4]. Edifícios comerciais que contêm medição e monitoramento modernos capacidades e sistemas combinados com sistemas eficientes de gerenciamento de edifícios são os melhores métodos para implementar atividades de redução de carga elétrica. Além disso, os benefícios econômicos potenciais que resultam em reduções na demanda de energia podem ser mais pertinentes para prosumidores – clientes que não apenas produzem energia, mas que consumi-lo [5].

Devido à facilidade de desenvolvimento e interpretação, e quando diferenciando os métodos de previsão, o modelo de regressão é o método mais comumente usado para previsão de carga de edifícios [6-9,59]. A literatura atual oferece uma base formidável na qual classificar o trabalho no que diz respeito aos tipos de modelos, previsão horizonte e escala (edifício único a nível regional ou nacional) [1,10].

Desde a década de 1990, pesquisadores criaram uma variedade de ferramentas de simulação para estimar o uso de energia em edifícios. Esses dispositivos são identificados como os seguintes métodos: engenharia, baseados em IA e híbridos [11]. O método de engenharia prevê o consumo de energia por utilizando equações termodinâmicas para explicar a comportamento físico, bem como suas interações com o meio ambiente. Isso ajuda a prever o uso de energia, ou seja, o consumo de energia de componentes individuais do edifício, ou de todo o edifício [12] e é definido como o método da 'caixa branca', uma vez que o interior lógica é conhecida e evidente.

Diferente da abordagem de engenharia, o método baseado em IA é conhecido como o método da 'caixa preta'. Isso porque estima consumo de energia sem o conhecimento da relação interna da edificação e seus segmentos. O método híbrido, que é referido como a 'caixa cinza', combina a caixa branca e a métodos de caixa preta para eliminar as limitações associadas cada método.

Os métodos de caixa branca e caixa cinza exigem construção de informações para simular as relações internas utilizadas para

ditar o uso de energia. Assim, o desenvolvimento do modelo requer uma experiência tediosa, que é bastante demorada para os edifícios existentes no que se refere aos seus estudos de consumo de energia, utilizando o os métodos de caixa branca e caixa cinza são impraticáveis, se não impossíveis, devido à falta de eficiência em fazê-lo. Grandes desafios e podem surgir dificuldades ao tentar obter especificações de envelopes de construção, bem como sistemas mecânicos. Isso resulta na incapacidade de usar esses métodos de forma abrangente para estoque de construção. No entanto, uma revisão completa do consumo de energia previsões em edifícios que incluem a caixa preta, caixa branca e métodos de caixa cinza está disponível em [11].

Algoritmos de aprendizado aplicado dentro desses métodos podem ser pertinentes ao determinar o consumo de energia. No entanto, um número limitado de estudos utilizou vários algoritmos de predição. De naqueles estudos que utilizaram algoritmos de aprendizagem aplicada, a robustez e as capacidades foram comparadas para verificar sua utilidade na previsão do consumo de energia [13,14]. Nossa revisão resultou nas seguintes porcentagens de aplicações de algoritmos de aprendizado para previsão de uso de energia: regressão (26%); Rede Neural Acrítica (RNA) (41%); Máquina de Vetor de Suporte (SVR) (12%); e todos os outros (21%). Das quatro categorias, encontramos ANN para ser os algoritmos mais utilizados RNAs compreendem, mas não são muito limitados aos seguintes elementos: Multilayer Perceptron (MLP) [3]; Rede Neural Feed-Forward (FFNN) [17]; Rede Neural de Retropropagação (BPNN) [15,16]; e Rede de Função de Base Radial (RBFN) [18]. Essas RNAs foram usadas nos estudos mais recentes. Eles foram amplamente favorecidos devido à implementação amigável e desempenho de previsão inequívoca.

Usando Regressão Linear Múltipla (MLR) em energia de longo prazo previsões de consumo resultaram em vantagens como fácil de usar, assim como as práticas de computação. Apenas cinco estudos alistaram o SVR para prever o consumo de energia do edifício. Com Dito isso, o SVR demonstrou sua excepcional precisão de previsão em a construção de preditores de uso de energia quando medido outros algoritmos de aprendizagem [16,19]. Além disso, o algoritmo Autoregressive Moving Average (ARMAX) [13], algoritmo Chi-Squared Automatic Interaction Detector (CHAID) [16] e Case-Based Reason (CBR) [20,21] algoritmo também foi alistado para a construção de uso de energia predição. Os pesquisadores selecionaram minuto a minuto [22], 15 min [23,24], semanal [25] e mensal [2] para prever o consumo de energia do edifício.

Nesta revisão, vários benefícios de realizar a previsão de energia em larga escala via simulação são encontrados. Estes incluem a identificação de: (i) valores atípicos de energia [27]; (ii) recursos de energia (por exemplo, calor ou energia residual) na cidade em diferentes edifícios ou distritos localizados na mesma área ou distrito [26]; (iii) candidatos para retrofit intervenção [29]; (iv) balanceamento local e operações de gerenciamento do lado da demanda [28]; (v) demanda de potência de pico [32]; (vi) grande análises de benchmarking envolvendo comunidades inteiras [30,31]; e (vi) melhor planejamento urbano dentro de uma área designada. Disponível dados e o nível de granularidade dos dados devem; maximizar quando analisando o ranking de consumo de energia de venda urbana. Por ser inteligente medição e maior conscientização e compreensão dos dados de utilização, a quantidade de coleta de dados possível de um único andar edifícios se expandiu durante os anos anteriores. Uma razão adicional para esse aumento é o aumento do uso.

É importante notar que, mesmo que os dados de consumo de energia está disponível para fins analíticos, proteção e políticas de privacidade podem excluí-los como fontes de informação úteis. Portanto, é essencial aplicar métodos de anonimização e agregação. No entanto, esses métodos podem comprometer a qualidade dos dados. [33]. Além disso, o uso de energia do edifício e a avaliação em larga escala podem consumir alocações de tempo, especialmente quando usado com as abordagens de simulação baseadas em edifício único. Isso se deve em grande parte ao processo demorado de coleta de dados, à execução de técnicas de monitoramento e simulação e aos fatores preditivos envolvidos na

incertezas [15]. Portanto, é crucial desenvolver novas ferramentas de coleta de dados que garantam resultados mais oportunos na coleta processos, preservando ao mesmo tempo granularidade de alto nível para não afetar adversamente quaisquer resultados finais. Essas ferramentas devem apoiar totalmente os processos de tomada de decisão. Neste artigo de revisão, categorizamos os algoritmos de aprendizado em quatro classificações da seguinte forma: (1) regressão; (2) RNA; (3) SVR; e (4) todos os outros.

Jani et al [230], vem conduzindo um estudo sobre a aplicabilidade de RNA para predição de desempenho de métodos de resfriamento desumidificador dessecante sólido (SDDC). Vários tipos de RNA são empregados para representar os sistemas SDDC. Com base na eficácia e uso de dados de teste, foi proposto um método de rede neural artificial que é composto por vários modelos. O nervo artificial previsão de rede para essas variáveis normalmente aceitas com o maior coeficiente de correlação com os valores experimentais. O redes neurais artificiais podem ser empregadas com maior precisão no cálculo da eficiência e desempenho do método SDDC. Esse A revisão foi útil para obter as diferentes possibilidades de promover e auxiliar a pesquisa de redes neurais artificiais e suas conveniência que é lisonjeira comum no próximo período.

Kulkarni et al. [231] narram os resultados da pesquisa, analisando o impacto de vários métodos de enviaçamento nas travessas e a diminuição da demanda de carga de resfriamento no ambiente do edifício. O software (DesignBuilder) tem sido praticado com o propósito de simulação de estimar a demanda da carga de resfriamento. Além disso, o a pesquisa também mostra o crédito de carbono equivalente e o potencial de redução da emissão de CO₂. Neste estudo, as abordagens de retrofit afetam ativamente o nível de economia de energia, no entanto, o período de retorno é geralmente bastante abundante na ordem de oito anos.

Alguns estudos foram conduzidos em algoritmos de RNA para um O modelo de ar condicionado híbrido dessecante sólido de compressão de vapor é propôs prever a capacidade de demanda de carga de resfriamento, o coeficiente de desempenho e potência de entrada do método. Esta pesquisa [232], também realiza a análise prática para configurar montar o teste de dados experimentais necessário. Os resultados de a investigação relata que os algoritmos de redes neurais artificiais podem ser implementados vigorosamente e podem acomodar altas confiabilidade e precisão para prognosticar a eficiência e desempenho dos sistemas SDDC [232–233].

Jani et al. [234] pesquisou o impacto da temperatura ambiente e taxa de umidade externa da temperatura do ar de alimentação e COP foram estimados. A diferença no COP foi adquirida em diferentes temperaturas de entrada e saída de regeneração. Os resultados das simulações explicam a adequação de tais modelos para requisitos de carga de resfriamento no ambiente de construção em ambientes quentes como bem como as circunstâncias de clima úmido.

Vildan [235] introduziu um modelo baseado em simulação é renderizado para a averiguação e determinação do impacto do sombreamento em edifícios. A 1ª parte do esquema de estimativa, os dados de radiação solar para estimativa foram adquiridos durante uma técnica por Kilic e Ozturk empregaram para verificar a relação de correlação, considerando os dados da Turquia. Na 2ª parte, sombreada espaços na vertical dos edifícios, projetados por edifícios adjacentes, praticam-se os componentes da sombra de um poste vertical sobre um método de coordenadas tridimensionais.

Esta revisão é composta sobre a importância de identificar pontos de partida e oportunidades de pesquisa para análises em nível urbano e rural do desempenho energético em nível de construção. Uma variedade de questões são investigadas, incluindo: eficiência energética e métricas de desempenho; uso final de diferentes tipos de construção; vários níveis de granularidade; e escalas urbanas e rurais. Cada técnica engloba uma variedade de informações de entrada para treinar a validação do modelos, bem como diferentes cálculos ou modelos de simulação ao longo com fornecendo resultados contrastantes que sugerem uma variedade de nós idades. A capacidade de prever o uso de energia do edifício em um meio rural e urbano, praticando um tipo diferente de

métricas de desempenho para várias granularidades e categorias de construção, em diferentes localizações ambientais e geográficas, é significativo para o planejamento perceptivo da energia futura.

Os principais benefícios da implementação orientada a dados e em larga escala (LS) previsão de energia na simulação de edifícios são numerosos, por ilustram, o reconhecimento de (i) melhor planejamento urbano e rural em uma área especificada; (ii) balanceamento local e gerenciamento do lado da demanda; (iii) outliers de energia; (iv) análise do encaixe da marcação de bancada comunidades inteiras; (v) invasão de retrofit de candidatos; (vi) pico demanda de uso de energia elétrica e; (vi) fontes de energia (por exemplo, calor ou energia residual) no nível da cidade ou vários edifícios da cidade similar, nível de país ou distrito. Examinar o uso de energia em diferentes gamas, o nível de granularidade e possível erudição da energia dados de consumo devem ser avaliados. O número de energia os dados de consumo e ambientais concebíveis de serem reunidos a partir do ambiente do edifício progrediram desde vários anos devido ao esfaqueamento da infraestrutura de 'medição inteligente', melhor compreensão e maior acesso da empresa elétrica ou dados de consumo líquido de energia da empresa de serviços públicos e a aplicação de superintendência ou sistemas de gestão no edifício nível.

No entanto, se os dados de consumo de energia estiverem aparentemente acessíveis para análise de previsão, proteção e procedimentos de privacidade podem eliminá-los como diferentes autorizações (fontes) de informações detalhadas. Os métodos de anonimização ou agregação são, consequentemente, necessário, sempre consiste na essência dos vários conjuntos de dados disponíveis na forma de dados de consumo de energia, bem como dados ambientais. A estimativa do uso de energia de edifícios em grande escala e orientada por dados pode consumir muito tempo se implementada com uma abordagem para construir a simulação, porque métodos de cálculo de dados, procedimentos de monitoramento e simulação e avaliação de contingências ou incertezas. Nesta circunstância, a exploração de diferentes técnicas de utilização de edifícios reais dados e acumular em relação a economia de tempo e comportamento eficiente enquanto preserva uma quantidade enorme de qualidade que não negocia, a consequência é um aumento significativo e notável para acessórios (acessórios) que auxiliariam no conforto da decisão. Com base em estratégias existentes para a modelagem em edifícios ambiente, é concebível classificar a simulação de construção técnicas para as três principais classificações como segue ou segue: (i) abordagens baseadas em híbridos (ii) abordagens baseadas em física e (iii) abordagens baseadas em dados e em larga escala.

Este artigo de revisão é testemunhado com uma consideração de abordagens de previsão de energia baseadas em dados e em larga escala empregadas para análise de energia do setor em nível rural e urbano. O revisão é motivada pela exigência de reconhecer os pontos de partida e oportunidades de pesquisa para o nível rural e urbano análise de edifícios, bem como eficiência energética e desempenho usando métodos de grande escala e orientados por dados. A Cognizance considerou diferentes preocupações, incluindo diferentes tipos de uso final e construção, vários níveis de granularidade, diferentes métricas de desempenho de energia e escalas urbanas. A visão geral da revisão é apresentada na Tabela 1.

A seção restante do artigo de revisão é designada da seguinte forma: A Seção 2 identifica as diferentes abordagens de base orientada por dados que consistem em modelos baseados em cluster, orientados por dados, redes neurais, máquina de vetores de suporte, modelos estatísticos e de aprendizado de máquina. A Seção 3 descreve as técnicas de previsão de energia do edifício em grande escala, incluindo abordagens baseadas em caixa cinza, métodos baseados em caixa branca e abordagens baseadas em caixa preta. A Seção 4 conclui este artigo de revisão.

2. Abordagens baseadas em dados

Várias empresas foram alistadas para construir grandes algoritmos de uso de energia em níveis de funcionalidade em escala de cidade e

tabela 1

Modelos de previsão de energia baseados em larga escala e baseados em dados.

Modelos de previsão	Categoria do modelo	Distribuição de categorias	Referências de Publicações		Faixa de anos
Baseado em dados abordagens	Orientado a dados baseado em cluster modelos	Previsão de energia modelos	10	[44–53]	[1985, 2003, 2005, 2008, 2009, 2012, 2014]
		Mapeamento de energia modelos	07	[54–60]	[1999, 2000, 2002, 2003, 2006, 2007]
		Modelos de perfil de energia	11	[61–72]	[1995, 1997, 2006, 2007, 2010, 2011]
	Estatística e regressão baseada modelos orientados a dados	Previsão de previsão modelos	21	[73–83, 228–229]	[2001, 2004, 2005, 2009, 2010, 2011]
		Modelos de comparação	09	[84–93]	[1999, 2002, 2005, 2008, 2009, 2010, 2013, 2015]
		Mapeamento de energia modelos	13	[94–107]	[1980, 2001, 2008, 2009, 2011, 2012, 2013, 2014]
	Modelos baseados em dados baseados em ANN	Modelos de perfil de energia	21	[108–129]	[2000, 2001, 2004, 2005, 2007, 2008, 2009, 2011, 2013, 2014]
		Previsão de previsão modelos	23	[130–147, 230–235]	[2001, 2002, 2005, 2006, 2007, 2008, 2009, 2010, 2012, 2013, 2014, 2017]
		avaliação comparativa modelos de previsão	07	[148–154]	[1988, 1996, 2000, 2002, 2003, 2005, 2006]
	Modelos orientados a dados baseados em SVM	Previsão de previsão modelos	22	[155–177]	[2004, 2006, 2007, 2008, 2009, 2010, 2012, 2014]
		Marcação de bancada modelos	13	[178–191]	[2000, 2008, 2009, 2010, 2012, 2014]
		Mapeamento de energia modelos	12	[192–203]	[1995, 2005, 2006, 2009, 2011, 2012, 2014]
Baseado em grande escala previsão de energia abordagens	Energia do setor de construção previsão em larga escala abordagens baseadas	Previsão de energia	04	[204–207]	2011, 2013, 2014
		mineração de dados de caixa branca abordagens baseadas			
		Mineração de dados de caixa cinza abordagens baseadas	05	[208–212]	2005, 2006, 2007, 2014
		Mineração de dados de caixa preta abordagens baseadas	14	[213–227]	1992, 2005, 2009, 2011, 2013, 2014, 2015, 2017

granularidade. As abordagens baseadas em dados (DDBA) fornecem uma equivalência entre a redução do período de desenvolvimento do algoritmo, mantendo uma ampla quantidade de precisão [34]. o as abordagens descritas neste estudo foram difundidas no nível do edifício. Descobriu-se que a consolidação de diferentes DDBAs é incorporada em larga escala para previsão de energia consumo e para compensar deficiências de dados. Este processo demonstrou que algum tipo de DDBA bem conhecido, como SVM e ANN continuam a ser negligenciados em grande escala. Esses modelos orientados a dados ajudam a fornecer informações precisas sobre o parque imobiliário (perfil do edifício). A pesquisa apresentou um discussão abrangente sobre a revisão da literatura sobre o atual utilização e aplicações de DDBA em escala rural e urbana nível, destacando a importância da importância futura da investigação neste contexto.

2.1. Modelos orientados por dados baseados em cluster

Os modelos orientados a dados baseados em clusters são uma abordagem de análise de dados de consumo de energia não supervisionada, incluindo a finalidade de descobrir conjuntos de dados não rotulados e informações ocultas [35,49]. Abordagens baseadas em agrupamento têm sido empregadas como períodos para desenvolver modelos como benchmarking que caracterizam elementos comuns de edifícios ilustrativos para comparações de linha de base [37,38]. Algoritmos baseados em cluster separam subgrupos onde cada componente em um sortimento se correlaciona com o grupo diferente dentro do cluster similar, mas distinto dos componentes nos diferentes tipos de clusters [36]. O agrupamento baseado os modelos são amplamente documentados, mas é praticado principalmente realizando atividades de categorização em uma classificação designada de setor de edifícios [40,41], para os quais existem estudos limitados em nível urbano [42,43]. O uso generalizado de clustering no setor da construção é evidente na literatura por realizar em um passo inicial para identificar edifícios representativos (centroídes) e criar arquétipos [39]. A maioria

algoritmos de cluster amplamente usados incluem clustering baseado em modelo (KMMBC); K-médias; K-Medoids (KM); e Agrupamento Aglomerativo Hierárquico (HAC).

2.1.1. Modelos de previsão de energia

A previsão do consumo de energia é fundamental para a política energética e economia nacional. No entanto, é complicado e incerto problema causado pelo ambiente externo, bem como vários fatores de incerteza. Modelos de previsão potencial para os países como Índia, Turquia, Reino Unido, Irã, Nova Zelândia, Finlândia e China [44-47] também foram discutidos. Preditores de curto prazo do consumo futuro de energia (próximas 24 horas) são necessários para decisão para comprometimento de parte ou unidade, equacionamento de demanda e oferta com vários parâmetros de rede e poder de venda/compra em as trocas de lugar do dia seguinte. Existe um grande número de material na forma de literatura sobre previsão de carga, incluindo semi-paramétricos abordagens (por exemplo, modelos aditivos), redes neurais, modelos de séries temporais sazonais, suavização exponencial (ver, por exemplo, [48–51]) e fatores exógenos (por exemplo, SARIMAX, PARX). O princípio fundamental do modelo de agrupamento baseado em análise de pares de conjuntos (SPA) é demonstrado como na referência [52]. Isto é seguido pela análise da incerteza de identidade Discrepância Contrary Analysis (IDCA) juntamente com previsão de uso de energia dentro de um ano especificado com base nas circunstâncias de impacto calculadas de cada classe. O fluxograma é mostrado na Fig. 2, com especificações do procedimento [52].

Execute 'análise de cluster' com uma 'partição ideal de Fisher modelo' para o crescente Indicador Relativo Dinâmico (DRI) de uso de energia cronicado. Além disso, os critérios para realizar a análise de pares de conjuntos (SPA) e os métodos de correlação são especificados para mudar o quantidades médias de Indicador Relativo Dinâmico (DRIs) dentro de valores intermediários para determinar e estimar o grau diferente, grau idêntico e grau contrário entre conjuntos de referência e fatores de influência. Em seguida, intercalados incluindo substâncias (pesos) de circunstâncias influentes, atingir números de conexão combinados

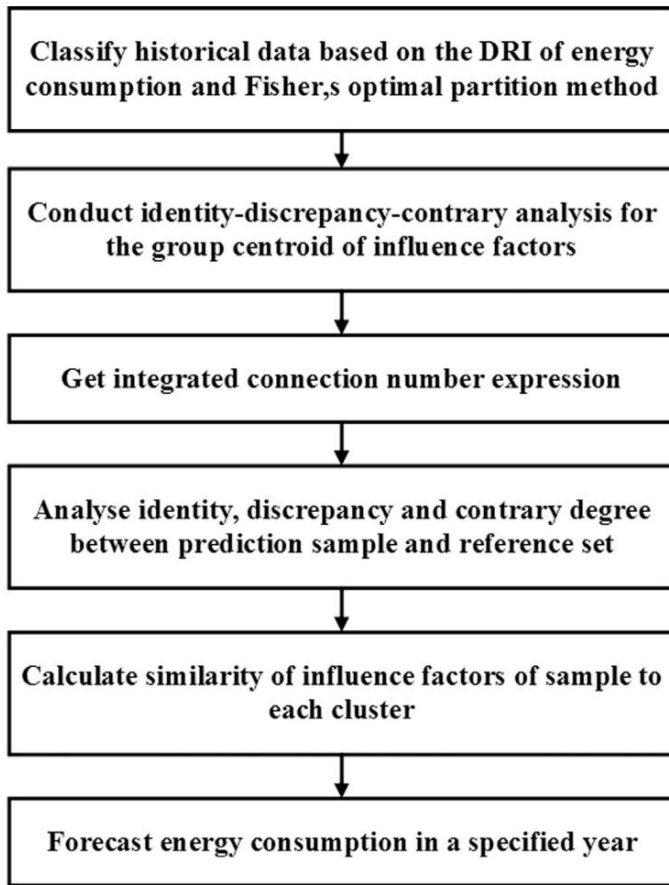


Fig. 2. Fluxograma do modelo de previsão de cluster baseado em SPA.

que apresentam os determinantes do magnetismo do consumo de energia de energia a ser prevista no ano selecionado com os valores de consolidação obtidos a partir do cálculo de suas similitudes com cada análise de cluster e de discrepância de identidade (ID-C). Finalmente, construir um modelo de previsão e estimar o consumo de energia em um ano designado.

Seja $k(k = 1, 2, \dots, k)$ representa o total de clusters. Os fatores de influência para cada tipo são narrados como:

$$\bar{x}_n(k) = \frac{1}{M} \sum_{m=1}^M x_n(k_m) \quad (1)$$

$\bar{x}_n(k)$ é a quantidade média de n -ésima para o tipo k . $x_n(k)$ é o correspondente quantidade de indicador relativo dinâmico n th com fator de influência na amostra de dados $m(m = 1, 2, \dots, M)$. Então, de acordo com o PSA [53], a quantidade combinada ou número $\tilde{y}k$, empregada para identificar diferentes elementos de crescimento pode ser apresentada como:


$$\tilde{y}k = ak + bki + ckj = \sum_{n=1}^N ankwn + eu \sum_{n=1}^N bnkwn + j \sum_{n=1}^N cnkwn \quad (2)$$

$$ank = \tilde{y}x^-(k) \quad (3)$$

$$cnk = \frac{a}{x^-(k)} \quad (4)$$

$$bnk = 1 - \tilde{y}ank - cnk \quad (5)$$

onde ak , bk e ck de grau diferente, grau idêntico e grau contrário, respectivamente; wn é um peso do indicador bnk , ank , e cnk é grau de discrepância, grau idêntico de n -ésimo similar

Fig. 3. Escopo do valor do coeficiente de \tilde{y} e \tilde{y}' [52].

ao conjunto de referência no tipo k , sequencialmente; j é o contrário coeficiente e i é o coeficiente de discrepância. \tilde{y} e \tilde{y}' mostra a coeficientes;

se $\bar{x}_n(k) \tilde{y} [xL, xU]$ \tilde{y} e \tilde{y}' irão satisfazer

$$0 < \tilde{y} \leq 25, 0, 25 \quad (6)$$

$$(xU)^2 \tilde{y} + \tilde{y} - xU \tilde{y} \geq 0 \quad (7)$$

$$(xL)^2 \tilde{y} + \tilde{y} - xL \tilde{y} \geq 0 \quad (8)$$

onde xL e xU são quantidades superiores e inferiores de DRI para indicadores de registro (históricos). Os vários invólucros de quantidade de \tilde{y} e \tilde{y}' são mostrados na Fig. 3 [52].

O ponto de interseção de duas funções lineares (9) é frequentemente usado para indicar \tilde{y} e \tilde{y}' ,

$$\tilde{y} = \frac{1}{(xU + xL)}, \tilde{y}' = \frac{xU xL}{(xU + xL)} \quad (9)$$

O grau de conexão entre o valor do indicador calculado de um ano de previsão e um conjunto de referência (xk $n = 1$) também pode ser estabelecido.

2.1.2. Modelos de mapeamento de energia

Conter a concepção do meio ambiente sustentável em nível de construção, o uso expandido de ferramentas de previsão específicas é necessária, tanto em várias escalas urbanas como na construção nível. Existe uma infinidade de ferramentas de previsão de energia e fiscalização ambiental no nível do edifício. No entanto, poucas ferramentas são capazes de prever energia em escala urbana. Na União Unido, o setor de construção é alterado em aproximadamente 1% por ano [54], qual penitenciária é relativamente mais comum para uma enorme terra pós-industrial desenvolvida. Para que as condições de construção tenham maior sustentabilidade, e para que as reduções de 'dióxido de carbono' sejam alcançadas, então medidas cruciais que pode melhorar as condições atuais de construção precisam ser analisadas [55]. Um modelo de prognóstico de eletricidade e ambiental tem foi construído em parceria com executivos regionais em Southland Wales, Reino Unido, como uma política consolidada para o aumento da sustentabilidade ambientais e para prever e estimar as diminuições de 'dióxido de carbono' e diferentes emanações [56]. O projeto do processador fornece estratégias para incorporar o controle de energia residencial e

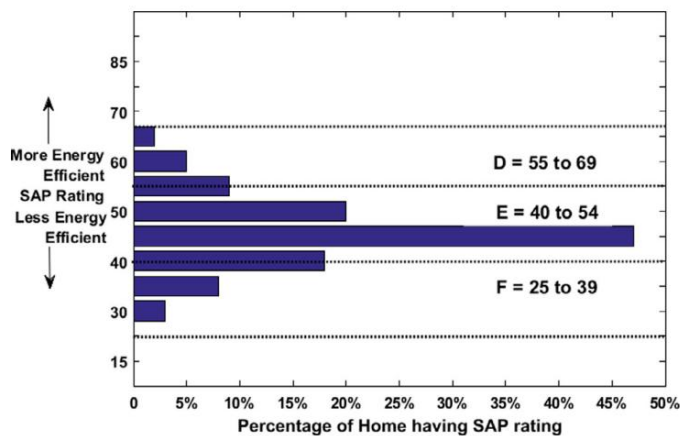


Fig. 4. Divisão das classificações SAP com cada etapa de desempenho de energia estabelecida com todos os ativos detidos pelas autoridades regionais [6].

mesa 2

Medidas de propriedade da casa galesa
avaliação SAP alvo através
espaço da história.

Área útil (m2)	Classificação SAP
Até 35,0	58,0
36,0–40,0	59,0
41,0–45,0	60,0
46,0–50,0	61,0
51,0–55,0	62,0
56,0–60,0	63,0
61,0–70,0	64,0
71,0–80,0	65,0
81,0–90,0	66,0
91,0–100,0	67,0
101,0–110,0	68,0
111,0–120,0	39,0
Acima de 120,0	70,0

preparação ambiental, capacitando os produtores de arranjos a contemplar o aumento da proficiência em energia. Originalmente produzido por 'Neath Port Talbot District Borough Council (NPTCBC)', Energia e A Previsão Ambiental (EEP) foi executada por diferentes governos políticos no Reino Unido e na Austrália [57].

O desempenho de energia dos ativos da sede da administração regional NPTCBC foi documentado para demonstrar a

dimensão das avaliações do Procedimento de Avaliação Padrão (SAP)

Fig. 4. O supracitado revela que as residências são frequentemente na banda E, classificação SAP de 40,0–54, conforme demonstrado pela medida inserido no pacote de conhecimento do resort em referência [6,58,59].

O 'Governo da Assembleia do País de Gales' lançou o 'Governo do País de Gales' Housing Quality Standard (WGQS) [60], como critério de uso geral para acomodações amigáveis no País de Gales. O modelo de previsão energética e ambiental fornece informações para autenticar

o padrão de desempenho de energia para administração regional e trimestres contratados. WGQS recomenda que a necessidade de hospedagem ser avaliada adotando a prática de avaliação SAP, e deve produzir um número entre 70 e 58, dependendo do terreno campo da residência Tabela 2 [6].

2.1.3. Modelos de perfis de energia

As residências gastam 40% do poder fundamental geral e 30% da energia sazonal, impactando massivamente o arboreto emanações gasosas. Como resultado, o desempenho da eletricidade doméstica e conceitos como a potência aproximadamente zero para os edifícios estão obtendo consistentemente atenção e notoriedade como medidas para diminuir as erupções de carbono, bem como a dependência dominante combustíveis de amostra. As metodologias propostas do

perfil de energia são implementados para as trajetórias de carga de várias residências, resultando no estabelecimento da melhor clusterização esquema. Os métodos podem ser implementados para qualquer casa. O perfil e a compreensão das tendências de consumo de eletricidade de suas instalações incentivarão a implementação de medidas de eficiência energética, eliminação de desperdício de eletricidade e gerenciamento do lado da demanda (DSM) soluções [61–63]. Algoritmos típicos de criação de perfil aplicados em quantidade de perfil de carga são os 'K-means', a Variação Mínima Critério (MVM), o mapa auto-organizado e o Fuzzy C-means. Esses tipos de algoritmos são usados principalmente devido à sua eficácia [64–66]. Outras abordagens com menor uso na curva de carga literatura de clustering incluem a rede neural Hopfield [67], o Algoritmo ISO DATA [68] e o Support Vector Clustering (SVC) [69].

Além dos algoritmos mencionados anteriormente, as utilizações de combinação híbrida também são levadas em consideração. No entanto, padrão esquemas de classificação anteriormente mencionados como o SVM [70] ou o classificador Bayes [71] são aplicados como uma ferramenta de perfil, mas não não alistado como uma solução de perfil de carga. Isso porque a categorização dos padrões de consumo de eletricidade dos edifícios é geralmente desenvolvido como uma tarefa de aprendizado de máquina não supervisionada, ou seja, a frequência de clusters e sua respectiva composição são um variável desconhecida a priori. Para tais desafios, amplo discernimento poderia ser aplicado à seleção e treinamento dos algoritmos de reconhecimento de padrões. Além disso, vários métodos têm sido proposto para conversões de perfil de carga para o domínio da frequência como uma medida de compressão da medição do agrupamento em dados de formação ancorados [72].

O agrupamento inicial dos dados registrados em subconjuntos pode aumentar a eficiência do procedimento de agrupamento e diminuir a tamanho do conjunto de dados de entrada. Portanto, as técnicas no domínio da frequência e utilizado para a análise dos dados de carga. Na modelagem de domínio de tempo (TD), o conjunto de dados contendo os dados medidos em quilowatts (kW) é $P = \{p_j, j = 1, \dots, N\}$, onde $N = 365$ e, respectivamente, a varredura de medição a cada dia é formulada como um vetor p_j :

$$p_j = [p_{j1} \dots p_{jN}] \quad (10)$$

Para cada edifício, estão previstos dois conjuntos de dados individuais que correspondem aos anos de 2010 e 2011. As curvas de carga são categorizadas de acordo com sua semelhança de forma, pois, na fase principal de agrupamento, a magnitude da carga é irrelevante. Cada padrão de membro do conjunto P é normalizado em $[0, 1]$ com o maior valor de o conjunto. A inclinação resultante com os padrões normalizados de dados é expressa como $X = \{x_j, j = 1, \dots, N\}$. A segunda técnica aplica a transformação reconhecida no domínio de frequência (FD) [72] usando a Transformada Rápida de Fourier (FFT). Acompanhamento a hipótese de Nyquist, as posições de rotação essenciais mais altas $h_{max} = T_o / (2 \dots T_{sam}) = 48$ a $T_o = 1440$ min como o período base (24 h). Em seguida, todas as 'amplitudes' são atribuídas em ordem de restrição, como refere o indicador [72]:

$$\tilde{y}_h = \frac{1}{N} \sum_{j=1}^N |A h_j \tilde{y} A^h| \quad (11)$$

onde $h = 1, \dots, h_{max}$, $A h_j$ e A^h h é a amplitude da j -ésima carga curva e o valor médio, respectivamente.

O vetor \tilde{y}_n inclui as amplitudes e duas características relacionadas às fases das n ordens harmônicas mais bem classificadas. Dois conjuntos diferentes de coeficientes baseados em harmônicos são levados em consideração assumindo redução de 50% e 25% do Time-Domain (TD) original amostras. Assim, os conjuntos de dados resultantes são \tilde{y}_{16} e \tilde{y}_{18} . As características relacionadas à fase \tilde{y}_h e \tilde{y}_h da ordem harmônica de fase h ângulo ah são identificados em (12) e (13) [72]:

$$\tilde{y}_h = \frac{1}{2} \tilde{y} \cos(ah) \frac{A_h}{A_{s_j} \dots A_s} \quad (12)$$

Tabela 3
Resumo de diferentes modelos orientados a dados baseados em cluster.

Categoria do modelo	Modelos orientados por dados baseados em cluster
Modelos de previsão de energia	
Modelo de previsão	K-means [48], Avaliação do ciclo de vida [47], Fuzzy C-means, classificador Bayes [49], modelo de Autorepressão Periódica (PAR) [48], SOM (proximidade)/FCM [49], K-means++ [49], Box-Jenkins [48], MVM [49], SOM (quadrado)/K-means++ [49], Modelo econométrico [52], FCM [49], SOM [49], SOM (proximidade) / K-means ++ [49], Modelos integrados [52], SOM (quadrado) / MVM [49], SOM (proximidade)/MVM [49], Modelos baseados em clima [50], SOM (quadrado)/FCM [49], Agrupamento baseado no modelo de análise de pares de conjuntos (SPA) [52], Modelo híbrido [45].
Programas	Matlab, Eneplus, Trnsys, BLAST, ESP-r
Aplicação e uso	Previsão de energia no ambiente de construção, curvas de carga diária, revelar oportunidades significativas de eficiência energética melhorias e operação eficiente dos edifícios durante todo o dia, fatores estatisticamente significativos que afetam o uso de energia
Vantagens	Possibilitando a operação e gestão eficiente da rede de distribuição em tempo real, identificando e prevendo os comportamento de clientes de grandes edifícios, Maximiza a diferença entre os clusters para permitir uma comparação significativa do diferenças entre a construção de clusters
Modelos de mapeamento de energia	
Modelo de previsão	Método de grau-dia [59], Método de fator de carga residencial [59], Análise de conjunto de pares [54], Otimização de enxame de partículas adaptável [56], Método de regressão [59], modelo de série de Fourier baseado em temperatura [59], Análise de Componentes Principais [59], Auto-Regressivo modelo [59], média móvel integrada auto-regressiva [59], análise de demanda condicional [59], retropropagação neural rede [59], Algoritmo Genético [59], Multi-Layer Perceptrons [59], Fuzzy C-mean clustering [59]
Programas	DOE-2, EnergyPlus, BLAST, ESP-r, MATLAB, Solvo@,
Aplicação e uso	Pré-processamento de dados, previsão de uso de eletricidade de construção, uso de energia de previsão é alcançável, eficiente e adequado para aplicativos eficazes
Vantagens	Previsões precisas e verdadeiras do uso de eletricidade, Depressão da tuberculose obscura do óleo combustível nas diferentes indústrias e áreas da fábrica, Reduzir os problemas de incerteza a partir de três perspectivas diferentes de identificação, Contrário e discrepância descreve e apresenta propriedades abrangentemente necessárias das coisas
Modelos de perfis de energia	
Modelo de previsão	Transformada Discreta de Fourier [72], Modelo de carga de eletricidade baseado em regressão [62], Análise de componentes curvilíneos [66], Modelagem matemática [64], modelo clássico [62], modelos de ponto de mudança [62], modelos de regressão linear [62], k-means clássico modelo [64], lógica difusa [66], modelo WARD [64], K-means [64], agrupamento hierárquico [64], modelos hierárquicos [64], Kohonen mapa auto-organizado [66], algoritmo de agrupamento Hopfield–K-Means [67], algoritmo ISODATA [68], Fuzzy k-means [69], Quadrático modelo de programação [69], abordagem de baixo para cima [72]
Programas	MATLAB, BLAST, ESP-r
Aplicação e uso	Classificação de clientes, previsão de curvas de carga diária
Vantagens	Previsão de energia precisa para os usuários industriais e comerciais, diminuir o problema de incerteza de três aspectos de identidade, alta volatilidade, presença de outliers

$$\ddot{y}_h = \frac{1}{2} \ddot{y}_{\text{pecado}(ah)} - \frac{Ah}{s_{jj} \dots A_2^2} \tag{13}$$

Para cada unidade de Controle de Supervisão e Aquisição de Dados (SCADA), um conjunto de características fn é definido em (14). Além do harmônico h componentes também o harmônico de ordem zero A_0 com ângulo de fase igual a zero está incluído em cada conjunto.

$$fn = Ap, \quad p, \quad \ddot{Y}_p \quad (p = 0) \ddot{y} \ddot{y}n \ddot{y} \{(Ap)(p = 0) \ddot{y} \quad (p = \ddot{y}n)\} \tag{14}$$

A Tabela 3 mostra o verão do tipo de modelo, vantagens, uso em diferentes aplicações de previsão de energia, mapeamento e energia métodos de perfilagem.

2.2. Modelos baseados em dados estatísticos e de regressão

Na modelagem estatística, a investigação de regressão é um método matemático usado para prever a inter-relação entre os parâmetros. Abrange muitos procedimentos para modelar e analisar inúmeros parâmetros, concentrando-se na associação entre uma ou mais variáveis independentes e uma variável dependente. Além disso, a dissecação de regressão demonstra de onde o quantidade esperada das modificações de variáveis menores durante qualquer um dos parâmetros livres é diverso, enquanto os parâmetros individuais adicionais existem solidificados. Várias dissecações de regressão calcular a expectativa dependente do parâmetro subordinado abordou os parâmetros autônomos.

2.2.1. Modelos de previsão de previsão

Atividade significativa na utilização de muitas redes inteligentes, como a resposta da demanda à superintendência de contingência é o curto prazo previsão de capacidade de energia em várias ordens, de um determinado consumidor para toda uma gama de consumidores. Previsão de previsão

modelos constroem uma avaliação quantitativa de várias 'máquinas métodos de aprendizagem" para previsão de demanda de energia de curto prazo no agregado e o nível individual. Neste cenário, a previsão de consumo de energia para diferentes horizontes de tempo (por exemplo, 1 h à frente, 1 dia à frente, 1 mês à frente) e escalas espaciais (por exemplo, transformador de distribuição, medidor individual de nível de casa) é cada vez mais importante para muitas aplicações da futura rede elétrica (ou Smart Grid), que inclui resposta de demanda, regulação de frequência e tensão, ou gestão autônoma de emergências [73]. A pesquisa de aprendizado de máquina aumentou vários métodos que se aplicam à energia previsão de consumo. Isso inclui regressão linear e ARMA modelo [74] para redes neurais [75] ou regressões SVM [76]. Não, essas técnicas normalmente têm sido implementadas em grandes escalas espaciais, como prever a carga elétrica de um segmento de mercado que fornece energia para milhares de clientes [77,78], ou mesmo um país inteiro [79].

Nesta seção, defina a metodologia adotada para decidir as características relevantes dos modelos de previsão de energia. Para decidir as características relevantes, contemple dois horizontes temporais: uma hora em diante e vinte e quatro horas à frente. Em cada caso, o valor previsto é o consumo por hora de a menos que um determinado cliente ou o todo o conjunto de usuários. Para avaliar quantitativamente a magnitude desse relação, formulou a autocorrelação da série temporal de consumo, que esclarece quanto o consumo em hora h está correlacionada com o consumo em uma hora $h < h$. o autocorrelação de uma série temporal $S = s_1, s_2, \dots, s_N$ para um certo atraso \ddot{y} é calculado como:

$$R(S, \ddot{y}) = \frac{E[(s_i - \ddot{y}(S)) \cdot (s_{i+\ddot{y}} - \ddot{y}(S))]}{2} = \ddot{y}(S) \tag{15}$$

onde E é o especulador de quantidade suspeito, S , e $\ddot{y}(S)$ é o desvio padrão e $\ddot{y}(S)$ é a média aritmética da escala de tempo. A Fig. 5, (a) mostra a auto-correlação da série temporal de consumo de energia para um cliente individual. É reconhecer o




Fig. 5. Autocorrelação do consumo (a) Família individual (id 1002) (b) Agregação (782 famílias) [80].

valor do uso por estar altamente correlacionado com o consumo anterior até 3 horas antes. Para horas passadas, existe um máximo de poder de compra local em correspondência com a hora

$h \{h \sim 23,9, h \sim 47,9, h \sim 71,9 \dots, h \sim 167,9\}$. Para demonstrar que o consumo de energia dos 7 dias anteriores na mesma hora

h possui alguns fatores preditivos. No nível agregado, o autocorrelação entre o consumo de energia na hora h e o uso passado na hora $h \{h \sim 23,9, h \sim 47,9, h \sim 71,9 \dots, h \sim 167,9\}$ é muito maior do que no caso de famílias individuais, como apresentado na Fig. 5(b) [80]. Portanto, isso implica que a previsão do consumo de energia ao incluir dados históricos é antecipada para aumentar a precisão mais em todo o nível do que no particular nível.

A literatura recente estabeleceu métodos de regressão baseados em SVM O SVR é um modelo capaz de prognosticar o consumo de energia esperado [77,79]. Outros métodos bem estabelecidos foram identificados como regressão linear e Multi-Layer Perceptron (M-LP). Wu et al. [81] fizeram um modelo para melhorar a previsão do clima e série temporal. On Demand Response (DR), empresas de serviços públicos trabalharam com grandes clientes industriais para reduzir seu consumo de energia durante os horários de pico de uso de energia designados. Para verificar redução do uso de energia dos clientes, as empresas de serviços públicos precisavam estimar o que os consumidores seriam utilizados na ausência de uma situação de DR (ou seja, a linha de base de DR). As linhas de base DR variam de média simples para regressão [82,83].

2.2.2. Modelos de previsão de benchmarking

Na desvinculação que ocorre quando da licitação no dia seguinte demanda de energia e a demanda de balanceamento de tempo de exceção, maneiras exigem previsões precisas para estabilizar os custos de mercado para chegar em determinações sábias. Uma variedade de padrões anteriores que delineou o equilíbrio das necessidades de previsão do mercado, incluindo um aumento menor, é comparado e os modelos são individualmente comparados para uma previsão de uma hora à frente e um dia à frente enquanto comparam projeções pontuais e intermediárias. Os padrões marcados em bancada renderam informando previsões pontuais com um dia de antecedência, apoiando essa erudição acessível de forma eficiente o plugging da demanda de um dia à frente é adequadamente indicada no preço de um dia à frente do mercado, de preferência do que os preços de equilíbrio de tendência de mercado.

Misiorek e Weron [84] propõem uma grande crítica à métodos de projeção. Em um limite de referência na sequência de tempo aproximações correspondentes a outra. Diferentes estudos que técnicas de previsão de 1 dia de referência são exploradas na literatura em referência [85], que examina três padrões distintos de escala de tempo, 'modelos neurais artificiais' e 'abordagens baseadas em wavelets' para a interconexão da PJM (Pensilvânia-Nova Jersey-Maryland) um dia à frente do preço, e que os experimentos conduzidos por No gales et al. [86], que associam dois padrões separados de ordem de tempo

Tabela 4

Revisão de padrões numéricos para benchmarking.

Nome	Algoritmo de estado	Volume do método de previsão
HIST.	Marcas	Forma dos valores históricos aleatórios
RND.	Marcas	Formas do aleatório da distribuição
CRUZ.	Chegada	Algoritmo ARI para séries de tempo-espaço desiguais
SARMA.	Nenhum	Modelo de ARNA sazonal

para o supermercado líder de 1 dia 'californiano' e 'espanhol' preços. Até onde sabemos, os resultados da pesquisa não existem, pois dizem respeito ao equilíbrio dos preços de mercado. No entanto, as considerações sobre o problema persistem, incluindo Skytte neste estudo [87], Pettersen e Fleten [88], Söder e Olsson [89], Jaehner et al. [90], Soder e Brolin [91] e Boomsmaa et al. [92], para os quais são todos de o mercado empresarial 'nórdico'. A participação no referido substância é uma análise bem organizada e métodos de benchmarking baseado em séries temporais para cálculo de preditores de preços de demanda. A importância é colocada no limite de um dia à frente, no entanto, ambos e as previsões de um dia e uma hora à frente são comparadas. UMA O resumo das regras para o montante referenciado pode ser determinado na Tabela 4 [93].

Para estimar as projeções intermediárias de diferentes incondicionais cobertura: Subleve y_t ser um significado reconhecido no limite fora do espécime e dê $L_t(p)$ e $U_t(p)$ seja o mais alto e solte limites das projeções de probabilidade para cobrir a probabilidade, p , sequencialmente. Mais tarde, reconheça uma variável de símbolo que pode ser descrita da seguinte forma:

$$I_t = \{1, \text{ se } y_t = L_t(p)U_t(p)\} \quad (16)$$

$$I_t = \{0, \text{ se } y_t = L_t(p)U_t(p)\} \quad (17)$$

A conclusão geral é considerada comparável para ambos os padrões na medida em que inclui as previsões de uma hora à frente, horas são prognosticadas com precisão, incluindo números que vão de 0,70 a 0,90, enquanto uma variedade dos tempos mostra-se complicado de prognosticar, recebendo assim uma recôndita montante [93]. A média do erro absoluto médio (MAE) dos 4 desenhos distintos podem ser detectados na Tabela 5 [93]. A classificação de os vários padrões são indiscutíveis: em direção à previsão de curto prazo (próxima hora), o padrão SARMA excede todos os outros digite toda semana. Para previsão de 1 dia à frente, o padrão CROST em meio a séries de eventos distribuídas de forma intermitente (alinhada) é superior para todas as semanas seguintes, excluindo a primeira semana e a semana 8 onde quer que o O padrão SARMA demonstrou resultados imensuráveis. A responsabilidade de prognosticar um dia à frente comparando o panfleto do supermercado é formidável; o padrão SARMA levou ao desempenho mais fraco durante a semana 10 e a semana 12, enquanto o CROST padrão é inferior na semana-1.

Tabela 5
MAE de estimar a previsão de volume de mercado para vários padrões.

w v t	Previsão de 1 hora à frente					Previsão do dia seguinte				
	CROST SARMA HIST RAND CROST SARMA HIST					RAND				
	109,800	67,53	59,120	37,99	76,73	77,68	110,18	103,63	107,25	108,44
1 2	46,73			33,56	53,96	59,74	30,60	54,64	86,50	88,97
3	86.650	68,89	44,57		60,36	65,54	45,17	72,20	98,39	100,28
4	35.050	33,79	34,13		54,83	66,18	56,23	20,61	61,09	60,97
5	90.430	96,0	41,69		68,02	43,23	83,28	47,40	71,47	80,81
6	43.030	33,21	25,02		49,28	44,04	83,49	25,54	53,64	70,54
7	21.450	19,38	15,22					14,69	27,99	50,19
8	43.020	33,62	18,97					28,89	19,04	56,10
9	121.850	78,31	35,90			83,81	65,02	78,69	107,01	106,29
10	94.840	58,70	35,48		77,77	89,05	50,86	145,74	87,48	87,94
11	98.370	65,66	43,86		71,35	73,21	55,78	57,52	113,50	117,01
12	39.880	39,85	30,60		36,59	45,85	41,55	104,29	64,10	66,52

MWh-Média Semanal

2.2.3. Modelos de mapeamento de energia

O mapeamento de energia introduz um método matemático de baixo para cima consiste em um Sistema de Informação Terrestre (TIS) para prever a energia das propriedades domésticas além de um país inteiro, província ou cidade. A adoção de um modelo de regressão linear múltipla permite a redução do consumo medido de gás natural e eletricidade do nível agregado do código postal para residências unifamiliares, que se baseia em vários descritores, como tipo de moradia, duração do desenvolvimento, fachada da história e alguns habitantes. o a utilização de energia é distribuída para diferentes usuários finais e corrigida para o clima, e então o potencial de economia de energia é estimado incluindo a implementação de reformas comuns medidas.

De acordo com a revisão de Swan e Ugursal [94], 2 personagens de padrões de poder instituinte de ativos ocorrem em grande escala: abordagens de cima para baixo trabalham para colocar uma correlação entre a soma consumo de energia e dados relacionados anteriormente mencionados como estatísticas de descrição de habitação ou dados econômicos [95-97]; debaixo para cima abordagens estimam os consumos de energia de um único edifício, ou grupos de edifícios para uma identidade diferente através de uma hierarquia de dados de entrada desagregados. Os resultados são então deduzidos para todo o parque imobiliário por meio de indicadores substitutos. Baseado em engenharia abordagens utilizam dados quantitativos que destacam características do propriedade residencial na qual calcular a utilização de energia de um conjunto de edifícios que representam o estoque com um modelo numérico [98–100]. Vários métodos estatísticos na literatura analisam a conexão entre o consumo individual de energia dos edifícios e um uma série de variáveis relacionadas às características do edifício, como a composição da casa e os comportamentos dos ocupantes no que se refere a um amostra de edifícios [101,102]. Embora muitos modelos de engenharia baseados em Informações Geográficas (GIS) tenham sido gerados na escala da cidade [103], existem apenas alguns modelos estatísticos baseados em GIS. Howard et al. [104] criaram um método analítico baseado em GIS para identificar o arranjo de instituir intensidades de utilização de energia em a cidade de Nova York.

As seguintes equações são mais normalmente alistadas para modelos de mapeamento de energia de gás e eletricidade:

$$y_{gas} = \sum_{i=1}^{25} \left(\hat{y}_0, gas + x_{f,loor} \cdot \hat{y}_f,loor, gas + x_{tipo,i,gas} \cdot \hat{y}_{tipo,i,gas} + \hat{y}_{gás} \right) \tag{18}$$

$$y_{ele} = \sum_{i=1}^5 \left(\hat{y}_0, ele + x_{f,andar} \cdot \hat{y}_f,andar, elec + x_{pessoas} \cdot \hat{y}_{pessoas, elec} + x_{type,i,elec} \cdot \hat{y}_{tyoe,i,elec} + \hat{y}_{elec} \right) \tag{19}$$

A variável dependente *y* é designada por valores anuais de consumo médio de energia por habitação (gás natural ou eletricidade) obtidos por área de código postal. As variáveis independentes são relativas às características dos domicílios e aos componentes dos domicílios: superfície do piso *x* piso , número de ocupantes *x* pessoas e tipo de domicílio *x* tipo . Com base no procedimento de regressão passo a passo, a superfície variável do piso *x*floor foi encontrada como sendo significativa tanto para os modelos de gás natural como de eletricidade, enquanto o número variável de ocupantes *x* pessoas só eram pertinentes para eletricidade [105–107].

2.2.4. Modelos de perfis de energia

Uma variedade de fatores corporais estabelece a necessidade de energia caracterização de carga. Aquisição da combinação ideal de estratégias e a mais recente instalação do sistema de energia renovável dita uma abordagem simplista para praticar no andaime do plano imediato. Área residencial, esboço de carga fumegante para vários as classificações das casas são formadas adotando o padrão térmico dinâmico, que foi criado empregando o esquema de rede de resistência térmica. A caracterização da carga de energia necessária para interrupção diária de aparelhos, aquecimento de ambientes residenciais e água quente pode ser determinada usando esta abordagem que

pode fornecer um esboço de carga diária de uma residência peculiar para moradores residenciais. Na lucrativa divisão de casas dos Estados Unidos, As práticas de aquecimento, ventilação e ar condicionado (AVAC) representam 40,0% do consumo de energia [108]. Quase 34,0% do edifício locais fornecem aquecimento interior, ventilação e ar condicionado controle [109,110] que produz conforto de refrigeração aplicando chillers para dispensa de temperatura e desfaça-o para assembléias de tratamento de ar. A cabeça é gerada por, usando caldeiras que a movem para o ventilador radiadores de bobina, conjuntos ou radiadores de rodapé [111–113]. o 'ANSI/ASHRAE 90.1-2007 sugere que os programas dos sistemas de aquecimento, ventilação e ar condicionado cumpram os inventários determinados para classes de estruturas representativas [114] que poderiam ser manipuladas em relação às apropriações de posse obtidas durante uma fase de layout de construção de acordo com experiências anteriores de engenheiros como bem como resultados de pesquisas de moradores em larga escala [115]. De acordo com certas direções, prática de aquecimento, ventilação e refrigeração devem se mover em uma sequência contínua de espaços ocupados e pode ser desligado e ligado para acomodar resfriamento e aquecimento demanda de carga em horas desertas [116].

No entanto, os pesquisadores demonstraram que a ocupação o espaço ou sequencial é indeterminado no universo; portanto, em circunstâncias de partida e chegada de habitantes são problemáticas para pré-destino [117-119]. Para compensar as ineficiências alinhado com a utilização de aquecimento, ventilação e ar predeterminados registros do sistema de condicionamento, muitos estudos têm praticado posse ou ocupação para refinar os processos de HVAC [120,121]. o

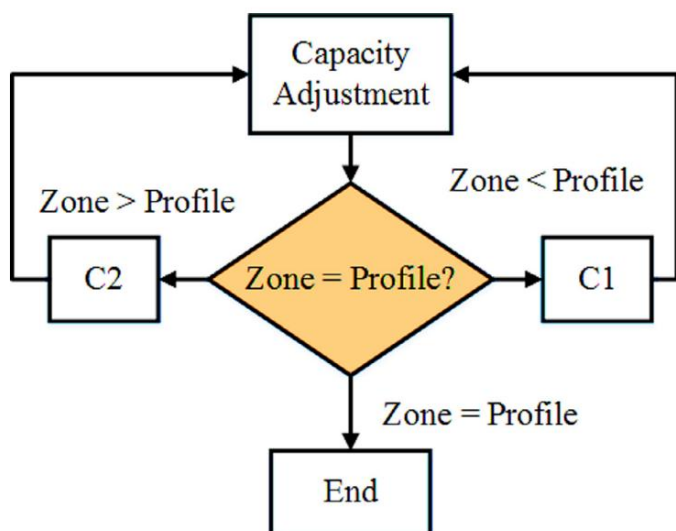


Fig. 6. Regras C para agrupamento de perfis [129].

intenção é que o consumo de energia possa ser conservado por não abrangendo o sistema HVAC na área desocupada. Considerável conservações de energia são publicadas em estudos anteriores, interrompendo pontos fixos imóveis na área abandonada [122–126] em que calores de área são permitidos para diversas variedades flutuantes, comprometendo se a área está congestionada ou oposta [127,128].

Na referência [129], o comprimento de 'Minkowski' é escolhido para determinar a conexão entre duas caracterizações onde é praticado como um propósito impreciso de conter horizonte de agrupamento.

$$Minkowski \text{ distância } dio = \sum_{p=1}^n \left(\frac{chip - molho}{r} \right)^{\frac{1}{r}} \quad (20)$$

dio é o comprimento construído no centróide i e no item o ; n mostra a dimensão do vetor, igual a 479,9 nesta pesquisa; xip representa a quantidade de probabilidade no tempo (p) para eficiência, e xiO mostra a probabilidade em diferentes períodos p para o centróide caracterização. Uma vez que o 'processo de agrupamento k-means' é encerrado, a modificação de habilidade é executada para estabelecer essa área limite é primoroso. Um número do perfil em um cluster subordinado não é equivalente ao espaço da área, a alteração subsequente, conhecida como "regra C" é adotada de acordo com a extensão entre os diferentes grupos de centróides e perfis Fig. 6 [129].

- (1) (bi) pode ser explicada a capacidade da i -ésima área. Enquanto isso, é limitado do que o número de perfil li , $bi < li$. bi de perfis ponto mais próximo do centróide que é atribuído à área da zona, enquanto os perfis restantes são selecionados para o área diferente, onde os centróides estão mais próximos do centróide de a área i . Esta prática é reconhecida como $C1$ nesta revisão papel.
- (2) A habilidade ou capacidade da i -ésima área de densidade bi é maior em comparação com o perfil número li , $bi > li$, todas as caracterizações são atribuídas a esta área, enquanto as aberturas adicionais são permeadas pelos perfis de consumidores que se aproximam da área contemporânea da zona i do centróide. Este edital é reconhecido como $C2$ nesta revisão.
- (3) As práticas Rg e Rl são executadas iterativamente, a menos que todas as áreas capacidade bi está de acordo com sua quantidade de caracterização li [129]. A Tabela 6 mostra o verão de diferentes estatísticas e modelos orientados a dados baseados em regressão.

2.3. Modelos baseados em dados baseados em ANN

Os sistemas conexonistas ou redes neurais artificiais são um modelo computacional usado na 'prática de aprendizado de máquina' e outros desenvolvimentos de experimentação relacionados. Penitenciária das ANNs é moldada de precedentes, de preferência do que explicitamente particularizados. Eles estão numerosos comumente usados em pomadas que são muito complicadas para se comunicar em um algoritmo de microcomputador convencional que alista familiar, programação baseada em regras. As RNAs fornecem uma variedade de soluções para uma grande variedade de responsabilidades, incluindo reconhecimento de voz, visão computacional, diagnóstico médico e tradução automática.

2.3.1. Modelos de previsão de previsão

A previsão de energia predial obteve aceitação por causa da análise catapultante no campo da eficiência predial. Uma ampla diversidade de modelos de poder de construção torna-se reconhecida para a previsão de energia de curto, médio e longo prazo [130,131]. Os padrões comumente usados nos tempos atuais são compreende 'aprendizado de máquina e modelos baseados em estatísticas' que determinar com precisão a previsão de energia e a correlação de uso a dados previamente designados. Últimos estudos fornecem especificado considerando sobre os modelos de previsão disponíveis e sua organização [132–134] da maioria desses modelos, no entanto, são compostos da base de RNAs e seus avanços [135–138]. Aydiinalp et al. [139] aplicaram RNA para prever a utilização de energia de aparelhos, refrigeração de ambientes, iluminação, na área doméstica. A aplicação de redes neurais artificiais demonstrou capacidades de previsão excepcionais quando comparada com uma simulação de construção modelo. Após dois anos, Aydiinalp et al. [140] utilizou o artificial rede neural para modelar a utilização de energia hídrica e o aquecimento do espaço. Zamarre et al. [141] praticaram NN artificial de realimentação para prognosticar a carga de energia de curto prazo. O padrão de feedback desenvolvido ou modelo fazia parte da exposição de doutorado de 'Schenker' [142].

Este arranjo incorpora a seção do rendimento, que é realimentado como um valor de entrada, bem como a falha de previsão relativa às saídas contidas que são então usadas para treinar a rede. Karatasou et al., redes neurais artificiais foram utilizadas por Aazadeh et al. em referência [143] para determinar a potência de longo prazo utilização na autoridade concentrada fazendo empresas na República do Irã. Eles também conduziram um estudo semelhante examinando medidas para projetar ativamente o uso mensal de energia [144]. Yokoya maa et al. [145] empregaram redes neurais artificiais de retropropagação para prever o requisito de carga de resfriamento para um prédio de escritórios. Eles introduziram um novo método chamado otimização global é conhecido como um método de corte modal para detectar os parâmetros de modelos [146]. O 'método de otimização global' pode estimar a diferentes neurônios influenciam nas diferentes (camadas ocultas) e põem na exatidão do prognóstico.

As aplicações existentes e as vantagens da RNA são apropriadamente admitidos em uma quantidade de restrições, particularmente em não lineares modelagem. O principal componente em redes neurais artificiais é a energia como mencionado anteriormente neurônios que se alinham em listras e anexado a neurônios em diferentes zonas em seções [147]. Essas conexões são apreendidas como os pesos do tipo sináptico poderiam, e as intenções do processo de treinamento do modelo são extrair certas substâncias. A ativação dos neurônios é circunscrita pela agregação dos parâmetros de entrada do modelo e pode ser (matematicamente) indicado como na Eq. (21):

$$O = f ((wijxj)) \quad (21)$$

Aqui, O é a saída do neurônio, xj é a entrada do neurônio, wij apresenta o peso da conexão da entrada, e f é a função de substituição. Essa função empregada em RNAs é comumente a

Tabela 6

Resumo de diferentes modelos baseados em dados estatísticos e de regressão.

Categoria do modelo	Modelos baseados em dados estatísticos e de regressão
Modelos de previsão de previsão Modelo de previsão	ARMA [76], modelo adaptativo [73], método HWT [74], modelo de série temporal (univariada) [75], modelos autoregressivos multiplicativos [75], filtragem de Kalman [75], modelos de rede neural univariada [74], método HWT [74], autoregressivo sazonal subótimo Modelos [74], regressão não paramétrica [75], modelos estruturais [75], procedimentos de ajuste de curvas [75], algoritmos genéticos (RSVMG) [76], Modelagem de séries temporais [79],
Programas	Matalb, EnergyPlus, Trnsys, etc.
Aplicação e uso	Modelagem de preços de eletricidade intradiários, Gerenciamento de tráfego e agendamento de equipe de call center, Pré-processamento de dados
Vantagens	Maior desempenho e eficiência de previsão, Pode ser apropriado para modelos desprezíveis, Convergência garantida, Computacionalmente eficiente por plano e design, não dependente do modelo
Modelos de comparação Modelo de previsão	Modelos semiparamétricos de séries temporais [84], modelos Wavelet [85], ARMA [84], modelo de regressão dinâmica [86], modelos ARX [84], Modelos de séries temporais [86], regressões de mudança de regime [84], modelo de programação linear estocástica [88]
Programas	Caixa de ferramentas MFE, SCA, Matlab, EnergyPlus
Aplicação e uso	Gestão do risco, Previsão de valores e preços spot de energia total consumida, Intervalos ou previsões de densidade, Daubechies ondas
Vantagens	Pode ser computacionalmente eficaz, não depende de modelo ou algoritmo de tipo diferente, os processos são estacionários, protegidos para concentrar na enzima ideal número inadequado de variáveis, computacionalmente altamente eficiente e eficaz, a frequência pode ser considerado alto
Modelos de mapeamento de energia Modelo de previsão	Algoritmos genéticos [94], modelo matemático simples [99], modelo de regressão [94], modelo de energia probabilística [100], Análise de demanda condicional [94], Modelagem estatística [102], Técnicas de regressão [94], Abordagem de modelagem top-down [105], BREDEM [94], modelo de atraso distribuído autorregressivo [94], modelo de correção de erro [97], modelo de simulação de energia [98], Modelos ascendentes [94], abordagem de redução de escala estatística baseada em GIS [107]
Programas	ESP-r, ERAD, EnergyPlus, eQuest, DOE-2.1E, eQUEST/DOE-2.2, BREDEM, HOT 2000, EPIQR, ECCABS, VBA, Sketch-up
Aplicação e uso	Análise de fornecimento com base em projeções de eletricidade de longo prazo, necessidade de eletricidade por estimativa para resposta de dados históricos, Aumento da necessidade de eletricidade das diferentes práticas finais, incluindo perspectivas comportamentais, refrigeração e aquecimento cargas, Uso de energia; Emissões de CO2
Vantagens	Previsão de energia em perceptivo de longo prazo, contém resposta e desempenho dos ocupantes, algoritmo com avanço tecnologias, Concretização dos impactos socioeconômicos e macroeconômicos, Determinação do fornecimento de energia apropriado como bem como seu uso no ambiente de construção, Conhecimento de entrada simples e gerenciável, Abrange inclinações de energia, Pratica os dados de faturamento de pesquisa simplista erudição
Modelos de perfis de energia Modelo de previsão	Modelos estocásticos de ocupação [115], modelo baseado em aprendizado [127], algoritmo de otimização livre de derivativos [126], baseado em agente modelo [117], método de processo estocástico [117], controle preditivo do modelo estocástico [124], modelo estocástico generalizado [118], Algoritmo de particionamento espectral [123], SHOCC [118], modelo Poisson [119], algoritmo de média móvel autorregressiva (ARMA) [129], algoritmo K-means [129], algoritmo de controle MPC [125]
Programas	DOE, EnergyPlus, ESP-r, DeST, TRNSYS, MATLAB, SUNtool, SER-Res
Aplicação e uso	Ambiente interno, Uso de eletricidade, Pertinência de segurança, Controle de iluminação, Uso de eletricidade do sistema HVAC quando o fluxo de ar ligado ao controle de ocupação e construção
Vantagens	Os modelos podem produzir a localização precisa de cada ocupante do edifício e o nível da zona, pode medir a ocupação estimativa de taxa para todo o edifício

'função sigmoidal', que contém a estrutura resultante (22):

$$S(t) = \frac{1}{1 + e^{y t}}$$

(22)

A saída do neurônio é transferida para a próxima camada na saída deste neurônio e esses pesos no filme subsequente podem ser denotado, e a forma mais simples é mostrada na Eq. (23), onde quer que *O*l esteja a saída do neurônio para a próxima camada e *w*jl é o 'peso' ligando o neurônio anterior:

$$O_l = f \left(\sum_j w_{jl} f(w_{ij} x_j) \right)$$

(23)

O objetivo da preparação do procedimento de treinamento do modelo é depreciar o erro quadrado entre as saídas medidas e as saídas previstas. *E* é diminuído do (modelo gradiente de perfume), que inclui estimar a derivada influenciada de *E* em relação à substância específica na interface.

$$E = \frac{1}{2} (O_n - O_m)^2$$

(24)

Aqui, *E* é a soma do erro referente ao total, *O*p é a estimativa saída e *O*m é a saída designada.

2.3.2. Modelos de previsão de benchmarking

O benchmarking de energia é imperativo para calcular o uso de energia do edifício e contrastando-a com edifícios relacionados em ambientes semelhantes. Os resultados de benchmarking adicionados calculam podem ser usado para diminuir o uso de energia quando a construção do gabinete foi

avaliado para utilizar níveis de poder imensos em comparação com o outras instalações semelhantes. Um modelo de benchmarking baseado em ANN é apresentado como uma abordagem profundamente útil. Esta técnica concentra-se particularmente na previsão de um índice ponderado de uso de energia, exercitando em conta variáveis específicas, antes mencionadas como iluminação tipo, densidade de carga do plugue e tempos do processo, 'tipo de equipamento de ar condicionado e eficiência' etc.

paradigma de referência de rede para prognosticar eletricidade latente foi estimada a conservação dos diferentes esquemas de retrofit.

Parâmetros de entrada de benchmarking foram alterados para indicar a conservação de energia inerente por um esquema de retrofit, e o conjunto de novos as entradas foram simuladas com o projeto de rede neural artificial. Matson e Piette [148] revisaram estudos de energia para estruturas de escritórios e comerciais do edifício. Uma regressão linear

A técnica proposta por Sharp [236,150] é variada geralmente aplicada em diferentes edifícios do tipo benchmarking. Detalhes maciços do power star (para energia predial) pode ser desenvolvido a partir da pesquisa de [151]. Em um estudo de [152], foi formado um 'método de benchmarking' baseado em modelo particularmente relevante para sala de laboratório. Análise complementar de benchmarking laboratorial e atenção pragmática e condições podem ser compreendidas a partir da referência [153,154]. A Tabela 7 descreve os diferentes aspectos dos dados baseados em ANN modelos.

2.4. Modelos orientados a dados baseados em SVM

Um SVM é um classificador discriminativo identificado por um hiperplano. Dito de outra forma, dados designados os dados de treinamento,

Tabela 7

Resumo de modelos baseados em dados baseados em ANN.

Categoria do modelo	Modelos baseados em dados baseados em ANN
Modelos de previsão de previsão Modelo de previsão	Redes neurais de alimentação direta [137], Função de base radial (RBF) [147], Modelos numéricos [232], Regressão linear múltipla com interações [131], abordagens baseadas em IA [131], modelos híbridos [134], modelos matemáticos [232], modelos causais [130], Modelos adaptativos [135], modelo de engenharia [138], modelo de estado pseudo-estacionário [233], modelo ANN simplificado [230], modelo de Gray [145], modelo ANOVA [143]
Programas	Matlab, DOE-2, EnergyPlus, BLAST, ESP-r, EnergyPlus
Aplicação e uso	Prognóstico de uso de eletricidade do edifício, pré-processamento de dados de consumo de energia, controle e previsão do pico de energia demanda, fluxo de distribuição de ar dentro da sala, velocidade do vento, temperatura do ar interior, ventilação de aquecimento e refrigeração dissecação do sistema, previsão do uso de eletricidade, previsão do uso de energia, radiação solar
Vantagens	Eficiência de classe mais alta, fácil de praticar e usar, a previsão pode ser implementada em toda a seção do edifício, imensurável na determinação de diferentes dificuldades não lineares, quantidade abrangente de zonas, caracterização precisa do fluxo de fluido ocorrendo dentro do setor de construção, um volume consistente de dados em forma de treinamento com os dados vetoriais essenciais
Modelos de previsão de benchmarking Modelo de previsão	Redes neurais multicamadas [149], CART [149], Árvore de classificação [149], CHAID [149], modelo de regressão linear [152], CART e Regressão Binominal Negativa (NBR) [149], Modelo empírico [152], Métodos de avaliação simples [152], Regressão logística [149], Análise da árvore de classificação [149]
Programas	FLUENT, COMSOL, MIT-CFD, PHOENICS-CFD, TmSys, EnergyPlus, IDA-ICE, ESP-r, Clim2000, BSim e BUILDOPT-VIE
Aplicação e uso	Evolução da demanda energética, Ventilação natural, Solar passivo, Sistema de ar condicionado, Ambiente climático, ocupantes comportamento, Conforto térmico interior, Ventilação artificial e natural, Evolução do tempo de utilização mundial de eletricidade, Previsão de temperatura interna com média de espaço
Vantagens	Alta eficiência e desempenho na previsão do uso substantivo de eletricidade, distribuição temporal e espacial do estado confinado parâmetros (concentração, temperatura, fluxo de ar, pressão) em um volume alto, Implementação é bastante mais fácil, Zona versátil de os prédios; O tempo de computação é razoável, Função que representa o sistema; Modelagem eficaz e modelo de otimização

as saídas do modelo de um hiperplano ótimo que classifica ilustrações adicionais. Ao aumentar a entrega de grupo linear, suporte máquina vetorial pode efetivamente conduzir uma análise não linear conhecida como o 'truque do kernel', delineando precisamente seus fatos dentro de períodos característicos de alta dimensão. Durante os dados de uso de energia são não rotulado, o treinamento controlado é impossível, e um treinamento não supervisionado método de aprendizagem é essencial. Esse tipo de procedimento atua para localizar 'clustering' espontâneo dos dados em combinações e, posteriormente, mapeia dados atuais para sortimentos certamente estabelecidos. O tipo do modelo de clustering aprimora o SVM. Esta atividade é apreendida como cluster de vetor de suporte (SV) e é frequentemente aplicada em assiduidade industrial, a menos que durante os dados não sejam rotulados ou enquanto isso, alguns dados exclusivos são rotulados como um pré-processamento para uma abordagem distribuída.

2.4.1. Modelos de previsão de previsão

O mercado elétrico, tornando a quantidade adequada de energia no momento apropriado, incluindo a melhor demanda de convite é crucial para que as concessionárias ampliem seus lucros. O meio-termo A previsão de preço de compensação do mercado de energia mudou para programação de manutenção de fontes, realocação, orçamento e planejamento e contratação bilateral. Embora existam vários disponíveis abordagens para a previsão de preço de compensação do mercado de energia de curto prazo, a quantidade de previsão de preço de compensação de mercado de energia de médio prazo é insignificante. Atualmente, a maioria dos mercados de eletricidade compensando os estudos de previsão de preços referem-se à previsão de preços de compensação do mercado de energia de curto prazo, que é normalmente associada ao horário de 24:00 h previsão de preço de energia um dia à frente. Bastante pequena pesquisa tem foi acompanhado pela previsão do preço de compensação do mercado de energia por médio prazo [155-160].

Recentemente, máquina de vetor de suporte, uma nova abordagem de treinamento compreende na minimização da incerteza fundamental, possui alcançou maior conscientização sobre a previsão de preço de energia [161-164]. Os principais benefícios do vetor de suporte sobre a rede neural artificial ou quaisquer técnicas de previsão são o suporte máquina vetorial pode evitar problemas desafiadores que incluem os gostos de dados sobreajustados e imprevisivelmente alta fora da amostra em erros de dados de consumo de energia, também correspondendo ao tempo de entrega de resultados imensuráveis. A máquina de vetores de suporte também é uma técnica de previsão bastante formidável. Não obstante as vantagens fundamentais, o uso da máquina de vetor de suporte será visto consistentemente como aquele que entrega resultados. Além disso, o SVM

o valor agregado de variáveis menos flexíveis correlacionadas a rede neural e, consequentemente, é considerada menos envolvida na o sortimento da variável de controle. Uma máquina de vetor de suporte convencional pode realizar aproximadamente 3% [165] melhor desempenho em contraste com uma rede neural artificial típica no que se refere ao previsão de previsão de preços do mercado de energia de curto prazo.

Muitos modelos são empregados para otimizar o treinamento de suporte máquina vetorial para melhorar a precisão da previsão SVM. Esses modelos combinam modelos de algoritmos genéticos [166-169], enxame artificial algoritmo de peixe [170], algoritmo de análise de componentes [171.172] e modelos de posições imprecisas [173,174]. Uma máquina de vetor de suporte aprimorada, que é conhecida como (vetor de suporte de mínimos quadrados machine) também foi formado para aumentar a veracidade da máquina de vetor de suporte inventivo [175,176]. Embora a classificação particular tenha determinado aumentos parciais demonstrados, a operação precisão.

Um SVM é uma nova abordagem de aprendizado de máquina que compreende a minimização da incerteza fundamental. Em sua infância, vetor de suporte máquina foi usada em diferentes propósitos de classificação [177]. Depois Em seguida, a 'função não linear de computação de regressão' foi enumerada determinando uma situação curva de 'otimização quadrática'. A classe de assunto diferente pode ser reconhecida como cálculo para regressão com a recorrência da quantidade de limite. Assumindo que $\{X_t, y_t\}$ para $(t = 1)$ a (N) é uma posição apresentada de diferentes dados onde $X_t = (x_{t1}, x_{t2}, \dots, x_{tk})$ é o vetor de entradas no tempo t com k componentes e y_t é o análogo a um preço de dados diferente no tempo t que pode ser interpretado como

$$y_t = f(X_t) = W \cdot \tilde{y}(X_t) + b \tag{25}$$

onde quer que h ; eu expresso o produto de ponto, W mostra o vetor para peso, b representa o viés e \tilde{y} representa a função de mapear as trocas de ping do vetor de entrada X_t em direção a um valor substancialmente maior período característico dimensional. A mesma dificuldade de otimização é então:

$$\begin{aligned} & \text{minimizar} \quad \frac{1}{2} \sum_{t=1}^N \left(\tilde{y}_t - W \cdot \tilde{y}(X_t) - b \right)^2 + C \sum_{t=1}^N \left(\tilde{y}_t + \tilde{y}_t' \right) \\ & \text{sujeito a} \quad \tilde{y}_t - W \cdot \tilde{y}(X_t) - b \leq \tilde{y}_t \\ & \quad \quad \quad W \cdot \tilde{y}(X_t) + b - \tilde{y}_t \leq \tilde{y}_t' \\ & \quad \quad \quad \tilde{y}_t \tilde{y}_t' > 0 \end{aligned} \tag{26}$$

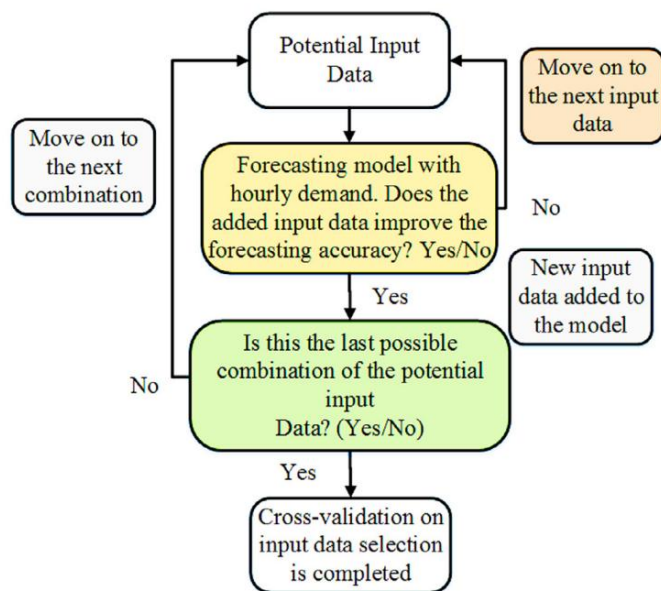


Fig. 7. Processo de seleção de dados [177].

Onde C é a constante de regularização relativa ao preço do segmento das transgressões. \tilde{y}_t e \tilde{y}_{t-1} são os parâmetros de folga que estimam o custo dos erros dois antes e posteriormente o valor objetivo nas circunstâncias de treinamento.

A 'função de perda insensível a ϵ ' com largura de banda de $2\tilde{y}$ é apresentada como:

$$|y_t - f(X_t)| \tilde{y} = \begin{cases} 0, & \text{se } |y_t - f(X_t)| \leq \tilde{y} \\ |y_t - f(X_t)| - \tilde{y}, & \text{caso contrário} \end{cases} \quad (27)$$

O problema dual, então, é:

$$\text{maximizar} - \frac{1}{2} \sum_{t=1}^N (\tilde{y}_t - \tilde{y}_{t-1})^2 - \sum_{t=1}^N \tilde{y}_t (y_t - f(X_t)) \quad (28)$$

$$\text{sujeito a} \quad \sum_{t=1}^N (\tilde{y}_t - \tilde{y}_{t-1}) = 0 \quad (29)$$

$$\text{sujeito a} \quad \sum_{t=1}^N (\tilde{y}_t - \tilde{y}_{t-1}) = 0 \quad (30)$$

Onde \tilde{y}_t , \tilde{y}_{t-1} e \tilde{y} são os 'multiplicadores de Lagrange'. A máquina de vetores de suporte final para funções não lineares pode ser formulada como

$$y_t = f(X_t) = \sum_{t=1}^N (\tilde{y}_t - \tilde{y}_{t-1}) K(X, X_t) + b \quad (31)$$

Onde $K(X, X_t) = \tilde{y}(X, X_t)$ representa a 'função kernel'. Radial A função gaussiana de base (32) é as várias temíveis em não lineares estimativa de propósito.

$$K(X, X_t) = \exp \tilde{y} \frac{X \tilde{y} X_t^2}{2\tilde{y}^2} \quad (32)$$

Ao executá-lo, a seleção dos dados mostrados na Fig. 7, garantir o teste não apenas de cada componente em particular, mas de cada sequência desejável de variáveis que aumentará para prever os resultados de saída [177]. Os elementos de entrada finais que se tornam

adquirido para a descrição do suporte múltiplo sugerido padrão de previsão de máquina vetorial a cada hora t são confinados à necessidade horária de energia no período t , um dia no máximo necessidade de eletricidade, demanda média de eletricidade, gás natural preços em base diária, a partir do número de preços de eletricidade do ano passado (1 a 4 representando as zonas de taxa: pico alto, médio e baixo) em t , em o mês (1 a 12) e também a hora do dia (quantidade 1–24). Além disso, os dados usados para a meta de uma hora t e o previsão do módulo de preço é o preço de compensação de marketing de energia no momento t .

2.4.2. Modelos de marcação de bancada

O benchmarking de energia permite a realização energética do setor de construção a ser pesado em relação ao objetivo de energia eficiente controle, bem como o projeto do edifício. O benchmarking de energia pode eliciar o consumo de avisos de energia e determinar a linha de base do desempenho de energia em um mercado designado. O gerenciamento de energia é usado para alcançar ou melhorar o 'nível de referência', e algumas estratégias de benchmarking que os modelos utilizam podem ser expandidas para acomodar o controle da energia do ambiente do edifício, conforme descrito por Wen e Li [178]. o concepção de benchmarking de energia para o setor de construção não é uma novo com suas metodologias, classificações e até processos de rotulagem evoluindo com o passar do tempo. Lombard et al. [179] fizeram uma consideração geral na identificação das variáveis fundamentais que são críticas para benchmarking de energia para edifícios.

Essas descobertas podem ser úteis para compreender a ideia básica dos modelos de benchmarking. O padrão de pesquisa na introdução do benchmark pode ser distorcido, como 'normalização', ou em procedimentos mais refinados, como engenharia e modelagem de máquinas [180,181]. Técnicas de ML na forma de máquina de vetores de suporte aplicadas aos diferentes tipos de problemas de regressão. A máquina de vetores de suporte é notavelmente útil para interpretar dificuldades ao usar uma pequena intensidade de amostra para o treinamento dados [182]. O método de modelagem de engenharia não é um padrão para as atividades de benchmarking. Ainda assim, a implantação deste sistema é completamente examinado e descrito por Torcillini et al. [183] e Fumio et al. [184], além disso, o processo é interpretado de Yaa et al. [185]. Os acessórios para as simulações energéticas do edifício dos diferentes padrões são imediatamente acessível, Crawley et al. [186] fez uma investigação completa de certos acessórios. Modelagem de energia, ferramentas de banco de dados são preparados pelo departamento de energia, Estados Unidos da América página inicial [187]. O aparato escolhido nesta pesquisa é a linguagem ou software (EnergyPlus), autorizado e desenvolvido pela departamento de energia [188].

Uma variedade de práticas de 'benchmarking' de poder foi descrita e é circunscrita por necessidades e resultados. o restrições podem ser encontradas como a acessibilidade dos dados de uso de eletricidade, o tamanho dos dados, bem como a cobertura dos dados [155]. A partir deste estudo, utiliza três técnicas utilizadas na previsão de energia, que são: (a) aprendizado de máquina; (b) modelagem de engenharia; e (c) modelagem estatística. Essas abordagens podem ser classificadas como uma estratégia de baixo para cima em que são utilizados dados separados. As abordagens de baixo para cima sinalizam conjuntos abrangentes de evidências, juntamente com a recuperação de dados refinada [189]. As técnicas de benchmarking decididas não são exclusivas dos conjuntos de consumo de energia de dados. Diferentes outras abordagens podem ser usadas. A título de ilustração, o a técnica de regressão do componente principal pode ser utilizada para compensar a influência da ressonância no conjunto de dados selecionado [190]. No entanto, as formas expandidas nesta pesquisa ilustram classificações de baixo custo empregando 'OLS' ao benchmarking altamente assíduo método de modelagem de engenharia.

O conjunto de amostras pode ser definido como $\{(X_i, Y_i)\}$, $i = 1, \dots, N$ onde quer que N amostra total, X_i descreve o uso de energia da i th amostra e Y_i é o consumo de energia normalizado da unidade i . A associação de

X_i a Y_i é dado por:

$$Y = W \cdot \tilde{y}(X) + b \quad (33)$$

A máquina de vetores de suporte deprecia a distinção entre o valor exato Y e o valor de previsão $f(X)$. Isso é feito depreciando a função regularizada como:

$$\text{minimizar}; \quad \frac{1}{2} \sum_{i=1}^N \tilde{y}_i^2 + \frac{C}{N} \sum_{i=1}^N L(Y_i, f(X_i)) \quad (34)$$

O segundo termo verifica o erro do prognóstico e são praticados os valores $L(Y_i, f(X_i)) = 0$ se $|Y_i - \tilde{y}(X_i)| \leq \tilde{y}$ e $L(Y_i, f(X_i)) = |Y_i - \tilde{y}(X_i)| - \tilde{y}$ para os outros. \tilde{y} é referido como o raio. Os valores para W e b são recebidos empregando a abordagem 'La grangian multiplicador'. Consequentemente,

$$\theta = \sum_{i=1}^N (\tilde{y}_i - \tilde{y}^-) TK(X_i, X) + b \quad (35)$$

$K(X_i, X) = \tilde{y}(X_i)^T \tilde{y}(X)$ representa a função de kernel. Nesta review, usa libsvm, conta 2.60 na programação 'R' [191].

2.4.3. Modelos de mapeamento de energia

Uma nova estratégia para montar e treinar RNAs foi recentemente divulgada, sem tais limitações. O moderno canais são denominados máquina de vetores de suporte [192]. Os modelos de mapeamento de energia SVM contam com um algoritmo de treinamento especial que aumenta a margem de divisão entre duas classes de dados. A previsão de energia baseada em sensores foi pesquisada para edifícios comerciais e residenciais. No entanto, devido à falta de informação sobre os edifícios residenciais, grande parte das obras anteriores tem se concentrado nas previsões de consumo de energia em edifícios comerciais. Algoritmos de aprendizado de máquina formam a base para modelos de mapeamento de energia baseados em sensores são apresentados em referência [193–197]. SVR refere-se à versão mais recente do vetor de suporte máquina para avaliação de 'regressão'. Foi introduzido em [34]. Prévio trabalho [198,199] demonstrou que o SVR supera os métodos ANN ao prever as cargas de energia do edifício associadas ao resfriamento.

Nesta parte, descreve uma ampla visão geral do modelo geral empregado para a seleção e avaliação de mapeamento de energia seleção do modelo, conforme mostrado na Fig. 8 [200]. O algoritmo é geral na medida em que é invariante à granularidade efêmera (espacial) do conjunto de dados de entrada, D , para evitar erros resultantes de procedimentos inconsistentes em todas as escalas [200]. Nesta figura, o fluxograma é usual em o conhecimento que não se transforma no espaço e no efêmero do conjunto de dados pela entrada D , para impedir erros ou erros originados em métodos irregulares além dos cálculos. Substancialmente, neste revisão se assemelhava às medições em relação a D para a escala de tempo relevante (a cada 10 minutos, de hora em hora, diariamente, ou seja.), e através da determinação o par de casas e famílias diferentes dentro da casa $f = B$ que seria empregado para prever o consumo total de energia da casa. Com base na escala unitária, cada unidade de escala formada como uma casa individualizada, bem como a medição do piso, e cada piso da casa é construído ou modelado como grupos individuais, enquanto que em toda a medida inicial a resposta é exibida como a uma substância $f = B$. Além disso, a seleção da variável D é realizada individualmente para qualquer casa ilustrada (família) f . O modelo para as variáveis o sortimento é apresentado na Fig. 8. A seleção subsequente de variáveis é estabelecida para a casa composta por uma família f ; métodos são comumente avaliados e preparados durante o processo de bootstrapping que fornece limitações na eficiência e desempenho de confiança do modelo, conforme estimado pelo coeficiente de variação resultar. A cada casa, iniciam-se os conjuntos dos dados N intervalos. Cada bootstrap iniciado D de I é dividido em uma validação diferente conjunto V e conjunto de treinamento T que são estimados 30% e 70% de D respectivamente.

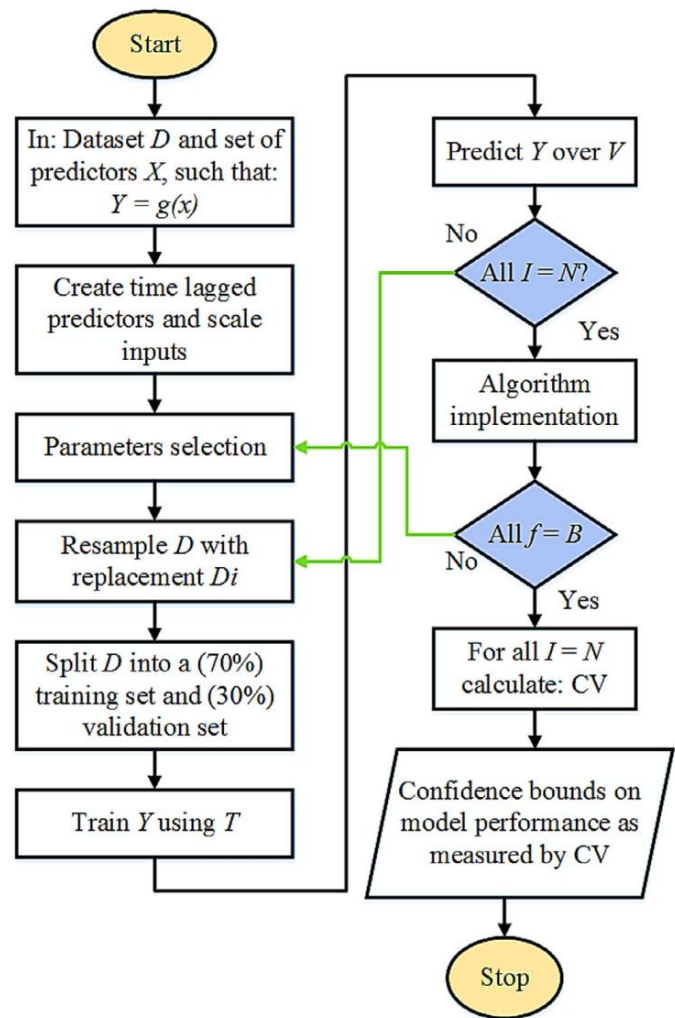


Fig. 8. Um algoritmo geral usado para seleção e validação do modelo [200].

Definimos dois conjuntos de entradas do modelo: M1 para validação do Dados 'Great Energy Forecasting Shootout' e M2 para teste em nosso conjunto de dados empíricos. M1 é consistente com as entradas apresentadas em [201] e é definido como o seguinte:

$$M1 = \tilde{y}\tilde{y}x(t) = [y(t \tilde{y} 1, 1), y(t \tilde{y} 2, 1), T(t)sh, s, ch] \quad (36)$$

Onde quer que $y(t \tilde{y} 1, 1)$ e $y(t \tilde{y} 2, 1)$ descrevam os valores de uso de energia identificados para as duas etapas anteriores, $T(t)$ representa o presente temperatura, $S(t)$ mostra o fluxo solar, s é um parâmetro de símbolo que denota fim de semana/feriado ou dia da semana, sh é o seno do hora presente (tempo) e ch é o cosseno da hora presente. Sediada em trabalhos anteriores [202,203] e falta de dados de fluxo solar, modificamos as entradas do modelo como M2 para testar no conjunto de dados Watt Hall como:

$$M2 = \tilde{y}\tilde{y}x(t) = [y(t \tilde{y} 1, 1), y(t \tilde{y} 2, 1), T(t), sh, s, ch] \quad (37)$$

A Tabela 8 demonstra a breve discussão da discussão do SVM modelos baseados em dados.

3. Previsão de energia do setor de construção usando em larga escala abordagens

Modelos baseados em caixa cinza, modelos baseados em caixa branca e caixa preta modelos baseados podem direcionar vários problemas associados à energia residencial de grande escala, por exemplo, previsão, previsão, mapeamento do consumo de energia urbano, perfil, benchmarking, bem como primeiro

Tabela 8
Resumo de modelos orientados a dados baseados em SVM.

Categoria do modelo	Modelos orientados a dados baseados em SVM
Modelos de previsão de previsão Modelo de previsão	Rede de mapa auto-organizado (SOM) [176], modelos SVM [164], média móvel integrada autorregressiva (ARIMA) [176], Máquina de vetores de suporte a análise de componentes independentes [170], Séries temporais [164], Modelos de Markov (IOHMM) [176], Arquitetura da rede híbrida [176], otimização baseada em algoritmo genético, denominada GA LS-SVM [168], análise de séries temporais [176], Transformada Wavelet [168], Matemática Box-Cox [176], Modelagem de Regressão de Máquina de Vetor de Suporte [170], Baseado em Máquina modelo de previsão de preços [165], modelagem de engenharia [155]
Programas	Matlab, CFD, TmSys, EnergyPlus
Aplicação e uso	Aproximação de funções e estimativa de regressão, estimativa de demanda de energia futura, demanda de carga industrial e comercial
Vantagens	predição, Eliminando informações redundantes e outras áreas para reduzir os dados de treinamento do SVM, Processamento de dados em larga escala, Superação a falta de algoritmo SVM
Modelos de marcação de bancada Modelo de previsão	Modelos de estoque de construção de baixo para cima [189], Regressão linear por partes [182], Regressão de componente principal [190], Multinível método de avaliação [185], modelos econométricos de cima para baixo [189], abordagem de baixo para cima [189], abordagem de agrupamento residual [190], Análise de regressão linear múltipla [190], modelos de previsão de luz do dia [186], abordagem híbrida [185], método grau-dia [184], Rede neural de função de base radial (RBFNN) [180], análise de densidade espectral de domínio de frequência [178]
Programas	EnergyPlus, Matlab, Trnsys,
Aplicação e uso	Simulação de energia do edifício, usado principalmente em edifícios antigos, onde a disponibilidade de dados é muitas vezes problemática
Vantagens	Ampla gama de recursos de uso de eletricidade com uma variação adequada e seleção das variáveis de energia, Adota o minimização de risco de estrutura, Empregada por redes neurais convencionais, Busca diminuir um limite inferior e superior pelo erro, problemas de regressão e classificação de destino geral válidos e eficazes ou aproximando-se, Mostrar uma regressão linear e mapeamento não linear, reduz a infiltração de ar e a taxa de perda de calor
Modelos de mapeamento de energia Modelo de previsão	Box-Jenkins [196], modelo ANN [194], máquinas de vetor de suporte para regressão [193], função de base radial [194], risco empírico método de princípio de minimização (ERM) [193], modelo esparsos [194], algoritmo GASA caótico [196], modelos SVR [194], transferência método de função [198], ARIMA [196], abordagem de sistema especialista baseado em conhecimento (KBES) [196], modelo de estimativa Bayesiana [196], Algoritmos de busca baseados em caos [196], teoria de Vapnik-Chernoverkis (VC) [199], algoritmo genético (GA) [196], vetor de suporte Regressão (SVR) [200], Aprendizado de máquina [201], Modelo de previsão de etapa única [200], Fuzzy C-Means [201], Neuro Adaptive Sistema de Inferência Fuzzy (ANFIS) [201], Modelos de regressão não linear [202], Máquina de vetores de suporte a mínimos quadrados (LS-SVM) [201], Método orientado a dados [203], Sistema de inferência difusa baseado em rede adaptável a algoritmo genético (GA-ANFIS) [203]
Programas	EnergyPlus, IDA-ICE, ESP-r, Clim2000, Trnsys, Matlab
Aplicação e uso	Eficiência não linear de dados climáticos e desempenho energético do edifício, o SVM é alcançável e apropriado no prognóstico das contas periódicas da discoteca do senhorio, Empregada pela rede neural convencional, Demanda de carga de aquecimento e refrigeração do edifício
Vantagens	predição Minimização do risco de estrutura, SVM se esforça para diminuir um limite inferior e superior do erro, útil para direcionar problemas gerais de regressão e classificação de alvos, cálculo de eletricidade aterrado, informações muito simples por entradas, Incorporação de impactos socioeconômicos e macroeconômicos, Verificação de cada uso final de energia por variedade, classificação, etc., inclinações das bússolas

interpretação de agrupamento, determinação de todas as variáveis praticadas em qual desenvolver protótipos. As revisões de pesquisa dos modelos são fornecidos abaixo.

3.1. Abordagens baseadas em mineração de dados de caixa branca de previsão de energia

O aprimoramento das técnicas de caixa branca para um planejamento intacto ativo de construção residencial exigiria uma medida substancial de tempo para simular o comportamento de construção do indivíduo. Além disso exigiria uma extensa coleta de dados para garantir que o cálculo da resposta energética do edifício seja adequadamente detalhado. o a responsabilidade de construção de energia nas áreas da cidade é especificada como um branco abordagens de caixa para simular o padrão de energia do edifício, descrito arquétipos; estes são produzidos mais tarde uma associação explícita e precisa das várias propriedades físicas gerais de diversos tipos de casas que exibem semelhanças [204-206].

Este esquema investiga uma parte menor do comportamento de estoque de energia do edifício, fornecendo gerenciamento de energia do edifício em brevemente, que além disso mantém a capacidade de discriminar a eficiência energética do edifício do portfólio intacto satisfatoriamente. Além disso, a ordem de construir estoque de energia com ereções características reconhecidas pelo desenvolvimento de (algoritmos de benchmarking) a nível distrital ou local. o O benefício diferente desta proposição está na probabilidade de avaliar misteriosas medidas de economia de eletricidade de retrofit e associar, situações potenciais para a cidade restante [207].

3.2. Abordagens de mineração de dados de caixa cinza

Métodos ou modelos de caixa cinza [208-211] integram conhecimento passado com informações de abordagem física derivadas da energia

fontes de dados de consumo. Os algoritmos de caixa cinza são tipicamente compostos por uma estrutura híbrida que assimila abordagens orientadas a dados bem como a física de primeiro princípio. Eles também incluem vantagens como deficiências dos métodos preto e branco e caixa. No maior número de técnicas de grande ou grande escala, a propriedade do edifício é sintetizada de acordo com uma analogia de um caminho de energia, onde uma sucessão diminuída 'Resistência-Capacitância (RC)' é capaz de estabelecer e especificar a potência desempenho do sector da construção [212].

3.3. Abordagens baseadas em mineração de dados de caixa preta

Uma extensa quantidade de caixas pretas aborda a construção aplicada A investigação de consumo de energia de nível superior prevê o comportamento do uso de eletricidade em um LS de edifícios em vez de um único edifício. E embora as abordagens de caixa preta obtenham uso extensivo de energia consumo, de acordo com a variedade de entradas de dados hierarquicamente significativas [213-215], diferentes exemplos de aplicabilidade dessas estratégias em larga escala apresentadas na referência [216,217]. Os métodos convencionais de caixa preta amplamente utilizados para previsão e previsão no setor de construção são [218]: MLR, o modelo de regressão simples, ANN, árvores de decisão (DT) e vetor de suporte máquina. As abordagens baseadas em dados dependem do acessibilidade de dados anteriores de uso de eletricidade para prever a eficiência e o desempenho da energia.

Com base nesse desafio, é fundamental desenvolver um padrão para treinar os diferentes métodos. Outra questão surge, porém, em que a privacidade da política de dados e assuntos financeiros resultam em dificuldade com o processo de coleta, muitas vezes diminuindo a qualidade de decisões. O arranjo de erudição geográfica está emergindo como um

Tabela 9
Resumo da previsão de energia do setor de construção usando abordagens baseadas em larga escala.

Categoria do modelo	Previsão de energia do setor de construção usando abordagens baseadas em larga escala
Abordagens baseadas em mineração de dados de caixa branca de previsão de energia, abordagens baseadas em mineração de dados de caixa cinza, abordagens baseadas em mineração de dados de caixa preta	
Modelo de previsão	Modelo simplificado [212], Método orientado a dados (caixa preta) [210], Engenharia simplificada [215], Modelos de regressão [206], FCM modelos [214], modelo linear [210], método de agrupamento hierárquico [214], os modelos matemáticos [208], modelos NARX [217], Modelo arquetípico paramétrico [206], método GMDH convencional [215], algoritmo de otimização de colônia de formigas [214], estado estacionário modelos [212], métodos explícitos de Euler [208], modelos de parâmetros concentrados [210], método CDA [218], métodos da série de Fourier [208], Abordagem empírica [224], técnicas de Sistemas de Informação Geográfica (GIS) [220], ferramentas de simulação orientadas para a cidade [212], Elaborar métodos de engenharia [215], algoritmo K-means [214], máquinas de vetor de suporte (SVM) [213], modelo de dois nós [208], Métodos baseados em modelo [214], Modelo de rede nodal [212], Modelos ascendentes [218], Análise de demanda condicional [218], Térmica modelos de rede [211], método de Moore [212], modelo físico [208], modelos ARX [210], modelo ARX linear [217], dois modelos paramétricos condicionais [210], modelo ARX não linear [217], modelo físico de conhecimento completo [212], linear e sistema invariante no tempo [212], princípio de minimização de risco empírico (ERM) [213], abordagens baseadas em engenharia [222], Fuzzy c-means(FCM) [214], Método híbrido [215], Métodos hierárquicos [214], Métodos de particionamento [214], Abordagens estatísticas [224], Métodos baseados em densidade [214], agrupamento de refinamento iterativo [214], método híbrido de método de grupo de manipulação de dados (GMDH) [215], Least Square Support Vector Machine (LSSVM) [215], Abordagens de caixa preta [217], Métodos de Inteligência Artificial [215], Modelo autorregressivo não linear com entradas exógenas [217], algoritmos de mineração de dados [215], modelo GA [218], baseado em GIS abordagem de redução de escala estatística [222], Integração de modelos de dinâmica de sistemas [224]
Programas	TRNSYS, eQuest, IES e ESP-r, Energy Plus, DOE-2.1E, ESP-r, MATLAB, SPSS, R
Aplicação e uso	Aplicativos de simulação de energia de construção, Previsão de demanda de energia, Aplicação em análise de previsão fornece resultados promissores para prever o uso de eletricidade do edifício, usa informações de pesquisa simples e dados de faturamento, abrange tendências
Vantagens	Simples, eficiente e escalável, Fácil de implementar, Forte capacidade de antinômias, Pode reconhecer os inúmeros recursos vitais incluindo auto-estabilidade, pode ser implementado sem nenhum problema, a rede pode executar a tarefa que um programa linear não pode, Pode ser executado em qualquer aplicação, os modelos de previsão de energia em larga escala podem aprender e não precisam ser programados, Previsão de longo prazo na inadequação de cada descontinuidade, Compreende a resposta do habitante, Adição de fatores socioeconômicos e impactos macroeconômicos, Inclusão de efeitos macroeconômicos e socioeconômicos, Determinação de energia de uso final típico contribuição, informações de entrada simples, verificação de qualidades de uso final compreende em simulação, verificação de cada o uso de eletricidade do consumidor por fúria, tipo, etc.,

fonte cada vez mais significativa na qual produz energia em larga escala métodos. Isso ocorre porque suas capacidades de visualização e alocando conforme apresentado nas referências [219-222]. Embora os desafios continuem aqui também, uma vez que um número limitado de bancos de dados GIS inclui recursos apropriados para captar a energia realização de consumo de uma vila ou cidade. Outros dados pertinentes conjuntos incluem: censo [223], reservas nacionais [224], padronização [224], inquéritos locais e nacionais [225], inquéritos [219] e dados ambientais. Ultimamente, diferentes novas técnicas de coleta de erudição, como fontes de dados de energia em massa, surgiram para desenvolver e preencher bancos de dados de cidades inteiras [226–229]. Novo e conhecimentos diferentes precisam ser concentrados, no entanto, o que depende das metodologias de previsão de energia. Aqui o os elementos mais relevantes são: limite de desenvolvimento, emprego (superfície/volume), quantidade de pisos, orientação, fator de superfície/vidro, quantidade tão grande de pisos diferentes, proteção solar, orientação, janelas uso de eletricidade da área em nível agregado ou nível de construção, erudição de medidas de eletricidade e dados ambientais. A Tabela 9 mostra o resumo da previsão de energia do setor de construção usando grande escala abordagens baseadas.

4. Conclusão

Inúmeras tentativas foram alistadas para compor em larga escala construção de abordagens de uso de energia em vários níveis de funcionalidade e granularidade. Uma série de várias abordagens foi criada com esta intenção. Abordagens baseadas em dados e em grande escala construir modelos de previsão de energia para oferecer uma equivalência adequada entre diminuir o tempo necessário para desenvolver o método em o tempo de sustentar um nível de precisão aceitável. Nesta revisão, modelos de previsão de demanda de energia de edifícios foi revisto em detalhe onde se descobriu que cada país está engajado em preparação abrangente de eletricidade e planejamento para seu avanço sustentável. Os métodos ilustrados neste artigo de revisão são amplamente empregado no setor de construção, mas sua aplicabilidade em grande escala produz menos resultados. O estudo, resumido em duas categorias principais, é:

- 1. Abordagens baseadas em dados.
- 2. Abordagens de previsão energética de edifícios em grande escala.

A abordagem baseada em dados é dividida em quatro tipos: (a) redes neurais artificiais; (b) estatística e máquina modelos de aprendizagem; (c) redes neurais artificiais; (d) máquina de vetor de suporte; (e) agrupamento igualmente aos modelos base. Cada tipo inclui quatro subcategorias: (i) previsão de energia; (ii) ping do mapa de energia; (iii) benchmarking; (iv) perfil energético. Descobriu-se que agregados de várias abordagens são aplicados em escala para prever o uso futuro de eletricidade e compensar a escassez de dados existentes sob a forma de consumo de energia e parâmetros climáticos. As abordagens de avaliação revelaram que algumas abordagens baseadas em dados famosamente observadas, como máquina de vetor de suporte e rede neural artificial são silencioso não empregado em grande escala que poderia apresentar conhecimento abrangente sobre o consumo de energia do edifício estoque. Isso é compreensível, reconhecendo o tremendo nível de especificação de dados de construção específicos que são necessários para criar esses padrões. Da análise e descrição anteriores, entende-se que um quantidade substancial de estimativas e cálculos são necessários para estimar a eficiência energética e o desempenho no ambiente do edifício, do nível do edifício ao nível do subsistema e também nacional e nível regional. De Algoritmos Individualmente, contém seus benefícios em diversas circunstâncias de assiduidade. Os modelos de produção de energia em larga escala apresentam variações significativas. Vários outros as remunerações podem ser associadas à expansão deste algoritmo. Isto observa-se que as abordagens baseadas em dados são apropriadas para estimativas precisas e exatas. Em contradição, ao somar políticas significativas, o acesso à melhoria ao mesmo tempo em que sustenta a precisão do modelo. Redes neurais artificiais e máquinas vetoriais de suporte são excelentes na determinação de obstáculos não lineares, executando-os muito apropriados para a previsão de energia na edificação meio Ambiente. Eles podem fornecer o prognóstico profundamente realista, e a seleção do modelo com configuração variável é adequadamente implementado. A máquina de vetores de suporte mostra, ainda mais, mais alto desempenho de previsão do que ANN. A nível distrital, a estrutura baseada em dados exige uma infiltração substancial dos dispositivos de medição de eletricidade e circunstâncias para analisar os dados de consumo de energia únicos do ativos de construção inteiros; certas contingências, no entanto, não são lidas

está disponível. Fica estabelecido que as abordagens associam energia, economia e condições climáticas para o planejamento sustentável da futura utilização de energia. Prevê-se que as abordagens mencionadas anteriormente permitirão aos planejadores de eletricidade delinear com precisão e precisão os aspectos futuros. Pesquisas adicionais sobre as plausibilidades de abordagens baseadas em dados e em larga escala são necessárias para explicar questões tão significativas como (i) por que é concebível produzir erudição precisa para edifícios descritos por vários padrões de dados de consumo de energia acessíveis?

Reconhecimentos

O autor agradece o apoio da 'Fundação Nacional de Ciências Naturais da China' (Grant 51576074 e 51328602).

Referências

- [1] W. Zeyu, SS Ravi, Uma revisão da previsão de uso de energia de construção baseada em inteligência artificial: Contrastando as capacidades de modelos de previsão únicos e conjuntos, *Renew. Sustentar. Energia Rev.* 75 (2017) 796–808 75.
- [2] T. Catalina, V. Iordache, B. Caracaleanu, Modelo de regressão múltipla para previsão rápida da demanda de energia de aquecimento, *Energy Build.* 57 (2013) 302–312.
- [3] SS Kwok, RK Yuen, EW Lee, Uma abordagem inteligente para avaliar o efeito da ocupação do edifício na previsão da carga de resfriamento do edifício, *Build. Ambiente.* 46 (8) (2011) 1681–1690.
- [4] D. Chirag, Z. Fan, Y. Junjing, EL Siew, WS Kwok, Uma revisão da previsão de uso de energia em edifícios baseados em inteligência artificial: Contrastando as capacidades de modelos de previsão simples e de conjunto, *Renew. Sustentar. Energia Rev.* 78 (2017) 796–808.
- [5] B. Yildiz, JI Bilbao, AB Sproul, Uma revisão e análise de regressão e modelos de aprendizado de máquina na previsão de carga de eletricidade de edifícios comerciais, *Renew. Sustentar. Energia Rev.* 73 (2017) 1104–1122.
- [6] J. Phil, P. Joanne, L. Simon, Modelagem do ambiente construído em escala urbana – Impactos de energia e saúde em relação à habitação, *Landscape Urban Plann.* (2007) 39–49.
- [7] A. Fouquier, S. Robert, F. Suard, L. Stephan, A. Jay, Estado da arte em modelagem de construção e previsão de desempenho de energia: uma revisão, *Renew. Sustentar. Energia Rev.* 23 (2013) 272–288.
- [8] L. Suganthi, AA Samuel, Modelos de energia para previsão de demanda-uma revisão, *Renovo. Sustentar. Energia Rev.* 16 (2012) 1223–1240.
- [9] VSKV Harish, A. Kumar, Uma revisão sobre modelagem e simulação de sistemas de energia de edifícios, *Renew. Sustentar. Energia Rev.* 56 (2016) 1272–1292.
- [10] AS Ahmad, MY Hassan, MP Abdullah, HA Rahman, F. Hussin, H. Abdullah, et al., Uma revisão sobre as aplicações de ANN e SVM para a construção de previsão de consumo de energia elétrica, *Renew. Sustentar. Energia Rev.* 33 (2014) 102–109.
- [11] A. Fouquier, S. Robert, F. Suard, L. Stéphan, A. Jay, Estado da arte em modelagem de construção e previsão de desempenhos energéticos: uma revisão, *Renew. Sustentar. Energia Rev.* 23 (2013) 272–288.
- [12] C. Robinson, B. Dilkina, J. Hubbs, W. Zhang, S. Guhathakurta, Mari lynA. Brown, Ram M. Pendyala, Abordagens de aprendizado de máquina para estimar o consumo de energia em edifícios comerciais, *Appl. Energia* 08 (2017) 889–904.
- [13] Z. Li, G. Huang, Reavaliação de modelos de previsão de carga de resfriamento de edifícios para uso em área subtropical úmida, *Energy Build.* 62 (2013) 442–449.
- [14] Y. Zhang, Z. Neill, B. Dong, G. Augenbroe, Comparações de abordagens de modelagem inversa para prever o desempenho energético de edifícios, *Build. Ambiente.* 86 (2015) 177–190.
- [15] M. Leung, NC Tse, L. Lai, T. Chow, O uso da demanda de energia elétrica do espaço de ocupação na previsão de carga de resfriamento de edifícios, *Energy Build.* 55 (2012) 151–163.
- [16] JS Chou, DK Bui, Modelagem de cargas de aquecimento e resfriamento por inteligência artificial para projetos de edifícios com eficiência energética, *Energy Build.* (2014) 437–447.
- [17] RE Edwards, J. New, LE Parker, Predizendo o futuro consumo de eletricidade residencial por hora: um estudo de caso de aprendizado de máquina, *Energy Build.* (2012) 591–603.
- [18] RZ Jovanovic, AA Sretenovic, BD Živkovic, Conjunto de várias redes neurais para previsão do consumo de energia de aquecimento, *Energy Build.* 91 (2015) 189–199.
- [19] J. Massana, C. Pous, L. Burgas, J. Melendez, J. Colomer, Forecast de carga de curto prazo em um edifício não residencial contrastando modelos e atributos, *Energy Build.* 92 (2015) 322–330.
- [20] D. Monfet, M. Corsi, D. Choiniere, E. Arkipova, Desenvolvimento de uma ferramenta de previsão de energia para edifícios comerciais usando raciocínio baseado em casos, *Energy Build.* 81 (2014) 152–160.
- [21] R. Platon, VR Dehkordi, J. Martel, Previsão horária do consumo de eletricidade de um edifício usando raciocínio baseado em casos, redes neurais artificiais e análise de componentes principais, *Energy Build.* 92 (2015) 10–18.
- [22] R. Mena, F. Rodríguez, M. Castilla, M. Arahah, Um modelo de previsão baseado em redes neurais para o consumo de energia de um edifício bioclimático, *Energy Build.* 82 (2014) 142–155.
- [23] X. Lv, T. Lu, CJ Kibert, M. Viljanen, Uma nova abordagem de modelagem dinâmica para prever o desempenho energético do edifício, *Appl. Energia* 114 (2014) 91–103.
- [24] EG Escrivá, CB Álvarez, CB Roldán, OM Alcázar, Novo método de previsão de rede neural artificial para previsão de consumo elétrico baseado em usos finais de construção, *Energy Build.* 43 (2011) 3112–3119.
- [25] J. Wu, J. Wang, H. Lu, Y. Dong, X. Lu, Técnica de previsão de carga de curto prazo baseada no método de ajuste exponencial sazonal e no modelo de regressão, *Energy Conversion Manag.* 70 (2013) 1–9.
- [26] FWH Yik, J. Burnett, I. Prescott, Previsão do consumo de energia do ar condicionado de um grupo de edifícios usando diferentes métodos de rejeição de calor, *Energy Build.* 33 (2) (2001) 151–166.
- [27] B. Howard, L. Marshall, J. Thompson, S. Hammer, J. Dickinson, V. Modi, distribuição espacial do consumo de energia do edifício urbano por uso final, *Energy Build.* 45 (2012) 141–151.
- [28] C. Yang, S. Létourneau, H. Guo, Desenvolvendo modelos baseados em dados para prever o consumo de energia de BEMs para sistemas de resposta à demanda, *Notas de Palestra Com put. Sci.* 8481 (1) (2014) 188–197.
- [29] T. Hong, L. Yang, D. Hill, W. Feng, Dados e análises para informar o retrofit de energia de edifícios de alto desempenho, *Appl. Energia* 126 (2014) 90–106.
- [30] M. Yalcintas, OU Aytun, Um modelo de benchmarking de energia baseado no método de rede neural artificial utilizando o banco de dados de pesquisa de consumo de energia de edifícios comerciais dos EUA (CBCECS), *Int. J. Energia Res.* 31 (4) (2007) 412–421.
- [31] M. Yalcintas, Um modelo de benchmarking de energia baseado no método de rede neural artificial com um exemplo de caso para climas tropicais, *Int. J. Energia Res.* 30 (14) (2006) 1158–1174.
- [32] C. Fan, F. Xiao, S. Wang, Desenvolvimento de modelos de previsão para consumo de energia de construção no dia seguinte e demanda de energia de pico usando técnicas de mineração de dados, *Appl. Energia* 127 (2014) 1–10.
- [33] Diretiva da UE 95/46/EC, 2012/148/EU2014/724/UE: Recomendação da Comissão de 10 de outubro de 2014 sobre o modelo de avaliação do impacto da proteção de dados para redes inteligentes e sistemas de medição inteligentes.
- [34] H. Drucker, CJ Burges, L. Kaufman, A. Smola, V. Vapnik, Máquinas de regressão vetorial de suporte, *Adv. Inf. Processo Sist.* (1997) 155–161.
- [35] P. Franches, R. Paap, Modelos de Séries Temporais Periódicas, Oxford University Press, 2003.
- [36] CM Bishop, Reconhecimento de Padrões e Aprendizado de Máquina, Springer, Cingapura, 2006.
- [37] TG Nikolaou, DS Kolokotsa, GS Stavrakakis, ID Skias, Sobre a aplicação de técnicas de agrupamento para classificação energética e de conforto térmico de edifícios de escritórios, rede inteligente, *IEEE Trans.* 3 (4) (2012) 2196–2210.
- [38] X. Gao, A. Malkawi, Uma nova metodologia para a construção de benchmarking de desempenho energético: uma abordagem baseada no algoritmo de agrupamento inteligente, *Energy Build.* 84 (2014) 607–616.
- [39] L. Arambula, P. Romagnoli, A. Gasparella, Seleção de edifícios representativos por meio de análise preliminar de cluster, Conferência Internacional de Edifícios de Alto Desempenho, 2014.
- [40] M. Heidarinejad, M. Dahlhausen, S. McMahon, C. Pyke, J. Srebric, Análise de cluster de uso de energia simulada para edifícios de escritórios com certificação LEED nos EUA, *Energy Build.* 85 (2014) 86–97.
- [41] N. Gaitani, C. Lehmann, M. Santamouris, G. Mihalakakou, P. Patargias, Using main component and cluster analysis in the heat assessment of the school building sector, *Applied Energy* 87 (6) (2010) 2079–2086.
- [42] D. Hsu, Caracterizando o uso de energia em edifícios comerciais e multifamiliares da cidade de Nova York, ACEEE Summer Study on Energy Efficiency in Buildings, 2012.
- [43] S. Banihashemi, G. Ding, J. Wang, Desenvolvendo um modelo híbrido de algoritmos de previsão e classificação para o consumo de energia em edifícios, *Energy Proc.* 110 (2017) 371–376.
- [44] K. Fatai, L. Oxley, FG Scrimgeour, Modelagem e previsão da demanda por eletricidade na Nova Zelândia: uma comparação de abordagens alternativas, *Energy J.* 24 (1) (2003) 75–102.
- [45] C. Hamzac, Previsão do consumo líquido de energia elétrica da Turquia em sec para bases, *Política Energética* 35 (3) (2007) 2009–2016.
- [46] KJ Baker, RM Rylatt, Melhorando a previsão da demanda doméstica de energia do Reino Unido usando dados de consumo anual, *Appl. Energia* 85 (6) (2008) 475–482.
- [47] S. Siitonen, M. Tuomaala, M. Suominen, P. Ahlta, Implicações de melhorias de eficiência energética de processo para consumo de energia primária e emissões de CO2 a nível nacional, *Appl. Energia* 87 (9) (2010) 2928–2937.
- [48] M. Espinoza, C. Joye, R. Belmans, Previsão de carga de curto prazo, identificação de perfil e segmentação de clientes: Uma metodologia baseada em séries temporais periódicas, *IEEE Trans. Sistema de energia* 20 (3) (2005) 1622–1630.
- [49] IP Panapakidis, TA Papadopoulos, GC Christoforidis, GK Papagiannis, Algoritmos de reconhecimento de padrões para análise da curva de carga elétrica de edifícios, *Energy Build.* 73 (2014) 137–145.
- [50] JW Taylor, Previsão de carga de curto prazo com metodologia exponencialmente ponderada ods, *IEEE Trans. Sistema de energia* 27 (1) (2012) 673–679.
- [51] DW Bunn, ED Farmer, Modelos Comparativos para Previsão de Carga Elétrica, Wiley, 1985.
- [52] W. Mingwu, W. Dongfang, L. Jian, J. Hui, J. Juliang, Um novo modelo de agrupamento baseado na análise de pares de conjuntos para a previsão de consumo de energia na China, *Math. Problemas Eng.* 8 (2014) 191–242.
- [53] MW Wang, JL Jin, YL Zhou, Métodos e aplicações de acoplamento baseados em análise de pares, Science Press, Pequim, China, 2014.
- [54] Dong Wang, Alistair G. Borthwick, Handan He, Yuankun Wang, Jieyu Zhu, Yuan Lu, Pengcheng Xu, Xiankui Zeng, Jichun Wu, Lachun Wang, Xinqing Zou, Jiufu Liu, Ying Zou, Ruimin He, A híbrida wavelet de -abordagem de análise de pares de ruído e Rank-Set para previsão de séries temporais hidrometeorológicas, *Environ. Res.* 160 (2018) 269–281.

- [55] União Europeia, Diretiva 2002/91/CE do Parlamento Europeu e do Conselho sobre o desempenho energético dos edifícios, dezembro (2002), 2002.
- [56] ZH Zhan, J. Zhang, Y. Li, HSH Chung, otimização de enxame de partículas adaptável, IEEE Trans. Sistema Homem Cybernet. Parte B 39 (dezembro de 2009) 1362–1381.
- [57] Jones, et al., Planejamento para uma cidade sustentável: um modelo de previsão energética e ambiental, J. Environ. Plano Gerenciado 43 (6) (2000) 855–872.
- [58] ODPM, Reforming the Home Buyselling Process in England and Wales Contents of the Home Information Pack a Consultation, HMSO, Londres, 2003.
- [59] H. Zhao, F. Magoulès, Uma revisão sobre a previsão do consumo de energia em edifícios, Renew. Sustentar. Energia Rev. 16 (2012) 3586–3592.
- [60] Welsh Assembly Government, The Welsh Housing Quality Standard-Guidance for Local Authorities on the Assessment Process and Achievement of the Standard, Welsh Assembly Government, 2002.
- [61] M. Munson, G. Jaskulski, C. Thomas, Se essas paredes pudessem pensar, IEEE PowerEn ergia Mag. 9 (2011) 50–55.
- [62] JL Mathieu, PN Price, S. Kiliccote, MA Plette, Quantificando mudanças no uso de eletricidade em edifícios, com aplicação à resposta à demanda, IEEE Trans. Rede Inteligente 2 (2011) 507–518.
- [63] OM Masoso, LG Grobler, The dark side of occupants' behavior on building use of energy, Energy Build. 42 (2007) 173–177.
- [64] GJ Tsekouras, ND Hatzigiorgiou, EN Dyalinas, Reconhecimento padrão de duas fases de curvas de carga para classificação de clientes de eletricidade, IEEE Trans. Sistema de energia 22 (2007) 1120–1128.
- [65] IP Panapakidis, MC Alexiadis, GK Papagiannis, Perfil de carga nos mercados de eletricidade desregulamentados: uma análise das aplicações, em: Proc. da 9ª Conferência Internacional sobre o Mercado Europeu de Energia, 2012, pp. 1–8.
- [66] G. Chicco, R. Napoli, F. Piglion, Comparações entre técnicas de agrupamento para classificação de clientes de eletricidade, IEEE Trans. Sistema de energia 21 (2006) 933–940.
- [67] JJ López, JA Aguado, F. Martín, F. Muñoz, A. Rodríguez, JE Ruiz, algoritmo de agrupamento Hopfield–K-Means: uma proposta para a segmentação de clientes de eletricidade, Electric Power Syst. Res. 81 (2011) 716–722.
- [68] A. Mutanen, M. Ruska, S. Repo, P. Järventausta, Método de perfilagem de carga de classificação do cliente para sistemas de distribuição, IEEE Trans. Fornecimento de energia 26 (2011) 1755–1763.
- [69] G. Chicco, IS Ilie, Agrupamento de vetores de suporte de dados de padrão de carga elétrica, Trans. IEEE Sistema de energia 24 (2009) 1619–1628.
- [70] C. Cortes, VN Vapnik, Redes de vetores de suporte, Aprendizado de máquina. 20 (1995) 273–297.
- [71] P. Domingos, M. Pazzani, Sobre a otimalidade do classificador Bayesiano simples sob perda zero-um, Aprendizado de Máquina. 29 (1997) 103–137.
- [72] E. Carpaneto, G. Chicco, R. Napoli, M. Scutariu, Classificação do consumidor de eletricidade usando dados de padrão de carga no domínio da frequência, Int. J. Elétrica. Sistema de energia de energia 28 (2006) 13–20.
- [73] K. Moslehi, R. Kumar, Uma perspectiva de confiabilidade da rede inteligente, Smart Grid, IEEE Trans. 57 (1) (2010) 64.
- [74] JW Taylor, Métodos sazonais tripos para previsão de demanda de eletricidade de curto prazo, Eur. J. Oper. Res. 204 (1) (2010) 139–152.
- [75] HS Hippert, CE Pedreira, RC Souza, Redes neurais para previsão de carga de curto prazo: uma revisão e avaliação, sistemas de potência, IEEE Trans. 16 (1) (2001) 44–55.
- [76] N. Sapankevych, R. Sankar, Previsão de séries temporais usando máquinas de vetor de suporte: uma pesquisa, Comput. Intel. Mag. 4 (2) (2009) 24–38.
- [77] Y. Ji, J. Hao, N. Reyhani, A. Lendasse, Previsão direta e recursiva de séries temporais usando seleção de informações mútuas, em: Inteligência Computacional e Sistemas Bioinspirados, Springer, 2005, pp. 1010–1017.
- [78] DC Sansom, TK Saha, Despacho de geração restrita de energia com base em previsões de preços, incluindo valores esperados e risco, em: Assembleia Geral da Sociedade de Engenharia de Energia, 2004, pp. 261–266.
- [79] BJ Chen, MW Chang, et al., Previsão de carga usando máquinas de vetor de suporte: um estudo sobre a competição EUNITE, Power Syst. Trans. IEEE 19 (4) (2004) 1821–1830.
- [80] KW Tri, H. Samuel, V. Matteo, A. Karl, Previsão de carga elétrica residencial: avaliação de previsões individuais e agregadas.
- [81] D. Wu, Y. Ke, J. Yu, P. Yu, L. Chen, Detectando líderes de séries temporais correlacionadas, em: H. Kitagawa, Y. Ishikawa, Q. Li, C. Watanabe (Eds.), Sistemas de Banco de Dados para Aplicações Avançadas de Notas de Aula em Ciência da Computação, Springer, Berlin Heidelberg, 2010, pp. 352–367.
- [82] PJM, Análise Empírica de Métodos de Linha de Base de Resposta à Demanda. (abril de 2011) Papel branco.
- [83] A linha de base da resposta à demanda, White Paper (2011).
- [84] R. Weron, A. Misiorek, Previsão de preços de eletricidade à vista: uma comparação de modelos de séries temporais paramétricos e semiparamétricos, Int. J. Previsão 24 (2008) 744–763.
- [85] AJ Conejo, J. Contreras, R. Espinola, M. Plazas, Previsão de preços de eletricidade para um mercado de energia elétrica baseado em pool para o dia seguinte, Int. J. Previsão 21 (2005) 435–462.
- [86] FJ Nogales, J. Contreras, AJ Conejo, R. Espfnola, Previsão de preços de eletricidade no dia seguinte por modelos de séries temporais, IEEE Trans. Sistema de energia 17 (2) (2002) 342–348.
- [87] K. Skytte, O mercado de energia regulador na bolsa de energia nórdica Nord Pool: uma análise econométrica, Energy Econ. 21 (4) (1999) 295–08.
- [88] SE Fleten, E. Pettersen, Construindo curvas de licitação para um varejista de tomada de preços no mercado de eletricidade norueguês, IEEE Trans. Sistema de energia 20 (2) (2005) 701–08.
- [89] M. Olsson, L. Söder, Modelagem de preços de mercado de energia de balanceamento em tempo real usando processos combinados SARIMAMarkov, IEEE Trans. Sistema de energia 23 (2) (2008) 443–450.
- [90] S. Jaehnert, H. Farahmand, GL Doorman, Modelagem de preços usando o volume no mercado regulatório de energia norueguês, IEEE PowerTech, Bucareste, 2009.
- [91] MO Brolin, L. Söder, Modelagem de preços de energia de balanceamento em tempo real suecos usando modelos de séries temporais não lineares, em: IEEE 11th International Conference on Probabilistic Methods Applied to Power Systems, 2010, pp. 358–363.
- [92] TK Boomsma, N. Juul, SE Fleten, Licitação em mercados de eletricidade sequenciais: o caso nórdico, No.6, Stochastic Programming E-Print Series, Institute fur Mathematic, 2013.
- [93] K. Gro, L. Anders, SEF Eriksrud, modelos de previsão baseados em séries temporais de benchmarking para preços de mercado de equilíbrio de eletricidade, Energy Syst. 6 (2015) 43–61.
- [94] L. Swan, V. Ugursal, Modelagem do consumo final de energia no setor residencial: uma revisão das técnicas de modelagem, Renew. Sustentar. Energia Rev. 13 (2009) 1819–1835.
- [95] E. Hirst, A model of residencial energy use, Simulation 30 (3) (1978) 69–74.
- [96] GP Saha, J. Stephenson, Um modelo de uso residencial de energia na Nova Zelândia, Energia 5 (2) (1980) 167–175.
- [97] J. Bentzen, T. Engsted, Um revival do modelo de atraso distribuído autoregressivo na estimativa de relações de demanda de energia, Energia 26 (1) (2001) 45–55.
- [98] E. Mata, AS Kalagasidis, F. Johnsson, Uma estratégia de modelagem para energia, carbono e avaliações de custos de estoques de edifícios, Energy Build. 56 (2013) 100–08.
- [99] GV Fracastoro, M. Serraino, Metodologia para avaliação do desempenho energético de estoques de edifícios de grande porte e possíveis aplicações, Energy Build. 43 (2011) 844–852.
- [100] W. Tian, R. Choudari, Um modelo de energia probabilística para setores de construção não domésticos aplicado à análise de edifícios escolares na grande Londres, Energy Build. 54 (2012) 01–11.
- [101] S. Guerra, L. Itard, H. Visscher, O efeito da ocupação e características do edifício sobre o uso de energia para aquecimento de espaço e água no estoque residencial holandês, Energy Build. 41 (2009) 1223–1232.
- [102] KJ Baker, RM Rylatt, Melhorando a previsão da demanda doméstica de energia do Reino Unido usando dados de consumo anual, Appl. Energia 85 (2008) 475–482.
- [103] P. Caputo, G. Costa, S. Ferrari, Um método de apoio à definição de estratégias energéticas no setor da construção à escala urbana, Energy Policy 55 (2013) 261–270.
- [104] I. Theodoridou, M. Karteris, G. Mallinis, AM Papadopoulos, M. Hegger, Avaliação de medidas de retrofitting e potencial de sistemas solares em áreas urbanas usando sistemas de informação geográfica: aplicação a uma cidade mediterrânea, Renew. Sustentar. Energia Rev. 16 (2012) 6239–6261.
- [105] S. Heiple, DJ Sailor, Usando simulação de energia de edifícios e técnicas de modelagem geoespacial para determinar perfis de consumo de energia de alta resolução no setor de edifícios, Energy Build. 40 (2008) 1426–1436.
- [106] B. Howard, L. Parshall, C. Thompson, S. Hammer, J. Dickinson, V. Modi, distribuição espacial do consumo de energia do edifício urbano por uso final, Energy Build. 45 (2012) 141–151.
- [107] AM Rotterdam, B. Olivier, S. Francesca, L. Ulrich, Estimativa de economia de energia para o estoque de edifícios residenciais de uma cidade inteira: uma abordagem de redução estatística baseada em GIS aplicada a Roterdã, Energy Build. 75 (2014) 358–367.
- [108] DOE, Building energy data book, 2011 Disponível em <http://buildingsdatabook.eren.doe.gov/>. Acessado em 07/10, 2013.
- [109] W. Detlef, K. Scott, Características de consumo de energia de sistemas HVAC de edifícios comerciais, em: Volume I: Chillers Refrigerant Compressors, and Heating Systems, 2001, pp. 33745–33750.
- [110] W. Detlef, K. Scott, Características de consumo de energia de sistemas HVAC de edifícios comerciais, Volume II: Distribuição Térmica, Equipamento Auxiliar e Ventilação, 1999.
- [111] W. Grondzik, R. Furst, Hvac Components and Systems, Vital Signs Project, 2000.
- [112] A. Padrão, Padrão para o projeto de edifícios verdes de alto desempenho, exceto edifícios residenciais baixos, em: Sociedade Americana de Engenheiros de Aquecimento, Refrigeração e Ar Condicionado, Atlanta, GA, 2009, p. 189.
- [113] ASHRAE, Manual ASHRAE: Fundamentos, ASHRAE, Atlanta, GA, 2009.
- [114] US Energy Information Administration, Pesquisa de consumo de energia em edifícios comerciais - visão geral das características de edifícios comerciais, 2003 Disponível em <http://www.eia.doe.gov/emeu/cbecs/cbecs2003/introduction.html>. Acessado em dezembro (2013).
- [115] C. Duarte, DK Van, C.Rieger Wymelenberg, Revelando padrões de ocupação em um edifício de escritórios através do uso de dados de sensores de ocupação, Energy Build. 67 (2013) 587–595.
- [116] A. Norma, Norma energética para edifícios excepto edifícios residenciais de baixa altura, Alt. Soc. Aquecimento Refrigeração Ar Condicionado Engenheiros 90 (1) (2007).
- [117] D.Yan C.Wang, Y. Jiang, A Novel Approach For Building Occupancy Simulation Building Simulation, 4, Tsinghua Press, Pequim, China, 2011.
- [118] J. Page, D. Robinson, N. Morel, J. Scartezzini, Um modelo estocástico generalizado para a simulação da presença de ocupantes, Energy Build. 40 (2) (2008) 83–98.
- [119] D. Wang, CC Federspiel, F. Rubinstein, Modelagem de ocupação em uma única pessoa escritórios, Energy Build. 37 (2005) 121–126.
- [120] LJ Lo, A. Novoselac, Ar condicionado localizado com controle de ocupação em escritório aberto, Energy Build. 42 (7) (2010) 1108–1120.
- [121] Y. Zhu, M. Liu, T. Batten, H. Noboa, DE Claridge, WD Turner, Otimização de estratégias de controle para caixas de terminais HVAC, em: Proceedings of 12th Sym-

- posium sobre Melhoria de Sistemas de Construção em Climas Quentes e Úmidos, San Antonio, 2000, pp. 278–284.
- [122] GP Henze, C. Felsmann, G. Knabe, Avaliação do controle ótimo para armazenamento térmico ativo e passivo do edifício, *Int. J. Thermal Sci.* 43 (2) (2004) 173–183.
- [123] K. Deng, P. Barooah, GP Mehta, SP Meyn, Redução do modelo térmico de construção desagregação dos estados, em: American Control Conference (ACC), Baltimore, MD, IEEE, 2010, pp. 5118–5123.
- [124] F. Oldewurtel, A. Parisio, NC Jones, et al., Clima de construção eficiente em energia controle usando controle preditivo de modelo estocástico e previsões meteorológicas, em: Conferência Americana de Controle (ACC), IEEE, 2010, pp. 5100–5105.
- [125] Y. Ma, G. Anderson, F. Borrelli, Uma abordagem de controle preditivo distribuído para regulação da temperatura do edifício, em: American Control Conference (ACC), San Francisco, IEEE, 2011, pp. 2089–2094. (2011).
- [126] XN Truong, GJ Pappas, controle de supervisão do horizonte de recuo do verde edifícios, em: American Control Conference (ACC), San Francisco, IEEE, 2011, págs. 4416–4421.
- [127] A. Aswani, N. Master, J. Taneja, D. Culler, C. Tomlin, Redução de transientes e consumo de eletricidade em estado estacionário em HVAC usando modelo baseado em aprendizado –controle preditivo, *Proc. IEEE* 100 (1) (2012) 240–253.
- [128] G. Gao, K. Whitehouse, O termostato autoprogramável: otimizando o recuo horários baseados em padrões de ocupação residencial, em: Proceedings of the First Workshop ACM sobre Sistemas de Sensoriamento Incorporado para Eficiência Energética em Edifícios, Berkeley, CA, ACM, 2009, pp. 67–72. 04 a 06 de novembro.
- [129] Y. Zheng, BG Burcin, Os efeitos acoplados do perfil de ocupação personalizado cronogramas HVAC baseados e redistribuição de sala no uso de energia do edifício, *Energy Build.* 78 (2014) 113–122.
- [130] HS Hippert, CE Pedreira, RC Souza, Redes neurais para carga de curto prazo previsão: uma revisão e avaliação, *IEEE Trans. Sistema de energia* 16 (2001) 44–55.
- [131] ME Baran, HL Willis, Modelagem e previsão de carga elétrica horária por regressão linear múltipla com interações, em: IEEE PES Gen. Meet., IEEE, 2010, págs. 1–8.
- [132] LP Lombard, J. Ortiz, C. Pout, Uma revisão sobre o consumo de energia dos edifícios em formação, *Energy Build.* 40 (2008) 394–398.
- [133] E. Delzendeh, S. Wu, A. Lee, Y. Zhou, O impacto do comportamento dos ocupantes na análise de energia de edifícios: uma revisão de pesquisa, *Renew. Sustentar. Energia Rev.* 80 (2017) 1061–1071.
- [134] A. Fouquier, S. Robert, F. Suard, LA Stéphan, Estado da arte em construção modelagem e previsão de desempenhos energéticos: uma revisão, *Renew. Sustentar. Energia Rev.* 23 (2013) 272–288.
- [135] J. Yang, H. Rivard, R. Zmeureanu, Previsão de energia de construção on-line usando redes neurais artificiais adaptativas, *Energy Build.* 37 (2005) 1250–1259.
- [136] AH Neto, FAS Fiorelli, Comparação entre simulação de modelo detalhado e rede neural artificial para prever o consumo de energia do edifício, *Energia Construir.* 40 (2008) 2169–2176.
- [137] S. Karatasou, M. Santamouris, V. Geros, Modelagem e previsão de edifícios uso de energia com redes neurais artificiais: métodos e resultados, *Energia Construir.* 38 (2006) 949–958.
- [138] AS Ahmad, MY Hassan, MP Abdullah, HA Rahman, F. Hussin, H. Abdullah, et al., Uma revisão sobre aplicações de RNA e SVM para construção de energia elétrica previsão de consumo, *Renovar. Sustentar. Energia Rev.* 33 (2014) 102–109.
- [139] V. Aydinap, U. Ismet, AS Fung, Modelagem do aparelho, iluminação e consumos de energia de refrigeração de espaços no setor residencial usando redes neurais, *Appl. Energia* 71 (2002) 87–110.
- [140] M. Aydinap, IV Ugursal, AS Fung, Modelagem do espaço e doméstico consumo de energia para aquecimento de água quente no setor residencial usando redes, *Ap. Energia* 79 (2004) 159–178.
- [141] PA González, JM Zamarre, Previsão do consumo horário de energia em edifícios baseados em uma rede neural artificial de feedback, *Energy Build.* 37 (2005) 595–610.
- [142] G. Schenker, Controle de Previsão Usando Redes Neurais de Feedback e Parciais Modelos, Instituto Federal Suíço de Tecnologia, 1996.
- [143] A. Azadeh, SF Ghaderi, S. Sohrabkhani, Previsão anual de consumo de eletricidade por rede neural em setores industriais de alto consumo de energia, *Gerenciamento de conversão de energia.* 49 (2008) 2272–2278.
- [144] A. Azadeh, SF Ghaderi, S. Sohrabkhani, Previsão de consumo elétrico por integração de Rede Neural, séries temporais e ANOVA, *Appl. Matemática. Computar.* 186 (2007) 1753–1761.
- [145] R. Yokoyama, T. Wakui, R. Satake, Previsão de demandas de energia usando neural rede com identificação de modelo por otimização global, *Energy Conversion Gerenciar* 50 (2009) 319–327.
- [146] R. Yokoyama, Capacidade de pesquisa global e melhoria no método de corte modal para otimização global, *JSME Int. J. Ser. C* 48 (2005) 730–737.
- [147] D. Chirag, SE Lee, Y. Junjing, S. Matheos, previsão de energia de resfriamento diurna carga para edifícios institucionais usando Redes Neurais Artificiais, *Energy Build.* 121 (2016) 284–297.
- [148] N. Matson, MA Piette, Revisão da Califórnia e métodos nacionais para benchmarking de desempenho energético para edifícios comerciais, em: Comissão de Energia da Califórnia, Programa de Pesquisa de Energia de Interesse Público, LBNL, 2005, pág. 57364.
- [149] Yuan Y Liu, Min Yang, Malcolm Ramsay, Xiao S. Li, Jeremy W. Coid, A comparação de regressão logística, classificação e árvore de regressão e neural modelos de redes na previsão de reincidência violenta (2011) 27:547–573.
- [150] T Sharp, Benchmarking energy use in schools, in: Proceedings of the ACEEE 1998 Summer Study on Energy Efficiency in Building, 3, 1988, pp. 305–316.
- [151] TW Hicks, BN Von, Uma avaliação dos primeiros edifícios ENERGY STAR da América: a classe de 1999, em: Proceedings of the ACEEE 2003 Summer Study on Energy Efficiency in Buildings, 4, 2000, pp. 177–185.
- [152] C. Federspiel, Q. Zhang, E. Arens, Benchmarking baseado em modelo com aplicações em edifícios de laboratório, *Energy Build.* 34 (3) (2002) 203–214.
- [153] P. Mathew, D. Sartor, GO Van, S. Reilly, Avaliação de eficiência energética e sustentabilidade em laboratórios: resultados e lições do programa Labs21, em: Proceedings of the ACEEE 2003 Summer Study on Energy Efficiency in Buildings, 4, 2003, pp. 321–329.
- [154] Y. Melek, Um modelo de benchmarking de energia baseado em rede neural artificial método com um exemplo de caso para climas tropicais, *Int. J. Energia Res.* 30 (2006) 1158–1174.
- [155] V. Shabunko, CM Lim, S. Brahim, Desenvolvimento de benchmarking de construção para Brunei Darussalam, *Energy Build.* 85 (2014) 79–85.
- [156] SS Torbaghan, A. Motamedi, H. Zareipour, LA Tuan, Eletricidade de médio prazo previsão de preços, em: Proceedings of North American power symposium, 2012, pp. 1–08.
- [157] X. Yan, Previsão de preços de compensação do mercado de eletricidade em um mercado de eletricidade desregulamentado, Departamento da Universidade de Engenharia Elétrica, Saskatchewan, 2009.
- [158] X. Yan, NA Chowdhury, previsão de preços de compensação do mercado de eletricidade em um mercado de eletricidade desregulamentado, em: Anais da 11ª conferência internacional sobre métodos probabilísticos aplicados a sistemas de energia Cingapura, 2010, págs. 36–41.
- [159] X. Yan, NA Chowdhury, Previsão de Preços de Compensação do Mercado de Eletricidade em um Mercado desregulamentado: uma abordagem de rede neural, VDM Verlag, Alemanha, 2010.
- [160] SS Torghaban, H. Zareipour, LA Tuan, mercado de eletricidade de médio prazo previsão de preços: uma abordagem orientada por dados, em: Proceedings of North American simpósio de energia, 2010, pp. 1–7.
- [161] W. Sun, JC Lu, M. Meng, Aplicação do modelo SVM baseado em séries temporais em previsão do preço da eletricidade no dia seguinte no mercado de energia desregulamentado, em: Proc Conferência Internacional Mach Learn Cyber, 2006, pp. 2373–2388.
- [162] DM Zhou, F. Gao, XH Guan, Aplicação de vetor de suporte online preciso regressão na previsão do preço da energia, em: Anais do 5º Congresso Mundial sobre controle inteligente e automação, 2004, pp. 1838–1842.
- [163] LL Hu, G. Taylor, HB Wan, M. Irving, Uma revisão de eletricidade de curto prazo técnicas de previsão de preços em mercados de eletricidade desregulamentados, em: Anais da 44ª Conferência Internacional de Engenharia de Energia das Universidades, 2009, pp. 1–5.
- [164] RA Swief, YG Hegazy, TS Abdel-Salam, MA Bader, Máquinas de vetor de suporte (SVM) com base na previsão de carga-preço de eletricidade de curto prazo, em: Proceedings of the IEEE Bucharest PowerTech, 2009, pp. 1–5 .
- [165] LM Saini, SK Aggarwal, A. Kumar, Otimização de parâmetros usando genética algoritmo para suporte ao modelo de previsão de preços baseado em máquina vetorial no mercado nacional de eletricidade, *IET Generation Trans. Distribuir* 4 (2010) 36–49.
- [166] W. Sun, J. Zhang, Previsão de preços spot de eletricidade com base em GASVM, em: Proc International Conference Internet Computing Sci Engineering, 2008, pp. 73–88.
- [167] YG Chen, GW Ma, Previsão de preços de eletricidade com base no vetor de suporte máquina treinada por algoritmo genético, em: Anais do 3º Simpósio Internacional de Aplicação Inteligente de Tecnologia da Informação, 2, 2009, págs. 292–305.
- [168] MJ Mahjoob, M. Abdollahzade, R. Zarringhalam, LS-SVM otimizado baseado em GA previsão do preço da eletricidade de curto prazo em mercados de energia competitivos, em: Proceedings of the 3rd IEEE conference on industrial electronics and applications, 2008, pp. 73–88.
- [169] DS Gong, JX Che, JZ Wang, JZ Liang, Previsão de preços de eletricidade de curto prazo com base no novo SVM usando algoritmo de enxame de peixes artificiais sob energia desregulamentada, em: Anais do 2º simpósio internacional sobre aplicação de tecnologia de informação inteligente , 2008, pp. 85–99.
- [170] H. Zheng, LZ Zhang, L. Xie, X. Li, modelo SVM do sistema baseado no preço marginal em análise de componentes independentes desenvolvidos, em: Proc International Conference Power Systems Technology, 2004, pp. 1437–1440.
- [171] Y. Wang, SQ Yu, Previsão de preços pela ICA-SVM na eletricidade competitiva mercado, em: Proceedings of the 3rd IEEE Conference on Industrial Electronics e Aplicações, 2008, pp. 314–319.
- [172] JY Tian, Y. Lin, Previsão de preços de eletricidade de curto prazo com base em conjuntos aproximados e SVM melhorado, em: Anais do 2º Workshop Internacional sobre Descoberta de Conhecimento e Mineração de Dados, 2009, pp. 68–71.
- [173] T. Wang, LJ Qin, Aplicação do SVM com base no conjunto aproximado dos preços da eletricidade previsão, em: Proceedings of the 2010 International Conference on Environmental Science and Information Application Technology, 2010, pp. 317–320.
- [174] L. Xie, H. Zheng, LZ Zhang, Previsão de preços de eletricidade por cluster ing-LSSVM, em: Proceeding International Power Engineering Conference, 2007, págs. 697–702.
- [175] S. Fan, JR Liao, K. Kaneko, LN Chen, Um modelo de aprendizado de máquina integrado para previsão de preços de eletricidade com antecedência, em: Proceeding Power System Conference Expos, 2006, pp. 1643–1649.
- [176] S. Fan, C. Mao, L. Chen, Previsão do preço da eletricidade no dia seguinte usando um híbrido rede, *IET Generation Trans. Distribuir* 1 (2007) 176–182.
- [177] Y. Xing, AC Nurul, Previsão de preços de compensação de médio prazo do mercado de eletricidade: uma abordagem SVM múltipla, energia elétrica e sistemas de energia, elétrica Sistema de energia de energia 58 (2014) 206–214.
- [178] X. Li, J. Wen, Previsão on-line do consumo de energia da construção usando física identificação do sistema baseado, *Energy Build.* 82 (2014) 1–12.
- [179] LL Prez, J. Ortiz, R. Gonzalez, IR Maestre, A review of benchmarking rating

e conceitos de rotulagem no âmbito da certificação energética de edifícios esquemas, *Energy Build.* 41 (3) (2009) 272-278.

[180] Q. Li, Q. Meng, J. Cai, H. Yoshino, A. Mochida, Previsão de carga horária de resfriamento em o edifício: uma comparação da máquina de vetor de suporte e diferentes redes neurais, *Energy Conversion Management*. 50 (1) (2009) 90–96.

[181] C. Filippin, Benchmarking da eficiência energética e emissões de gases de efeito estufa de prédios escolares no centro da Argentina, *J. Build. Ambiente*. 35 (5) (2000) 407-414.

[182] REE Edwards, J. New, LE Parker, Predizendo o futuro consumo de eletricidade residencial por hora: um estudo de caso de aprendizado de máquina, *Energy Build.* 49 (2012) 591-603.

[183] P. Torcellini, M. Deru, M. Griffith, K. Benne, DB Crawley, DOE Comercial Building Benchmark Models, National Renewable Energy Laboratory, 2008.

[184] N. Fumo, P. Mago, R. Luck, Metodologia para estimar o consumo de energia do edifício usando modelos de referência EnergyPlus, *Energy Build.* 42 (12) (2010) 2331-2337.

[185] C. Yan, S. Wang, F. Xiao, Um método simplificado de avaliação do desempenho energético para edifícios existentes com base na desagregação da fatura de energia, *Energy Build.* 55 (2012) 563-574.

[186] B. Crawley, W. Hand, T. Kummert, Contrastando as capacidades dos programas de simulação de desempenho de energia de construção, *Building Environ.* 43 (2008) 661-673.

[187] Departamento de Energia dos EUA, DOE-2, Ferramentas de Simulação Disponíveis, 2014, Disponível em: <http://apps1.eere.energy.gov/buildings/toolsdirectory/subject.cfm?pagename=subjects&pagenamemenu=wholebuildinganalysis/pagenesubmenu=simulacao+de+energia> (acessado em 09.02.14).

[188] Departamento de Energia dos EUA, EnergyPlus: software de simulação de energia, 2012 Disponível em <http://apps1.eere.energy.gov/buildings/energyplus>. (acessado 01.05.12).

[189] MM Kavagic, AA Mavrogiani, DD Mumovic, AJ Summerfield, ZZ Ste vanovic, Djurovic-M. Petrovic, Uma revisão de modelos de estoque de construção de baixo para cima para consumo de energia no setor residencial, *Building Environ.* 45 (2010) 1683-1697.

[190] E. Wang, Z. Shen, K. Grosskop, Benchmarking energy performance of building envelopes por meio de uma abordagem seletiva de agrupamento residual usando um conjunto de dados de alta dimensão, *Energy Build.* 75 (2014) 10-22.

[191] D. Meyer, Support Vector Machines. A Interface para libsvm no Pacote e1071, FH Technikum Wien, Áustria, 2014, Disponível em: <https://cran.r-project.org/web/packages/e1071/vignettes/svmdoc.pdf> (acessado em 04.04.14).

[192] V. Vapnic, em: Teoria da Aprendizagem Estatística, Springer, Nova York, 1995, pp. 133-157.

[193] B. Dong, C. Cao, SE Lee, Aplicando máquinas de vetor de suporte para prever o consumo de energia de construção na região tropical, *Energy Build.* 37 (2005) 545-553.

[194] K. Kavaklioglu, Modelagem e previsão do consumo de eletricidade da Turquia usando regressão de vetor de suporte, *Appl. Energia* 88 (2011) 368-375.

[195] HX Zhao, F. Magoulès, Seleção de recursos para prever o consumo de energia do edifício com base no método de aprendizado estatístico, *J. Algor Comput. Tecnol.* 6 (2012) 59-78.

[196] WY Zhang, WC Hong, Y. Dong, G. Tsai, JT Sung, GF Fan, Aplicação de SVR com algoritmo GASA caótico na previsão de carga elétrica cíclica, *Energia* 45 (2012) 850-858.

[197] M. Espinoza, JAK Suykens, BD Moor, Mínimos quadrados de tamanho fixo suportam máquinas vetoriais: uma aplicação em larga escala na previsão de carga elétrica, *CMS* 3 (2006) 113-129.

[198] KW Mui, LT Wong, Cálculos de carga de resfriamento em clima subtropical, *Construção Aproximadamente*. 42(7)(2007) 2498-7.

[199] Q. Li, Q. Meng, J. Cai, H. Yoshino, A. Mochida, Aplicando máquina de vetor de suporte para prever carga horária de resfriamento no edifício, *Appl. Energia* 86 (2009) 2249-2256.

[200] K. Rishee, MK Smith, JP Culligan, EJ Taylor, Previsão de consumo de energia de edifícios residenciais multifamiliares usando regressão de vetor de suporte: Investigando o impacto da granularidade de monitoramento temporal e espacial na precisão do desempenho, *Appl. Energia* 123 (2014) 168–178.

[201] RE Edwards, J. New, LE Parker, Previsão de eletricidade residencial horária futura consumo: um estudo de caso de aprendizado de máquina, *Energy Build.* 49 (2012) 591-03.

[202] S. Karatasou, M. Santamouris, V. Geros, Modelagem e previsão de edifícios uso de energia com redes neurais artificiais: métodos e resultados, *Energia e Edifício* 38 (2006) 949-958.

[203] K. Li, H. Su, J. Chu, Previsão do consumo de energia do edifício usando redes neurais e sistema neuro-fuzzy híbrido: um estudo comparativo, *Energy Build.* 43 (2011) 2893-2899.

[204] I. Ballarini, SP Corgnati, V. Corrado, N. Talà, Melhorando a modelagem energética de grande estoque de edifícios através do desenvolvimento de edifícios arquétipos (2011) 2874-81.

[205] I. Ballarini, SP Corgnati, V. Corrado, Uso de edifícios de referência para avaliar a Potenciais de economia de energia do parque imobiliário residencial: a experiência de Projeto TABULA, *Política Energética* 68 (2014) 273–284.

[206] I. Korolija, LH Marjanovic, Y. Zhang, VI Hanby, arquetípico dos edifícios de escritórios do Reino Unido modelo como abordagem metodológica no desenvolvimento de modelos de regressão para prever o consumo de energia do edifício a partir de demandas de aquecimento e resfriamento, *Construção de Energia*. 60 (2013) 152-162.

[207] G. Mustafaraj, D. Marini, A. Costa, M. Keane, Calibração de modelo para construção simulação de eficiência energética, *Appl. Energia* 130 (2014) 72–85.

[208] JH Kämpf, D. Robinson, Um modelo térmico simplificado para apoiar a análise de fluxos de recursos urbanos, *Energy Build.* 39 (4) (2007) 445-453.

[209] DFH Robinson, J. Kämpf, P. Leroux, D. Perez, A. Rasheed, U. Wilke, CITYSIM: micro-simulação abrangente de fluxos de recursos para planejamento, *Proc Build. Simul.* (2009).

[210] HA Nielsen, H. Madsen, Modelagem do consumo de calor no aquecimento urbano sistemas usando uma abordagem de caixa cinza, *Energy Build.* 38 (1) (2006) 63–71.

[211] M. Lauster, J. Teichmann, M. Fuchs, R. Streblow, D. Mueller, modelos de rede térmica de baixa ordem para simulações dinâmicas de edifícios no distrito da cidade escala, *construir. Ambiente*. 73 (2014) 223-231.

[212] EJ Kim, G. Plessis, JL Hubert, JJ Roux, Simulação de energia urbana: simplificação e redução de modelos de envolvente de edifícios, *Energy Build.* 84 (2014) 193-202.

[213] B. Dong, C. Cao, SE Lee, Aplicando máquinas de vetor de suporte para prever o consumo de energia de edifícios na região tropical, *Energy Build.* 37 (5) (2005) 545-553.

[214] KI Zhou, SI Yang, C. Shen, Uma revisão da classificação de carga elétrica em smart ambiente de grade, *Renovar. Sustentar. Energia Rev.* 24 (2013) 103–110.

[215] AS Ahmad, MY Hassan, MP Abdullah, HA Rahman, F. Hussin, H. Abdul lah, Uma revisão sobre aplicações de ANN e SVM para a construção de energia elétrica previsão de consumo, *Renovar. Sustentar. Energia Rev.* 33 (2014) 102–109.

[216] S. Humeau, TK Wijaya, M. Vasirani, K. Aberer, Previsão de carga de eletricidade para clientes residenciais: explorando agregação e correlação entre lares, em: 2013 Sustainable Internet and ICT for Sustainability - Conferência Continuação, 2013, pp. 1–6.

[217] KM Powell, A. Sriprasad, WJ Cole, TF Edgar, Aquecimento, refrigeração e previsão de carga elétrica para um sistema de energia distrital de grande escala, *Energy* 74 (2014) 877-885.

[218] LG Swan, VI Ugursal, Modelagem do consumo final de energia no setor residencial: uma revisão das técnicas de modelagem, *Renew. Sustentar. Energia Rev.* 13 (8) (2009) 1819-1835.

[219] F. Ascione, RFM De, F. Rossi, R. Fistola, M. Sasso, GP Vanoli, Análise e diagnóstico do desempenho energético de edifícios e bairros: metodologia, validação e desenvolvimento de Mapas de Energia Urbana, *Cidades* 35 (2013) 270–283.

[220] F. Ascione, M. Canelli, M. Sasso, GP Vanoli, Refrigeração, aquecimento e energia para pequenos distritos urbanos: um estudo de caso italiano, *Appl. Engº Térmico* 71 (2) (2014) 705-713.

[221] S. Taylor, D. Fan, M. Rylatt, Enabling urban-scale energy modelling: a new abordagem espacial, *Build. Res. Inf.* 42 (1) (2013) 4–16.

[222] A. Masstrucci, O. Baume, F. Stazi, U. Leopold, Estimativa de economia de energia para o estoque de edifícios residenciais de uma cidade inteira: Uma abordagem de redução de escala estatística baseada em GIS aplicada a Rotterdam, *Energy Build.* 75 (2014) 358-367.

[223] P. Caputo, G. Costa, S. Ferrari, Um método de apoio à definição de estratégias energéticas no setor da construção à escala urbana, *Energy Policy* 55 (2013) 261–270.

[224] F. Ascione, M. Canelli, RF Masi, M. Sasso, GP Vanoli, Refrigeração, aquecimento e energia combinados para pequenos distritos urbanos: um estudo de caso italiano, *Appl. Térmico Eng.* 71 (2) (2014) 705-713.

[225] K. Orehounig, G. Mavromatidis, R. Evins, V. Dorer, prevendo o consumo de desempenho energético de um bairro usando simulação de desempenho de construção, *Energy* (2011).

[226] GlasgowEnergyApp: <http://www.iesve.com/news/article/New-Energy-App-Helps-Residents-Cut-Bills/4332?modal=1>.

[227] T. Giovanni, K. Ruth, O. Mike, O. James, F. Donal, Abordagens orientadas por dados para previsão de energia predial, consumo em nível urbano, em: 6th International Building Physics Conference, IBPC, 2015, pp. 3378–3383. *Energia Processo* dia 78 (2015).

[228] T. Ahmad, Prevenção de perda não técnica usando medidores inteligentes, *Renew. Sustentar. Energia Rev.* 75 (2017) 573–589.

[229] T. Ahmad, H. Chen, J. Wang, Y. Guo, Revisão de várias técnicas de modelagem para a detecção de roubo de energia elétrica em ambiente de rede inteligente, *Renew. Sustente. Energia Rev. Parte 3* 82 (fevereiro de 2018) 2916–2933.

[230] DB Jani, M. Mishra, PK Sahoo, Aplicação de rede neural artificial para Previsão de desempenho de sistemas de resfriamento dessecante sólido – Uma revisão, *Renew. Sustentar. Energia Rev.* 80 (2017) 352–366.

[231] K. Kulkarni, PK Sahoo, M. Mishra, Otimização da carga de resfriamento para uma palestra teatro em um clima composto na Índia, *Energy Build.* 43 (2011) 1573-1579.

[232] DB Jani, M. Mishra, PK Sahoo, Previsão de desempenho do desumidificador de dessecação sólido rotativo em sistema de ar condicionado híbrido usando sistema neural artificial rede, *Ap. Engº Térmico* 98 (2016) 1091-03.

[233] DB Jani, M. Mishra, PK Sahoo, Previsão de desempenho de dessecante sólido - sistema de ar condicionado híbrido de compressão de vapor usando rede neural artificial, *Energy* 103 (2016) 618–629.

[234] DB Jani, M. Mishra, PK Sahoo, Estudos de desempenho do sistema de ar condicionado de compressão de vapor sólido desidratante híbrido para climas quentes e úmidos, *Construção de Energia*. 102 (2015) 284-292.

[235] V. Ok, Um procedimento para calcular a carga de resfriamento devido à radiação solar: o efeito de sombreamento de edifícios adjacentes ou próximos, *Energy Build.* 19 (1) (1992) 11-20.

[236] T. Sharp, benchmarking de energia em edifícios de escritórios comerciais, em: Proceedings of the ACEEE 1996 Summer Study on Energy Efficiency in Buildings, 4, 1996, pp. 321-329.