

REVEJA

Uma revisão abrangente sobre abordagens de aprendizado profundo em aplicativos de previsão de vento

Zhou Wu¹ | Gan Luo¹ | Zhile Yang² | Yuanjun Guo² | Kang Li³ |

¹Faculdade de Automação, Universidade de Chongqing, Chongqing, China

²Instituto de Tecnologia Avançada de Shenzhen, Academia Chinesa de Ciências, Shenzhen, Guangdong, China

³Escola de Engenharia Eletrônica e Elétrica, Universidade de Leeds, Leeds, Reino Unido

⁴State Grid Electric Power Research Institute, Nanjing, Jiangsu, China

Correspondência

Zhile Yang, Instituto de Tecnologia Avançada de Shenzhen, Academia Chinesa de Ciências, Shenzhen, Guangdong 518055, China.
E-mail: z.l.yang@siat.ac.cn

Informações de financiamento

Fundação Nacional de Ciências Naturais da China, Números de concessão/prêmio: 52077213, 62003332; Estado Laboratório Chave de Equipamentos de Transmissão de Energia e Segurança de Sistemas e Novas Tecnologias

Resumo

O uso efetivo da energia eólica é parte essencial do desenvolvimento sustentável da sociedade humana, em particular, diante da recente pressão sem precedentes na formação de um ambiente energético de baixo carbono. A previsão precisa dos recursos eólicos e da energia desempenha um papel fundamental na melhoria da penetração do vento. No entanto, não foi bem adotado nas aplicações do mundo real devido às fortes características estocásticas da energia eólica. Nos últimos anos, o aumento da aplicação de métodos de aprendizado profundo fornece novas ferramentas eficazes na previsão de vento. Este artigo fornece uma visão abrangente dos modelos de previsão baseados em deep learning no campo da energia eólica. As abordagens em destaque incluem redes neurais recorrentes baseadas em séries temporais, máquinas de Boltzmann restritas, redes neurais convolucionais, bem como abordagens baseadas em autocodificadores. Além disso, as direções de desenvolvimento futuro da previsão de energia eólica baseada em aprendizado profundo também foram discutidas.

PALAVRAS-CHAVE

aprendizado profundo, redes neurais profundas, aprendizado (inteligência artificial)

1 | INTRODUÇÃO

Dado o crescente crescimento das demandas de energia, é fundamental incorporar energia renovável no fornecimento de energia. Espera-se que a demanda por energia renovável aumente devido aos custos operacionais mais baixos e ao uso preferencial de muitos sistemas de energia [1]. Como um tipo de energia renovável com características verdes, limpas, ecologicamente corretas e com altos benefícios econômicos, a energia eólica é muito importante para o desenvolvimento sustentável da sociedade humana. Devido à superioridade da energia eólica, ela se desenvolveu aos trancos e barrancos nos últimos 10 anos e se tornou uma das fontes de energia mais competitivas do mundo. Em 2020, a capacidade instalada global de energia eólica foi de 93 GW. A China e os Estados Unidos são os maiores mercados de energia eólica terrestre do mundo, que

juntas representam mais de 60% da nova capacidade instalada em 2020 [2]. Até 2020, a capacidade instalada acumulada de energia eólica da China ultrapassou 216 milhões de quilowatts, representando cerca de 40% do total mundial. A China tornou-se um dos líderes no desenvolvimento da energia eólica global [3].

A capacidade instalada acumulada de geração de energia nova na Área de Operação da State Grid é de 350 milhões de quilowatts, dos quais a capacidade instalada de geração de energia eólica é de 169 milhões de quilowatts com um aumento anual de 16%. A geração anual de energia da nova energia é de 510,2 bilhões de kWh, representando 9,2% da geração total de energia, sendo a geração eólica de 315,2 bilhões de quilowatts-hora (kWh) com um aumento anual de 11% [4]. A energia eólica americana atingiu um marco importante em 2019, atingindo uma capacidade operacional de 100 GW. Desde 2008, a geração de energia eólica

Este é um artigo de acesso aberto sob os termos da Creative Commons Attribution License, que permite o uso, distribuição e reprodução em qualquer meio, desde que o trabalho original seja devidamente citado.

© 2022 Os Autores. Transações CAAI em Tecnologia de Inteligência publicadas por John Wiley & Sons Ltd em nome da Instituição de Engenharia e Tecnologia e da Universidade de Tecnologia de Chongqing.

A capacidade quadruplicou e tornou-se a maior fonte de capacidade de geração de energia renovável nos Estados Unidos, que representará 7,2% da eletricidade dos EUA até 2019 [5]. Os principais países em capacidade instalada global de energia eólica, como Alemanha, Índia, Itália, Espanha, Reino Unido, França, Brasil e Canadá, também estão desenvolvendo vigorosamente a energia eólica [6].

Apesar das vantagens da energia eólica, a integração suave da energia eólica em larga escala na rede ainda enfrenta muitos desafios. Devido à aleatoriedade, volatilidade e intermitência do vento, a conexão à rede de energia eólica em larga escala torna muito difícil equilibrar a oferta e a demanda de energia, e também trouxe uma redução universal da energia eólica. Uma possível solução para equilibrar o desafio é aumentar a velocidade do vento e a previsão de potência. Melhorar a precisão da previsão do vento pode ajudar a otimizar o planejamento geral e a programação da rede elétrica, encontrar a combinação ideal de turbinas eólicas e garantir a operação segura e estável do sistema de energia, aumentando ainda mais os benefícios econômicos do vento.

Enquanto isso, a previsão precisa do vento também é um dos principais pré-requisitos para fornecer recursos de absorção de energia eólica.

A previsão de energia eólica tem sido um problema intratável no sistema de energia, onde inúmeras revisões foram propostas cobrindo amplamente o processamento de dados, previsão de energia e recursos. Jung et al. [7] revisaram as tecnologias potenciais que podem melhorar o desempenho dos modelos de previsão de energia eólica e enfatizaram o sistema de conhecimento promissor na previsão. Tascikaraoglu et al. [8] delineou os métodos combinados de previsão de energia eólica e focou nas várias combinações de modelos. Wang et al. [9] resumiram oito estratégias de previsão de velocidade do vento em várias etapas, onde 48 modelos híbridos foram comparados com base nessas oito estratégias.

Bokde et al. [10] compararam o método existente com a decomposição em modo empírico (EMD) e suas versões melhoradas em termos de tecnologias de pré-processamento. Liu et al. [11] forneceram uma revisão detalhada e classificação das técnicas de processamento de dados na previsão de energia eólica, e um estudo aprofundado de cada método de processamento de dados mencionado, incluindo propósito, função, detalhes e desempenho também foi fornecido. Liu et al. [12] revisaram oito tipos de preditores inteligentes para aprendizado superficial e profundo no campo de previsão de energia eólica e métodos auxiliares que podem melhorar a capacidade preditiva do modelo preditivo que inclui algoritmos integrados de aprendizado e otimização. Vargas e col. [13] demonstraram um novo método de revisão de literatura chamado análise sistemática de rede de literatura, que foi usado para resumir o desenvolvimento da análise de energia eólica no processo de tomada de decisão nos últimos 30 anos.

Os autores apontaram que os métodos mais usados este ano são a simulação de Monte Carlo e os métodos de redes neurais artificiais. Wang et al. [14] revisaram aplicações de algoritmos de inteligência artificial na previsão de energia eólica.

Gonzalez et al. [15] resumiu os indicadores de desempenho comumente usados para previsão de energia eólica determinística e probabilística de curto prazo e explicou o desempenho desses indicadores em diferentes conjuntos de dados, resoluções de tempo e certos atributos específicos do modelo. Yang et al. [16] forneceu um resumo abrangente e comparação de mais de um

centenas de métodos de previsão de vento de três perspectivas: velocidade do vento e previsão de potência, previsão de incerteza e previsão de tempo de inclinação.

Embora inúmeras revisões tenham sido propostas em termos de previsão de vento, a tecnologia emergente de inteligência artificial, em particular, métodos de aprendizado profundo, aumentou nos últimos anos e fornece uma série de novas tecnologias na previsão de vento. No entanto, as revisões anteriores se concentraram principalmente em questões de classificação, mas não discutiram as tendências de desenvolvimento em detalhes. Este artigo tenta resumir os métodos de previsão de vento baseados em aprendizado profundo nos últimos 5 anos, fornecendo uma pesquisa abrangente para pesquisadores no desenvolvimento de novas ferramentas eficazes de previsão de vento.

O restante do artigo está organizado da seguinte forma: a seção 2 descreve alguns conceitos básicos na área de previsão de energia eólica. A seção 3 apresenta modelos de previsão de vento baseados em deep learning. A seção 4 discute a possível direção de pesquisa futura da previsão de energia eólica. A Seção 5 conclui este artigo. Além disso, a estrutura de previsão baseada em aprendizado profundo é mostrada na Figura 1, que resumiu as categorias de cada técnica.

2 | VISÃO GERAL DA ENERGIA EÓLICA PREVISÃO

O vento é o movimento da atmosfera e uma forma de destaque da energia solar. Quando há uma diferença de pressão atmosférica, o ar se move da área de maior pressão para a área de menor pressão. É causada por três eventos simultâneos: o aquecimento desigual da atmosfera da Terra pelo Sol, irregularidades encontradas na superfície da Terra e a rotação da Terra. O vento flui através das pás da turbina eólica, e as pás com uma estrutura especial produzem uma diferença de pressão de ar que produz sustentação e arrasto. Quando a sustentação é mais forte que o arrasto, os eixos do rotor giram para acionar o gerador para gerar eletricidade [17, 18]. A energia eólica P pode ser calculada da seguinte forma:

$$P = \frac{1}{2} \rho A v^3 \quad (1)$$

onde P representa a potência eólica, ρ denota a densidade do ar, A é a área varrida da turbina eólica e v é a velocidade do vento.

A energia eólica exibe uma dependência cúbica altamente não linear da velocidade do vento, e a previsão precisa da velocidade do vento pode fornecer maior potência [19]. Além disso, estudos mostraram que se a precisão da previsão da velocidade do vento for aumentada em 10%, a geração de energia eólica aumentará cerca de 30% do que o esperado [20].

2.1 | Classificações e aplicações de previsão de séries temporais de vento

Até o momento, não existe um padrão uniforme e rígido para os limites de prazo de previsão. Eles são separados fortemente de acordo com

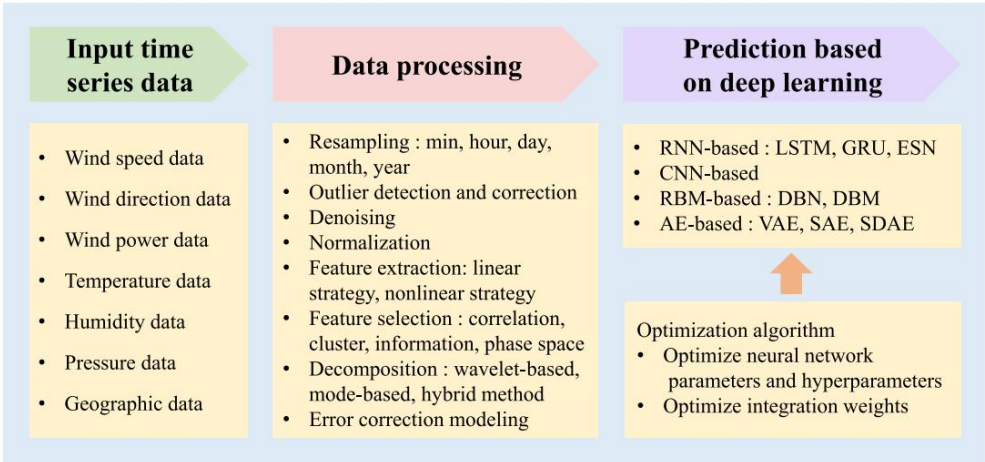


FIGURA 1 Estrutura de previsão de energia eólica baseada em aprendizado profundo. AE, autocodificador; CNN, rede neural convolucional; DBM, máquinas profundas de Boltzmann; DBN, rede de crenças profundas; ESN, rede de estado de eco; GRU, unidade recorrente fechada; LSTM, memória de curto prazo longo; RBM, máquina Boltzmann restrita; RNN, rede neural recorrente; SAE, codificador automático empilhado; SDAE, codificadores automáticos de denoising empilhados

às aplicações. Soman et al. [21] dividiram o período de previsão em quatro categorias: muito curto prazo, curto prazo, médio prazo e longo prazo, conforme mostrado na Figura 2.

O período de previsão é igual ao tempo de resolução multiplicado pelos passos previstos, geralmente referindo-se ao período do conjunto de teste e não ao conjunto de treinamento, que é calculado da seguinte forma:

$$Tp \propto ti \cdot st$$

onde Tp é o período de previsão, ti é a unidade de tempo dos dados, st é o passo de tempo.

As aplicações correspondentes são as seguintes:

- (1) Curto prazo: compensação do mercado de eletricidade, regulamentos de eletricidade, operações de rede em tempo real, controle de turbinas eólicas, pesquisa de qualidade de energia, acompanhamento de carga e distribuição
- (2) Curto prazo: planejamento econômico de despacho de carga, decisões de incremento/decremento de carga, compartilhamento de carga e segurança operacional no mercado de eletricidade
- (3) Médio prazo: alocação de energia, despacho econômico, decisões de requisitos de reserva, decisões de gerador online/offline, coordenação de parque eólico e dispositivo de armazenamento, manutenção planejada em linhas de rede, planejamento de rede de transmissão, gerenciamento de congestionamento, energia e reserva para o dia seguinte programação, manutenção de parques eólicos e solução de problemas
- (4) Longo prazo: avaliação de recursos de energia eólica, planejamento de construção de parques eólicos, custo operacional ótimo, plano de manutenção anual, operação e manutenção de geração convencional, gerenciamento de operação, estudo de viabilidade para parque eólico, projeto de plano de operação de parque eólico, energia estratégia de negociação e coordenar o portfólio de unidades ideal [10, 21-26]

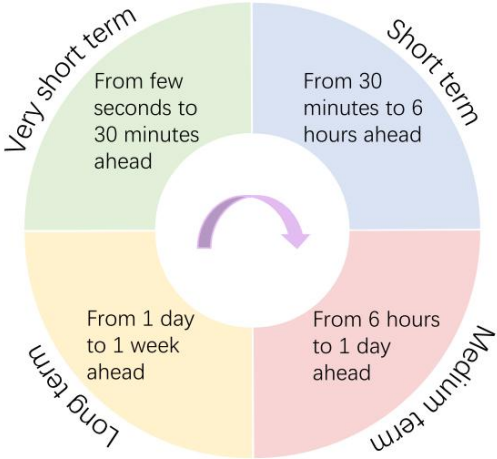


FIGURA 2 Classificações do período de previsão

2.2 | Objetivos e resultados da previsão de energia eólica

Para que o planejamento e a tomada de decisões energéticas sejam mais eficazes, a previsão de energia eólica é indispensável. Do ponto de vista do processo de previsão, existem dois tipos de previsão, a saber, a previsão direta e a previsão indireta, respectivamente. A previsão direta refere-se à previsão direta por meio de dados históricos de velocidade do vento ou energia eólica. A previsão indireta primeiro prevê a velocidade do vento futura e, em seguida, converte a velocidade do vento prevista em previsão de energia eólica de acordo com a curva de potência da turbina eólica [10]. Os métodos indiretos são mais precisos e, portanto, mais populares.

De acordo com os resultados da previsão de vento, os modelos de previsão de vento também podem ser divididos em duas categorias, previsão determinística e previsão probabilística [27, 28]. A previsão determinística também é chamada de previsão pontual e o resultado da previsão é um valor determinístico. O resultado da probabilidade

a previsão é geralmente um intervalo, e a distribuição de probabilidade dos valores do intervalo pode ser fornecida. Um único método determinístico não pode refletir a incerteza e aleatoriedade da velocidade do vento. Muitas aplicações no campo da energia eólica precisam considerar a incerteza e a aleatoriedade para que as previsões probabilísticas tenham atraído cada vez mais atenção nos últimos anos [29].

2.3 | Modelos de previsão de energia eólica

Dos tipos mais básicos, os métodos de previsão de vento podem ser divididos em cinco categorias: método de persistência, método físico, método estatístico convencional, método de aprendizado de máquina com estrutura rasa, método de aprendizado de máquina com estrutura profunda, ou seja, aprendizado profundo [25].

O método de persistência é bastante simples. Supõe-se que a velocidade ou potência do vento em um determinado momento futuro será a mesma de quando a previsão é feita [24]. A expressão deste método é a seguinte:

$$P_{t+\Delta t} = P_t \quad (3)$$

Este modelo tem um bom desempenho em previsões de muito curto prazo, mas à medida que a escala de tempo aumenta, sua precisão diminui gradualmente. Por isso, geralmente é usado como um modelo de referência para comparar com novos modelos [30].

O método físico geralmente se refere ao modelo de previsão numérica do tempo (NWP). O modelo NWP estabelece um modelo físico e matemático complexo para simular o processo de mudança do vento, considerando de forma abrangente fatores meteorológicos e geográficos, como temperatura, umidade, pressão do ar e terreno [31]. Os modelos NWP geralmente são usados para previsões meteorológicas em áreas maiores, e as previsões de velocidade do vento são apenas parte disso. Existem dois tipos de modelos NWP: modelos globais e regionais.

Na Ref.

[26]. O método físico pode refletir a essência do movimento atmosférico para que a precisão seja maior. No entanto, esse método precisa processar uma quantidade extremamente grande de dados e realizar cálculos complexos. Existem requisitos extremamente altos para poder de computação, o que leva a dificuldades significativas para pesquisadores comuns [32]. Entretanto, devido à natureza caótica das equações diferenciais parciais no modelo matemático, é impossível obter uma solução precisa, e o erro será multiplicado com o aumento do tempo. À luz disso, os modelos NWP não são adequados para tempos de previsão curtos, mas mais adequados para previsões de médio ou longo prazo [8, 21]. Em trabalhos de pesquisa recentes, os períodos de previsão são geralmente focados em previsões de muito curto ou curto prazo [13], de modo que as aplicações do NWP são menores.

O método de estatística convencional usa os dados de séries temporais de velocidade do vento coletados para fornecer previsões. Depois de muitos anos

de desenvolvimento, tem havido muitos modelos estatísticos para a previsão da velocidade do vento. Poggi et al. [33] começaram a utilizar a autoregressividade (AR) para simular séries temporais de velocidade do vento, e Nielsen et al. [34] usaram regressão quantílica (QR) para fazer previsões de forma independente. A fim de melhorar o desempenho da previsão, muitos modelos de média móvel auto-regressiva foram desenvolvidos [35–38]. Além disso, vários modelos baseados em AR também foram desenvolvidos para a previsão da velocidade do vento, como vetor auto-regressivo [39], auto-regressivo com entrada exógena (ARX) [40], auto-regressivo condicional heteroscedasticidade [41, 42], média móvel integrada auto-regressiva (ARIMA) [43–46], ARIMA sazonal [47], ARIMA fracionária [48] e ARFIMA [49]. A fim de melhorar a precisão da previsão e a robustez do modelo, pesquisadores também desenvolveram muitos modelos híbridos baseados no modelo ARIMA, como WT-ARIMA [50], RWT-ARIMA [43] e VMD-ARIMA [51]. No entanto, esses modelos analisam apenas a relação superficial entre as variáveis na série temporal, sendo difícil lidar com a relação complicada e não linear.

Para obter resultados de previsão mais satisfatórios, vários modelos estatísticos não lineares foram propostos [52]. Zhang et al. [53] combinaram AR e regressão de processo gaussiana (GPR) para melhorar a precisão da previsão. Em Karakucs et al. [54], é proposto o auto-regressivo polinomial, que é um modelo não linear com parâmetros lineares. Devido ao termo não linear do modelo de Hammerstein, o modelo autorregressivo de Hammerstein é superior aos ARIMAs [55]. Alguns modelos aprimorados, como transição suave auto-regressiva, auto-excitação de limiar auto-regressivo [56] e comutação de Markov auto-regressiva [57] também foram propostos. Além disso, os pesquisadores também usaram alguns modelos incomuns, por exemplo, auto-regressivo não linear com entrada exógena [58], heteroscedasticidade condicional auto-regressiva generalizada (GARCH) [59], regressão vetorial de relevância de múltiplos kernels [60], limiar heteroscedasticidade condicional auto-regressiva sazonal [61], regressão multi-kernel robusta adaptativa baseada em Bayesian [62]. No entanto, com a crescente complexidade dos dados de séries temporais, não é fácil atender aos requisitos de precisão de previsão porque os modelos estatísticos tradicionais têm pouca capacidade de extrair as características dos dados.

Os métodos rasos de aprendizado de máquina incluem redes neurais com algumas camadas. Marugan et al. [63] resumem a maioria dos modelos de redes neurais superficiais.

Comparado com o método de persistência e o método estatístico tradicional, o método de aprendizado de máquina raso tem maior precisão de previsão e melhor efeito na prática.

Os métodos rasos de aprendizado de máquina podem aprender as características superficiais nos dados de séries temporais do vento e precisam de engenharia de características extensiva [64].

O aprendizado profundo é um método de aprendizado de máquina para arquitetura de rede profunda. As características dos dados de entrada são aprendidas através de um modelo computacional composto por múltiplas camadas de processamento não lineares. Comparado com modelos de aprendizado de máquina superficiais e modelos estatísticos tradicionais, o aprendizado profundo

TABELA 1 Resumo dos modelos com preditor LSTM

Ref.	Dados de entrada	Intervalo de tempo	Modelo	Desempenho de previsão
Yang et ai. [68]	Velocidade do vento	1 hora	Olho Mágico LSTM	MAPA 0,0421
Yu et ai. [69]	Força do vento	10 minutos	LSTM-EFG	MSE 5.531
Zhang et ai. [70]	Velocidade do vento	15 minutos	SWLSTM-GPR	RMSE 0,174
Araya et ai. [72]	Velocidade do vento	1 hora	LSTM-Ms	IS 1.081
Pei et ai. [73]	Velocidade do vento	15 minutos	EWT-NCULSTM	MAE 0,10 MAPE 5,45 RMSE 0,15
Zhang et ai. [74]	Velocidade do vento	1 hora	NLSTM	RMSE 0,45 MAPE 8,16
Qu et ai. [76]	Força do vento	5 minutos	PCA-LSTM	NMAE 0,5672 NRMSE 1,0732
Xu et ai. [77]	Força do vento	10 minutos	LSTM adaptável	MAPA 2.7
Huang et ai. [78]	Velocidade do vento	1 hora	EEMD-LSTM-GPR-vc	MAPE 14,28 RMSE 0,83 MAE 0,71
Liu et ai. [79]	Velocidade do vento	1 hora	EWT-LSTM-Elman	MAPE 3,24 MAE 0,28 RMSE 0,37
Li et ai. [80]	Velocidade do vento	10 minutos	mm-LSTM	1,8682 RMSE2,8484
Liu et ai. [81]	Força do vento	15 minutos	DWT-LSTM	MAE 5,49 MAPE 1,75 RMSE 8,64
Liu et ai. [82]	Velocidade do vento	10 minutos	SDAE-LSTM	MAPE 7,1323 MAE 0,3066 RMSE 0,3880
Wu et ai. [83]	Velocidade do vento	10 minutos	DBSCAN-SDAE-LSTM	NMAE 0,0798
Li et ai. [85]	Velocidade do vento	10 minutos	EWT-LSTM-RELM-IEWT	MAPE 0,3202 MAE 0,0359 RMSE 0,0465
Jasena et ai. [86]	Velocidade do vento	10 minutos	SAE-LSTM	0,3982 RMSE É 0,5969
Moreno et ai. [87]	Velocidade do vento	10 minutos	VMD-SSA-LSTM	MSE 0,021 RMSE 0,145 MAPE 1,75
Ma et ai. [88]	Velocidade do vento	15 minutos	CEEMDAN-erro-VMD-LSTM	RMSE 0,111 MAPE 3,21 MAE 0,0831
Liang et ai. [89]	Velocidade do vento	5 minutos	MSLSTM	MSE 0,00297 RMSE 0,05448 MAE 0,04275
Liu et ai. [90]	Velocidade do vento	1 hora	VMD-SSA-LSTM-ELM	MAPE 3,04 MAE 0,42 RMSE 0,53
Wang et ai. [91]	Velocidade do vento	1 hora	VMD-OFE-LSTMN-ECS	MAE 0,37 RMSE 0,73 MAPE 27,15
Chen et ai. [92]	Velocidade do vento	15 minutos	SSA-CEEMDAN-ConvLSTM	MSE 0,006 MAE 0,052 MAPE 1,135
Lu et ai. [93]	Força do vento	15 minutos	E-D LSTM	RMSE 2,6
Yin et ai. [94]	Força do vento	1 hora	EMD-VMD-CNN-LSTM	É 0,222 RMSE 0,296
Wang et ai. [95]	Força do vento	15 minutos	LW-CLSTM	MSE 12,7 RMSE 3,5 MAE 1,36
Chen et ai. [96]	Velocidade do vento	5 minutos	MFSTC-CNN-LSTM	1,0384 RMSE É 1,4003
Zhu et ai. [97]	Velocidade do vento	10 minutos	PSTN	RMSE-A 0,531 MAPE-A 3,674
Xiang e outros [98]	Velocidade do vento	15 minutos	WT-bi-LSTM	MAE 0,074 MAPE 0,551 RMSE 0,157

Abreviaturas: CEEMDAN, decomposição em modo empírico de conjunto completo com ruído adaptativo; CNN, rede neural convolucional; DBSCAN, agrupamento espacial baseado em densidade de aplicações com ruído; EEMD, decomposição de modo empírico em conjunto; EMD, decomposição em modo empírico; GPR, regressão do processo gaussiano; ELM, máquina de aprendizado extremo; IEWT, transformada wavelet empírica inversa; LSTM, memória de curto prazo longo; SAE, codificador automático empilhado; SDAE, codificadores automáticos de denoising empilhados; SSA, análise de espectro singular; VMD, decomposição em modo variacional.

métodos podem extrair recursos mais abstratos e ocultos nos dados, para obter melhor precisão nas tarefas de previsão. A eficácia e a precisão dos modelos de previsão baseados em aprendizagem têm sido amplamente reconhecidos.

3 | VENTO BASEADO EM APRENDIZAGEM PROFUNDA PREVISÃO

Normalmente, há três etapas na previsão da velocidade do vento: processamento de dados de energia, previsão de previsão e modelo avaliação de desempenho. A rede neural profunda (DNN) é

geralmente usado como um extrator de recursos e um preditor. No Atualmente, muitas DNNs têm sido aplicadas à previsão do vento. As estruturas básicas de previsão baseadas em aprendizado profundo incluem principalmente rede neural recorrente (RNN), rede neural convolucional (CNN), máquina de Boltzmann restrita (RBM) e assim por diante. Além disso, existem alguns outros profundos redes como a rede adversária generativa, máquina de aprendizado (ELM), codificador automático empilhado (SAE), codificadores automáticos de remoção de ruído empilhados (SDAE) etc. A Tabela 1 fornece o resumo dos modelos com memória de curto prazo longa (LSTM) e a Tabela 2 mostra o resumo de outros modelos de previsão.

TABELA 2 Resumo de outros modelos de previsão

Ref.	Dados de entrada	Intervalo de tempo	Modelo	Desempenho de previsão
Peng et ai. [104]	Velocidade do vento	1 hora	WSTDGRU	RMSE 0,3757
Liu et ai. [105]	Velocidade do vento	15 minutos	SSA-CNNGRU-SVR	MAPE 0,97 MAE 1,72 MAE 2,41
Liu et ai. [106]	Velocidade do vento	1 hora	STN-VB	RMSE 0,226
Niu et ai. [107]	Força do vento	1 hora	AGRU	NRMSE 6.26 MAPE 4.25 MAPE 14.94
Xian et ai. [108]	Velocidade do vento	10 minutos	SD-BIGRU	MAE 0,1456 MAPE 4,78 RMSE 0,1871
Chitsazan et ai. [109]	Velocidade do vento	10 minutos	NESN-MP	MAE 0,3 RMSE 0,43 MSE 0,19
Gouveia et ai. [110]	Força do vento	1 hora	WTESN	NMAE 0,03
Hu et ai. [111]	Força do vento	1 mês	DeepESN	MAE 1,71 RMSE 2,2567 MAPE 5,23
Khan et ai. [112]	Força do vento	1 hora	DBN-wp	MAE 0,0754 RMSE 0,1010 SDE 0,1007
Wang et ai. [113]	Força do vento	10 minutos	kmeans-DBN	MAPA 1.1739
Wang et ai. [114]	Velocidade do vento	5 minutos	WT-DBN	MAE 0,4947 RMSE 0,6671 MAPE 4,76
Yu et ai. [115]	Velocidade do vento	10 minutos	DBNLP	MAIO 2,3355 RMSE 3,0609
Zhu et ai. [116]	Velocidade do vento	5 minutos	PDCNN	A-MAPE 4.414 A-RMSE 0.400
Mujeeb et ai. [117]	Força do vento	1 hora	EDCNN	MAPE 2,43 NRMSE 0,096 MAE 2,24
Segundo Yildiz et al. [118]	Força do vento	1 hora	RBCNN	RMSE 0,0499 MAE 0,0376 SMAPE 0,2532
Shivam et ai. [119]	Velocidade do vento	10 minutos	ResAUnet	MAE 1,035 RMSE 1,342 MAPE 0,272
Yan et ai. [120]	Força do vento	10 minutos	SDAE - mm	NRMSE 0,14
Chen et ai. [121]	Velocidade do vento	1 hora	SDAE-ELM	RMSE 0,21 MAIO 0,28

Abreviaturas: DBN, rede de crenças profundas; ELM, máquina de aprendizado extremo; SDAE, codificadores automáticos de denoising empilhados.

TABELA 3 Resumo das revisões atuais

Ref.	Contribuição chave
Bokde et ai. [10]	Modelos híbridos EMD ou EEMD, a evolução do método baseado em EMD, novas técnicas de tratar funções de modo inerentes, medidas de erro trabalhos de pesquisa baseados em EMD
Liu et ai. [11]	Revisão e categorização de técnicas de processamento de dados, uma avaliação geral com diferentes Perspectivas, direções de pesquisa e desafios
Jung et ai. [7]	Abordagens de previsão de última geração, precisão geral de previsão, técnicas para melhorar a desempenho de previsão
Tascikaraoglu et al. [8]	Abordagens de previsão combinadas, bibliografia anotada atualizada
Wang et ai. [9]	Comparação de oito estratégias de previsão em várias etapas, duas melhorias na previsão
Liu et ai. [12]	Classificação de alguns preditores inteligentes, resume seus méritos e limitações, dois métodos auxiliares: aprendizagem em conjunto e algoritmos de otimização metaheurística
Vargas e col. [13]	A evolução da análise de energia eólica nos últimos 30 anos, uma revisão de literatura inovadora abordagem
Wang et ai. [14]	Aplicações de algoritmos de inteligência artificial em parques eólicos
Gonzalez et ai. [15]	O modelo de previsão recentemente proposto, métodos de avaliação de desempenho
Yang et ai. [16]	Três novas tecnologias, quatro classificações de dados de vento, 37 critérios de avaliação, 100 métodos, 22 subcategorias de abordagens de previsão em três perspectivas

Abreviaturas: EEMD, ensemble de decomposição em modo empírico; EMD, decomposição em modo empírico.

3.1 | Modelos baseados em RNN

A RNN originou-se de uma rede neural feed-forward. Diferente redes neurais feed-forward convencionais, adota uma

estrutura de conexão que reutiliza o resultado do cálculo do iteração anterior do laço, ganhando uma função de memória [65]. O RNN tem uma grande vantagem de aprendizado para as características não lineares dos dados de sequência.

3.1.1 | Modelos com preditor de memória de curto prazo longo

A rede LSTM é projetada para resolver o problema do gradiente de fuga que ocorre quando o RNN aprende sequências com dependência de longo prazo [66]. Comparado com a estrutura simples do RNN, o LSTM é muito mais complicado. Devido à sua versatilidade, seu princípio não será apresentado em detalhes. Ele consiste em portão de entrada i_t , portão de esquecimento f_t , portão de atualização g_t e portão de saída o_t . A Figura 3 ilustra uma única célula LSTM. As fórmulas de cálculo do LSTM são as seguintes:

$$f_t = \sigma(W_f \cdot [x_{t-1}; x_t] + b_f)$$
$$i_t = \sigma(W_i \cdot [x_{t-1}; x_t] + b_i)$$
$$g_t = \tanh(W_g \cdot [x_{t-1}; x_t] + b_g)$$
$$o_t = \sigma(W_o \cdot [x_{t-1}; x_t] + b_o)$$
$$c_t = f_t \cdot c_{t-1} + i_t \cdot g_t$$
$$h_t = o_t \cdot \tanh(c_t)$$

04b

5 a

06b

07b

8b

9b

onde W_i, f, g, o são as matrizes de peso, b_i, f, g, o são os vetores de polarização, c_t é a célula de memória e σ é a função de ativação sigmoide.

Wu et al. [67] adotaram uma CNN para extrair características e então usaram LSTM para previsão de curto prazo. No entanto, existem deficiências, como longo tempo de treinamento e precisão de previsão insuficiente. Para otimizar o desempenho do LSTM, os pesquisadores também fizeram muitas melhorias com base nele. Estender a célula LSTM através de conexões peephole resolve o problema de que quando o LSTM fecha a porta de saída, a porta não consegue obter nenhuma informação da saída da unidade de armazenamento, trazendo melhores efeitos de previsão [68]. Yu et al. [69] propuseram LSTM-EFG, que potencializa o efeito de esquecer a porta e melhora a função de ativação. O modelo de rede de memória de longo prazo de peso compartilhado é introduzido para reduzir o tempo de treinamento e as variáveis que precisam ser otimizadas [70].

Para controlar ainda mais o problema de sobreajuste do LSTM, Eze et al. [71] projetaram um modelo oLSTM baseado na regularização mista de LSTM e dropout. O modelo proposto é um método de regressão baseado em energia que captura a




FIGURA 3 A estrutura da memória de longo prazo

adaptação cooperativa de variáveis de entrada. Este método pode controlar efetivamente o problema do gradiente de fuga de mapeamento de dados de vento de entrada e saída. Um modelo LSTM-Ms foi projetado para usar redes neurais feed-forward para construir sequências de escala de tempo mais ásperas do que o modelo original e, em seguida, usou LSTM para processar essas sequências [72]. Por meio de LSTM-Ms, é mais fácil aprender a dependência de longo prazo das sequências de velocidade do vento. Pei et al. [73] propuseram um EWT-NCULS. Comparado com o LSTM tradicional, o modelo proposto combina a porta de entrada e a porta de esquecimento como uma porta de atualização e melhora o método de atualização da unidade de armazenamento com referência à unidade recorrente fechada (GRU). A estratégia empírica de transformada wavelet (EWT) é empregada para decompor os dados de velocidade do vento para atingir o objetivo de redução de ruído. Depois disso, o novo modelo de rede de memória de longo prazo de atualização de célula é adotado para prever cada sub-sequência e por último somar para obter o resultado final. Muitos métodos consideram apenas a correlação de fatores meteorológicos, mas não consideram sua causalidade. Zhang et al. [74] empregaram um novo método, conhecido como rede de memória de longo prazo baseada em portas de vizinhança (NLSTM), que ajusta dinamicamente a estrutura da rede de acordo com a causalidade da árvore equivalente específica para lidar com a causalidade complexa na previsão da velocidade do vento, melhorando assim a precisão da previsão.

O empilhamento excessivo de unidades LSTM pode levar a uma diminuição na precisão e eficiência do treinamento. Lopes et al. [75] encontraram um melhor ponto de partida para o treinamento avaliando um número de instâncias e usando esses sinais de saída para realizar uma regressão de cume para obter os pesos da camada de saída. Geralmente, a subsérie de velocidade do vento de alta frequência tem dependência de curto prazo, enquanto a subsérie de baixa frequência tem dependência de curto e longo prazo. Liu et al. [12] modelos propostos com características diferentes para prever sub-sequências com diferentes frequências são mais propensos a alcançar o resultado satisfatório. Para melhorar ainda mais a precisão das previsões, os pesquisadores desenvolveram muitos modelos híbridos. A ideia básica é usar vários métodos de processamento e análise de sinais para refinar os dados de entrada e, em seguida, usar um ou mais preditores para fazer previsão.

Qu et al. [76] empregaram uma análise de componentes principais (PCA) para extrair informações válidas do NWP e inseri-las no LSTM para previsão. Propõe-se que o LSTM adaptativo use a análise de Pearson para extrair fatores de correlação fortes e inseri-los no LSTM para predição [77]. Huang et al. [78] projetaram um método EEMD-GPR-LSTM, onde a decomposição de modo empírico de conjunto (EEMD) é adotada para decompor os dados originais da velocidade do vento. Em seguida, os métodos LSTM e GPR são usados para prever as funções de modo inerentes, respectivamente. Finalmente, determine o peso dos dois resultados de previsão pelo método de variância-covariância e forneça resultados de previsão combinados.

Liu et al. [79] projetaram um novo modelo híbrido que mistura duas RNNs. O modelo EWT-LSTM-Elman proposto usa EWT para obter vários subsinais e usa LSTM para prever subsinais de baixa frequência e ElmanNN para prever subsinais de alta frequência. Os resultados experimentais são satisfatórios. Li et al. [80] adotaram MM para processar a sequência de velocidade do vento em uma linha de base estacionária de longo prazo e uma não

resíduo estacionário de curto prazo e, em seguida, use LSTM para fazer previsões. Liu et al. [81] introduziram um modelo DWT-LSTM para previsão de energia eólica de curto prazo. O DWT é utilizado para manipular as séries temporais não estacionárias em múltiplos componentes altamente estacionários e, em seguida, usar o LSTM para prever independentemente cada componente e, finalmente, obter o resultado final da previsão somando linearmente os valores de previsão de cada componente. Liu et al. [82] propuseram uma arquitetura profunda SDAE-LSTM com seleção de recursos. Neste modelo, uma estrutura de seleção de recursos baseada em informações mútuas foi desenvolvida pela primeira vez para determinar a entrada mais adequada para o modelo de previsão. Em seguida, os autores usaram o SDAE para capturar os recursos inerentes contidos nos dados originais e usaram o LSTM (ELM) para fazer as previsões.

Wu et al. [83] propuseram um modelo DBSCAN-SDAE-LSTM, que primeiro selecionou amostras de treinamento representativas de dados NWP por agrupamento espacial baseado em densidade de aplicativos com ruído (DBSCAN), usou SDAE junto com normalização em lote para extração profunda de recursos e, finalmente, utilizou LSTM para previsão. Liu et al. [84] utilizaram a decomposição de pacotes wavelet (WPD) para processar os dados originais em dois níveis de alta e baixa frequência, 1D-CNN é adotado para prever subsequências de alta frequência, e subsequências de baixa frequência são previstas pelo CNNLSTM, formando uma arquitetura híbrida WPD-LSTMCNN- CNN. Li et al. [85] desenvolveram um modelo combinado EWT-LSTM-RELM-IEWT. Ao contrário de outros modelos, o modelo híbrido usou máquina de aprendizado extremo regularizada para modelar a sequência de erro de cada sub-sinal e adotou uma transformada wavelet empírica inversa (IEWT) para construir a sequência de previsão final e filtrar os outliers.

Jaseena et al. [86] propuseram um modelo SAE-LSTM, que fez uso do SAE para reconhecer as características profundas da série de entrada e, em seguida, empregou o StackedLSTM para fazer previsões. Moreno et al. [87] propuseram uma estrutura de previsão de quatro etapas: (1) demodulação AM-FM; (2) decomposição VMD-SSA (análise de espectro singular); (3) Previsão e reconstrução do conjunto; (4) Verificação da precisão do modelo.

A literatura considerou erros de predição preliminares e propôs CEEMDAM-error-VMD-LSTM que usou uma estratégia de predição de decomposição multi-passo. Em primeiro lugar, os dados originais são processados em sub-sequências e sequências residuais pelo algoritmo de decomposição de modo empírico de conjunto completo com ruído adaptativo (CEEMDAN) e, em seguida, cada sequência é prevista usando LSTM. A sequência de erro é obtida subtraindo o resultado da predição da sequência original e o valor de observação original. Variational mode decomposition (VMD) é empregado para processar o sinal de erro em uma série de subsequências e então usar LSTM para prever cada subsequência. Finalmente, a sequência de erro prevista é empregada para corrigir o resultado de previsão da sequência original para obter um melhor resultado de previsão [88].

Dados de séries temporais únicas podem ter um impacto na precisão da previsão. Liang et al. [89] desenvolveram o MSLSTM que pode usar várias variáveis meteorológicas históricas, incluindo velocidade do vento, direção do vento, temperatura, umidade, pressão, ponto de orvalho e radiação solar para fazer previsões. Para melhorar a robustez da previsão multi-passo, Liu et al. [90] aconselharam um modelo híbrido de VMD-SSA-LSTM-ELM. VMD

é aplicado para processar dados brutos em vários sub-sinais. O SSA é empregado para extrair ainda mais as informações de tendência de todos os subsinais; O LSTM é adotado para completar a previsão dos subsinais de baixa frequência; e finalmente, o ELM é utilizado para completar a previsão dos subsinais de alta frequência.

Embora muitos métodos decomponham os dados, isso não elimina o papel de informações irrelevantes nos dados de vento de entrada. Portanto, para eliminar a interferência de componentes desnecessários no sinal de entrada e melhorar a precisão da predição, Wang et al. [91] desenvolveram um método EMD-OFE-LSTMN-ECS. Em primeiro lugar, o VMD é aplicado para processar o sinal de velocidade do vento não estacionário, e a divergência de Kullback-Leibler e a medida de energia (ELM) são adotados para capturar os principais recursos. Em seguida, os recursos-chave de reorganização de entropia de amostra são aplicados ao LSTMN de entrada para previsão. Ao mesmo tempo, uma estratégia de correção de erros baseada em GARCH também é empregada para corrigir o erro de previsão sem ignorar sua correlação e heterocedasticidade inerentes. Chen et al. [92] adotaram SSA, CEEMDAN e invert-EMD para reduzir o ruído e decompor os dados originais e, em seguida, usaram o modelo de previsão mestre-escravo composto por ConvLSTM e BPNN para fazer previsões. Os resultados dos testes mostraram que a precisão da previsão é competitiva. Lu et al. [93] propuseram um modelo E-D LSTM para reduzir o risco de especificação. Este modelo usa o modelo E-D baseado em LSTM (codificador-decodificador) para construir um codificador automático para mapear séries temporais de energia eólica para um formato de comprimento fixo.

Em seguida, insira vários LSTMs juntamente com informações de previsão do tempo para fazer previsões. Su et al. [99] levou em consideração os componentes da frequência do vento e o status da turbina eólica e propõe um modelo WPD-EEMD-LSTM para previsão de energia eólica de muito curto prazo. Yin et al. [94] desenvolveram a arquitetura EMD-VMD-CNN-LSTM que efetivamente utilizou a relação entre velocidade do vento, energia eólica e direção do vento. O método adotou EMD-VMD para processar os dados originais para gerar sub-sequências com relação de acoplamento, utilizou CNN-LSTM como modelo de previsão em cascata e finalmente sobrepôs todos os valores de previsão de sub-sequência para produzir os resultados.

Alguns estudos não levaram em conta as características meteorológicas multidimensionais. Li et al. [100] usaram o perceptron multicamada (MLP) para extrair características meteorológicas altamente relacionadas à velocidade real do vento em dados históricos meteorológicos multidimensionais divididos em estações secas e chuvosas, então aplicaram CNN para extrair características de dados históricos e, finalmente, inserir as características extraídas em LSTM para previsão. Para utilizar ainda mais as informações de dados multivariados, Wang et al. [95] desenvolveram o modelo LW-CLSTM. Em primeiro lugar, os dados de energia eólica, dados históricos de medição e dados de status da turbina são fundidos, limpos, reduzidos em dimensão e padronizados para extrair as características de período de tempo da potência de saída. Em seguida, o método proposto utilizou o algoritmo de janela deslizante no tempo para construir um conjunto de dados e inseri-lo em uma rede composta por CNN e LSTM para previsão.

O modelo geral de previsão de energia eólica não considera a correlação espaço-temporal entre as dimensões dos dados. Dou et al. [101] propuseram um método de modelagem de entrada de dados espaço-temporal multidimensional baseado em NWP em grade

e então usou uma rede com estrutura CNN e LSTM para previsão. Embora alguns modelos considerem a correlação espaço-temporal, eles ignoraram a influência de fatores meteorológicos com propriedades espaço-temporais na velocidade do vento. Chen et al. [96] desenvolveram um modelo de combinação de correlação espaço-temporal multifatorial CNN-LSTM. CNN é adotado para aprender a relação de características espaciais entre elementos meteorológicos em cada local e LSTM é empregado para aprender a relação de características temporais entre pontos de tempo históricos. Zhu et al. [97] introduziram uma arquitetura profunda denominada rede espaço-temporal preditiva. Primeiramente, as características espaciais das matrizes de velocidade do vento são extraídas pela CNN. Então, o LSTM captura a dependência temporal entre as feições espaciais.

Finalmente, insira os dois juntos no LSTM para previsão.

Alguns pesquisadores também empregaram redes LSTM com estruturas diferentes. Xiang et al. [98] fizeram pleno uso de informações de direções passadas e futuras e estabeleceram um modelo auto-regressivo baseado em um modelo de rede neural de memória de curto prazo bidirecional (WT-bi-LSTM) com decomposição wavelet para prever a velocidade do vento em várias escalas de tempo.

3.1.2 | Modelos com preditor de GRU

GRU é uma versão atualizada dos métodos baseados em RNN e compartilha uma estrutura semelhante com os métodos LSTM. Ele abandona o mecanismo da unidade de armazenamento, substitui a porta de esquecimento e a porta de entrada por uma porta de atualização z_t e substitui as portas de saída por uma porta de reinicialização r_t [102]. Muitos trabalhos de pesquisa mostraram que LSTM e GRU têm efeitos experimentais semelhantes, enquanto GRU é computacionalmente mais barato e eficiente [103]. A única célula GRU é ilustrada como Figura 4, e as formulações de seus nós são dadas como segue:

$$\tilde{y} = WZ \tilde{y} + b$$

$$\tilde{y} = \sigma(\tilde{y})$$

$$\tilde{y} = \tanh(\tilde{y})$$

$$\tilde{y} = \tilde{y} + \tilde{y}$$

onde W , Z , W_r são as matrizes de peso e \tilde{y} é a função de ativação sigmóide.




FIGURA 4 A estrutura de uma unidade recorrente fechada

Os métodos GRU foram combinados com várias abordagens de processamento e previsão de dados. Na Ref. [122], um modelo EMD-GRU bivariado é proposto e a função de cópula é utilizada para analisar a relação não linear entre a energia eólica e os fatores meteorológicos e extrair os fatores-chave com maior correlação com a energia eólica. Os dados bivariados compostos dos dois são inseridos em EMD bivariado, decompostos para obter dados de subsequência e, finalmente, feitas previsões usando GRU.

Para ampliar as aplicações do método quase-EMD na previsão real, a redução de ruído de limiar suave wavelet é aplicada à redução de ruído de séries temporais de velocidade do vento, seguido por GRU para previsão [104]. Tal combinação não só melhora a precisão da previsão, mas também reduz a volatilidade dos resultados. Embora o GRU possa capturar a dependência do intervalo de tempo e seja adequado para dados de séries temporais, ele não considera a correlação espacial. ConvGRU foi desenvolvido para combinar as vantagens de ambos para resolver o problema de previsão espaço-temporal [123]. O SSA-CNNGRU-SVR proposto combinou um CNNGRU para tendências

predição de componentes, uma camada convolucional para capturar recursos profundos e uma camada GRU para obter dependências de longo prazo [105]. Liu et al. [106] introduziram um modelo de rede neural espaço-temporal que integrou ConvGRU e CNN 3D e usou uma nova estrutura de previsão de codificação para gerar resultados espaço-temporais.

Mecanismos avançados de atenção e estratégias MIMO são usados para seleção de recursos. Niu et al. [107] propuseram uma arquitetura desenrolada de GRU sequência a sequência com o mecanismo de atenção (AGRU). O mecanismo de atenção avaliou a importância de cada variável de entrada em relação ao valor de energia eólica alvo e, em seguida, gerou uma representação ponderada com base em sua correlação com a variável alvo. O método de seleção de características baseado em um novo mecanismo de atenção identificou os fatores mais importantes que afetam o processo de geração de energia eólica em diferentes condições ambientais.

Alguns pesquisadores adotaram uma abordagem diferente e propuseram um novo método baseado em NWP. Em primeiro lugar, extraiu o desvio padrão do erro numérico da velocidade do vento da previsão meteorológica como pesos e reordena esses pesos de acordo com a série temporal numérica da velocidade do vento da previsão meteorológica para obter a série temporal ponderada.

Em seguida, é proposto um modelo de correção de erros baseado em um BiGRU. A velocidade do vento da previsão numérica do tempo, as tendências das séries temporais ponderadas e os detalhes são usados como entradas para corrigir o erro numérico da velocidade do vento da previsão do tempo. Ao usar a velocidade do vento de previsão numérica corrigida, o modelo de curva de energia eólica é empregado para prever a energia eólica de curto prazo [124]. Semelhante ao LSTM, o GRU também combinou métodos baseados em ideias de decomposição e previsão. Em [108], o SSA é usado para processar os dados originais em série principal e série residual, e o algoritmo VMD é adotado para processar o sinal residual, associado ao PSR para reconstruir a sequência decomposta no espaço de fase de alta dimensão e entrada BiGRU para previsão.

3.1.3 | Modelos com preditor de rede de estado de eco

A rede de estado de eco (ESN) é outro cluster importante nas áreas de aprendizado profundo. Ao contrário de outras RNNs, ESN usa o reservatório como uma camada oculta, consistindo na camada de entrada x , reservatório u e camada de saída y [125]. O reservatório mapeia os dados de entrada de um espaço de entrada de dimensão relativamente baixa para um espaço de estado de alta dimensão. Ele contém muitos neurônios esparsamente conectados com pesos iniciais aleatórios. Os pesos aleatórios iniciais permanecem inalterados durante o processo de treinamento. O processo de treinamento do ESN é aprender os pesos de conexão do reservatório para a camada de saída. A equação de atualização da rede é expressa da seguinte forma:

$$u(t+1) = f_1(W_{in}x(t) + W_{hh}u(t) + b_u)$$
$$y(t) = f_2(W_{hu}u(t) + b_y)$$

δ14p

δ15p

onde f_1 , f_2 são as funções de ativação, W_{in} , W_{hh} e W_{hu} denotam a matriz de peso de entrada, matriz de peso de reservatório e matriz de peso de saída, respectivamente.

Chitsazan et al. [109] desenvolveram NESN-P (polinômio) e NESN-MP (polinômio multivariável) para melhorar a capacidade de aprendizado e a eficiência computacional do ESN. Os autores projetaram um reservatório contendo um estado interno linear e uma leitura cuja saída é uma função não linear do estado interno. MP é um polinômio multivariado cúbico para reduzir o número de estados internos em relação ao ESN clássico.

No campo da previsão de séries temporais, decomposição e previsão são ideias mais comuns. WT é aplicado para eliminar a flutuação irregular da sequência e então utilizado PCA para reduzir a informação redundante da série de entrada. Além disso, SC é utilizado para selecionar o conjunto de amostra apropriado e ESN de entrada para previsão [126]. Um modelo WTESN é proposto, que usou o método de análise multi-resolução baseado em WT para decompor séries temporais em diferentes escalas de tempo [110].

A maioria dos estudos usa um único modelo para fazer previsões, enquanto sofre de baixa estabilidade e baixa precisão de previsão.

A literatura adotou ESN para integrar os resultados intermediários de quatro modelos mistos para produzir os resultados finais de previsão [127]. Por um lado, os maiores custos computacionais podem advir do uso de LSTM, que são overfitting devido aos hiperparâmetros e estruturas. Por outro lado, a simplicidade do ESN tradicional levará a uma baixa capacidade de generalização. Lopes et al. [128] combinaram os dois para propor um modelo LSTM + ESN, usando LSTM como o neurônio na camada oculta do ESN. Redes neurais mais profundas também podem melhorar o desempenho da previsão. Hu et al. [111] desenvolveram um DeepESN com múltiplos reservatórios para previsão de energia eólica.

3.2 | Modelos baseados em RBM

A máquina de boltzmann restrita (RBM) é uma rede neural estocástica generativa que aprende a distribuição de probabilidade de seus

entradas. Ela consiste em uma camada visível e uma camada oculta, e as unidades de uma camada são conectadas a todas as unidades da outra camada. Vale ressaltar que não há conexão entre nós dentro da camada visível ou oculta do RBM. O processo de treinamento é aprender o peso da conexão entre a camada de exibição e a camada oculta. Uma rede de crenças profundas (DBN) e máquinas de boltzmann profundas (DBM) podem ser formadas empilhando RBM. As duas camadas superiores do DBN são grafos não direcionados e as camadas restantes formam uma conexão direcionada de cima para baixo. DBM e DBN têm a mesma estrutura, mas todas as conexões são não direcionadas [129].

É um problema difícil para redes gerais extrair recursos avançados de sequências originais. É proposto um PDBM, que adiciona uma camada preditiva composta por vários valores de inferência sobre o DBM. O PDBM prevê a velocidade do vento por características de alto nível extraídas de características de baixo nível de séries de entrada [130]. Tao et al. [131] usaram DBN para previsão de energia eólica e obtiveram resultados relativamente bons. Khan et al. [112] combinaram ARIMA e DBN para fazer previsões, usaram ARIMA para prever os componentes convencionais após a decomposição VMD, adotaram DBN para prever os componentes irregulares e finalmente combinaram as técnicas para gerar o resultado final da previsão. Wang et al. [113] introduziram o método de agrupamento K-means para selecionar dados de amostra NWP que influenciam a precisão da previsão e entram no DBN para previsão.

Um modelo WT-DBN-QR é proposto, usando DBN para extrair estruturas invariantes profundas e características não lineares ocultas na sequência decomposta por WT [114].

À medida que o tamanho da amostra de treinamento aumenta, a complexidade computacional se torna maior. Yu et al. [115] propuseram a técnica DBNLP, que mapeia uma série temporal unidimensional para um espaço de alta dimensão, então seleciona amostras de treinamento com o mesmo padrão das amostras preditas com base na distância de Euclides e finalmente extrai DBN para predição.

3.3 | Modelos baseados em CNN

CNN é um tipo de rede neural feed-forward que consiste em camada de convolução, camada de amostragem e camada totalmente conectada [132]. A CNN é frequentemente usada para tarefas como classificação de gestos de mão, detecção de objetos e previsão de séries temporais [133].

A CNN usa a camada de convolução como o núcleo. A operação de um kernel de convolução aprende efetivamente os recursos espaciais complexos e a estrutura invariável nos dados. Sua expressão de cálculo é a seguinte:

$$y_k = f(\sum_j w_{kj}x_j + b_k)$$

δ16p

onde f representa a função de ativação e w , b denotam o peso e o desvio da k -ésima camada.

O método CNN atua como o principal previsor na previsão do vento. Wang et al. [134] empregou WT para decompor os dados de entrada em múltiplas frequências e, em seguida, utilizou DeepCNN para prever cada frequência. Zhu et al. [116] propuseram um PDCNN, onde a CNN foi aplicada para extrair

características e MLP foi aplicado para extrair a correlação espacial das características espaciais. Para melhorar o desempenho de previsão da CNN, os pesquisadores fazem melhorias com base na CNN tradicional. Mujeeb et al. [117] propuseram redes neurais de convolução profunda eficientes com uma camada de saída modificada, que é chamada de camada de saída de regressão aprimorada. Yildiz et al. [118] projetaram uma CNN profunda baseada em resíduos aprimorada.

O modelo proposto tem desempenho mais competitivo do que muitas redes atuais de última geração.

O simples aumento da profundidade da CNN não necessariamente faz com que o modelo tenha uma melhor capacidade de aprendizado. Na literatura [119], a rede convolucional dilatada residual baseada no modelo Unet com atenção não linear (ResAUnet) composta por rede convolucional causal dilatada como unidade básica é proposta. A arquitetura U-net foi usada para copiar os recursos de baixo nível para os recursos de alto nível correspondentes para recuperar ou aprimorar as informações temporais. Ele também aplicou um bloco de atenção residual para combinar o mapeamento de recursos de blocos residuais de nível inferior e um de nível superior e, em seguida, os dados são alimentados no bloco residual com a mesma dilatação

valor como o bloco residual de nível inferior correspondente.

3.4 | Modelos baseados em EA

Auto-encoder (AE) é uma variante de destaque de redes neurais para aprendizado não supervisionado, composto de camada de entrada, camada oculta e camada de saída. Ele usa codificadores e decodificadores para mapear entrada para saída para reconstruir dados [135].

Em [136], um modelo de previsão de dois estágios foi construído por AE. Na etapa de pré-treinamento, a rede modelo é composta por três EAs e, na etapa de ajuste fino, uma outra camada é adicionada ao final da rede de pré-treinamento. Yan et al. [120] estabeleceram uma rede de mapeamento multi-para-multi combinada com um auto-encoder empilhado sem ruído (SDAE) para previsão de energia eólica em multi-escala. Primeiro, os dados de entrada NWP baseados em SDAE são corrigidos e vários SDAEs com diversos parâmetros de modelo e recursos de entrada são integrados ao conjunto SDAE para previsão. Chen et al. [121] propuseram um modelo SDAE-ELM para previsão multi-período.

A análise de variância é aplicada para reduzir o impacto das flutuações de séries temporais e, em seguida, o SDAE é empregado para processar recursos não lineares de baixo nível e redução de ruído. Baseado em ELM O aluno integrado é usado para otimizar o processo de ajuste fino do SDAE.

Para melhorar o desempenho de generalização da EA, a esparsidade é introduzida como um item de regularização no processo de reciclagem de papel. Os EAs esparsos profundos são usados como regressores de base [137] para melhorar a previsibilidade da incerteza da velocidade do vento e eliminar o ruído dos dados. Khodayar et al. [138] projetaram uma arquitetura DNN com autocodificador empilhado SAE e SDAE para previsão. Ao mesmo tempo, neurônios ásperos também são usados para estender AE e DAE para formar um DNN robusto com camadas de regressão ásperas. Jahangir et al. [139] projetaram um método multimodal, usando SDAE para reduzir o ruído dos dados de entrada e uma rede neural áspera com uma função de ativação senoidal para previsão.

4 | DISCUSSÃO E FUTURO DIREÇÃO

Com o contínuo desenvolvimento da previsão de energia eólica, muitos trabalhos de pesquisa mostram que a precisão de previsão dos modelos híbridos combinando várias técnicas supera o modelo não híbrido [7]. Os trabalhos de pesquisa recentes utilizam principalmente o modelo híbrido. A Tabela 3 mostra o desempenho dos modelos citados no artigo. Resumindo o trabalho dos pesquisadores, descobrimos que a estrutura de previsão híbrida de energia eólica consiste em quatro etapas principais: pré-processamento de dados, previsão de previsão, pós-processamento de erros e avaliação de desempenho do modelo. As tecnologias que podem ser usadas em todo o processo de previsão podem ser divididas em 10 categorias: eliminação de ruído, detecção e correção de outliers, reamostragem, normalização, decomposição, engenharia de recursos, modelagem de erros residuais, correção baseada em filtros, algoritmo de previsão e otimização [7]. , 11, 140-142]. Houve uma revisão detalhada dessas tecnologias por estudiosos, e não vamos repeti-las aqui. Além disso, fornecemos algumas recomendações de pesquisa para desafios e questões em aberto no campo de previsão de energia eólica, como segue.

A perspectiva de aprendizagem multimodal que integra dados heterogêneos de várias fontes é ampla. A fusão adequada de dados multimodais pode efetivamente usar as informações abstratas existentes nos dados para obter percepção e previsão integradas [143]. O sistema de informações geográficas (GIS) pode fornecer informações detalhadas sobre o espaço geográfico dos parques eólicos, e a fusão dos dados fornecidos pelo GIS pode vincular as informações de localização das turbinas eólicas para uma previsão centralizada. O radar de abertura sintética interferométrica é uma tecnologia de radar usada em levantamento, mapeamento e sensoriamento remoto. Imagens obtidas por radar de abertura sintética são usadas para processamento coerente para gerar um modelo digital de elevação. Podemos extrair informações espaciais do modelo para previsão de energia eólica.

Deve-se colocar ênfase suficiente nas fronteiras do aprendizado profundo. Os transformadores têm grandes vantagens no processamento de dados de sequência, modelando dependências de longo prazo entre elementos de sequência de entrada e suportando processamento paralelo de sequências [144]. Podemos usar modelos desenvolvidos por pesquisadores baseados em transformadores, como DeepTransformer [145] e Informer [146], para tarefas de previsão de energia eólica, que podem ter resultados incríveis. Redes neurais de diferentes estruturas de topologia são viáveis. A rede neural gráfica pode ser usada para processar a relação de dependência entre dados multivariados de energia eólica e então fazer previsões [147]. Os dados processados pelo método de multi-resolução podem tirar proveito das informações ocultas pelos dados [148]. A rede neural baseada no mecanismo de atenção tem melhor desempenho que a RNN tradicional e traz resultados muito bons em muitas tarefas de processamento de sequências [149, 150]. É uma boa escolha para aprender a correlação temporal interna dos dados. Redes convolucionais gráficas podem ser aplicadas para aprender a correlação espacial entre sítios vizinhos [151]. A previsão determinística não pode

refletem a incerteza no mundo real, e a previsão probabilística é a direção de desenvolvimento da previsão de energia eólica no futuro. GAN condicional pode ser utilizado para aprender a distribuição de probabilidade condicional de conjuntos de dados de energia eólica [152].

Embora o modelo de previsão de energia eólica desenvolvido pelos pesquisadores já possa ser utilizado na prática, sua interpretabilidade ainda carece de pesquisas sistemáticas. Interpretabilidade significa que, ao resolver um problema, podemos obter informações suficientes de que precisamos e entendemos [153]. No campo da previsão de energia eólica, a interpretabilidade de modelos de aprendizado profundo pode fornecer a base para a tomada de decisão para cada previsão. Como resultado, os modelos explicativos são mais seguros e suas previsões mais confiáveis. A pesquisa de interpretabilidade é necessária para o controle e gestão de riscos no campo da energia eólica.

5 | CONCLUSÃO

A energia eólica é um tipo de fonte de energia renovável com a maior capacidade instalada do mundo e o desenvolvimento mais promissor no futuro. A precisão da previsão de energia eólica tem um grande impacto na estabilidade e segurança da rede. Melhorar a precisão da previsão de energia eólica pode trazer maiores benefícios econômicos e ambientais. Como um método importante no campo de previsão de energia eólica, o aprendizado profundo foi desenvolvido rapidamente nos últimos anos, e muitos estudiosos também revisaram esse campo. No entanto, a revisão existente não presta atenção à lógica de desenvolvimento do aprendizado profundo no campo da previsão de energia eólica.

Este artigo apresenta vários modelos de previsão de energia eólica baseados em aprendizado profundo. Preditores de aprendizado profundo incluem principalmente CNN, RNN, DBN, etc. Esses modelos híbridos de previsão baseados em DNNs têm suas próprias vantagens e desvantagens em diferentes tarefas de previsão. Por exemplo, modelos baseados em RNN são melhores para extrair dependências dentro de séries temporais, e baseados no modelo CNN são melhores para extrair a correlação de várias séries temporais. Algumas possíveis tendências de desenvolvimento futuro também são fornecidas para referência dos pesquisadores. Por exemplo, métodos em outros campos de previsão de séries temporais podem ser migrados para o campo de previsão de energia eólica, e arquiteturas de redes neurais avançadas desenvolvidas nos últimos anos também podem ser usadas. Na literatura revisada, não envolve o uso de algoritmos de otimização para otimizar parâmetros de redes neurais ou modelos de hiperparâmetros, mas foca principalmente na arquitetura e métodos de modelos preditivos.

AGRADECIMENTOS

Fundação Nacional de Ciência da China sob os subsídios 52077213 e 62003332, Apoiado pela Bolsa Visitante do Laboratório Chave do Estado de Equipamentos de Transmissão de Energia e Segurança de Sistemas e Novas Tecnologias (Universidade de Chongqing).

DECLARAÇÃO DE DISPONIBILIDADE DE DADOS Sim.

ORCID

Zhile Yang  <https://orcid.org/0000-0001-8580-534X>

REFERÊNCIAS

1. IEA: Global Energy Review 2020. Agência Internacional de Energia (2020)
2. GWEC: Relatório Global de Energia Eólica 2019. Conselho Global de Energia Eólica (2020)
3. Zhang, S., et al.: China no desenvolvimento global de energia eólica: papel, status e impacto. *Renovar. Sustentar. Energia Rev.* 127, 109881 (2020)
4. Grid, S.: State Grid Co. Ltd. Service New Energy Development Report 2020 (2020)
5. AWEA: Relatório Anual de 2019 da Wind Powers America. American Wind Agência de Energia (2019)
6. WWEA: Capacidade instalada até o final de 2019 (MW). Vento Mundial Agência de Energia (2019)
7. Jung, J., Broadwater, RP: Situação atual e avanços futuros para a velocidade do vento e previsão de energia. *Renovar. Sustentar. Energia Rev.* 31, 762–777 (2014)
8. Tascikaraoglu, A., Uzunoglu, M.: Uma revisão de abordagens combinadas para previsão de velocidade e potência do vento de curto prazo. *Renovar. Sustentar. Energia Rev.* 34, 243–254 (2014)
9. Wang, J., et al.: Análise e aplicação de modelos de previsão na integração de energia eólica: uma revisão de modelos de previsão de velocidade do vento multi-passo à frente. *Renovar. Sustentar. Energia Rev.* 60, 960–981 (2016)
10. Bokde, N., et al.: Uma revisão sobre modelos híbridos de decomposição de modo empírico para velocidade do vento e previsão de energia eólica. *Energias.* 12(2), 254 (2019)
11. Liu, H., Chen, C.: Estratégias de processamento de dados em modelos e aplicações de previsão de energia eólica: uma revisão abrangente. *Aplic. Energia.* 249, 392–408 (2019)
12. Liu, H., et al.: Previsão determinística de energia eólica: uma revisão de preditores inteligentes e métodos auxiliares. *Energia Convers. Gerenciar* 195, 328–345 (2019)
13. Vargas, SA, et al.: Geração de energia eólica: uma revisão e uma agenda de pesquisa. *J. Limpo. Prod.* 218, 850–870 (2019)
14. Wang, Y., et al.: Uma revisão de aplicações de algoritmos de inteligência artificial em parques eólicos. *Artif. Intel. Rev.* 53(5), 3447–3500 (2020)
15. González-Sopeña, J., Pakrashi, V., Ghosh, B.: Uma visão geral das métricas de avaliação de desempenho para previsão estatística de energia eólica de curto prazo. *Renovar. Sustentar. Energia Rev.* 183, 110515 (2020)
16. Yang, B., et al.: Manual completo de última geração sobre tecnologias de previsão de vento: uma visão geral de classificações, metodologias e análises. *J. Limpo. Prod.* 283, 124628 (2020)
17. Martinez, C., et al.: Prevendo a erosão das pás de turbinas eólicas usando aprendizado de máquina. *SMU Data Sci. Rev.* 2(2), 17 (2019)
18. Letcher, TM: Engenharia de energia eólica: um manual para onshore e turbinas eólicas offshore. *Imprensa Acadêmica* (2017)
19. Kalmikov, A.: Fundamentos de energia eólica. In: Jain, P. (ed.) *Energia Eólica Engenharia*, pp. 17–24. Elsevier (2017)
20. Ackermann, T., Söder, L.: Tecnologia de energia eólica e status atual: uma revisão. *Renovar. Sustentar. Energia Rev.* 4(4), 315–374 (2000)
21. Soman, SS, et al.: Uma revisão dos métodos de previsão de energia eólica e velocidade do vento com diferentes horizontes de tempo. In: *North American Power Symposium* 2010, pp. 1–8. IEEE (2010)
22. Colak, I., Sagiroglu, S., Yesilbudak, M.: Mineração de dados e previsão de energia eólica: uma revisão da literatura. *Renovar. Energia.* 46, 241–247 (2012)
23. Wang, Y., et al.: Uma revisão de aplicações de algoritmos de inteligência artificial em parques eólicos. *Artif. Intel. Rev.* 53(5), 3447–3500 (2019)
24. Zhao, X., Wang, S., Li, T.: Revisão dos critérios de avaliação e principais métodos de previsão de energia eólica. *Energia Proc.* 12, 761–769 (2011)
25. Chang, WY, et al.: Uma revisão da literatura de métodos de previsão de vento. *J. Energia Energia Eng.* 2(04), 161–168 (2014)
26. Monteiro, C., et al.: Previsão de energia eólica: estado da arte 2009. Relatório técnico, Argonne National Lab. (ANL), Argonne, IL (Estados Unidos) (2009)

27. Jiang, Y., et al.: Uma nova estrutura híbrida para previsão probabilística da velocidade do vento usando seleção profunda de recursos e modificação de múltiplos erros. *Energia Convers. Gerenciar* 199, 111981 (2019)
28. Giebel, G., et al.: O estado da arte na previsão de curto prazo de energia eólica: uma visão geral da literatura. *ANEMOS*. mais (2011)
29. Haque, AU, Nehrir, MH, Mandal, P.: Um modelo inteligente híbrido para abordagem de regressão determinística e quantílica para previsão de energia eólica probabilística. *Trans. IEEE Sistema de energia* 29(4), 1663–1672 (2014)
30. Stetsos, A.: Uma comparação de várias técnicas de previsão aplicadas a séries temporais de velocidade média horária do vento. *Renovar. Energia*. 21(1), 23–35 (2000)
31. Liu, H., Tian, Hq, Li, Yf: Comparação de dois novos métodos híbridos ARIMA-ANN e ARIMA-Kalman para previsão da velocidade do vento. *Aplic. Energia*. 98, 415–424 (2012)
32. Zhou, Q., Wang, C., Zhang, G.: Sistema de previsão híbrido baseado em uma estratégia de seleção de modelo ótimo para diferentes problemas de previsão de velocidade do vento. *Aplic. Energia*. 250, 1559–1580 (2019)
33. Poggi, P., et al.: Previsão e simulação da velocidade do vento na Córsega usando um modelo autorregressivo. *Energia Convers. Gerenciar* 44(20), 3177–3196 (2003)
34. Nielsen, HA, Madsen, H., Nielsen, TS: Usando regressão quantílica para estender um sistema de previsão de energia eólica existente com previsões probabilísticas. *Energia eólica*. 9(1-2), 95-108 (2006)
35. Rajagopalan, S., Santos, S.: Previsão de energia eólica e análise de erros usando a modelagem de média móvel autoregressiva. In: *Assembleia Geral da Sociedade de Energia e Energia do IEEE 2009*, pp. 1–6. IEEE (2009)
36. Erdem, E., Shi, J.: Abordagens baseadas em ARMA para prever a tupla de velocidade e direção do vento. *Aplic. Energia*. 88(4), 1405–1414 (2011)
37. Cao, Y., et al.: Método de previsão de energia eólica de ultracurto prazo combinado com combinação de padrões e modelo ARMA. In: *2013 IEEE Gre Noble Conference*, pp. 1–4. IEEE (2013)
38. Torres, JL, et al.: Previsão da velocidade média horária do vento com ARMA modelos em Navarra (Espanha). *Sol. Energia*. 79(1), 65–77 (2005)
39. Liu, Y., Roberts, MC, Sioshansi, R.: Um modelo meteorológico de autorregressão vetorial para modelagem de oferta e demanda de eletricidade. *J. Mod. Sistema de energia Energia limpa*. 6(4), 763-776 (2018)
40. Tastu, J., et al.: Análise espaço-temporal e modelagem de erros de previsão de energia eólica de curto prazo. *Energia eólica*. 14(1), 43-60 (2011)
41. Lv, P., Yue, L.: Previsão da velocidade do vento a curto prazo com base na análise de séries temporais não estacionárias e modelo ARCH. In: *2011 International Conference on Multimedia Technology*, pp. 2549–2553. IEEE (2011)
42. Wang, MD, Qiu, QR, Cui, BW: Método de série temporal combinado de previsão de velocidade do vento de curto prazo e modelo de arco. In: *2012 International Conference on Machine Learning and Cybernetics*, vol. 3, pp. 924-927. IEEE (2012)
43. Singh, S., Mohapatra, A., et al.: Modelo ARIMA baseado em transformada wavelet repetida para previsão de velocidade do vento de muito curto prazo. *Renovar. Energia*. 136, 758-768 (2019)
44. Shukur, OB, Lee, MH: Previsão diária da velocidade do vento através do modelo híbrido KF-ANN baseado em ARIMA. *Renovar. Energia*. 76, 637-647 (2015)
45. Yunus, K., Thiringer, T., Chen, P.: modelagem decomposta em frequência baseada em ARIMA de séries temporais de velocidade do vento. *Trans. IEEE Sistema de energia* 31(4), 2546–2556 (2015)
46. Liu, H., Tian, Hq, Li, Yf: Um método ARIMA recursivo EMD para prever a velocidade do vento para o sistema ferroviário de alerta de vento forte. *J. Wind Eng. Ind. Aerod*. 141, 27-38 (2015)
47. Wang, J., et al.: Técnicas de aplicação de redução de ruído wavelet em um modelo combinado para previsão de carga de curto prazo. *Int. J. Eletr. Sistema de energia de energia* 62, 816-824 (2014)
48. Kavasseri, RG, Seetharaman, K.: Previsão da velocidade do vento no dia anterior usando modelos f-ARIMA. *Renovar. Energia*. 34(5), 1388–1393 (2009)
49. Yuan, X., et al.: Previsão de energia eólica usando máquina de vetor de suporte de mínimos quadrados e média móvel autoregressiva híbrida fracionadamente integrada. *Energia*. 129, 122–137 (2017)
50. Fang, C., Gao, Y., Ruan, Y.: Melhorando a precisão da previsão do consumo diário de energia do prédio de escritórios usando análise de séries temporais na decomposição da transformada wavelet. In: *IOP Conference Series: Earth and Environmental Science*, vol. 294, pág. 012031. Publicação IOP (2019)
51. Deng, Y., Wang, B., Lu, Z.: Um modelo híbrido baseado em estratégia de pré-processamento de dados e sistema de correção de erros para previsão de velocidade do vento. *Energia Convers. Gerenciar* 212, 112779 (2020)
52. Lydia, M., et al.: Modelos autorregressivos lineares e não lineares para previsão de velocidade do vento de curto prazo. *Energia Convers. Gerenciar* 112, 115–124 (2016)
53. Zhang, C., et al.: Uma abordagem híbrida baseada em regressão de processo gaussiana para previsão de velocidade do vento a curto prazo. *Energia Convers. Gerenciar* 126, 1084–1092 (2016)
54. Karakuş, O., Kuruoğlu, EE, Altınkaya, MA: Previsão de velocidade/potência do vento de um dia à frente com base no modelo autoregressivo polinomial. *Renovação IET. Gerador de energia*. 11(11), 1430–1439 (2017)
55. Maatallah, OA, et al.: Previsão recursiva da velocidade do vento com base no modelo Auto-Regressivo de Hammerstein. *Aplic. Energia*. 145, 191–197 (2015)
56. Pinson, P., et al.: Modelagem de mudança de regime das flutuações da geração eólica offshore. *J. Wind Eng. Ind. Aerod*. 96(12), 2327–2347 (2008)
57. Ailliot, P., Monbet, V.: Modelos autorregressivos de comutação de Markov para séries temporais de vento. *Ambiente. Modelo. Programas*. 30, 92-101 (2012)
58. Cadenas, E., et al.: Previsão da velocidade do vento usando um modelo ARIMA univariado e um modelo NARX multivariado. *Energias*. 9(2), 109 (2016)
59. Jiang, Y., et al.: Um novo método de previsão da velocidade do vento: híbrido de DWT auxiliado por correlação, LSSVM e GARCH. *J. Wind Eng. Ind. Aerod*. 174, 28–38 (2018)
60. Fei, Sw: Um modelo híbrido de EMD e algoritmo RVR de núcleo múltiplo para previsão da velocidade do vento. *Int. J. Eletr. Sistema de energia de energia* 78, 910-915 (2016)
61. Ambach, D., Schmid, W.: Uma nova abordagem de séries temporais de alta dimensão para a velocidade do vento, direção do vento e previsão da pressão do ar. *Energia*. 135, 833-850 (2017)
62. Wang, Y., et al.: Previsão de energia eólica determinística e probabilística usando um modelo de regressão multi-kernel robusto adaptativo variacional baseado em Bayesiano. *Aplic. Energia*. 208, 1097-1112 (2017)
63. Marugán, AP, et al.: Um levantamento de rede neural artificial em sistemas de energia eólica. *Aplic. Energia*. 228, 1822–1836 (2018)
64. Hu, Q., Zhang, R., Zhou, Y.: Transferência de aprendizado para previsão de velocidade do vento de curto prazo com redes neurais profundas. *Renovar. Energia*. 85, 83-95 (2016)
65. Goodfellow, I., Bengio, Y., Courville, A.: *Aprendizado profundo*. Imprensa do MIT (2016)
66. Hochreiter, S., Schmidhuber, J.: Longa memória de curto prazo. *Computação Neural*. 9(8), 1735–1780 (1997)
67. Wu, W., et al.: Previsão probabilística de energia eólica de curto prazo com base em redes neurais profundas. In: *2016 International Conference on Probabilistic Methods Applied to Power Systems (PMAPS)*, pp. 1–8. IEEE (2016)
68. Yang, T., et al.: Um novo método de previsão da velocidade do vento por olho mágico LSTM. In: *2018 International Conference on Power System Technology (POWERCON)*, pp. 364–369. IEEE (2018)
69. Yu, R., et al.: LSTM-EFG para previsão de energia eólica com base em recursos de correlação sequencial. *Geração Futura. Computar. Sistema* 93, 33-42 (2019)
70. Zhang, Z., et al.: Método de previsão da velocidade do vento usando rede de memória de longo prazo de peso compartilhado e regressão de processo gaussiana. *Aplic. Energia*. 247, 270–284 (2019)
71. Eze, EC, Chatwin, CR: Rede neural recorrente aprimorada para previsão de produção de energia de parques eólicos de curto prazo. *IJRDO J. Appl. Sci*. 5(2), 28–35 (2019)
72. Araya, IA, Valle, C., Allende, H.: modelo multi-escala baseado em LSTM para previsão da velocidade do vento. In: *Congresso Iberoamericano de Reconhecimento de Padrões*, pp. 38–45. Springer (2018)
73. Pei, S., et al.: Método de previsão da velocidade do vento baseado em transformada wavelet empírica e nova rede de memória de longo prazo de atualização de célula. *Energia Convers. Gerenciar* 196, 779-792 (2019)

74. Zhang, Z., et al.: Rede de memória de curto prazo longa baseada em portas de vizinhança para processamento de causalidade complexa na previsão da velocidade do vento. *Energia Convers. Gerenciar* 192, 37-51 (2019)
75. López, E., et al.: Treinamento eficiente sobre redes de memória de curto prazo para previsão da velocidade do vento. In: Congresso Iberoamericano de Reconhecimento de Padrões, pp. 409–416. Springer (2016)
76. Xiaoyun, Q., et al.: Previsão de curto prazo da energia eólica com base na memória de longo prazo profunda. In: 2016 IEEE PES Asia-Pacific Power and Energy Engineering Conference (APPEEC), pp. 1148–1152. IEEE (2016)
77. Xu, G., Xia, L.: Previsão de curto prazo da energia eólica com base no LSTM adaptativo. In: 2ª Conferência IEEE sobre Energia, Internet e Integração de Sistemas de Energia (EI2), pp. 1–5. IEEE (2018)
78. Huang, Y., Liu, S., Yang, L.: Método de previsão da velocidade do vento usando EEMD e o método de previsão combinado baseado em GPR e LSTM. *Sustentabilidade*. 10(10), 3693 (2018)
79. Liu, H., Mi, Xw, Li, Yf: Método de previsão da velocidade do vento baseado em estratégia de aprendizado profundo usando transformada wavelet empírica, rede neural de memória de longo prazo e rede neural Elman. *Energia Convers. Gerenciar* 156, 498–514 (2018)
80. Li, M., et al.: Previsão de velocidade do vento de prazo ultracurto usando decomposição de morfologia matemática e memória de curto prazo longo. *CSEE J. Power Energy Syst.* 6(4), 890–900 (2020)
81. Liu, Y., et al.: Previsão de curto prazo de energia eólica com base em LSTM e transformada wavelet discreta. *Aplic. Sci.* 9(6), 1108 (2019)
82. Liu, X., et al.: Previsão da velocidade do vento usando rede neural profunda com seleção de recursos. *Neurocomputação*. 397, 393–403 (2020)
83. Wu, YX, Wu, QB, Zhu, JQ: Previsão de velocidade do vento baseada em dados usando extração de características profundas e LSTM. *Renovação IET. Gerador de energia*. 13(12), 2062–2069 (2019)
84. Liu, H., Mi, X., Li, Y.: Modelo de previsão de velocidade do vento baseado em aprendizado profundo inteligente usando decomposição de pacotes wavelet, rede neural convolucional e rede de memória de longo prazo convolucional. *Energia Convers. Gerenciar* 166, 120–131 (2018)
85. Li, Y., Wu, H., Liu, H.: Previsão da velocidade do vento em várias etapas usando decomposição EWT, computação principal LSTM, computação subordinada RELM e reconstrução IEWT. *Energia Convers. Gerenciar* 167, 203-219 (2018)
86. Jaseena, K., Kovoov, BC: Um modelo híbrido de previsão de velocidade do vento usando autoencoder empilhado e LSTM. *J. Renovar. Sustentar. Energia*. 12(2), 023302 (2020)
87. Moreno, SR, et al.: Previsão de velocidade do vento em várias etapas com base no modelo híbrido de decomposição em vários estágios e rede neural de memória de longo prazo. *Energia Convers. Gerenciar* 213, 112869 (2020)
88. Ma, Z., et al.: Aplicação de modelo híbrido baseado em posição de dupla decomposição, correção de erros e aprendizado profundo na previsão de velocidade do vento de curto prazo. *Energia Convers. Gerenciar* 205, 112345 (2020)
89. Liang, S., Nguyen, L., Jin, F.: Uma rede de memória de longo prazo empilhada multivariável para previsão da velocidade do vento. In: 2018 IEEE International Conference on Big Data (Big Data), pp. 4561–4564. IEEE (2018)
90. Liu, H., Mi, X., Li, Y.: Modelo inteligente de aprendizado profundo de várias etapas para previsão de velocidade do vento com base na decomposição de modo variacional, análise de espectro singular, rede LSTM e ELM. *Energia Convers. Gerenciar* 159, 54-64 (2018)
91. Wang, J., Li, Y.: Previsão de velocidade do vento de vários passos à frente com base na extração de recursos ideal, rede neural de memória de longo prazo e estratégia de correção de erros. *Aplic. Energia*. 230, 429–443 (2018)
92. Chen, G., et al.: Previsão de velocidade do vento de curto prazo com preditor subordinado de princípio baseado em conv-LSTM e BPNN melhorado. *Acesso IEEE*. 8, 67955–67973 (2020)
93. Lu, K., et al.: Modelo de previsão de energia eólica de curto prazo baseado no codificador-decodificador LSTM. In: IOP Conference Series: Earth and Environmental Science, vol. 186, pág. 012020 (2018)
94. Yin, H., et al.: Uma abordagem de previsão de energia eólica de aprendizado profundo em cascata com base em duas camadas de decomposição de modo. *Energia*. 189, 116316 (2019)
95. Wang, Y., et al.: Um modelo de previsão de potência de saída de curto prazo de energia eólica baseado em aprendizado profundo de séries temporais agrupadas. *EUR. J. Elec. Eng.* 22(1), 29–38 (2020)
96. Chen, Y., et al.: Modelo de correlação espaço-temporal multifatorial baseado em uma combinação de rede neural convolucional e rede neural de memória de longo prazo para previsão de velocidade do vento. *Energia Convers. Gerenciar* 185, 783-799 (2019)
97. Zhu, Q., et al.: Aprendendo correlações temporais e espaciais em conjunto: uma estrutura unificada para a previsão da velocidade do vento. *Trans. IEEE Sustentar. Energia*. 11(1), 509–523 (2019)
98. Xiang, J., et al.: Previsão de velocidade do vento em escala multi-tempo com base em WT-bi-LSTM. In: MATEC Web of Conferences, vol. 309, pág. 05011. EDP Ciências (2020)
99. Su, Y., et al.: Um método de previsão de energia eólica baseado em LSTM considerando componentes de frequência do vento e os estados da turbina eólica. In: 22ª Conferência Internacional de Máquinas e Sistemas Elétricos de 2019 (ICEMS), pp. 1–6. IEEE (2019)
100. Li, G., et al.: A aplicação do algoritmo de rede neural profunda considerando extração de características meteorológicas multidimensionais na previsão da velocidade do vento a curto prazo. In: 2019 IEEE 3rd Technology, Networking, Electronic and Automation Control Conference (ITNEC), pp. 2432–2437. IEEE (2019)
101. Dou, J., Liu, C., Wang, B.: Previsão de energia eólica de curto prazo com base em correlações espaço-temporais. In: 2018 International Conference on Mechanical, Electrical, Electronic Engineering & Science (MEEES 2018). Atlantis Press (2018)
102. Bahdanau, D., Cho, K., Bengio, Y.: Tradução automática neural aprendendo conjuntamente a alinhar e traduzir. *arXiv pré-impressão arXiv:1409.0473* (2014)
103. Wang, W., et al.: R-NET: compreensão de leitura de máquina com redes de auto-correspondência. Natural Language Computer Group, Microsoft Research. Ásia, Pequim', relatório técnico, China, relatório técnico 5, (2017)
104. Peng, Z., et al.: Um novo modelo de conjunto de aprendizado profundo com redução de ruído de dados para previsão de velocidade do vento de curto prazo. *Energia Convers. Gerenciar* 207, 112524 (2020)
105. Liu, H., et al.: Smart wind speed deep learning baseado em multi-step fore casting model usando análise de espectro singular, rede convolucional Gated Recurrent Unit e Support Vector Regression. *Renovar. Energia*. 143, 842-854 (2019)
106. Liu, Y., et al.: Previsão probabilística espaço-temporal da velocidade do vento com base em um modelo de aprendizado profundo Bayesiano variacional. *Aplic. Energia*. 260, 114259 (2020)
107. Niu, Z., et al.: Previsão de energia eólica usando rede de unidades recorrentes fechadas baseadas em atenção. *Energia*. 196, 117081 (2020)
108. Xiang, L., et al.: Previsão multi-passo determinística e probabilística para velocidade do vento de curto prazo com base na decomposição secundária e um método de aprendizado profundo. *Energia Convers. Gerenciar* 220, 113098 (2020)
109. Chitsazan, MA, Fadali, MS, Trzynadlowski, AM: Velocidade do vento e previsão da direção do vento usando rede de estado de eco com funções não lineares. *Renovar. Energia*. 131, 879-889 (2019)
110. Gouveia, HTV, De Aquino, RRB, Ferreira, AA: Melhorar a previsão de energia eólica de curto prazo através de análise multiresolução e redes de estados de eco. *Energias*. 11(4), 824 (2018)
111. Hu, H., Wang, L., Lv, SX: Previsão de consumo de energia e geração de energia eólica usando rede de estado de eco profundo. *Renovar. Energia*. 154, 598-613 (2020)
112. Khan, A., et al.: Geração e regressão de recursos baseados em redes de crença profunda para prever a energia eólica. *arXiv pré-impressão arXiv:1807.11682* (2018)
113. Wang, K., et al.: Abordagem de cluster k-means baseada em rede de crença profunda para previsão de energia eólica de curto prazo. *Energia*. 165, 840-852 (2018)
114. Wang, H., et al.: Abordagem de previsão de velocidade do vento determinística e probabilística baseada em rede de crenças profundas. *Aplic. Energia*. 182, 80-93 (2016)
115. Yu, Y., et al.: Previsão da velocidade do vento de curto prazo usando uma rede de crença profunda combinada com um preditor local. *Trans. IEEJ Eletr. Elétron. Eng.* 14 (2), 238–244 (2019)

116. Zhu, Q., et al.: Previsão da velocidade do vento com correlação espaço-temporal: uma abordagem de aprendizado profundo. *Energias*. 11(4), 705 (2018)
117. Mujeeb, S., et al.: Previsão de energia eólica baseada em redes neurais de convolução profunda eficientes. In: *International Conference on P2P, Parallel, Grid, Cloud and Internet Computing*, pp. 47–56. Springer (2019)
118. Yildiz, C., et al.: Uma rede neural convolucional baseada em resíduo aprimorada para previsão de energia eólica de muito curto prazo. *Energia Convers. Gerenciar* 228, 113731 (2021)
119. Shivam, K., Tzou, JC, Wu, SC: Previsão de velocidade do vento de curto prazo em várias etapas usando uma rede convolucional causal dilatada residual com atenção não linear. *Energias*. 13(7), 1772 (2020)
120. Yan, J., et al.: Previsão da alta penetração da energia eólica em múltiplas escalas usando mapeamento multi-para-multi. *Trans. IEEE Sistema de energia* 33(3), 3276–3284 (2018)
121. Chen, L., Li, Z., Zhang, Y.: Previsão de velocidade do vento multiperiod-ahead usando arquitetura neural profunda e aprendizado de conjunto. *Matemática. Problema Eng.* 1–14 (2019)
122. Liu, H., Lin, W., Li, Y.: Previsão de energia eólica de curto prazo com base na função de cópula e algoritmo de decomposição EMD bivariada. *Arco. Eletr. Eng.* 69(2), 271–286 (2020)
123. Liu, Y., et al.: Previsão espaço-temporal do conjunto de irradiação solar usando rede de unidade recorrente de portão convolucional Bayesiano variacional. *Aplic. Energia*. 253, 113596 (2019)
124. Ding, M., et al.: Um modelo de correção de erro de velocidade do vento baseado em redes neurais de unidade recorrente fechada para previsão de energia eólica de curto prazo. *Neurocomputação*. 365, 54–61 (2019)
125. Jaeger, H., Haas, H.: Aproveitando a não linearidade: prevendo sistemas caóticos e economizando energia em comunicação sem fio. *Ciência*. 304(5667), 78–80 (2004)
126. Liu, D., Wang, J., Wang, H.: Previsão de velocidade do vento de curto prazo com base em agrupamento espectral e redes otimizadas de estado de eco. *Renovar. Energia*. 78, 599–608 (2015)
127. Chen, Y., et al.: Um novo modelo combinado baseado em rede de estado de eco para previsão de velocidade do vento em várias etapas: um estudo de caso do NREL. *Energia Convers. Gerenciar* 179, 13–29 (2019)
128. López, E., et al.: Previsão de energia eólica com base em redes de estado de eco e memória de longo prazo. *Energias*. 11(3), 526 (2018)
129. Salakhutdinov, R., Hinton, G.: Um procedimento de aprendizagem eficiente para máquinas profundas de Boltzmann. *Computação Neural*. 24(8), 1967–2006 (2012)
130. Zhang, CY, et al.: Máquina de Boltzmann profunda preditiva para previsão de velocidade do vento multiperíodo. *Trans. IEEE Sustentar. Energia*. 6(4), 1416–1425 (2015)
131. Tao, Y., Chen, H., Qiu, C.: Previsão de energia eólica e recurso de padrão baseado no método de aprendizado profundo. In: *2014 IEEE PES Asia-Pacific Power and Energy Engineering Conference (APPEEC)*, pp. 1–4. (2014)
132. LeCun, Y., Bengio, Y., et al.: Redes convolucionais para imagens, fala e séries temporais. *Manual Teoria do Cérebro Rede Neural*. 3361(10), 1995 (1995)
133. Gadekallu, TR, Mamoun, A., et al.: Classificação do gesto da mão usando um novo algoritmo de busca CNN-corvo. *Inteligência Complexa. Sistema* 19(1), 1–14 (2021)
134. Wang, Hz, et al.: Abordagem de conjunto baseada em aprendizado profundo para previsão probabilística de energia eólica. *Aplic. Energia*. 188, 56–70 (2017)
135. Bengio, Y., et al.: Treinamento em camadas gananciosos de redes profundas. In: *Avanços em Sistemas de Processamento de Informação Neural*, pp. 153–160. (2007)
136. Jiao, R., et al.: Um modelo que combina codificador automático empilhado e algoritmo de retropropagação para previsão de energia eólica de curto prazo. *Acesso IEEE*. 6, 17851–17858 (2018)
137. Qureshi, AS, et al.: Previsão de energia eólica usando meta-regressão baseada em rede neural profunda e aprendizado de transferência. *Aplic. Computação Suave*. 58, 742–755 (2017)
138. Khodayar, M., Kaynak, O., Khodayar, ME: Textura de archie neural profunda áspera para previsão de velocidade do vento de curto prazo. *Trans. IEEE Ind. Inf.* 13 (6), 2770–2779 (2017)
139. Jahangir, H., et al.: Quadro de previsão de velocidade do vento de curto prazo com base em auto-encoders empilhados de denoising com RNA bruto. *Sustentar. Avaliações Tecnológicas Energéticas*. 38, 100601 (2020)
140. Deng, X., et al.: Métodos de previsão de energia eólica baseados em aprendizado profundo: uma pesquisa. *Computar. Modelo. Eng. Sci.* 122(1), 273–301 (2020)
141. Wang, Y., et al.: Um modelo de previsão para potência de saída de ultra-curto prazo de parques eólicos com base em aprendizado profundo. *Int. J. Computação. Comum. Ao controle*. 15(4) (2020)
142. Lei, M., et al.: Uma revisão sobre a previsão da velocidade do vento e gerado potência. *Renovar. Sustentar. Energia Rev.* 13(4), 915–920 (2009)
143. Ramachandram, D., Taylor, GW: Aprendizagem multimodal profunda: uma pesquisa sobre avanços e tendências recentes. *Processo de Sinal IEEE. Mag.* 34(6), 96–108 (2017)
144. Vaswani, A., et al.: Atenção é tudo que você precisa. In: *Avanços em Sistemas de Processamento de Informação Neural*, pp. 5998–6008. (2017)
145. Wu, N., et al.: Modelos de transformadores profundos para previsão de séries temporais: o caso de prevalência da gripe. *arXiv pré-impressão arXiv:2001.08317* (2020)
146. Zhou, H., et al.: Informador: além de transformador eficiente para previsão de séries temporais de sequência longa. *arXiv pré-impressão arXiv:2012.07436* (2020)
147. Wu, Z., et al.: Conectando os pontos: previsão de séries temporais multivariadas com redes neurais gráficas. *arXiv pré-impressão arXiv:2005.11650* (2020)
148. Liu, H., Yang, R., Duan, Z.: Previsão da velocidade do vento usando uma nova fusão multifatorial e modelo de conjunto multirresolução com tempo real decomposição e correção adaptativa de erros. *Energia Convers. Gerenciar* 217, 112995 (2020)
149. Dai, Z., et al.: Transformer-xl: modelos de linguagem atentos além de um contexto de comprimento fixo. *arXiv pré-impressão arXiv:1901.02860* (2019)
150. Lan, Z., et al.: Albert: a lite bert para aprendizagem auto-supervisionada de representações de linguagem. *arXiv pré-impressão arXiv:1909.11942* (2019)
151. Zhu, J., et al.: A3T-GCN: rede convolucional atenção gráfico temporal para previsão de tráfego. *arXiv pré-impressão arXiv:2006.11583* (2020)
152. Koochali, A., Dengel, A., Ahmed, S.: Se você gosta, GAN. Previsão de séries temporais multivariadas probabilísticas Com GAN. *arXiv pré-impressão arXiv:2005.01181* (2020)
153. Zhang, Qs, Zhu, SC: Interpretabilidade visual para aprendizado profundo: uma pesquisa. *Fronte. Inf. Tecnol. Elétron. Eng.* 19(1), 27–39 (2018)

Como citar este artigo: Wu, Z., et al.: Uma revisão abrangente sobre abordagens de aprendizado profundo em aplicações de previsão de vento. *CAAI Trans. Intel. Tecnol.* 1-15 (2022). <https://doi.org/10.1049/cit2.12076>