



Análise

# Explorando Modelos de Previsão de Séries Temporais para Preços Dinâmicos em Publicidade de Sinalização Digital

Yee-Fan Tan , Lee-Yeng Ong\* , Meng-Chew Leow e Yee-Xian Goh

Faculdade de Ciência e Tecnologia da Informação, Universidade Multimídia, Melaka 75450, Malásia;  
1171202077@student.mmu.edu.my (Y.-FT); mcleow@mmu.edu.my (M.-CL); 1171201118@student.mmu.edu.my (Y.-XG)

\* Correspondência: lyong@mmu.edu.my; Tel.: +60-625-23-761

**Resumo:** A atenção do público é vital na Digital Signage Advertising (DSA), pois tem um impacto significativo na decisão de preços para anunciar nesses meios. Vários fatores ambientais afetam o nível de atenção do público em relação à sinalização publicitária. As estratégias de preço fixo, que foram aplicadas em DSA para decisões de preços, geralmente são ineficientes para maximizar o lucro potencial do provedor de serviços, pois os fatores ambientais que podem afetar a atenção do público estão mudando rapidamente e geralmente não são considerados na precificação atual soluções em tempo hábil.

Portanto, o método de previsão de séries temporais é uma solução de precificação adequada para DSA, pois melhora a decisão de precificação ao modelar as mudanças nos fatores ambientais e no nível de atenção do público em relação à sinalização para precificação ideal. No entanto, é difícil determinar um modelo de previsão de preço ideal para DSA com o número crescente de modelos de previsão de séries temporais disponíveis nos últimos anos. Com base nos 84 artigos de pesquisa revisados, a análise das características dos dados em termos de linearidade, estacionaridade, volatilidade e tamanho do conjunto de dados é útil para determinar o modelo ideal para a previsão de preços de séries temporais. Este artigo revisou os modelos de previsão de séries temporais amplamente utilizados e identificou as características de dados relacionadas de cada modelo. Um framework é proposto para demonstrar o processo de seleção de modelos para precificação dinâmica em DSA com base em sua análise de características de dados, abrindo caminho para futuras pesquisas de soluções de precificação para DSA.

**Palavras-chave:** previsão de séries temporais; precificação dinâmica; publicidade de sinalização digital; características dos dados; seleção de modelo



**Citação:** Tan, Y.-F.; Ong, L.-Y.; Leow, M.-C.; Goh, Y.-X. Explorando Modelos de Previsão de Séries Temporais para Preços Dinâmicos em Publicidade de Sinalização Digital. *Internet futura* **2021**, *13*, 241.  
<https://doi.org/10.3390/fi13100241>

Editores Acadêmicos:

Vijayakumar Varadarajan,  
Rajanikanth Aluvalu e  
Ketan Kotecha

Recebido: 26 de agosto de 2021

Aceito: 13 de setembro de 2021

Publicado: 22 de setembro de 2021

**Nota do editor:** MDPI permanece neutro em relação a reivindicações jurisdicionais em mapas publicados e afiliação institucional ias.



**Direitos autorais:** © 2021 pelos autores. Licenciado MDPI, Basileia, Suíça.

Este artigo é um artigo de acesso aberto distribuídos nos termos e condições do Creative Commons

Licença de atribuição (CC BY) (<https://creativecommons.org/licenses/by/4.0/>).

## 1. Introdução

A atenção do público é um fator que tem o impacto mais significativo na decisão de preço da Digital Signage Advertising (DSA) [1]. Geralmente, quanto maior o nível de atenção recebido por um anúncio de sinalização digital, maior a expectativa de lucro. Vários fatores ambientais podem influenciar o nível de atenção do público, incluindo a popularidade do local, temperatura e umidade do ar, condições climáticas, classe social da comunidade do entorno, entre outros [2]. Esses fatores são importantes para determinar a decisão de preço do DSA para maximizar a receita e aumentar a eficácia da publicidade.

As atuais soluções de precificação da DSA apresentam algumas deficiências na obtenção da decisão ótima de precificação. Comumente, os mecanismos de precificação aplicados ao DSA são a estratégia de preço fixo ou a estratégia de precificação baseada em leilão [1,3]. Em uma estratégia de preço fixo, o spot publicitário em uma sinalização digital específica é cobrado com um preço fixo pré-determinado. Pode ser na forma de vendas diretas ou de um contrato garantido com o prestador de serviços. O preço é comumente estabelecido com base no nível de atenção do público de um spot publicitário. No entanto, as mudanças no nível de atenção para o local no tempo devido às mudanças nos fatores ambientais circundantes não são consideradas, resultando em preços abaixo do ideal. Em uma estratégia de preços baseada em leilão, o preço varia com base em informações contextuais, como local e horário, número de dispositivos móveis detectados nas proximidades e outros. Essas informações são usadas como fatores para gerar um lance, e o spot publicitário



Este artigo está dividido em quatro seções. A Seção 2 apresenta a revisão das séries temporais modelos de previsão baseados nas características dos dados. A Seção 3 mostra um resumo de as características de dados adequadas para os modelos de previsão de séries temporais e uma proposta estrutura para seleção de modelo ideal com base na análise de características de dados de DSA. As conclusões são tiradas na Seção 4.

## 2. Revisão dos Estudos de Previsão de Séries Temporais


A previsão de séries temporais é usada para prever atividades futuras com base no histórico atual. dados [9]. Comumente, os dados de séries temporais possuem as seguintes características: linearidade, estacionaridade e volatilidade. A linearidade refere-se às relações lineares dos dados da série temporal para o tempo [10]. Dados estacionários de séries temporais podem ser reconhecidos como uma propriedade que não dependem do tempo [11]. Geralmente, os dados de séries temporais não estacionárias incluem observações com tendência e sazonalidade. A tendência indica o movimento geral dos dados em cada período de tempo observado sem considerar a sazonalidade dos dados. A sazonalidade indica uma flutuação periódica, que pode ser afetada pelo tempo, magnitude e direção. Volatilidade refere-se ao aumento ou queda inesperada de dados de séries temporais, que também é conhecido como heterocedasticidade, onde a variação de dados de séries temporais compreende mudanças rápidas entre extremamente alto e valores baixos [12]. Como existem muitos modelos de previsão de séries temporais disponíveis, o a seleção do modelo pode ser difícil. Assim, as características de dados acima mencionadas são essencial na seleção de um modelo ótimo de previsão de séries temporais, pois os diferentes modelos têm diferentes capacidades para lidar com diferentes características de dados. Além dos três dados características, incluímos o tamanho do conjunto de dados como outra consideração na seleção do modelo ótimo, pois pode influenciar o desempenho do modelo, como será visto em breve.

A evolução de sete modelos de previsão de séries temporais nas últimas duas décadas foi estudado para descobrir os modelos populares para preços dinâmicos. A Tabela 1 mostra o listagem dos estudos. A Figura 2 ilustra a distribuição dos estudos, mostrando a evolução da aplicação do modelo em diferentes domínios. O Integrado Autoregressivo Média Móvel (ARIMA) e Heterocedasticidade Condicional Autoregressiva Generalizada (GARCH) modelos de regressão, como uma subcategoria dos modelos estatísticos, foram aplicados desde 2003. As aplicações do modelo de regressão se estenderam por mais de duas décadas. Estocástico modelos, como Hidden Markov Model (HMM), têm sido usados desde 2007. A aplicação deste modelo não apresenta nenhum pico durante o período estudado. No entanto, notou-se que a aplicação de modelos de regressão e estocásticos foram aprimorados ou combinados com outras abordagens, como o modelo de IA, nos modelos híbridos a partir do 2010 para complementar suas deficiências.

**Tabela 1.** Revisão dos estudos de previsão de séries temporais para preços dinâmicos de 2001 a 2021.

Categoria	Modelo	Contar	Referências de intervalo de tempo	
Modelo de regressão	ARIMA	14	2003–2019	[13–27]
	GARCH	9	2005–2021	[12,28–35]
Modelo estocástico	HMM	8	2007–2016	[36–43]
Aprendizado de máquina	SVM	12	2005–2021	[44–55]
	RF	6	2006–2021	[56–61]
Aprendizado Profundo	ANN	10	2004–2020	[62–70]
	RN	12	2006–2020	[71–82]
Modelo Híbrido	Regressão + Estocástico	1	2017	[83]
	Regressão + ML	4	2005–2021	[84–87]
	Regressão + DL	6	2014–2021	[88–93]
	Estocástico + DL	1	2007	[94]
	DL + DL	1	2020	[95]

As aplicações do modelo de regressão duraram mais de duas décadas. Modelos estocásticos, como o Hidden Markov Model (HMM), são utilizados desde 2007. A aplicação deste modelo não apresenta nenhum pico durante o período estudado. No entanto, notou-se que a aplicação de modelos de regressão e estocásticos foi aprimorada ou combinada com outras abordagens, como o modelo de IA, nos modelos híbridos a partir da década de 2010 para complementar suas deficiências.



(a) A distribuição dos modelos de 2001 a 2021

(b) As aplicações do modelo em diferentes domínios

**Figura 2.** A evolução dos modelos de previsão de séries temporais em diferentes domínios ao longo de duas décadas.

Os modelos de Machine Learning (ML) (dos modelos de IA) são aplicados desde 2006, incluindo Random Forest (RF) e Support Vector Machine (SVM). Foi notado que essas abordagens estavam se tornando mais difundidas na década de 2010, à medida que a IA recebe mais atenção. Além disso, modelos de Deep Learning (DL), como uma subcategoria dos modelos de IA, incluindo a Rede Neural Artificial (ANN) e a Rede Neural Recorrente (RNN), foram introduzidas no início dos anos 2000, embora não tenha sido dada muita atenção à aplicação de modelos DL até a década de 2010. A partir da revisão, a aplicação de modelos DL na década de 2000 foi inferior a a aplicação dos modelos de regressão e estocástico, conforme mostrado na Figura 2a. No decorrer daquela época, os pesquisadores estavam investigando novas maneiras de melhorar o desempenho do modelo. Assim, diferentes combinações de modelos híbridos foram propostas e apresentadas. Mais atenção foi dada aos modelos híbridos da década de 2010 devido à sua robustez e disponibilidade de recursos computacionais.

Notavelmente, os mercados de ações e eletricidade sempre foram um foco de séries temporais previsão, como mostrado na Figura 2b. Diferentes modelos têm uma aplicação relativamente maior contam nesses dois campos, o que provavelmente se deve à complexidade do mercado que é altamente volátil. Nota-se também que a aplicação da previsão de séries temporais está se estendendo a outros domínios para preços dinâmicos recentemente. A seção a seguir apresenta o modelo estatístico, AI modelo e modelo híbrido para soluções de preços dinâmicos.

### 2.1. Modelo Estatístico

Um modelo estatístico é um modelo matemático que pode ser usado para previsão de séries temporais [96]. É classificado em duas categorias de modelos de regressão e estocásticos.

#### 2.1.1. Modelo de regressão

Um modelo de regressão é uma técnica estatística que é usada para encontrar a relação entre os dados. É amplamente aplicável, pois é mais simples de calcular [5,10]. Este modelo pode estabelecer a relação entre os dados da série temporal e o preço previsto. A maioria modelos de regressão popularmente usados, incluindo a média móvel integrada autorregressiva (ARIMA) e Heterocedasticidade Condicional Autoregressiva Generalizada (GARCH), são introduzido nesta seção.

#### Média Móvel Integrada Autoregressiva (ARIMA)

ARIMA é um modelo de regressão linear que funciona eficientemente com dados de séries temporais correlacionadas estáveis [82]. Pode ser aplicado a problemas de previsão de séries temporais em qualquer domínio baseado no princípio da análise univariada. O modelo funciona bem em séries temporais estacionárias dados. A base teórica do ARIMA é explicada em [97].

Alguns estudos exemplificam a aplicabilidade do ARIMA na previsão de séries temporais em diferentes domínios, como criptomoedas [13], ações [14–16], borracha e látex [17,18], produtos agrícolas e de comércio eletrônico [19–21,27], ouro [22,23] e eletricidade [24–26] de 2003 a 2019 e demonstrou resultados excepcionalmente promissores. Dos estudos feitos, ARIMA tem dificuldade ao lidar com dados de séries temporais não estacionárias, pois está tentando modelar as mudanças com base nos dados históricos de séries temporais com suposições de linearidade ao realizar a previsão. Percebe-se que os seguintes fatores afetarão o modelo desempenho: flutuação repentina [23], dados de séries temporais não lineares e não estacionárias [21], e previsão multi-passo à frente [98]. Existem outras variações de ARIMA introduzidas, como ARIMA com a variável independente (ARIMAX) [17] e sazonal ARIMA (SARIMA) [18] para modelagem multivariada e problemas de dados de séries temporais sazonais, respectivamente. É perceptível que o ARIMA produz um desempenho excepcional quando os dados são lineares e estacionárias. A Tabela 2 resume os estudos que aplicam o ARIMA.

**Tabela 2.** Previsão de séries temporais ARIMA de 2003 a 2019.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Criptomoedas	Mittal et al., 2018 [13]	Criptomoedas (2013 a maio de 2018)	ARIMA	Precisão de 86.424
	Ayodele et al., 2014 [14]	Bolsa de Valores de Nova Iorque e Bolsa de Valores da Nigéria	ARIMA	$2R_{adj}$ de 0,0033 e 0,9972
Estoque	Rotela Junior et al., 2014 [15]	Índice Bovespa (janeiro de 2000 até dezembro de 2012)	ARIMA	MAPE de 0,064
	Setyo, 2017 [16]	Estoque Composto da Indonésia Índice de Preço	ARIMA	MAPE de 0,8431
Borracha	Sukanya e Vichai, 2016 [17]	Bangkok e mundo natural preço da borracha (janeiro de 2002 a dezembro de 2015)	ARIMAX	MAPE de 1.11
Látex	Chalakora e Vichai, 2018 [18]	Mercado Central da Borracha de Hat Yai, Tailândia	SARIMA	MAPE de 24,60 e RMSE de 14,90
Agricultura e produto de e-commerce	Verma et al., 2016 [19]	Mercado de produtos agrícolas Comitê, Ramganj (maio 2003 a junho de 2015)	ARIMA	MAPE de 6,38
	Jadhav et al., 2017 [20]	Preço dos cereais em Karnataka (2002 a 2016)	ARIMA	MAPE de 2.993, 1.859, 1.255 arrozal, ragi e milho, respectivamente
	Carta e outros, 2018 [27]	Os preços dos produtos da Amazon, com dados do Google Trends usado como características exógenas	ARIMA	Atinge o menor MAPE médio de 4,77
	Anil Kumar et al., 2019 [21]	Preço no mercado Kadirí, Índia (janeiro de 2011 a dezembro 2015)	ARIMA	MAPE de 2,30
Ouro	Banhi e Gautam, 2016 [22]	Bolsa de várias mercadorias da Índia (novembro de 2003 a Janeiro de 2014)	ARIMA	MAPE de 3.145
	Yang, 2019 [23]	Conselho Mundial do Ouro (julho 2013 a junho de 2018)	ARIMA	Erro relativo menor do que 1,2%
Eletricidade	Contreras et al., 2003 [24]	espanhol e californiano mercado de eletricidade de 2000	ARIMA	Erros médios de menos de 11%
	Mingzhou et al., 2004 [25]	mercado de energia da Califórnia de 1999	ARIMA	MSE de 0,1148
	Tina et al., 2011 [26]	Troca de energia EPEX	ARIMA	MAPE de 3,55



### Heterocedasticidade Condicional Autoregressiva Generalizada (GARCH)

O GARCH é refinado a partir do modelo ARCH, conforme proposto por Bollerslev [99]. Este modelo supera as fraquezas do modelo ARCH, pois o modelo ARCH é de ordem muito alta com um grande número de estimativas de parâmetros [12]. O GARCH é amplamente aplicado para previsão de séries econômicas e financeiras. Este modelo mostrou ter maior eficiência na previsão ao trabalhar com dados de alta volatilidade em comparação ao ARIMA. Este último é limitado no efeito de heterocedasticidade autorregressiva (ARCH) e é de dados de séries temporais lineares, pois assume-se que o valor futuro está em uma relação linear com o tempo [12,100].

A partir da revisão, o GARCH foi implantado em diferentes domínios para previsão de dados com alta volatilidade, como os preços do ouro [28,29], ações e mercado financeiro [30-33], produtos agrícolas [34] e energia e eletricidade [12,35] de 2005 a 2021. GARCH provou ter melhor desempenho do que ARIMA se os dados tiverem alta volatilidade. Isso pode ser verificado por meio do teste do Multiplicador de Lagrange (LM) [28,34]. Os resultados indicam que o ARIMA não consegue prever bem devido à volatilidade dos dados. Existem diferentes refinamentos do GARCH, incluindo GARCH Exponencial (EGARCH) [12] (capturando a volatilidade assimétrica dos dados) e GARCH não paramétrico (NPGARCH) [33] (removendo as premissas parametrizadas, que indica que os dados estão na relação de quadrado linear e estocasticamente volátil). No geral, o GARCH é adequado para dados com alta volatilidade. No entanto, para casos em que os dados de série temporal têm uma relação linear, esse modelo pode não ser capaz de modelar bem os dados de série temporal em comparação com a abordagem ARIMA. A Tabela 3 resume a revisão sobre os estudos do GARCH.

**Tabela 3.** Previsão de séries temporais GARCH de 2005 a 2021.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Óleo	Lama et al., 2015 [12]	Cotlook A (abril de 1982 a março de 2012)	GARCH, EGARCH	A EGARCH alcançou o melhor desempenho com RMSE de 14,41
	Ping et al., 2013 [28]	Preços Kijiang Emas (julho de 2001 a setembro de 2012)	GARCH	MAPE de 0,809767
Ouro	Yaziz et al., 2019 [29]	Preço do ouro da Malásia (janeiro de 2003 a junho de 2014)	ARIMA, GARCH, ARIMA-GARCH	ARIMA-GARCH alcançou o melhor resultado com um erro de preço menor que 2
	Xing et al., 2021 [30]	West Texas Intermediário (janeiro de 2015 a maio de 2018) e CSI300 (maio de 2015 a 2016)	GARCH com função não linear	AIC de -1119,77 e $\hat{y}$ 11373,6 para CSI300 e conjunto de dados WTI
Estoque	Tripathi e Raahman, 2013 [31]	Bolsa de Valores de Bombaim e Bolsa de Valores de Xangai (1990 a 2013)	GARCH	AIC de -5,512662 e -5,260705 para conjunto de dados BSE e SSE
	Erica et al., 2018 [32]	Preço das ações da Adaro Energy (janeiro de 2014 a dezembro de 2016)	GARCH	MAPE de 2,16
Poder	Hong Li et al., 2008 [33]	Preço da energia na Califórnia de 2000	NP-GARCH, GARCH, ARIMA	NP-GARCH alcançado o menor MPE de 3,62 e 4,86
Agrícola produtos	Bhardwaj et al., 2014 [34]	Preço do grama em Delhi (janeiro de 2007 a abril de 2012)	GARCH, ARIMA	O GARCH obteve o melhor desempenho com um erro médio inferior a 2
Eletricidade	Garcia et al., 2005 [35]	Poder espanhol e californiano Mercado (setembro de 1999 a novembro de 2000) e (janeiro de 2000 a dezembro de 2000)	GARCH	FMSE inferior a 6 e 69 para espanhol e mercado californiano

### 2.1.2. Modelo estocástico

O modelo estocástico é amplamente aplicado para previsão de séries temporais [7] para fazer inferências das características dos dados de séries temporais [5]. Diferente do modelo de regressão, as inferências feitas usando o modelo estocástico são baseadas nos princípios das probabilidades. Por outro lado, o modelo de regressão é usado para identificar a relação linear entre os dados da série temporal e o resultado do preço. Um dos modelos estocásticos, Hidden Markov Modelo (HMM) é explicado nesta seção.

#### Modelo de Markov Oculto (HMM)

O HMM foi introduzido pela primeira vez em 1996 por Baum e Petrie [101]. HMM é duplo processo estocástico que introduz os estados ocultos com o não observável subjacente processo estocástico. O HMM foi aplicado à previsão de séries temporais em diferentes domínios como a previsão de preços de ações e opções [36–38], mercado de commodities [39], eletricidade [40,41], petróleo bruto [42] e taxa de câmbio [43] de 2007 a 2018. A vida mercado é complexo e altamente volátil com relacionamentos não lineares, o HMM ajuda a modelar os dados da série temporal com os estados ocultos. O modelo pode encontrar os estados ocultos do dados de séries temporais para melhorar sua capacidade de previsão e precisão [102]. HMM é adequado para dados com alta volatilidade, pois estados ocultos do modelo podem simular diferentes volatilidades regimes. Além disso, o modelo considerou a correlação de dados de séries temporais na interpretação da característica dos dados. Portanto, o modelo é adequado para precificação dinâmica quando os dados de séries temporais são não estacionários e de alta volatilidade. Percebe-se que o HMM possui um melhor desempenho em comparação com modelos de regressão como GARCH quando os dados são alta em volatilidade e tem um tamanho de amostra maior [38,103]. O HMM também pode superar alguns Modelos de Deep Learning (DL) devido à sua arquitetura de estado totalmente probabilística [36,104]. Dentro Além disso, o modelo não requer uma grande quantidade de dados de treinamento como os modelos DL. Dentro Resumindo, o HMM é adequado para dados não lineares e altamente voláteis, pois pode capturar as alterações de cada passo de tempo bem. A Tabela 4 resume os estudos usando HMM.

**Tabela 4.** Previsão de séries temporais HMM de 2007 a 2018.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Estoque	Hassan e Nath, 2005 [36]	Quatro índices de ações de companhias aéreas HMM		MAPE inferior a 6.850 para incluso ações
	Hassan, 2009 [37]	Seis preços de ações diferentes	Lógica difusa modelo e HMM	MAPE inferior a 4.535
	Dimoulkas, 2016 [38]	BM nórdico	Hum, ARIMA	HMM tem o melhor precisão de 73%
Mercadoria	Data e outros, 2013 [39]	Mercadoria do mercado financeiro preços	HMM	RMSE de 0,08502
Eletricidade	Valizadeh Haghi e SM Disfarçar adequadamente, 2007 [40]	Mercado spot espanhol de 2005 HMM		
	Jianhua Zhang et al., 2010 [41]	Dados do mercado de eletricidade de agosto de 2009	HMM	MAPE de 4,1598
Óleo	Bon e Isah, 2016 [42]	Conjunto de dados WTI para os preços do petróleo de 2015	HMM	
Financeiro	Shaaib, 2015 [43]	Câmbio de moeda estrangeira cotação do euro em relação ao dólar (abril de 2007 a fevereiro de 2011)	HMM, ANN	O HMM alcançou o melhor desempenho com MSE inferior a 0,04

## 2.2. Modelo de Inteligência Artificial (IA)

A Inteligência Artificial (IA) refere-se a uma máquina que pode imitar ou agir como um humano quando provida de recursos semelhantes aos humanos, como percepção, manipulação, comunicação, aprendizado e resolução de problemas [105]. Comparando com os modelos estatísticos, o modelo de IA aprende com dados anteriores para melhorar seu desempenho em vez de identificar os parâmetros ideais com base na probabilidade, como nos modelos estatísticos. Além disso, os modelos de IA são amplamente aplicados na previsão de séries temporais para identificar os padrões de dados ocultos para fazer uma aproximação precisa [8]. Duas subcategorias de modelos de IA são os modelos de Machine Learning (ML) e os modelos de Deep Learning (DL).

### 2.2.1. Modelo de aprendizado de máquina (ML)

Os modelos de ML podem produzir previsões confiáveis, identificando os padrões ocultos dos dados históricos para tendências e relacionamentos [106]. Ele pode ser usado para previsão de séries temporais, pois pode extrair as informações dos dados de séries temporais durante o processo de aprendizado e aprender com as informações extraídas para realizar previsões futuras [107]. As duas abordagens de aprendizado de máquina mais amplamente aplicadas são Support Vector Machine (SVM) e Random Forest (RF).

#### Máquina de vetores de suporte (SVM)

V. Vapnik propôs pela primeira vez a Support Vector Machine (SVM) em 1995 [108]. O SVM é um tipo de algoritmo de aprendizado proposto para melhorar a generalização da rede neural para alcançar as soluções ótimas globais. O SVM foi introduzido pela primeira vez para tarefas de classificação e é estendido para problemas de previsão de regressão e séries temporais com excelentes resultados [47,109].

O SVM tem sido aplicado em vários domínios para previsão de preços, como petróleo bruto [44-47], borracha [48], ouro [49] e elétrico [50-53], agrícola [54] e estoque [55] de 2005 a 2021.

O SVM pode evitar o problema de overfitting e modelar as relações não lineares de forma estável, pois aplicou o princípio de minimização de risco no treinamento. O SVM foi testado e comparado com modelos estatísticos como o ARIMA e mostrou um melhor desempenho [47,49]. O resultado interpretado sugere que o SVM tem melhor desempenho na captura de relações não lineares e no tratamento de irregularidades do que os modelos estatísticos. No entanto, SVM tem menor transparência com dimensionalidades muito altas, onde a pontuação dos resultados não pode ser representada como uma simples função paramétrica [110]. O modelo também requer muitas etapas para chegar aos melhores parâmetros para ajustar o modelo. No entanto, o SVM geralmente não funcionará bem em um grande conjunto de dados, pois é limitado pela otimização de tempo e memória [111]. A partir da revisão, o SVM é robusto na modelagem dos dados não lineares. A Tabela 5 mostra os estudos sobre os modelos SVM.

**Tabela 5.** Previsão de séries temporais SVM de 2005 a 2021.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Óleo cru	Xie et al., 2006 [44]	Preço do petróleo bruto WTI (janeiro de 1970 a dezembro de 2003)	SVM, ARIMA, BPNN	SVM tem o melhor desempenho com RMSE de 2,1921
	Qi e Zhang, 2009 [45]	Índice de petróleo OPEP, DJAIS e AMEX	SVM	Taxa de erro de 16,23%
	Khashman e Nwulu, 2011 [46]	Preço do petróleo bruto WTI (2002 a 2008)	SVM, ANN	SVM tem a maior taxa de previsão correta de 81,27
	Yu et al., 2017 [47]	Preço do petróleo WTI	SVM, ARIMA, FNN, ARFIMA, MS-ARFIMA, Caminhada aleatória, SVM	SVM tem o melhor desempenho com maior Teste Diebold-Mariano pontuação



Tabela 5. Cont.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Borracha	Jing Jong et al., 2020 [48]	Látex a granel	ARIMA	ARIMA-SVM alcançado o MAPE mais baixo de 0,3535
Ouro	Makala e Li, 2021 [49]	Conselho Mundial do Ouro (1979 a 2019)	SVM, ARIMA	A SVM obteve o melhor resultado com um RMSE de 0,028
Eletricidade	Swief et al., 2009 [50]	PJM (março de 1997 a abril de 1998)	SVM	MAPE de 1,3847
	Mohamed e El-Hawary, 2016 [51]	ISO da Nova Inglaterra (2003 a 2010)	SVM	MAPE de 8,0386
	Saini et al., 2016 [52]	Mercado Elétrico Australiano	SVM	MAPE inferior a 1,78
	Ma et al., 2018 [53]	ERCOT	SVM	MAPE de 6,57
Agrícola	Akin et al., 2018 [54]	Conjunto de dados Raisin World Export	SVM, ANN	SVM é melhor que ANN com precisão de 0,888
Estoque	Kumar et al., sd [55]	Dados de séries temporais financeiras	SVM, RF	O SVM supera o RF em 1,04% da taxa de acerto

#### Floresta Aleatória (RF)

Random Forest (RF) é um método de ensemble formado por muitas árvores de decisão que são usado tanto para processos de classificação quanto de regressão, que foi introduzido por Breiman em 2001 [112]. A RF foi aplicada na previsão de séries temporais para preços dinâmicos, incluindo previsão dos preços de carga de energia [56] e eletricidade [57], diamante [58], câmbio taxa [59], ouro [60] e estoque [61] de 2006 a 2021. RF funciona melhor para dados com alta volatilidade e aleatoriedade, como taxa de câmbio, e superou o SVM [59].

Além disso, a RF pode funcionar mais rápido e melhor em grandes amostras de treinamento, com o tempo de treinamento significativamente mais rápido que o SVM. No entanto, alguns estudos mostraram que a RF realizada pior do que os modelos de regressão na modelagem de dados lineares [55,113]. Em suma, é adequado para dados não lineares, estacionários e altamente voláteis. A Tabela 6 incluiu os estudos da Modelos de RF.

Tabela 6. Previsão de séries temporais de RF de 2006 a 2021.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Carregar	Lahouar e Ben Hadj Palha, 2015 [56]	Companhia Tunisiana de Eletricidade e Gás (janeiro 2009 a agosto de 2014)	RF, ANN, SVM	RF tem o menor MAPE inferior a 4.2302
Eletricidade	Mei et al., 2014 [57]	NYISO	RF, ANN, ARIMA	RF tem o menor MAPE de 12.05
Diamante	Sharma et al., 2021 [58]	Kaggle	RF, Árvore de Decisão, Lasso, Ada Boost, Gradiente do cume Impulsionando, Linear Regressão, Rede elástica	RF tem o menor RMSE de 581,905423
Taxa de câmbio	Ramakrishnan et al., 2017 [59]	Departamento de Estatística Malásia, Banco Mundial, Conselho de Óleo de Palma da Malásia, Exportação de borracha da Malásia Conselho de Promoção, Federal banco de reserva	RF, NN, SVM	RF tem o menor RMSE de 0,018

Tabela 6. Cont.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Ouro	Liu e Li, 2017 [60]	DJIA, S&P500, USDX	RF	A RF mostrou um resultar na previsão de diferentes conjuntos de dados, com desempenho de previsão até 0,99
Estoque	Khaidem et al., 2016 [61]	Samsung, GE e, ações da Apple	RF	Precisão de maior do que 86,8396

## 2.2.2. Modelo de aprendizado profundo

Ao contrário do modelo ML, o modelo DL é inspirado na estrutura neurológica humana, e é composto por uma coleção de neurônios que são conectados entre camadas para formar uma rede [114]. No entanto, os modelos ML e DL aprendem com os dados para melhorar a performance deles. Além disso, o modelo DL funciona excepcionalmente bem em comparação com o modelo métodos estatísticos na previsão de dados não lineares [114]. Rede Neural Artificial (ANN) e Rede Neural Recorrente (RNN) são explicados na seção a seguir.

## Rede Neural Artificial (ANN)

Warren e Walter propuseram a RNA em 1943 [115], que é um modelo computacional inspirado no sistema nervoso biológico humano. É composto por camadas de neurônios. A ANN tem sido aplicada em muitos domínios para previsão de séries temporais, incluindo a previsão de preços para o produto agrícola [62], eletricidade [63–66], ouro [67], e estoque [68–70] de 2004 a 2020. A aplicação da RNA é mais robusta que a modelos estatísticos na captura das tendências e sazonalidade dos dados - a não estacionaridade dos dados [62]. A ANN provou funcionar melhor do que o modelo estatístico com os dados de séries temporais que são não lineares, estacionários e têm mudanças repentinas através da camada hierarquia [70]. Apesar de seu resultado superior, a única desvantagem significativa da RNA é sua natureza caixa-preta [116]. O processo computacional da RNA é complexo, e como o modelo decide é dificilmente compreensível. Existe também o risco de overfitting quando há poucas observações de dados. O modelo memorizará apenas os recursos de dados exclusivos, que significa que ele não aprende a relação subjacente dos dados, resultando em menor generalização. A Tabela 7 resume os estudos de previsão de séries temporais de RNA.

Tabela 7. Previsão de séries temporais de ANN de 2004 a 2020.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Agrícola	Jha e Sinha, 2013 [62]	Preço da soja da SOPA, mostarda de colza de Delhi	ANN, ARIMA, TDNN	ARIMA obteve melhor resultado para o preço da soja previsão com um RMSE de 5,43, híbrido ARIMA-TDNN tem melhor desempenho com um RMSE de 3,46
Eletricidade	Yamin et al., 2004 [63]	mercado de energia californiano (janeiro de 1999 a setembro 1999)	ANN	MAPE inferior a 9,23
	Ozozen et al., 2016 [64]	EPIAS (2014 a 2015)	ANN, ARIMA, ARIMA-ANN	O modelo híbrido alcançou um MAPE de 4,08
	Ranjbar et al., 2016 [65]	mercado de energia de Ontário (janeiro de 2003 a dezembro 2003)	ANN	MAPE de 9,51
	Sahay e Singh, 2018 [66]	Dados históricos de energia (2007 a 2013)	Retropropagação algoritmo	MAPE de 6,60

Tabela 7. Cont.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Ouro	Verma et al., 2020 [67]	Preço do ouro do site de investimento, (janeiro de 2015 a dezembro 2018)	GDM, RP, SCG, LM, BR, BFGS, NÓS	O algoritmo GDM tem o MAPE mais baixo de 4,06
	Laboissiere et al., 2015 [68]	CEBR3, CSRN3	ANN	MAE de 0,0009 e 0,0042 para CEBR3 e CSRN3
Estoque	Prastyo et al., 2017 [69]	Preços diários de fechamento de ações de Wanjawa e Lawrence	ANN	RMSE de 0,1830
	Wijesinghe e Rathnayaka, 2020 [70]	Bolsa de Valores de Colombo	ANN, ARIMA	ANN tem o MAPE mais baixo de 0,1783

### Rede Neural Recorrente (RNN)

RNN é uma variação de ANN [117] com uma arquitetura de feedback que contém um feedback loop para que as camadas posteriores da rede voltem para a camada de entrada. RN foi comprovado ser um método adequado para previsão de séries temporais, como exemplificado pelos estudos de previsão dos preços das ações [71–75], Bitcoin [76], combustível [77], ouro [78], eletricidade [79–81], e agrícola [82] de 2006 a 2020. O estado oculto introduzido na RNN com a capacidade memorizar informações anteriores ajuda a melhorar sua capacidade de previsão, embora a escala de dados é mais extensa [82]. A memória de longo prazo (LSTM) é introduzida também como um refinamento do RNN em lembrar valores por tempos mais longos ou mais curtos [72]. A partir de das revisões, a RNN mostrou um excelente resultado na previsão de séries temporais não lineares, pois comparado ao modelo estatístico. A RNN pode modelar tanto o não linear quanto o altamente volátil dados bem. Portanto, RNN seria uma boa escolha para previsão de séries temporais para o característica de dados acima mencionada, desde que haja observações de dados suficientes. A Tabela 8 mostra a revisão resumida dos estudos de RNN para previsão de séries temporais.

Tabela 8. Previsão de séries temporais RNN de 2006 a 2020.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Estoque	Sun e Ni, 2006 [71]	Yahoo Finance (abril de 2005 a agosto de 2005)	RN	Precisão de 0,9784
	Li e Liao, 2017 [72]	mercado de ações da China (2008 a 2015)	RNN, LSTM, MLP	LSTM tem a maior desempenho com um precisão de 0,473
	Wang et al., 2018 [73]	Dados de ações de Yunnan Baiyao	LSTM	Precisão de 50-65%
	Sima et al., 2018 [74]	Yahoo Finance (janeiro de 1985 até agosto de 2018)	LSTM, ARIMA	ARIMA e LSTM alcançou um RMSE de 5,999 e 0,936, respectivamente
	Du et al., 2019 [75]	Dados de ações da Apple americana de 2008	LSTM	TAMANHO de 0,155
Criptomoeda	Tandon et al., 2019 [76]	Site da Coin Market Cap	LSTM, RF, Linear Regressão	LSTM tem o melhor desempenho com um TAMANHO de 0,1518
Combustível	Chaitanya Lahari et al., 2018 [77]	Dados históricos das principais cidades metropolitanas	RN	Precisão acima de 90%
Ouro	S e S, 2020 [78]	Conselho Mundial do Ouro	LSTM	RMSE de 7,385

Tabela 8. Cont.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Eletricidade	Mandal et al., 2007 [79]	PJM	RN	MAPE inferior a 10
	Zhu et al., 2018 [80]	Nova Inglaterra ISO e PJM	LSTM, SVM, DT	LSTM tem o melhor desempenho com um MAPE inferior a 39
	Ugurlu et al., 2018 [81]	mercado de eletricidade turco de 2016	LSTM, GRU, ANN	GRU tem o melhor desempenho com um TAMANHO de 5,36
Agrícola	Weng et al., 2019 [82]	Mercado Xinfadi de Pequim (agosto de 2015 a julho de 2018)	RN, ARIMA, BPNN	A RNN alcançou o melhor desempenho com o menor AAE de 0,49, 0,21, 0,15

### 2.3. Modelo Híbrido

Os modelos híbridos são geralmente uma combinação de dois ou mais modelos da estatística. e categorias de IA. O modelo híbrido costuma ser mais robusto que os modelos simples, pois combina e complementa as vantagens de um único modelo para melhorar a precisão das previsões. O modelo híbrido é amplamente utilizado em diferentes domínios para esquemas de preços dinâmicos, incluindo o domínio do estoque [83-85,94,95], petróleo bruto [86,88,89], energia [90], carbono [87,91], eletricidade [92] e ouro [93] de 2004 a 2021. Diferentes combinações foram comprovadas integrar com sucesso as vantagens de diferentes modelos para melhorar o desempenho. Por exemplo, ANN-GARCH [93] aceita não linearidade e volatilidade de dados. O proposto O modelo demonstrou uma vantagem significativa na modelagem de dados de séries temporais altamente não estacionários e não lineares, superando qualquer um dos modelos únicos. A partir desses estudos, o O modelo híbrido provou ter melhor capacidade de previsão para dados de séries temporais.

Embora o modelo híbrido tenha demonstrado um resultado promissor, tal modelo é geralmente altamente complexo e computacionalmente intensivo [118]. A determinação de os modelos para combinação são muitas vezes complicados e desafiadores, pois exigem uma análise aprofundada compreensão de cada método. Assim, um forte background de diferentes modelos deve ser dominado e bem compreendido para decidir sobre uma arquitetura híbrida adequada. O híbrido modelos também têm menor flexibilidade, uma vez que é projetado especificamente para lidar com um determinado problema. A Tabela 9 mostra os estudos revisados para os modelos híbridos.

Tabela 9. Previsão de séries temporais do modelo híbrido de 2004 a 2021.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Estoque	Tang e Diao, 2017 [83]	Banco de dados WIND (janeiro de 2010 até setembro de 2016)	HMM-GARCH	RMSE de 0,0238 e 0,0075
	Pai e Lin, 2005 [85]	Conjunto de dados de dez ações (outubro de 202 até dezembro de 2002)	ARIMA, SVM, ARIMA-SVM	O modelo híbrido tem a MAE mais baixo para o incluiu dez ações
	Raiful Hassan et al., 2007 [94]	Preço diário das ações da Apple, IBM e Dell do Yahoo Finança	ANN-GA HMM	MAPE de 1,9247, 0,84871, e 0,699246 para o estoque, respectivamente
	Wang e Guo, 2020 [84]	Conjunto de dados de dez ações (2015 a 2018)	DWT-ARIMA GSXGB	RMSE inferior a 20.3013 para o pior caso, os casos gerais têm RMSE inferior a 0,3
	Chen et al., 2020 [95]	Yahoo Finance (setembro 2008 a julho de 2019)	MLP-Bi-LSTM com AM	TAMANHO de 0,025393

Tabela 9. Cont.

Domínio	Autor	Conjunto de dados	Modelo	Resultado
Óleo cru	Shabri e Samsudin, 2014 [88]	Preços do petróleo Brent e preços do petróleo WTI	ANN, QUANDO	WANN tem o melhor desempenho com MAPE de 1,31 e 1,39 para conjunto de dados Brent e WTI
	Zhang et al., 2015 [86]	Petróleo WTI e Brent (janeiro de 1986 a 2005) e (maio de 1987 a junho de 2005)	EEMD-LSSVM PSO-GARCH	MAPE de 1,27 e 1,53 para WRI e conjunto de dados Brent
	Safari e Davallou, 2018 [89]	Preços do petróleo bruto da OPEP (janeiro de 2003 a setembro de 2016)	ESM-ARIMA NAR	MAPE de 2,44, obteve o menor erro em comparação com outros modelos únicos
Energia	Bissing et al., 2019 [90]	mercado ibérico de eletricidade (fevereiro a julho de 2015)	ARIMA-MLR e ARIMA-Holt inverno	ARIMA-Holt Winter tem melhor desempenho com um MAPE inferior a 5,07 para diferentes previsões de dias
Carbono	Zhu e Wei, 2013 [87]	Bolsa Climática Europeia (ECX) de dezembro de 2010 e dezembro 2012	ARIMA LSSVM	RMSE de 0,0311 e 0,0309 para DEC10 e DEC12
	Huang et al., 2021 [91]	EUA futures from Wind base de dados	VMD-GARCH e LSTM	VMS-GARCH tem a melhor desempenho com o primeiro lugar em termos de RMSE, MAE e MAPE
Eletricidade	Shafie-khah et al., 2011 [92]	mercado de eletricidade espanhol de 2002	Wavelet ARIMA-RBFN	Variações de erro inferiores a 0,0049
Ouro	Kristjanpoller e Minutolo, 2015 [93]	Preço à vista de ouro e ouro Preço futuro da Bloomberg (setembro de 1999 a março de 2014)	ANN-GARCH	MAPE de 0,6493 e 0,6621

### 3. Discussão

Após revisar os diferentes modelos de previsão de séries temporais apresentados na Seção 2, pode-se concluir que a análise das características dos dados é um passo importante na decisão do modelo ideal para previsão, pois cada um deles tem melhor desempenho em características particulares dos dados. Consequentemente, a fim de determinar a seleção de modelo ideal para DSA, a análise das características dos dados é realizada. Esta seção apresenta um resumo das características de dados adequadas para os modelos apresentados na Seção 2, que é seguido pela análise de dados DSA e uma estrutura proposta para a seleção de modelo ideal com base na análise de resultados.

#### 3.1. Resumo das Características de Dados Adequadas para os Modelos Incluídos

Na revisão dos sete modelos de previsão, destaca-se a importância das diferentes características dos dados na seleção do modelo ótimo para a previsão de preços. A Tabela 10 mostra a adequação das características dos dados para cada modelo. Cada modelo tem desempenho variável para as diferentes características dos dados. O grande conjunto de dados geralmente é construído com mais de 100.000 observações e o pequeno conjunto de dados tem menos observações. Esta seção apresenta um resumo dos pontos fortes e fracos dos modelos.

**Tabela 10.** Seleção do modelo ótimo com suas características de dados adequadas.

Modelo	Linear	Estacionário não linear	Não Estacionário	Volátil	Não Volátil	Grande Conjunto de dados	Conjunto de dados pequeno
ARIMA	✓	✓			✓		✓
GARCH		✓	✓	✓			✓
HMM		✓	✓	✓		✓	
SVM		✓	✓		✓		✓
RF		✓	✓	✓		✓	
ANN		✓	✓		✓	✓	
RN		✓	✓	✓		✓	

Primeiro, para modelos de regressão, ARIMA é adequado para dados lineares e estacionários, enquanto o modelo GARCH tem um melhor desempenho quando os dados são de alta volatilidade e é adaptável a dados não estacionários. No entanto, quando os dados têm uma relação linear, ARIMA terá um desempenho melhor que GARCH. O modelo estocástico, HMM, introduziu os estados ocultos que podem simular diferentes regimes de volatilidade. Portanto, tem melhor desempenho do que um modelo de regressão como GARCH quando os dados são altos em volatilidade e há um tamanho de amostra maior. No entanto, deve-se notar que o oculto parâmetros de HMM são difíceis de determinar, e o algoritmo provavelmente irá parar em um máximo local antes de atingir o resultado mais satisfatório. Assim, isso resulta em menor precisão na previsão de preços.

Como um dos modelos de ML, o SVM é mais eficaz do que modelos estatísticos como ARIMA e GARCH no sentido de sua melhor capacidade de trabalhar com o não linear, dados não estacionários e altamente voláteis. Ao contrário dos modelos de regressão, o SVM não é limitado para trabalhar com dados que tenham uma relação linear ou alta volatilidade, o algoritmo é convexo otimizado. Isso significa que ele pode encontrar o ótimo global do resultado. Portanto, é melhor do que HMM em alcançar o resultado mais promissor. Pode generalizar bem para anteriormente dados invisíveis, superando os problemas existentes, como a previsão de uma flutuação repentina. No entanto, se o conjunto de dados for muito grande, o SVM pode não ter um bom desempenho devido à memória e restrições de otimização. A principal vantagem do RF em relação ao SVM é sua capacidade de lidar com grandes conjuntos de dados. RF tem uma boa capacidade de evitar overfitting limitando o erro de generalização com um requisito importante de um grande conjunto de dados com menos ruído. No entanto, ao estimar os dados lineares, RF pode ter desempenho inferior em comparação para SVM e ARIMA devido ao seu comportamento aleatório, e a previsão é calculada com base em os valores médios.

Modelos DL como ANN e RNN são ambos modelos de rede neural inspirados no sistema nervoso humano. Eles têm alguns prós e contras em comum, como boa capacidade de generalização e bom desempenho na modelagem de dados não lineares e não estacionários. No entanto, esses modelos também são de natureza caixa preta, o que resulta em baixa transparência do modelo. Ambos Os modelos DL mostraram melhores resultados em comparação com os modelos ML quando o tamanho do conjunto de dados é suficiente para o treinamento. Entre ANN e RNN, RNN demonstrou um resultado melhor do que ANN na previsão de dados com alta volatilidade.

Além disso, o modelo híbrido tem demonstrado sua robustez como um modelo que combina dois ou mais modelos, complementando as vantagens do modelo único. Portanto, um modelo híbrido pode modelar melhor o relacionamento subjacente e obter uma resultado do que qualquer modelo único. No caso de um único modelo não poder cuidar do diferentes características dos dados, a aplicação do modelo híbrido é mais adequada.

Os modelos discutidos geralmente estão sendo amplamente aplicados em diferentes áreas e têm alcançou excelentes resultados. Além disso, diferentes estudos comparativos têm apontado para a adequação de um modelo particular em certas características de dados. Em conclusão, esta seção mostrou de forma abrangente as características de dados adequadas para cada modelo.



### 3.2. Análise de dados DSA e estrutura proposta para seleção de modelo ideal

Como as características dos dados podem influenciar o desempenho do modelo, um estudo é realizado com base em um conjunto de dados coletados de DSA. Como o nível de atenção à sinalização pode influenciar muito a decisão de preço, a dependência e a relação dos fatores ambientais relacionados ao nível de atenção devem ser cuidadosamente consideradas. Os fatores ambientais incluídos neste estudo são localização, clima e temperatura. Esses fatores têm impactos significativos no nível de atenção e na decisão final de preço [2]. A Tabela 11 mostra dois exemplos de como os fatores ambientais impactam o nível de atenção e consequentemente a precificação do DSA.

**Tabela 11.** Fatores ambientais e seu impacto no nível de atenção e precificação da DSA.

Fatores	Exemplo	Nível de atenção	Preço
Localização	Alta popularidade, alta classificação de instalações públicas ao redor, negócios	Aumentar $\ddot{y}$	Aumentar $\ddot{y}$
Clima e temperatura	Chovendo, temperatura extremamente alta ou baixa e umidade do ar	Diminuir $\ddot{y}$	Diminuir $\ddot{y}$

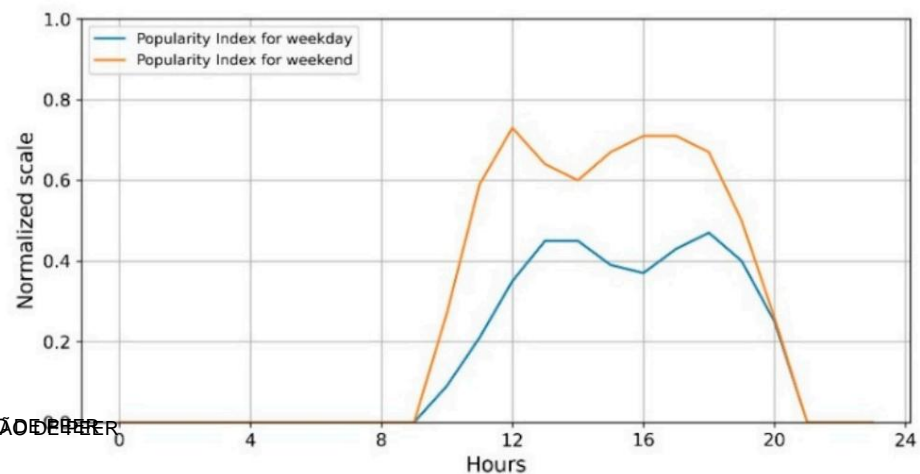
Percebendo os impactos dos fatores ambientais na decisão de precificação, o conjunto de dados coletados é composto por três atributos, incluindo a temperatura, o nível de umidade do ar e o índice de popularidade do ambiente de negócios circundante com base nos dois fatores ambientais, conforme mostrado na Tabela 11. Eles foram coletados de 13 locais de sinalização digital na Malásia usando métodos de extração de dados de abril a junho de 2021. Os dados de temperatura e umidade foram obtidos da API OpenWeather, enquanto o índice de popularidade foi extraído do Google Maps.

Essas características dos dados são utilizadas para medir o índice que representa o nível de atenção, que afeta indiretamente a previsão de preços da ASD. Assim, este estudo tem como objetivo investigar as características dos dados de DSA coletados diariamente, mensalmente e como um todo. A sinalização em análise foi selecionada aleatoriamente. A sinalização com ID 1000, localizada em Negeri Sembilan, Malásia, com coordenadas (101.9119, 2.70179) foi investigada no estudo. Os resultados para outras sinalizações não foram apresentados neste artigo para evitar informações repetitivas.


#### 3.2.1. Localização

A localização é o fator mais aplicado no esquema de precificação tradicional para DSA, como estratégia de preço fixo e mecanismo de precificação baseado em leilão [1]. O ambiente geográfico e as instalações que envolvem a sinalização digital são os fatores mais cruciais, pois afetam fortemente a acessibilidade e visibilidade da sinalização digital, determinando o nível de atenção do público. Por exemplo, uma classificação mais alta das empresas vizinhas pode aumentar a multidão de um determinado local, o que indiretamente aumenta o nível de atenção para o anúncio. Assim, quanto mais próspero for um local, maior o nível de atenção que pode ser obtido para melhorar a eficácia do anúncio. Os diferentes dias e horários também têm um impacto direto no tamanho da multidão do local. Por exemplo, a multidão nos finais de semana geralmente será maior do que nos dias úteis. Assim, aumenta a demanda por um spot DSA e resulta em preços mais altos. Esses índices são, de fato, imperativos para afetar a decisão de preços. Considerando sua relação com o nível de atenção que pode ser obtido, quanto maior o valor desses índices, maior o preço.


A Figura 3 ilustrou a comparação dos índices de popularidade da sinalização com o ID 1000 durante 24 h nos dias úteis e durante o fim de semana. Os índices de popularidade mostram diferentes horários de pico dos dias de semana e fim de semana. Notavelmente, o índice de popularidade é maior nos fins de semana em comparação com os dias da semana. Assim, isso exemplifica a suposição de que a sinalização estará atraindo níveis de atenção mais altos durante o fim de semana do que nos dias de semana, resultando em preços mais altos para DSA.



**Figura 3.** Comparação do índice de popularidade em 24 h para dias da semana e finais de semana para ambos os dias da semana e dos dois períodos de tempo. A tendência sazonal nos gráficos conjuntos mensais de todo o conjunto completo de dados da tendência sazonal nos gráficos mensais e de todo o conjunto de dados do DSA da estação é mostrados nas figuras 4 e 5. O gráfico apresenta a tendência de longo prazo de dados não estacionários, conforme mostrado nas Figuras 4 e 5. -característica de dados estacionários. Geralmente, ambas as figuras mostram a mesma tendência sazonal como o índice de popularidade. Geralmente, ambas as figuras mostram a mesma tendência sazonal, com o índice de popularidade subindo e caindo repetidamente a tendência de longo prazo de longo prazo, o que pode ser explicado pelo fato de que a estação de pesquisa não pode ser aplicada ao caso DSA, indicando DSA DSA para maximizar o lucro.



**Figura 4.** Variação de índice de popularidade em 30 dias




**Figura 5.** Subtítulos en el documento para el análisis de datos.

### 3.2.2. Clima e Temperatura

Os dados de temperatura e umidade são coletados em um período maior de 30 dias e no gráfico para todos os dados

Os dados de temperatura e umidade do ar são analisados. O dat um para o outro. Quando os valores de umidade do ar diminuem, os valores da Figura 6 mostram as mudanças na temperatura e umidade do ar ao longo do dia selecionado para ilustrar como esses atributos mudam em um dia. O movimento d em um período de tempo maior de 30 dias e no gráfico para t dia selecionado para ilustrar como esses atributos mudam em um dia. Os dados mostram uma irreg mostrada nas Figuras 7 e 8, respectivamente. Geralmente, a temperatura um movimento um período de tempo maior de 30 dias e no gráfico para todo o conjunto de dados, como 7 e 8, respectivamente. O padrão de tempo. O clima pode afetar o tamanho da multidão. temperatura extremamente alta ou baixa resultará na aglomeração de um local. Uma tabela os fatores ambientais apresentam uma característica de dados diferente.



17 de 24

Figura 6. Temperatura e umidade do ar em 24 h.




Figura 7. Temperatura e umidade do ar em 30 dias.


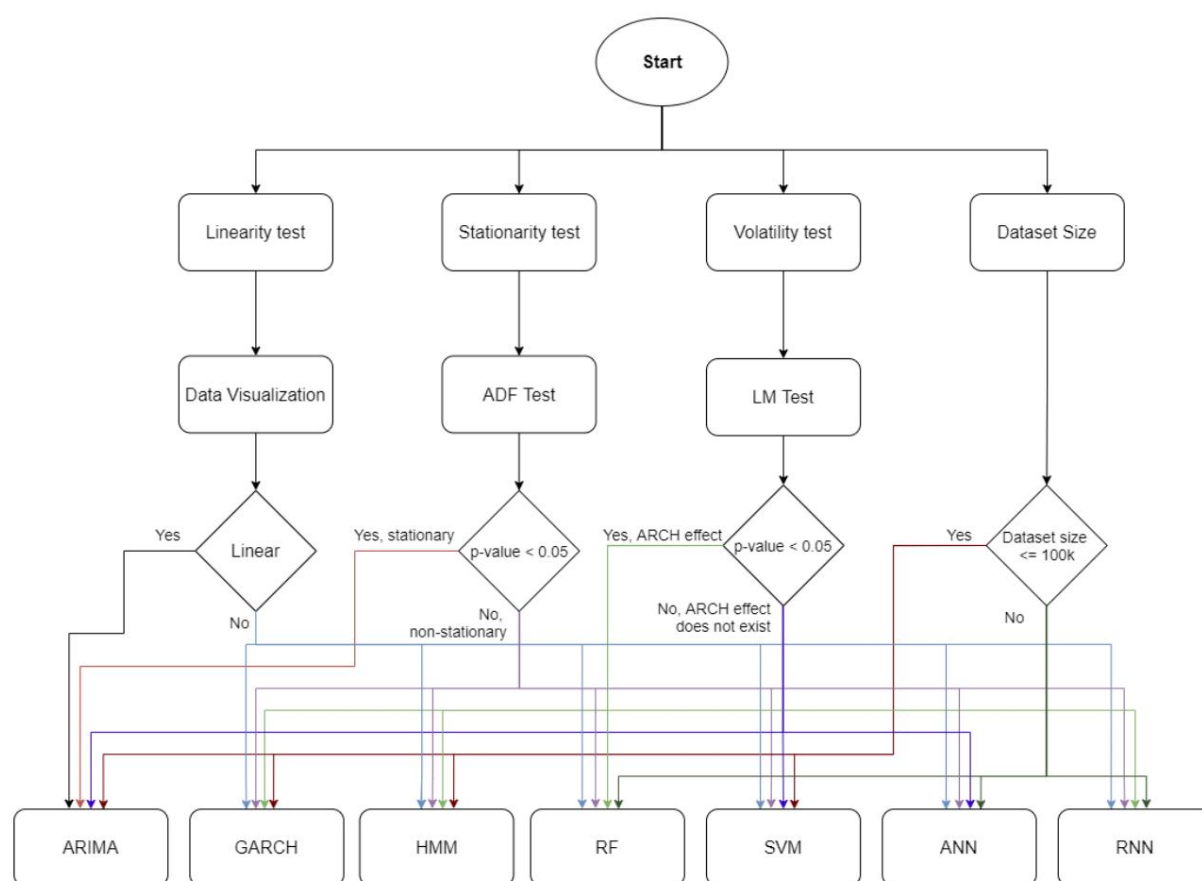


Figura 8. Temperatura e umidade do ar em 30 dias.

Portanto, observamos que os dados de cada fator da DSA apresentam características diferentes. Portanto, observamos que os dados de cada fator da DSA apresentam características diferentes. Com base nos estudos de revisão, uma estrutura é desenvolvida para analisar os dados para a seleção ideal de dados. Uma lista de procedimentos e testes pode ser usada para determinar as seleções de dados disponíveis. Este teste de triagem pode ser realizado através da visualização de dados usando características de dispersão observadas e agrupamento em forma de uma linha diagonal. Os dados estão sendo analisados para

1.3 x PARA REVISÃO PELOS PARES




**Figura 9.** Estrutura proposta para seleção de modelo ideal.




A partir da análise acima, percebe-se que cada ponto de dados possui diferentes movimentos no tempo. Os testes de linearidade, estacionariedade e volatilidade para os fatores ambientais do conjunto de dados DSA são realizados para examinar as características dos dados para cada um. Seguindo os passos ilustrados na Figura 9,


Fator Ambiental		Sim	Sim	Sim	Modelo selecionado
Localização	ar Temperatura	Sim	Sim	Sim	ARIMA
	Umidade do ar	Não	Sim	Sim	ARIMA



(a) Índice de popularidade



(b) Temperatura



(c) Umidade do ar

Figura 10. Gráfico de dispersão para índice de popularidade, temperatura e umidade do ar.  
Figura 10. Gráfico de dispersão para índice de popularidade, temperatura e umidade do ar.

Tabela 12. Testes de características dos dados e resultados.

Fator Ambiental		Sim	Sim	Sim	Modelo selecionado
Localização	Índice de popularidade	Não	Não	Não	Múltiplo
	Temperatura	Não	Não	Não	SVM
Clima	Umidade do ar	Não	Não	Não	ARIMA
	Humidade do ar	Não	Não	Não	ARIMA

etiqueta de preço não está disponível, um sistema baseado em regras pode ser aplicado definindo um limite para cada fator ambiental para gerar o preço. Isso pode ajudar a prever efetivamente o nível de atenção e a decisão de preços para DSA. Como os fatores ambientais afetam o nível de atenção e consequentemente os modelos para diferentes características de dados para decisões de preços. No nosso caso, onde o

#### 4. Conclusões e Trabalho Futuro

Este artigo apresentou uma lista de modelos de previsão de séries temporais amplamente utilizados para preços com base em uma extensa revisão da literatura. Esses modelos provaram ter realização notável em diferentes domínios. A partir da revisão, cada modelo tem sua força ao lidar com diferentes características de dados. As vantagens e desvantagens de cada um dos modelos são discutidos e apresentados. Além disso, as relações entre os modelos e as diferentes características dos dados são investigadas para sugerir a seleção de modelo ideal para a previsão de preços da DSA. A partir daí, uma estrutura de seleção de modelo ideal é proposta com base na análise das características dos dados da DSA. Esta revisão estruturada fornece uma solução de precificação dinâmica usando previsão de séries temporais, abrindo caminho para pesquisas futuras sobre preços dinâmicos em DSA.

Para trabalhos futuros, será realizado um estudo experimental para examinar a aplicabilidade da estrutura de seleção de modelo ideal proposta. Mais dados de séries temporais devem ser coletados para realizar o estudo experimental de precificação dinâmica em DSA para investigar a eficácia da estrutura de seleção de modelo ideal. Além disso, um comportamento do cliente abordagem de segmentação pode ser considerada na identificação de suas preferências para uma melhor publicidade efeitos [121].

**Contribuições dos Autores:** Aquisição de fundos, M.-CL; Investigação, Y.-FT; Administração de projetos, M.-CL; Supervisão, L.-YO; Visualização, Y.-XG; Redação — rascunho original, Y.-FT; Redação—revisão e edição, L.-YO e M.-CL. Todos os autores leram e concordaram com a versão publicada de o manuscrito.

**Financiamento:** Esta pesquisa foi financiada pela Telekom Malaysia Research & Development, número de concessão RDTG/191001 (MMUE/190086) e Multimedia University.

**Declaração de disponibilidade de dados:** Não aplicável, o estudo não relata nenhum dado.

**Conflitos de interesse:** Os autores declaram não haver conflito de interesse.

## Referências

- Bauer, C.; Dohmen, P.; Strauss, C. Um framework conceitual para serviços de backend de sinalização digital contextual. *J. Serv. Sci. Res.* **2012**, *4*, 271-297. [\[CrossRef\]](#)
- O'Driscoll, C. Publicidade em tempo real, direcionada e fora de casa com preços dinâmicos. Trinity College Dublin. 2019. Disponível online: <https://www.scss.tcd.ie/publications/theses/diss/2019/TCD-SCSS-DISSERTATION-2019-012.pdf> (acessado em 12 de setembro de 2021).
- Choi, H.; Mela, C.; Balseiro, S.; Leary, A. Mercados de publicidade de exibição on-line: uma revisão da literatura e direções futuras. *Inf. Sistema Res.* **2020**, *31*, 556-575. [\[CrossRef\]](#)
- Zhang, F.; Wang, C. Estratégia dinâmica de preços e coordenação em uma cadeia de suprimentos de canal duplo, considerando o valor do serviço. *Aplic. Matemática. Modelo.* **2018**, *54*, 722-742. [\[CrossRef\]](#)
- Athiyarath, S.; Paulo, M.; Krishnaswamy, S. Um Estudo Comparativo e Análise de Técnicas de Previsão de Séries Temporais. *Computação SN. Sci.* **2020**, *1*, 175. [\[CrossRef\]](#)
- Wang, D.; Luo, H.; Grunder, O.; Lin, Y.; Guo, H. Previsão de preços de eletricidade com vários passos à frente usando um modelo híbrido baseado na técnica de decomposição de duas camadas e rede neural BP otimizada pelo algoritmo firefly. *Aplic. Energia* **2017**, *190*, 390-407. [\[CrossRef\]](#)
- Sehgal, N.; Pandey, KK Métodos de inteligência artificial para previsão do preço do petróleo: uma revisão e avaliação. *Sistema de Energia* **2015**, *6*, 479-506. [\[CrossRef\]](#)
- Gao, W.; Aamir, M.; Shabri, AB; Dewan, R.; Aslam, A. Previsão do preço do petróleo bruto usando filtro de Kalman com base na reconstrução do modelo de conjunto de modos de decomposição. Acesso IEEE **2019**, *7*, 149908–149925. [\[CrossRef\]](#)
- Mahalakshmi, G.; Sridevi, S.; Rajaram, S. Uma pesquisa sobre previsão de dados de séries temporais. In Proceedings of the 2016 International Conference on Computing Technologies and Intelligent Data Engineering (ICCTIDE'16), Kovilpatti, Índia, 7–9 de janeiro de 2016; págs. 1–8.
- Montgomery, DC; Peck, EA; Vining, GG Introdução à Análise de Regressão Linear; John Wiley & Sons: Hoboken, NJ, EUA, 2021.
- Hyndman, RJ Previsão: Princípios e Práticas, 2ª ed.; Textos O: Melbourne, Austrália, 2018.
- Lama, A.; Jha, GK; Paulo, RK; Gurung, B. Modelagem e Previsão de Volatilidade de Preços: Uma Aplicação de GARCH e Modelos EGARCH. *Agrícola. Eco. Res. Rev.* **2015**, *28*, 73. [\[CrossRef\]](#)
- Mittal, R.; Gehi, R.; Bhatia, MPS Prevendo o Preço de Criptomoedas e Validando Usando Arima. *Int. J. Inf. Sistema Gerenciar Sci.* **2018**, *1*, 5.
- Ariyo, AA; Adewumi, AO; Ayo, CK Previsão de preços de ações usando o modelo ARIMA. In Proceedings of the 2014 UKSim-AMSS 16th International Conference on Computer Modeling and Simulation, Cambridge, Reino Unido, 26–28 de março de 2014; IEEE: Washington, DC, EUA, 2014; págs. 106-112.
- Rotela Júnior, P.; Salomão, FLR; de Oliveira Pamplona, E. ARIMA: Modelo Aplicado de Previsão de Séries Temporais para o Índice Bovespa. *Aplic. Matemática.* **2014**, *5*, 3383-3391. [\[CrossRef\]](#)
- Wahyudi, ST O modelo ARIMA para o preço das ações da Indonésia. *Int. J. Eco. Gerenciar* **2017**, *11*, 223-236.
- Cherdchoongam, S.; Rungreunganun, V. Previsão do preço da borracha natural na Tailândia usando o modelo ARIMA. *Univ do Rei Mongkut. Tecnol. Norte. Bangk. Int. J. Appl. Sci. Tecnol.* **2016**, *7*. [\[CrossRef\]](#)
- Udomraksasakul, C.; Rungreunganun, V. Previsão do preço do látex de campo na área da costa sudeste da Tailândia usando o modelo ARIMA. *Int. J. Appl. Eng. Res.* **2018**, *13*, 550-556.
- Verma, VK; Kumar, P. Uso de modelagem ARIMA na previsão de preços de coentro para Rajasthan. *Int. J. Seed Spices* **2016**, *6*, 42–45.
- Jadhav, V.; Reddy, BVC; Gaddi, GM Aplicação do Modelo ARIMA para Previsão de Preços Agrícolas. *J. Agric. Sci. Tecnol.* **2017**, *19*, 981-992.
- Kumar Mahto, A.; Biswas, R.; Alam, MA Previsão de curto prazo do preço de commodities agrícolas usando ARIMA: com base no mercado indiano. Em *Avanços em Computação e Ciências de Dados*; Singh, M., Gupta, PK, Tyagi, V., Flusser, J., Oren, T., Kashyap, R., Eds.; Comunicações em Informática e Ciência da Informação; Springer: Cingapura, 2019; Volume 1045, pp. 452-461. ISBN 9789811399381.
- Bandyopadhyay, G. Gold Price Forecasting Using ARIMA Model. *J. Av. Gerenciar Sci.* **2016**, *4*, 117-121. [\[CrossRef\]](#)
- Yang, X. A previsão do preço do ouro usando o modelo ARIMA. In Proceedings of the 2nd International Conference on Social Science, Public Health and Education (SSPHE 2018), Sanya, China, 28–27 de novembro de 2018; Atlantis Press: Sanya, China, 2019.
- Contreras, J.; Espinola, R.; Nogales, FJ; Conejo, AJ Modelos ARIMA para prever preços de eletricidade no dia seguinte. *Trans. IEEE Sistema de energia* **2003**, *18*, 1014-1020. [\[CrossRef\]](#)
- Zhou, M.; Yan, Z.; Ni, Y.; Li, G. Uma abordagem ARIMA para prever o preço da eletricidade com melhoria da precisão por erros previstos. In Proceedings of the IEEE Power Engineering Society General Meeting, Denver, CO, EUA, 6–10 de junho de 2004; Volume 2, pp. 233-238.



26. Jakasa, T.; Androcec, I.; Sprcic, P. Previsão de preços de eletricidade – abordagem do modelo ARIMA. In Proceedings of the 2011 8th International Conference on the European Energy Market (EEM), Zagreb, Croácia, 25–27 de maio de 2011; págs. 222-225.
27. Carta, S.; Medda, A.; Pili, A.; Reforgiato Recupero, D.; Saia, R. Previsão de preços de produtos de comércio eletrônico combinando um modelo ARIMA (Autoregressive Integrated Moving Average) e dados do Google Trends. *Internet futura* **2018**, 11, 5. [\[CrossRef\]](#)
28. Ping, PY; Miswan, NH; Ahmad, MH Previsão de ouro da Malásia usando o modelo GARCH. *Aplic. Matemática. Sci.* **2013**, 7, 2879-2884. [\[CrossRef\]](#)
29. Yaziz, SR; Zakaria, R. Suhartono ARIMA e modelos simétricos do tipo GARCH na previsão do preço do ouro na Malásia. *J. Física. conf. Ser.* **2019**, 1366, 012126. [\[CrossRef\]](#)
30. Xing, D.-Z.; Li, H.-F.; Li, J.-C.; Long, C. Previsão do preço do crash do mercado financeiro através de um novo modelo GARCH potencial não linear. *Física Estado. Mec. Aplic.* **2021**, 566, 125649. [\[CrossRef\]](#)
31. Tripathia, S.; Rahman, A. Previsão da volatilidade diária das ações usando o modelo GARCH: uma comparação entre BSE e SSE. *IUP J. Aplic. Financiar* **2013**, 19, 71-83.
32. Virginia, E.; Ginting, J.; Elfaki, FAM Aplicação do Modelo GARCH para Previsão de Dados e Volatilidade do Preço das Ações de Energia (Estudo sobre Adaro Energy Tbk, LQ45). *Int. J. Economia de Energia. Política* **2018**, 8, 131-140.
33. Li, H.; Xiong, H.; Li, W.; Sun, Y.; Xu, G. Um método de previsão de preços de energia baseado no modelo GARCH não paramétrico. In Proceedings of the 2008 Third International Conference on Electric Utility Desregulation and Restructuring and Power Technologies, Nanjing, China, 6–9 de abril de 2008; págs. 285-290.
34. Bhardwaj, SP; Paulo, RK; Singh, DR; Singh, KN Uma Investigação Empírica dos Modelos Arima e Garch no Preço Agrícola Previsão. *Eco. Aff.* **2014**, 59, 415. [\[CrossRef\]](#)
35. Garcia, RC; Contreras, J.; vanAkkeren, M.; Garcia, JBC Um modelo de previsão GARCH para prever os preços da eletricidade para o dia seguinte. *Trans. IEEE Sistema de energia* **2005**, 20, 867-874. [\[CrossRef\]](#)
36. Hassan, MR; Nath, B. Previsão do mercado de ações usando o modelo oculto de Markov: Uma nova abordagem. In Proceedings of the 5th International Conference on Intelligent Systems Design and Applications (ISDA'05), Varsóvia, Polônia, 8–10 de setembro de 2005; págs. 192-196.
37. Hassan, MR Uma combinação de modelo oculto de Markov e modelo fuzzy para previsão do mercado de ações. *Neurocomputação* **2009**, 72, 3439-3446. [\[CrossRef\]](#)
38. Dimoulkas, I.; Amelin, M.; Hesamzadeh, MR Previsão de equilíbrio de preços de mercado usando modelos ocultos de Markov. In Proceedings of the 2016 13th International Conference on the European Energy Market (EEM), Porto, Portugal, 6–9 de junho de 2016; págs. 1–5.
39. Data, P.; Mamon, R.; Tenyakov, A. Filtrando e prevendo preços futuros de commodities sob uma estrutura HMM. *Energia Econ.* **2013**, 40, 1001-1013. [\[CrossRef\]](#)
40. Valizadeh Haghi, H.; Tafresh, SMM Uma Visão Geral e Verificação dos Modelos de Previsão de Preços de Eletricidade. Em *Processos de a Conferência Internacional de Engenharia de Energia de 2007 (IPEC 2007)*, Cingapura, 3 a 6 de dezembro de 2007.
41. Zhang, J.; Wang, J.; Wang, R.; Hou, G. Previsão de preços de eletricidade no dia seguinte com Hidden Markov Models. In Proceedings of the 2010 5th IEEE Conference on Industrial Electronics and Applications, Taichung, Taiwan, 15–17 de junho de 2010; págs. 1736-1740.
42. Bon, AT; Isah, N. Modelo Oculto de Markov e Algoritmo Forward-Backward na Previsão do Preço do Petróleo Bruto. *Conferência IOP Ser. Mater. Sci. Eng.* **2016**, 160, 012067. [\[CrossRef\]](#)
43. Shaaib, AR Estudo Comparativo de Redes Neurais Artificiais e Modelo de Markov Oculto para Previsão de Séries Temporais Financeiras. *Int. J. Eng. Inf. Tecnol.* **2015**, 1, 7.
44. Xie, W.; Yu, L.; Xu, S.; Wang, S. Um novo método para previsão de preços de petróleo bruto com base em máquinas de vetores de suporte. Em *Ciência da Computação—ICCS 2006*; Alexandrov, VN, van Albada, GD, Sloot, PMA, Dongarra, J., Eds.; Notas de Aula em Ciência da Computação; Springer: Berlim/Heidelberg, Alemanha, 2006; Volume 3994, pp. 444-451. ISBN 978-3-540-34385-1.
45. Qi, Y.-L.; Zhang, W.-Y. O Método SVM Aprimorado para Previsão da Flutuação do Preço Internacional do Petróleo Bruto. In Proceedings of the Electronic Commerce and Business Intelligence International Conference, Pequim, China, 6-7 de junho de 2009.
46. Khashman, A.; Nwulu, NI Support Vector Machines versus Algoritmo de Retropropagação para Previsão do Preço do Petróleo. Em *Avanços em Redes Neurais—ISNN 2011*; Liu, D., Zhang, H., Polycarpou, M., Alippi, C., He, H., Eds.; Notas de Aula em Ciência da Computação; Springer: Berlim/Heidelberg, Alemanha, 2011; Volume 6677, pp. 530-538. ISBN 978-3-642-21110-2.
47. Yu, L.; Zhang, X.; Wang, S. Avaliando a potencialidade do método de máquina de vetor de suporte na previsão de preços de petróleo bruto. *EURÁSIA J. Matemática. Sci. Tecnol. Educ.* **2017**, 13, 7893-7904. [\[CrossRef\]](#)
48. Jing Jong, L.; Ismail, S.; Mustafá, A.; Helmy Abd Wahab, M.; Zulkarnain Syed Idrus, S. A Combinação de Média Móvel Integrada Autoregressiva (ARIMA) e Máquinas de Vetor de Suporte (SVM) para Previsão Diária de Preços de Borracha. *Conferência IOP Ser. Mater. Sci. Eng.* **2020**, 917, 012044. [\[CrossRef\]](#)
49. Makala, D.; Li, Z. Previsão do preço do ouro com ARIMA e SVM. *J. Física. Conf. Ser.* **2021**, 1767, 012022. [\[CrossRef\]](#)
50. Swief, RA; Hegazy, YG; Abdel-Salam, TS; Bader, MA Suporte a máquinas vetoriais (SVM) com base na previsão de preços de carga de eletricidade de curto prazo. In Proceedings of the 2009 IEEE Bucharest PowerTech, Bucareste, Romênia, 28 de junho a 2 de julho de 2009; págs. 1–5.
51. Mohamed, A.; El-Hawary, ME Previsão de preços de eletricidade de médio prazo usando SVM. In Proceedings of the 2016 IEEE Canadian Conference on Electrical and Computer Engineering (CCECE), Vancouver, BC, Canadá, 15 a 18 de maio de 2016.
52. Saini, D.; Saxena, A.; Bansal, RC Previsão de preços de eletricidade por regressão linear e SVM. In Proceedings of the 2016 International Conference on Recent Advances and Innovations in Engineering (ICRAIE), Jaipur, Índia, 23–25 de dezembro de 2016; págs. 1–7.

53. Ma, Z.; Zhong, H.; Xie, L.; Xia, Q.; Kang, C. Previsão do perfil de preço médio diário da eletricidade com um mês de antecedência com base em uma regressão não linear híbrida e modelo SVM: Um estudo de caso ERCOT. *J. Mod. Sistema de energia Energia Limpa* **2018**, 6, 281-291. [\[CrossRef\]](#)
54. Akin, B.; Dizbay, İE.; Gümü,so ygü, S.; Güdücü, E. Previsão da Direção do Índice de Preços de Commodities Agrícolas através ANN, SVM e Árvore de Decisão: Evidência de Raisin. *Ege Acad. Rev.* **2018**, 18, 579-588.
55. Kumar, M. Forecasting Stock Index Movement: A Comparison of Support Vector Machines e Random Forest. Disponível on-line: <https://ssrn.com/abstract=876544> (acessado em 1 de julho de 2021).
56. Lahouar, A. Previsão de carga para o dia seguinte usando floresta aleatória e seleção de entrada de especialistas. *Energia Convers. Gerenciar* **2015**, 103, 1040-1051. [\[CrossRef\]](#)
57. Mei, J.; Ele, D.; Harley, R.; Habetler, T.; Qu, G. Um método de floresta aleatória para previsão de preços em tempo real no mercado de eletricidade de Nova York. In *Proceedings of the 2014 IEEE PES General Meeting|Conference & Exposition, National Harbor, MD, EUA, 27–31 de julho de 2014*; págs. 1–5.
58. Sharma, G.; Tripathi, V.; Mahajan, M.; Kumar Srivastava, A. Análise Comparativa de Modelos Supervisionados para Previsão de Preços de Diamantes. In *Proceedings of the 2021 11th International Conference on Cloud Computing, Data Science & Engineering (Confluence), Noida, Índia, 28 a 29 de janeiro de 2021*; págs. 1019-1022.
59. Ramakrishnan, S.; Butt, S.; Chohan, MA; Ahmad, H. Previsão da taxa de câmbio da Malásia usando técnicas de aprendizado de máquina com base nos preços das commodities. In *Proceedings of the 2017 International Conference on Research and Innovation in Information Systems (ICRIIS), Langkawi, Malásia, 16–17 de julho de 2017*; págs. 1–5.
60. Liu, D.; Li, Z. Previsão do preço do ouro e análise de fatores de influência relacionados com base em floresta aleatória. In *Proceedings of the X International Conference on Management Science and Engineering Management*; Xu, J., Hajiye, A., Nickel, S., Gen, M., Eds.; *Avanços em Sistemas Inteligentes e Computação*; Springer: Cingapura, 2017; Volume 502, pp. 711-723. ISBN 978-981-10-1836-7.
61. Khaidem, L.; Saha, S.; Dey, SR Prevendo a direção dos preços do mercado de ações usando floresta aleatória. *arXiv* **2016**, arXiv:1605.00003.
62. Jha, GK; Sinha, K. Previsão de Preços Agrícolas Usando Modelo de Rede Neural: Um Sistema Inovador de Entrega de Informações. *Agrícola. Eco. Res.* **2013**, 26, 229-239.
63. Yamin, H.; Shahidepour, S.; Li, Z. Previsão adaptativa de preços de eletricidade de curto prazo usando redes neurais artificiais no mercados de energia reestruturados. *Int. J. Eletr. Sistema de energia de energia* **2004**, 26, 571-581. [\[CrossRef\]](#)
64. Ozozen, A.; Kayakutlu, G.; Ketterer, M.; Kayalica, O. Um modelo combinado sazonal ARIMA e ANN para melhores resultados na previsão de preços à vista de eletricidade: Estudo de caso na Turquia. In *Proceedings of the 2016 Portland International Conference on Management of Engineering and Technology (PICMET), Honolulu, HI, EUA, 4–8 de setembro de 2016*; págs. 2681–2690.
65. Ranjbar, M.; Soleymani, S.; Sadati, N.; Ranjbar, AM Previsão de Preços de Eletricidade Usando Rede Neural Artificial. *Int. J. Eletr. Sistema de energia de energia* **2011**, 33, 550-555.
66. Sahay, KB; Singh, K. Previsão de Preço de Curto Prazo Usando Algoritmos ANN. Nos Anais do Congresso Elétrico Internacional de 2018 Congresso de Engenharia (iEECON), Krabi, Tailândia, 7 a 9 de março de 2018.
67. Verma, S.; Thampi, GT; Rao, M. Método baseado em ANN para melhorar a precisão da previsão do preço do ouro através do gradiente modificado métodos de descida. *IAES Int. J. Artif. Intel. IJ-AI* **2020**, 9, 46 .
68. Laboissiere, LA; Fernandes, RAS; Lage, GG Previsão de preço máximo e mínimo de ações de distribuidoras brasileiras de energia com base em redes neurais artificiais. *Aplic. Computação Suave.* **2015**, 35, 66-74. [\[CrossRef\]](#)
69. Prastyo, A.; Junaedi, D.; Sulistiyo, MD Previsão de preço de ações usando rede neural artificial: (Estudo de caso: PT. Telkom Indonésia). In *Proceedings of the 2017 5th International Conference on Information and Communication Technology (IColC7), Malaca, Malásia, 17–19 de maio de 2017*; págs. 1–6.
70. Wijesinghe, GWRI; Rathnayaka, RMKT ARIMA e ANN Abordagem para prever as flutuações diárias dos preços das ações das indústrias na Bolsa de Valores de Colombo, Sri Lanka. In *Proceedings of the 2020 5th International Conference on Information Technology Research (ICITR), Moratuwa, Sri Lanka, 2–4 de dezembro de 2020*; págs. 1–7.
71. Sun, X.; Ni, Y. Rede Neural Recorrente com Extração de Característica de Kernel para Previsão de Preços de Ações. In *Proceedings of the 2006 International Conference on Computational Intelligence and Security, Guangzhou, China, 3–6 de novembro de 2006*; págs. 903-907.
72. Li, W.; Liao, J. Um estudo comparativo sobre a abordagem de previsão de tendências para séries temporais de preços de ações. In *Proceedings of the 2017 11th IEEE International Conference on Anti-Falling, Security, and Identification (ASID), Xiamen, China, 27–29 de outubro de 2017*; págs. 74–78.
73. Wang, Y.; Liu, Y.; Wang, M.; Liu, R. Otimização do Modelo LSTM na Previsão de Preços de Ações. In *Proceedings of the 2018 17th International Symposium on Distributed Computing and Applications for Business Engineering and Science (DCABES), Wuxi, China, 19 a 23 de outubro de 2018*; págs. 173-177.
74. Siami-Namini, S.; Tavakoli, N.; Siami Namin, A. Uma comparação de ARIMA e LSTM na Previsão de Séries Temporais. In *Proceedings of the 2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA), Orlando, FL, EUA, 17 a 20 de dezembro de 2018*; pp. 1394-1401.
75. Du, J.; Liu, Q.; Chen, K.; Wang, J. Previsão de preços de ações de duas maneiras com base na rede neural LSTM. In *Proceedings of the 2019 IEEE 3rd Information Technology, Networking, Electronic and Automation Control Conference (ITNEC), Chengdu, China, 15 a 17 de março de 2019*; págs. 1083-1086.
76. Tandon, S.; Tripathi, S.; Saraswat, P.; Dabas, C. Bitcoin Price Forecasting usando LSTM e validação 10-Fold Cross. In *Proceedings of the 2019 International Conference on Signal Processing and Communication (ICSC), Noida, Índia, 7 a 9 de março de 2019*; pp. 323-328.

77. Chaitanya Lahari, M.; Ravi, DH; Bharathi, R. Previsão de preço de combustível usando RNN. In Proceedings of the 2018 International Conference on Advances in Computing, Communications and Informatics (ICACCI), Bangalore, Índia, 19–22 de setembro de 2018; págs. 1510-1514.
78. Vidya, GS; Hari, VS Previsão e Modelagem do Preço do Ouro usando Técnicas de Aprendizado Profundo. In Proceedings of the 2020 IEEE Recent Advances in Intelligent Computational Systems (RAICS), Thiruvananthapuram, Índia, 3–5 de dezembro de 2020; págs. 28–31.
79. Mandal, P.; Senjyu, T.; Urasaki, N.; Yona, A.; Funabashi, T.; Srivastava, AK Previsão de preços para o mercado de eletricidade no dia seguinte usando rede neural recursiva. In Proceedings of the 2007 IEEE Power Engineering Society General Meeting, Tampa, FL, EUA, 24–28 de junho de 2007; págs. 1–8.
80. Zhu, Y.; Dai, R.; Liu, G.; Wang, Z.; Lu, S. Power Market Previsão de Preços via Deep Learning. In Proceedings of the IECON 2018 —44th Annual Conference of the IEEE Industrial Electronics Society, Washington, DC, EUA, 21–23 de outubro de 2018; págs. 4935-4939.
81. Ugurlu, U.; Oksuz, I.; Tas, O. Previsão de Preços de Eletricidade Usando Redes Neurais Recorrentes. *Energias* **2018**, 11, 1255. [\[CrossRef\]](#)
82. Weng, Y.; Wang, X.; Hua, J.; Wang, H.; Kang, M.; Wang, F.-Y. Previsão de preço de produtos hortícolas usando modelo ARIMA e rede neural com base em um conjunto de dados de grande escala coletado pelo rastreador da Web. *Trans. IEEE Computar. Soc. Sistema* **2019**, 6, 547-553. [\[CrossRef\]](#)
83. Tang, L.; Diao, X. Precificação de opções com base no modelo HMM e GARCH. In Proceedings of the 2017 29th Chinese Control and Decision Conference (CCDC), Chongqing, China, 28–30 de maio de 2017; págs. 3363-3368.
84. Wang, Y.; Guo, Y. Método de previsão da volatilidade do mercado de ações em dados de séries temporais com base em modelo misto de ARIMA e XGBoost. *China Comun.* **2020**, 17, 205-221. [\[CrossRef\]](#)
85. Pai, P.-F.; Lin, C.-S. Um modelo híbrido ARIMA e máquinas vetoriais de suporte na previsão de preços de ações. *Ômega* **2005**, 33, 497-505. [\[CrossRef\]](#)
86. Zhang, J.-L.; Zhang, Y.-J.; Zhang, L. Um novo método híbrido para previsão do preço do petróleo bruto. *Energia Econ.* **2015**, 49, 649-659. [\[CrossRef\]](#)
87. Zhu, B.; Wei, Y. Previsão de preços de carbono com um novo ARIMA híbrido e metodologia de máquinas vetoriais de suporte de mínimos quadrados. *Ômega* **2013**, 41, 517-524. [\[CrossRef\]](#)
88. Shabri, A.; Samsudin, R. Previsão Diária do Preço do Petróleo Bruto Usando Wavelet Híbrido e Modelo de Rede Neural Artificial. *Matemática. Problema Eng.* **2014**, 11. [\[CrossRef\]](#)
89. Safari, A.; Davallou, M. Previsão do preço do petróleo usando um modelo híbrido. *Energia* **2018**, 148, 49-58. [\[CrossRef\]](#)
90. Bissing, D.; Klein, MT; Chinnathambi, RA; Selvaraj, DF; Ranganathan, P. Um Modelo de Regressão Híbrida para Energia do Dia Adiante Previsão de Preços. *Acesso IEEE* **2019**, 7, 36833–36842. [\[CrossRef\]](#)
91. Huang, Y.; Dai, X.; Wang, Q.; Zhou, D. Um modelo híbrido para previsão de preços de carbono usando GARCH e memória de longo prazo rede. *Aplic. Energia* **2021**, 285, 116485. [\[CrossRef\]](#)
92. Shafie-khah, M.; Moghaddam, MP; Sheikh-El-Eslami, MK Previsão de preços dos mercados de eletricidade para o dia seguinte usando um híbrido método de previsão. *Energia Convers. Gerenciar* **2011**, 52, 2165-2169. [\[CrossRef\]](#)
93. Kristjanpoller, W.; Minutolo, MC Volatilidade do preço do ouro: Uma abordagem de previsão usando o modelo Rede Neural Artificial – GARCH . *Sistema especialista. Aplic.* **2015**, 42, 7245-7251. [\[CrossRef\]](#)
94. Hassan, MR; Nath, B.; Kirley, M. Um modelo de fusão de HMM, ANN e GA para previsão do mercado de ações. *Sistema especialista. Aplic.* **2007**, 33, 171-180. [\[CrossRef\]](#)
95. Chen, Q.; Zhang, W.; Lou, Y. Previsão de preços de ações usando um modelo híbrido de aprendizado profundo que integra o mecanismo de atenção, o Perceptron de várias camadas e a rede neural bidirecional de memória de longo prazo. *Acesso IEEE* **2020**, 8, 117365-117376. [\[CrossRef\]](#)
96. Nisha, KG; Sreekumar, K. Uma Revisão e Análise de Aprendizado de Máquina e Abordagens Estatísticas para Previsão. In Proceedings of the 2017 International Conference on Inventive Communication and Computational Technologies (ICICCT), Coimbatore, Índia, 10 a 11 de março de 2017.
97. Young, WL A abordagem Box-Jenkins para análise e previsão de séries temporais: Princípios e aplicações. *RAIRO-Oper. Res.* **1977**, 11, 129-143. [\[CrossRef\]](#)
98. Babu, CN; Reddy, BE Previsões de ações indianas selecionadas usando um modelo híbrido ARIMA-GARCH. In Proceedings of the 2014 International Conference on Advances in Electronics Computers and Communications, Bangalore, Índia, 10–11 de outubro de 2014; págs. 1–6.
99. Bollerslev, T. Heteroscedasticidade condicional autoregressiva generalizada. *J. Econom.* **1986**, 31, 307-327. [\[CrossRef\]](#)
100. Zhang, X.; Xue, T.; Eugene Stanley, H. Comparação de Modelos Econométricos e Algoritmos de Redes Neurais Artificiais para o Previsão do Índice de Seca do Báltico. *Acesso IEEE* **2019**, 7, 1647-1657. [\[CrossRef\]](#)
101. Baum, LE; Petrie, T. Inferência estatística para funções probabilísticas de cadeias de Markov de estado finito. *Ana Matemática. Estado.* **1966**, 37, 1554-1563. [\[CrossRef\]](#)
102. Liu, D.; Cai, Z.; Li, X. Previsão de preço spot baseada no modelo oculto de Markov para computação em nuvem. In Proceedings of the 2017 IEEE International Symposium on Parallel and Distributed Processing with Applications e 2017 IEEE International Conference on Ubiquitous Computing and Communications (ISPA/IUCC), Guangzhou, China; 2017; págs. 996–1003.
103. Mamon, RS; Erlwein, C.; Bhushan Gopaluni, R. Processamento de sinal adaptativo de dinâmica de preços de ativos com análise de previsibilidade. *Inf. Sci.* **2008**, 178, 203-219. [\[CrossRef\]](#)
104. Ky, DX; Tuyen, LT A Modelo Markov de ordem superior para previsão de séries temporais. *Int. J. Appl. Matemática. Estado.* **2018**, 57, 1-18.

105. Williams, C. Uma breve introdução à Inteligência Artificial. In Proceedings of the OCEANS '83, San Francisco, CA, EUA, 29 de agosto a 1 de setembro de 1983.
106. Angra, S.; Ahuja, S. Aprendizado de máquina e suas aplicações: Uma revisão. Nos Anais da Conferência Internacional de Grandes Empresas de 2017 Análise de dados e inteligência computacional (ICBDAC), Chirala, Índia, 23 a 25 de março de 2017; págs. 57-60.
107. Ramírez-Amaro, K.; Chimal-Eguía, JC Machine Learning Tools para Previsão de Séries Temporais. Em Anais da Sexta Conferência Internacional Mexicana sobre Inteligência Artificial de 2007, Sessão Especial (MICAI), Aguascalientes, México, 4–10 de novembro de 2007; págs. 91-101.
108. Cortes, C.; Vapnik, V. Redes de vetores de suporte. Mach. Aprender. **1995**, 20, 273-297. [\[CrossRef\]](#)
109. Características e categorias sintáticas. Sintaxe alemã declarativa; DE GRUYTER: Berlim, Alemanha, 1999; págs. 1–13. ISBN 978-3-484-30394-2.
110. Auria, L.; Moro, RA Support Vector Machines (SVM) como Técnica para Análise de Solvência. Elétron SSRN. J. **2008**, 20, 577-588. [\[CrossRef\]](#)
111. Wang, H.; Hu, D. Comparação de SVM e LS-SVM para Regressão. Nos Anais da Conferência Internacional de 2005 sobre Redes Neurais e Cérebro, Pequim, China, 13–15 de outubro de 2005; Volume 1, pp. 279–283.
112. Breiman, L. Random Forests. Mach. Aprender. **2001**, 45, 5-32. [\[CrossRef\]](#)
113. Felizardo, L.; Oliveira, R.; Del-Moral-Hernandez, E.; Cozman, F. Estudo comparativo da previsão de preços do Bitcoin usando WaveNets, Redes Neurais Recorrentes e outros Métodos de Aprendizado de Máquina. In Proceedings of the 2019 6th International Conference on Behavioral, Economic and Socio-Cultural Computing (BESC), Pequim, China, 28 a 30 de outubro de 2019; págs. 1–6.
114. Istiaque Sunny, MA; Maswood, MMS; Alharbi, AG Previsão de preços de ações baseada em aprendizado profundo usando LSTM e modelo LSTM bidirecional. In Proceedings of the 2020 2nd Novel Intelligent and Leading Emerging Sciences Conference (NILES), Gizé, Egito, 24 a 26 de outubro de 2020; págs. 87-92.
115. McCulloch, WS; Pitts, W. Um cálculo lógico das idéias iminentes na atividade nervosa. Touro. Matemática. Biol. **1943**, 5, 115-133. [\[CrossRef\]](#)
116. Dumitru, C.; Maria, V. Vantagens e Desvantagens do Uso de Redes Neurais para Previsões. Ovídio Univ. Ana Eco. Sci. Ser. **2013**, 13, 444–449.
117. Welch, RL; Ruffing, SM; Venayagamoorthy, GK Comparação de arquiteturas de rede neural feedforward e feedback para previsão de velocidade do vento de curto prazo. In Proceedings of the 2009 International Joint Conference on Neural Networks, Atlanta, GA, EUA, 14–19 de junho de 2009.
118. Deb, C.; Zhang, F.; Yang, J.; Lee, SE; Shah, KW Uma revisão sobre técnicas de previsão de séries temporais para o consumo de energia em edifícios. Renovar. Sustentar. Energia Rev. **2017**, 74, 902-924. [\[CrossRef\]](#)
119. Kothapalli, S.; Totad, SG Uma previsão e análise do tempo em tempo real. In Proceedings of the 2017 IEEE International Conference on Power, Control, Signals and Instrumentation Engineering (ICPCSI), Chennai, Índia, 21-22 de setembro de 2017; págs. 1567-1570.
120. Cheung, Y.-W.; Lai, KS Lag order e valores críticos do teste de Dickey-Fuller aumentado. J. Ônibus. Eco. Estado. **1995**, 13, 277-280.
121. Saia, R.; Borato, L.; Carta, S. Uma Estratégia de Reconhecimento de Padrões Semânticos Latentes para uma Publicidade Direcionada Não Trivial. In Proceedings of the 2015 IEEE International Congress on Big Data, Nova York, NY, EUA, 27 de junho a 2 de julho de 2015; págs. 491–498.