


Listas de conteúdo disponíveis em [ScienceDirect](#)

Energia Aplicada

página inicial da revista: www.elsevier.com/locate/apenergy

Estratégias de processamento de dados em modelos e aplicações de previsão de energia eólica: uma revisão abrangente

Hui Liu[✉], Chao Chen

Instituto de Inteligência Artificial e Robótica (IAIR), Laboratório Chave de Segurança no Trânsito na Trilha do Ministério da Educação, Escola de Engenharia de Trânsito e Transportes, Central South University, Changsha 410075, China

LUZES

- Métodos de processamento de dados para modelos de previsão de energia eólica são revisados.
- Sete categorias são classificadas com base em seus procedimentos de computação.
- Uma avaliação geral de diferentes perspectivas é apresentada para a revisão.
- Discutem-se tendências e desafios na aplicação de métodos de processamento de dados.

INFORMAÇÕES DO ARTIGO

Palavras-chave:

Previsão de energia eólica
Processamento de dados
Decomposição
Redução de dimensionalidade
Correção de dados

RESUMO

Dada a natureza intermitente do vento, a previsão precisa da energia eólica é importante para a utilização adequada de fontes de energia renovável. Nos últimos anos, modelos orientados a dados baseados em observações passadas têm sido amplamente empregados na literatura. Vários tipos de métodos de processamento de dados são aplicados com sucesso para auxiliar esses modelos e melhorar ainda mais o desempenho da previsão. A pesquisa abrangente de suas metodologias é necessária para uma compreensão completa dos desafios atuais que afetam a precisão e a eficiência do modelo. Para abordar a lacuna de conhecimento, este artigo apresenta uma revisão exaustiva e categorização do processamento de dados na previsão de energia eólica. As técnicas utilizadas são classificadas em sete categorias de acordo com as aplicações: decomposição, seleção de características, extração de características, eliminação de ruídos, modelagem de erros residuais, detecção de outliers e correção baseada em filtros. Uma análise geral de suas intenções, posições, características e detalhes de implementação é fornecida. Uma avaliação geral é realizada a partir de diferentes perspectivas, incluindo melhoria da precisão, frequência de uso, consumo de tempo, robustez aos parâmetros, maturidade e dificuldade de implementação. Entre os métodos de processamento de dados existentes, a detecção de outliers e a correção baseada em filtros são relativamente menos utilizados. Seu potencial pode ser melhor explorado no futuro. Além disso, são fornecidas algumas possíveis direções de pesquisa e desafios de processamento de dados na previsão de energia eólica, a fim de incentivar pesquisas posteriores.

1. Introdução

A energia eólica é atualmente a fonte de energia renovável mais promissora, que tem ganhado cada vez mais atenção em todo o mundo. A energia eólica é propícia à proteção dos recursos ambientais globais. No entanto, os recursos eólicos são incontáveis e a instabilidade interna torna a taxa de utilização relativamente baixa [1]. A previsão precisa da energia eólica e da velocidade do vento tem sido atribuída grande importância à exploração de fontes de energia renováveis. Muitos pesquisadores têm feito grandes esforços no desenvolvimento e aperfeiçoamento da velocidade do vento e previsão de energia eólica.

Existem dois critérios básicos para a classificação preliminar de modelos de previsão de energia eólica: horizonte de tempo de previsão e abordagem de previsão. Com relação ao horizonte de tempo, a previsão de energia eólica pode ser dividida em quatro categorias, incluindo muito curto prazo, curto prazo, médio prazo e longo prazo [2,3]. A classificação da escala de tempo dos modelos de previsão é relativamente vaga, como mostrado na Fig. 1. Em geral, horizontes de tempo de previsão mais curtos podem fornecer resultados mais detalhados e precisos, mas menos tempo restante para a implantação da geração de energia eólica. O horizonte de tempo de previsão mais longo fornece informações de longo prazo sobre a energia eólica futura, mas geralmente a precisão é relativamente

[✉] Autor correspondente em: Instituto de Inteligência Artificial e Robótica, Laboratório Chave de Segurança no Trânsito na Trilha do Ministério da Educação, Escola de Trânsito e Engenharia de Transportes, Central South University, Changsha 410075, Hunan, China.

E-mail: csulihui@csu.edu.cn (H. Liu).

<https://doi.org/10.1016/j.apenergy.2019.04.188> Recebido em

2 de março de 2019; Recebido em formulário revisado em 27 de abril de 2019; Aceito em 30 de abril de 2019

Disponível online em 09 de maio de 2019 0306-2619/© 2019 Elsevier Ltd. Todos os direitos reservados.

Nomenclatura	
<i>Lista de abreviações</i>	
Função de autocorrelação ACF	Divergência KLD Kullback-Leibler
Rede neural artificial ANN	Análise de componentes principais do kernel KPCA
Modelo de média móvel integrada autoregressiva ARIMA	Fator de outlier local LOF
Algoritmo de busca de retrocesso binário BBSA	Máquina de vetor de suporte de mínimos quadrados LSSVM
Rede neural de retropropagação BPNN	Memória de curto prazo longa LSTM
Otimização de enxame de partículas binárias BPSOGSA e gravitacional	Erro Absoluto Médio MAE
algoritmo de pesquisa	Informações mútuas do erro percentual médio absoluto
Decomposição de modo empírico complementar CEEMD	MIM do MAPE
Decomposição de modo empírico de conjunto completo CEEMDAN com ruído	Transformação wavelet discreta de sobreposição máxima MODWT
adaptativo	não paramétrica
Informação mútua condicional CMi	Decomposição de modo variacional otimizada OVMD
Algoritmo de otimização de recifes de coral CRO	Função de autocorrelação parcial PACF
Clustering espacial baseado em densidade DBSCAN de aplicativos com ruído	Análise de componentes principais do PCA
evolução diferencial	Reconstrução do espaço de fase de otimização
Transformada wavelet discreta DWT	PSR de enxame de partículas PSO
Decomposição de modo empírico do conjunto EEMD	RELM regularizou floresta aleatória de máquina de
Decomposição de modo empírico EMD	RF aprendizado extremo
Transformada wavelet empírica EWI	RF eliminação de
Decomposição em modo empírico de conjunto rápido FEEMD	RFE recursos recursivos de floresta aleatória
Algoritmo Genético GA	Agrupamento espectral de erro quadrático
Heteroscedasticidade condicional autoregressiva generalizada GARCH	médio de RMSE
Análise de correlação de cinza GCA	Análise de espectro singular de
Teste de causalidade GCT Granger	SSA entropia de amostra SC
GSO Gram-Schmidt ortogonal	Decomposição de valor singular SVD
ICEMDAN melhorado CEEMDAN	Máquina de vetores de suporte SVM
Transformada wavelet empírica inversa IEWT	TVF-EMD decomposição de modo empírico baseado em filtro variável no tempo
Transformada wavelet inversa IWT	Decomposição do modo variacional VMD
Agrupamento fuzzy c-means baseado em kernel KFCM	Filtro wavelet WF
	Decomposição de pacotes wavelet WPD
	Transformada WT wavelet
	Denoising de limiar de wavelet WTD

pobre. O papel básico dos modelos de previsão de energia eólica é fornecer a velocidade do vento e o status da energia para os próximos segundos, minutos, horas ou mais. Modelos com lead time de previsão diferente possuem aplicações específicas, conforme apresentado na Tabela 1.

De acordo com as abordagens de previsão, quatro tipos de modelos mainstream foram propostos, conhecidos como modelos físicos, estatísticos, inteligentes e híbridos. Os modelos físicos referem-se principalmente à previsão numérica do tempo (NWP) que utiliza vários dados meteorológicos coletados de sistemas de observação para simular a tendência da velocidade do vento. Eles têm utilidade prática limitada no lead time de previsão de 0-2 h devido a problemas de latência e precisam de condições iniciais precisas de parques eólicos que nem sempre podem ser garantidas [4]. No entanto, com situações climáticas significativas, os modelos NWP podem representar fenômenos climáticos que podem causar rampas de vento, como frentes e trovoadas. Diferente deles, o conceito central dos modelos estatísticos e inteligentes é considerar a previsão da energia eólica como um processo estocástico [5] e usar observações passadas para minerar as relações variantes no tempo dentro de séries temporais. Os métodos estatísticos mais populares incluem o filtro de Kalman [6], Box. Modelos Jenkins (modelos AR, ARIMA, etc.) [7], regressão Bayesiana [8], e assim por diante. Eles podem alcançar uma precisão satisfatória na previsão de séries temporais simples. Mas suas aplicações são limitadas devido à capacidade inadequada de processar dados não lineares. Associados ao aprendizado de máquina, os modelos inteligentes são cada vez mais predominantes para a previsão de energia eólica, como o multilayer perceptron (MLP) [9], suporte a máquina vetorial

(SVM) [10], e rede neural recorrente (RNN) [11]. Esses modelos geralmente superam os métodos estatísticos tradicionais devido às vantagens da auto-organização e da aprendizagem adaptativa.

Vários métodos têm sido apresentados com base em um único algoritmo de previsão, como rede neural convolucional (CNN) [12], rede de estado de eco (ESN) [13] e rede neural profunda (DNN) [14], cuja eficácia foi demonstrada por experimentos de comparação.

No entanto, as abordagens únicas nem sempre podem garantir alta precisão devido a algumas desvantagens inerentes, como falta de padrões teóricos para determinação de parâmetros e robustez insuficiente ao ruído. Para tanto, diversos métodos têm sido aplicados em modelos híbridos para obter previsões mais precisas e robustas. Por exemplo, os modelos NWP pós-processados por métodos estatísticos podem gerar uma previsão melhor do que qualquer método sozinho [15]. Além disso, para resolver a configuração de parâmetros de modelos, algoritmos de otimização metaheurística são empregados para buscar de forma adaptativa soluções globalmente ótimas. Exemplos incluem evolução diferencial (DE) [16], otimização de lobo cinzento (GWO) [17], busca de cuco (CS) [18], algoritmo de otimização multi-objetivo de baleias (MOWOA) [19], e etc. Entre eles, algoritmos de otimização multi-objetivos têm se mostrado eficazes para garantir a precisão e estabilidade do modelo de forma síncrona [20,21]. Para superar a estabilidade e a fraqueza de um único modelo, o ensemble learning integra vários modelos básicos e gera um preditor mais forte. Alguns métodos de ensemble famosos foram adotados para garantir a diversidade de base




Fig. 1. Classificação temporal da previsão de energia eólica.

tabela 1
Aplicações de modelos de previsão de energia eólica com diferentes horizontes temporais.

Horizonte temporal	Formulários
Muito curto prazo	– Regulação da turbina
Curto prazo	– Liquidação do mercado de eletricidade
Termo médio	– Compartilhamento de pré-carregamento
	– Alocação de energia
Longo prazo	– Gerenciamento do sistema de energia elétrica
	– Programação de manutenção de equipamentos relacionados

preditores, como reforço adaptativo (AdaBoost) [22] e bootstrap agregação (ensacamento) [23]. Além dos dois citados tipos de métodos, muitos métodos de processamento de dados têm sido amplamente utilizados para auxiliar os modelos orientados a dados. A decomposição do vento séries de velocidade, por exemplo, podem tornar os dados de entrada mais estacionários. Treinados pelos dados pré-processados, os modelos orientados a dados são mais provavelmente aprenderão as características não lineares do vento. A eficácia de combinar o processamento de dados foi verificada no aspecto de tanto precisão quanto eficiência.

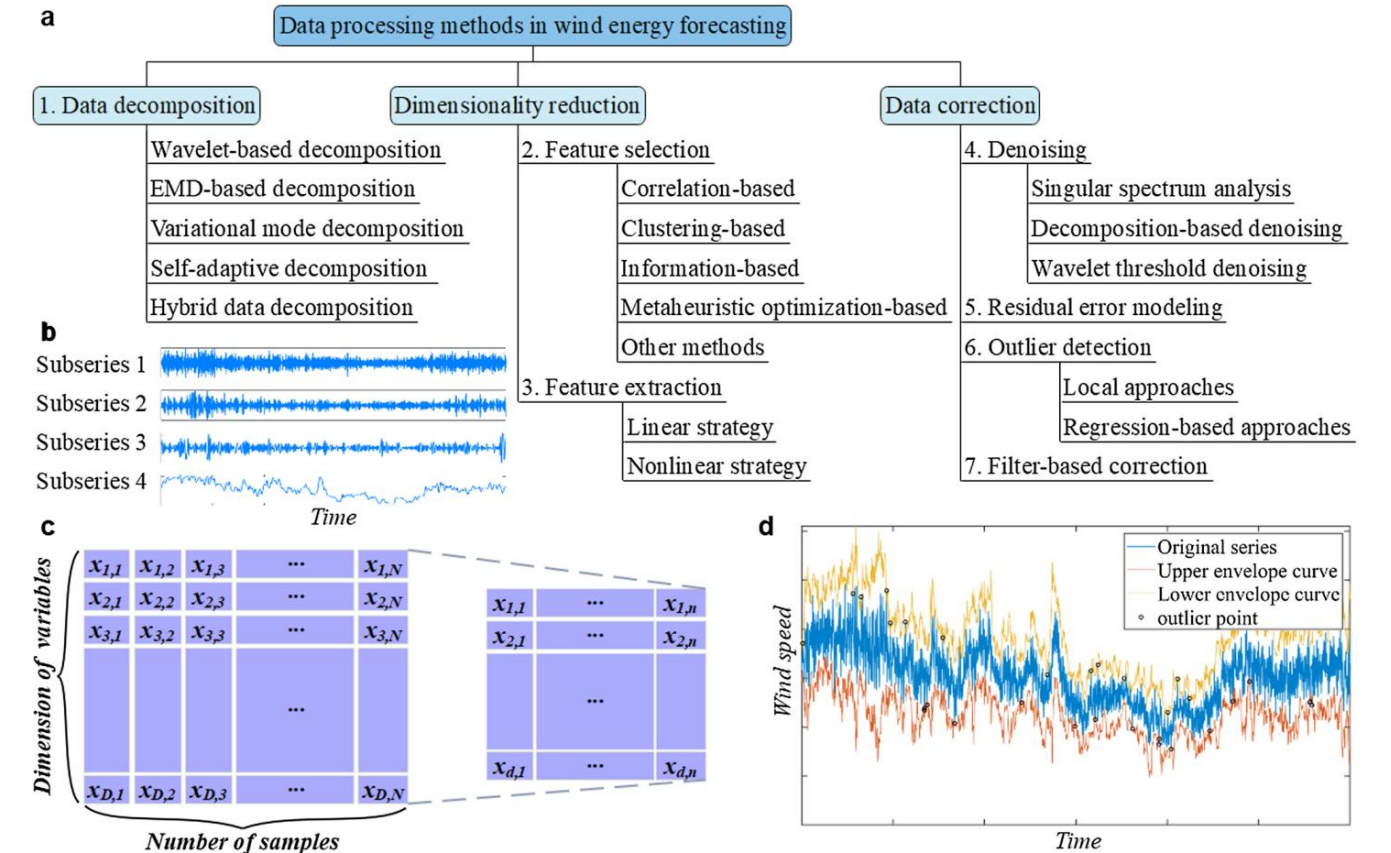
Dada a importância da previsão de energia eólica, muitos revisam trabalhos têm sido focados nas metodologias nele. Yan et al. revisou a análise de incerteza da previsão de energia eólica [24]. Okumus et al. encapsularam o estado atual da previsão de energia eólica e propuseram um método híbrido para previsões horárias [25]. Marugán pesquisou as aplicações de RNA em sistemas de energia eólica [26]. Wang et al. resumiu oito estratégias de previsão multi-passo à frente e as comparou em modelos inteligentes [27]. Shi et al. avaliou as abordagens de previsão híbrida de RNA, SVM e ARIMA [28]. Tascikaraoglu et al. revisou a previsão de energia eólica híbrida

modelos [29]. Zendehboudi et al. pesquisou as aplicações do SVM em previsão de energia solar e eólica [30]. Essas revisões resumiam a modelos de previsão de energia eólica sob diferentes perspectivas. Embora alguns deles falassem sobre o processamento de dados, a indução e classificação não são relativamente aprofundadas e abrangentes. Por exemplo, a composição não é a única maneira de pré-processar a energia eólica original dados. Métodos de pré-processamento, como seleção de recursos e eliminação de ruídos, não atraíram muita atenção. Mas eles são amplamente utilizados, e sua eficácia foi verificada em muitos trabalhos de pesquisa. Um abrangente a revisão desses métodos é chamada. A principal contribuição deste artigo é apresentar uma categorização clara das aplicações de dados processamento na previsão de energia eólica, bem como os detalhes teóricos e de implementação. Pesquisadores em previsão de energia eólica podem obter conhecimento da situação atual, tendências futuras e desafios. Além do mais, para os métodos menos usados, esperamos que possam atrair mais atenção e ser amplamente experimentado no futuro.

A estrutura do artigo está organizada da seguinte forma: a Seção 2 apresenta uma classificação geral e introdução do processamento de dados discutido tecnologias. As seções 3 a 5 revisam os métodos de processamento de dados que são adotados para diferentes finalidades: decomposição de dados, redução de dimensionalidade e correção de dados. A Seção 6 apresenta uma discussão abrangente desses métodos, incluindo avaliação de desempenho, direções de pesquisa futuras e desafios. Por fim, a Seção 7 conclui o artigo.

2. Aplicações de processamento de dados na previsão de energia eólica

Um resumo gráfico das tecnologias discutidas neste artigo é mostrado na Fig. 2. Sete categorias de métodos de processamento de dados foram relatados em modelos inteligentes híbridos: (1) decomposição, (2) característica



seleção, (3) extração de recursos, (4) redução de ruído, (5) erro residual modelagem, (6) detecção de outlier e (7) correção baseada em filtro. Eles estão adotados em modelos de previsão para diversos fins. Em geral, a composição é adotada para transformar a série original em várias subséries estacionárias, de modo a reduzir a dificuldade de previsão. A seleção e extração de recursos são usadas para reduzir a dimensionalidade. E os outros quatro métodos são empregados para corrigir conjuntos de dados de entrada ou previsão de resultados.

Quanto às suas posições no modelo, os métodos adotados são integrado com diferentes estratégias, nomeadamente pré-processamento e pós-processamento. Eles têm diferentes intenções e resultados processados, como mostrado na Tabela 2. Em geral, o conceito principal de pré-processamento é reduzir a complexidade ou o ruído dos dados originais antes de serem inseridos modelos preditivos, enquanto o pós-processamento é para aprimorar saída de previsão.

3. Decomposição de dados

Nos últimos anos, mais de 100 trabalhos de pesquisa se concentraram em modelos híbridos baseados em decomposição [31]. Na literatura publicada, os modelos híbridos baseados em decomposição adotam basicamente o mesmo framework, que pode ser denominado como os modelos de decomposição-e-integração estrutura, como mostrado na Fig. 3. A estrutura utiliza decomposição métodos para decompor séries temporais originais não estacionárias em vários subsérie relativamente estacionária e, em seguida, constrói um modelo de previsão sobre cada subsérie para obter vários resultados de previsão individuais. O final resultado da previsão é obtido pela soma de todas as previsões individuais resultados. Ao prever independentemente cada subsérie usando o preditor pode melhorar a precisão da previsão da série de energia eólica. o A eficácia da decomposição também pode ser explicada pelo aspecto de frequência. As subséries têm com frequência mais concentrada

bandas, o que faz com que os preditores só precisem focar nos componentes de uma única banda de frequência e reduzir a dificuldade de previsão. Após uma revisão abrangente da literatura, a decomposição do mainstream Os métodos usados na previsão de energia eólica podem ser divididos em cinco categorias: (a) baseado em wavelet, (b) baseado em EMD, (c) modo variacional decomposição, (d) decomposição auto-adaptativa e (e) composição híbrida.

3.1. Decomposição baseada em wavelets

A teoria da análise wavelet é o representante mais destacado conquistas no campo do controle inteligente e da matemática aplicada. Possui boas propriedades de localização no domínio do tempo e no domínio da frequência, que podem decompor o sinal em componentes em diferentes bandas de frequência e, em seguida, obter resultados de decomposição de alta resolução.

Wang et al. transformada wavelet (WT) realizada com base na Wavelet de Daubechies com nove momentos de fuga e três camadas de decomposição na série de energia eólica original para gerar uma série aproximada A3, e três séries detalhadas, D1, D2 e D3 [32]. Dentro aplicações práticas, wavelet contínua e wavelet contínua transformação deve ser processada discretamente para operação do computador, o que resulta na transformada wavelet discreta (DWT). No entanto, o DWT tradicional tem uma limitação no tamanho do sinal de entrada. Em ordem de superar este problema, outro método de decomposição baseado em wavelets A transformada de wavelet discreta de sobreposição máxima (MODWT) também é utilizado para pré-processar a série de velocidade do vento [33]. O uso do MODWT e a análise multirresolução é bastante útil na previsão da velocidade do vento.

O WT apenas subdivide os componentes aproximados de cada camada. No entanto, em muitas aplicações, a série temporal contém muitas informações na frequência intermediária ou na alta frequência. Isso é

mesa 2
As intenções, resultados e posições de sete métodos de processamento de dados classificados.

Categoria	Intenções	Resultados	Pré-processando	Pós-processamento
Decomposição	• Reduza a dificuldade de previsão	Várias subséries relativamente estacionárias	ŷ	
Seleção de recursos	• Remova recursos redundantes ou obtenha o subconjunto mínimo	Subconjunto de conjuntos originais	ŷ	
Extração de recursos	• Reduza a dimensão com apenas uma pequena perda de informações	Novas características	ŷ	
Eliminar ruído	• Classifique e fortaleça as informações efetivas dos dados de entrada	Série sem ruído	ŷ	
Modelagem de erros residuais	• Corrija os erros sistemáticos	Série corrigida		ŷ
Deteção de valores discrepantes	• Melhore a qualidade do conjunto de dados	Dados sem outliers	ŷ	ŷ
Correção baseada em filtro	• Corrija o resultado da previsão	Série corrigida		ŷ
	• Remova os componentes extras gerados pela previsão			

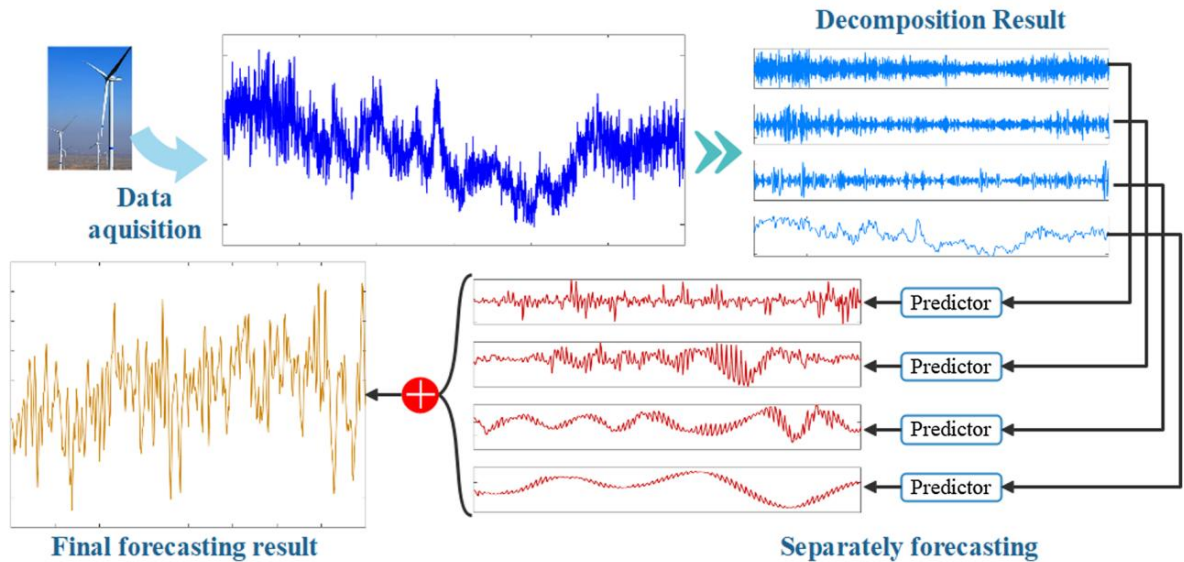


Fig. 3. A estrutura de decomposição e integração da previsão de energia eólica.

necessário para decompor ainda mais os componentes detalhados de alta frequência. A decomposição de pacotes wavelet (WPD) é uma variante de wavelet decomposição. As árvores binárias de WT e WPD com três camadas de decomposição são mostradas na Fig. 4. WPD pode decompor o componente de aproximação (A) e o componente detalhado (D) de cada camada para obter uma árvore binária de decomposição completa e uma divisão de informação mais abrangente. Foi provado que o modelo WPD-ELM supera o modelo WT-ELM porque o algoritmo WPD pode obter mais informações dos dados originais de velocidade do vento do que WT [34]. Portanto, WPD é uma escolha melhor do que WT quando se considera a composição de séries de energia eólica por tecnologias baseadas em wavelets.

3.2. Decomposição baseada em EMD

Como o método de decomposição baseado em wavelets depende muito a estrutura da árvore binária de decomposição e a escolha da wavelet função e nível de decomposição, dados experimentais suficientes ou conhecimento é necessário para alcançar bons resultados em aplicações práticas. Até certo ponto, a natureza não adaptativa limita seu uso. Empírico modo de decomposição (EMD) proposto por Huang et al. na década de 1990 pode decompor séries temporais complexas adaptativamente em um número limitado de funções de modo intrínseco (IMFs) [35]. A subsérie obtida tem um frequência instantânea com um significado físico claro, que pode muito bem descreva a oscilação da série temporal original em cada local.

Muitos pesquisadores empregaram o EMD para pré-processar a energia eólica série e os resultados comprovaram a eficácia [36]. Nos últimos anos, O EMD desenvolveu-se rapidamente e gerou muitas variações, o que é mostrado na Fig. 5. O EMD é um método de decomposição de sinal adaptativo, e há alguns hiperparâmetros que precisam ser ajustados. Mas dois principais problemas ainda existem em seu uso: (a) efeito de extremidade e (b) modo mistura. No algoritmo, é necessário usar a curva spline cúbica para ajuste os pontos extremos do sinal para construir as partes superior e inferior envelopes. No sinal real, o valor do ponto final não é necessariamente um valor extremo. Se o valor do endpoint for tratado como um valor extremo, ele resultará em um efeito de ponto final. O problema de mixagem de modo refere-se a sinais com diferentes segmentos de frequência em um IMF, ou sinais no mesmo segmento de frequência aparecem em diferentes IMFs. Para resolver este problema, foi aplicado um EMD baseado em filtro variável no tempo (TVF-EMD) para decompor a série de velocidade do vento, o que poderia fazer uma definição mais detalhada do FMI e ajustar a frequência de corte [37].

Outra versão melhorada do EMD é o modo de composição empírico de conjunto (EEMD). O EEMD adiciona ruído branco ao sinal original

uniformemente distribuído por todo o espaço tempo-frequência do sinal. Como o ruído branco tem um espectro uniformemente distribuído, os sinais de diferentes escalas são automaticamente associadas a escalas de referência apropriadas para ruído branco. Devido às características de média zero ruído, após vários cálculos, o ruído será cancelado iterativamente, então a média de múltiplos conjuntos de funções de modo próprio pode ser calculada como o resultado final da decomposição real. Resultados experimentais demonstraram que o EEMD pode ajudar a determinar as características do vento séries de velocidade, de modo a melhorar efetivamente o desempenho e robustez dos modelos de previsão [38].

Devido à adição de ruído branco auxiliar no EEMD, cada IMF tem mais ruído no processo de reconstrução. Para eliminar o ruído residual, geralmente é necessário aumentar o número de EMD operações e realizar uma grande média geral, o que reduz muito a eficiência computacional do EEMD. No entanto, quando complementares A decomposição em modo empírico do conjunto (CEEMD) adiciona ruído, a polaridade oposta é usada, ou seja, ruído branco com a mesma amplitude, mas fase oposta é adicionada ao sinal alvo, respectivamente, e o efeito de eliminar o ruído residual pode ser rapidamente alcançado usando apenas um pequeno número de tempos médios. Diversas literaturas utilizam o CEEMD para compor séries de velocidade do vento e obter melhor desempenho [39].

Para obter um menor custo computacional, a decomposição em modo empírico de conjunto completo com ruído adaptativo (CEEMDAN) foi adotado para pré-processar a série de velocidade do vento, que tem o seguinte vantagens: (1) Introduzir vetor de coeficiente de ruído adicional para controlar o nível de ruído de cada estágio de decomposição; (2) A reconstrução é completado sem ruído; (3) O número de ensaios é inferior ao EEMD e CEEMD; (4) O problema de que o EEMD e o CEEMD têm tendência a produzir componentes incorretos é resolvido [40,41]. No entanto, o CEEMDAN ainda tem dois problemas que precisam ser melhorados: (1) A o modo contém uma certa quantidade de ruído residual; (2) As informações do sinal aparecem "depois" do EEMD, e existem alguns modos espúrios em o início da decomposição [42]. Para resolver esses problemas, O CEEMDAN melhorado (ICEEMDAN) foi proposto e utilizado para decompor a série de velocidade do vento na Ref. [43]. Os resultados experimentais mostraram que comparando ICEEMDAN com EMD, EEMD e CEEMDAN, o as melhorias médias do MAPE foram superiores a 5,82% na proposta modelos. Portanto, pode-se concluir que o ICEEMDAN O método é mais poderoso do que EMD, EEMD e CEEMDAN na execução da decomposição de séries de energia eólica.

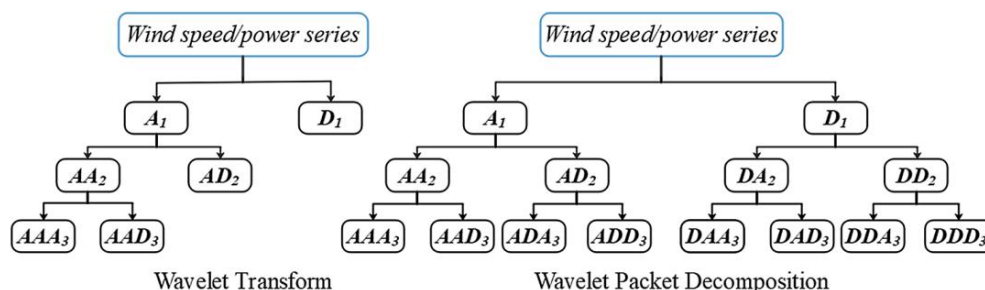


Fig. 4. As árvores binárias de WT e WPD. A representa a subsérie aproximada, enquanto D representa a subsérie detalhada.




Fig. 5. O desenvolvimento e melhoria processo do EMD e suas variantes.

3.3. Decomposição em modo variacional

Outra tecnologia avançada de decomposição tem prevalecido em últimos anos, ou seja, decomposição em modo variacional (VMD), proposta por Dragomiretskiy e Zosso [44]. Pode decompor o não estacionário sinal em funções de modo intrínseco de banda limitada múltipla (BLIMFs) por métodos não recursivos. Em comparação com a decomposição baseada em EMD métodos, VMD evita erros causados durante o cálculo de recursão e o fim da recursão. Tem sido amplamente aplicado na velocidade do vento previsão [45–48]. X. Wang et al. comparou modelos baseados em EEMD com Modelos baseados em VMD para previsão de velocidade do vento de curto prazo. Resultados mostrou que o primeiro era sensível tanto ao ruído quanto à amostragem. Ao contrário, o modelo baseado em VMD demonstrou melhor robustez ao ruído e separação de componentes mais precisa [49].

3.4. Decomposição auto-adaptativa

Todos os métodos de decomposição mencionados acima precisam pré-determinar vários parâmetros, como a função wavelet e o nível de composição em WPD, o número de IMFs em EMD e o número de modos em VMD. Mas os métodos de decomposição auto-adaptativos podem ajustar os parâmetros de forma adaptativa. Duas decomposição auto-adaptativa métodos têm sido relatados e aplicados na previsão de energia eólica, nomeadamente decomposição em modo variacional otimizado (OVMD) e transformada wavelet empírica (EWT).

Dragomiretskiy relatou que poucos modos no VMD podem levar a segmentação insuficiente, enquanto muitos modos podem capturar ruído adicional ou causar problemas de mixagem de modo [44]. Na Ref. [50], C. Zhang et al. propôs um novo método para decidir os parâmetros ótimos de VMD. Primeiro calcula a frequência central do modo de decomposição com valores de k diferentes. Uma vez que o fenômeno de frequência semelhante ocorre, $k-1$ é selecionado como o K ótimo para decomposição. Então, diferentes valores do parâmetro de atualização são testados e o melhor parâmetro é selecionado de acordo com o erro quadrático médio (RMSE) entre a série temporal de denoising e a sequência original. Daí, o

o número de modos no VMD pode ser determinado de forma adaptativa.

O EWT [51] supera o defeito de predeterminar parâmetros, que pode dividir a banda de frequência autonomamente de acordo com a espectro do sinal e gerar uma série de filtros para decompor os dados, como é mostrado na Fig. 6. Devido à sua excelente capacidade de adaptação, muitas publicações artigos utilizaram EWT para decompor a série original de energia eólica [52]. Na Ref. [53], três métodos de decomposição, incluindo EMD, WPD e EWT foram utilizados para decompor a série de velocidade do vento em várias sub-séries. As sub-séries de baixa e alta frequência foram previstas por longa rede neural de memória de curto prazo e rede neural Elman, respectivamente. O desempenho de três métodos de decomposição diferentes foram comparados. E o resultado mostrou que a previsão baseada no EWT os modelos tiveram maior precisão do que os modelos baseados em WPD e EMD.

3.5. Decomposição de dados híbrida

Para melhorar ainda mais o desempenho da decomposição método, alguns estudiosos propuseram algoritmos de decomposição híbrida, também denominado algoritmo de decomposição secundária (SDA) [54]. Geralmente, os algoritmos de decomposição híbrida decompõem ainda mais os componentes obtidos da decomposição da primeira camada para extrair componentes mais detalhados da sequência original. Sob a condição de esquema de decomposição razoável, o efeito do modelo de previsão é melhor do que outros métodos de decomposição.

A seleção de componentes decompostos é um fator importante afetando o desempenho das tecnologias de decomposição híbrida. Liu et al. [55] estudaram três casos diferentes com base no aprendizado extremo máquina (ELM): decomposição secundária de baixa frequência, alta frequência ou todos os componentes nos resultados da decomposição da primeira camada. Os resultados da comparação mostraram que a decomposição de segunda ordem de baixa frequência e todos os componentes podem melhorar significativamente o precisão de previsão, enquanto a decomposição de segunda ordem de alta frequência não poderia. Isso implica que determinar quais sub-séries do resultado da decomposição da primeira camada deve ser ainda mais decomposto é um passo importante nos métodos de decomposição híbrida. Na literatura, dois estratégias são adotadas para resolver este problema. Elas são resumidas como segue:

Estratégia de decomposição híbrida 1: especifique a sub-série a ser mais decomposto. Essa estratégia de decomposição híbrida seleciona diretamente sub-séries específicas para alcançar a decomposição secundária. A sub-série selecionada é geralmente aquela com maior frequência. Yin et al. acreditava que a primeira função de modo intrínseco (IMF1) derivada de EMD continha muitas informações características potenciais e descobriu que utilizar o WPD para processar o IMF1 poderia melhorar significativamente a precisão do modelo. Um fenômeno interessante foi que a utilização de WPD para processar apenas o IMF1 foi melhor do que os resultados da previsão de utilizando WPD para processar IMF1 e IMF2 ao mesmo tempo [56]. Da mesma forma, Peng et al. usou VMD para decompor o componente com o maior frequência obtida pelo CEEMDAN. Quanto maior a frequência foi, quanto mais forte o não estacionário e mutagenicidade da sequência, levando à diminuição da previsibilidade [57]. Yu et al. WPD empregado para decompor a série de velocidade do vento, e aplicado SSA para remover informações redundantes da sub-série com a maior frequência D1 [58]. Na Ref. [59], foi proposta a decomposição do sinal trifásico, que primeiro obteve os componentes sazonais e de tendência por SSA. E então o componente de tendência foi decomposto por um secundário método de decomposição.

Estratégia de decomposição híbrida 2: use indicadores para determinar as sub-séries a serem decompostas posteriormente. Esta estratégia de composição híbrida utiliza critérios de avaliação para comparar a estabilidade ou desordem de sub-séries de primeira camada. E as sub-séries mais não estacionárias são ainda mais decompostas. Sampleentropy (SE) é um método comumente usado




Fig. 6. EWT: a detecção automática de limites no domínio da frequência. Neste caso, a série de velocidade do vento é decomposta em 28 segmentos.

critério de avaliação em tecnologias de decomposição híbrida, que podem medir bem a previsibilidade de sequências. O componente com maior SE geralmente apresenta as subséries mais desordenadas. Zhang et al. utilizou o SE para estimar a complexidade das subséries na decomposição da primeira camada obtida pelo VMD e a subsérie com o maior SE foi ainda decomposta pelo WPD. Não surpreendentemente, o modelo baseado em algoritmo de decomposição híbrida obteve melhor precisão do que os outros modelos baseados em decomposição [60]. Da mesma forma, algumas outras literaturas empregaram o SE, como CEEMD-SE-VMD [61] e WPD SE-VMD [62]. Mi et al. adotou o teste de Dickey-Fuller aumentado (ADF) para determinar se as subséries obtidas por WPD eram estacionárias [63]. As subséries não estacionárias foram decompostas em uma série de FIMs pela EMD.

Ambas as estratégias de decomposição híbrida acima provaram ser eficazes. Os modelos baseados em algoritmos de decomposição híbrida geralmente apresentam melhor desempenho no aspecto de precisão e estabilidade. Mas à medida que o número de subséries aumenta, aumenta o tempo de computação. Ao realmente aplicar algoritmos de decomposição secundária, a compensação deve ser feita para equilibrar a precisão do cálculo e o tempo.

A Tabela 3 resume os métodos de decomposição mencionados acima, incluindo suas características, detalhes de implementação e algoritmos utilizados nas referências.

4. Redução de dimensionalidade

Além de melhorar a precisão da previsão através da decomposição da série original de energia eólica, a gestão dos dados de entrada também se preocupa como uma forma potencial de melhorar o desempenho dos modelos híbridos. A redução da dimensionalidade dos dados de entrada pode reduzir bastante a complexidade computacional e o erro de previsão causado por informações redundantes. A seleção de recursos e a extração de recursos são duas principais formas de obter redução de dimensionalidade. Mas eles têm algumas diferenças. A seleção de recursos refere-se à seleção de um subconjunto do conjunto de recursos existente de acordo com determinados critérios, enquanto os recursos obtidos pela extração de recursos são um mapeamento do conjunto de recursos original, ou seja, a extração de recursos pode produzir novos recursos a partir dos dados originais.

4.1. Seleção de recursos

Tem sido bem reconhecido que as combinações de características individualmente boas não levam necessariamente a um bom desempenho [78].

Tabela

3 Um resumo dos métodos de decomposição na previsão de energia eólica.

Categoria	Subcategoria	Características ou detalhes de implementação	Algoritmos utilizados nas referências
Decomposição Baseado em Wavelet		• Boas propriedades de localização no domínio do tempo e domínio da frequência • Análise multiresolução • Depende muito da estrutura da árvore binária de decomposição e da escolha da função wavelet e do nível de decomposição	WT [11], DWT [64], MODWT [33], WPD [65]
	Baseado em EMD	• A subsérie tem uma frequência instantânea com um significado físico claro	EMD [66], EEMD [67], FEEMD [68], CEEMD [69], TVF-EMD [37], CEEMDAN [40], ICEMDAN [70]
		• O EMD tradicional tem problemas de efeito de ponto final e mixagem de modo • Adaptativo, poucos hiperparâmetros • Muitas variantes foram propostas para melhorar seu	
	Decomposição em modo variacional	habilidade	[71,72]
Decomposição auto-adaptativa		• Múltiplas funções de modo intrínseco de banda limitada • Método não recursivo • Dividir a banda de frequência de forma autônoma • Superar o defeito de predeterminação de parâmetros • Combinação de diferentes métodos de decomposição • Extrair componentes mais detalhados • Melhor desempenho em termos de precisão e estabilidade • Não é fácil de fazer esquema de decomposição razoável • Aumento do tempo de computação	OVMD [50], EWT [73]
	Decomposição híbrida		WT + SSA [58], WPD + VMD [62], WPD + EMD [55,63], WPD + FEEMD [54], WPD + CEEMDAN [74], EMD + WPD [56], CEEMD + VMD [75], CEEMDAN + VMD [57,76], VMD + SSA [77], VMD + WPD [60], SSA + FEEMD + VMD [59]

Os métodos de seleção de recursos fazem esforços para encontrar o subconjunto mínimo do conjunto de recursos de entrada, a fim de aumentar a eficiência da computação da rede [79]. Existem dois frameworks básicos para realizar a seleção de recursos: **wrapper** e **filtro** [80], como mostrado na Fig. 7. A abordagem wrapper usa o desempenho do aluno como critério de avaliação do conjunto de recursos para seleção de recursos. A abordagem de filtro usa critérios de avaliação para aprimorar a correlação entre recursos e classes e para reduzir a correlação entre recursos. Como o nome indica, é como um filtro que exclui recursos desnecessários. A principal diferença entre as duas formas de seleção de recursos mencionadas acima é se usar algoritmos de aprendizado. Em geral, a abordagem do filtro é de alta velocidade, enquanto a abordagem do wrapper tem melhor precisão.

De acordo com os métodos adotados, a seleção de recursos na previsão de energia eólica pode ser dividida em cinco categorias: (1) baseada em correlação, (2) baseada em agrupamento, (3) baseada em informações, (4) baseada em otimização metaheurística e (5) outros métodos de seleção de recursos. Na maioria dos casos, correlação, agrupamento e seleção de recursos baseados em informações são métodos de filtro, enquanto os métodos de otimização baseados em algoritmos são métodos wrapper.

4.1.1. Métodos baseados em correlação

Os métodos de seleção de recursos baseados em correlação consideram a correlação entre recursos ou correlação entre recursos e saída.

A função de autocorrelação (ACF) e a função de correlação parcial (PACF) foram relatadas na escavação da extensão inerente do atraso nos conjuntos de dados [59]. Liu et al. utilizou ACF e PACF juntamente com o teste de causalidade de Granger para primeiro obter as características de velocidade do vento que estavam altamente correlacionadas com os dados alvo e, em seguida, selecionou o conjunto de características como a entrada do preditor [81]. Em sua pesquisa, a relação entre temperatura e velocidade do vento foi analisada e os resultados foram bastante interessantes: a temperatura afetaria a velocidade do vento defasada dois e três (1 h e 1,5 h). Portanto, as variáveis de entrada para o preditor foram selecionadas como a velocidade histórica do vento 0,5 h e 1,5 h à frente, e a temperatura 1,5 h à frente.

A teoria do sistema cinza também é utilizada para implementar a análise de correlação de recursos. Jiang et al. usou Lag 1 a Lag 6 de duas séries de velocidade do vento coletadas dos geradores de turbinas eólicas adjacentes como entradas originais e aplicou análise de correlação de cinza (GCA) para selecionar informações úteis de flutuação [82]. Eles utilizaram o método de classificação para classificar o grau relacional cinza das variáveis de grande para pequeno. O subconjunto foi selecionado a partir das primeiras enésimas variáveis. Os resultados do ranking mostraram que as velocidades históricas do vento 10 min, 20 min, 30 min e 40 min à frente coletadas do local alvo e 10 min à frente de sua turbina eólica adjacente foram crucialmente representativas.

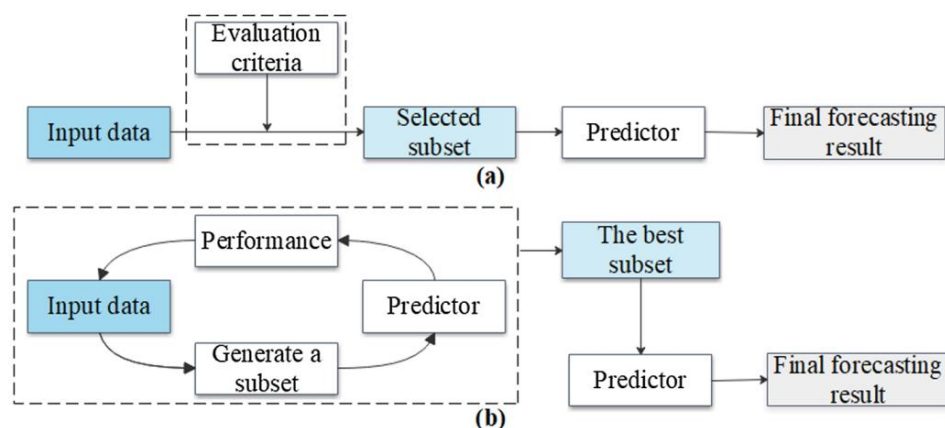


Fig. 7. As estruturas básicas de seleção de recursos: (a) filtro, (b) wrapper.

Na Ref. [64], um novo modelo de seleção de recursos baseado em correlação foi incluído na decomposição DWT. Eles primeiro calcularam o coeficiente de correlação de subséries decompostas e dados originais. Se o coeficiente de correlação foi menor do que o limite especificado, seria descartado como componente ilusório. Os dados originais foram decompostos em nove subséries. Os coeficientes de correlação mostraram que a 6ª subsérie apresentou o maior valor absoluto (0,600). Mas o 4º subsérie foi de apenas 0,004, que foi inferior ao limite selecionado (0,06). Portanto, foi eliminado para alcançar a seleção de conjuntos de recursos.

4.1.2. Métodos baseados em cluster

Alguns outros métodos de seleção de recursos são baseados em agrupamento técnico, que vêm atraindo cada vez mais atenção nos últimos anos. Os métodos de seleção de recursos baseados em cluster primeiro agregam os dados de entrada em vários clusters e, em seguida, remove alguns clusters dele, ou seleccione os clusters mais semelhantes ao alvo previsto.

Yu et al. empregou agrupamento espacial baseado em densidade de aplicativos com ruído (DBSCAN) para agrupar as amostras de treinamento originais em vários grupos, que contêm os outliers e outros [83]. O utilizado método de agrupamento pode efetivamente identificar outliers que geralmente não ocorrem e não são representativos, para que possam ser eliminados fortalecer a capacidade de previsão. Mas o DBSCAN é sensível ao seu dois parâmetros-chave, ou seja, ϵ e $MinPts$. Na literatura, eles optaram por aumentar o valor $MinPts$ para 10, a fim de classificar mais outliers. o a precisão da previsão do modelo com seleção de recursos teve 30% melhoria em comparação com modelos sem seleção de recursos.

Wang et al. usaram o método k-means para classificar o conjunto de dados incluindo velocidade do vento, direção do vento, temperatura, umidade e pressão em k clusters [84]. Os objetos de agrupamento foram vetores construídos pela velocidade do vento, temperatura, umidade e pressão. Elas amostras de cluster selecionadas que eram semelhantes ao alvo como entrada de modelo de previsão. O método de seleção de recursos k-means proposto apresentou a maior melhoria na precisão de previsão e eficiência do modelo proposto. Azimi et al. propuseram um algoritmo de k meios melhorado para agrupar dados de energia eólica [85]. No algoritmo proposto, eles usaram um novo método para resolver o problema da inicialização aleatória dos centróides do cluster. Ele mostrou melhor precisão do que a seleção tradicional de recursos de agrupamento k-means. Comparado com o k-médias

abordagens, clustering espectral (SC) é mais adaptável aos dados e requer menos carga computacional. Gerado a partir da teoria dos grafos, o SC converte o problema de agrupamento em particionamento espectral em um grafo não direcionado e ponderado. O SC foi empregado para reduzir a 5840 amostras para menos de 1000, o que aumentou muito a eficiência do modelo [86].

Na Ref. [87], o agrupamento fuzzy c-means baseado em kernel (KFCM) foi usado para agrupar as amostras em padrões de flutuação semelhantes. Para resolver o problema da descontinuidade de dados ao usar intermitentemente pontos amostrais, eles adotaram uma melhoria no agrupamento proposto

método alterando o objeto de cluster de pontos de dados para dados vetores. Os experimentos de comparação mostraram que usando as amostras reduzido pela metade pelo KFCM para alcançar a previsão pode obter resultados melhores ou semelhantes atuação. Isso implicava que a seleção de recursos do KFCM é útil para extrair as características dos dados.

4.1.3. Métodos baseados em informações

Os métodos de seleção de recursos baseados em informações relatados em vento a previsão de energia inclui informações mútuas (MI) [88] e informações mútuas condicionais (CMI) [89,90], que são baseadas na entropia.

A Fig. 8 mostra o diagrama de Venn de relacionamentos entre variáveis X e Y. MI estima o nível de informação entre dois variáveis. O MI entre X e Y é definido da seguinte forma:

$$I(X;Y) = \sum_{x \in X} \sum_{y \in Y} P(xy) \log \frac{P(xy)}{P(x)P(y)} = H(X|Y) \quad (1)$$

onde $H(X)$ e $H(X|Y)$ são a entropia e a entropia condicional, respectivamente.

O CMI é uma extensão do MI. Dadas as variáveis aleatórias X, Y e Z, o O CMI é definido como:

$$I(X;Y|Z) = H(X,Y|Z) - H(X|Y,Z) - H(Y|X,Z) \quad (2)$$

Os recursos selecionados pelo CMI possuem informações independentes e dependência mútua fraca. Huang comparou o CMI com o MI e Coeficiente de Correlação de Pearson (PCC) [90]. O conjunto de recursos de redundância experimental foram os indicadores históricos e estatísticos de velocidade do vento e fatores meteorológicos em 21 de janeiro, 17 de abril, 18 de julho e 7 de novembro de 2009. Os resultados provaram que o CMI pode melhorar melhor o desempenho do modelo do que o MI.

4.1.4. Métodos baseados em otimização metaheurística

Vários trabalhos de pesquisa adotaram a otimização metaheurística algoritmos para alcançar a seleção de recursos. O conceito geral é considerar a seleção de subconjuntos como um problema de otimização de busca aleatória para




Fig. 8. O diagrama de Venn de relacionamentos entre variáveis correlacionadas X e Y.

o conjunto de dados original. O processo de otimização de dados de entrada é uma típica seleção de recurso de wrapper. Ele usa algoritmos de otimização metaheurística para gerar um subconjunto de variáveis de entrada, e o subconjunto é usado para treinar um preditor, de modo a obter os resultados de previsão correspondentes. Em seguida, a qualidade do subconjunto é avaliada a precisão do resultado da previsão. Esse processo é repetido várias vezes e obtém diferentes subconjuntos. Por fim, os subconjuntos obtidos são comparados para obter o melhor subconjunto. Em geral, o subconjunto com o menor erro de previsão no conjunto de validação é selecionado como o melhor subconjunto.

Salcedo-Sanz utilizou o algoritmo de otimização de recifes de coral (CRO), uma abordagem de inspiração biológica para selecionar o melhor conjunto de variáveis de entrada. Experimentos de parques eólicos nos EUA mostraram que o modelo baseado em CRO poderia obter melhores resultados [91]. Os métodos de otimização baseados em população têm sido amplamente implementados para seleção de características de séries de velocidade do vento, como otimização por enxame de partículas (PSO) [92], algoritmo genético (GA) [93]. Ref. [94] compararam dois algoritmos de otimização, a saber, PSO e evolução diferencial (DE). As entradas candidatas foram vetores de atraso de tempo de dados coletados de 30 parques eólicos e as entradas selecionadas foram usadas para prever um único parque eólico em alemão. Comparado com a seleção manual de variáveis de entrada, o erro de previsão apresentou uma grande redução usando os métodos de seleção automatizada de recursos propostos.

Alguns outros algoritmos de otimização usados para seleção de recursos são introduzidos como versões binárias para resolver o problema de otimização de parâmetros discretos. Na Ref. [50], o PACF foi primeiramente usado para determinar a ordem de atraso, e então a entrada candidata foi selecionada usando um algoritmo de busca de retorno de valor binário (BBSA). Na Ref. [37], a decomposição TVF-EMD foi combinada com a seleção de características. Os IMFs decompostos foram construídos para o recurso candidato, e um novo algoritmo baseado em população híbrida chamado otimização de enxame de partículas binárias e algoritmo de busca gravitacional (BPSOGSA) foi aplicado para alcançar a seleção de recursos. Os modelos com seleção de atributos geralmente obtiveram menor erro de previsão do que os modelos sem seleção de atributos.

4.1.5. Outros métodos de seleção de recursos

Além dos métodos de seleção de recursos mencionados acima, alguns outros métodos populares também são usados. Seus detalhes de implementação serão apresentados nesta subseção.

A reconstrução do espaço de fase (PSR) é um método baseado na teoria do caos, no qual o tempo de atraso é levado em consideração [95]. Ele é usado para analisar as características dinâmicas de séries temporais e mapear as sequências no espaço de fase. Depois que as séries temporais de velocidade do vento são transformadas no espaço de fase, os dados no espaço de fase são usados como entrada para realizar a previsão. Wang et al. usaram o método CC para determinar a dimensão de incorporação e o tempo de atraso do PSR e, em seguida, o utilizaram para selecionar a forma de entrada das séries de velocidade do vento coletadas das montanhas Zhangye, Wuwei, Jiuquan e Mazong na China [96]. Alguns estudiosos combinaram PSR com SE para obter a seleção de recursos [68]. A série original de velocidade do vento foi primeiramente decomposta em 8 IMFs e um resíduo por FEEMD, e então as subséries foram recombinadas de acordo com os valores de SE. Os cinco subconjuntos obtidos foram considerados como candidatos

Tabela

4 Um resumo dos métodos de seleção de recursos na previsão de energia eólica.

Categoria	Subcategoria	Características ou detalhes de implementação	Algoritmos utilizados nas referências
Seleção de recursos Baseado em correlação		• Considere a correlação entre os recursos ou a correlação entre os recursos e a saída • Agrega os dados de entrada em vários clusters • Forte interpretabilidade • Com base na entropia • Não há necessidade de fazer qualquer suposição sobre a relação entre dados	DWT auxiliado por correlação [64], ACF e PACF [99], GSO [47], GCA [82]
	Baseado em cluster		DBSCAN [83], KFCM [87], K-means [84,85], SC [86]
	Baseado em informações		MI [100], MIC [90]
	Otimização metaheurística baseada	• Pesquisa aleatória de combinações ótimas de variáveis de entrada • Boa aplicabilidade • Não sujeito a características específicas de dados	BPSOGSA [37], BBSA [50], CRO [91], GA [93], PSO [94], DE [94]
	Outros	• Alguns outros métodos populares de seleção de recursos, incluindo hibridização de vários algoritmos	RF [32], PSR [101], Seleção de recursos profundos [97], KLD-EM-SE [98]

entrada e transformada em dados no espaço de fase. Um estudo de caso de dois parques eólicos diferentes na China verificou a validade e eficácia.

Random Forest (RF) é um algoritmo de aprendizado de máquina novo e altamente flexível, que vem ganhando cada vez mais atenção. Sua essência é, na verdade, o conjunto de inúmeras árvores de decisão. Na Ref. [32], foi adotado um método de seleção de características de entrada baseado em RF. A importância das características candidatas, incluindo temperatura, umidade, pressão atmosférica e velocidade histórica do vento, foram avaliadas pela RF. A seleção de recursos de RF proposta foi baseada no método wrapper. Em cada iteração, o erro de previsão foi calculado e após todas as iterações concluídas, o subconjunto de recursos obtido teve o menor número de variáveis e os melhores resultados de previsão. Concluiu-se que o método RF melhorou efetivamente a capacidade de previsão dos preditores inteligentes ao selecionar as variáveis de entrada ótimas.

Gram-Schmidt ortogonal (GSO) pode vetorizar um conjunto em um grupo de vetores ortogonais padrão. Na Ref. [47], o processo GSO foi utilizado para selecionar iterativamente o recurso que poderia maximizar o cosseno do ângulo entre o vetor de recursos de entrada e o vetor de saída. Vale ressaltar que eles definiram o número de feições selecionadas por um método de otimização chamado algoritmo de busca gravitacional (GSA), e foi adotado o número de feições selecionadas com o menor RMSE. Portanto, é uma combinação de métodos de wrapper e filtro.

No entanto, a maioria dos métodos de seleção de características existentes sofre de duas grandes desvantagens: (a) métodos lineares como ACF e PACF só levam em consideração relações lineares; (b) métodos não lineares como KPCA usam subconjunto de recursos contínuos como um fator sem analisar o atraso. Para resolver esses problemas, Feng et al. propôs uma estrutura de seleção de recursos profunda [97]. Combinou quatro abordagens: (a) PCA; (b) Teste de causalidade de Granger (GCT); (c) ACF e PACF; e (d) eliminação de recursos recursivos (RFE). Eles primeiro realizaram o PCA para reduzir a dimensão da variável e, em seguida, o GCT foi usado para estudar a correlação entre outras variáveis e séries de velocidade do vento. Para explorar a defasagem das variáveis, foram empregados ACF e PACF. Por fim, eles utilizaram o RFE para garantir a integração efetiva com outras defasagens de tempo variáveis. A estrutura de seleção profunda de recursos proposta é bastante instigante. Conforme esperado, os experimentos usando dados de sete locais de Radiação de Superfície (SURFRAD) provaram que o modelo proposto poderia melhorar significativamente o desempenho da previsão de 1 hora à frente. Da mesma forma, Wang et al. utilizaram divergência de Kullback-Leibler (KLD), medida de energia (EM) e SE para alcançar a seleção e extração de características ótimas de subséries de energia eólica decomposta [98]. Eles recombinaram os componentes em menos subséries com base no valor SE, o que pode melhorar a eficiência do cálculo e a precisão da previsão. A classificação dos métodos de seleção de recursos discutidos acima é fornecida na Tabela 4.

4.2. Extração de recursos

4.2.1. Estratégia linear

O método de extração de características mais comumente usado é a análise de componentes principais (PCA). É um método de extração de recursos linear. De

Por meio de transformações ortogonais, o vetor aleatório original cujos componentes estão relacionados entre si é transformado em um novo vetor aleatório cujos componentes não estão relacionados entre si. Em seguida, a redução da dimensionalidade é realizada no sistema de variáveis multidimensionais para que ele possa ser convertido para o sistema de variáveis de baixa dimensão com maior precisão.

Muitas aplicações de PCA têm sido feitas na previsão de energia eólica [102]. Kong et al. empregou o PCA para extrair as principais variáveis que realmente afetam a velocidade do vento [103]. As taxas de contribuição dos componentes principais foram classificadas como velocidade do vento, temperatura, pressão do ar, direção do vento em ordem decrescente. Se todos os componentes principais fossem considerados e escolhidos como insumo, os índices de erro de previsão não seriam os melhores, o que articulava a redundância de fatores em nada adiantar aos modelos de previsão. Além disso, a previsão baseada na combinação de velocidade do vento, temperatura e pressão do ar teve o melhor desempenho. Seu experimento demonstra que considerar todos os fatores que afetam a velocidade do vento é desnecessário e inútil. Na Ref. [104], um vetor original de 47 dimensões foi reduzido em um espaço de 18 dimensões usando PCA generalizada. Uma conclusão interessante é que o modelo baseado em PCA superou o modelo baseado em clusters, demonstrando a eficácia da extração de recursos.

4.2.2. Estratégia não linear

A análise de componentes principais do kernel (KPCA) é uma versão não linear do PCA. Ele primeiro realiza a transformação não linear para a amostra e, em seguida, adota o PCA no espaço de transformação. O KPCA generaliza o PCA para condições não lineares por meio da função kernel. Sun et al. desenvolveu uma abordagem integrada para a previsão da velocidade do vento, combinando PSR com KPCA [101]. O PSR foi usado para selecionar os vetores de entrada e o KPCA foi usado para reduzir a dimensão. Os resultados experimentais mostraram que o modelo híbrido proposto superou significativamente outros modelos de benchmark.

5. Correção de dados

Esta seção revisa os métodos de processamento de dados que são utilizados para corrigir conjuntos de dados de entrada ou resultados de previsão. Quatro métodos de correção de dados totalmente diferentes foram adotados nos artigos publicados, incluindo denoising, modelagem de erro residual, detecção de outlier e correção baseada em filtro.

5.1. Eliminar ruído

A remoção de ruído dos dados de entrada é uma maneira importante de melhorar o desempenho dos modelos de previsão. O objetivo do denoising é separar e fortalecer as informações efetivas dos dados de entrada e remover as informações de ruído que interferem no treinamento do modelo.

5.1.1. Análise de espectro singular

A análise de espectro singular (SSA) é um método baseado em decomposição de valor singular (SVD) que pode efetivamente decompor e reconstruir sinais. Primeiramente, ele converte os dados unidimensionais em uma matriz de trajetória por um comprimento de janela apropriado, e os principais autovalores são selecionados para reconstruir componentes com informações de tendência significativas. Uma ilustração detalhada das etapas cruciais da SSA é fornecida na Fig. 9.

Aparentemente, os primeiros valores próprios são representativos dos modos estatisticamente significativos de velocidade do vento. A série reconstruída reflete a tendência de variação da energia eólica, enquanto a série residual contém principalmente ruído. O SSA tem sido amplamente aplicado para reduzir o impacto negativo das características de interferência aleatória em dados brutos [77]. L. Xiao et al. compararam SSA com FEEMD e concluíram que o modelo baseado em SSA prevaleceu sobre o modelo baseado em FEEMD no aspecto de precisão, independentemente da previsão de uma ou várias etapas [105]. Na Ref. [106], a fim de melhorar o desempenho, um método de otimização denominado otimização de tempestade cerebral (BSO) foi empregado para determinar a

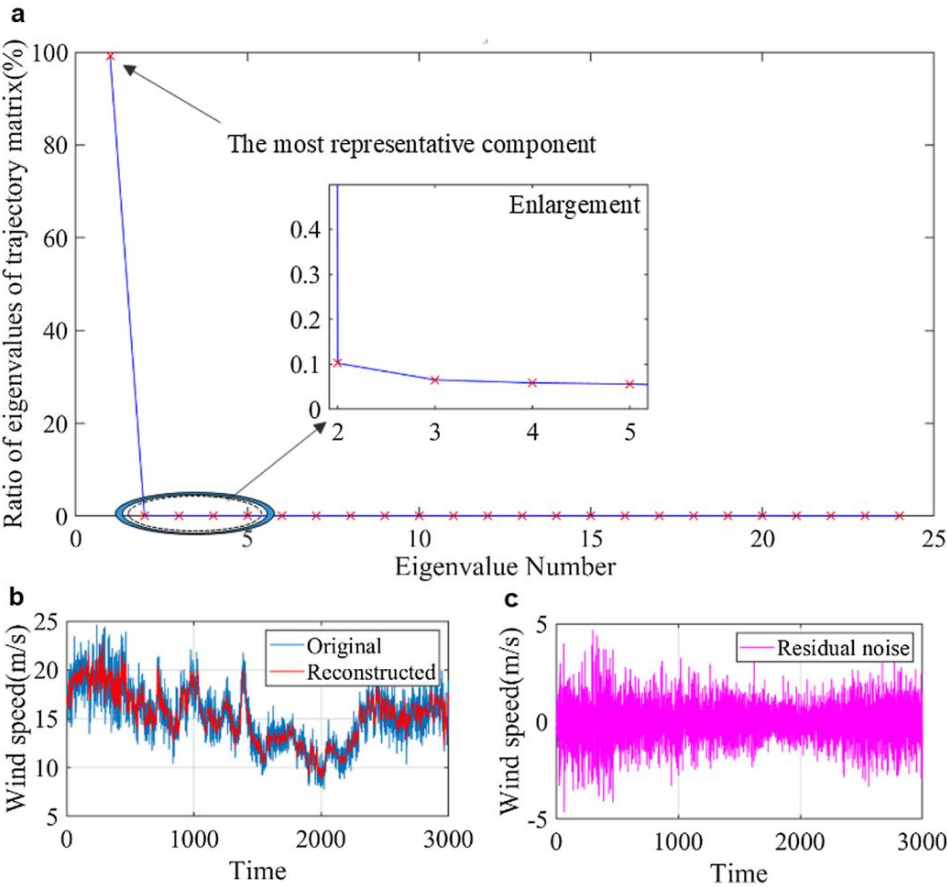


Fig. 9. A ilustração de etapas cruciais na SSA. (a) Autovalores da matriz de trajetória. O número de autovalores é igual ao comprimento da janela, que é definido como 24 neste caso. (b) Série reconstruída, determinada pelos autovalores selecionados. A curva vermelha representa o componente de tendência reconstruído pelos primeiros 5 autovalores. Séries residuais reconstruídas a partir dos 19 autovalores restantes. Geralmente é considerado como ruído.

Tabela 5
Os detalhes de implementação de métodos de redução de ruído baseados em decomposição.

Método de decomposição	Resultados de decomposição	Componentes descartados	Referência
WT	Um componente de aproximação e um componente detalhado	O componente detalhado	[81]
WPD	Dois componentes de aproximação e dois componentes detalhados	Componente de frequência mais alta	[96]
EMD	Cinco FMIs e um resíduo	FMI1	[107]
CEEMD	Oito a dez FMIs e um	Componente de alta	[90]
CEEMDAN	Nove FMIs e um resíduo	frequência do FMI altamente volátil	[108]
EWT	Três modos não correlacionados e um residual	O resíduo	[109]
EEMD	Sete FMIs e um resíduo	FMI1	[110]
	Sete FMIs e um resíduo	FMI1 e FMI2	[111]
	Cinco FMIs e um resíduo	FMI1 e residual	[112]

comprimento ideal da janela e número de autotripsos de SSA. Os resultados experimentais mostraram que os erros de previsão diminuiram significativamente após a remoção de ruído BSO-SSA.

5.1.2. Denoising baseado em decomposição

O método de eliminação de ruído baseado em decomposição está associado a Seção 3. A série original de energia eólica é decomposta em vários subséries e então algumas das subséries são consideradas como ruído e descartado. A Tabela 5 lista os componentes descartados dos métodos de eliminação de ruído baseados em decomposição relatados na literatura. Embora os componentes selecionados sejam diferentes, todos eles têm uma coisa em comum: são componentes com maior frequência nos resultados de decomposição. Ao descartar componentes voláteis, a precisão da previsão e a eficiência do modelo pode ser efetivamente melhorada [90].

O tratamento de descartar o IMF1 parece ir contra a alguns algoritmos de decomposição híbrida mencionados na Seção 3.5, que decompor ainda mais o FMI1 para obter uma melhor precisão de previsão. No entanto, duas maneiras de lidar com o FMI1 fazem sentido. Como é relatado na Ref. [107], o IMF1 de alta frequência é muito pequeno para influenciar o resultado final resultado da previsão e sua previsão é imprevisível. Daí, alguns modelos optam por negligenciar o componente IMF1 e considerá-lo como ruído, porque a precisão da previsão pode ser pior quando o FMI1 é levado em consideração conta (como encontrado na Ref. [56]). Enquanto em decomposição híbrida modelos, a subsérie mais desordenada e irregular IMF1 é ainda decomposta para diminuir a dificuldade de previsão, possibilitando prever.

5.1.3. Denoising de limiar wavelet

Outro método de redução de ruído usado para séries de velocidade do vento é wavelet redução de ruído de limiar (WTD), cujo procedimento é mostrado na Fig. 10 . primeiro decompõe a série original em várias subséries, e depois os coeficientes wavelet de cada subsérie são manipulados usando um limiar apropriado. Uma vez que os coeficientes wavelet de sinais e

ruídos têm diferentes distribuições de intensidade em diferentes escalas, os coeficientes wavelet de ruídos em cada escala são removidos e a wavelet coeficientes de sinais podem ser retidos. Por fim, os coeficientes wavelet após o processamento são reconstruídos usando a forma inversa de wavelet trans para realizar a eliminação de ruído. Nas Refs. [63,113], o WTD foi usado para reduzir o ruído da série original da velocidade do vento e reduzir o ruído contido. Os resultados mostraram que ele alcançou mais de 10% de melhoria de precisão da previsão.

5.2. Modelagem de erros residuais

A modelagem de erros residuais é o método de pós-processamento mais utilizado na previsão de energia eólica. A Fig. 11 mostra sua estrutura. Estabelece um preditor para ajustar o resíduo de previsão erro, e o modelo de previsão de erro residual treinado é usado no teste definir. A série de erros de previsão é sobreposta com a série preliminar resultados de previsão para corrigir os erros sistemáticos. Em conformidade, o modelos construídos para a série original e erro residual são anotados como o **preditor principal** e o preditor **subordinado**, respectivamente. A modelagem de erros residuais é um processo que usa um preditor subordinado para aprender a tendência de mudança de erros e corrigir o resultado de previsão preliminar obtido pelo preditor principal.

Li et al. memória de longo prazo selecionada (LSTM) e regularizada Extreme Learning Machine (RELM) como preditor principal e subordinado, respectivamente [52]. Os resultados mostraram que o erro residual modelo poderia melhorar significativamente o desempenho da previsão. Na Ref. [43], a série residual foi decomposta em vários FMIs pelo ICEE MDAN. Eles construíram um modelo ARIMA para cada FMI. A modelagem de erro residual proposta é uma estrutura de uso comum para previsão de velocidade do vento baseada em decomposição.

Alguns pesquisadores usaram modelos com características diferentes para modelar componentes lineares e não lineares de séries de velocidade do vento, respectivamente. A hipótese de que existe uma relação aditiva entre o




Fig. 10. O procedimento de WTD.

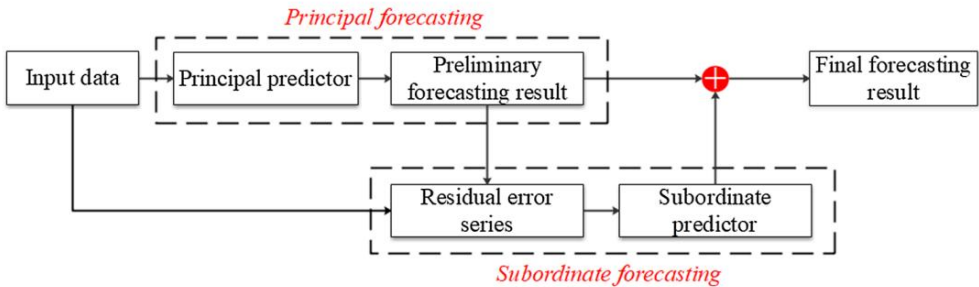


Fig. 11. A estrutura geral da modelagem de erros residuais.

Tabela 6
Os resultados de artigos publicados usando modelagem de erro residual.

Referência	Preditor principal	Previsor subordinado	Fontes de dados	Horizonte de previsão	Percentual de melhoria
[98]	LSTM	LSTM & GARCH	Corredor Hexi da China	1-5h	24,56–10,75% (MAE)
[116]	LSSVM	Markov	Noroeste da China	1 dia	2,67% (MAPE)
[28]	ARIMA	ANN/SVM	Colorado, EUA	1–9 h	4,99% a -0,18%
[43]	OLMO	ICEMDAN-ARIMA	Corredor Hexi da China	10 minutos	29,75% (MAE)
[52]	LSTM	RELM	Xinjiang, China	10-50 minutos	72,18–63,83% (MAPE)
[64]	LSSVM	GARCH	Minnesota, EUA	30 minutos	1,82% (RMSE)
[114]	ARMA	BP/SVM/RF	Seis estações de observação na China	1h	23,6% (MAE)
[115]	SVM	ELM/SVM	Província de Hebei, China	1-6h	23,94–36,74% (NMAE)

– A porcentagem de melhoria é baseada nos índices de erro de previsão usando modelagem de erro residual E1 e previsão sem modelagem de erro residual E2.

Porcentagem de melhoria = $\frac{E_1 - E_2}{E_2} \times 100\%$

componente linear e não linear da série de velocidade do vento é assumida [28], que pode ser expresso da seguinte forma:

$$\hat{y}_t = \mathbf{L} \mathbf{y}_t + \mathbf{N}_t \quad (3)$$

onde \mathbf{y}_t é o resultado final da previsão, \mathbf{L} é a componente linear e \mathbf{N}_t é o componente não linear.

Shi et al. usou o modelo ARIMA para capturar o componente linear de série de velocidade do vento. As séries residuais foram ajustadas por modelos não lineares incluindo ANN e SVM [28]. A combinação de um não paramétrico (NP) e três modelos AI/ML foram aplicados [114]. No modelo híbrido-ARMA-NP proposto, o ARMA é usado para obter o resultado da previsão, e NP é usado para capturar os componentes não lineares. Modelos AI/ML, incluindo BP, SVM e RF, são usados para comparação. Dentro o modelo híbrido-NP-ARMA proposto, os modelos NP e AI/ML são usados como modelo principal, enquanto ARMA é usado como modelo subordinado.

Os métodos de modelagem de erro residual propostos mencionados acima simplesmente prever a série residual. No entanto, alguma decisão métodos podem ser feitos antes da modelagem do erro residual. Correlação a análise foi implementada, e o modelo SVM ou ELM foi utilizado para modelar o resíduo de acordo com os resultados da análise de correlação [115]. Na Ref. [98], a correlação e a heterocedasticidade do erro residual foram consideradas. Eles dividem os estados de erro componentes em quatro tipos: (a) a série residual tem correlação e heterocedasticidade, (b) a série residual só tem correlação, (c) residual a série tem apenas heterocedasticidade, e (d) a correlação e a heterocedasticidade não são óbvias nas séries residuais. Para correlação, eles aplicaram o LSTM para prever o erro residual, enquanto para a heterocedasticidade utilizaram a heterocedasticidade condicional autorregressiva generalizada (GARCH). Os modelos com modelagem de erro residual executaram outros modelos para um passo, três passos e cinco passos à frente previsão.

O modelo de Markov também foi empregado para corrigir a previsão erro na ref. [116], que emprega probabilidade de transição de estado para calcular o estado de erro de previsão. Eles descobriram que a previsão os resultados após a modelagem de erros foram às vezes mais pobres do que antes modelagem de erros. Portanto, os valores médios dos valores originais e corrigidos resultado da previsão foram considerados como o resultado final da previsão. A média estratégia provou ser mais poderosa do que outros modelos. Tabela 6 lista o resultado de artigos publicados usando modelagem de erro residual métodos. Na maioria dos modelos propostos, a modelagem do erro residual pode melhorar a precisão em mais de 10 por cento, o que implica a sua eficácia.

5.3. Detecção de valores discrepantes

Em geral, outliers de séries temporais são pontos de dados que não seguem uma padrão geral de mudança ou tendência histórica. Quando os dados são contaminados por outliers, os modelos orientados por dados podem aprender erroneamente o informações anormais dos próprios dados, e é difícil conseguir alta precisão na previsão com base no conjunto de dados.

Existem duas soluções principais utilizadas para reduzir o impacto negativo de outliers no modelo, incluindo métodos de detecção de outliers e modelos de regressão [117]. Os métodos de detecção de outliers servem como método de pré-processamento para detectar e corrigir os outliers. Enquanto os modelos de regressão robustos não detectam ou tratam valores discrepantes diretamente, mas controlam a influência da anomalia através da função de perda ou distribuições de erro. Mais detalhes de modelos de regressão robustos para previsão de velocidade do vento podem ser encontrado nas Refs. [117-120]. Aqui nos concentramos nos métodos de pré-processamento de detecção de outliers. As publicações relacionadas à previsão de energia eólica são relativamente raras. No entanto, as etapas gerais dos métodos de processamento de detecção de valores discrepantes são consistentes. Eles alteram pontos específicos em séries de previsão de acordo com certas regras. A implementação processo inclui duas etapas: (a) detecção e (b) correção ou remoção.

5.3.1. Abordagens locais

As abordagens locais usam janela deslizante ou densidade local para detectar as anomalias dos pontos de dados. Esses tipos de métodos de detecção de valores discrepantes são sensíveis aos parâmetros dos modelos. Na Ref. [121], a coleta dados de vento foram divididos em seis categorias, ou seja, dados válidos, dados ausentes, dados constantes, dados excedentes, dados irracionais e não naturais. Os dados irracionais significavam ilógicos em física e os dados não naturais apresentavam baixa produção de energia eólica durante períodos de alta velocidade do vento. Essas duas categorias se desviaram muito dos padrões majoritários e foram considerados forasteiros. O algoritmo de fator de outlier local (LOF) e medição de similaridade foram usados para detectar e remover valores discrepantes, que identificam se o ponto é anormal comparando a densidade de cada ponto e seus pontos de vizinhança. Se a densidade de um ponto é menor, é mais provável que seja identificado como um ponto anormal. Numérico experimentos baseados nos dados coletados no noroeste da China verificados a eficácia do método de detecção de outlier proposto.

A detecção de outliers também foi usada na pós-processamento. O trem de pensamento é aliviar o fenômeno de over-fitting do preditor, com base em observações reais de séries de velocidade do vento. Mi et al. propôs um método de detecção de outliers com eficiência de tempo baseado em uma janela deslizante [63]. Os limites superior e inferior foram determinados com m valores observados para decidir se o valor previsto foi um outlier. Se o previsto valor fosse um outlier, ele seria corrigido como o valor médio de n observações. O método de pós-processamento de detecção de outlier proposto prevaleceu significativamente outros modelos, especialmente quando a previsão horizontes foram expandidos para cinco passos à frente.

5.3.2. Abordagens baseadas em regressão

Wang et al. propuseram dois métodos baseados em regressão para detecção de outliers e correção de séries de velocidade do vento [122,123]. Em [122], eles adotou o algoritmo dos mínimos quadrados ponderados (WLS) para determinar o valores atípicos. Se o resíduo estudantil da regressão $t_i > 1,96$, o observado valor no ponto i era visto como um outlier e seria corrigido pelo algoritmo de interpolação de spline cúbico. Outro método proposto é com base na regressão do vetor de suporte (SVR) [123]. Eles primeiro construíram o modelo SVR para prever a série original de velocidade do vento e em seguida, calculou-se a série residual. Se os resíduos da amostra $E_i > \sigma, 0 \leq i$




Fig. 12. Um banco de filtros empíricos de EWT no domínio de Fourier. Neste caso, são obtidos 28 filtros passa-faixa.

amostra foi considerada outlier e substituída pelo valor previsto.

Ambos os modelos propostos mostraram-se eficazes para a previsão diária da velocidade do vento.

5.4. Correção baseada em filtro

A filtragem é uma operação para filtrar a frequência de uma banda específica no sinal. É uma medida importante para suprimir e prevenir interferências. A suposição básica dos métodos de correção baseados em filtros é que a banda de frequência da série de previsão é consistente com a da série original. O segmento do espectro da série original é tomado como padrão para filtrar o erro, de modo a remover os componentes extras gerados pela previsão.

Filtro Wavelet (WF) tem sido utilizado para corrigir resultados de previsão de séries de velocidade do vento [62]. Os autores removeram o componente de frequência excessiva utilizando limiares apropriados para dispor os coeficientes wavelet, que apresentaram ótimo desempenho em resultados de previsão multietapas. Além disso, em vez de apenas resumir subséries de previsão como a maioria dos modelos baseados em decomposição geralmente fazem [31], alguns métodos inversos foram aplicados com sucesso, principalmente incluindo WT inverso (IWT) [88] e EWT inverso (IEWT) [52, 73]. As transformações inversas são realizadas de acordo com o banco de filtros, conforme mostrado na Fig. 12. Os resultados de previsão de subséries são transformados de volta no do main original, para obter a série reconstruída. Eles são considerados métodos para filtrar pontos anormais em séries de previsão, que foram relatados para evitar os valores de previsão inesperados e melhorar a estabilidade do modelo, bem como a precisão da previsão [73].

6. Discussão

Uma análise geral dos métodos de processamento de dados na previsão de energia eólica foi apresentada neste artigo. Eles são claramente classificados como decomposição, seleção de recursos, extração de recursos, eliminação de ruído, detecção de outlier e correção baseada em filtro. Como a atenção e a aplicação de cada método são diferentes, as frequências de uso também são diferentes, como mostra a Fig. 13. Aparentemente, a decomposição é o método de processamento de dados mais utilizado. Isso ocorre porque seu efeito na precisão da previsão é o mais óbvio. Alguns modelos que utilizam métodos de decomposição podem reduzir o erro de previsão em mais de 50% quando comparados com modelos sem algoritmos de decomposição [46,50]. No entanto, a correção baseada em filtros não ganha muita atenção como outros métodos. No entanto, provou-se trazer mais de 30% de melhoria na precisão da previsão [52]. Seu potencial na previsão de energia eólica, especialmente em modelos baseados em decomposição, pode ser

mais explorado. Nas sete categorias de métodos de processamento de dados, a literatura de detecção de outliers também não é relativamente extensa. Isso se deve principalmente à dificuldade em identificar se uma amostra é um ponto atípico ou normal. Confundir os dados normais como um outlier e realizar o processo de correção pode destruir a regularidade inerente da série de energia eólica, resultando em uma precisão de previsão ainda pior.

Para resolver essa preocupação, identificadores mais robustos para valores discrepantes podem ser desenvolvidos e experimentados no futuro.

A Tabela 7 fornece uma avaliação geral desses métodos a partir de seis aspectos diferentes, incluindo melhoria da precisão, frequência de uso, consumo de tempo, robustez aos parâmetros, maturidade e dificuldade de implementação. Vale ressaltar que, como os métodos de processamento de dados não são mutuamente exclusivos ou antagônicos, nenhum método é absolutamente superior aos demais. Na verdade, eles às vezes são combinados para construir modelos de previsão mais poderosos [64].

6.1. Possíveis tendências de desenvolvimento

Futuramente, modelos cada vez maiores baseados em dados serão propostos para previsão de energia eólica e os métodos de processamento de dados precisam de mais atenção, pois os dados históricos são sempre a base dos preditores. Existem alguns pontos de vista que podem ser direções futuras de pesquisa de métodos de processamento de dados na previsão de energia eólica. Eles estão listados a seguir:

6.1.1. Variáveis de entrada exógenas

A maioria dos trabalhos publicados adotou apenas a velocidade do vento histórica ou a série de potência para completar as tarefas de previsão. Eles podem ser referidos como




Fig. 13. As frequências de uso do processamento de dados em modelos de previsão de energia eólica: resultados derivados de 130 casos de aplicação.

Tabela 7

A avaliação do desempenho de métodos de processamento de dados na previsão de energia eólica.

Categoria	Melhoria de precisão	Frequência de uso	Consumindo tempo	Robustez aos parâmetros	Maturidade	Dificuldade de implementação
Decomposição	****	*****	*****	**	****	**
Seleção de recursos	***	****	***	**	***	**
Extração de recursos	**	**	**	***	***	**
Eliminar ruído	*	***	*	****	****	*
Modelagem de erros residuais	**	**	***	***	**	***
Deteção de valores discrepantes	***	*	*	*	*	***
Correção baseada em filtro	***	*	*	****	***	*

modelos sem variáveis exógenas. No entanto, a inclusão de algumas variáveis exógenas nos modelos de previsão pode melhorar a interpretabilidade. As condições meteorológicas são fatores importantes que podem causar vento. Alguns pesquisadores praticamente levaram isso em consideração e selecionou diferentes variáveis exógenas como entrada dos modelos de treinamento. No entanto, considerar as variáveis exógenas pode, por vezes, induzir a maldição da dimensionalidade. Portanto, alguns métodos de redução de dimensionalidade também são adotados. As variáveis de entrada selecionadas e métodos de redução de dimensionalidade em modelos de previsão de energia eólica estão listados na [Tabela 8](#) para referência. Com o desenvolvimento contínuo de aprendizado profundo, são necessários mais dados e conjuntos de recursos sobre energia eólica para melhorar ainda mais a precisão da previsão.

6.1.2. Aplicações de computação distribuída

Com a expansão dos conjuntos de dados, a computação paralela de grandes dados tem ganhado gradativamente a atenção. Algoritmos paralelos distribuídos razoáveis e eficientes tornaram-se um método importante para utilizar efetivamente o processador no ambiente distribuído e melhorar o desempenho do sistema distribuído. Recentemente, o Apache

A estrutura Spark foi empregada para prever séries temporais de big data, que demonstrou grande viabilidade e escalabilidade [127]. No entanto, tem nunca foi usado no campo da previsão de energia eólica. Mais relacionado algoritmos paralelos devem ser investigados. O Apache Spark é um possível aplicação para a computação distribuída de energia eólica previsão. É um mecanismo de computação rápido especialmente projetado para processamento de dados em grande escala. Ele aproveita ao máximo o clustering para computação e armazenamento de alta velocidade. Ao executar programas distribuídos em clusters, a eficiência computacional pode ser muito melhorada. o O Apache Spark é fácil de ser integrado a outros produtos de código aberto, como o Apache Mesos que pode ser usado diretamente como recurso gerenciamento. Além disso, os dados podem ser acessados a partir do armazenamento de dados sistema sem migração de dados, como o Hadoop Distributed File Sistema (HDFS). As aplicações da computação distribuída também se tendência de desenvolvimento futuro de big data.

Tabela 8

Os modelos de previsão de energia eólica com variáveis de entrada exógenas.

Referência	Variáveis	Redução de dimensionalidade
<i>Sem redução de dimensionalidade</i>		
Gallego [124]	Energia eólica, velocidade do vento, direção do vento	—
Camelo [125]	Velocidade do vento, pressão, temperatura, precipitação	—
De Giorgi [126]	Energia eólica, pressão, temperatura, umidade relativa	—
Lidia [23]	Velocidade do vento, direção do vento, radiação solar, temperatura	—
<i>Com redução de dimensionalidade</i>		
Azimi [85]	Energia eólica, direção do vento, temperatura do ar	Seleção de recursos: TSB K-means
Wang [32]	Velocidade do vento, temperatura, umidade, pressão atmosférica	Seleção de recursos: RF
Curvo [97]	Velocidade do vento, temperatura, umidade, direção do vento, pressão	Seleção profunda de recursos
Wang [84]	Energia eólica, direção do vento, temperatura, umidade, pressão	Seleção de recursos: K-means
Huang [90]	Velocidade do vento, temperatura, umidade relativa, umidade absoluta, pressão atmosférica, cisalhamento do vento	Seleção de recursos: CMI
Liu [86]	Velocidade do vento, temperatura, caracteres (máximo, mínimo, médio)	Extração de recursos: PCA
Sol [101]	Velocidade do vento, temperatura do ar, pressão do ar, umidade relativa	Seleção de recursos: SC
		Seleção de recursos: PSR
		Extração de recursos: KPCA
Salcedo-Sanz [91]	Direção do vento em 5 alturas diferentes, temperatura em 3 alturas diferentes, umidade, pressão ao nível do mar, onda longa para baixo radiação, radiação descendente de ondas curtas, precipitação, 8 combinações de funções de variáveis	Seleção de recursos: CRO

6.1.3. Aplicações de extração de recursos baseada em aprendizado profundo

A aprendizagem profunda é um método poderoso e tem sido bem sucedido aplicado em vários campos. Ele empilha várias camadas e utiliza uma camada mais profunda estrutura para melhorar a capacidade de aprendizagem dos modelos. Na energia eólica previsão, o aprendizado profundo tem sido usado para construir preditores em vários trabalhos de pesquisa [85]. No entanto, o recurso baseado em aprendizado profundo extração nunca foi desenvolvida para processar dados de vento, embora algumas aplicações podem ser encontradas em outros campos. Por exemplo, na Ref. [128], um autoencoder (AE) foi utilizado para realizar a extração de recursos de dados de energia solar. Em seu modelo proposto, as saídas do codificador foram consideradas como as características da energia solar, e outra profunda rede neural recorrente, ou seja, LSTM foi adotado para modelar a parte de codificação da EA. Mostrou grande superioridade na extração de recursos da energia solar.

Em comparação com as abordagens tradicionais de extração de recursos, técnicas de aprendizado podem extrair a representação oculta de dados devido a sua estrutura mais profunda e melhor capacidade. Isso tem um grande significado às aplicações de extração de recursos baseada em aprendizado profundo, especialmente para os modelos orientados a dados que exigem recursos úteis maciços de vento.

6.2. Desafios na aplicação de métodos de processamento de dados

Embora vários métodos de processamento de dados tenham sido amplamente empregados nos últimos anos, ainda existem alguns desafios que existem as aplicações atuais. Eles precisam ser notados e mais estudados.

6.2.1. Avaliar de forma adaptativa os resultados do pós-processamento

Nos métodos de pós-processamento, como modelagem de erro residual e detecção de outliers, é possível que ocorra a sobrecorreção dos dados. No entanto, as aplicações atuais raramente se preocupam com o racional avaliação dos resultados do processamento. Desta forma, a precisão nos testes dados podem ser piores, quando uma supercorreção da previsão preliminar resultado ocorre. Alguns critérios de avaliação ou métodos para correção de dados

os resultados podem ser desenvolvidos para garantir a eficácia dos algoritmos de pós-processamento.

6.2.2. Escolha diversos preditores para prever diferentes subséries

Os modelos híbridos baseados em decomposição geralmente adotam o mesmo preditor para prever todas as subséries. Eles negligenciam a diversidade de subséries com diferentes frequências. Como escolher de forma adaptativa o preditor ótimo para cada subsérie é um problema digno de estudo. Levando em consideração as características das subséries, os resultados de previsão correspondentes podem ser mais precisos. Do ponto de vista da interpretação do modelo, isso também pode ser um avanço na melhoria do desempenho mance.

6.2.3. Utilize totalmente o conjunto de dados original de alta

resolução O conjunto de dados original dos modelos orientados a dados existentes geralmente é uma série de alta resolução com uma taxa de amostragem de segundo nível, como 1 s [124], 3 s [62] e 5 s [14]. Para remover os dados redundantes e alcançar horizontes de previsão mais longos, geralmente é empregado um método simples para converter os dados originais em resultados de baixa resolução, ou seja, média. Pode ser considerado como um método de filtro capaz de remover flutuações rápidas [117]. No entanto, há um fato notável de que, ao processar os dados de alta resolução por média, informações úteis extensas também são perdidas. As abordagens para explorar e utilizar totalmente o conjunto de dados original de alta resolução devem ser analisadas.

7. Conclusões

Diante de problemas ambientais cada vez mais sérios, a velocidade do vento e a previsão da energia eólica são vitais para a gestão e utilização dos recursos de energia eólica. Os modelos de previsão baseados em dados existentes atribuem grande importância à aplicação adequada dos métodos de processamento de dados. Neste artigo, sete tipos de métodos de processamento de dados relatados na literatura foram resumidos, incluindo composição, seleção de recursos, extração de recursos, remoção de ruído, modelagem de erros residuais, detecção de outliers e correção baseada em filtros. As metodologias, funções, desempenho de cada tipo de método de processamento de dados foram exaustivamente investigados. Eles foram avaliados sob diferentes aspectos, incluindo melhoria de precisão, consumo de tempo e maturidade. Além disso, também foram apresentadas algumas possíveis tendências de desenvolvimento, perspectivas e desafios. Várias conclusões importantes podem ser extraídas da presente revisão:

- Nas sete categorias classificadas, a detecção de outliers e a correção baseada em filtros são relativamente menos utilizadas, representando apenas 3% e 2% dos métodos empregados, respectivamente. Mais atenção pode ser dada aos projetos adequados desses métodos de pós-processamento. Além disso, para garantir sua eficácia, os modelos devem tentar evitar a correção excessiva dos dados.
- Não existe um método absolutamente superior e é impraticável desenvolver apenas uma estratégia de processamento de dados para lidar com vários cenários de previsão. Por exemplo, modelos baseados em decomposição geralmente requerem mais tempo computacional por causa da estrutura específica.

Embora tenham se mostrado extremamente eficazes em melhorar a precisão da previsão, a eficiência de tempo do modelo é sacrificada. Portanto, eles não são adequados para tarefas preditivas com altos requisitos de tempo real. • Diferentes métodos de processamento de dados não são antagônicos entre si.

Alguns modelos híbridos incluem decomposição de dados e seleção de características ao mesmo tempo. Com o desenvolvimento de diferentes tipos de métodos, mais combinações possíveis deles podem ser propostas para melhorar ainda mais o desempenho do modelo.

Com o advento da era do big data, são necessárias investigações contínuas de tecnologias de processamento de dados para explorar melhor o potencial dos modelos híbridos orientados por dados e estabelecer uma boa base para melhorar ainda mais a precisão e a eficiência da previsão.

Reconhecimentos

Este estudo é totalmente apoiado pela Fundação Nacional de Ciências Naturais da China (Concessão No. 61873283), o Projeto de Ciência e Tecnologia de Changsha e Programa de Treinamento para Excelentes Jovens Inovadores de Changsha (Concessão No. KQ1707017), o Programa de Talentos Shenghua Yu-ying de a Central South University e o projeto de inovação da Central South University (Projeto No.

2019CX005).

Referências

- [1] Wang J, Shahidepour M, Li Z. Compromisso da unidade com restrições de segurança com geração de energia eólica volátil. *Lee T Power Syst* 2008;23(3):1319–27.
- [2] Jung J, Broadwater RP. Situação atual e avanços futuros para a velocidade do vento e previsão de energia. *Renovar Sustain Energy Rev* 2014;31:762–77.
- [3] Lawan S, Abidin W, Chai W, Baharun A, Masri T. Diferentes modelos de previsão da velocidade do vento; uma revisão abrangente. *Int J Sci Eng Res* 2014;5(1):1760–8.
- [4] Cheng WY, Liu Y, Bourgeois AJ, Wu Y, Haupt SE. Previsão de vento de curto prazo de um sistema de assimilação de dados/previsão do tempo com assimilação de medição de anemômetro de turbina eólica. *Energias Renováveis* 2017;107:340–51.
- [5] Pinson P. Energia eólica: desafios de previsão para sua gestão operacional. *Stat Sci* 2013;28(4):564–85.
- [6] Liu H, QG de Tian, Li YF. Comparação de dois novos métodos híbridos ARIMA-ANN e ARIMA-Kalman para previsão da velocidade do vento. *Appl Energy* 2012;98:415–24.
- [7] Akcay H, Filik T. Previsão de velocidade do vento de curto prazo por análise espectral de observações de longo prazo com valores ausentes. *Appl Energy* 2017;191:653–62.
- [8] Wang Y, Xie Z, Hu Q, Xiong S. Correlação ciente de vários passos à frente da previsão da velocidade do vento com aprendizagem multi-kernel heteroscedástica. *Energy Convers Manage* 2018;163:384–406.
- [9] Hui L, QG Tian, Li YF. Comparação dos novos híbridos FEEMD-MLP, FEEMD-ANFIS, Wavelet Packet-MLP e Wavelet Packet-ANFIS para previsões de velocidade do vento. *Energy Convers Manage* 2015;89:1–11.
- [10] Xiao L, Dong YX, Dong Y. Uma abordagem de combinação aprimorada baseada no algoritmo Adaboost para previsão de séries temporais de velocidade do vento. *Energy Convers Manage* 2018;160:273–88.
- [11] Yu C, Li Y, Bao Y, Tang H, Zhai G. Uma nova estrutura para previsão de velocidade do vento com base em redes neurais recorrentes e máquina de vetor de suporte. *Energy Convers Manage* 2018;178:137–45.
- [12] Wang HZ, Li GQ, Wang GB, Peng JC, Jiang H, Liu YT. Abordagem de conjunto baseada em aprendizado profundo para previsão probabilística de energia eólica. *Appl Energy* 2017;188:56–70.
- [13] Chitsazan MA, Fadal MS, Trzynadlowski AM. Previsão de velocidade e direção do vento usando rede de estados de eco com funções não lineares. *Renovar Energia* 2019;131:879–89.
- [14] Hu Q, Zhang R, Zhou Y. Transferência de aprendizado para previsão de velocidade do vento de curto prazo com redes neurais profundas. *Renovar Energia* 2016;85:83–95.
- [15] Cheng WY, Liu Y, Liu Y, Zhang Y, Mahoney WP, Warner TT. O impacto da física do modelo nas previsões numéricas de vento. *Renovar Energia* 2013;55:347–56.
- [16] Hu YL, Chen L. Um modelo híbrido não linear de previsão de velocidade do vento usando rede LSTM, ELM histerético e algoritmo de Evolução Diferencial. *Energy Convers Manage* 2018;173:123–42.
- [17] Song JJ, Wang JZ, Lu HY. Um novo modelo combinado baseado em algoritmo avançado de otimização para previsão de velocidade do vento de curto prazo. *Appl Energy* 2018;215:643–58.
- [18] Li C, Lin S, Xu F, Liu D, Liu J. Previsão de energia eólica de curto prazo com base em tecnologia de mineração de dados e método de máquina vetorial de suporte aprimorado: Um estudo de caso no noroeste da China. *J Cleaner Prod* 2018;205:909–22.
- [19] Wang JZ, Du P, Niu T, Yang WD. Um novo sistema híbrido baseado em um novo algoritmo proposto - Algoritmo de Otimização de Baleias Multiobjetivo para previsão de velocidade do vento. *Appl Energy* 2017;208:344–60.
- [20] Jiang P, Yang H, Heng J. Um sistema de previsão híbrido baseado em séries temporais difusas e otimização multiobjetivo para previsão da velocidade do vento. *Appl Energy* 2019;235:786–801.
- [21] Hao Y, Tian C. Um novo modelo de previsão de dois estágios baseado em fator de erro e método de conjunto para previsão de energia eólica em várias etapas. *Appl Energy* 2019;238:368–83.
- [22] Liu H, Duan Z, Li Y, Lu H. Um novo modelo de conjunto de diferentes ondas-mãe para previsão de várias etapas da velocidade do vento. *Appl Energy* 2018;228:1783–800.
- [23] Lydia M, Kumar SS, Selvakumar AI, Kumar GEP. Auto linear e não linear modelos regressivos para previsão de velocidade do vento de curto prazo. *Energy Convers Manage* 2016;112:115–24.
- [24] Yan J, Liu Y, Han S, Wang Y, Feng S. Comentários sobre a análise de incerteza da previsão de energia eólica. *Renovar Sustain Energy Rev* 2015;52:1322–30.
- [25] Okumus I, Dinler A. Situação atual da previsão de energia eólica e um método híbrido para previsões horárias. *Energy Convers Manage* 2016;123:362–71.
- [26] Marugán AP, Márquez FPG, Perez JMP, Ruiz-Hernández D. Um levantamento da rede neural artificial em sistemas de energia eólica. *Appl Energy* 2018;228:1822–36.
- [27] Wang J, Song Y, Liu F, Hou R. Análise e aplicação de modelos de previsão na integração de energia eólica: Uma revisão de modelos de previsão de velocidade do vento multi-passo à frente. *Renovar Sustain Energy Rev* 2016;60:960–81.
- [28] Shi J, Guo J, Zheng S. Avaliação de abordagens de previsão híbrida para velocidade do vento

e séries temporais de geração de energia. *Renovar Sustain Energy Rev* 2012;16(5):3471–80.

[29] Tascikaraoglu A, Uzunoglu M. Uma revisão de abordagens combinadas para previsão de velocidade e potência do vento a curto prazo. *Renovar Sustentat Energia Rev* 2014;34(6):243–54.

[30] Zendejboudi A, Baseer M, Saidur R. Aplicação de modelos de máquinas vetoriais de suporte para previsão de recursos de energia solar e eólica: uma revisão. *J Cleaner Prod* 2018;199:272–85.

[31] Qian Z, Pei Y, Zareipour H, Chen N. Uma revisão e discussão de modelos híbridos baseados em decomposição para aplicações de previsão de energia eólica. *Appl Energy* 2019;235:939–53.

[32] Wang H, Sun JX, Sun JB, Wang JL. Usando florestas aleatórias para selecionar variáveis de entrada ideais para modelos de previsão de velocidade do vento de curto prazo. *Energias* 2017;10(10):1522.

[33] Li FD, Liao HY. Um método inteligente de previsão de energia eólica baseado em previsão de eventos de inclinação de potência integrada e previsão de velocidade do vento. *Ieej T Electr Electr* 2018;13(8):1099–105.

[34] Sun SZ, Fu JQ, Zhu F. Um método de previsão de velocidade do vento de curto prazo usando decomposição de sinal e máquina de aprendizado extremo. *Comm Com Inf Sc* 2017;763:22–31.

[35] Huang NE, Shen Z, Long SR, Wu MC, Shih HH, Zheng Q, et al. A decomposição de modo empírico e o espectro de Hilbert para análise de séries temporais não lineares e não estacionárias. *Proc Roy Soc London Ser A: Math, Phys Eng Sci* 1998;454(1971):903–95.

[36] Wang J, Zhang W, Li Y, Wang J, Dang Z. Previsão da velocidade do vento usando a decomposição de modo empírico e a rede neural Elman. *Appl Soft Comput* 2014;23:452–9.

[37] Zheng WQ, Peng XG, Lu D, Zhang D, Liu Y, Lin ZH, et al. **Máquina de aprendizado extremo de regressão** quantílica composta com seleção de recursos para previsão de velocidade do vento de curto prazo : uma nova abordagem. *Energy Convers Manage* 2017;151:737–52.

[38] Huang YS, Liu SJ, Yang L. Método de previsão da velocidade do vento usando EEMD e o método de previsão combinado baseado em GPR e LSTM. *Sustainab-Basileia* 2018;10(10):3693.

[39] Yang ZS, Wang J. Uma abordagem de previsão combinada aplicada na previsão de velocidade do vento em várias etapas com base em uma estratégia de processamento de dados e um algoritmo de inteligência artificial otimizado. *Appl Energy* 2018;230:1108–25.

[40] Zhang WY, Qu ZX, Zhang KQ, Mao WQ, Ma YN, Fan X. Um modelo combinado baseado em CEEMDAN e algoritmo de polinização de flores modificado para previsão de velocidade do vento . *Energy Convers Manage* 2017;136:439–51.

[41] Li X, Li C. Modelagem CEEMDAN e PSO-SVR aprimorada para não infravermelho próximo detecção invasiva de glicose. *Métodos matemáticos de computação Med* 2016;2016.

[42] Colominas MA, Schlotthauer G, Torres ME. EMD de conjunto completo aprimorado: Uma ferramenta adequada para processamento de sinais biomédicos. *Controle de Processo de Sinal Biomédico* 2014;14:19–29.

[43] Wang L, Li X, Bai Y. Previsão de velocidade do vento de curto prazo usando um modelo de máquina de aprendizado extremo com correção de erros. *Energy Convers Manage* 2018;162:239–50.

[44] Dragomirskiy K, Zosso D. Decomposição em modo variacional. *Sinal de Transmissão IEEE Processo* 2014;62(3):531–44.

[45] Zhou JZ, Liu H, Xu YH, Jiang W. Uma estrutura híbrida para previsão de velocidade do vento em várias etapas de curto prazo com base na decomposição do modelo variacional e rede neural convolucional. *Energias* 2018;11(9):2292.

[46] Zhou JZ, Sun N, Jia BJ, Peng T. Um novo modelo de otimização de decomposição para previsão de velocidade do vento a curto prazo. *Energias* 2018;11(7):1752.

[47] Li CS, Xiao ZG, Xia X, Zou W, Zhang C. Um modelo híbrido baseado em otimização síncrona para previsão de velocidade do vento de curto prazo em várias etapas. *Appl Energy* 2018;215:131–44.

[48] Wang DY, Luo HY, Grunder O, Lin YB. Previsão de velocidade do vento em vários passos usando uma rede neural wavelet aprimorada combinando posição de decomposição de modo variacional e reconstrução de espaço de fase. *Renovar Energia* 2017;113:1345–58.

[49] Wang XD, Yu QB, Yang Y. Previsão de velocidade do vento de curto prazo usando decomposição de modo variacional e regressão vetorial de suporte. *J Intell Fuzzy Syst* 2018;34(6):3811–20.

[50] Zhang C, Zhou JZ, Li CS, Fu WL, Peng T. Uma estrutura composta de ELM baseada na seleção de recursos e otimização de parâmetros usando algoritmo de busca de retrocesso híbrido para previsão de velocidade do vento. *Energy Convers Manage* 2017;143:360–76.

[51] Gilles J. Transformada wavelet empírica. *Processo IEEE Trans Signal* 2013;61(16):3999–4010.

[52] Li YF, Wu HP, Liu H. Previsão da velocidade do vento em várias etapas usando decomposição EWT, computação principal LSTM, computação subordinada RELM e reconstrução IEWT . *Energy Convers Manage* 2018;167:203–19.

[53] Liu H, Mi XW, Li YF. Método de previsão de velocidade do vento baseado em aprendizado profundo estratégia usando transformada wavelet empírica, rede neural de memória de longo prazo e rede neural de Elman. *Energy Convers Manage* 2018;156:498–514.

[54] Liu H, Tian HQ, Liang XF, Li YF. Abordagem de previsão da velocidade do vento usando algoritmo de decomposição secundária e redes neurais de Elman. *Appl Energy* 2015;157:183–94.

[55] Liu H, Mi X, Li Y. Uma investigação experimental de três novos modelos híbridos de previsão de velocidade do vento usando estratégia de decomposição múltipla e algoritmo ELM. *Renovar Energia* 2018;123:694–705.

[56] Yin H, Dong Z, Chen Y, Ge J, Lai LL, Vaccaro A, et al. Um secundário eficaz abordagem de decomposição para previsão de energia eólica usando máquina de aprendizado extremo treinada por otimização cruzada. *Energy Convers Manage* 2017;150:108–21.

[57] Peng T, Zhou JZ, Zhang C, Zheng Y. Previsão de velocidade do vento em vários passos à frente usando um modelo híbrido baseado na técnica de decomposição de dois estágios e máquina de aprendizado extremo AdaBoost-ex . *Energy Convers Manage* 2017;153:589–602.

[58] Yu CJ, Li YL, Zhang MJ. Uma transformada wavelet aprimorada usando análise de espectro singular para previsão de velocidade do vento com base na rede neural Elman. *Energia*

Converse Manage 2017;148:895–904.

[59] Wang J, Wang Y, Li Y. Uma nova estratégia híbrida usando extração de recursos trifásicos e uma máquina de aprendizado extremo regularizada ponderada para previsão de velocidade do vento em vários passos à frente. *Energias* 2018;11(2):321.

[60] Zhang D, Peng X, Pan K, Liu Y. Uma nova previsão de velocidade do vento baseada em decomposição híbrida e máquina de aprendizado extremo robusto de outlier sequencial online. *Energy Convers Manage* 2019;180:338–57.

[61] Tian C, Hao Y, Hu J. Um novo sistema de previsão da velocidade do vento baseado em pré-processamento de dados híbridos e otimização multi-objetivo. *Appl Energy* 2018;231:301–19.

[62] Liu H, Duan Z, Han FZ, Li YF. Grande modelo de previsão de velocidade do vento em várias etapas baseado em decomposição secundária, método de conjunto e algoritmo de correção de erros. *Energy Convers Manage* 2018;156:525–41.

[63] Mi XW, Liu H, Li YF. Método de previsão de velocidade do vento usando wavelet, máquina de aprendizado extremo e algoritmo de correção de outlier. *Energy Convers Manage* 2017;151:709–22.

[64] Jiang Y, Huang G, Peng X, Li Y, Yang Q. Um novo método de previsão da velocidade do vento: Híbrido de DWT auxiliado por correlação, LSSVM e GARCH. *J Wind Eng Ind Aerod* 2018;174:28–38.

[65] Liu H, Mi X, Li Y. Modelo de previsão de velocidade do vento baseado em aprendizado profundo inteligente usando decomposição de pacotes wavelet, rede neural convolucional e rede de memória de longo prazo convolucional. *Energy Convers Manage* 2018;166:120–31.

[66] Niu DX, Liang Y, Hong WC. Previsão de velocidade do vento baseada em EMD e GRNN otimizada por FOA. *Energias* 2017;10(12):2001.

[67] Bokde N, Feijoo A, Kulat K. Análise de diferenciação e pré-decomposição métodos de processamento para a previsão da velocidade do vento. *Appl Soft Comput* 2018;71:926–38.

[68] Sun W, Wang YW. Previsão de velocidade do vento de curto prazo com base em conjunto rápido decomposição de modo empírico, reconstrução de espaço de fase, entropia de amostra e rede neural de retropropagação melhorada. *Energy Convers Manage* 2018;157:1–12.

[69] Du P, Wang JZ, Guo ZH, Yang WD. Pesquisa e aplicação de um novo sistema de previsão híbrido baseado em otimização multiobjetivo para previsão de velocidade do vento . *Energy Convers Manage* 2017;150:90–107.

[70] Du P, Wang J, Yang W, Niu T. Um novo modelo híbrido para energia eólica de curto prazo previsão. *Appl Soft Comput* 2019;80:93–106.

[71] Yang W, Wang J, Lu H, Niu T, Du P. Sistema híbrido de previsão e análise de energia eólica baseado no esquema de dividir e conquistar: um estudo de caso na China. *J Cleaner Prod* 2019;222:942–59.

[72] Li R, Jin Y. Um sistema de previsão de intervalo de velocidade do vento baseado em otimização multiobjetivo para o método de aprendizado de máquina. *Appl Energy* 2018;228:2207–20.

[73] Liu H, Wu HP, Li YF. Previsão inteligente da velocidade do vento usando a decomposição EWT, Otimização evolutiva GWO, aprendizado RELM e reconstrução IEWT. *Energy Convers Manage* 2018;161:266–83.

[74] Liu H, Mi XW, Li YF. Comparação de duas novas abordagens inteligentes de previsão de velocidade do vento baseadas em Decomposição de Pacotes Wavelet, Decomposição em Modo Empírico de Ensemble Completo com Ruído Adaptativo e Redes Neurais Artificiais. *Energy Convers Manage* 2018;155:188–200.

[75] Wang JZ, Yang WD, Du P, Niu T. Um novo sistema híbrido de previsão da velocidade do vento baseado em um algoritmo de seno cosseno multi-objetivo recém-desenvolvido. *Energy Convers Manage* 2018;163:134–50.

[76] Yu CJ, Li YL, Zhang MJ. Estudo comparativo de três novos modelos híbridos usando **as tecnologias** Elman Neural Network e Empirical Mode Decomposition, aprimoradas pela Análise de Espectro Singular para previsão de velocidade do vento com uma hora de antecedência. *Energy Convers Manage* 2017;147:75–85.

[77] Liu H, Mi XW, Li YF. Modelo inteligente de aprendizado profundo em várias etapas para previsão de velocidade do vento com base na decomposição de modo variacional, análise de espectro singular, rede LSTM e ELM. *Energy Convers Manage* 2018;159:54–64.

[78] Capa TM. As duas melhores medições independentes não são as duas melhores. *IEEE Trans Syst, Man, Cybernet* 1974; 1:116-7.

[79] Abedinia O, Amjadi N, Zareipour H. Uma nova técnica de seleção de recursos para previsão de carga e preço de sistemas elétricos de potência. *Iee T Power Syst* 2017;32(1):62–74.

[80] Peng H, Long F, Ding C. Seleção de recursos com base em critérios de informação mútua de dependência máxima, relevância máxima e redundância mínima. *IEEE Trans Pattern Anal Mach Intell* 2005;27(8):1226–38.

[81] Liu D, Niu D, Wang H, Fan L. Previsão de velocidade do vento de curto prazo usando transformada wavelet e máquinas de vetor de suporte otimizadas por algoritmo genético. *Renovar Energia* 2014;62:592–7.

[82] Jiang P, Wang Y, Wang JZ. Previsão da velocidade do vento a curto prazo usando um modelo híbrido. *Energia* 2017;119:561–77.

[83] Yu CJ, Li YL, Xiang HY, Zhang MJ. **Previsão de** velocidade do vento de curto prazo assistida por mineração de dados por decomposição de pacotes wavelet e rede neural Elman. *J Wind Eng Ind Aerod* 2018;175:136–43.

[84] Wang K, Qi X, Liu H, Song J. Abordagem de cluster k-means baseada em rede de crença profunda para previsão de energia eólica de curto prazo. *Energia* 2018;165:840–52.

[85] Azimi R, Ghofrani M, Ghayekhloo M. Um modelo híbrido de previsão de energia eólica baseado em mineração de dados e análise de wavelets. *Energy Convers Manage* 2016;127:208–25.

[86] Liu D, Wang J, Wang H. Previsão de velocidade do vento de curto prazo com base em clustering e redes otimizadas de estado de eco. *Renovar Energia* 2015;78:599–608.

[87] He QQ, Wang JZ, Lu HY. Um sistema híbrido para previsão de velocidade do vento de curto prazo. *Appl Energy* 2018;226:756–71.

[88] Osório G, Matias J, Catalão J. Previsão de energia eólica de curto prazo usando sistema de inferência neuro-fuzzy adaptativo combinado com otimização evolutiva de enxame de partículas , transformada wavelet e informação mútua. *Renovar Energia* 2015;75:301–7.

[89] Li S, Wang P, Goel L. Previsão de energia eólica usando conjuntos de redes neurais com

seleção de recursos. IEEE Trans Sustain Energy 2015;6(4):1447–56.

[90] Huang NT, Xing EK, Cai GW, Yu ZY, Qi B, Lin L. Previsão de velocidade do vento de curto prazo com base na seleção de recursos de baixa redundância. Energias 2018;11(7):1638.

[91] Salcedo-Sanz S, Pastor-Sánchez A, Prieto L, Blanco-Aguilera A, García-Herrera R. **Seleção de recursos em sistemas de previsão de velocidade do vento com base em uma abordagem de máquina de aprendizado extremo de otimização de recifes de coral híbridos**. Energy Convers Manage 2014;87:10–8.

[92] Jursa R. Seleção de variáveis para previsão de energia eólica usando otimização de enxame de partículas . Anais da 9ª Conferência Anual de Computação Genética e Evolutiva. 2017. pág. 2059-65.

[93] Gupta R, Kumar R, Bansal AK. Seleção de variáveis de entrada para a previsão da velocidade do vento em parques eólicos com base em algoritmo genético. Wind Eng 2011;35(6):649–60.

[94] Jursa R, Rohrig K. Previsão de energia eólica de curto prazo usando algoritmos evolutivos para a especificação automatizada de modelos de inteligência artificial. Int J Previsão 2008;24(4):694–709.

[95] Takens F. Detectando atratores estranhos em turbulência. Sistemas dinâmicos e tur bulência, Warwick 1980. Springer; 1981. pág. 366-81.

[96] Wang JZ, Wang Y, Jiang P. O estudo e aplicação de um novo modelo de previsão de previsão de velocidade do vento na China. Appl Energy 2015;143:472–88.

[97] Cong F, Cui M, Hodge BM, Jie Z. Uma metodologia multimodelo orientada por dados com seleção profunda de recursos para previsão de vento de curto prazo. Appl Energy 2017;190:1245–57.

[98] Wang J, Li Y. Previsão da velocidade do vento com vários passos à frente com base no recurso ideal extração, rede neural de memória de longo prazo e estratégia de correção de erros. Appl Energy 2018;230:429–43.

[99] Hu J, Heng J, Tang J, Guo M. Pesquisa e aplicação de um modelo híbrido baseado na estratégia de meta-aprendizagem para previsão determinística e probabilística de energia eólica. Energy Convers Manage 2018;173:197–209.

[100] Liu T, Wei H, Zhang K. Previsão de energia eólica com dados ausentes usando regressão de processo gaussiana e imputação múltipla. Appl Soft Comput 2018;71:905–16.

[101] Sun SL, Qiao H, Wei YJ, Wang SY. Uma nova abordagem integrada dinâmica para a previsão da velocidade do vento. Appl Energy 2017;197:151–62.

[102] Davò F, Alessandrini S, Sperati S, Delle Monache L, Airolidi D, Vespucci MT. **Técnicas de pós- processamento e análise de componentes principais para previsão regional de energia eólica e irradiância solar**. Sol Energy 2016; 134: 327–38.

[103] Kong X, Liu X, Shi R, Lee KY. Previsão da velocidade do vento usando vetor de suporte reduzido máquinas com seleção de recursos. Neurocomputing 2015;169:449–56.

[104] Hu Q, Su P, Yu D, Liu J. Previsão de velocidade do vento baseada em padrões com base em generalizado análise do componente principal. Ieee T Sustain Energ 2014;5(3):866–74.

[105] Xiao LY, Qian F, Shao W. Previsão de velocidade do vento em várias etapas com base em um híbrido arquitetura de previsão e um algoritmo de morcego aprimorado. Energy Convers Manage 2017;143:410–30.

[106] Ma XJ, Jin Y, Dong QL. Uma rede neural difusa dinâmica generalizada baseada em análise de espectro singular otimizada pela otimização de tempestade cerebral para previsão de velocidade do vento de curto prazo. Appl Soft Comput 2017;54:296–312.

[107] Guo Z, Zhao W, Lu H, Wang J. Previsão em várias etapas para a velocidade do vento usando um modelo de rede neural artificial baseado em EMD modificado. Renovar Energia 2012;37(1):241–9.

[108] Niu X, Wang J. Um modelo combinado baseado em estratégia de pré-processamento de dados e algoritmo de otimização multiobjetivo para previsão de velocidade do vento de curto prazo. Appl Energy 2019;241:519–39.

[109] Hu J, Wang J, Ma K. Uma técnica híbrida para previsão da velocidade do vento a curto prazo. Energia 2015;81:563–74.

[110] Santhosh M, Venkaiah C, Kumar DV. Decomposição do modo empírico do conjunto baseado no método de rede neural wavelet adaptável para a previsão da velocidade do vento. Energy Convers Manage 2018;168:482–93.

[111] Zhang KQ, Qu ZX, Wang JZ, Zhang WY, Yang FY. Uma nova abordagem híbrida baseada no algoritmo de otimização de busca de cuco para previsão de velocidade do vento a curto prazo. Environ Prog Sustain 2017;36(3):943–52.

[112] Hu J, Wang J, Zeng G. Uma abordagem de previsão híbrida aplicada a séries temporais de velocidade do vento. Renovar Energia 2013;60:185–94.

[113] Cheng L, Zang H, Ding T, Sun R, Wang M, Wei Z, et al. Conjunto neural recorrente abordagem probabilística de previsão da velocidade do vento baseada em rede. Energias 2018;11(8):1958.

[114] Han QK, Meng FM, Hu T, Chu FL. Modelos híbridos não paramétricos para previsão da velocidade do vento. Energy Convers Manage 2017;148:554–68.

[115] Liang Z, Liang J, Wang C, Dong X, Miao X. Previsão combinada de energia eólica de curto prazo com base na correção de previsão de erro. Energy Convers Manage 2016;119:215–26.

[116] Wang Y, Wang J, Wei X. Um modelo híbrido de previsão da velocidade do vento baseado na teoria da reconstrução do espaço de fase e no modelo de Markov: Um estudo de caso de parques eólicos no noroeste da China. Energia 2015;91:556–72.

[117] Wang Y, Wang HB, Srinivasan D, Hu QH. Regressão funcional robusta para vento previsão de velocidade com base na aprendizagem esparsa bayesiana. Renovar Energia 2019;132:43–60.

[118] Hu Q, Zhang S, Xie Z, Mi J, Wan J. Modelo de ruído baseado em regressão vetorial de suporte y com sua aplicação à previsão de velocidade do vento de curto prazo. Redes Neurais 2014;57:1–11.

[119] Zhang S, Hu Q, Xie Z, Mi J. Regressão de cume do kernel para modelo de ruído geral com sua aplicação. Neurocomputing 2015;149:836–46.

[120] Zuluaga CD, Alvarez MA, Giraldo E. Previsão de velocidade do vento de curto prazo com base em filtragem robusta de Kalman: Uma comparação experimental. Appl Energy 2015;156:321–30.

[121] Zheng L, Hu W, Min Y. Pré-processamento de dados de vento bruto: uma abordagem de mineração de dados. Ieee T Sustain Energ 2015;6(1):11–9.

[122] Wang J, Xiong S. Um modelo de previsão híbrido baseado na detecção de valores discrepantes e séries temporais difusas – um estudo de caso no parque eólico de Hainan na China. Energia 2014;76:526–41.

[123] Wang J, Qin S, Zhou Q, Jiang H. Previsão de velocidade do vento a médio prazo utilizando modelos híbridos para três locais diferentes em Xinjiang, China. Renovar Energia 2015;76:91–101.

[124] Gallego C, Pinson P, Madsen H, Costa A, Cuerva A. Influência da velocidade e direção do vento local na dinâmica da energia eólica – Aplicação à previsão offshore de muito curto prazo . Appl Energy 2011;88(11):4087–96.

[125] Camelo HD, Lúcio PS, Leal JBV, Carvalho PCM. Um modelo híbrido baseado em modelos de séries temporais e rede neural para previsão da velocidade do vento na região nordeste do Brasil. Sustain Energy Techn 2018;28:65–72.

[126] De Giorgi MG, Ficarella A, Tarantino M. Avaliação dos benefícios da previsão numérica do tempo na previsão de energia eólica com base em métodos estatísticos. Energia 2011;36(7):3968–78.

[127] Galicia A, Torres J, Martínez-Álvarez F, Troncoso A. Um novo algoritmo de previsão multi-passo baseado em Spark para séries temporais de big data. Inf Sci 2018;467:800–18.

[128] Gensler A, Henze J, Sick B, Raabe N. Deep Learning para energia solar previsão—Uma abordagem usando AutoEncoder e LSTM Neural Networks. 2016 IEEE International Conference on Systems, Man, and Cybernetics (SMC). 2016. pág. 002858-65.