

Listas de conteúdo disponíveis em [ScienceDirect](#)

Diário de Computação Suave Aplicada

página inicial da revista: www.elsevier.com/locate/asoc

Artigo de revisão

Estratégias de modelagem inteligente para previsão de séries temporais de qualidade do ar: A Reveja

Hui Liu[∗], Guangxi Yan, Zhu Duan, Chao Chen

Instituto de Inteligência Artificial e Robótica (IAIR), Laboratório Chave de Segurança no Trânsito na Trilha do Ministério da Educação, Escola de Trânsito e Engenharia de Transportes, Central South University, Changsha 410075, China

informações do artigo

Historia do artigo:

Recebido em 27 de abril de 2020

Recebido em formulário revisado em 25 de setembro de 2020

Aceito em 27 de novembro de 2020

Disponível on-line em 20 de janeiro de 2021

Palavras-chave:

Previsão da qualidade do ar

Preditores inteligentes

Estratégias de modelagem híbrida

resumo

Nos últimos anos, a deterioração da qualidade do ar, os frequentes eventos dos contaminantes do ar e os impactos na saúde disso têm causado atenção contínua por parte do governo e do público. Com base nisso, ferramentas de previsão adequadas e eficazes são urgentemente necessárias na pesquisa científica. Dentro Neste estudo, os algoritmos básicos de previsão são apresentados como os modelos de previsão simples com seus antecedentes, aplicações, vantagens e limitações, que incluem preditores superficiais e profundos preditores de aprendizado. Então, para melhorar a capacidade de previsão, os métodos de processamento de dados e dois métodos auxiliares comumente usados (o aprendizado em conjunto e a otimização metaheurística) no modelos híbridos foram revisados. Os artigos recentes dos aspectos espaço-temporais também trouxeram mudanças tanto na análise quanto nos métodos de modelagem. Além disso, os modelos representativos são resumidos para apresentar as estruturas de modelos preditivos eficientes. Algumas direções de pesquisa possíveis da previsão da poluição do ar são dadas no final. Esta revisão tem como objetivo fornecer uma resumo da literatura das estratégias de modelagem inteligente na previsão da qualidade do ar, que podem ser útil para estudos posteriores.

© 2021 Elsevier BV Todos os direitos reservados.

Conteúdo

1. Introdução.....	2
1.1. Os principais poluentes	2
1.2. A pesquisa atual de modelos de previsão da qualidade do ar 2	
1.3. A motivação da revisão 4	
1.4. Organização e os índices de avaliação 5	
1.5. Busca de literatura e estratégia de seleção	5
2. Preditores inteligentes eficazes	5
2.1. Preditores inteligentes rasos	6
2.1.1. Rede neural artificial 2.1.2.	6
Máquina de vetores de suporte 2.1.3.	7
Modelo de lógica fuzzy 2.1.4. Máquina	8
de aprendizado extremo 2.2. Preditores de	8
aprendizado profundo	8
2.2.1. Rede de crença profunda 8	
2.2.2. Rede neural convolucional 9	
2.2.3. Rede neural recorrente 9	
2.3. Epílogo.....	9
3. Processamento de dados para estratégias de modelagem	11
3.1. Extração de recursos	11
3.2. Decomposição de dados	11
3.2.1. Decomposição Wavelet	11
3.2.2. Decomposição EMD	13

[∗] Correspondência para: Instituto de Inteligência Artificial e Robótica (IAIR), Laboratório Chave de Segurança no Trânsito na Trilha do Ministério da Educação, Escola de Trânsito e Engenharia de Transportes, Central South University, Changsha 410075, Hunan, China.

E-mail: csulihui@csu.edu.cn (H. Liu).

3.2.3. Outra decomposição simples	14	
3.2.4. Decomposição híbrida		14
4. Método auxiliar I: Otimização metaheurística		15
4.1. Algoritmos heurísticos e metaheurísticos	4.2.	15
Classificação por objetos otimizados		15
4.2.1. Métodos de otimização de pesos de combinação		15
4.2.2. Métodos de otimização de parâmetros em preditores		16
5. Método auxiliar II: Aprendizagem em conjunto	17	
5.1. Ensacamento		17
5.2. Impulsionando	17	
5.3. Empilhamento		17
6. Análise espaço-temporal para estratégias de modelagem.....	18	
6.1. Análise de dados múltiplos		18
6.2. Modelos individuais melhorados	19	
6.3. Modelos híbridos espaço-temporais 20		
7. Discussão e recomendações para trabalhos futuros	20	
7.1. A estrutura representativa de modelos preditivos e análise comparativa	20	
7.2. Possíveis tendências e desafios de desenvolvimento futuro	21	
7.2.1. Escolha os preditores adequados para a previsão de subséries	21	
7.2.2. A aplicação da IoT na Cidade Inteligente	22	
7.2.3. Os desafios da coleta de dados	22	
7.2.4. Aplicações da computação distribuída	22	
8. Conclusões.....	22	
Declaração de interesse concorrente	23	
Agradecimentos	23	
Referências 23.....		

1. Introdução

Com o rápido progresso da indústria moderna e do tráfego, a inflação explosiva da população, e o processo de urbanização, a poluição do ar tornou-se um problema global [1,2]. Vários ar poluentes agravarão o meio ambiente e causarão graves desastres ambientais como o efeito estufa, o buraco na camada de ozônio, e smog fotoquímico [3], levando a um aumento em todo o mundo riscos para a saúde e cargas de doenças, como o sistema respiratório humano doenças crônicas, doenças cardiovasculares, ou mesmo câncer [4,5]. Além disso, a neblina da poluição do ar tem um forte impacto sobre o desenvolvimento econômico [6] em todo o mundo e políticas, como à medida que o PIB diminui nos países em desenvolvimento [7], o consumo de energia e a estrutura energética [8], e a carga de bem-estar social em países desenvolvidos [9]. A poluição do ar é um processo gradual e pode levar a consequências catastróficas sem um controle efetivo. Portanto, reduzir a poluição do ar pode ser uma medida eficaz para controlar as doenças acima e beneficiar a sociedade [10].

1.1. Os principais poluentes

Os principais poluentes incluem SO₂, TSP (poeira, PM₁₀, PM_{2.5}), NO_x, CO, O₃, que são uma mistura de partículas e gases e passam a ser um problema crescente [11,12]. As partículas (PM) não são um único tipo de partículas, mas uma mistura de pequenas partículas no atmosfera, o que leva à deterioração da qualidade do ar e da ocorrência frequente de clima de neblina. As pesquisas comprovaram que o Partículas de 10µm de diâmetro podem atingir o trato respiratório superior e as partículas abaixo de 5µm de diâmetro podem entrar no fundo parte dos brônquios [13]. Além disso, as partículas sob 1µm pode até penetrar nos alvéolos [13]. O dióxido de enxofre (SO₂) é concentrada por erupções vulcânicas e desenvolvimento industrial. Combustíveis fósseis, como carvão e petróleo, contêm enxofre. O enxofre O dióxido de carbono pode ser formado durante o consumo de energia fóssil. O SO₂ na atmosfera também pode fazer com que as chuvas ácidas prejudiquem o meio ambiente. E o SO₂ também tem grandes efeitos no aumento a taxa de doenças respiratórias [14].

A maior parte das emissões de NO₂ são provenientes da combustão de combustíveis fósseis combustíveis na indústria e veículos [3]. O NO₂ também é considerado um dos

as principais causas das chuvas ácidas e também desempenha um papel importante papel na forma de ozônio [15]. Além disso, o NO₂ tem efeitos negativos sobre a saúde humana e os ecossistemas, levando a uma alta incidência de doenças pulmonares. Devido às fortes propriedades oxidantes, o ozônio é um tipo de gás nocivo e pode até prejudicar a saúde humana em nível do solo. Por alta concentração, é fácil causar lesões no trato respiratório superior e irritação da pele, olhos e nariz [16]. Uma alta concentração de O₃ tem uma influência negativa nos rendimentos das culturas alimentares e a perda de culturas pode ser maior no futuro [17].

1.2. A pesquisa atual de modelos de previsão da qualidade do ar

A previsão da qualidade do ar pode fornecer dados efetivos da qualidade ambiental para a sociedade e o governo e refletir antecipadamente as tendências da poluição ambiental. Lá são alguns índices fundamentais para a classificação aproximada de modelos de previsão da qualidade do ar: a classificação em escala de tempo de modelos de previsão, abordagem de previsão e o tipo de entradas. Pela resolução dos dados do tempo, a previsão da qualidade do ar inclui categorias de curto prazo, curto prazo, médio prazo e longo prazo, conforme mostrado na Fig. 1. Os dados de previsão nos artigos revisados são principalmente em resolução horária e diária. Os valores diários são geralmente dos dados por anos, que representam tendências de longo prazo do desenvolvimento da contaminação [18].

Em geral, uma extensão temporal de previsão mais curta pode alcançar resultados mais detalhados e precisos e extensão temporal de previsão mais longa fornecem informações de longo prazo para pesquisa. Esse tipo de aplicação da pesquisa de previsão ajuda a realizar processos de controle de poluição de longo prazo, enquanto a previsão horária pode contribuir para a monitorização e gestão da qualidade do ar a curto prazo de maior precisão. O estabelecimento da modelagem da qualidade do ar é um processo complexo de engenharia de sistemas e um ponto difícil na pesquisa em ciências ambientais, o que ajuda a estudar a relevância das causas e resultados dos contaminantes e contribui às soluções de mitigação no futuro com uma análise eficaz.

Nos últimos anos, os modelos de previsão da qualidade do ar têm sido continuamente aprimorados e expandidos. Para que vários métodos e abordagens para dados de séries temporais podem ser adotadas para facilitar o controle direcionado da poluição atmosférica e prevenir incidentes de poluição.

Nomenclatura	
Abreviaturas	
<i>AdaBoostGenericName</i>	Reforço Adaptativo
QUE	Entrada múltipla adaptável
ANFIS	Sistema de inferência fuzzy de rede neural adaptável
ANN	Rede neural artificial
AQI	Índice de qualidade do ar
ARIMA	Modelo de média móvel integrado autorregressivo
NÃO	Algoritmo de morcego
BPNN	Rede neural de retropropagação
CAMX	Modelo abrangente de qualidade do ar com extensões
CEEMD	Modo de composição empírico complementar
CEEMDAN	Modo empírico de conjunto completo decomposição com ruído adaptativo
CMAQ	Qualidade do ar multiescala comunitária
CNN	Rede neural convolucional
CPSOGSA	Otimização de enxame de partículas caóticas algoritmo de pesquisa de método e gravitação
CS	Pesquisa de cuco
DBN	Rede de crenças profundas
<i>A PARTIR DE</i>	Evolução diferencial
<i>A PARTIR DE</i>	Suavização exponencial dupla
DESVN	Máquina vetorial de suporte otimizada para evolução diferencial
DWT	Transformada wavelet discreta
EEMD	Decomposição de modo empírico de conjunto
OLMO	Máquina de aprendizado extremo
EMD	Decomposição em modo empírico
QUE	rede neural Elman
EWV	Transformada wavelet empírica
FCM	Fuzzy C-Means
FFnn	Rede neural de feedforward
FKM	Fuzzy K-Medoid
FLM	Modelo de lógica difusa
STF	Série temporal difusa
GA	Algoritmo genético
GABP	Ação de backprop otimizada por algoritmo genético
GCN	Redes convolucionais do gráfico
GK	Gustavo-Kessel
GM	Modelo cinza
GRNN	Rede neural de regressão generalizada
GRU	Unidade recorrente fechada
<i>EXCELENTE</i>	Otimizador de lobo cinzento
ICEMDAN	Decomposição de modo empírico de conjunto completo melhorada com barulho
I A	Índices de acordo
FMI	Função de modo intrínseco
KNN	K-vizinho mais próximo

LAÇO	Encolhimento e seleção menos absolutos operador
LLE	Incorporação linear local
LSSVM	Máquina de vetores de suporte aos mínimos quadrados
LSTM	Memória de curto prazo longa
MADRI	Modelo de dinâmica de aerossol, reação, ionização e dissolução
<i>MUITO DE</i>	Erro absoluto médio
MAPA	Erro percentual absoluto médio
MCSDE	Pesquisa e diferencial de cuco modificados algoritmo de evolução
MGWO	otimização de lobo cinzento modificada
MIM	Informação mútua
ML	Aprendizado múltiplo
MLP	Perceptron multicamada
MLR	Regressão linear múltipla
<i>MILÍMETROS</i>	Modelo de mesoescala
MOALO	Otimizador de leão formiga multiobjetivo
MODWT	Wavelet discreta de sobreposição máxima transformar
MOHMO	Algoritmo de enxame de salp multi-objetivo
JOGADA	Pesquisa e diferencial de cuco modificados algoritmo de evolução
MSE	Erro quadrado médio
MTL	Aprendizagem multitarefa
OLDBN	Rede de crenças profundas online
PCA	Análise do componente principal
PCR	Regressão do componente principal
PSO	Otimização de enxame de partículas
PSOGSA	Otimização de enxame de partículas e algoritmo de busca gravitacional
RBF	Função de base radial
RBFNN	Rede neural de função de base radial
RBM	rede neural recorrente
retomar	Unidade linear retificada
RF	Floresta aleatória
RFELM	Máquina de aprendizagem extrema aleatória fourier
RSP	Partícula Suspensa Respirável
RMSE	Erro quadrático médio
RN	rede neural recorrente
SAE	Codificador automático empilhado
SD	Decomposição secundária
SE	Entropia de amostra
SPM	Partículas suspensas
SSA	Análise de espectro singular
STELSTM	Estratégia de conjunto espaço-temporal
STFV	Vetor de recurso espaço-temporal
STSVR	Regressão vetorial de suporte espaço-tempo
SVM	Máquina de vetores de suporte
SVR	Regressão de vetor de suporte
TSP	Partículas suspensas totais
VM	Modo Variacional
VMD	Decomposição em modo variacional
WELM	Máquina de aprendizado extremo ponderada
WPD	Decomposição de pacotes wavelet
WRF	Pesquisa e previsão do tempo

WRF-Química	Pesquisa e previsão do tempo/química
WM	Modelo-Vencedor
WNN	Redes Neurais Wavelet
WT	Transformação wavelet
XGBOOST	Aumento de gradiente extremo

Os modelos de transporte químico (CTMs) visam descrever processos químicos e meteorológicos na atmosfera, com foco na emissão, transporte e mistura de concentrações de poluentes atmosféricos para estabelecer um modelo matemático correspondente [19, 20]. Os modelos baseados em pesquisa e previsão do tempo (WRF) são utilizados para pesquisa atmosférica e aplicações em previsão, como WRF-Chem [21] e WRF/Chem-MADRID [22]. Outro métodos determinísticos como CAMx [23], modelo CMAQ [24], e LOTOS-EUROS [25] também são usados na previsão de poluentes atmosféricos por estudiosos. Muitas condições dinâmicas químicas, índice de reação, e produtos químicos devem ser levados em consideração. o precisão desses métodos determinísticos depende da abundância de informações e dados de fontes poluentes e descrição explícita de reações químicas e processos físicos [26]. Os pontos-chave para melhoria adicional pode ser a aquisição da não linearidade entre a concentração dos poluentes e as fontes de seu transporte e difusão [27,28], especialmente por aplicação em área com terreno complexo [29].

Os métodos estatísticos refletem principalmente as conexões estatísticas entre vários impactos e poluentes atmosféricos em séries temporais, aplicando os dados históricos para prever a qualidade do ar em vez de processos físicos, químicos e biológicos. Eles são baseados em dados modelos com a teoria da estatística matemática, probabilidade, e processos estocásticos. Os modelos estatísticos tradicionais usados na previsão da poluição do ar são movimentos integrados autorregressivos média (ARIMA) [30], modelo cinza (GM) [31] e outra regressão modelos. A precisão da previsão do modelo cinza depende muito nas características dos dados e nos parâmetros de cinza. Os modelos de regressão utilizados para a previsão de concentrações de poluentes incluem principalmente a regressão stepwise [32], componente principal regressão (PCR) [33] e regressão linear múltipla (MLR) [34]. Os modelos estatísticos funcionam com o princípio de descrever a relação entre as variáveis com base na possibilidade e na estatística. média e geralmente podem atingir uma precisão satisfatória do nível de concentração para previsões futuras [35]. No entanto, os modelos estatísticos ainda têm espaço para melhorias no precisão enquanto o comportamento de contaminações do ar e outros características regionais podem ser complexas, desordenadas e altamente não lineares [36]. Portanto, abordagens eficazes ainda são necessárias para conta para lidar com a modelagem da qualidade do ar.

Com o rápido progresso da inteligência artificial e da máquina aprendizagem nos últimos anos, a previsão baseada em inteligência artificial os modelos estão ficando populares e atraem mais atenção. Os preditores inteligentes podem alcançar melhor desempenho de precisão em abordagens ao lidar com não linearidades e relações na modelagem da poluição do ar [37]. As principais vantagens dos modelos são eles podem manipular os elementos não lineares, conduzir a operação de volumes de dados em grande escala para resolver problemas. A aplicação não requer um conhecimento profundo de os processos dinâmicos e químicos entre a contaminação do ar níveis e outras variáveis relativas na atmosfera [38]. UMA preditor comumente usado é uma rede neural artificial (ANN), que simula o sistema do cérebro humano e sistema nervoso para modelar séries não lineares. As redes neurais também são aprimoradas em anos de aplicação, resultando em mais versões evolutivas para a previsão da poluição do ar, como

a rede neural de retropropagação (BPNN) [39], a base radial rede neural funcional (RBFNN) [40], a rede neural de regressão generalizada (GRNN) [41], a rede neural wavelet (WNN) [42,43]. Outros modelos, que também são populares na previsão de poluentes atmosféricos, são a máquina de vetores de suporte (SVM) e o fuzzy lógica. Semelhante à RNA, tanto o SVM quanto o modelo de lógica fuzzy (FLM) têm versões aprimoradas de melhor capacidade de lidar com variáveis e aumentar a precisão, como o suporte aos mínimos quadrados máquina de vetores (LSSVM) [44] e o sistema adaptativo de inferência neuro-fuzzy (ANFIS) [45,46]. Além disso, os modelos de aprendizado profundo baseado em algoritmos de previsão pode realizar as funções com várias camadas. E a eficácia desses modelos tem sido apresentado por comparação em experimentos da rede de crenças profundas (DBN) [47], a rede neural convolucional (CNN) [48], e a memória de longo prazo (LSTM) [49].

Recentemente, muito esforço tem sido feito para revisar e pesquisar as características de diferentes tipos de modelos preditivos inteligentes no campo da qualidade do ar [50-52]. Foi geralmente concluído que nenhum preditor único pode ser apropriado em todos os aspectos da modelagem por causa de suas limitações e não houve abordagem inteligente apropriada para todos os problemas específicos. Os modelos híbridos geralmente significam não apenas a combinação de diferentes algoritmos ou métodos, mas também a combinação de vantagens de cada componente, o que leva a melhores desempenhos. o os modelos híbridos incluem principalmente várias estratégias de modelagem [53]. O modelo híbrido simples, Mishra e Goyal construíram um novo modelo por PCA e ANN para previsão de concentrações de NO2 [54], que combina o método de extração de recursos com preditores. Bai et al. usou a transformada wavelet (WT) para pré-processar os dados relevantes em uma série de subcamadas como decomposição de dados e, em seguida, usado o BPNN para realizar a previsão e a acurácia da previsão é maior que a do modelo BPNN simples [55]. o modelos híbridos inteligentes de última geração podem combinar mais processamento de dados ou algoritmos de otimização. Liu et al. propôs um modelo de previsão híbrido [53]. A decomposição do pacote wavelet (WPD) é aplicado para processar os dados de entrada e o BPNN é usado para realizar a previsão em três etapas, que será otimizada pela otimização de enxame de partículas (PSO) e reforçada pelo algoritmo de reforço adaptativo (Adaboost). De exemplos acima, pode-se ver que além dos preditores e o processamento de dados como componentes de modelos híbridos [56-58], a aplicação de otimização metaheurística [59-62] e ensemble learning [63-65] também são populares na aplicação. o otimizações metaheurísticas procuram os parâmetros ótimos em uma gama aceitável e aprendizagem em conjunto integra vários modelos para alcançar um modelo com melhor desempenho.

Além disso, como o desenvolvimento contínuo e avançado de ar pesquisa sobre poluição, as áreas e alvos de pesquisa não devem ser limitado a um pequeno escopo de locais ou certas áreas urbanas. UMA gama mais ampla de tendências gerais de poluição do ar, que contém uma enorme quantidade de conjuntos de dados de entrada no espaço, deve ser levado em consideração para realizar uma análise precisa e abrangente para qualidade do ar de muitos lugares em uma grande região ou vários períodos. Pré-processamento de vários dados [66-68], melhorando modelos para interação espaço-temporal [69,70] e uma combinação de preditores espaciais e temporais em modelos híbridos [71,72] são três aspectos principais nesta seção.

1.3. A motivação da revisão

Recentemente, alguns artigos de revisão focaram nas metodologias preditivas da qualidade do ar. O conteúdo principal dos comentários de 2015 a 2020 é resumida a seguir. Bai et al. revisou métodos de previsão estatística, métodos de inteligência artificial e métodos de previsão numérica para a qualidade do ar previsão, mas não discutiu os modelos inteligentes e as




Fig. 1. A classificação temporal da previsão da qualidade do ar.

combinação deles em profundidade [52]. Cabaneros et al. pesquisou principalmente a aplicação de RNA com algumas estratégias híbridas para previsão de poluição do ar [38]. Taheri Shahraini e Sodoudi listaram as modelagens estatísticas de PM10 em áreas urbanas [73]. Rybarczyk e Zalakeviciute resumiram os modelos de aprendizado de máquina para prever a poluição do ar e compararam esses métodos com as abordagens tradicionais [51]. Masih revisou as principais técnicas de aprendizado de máquina aplicadas para estimativa e previsão de concentração de poluentes [50]. Wang et al. revisaram alguns modelos de previsão da qualidade do ar, mas o principal objetivo era a interação da poluição do ar e do nexo do terreno com os impactos da geração e consumo de energia [74]. Gulia et al. resumiu as estratégias do plano de gestão da qualidade do ar (UAQMP) na gestão da poluição do ar urbano e monitoramento da qualidade do ar em diferentes países [75]. Casazza et al. concentrou-se no monitoramento e modelagem espacial e nos modelos de avaliação e previsão listados para o planejamento portuário urbano [76].

Embora as revisões supracitadas resumam e analisem excelentemente o status da pesquisa e a perspectiva do estudo preditivo de poluentes atmosféricos sob diferentes aspectos, as revisões aprofundadas das estratégias de modelagem inteligente são raras e as revisões extensas dos modelos avançados ainda são necessárias. As estratégias baseadas em dados se desenvolveram rapidamente nas últimas décadas. Eles têm sido o foco da pesquisa de previsão atual e vários métodos inteligentes aprimorados podem ser aplicados à previsão de poluição [77-91]. Portanto, novas teorias devem ser concluídas e esclarecidas. Este artigo enfoca essas lacunas de pesquisa e apresenta uma revisão integrada dos métodos de modelagem inteligente para previsão da qualidade do ar. Os métodos de processamento de dados comumente usados e os métodos auxiliares são aplicados em modelos inteligentes híbridos para aumentar a capacidade preditiva dos preditores inteligentes. Com as tendências de aumento de dados de entrada e uma gama mais ampla de pesquisas sobre qualidade do ar, também resumimos os métodos espaço-temporais adotados e buscamos a forma como eles aumentaram a capacidade preditiva dos modelos híbridos. A principal contribuição da revisão é apresentar e classificar de forma abrangente os métodos inteligentes de modelagem para previsão da qualidade do ar, bem como os resultados teóricos e estatísticos. Esperamos complementar as tecnologias existentes na vertente da investigação científica.

1.4. Organização e os índices de avaliação

Este estudo se concentra nas deficiências acima e oferece uma revisão detalhada das aplicações de estratégias de modelagem inteligente na previsão da qualidade do ar. Mais especificamente, resumimos a melhoria progressiva na previsão da qualidade do ar. Neste artigo, diferentes modelos serão classificados e comparados. O restante da revisão é apresentado a seguir: A Seção 2 fornece uma introdução e classificação aprofundadas de preditores inteligentes para aplicação preditiva e resume suas vantagens e limitações. A Seção 3 apresenta uma revisão dos métodos de processamento de dados, que inclui decomposição e extração de características.

A Seção 4 e a Seção 5 apresentam métodos auxiliares de modelos híbridos inteligentes (ou seja, otimização metaheurística e aprendizado de conjunto). A seção 6 revisa os trabalhos de pesquisa recentes nos aspectos espaciais e temporais. A Seção 7 apresenta uma extensa discussão sobre esses métodos e as tendências e desafios da pesquisa da qualidade do ar no futuro. A Seção 8 conclui para encerrar este papel.

Muitos índices de avaliação têm sido usados no campo da avaliação de erros. As definições e fórmulas dos índices envolvidos nesta revisão são mostradas na Tabela 1, onde n é o número total de instâncias, P_i representa o valor previsto e A_i representa o valor real, \bar{A} e \bar{P} representam a média real e média prevista valor.

1.5. Pesquisa de literatura e estratégia de seleção

A pesquisa bibliográfica foi realizada na base de dados de pesquisa sistemática altamente indexada Google Scholar e Web of Science periódicos para literatura relevante publicada principalmente na última década. Eles estão entre os poucos bancos de dados que compilam os bancos de dados científicos mais significativos, como IEEE Xplore, Science Direct e Springer, onde os principais artigos podem ser encontrados na pesquisa da qualidade do ar.

Os principais termos de pesquisa incluíram "Qualidade do ar", "previsão", "previsão", "simulação", "área urbana", "modelagem", "modelo híbrido" e "aprendizagem de máquina" com diferentes combinações. O objetivo principal é em estudos recentes do trabalho de pesquisa científica mais credível, autoritativo e confiável que abrange o âmbito mundial. Alguns trabalhos de conferência também foram selecionados. O processo de busca foi repetido até que a citação relevante parasse. A lista de referências dos artigos escolhidos também foi analisada para identificar outras referências. Apenas a literatura publicada na língua inglesa foi finalmente selecionada. Os artigos foram então categorizados de acordo com a expressão das informações necessárias (por exemplo, embasamento científico, variáveis de entrada, processo de modelagem e precisão da previsão). Além das citações de artigos de metodologia originais, o conteúdo principal dos artigos de aplicação é do ano de 2000 a 2020 e cerca de 90% deles são de 2010 a 2020. Todo o processo de busca é mostrado na Fig. 2.

Como resultado da busca na literatura, foram escolhidos 209 artigos. A segunda etapa foi a leitura do título e resumo de todos os artigos e verificação dos quartis dos periódicos. Com base nessa filtragem, 20 artigos foram reduzidos da lista de seleção porque; (1) não abordaram o tema; (2) os trabalhos não foram baseados em modelos computacionais; (3) os trabalhos semelhantes dos mesmos autores. Outra limitação de 12 artigos foi focar nos quartis recentes dos periódicos de acordo com o Journal Citation Reports (JCR), que conclui as categorias Q1-Q4. O resultado da segunda etapa nos fornece 177 documentos no conteúdo da revisão. Na última etapa, foram excluídos 66 artigos da metodologia original e da introdução do princípio ao invés de artigos de aplicação. Por fim, um total de 111 manuscritos foram incluídos para a análise qualitativa e quantitativa da revisão após leitura cuidadosa. A Figura 3 representa o fluxograma da seleção dos artigos para a revisão sistemática, que se baseia na diretriz PRISMA.

2. Preditores inteligentes eficazes

Após uma pesquisa detalhada e abrangente da literatura, os preditores inteligentes comumente usados para previsão da qualidade do ar são preditores superficiais e preditores de aprendizado profundo. Cada preditor foi otimizado em desenvolvimento contínuo. Devido às semelhanças de estrutura e algoritmo, os modelos inteligentes simples atualizados serão classificados e discutidos nesta seção.

As definições e fórmulas dos índices aplicados nesta revisão.

Índice	Definição	Equação
MJITO DE	Erro absoluto médio	$FÁCIL = \frac{1}{n} \sum_{i=1}^n P_i - A_i $
MSE	Erro quadrático médio	$MSE = \frac{1}{n} \sum_{i=1}^n (P_i - A_i)^2$
RMSE	Erro quadrático médio	$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (P_i - A_i)^2}$
MAPA	Erro percentual absoluto médio	$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{ A_i - P_i }{A_i} \times 100\%$
I A	Índice de acordo	$IA = 1 - \frac{\sum_{i=1}^n P_i - A_i }{\sum_{i=1}^n (P_i + A_i)}$
CC	Coefficiente de correlação	$CC = \frac{\sum_{i=1}^n (P_i - \bar{P})(A_i - \bar{A})}{\sqrt{\sum_{i=1}^n (P_i - \bar{P})^2} \sqrt{\sum_{i=1}^n (A_i - \bar{A})^2}}$




Fig. 2. O processo da metodologia utilizada para pesquisa na literatura.

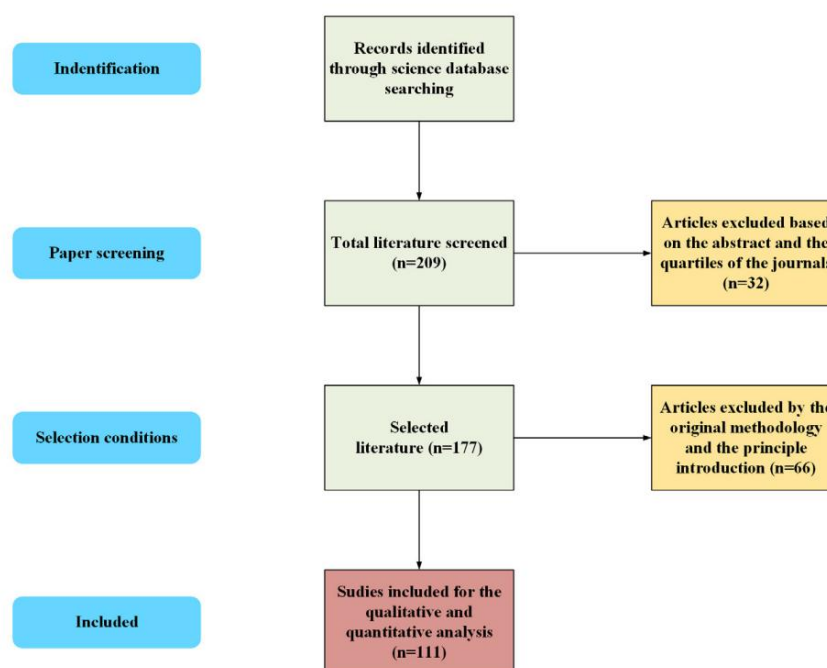


Fig. 3. Fluxograma PRISMA para a seleção sistemática dos artigos relevantes.

2.1.1. Rede neural artificial

A RNA simula a estrutura neuronal do cérebro humano para construir um modelo simplificado com diferentes redes de acordo com os requisitos da aplicação. A RNA básica é um modelo preditivo de nós massivamente conectados, em que cada nó representa uma função de ativação. A RNA é o algoritmo mais predominante usado em vários campos da engenharia e pode usar uma enorme quantidade

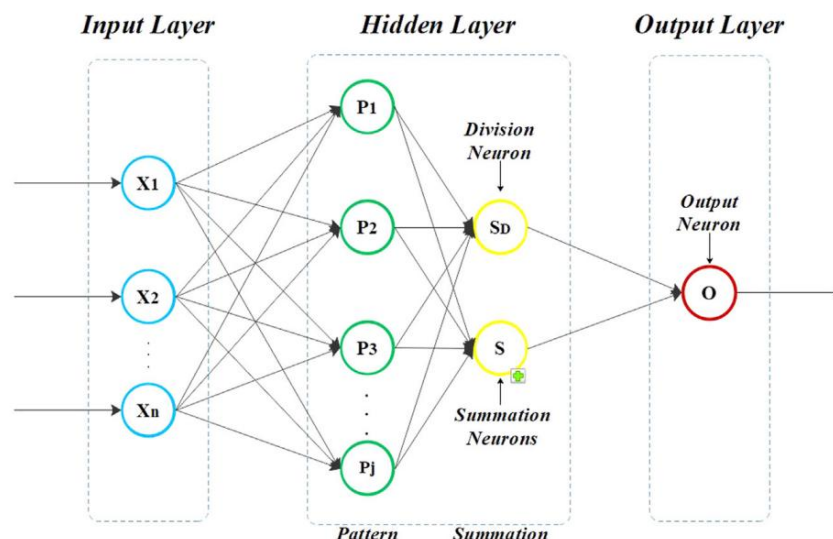


Fig. 4. Uma estrutura básica do GRNN.

de neurônios para aprender as informações não lineares dos dados de entrada e inferir a relação complexa entre os dados desconhecidos para construir modelos para que os modelos possam generalizar e prever dados desconhecidos de poluentes do ar [92,93]. Com aplicação e atualização contínuas, muitos modelos aprimorados de RNA tradicionais têm sido propostos e usados para previsão da qualidade do ar.

O modelo de rede neural de retropropagação (BPNN) é um método de aprendizado de máquina amplamente utilizado com redes multicamadas feed-forward. O algoritmo BP tem sido usado para melhorar a RNA. Na estrutura BPNN, é um preditor de 3 camadas, no qual os dados de entrada são entregues por neurônios artificiais da camada de entrada para a camada oculta para que a informação flua para frente e os resultados sejam transmitidos para a camada de saída. Os erros da rede, entretanto, serão propagados para trás conforme o feedback [39].

O modelo BPNN também tem sido aplicado para resolver os problemas de previsão da qualidade do ar [94,95].

A rede neural de função de base radial (RBFNN) usa a função de base radial como função de ativação. A principal diferença da RBFNN com outras RNAs é que o número de neurônios ocultos na camada oculta pode ser ajustado adequadamente para atender a convergência para o objetivo planejado. Zheng e Shang compararam dois tipos de rede neural BPNN e RBFNN para a previsão da concentração de PM_{2,5}, e os resultados provaram que RBFNN tem maior precisão (MAE = 0,0040 e CC = 0,9851) do que BPNN na previsão [96]. A rede neural de regressão generalizada (GRNN) é um algoritmo aprimorado baseado em RBFNN e possui bom desempenho de aproximação não linear e convergência rápida. O GRNN possui quatro camadas, nas quais a camada oculta foi dividida em camada de padrão e camada de soma [97]. A camada de soma tem dois tipos de neurônios, os neurônios de soma e um neurônio de divisão. O número de neurônios de somação mantém-se sempre igual ao número de neurônios de saída GRNN, conforme mostrado na Fig. 3. Zheng et al. comparou GRNN e BPNN tradicional pelas emissões de NO_x previstas e os valores reais para melhor taxa de convergência, precisão preditiva e menos tempo de computação cerca de 1/6 do BPNN [98]. Antanasijević et al. usou GRNN para prever a concentração de PM₁₀ e comparou com o modelo convencional de regressão de componentes principais (PCR), cujos resultados mostraram que o GRNN tem melhores capacidades preditivas do que o modelo PCR com os mesmos conjuntos de dados e dados de entrada [99]. Uma comparação semelhante de BPNN e GRNN é realizada por Sun et al. para prever os níveis de NH₃, H₂S, CO₂ e PM₁₀ e demonstra as vantagens do GRNN sobre o BPNN, incluindo tempo de execução mais rápido, melhor aproximação e estabilidade extra [100].

Combinado com a análise de RNA e wavelet, as redes neurais wavelet (WNN) utilizam uma função de base wavelet como função de ativação. Para que possa tirar proveito de ambas as redes para obter uma melhor capacidade de aprendizado e maior precisão para a previsão da poluição do ar [43,101]. Elman propôs a rede neural Elman (ENN) em 1990 [102]. Ao adicionar uma camada de contexto à camada oculta como um operador de atraso de uma etapa, o ENN atinge o objetivo de melhorar a memória e a capacidade de se ajustar à identidade variável no tempo e melhorar a estabilidade da rede.

Muitos pesquisadores usaram ENN para a previsão de concentrações de poluentes e otimizaram o modelo ENN para melhor desempenho preditivo [103-105].

2.1.2. Máquina de vetores de suporte

A máquina de vetores de suporte (SVM) é um método de aprendizado de máquina baseado na teoria de minimização de risco estrutural (SRM) para minimizar o erro de generalização do erro de treinamento.

No entanto, as estruturas matemáticas e os métodos de processamento do SVM são bastante diferentes das RNAs. SVM constrói hiperplanos para separar diferentes classes. Para uma variável de saída contínua, a análise de regressão pode ser usada para substituir a classificação. Nieto et al. usaram a regressão vetorial de suporte (SVR), que é o tipo de modelagem otimizada para encontrar uma solução aproximada de problemas altamente não lineares e pesquisar a qualidade do ar na área urbana de Oviedo no norte da Espanha com sucesso [106]. Uma estrutura de função básica de SVR é mostrada na Fig. 5, onde \hat{y}_i e \tilde{y} são variáveis de falta. Liu et al. tomaram dados de entrada para prever o índice de qualidade do ar (AQI) usando o algoritmo SVR, com o objetivo de aumentar a precisão da previsão AQI [107]. O trabalho de Sánchez et al. também mostrou que o modelo SVR teve alta precisão na previsão da dependência entre os principais poluentes como CO, NO₂, SO₂ na área urbana de Avilés [108].

SVM representa ser eficiente com bom desempenho, e muitas pesquisas sobre previsão da qualidade do ar são baseadas no modelo SVM [109] e análise. Lu e Wang fizeram comparações de SVM e função de base radial (RBF) na previsão de níveis poluentes de CO, SO₂, NO_x, O₃ e partículas suspensas respiráveis (RSP), enquanto SVM mostrou melhor desempenho de generalização e menor erro. O SVM também tem sido usado com diferentes modelos de kernel para prever poluentes em regressão e séries temporais [110].

Saxena e Shekhawat também desenvolveram um modelo SVM, no qual o parâmetro do kernel e o viés são tratados pelo otimizador de lobo cinza (GWO) [111]. Máquina de vetores de suporte de mínimos quadrados

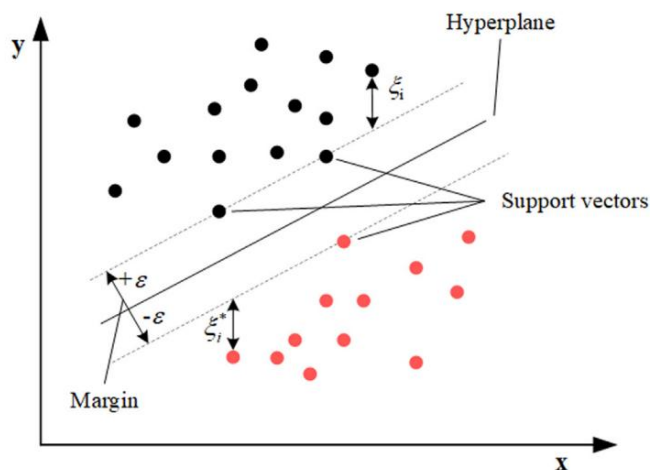


Fig. 5. Uma estrutura básica da divisão de um conjunto de dados por SVR.

(LSSVM) foi proposto por Suykens e Vandewalle para resolver problemas por classificação de padrões e estimação de funções [112]. O SVM tradicional usa o método de programação quadrática, mas o LSSVM aplica o sistema linear de mínimos quadrados como a função de perda. Alguns pesquisadores utilizaram o LSSVM para prever os níveis de poluentes do ar [44,113].

2.1.3. Modelo de lógica fuzzy

O modelo de lógica fuzzy (FLM) é uma abordagem de lógica de múltiplos valores para imitar a incerteza do cérebro humano e a forma de modelos desconhecidos ou indeterminados. Baseia-se no conceito de conjunto fuzzy e utiliza o conceito de função de pertinência para lidar com relações fuzzy e resolver vários tipos de problemas incertos. Song e Chissom propuseram um modelo de previsão para séries temporais difusas e iniciaram a pesquisa da teoria e aplicação de séries temporais difusas. Em geral, a previsão de séries temporais é um dos principais objetivos da análise de séries temporais [114]. Baseado na lógica fuzzy, o algoritmo fuzzy time series (FTS) é composto pelos conjuntos fuzzy correspondentes e adequados à incerteza nos dados, o que reduz a influência de dados imprecisos na precisão do modelo. Dincer e Akkuş usaram um modelo FTS aprimorado com algoritmo fuzzy k-medoids (FKM) na previsão de concentrações de SO₂ e compararam os resultados com modelos FTS aprimorados pelos algoritmos Gustafson-Kessel (GK) e fuzzy c-means (FCM) [115]. Domańska e Wojtylak estabeleceram um modelo de previsão de poluição do ar de FTS para obter um conjunto de dados de poluentes por agrupamento difuso [116].

O sistema adaptativo de inferência neuro-fuzzy (ANFIS), desenvolvido por Jang, é um novo sistema composto por um sistema de inferência fuzzy e RNA [117]. A Fig. 4 mostra que a arquitetura geral do ANFIS é composta por seis camadas. O ANFIS pode ser utilizado para ajustar os parâmetros de premissa e parâmetros de conclusão, e pode obter automaticamente as regras If-Then. Além disso, a técnica neuro fuzzy pode manipular e analisar vários tipos de informação e alcançar propriedades de autoaprendizagem, o que melhorará ainda mais a qualidade da previsão [118]. Os modelos neuro-fuzzy têm sido amplamente utilizados na previsão do nível de poluentes do ar por estudiosos [46,119,120].

2.1.4. Máquina de aprendizado extremo

Extreme Learning Machine (ELM) é um tipo de sistema de aprendizado de máquina na rede de neurônios feedforward (FFNN), que é adequado para aprendizado supervisionado e problemas de aprendizado não supervisionado. Sua identidade proeminente é que os pesos dos nós da camada oculta são dados aleatórios ou artificialmente e não requerem atualização

após a configuração do índice [121]. O ELM tradicional possui uma única camada oculta, cuja função de ativação pode ser uma função linear ou uma função sigmoide. A Fig. 7 mostra o quadro básico do ELM com n neurônios de entrada, j neurônios ocultos, m saída w é a matriz de pesos entre a camada de entrada e a camada oculta e \tilde{y} é a matriz de saída entre a camada oculta e a camada de saída.

Quando comparado com outros sistemas de aprendizado superficial, como perceptron de camada única e SVM, é considerado como tendo uma melhor taxa de aprendizado e uso na aplicação de ciências da terra e ambientais [121]. Zhao et al. propôs um ELM para prever a qualidade do ar com registros horários em torno de Helsinque [122].

Zhang e Ding estudaram a concentração de poluentes atmosféricos em Hong Kong e avaliaram os poluentes a partir de parâmetros meteorológicos e temporais [123]. Após a comparação do desempenho de previsão do MLR, FFANN-BP e ELM, os resultados mostraram que o ELM tem um bom desempenho nos aspectos de precisão, robustez e generalização.

A máquina de aprendizado extremo sequencial on-line (OSELM) foi proposta para obter os dados pedaço por pedaço [124]. Bueno et al. conduziram a previsão da qualidade do ar em São Paulo, Brasil, e compararam OS-ELMs com ELMs, mostrando maior precisão do OSELM em processos individuais e em conjunto [125]. A pesquisa semelhante em todo o Canadá sobre as previsões de concentração horária de ozônio, PM_{2,5} e NO₂ foi proposta por Peng et al. em que o OSELM geralmente obteve melhor desempenho preditivo para o MLPNN, ELM e atualizado-MLR e atualizado-ELM) no MAE e nos escores de correlação [126]. Para aumentar a capacidade robusta insuficiente de ELM contra outliers, Deng et al. propuseram um ELM melhorado, chamado de máquina de aprendizagem extrema regularizada ponderada (WRELM) [127]. Devido ao excelente desempenho em generalização e robustez, o WRELM também é selecionado no campo da previsão de poluentes atmosféricos [128].

2.2. Preditores de aprendizado profundo

O aprendizado profundo é um subcampo do aprendizado de máquina e uma classe de algoritmos, que usam redes neurais artificiais como estrutura básica para caracterizar e aprender dados. Comparados aos métodos tradicionais, que aumentam muitos neurônios para resolver problemas, os modelos de aprendizado profundo utilizam múltiplas camadas para atingir as funções de forma gradual. O objetivo do aprendizado profundo é extrair mais recursos modelando com mais camadas ocultas e uma grande soma de dados de treinamento, para aprimorar a precisão preditiva.

Os modelos de aprendizado profundo comumente usados na previsão da qualidade do ar são máquina de Boltzmann restrita, rede neural convolucional e rede neural recorrente.

2.2.1. Rede de crença profunda

A máquina restrita de Boltzmann (RBM) foi inventada por Smolensky, que pode adquirir a distribuição de probabilidade através dos dados de entrada [132]. A unidade RBM é composta por uma camada visual e uma camada oculta e também é um componente de pilha da rede de crenças profundas (DBN) [133]. A estrutura é descrita na Fig. 5, na qual apenas a camada superior é não direcionada. Os estudiosos muitas vezes combinavam algoritmos para formar os modelos individuais para melhorar ainda mais a geração de dados, a precisão da previsão e a eficiência [47,131].

Xie desenvolveu um modelo baseado em DBN combinado com manifold learning (ML) ou algoritmo de incorporação linear local (LLE), que processa dados não lineares e permite redução de dimensão, para superar a escassez de redes neurais tradicionais pela estrutura superficial e obter entrada de baixa dimensão para a rede neural profunda [47]. Li et al. também construiu um modelo DBN com o algoritmo de aprendizado multitarefa (MTL) [131]. A vantagem do MTL é que ele pode explorar a relação entre subtarefas, então as correlações entre os poluentes do ar (PM_{2,5}, SO₂ e NO₂) foram analisadas no processo para provar a adequação do sistema ao modelo de previsão.

mesa 2

Parte dos modelos de aprendizado profundo na previsão da qualidade do ar.

Modelos de aprendizado profundo	Poluentes	Cidades	Resolução de dados	Contrastante modelos	Grau de melhoriaa
CNN [48]	O3	Seul	de hora em hora	AN, SAE, LSTM	11,19% (MAE em picos), 10,43% (MAE em diurno), 17,58% (MAE noturno), 6,76% (CC).
LSTM [129]	O3, PM2,5, NOx, CO	NCT-Déli	de hora em hora	SVM, ANN, M5P, e REPTree	O3: 22,4% (CC), PM2,5:8,99% (CC), NOx: 17,7% (CC), CO: 9,5% (CC)
LSTM [130]	PM10	Seul	diário	LR, RN	4,85% (MSE), 5,1% (RMSE)
LSTM [49]	O3	Kuwait	de hora em hora	FFANN, ARIMA	98,46% (MAE)
DBN (LLE) [47]	PM2,5	Chongqing	diário	DBN, BPNN	8,34% (MAPE), 3,59% (RMSE)
DBN (MTL) [131]	PM2,5, SO2, NO2	Pequim	de hora em hora	OLDBN, DBN, WM	PM2,5: 21,6% (MAE), 17,76% (MAPE) SO2: 3,63% (MAE), 34,66% (MAPE) NO2: 2.22% (MAE), 25,54% (MAPE)

aO grau de melhoria é a partir dos índices de erro do modelo proposto e do melhor modelo contrastivo.

2.2.2. Rede neural convolucional

Ao contrário de outros modelos de previsão inteligentes, o modelo convolucional rede neural (CNN) é um tipo de FFNN formado por estruturas profundas e cálculo de convolução para analisar as imagens de entrada e simular a percepção visual de organismos biológicos.

Zhang et al. propôs um modelo baseado em CNN incluindo nove camadas de convolução, duas camadas de pooling e duas camadas de dropout com a unidade linear retificada (ReLU) como ativação. As camadas de abandono pode ser utilizado para evitar problemas de overfitting [134]. Rijal et al. desenvolveu três modelos CNN com diferentes estruturas como base alunos, combinados com a rede feedforward, para avaliar Níveis de PM2,5 das imagens [135]. Eslami et al. forneceu uma CNN modelo com cinco camadas convolucionais, uma camada totalmente conectada e camada de saída na previsão em tempo real das concentrações de O3 em Seul na Coreia do Sul, e comparado com um longo e curto prazo modelo de memória (LSTM), ANN e um codificador automático empilhado (SAE) modelo [48]. Os resultados experimentais mostraram que o modelo CNN tinha os melhores índices de concordância (0,87) e o menor MAE (10,3).

2.2.3. Rede neural recorrente

Diferente da construção projetada para dados de imagem em CNN, as redes neurais recorrentes (RNN) usam um tipo de tempo dados de série em estruturas de loop, que transfere as informações de dados de forma circular. No entanto, as únicas RNNs tradicionais são difíceis de capturar a correlação de longo prazo das informações de poluentes atmosféricos por explosão de gradiente ou desaparecimento de gradiente. Portanto, os dois modelos RNN aprimorados a seguir são mais prático na aplicação da previsão da qualidade do ar: memória de longo prazo (LSTM) [49.129.130.136-138], unidade recorrente fechada (GRU) [139.140].

A chave do LSTM é o estado das células, que é como um transportador cinto e percorre todo o processo com apenas algumas interações mas também incapaz de controlar as informações memorizadas. LSTM controla o estado das células pelas portas (entrar, esquecer e porta de saída) para transmitir e transformar o status, que passa através de diferentes portas a serem removidas ou adicionadas ao estado da célula. A estrutura básica do LSTM é apresentada na Fig. 9. GRU é um RNN melhorado que é como LSTM e obter uma forma mais simples. Tem apenas um portão de descanso e um portão de atualização e não pode controlar ou preservar memória interna.

2.3. Epílogo

O objetivo desta seção é uma revisão dos conceitos básicos de inteligência preditores na previsão da qualidade do ar. Esses preditores foram resumido a partir de artigos de pesquisa e organizados nesta seção: ANN, SVM, FLM, ELM, DBN, CNN e RNN. Embora sejam os fundamental da previsão inteligente, ainda existem diferenças

Tabela 3

A porcentagem da frequência de aplicação dos preditores superficiais.

Tipo de modelo	Frequência	Por cento
ANN	12	40%
SVM	7 6	23,33%
FLM		20%
OLMO	5	16,67%
Total de artigos	30	100%

Tabela 4

A porcentagem da frequência de aplicação dos preditores de aprendizado profundo.

Tipo de modelo	Frequência	Por cento
DBN	2	15,38%
CNN	3	23,08%
RN	8	61,54%
Total de artigos	13	100%

nas capacidades de previsão. A Tabela 2 descreve parte da revisão resultados dos métodos de aprendizado profundo. O aprendizado profundo tem desenvolvido rapidamente nos últimos anos, mas a partir de artigos relacionados sobre previsão da qualidade do ar, sua aplicação neste campo não é extensa. Após a revisão, pode-se concluir que a aprendizagem profunda métodos podem alcançar maior precisão, velocidade mais rápida e melhor eficiência na previsão. Por exemplo, por Freeman et al. O significativo erro absoluto (MAE) do modelo LSTM diminuiu quase 98,46% em comparação com a FFNN simples [49].

As Tabelas 3 e 4 mostram a frequência de aplicação do único modelos de previsão. De acordo com as tabelas, as tendências atuais pode ser encontrado que a RNA como preditores rasos e o RNN já que os preditores de aprendizado profundo são usados com mais frequência do que outros. Isso pode ser levado em consideração para estudos futuros entre as estratégias de modelagem.

A Tabela 5 demonstra os resultados detalhados da pesquisa de previsão modelos de qualidade do ar, incluindo méritos e deméritos, tipos de ar poluentes e algoritmos correspondentes.

A RNA é um modelo simplificado de acordo com a estrutura do rede de neurônios do cérebro humano para processamento de informações. Lá também são muitas melhorias ao longo dos anos. As RNAs têm alta precisão na classificação e é fácil de aprender e construir modelos para conexões não lineares, levando a uma boa precisão no ar previsão de qualidade. No entanto, as RNAs também têm as limitações que redes neurais requerem muitos hiperparâmetros para serem ajustados que podem afetar os resultados da previsão e o processo de aprendizagem não pode ser observado. Uma enorme quantidade de neurônios em modelos pode causar prolongamento do tempo de aprendizagem.

Na estrutura do SVM, as funções do kernel são usadas para mapear espaços de alta dimensão e resolver a classificação não linear,

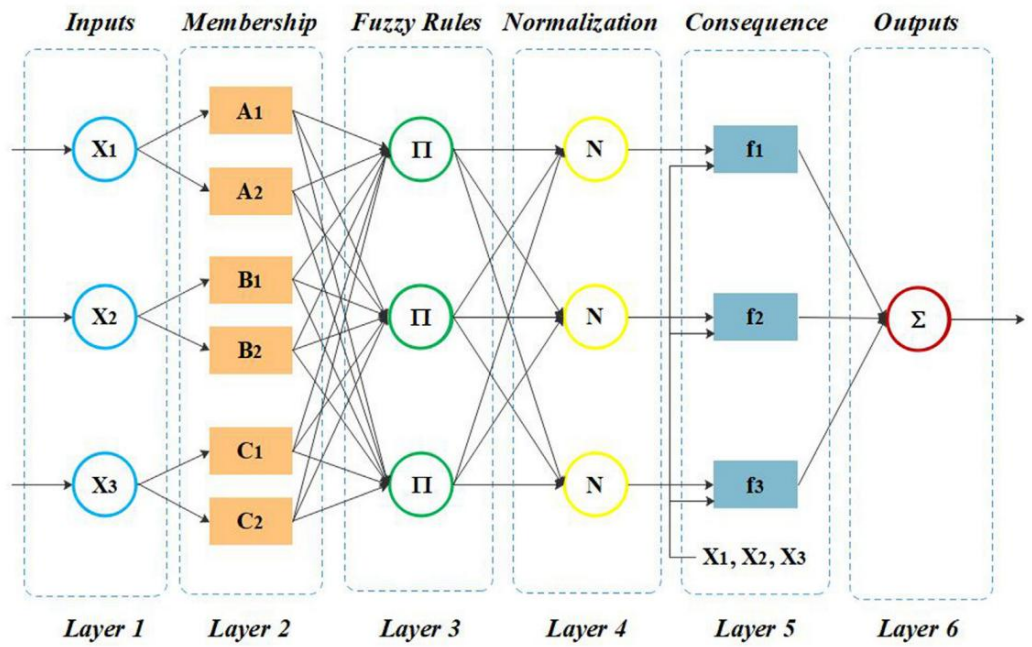


Fig. 6. Estrutura geral do ANFIS.




Fig. 7. Uma estrutura básica do ELM.

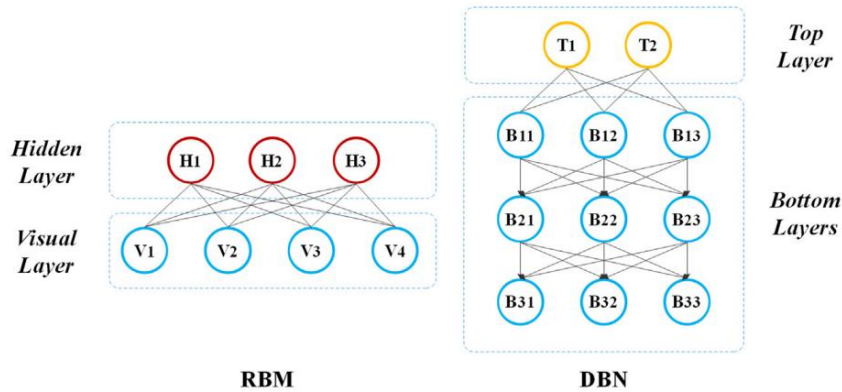


Fig. 8. As representações gráficas de RBM e DBN.

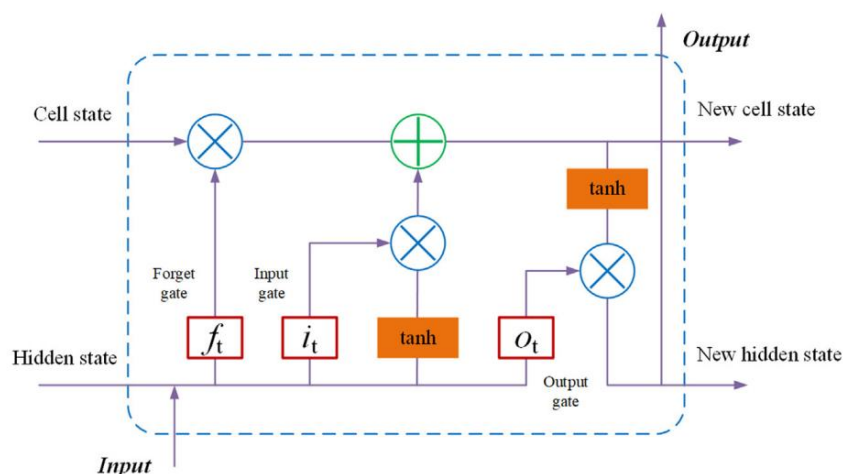


Fig. 9. A estrutura básica da rede LSTM.

por isso é muito importante e sensível para o SVM selecionar os parâmetros e funções do kernel. A seleção de estrutura de redes neurais e problemas de ponto mínimo local podem ser evitados.

No entanto, o SVM é difícil de treinar dados em grande escala e não pode suportar com eficiência várias classificações.

Com a aplicação de regras fuzzy, o FLM tem méritos em adaptabilidade e interação. No entanto, o processo fuzzy dos dados pode comprometer a precisão do controle e a qualidade dinâmica do modelo. Devido à menor sistematização, também dificulta o trabalho de controle fuzzy de sistemas complexos.

Os ELMs têm as vantagens de uma estrutura relativamente simples, menos ajuste de parâmetros e menor complexidade computacional.

Os caracteres do ELM são apropriados para a previsão da poluição do ar a curto prazo. No entanto, a inicialização aleatória do peso de entrada e deslocamento de elementos ocultos no ELM ainda é controverso. Para um nível superior em várias aplicações de ELM, o projeto estrutural razoável e a pesquisa sobre o tipo de geração de nós ocultos são essenciais.

Os modelos de previsão de aprendizado profundo se desenvolveram rapidamente e as melhorias em relação ao reconhecimento visual e de fala tradicional foram alcançadas pela atualização contínua. Embora os modelos de previsão de aprendizado profundo tenham méritos óbvios, como grande capacidade de aprendizado e adaptabilidade, os problemas de verificação complexa e velocidade de treinamento não podem ser ignorados.

3. Processamento de dados para estratégias de modelagem

A partir da análise dos modelos inteligentes, pôde-se concluir que cada modelo tem suas vantagens e desvantagens. Devido à complexidade dos níveis de poluentes atmosféricos, à influência de múltiplos fatores e às complexas tendências de mudança, é muito difícil utilizar um preditor simples para uma previsão eficaz.

Aproveitando vários preditores inteligentes, as informações preditivas de diferentes modelos podem ser combinadas para formar um modelo híbrido para melhorar efetivamente a capacidade de ajuste e aumentar a precisão da previsão. Nesta seção, a classificação e introdução de componentes em modelos de previsão da qualidade do ar da literatura publicada serão descritos e discutidos principalmente. incluindo os métodos de processamento de dados comumente usados: decomposição de dados e extração de recursos.

3.1. Extração de recursos

Na previsão da poluição do ar, a análise de componentes principais (PCA) é um método de extração de características lineares muito comum para redução de dimensão. Encontrar novos mapeamentos ortogonais é

atingir o objetivo de que a variância dos pontos de mapeamento dos dados na direção seja a maior possível após a transformação, contendo assim uma quantidade maior de informações. Isso também pode ser considerado como transformação de base, que elimina a nova direção de base com menos informações e implementa redução de dimensionalidade.

A aplicação do PCA na previsão da qualidade do ar é geralmente em modelos híbridos. Mishra e Goyal combinaram PCA com ANN na previsão de dados de séries temporais para concentrações horárias de NO₂, em que o PCA foi usado para selecionar as variáveis de entrada importantes.

Então as variáveis seriam tomadas como entrada para realizar a predição pela RNA [54]. Sun et al. propuseram o PCA para extrair informações importantes e reduzir a dimensão das variáveis originais como o primeiro passo no processo híbrido para prever a poluição PM_{2.5} [77].

Lu et al. proposto como a rede PCA-RBF para prever as concentrações de RSP, NO_x e NO₂ de séries temporais, em que os resultados da comparação entre os modelos demonstram que o PCA-RBF pode atingir maior precisão e velocidade de treinamento mais rápida do que os modelos únicos [78]. Parte dos modelos híbridos está listada na Tabela 6. Pode-se concluir que a predição de abordagens híbridas supera seus métodos componenciais.

3.2. Decomposição de dados

No entanto, a precisão dos modelos inteligentes pode ser melhorada usando métodos de pré-processamento de dados. Na literatura revisada, a tendência atual é que os pesquisadores estejam aproveitando vários modelos híbridos, que em sua maioria começam com métodos de decomposição de dados que simplificam a sequência de componentes complexos. A estrutura, como mostrado na Fig. 6, é normalmente o processo de decomposição e integração. Ele usa métodos de decomposição para separar os dados de entrada originais de séries temporais em várias subséries e, em seguida, gera resultados de previsão relativamente independentes, estabelecendo modelos de previsão individuais, o que melhorou muito a precisão da previsão da qualidade do ar.

Depois de combinar todos os resultados da previsão, os resultados podem ser obtidos. Com o levantamento da literatura, as principais estratégias de decomposição aplicadas na previsão da qualidade do ar são apresentadas a seguir (ver Figs. 10 e 11).

3.2.1. Decomposição Wavelet

A transformada wavelet (WT) é um excelente método de análise de transformação da ciência e tecnologia da informação. Baseado na transformada de Fourier, é apropriado para análise e processo de tempo-frequência do sinal, em que o sinal é separado em diferentes faixas de frequência e extrai informações do sinal para se adequar aos requisitos da análise.

Tabela 5
Resumo parcial de modelos preditivos inteligentes para qualidade do ar.

Categorias	Vantagens	Desvantagens	Resolução de dados	Principais poluentes do ar	Parcialmente usado algoritmos e referências
Artificial neural rede	<ul style="list-style-type: none">• Bom aprendizado e construindo habilidades para resolver problemas complexos não lineares• alta precisão de classificação	<ul style="list-style-type: none">• Muitos hiperparâmetros ser ajustado que poderia afetar a previsão resultados• O processo de aprendizagem não pode ser observado• Possibilidade de extensão o tempo de aprendizado	De hora em hora, diariamente	PM2,5, PM10, O3, SO2, CO2, NO2 e CO	BPNN [39,94,95], RBFNN [40,96], GRNN [41,99], WNN [42,43], ENN [103–105]
Vetor de suporte máquina	<ul style="list-style-type: none">• Usando funções do kernel para resolva a dimensão problema• Evitar a seleção de estrutura de NN e local problema do ponto mínimo	<ul style="list-style-type: none">• Difícil para treinamento dados em grande escala• Sensível ao seleção de parâmetros e funções do kernel	De hora em hora, diariamente	PM2,5, PM10, O3, SO2, NO, NO2 e CO	SVM [109–111], SVR [106,108], LSSVM [44]
Lógica difusa modelo	<ul style="list-style-type: none">• Menos dependência de matemática precisa modelos• Boa tolerância a falhas e robustez• Fácil de conectar interface homem-máquina	<ul style="list-style-type: none">• O processo difuso pode reduzir o controle precisão e qualidade dinâmica	De hora em hora, diariamente	PM2,5, O3, SO2, CO, e NO2	FTS [115,116], ANFIS [45,46,118,119]
Extremo Aprendendo máquina	<ul style="list-style-type: none">• Adequado para não linear funções de ativação• Convergência rápida e velocidade de aprendizado mais rápida	<ul style="list-style-type: none">• O aleatório inicialização é controverso	De hora em hora, diariamente	AQI, NO, NO2, O3, PM10 e PM2,5	ELM [122]; OSELM [125,126]
Aprendizado profundo	<ul style="list-style-type: none">• Bom aprendizado de transferência propriedade e adaptabilidade• Grande capacidade de aprendizado	<ul style="list-style-type: none">• Verificação complexa de correção do modelo• Insuficiente interpretabilidade do camadas intermediárias• Velocidade de treinamento lenta	De hora em hora, diariamente	PM2,5, PM10, CO, NO2, NO, O3, SO2 e NH3	CNN [48,134,135], DBN [47,131,141], LSTM [49,129,130,138], GRU [139,140]

Tabela 6
Parte de modelos híbridos simples na previsão da qualidade do ar.

Modelos híbridos	Poluentes	Cidades	Resolução de dados	Modelos contrastantes	Grau de melhoriaa
PCA-ANN [54]	NO2	Taj Mahal, Agra	De hora em hora	MLP	31,88% (CC)
PCA-RBF [78]	RSP, NOx, NO2	Hong Kong	De hora em hora	RBF	RSP: 31,49% (MAE), 31,49% (RMSE) NOx: 34,24% (MAE), 34,23% (RMSE) NO2: 13,18% (MAE), 17,46% (RMSE)
PCA-CS-LSSVM[77]	PM2,5	Baoding	De hora em hora	GRNN, LSSVM	Fuyong: 5,23% (MAE), 3,43% (RMSE) Longhua: 2,14% (MAE), 2,15% (RMSE)

aO grau de melhoria é a partir dos índices de erro do modelo proposto e do melhor modelo contrastivo.

Cheng et al. modelos híbridos propostos para previsão de PM2.5. Com base no WT, os modelos decompõem os dados originais, então combine com preditores simples como ANN e SVM para prever dados para a série [79]. Por fim, a wavelet será utilizada para reconstruir os resultados de previsão das séries para obter os resultados. As melhorias de MAE, RMSE e R2 em modelos híbridos de previsão são visíveis na previsão de diferentes cidades quando comparado com ANN e SVM tradicionais. Em séries temporais práticas previsão, a transformada wavelet discreta (DWT) é processada em operação computacional em vez de WT contínuo e usado por muitos estudiosos [18,56,142]. Uma decomposição dos dados de entrada pode ser dividido em partes de diferentes frequências. As partes de baixa frequência A1, A2, . . . An são aproximações de dados de entrada, e as partes de alta frequência D1, D2, . . . Dn é a especificidade da entrada dados. No entanto, o DWT tem um problema com o sinal de entrada que a estabilidade dos coeficientes na transformada pode ser afetados pela área de análise nos dados originais. Para superar isso problema, uma versão melhorada do DWT, a sobreposição máxima

Transformada wavelet discreta (MODWT), também tem sido aplicada em previsão da qualidade do ar [80]. No processo WT, apenas os componentes de baixa cada camada será decomposta. Assim, em muitos casos, o útil informações de séries temporais nas partes de alta frequência podem ser ignorado. Comparado com o método WT, o pacote wavelet A decomposição (WPD) pode ser usada para decompor os coeficientes apropriados e os coeficientes detalhados para aumentar a precisão [81]. A comparação entre WT e WPD no processo da estrutura em decomposição é mostrado na Fig. 7 como o simplificado árvore binária com três camadas. Liu et al. aplicaram um modelo híbrido WPD-GBRT LPBoost-MLP-DPMM na previsão PM2.5 [82]. No processo de combinação, a árvore de regressão de impulso de gradiente (GBRT) é usado para selecionar a parte mais importante dos conjuntos de recursos originais. O algoritmo de reforço de programação linear (LPBoost) é um algoritmo de otimização para o peso do preditor e do MLP poderia conduzir a previsão determinística PM2.5 enquanto o Dirichlet modelo de mistura de processo (DPMM) poderia obter predição probabilística PM2.5 . Este modelo foi testado com poluentes em tempo real

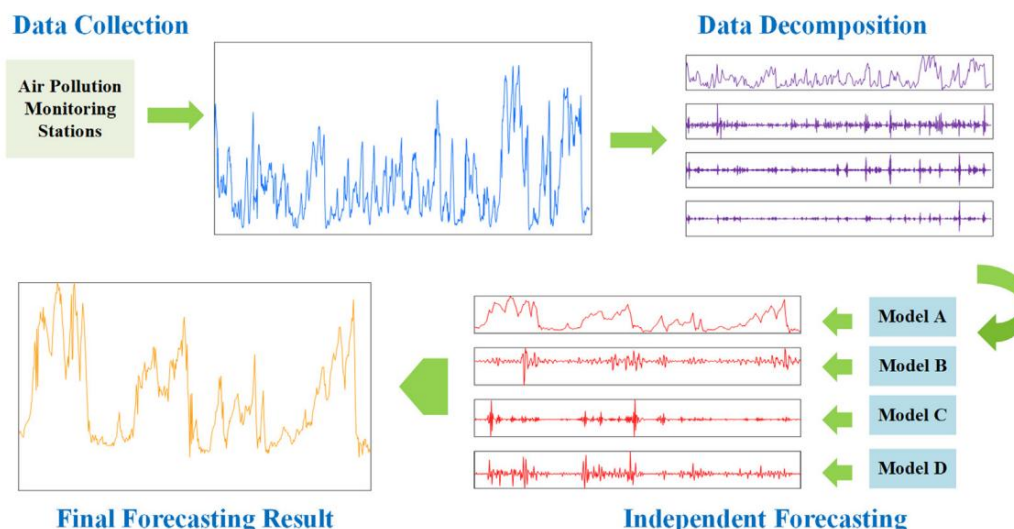


Fig. 10. O processo de decomposição e integração na previsão da qualidade do ar.

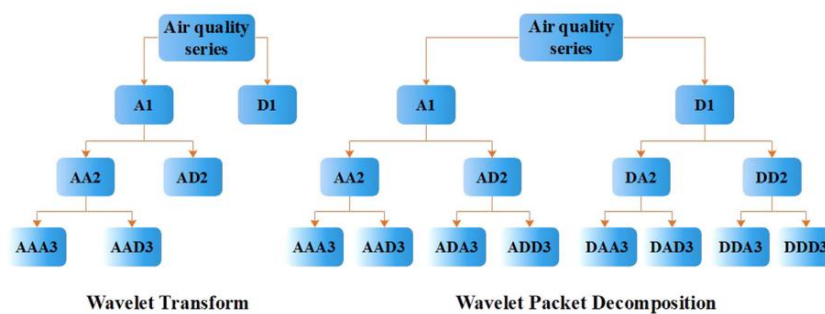


Fig. 11. A comparação entre WT de três camadas e WPD de estrutura em decomposição.

dados e comparados com outros algoritmos e modelos híbridos, como MLP, ARMA, WPD-MLP, WPD-LPBoost-MLP, WPD-GBRT MLP, WPD-GBRT-LPBoost-MLP para a previsão determinística e ARMA, ARMA-GARCH, WPD-GBRT-LPBoost-MLP-Gaussian para a previsão probabilística. Os resultados da Tabela 7 mostram que o modelo proposto tem a melhor precisão de previsão.

3.2.2. Decomposição EMD

Comparada com a escolha das funções wavelet e o ajuste dos níveis de decomposição por decomposição wavelet na predição, a decomposição em modo empírico (EMD) separa os sinais pelas características dos dados sem pré-ajuste das funções básicas [143]. Portanto, os sinais complexos serão decompostos adaptativamente em um número finito de funções de modo intrínseco (IMFs), contendo diferentes caracteres de escala de tempo local dos sinais originais.

Zhu et al. usaram modelos híbridos para prever os níveis de poluição em Xingtai. Com base no EMD, os IMFs com alta frequência serão removidos e os IMFs restantes serão usados como entrada no modelo LS-SVR e ARIMA sazonal para previsão (EMD-SVR-híbrido) [83].

Outro modelo é o EMD-FMIs-híbrido, no qual os FMIs serão modelados e previstos separadamente.

A decomposição de modo empírico de conjunto (EEMD) é um EMD aprimorado que acrescenta ruído branco ao sinal a ser decomposto e aproveita a distribuição uniforme no espectro de ruído branco para que o ruído branco de fundo possa se distribuir em todo o espaço de tempo-frequência por a aplicação.

Os ruídos se neutralizarão após a média múltipla e os resultados do cálculo podem ser considerados como o resultado.

Na previsão da qualidade do ar, o EEMD pode ajudar a determinar diferentes

escalas de informação distintas nos dados originais e evitar a mistura de modos de forma eficaz [84,85]. Bai et al. propuseram um modelo EEMD-LSTM para previsão de concentração de PM_{2.5} e Niu et al. propôs EEMD-PSR-LSSVM para previsão de concentração de PM_{2.5} para o dia seguinte, na qual os resultados foram satisfeitos em comparação com os modelos individuais separados.

Ao adicionar ruído para análise em EEMD, também pode trazer certo grau de dano ao sinal original e o ruído residual não pode ser completamente neutralizado, o que eleva as complexidades computacionais e enfraquece a eficiência. Para resolver esse problema, a decomposição de modo empírico de conjunto complementar (CEEMD) é utilizada para melhorar o pré-processamento. Tanto o ruído branco positivo quanto o negativo com a mesma amplitude foram anexados em pares para que o ruído redundante seja amplamente eliminado quando o sinal for reconstruído. O CEEMD tem sido usado em artigos para decompor dados de poluentes atmosféricos em modelos híbridos e alcançar melhor precisão de previsão do que EMD e EEMD [86,87], conforme mostrado na Tabela 8 a seguir. Niu et al. propuseram o modelo para previsão de concentração de PM_{2.5} de curto prazo, em que o SVR otimizado pelo algoritmo de otimização do lobo cinzento (GWO) é o preditor [144].

A decomposição de modo empírico de conjunto completo com ruído adaptativo (CEEMDAN) é a versão atualizada do CEEMD.

A característica principal do CEEMDAN é a adição de ruído adaptativo em comparação com o EEMD, mas ainda tem problemas que os modos possuem algum ruído residual e vários modos espúrios estão na fase inicial de decomposição por parâmetros inadequados. Assim, o CEEMDAN melhorado (ICEEMDAN) foi introduzido e aplicado para decompor os dados de entrada dos níveis de poluentes do ar [145,146].

Sharma et al. aplicaram os modelos híbridos para previsão horária em

Tabela 7

Os resultados de previsão determinística horária dos modelos no 1-step [82].

Modelos	MUITO DE	MAPA	RMSE	I A
MLP	15,4043	24,0740	20,9419	0,8784
WPD-MLP	16,1768	26,5835	21,6145	0,8704
WPD-LPBoost-MLP	12,1657	18,6309	16,2762	0,9265
WPD-GBRT-MLP	13,6102	21,4844	18,3437	0,9067
WPD-GBRT-LPBoost-MLP	10,4672	16,7833	13,5670	0,9490

Tabela 8

Comparação dos resultados da previsão usando diferentes modelos [144].

Modelos	Cidade 1			Cidade 2		
	MSE	MAPA	MUITO DE	MSE	MAPA	MUITO DE
SVR-GWO	0,2196	23,1163	5,5300	0,1303	27,1406	9,0079
EMD-SVR-GWO	0,1233	19,7902	4,2689	0,1444	27,4051	8,7655
EEMD-SVR-GWO	0,0648	14,7810	3,1177	0,0473	16,3081	5,3451
CEEMD-SVR-GWO	0,0412	10,6033	2,4103	0,0186	10,4454	3,1741

Tabela 9

Melhorar as porcentagens de grupos de comparação na previsão de 1 etapa [88].

O modelo proposto vs.	PMSE(%)	PMAP (%)	PRMSE(%)
AMI-H / LSAE-DESN	80.047	78.654	81.040
VMD-H/LSAE-DESN	82.343	80.975	82.622
VMD-AMI-DESN	61.004	60.578	63.517

Tabela 10

A porcentagem da frequência de aplicação dos métodos de decomposição.

Tipo de decomposição	Frequência	Por cento
WT	8	30,77%
EMD	9	34,62%
VMD	2	7,69%
EWT		11,54%
Híbrido	3	15,38%
Total de artigos	4 26	100%

Austrália combinando ICEEMDAN com diferentes preditores [147]. Em modelos preditivos híbridos, os estudiosos compararam e escolheram com EMD, EEMD, CEEMDAN e ICEEMDAN de acordo com suas necessidades práticas e efeitos de previsão. O processo de aperfeiçoamento de o EMD e suas variações são apresentados na Fig. 8.

3.2.3. Outra decomposição simples

Um método de decomposição prevalente e eficaz é a decomposição de modo variacional (VMD) [148]. Comparado ao EMD decomposição, o VMD tem excelente resistência ao ruído, melhor desempenho de composição e estabilidade e também pode ser utilizado para extração de recursos e diagnóstico de falhas. No ar prático processo de previsão de qualidade, o VMD pode funcionar com outros métodos de otimização para obter resultados de separação precisos [58,149]. Xu et al. construiu o modelo VMD-AMI-H/LSAE-DESN e realizou uma análise comparativa, e os resultados na Tabela 9 mostrou que cada componente também contribuiu para o desempenho de o modelo [88].

A transformada wavelet empírica (EWT) é uma abordagem de decomposição acoplando as vantagens de EMD e transformada wavelet [150], que pode dividir autonomamente o espectro de Fourier e separar os diferentes modos e construir filtros de passagem de banda adaptáveis para decompor os dados e extrair diferentes componentes úteis. Devido à sua boa adaptabilidade e para a capacidade de aprendizagem, algumas referências tendem a tomar EWT como uma parte importante de modelos complexos para decompor a série de poluentes do ar [151.152]. Liu e Chen construíram o modelo híbrido HI-EWT-NNA-WRELM-IEWT para a previsão de PM2,5 [128]. As etapas de processamento deste modelo híbrido são da seguinte forma: a primeira etapa utilizou o identificador Hampel (HI) para corrigir a correção discrepante dos dados originais, então EWT

decompõe os dados em várias subséries. WRELM conduziu previsão de várias etapas para cada subsequência como a terceira etapa com e otimização do algoritmo de rede neural (NNA). No por último, o IEWT reconstruiu a subsérie para gerar a resultados de previsão. Além disso, os resultados experimentais mostram que a precisão de previsão deste modelo é muito maior do que outros modelos de benchmark, por exemplo, as melhorias do #1 séries são 66,70% (MAPE), 66,70% (MAE), 68,00% (RMSE).

3.2.4. Decomposição híbrida

Para obter um melhor desempenho da decomposição no No processo de predição, muitos pesquisadores desenvolveram métodos de decomposição híbrida, como a decomposição secundária (SD). Normalmente, através da decomposição em duas camadas, os algoritmos de decomposição híbrida podem extrair mais informações dos dados originais série do que a simples decomposição, de modo que a previsão total modelo pode alcançar maior precisão e obter melhor desempenho. Escolher os componentes decompostos apropriados é um impacto essencial na decomposição híbrida. Gan et al. propôs um híbrido modelo combinando WPD e CEEMD como decomposição [153]. o O WPD decompõe a série de dados original em componentes de tanto de baixa frequência como de alta frequência. O CEEMD é usado como técnica de decomposição de segunda camada para decompor continuamente componentes de alta frequência. Dessa forma, os modelos híbridos de uma estrutura de duas camadas pode ser eficaz para resolver a decomposição problema.

Outros estudiosos também propuseram muitas decomposição híbrida métodos. Por Wang et al. o CEEMD é usado como a primeira camada para decompor a série do índice de qualidade do ar em IMFs de diferentes frequências e o VMD seguirá para decompor o IMFs de alta frequência em modos de variação (VMs) para eliminar resultados de previsão insatisfeitos [154]. Wang et al. também empregado VMD como a decomposição da segunda camada, mas WT como a primeira camada é definida para desmontar a série de concentração original PM2.5 [155]. A análise de espectro singular (SSA) foi aplicada para otimizar os componentes e remover ruídos redundantes no sinal original [89]. Na referência, decomposição simples de EEMD e nenhuma decomposição em modelos de referência foi usada para experimentos de comparação. É conhecido pela experiência resultados indicaram que o modelo de decomposição híbrida tem melhor precisão de previsão do que outros fazem (veja a Fig. 12).

A Tabela 10 apresenta a frequência de aplicação dos métodos de decomposição. De acordo com as tabelas, as tendências atuais pode ser encontrado que WT e EMD são usados com mais frequência do que outros. Além disso, as estratégias híbridas foram tomadas na consideração para estudos nos últimos anos. O de cima estratégias de decomposição híbrida têm se mostrado eficazes na aspecto de precisão e estabilidade. No entanto, com o aumento de subséries e camadas da estrutura do modelo, a carga de computação

Tabela 11

Um resumo das abordagens de decomposição em modelos híbridos de previsão da qualidade do ar.

Categoria	Subcategorias	Abordagens e referências aplicadas
Decomposição	Decomposição Wavelet	Especialidades • Boa localização abrangendo o domínio do tempo e domínio da frequência para descrições completas • Recursos de multirresolução são adequados para análise de séries temporais • Confie na estrutura de decomposição formada pela função wavelet e níveis de decomposição
	Decomposição EMD	• Adequado para analisar sequências de sinal não lineares e não estacionárias • Desvantagens da mixagem de ponto final e modo em EMD • Versões aprimoradas foram desenvolvidas para aprimorar a capacidade de previsão
	Outra decomposição simples	• Excelente resistência ao ruído, desempenho de decomposição e estabilidade • EWT combina as vantagens de EMD e WT
	Decomposição híbrida	• Combine com diferentes métodos como decomposição secundária • Obtenha maior precisão e melhor desempenho de previsão • Pode levar a mais tempo de computação
		WT [79], DWT [18,56,142,156], MODWT [80], WPD [53,82]
		EMD [83], EEMD [84], CEMD [57,86,144], ICEMDAN [145–147]
		VMD [58.149.154.155], EWT [128.151.152]
		WPD + CEEMD [153], CEEMD + VMD [154], WT + VMD [155], VMD + CEEMD [149], EEMD + SSA [89]

também pode aumentar consideravelmente. Assim, é necessário um compromisso entre a precisão do cálculo e o tempo de execução na aplicação de abordagens de decomposição secundária. A [Tabela 11](#) conclui os métodos acima com as subcategorias, especialidades e abordagens aplicadas nas referências.

4. Método auxiliar I: Otimização metaheurística

Embora os modelos preditivos simples e os métodos de processamento de dados possam aprimorar muito as habilidades dos modelos inteligentes, o desempenho da previsão pode ser melhorado ainda mais na estrutura e nos hiperparâmetros. Os algoritmos de otimização metaheurística visam otimizar ainda mais os dados originais. Todo o processo de entrada de dados é uma típica seleção de recursos, em que algoritmos metaheurísticos são usados para gerar dados de entrada e os dados serão usados como amostras de treinamento para previsão de resultados.

4.1. Algoritmo heurístico e metaheurístico

Os algoritmos heurísticos são uma espécie de algoritmos construídos de forma intuitiva ou empírica que fornecem uma solução viável para problemas específicos a serem resolvidos. Os algoritmos metaheurísticos são o aperfeiçoamento dos algoritmos heurísticos, que são a combinação de algoritmos aleatórios e algoritmos de busca local como estratégias heurísticas gerais. Muitos algoritmos metaheurísticos simulam os fenômenos biológicos ou físicos da natureza em estruturas matemáticas para resolver problemas [157]. Alguns algoritmos metaheurísticos usados em modelos de previsão da qualidade do ar são demonstrados na [Fig. 13](#).

Os algoritmos heurísticos são os métodos que dependem do problema. Portanto, eles geralmente se adaptam ao problema atual e tentam aproveitar ao máximo a particularidade desse problema.

No entanto, eles geralmente caem em um estado ótimo local e, portanto, geralmente não podem obter uma solução globalmente ótima. Embora os algoritmos metaheurísticos sejam diferentes no mecanismo, eles são métodos independentes do problema. Eles não são tão gananciosos que lhes permitam explorar o espaço de solução mais completamente e repetir até que o critério de convergência seja bom o suficiente para obter as soluções ótimas [158]. Ainda é necessário fazer alguns ajustes em seus parâmetros internos principalmente nos hiperparâmetros, como número de iterações, número de camadas ocultas, número de neurônios em cada camada, taxa de aprendizado, etc.

O algoritmo genético (AG) é um método de busca de soluções ótimas por meio da simulação da seleção evolutiva natural, visando todos os indivíduos da população. A otimização do enxame de partículas

(PSO) também é um método de otimização baseado em população desenvolvido pela simulação do comportamento coletivo das aves para obter a solução ideal [59,159]. Na Ref. [160], semelhante ao AG, o algoritmo de evolução diferencial (DE) é utilizado para a busca global de otimização em modelos híbridos. Outros algoritmos metaheurísticos, como busca de cuco (CS) [62.161], algoritmo de morcego (BA) [162] e otimizador de lobo cinzento (GWO) [90], também têm sido comumente utilizados para melhorar o desempenho da previsão. A combinação de algoritmos metaheurísticos pode melhorar ainda mais os parâmetros baseados na complexidade de modelos híbridos, como algoritmo de busca gravitacional e otimização de enxame de partículas (PSOGSA) e algoritmo de busca e evolução diferencial de cuco modificado (MCSDE).

4.2. Classificação por objetos otimizados

De acordo com os objetos otimizados da aplicação em modelos de previsão de qualidade do ar, os algoritmos de otimização metaheurística podem ser ainda classificados em dois tipos: (1) métodos de otimização de pesos de combinação e (2) métodos de otimização de parâmetros em preditores.

4.2.1. Métodos de otimização de pesos de combinação

A aplicação de modelos híbridos é tirar vantagem de cada modelo de previsão, evitando suas fraquezas. Um método é obter a combinação do coeficiente de peso de cada modelo. O algoritmo de otimização metaheurística é aplicado para buscar os pesos de combinação ideais dos modelos individuais, para que os resultados ótimos previstos da previsão da qualidade do ar possam ser alcançados. O fluxograma do processo é mostrado na [Fig. 14](#).

Yang et al. propôs um sistema de previsão de combinação de decomposição de dados, otimização metaheurística e modelos de previsão individuais [161]. Os preditores básicos do modelo proposto incluem três preditores: BPNN, ELM e suavização exponencial dupla (DES). O algoritmo de busca de cuco (CS) usado no artigo pode determinar os pesos de combinação para agregação do modelo e os resultados mostram que a otimização do CS pode aumentar ainda mais a precisão da previsão e a estabilidade do modelo. A análise de sensibilidade também foi realizada para analisar o impacto dos hiperparâmetros nos resultados e sua configuração ideal, incluindo o tamanho da população, número máximo de iterações e taxa de descoberta.




Fig. 12. O processo de desenvolvimento do EMD e versões melhoradas.

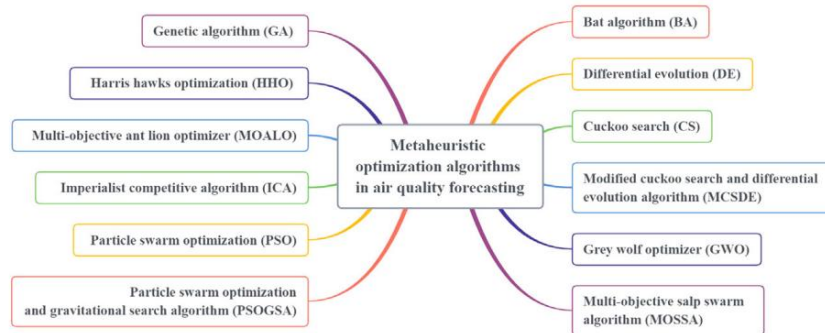


Fig. 13. Os mecanismos dos algoritmos metaheurísticos utilizados em modelos de previsão da qualidade do ar.




Fig. 14. O fluxograma do processo de otimização de pesos de combinação.




Fig. 15. O fluxograma do processo de otimização dos parâmetros do modelo.

4.2.2. Métodos de otimização de parâmetros em preditores

A otimização metaheurística também pode ser aplicada na combinação com outros preditores, cujos parâmetros são otimizados com métodos metaheurísticos, para tornar os preditores adequados aos conjuntos de dados de entrada. O conjunto de dados de entrada geralmente é dividido em três partes: o conjunto de treinamento, o conjunto de validação e o conjunto de teste. Os parâmetros com o menor erro por otimização meta-heurística no conjunto de validação são escolhidos como parâmetros ótimos. O fluxograma do processo é mostrado na Fig. 15.

Recentemente nos estudos de previsão da qualidade do ar, a maioria dos modelos ótimos tem sido propostos com a teoria da combinação de parâmetros. O peso inicial e o limiar geralmente são usados como parâmetros para otimização. Du et al. propôs o algoritmo de otimização multi-objetivo de Harris Hawks (MOHHA) para otimizar o peso e o limiar de ELM [163]. O otimizador de leão de formiga multiobjetivo (MOALO) é uma versão melhorada do otimizador de leão de formiga (ALO) para obter uma solução ótima global mais precisa por meio de muitos cálculos iterativos. O MOALO foi usado para construir a previsão SSA-EEMD-MOALO- L2.1RFELM

modelo, do qual o L2.1RFELM é uma versão melhorada do otimizado para previsão PM2.5 por MOALO [89]. Pode-se concluir pelos resultados da Tabela 12 que o MOALO contribuiu para o aumento do modelo híbrido.

Para melhorar a capacidade de aplicação dos preditores, algoritmos de otimização metaheurística também têm sido utilizados para otimizar outros parâmetros importantes nos modelos híbridos. Wu et al. usaram o algoritmo Bat (BA) para otimizar os dois parâmetros, ou seja, o coeficiente de penalidade c e o parâmetro de kernel γ no LSSVM para melhor adaptabilidade e precisão [162]. Por Xing et al. o algoritmo de otimização do lobo cinzento modificado (MGWO) é proposto, que possui boa convergência não linear e robustez computacional, para melhorar os parâmetros da estrutura DBN [141]. Comparado a outros modelos como BPNN, SVM e floresta aleatória, o modelo DBN obteve melhores resultados com o menor MAE ($17,604 \mu\text{g}/\text{m}^3$) e MSE ($410,266 \mu\text{g}^2/\text{m}^6$). Sun et al. propôs o LSSVM para otimizar os parâmetros do LSSVM e prever a poluição PM2.5, e o PCA extrai informações importantes e reduz a dimensão das variáveis originais como o primeiro passo no processo híbrido [77]. O LSSVM melhorou

Tabela 12
Comparação dos resultados de previsão de PM2.5 de diferentes modelos [89].

Modelos	Cidade 1			Cidade 2		
	MAPA	MUITO DE	RMSE	MAPA	MUITO DE	RMSE
L2,1RFELM	9,8328	2,9938	4,4955	5,6780	1,1164	1,6233
MOALO-L2,1RFELM	9,6955	2,9843	4,4070	5,5808	1,1004	1,6095
EEMD-MOALO-L2,1RFELM	3,7076	1,0804	1,6058	2,7503	0,5191	0,6755
SSA-EEMD-MOALO- L2,1RFELM	3,6465	1,0598	1,4796	2,6965	0,5028	0,6698

Tabela 13
Os parâmetros otimizados em preditores na previsão da qualidade do ar.

Parâmetros otimizados	Preditores
Peso inicial e limite	BPNN [62,89,146,160,164], ELM [163,165], L2,1RFELM [89], ENN citar90.149
Coefficiente de penalidade e parâmetro do kernel	SVM [59,159], SVR [57,86,144], LSSVM [77,162,166]
Outros	Parâmetros de estrutura de DBN [141]

por CS parece ser muito atraente e mostra um grande grau de melhora nos resultados de 23,53% no MAE, 26,76% no MAPE, e 33,47% em RMSE. Os parâmetros otimizados em preditores são listados na [Tabela 13](#).

5. Método auxiliar II: Aprendizagem em conjunto

O aprendizado conjunto é um método importante em modelos inteligentes para previsão da qualidade do ar, que constrói múltiplas modelos por certos algoritmos e, em seguida, combina-os com um determinada estratégia para obter um modelo poderoso para completar o tarefa e melhorar os resultados da previsão. Para atingir esse objetivo, existem atualmente três métodos populares aplicados na previsão da qualidade do ar: Impulsionar, ensacar e empilhar.

5.1. Acondicionamento

O princípio do Bagging é a amostragem aleatória, que consiste em coletar um número fixo de amostras em nosso conjunto de treinamento. Essas amostras será usado em treinamento paralelo em modelos fracos que serão integrados em um modelo poderoso por meio de estratégias específicas. Aleatório Forest (RF) é uma versão evolucionária do algoritmo Bagging, que pode lidar com problemas lineares e não lineares sem preocupação das variáveis independentes ou dependentes. Formado por um número projetado de árvores de decisão binárias, os RFs usam amostras subconjuntos coletados independentemente de árvores únicas para agregar e otimizar os resultados das previsões finais para a poluição do ar [167].

No estudo de previsão dos níveis de poluentes atmosféricos na Região de Múrcia (Espanha), usando o Bagging, Random Committee, Random Forest, uma árvore de decisão e uma técnica baseada em instâncias foram utilizadas para conduzir a pesquisa com conjuntos de dados de dois anos e comparar os resultados por meio de índices como MAE e RMSE [168]. Dotse et al. propôs um modelo híbrido GA-RF-BPNN para prever Excedentes dos níveis de PM10 [64]. O modelo combina GA e RF para pré-processamento para selecionar variáveis de entrada antes do treinamento de dados no BPNN e produz melhores resultados ([Tabela 14](#)) no desenvolvimento de um sistema de previsão em tempo real. Philibert et al. também adotou Random Floresta para prever uma emissão de gases de efeito estufa N2O usando dados meteorológicos e de colheita [169]. Para uma validação precisa, o resultados foram comparados com o modelo de regressão e o simples modelo não linear. O melhor resultado no RMSE do melhor modelo pode chegar a 11,34% do que o modelo comparado.

Tabela 14
Comparação dos resultados da previsão usando diferentes modelos [64].

Modelos	Estação 1			Estação 2		
	CC	I A	RMSE CC	I A	RMSE	
BPNN	0,9223	0,9563	0,9266	4,0057	0,9072	0,9468
GA-BPNN	0,9612	0,9727		3,9080	0,9113	0,9490
GA-RF-BPNN	0,9502			3,2942	0,9397	0,9677

5.2. Impulsionando

Impulsionar refere-se a converter vários alunos fracos em um modelo preditivo forte através de um conjunto de algoritmos. Adaptativo Boosting (AdaBoost) é um algoritmo iterativo comumente usado de impulsionando. Após cada iteração, um novo aprendiz é gerado e as amostras serão previstas. Com base no desempenho do treinamento, as amostras com erro de previsão podem ser atribuídas um peso maior que quanto maior o peso, maior o proporção da próxima iteração é. Liu et al. desenvolveu o modelo WPD PSO-BP-Adaboost na previsão de concentração de PM2,5 , em qual Adaboost treina o aluno fraco feito pelo PSO-BP modelo [53]. Comparado com o modelo WPD-PSO-BP, o MAPE foi reduzido em 18,79%, 20,89% e 6,28% em 1 etapa, 2 etapas e Previsão em 3 etapas e isso significa que o modelo híbrido proposto tem um aumento significativo na precisão, garantindo a estabilidade por adicionando Adaboost. Liu e Chen propuseram um novo modelo híbrido para previsão do índice de qualidade do ar [170], em que Adaboost.MRT, como uma versão atualizada do Adaboost, foi usado para melhorar a desempenho do preditor de base ORELM em cada subsérie. Então o os resultados de todas as subséries são combinados para alcançar o resultado final da previsão. A estrutura da estratégia Boosting é apresentada na [Fig. 16](#).

5.3. Empilhamento

O empilhamento é um algoritmo diferente do ensacamento e aumento. A principal característica é integrar os resultados de algoritmos anteriores, ou seja, um framework baseado nos aprendizes fracos, que combina os alunos fracos anteriores com um aprendizado de máquina algoritmo. Sun e Li propuseram um modelo de conjunto orientado por empilhamento para obter resultados de previsão precisos de preditores básicos e os resultados são considerados como a entrada do meta-modelo SVR, para obter o resultado final resultados de previsão [171]. Zhai e Chen também projetaram um empilhador modelo de conjunto para prever PM2,5 em Pequim, China [65]. Individual modelos, incluindo o menor encolhimento absoluto e operador de seleção (LASSO), Adaboost, extreme gradient boosting (XGBoost) e GA MLP, são para realizar treinamento de dados por camadas e a saída será integrado ao SVR pelo processo empilhado. Os resultados mostram que o modelo ensemble tem melhor desempenho, em comparação com o melhores resultados de modelos simples no conjunto de teste, incluindo IA (1,04%), MAE (18,98%), RMSE (6,91%). A estrutura da estratégia de empilhamento é demonstrada na [Fig. 17](#). [A Tabela 15](#) apresenta a aplicação frequência dos métodos de aprendizagem em conjunto. De acordo com tabelas, as tendências atuais podem ser encontradas que a frequência do A aplicação de ensacamento é igual à soma de Boosting e Stacking. Em artigos recentes, os estudiosos tendem a escolher o Boosting e Empilhamento para as estratégias híbridas [53,65,170,171].




Fig. 16. A estrutura proposta da estratégia Boosting na Ref. [170].

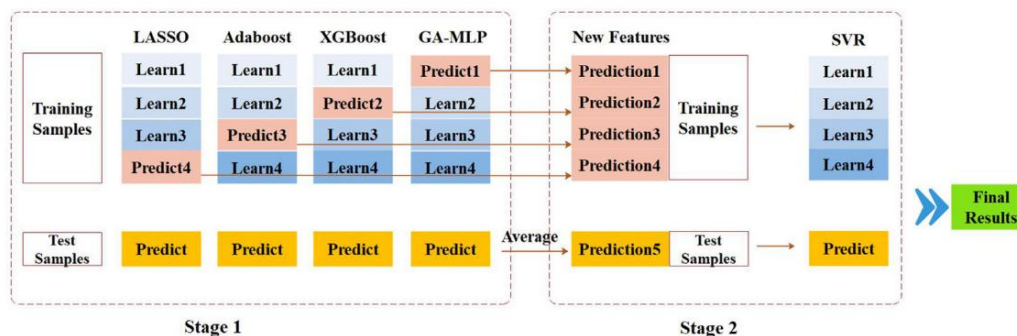


Fig. 17. A estrutura proposta da estratégia de empilhamento na Ref. [65].

Tabela 15

A porcentagem dos melhores resultados de aprendizagem em conjunto.

Tipo de método	Frequência	Por cento
Acondicionamento	4	50%
Impulsionando	2	25%
Empilhamento	2	25%
Total de artigos	8	100%

6. Análise espaço-temporal para estratégias de modelagem

Devido à complexidade da poluição do ar, a previsão das concentrações de poluentes é facilmente afetada por muitos fatores em horários e locais. Estudos anteriores para previsão de concentrações de poluentes atmosféricos baseiam-se nos dados de séries temporais do índice de qualidade do ar (AQI) emitidos regularmente por estações de monitoramento da qualidade do ar de cidades ou regiões específicas. Porque os poluentes do ar têm a propriedade de difusão regional, pesquisa de qualidade do ar com base em cidades tem grandes limitações, que podem ser afetadas pela geografia processo, situação atmosférica ou outros fatores.

Portanto, é necessário analisar a correlação interna da qualidade do ar entre as cidades alvo e o meio envolvente numa perspectiva regional ou nacional, nomeadamente as características temporais e espaciais das informações meteorológicas relacionadas à qualidade do ar devem ser levadas em consideração. o impactos mais importantes em modelos espaço-temporais de artigos são análise de dados múltiplos, modelos individuais melhorados, e modelos híbridos espaço-temporais, e o resumo parcial de os artigos citados nesta revisão são apresentados na Fig. 18.

6.1. Análise de dados múltiplos

Vários dados de muitas estações na área de destino oferecem uma variedade de escolhas e possibilidades comparativas de previsão. Awad et al. utilizou os dados de 368 monitores de 12 anos no Estados da Nova Inglaterra (EUA) para analisar a interação espaço-temporal da concentração ambiente de Carbono Negro (BC) [66]. Com o grande quantidade de dados de 368 estações de monitoramento em 12 anos, o experimento e a análise podem ser conduzidos que mais repetidos

medições e monitoramento levam à obtenção de características temporais mais completas. Um modelo de regressão do uso da terra é aprimorado pela aplicação de um nu-SVR e um modelo aditivo generalizado é aplicado para reajustar os resíduos do nu-SVR. A análise espacial de características de transporte, topográficas e de vizinhança também contribuíram para a previsão juntamente com os termos temporais. O modelo é testado em estações frias e quentes em comparação com dados reais.

Quanto à análise de vizinhança ou distância, Kurt e Oktay descreveu três modelos de previsão geográfica usando RNA pelo dados de poluentes de 10 estações de monitoramento diferentes em Istambul, como mostrado na Fig. 19 [67]. O modelo de vizinhança de site único usou os dados de poluição do ar de um ou mais distritos próximos como entrada extra para o distrito alvo. No entanto, o modelo de bairro de dois locais teve como alvo dois distritos vizinhos objeto em vez de um. Diferente dos dois acima, o modelo baseado em distância fez a média dos dados de poluentes atmosféricos com o peso de distâncias em três bairros vizinhos para calcular a influência combinada para o espaço central, que também indicou a melhor desempenho do que outros modelos durante a análise comparativa.

Para melhor dividir a área de pesquisa e aplicar dados de poluentes, uma grade de $0,1 \times 0,1$ \bar{y} (98341 células no total) em toda a China foi aplicado para a previsão diária de O₃ na Ref. [68]. O aleatório floresta foi proposta para prever as distribuições espaço-temporais O₃ na China por informações meteorológicas de 1608 locais de monitoramento todo o país em 2015 e os resultados seriam ainda somados e ponderados por épocas, regiões e distritos de grande população. As variáveis meteorológicas respondem por 65% do precisão preditiva para os recursos preditivos. Nesse artigo, emissões antropogênicas (NH₃, Carbono Orgânico, CO e NO_x) apresentam importância comparativamente menor do que a meteorologia, e menor precisão é apresentada para a área com pouco monitoramento estações. Assim, a precisão depende da complexidade do rede.

Wen et al. também utilizou um método para extrair eficientemente as correlações espaço-temporais e melhorar a capacidade de previsão [172]. o foram coletados dados de 1.233 estações de monitoramento da qualidade do ar em período de dois anos. Com base no algoritmo de k-vizinhos mais próximos (KNN), as estações adaptativas k-vizinhos mais próximas em estações únicas foram selecionadas para garantir o parentesco de modo que a CNN e

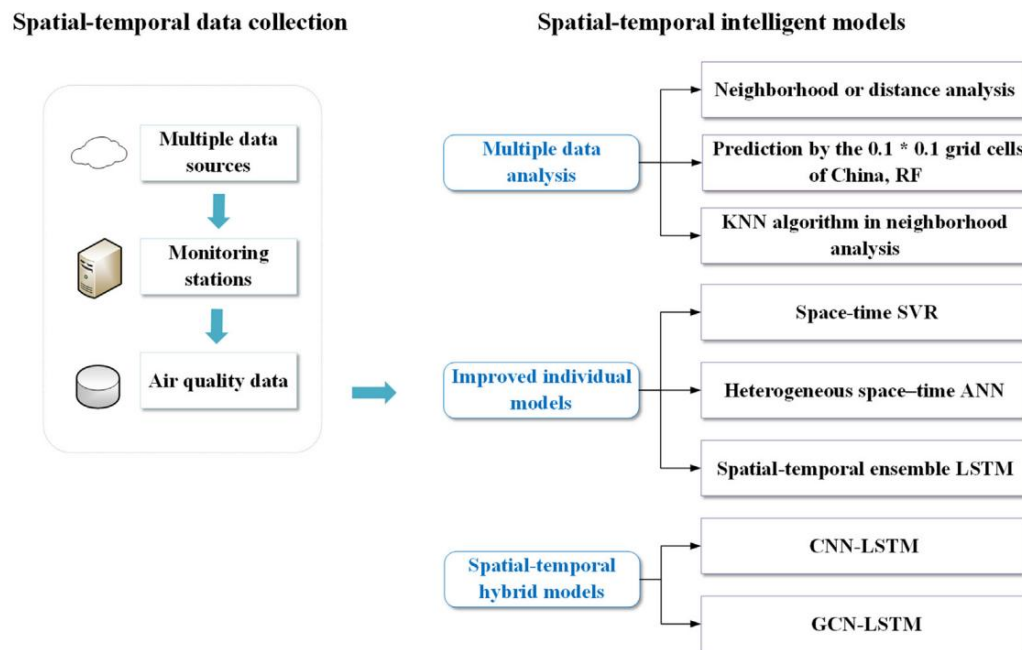


Fig. 18. Um resumo parcial de modelos inteligentes espaço-temporais na previsão da qualidade do ar.

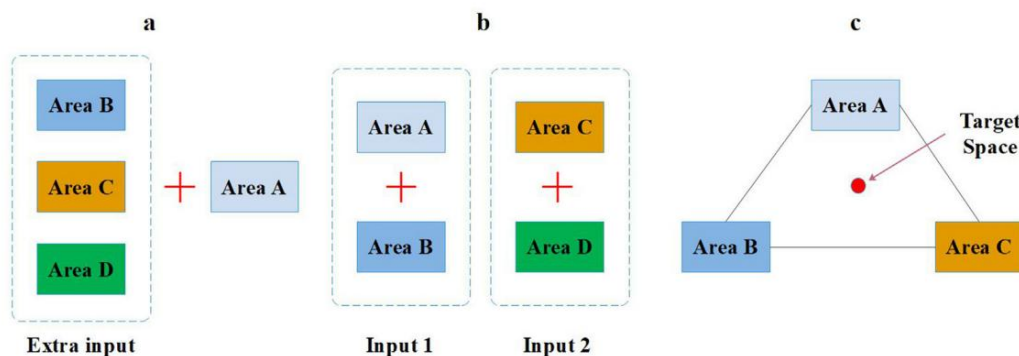


Fig. 19. Um resumo gráfico de três modelos de previsão geográfica. (a) Modelo de vizinhança de um local (b) Modelo de vizinhança de dois locais (c) Modelo baseado em distância [67].

Modelos LSTM podem ser utilizados para extrair características espaço-temporais.

Os dados de poluição do ar podem ser coletados por estações de monitoramento em todo o país, a Fig. 20 mostra as localizações atuais de 1.635 estações de monitoramento de qualidade do ar na China, que são semelhantes aos estudos acima e realizam um melhor entendimento da distribuição geográfica e qualidade do ar. Os locais podem ser selecionados aleatoriamente como alvos de previsão para testar a eficácia do modelo proposto. [68]. Eles estão nas cidades de Pequim, Xangai, Chengdu, Guangzhou, Lasa e Urumqi cujos códigos são 1004A, 1143A, 1352A, 1435A, 1460A e 1493A.

6.2. Modelos individuais aprimorados

Em pesquisas recentes sobre poluentes atmosféricos, o estudo da correlação espacial é uma direção de previsão não negligenciável. Começando com a metodologia, muitos estudiosos ofereceram novas estruturas de modelos individuais baseados na dependência espacial. Uma extensão do modelo de dados não espaciais para dados geoespaciais foi proposta na Ref. [69]. Com a consideração de fatores espaciais, foi desenvolvido um modelo de regressão de vetores de suporte espaço-tempo (STSVR) em que a análise de agrupamento espacial e variáveis de autocorrelação espacial foram adicionadas à estrutura, visando aumentar

correlação e dependência. Uma RNA espaço-tempo heterogênea foi projetada para a previsão de PM2.5 que tanto a dependência espaço-tempo quanto a heterogeneidade foram adicionadas à estrutura de feedback, resultando em melhores valores de avaliação do que a RNA tradicional e o modelo híbrido [91].

Wang e Song propuseram um modelo de 3 etapas com uma estratégia de conjunto espaço-temporal profunda (STELSTM) [173]. O primeiro passo é estabelecer um método de ensemble baseado em padrões climáticos e estratégia de particionamento. Em seguida, o segundo passo é explorar a correlação espacial das estações vizinhas. Por fim, o LSTM combina os dados locais e vizinhos para funcionar como preditor temporal. Ma et al. definiram uma Geo-camada na rede neural LSTM para uma análise espacial abrangente para que a correlação espaço-temporal das estações de monitoramento relativas pudesse ser integrada ao modelo [70]. Após a seleção da Geo-camada, as informações de 37 estações de monitoramento da área, que possuem correlações mais fracas, serão removidas. O modelo Geo-LSTM pode interpolar a distribuição espacial dos poluentes atmosféricos, o que significa que os impactos espaciais e temporais dos poluentes atmosféricos serão inclusivos ao mesmo tempo. Além disso, comparado com outros modelos, como ANN, RNN, RF, SVR, LSTM comum, o modelo Geo LSTM proposto possui o menor RMSE. As melhorias de RMSE para o LSTM comum atingiram mais de 42%.

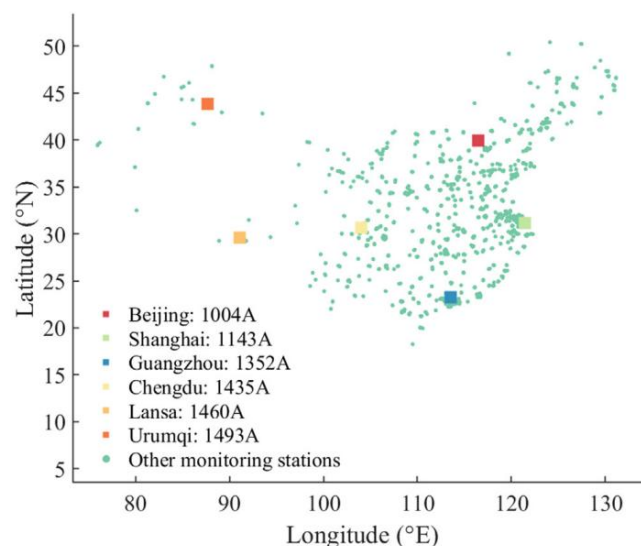


Fig. 20. Localização das estações de monitoramento da poluição do ar.

Tabela 16

A porcentagem dos melhores resultados do ELM.

Tipo de modelo	Frequência	Por cento
Análise de dados múltiplos	4	36,36%
Modelos individuais aprimorados	4	36,36%
Modelos híbridos espaço-temporais	3	27,28%
Total de artigos	11	100%

6.3. Modelos híbridos espaço-temporais

Além do pré-processamento de dados e modelos individuais aprimorados, existem alguns outros modelos híbridos no aplicativo. Cada parte do modelo é projetado para realizar funções específicas ou visar tipos específicos de informações. O processo geral está presente em Fig. 15. Pak et al. utilizou o modelo híbrido CNN-LSTM para prever a níveis diários de PM_{2,5}. Após a análise de correlação espaço-temporal pelo estimador de informação mútua (MI), o vetor de características espaciais de saída (STFV) foi construído [71]. Então a CNN começou a extrair as características inerentes importantes da entrada e o LSTM foi usado para lidar com a integração do tempo de recurso série passou a CNN para representar o processo histórico de longo prazo de dados temporais de entrada e formam a saída final da previsão.

Baseado na capacidade de reconhecimento de imagem para processamento de dados espaciais e ótimo desempenho no processamento de dados de séries temporais, alguns pesquisadores combinaram diretamente CNN e LSTM como um híbrido modelo para realizar experimentos de previsão da qualidade do ar. Qin et al. utilizou a CNN para extrair características espaciais e reduzir a redundância do conjunto de dados de Xangai que contém dados em três anos como o primeiro passo, então o LSTM pode lidar com informações de séries temporais [72]. Comparado com outros modelos (BPNN, CNN, RNN, LSTM), os resultados de experimentos (épocas = 100) apresentou a proposta CNN LSTM alcançou o menor RMSE (14,3) e a maior correlação coeficiente (0,97). Existe também um modelo similar formado por LSTM e redes convolucionais gráficas (GCN), que tem melhor desempenho no estudo não linear e espacial do que a CNN [174]. GCN também extraiu a correlação espacial de muitas estações e LSTM ainda trabalhou na dependência temporal para previsão. Tabela 16 apresentar a frequência de aplicação dos métodos espaço-temporais. De acordo com as tabelas, todos os três métodos atualmente têm quase o mesmo no aplicativo de modelagem. No estudo futuro, o escolha do modelo espaço-temporal inteligente pode depender os requisitos reais de pesquisa (ver Fig. 21).

7. Discussão e recomendações para trabalhos futuros

Uma análise geral dos métodos baseados em dados na previsão da qualidade do ar foi demonstrada neste artigo. Os preditores inteligentes, métodos de processamento de dados, otimização metaheurística, aprendizado de conjunto e análise espaço-temporal são partes importantes em estratégias de previsão, enquanto as estruturas matemáticas de os modelos variam de estruturas simples a complexas. Os preditores shallow e os preditores de aprendizado profundo transformaram de preditores independentes para predição híbrida combinada com múltiplas técnicas populares, visando melhor desempenho em previsão. Nesta revisão, a previsão atual da poluição do ar modelos são completamente resumidos pelo propósito, aplicação, e características de vários métodos. Nesta seção, diferentes métodos de modelagem serão comparados e avaliados, os modelos preditivos em inteligência artificial e alguns possíveis futuros tendências de desenvolvimento são discutidas e propostas.

7.1. A estrutura representativa de modelos preditivos e análise comparativa

Para alcançar alta precisão no campo da previsão da qualidade do ar, muitos modelos preditivos são modelos híbridos baseados em algoritmos, como ANN, SVM, lógica fuzzy, ELM e preditores de aprendizado profundo. Com o desenvolvimento de modelos híbridos, esses preditores relacionam-se a mais algoritmos e métodos, adaptando-se a vários requisitos de previsão. Neste artigo, o processamento de dados, a otimização metaheurística, o ensemble learning e são integrados nas estruturas híbridas e a Tabela 17 lista alguns modelos preditivos representativos.

A tendência da combinação de diferentes métodos no ar a previsão de qualidade é óbvia e a decomposição é a mais método usado entre os métodos de processamento de dados por causa da aumento efetivo na precisão da previsão. Alguns modelos podem reduzir o erro de previsão para 40%–60% [144,147] por diferentes métodos de decomposição quando comparados aos modelos sem algoritmos de decomposição. A partir da análise comparativa de nas seções acima, indicou que a otimização metaheurística, aprendizado conjunto de métodos auxiliares e modelos também contribuem para o aumento da precisão das previsões.

Para comparar ainda mais os diferentes métodos e selecionar o modelos eficientes de todos os métodos para as conclusões acima, por

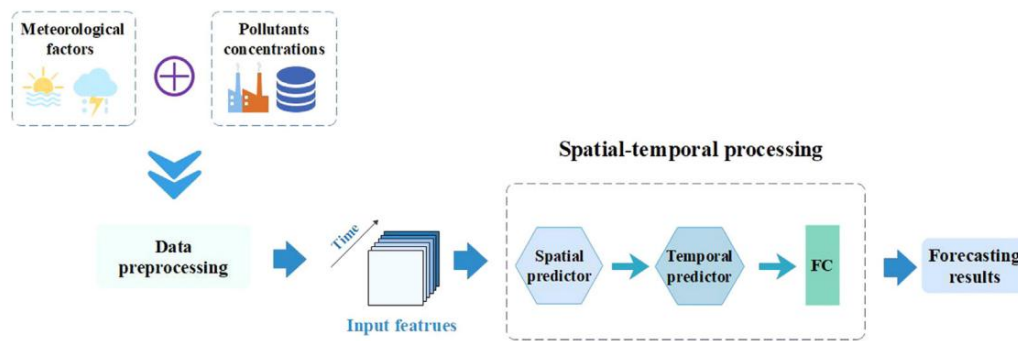


Fig. 21. A estrutura geral da modelagem híbrida espaço-temporal [72].

Tabela 17

Estruturas representativas parciais de modelos híbridos na previsão da qualidade do ar.

Estrutura do modelo	Métodos	assuntos	Índice de erros	Referência
Decomposição + preditor	EEMD + LSTM	PM2,5	19,604% (MAPE)	[85]
Decomposição híbrida + preditor	VMD + SE + LSTM	AQI	9,09% (MAPE)	[58]
Decomposição secundária + preditor + otimização metaheurística	WPD + CEEMD + LSSVR + CPSOGSA	PM2,5	Shenyang: 9,83% (MAPE) Chengdu: 8,41% (MAPE)	[153]
Decomposição + metaheurística otimização + preditores	CEEMD + PSO GSA + SVR + GRNN	PM2,5	Chongqing: 3,9374 (RMSE) Harbin: 4,0263 (RMSE) Jinan: 6,2995 (RMSE)	[86]
Otimização metaheurística + aprendizado conjunto + preditor	GA + RF + BPNN	PM10	Brunei-Muara: 2.4032 (MAE) Temburong: 3.1072 (MAE) Belait: 7,5557 (MAE) Conta: 8.2211 (MAE)	[64]
Otimização metaheurística + preditor	PSO + ELM	CO2	71,11% (RMSE), 73,73% (MAPE)	[165]
Decomposição + metaheurística otimização + preditor + ensemble Aprendendo	WPD + PSO + BPNN + Adaboost	PM2,5	Caso 1 (1-passo): 9,04% (MAPE) Caso 2(1-passo): 6,69% (MAPE)	[53]
Extração de recursos + metaheurística otimização + preditor	PCA + CS + LSSVM	PM2,5	12,56% (MAPE)	[175]
Preditor espacial + temporal preditor	CNN + LSTM	PM2,5	14.3 (RMSE)	[72]

os dados experimentais em [153], os MAPEs dos três modelos WPD-LSSVR-CPSOGSA, CEEMD-LSSVR-CPSOGSA e WPT CEEMD-LSSVR-CPSOGSA foram comparados. Pode ser visto de Fig. 22 que a capacidade de melhoria de precisão do LSSVR CPSOGSA é gradualmente melhorada quando combinada com o WPT, CEEMD e decomposição híbrida.

De acordo com os dados experimentais em [53], as estratégias híbridas podem melhorar a capacidade de previsão dos modelos de referência. A comparação em BP, WPD-BP, WPD-PSO-BP e WPD-PSO BP-Adaboost foi usada como modelos de referência para alcançar o

MAPEs de previsão de 1 passo. Pode-se ver na Fig. 23 que os modelos preditivos podem ser melhorados por uma combinação dos algoritmos de decomposição, a otimização metaheurística e o aprendizado conjunto. As habilidades de previsão do benchmark modelos também são gradualmente aumentados. Assim, a conclusão pode ser desenhado que os modelos híbridos com os métodos acima poderia atingir o alto nível na previsão da qualidade do ar e o espaço análise para os dados e os preditores podem ser incluídos no exploração futura.

Os modelos híbridos podem tirar vantagem de seus subordinados componentes para alcançar os resultados de previsão satisfatórios com maior precisão, melhor robustez e menos erros, o que pode ser concluído pela análise de experimentos comparativos no Reveja. No entanto, as construções complexas de modelos também trazem mais custos no processo de computação. Não há perfeito absoluto método, e a qualidade do ar não pode depender de poucas estratégias para

lidar com uma variedade de situações de previsão. Os modelos híbridos de estruturas complexas geralmente precisam de mais tempo de execução por causa de a estrutura. A eficiência de tempo do modelo pode diminuir enquanto a precisão da previsão foi melhorada para que eles sejam não é adequado para as altas demandas de previsão em tempo real. Portanto, o equilíbrio entre os fatores de modelagem deve ser considerado em mais pesquisas.

7.2. Possíveis tendências e desafios futuros de desenvolvimento

Em comparação com os modelos acima mencionados, outros aspectos de pesquisa também podem ser tendências de desenvolvimento futuro de impactos críticos na previsão da poluição do ar, como a coleta de dados e pré-processando. Através do levantamento das referências, há ainda alguns desafios nas aplicações recentes, os pontos de vista são dados da seguinte forma:

7.2.1. Escolha preditores adequados para previsão de subséries

Além dos algoritmos tradicionais resumidos no revisão, a busca e aplicação de novos algoritmos de previsão ainda deve ser realizado. Além das tradicionais ANN, SVM, FLN, ELM, etc., a versão melhorada deles tem sido utilizada em os modelos híbridos como OSELM [147] e WRELM [128], bem como como o novo preditor como DESN [88]. Além disso, como escolher um preditor adequado para vários processos de previsão de poluentes do ar pode levar a um avanço no aumento do desempenho da previsão.




Fig. 22. Os MAPEs de LSSVR-CPSOGSA por WPT, CEEMD e decomposição híbrida [153].




Fig. 23. Análise comparativa dos MAPEs em [53].

Por exemplo, os modelos híbridos com métodos de decomposição geralmente utilizam o mesmo preditor para prever todas as subséries e os métodos de otimização metaheurística visam buscar pesos de combinação ideais de preditores individuais em cada subsérie.

Mas falta análise para a diversidade de subséries com diferentes frequências, o que ainda é um problema digno de pesquisa. Com a consideração e escolha de preditores ótimos para subséries, os resultados finais da previsão podem ser mais precisos.

7.2.2. A aplicação da IoT na Cidade Inteligente

Recentemente, o novo conceito de Cidade Inteligente trouxe possibilidades de resolver problemas ambientais e sociais e oferecer um modelo aprimorado de dispositivos inteligentes baseados na vida. Os dispositivos da Internet das Coisas (IoT) podem realizar comunicação inteligente para interagir uns com os outros e se conectar à Internet. Com as estratégias, todas as unidades individuais poderiam ser conectadas por sistemas inteligentes para tornar a cidade inteligente sustentável [176]. E o sistema Smart City pode lidar com uma enorme quantidade de dados em tempo real da cidade e orientar as autoridades para tomar melhores decisões [177].

As estratégias de aprendizado de máquina e a técnica de detecção baseada em IA do monitoramento inteligente da qualidade do ar podem levar a aplicações em estudos futuros da rede IoT [178].

7.2.3. Os desafios da coleta de dados A

julgar pelos artigos envolvidos na revisão, os vários modelos da revisão se baseiam principalmente em dados históricos de publicações oficiais, que são coletados por estações nacionais de monitoramento em toda a área. Mas ainda não é suficiente em aplicações práticas, a aplicação de dispositivos móveis inteligentes de monitoramento de poluição e sensores de poluição do ar de baixo custo para medições em tempo real surgiram em estudo recente [179], incluindo os sensores da série PMS, sensores da série MQ (especialmente MQ-135), Azimut, Kit Cidadão Inteligente, NetAtmo e assim por diante. A possível estrutura para a combinação dos dados móveis e dados da estação poderia contribuir para a previsão da qualidade do ar pela resolução dos dados de tempo e a divisão espacial precisa e a análise temporal completa dos dados originais melhoraria ainda mais a capacidade científica e

precisão da previsão, na qual são necessários muitos conhecimentos avançados ou habilidades para resolver problemas. Além disso, o conhecimento maciço da técnica de detecção tem grande potencial para desenvolvimento.

7.2.4. Aplicações de computação distribuída

Com o aumento dos dados de qualidade do ar, a modelagem orientada por big data de uma grande soma de dados tem ganhado gradativamente mais atenção e tem se mostrado eficaz em melhorar a estabilidade do modelo híbrido com informações e recursos suficientes e aumentar a velocidade de treinamento dos o modelo pela computação distribuída [88]. Atualmente, o framework Apache Spark foi aplicado para prever séries de big data por alguns estudiosos [180], que é um sistema de processamento distribuído comumente usado em cargas de trabalho de big data com desempenho de alta velocidade. Ao aplicar a computação em cluster da plataforma de big data e do sistema de armazenamento, como o Hadoop Distributed File System (HDFS), a eficiência pode ser bastante aumentada. A combinação de técnicas baseadas em big-data e aprendizado de máquina para previsão da qualidade do ar pode obter maiores resultados no desenvolvimento futuro.

8. Conclusões

Este artigo revisou de forma abrangente as metodologias e algoritmos de modelagem recentes na previsão da poluição do ar. No início deste trabalho, são classificados diferentes tipos de preditores inteligentes simples e suas versões aprimoradas. Os modelos têm suas vantagens e limitações e são aplicados nas tarefas de previsão correspondentes a diferentes variáveis.

À medida que a pesquisa avança e o aumento de dados de entrada em massa, modelos simples estão se tornando insuficientes para suportar condições complexas. Além dos preditores simples, outros componentes também foram combinados nos modelos para formar os modelos preditivos híbridos. Resumiram-se os principais tipos de componentes adotados na literatura, a saber, os métodos de processamento de dados e os métodos auxiliares: otimização metaheurística e ensemble learning, cujas características também são resumidas. Com

a preocupação com a complexidade da poluição do ar e a consideração geral do espaço de pesquisa, a análise espacial dos dados massivos foi adicionada às estruturas de modelagem com os preditores aprimorados ou os modelos híbridos espaço-temporais. No final deste artigo, alguns modelos de previsão representativos são listados para descrever as estruturas e características do ar previsão de qualidade. A análise comparativa para a seleção de modelos eficientes também é realizada. Além disso, os pontos de tendências de desenvolvimento futuro são dados. As direções de pesquisa possíveis ou potenciais podem levar a uma melhoria adicional do desempenho da previsão.

Declaração de interesse concorrente

Os autores declaram que não conhecem interesses financeiros concorrentes ou relações pessoais que possam ter influenciado o trabalho relatado neste artigo.

Agradecimentos

Este estudo é totalmente apoiado pela Fundação Nacional de Ciências Naturais da China (concessão nº 52072412), o Changsha Science & Technology Project, China (concessão nº. . 2019CX005).

Referências

- [1] Y. Zhou, X. Zhao, K. Y. P. Lin, C.-H. Wang, L. Li, Um algoritmo de aprendizado iterativo de corte rígido baseado em modelo de mistura de processo gaussiano para previsão de qualidade do ar, *Appl. Computação Suave*. 85 (2019) 105789.
- [2] M. Péres, G. Ruiz, S. Nesmachnow, A. C. Olivera, Otimização evolutiva multiobjetiva do fluxo de tráfego e poluição em Montevideo, Uruguai, *Appl. Computação Suave*. 70 (2018) 472-485.
- [3] YSH Najjar, Formação de poluentes gasosos e seus efeitos nocivos na saúde e no meio ambiente, *Innov. Políticas de Energia* 1 (2011) 1–9.
- [4] X. Han, Y. Liu, H. Gao, J. Ma, X. Mao, Y. Wang, X. Ma, Previsão de morbidade por câncer de pulmão masculino induzida por PM 2.5 na China usando PM 2.5 recuperado por satélite e análise espacial, *Sci. Ambiente Total*. 607-608 (2017) 1009-1017.
- [5] A. J. Cohen, M. Brauer, R. Burnett, H. Anderson, J. Frostad, K. Estep, K. Balakrishnan, B. Brunekreef, L. Dandona, R. Dandona, Estimativas e tendências de 25 anos da carga global de doenças atribuíveis à poluição do ar ambiente: uma análise de dados do Estudo de Carga Global de Doenças, 2015, *Lancet* 389 (2017)) 1907-1918.
- [6] Y. Hao, H. Peng, T. Temulun, L. Liu, J. Mao, Z. Lu, H. Chen, Quão prejudicial é a poluição do ar para o desenvolvimento econômico? Novas evidências de concentrações de PM_{2.5} de cidades chinesas, *J. Cleaner Prod.* 172 (2018) 743-757.
- [7] Y. Xia, D. Guan, X. Jiang, L. Peng, H. Schroeder, Q. Zhang, Avaliação dos custos socioeconômicos da poluição do ar na China, *Atmos. Ambiente*. 139 (2016) 147-156.
- [8] W. Wei, L. Peng, H. Wang, M. Song, Quantificando os efeitos das políticas de controle da poluição do ar : Um caso da província de Shanxi na China, *Atmos. Poluir. Res.* 9 (2017) 429-438.
- [9] K.-M. Nam, N. E. Selin, J. M. Reilly, S. Paltsev, Medindo a perda de bem-estar causada pela poluição do ar na Europa: Uma análise CGE, *Energy Policy* 38 (2010) 5059–5071.
- [10] W. Zhu, J. Wang, W. Zhang, D. Sun, Efeitos de curto prazo da poluição do ar em doenças respiratórias inferiores e previsão pelo método de grupo de manipulação de dados, *Atmos. Ambiente*. 51 (2012) 29-38.
- [11] F. Cereceda-Balic, M. Toledo, V. Vidal, F. Guerrero, L. A. Diaz-Robles, X. Petit-Breuilh, M. Lapuerta, Fatores de emissão para PM_{2.5}, CO, CO₂, NO_x, SO₂ e distribuições granulométricas da combustão de espécies de madeira usando uma nova câmara de combustão controlada 3CE, *Sci. Ambiente Total*. 584 (2017) 901-910.
- [12] K. Xiao, Y. Wang, G. Wu, B. Fu, Y. Zhu, características espaço-temporais de poluentes atmosféricos (PM₁₀, PM_{2.5}, SO₂, NO₂, O₃ e CO) na cidade da bacia interior de Chengdu, sudoeste da China, *Atmosfera* 9 (2018) 74.
- [13] K.-H. Kim, E. Kabir, S. Kabir, Uma revisão sobre o impacto na saúde humana de partículas transportadas pelo ar, *Environ. Int.* 74 (2015) 136-143.
- [14] F. Zhu, R. Ding, R. Lei, H. Cheng, J. Liu, C. Shen, C. Zhang, Y. Xu, C. Xiao, X. Li, Os efeitos a curto prazo do ar poluição em doenças respiratórias e mortalidade por câncer de pulmão em hefei: uma análise de séries temporais, *Respir. Med.* 146 (2019) 57-65.
- [15] A. Sotomayor-Olmedo, M. Aceves-Fernández, E. Gorrostieta-Hurtado, C. Pedraza-Ortega, J. M. Ramos-Arreguín, J. E. Vargas-Soto, Previsão da poluição do ar urbano na Cidade do México usando máquinas de vetor de suporte: Uma abordagem de desempenho do kernel, *Int. J. Intel. Sci.* 3 (2013) 126.
- [16] E. Velasco, A. Retama, a ameaça do Ozônio atinge de volta a Cidade do México, *Sustain. Cidades Soc.* 31 (2017) 260-263.
- [17] S. Avner, D. L. Mauzerall, J. Liu, L. W. Horowitz, Reduções globais da produção agrícola devido à exposição ao ozônio superficial: 2. Ano 2030 , perdas potenciais de produção agrícola e danos econômicos em dois cenários de poluição por O₃, *Atmos. Ambiente*. 45 (2011) 2297-2309.
- [18] S. Osowski, K. Garanty, Previsão da poluição meteorológica diária usando wavelets e máquina de vetores de suporte, *Eng. Aplic. Artif. Intel.* 20 (2007) 745-755.
- [19] I. B. Konovalov, M. Beekmann, F. Meleux, A. Dutot, G. Foret, Combinando abordagens determinísticas e estatísticas para previsão de PM₁₀ na Europa, *Atmos. Ambiente*. 43 (2009) 6425-6434.
- [20] C. Seigneur, M. Moran, Capítulo 8, Modelos de Transporte Químico, 2010.
- [21] G. Zhou, J. Xu, Y. Xie, L. Chang, W. Gao, Y. Gu, J. Zhou, Previsão numérica da qualidade do ar no leste da China: Uma aplicação operacional do WRF-Chem, *Atmos. Ambiente*. 153 (2017) 94-108.
- [22] M.-T. Chuang, Y. Zhang, D. Kang, Aplicação do WRF-Chem-MADRID para previsão da qualidade do ar em tempo real no sudeste dos Estados Unidos, *Atmos. Ambiente*. 45 (2011) 6241-6250.
- [23] Y.-S. Koo, D.-R. Choi, H.-Y. Kwon, Y.-K. Jang, J.-S. Han, Melhoria da previsão de PM₁₀ no leste da Ásia usando modelagem inversa, *Atmos. Ambiente*. 106 (2015) 318-328.
- [24] X. Qiao, Q. Ying, X. Li, H. Zhang, J. Hu, Y. Tang, X. Chen, Distribuição da fonte de PM_{2.5} para 25 capitais provinciais e municípios chineses usando uma fonte orientada Modelo comunitário de qualidade do ar multiescala, *Sci. Ambiente Total*. 612 (2018) 462-471.
- [25] A. M. Manders, M. Schaap, R. Hoogerbrugge, Testando a capacidade do modelo de transporte químico LOTOS-EUROS para prever os níveis de PM₁₀ na Holanda, *Atmos. Ambiente*. 43 (2009) 4050-4059.
- [26] X. Feng, Q. Li, Y. Zhu, J. Hou, L. Jin, J. Wang, Previsão de redes neurais artificiais de poluição PM_{2.5} usando modelo geográfico baseado em trajetória de massa de ar e transformação wavelet, *Atmos. Ambiente*. 107 (2015) 118–128.
- [27] H. Shimadera, T. Kojima, A. Kondo, Avaliação do desempenho do modelo de qualidade do ar para simular transporte de longo alcance e poluição local de PM_{2.5} no Japão, *Adv. Meteorol.* 2016 (2016) 13.
- [28] J. Chen, H. Chen, Z. Wu, D. Hu, J. Z. Pan, Previsão de riscos à saúde relacionados ao smog com base em mídia social e sensor físico, *Inf. Sistema* 64 (2017) 281-291.
- [29] M. Ritter, M. D. Müller, M.-Y. Tsai, E. Parlow, Modelagem da poluição do ar em terrenos muito complexos: uma avaliação do WRF-Chem sobre a Suíça por dois períodos de 1 ano, *Atmos. Res.* 132 (2013) 209-222.
- [30] A. Kumar, P. Goyal, Previsão do índice diário de qualidade do ar em Delhi, *Sci. Ambiente Total*. 409 (2011) 5517-5523.
- [31] J. Zhou, J. Zhao, P. Li, Estudo sobre modelo numérico cinza de poluição do ar na cidade de Wuhan, em: 2010 Conferência Internacional sobre Desafios em Ciência Ambiental e Engenharia de Computação, IEEE, 2010, pp. 321– 323.
- [32] E. L. Zvereva, M. V. Kozlov, Respostas de artrópodes terrestres à poluição do ar: uma meta-análise, *Environ. Sci. Poluir. Res.* 17 (2010) 297-311.
- [33] A. Kumar, P. Goyal, Previsão da qualidade do ar em Delhi usando a técnica de regressão de componentes principais, *Atmos. Poluir. Res.* 2 (2011) 436-444.
- [34] A. Donnelly, B. Misstear, B. Broderick, Previsão da qualidade do ar em tempo real usando técnicas de regressão paramétrica e não paramétrica integradas, *Atmos. Ambiente*. 103 (2015) 53-65.
- [35] A. Russo, A. O. Soares, Modelo híbrido para previsão da poluição do ar urbano: Uma abordagem espaço-temporal estocástica, *Math. Geosci.* 46 (2014) 75-93.
- [36] A. Chaloulakou, M. Saisana, N. Spyrellis, Avaliação comparativa de redes neurais e modelos de regressão para previsão de ozônio de verão em Atenas, *Sci. Ambiente Total*. 313 (2003) 1–13.
- [37] Y. Zhang, M. Bocquet, V. Mallet, C. Seigneur, A. Baklanov, Previsão da qualidade do ar em tempo real , parte I: História, técnicas e status atual, *Atmos. Aproximadamente*. 60 (2012) 632-655.
- [38] S. M. Cabaneros, J. K. Calautit, B. R. Hughes, Uma revisão de modelos de redes neurais artificiais para previsão de poluição do ar ambiente, *Environ. Modelo. Softw.* 119 (2019) 285-304.
- [39] M. M. Kamal, R. J. Jallani, R. L. A. Shauri, Previsão da qualidade do ar ambiente com base na técnica de rede neural, em: 2006 4th Student Conference on Research and Development, IEEE, 2006, pp. 115–119.
- [40] H. Wahid, Q. P. Ha, H. N. Duc, Estimativa de inteligência computacional do nível de ozônio de fundo natural e sua distribuição para modelagem da qualidade do ar e controle de emissões, em: Proceedings of the 28th International Symposium on Automation and Robotics in Construction, ISARC 2011, 2011.
- [41] D. Z. Antanasijević, V. V. Pocač, D. S. Povrenović, M. D. Ristić, A. A. Perić, J. Grujić, previsão de emissões PM₁₀ usando redes neurais artificiais e otimização de variáveis de entrada de algoritmo genético, *Sci. Ambiente Total*. 443 (2013) 511-519.

- [42] S. Zhang, X. Li, Y. Li, J. Mei, Previsão da concentração urbana de PM 2.5 com base na rede neural wavelet, em: Conferência Chinesa de Controle e Decisão de 2018, CCDC, IEEE, 2018, pp. 5514–5519.
- [43] T. Li, X. Li, L. Wang, Y. Ren, T. Zhang, M. Yu, método de previsão de conjunto multimodelo de PM2.5 baseada em redes neurais wavelet, em: 2018 1st International Cognitive Cities Conference, IC3, IEEE, 2018, pp. 81–86.
- [44] Z. Li, J. Yang, uso de previsão PM-25 para reconstruir o espaço de fase LS-SVM, 2010, 2ª Conferência sobre Ciência Ambiental e Tecnologia de Aplicação da Informação, IEEE, 2010, pp. 143–146.
- [45] Y. Yildirim, M. Bayramoglu, Modelagem adaptativa baseada em neuro-fuzzy para a previsão dos níveis diários de poluição do ar na cidade de Zonguldak, *Chemosphere* 63 (2006) 1575–1582.
- [46] TE Alhanafy, F. Zaghloul, A. Moustafa, esquema de modelagem neuro difusa para a previsão da poluição do ar, *J. Am. Sci.* 6 (2010) 605–616.
- [47] J. Xie, Rede neural profunda para previsão de poluição PM2.5 com base no aprendizado múltiplo, em: 2017 Conferência Internacional sobre Detecção, Diagnóstico, Prognóstico e Controle, SDPC, IEEE, 2017, pp. 236–240.
- [48] E. Eslami, Y. Choi, Y. Lops, A. Sayeed, Um sistema de previsão de ozônio por hora em tempo real usando rede neural convolucional profunda, *Computação Neural. Aplic.* (2019) 1–15.
- [49] BS Freeman, G. Taylor, B. Gharabaghi, J. Thé, Previsão de séries temporais de qualidade do ar usando aprendizado profundo, *J. Air Waste Manage. Associação* 68 (2018) 866–886.
- [50] A. Masih, algoritmos de aprendizado de máquina na modelagem da qualidade do ar, *Glob. J. Ambiente. Sci. Gerenciar.* 5 (2019) 515–534.
- [51] Y. Rybarczyk, R. Zalakeviciute, Abordagens de aprendizado de máquina para modelagem da qualidade do ar externo: Uma revisão sistemática, *Appl. Sci.* 8 (2018) 2570.
- [52] L. Bai, J. Wang, X. Ma, H. Lu, Previsões da poluição do ar: Uma visão geral, *Int. J. Ambiente. Res. Publ. Saúde* 15 (2018) 780.
- [53] H. Liu, K. Jin, Z. Duan, Air PM 2.5 concentração multi-passo de previsão usando um novo método de modelagem híbrida: Comparando casos para quatro cidades na China, *Atmos. Poluir. Res.* 10 (2019) 1588–1600.
- [54] D. Mishra, P. Goyal, Desenvolvimento de modelos de previsão de NO2 baseados em inteligência artificial no Taj Mahal, Agra, *Atmos. Poluir. Res.* 6 (2015) 99–106.
- [55] Y. Bai, Y. Li, X. Wang, J. Xie, C. Li, Previsão de concentrações de poluentes atmosféricos usando rede neural de retropropagação com base na decomposição wavelet com condições meteorológicas, *Atmos. Poluir. Res.* 7 (2016) 557–566.
- [56] RC Deo, MK Tiwari, JF Adamowski, JM Quilty, Previsão do índice de seca efetiva usando um modelo de máquina de aprendizado extremo de wavelet (W-ELM), *Stoch. Ambiente. Res. Avaliação de Risco.* 31 (2017) 1211–1240.
- [57] S. Zhu, X. Qiu, Y. Yin, M. Fang, X. Liu, X. Zhao, Y. Shi, modelo híbrido de duas etapas baseado em pré-processamento de dados e algoritmos de otimização inteligente (CS e GWO) para Previsão de NO2 e SO2, *Atmos. Poluir. Res.* 10 (2019) 1326–1335.
- [58] Q. Wu, H. Lin, Previsão diária do índice de qualidade do ar urbano com base na decomposição de modo variacional, entropia de amostra e rede neural LSTM, *Sustain. Cidades Soc.* 50 (2019) 101657.
- [59] S. Chen, J. Wang, H. Zhang, Um modelo híbrido PSO-SVM baseado em algoritmo de agrupamento para previsão de concentração de poluentes atmosféricos de curto prazo, *Technol. Previsão. Soc. Alteração* 146 (2019) 41–54.
- [60] J. Murillo-Escobar, JP Sepulveda-Suescun, MA Correa, D. Orrego Metaute, Previsão de concentrações de poluentes atmosféricos usando regressão vetorial de suporte melhorada com otimização de enxame de partículas: Estudo de caso no Vale de Aburrá, Colômbia, *Urban Clim.* 29 (2019) 100473.
- [61] Rubal, D. Kumar, Evolving diferencial método de evolução com floresta aleatória para previsão de poluição do ar, *Procedia Comput. Sci.* 132 (2018) 824–833.
- [62] S. Qin, F. Liu, J. Wang, B. Sun, Análise e previsão dos níveis de concentração de material particulado (PM) em quatro grandes cidades da China usando modelos híbridos, *Atmos. Ambiente.* 98 (2014) 665–675.
- [63] JA Kamijska, Um modelo aleatório de partição florestal para prever as concentrações de NO2 a partir do fluxo de tráfego e das condições meteorológicas, *Sci. Ambiente Total* . 651 (2019) 475–483.
- [64] S.-Q. Dotse, MI Petra, L. Dagar, LC De Silva, Aplicação de técnicas de inteligência computacional para prever excedências diárias de PM10 em Brunei Darussalam, *Atmos. Poluir. Res.* 9 (2018) 358–368.
- [65] B. Zhai, J. Chen, Desenvolvimento de um modelo de conjunto empilhado para previsão e análise de PM2 média diária. 5 concentrações em Pequim, China, *Sci. Ambiente Total.* 635 (2018) 644–658.
- [66] YA Awad, P. Koutrakis, BA Coull, J. Schwartz, Um modelo de previsão espaço-temporal baseado na regressão de máquina de vetor de suporte: Carbono Negro Ambiente em três Estados da Nova Inglaterra, *Environ. Res.* 159 (2017) 427–434.
- [67] A. Kurt, AB Oktay, Previsão de níveis de indicadores de poluentes atmosféricos com modelos geográficos com 3 dias de antecedência usando redes neurais, *Expert Syst. Aplic.* 37 (2010) 7986–7992.
- [68] Y. Zhan, Y. Luo, X. Deng, ML Grieneisen, M. Zhang, B. Di, Previsão espaço-temporal dos níveis diários de ozônio ambiente em toda a China usando floresta aleatória para avaliação da exposição humana, *Environ. Poluir.* 233 (2018) 464–473.
- [69] W. Yang, M. Deng, F. Xu, H. Wang, Previsão de PM2 horária. 5 usando um modelo de regressão vetorial de suporte espaço-tempo, *Atmos. Ambiente.* 181 (2018) 12–19.
- [70] J. Ma, Y. Ding, JCP Cheng, F. Jiang, Z. Wan, Um método de interpolação e extrapolação temporal-espaço baseado na rede neural geográfica de Long Short-Term Memory para PM2.5, *J. Cleaner Prod.* 237 (2019) 117729.
- [71] U. Pak, J. Ma, U. Ryu, K. Ryom, U. Juhok, K. Pak, C. Pak, Previsão de PM2.5 baseada em aprendizado profundo considerando as correlações espaço-temporais: Um estudo de caso de Pequim, China, *Sci. Ambiente Total.* 669 (2019) 133561.
- [72] D. Qin, J. Yu, G. Zou, R. Yong, Q. Zhao, B. Zhang, Um novo esquema de previsão combinado baseado em CNN e LSTM para concentração urbana de PM 2.5, *IEEE Access* 7 (2019) 20050–20059.
- [73] H. Taheri Shahraiyni, S. Sodoudi, Abordagens de modelagem estatística para previsão de PM10 em áreas urbanas; Uma revisão de estudos do século XXI, *Atmosphere* 7 (2016) 15.
- [74] X. Wang, JJ Klemeš, X. Dong, W. Fan, Z. Xu, Y. Wang, PS Varbanov, Nexus do terreno da poluição do ar: Uma revisão considerando geração e consumo de energia, *Renew. Sustentar. Energia Rev.* 105 (2019) 71–85.
- [75] S. Gulia, SS Nagendra, M. Khare, I. Khanna, Gestão da qualidade do ar urbano -A revisão, *Atmos. Poluir. Res.* 6 (2015) 286–304.
- [76] M. Casazza, M. Lega, E. Jannelli, M. Minutillo, D. Jaffe, V. Severino, S. Ulgiati, monitoramento 3D e modelagem da qualidade do ar para o planejamento portuário urbano sustentável: Revisão e perspectivas, *J. Cleaner Prod.* 231 (2019) 1342–1352.
- [77] W. Sun, J. Sun, previsão diária de concentração de PM 2.5 com base na análise de componentes principais e LSSVM otimizado pelo algoritmo de busca de cuco, *J. Ambiente. Gerenciar.* 188 (2017) 144–152.
- [78] W.-Z. Lu, W.-J. Wang, X.-Y. Wang, S.-H. Yan, JC Lam, Avaliação potencial de um modelo de rede neural com abordagem PCA/RBF para previsão de tendências de poluentes no ar urbano de Mong Kok, Hong Kong, *Environ. Res.* 96 (2004) 79–87.
- [79] Y. Cheng, H. Zhang, Z. Liu, L. Chen, P. Wang, algoritmo híbrido para previsão de curto prazo de PM2.5 na China, *Atmos. Ambiente.* 200 (2019) 264–279.
- [80] A. Prakash, U. Kumar, K. Kumar, VK Jain, Um modelo de rede neural baseado em wavelet para prever a concentração de poluentes do ar ambiente, *Environ. Modelo. Avaliar.* 16 (2011) 503–517.
- [81] F. Jiang, J. He, T. Tian, Uma abordagem de agrupamento baseada em agrupamento com otimização inspirada em pombos aprimorada e máquina de aprendizado extremo para previsão da qualidade do ar, *Appl. Computação Suave.* 85 (2019) 105827.
- [82] H. Liu, Z. Duan, C. Chen, Uma estrutura híbrida para a previsão de concentrações de PM2.5 usando estratégia determinística e probabilística de várias etapas, *Air Qual. Atmos. Saúde* 12 (2019) 785–795.
- [83] S. Zhu, X. Lian, H. Liu, J. Hu, Y. Wang, J. Che, Previsão diária do índice de qualidade do ar com modelos híbridos: Um caso na China, *Environ. Poluir.* 231 (2017) 1232–1244.
- [84] M. Niu, K. Gan, S. Sun, F. Li, Aplicação do paradigma de aprendizagem de conjunto de decomposição com reconstrução de espaço de fase para previsão de concentração PM2.5 no dia seguinte, *J. Environ. Gerenciar.* 196 (2017) 110–118.
- [85] Y. Bai, B. Zeng, C. Li, J. Zhang, An ensemble long short-term memory neural network for hourly PM2.5 concentração forecasting, *Chemosphere* 222 (2019) 286–294.
- [86] S. Zhu, X. Lian, L. Wei, J. Che, X. Shen, L. Yang, X. Qiu, X. Liu, W. Gao, X. Ren, PM2.5 previsão usando SVR com algoritmo PSOGSA baseado em CEEMD, GRNN e GCA considerando fatores meteorológicos, *Atmos. Aproximadamente.* 183 (2018) 20–32.
- [87] J. Wang, H. Li, H. Lu, Aplicação de um novo sistema de alerta precoce baseado em séries temporais difusas na previsão da qualidade do ar urbano na China, *Appl. Computação Suave* . 71 (2018) 783–799.
- [88] Y. Xu, H. Liu, Z. Duan, Um novo modelo híbrido para previsão diária de AQI em várias etapas impulsionada por big data de poluição do ar, *Air Qual. Atmos. Saúde* 13 (2020) 197–207.
- [89] J. Wang, L. Bai, S. Wang, C. Wang, Pesquisa e aplicação do modelo de previsão híbrido baseado em denoising secundário e otimização multi-objetivo para sistema de alerta precoce de poluição do ar, *J. Cleaner Prod.* 234 (2019) 54–70.
- [90] Y. Xu, P. Du, J. Wang, Pesquisa e aplicação de um modelo híbrido baseado na avaliação sintética fuzzy dinâmica para o estabelecimento de previsão da qualidade do ar e sistema de alerta precoce: Um estudo de caso na China, *Environ. Poluir.* 223 (2017) 435–448.
- [91] M. Deng, W. Yang, Q. Liu, R. Jin, F. Xu, Y. Zhang, Redes neurais artificiais espaço-tempo heterogêneas para previsão de séries espaço-temporais, *Trans. GIS* 22 (2018) 183–201.
- [92] MA Elangasinghe, N. Singhal, KN Dirks, JA Salmond, Desenvolvimento de um sistema de previsão de poluição do ar baseado em ANN com conhecimento explícito por meio de análise de sensibilidade, *Atmos. Poluir. Res.* 5 (2014) 696–708.
- [93] G. de Gennaro, L. Trizio, A. Di Gilio, J. Pey, N. Pérez, M. Cusack, A. Alastuey, X. Querol, modelo de rede neural para a previsão de concentrações diárias de PM10 em dois locais no Mediterrâneo Ocidental, *Sci. Ambiente Total* . 463 (2013) 875–883.

- [94] Z. Jiang, X. Meng, C. Yang, G. Li, A BP modelo de previsão de rede neural da qualidade do ar urbano com base em um conjunto aproximado, em: 2008 Quarta Conferência Internacional sobre Computação Natural, IEEE, 2008, pp 362–370.
- [95] H. Zhang, Y. Liu, R. Shi, Q. Yao, Avaliação da previsão de PM10 com base no modelo de rede neural artificial e fração de entrada em uma área urbana: Um estudo de caso na cidade de Taiyuan, China, J. Air Gerenciamento de Resíduos. Associação 63 (2013) 755-763.
- [96] H. Zheng, X. Shang, Estudo sobre a previsão de PM2.5 atmosférico com base na rede neural RBF, em: 2013 Quarta Conferência Internacional sobre Manufatura Digital e Automação, IEEE, 2013, pp. 1287-1289.
- [97] DF Specht, Uma rede neural de regressão geral, IEEE Trans. Rede Neural. 2 (1991) 568-576.
- [98] L. Zheng, S. Yu, M. Yu, Monitorando as emissões de NOx de caldeiras a carvão usando rede neural de regressão generalizada, em: 2008 2ª Conferência Internacional de Bioinformática e Engenharia Biomédica, 2008.
- [99] DZ Antanasijević, M.D. Ristić, AA Perić-Grujić, VV Pocajt, Previsão da exposição humana ao PM10 em nível nacional usando uma abordagem de rede neural artificial, J. Chemometr. 27 (2013) 170-177.
- [100] G. Sun, SJ Hoff, BC Zelle, MA Smith, Desenvolvimento e comparação de modelos de rede neural de retropropagação e regressão generalizada para prever concentrações e emissões diurnas e sazonais de gás e PM10 de edifícios de suínos, em: 2008 Providence, Rhode Island, 29 de junho a 2 de julho de 2008, Sociedade Americana de Engenheiros Agrícolas e Biológicos, 2008, p. 1.
- [101] Z. Zainuddin, O. Pauline, Rede neural wavelet modificada na aproximação de função e sua aplicação na previsão de dados de poluição de séries temporais, Appl. Computação Suave. 11 (2011) 4866-4874.
- [102] JL Elman, Encontrando estrutura no tempo, Cogn. Sci. 14 (1990) 179-211.
- [103] U. Brunelli, V. Piazza, L. Pignato, F. Sorbello, S. Vitabile, Previsão de dois dias à frente das concentrações máximas diárias de SO2, O3, PM10, NO2, CO na área urbana de Palermo, Itália, Atmos. Ambiente. 41 (2007) 2967-2995.
- [104] U. Brunelli, V. Piazza, L. Pignato, F. Sorbello, S. Vitabile, Previsão de três horas à frente da concentração de poluentes SO2 usando um preditor baseado em neural elman, Build. Ambiente. 43 (2008) 304-314.
- [105] S. Wu, Q. Feng, Y. Du, X. Li, Modelos de redes neurais artificiais para previsão diária do índice de poluição do ar PM10 na área urbana de Wuhan, China, Environ. Eng. Sci. 28 (2011) 357-363.
- [106] PJG Nieto, EF Combarro, JJDC Díaz, E. Montañés, Um modelo de regressão baseado em SVM para estudar a qualidade do ar em escala local na área urbana de Oviedo (Norte da Espanha): Um estudo de caso, Appl. Matemática. Computar. 219 (2013) 8923-8937.
- [107] BC Liu, A. Binaykia, PC Chang, MK Tiwari, CC Tsao, Previsão da qualidade do ar urbano com base na Regressão do Vetor de Suporte multidimensional (SVR): Um estudo de caso de Pequim-Tianjin-Shijiazhuang, PLoS One 12 (2017).
- [108] AS Sánchez, PJG Nieto, PR Fernández, JJ del Coz Díaz, FJ Iglesias Rodríguez, Aplicação de um modelo de regressão baseado em SVM ao estudo da qualidade do ar à escala local na zona urbana de Avilés (Espanha), Math. Computar. Modelagem 54 (2011) 1453-1466.
- [109] L. Tang, C. Zhou, L. He, S. Zhang, Pesquisa sobre a qualidade do ar da região de Pequim-Tianjin Hebei com base em SVM e análise de regressão, em: 2017 Conferência Internacional sobre Educação, Economia e Pesquisa de Gestão, ICEEMR 2017, Atlantis Press, 2017.
- [110] W. Lu, W. Wang, Avaliação potencial do método de máquina de vetor de suporte na previsão de tendências de poluentes do ar ambiente, Chemosphere 59 (2005) 693-701.
- [111] A. Saxena, S. Shekhawat, classificação da qualidade do ar ambiente por máquina de vetor de suporte baseada em otimizador de lobo cinzento, J. Environ. Publ. Saúde 2017 (2017).
- [112] JAK Suykens, J. Vandewalle, classificadores de máquina vetorial de suporte de mínimos quadrados, Processo Neural. Lett. 9 (1999) 293-300.
- [113] Y. Zhai, X. Ding, X. Jin, L. Zhao, Método de previsão iterativo baseado em LSSVM adaptativo para previsão de concentração de NOx em usina a carvão considerando atraso do sistema, Appl. Computação Suave. 89 (2020) 106070.
- [114] Q. Song, BS Chissom, Fuzzy time series and its models, Fuzzy Sets Systems 54 (1993) 269–277.
- [115] NG Dincer, Ö. Akcuş, Um novo modelo de série temporal difusa baseado em agrupamento robusto para previsão de poluição do ar, Ecol. Informar. 43 (2018) 157-164.
- [116] D. Domajška, M. Wojtylak, Aplicação de modelos fuzzy de séries temporais para a previsão de concentrações de poluição, Expert Syst. Aplic. 39 (2012) 7673-7679.
- [117] JSR Jang, ANFIS: sistema de inferência fuzzy baseado em rede adaptável, IEEE Trans. Sistema Homem Cibernético. 23 (1993) 665-685.
- [118] S. Jain, M. Khare, Modelagem neuro-fuzzy adaptativa para previsão da concentração de CO ambiente em interseções urbanas e estradas, Air Qual. Atmos. Saúde 3 (2010) 203-212.
- [119] M. Oprea, SF Mihalache, M. Popescu, Um estudo comparativo de técnicas de inteligência computacional aplicadas à previsão de poluição atmosférica PM2.5, em: 2016 6th International Conference on Computers Communications and Control, ICCCC, IEEE, 2016, pp 103-108.
- [120] Y.-C. Lin, S.-J. Lee, C.-S. Ouyang, C.-H. Wu, Previsão da qualidade do ar por abordagem de modelagem neuro-fuzzy, Appl. Computação Suave. 86 (2020) 105898.
- [121] G. Huang, Q. Zhu, CK Siew, Extreme learning machine: teoria e aplicações, Neurocomputing 70 (2006) 489-501.
- [122] C. Zhao, M. van Heeswijk, J. Karhunen, Previsão da qualidade do ar usando redes neurais, em: 2016 IEEE Symposium Series on Computational Intelligence, SSCI, IEEE, 2016, pp. 1–7.
- [123] J. Zhang, W. Ding, Previsão da concentração de poluentes atmosféricos com base em uma máquina de aprendizado extremo: o caso de Hong Kong, Int. J. Ambiente. Res. Publ. Saúde 14 (2017) 114.
- [124] N. Liang, G. Huang, P. Saratchandran, N. Sundararajan, Um algoritmo de aprendizagem sequencial online rápido e preciso para redes feedforward, IEEE Trans. Rede Neural. 17 (2006) 1411-1423.
- [125] A. Bueno, GP Coelho, JR Bertini, Aprendizagem sequencial online baseado em máquinas de aprendizado extremo para previsão de material particulado, em: 2017 Brazilian Conference on Intelligent Systems, BRACIS, IEEE, 2017, pp. 169–174.
- [126] H. Peng, AR Lima, A. Teakles, J. Jin, AJ Cannon, WW Hsieh, Avaliando a previsão horária da qualidade do ar no Canadá com métodos de aprendizado de máquina não lineares atualizáveis, Air Qual. Atmos. Saúde 10 (2017) 195-211.
- [127] W. Deng, Q. Zheng, L. Chen, Máquina de aprendizagem extrema regularizada, em: 2009 IEEE Symposium on Computational Intelligence and Data Mining, IEEE, 2009, pp. 389–395.
- [128] H. Liu, C. Chen, Previsão de concentrações externas de PM2.5 com base em um modelo de rede neural híbrida de três estágios, Atmos. Poluir. Res. 11 (2020) 469-481.
- [129] M. Krishan, S. Jha, J. Das, A. Singh, MK Goyal, C. Sekar, Modelagem da qualidade do ar usando memória de longo prazo (LSTM) sobre NCT-delhi, Índia, Air Qual. Atmos. Saúde 12 (2019) 899-908.
- [130] J.-H. Park, S.-J. Yoo, K.-J. Kim, Y.-H. Gu, K.-H. Lee, U.-H. Son, modelo de previsão de densidade PM10 usando memória de longo prazo, em: 2017 Nona Conferência Internacional sobre Redes Ubíquas e Futuras, ICUFN, IEEE, 2017, pp. 576–581.
- [131] J. Li, X. Shao, R. Sun, Um modelo de rede neural profunda baseado em DBN com aprendizado multitarefa para previsão on-line da qualidade do ar, J. Control Sci. Eng. 2019 (2019) 9.
- [132] P. Smolensky, Processamento de Informação em Sistemas Dinâmicos: Fundamentos da Teoria da Harmonia, Colorado Univ em Boulder Dept of Computer Science, 1986.
- [133] R. Salakhutdinov, G. Hinton, Deep boltzmann machines, em: Inteligência Artificial e Estatística, 2009, pp. 448–455.
- [134] C. Zhang, J. Yan, C. Li, X. Rui, L. Liu, R. Bie, Sobre a estimativa da poluição do ar a partir de fotos usando rede neural convolucional, em: Proceedings of the 24th ACM International Conference on Multimedia, ACM, 2016, pp. 297-301.
- [135] N. Rijal, RT Gutta, T. Cao, J. Lin, Q. Bo, J. Zhang, Conjunto de redes neurais profundas para estimar material particulado de imagens, em: 2018 IEEE 3rd International Conference on Image, Vision and Computação, ICIVC, IEEE, 2018, pp. 733-738.
- [136] Q. Wang, T. Xie, S. Wang, Pesquisa sobre o método de reconhecimento de gases de poluição do ar com base na rede neural recorrente LSTM e matriz de sensores de gás, em: 2018 Chinese Automation Congress, CAC, IEEE, 2018, pp. 3486–3491.
- [137] X. Li, L. Peng, X. Yao, S. Cui, Y. Hu, C. You, T. Chi, Rede neural de memória de longo prazo para previsões de concentração de poluentes atmosféricos: Desenvolvimento e avaliação de métodos, Ambiente. Poluir. 231 (2017) 997-1004.
- [138] KS Rao, GL Devi, N. Ramesh, Previsão da qualidade do ar em Visakhapatnam com redes neurais recorrentes baseadas em LSTM, Int. J. Intel. Sistema Aplic. 11 (2019) 18–24.
- [139] B. Liu, S. Yan, J. Li, G. Qu, Y. Li, J. Lang, R. Gu, Um método de previsão da qualidade do ar baseado em atenção, em: 2018 17th IEEE International Conference on Machine Learning e Aplicativos, ICMLA, IEEE, 2018, pp. 728–733.
- [140] X. Zhou, J. Xu, P. Zeng, X. Meng, Previsão de concentração de poluentes atmosféricos com base no método GRU, J. Phys.: Conf. Ser. (2019) 032058.
- [141] Y. Xing, J. Yue, C. Chen, Y. Xiang, Y. Chen, M. Shi, Uma rede de crença profunda combinada com algoritmo de otimização de lobo cinzento modificado para previsão de concentração de PM2.5, Appl. Sci. 9 (2019) 3765.
- [142] M. Ashish, B. Rashmi, Previsão da poluição do ar diária usando decomposição wavelet e sistema de inferência fuzzy baseado em rede adaptativa, Int. J. Sobre. Ciência. 2 (2011) 185.
- [143] NE Huang, Z. Shen, SR Long, MC Wu, HH Shih, Q. Zheng, N.-C. Yen, CC Tung, HH Liu, A decomposição de modo empírico e o espectro de Hilbert para análise de séries temporais não lineares e não estacionárias, Proc. R. Soc. Londres. Ser. Uma matemática. Física Eng. Sci. 454 (1998) 903-995.
- [144] M. Niu, Y. Wang, S. Sun, Y. Li, Um novo modelo híbrido de decomposição e conjunto baseado em CEEMD e GWO para previsão de concentração de PM2.5 de curto prazo, Atmos. Ambiente. 134 (2016) 168-180.
- [145] C. Li, Z. Zhu, Pesquisa e aplicação de um novo sistema híbrido de alerta precoce da qualidade do ar: Um estudo de caso na China, Sci. Ambiente Total. 626 (2018) 1421-1438.
- [146] P. Jiang, C. Li, R. Li, H. Yang, Um sistema híbrido inovador de alerta precoce da poluição do ar com base na previsão de poluentes e avaliação extênicos, Knowl.-Based Syst. 164 (2019) 174-192.

- [147] E. Sharma, RC Deo, R. Prasad, AV Parisi, Uma estrutura de alerta antecipado de qualidade do ar híbrida: Um modelo de previsão de hora em hora com máquinas de aprendizado extremo sequenciais on-line e algoritmos de decomposição de modo empírico, *Sci. Ambiente Total*. 709 (2020) 135934.
- [148] K. Dragomiretskiy, D. Zosso, decomposição de modo variacional, *IEEE Trans. Processo de Sinal*. (2014) 531-544.
- [149] Y. Hao, C. Tian, O estudo e aplicação de um novo sistema híbrido para alerta precoce da qualidade do ar, *Appl. Computação Suave*. 74 (2019) 729-746.
- [150] J. Gilles, Empirical wavelet transform, em: *IEEE Trans. Processo de Sinal.*, 2013, págs. 3999–4010.
- [151] H. Liu, H. Wu, X. Lv, Z. Ren, M. Liu, Y. Li, H. Shi, Um modelo híbrido inteligente para previsão de concentrações de poluentes atmosféricos: Caso de Pequim na China, *Sustain. Cidades Soc.* 47 (2019) 101471.
- [152] H. Liu, Y. Xu, C. Chen, algoritmos híbridos de previsão de poluição melhorados baseados no método de conjunto, *Appl. Matemática. Modelo*. 73 (2019) 473-486.
- [153] K. Gan, S. Sun, S. Wang, Y. Wei, Um paradigma de aprendizagem de conjunto de decomposição secundária para a previsão de concentração de PM2.5, *Atmos. Poluir. Res.* 9 (2018) 989-999.
- [154] D. Wang, S. Wei, H. Luo, C. Yue, O. Grunder, Um novo modelo híbrido para previsão do índice de qualidade do ar com base na técnica de decomposição de duas fases e máquina de aprendizado extremo modificada, *Sci. Ambiente Total*. 580 (2017) 719-733.
- [155] D. Wang, Y. Liu, H. Luo, C. Yue, S. Cheng, Previsão de concentração da PM 2.5 do dia anterior usando o método de decomposição baseado em WT-VMD e rede neural de retropropagação melhorada pela evolução diferencial, *Int. J. Ambiente. Res. Publ. Saúde* 14 (2017) 764.
- [156] K. Siwek, S. Osowski, Melhorando a precisão da previsão da poluição PM10 pela transformação wavelet e um conjunto de preditores neurais, *Eng. Aplic. Artif. Intel.* 25 (2012) 1246-1258.
- [157] KS Lee, ZW Geem, Um novo algoritmo meta-heurístico para otimização contínua de engenharia: teoria e prática de busca de harmonia, *Comput. Métodos Aplic. Mec. Eng.* 194 (2005) 3902-3933.
- [158] P. Chen, Z. Zeng, Desenvolvendo dois algoritmos heurísticos com algoritmos metaheurísticos para melhorar soluções de problemas de otimização com restrições leves e rígidas: Uma aplicação para problemas de rostering de enfermagem, *Appl. Computação Suave*. 93 (2020) 106336.
- [159] W. Liu, G. Guo, F. Chen, Y. Chen, análise de padrão meteorológico assistida diariamente PM2.5. Previsão de 5 graus usando SVM otimizado pelo algoritmo PSO, *Atmos. Poluir. Res.* 10 (2019) 1482-1491.
- [160] Y. Teng, X. Huang, S. Ye, Y. Li, Previsão da concentração de material particulado em Chengdu com base no algoritmo de evolução diferencial aprimorado e modelo de rede neural BP, em: *2018 IEEE 3rd International Conference on Cloud Computing and Análise de Big Data, ICCCBDA*, 2018.
- [161] H. Yang, Z. Zhu, C. Li, R. Li, Um novo sistema de previsão combinado para concentração de poluentes atmosféricos com base na teoria fuzzy e otimização do peso de agregação, *Appl. Computação Suave*. 87 (2020) 105972.
- [162] Q. Wu, H. Lin, Um novo modelo híbrido ideal para a previsão diária do índice de qualidade do ar considerando fatores poluentes do ar, *Sci. Ambiente Total*. 683 (2019) 808-821.
- [163] P. Du, J. Wang, Y. Hao, T. Niu, W. Yang, Um novo modelo híbrido baseado no algoritmo de otimização multi-objetivo Harris Hawks para previsão diária de PM2.5 e PM10, *Appl. Computação Suave*. (2020) 106620.
- [164] B. Wang, Z. Tian, Previsão do índice de qualidade do ar com base em rede neural aprimorada, em: *2017 Conferência Internacional sobre Sistemas Computacionais, Eletrônica e Controle, ICCSEC, IEEE*, 2017, pp. 200–204.
- [165] W. Sun, C. Wang, C. Zhang, análise fatorial e previsão de emissões de CO2 em Hebei, usando máquina de aprendizado extremo com base na otimização de enxame de partículas, *J. Cleaner Prod.* 162 (2017) 1095-1101.
- [166] F. Zhao, W. Li, Um modelo combinado baseado na seleção de recursos e woa para previsão de concentração pm2.5, *Atmosfera* 10 (2019) 223.
- [167] L. Breiman, Florestas aleatórias, *Mach. Aprender*. 45 (2001) 5-32.
- [168] R. Martínez-España, A. Bueno-Crespo, I. Timón, J. Soto, A. Munoz, JM Cecilia, Previsão da poluição do ar em cidades inteligentes por meio de métodos de aprendizado de máquina: Um caso de estudo em Múrcia, Espanha, *J. UCS* 24 (2018) 261–276.
- [169] A. Philibert, C. Loyce, D. Makowski, Previsão de emissão de N2O a partir de informações locais com Random Forest, *Environ. Poluir.* 177 (2013) 156-163.
- [170] H. Liu, C. Chen, modelo de previsão do índice de qualidade do ar espacial baseado em decomposição, reforço adaptativo e seleção de recursos em três estágios: um estudo de caso na China, *J. Cleaner Prod.* (2020) 121777.
- [171] W. Sun, Z. Li, previsão de concentração de PM 2.5 por hora com base na técnica de decomposição-recombinação de modo e abordagem de aprendizagem em conjunto em episódios de neblina severa da China, *J. Cleaner Prod.* (2020) 121442.
- [172] C. Wen, S. Liu, X. Yao, L. Peng, X. Li, Y. Hu, T. Chi, Uma nova rede neural de curto prazo convolucional espaço-temporal para previsão de poluição do ar, *Sci. Ambiente Total*. 654 (2019) 1091-1099.
- [173] J. Wang, G. Song, Um modelo de conjunto espaço-temporal profundo para previsão da qualidade do ar, *Neurocomputing* 314 (2018) 198–206.
- [174] Y. Qi, Q. Li, H. Karimian, D. Liu, Um modelo híbrido para previsão espaço-temporal de PM2.5 com base em rede neural convolucional de gráfico e memória de curto prazo longo, *Sci. Ambiente Total*. 664 (2019) 1–10.
- [175] W. Sun, J. Sun, Previsão de concentração diária de PM 2.5 com base na análise de componentes principais e LSSVM otimizado pelo algoritmo de busca de cuco, *J. Ambiente. Gerenciar* 188 (2016) 144-152.
- [176] S. Singh, PK Sharma, B. Yoon, M. Shojafar, GH Cho, I.-H. Ra, Convergência de blockchain e inteligência artificial na rede IoT para a cidade inteligente sustentável, *Sustain. Cidades Soc.* 63 (2020) 102364.
- [177] MM Rathore, A. Paul, W.-H. Hong, H. Seo, I. Awan, S. Saeed, Explorando IoT e análise de big data: Definindo cidade digital inteligente usando dados urbanos em tempo real, *Sustain. Cidades Soc.* 40 (2018) 600-610.
- [178] S. De Vito, G. Di Francia, E. Esposito, S. Ferlito, F. Formisano, E. Massera, Estratégias de aprendizado de máquina adaptáveis para calibração de rede de dispositivos inteligentes de monitoramento de qualidade do ar IoT, reconhecimento de padrões. *Lett.* 136 (2020) 264-271.
- [179] AS Mihjiyy, L. Dupont, O. Chery, M. Camargo, C. Cai, Avaliando a qualidade do ar combinando monitoramento estacionário, móvel inteligente da poluição e modelagem orientada por dados, *J. Cleaner Prod.* 221 (2019) 398-418.
- [180] M. Asgari, M. Farnaghi, Z. Ghaemi, Mapeamento preditivo da poluição do ar urbano usando Apache Spark em um cluster Hadoop, em: *Proceedings of the 2017 International Conference on Cloud and Big Data Computing*, 2017, pp. 89–93.