

Listas de conteúdo disponíveis em [ScienceDirect](#)

Revista de Ciência e Engenharia de Gás Natural

página inicial do jornal: <http://www.elsevier.com/locate/jngse>

Artigo de revisão



Previsão do consumo de gás natural: uma discussão sobre a história da previsão e os desafios futuros

Jinyuan Liu ^{a,*,}, Shouxi Wang ^{a,**}, Nan Wei ^{b,*}, Xi Chen ^c, Hanyu Xie ^a, Jie Wang ^a^a Faculdade de Engenharia de Petróleo, Southwest Petroleum University, Chengdu, Sichuan, 610500, China^b Instituto de Tecnologia Avançada do Ciberespaço, Universidade de Guangzhou, Guangzhou, 510000, China^c Instituto de Pesquisa de Exploração e Desenvolvimento da PetroChina HuaBei Oilfield Company, Hebei, 062552, China

INFORMAÇÕES DO ARTIGO

Palavras-chave:

Previsão de consumo de gás natural
Horizontes de previsão
Fatores de influência
Previsão de desempenho
Fase de previsão

RESUMO

A tecnologia de previsão do consumo de gás natural é pesquisada há 70 anos. Este artigo revisa o histórico da previsão do consumo de gás natural e discute as mudanças nos horizontes de previsão, fatores de influência e desempenho da previsão. De acordo com as características dos modelos de previsão utilizados em diferentes períodos, o histórico de previsão do consumo de gás natural pode ser categorizado em estágio inicial, estágio convencional, estágio de IA e estágio geral. As características do estágio, modelos típicos, vantagens e desvantagens em diferentes estágios foram resumidas. Os resultados da revisão mostram que, afetada pelo desenvolvimento da ciência da computação e da tecnologia de IA, a previsão de curto prazo é o horizonte de previsão de crescimento mais rápido, seguido por longo e médio prazo. Além disso, a previsão de longo prazo é afetada principalmente pela produção, população e variáveis econômicas. A previsão de médio prazo é afetada principalmente por variáveis econômicas e de temperatura. Os fatores que influenciam a previsão de curto prazo dependem principalmente das variáveis de temperatura, condições climáticas e tipo de data.

Além disso, a análise estatística das características dos dados, características do modelo e resultados de previsão mostra que os modelos de séries temporais são os melhores modelos para previsão de longo prazo. Possui o menor erro percentual médio absoluto (1,90%) na previsão de longo prazo. Para a previsão de médio e curto prazo, os modelos baseados em IA apresentam o melhor desempenho. Entre eles, os modelos de redes neurais artificiais (2,21%) são os preferidos para previsão de médio prazo, e os modelos de regressão vetorial de suporte (4,98%) são mais adequados para previsão de curto prazo. Além disso, este artigo propõe uma estrutura para seleção de modelos e fornece sugestões específicas para futuras direções de pesquisa.

1. Introdução

Desde que o gás natural se tornou a principal fonte de energia para o desenvolvimento sustentável, a demanda por gás natural cresceu exponencialmente em todo o mundo. A Fig. 1 mostra o desenvolvimento do gás natural em várias regiões do mundo de 1990 a 2019 (Enerdata, 2020). Observa-se que o consumo de gás natural vem crescendo desde 1990, sendo que os consumos nos últimos cinco anos são 3555, 3631, 3725, 3917 e 4018bcm, respectivamente. O consumo em larga escala de gás natural não só reflete o sucesso das políticas de proteção ambiental e o rápido crescimento da economia, mas também contribui para a gestão ineficaz do abastecimento de gás. Uma gestão eficaz do fornecimento de gás depende principalmente da tecnologia de previsão precisa do consumo de gás natural, que pode ajudar países e empresas a formular gás razoável

planos de fornecimento, gerenciar contratos de fornecimento, melhorar a eficiência operacional, fornecer dados básicos para planejamento de produção e construção de infraestrutura, economizando energia e reduzindo custos. Refere-se à segurança, confiabilidade e benefícios econômicos dos sistemas nacionais e corporativos de fornecimento de gás. Por exemplo, 98% do consumo de gás natural da Turquia é adquirido por meio de uma empresa estrangeira de gás natural. Se não houver previsão precisa de consumo, o prejuízo chegará a bilhões de dólares. Portanto, a previsão do consumo de gás natural é essencial para o desenvolvimento sustentável de qualquer país.

Muitas pesquisas sobre tecnologia de previsão de consumo de gás natural foram realizadas até o momento, e centenas de modelos avançados de previsão foram desenvolvidos para melhorar a precisão, incluindo modelos estatísticos tradicionais, modelos baseados em IA e modelos combinados.

Dois pesquisadores já revisaram essas técnicas de previsão existentes. Soldo (2012) revisou quase todos os trabalhos na área de

* Autor correspondente.

** Autor correspondente.

Endereços de e-mail: a7liujinyuan@163.com (S. Wang), joey_weinan@126.com (N. Wei).<https://doi.org/10.1016/j.jngse.2021.103930> Recebido

em 6 de janeiro de 2021; Recebido em formulário revisado em 22 de fevereiro de 2021; Aceito em 9 de março de 2021

Disponível online em 22 de março de 2021

1875-5100/© 2021 Elsevier BV Todos os direitos reservados.

Abreviaturas		LR	Regressão linear
		LS	Mínimos Quadrados
AFF		Memória de Longo Prazo LSTM	
AFL		MA Média Móvel	
AFLC		MAD Desvio Absoluto Médio	
IA		Erro Absoluto Médio MAE	
Sistema de Inferência Fuzzy Baseado em Rede Adaptativa ANFIS		Erro de Porcentagem Absoluta Média MAPE	
Rede Neural Artificial ANN		Erros normalizados de intervalo absoluto médio MARNE	
COM		MLP Multilayer Perceptron	
ESTÃO		Regressão Linear Múltipla MLR	
Média Móvel Integrada Autoregressiva ARIMA		Erro de Porcentagem Absoluta Normalizada Média MNAPE	
Média Móvel Autoregressiva ARMA		SENHOR	
BANIMENTO		Regressão múltipla	
Rede Neural de Propagação Regressiva BPNN		Erro quadrado médio MSE	
CBR		NLR	
CC		Regressão Não Linear	
Algoritmo genético de mapeamento caótico de gato CCMGA		Modelo Cinza Metabólico Não Linear NMGM	
CDD		Erro quadrado médio normalizado NMSE	
FC		Análise de Correlação de Componentes Principais PCCA	
CPI		Curva polinomial PCMACP e combinação de média móvel	
DEA		Projeção	
DL		PSO	
Mineração de dados DM		Otimização de enxame de partículas	
DmGNN Data mining Rede genética-neural		R2	
Rede Neural Profunda DNN		Coeficiente de correlação ao quadrado	
ELFIS		Rede Neural de Função de Base Radial RBFNN	
Rede Neural Elman ELNN		Máquinas Boltzmann restritas RBM	
Análise de Envoltório de Dados Fuzzy FDEA		RÉ	
Rede neural de feedforward FFnn		Erro quadrático médio RMSE	
Algoritmo de Otimização FFOA Fruit Fly		Rede Neural Recorrente RNN	
FGC		Máquina de vetores de relevância RVM	
Monitoramento de Previsão FM-MLP-Perceptron em várias camadas		em	
FNN		Recozimento simulado	
FSA		SARIMAX Sazonal Autoregressivo Integrated Moving Average com	
GA		variáveis adicionais	
Previsor de Carga Automatizado de Gás GAULF		Regressão de vetor de suporte calibrado com estrutura SC-SVR	
PIB		SD	
GIP		Desvio padrão	
Modelo GM Cinza		SE	
Rede Neural de Regressão Generalizada GRNN		Programa de Avaliação de Estratégia	
Dia do grau de aquecimento do HDD		SFA	
AGORA		Análise de Fronteira Estocástica	
Algoritmo de otimização de baleias aprimorado da IWOA		Modelo cinza inteligente autoadaptável SIGM	
PMD		Vetor de suporte de otimização mínima sequencial SMOSVM	
LGA		Máquina	
LM		SOFM-MLP Mapa de recursos auto-organizado Perceptron de várias camadas	
LogR Regressão Logística		Máquina de vetores de suporte SVM	
		SVR	
		SVD	
		TS	
		WMAPE MAPE ponderado	
		Rede Neural WNN Wavelet	
		Transformada Wavelet WT	

previsão de consumo e produção de gás natural de 1949 a 2010, discutida em termos de área aplicada, horizonte de previsão, dados de entrada e modelos. Tamba et al. (2018) estenderam o trabalho de Soldo para 2015, eles forneceram análise e síntese de trabalhos publicados sobre modelos e área aplicada, dados de entrada, fonte de dados, tamanho dos dados, horizonte de previsão, resultados e desempenho do modelo. No entanto, Soldo e Tamba apenas listaram e classificaram os trabalhos nessas áreas. Ainda não há pesquisas relacionadas que possam descrever a história da previsão do consumo de gás natural e resumir as características em diferentes etapas de forma clara. Além disso, faltam estudos de revisão que discutam o histórico de desenvolvimento de uma perspectiva mais multivariada, incluindo horizonte de previsão, fatores de influência e desempenho de previsão.

Para diminuir essas lacunas de conhecimento, este artigo revisa sistematicamente a história da previsão do consumo de gás natural, resume as características, modelos típicos, vantagens e desvantagens em cada

diferentes estágios, discute as mudanças nos horizontes de previsão, fatores de influência e desempenho da previsão e propõe as perspectivas e sugestões para futuras direções de pesquisa. O restante deste trabalho está organizado da seguinte forma: Na seção 2, é descrita a metodologia de pesquisa deste trabalho. A seção 3 revisa o histórico de previsão do consumo de gás natural com base no desenvolvimento de modelos de previsão, discute as mudanças no histórico de previsão. A seção 4 deste artigo apresenta as futuras direções de pesquisa e sugestões para a previsão do consumo de gás natural. As principais conclusões são apresentadas na Seção 5.

2. Metodologia

O método de pesquisa deste trabalho pode ser resumido da seguinte forma:

- Pesquisando os documentos relacionados

Motores de busca: Google scholar, uma poderosa ferramenta de busca de papel, que são críticos para os pesquisadores acadêmicos.

Palavras-chave de pesquisa: As palavras-chave de pesquisa usadas neste documento incluem: previsão de carga de gás, previsão de carga de gás, previsão de consumo de gás, previsão de consumo de gás, previsão de demanda de gás e previsão de demanda de gás.

Período de busca: Desde o surgimento do primeiro modelo de previsão de consumo de gás natural até o presente (1950–2019).

Nesta etapa, foram coletados 98 trabalhos.

• Triagem dos papéis coletados

Existem dois critérios para triagem de artigos. Em primeiro lugar, deve ser um documento relacionado com a previsão de consumo de gás natural, e não inclui outras fontes de energia, exceto o gás natural, nem considera a previsão de preço, produção de gás natural, etc. Em segundo lugar, o documento deve incluir pelo menos um método de previsão.

Nesta etapa, foram selecionados 72 artigos dentre os 98 artigos pesquisados.

• Revisando os papéis

Revise o modelo de previsão, área aplicada, país, horizonte de previsão, tamanho dos dados, fator de influência e desempenho de todos os documentos coletados.

Nesta etapa, todos os resultados de 72 artigos publicados foram listados no Anexo.

• Apresentando a história e o futuro da tecnologia de previsão de consumo de gás natural

Na seção 3, o histórico da tecnologia de previsão de consumo de gás natural foi dividido em quatro etapas com base no desenvolvimento de modelos de previsão, resumindo as características, modelos típicos, vantagens e desvantagens de cada etapa. Além disso, discutiu-se como o horizonte de previsão, o fator de influência e o desempenho da previsão (3 indicadores com mudanças significativas) mudaram ao longo do desenvolvimento da tecnologia de previsão de consumo de gás natural.

A seção 4 apresentou as futuras direções de pesquisa para a previsão do consumo de gás natural e forneceu sugestões específicas para a seleção de modelos e parâmetros.

Nesta etapa, as características, modelos típicos, vantagens e desvantagens para cada etapa histórica foram listadas na tabela correspondente.

3. Histórico de previsão de consumo de gás natural

A pesquisa sobre a previsão do consumo de gás natural começou na década de 1950. De acordo com as características dos modelos de previsão utilizados em diferentes períodos, o histórico de desenvolvimento pode ser dividido em quatro

estágios: estágio inicial (1950–1970), estágio convencional (1970–1992), estágio de inteligência artificial (IA) (1992–2006) e estágio geral (2006–presente). A Fig. 2 apresenta os eventos mais importantes na história do desenvolvimento da previsão do consumo de gás natural.

3.1. Estado inicial

A fase inicial da previsão do consumo de gás natural foi 1950–1970. Limitados pelas condições de computação para trás, os cientistas neste período estabeleceram modelos estatísticos estruturais simples que se baseiam principalmente em fatores, como preços do gás natural, renda nacional, produção, volume de comércio, etc., para prever o consumo de gás natural a longo prazo (Durrer et al., 1969; Elliott e Linden, 1968). Modelos estatísticos poderiam prever tendências futuras por meio do estabelecimento de relações entre uma ou mais variáveis independentes e dependentes (Catalina et al., 2013). Não só pode obter resultados de previsão confiáveis, mas pode ser usado para encontrar a relação entre o consumo de gás e os fatores de influência (Tse kouras et al., 2007). Modelos de estatísticas iniciais, incluindo modelo de curva de Hubbert, modelo exponencialmente ponderado, modelo de mínimos quadrados, modelo de regressão logística, modelo de curva de Gompertz, etc.

Verhulst (1950) considerando o consumo de gás natural em função da renda primária do usuário e do preço do gás, estabeleceu um modelo de previsão baseado na análise da demanda de 46 usinas de gás natural na França.

Durante o mesmo período, Hubbert propôs uma curva de crescimento logarítmica chamada “curva de Hubbert” (Hubbert, 1949, 1956), que pode descrever as mudanças na produção de petróleo analisando o ciclo de vida da produção de energia fóssil nos Estados Unidos. O modelo de curva previu com sucesso o pico de produção de petróleo dos EUA de 1967 a 1973 com quase 10 anos de antecedência, tornando a “curva de Hubbert” extremamente famosa, e muitos pesquisadores a aplicaram à previsão do consumo de gás natural (Al-Fattah e Startzman, 2000; Siemek et al., 2003; Wang et al., 2016).

Berrisford (1965) acreditava que o sucesso da previsão de demanda de gás natural dependia fortemente de encontrar o melhor modelo ponderado para as temperaturas atuais e anteriores. Portanto, foi proposto um modelo de previsão exponencialmente ponderado que não precisava considerar padrões sazonais. O novo modelo melhorou muito a capacidade de ajuste de dados, e a precisão pode ser mantida mesmo sob condições climáticas anormais prolongadas. Ward (1965) usou modelos estatísticos de mínimos quadrados, semi-logarítmicos e duplo-logarítmicos para prever o consumo de energia nos próximos 7 anos, e apontou que a previsão de carga anual precisa requer uma perspectiva profissional, como petróleo e economia, para considerar todos fatores internos e externos que podem afetar o consumo de energia para obter melhores previsões.

Balestra e Nerlove (1966) desenvolveram um modelo de previsão denominado modelo BAN, baseado no método dos mínimos quadrados ordinários, para prever a demanda de gás natural no setor residencial e comercial. O modelo proposto fornece um começo significativo para a previsão de longo prazo do consumo de gás natural (Berndt et al., 1980). Johnson (1968) propôs que, exceto por fatores inerentes, como renda nacional,




Fig. 1. Estatísticas de consumo de gás natural em diferentes regiões (Enerdata, 2020).

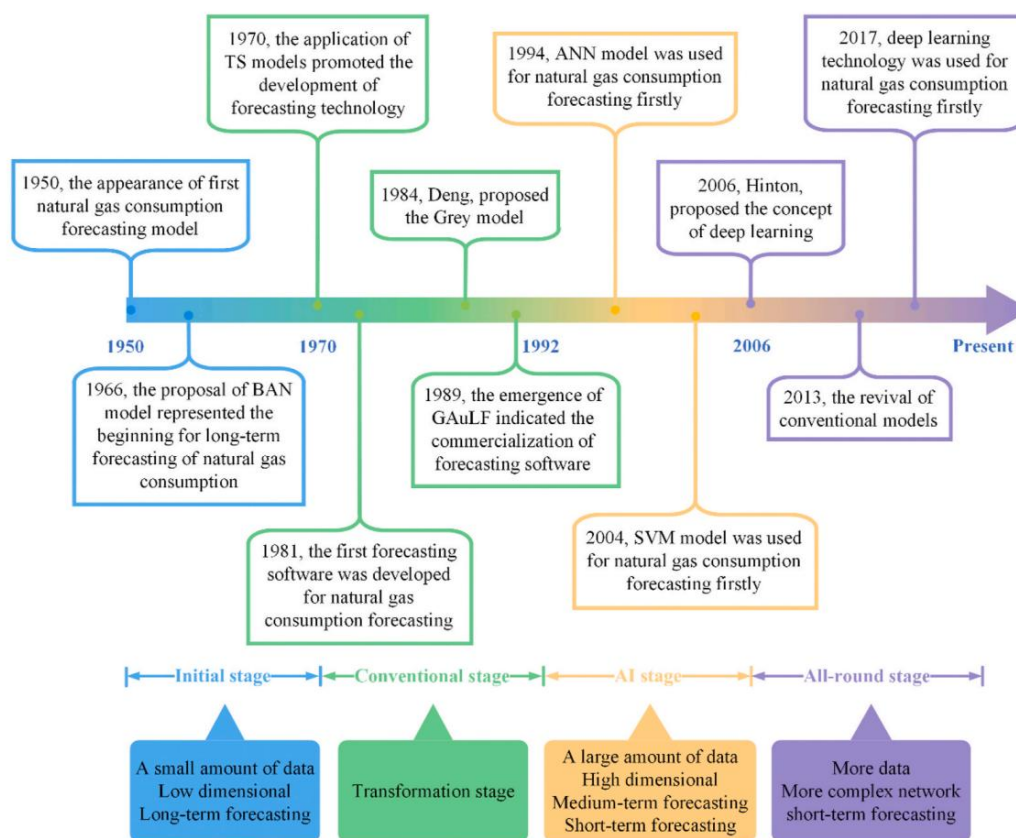


Fig. 2. Histórico de desenvolvimento da previsão de consumo de gás natural.

Tabela

1 Fase Inicial - Visão geral dos artigos publicados por anos.

Ano de publicação	Referências
1950	Verhulst
1956	Hubbert
1965	Berrisford, Ward
1966	Balestra e Nerlove Elliott
1968	e Linden, Johnson Durrer et al.
1969	

temperatura efetiva, etc., também é necessário prever as vendas de equipamentos a gás e aquecimento central para obter resultados de previsão precisos. Após aplicar o modelo de curva lógica logarítmica e o modelo de curva de Gompertz para prever as vendas de equipamentos a gás, a tecnologia de regressão múltipla foi combinada para prever o consumo de gás natural nos próximos anos no Reino Unido.

Limitados pela tecnologia de computação atrasada e pela falta de dados, os modelos de previsão nesta fase são principalmente modelos estatísticos, e os pesquisadores neste período se concentraram em usar uma fórmula matemática simples para descrever as tendências de consumo de gás nacional ou global. No entanto, os modelos estatísticos só podem explicar a relação entre consumo e variáveis com estrutura simples. Não pode descrever com precisão a tendência de desenvolvimento do consumo de gás e conter mais dados históricos e variáveis. Portanto, as primeiras previsões de consumo focavam principalmente em previsões de longo prazo com baixo volume de dados, baixa dimensão e longo prazo.

3.2. Estágio convencional

A pesquisa sobre previsão de consumo de gás natural entrou na fase Convencional de 1970 a 1992. O surgimento de microcomputadores e o aprimoramento da capacidade de cálculo promoveram a

desenvolvimento de modelos estatísticos (Caton, 1984; Haenel, 1973; Piggott, 1983; Tinic et al., 1973). Muitos modelos clássicos de previsão surgiram, como modelos TS e modelos de regressão (LR e NLR). Em comparação com modelos de previsão anteriores, os modelos que aparecem neste período melhoraram significativamente as capacidades de processamento de relações não lineares entre dados (Berndt e Watkins, 1977; Lyness, 1981, 1984; Taylor e Tomas, 1982; Wang et al., 2019). Portanto, a previsão do consumo de gás natural não está mais limitada a uma pequena quantidade de dados e previsões de longo prazo de baixa dimensão, um grande número de dados, previsões de médio e curto prazo de alta dimensão começaram a aparecer (Tso e Yau, 2007).

Em 1970, o livro *Time Series Analysis: Forecasting and Control*, publicado por Box e Jenkins, discutiu a aplicação de vários modelos TS na previsão e revelou o prelúdio para a previsão do consumo de gás natural com base em modelos TS. Os modelos TS podem prever tendências futuras em uma pequena quantidade de dados históricos sem variáveis externas (Azadeh e Tarverdian, 2007; Nadimi e Tokimatsu, 2017), incluindo o modelo Autoregressivo (AR) (Andersen et al., 2013, 2014), Moving-average (MA) (Xu e Wang, 2010), modelo de média móvel autorregressiva (ARMA) (Pappas et al., 2010), média móvel integrada autorregressiva (ARIMA) (Conejo et al., 2005) e outros modelos TS melhorados (Zhu e outros, 2014).

Pepper (1985) construiu um modelo ARIMA de variáveis de entrada e saída multidimensionais baseado no algoritmo de Box-Jenkins, que foi usado para prever o principal consumo de energia, incluindo petróleo, eletricidade e gás natural no Reino Unido. Drevna (1985) adicionou uma função de transferência ao modelo ARIMA. Comparado com o modelo econômico, o modelo ARIMA aprimorado reduziu a entrada de parâmetros do modelo e apresentou mais precisão que o ARIMA. Nelder e Wedderburn (1972) propuseram um modelo linear generalizado que unificou LR e logR em um sistema. Herbert (1987b) estabeleceu um modelo LR e introduziu variáveis econômicas, como preço do gás, custos de eletricidade, demanda de aquecimento, tributação cumulativa, etc., para prever a demanda mensal de gás industrial

mesa 2

Fase convencional - Visão geral de artigos publicados por anos.

Ano de publicação	Referências
1971	Rodger et al.
1972	Nelder e Wedderburn
1973	Haenel, Tinic et al.
1977	Berndt e Watkins
1981	Lyness Taylor e Tomas
1982	Piggott Lyness, Caton
1983	Drevna, Pepper Herbert
1984	et al. (1987a, 1987b)
1985	
1987	
1989	Jabbour e Meyer Liu e
1991	Lin

e gás residencial (Herbert, 1987a). O erro relativo dos resultados de previsão foi baixo para 0,7%.

Rodger et al. (1971) integrou os métodos de previsão do Scottish Gas Board para diferentes tipos de previsão (industrial, comercial, residencial), e estabeleceu um modelo de previsão de regressão combinada que pode prever com precisão o pico de consumo diário. Gray Model (GM) proposto pelo professor chinês Julong Deng em 1984, pode descrever as tendências de desenvolvimento vagamente através de uma pequena quantidade de informações incompletas. O modelo proposto gerou uma acirrada discussão no meio acadêmico, e tem sido amplamente utilizado em diversos campos de pesquisa.

Em 1989, o GAuLF (Gas Automated Load Forecaster) foi desenvolvido para ajudar os operadores de gás da Niagara Mohawk Power Corporation (NMPC) a estimar a demanda de gás de curto prazo por Jabbour e Meyer (1989). Como um software comercial desenvolvido para previsão de consumo de gás natural, a aplicação do GAuLF representou que a tecnologia de previsão estava amadurecendo gradativamente, e seus produtos derivados foram se tornando mais comercializados. Liu e Lin (1991) adotaram um modelo de função de transferência linear, baseado em duas variáveis independentes de preço e temperatura do gás natural, para prever o consumo de médio prazo de residências em Taiwan, e concluíram que a temperatura era o principal fator que afetava a precisão do previsão de prazo. A visão geral dos artigos publicados no estágio convencional está listada na Tabela 2.

O surgimento dos microcomputadores e a melhoria da capacidade de cálculo resultaram em muitos modelos estatísticos aprimorados, fazendo com que os modelos neste estágio tenham capacidades não lineares mais fortes do que no estágio inicial. As direções de pesquisa neste período também começaram a mudar para previsões de curto e médio prazo com mais dados, maior dimensão e menor intervalo de tempo. No entanto, o cálculo dos modelos estatísticos aprimorados ainda é baseado em uma pequena quantidade de dados históricos, e a precisão dos modelos depende em grande parte do tamanho do conjunto de dados selecionado. Portanto, os modelos estatísticos aprimorados não aprenderão mudanças suficientes com base em uma pequena quantidade de conjunto de dados e não poderão refletir com precisão a relação entre consumo e variáveis.

3.3. Estágio de IA

O estágio dos modelos baseados em IA foi 1992-2006. A proposta de algoritmo de retropropagação (Rumelhart et al., 1986) e Máquina de Vetor de Suporte não linear (SVM) (Boser et al., 1992) representou o surgimento do aprendizado de máquina no campo da IA (Musilek et al., 2006; Suykens et al., 1996). Também promoveu uma tendência de que os modelos estatísticos tradicionais e os modelos de aprendizado de máquina avançassem juntos na previsão do consumo de gás natural (Magoules e Zhao, 2016). Comparados aos modelos estatísticos, os modelos de aprendizado de máquina têm vantagens óbvias no processamento de dados não lineares complexos, especialmente alta precisão na previsão de consumo de curto prazo (Ivezic, 2006; Peng et al., 2019; Szoplik, 2015). Portanto, a tecnologia de aprendizado de máquina foi utilizada para prever o consumo de gás natural neste período tornou-se pesquisa

hotspots na academia (Bai e Li, 2016; Lee e Tong, 2011; Pelikan e Simunek, 2005).

Modelos de aprendizado de máquina são uma subclasse de modelos de IA, modelos representativos incluem Rede Neural Artificial (RNA) e Regressão de Vetor de Suporte (SVR) (Gerven e Bohte, 2018). Na verdade, a RNA é uma estrutura para muitos modelos de redes neurais diferentes trabalharem juntos e processarem dados de entrada complexos, não um modelo específico. Os modelos de RNA aplicados no campo da previsão de consumo de gás natural incluem: Feedforward Neural Network (FFNN) (Azadeh et al., 2013b; Jebaraj et al., 2011; Kermanshahi, 1998; Soldo et al., 2014), Back Propagation Neural Network (BPNN) (Demirel et al., 2012; Miura e Sato, 1998; Peharda et al., 2001; Yu e Xu, 2014), Rede Neural de Função de Base Radial (RBFNN), Sistema de Inferência Fuzzy Baseado em Rede Adaptativa (ANFIS) (Azadeh et al., 2011, 2013a; Kaynar et al., 2011) e Wavelet Neural Network (WNN) (Bhaskar e Singh, 2012; Catalao et al., 2011; Zhang et al., 2018; Zhang e Wang, 2012), etc. Como os primeiros modelos de RNA, FFNN e BPNN têm a mesma estrutura, a diferença está apenas no método de cálculo do erro de treinamento, ambos são chamados de modelos de RNA em muitos estudos de previsão (Amber et al., 2018; Jebaraj et al., 2011; Soldo et al., 2014).

Brown et al. (1994) usaram o modelo FFNN para prever o consumo diário de uma determinada área em Milwaukee, Wisconsin. Os resultados indicaram que o erro quadrático médio residual de FFNN foi de 48% dos modelos de regressão linear usando os mesmos fatores (Brown e Matin, 1995). Klement e Kout (1999) combinaram algoritmo CBR, algoritmo NLR processado por SVD e BPNN baseado em regras delta, propuseram um algoritmo geral de previsão baseado em tecnologia de IA e análise estatística clássica. O MAPE do modelo combinado foi de cerca de 4%, o que pode prever com sucesso o envio na rede local de distribuição de gás.

Khotanzad e Elragal (1999) propuseram três métodos de previsão de dois estágios baseados em RNA. Na primeira etapa desses três métodos, dois ou três modelos de RNA adaptativos foram usados para prever o consumo diário. Na segunda etapa, combinação ponderada, combinação não linear de funções e combinação genética fuzzy foram aplicadas para combinar os resultados da previsão. Os resultados de previsão desses três métodos mostraram que o modelo combinado proposto pode fornecer resultados mais precisos do que usar um único preditor (Elragal, 2004; Khotanzad et al., 2000).

Gorucu et al. (2004) usaram o BPNN para prever o consumo diário em condições otimistas (estabilidade econômica) e pessimistas (crise econômica) em Ancara, na Turquia. Os resultados foram satisfatórios e lógicos. Viet e Mandziuk (2005) adotaram modelo de previsão ingênuo, modelos de regressão linear e quadrática, rede feedforward única, redes neurais feedforward combinadas, redes de contexto de temperatura, modelo de previsão de dias úteis, rede neural fuzzy única para prever o consumo de 3 horizontes de previsão diferentes em áreas rurais e áreas urbanas na Polônia. Os resultados mostraram que a acurácia dos modelos de rede neural foi melhor que os modelos convencionais, e o desempenho do FNN é melhor que o da RNA nos modelos de rede neural.

Embora a RNA tenha melhor desempenho na previsão de curto prazo, ela ainda possui defeitos inerentes, como velocidade de convergência lenta, baixa capacidade de generalização, otimização local e overfitting, etc. SVR para evitar os defeitos da RNA de forma eficaz (Bai et al., 2018; Beyca et al., 2019). Liu et al. (2004a) consideraram a influência da temperatura e feriados no consumo e adotaram SVM, LS-SVM e SOFM-MLP para prever o consumo diário em Xi'an. O MAPE dos três modelos foi de 1,6246%, 1,704% e 3,3059%, respectivamente. Indica-se que o método de previsão baseado em SVM é melhor que o método de rede neural (Liu et al., 2004b). Zhu et al. (2015) propuseram um SVR melhorado para prever o consumo de curto prazo da rede nacional de gasodutos no Reino Unido e provaram que o modelo tem um erro menor do que ARMA e ANN. O MAPE mais baixo foi de apenas 3,4%. Visão geral de

Tabela

3 AI Stage-Overview de artigos publicados por anos.

Ano de publicação	Referências
1994	Brown et al.
1995	Marrom e Matin
1996	Suykens et al.
1998	Miura e Sato
1999	Klema e Kout, Khotanzad e Elragal Al-Fattah e
2000	Startzman, Khotanzad et al.
2001	Peharda et al.
2003	Siemek et al.
2004	Elragal, Gorucu et al., Liu et al. (2004a, 2004b)
2005	Viet e Man'dziuk, Pelikan e Simunek Musilek et al.
2006	Ivezic

artigos publicados no estágio de IA estão listados na Tabela 3.

Graças ao avanço da informática e da inteligência artificial, os modelos de previsão nesta fase puderam realizar cálculos mais complexos. Em particular, o aparecimento de ANN e SVM melhorou muito a capacidade de aprendizado e a capacidade de ajuste não linear dos modelos de previsão. Além disso, os modelos de previsão neste período poderiam levar em consideração mais variáveis, lidar melhor com a interação entre características não lineares e extrair as regras razoáveis entre entrada e saída automaticamente para prever as tendências de desenvolvimento. Assim, os pesquisadores passaram a focar em previsões de médio e curto prazo, que demandam uma grande quantidade de dados.

Apesar dessas vantagens, os modelos nesta fase ainda têm suas falhas inerentes. A estrutura e os parâmetros dos modelos de previsão sempre foram diferentes, e até agora não existe uma teoria unificada para declarar como construir a estrutura e os parâmetros. Tentativa e erro é a única maneira de resolver esses problemas. Além disso, as capacidades de aproximação e promoção do modelo estão intimamente relacionadas às amostras de aprendizado, e é um problema difícil selecionar amostras razoáveis para formar o conjunto de treinamento. Além disso, convergência lenta, tempo computacional longo, overfitting e underfitting sempre foram os defeitos dos modelos de previsão nesta fase.

3.4. Palco todo-o-terreno

Desde 2006, a pesquisa sobre a previsão do consumo de gás natural entrou em um estágio de desenvolvimento integral. Maior conscientização sobre conservação de energia e proteção ambiental, promoção de conceitos de economia verde, eclosão da revolução do gás de xisto, avanço na pesquisa de hidratos de gás natural, etc., todos indicaram a importância do gás natural na estrutura energética futura. Países ao redor do mundo também estão pedindo vigorosamente a promoção e aplicação do gás natural (Liu et al., 2019). Nesse período, o número de trabalhos de pesquisa sobre previsão de consumo de gás natural aumentou e envolve principalmente três aspectos: o surgimento do modelo de aprendizado profundo, a aplicação do modelo combinado e a retomada do modelo convencional.

3.4.1. Aparecimento do modelo de aprendizado

profundo Em 2006, com o aprimoramento da capacidade computacional, o cientista britânico Hinton estabeleceu uma rede neural multicamada e propôs o conceito de aprendizado profundo (DL) primeiramente, marcando a pesquisa sobre aprendizado de máquina entrando no campo de aprendizado profundo. aprendendo gradualmente (Chen et al., 2018). O modelo Long Short-Term Memory (LSTM) é uma forma especial de RNN e também o modelo de deep learning mais popular (Ghasemi et al., 2018) atualmente. Ele pode efetivamente resolver o problema de desaparecimento de gradiente de RNN, e a informação do momento anterior é registrada em cada célula através da variável de estado ao mesmo tempo, tornando a conexão de informação entre os diferentes momentos. Portanto, é amplamente utilizado para resolver vários problemas de previsão de séries temporais (Graves, 2012; He, 2017).

Em 2019, Wei et al. modelo LSTM empregado sucessivamente, combinado com algoritmo de análise de recursos (Wei et al., 2019b) e redução de ruído de dados

Algoritmo (Su et al., 2019; Wei et al., 2019c), para prever o consumo diário em diferentes regiões. Os resultados mostraram que o modelo LSTM tem maior precisão e melhor robustez do que o modelo de aprendizado de máquina e o modelo de regressão. Laib et al. (2019) desenvolveram um modelo de dois estágios de Previsão Monitor-Multilayer Perceptron LSTM para prever o consumo horário na Argélia. O MAPE médio deste método foi de 5,48%, que foi 16,42%, 14,41%, 13,50% e 56,75% menor que MLP, LSTM, SARIMAX e MLR, respectivamente. Su et al. (2019) combinou a transformada wavelet, modelo bidirecional-LSTM multicamadas, modelo GA e LSTM para estabelecer um modelo de previsão robusto. Os resultados indicaram que o modelo estabelecido foi superior ao LSTM de três camadas e aos modelos autorregressivos não lineares.

Merkel et al. (2017) usaram o modelo DNN baseado no algoritmo RBM para prever o consumo de gás natural em 176 regiões operacionais nos Estados Unidos. Os resultados mostraram que o RBM-DNN tem melhor desempenho de previsão do que os modelos RNA e LR, independentemente de quaisquer condições, e um desempenho melhor no fluxo mais alto (Merkel et al., 2018). Hafezi et al. (2019) propuseram um modelo de previsão inteligente DmGNn baseado no algoritmo DMjANN e GA para prever a demanda global de GN. Os resultados mostraram que o DmGNn proposto (MAPE 1,69%) foi significativamente melhor que os modelos MLP (3,8%), ANFIS (1,89%), RBFNN (10,42%) e GRNN (4,17%) (Liu et al., 2020). Hribar et al. (2019) adotou a RNN para prever o consumo residencial em Ljubljana, Eslovênia. Comparado com os modelos LR, KM, TRM, TLM e TNM, o RNN tem o MAPE mais baixo (9,3% por hora, 6,8% por dia).

3.4.2. Aplicação do modelo combinado Para

superar os defeitos inerentes ao modelo único, muitos algoritmos de otimização, como PSO, GA, etc., foram propostos para combinar com o modelo de previsão. As pesquisas relacionadas provaram que a combinação do modelo com algoritmos de otimização de parâmetros, algoritmos de pré-processamento de dados e algoritmos de seleção de recursos pode efetivamente melhorar a precisão do modelo de previsão (Akpınar et al., 2017; Cao e Wu, 2016; Kizilaslan e Karlik, 2008; Wang e Jiang, 2019).

Vitolo et al. (2009) utilizaram os algoritmos MLR, ANN e GD (algoritmo combinado de MLR e ANN) para prever o consumo de gás nos próximos 30 dias em 14 áreas operacionais. A conclusão mostrou que o desempenho do modelo combinado foi significativamente melhor do que outros modelos. Azadeh et al. (2013a) propuseram um algoritmo integrado ANFIS-DEA-FDEA para melhorar a previsão de longo prazo em cinco países sul-americanos. Os resultados mostraram que o modelo combinado foi superior ao algoritmo LR, e possui melhor superioridade e robustez (Azadeh et al., 2015). No caso da previsão do consumo de gás natural das principais cidades da Grécia, o modelo proposto por Panapakidis e Dagoumas (2017) combinou algoritmo de decomposição wavelet, GA, ANFIS e FFNN, o que pode efetivamente reduzir 13,04% do MAPE do ANFIS.

Fan et al. (2018) combinaram o mecanismo de tendência de mudança anual de ações com os algoritmos GM (1,1), SIGM e GA para estabelecer o modelo GM-S-SIGM-GA. Os resultados mostraram que o modelo combinado foi superior a outros modelos baseados em cinza, e tem a maior precisão de previsão em MAPE (4,48%), RMSE (11,59) e MAE (8,41). Qiao et al. (2019) propuseram um modelo de previsão híbrido, que integrou algoritmos IWOA e RVM, para prever o consumo horário de gás na estação Lixin Gate e na estação Sanshibu Gate em Anhui, China. Os resultados mostraram que, comparado aos algoritmos RBFNN, GRNN, ELNN, LSSVM e SMOSVM, o modelo IOWA-RVM possui maior precisão de previsão, e seu MAPE é de apenas 0,02% (Qiao et al., 2020).

Lu et al. (2019) integrou algoritmos FFOA, SA, CF e SVM para prever o consumo de gás natural em Kunming, China. Comparado com PSO-SVM, BPNN, GM (1, 1) e ARIMA, o algoritmo CF-SA-FFOA-SVM tem o MAPE mais baixo (3,07%). O algoritmo genético de vida e SVR foram combinados por Wei et al. (2019a) para prever o consumo diário em 12 meses do ano, respectivamente. O erro absoluto do resultado da previsão foi melhorado em quase 50% em comparação com o modelo GA-SVR.

3.4.3. Renascimento do modelo convencional

O advento da era do big data faz com que os pesquisadores prefiram modelos baseados em IA com poderosos recursos de processamento de dados. Embora os modelos baseados em IA tenham vantagens na precisão e eficiência da computação, as desvantagens também são óbvias (Liu et al., 2020). Como um modelo orientado a dados, os modelos baseados em IA prestam mais atenção aos dados em si e otimizam os parâmetros do modelo por meio de treinamento para obter os resultados. Durante esse processo, é difícil para os usuários observar a relação entre as diferentes variáveis e a forma específica do modelo, e difícil explicar ou modificar os resultados. No entanto, os modelos estatísticos tradicionais têm forte interpretabilidade. Nos últimos anos, pesquisas têm mostrado que, quando os parâmetros são selecionados de forma razoável, o desempenho dos modelos estatísticos tradicionais é comparável aos modelos baseados em IA (Potočnyk et al., 2014). Portanto, apesar do rápido desenvolvimento de vários modelos baseados em IA, os modelos estatísticos tradicionais ainda podem ter seu efeito no campo da previsão do consumo de gás natural.

Taspiner et al. (2013) empregaram modelos MLR, SARIMAX, ANN-MLP e ANN-RBFNN para prever o consumo diário na província de Sakarya. O resultado mostrou que o desempenho do modelo TS SARIMAX foi melhor que o modelo ANN. Akpinar e Yumusak adotaram os dados diários de consumo de gás, fornecidos pela AGDAS Company (Erdem, 2020) em turco, para verificar a precisão da previsão de MLR (Akpinar e Yumusak, 2013a), ARIMA (Akpinar e Yumusak, 2013b) e modelo de regressão exponencial (Akpinar e Yumusak, 2017) sucessivamente. Em seu estudo, o MAPE de ARIMA, MLR e modelo de regressão exponencial foi de 11,73%, 14,38% e 14,10%, respectivamente.

Ozmen et al. (2016) propuseram um modelo de MA aprimorado para prever o consumo de gás em áreas residenciais. O MAPE foi de 4,8%. Marziali et al. (2019) usaram regressão Ridge, processo gaussiano, vizinho K-mais próximo, ANN e um modelo toroidal para prever o consumo diário de gás da Itália no próximo ano. O resultado apresentou que o Processo Gaussiano teve um desempenho melhor que outros modelos, e seu menor MAE foi de 2,56, 0,05 menor que RNA. A visão geral dos artigos publicados na fase geral está listada na Tabela 4.

O apêndice mostra uma visão geral atualizada dos trabalhos publicados na área de previsão de gás natural, incluindo o modelo de previsão, área aplicada, país, horizonte de previsão, tamanho dos dados, fator de influência e desempenho.

Em conclusão, a aplicação de tecnologias de IA, como o programa "AlphaGo", sistemas de reconhecimento facial, carros sem motorista, etc., promove a integração da IA e vários campos ao redor do mundo. A tecnologia de previsão que depende da ciência da computação também foi aprimorada.

Comparado com outros estágios, os modelos de previsão neste estágio podem resolver problemas mais complexos. Especialmente com o surgimento da tecnologia de aprendizado profundo, a aplicação do modelo combinado e o renascimento dos modelos estatísticos convencionais, as capacidades de ajuste não linear, autoaprendizagem e autoadaptação foram bastante aprimoradas.

Apesar destas vantagens, os modelos nesta fase ainda têm muitos

Tabela

4 Visão geral do estágio geral de artigos publicados por anos.

Ano de publicação	Referências
2008	Kizilaslan e Karlik Vitullo
2009	et al.
2010	Xu e Wang
2011	Azadeh et al. Kaynar et al.
2012	Segundo Demirel e cols.
2013	Soldo Azadeh et al. Taspýnar et al., Akpinar e Yumusak (2013a, 2013b)
2014	Soldo et al. Yu e Xu Szoplik,
2015	Zhu et al. Azadeh et al.
2016	Bai e Li
2017	Merkel et al. Panapakidis e Dagourmas, Akpinar e Yumusak Merkel et al. Fan et al., Ozmen et al. Tamba et al.
2018	
2019	Wei et al. (2019a, 2019b, 2019c, 2019d), Laib et al. Su et al., Hafezi et al. Hribar et al., Qiao et al. Wang e Jiang, Beyca et al. Lu et al., Marziali et al.

[illegible]




Fig. 3. Transformação para horizonte de previsão. Nota: IS representa o estágio inicial, CS representa o estágio convencional, AI representa o estágio de Inteligência Artificial, AR representa o estágio geral.

Tabela

6 Fatores de influência em diferentes horizontes e estágios de previsão.

Tipo		Fatores de Influência do Estágio
Anual	É	Produção de GN, produção industrial/doméstica, clima, temperatura efetiva, preço do gás, população, receita de vendas, receita, vendas de incêndio a gás, aquecimento central
	CS	Consumo histórico, temperatura média, gás/preço médio do gás, HDD
	IA	Consumo histórico, dados de descoberta de gás, reservas provadas, HDD, preço do gás, número de consumidores, taxa de câmbio
	COM	Consumo histórico, PIB, IPC, PIB, PIB da indústria primária/secundária/terciária, população, número de consumidores, renda nacional, oferta de gás/GLP, energia alternativa e nuclear, emissões de CO2, produção de GN, consumo de petróleo
CS trimestral	Consumo histórico, preço médio/mensal do gás, PIB, gastos dos consumidores, temperatura mensal	
	CS	HDD, CDD, temperatura, preço do gás, óleo combustível residual, preço do óleo combustível residual, índice de renda
	IA	Temperatura, diferença entre temperatura real e esperada, preço do petróleo, número de consumidores, consumo da indústria
	COM	Consumo histórico, temperatura média mensal/diária, condição meteorológica, dia da semana, feriado, preço do gás, população, PIB, número de consumidores, índice sazonal
Semanalmente	IA	Temperatura média diária, dia da semana Consumo
	COM	histórico, sete dias/dia/temperatura média máxima e mínima, condição meteorológica, número médio de consumidores, dia da semana, feriado Diária/Dia anterior/Exp. temperatura ponderada, dia da semana, precipitação, horas de sol, velocidade do vento Temperatura efetiva/diária, condição meteorológica, precipitação, cobertura de nuvens, umidade, dia da semana, estação do ano, feriado, índice
Diário	É	para indústrias manufatureiras, vendas de incêndio de gás, aquecimento central, produtividade comercial e industrial Consumo histórico, temperatura média diária/diária, velocidade do vento, dia da semana/ano, feriado, PIB, HDD Consumo histórico, mínimo e máximo/mínimo do dia anterior e máximo/média diária/temperatura quadrada, condições climáticas, ponto de orvalho mais baixo/médio/mais alto, umidade mais baixa/média/mais alta, visibilidade mais baixa/média/mais alta, pressão de ar mais baixa/média/mais alta, velocidade do vento mais baixa/média/mais alta, precipitação, umidade, solar, radiação, dia da semana/mês/ano, feriado, dia antes/depois do feriado, dia entre feriado e fim de semana/número de consumidores, preço do gás, pressão, HDD, geologia Consumo histórico, temperatura horária, máximo/mínimo/médio temperatura de raiva ontem Consumo histórico, temperatura horária, dia da semana Consumo histórico, temperatura, dia da semana, feriado, dia entre feriado e fim de semana, condição meteorológica, clima, preço do gás
	CS	
	IA	
	COM	
De hora em hora	É	
	IA	
	COM	

defeitos. A estrutura dos modelos DL é complicada e difícil de explicar. O treinamento do modelo requer uma configuração de hardware mais alta e precisa de mais tempo para calcular. Além disso, a seleção dos melhores parâmetros, topologia de rede e tamanho do conjunto de dados são determinados pela experiência humana.

As características do palco, modelos típicos, vantagens e desvantagens As tags em diferentes estágios estão resumidas na Tabela 5, como segue:

3.5. Mudanças no histórico de previsão

Nesta revisão, ao resumir 72 trabalhos publicados, pode-se resumir que horizonte de previsão, fator de influência e desempenho de previsão apresentam mudanças significativas em quatro estágios diferentes. Como esses fatores mudaram no longo histórico de previsão será discutido nesta seção.

3.5.1. Discussão sobre o horizonte de previsão

Quanto à previsão do consumo de gás natural, o horizonte de previsão pode ser dividido em três categorias: previsão de curto prazo (semanal, diário, horário), previsão de médio prazo (trimestral, mensal) e previsão de longo prazo (anual). O gráfico de pizza apresenta a transformação para o horizonte de previsão na Fig. 3.

Observando a Fig. 3, o estágio inicial é dominado pela previsão de longo prazo, que responde por 75%. Devido à tecnologia atrasada e à falta de dados, as primeiras previsões de consumo se concentraram principalmente em previsões de longo prazo com baixo volume de dados, baixa dimensão e longo período de tempo. Para o estágio Convencional, a proporção de médio prazo

(27%) e as previsões de curto prazo (47%) aumentaram. Ele ilustra que o surgimento de microcomputadores e a melhoria da capacidade de cálculo fazem com que os modelos nesta fase tenham capacidades não lineares mais fortes, e a direção da pesquisa também começou a mudar para previsões de curto e médio prazo.

No estágio de IA, a pesquisa sobre previsão de curto prazo continua aumentando, enquanto a previsão de longo prazo diminuiu ligeiramente (17%). Ele faz com que os poderosos recursos de ajuste não linear de ANN e SVM conscientizem os pesquisadores sobre o potencial da tecnologia de IA e tenham mais confiança em melhorar a precisão dos modelos de previsão de curto prazo.

Para o estágio geral, a pesquisa sobre previsão de curto prazo aumentou para 75%, seguida por previsão de longo prazo (17%) e médio prazo (8%). Isso indica que, com a melhoria das capacidades computacionais e o desenvolvimento da EAD, o ajuste não linear e a capacidade de aprendizado dos modelos de previsão foram bastante aprimorados. Portanto, a pesquisa sobre previsão de curto prazo com maior conjunto de dados, maior dimensão e menor período de tempo está se aprofundando.

Para resumir, a pesquisa sobre previsão de curto prazo aumentou de 25% para 75% durante o desenvolvimento do histórico de previsão. Pode-se concluir que, afetado pelo desenvolvimento da ciência da computação e da tecnologia de IA, a previsão de curto prazo é o horizonte de previsão que mais cresce, seguido por longo e médio prazo. Deve ficar claro que isso não significa que outros horizontes de previsão não sejam importantes. Apenas indica que, em comparação com outros horizontes de previsão, a previsão de curto prazo tem mais espaço para melhorar, devido à sua estrutura complexa e grande quantidade de dados.

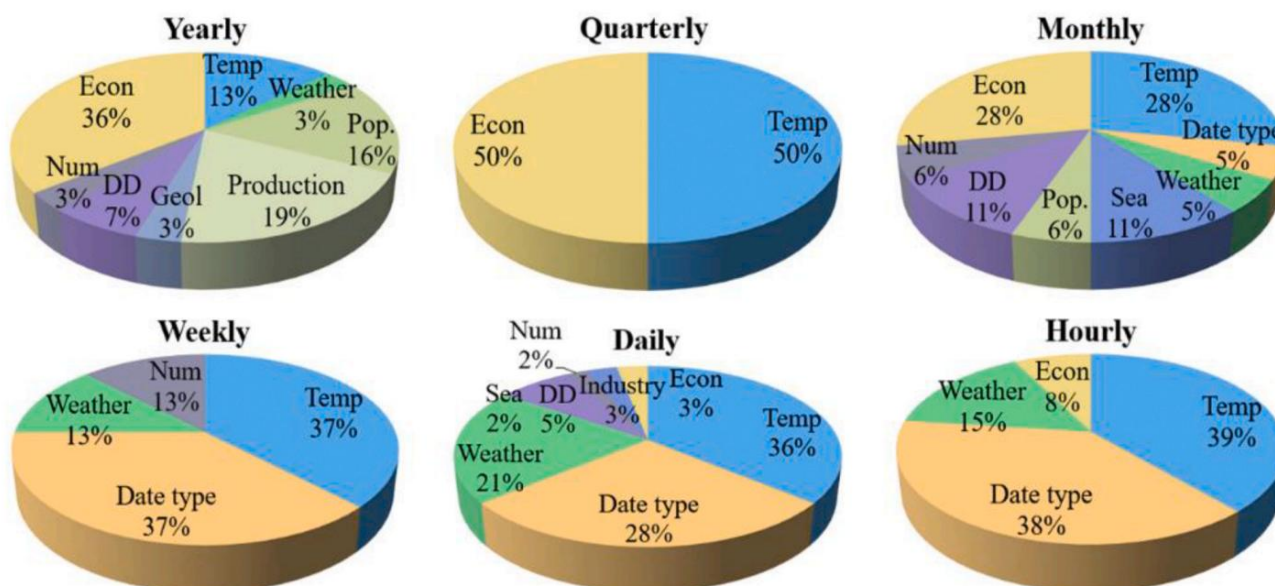


Fig. 4. Proporção de fatores de influência em diferentes horizontes de previsão. Nota: Num representa o número de consumidores, Sea representa o índice sazonal, DD representa as variáveis graus-dia.

3.5.2. Discussão sobre o fator de influência

Os fatores de influência são um dos fatores que têm um impacto significativo na precisão das previsões. Durante a história da tecnologia de previsão de consumo de gás natural, os fatores de influência de vários horizontes de previsão considerados pelos autores em diferentes estágios sempre foram mudando. De acordo com os 72 artigos publicados, os fatores de influência em diferentes horizontes e estágios de previsão podem ser resumidos da seguinte forma (ver [Tabela 6](#)).

A proporção de fatores de influência em diferentes horizontes de previsão é resumido como [Fig. 4](#).

Pode-se observar na [Tabela 6](#) que fatores influenciadores, como produção, economia, população e clima, são considerados principalmente nas três primeiras etapas para a previsão anual de consumo. Para a etapa All round, também foram levados em consideração o número de consumidores, fontes alternativas de energia, emissões de CO₂ e outros fatores econômicos. A previsão trimestral só foi estudada na fase Convencional. Os fatores que influenciam incluem temperatura e variáveis econômicas. A previsão mensal considera as variáveis de produção, meteorológicas e econômicas como os fatores que influenciam nas três primeiras etapas. Ao estágio All-round também são adicionados fatores como população, número de consumidores e tipo de data. A previsão semanal de consumo considera apenas a condição climática e o tipo de data na fase inicial e aumenta o número de consumidores e as variáveis de temperatura na fase posterior. As condições meteorológicas, o tipo de data e as variáveis econômicas são os principais fatores de influência na fase inicial da previsão diária do consumo. Para o estágio All-round, são levados em consideração o número de consumidores, as condições climáticas mais complexas e o tipo de data. Os fatores de influência para a previsão de consumo por hora têm poucas mudanças.

Apenas as condições meteorológicas e o tipo de data são considerados na fase inicial,

e aumentar a temperatura e as variáveis econômicas posteriormente.

A [Figura 4](#) ilustra que, para a previsão de consumo de longo prazo, a produção (19%), a população (16%) e as variáveis econômicas (36%) são os principais fatores de influência. A previsão de médio prazo (trimestral, mensal) é afetada principalmente por variáveis econômicas (50%, 28%) e de temperatura (50%, 28%). Os fatores que influenciam a previsão de curto prazo (semanal, diário, horário) dependem principalmente das variáveis de temperatura (37%, 36%, 39%), condição climática (13%, 21%, 15%) e tipo de data (37%, 28%, 38%).

Em conclusão, desde que considerados no modelo, os fatores de influência de vários horizontes de previsão em diferentes estágios sempre foram crescentes. Para o estágio All-round, afetado pelo desenvolvimento da ciência da computação e da tecnologia de IA, os fatores de influência considerados no modelo são mais do que outros estágios. Mas, de um modo geral, a previsão de longo prazo é afetada principalmente pela produção, população e variáveis econômicas. A previsão de médio prazo é afetada principalmente por variáveis econômicas e de temperatura. Os fatores que influenciam a previsão de curto prazo dependem principalmente das variáveis de temperatura, condições climáticas e tipo de data.

3.5.3. Discussão sobre o desempenho da previsão

Durante a história da previsão do consumo de gás natural, 12 métodos de avaliação foram usados para quantificar o desempenho dos modelos de previsão, incluindo: MAPE, MNAPE, MARNE, WMAPE, RMSE, NMSE, R2, MAE, MSE, ARE, CC, SD. Esses métodos de avaliação podem ser definidos da seguinte forma:

$$MAPE = \frac{1}{N} \sum_{i=1}^N \frac{|y_i - \hat{y}_i|}{\hat{y}_i} \times 100\% \quad (1)$$




Fig. 5. Transformação para métodos de avaliação.

Tabela

7 Resumo das características dos dados de diferentes modelos de previsão.

Características dos dados	Modelos estatísticos			Modelos baseados em IA		
	Modelos TS	RM	GMs	RNAs	SVRs	DLs
Tamanho dos dados	Dezenas a centenas	Dezenas a centenas	Dezenas	Centenas a milhares	Centenas	Centenas a milhares
Número de fatores	Menos de dez	Menos de dez	Nenhum	Menos de vinte	Menos de dez	Menos de vinte
Tipo de dados	Tudo	Tudo	Exponencial	Periodicidade	Tudo	Periodicidade

Tabela

8 Resumo das características dos diferentes modelos de previsão.

Características do modelo	Modelos estatísticos			Modelos baseados em IA		
	Modelos TS	RM	GMs	RNAs	SVRs	DLs
Vantagens	Estrutura simples, facilidade de uso, Eficiente e Econômico	Estrutura simples, facilidade de uso, eficiente e Econômico	Estrutura simples, facilidade de uso, sem necessidade de fatores de influência	Resolver problemas não lineares complexos	Bom equilíbrio entre precisão e tempo de cálculo; melhor estabilidade	Poderosa capacidade de ajuste não linear, generalização e robustez, alta portabilidade, melhor precisão
Desvantagens	Não pode conter mais variáveis	Não pode refletir com precisão a relação entre consumo e variáveis	Incapacidade de lidar com problemas não lineares complexos	Muitos parâmetros precisam ser determinados, convergência lenta, overfitting, underfitting	A função do núcleo é crucial e difícil estar determinado	Os parâmetros do modelo são difíceis de determinar, tempo de cálculo longo, overfitting, underfitting
Complexidade	Fácil	Fácil	Fácil	Médio	Médio	Difícil
Velocidade de computação	Rápido	Rápido	Rápido	Médio	Médio	Lento

Tabela

9 Resumo dos MAPEs médios de diferentes modelos em diferentes horizontes de previsão.

Horizonte	Modelos estatísticos		Modelos baseados em IA			
	Modelos TS	RMs	GMs	RNAs	SVRs	DLs
Longo prazo	1,90%	3,42%	4,48%	5,31%		2,15%
Médio prazo	2,40%			2,21%	4,93%	
Curto prazo	14,18%	6,68%		6,52%	4,98%	5,94%

$$MNAPE = \frac{1}{N} \sum_{i=1}^N \frac{|y_i - \hat{y}_i|}{\bar{y}} \times 100\%$$

(2)

$$MARINHO = \frac{1}{N} \sum_{i=1}^N \frac{y_i - \hat{y}_i}{\max(y_i, \hat{y}_i)} \times 100\%$$

(3)

$$WMAPE = \frac{\sum_{i=1}^N (y_i - \hat{y}_i)}{\sum_{i=1}^N y_i} \times 100\%$$

(4)

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

(5)

$$NMSE = \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

(6)

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

(7)

$$FACIL = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

(8)

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

(9)

$$S\tilde{A}O = \frac{\sum_{i=1}^N |e_i|}{N}$$

(10)

$$CC = \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}$$

(11)

$$SD = \sqrt{\frac{\sum_{i=1}^N (y_i - \bar{y})^2}{N}}$$

(12)

onde N é o tamanho do conjunto de dados; y_i é o consumo real de gás natural; \hat{y}_i é o valor previsto; cov (y_i, \hat{y}_i) representa a covariância entre o fator de índice y_i e \hat{y}_i ; $D(y_i)$ é a variância de y_i ; \bar{y} é o valor médio de y_i .

A Fig. 5 apresenta a transformação dos métodos de avaliação no histórico de previsão. Pode-se observar que o método de avaliação é baseado principalmente na SE (50%) na fase inicial. Para o estágio Convencional e IA, devido à excelente capacidade de avaliação, o MAPE tem sido mais bem aplicado. O número de MAPE utilizado em artigos representa 50% e 65%. Para o estágio All-round, embora o MAPE ainda seja a principal ferramenta para avaliar o desempenho do modelo (36%), os pesquisadores acreditam que o uso de um único método para avaliar o desempenho do modelo não pode refletir com precisão os resultados da previsão. Assim, muitos pesquisadores começaram a combinar o MAPE com outros métodos de avaliação nesta fase. Mas de um modo geral, o MAPE é o método de avaliação mais popular do que outros. Além disso, para diferentes conjuntos de dados, RMSE, R², MAPE e MARINHO têm uma grande diferença. Portanto, para comparar o desempenho da previsão com critérios unificados, o MAPE é apresentado como principal método de avaliação na pesquisa a seguir.

O desempenho da previsão depende muito do modelo e das características dos dados. Para selecionar os melhores modelos adequados para diferentes frentes horizontes de projeção, as características do modelo e dos dados estão resumidas na Tabela 7 e na Tabela 8. É óbvio que, devido à estrutura simples e alta velocidade de computação, os modelos estatísticos são adequados para previsões de longo prazo com poucos dados registrados. Entre eles, os modelos TS apresentam melhor desempenho que os demais. Para médio e curto prazo

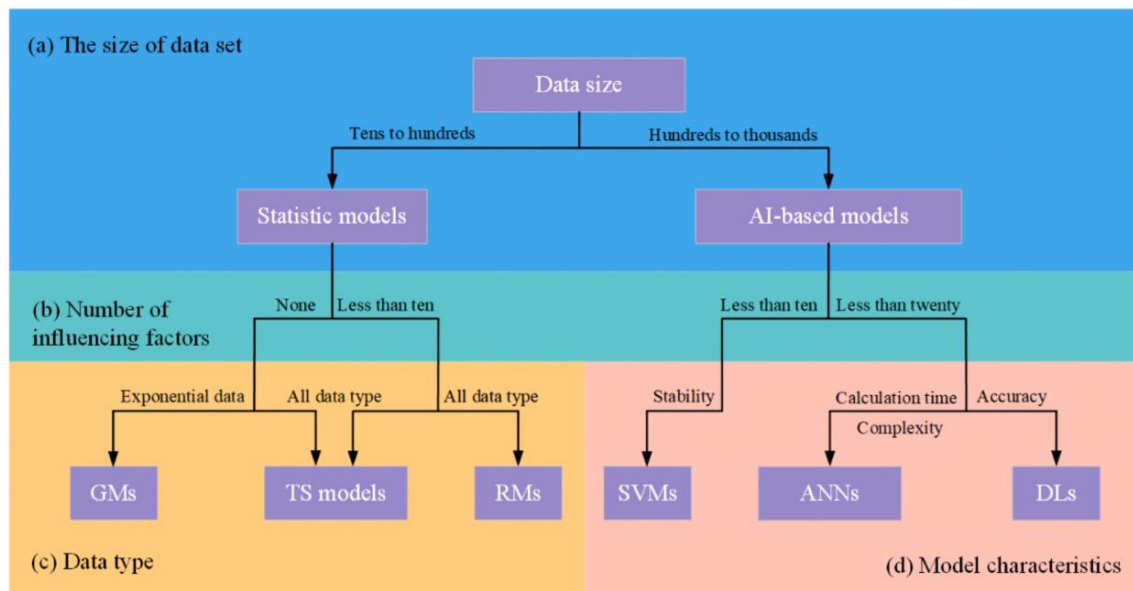


Fig. 6. O processo de seleção de modelos.

previsão com uma grande quantidade de dados, os modelos baseados em IA têm melhor desempenho. Entre eles, as RNAs podem resolver os problemas complexos não lineares, mas muitos parâmetros são difíceis de determinar. DLs têm a melhor precisão, mas o tempo de cálculo é maior e a estrutura do modelo é mais complexa.

Os SVRs podem manter um bom equilíbrio entre precisão e tempo de cálculo. Apresenta também a melhor estabilidade. Assim, os SVRs podem ser adequados para previsão de curto prazo.

Para verificar os resultados analisados acima, a análise estatística dos MAPEs médios dos modelos em diferentes horizontes de previsão está sumarizada na Tabela 9, de acordo com os 72 trabalhos publicados. Observa-se que, na previsão de longo prazo, o MAPE médio dos modelos TS é de 1,90%, inferior aos modelos RM, GM, ANN e DL. Os modelos de RNA têm o MAPE médio mais baixo (2,21%) na previsão de médio prazo. O MAPE médio dos modelos SVR é de 4,98%, o que é melhor do que os modelos TS, RM, ANN e DL na previsão de curto prazo.

Ele indicou que os modelos TS são os melhores modelos para realizar previsões de longo prazo com uma pequena quantidade de dados. Para a previsão de médio e curto prazo com grande quantidade de dados e maior dimensão, os modelos baseados em IA apresentam o melhor desempenho. Entre elas, as RNAs são preferidas para previsão de médio prazo e as SVRs são mais adequadas para previsão de curto prazo.

4. Direções de pesquisas futuras

Com base na discussão do histórico de previsão, as futuras direções de pesquisa de previsão de consumo de gás natural são resumidas a seguir.

4.1. Seleção do melhor modelo

Pode-se constatar a partir do histórico de previsão que existem centenas de modelos que podem ser utilizados para prever o consumo de gás natural, mas nem todos os modelos apresentam excelente desempenho (Soldo, 2012; Tamba et al., 2018). Para obter melhor precisão, os autores continuarão a propor novos modelos, o que significa perder muito tempo e resultar em muitos modelos sem sentido (Wang e Srinivasan, 2017). Assim, a seleção do melhor modelo tornou-se a questão mais preocupante para pesquisadores e previsores.

Para resolver este problema, todos os modelos referidos nos artigos publicados são divididos em seis modelos de base conforme discutido na Seção 3.5.3, e uma estrutura de seleção de modelos é proposta com base em dados e modelos

características. A Fig. 6 mostra o processo de seleção do modelo. As etapas específicas estão listadas a seguir: Etapa 1: Selecionando o tipo de modelo inicialmente, determinando se o seu

o tamanho dos dados é adequado para modelos estatísticos ou baseados em IA;

Passo 2: Seleção de modelos de acordo com o número de fatores influenciadores e a capacidade do modelo; Passo 3: Selecionando o modelo específico com base em suas necessidades. Por exemplo, se o resultado precisar de mais estabilidade, SVMs é a melhor escolha e você pode escolher DLs se a precisão for mais importante; Passo 4: Analisar as características dos dados coletados e selecionar o algoritmo apropriado para otimizar os defeitos inerentes ao modelo base; Passo 5: Comparando o modelo base selecionado e o modelo otimizado para

verificar o desempenho do modelo.

O processo proposto acima fornece uma estrutura de seleção de modelos para pesquisadores, será muito útil para simplificar o processo de seleção de modelos. No entanto, o processo é derivado apenas com base em dados e características do modelo sem suporte de dados. Ele ainda precisa ser mais discutido a partir de uma perspectiva múltipla no futuro.

4.2. Seleção dos parâmetros do modelo

Após selecionar o modelo correto, ainda existe o problema de identificar os melhores parâmetros do modelo, e os melhores parâmetros mais próximos só podem ser obtidos por tentativa e erro (Liu et al., 2004a). Além disso, um modelo mais bem treinado seria adequado apenas para cidades que vivem em estruturas de consumo, zonas climáticas, níveis de riqueza, desenvolvimento econômico e sistemas políticos nacionais semelhantes (Szoplik, 2015). No entanto, pesquisadores em diferentes países têm feito seu trabalho apenas com base em seu próprio conhecimento e experiência. Utilizar o mesmo modelo, mas estrutura e parâmetros diferentes para prever, não pode medir com precisão o desempenho do modelo. Portanto, um método e critério confiáveis na seleção dos parâmetros do modelo serão essenciais no futuro.

Três métodos são sugeridos para a seleção de parâmetros. Primeiramente, os algoritmos de otimização, como PSO, GA et al., poderiam ser usados para otimizar os parâmetros do modelo. Em segundo lugar, os pesquisadores poderiam dividir o processo de seleção de parâmetros em diferentes etapas e priorizar o ajuste de parâmetros que tenham maior impacto no desempenho do modelo.

Em terceiro lugar, os pesquisadores poderiam experimentar diferentes parâmetros em um conjunto de dados simplificado para reduzir o tempo de teste e, em seguida, experimentar o conjunto de dados original.

Além disso, a seleção de parâmetros do modelo é fortemente dependente de

as características dos dados. Portanto, para o estabelecimento do critério de seleção de parâmetros, uma solução possível é classificar os dados com diferentes características, determinar a faixa de parâmetros de diferentes tipos de dados por meio de experimentos ou algoritmos de otimização e formular diferentes critérios de previsão. Será muito benéfico para os pesquisadores simplificar o processo de seleção de parâmetros e encurtar o tempo de seleção.

4.3. Estabelecimento do banco de dados padrão

Estudos anteriores mostraram que os conjuntos de dados usados em 72 artigos publicados são sempre diferentes. O que significa que não existe um banco de dados unificado para verificar o desempenho do modelo para os pesquisadores. A verificação do desempenho do modelo é baseada apenas nos dados que eles podem coletar (Ivezic, 2006). Mesmo que os autores acreditem que o modelo proposto tenha alcançado melhor desempenho, ainda é um problema saber se o modelo é aplicável para outros conjuntos de dados.

Assim, é essencial estabelecer um banco de dados padrão que inclua várias características dos dados, como estruturas de consumo, zonas climáticas, níveis de riqueza, sistemas políticos nacionais e outros, para que os pesquisadores possam selecionar diferentes características dos dados para treinamento. É muito benéfico para o modelo aprender recursos suficientes para melhorar o desempenho da previsão. O estabelecimento do banco de dados padrão fornecerá uma plataforma para testar o desempenho do modelo. Ele será amplamente utilizado por pesquisadores de todo o mundo para testar o desempenho do modelo proposto.

4.4. Melhoria do método de seleção de recursos

Conforme discutimos na seção 3.5.2, os fatores de influência considerados em vários horizontes de previsão sempre foram crescentes. Os fatores de influência crescentes não apenas tornarão a estrutura do modelo mais complicada, mas também aumentarão o tempo de cálculo. Portanto, métodos de seleção de recursos, como PCA, KPCA et al., foram desenvolvidos para rastrear fatores de influência (Hafezi et al., 2019; Wei et al., 2019b). Os métodos de seleção de características utilizados em artigos publicados focam principalmente na redução da dimensionalidade, ou seja, reduzir a dimensionalidade extraíndo os principais componentes dos dados. No entanto, este método de filtro tem um defeito inerente. Embora os componentes principais sejam extraídos, e a estrutura do modelo e o tempo de cálculo sejam simplificados, é inevitável que algumas informações importantes possam ser perdidas, o que resultará em um erro não desprezível.

Diante disso, é necessário propor um método de redução de dimensionalidade que não perca nenhuma informação de dados. Uma solução possível é que, de acordo com a função objetivo, podemos selecionar vários recursos ou excluir vários recursos, até que o melhor subconjunto seja selecionado para obter o melhor desempenho. Embora o método possa ser mais complicado, ele pode ser usado para redução de dimensionalidade sem perder nenhuma informação.

4.5. Referência de avaliação de previsão com base em múltiplas perspectivas

Pode-se observar na Fig. 5 que os métodos de avaliação utilizados em 72 artigos publicados são diferentes. Alguns pesquisadores perceberam que não existe um benchmark de avaliação de previsão unificado e propuseram vários benchmarks de avaliação com base em seus próprios métodos. Lewis (1986) propôs o benchmark para a avaliação da acurácia da modelagem baseada no MAPE e o dividiu em quatro níveis, incluindo Altamente preciso, Bom, Razoável e Impreciso. Wei et al. (2019d) dividiram o 'Altamente preciso' de Lewis em quatro níveis para diferentes horizontes de previsão.

Embora esses benchmarks tenham sido propostos, eles ainda não são reconhecidos e aplicados pelo público. E ainda há o problema de como usar vários métodos de avaliação, não apenas o MAPE, para formular diferentes benchmarks de avaliação para diferentes objetos de avaliação. Portanto, é essencial formular uma avaliação de previsão unificada

benchmark baseado em múltiplas perspectivas para regular o mercado de previsão.

5. Conclusões e sugestões

Este artigo revisa a história da previsão de consumo de gás natural, resume as características, modelos típicos, vantagens e desvantagens em diferentes etapas. Contribuições e experimentos propostos pelos pesquisadores foram coletados para discutir as mudanças nos horizontes de previsão, fatores de influência e desempenho da previsão ao longo da história do desenvolvimento. Perspectivas e sugestões para o futuro também foram analisadas. De acordo com os resultados da revisão, as principais conclusões podem ser resumidas da seguinte forma:

1. A pesquisa sobre previsão de curto prazo aumentou de 25% para 75% durante o histórico de previsão. Pode-se concluir que, afetado pelo desenvolvimento da ciência da computação e da tecnologia de IA, a previsão de curto prazo é o horizonte de previsão que mais cresce, seguido por longo e médio prazo.
2. Os fatores de influência exigidos pelos modelos de previsão passaram por mudanças que de nunca consideradas para uma pequena quantidade de dados e de baixa dimensão, e para uma grande quantidade de dados e de maior dimensão até agora. Mas, de um modo geral, a previsão de longo prazo é afetada principalmente pela produção (19%), população (16%) e variáveis econômicas (36%). A previsão de médio prazo (trimestral, mensal) é afetada principalmente por variáveis econômicas (50%, 28%) e de temperatura (50%, 28%). Os fatores que influenciam a previsão de curto prazo (semanal, diário, horário) dependem principalmente das variáveis de temperatura (37%, 36%, 39%), condição climática (13%, 21%, 15%) e tipo de data (37%, 28 %, 38%).
3. A análise estatística das características dos dados, características do modelo e resultados de previsão mostra que os modelos TS são os melhores modelos para realizar previsões de longo prazo. Possui o MAPE médio mais baixo (1,90%) na previsão de longo prazo. Para a previsão de médio e curto prazo, os modelos baseados em IA apresentam o melhor desempenho. Entre elas, as RNAs (2,21%) são as preferidas para previsões de médio prazo e as SVRs (4,98%) são mais adequadas para previsões de curto prazo.

Além disso, ainda há algumas sugestões para pesquisas futuras: por um lado, os dados de consumo são sempre considerados intimamente relacionados ao tempo. No entanto, Wei et al. (2019c) comprovaram que a localização geográfica pode ter impacto na precisão das previsões, ou seja, os dados de consumo podem não ter apenas uma ótima relação com o tempo, mas também com o espaço. Portanto, os dados de consumo devem ser considerados como dados espaço-temporais. Deve ser discutido ainda sob a perspectiva dos dados espaço-temporais. Por outro lado, alguns pesquisadores indicaram que os modelos DL têm melhor desempenho do que outros modelos baseados em IA.

No entanto, de acordo com nossa pesquisa, os modelos DL têm sido usados muito poucos na previsão do consumo de gás natural até agora. Mais modelos DL devem ser tentados para melhorar o desempenho da previsão no futuro.

Declaração de interesse concorrente

Os autores declaram que não têm interesses financeiros concorrentes ou relações pessoais que possam ter influenciado o trabalho relatado neste artigo.

Reconhecimentos

Os autores agradecem ao editor e aos revisores anônimos por suas sugestões para melhorar a qualidade do artigo. Agradecimentos especiais a Xu Wang por fornecer ajuda linguística, Shouxi Wang por assistência de redação e aquisição de financiamento.

Apêndice

Tabela A

Os resultados da revisão de 72 artigos publicados

Etapas	Referência	Modelo de previsão	Área aplicada	País	Horizonte de previsão	Tamanho dos dados	Fatores de influência	atuação
Estado inicial	Hubbert (1949)	modelo Hubbert	Mundo & nacional	NÓS	Anual	1911-1961	Estatísticas anuais de produção e estimativa	
	Hubbert (1956)	modelo Hubbert	Mundo	NÓS	Anual	1911-1961	Estatísticas anuais de produção e estimativa	
	Berrisford (1965)	Exponencialmente Modelo ponderado	Noroeste área		Diário	abril de 1963	Temperatura, Temperatura do dia anterior, Exp. temperatura ponderada, dia da semana, precipitação, horas de sol, velocidade do vento Produção industrial, outras condições de produção doméstica, preço do gás, população, vendas	2-2,5% (SE)
	Aia (1965)	Registro duplo Múltiplo Correlações	Nacional		Anual	1948-1965		0,032 (SE)
	Besta e Nerlove (1966)		Residencial e comercial setor	NÓS	Anual	1957-1962		0,9570 (Coef. de Correlação)
	Elliot e Linden (1968)	Modelo Empírico	Nacional	NÓS	Anual	1980-2000	receita Economia, tecnologia, geologia Receita, temperatura efetiva, vendas de incêndio a gás, aquecimento central	
	Johnson (1968)		Nacional	Reino Unido	Anual	1958-1972	Consumo histórico, temperatura horária, temperatura média diária ontem, temperatura máxima ontem, temperatura mínima ontem Temperatura efetiva, índice para indústrias transformadoras, gás Fogo, aquecimento central 32 variáveis incluem temperatura, condição meteorológica, tipo de dados, produtividade comercial e industrial et al.	
	Durrer et al. (1969)	TS	14 residências em Norte Califórnia	NÓS	De hora em hora	70 horas		0,3-34,8% (MAPE)
Convencional Etapas	Rodger et al. (1971)	Modelo de regressão combinado	Nacional	escocês	Diário	1962/63-1969/70		
	Haenel (1973)	Automático Interação Detecção	LDC (Sul Califórnia)	NÓS	Diário			
	Tinic et al. (1973)	Modelo empírico	Região rural (Alberta)	Canadá	Anual			
	Berndt e Watkins (1977)		Colômbia e Ontário	Reino Unido	Anual			
	Método de Monte Carlo de Lyness (1981)		Nacional transmissão sistema	Reino Unido	Diário		Temperatura, tipo de dados	
	Taylor e Tomás (1982)	Adaptativo Método Bayesiano	nacional sistema	Reino Unido	Diário		Temperatura, velocidade do vento, precipitação, dia da semana, estação do ano, feriado	
	Piggott (1983)	Box Jenkins	PMD		Diariamente e semanalmente			
	Lyness (1984)	Box Jenkins	Nacional transmissão sistema	Reino Unido	Diariamente, mensalmente e anualmente		Temperatura efetiva, efeito do vento, variáveis da indústria, variáveis econômicas	
	Catão (1984) Antigo (1985)	Box Jenkins	Norte do Tamisa LDC (Colômbia)	Reino Unido	Diário Anual	1977-1984	Temperatura Temperatura, preço médio do gás, HDD	0,81-4,8% (MAPE)
	Pepper (1985)	Box Jenkins	Nacional	Reino Unido	Trimestral	Q1, 1960-Q4, 1983	Preço médio do gás, PIB, gastos dos consumidores, temperatura	3,1-9,4% (RE)
	Herbert et al. (1987)	Modelo de regressão Nacional		NÓS	Por mês		HDD, preço do gás, óleo combustível residual	
	Herbert et al. (1987)	Modelo de regressão Nacional		NÓS	Por mês	Janeiro 1980 - dez. 1984	HDD, graus-dia de resfriamento, preço do gás, índice de renda, preço do óleo combustível residual, temperatura	7% (MAPE)
			PMD	NÓS	Diário			

(Continua na próxima página)

Tabela A (continuação)

Etapas	Referência	Modelo de previsão	Área aplicada	País	Horizonte de previsão	Tamanho dos dados	Fatores de influência	atuação
Estágio de IA	Jabbour e Meyer (1989)	Método híbrido baseado em sistema especialista e reconhecimento de padrões					Temperatura, velocidade do vento, cobertura de nuvens, umidade, feriado, variações diárias, variações semanais, variações sazonais	
	Liu e Lin (1991)	Função de transferência Taiwan		China	Trimestral e anual	Janeiro 1975 – dez. 1988	Consumo histórico, temperatura mensal, preço mensal	0,02182–0,0341 (RMSE)
	Brown et al. (1994)	ANN	Wisconsin (LDC)	NÓS	Diário		Consumo histórico, HDD, temperatura, velocidade do vento, dia da semana, dia do ano	
	Marrom e Manhã (1995)	ANN	Wisconsin (2 LDCs)	NÓS	Diário	21 de dezembro de 1989-mar. 29, 1994	Consumo histórico, HDD, temperatura, velocidade do vento, dia da semana, dia do ano	
	Suykens et al. (mil novecentos e noventa e seis)	ANN	Nacional	Bélgica	Por mês	Jun.1-Out. 20, 1982	Temperatura, diferença entre temperatura real e esperada, preço do petróleo, número de consumidores, consumo da indústria	
	Miura e Sato (1998)	BPNN	4 PMDs	Japão	De hora em hora	3 meses no inverno	Consumo histórico, temperatura, tipo de data	2,11 / 2,73 / 3,32 / 3,35% (MAPE)
	Klema e Curta (1999)	CBR-NLR_SVD ANN	PMD	Alemanha	De hora em hora			4% (MAPE)
	Khotanzad e Elragal (1999)	AFLC	4 PMDs		Diariamente (Um/ Dois/três dias à frente)		Consumo histórico, temperatura, velocidade do vento, dia da semana	3,94/4,26/4,41% (Média MAPE) 4,09/4,25/4,3% (Média SD)
	Al-Fattah e Startzman (2000)	modelo Hubbert	Mundo		Anual	1900–1997	Produção anual histórica, dados de descoberta de gás, comprovados reservas	
	Khotanzad et al. (2000)	AFF_ANN	6 PMDs		Diário	Período inverno de 1994-1997	Consumo histórico, dia da semana, temperatura, velocidade do vento	3,82/5,95% (Média MAPE com dados meteorológicos reais/previstos) 3,87/5,69% (média SD com dados meteorológicos reais/previstos) 3,78/5,89% (Média MAPE com dados meteorológicos reais/previstos) 3,83/5,76% (Média SD com dados meteorológicos reais/previstos)
		AFL_ANN						
	Peharda et al. (2001)	BPNN	Residencial e comercial consumidor	Croácia	De hora em hora	1 de novembro a dez. 15, 2000	Consumo histórico, tipo de data, temperatura	4,7% (Média MAPE) 4,3% (MNAPE médio) 0,35% (SD médio)
	Siemek et al. (2003)	modelo Hubbert	Nacional	Polônia	Anual	1970–2001	Consumo anual histórico	
	Gorucu et al. (2004)	BPNN	Ancara	Peru	Anual	1991–2005	Graus-dia, preço de venda, número de consumidores, taxa de câmbio	
	Elragal (2004)	FGC	4 PMDs		Diariamente (Um/ Dois/três dias à frente)	Período inverno de 600 dias	Consumo histórico, velocidade do vento, temperatura, dia da semana	3,97/4,48/4,85% (Média MAPE) 4,07/4,27/4,63% (Média SD)
	Liu et al. (2004)	SVM	Xi'an	China	Diário	Janeiro 1, 2001 – jan. 31, 2003	Temperatura média, tipo de data	1,6246% (MAPE)
	Liu et al. (2004)	LS-SVM	Xi'an	China	Diário	Janeiro 1, 2001 – jan. 31 de janeiro de 2003.	Temperatura média, tipo de data	1,7024% (MAPE)
	vietnamita e Man'dziuk (2005)	FNN	Região rural	Polônia	Diário	1, 2000 – Dez. 31, 2002	Temperatura média diária, dia da semana	4,24 / 3,97 / 4,60% (AVG / MIN / MAX)

(Continua na próxima página)

Tabela A (continuação)

Etapa	Referência	Modelo de previsão	Área aplicada	País	Horizonte de previsão	Tamanho dos dados	Fatores de influência	atuação
Palco todo-o-terreno			Altamente industrializado área		Semanalmente			MAPE) 0,0013 (SD) 7,62 / 7,07 / 8,87% (AVG / MIN / MAX MAPE) 0,0037 (SD) 8,16 / 7,29 / 9,10% (AVG / MIN / MAX MAPE) 0,0037 (SD) 5,63 / 5,32 / 6,28% (AVG / MIN / MAX MAPE) 0,0016 (SD) 10,44 / 9,57 / 12,27% (AVG / MIN / MAX MAPE)
					4 Semanalmente			0,0059 (SD) 11,37/9,80/14,35% (AVG/MIN/MAX MAPE) 0,0092 (SD) 3,6% (MAPE)
					Diário			
					Semanalmente			
					4 Semanalmente			
	Musilek et al. (2006)	Híbrido RNN	PMD		Diário	Janeiro 1, 2001 – Dez. 31, 2004	Temperatura média diária, dia da semana, feriado, consumo histórico	
	Ivezic (2006) ANN		Cidade	Sérvia	Diário	1º de outubro de 2001- fev. 7, 2005	Consumo histórico, temperatura, tipo de data	5,07% (MAPE)
	Kizilaslan e Karlik (2008)	ANN	Istambul	Peru	Diário	1º de janeiro de 2004– set. 30, 2007	Temperatura mínima e máxima, temperatura mínima e máxima do dia anterior, consumo histórico, tipo de dados, número de	6,5% (ARE) 0,9915 (Correlação) 0,9826 (R2)
					Semanalmente		consumidores Temperatura média de sete dias, média máxima e mínima temperatura, número médio de consumidores, tipo de data	8,2% (ARE) 0,993936 (Correlação) 0,987683 (R2)
	Vitulo et al. (2009)	ANN-MLR	14 PMDs	NÓS	Diário	1º de outubro de 2009– jul. 31, 2010	Consumo histórico, velocidade do vento, temperatura, dia da semana, feriado	5,21–19,59% (MAPE)
	Xu e Wang (2010)	PCMACP	Nacional	China	Anual	1995–2008		3,42% (MAPE)
	Azadeh et al. (2011)	ANFIS-SFA	Nacional	Bahreïn saudita Arábia Síria	Anual	1980–2007	PIB, população	0,018% (MAPE) 0,014% (MAPE) 0,014% (MAPE) 0,075% (MAPE) 0,016% (MAPE)
	Kaynar et al. (2011)	MLP	Nacional	Peru	Semanalmente	Janeiro 2002–Abr. 2006		5,477% (MAPE) 5,468% (MAPE)
	Demirel et al. (2012)	ANFIS BPNN	Istambul	Peru	Diário	Janeiro 1, 2004 – nov. 30, 2009	16 variáveis incluem temperatura média diária, temperatura quadrática, preço do gás, número de consumidores et al.	0,1833% (MAPE) 0,0347 (RMSE) 0,0376 (MAD)
	Azadeh et al. (2013)	ANFIS-DEA FDEA	Nacional	Argentina	Anual	1980–2007	PIB, população	2,9/5,1% (MAPE, dados originais/ruídos) 49.827 (RMSE) 0,994 (R2) 3,5 / 7,5% (MAPE) 27.183 (RMSE) 0,95 (R2) 1,6 / 4,2% (MAPE) 3.872 (RMSE) 0,99 (R2) 6,4 / 9,3% (MAPE) 67.039 (RMSE) 0,62 (R2)

(Continua na próxima página)

Tabela A (continuação)

Etapas	Referência	Modelo de previsão	Área aplicada	País	Horizonte de previsão	Tamanho dos dados	Fatores de influência	atuação
								1,6 / 5,3% (MAPE) 0,271 (RMSE) 0,85 (R2)
	Taspinar et al. (2013)	ANN-MLP	Sakarya (LDC)	Peru	Diário	2007–2011	Umidade, atmosférica, velocidade do vento, pressão, temperatura ambiente	0,441 (RMSE) 0,814% (MAPE) 0,823 (R2) 9,84–18,51% (MAPE)
	Akpınar e Suave (2013)	ARIMA	Doméstico	Peru	Diário	Janeiro 1, 2009 – Dez. 31 de novembro de 2012 6		
	Soldo et al. (2014)	MLP	Casa	Croácia	Diário	de abril de 2011 – 27 de novembro de 2012 8 de abril de 2012 – 1, 2013	Temperatura, solar, radiação, feriado, dia da semana	5,06% (MAPE) 0,635 (R2) 2,52% (MAPE) 0,908 (R2)
			PMD					
	Yu e Xu (2014)	CCMGA-BPNN	Xangai	China	Diário	novembro 15, 2005 – Out. 13, 2008	Temperaturas máximas, mínimas, médias, tipo de data, condições meteorológicas, consumo histórico	7857,5 (MAE) 4,59% (MAPE) 12.582 (RMSE)
	Azadeh et al. (2015)	ELFIS	Nacional	Irã	Anual	1973–2006	POP, CPI	7,2568% (MAPE) 0,0036 (NMSE) 3,6789s (Tempo) 12,3630% (MAPE) 0,0030 (NMSE) 3,5062s (Tempo) 13,6282% (MAPE) 0,00363 (NMSE) 1,5310s (Tempo) 13,7855% (MAPE) 0,0125 (NMSE) 5,0569s (Tempo) 10,1681% (MAPE) 0,0045 (NMSE) 7,3836s (Tempo) 6,7119% (MAPE) 0,0026 (NMSE) 7,6435s (Tempo)
							POP, NI	
							POP, PIB	
							POP, NI, PIB	
							POP, NI, PIB, CPI	
							POP, NI, PIB, CPI, demanda do ano anterior	
	Szoplík (2015)	MLP	Szczecin	Polônia	Diário	Janeiro 1, 2009 – Dez. 31, 2011	Mês, dia do mês, dia da semana, hora, temperatura	5,5–11,0% (MAPE) 582,2–2166,6 (RMSE)
	Zhu et al. (2015)	Vizinhos falsos SVR filtrados	Nacional	Reino Unido	Diário	Janeiro 1, 2009 – Dez. 31, 2012	Temperatura, velocidade do vento	3,4 / 3,8% (MAPE) 8,3–9,2 (MAE)
	Bai e Li (2016)	SC-SVR	Anqing	China	Diário	Janeiro 2012 – dez. 2012		2,36% (MAPE) 3913,88 (RMSE)
	Merkel et al. (2017)	DNN baseado em RBM	176 PMDs	NÓS	Diário		Consumo histórico, velocidade do vento, temperatura, dia da semana	
	Panapakidis e Dagoumas (2017)	WT-GA-ANFIS FFnn	PMD	Grécia	Diário	1º de janeiro de 2014– jun. 30, 2016	Temperatura média diária, tipo de dados	1,87–12,12% (MARGA)
	Ozmen et al. (2018)	Spline de regressão adaptativa multivariada	Áncara (residencial)	Peru	Diário	2009–2013	Temperaturas mínimas e máximas diárias, HD	0,992 (R2) 0,189 (MAE) 0,295 (RMSE) 0,996 (Coef. de Correlação) 4,9% (MAPE) 0,992 (R2) 0,198 (MAE) 0,299 (RMSE) 0,996 (Coef. de Correlação) 4,9% (MAPE)
		Spline de regressão adaptativa multivariada cônica						
	Merkel et al. (2018)	DN	62 PMDs	NÓS	Diário	Pelo menos 10 anos de dados para treinamento e 1 ano para testes	HDD, ponto de orvalho, CDD, dia da semana, dia do ano	5,78% (Média WMAPE) 5,58% (Média WMAPE) 4,48% (MAPE) 11,59 (RMSE) 8,41 (MAE)
		DNN grande						
	Fan et al. (2018)	GM-S-SIGM-GA	Nacional	China	Anual	2002–2017		

(Continua na próxima página)

Tabela A (continuação)

Etapas	Referência	Modelo de previsão	Área aplicada	País	Horizonte de previsão	Tamanho dos dados	Fatores de influência	atuação
	Wei et al. (2019)	LSTM-PCCA	Xi'an	China	Diário	Janeiro 1, 2015 - set. 31 de janeiro de 2017 1 de fevereiro de 2015 - 2 de fevereiro de 2018	14 fatores climáticos	3,22% (MAPE) 3,02% (MARINHO)
			Atenas	Grécia				7,29% (MAPE) 6,66% (MARINHO)
	Wei et al. (2019)	ISSA-LSTM	Londres	Reino Unido	Diário	1º de janeiro de 2015–maio. 31, 2018	19 fatores climáticos, dia, mês, ano, preço do gás	10,01% (MAPE) 4,68% (MARINHO) 9,94% (MAPE) 5,72% (MARINHO)
			Melbourne	Austrália				14,10% (MARINHO) 14,37% (MAPE) 5,76% (MARINHO)
	Wei et al. (2019)	FSA-LGA-SVR	Atenas	Grécia	Diário	Janeiro 1 de dezembro de 2015 - 31, 2017	19 fatores climáticos	9,06% (MAPE) 1,90% (MARINHO) 18,69% (MAPE) 2,26% (MARINHO) 12,10% (MAPE) 2,12% (MARINHO)
			Salónica					
			Larissa					
	Laib et al. (2019)	FM MLP	Residenciais e Industriais setores	argelino	De hora em hora	Janeiro 1 de janeiro de 2014 - jan. 1, 2015	Temperatura, tipo de dados	5,48% (MAPE) 0,0083 (MAE) 0,0108 (RMSE)
	Beyca et al. (2019)	SVR	Istambul	Peru	Por mês	Jan. 2005–Out. 2015	Índice sazonal, temperatura, preço do gás, população, consumo histórico	5,53% (MAPE) 36.130.270 (MSE)
	Su et al. (2019)	WT-GA-RNN	Nacional	NÓS	Por hora (previsão de 1 h)	Dados de verão/inverno (150 h/150 h)	Tipo de dados, condição meteorológica, clima, preço do gás	19.0497 / 81.4731 (mae) 0,0058 / 0,0061 (mre) 25.9278 / 109.5693 (RMSE) 53.9272 / 124.0326 (mae) 0,0180 / 0,019 (MRE) 69.6089 / 154.3480 (RMSE) 125.7692 / 594.2678 / 0,0678 (MRE) 0,0584 / 0,0678 (MRE) 0,0584 / 0,0678 (MRE) 167.149 / 744.4329 (RMSE)
					Por hora (previsão de 5 h)	Dados de verão/inverno (150 h/150 h)		
					Por hora (previsão de 10 h)	Dados de verão/inverno (150 h/150 h)		
					Por hora (previsão de 1 h)	Dados de verão (150h)		10.2701 (MAE) 0,0094 (MRE) 11,8352 (RMSE)
					Por hora (previsão de 5 h)	Dados de verão (150 h)		11,9608 (MAE) 0,0110 (MRE) 14.1134 (RMSE)
					Por hora (previsão de 10 h)	Dados de verão (150 h)		55.1135 (MAE) 0,0501 (MRE) 69.2558 (RMSE)
	Wang e Jiang (2019)	NMGM-ARIMA	Pensilvânia	NÓS	Por mês	Janeiro 2012 - dez. 2018		3,16% (MAPE) 0,79% (RMSE) 1,64% (MAPE) 0,37% (RMSE) 2,06% (MAPE) 0,57% (RMSE) 1,38% (MAPE) 0,33% (RMSE)
			Texas					0,9847 (R2) 52.19 (MAE) 1,69% (MAPE) 13,54 (MBE) 61,33 (RMSE) 0,9679 (R2) 79,96 (MAE) 2,61% (MAPE) 2,66 (MBE) 94,21 (RMSE)
		ARIMA-ANN	Pensilvânia					
			Texas					
	Hafezi et al. (2019)	DmGNn	Mundo	Mundo	Anual	1965–2013 (Dados processados)	Energia alternativa e nuclear, emissões de CO2 , PIB per capita, população, produção de GN, consumo de petróleo	
						1965–2013 (Dados não tratados)		

(Continua na próxima página)

Tabela A (continuação)

Etapas	Referência	Modelo de previsão	Área aplicada	País	Horizonte de previsão	Tamanho dos dados	Fatores de influência	atuação
	Lu et al. (2019)	CF-SA-FFOA SVM	Kunming	China	Diário	Janeiro 1 de novembro de 2012 – 30, 2013	Temperatura média diária, condição meteorológica, tipo de data, feriado, consumo histórico	3,35% (MAPE) 1,14 × 109 (MSE) 3,38 × 104 (RMSE) 3,59% (MAPE) 1,07 × 1011 (MSE) 3,26 × 105 (RMSE)
					Semanalmente			4,33% (MAPE) 1,20 × 1012 (MSE) 1,09 × 106 (RMSE)
					Por mês			
	Hribar et al. (2019)	RN	residencial consumidor (Liubliana)	Eslovênia	De hora em hora	A demanda total de gás em	Consumo histórico, temperatura, feriado, dia	9,3% (MAPE) 0,00106 (MAE)
					Diário	Liubliana por cada hora nos últimos 8 invernos temporadas	entre feriado e fim de semana	6,8% (MAPE) 0,0183 (MAE)
	Qiao et al. (2019)	IWOA-RVM	Estação Lixin Gate (Anhui)	China	De hora em hora	360 horas		0,02% (MAPE) 82,51 (MAE) 9064,71 (RMSE)
			Estação do portão de Sanshibu (Anhui)			2160 horas		0,02% (MAPE) 45,60 (MAE) 2515,06 (RMSE)
	Marcial et al. (2019)	Processo Gaussiano	Gás residencial Demanda	Itália	Diário	Janeiro 1, 2007 – Dez. 31, 2017	Temperatura, HDD, dia da semana, feriado	2,56 (MAE médio) 4,25 (RMSE médio)

Financiamento

Este trabalho foi apoiado pela Fundação Nacional de Ciências Naturais da China (número de concessão 51704236), a China Petroleum and Chemical Corporation (número de concessão 318019–7) e o Bureau de Ciência e Tecnologia de Xi'an da China (número de concessão GXYS15.2).

Referências

Al-Fattah, SM, Startzman, RA, 2000. Previsão da oferta mundial de gás natural. J. Gasolina. Tecnol. 52, 62-72.

Akpınar, M., Adak, MF, Yumusak, N., 2017. Previsão de demanda de gás natural no dia anterior usando rede neural otimizada baseada em ABC com técnica de janela deslizante: o estudo de caso de base regional na Turquia. Energias 10, 781-801.

Akpınar, M., Yumusak, N., 2013a. Estimativa do consumo doméstico de gás natural com regressão múltipla: efeito do ciclo. In: Conferência Internacional de Computadores Eletrônicos e Computação, pp. 188–191.

Akpınar, M., Yumusak, N., 2013b. Previsão de consumo doméstico de gás natural com modelo ARIMA: um estudo de caso de ciclo de remoção. In: Conferência Internacional sobre Aplicação de Tecnologias de Informação e Comunicação, pp. 1–6.

Akpınar, M., Yumusak, N., 2017. Previsão de gás natural para o dia seguinte usando métodos de suavização exponencial não sazonais. Conferência Internacional sobre Meio Ambiente e Engenharia Elétrica 1–4.

Amber, KP, Ahmad, R., Aslam, MW, Kousar, A., Usman, M., Khan, MS, 2018. Técnicas inteligentes para previsão do consumo de eletricidade de edifícios. Energia 886-893.

Andersen, FM, Larsen, HV, Gaardstrup, RB, 2013. Previsão de longo prazo do consumo horário de eletricidade em áreas locais na Dinamarca. Aplic. Energia 110, 147-162.

Andersen, FM, Larsen, HV, Juul, N., Gaardstrup, RB, 2014. Projeções diferenciadas de longo prazo do consumo horário de eletricidade em áreas locais. O caso da Dinamarca Ocidental. Aplic. Energia 135, 523-538.

Azadeh, A., Asadzadeh, SM, Mirseraji, GH, Saberi, M., 2015. Uma abordagem de inferência neuro-fuzzy de aprendizado emocional para treinamento e previsão ideais de modelos de estimativa de consumo de gás com dados cognitivos. Tecnol. Previsão. Soc. Altere 91, 47–63.

Azadeh, A., Asadzadeh, SM, Saberi, M., Nadimi, V., Tajvidi, A., Sheikhalishahi, M., 2011. Uma abordagem de análise de fronteira neuro-fuzzy-estocástica para previsão de consumo de gás natural de longo prazo e análise de comportamento: os casos do Bahrein, Arábia Saudita, Arábia, Síria e Emirados Árabes Unidos. Aplic. Energia 88, 3850-3859.

Azadeh, A., Babazadeh, R., Asadzadeh, SM, 2013b. Estimativa ótima e previsão do consumo de energia renovável por redes neurais artificiais. Renovar. Sustentar. Energia Rev. 27, 605-612.

Azadeh, A., Saberi, M., Asadzadeh, SM, Hussain, OK, Saberi, Z., 2013a. Um algoritmo multivariado neuro-fuzzy para estimativa precisa do consumo de gás na América do Sul com entradas ruidosas. Int. J. Eletr. Sistema de energia de energia 46, 315-325.

Azadeh, A., Tarverdian, S., 2007. Integração de algoritmo genético, simulação computacional e desenho de experimentos para previsão de consumo de energia elétrica. Energia Pol. 35, 5229-5241.

Bai, Y., Li, C., 2016. Previsão diária do consumo de gás natural com base em uma abordagem de regressão vetorial de suporte calibrada de estrutura. Construção de Energia. 127, 571-579.

Bai, Y., Sun, Z., Zeng, B., Long, J., Li, L., Oliveira, JVD, Li, C., 2018. Uma comparação de técnicas de redução de dimensão para modelagem de máquina vetorial de suporte de multiparâmetros previsão de qualidade de fabricação. J. Intel. Manuf. 30, 2245-2256.

Balestra, P., Nerlove, M., 1966. Agrupando dados de corte transversal e séries temporais no estimação de um modelo dinâmico: a demanda por gás natural. Econometria 34, 585-612.

Berndt, ER, Morrison, CJ, Watkins, GC, 1980. Modelos dinâmicos de demanda de energia: um Avaliação e Comparação.

Berndt, ER, Watkins, GC, 1977. Demanda por gás natural: mercados residenciais e comerciais em ontário e colúmbia britânica. Lata. J. Eco. 10, 97-111.

Berrisford, HG, 1965. A relação entre demanda de gás e temperatura: um estudo em previsão estatística de demanda. J. Oper. Res. Soc. 16, 229-246.

Beyca, OF, Ervural, BC, Tatoglu, E., Ozuyar, PG, Zaim, S., 2019. Usando máquina ferramentas de aprendizagem para a previsão do consumo de gás natural na província de Istambul. Energia Econ. 80, 937-949.

Bhaskar, K., Singh, SN, 2012. Previsão de energia eólica assistida por Awnn usando rede neural feed-forward. IEEE Transactions on Sustainable Energy 3, 306–315.

Boser, BE, Guyon, IM, Vapnik, VN, 1992. Um algoritmo de treinamento para classificadores de margem ótima. conferência sobre teoria da aprendizagem 144-152.

Brown, RH, Kharouf, P., Feng, X., Piessens, LP, Nestor, D., 1994. Desenvolvimento de modelos de rede feed forward para prever o consumo de gás. In: Congresso Mundial de Inteligência Computacional, pp. 802–805.

Brown, RH, Matin, I., 1995. Desenvolvimento de modelos de redes neurais artificiais para prever o consumo diário de gás. In: Conferência da Sociedade Eletrônica Industrial, pp. 1389-1394.

Cao, G., Wu, L., 2016. Suporte a regressão vetorial com algoritmo de otimização de mosca da fruta para previsão de consumo sazonal de eletricidade. Energia 115, 734-745.

Catalão, JPS, Pousinho, HMI, Mendes, VMF, 2011. Energia eólica de curto prazo previsão em Portugal por redes neurais e transformada wavelet. Renovar. Energia 36, 1245-1251.

Catalina, T., Iordache, V., Caracaleanu, B., 2013. Modelo de regressão múltipla para previsão rápida da demanda de energia de aquecimento. Construção de Energia. 57, 302-312.

Caton, HG, 1984. Planejamento de suprimento e armazenamento de gás: uma abordagem de simulação. J. Oper. Res. Soc. 35, 593-596.

Chen, H., Engkvist, O., Wang, Y., Olivecrona, M., Blaschke, T., 2018. A ascensão do aprendizado profundo na descoberta de medicamentos. Descoberta de Drogas Hoje 23, 1241-1250.

Conejo, AJ, Plazas, MA, Espínola, R., Molina, AB, 2005. Previsão de preços de eletricidade para o dia anterior usando a transformada wavelet e modelos ARIMA. Trans. IEEE Sistema de energia 20, 1035-1042.

Demirel, OF, Zaim, S., Caliskan, A., Ozuyar, P., 2012. Previsão do consumo de gás natural em Istambul usando redes neurais e métodos multivariados de séries temporais. Turco. J. Eletr. Eng. Computar. Sci. 20, 695-711.

Drevna, MJ, 1985. Uma Aplicação das Funções de Transferência Box-Jenkins à Previsão da Demanda de Gás Natural . Universidade de Ohio.

Durrer, EJ, Somerton, WH, Mueller, TD, 1969. Processo multivariado de curto alcance
Previsão para Uso em Sistemas Automatizados. Society of Petroleum Engineers of AIME, Denver, Colo.

Elliott, MA, Linden, HR, 1968. Uma nova análise do suprimento de gás natural dos EUA. J. Gasolina. Tecnol. 20, 135-141.

Elragal, H., 2004. Melhorando a previsão de redes neurais usando modelo fuzzy-genético. In: Congresso Nacional de Radiologia.

Enerdata, 2020. Anuário Estatístico Global de Energia 2020. <https://yearbook.enerdata.net/natural-gas/gas-consumption-data.html>.

Erdem, H., 2020. Agdas Natural Gas Distributor INC. <http://www.erdem.com.tr/en/c-ompany-detail/agdas-natural-gas-distributor-inc-7>.

Fan, G., Wang, A., Hong, W., 2018. Combinando modelo cinza e modelo cinza inteligente autoadaptável com algoritmo genético e mudanças anuais de participação na previsão de demanda de gás natural. Energias 11, 1-21.

Gervén, MV, Bohte, S., 2018. Redes Neurais Artificiais como Modelos de Neural Processando informação.

Ghasemi, F., Mehridehnavi, A., Fassihi, A., Perez-Sanchez, H., 2018. Rede neural profunda em estudos de QSAR usando rede de crenças profundas. Aplic. Computação Suave. 62, 251-258.

Gorucu, FB, Geris, PU, Gumrah, F., 2004. Modelagem de redes neurais artificiais para previsão de consumo de gás. Fontes de Energia 26, 299-307.

Graves, A., 2012. Rotulagem de Sequência Supervisionada com Redes Neurais Recorrentes.

Haenel, RD, 1973. Previsão de gás natural-uma comparação de dois modelos. Sociedade de Engenheiros de Petróleo da AIME.

Hafezi, R., Akhavan, A., Zamani, M., Pakseresh, S., Shamsheirband, S., 2019. Desenvolvendo um modelo baseado em mineração de dados para extrair fatores preditores em sistemas de energia: aplicação da demanda global de gás natural. Energias 12.

He, W., 2017. Previsão de carga via redes neurais profundas. Procedia Ciência da Computação 122, 308-314.

Herbert, JH, 1987a. Uma análise das vendas mensais de gás natural para clientes residenciais nos Estados Unidos. Sistema de Energia Pol. 10, 127-147.

Herbert, JH, 1987b. Demanda de gás natural pelas residências em nível estadual: vinte anos de esforço. Rev. Reg. Viga. 17, 79-87.

Herbert, JH, Sitzer, S., Eades-Pryor, YJE, 1987. Uma avaliação estatística da demanda industrial mensal agregada de gás natural nos EUA. Energia 12, 1233-1238.

Hribar, R., Potocnik, P., Silc, J., Papa, G., 2019. Comparação de modelos para previsão da demanda de gás natural residencial de uma área urbana. Energia 167, 511-522.

Hubbert, MK, 1949. Energia de combustíveis fósseis. Ciência 109, 103-109.

Hubbert, MK, 1956. Energia Nuclear e os Combustíveis Fósseis. Conferência API.

Ivezic, D., 2006. Previsão de consumo de gás natural a curto prazo. Transações FME 34, 165-169.

Jabbour, K., Meyer, W., 1989. GAuLF: previsão de carga automatizada de gás. In: Simpósio Centro-Oeste de Circuitos e Sistemas. Siracusa, Nova York, pp. 20-23.

Jebaraj, S., Iniyan, S., Goic, R., 2011. Previsão do consumo de carvão usando uma rede neural artificial e comparação com várias técnicas de previsão. Fontes de Energia , Parte A Recuperação, Util. Ambiente. Ef. 33, 1305-1316.

Johnson, FJ, 1968. Problemas de previsão na indústria do gás. EUR. J. Mercado. 2, 287-297.

Kaynar, O., Yilmaz, I., Demirkoparan, F., 2011. Previsão de consumo de gás natural com rede neural e sistema neuro fuzzy. Energia Educação Ciência e Tecnologia 26, 221-238.

Kermanshahi, B., 1998. Rede neural recorrente para previsão de cargas de nove concessionárias japonesas nos próximos 10 anos. Neurocomputing 23, 125-133.

Khotanzad, A., Elragal, H., 1999. Previsão de carga de gás natural com combinação de redes neurais adaptativas. Conferência Conjunta Internacional sobre Rede Neural 4069-4072.

Khotanzad, A., Elragal, H., Lu, TL, 2000. Combinação de rede neural artificial meteorologistas para previsão do consumo de gás natural. Trans. IEEE Rede neural. 11, 464-473.

Kizilaslan, R., Karlik, B., 2008. Comparação de modelos de redes neurais para curto prazo previsão do consumo de gás natural em Istambul. In: Conferência Internacional sobre Aplicações de Informação Digital e Tecnologias Web, pp. 448-453.

Klema, J., Kout, J., 1999. Previsão do Consumo de Gás.

Laib, O., Khadir, MT, Mihaylova, L., 2019. Rumo a sistemas de energia eficientes baseados na previsão de consumo de gás natural com redes neurais recorrentes LSTM. Energia 530-542.

Lee, YS, Tong, LI, 2011. Previsão de séries temporais usando uma metodologia baseada em média móvel integrada autoregressiva e programação genética. Conhecimento Sistema básico 24, 66-72.

Lewis, C., 1986. Métodos de previsão industrial e comercial. Butterworth Científico.

Liu, Y., Chen, P., Wu, B., Ma, T., Wu, B., Zhang, X., Jeffrey, RG, 2020. Mecânica do crescimento de fraturas hidráulicas de um furo de poço que cruza fraturas naturais. SPE J. 25, 646-664.

Liu, E., Li, W., Cai, H., Peng, S., 2019. Mecanismo de formação de óleo residual no óleo produto encanamento. Processos 7.

Liu, H., Liu, D., Liang, YM, Zheng, G., 2004b. Pesquisa sobre previsão de carga de gás natural com base na máquina de vetores de suporte de mínimos quadrados. In: Conferência Internacional sobre Aprendizado de Máquina e Cibernética, pp. 3124-3128. Xangai, China.

Liu, H., Liu, D., Zheng, G., Liang, YM, Ni, YF, 2004a. Pesquisa de Previsão de Carga de Gás Natural Baseada na Regressão do Vetor de Suporte. Congresso Mundial de Controle e Automação Inteligentes, Hangzhou, China, pp. 3591-3595.

Liu, LM, Lin, MW, 1991. Previsão do consumo residencial de gás natural usando séries temporais mensais e trimestrais. Int. J. Previsão. 7, 3-16.

Liu, Y., Ma, T., Chen, P., Wu, B., Zhang, X., Wu, B., 2020. Efeitos de plugues permeáveis sobre reforço do poço. Int. J. Rock Mech. Min. Sci. 132.

Lu, H., Azimi, M., Iseley, T., 2019. Previsão de carga de curto prazo de gás urbano usando um modelo híbrido baseado em algoritmo aprimorado de otimização de moscas-das-frutas e máquina de vetores de suporte. Energia Rep. 5, 666-677.

Lyness, FK, 1981. Previsão consistente de demanda severa de gás no inverno. J. Oper. Res. Soc. 32, 347-359.

Lyness, FK, 1984. Previsão de demanda de gás. O Estatístico 33, 9-21.

Magoul'es, F., Zhao, HX, 2016. Data Mining and Machine Learning in Building Energy Análise: rumo à Computação de Alto Desempenho.

Marziali, A., Fabbiani, E., Nicolao, GD, 2019. Previsão de curto prazo da demanda de gás residencial italiana. Computadores e Sociedade arXiv.

Merkel, GD, Povinelli, RJ, Brown, RH, 2017. Regressão de Rede Neural Profunda para Previsão de Carga de Curto Prazo de Gás Natural. Pesquisa e Publicações da Faculdade de Engenharia Elétrica e de Computação .

Merkel, GD, Povinelli, RJ, Brown, RH, 2018. Previsão de carga de curto prazo de gás natural com regressão de rede neural profunda. Energias 11.

Miura, K., Sato, R., 1998. Previsão de demanda de gás baseada em rede neural artificial. Conferência Internacional de Oleodutos 2, 887-893.

Musilek, P., Pelikan, E., Brabec, T., Simunek, M., 2006. Gating baseado em rede neural recorrente para sistema de previsão de carga de gás natural. In: Conferência Conjunta Internacional sobre Redes Neurais. Canadá, Vancouver, BC, pp. 3736-3741.

Nadimi, R., Tokimatsu, K., 2017. Análise de energia renovável e não renovável consumo por inferência bayesiana. Energia Procedia. Cardiff, Reino Unido 142, 2773-2778.

Nelder, JA, Wedderburn, RWM, 1972. Modelos lineares generalizados. J. Roy. Estado. Soc. 135, 370-384.

Ozmen, A., Yilmaz, Y., Weber, GW, 2018. Previsão de consumo de gás natural com modelos MARS e CMARS para usuários residenciais. Energia Econ. 70, 357-381.

Panapakidis, IP, Dagoumas, AS, 2017. Previsão da demanda de gás natural para o dia seguinte baseado na combinação de transformada wavelet e ANFIS/algoritmo genético/ modelo de rede neural. Energia 118, 231-245.

Pappas, SS, Ekonomou, L., Karamelas, P., Karamousantas, DC, Katsikas, SK, Chatzarakis, GE, Skafidas, PD, 2010. Previsão de carga de demanda de eletricidade do sistema de energia helênico usando um modelo ARMA. Eletr. Sistema de energia Res. 80, 256-264.

Peharda, D., Delimar, M., Loncaric, S., 2001. Previsão horária de curto prazo do consumo de gás usando redes neurais. Interfaces de Tecnologia da Informação, Pula, Croácia, pp. 367-371.

Pelikan, E., Simunek, M., 2005. Gestão de risco do consumo de gás natural usando algoritmos genéticos. Rede Neural. Mundo 15, 425-436.

Peng, S., Chen, Q., Zheng, C., Liu, E., 2019. Análise da deposição de partículas em um sistema de placas retificadoras de novo tipo durante a extração de gás de xisto. Energy Science & Engineering 8, 702-717.

Pepper, MPG, 1985. Análise Multivariada Box-Jenkins: um estudo de caso na energia do Reino Unido previsão de demanda. Energia Econ. 7, 168-178.

Piggott, JL, 1983. Uso da modelagem Box-Jenkins para a previsão da demanda diária e semanal de gás. IEE Colloquium Digest 4, 1.

Potočnik, P., Soldo, B., Simunović, G., Sarić, T., Jeromen, A., Govekar, E., 2014. Comparação de modelos estáticos e adaptativos para previsão de gás natural residencial de curto prazo na Croácia. Aplic. Energia 129, 94-103.

Qiao, W., Huang, K., Azimi, M., Han, S., 2019. Um novo modelo de previsão híbrida para o consumo de gás por hora no lado da oferta com base no algoritmo aprimorado de otimização de baleias e na máquina de vetor de relevância. Acesso IEEE 7, 88218-88230.

Qiao, W., Yang, Z., Kang, Z., Pan, Z., 2020. Consumo de gás natural de curto prazo previsão baseada no filtro adaptativo volterra e no algoritmo de otimização de baleias melhorado. Eng. Aplic. Artif. Intel. 87, 103323.

Rodger, AAS, Rawlings, WJ, Simpson, JM, 1971. Previsão em uma placa de gás da área. O Estatístico 20, 3-14.

Rumelhart, DE, Hinton, GE, Williams, RJ, 1986. Representações de aprendizagem por volta propagando erros. Natureza 323, 696-699.

Siemek, J., Nagy, S., Rychlicki, S., 2003. Estimativa do consumo de gás natural na Polónia com base na interpretação da curva logística. Aplic. Energia 75, 1-7.

Soldo, B., 2012. Previsão do consumo de gás natural. Aplic. Energia 92, 26-37.

Soldo, B., Potocnik, P., Simunovic, G., Saric, T., Govekar, E., 2014. Improving the modelos de previsão de consumo de gás natural residencial usando radiação solar. Construção de Energia. 69, 498-506.

Su, H., Zio, E., Zhang, J., Xu, M., Li, X., Zhang, Z., 2019. Um método híbrido de previsão de demanda horária de gás natural baseado na integração de transformada wavelet e Deep aprimorado -Modelo RNN. Energia 178, 585-597.

Su, Z., Liu, E., Xu, Y., Xie, P., Shang, C., Zhu, Q., 2019. Campo de fluxo e ruído características do manifold em estação de transporte de gás natural. In: Oil & Gas Science and Technology – Revue D'IFF Energies Nouvelles, p. 74.

Suykens, J., Lemmerling, P., Favoreel, W., Moor, BD, Crepel, M., Briol, P., 1996. Modelagem do consumo de gás belga usando redes neurais. Processo Neural. Lett. 4, 157-166.

Szoplik, J., 2015. Previsão de consumo de gás natural com redes neurais artificiais. Energia 85, 208-220.

Tamba, JG, Essiane, SN, Sapnken, EF, Koffi, FD, Nsouand'el'e, JL, Soldo, B., Njomo, D., 2018. Previsão de gás natural: uma pesquisa bibliográfica. Int. J. Economia de Energia. Pol. 8, 216-249.

Taspinar, F., Celebi, N., Tutkun, N., 2013. Previsão do consumo diário de gás natural em base regional na Turquia usando vários métodos computacionais. Construção de Energia. 56, 23-31.

Taylor, PF, Tomas, ME, 1982. Previsão de curto prazo: cavalos para cursos. J. Oper. Res. Soc. 33, 685-694.

Tinic, SM, Harden, BM, Janssen, CTL, 1973. Estimativa da demanda rural por recursos naturais gás. Gerencia Sci. 20, 604-616.

Tsekouras, GJ, Dialynas, EN, Hatzigiorgiou, ND, Kavatza, S., 2007. Um modelo de regressão multivariável não linear para previsão de energia de médio prazo de sistemas de energia. *Eletr. Sistema de energia Res.* 77, 1560-1568.

Tso, GKF, Yau, KKW, 2007. Previsão do consumo de energia elétrica: uma comparação de análise de regressão, árvore de decisão e redes neurais. *Energia* 32, 1761-1768.

Verhulst, MJ, 1950. A teoria da demanda aplicada à indústria francesa de gás. *Econometria* 18, 45-55.

Viet, NH, Mandziuk, J., 2005. Redes neurais neurais e difusas na previsão do natural consumo de gás. *Neural, Paralela Sci. Computar.* 265-286.

Vitullo, S., Brown, RH, Corliss, GF, Marx, BM, 2009. Modelos matemáticos para previsão de gás natural. *Lata. Aplic. Matemática. Q.* 17, 1005-1013.

Wang, J., Jiang, H., Zhou, Q., Wu, J., Qin, S., 2016. Análise da produção e consumo de gás natural da China com base no modelo multiciclo Hubbert e no modelo Rolling Gray . *Renovar. Sustentar. Energia Rev.* 53, 1149-1167.

Wang, Q., Jiang, F., 2019. Integrando técnicas de previsão linear e não linear com base na teoria cinza e inteligência artificial para prever a produção mensal de gás de xisto na Pensilvânia e no Texas dos Estados Unidos. *Energia* 178, 781-803.

Wang, Y., Wei, N., Wan, D., Wang, S., Yuan, Z., 2019. Simulação numérica para pré- aquecimento de novos oleodutos submarinos. *Energias* 12.

Wang, Z., Srinivasan, RS, 2017. Uma revisão da previsão de uso de energia de construção baseada em inteligência artificial : contrastando as capacidades de modelos de previsão simples e de conjunto. *Renovar. Sustentar. Energia Rev.* 75, 796-808.

Ward, RJ, 1965. Previsão de consumo de produtos com computadores. *Eng. Eco.* 10, 1-22.

Wei, N., Li, C., Duan, J., Liu, J., Zeng, F., 2019b. Previsão diária de carga de gás natural com base em um modelo híbrido de aprendizado profundo. *Energias* 12, 1-15.

Wei, N., Li, C., Li, C., Xie, H., Du, Z., Zhang, Q., Zeng, F., 2019a. Previsão de curto prazo do consumo de gás natural usando algoritmo de seleção de fatores e regressão otimizada de vetores de suporte. *J. Recursos Energéticos. Tecnol.* 141.

Wei, N., Li, C., Peng, X., Li, Y., Zeng, F., 2019c. Consumo diário de gás natural previsão através da aplicação de um novo modelo híbrido. *Aplic. Energia* 250, 358-368.

Wei, N., Li, C., Peng, X., Zeng, F., Lu, X., 2019d. Modelos convencionais e artificiais modelos baseados em inteligência para previsão de consumo de energia: uma revisão. *J. Gasolina. Sci. Eng.* 181.

Xu, G., Wang, W., 2010. Previsão do consumo de gás natural da China com base em um modelo de combinação. *J. Nat. Gás Química.* 19, 493-496.

Yu, F., Xu, X., 2014. Um modelo de previsão de carga de curto prazo de gás natural baseado em algoritmo genético otimizado e rede neural BP aprimorada. *Aplic. Energia* 134, 102-113.

Zhang, J., Wei, YM, Li, D., Tan, Z., Zhou, J., 2018. Carga de eletricidade de curto prazo previsão usando um modelo híbrido. *Energia* 774-781.

Zhang, P., Wang, H., 2012. Redes neurais fuzzy wavelet para previsão do consumo de energia elétrica da cidade. *Energia Procedia* 17, 1332-1338.

Zhu, L., Li, MS, Wu, QH, Jiang, L., 2015. Previsão de demanda de gás natural de curto prazo com base na regressão do vetor de suporte com falsos vizinhos filtrados. *Energia* 80, 428-436.

Zhu, Q., Zhang, Z., Li, R., Lai, KK, Wang, S., Chai, J., 2014. Análise estrutural e previsão de demanda total de carvão na China. In: *Discrete Dynamics in Nature and Society*, 2014.