



# Uma revisão sobre os modelos de previsão COVID-19

Iman Rahimi<sup>1</sup> • Fang Chen<sup>2</sup> • Amir H. Gandomi<sup>2</sup>

Recebido: 16 de setembro de 2020 / Aceito: 11 de dezembro de 2020

O(s) autor(es), sob licença exclusiva da Springer-Verlag London Ltd. parte da Springer Nature 2021

## Resumo

O novo coronavírus (COVID-19) se espalhou para mais de 200 países em todo o mundo, levando a mais de 36 milhões de casos confirmados em 10 de outubro de 2020. Assim, vários modelos de aprendizado de máquina que podem prever o surto globalmente foram lançados. Este trabalho apresenta uma revisão e breve análise dos mais importantes modelos de previsão de aprendizado de máquina contra a COVID-19. O trabalho apresentado neste estudo possui duas partes. Na primeira seção, uma análise cientométrica detalhada apresenta uma ferramenta influente para análises bibliométricas, que foram realizadas em dados COVID-19 das bases de dados Scopus e Web of Science. Para a análise acima mencionada, palavras-chave e áreas temáticas são abordadas, enquanto a classificação de modelos de previsão de aprendizado de máquina, avaliação de critérios e comparação de abordagens de solução são discutidas na segunda seção do trabalho. A conclusão e a discussão são apresentadas como as seções finais deste estudo.

Palavras-chave Análise de previsão COVID-19 SIR SEIR Série temporal

## 1. Introdução

Em dezembro de 2019, o governo chinês informou ao resto do mundo que um novo coronavírus, o Coronavírus 2 Relacionado à Síndrome Respiratória Aguda Grave (COVID 19), estava se espalhando rapidamente por toda a China, que rapidamente se infiltrou em muitos outros países. Os Centros de Controle e Prevenção de Doenças dos Estados Unidos (CDC) reconheceram um mercado de frutos do mar em Wuhan como o centro do surto. Em 13 de janeiro de 2020, a Organização Mundial da Saúde (OMS) relatou um caso na Tailândia, o primeiro caso a ser identificado fora da China. Em 16 de janeiro, o Japão confirmou seu primeiro caso e, em 20 de janeiro, a Coreia do Sul relatou seu primeiro caso confirmado. Atualmente, a maioria dos países do mundo foram afetados por esse vírus.

Putra e Khozin Mu'tamar [1] usaram o algoritmo Particle Swarm Optimization (PSO) para estimar parâmetros no modelo Susceptible, Infected, Recovered (SIR). o

os resultados indicam que o método sugerido é preciso e tem um erro baixo o suficiente em comparação com outros métodos analíticos. Mbuvha e Marwala [2] calibraram o modelo SIR para os casos relatados na África do Sul após considerarem diferentes cenários do número de reprodução ( $R_0$ ) para relatar infecções e estimativas de recursos de saúde. Qi e Xiao [3] propuseram que tanto a temperatura diária quanto a umidade relativa podem influenciar a ocorrência do COVID-19 em Hubei e outras províncias.

Salgotra e Gandomi [4] desenvolveram dois modelos de previsão de COVID-19 baseados em programação genética e aplicaram esses modelos na Índia. Os resultados de um estudo de [4] mostram que os modelos de programação evolutiva genética provaram ser altamente confiáveis para casos de COVID-19 na Índia.

O restante do artigo está organizado nas seções a seguir. As seções 2 e 3 apresentam o procedimento do método de busca e outras revisões, respectivamente. A seção 4 mostra os principais campos de pesquisa. Ilustrações genéricas são fornecidas na Sec. 5. A modelagem matemática e a avaliação de critérios são apresentadas nas Seções. 6 e 7. Abordagens de solução, incluindo modelo autorregressivo, modelos exponenciais, aprendizado profundo, métodos de regressão, etc., são descritos na Seção. 8. A Seção 9 descreve os pontos fortes e fracos dos vários modelos de previsão. Por fim, a conclusão, a discussão dos resultados e as direções futuras são apresentadas na Seção. 10.

✉ Amir H. Gandomi

gandomi@uts.edu.au

<sup>1</sup> Departamento de Engenharia Mecânica e de Fabricação,  
Faculdade de Engenharia, Universiti Putra Malaysia,  
Seri Kembangan, Malásia

<sup>2</sup> Instituto de Ciência de Dados, Universidade de Tecnologia de Sydney,  
Último 2007, NSW, Austrália

2 Procedimento do método de pesquisa

O processo utilizado para identificar os artigos para a revisão deste estudo é apresentado nesta seção.

2.1 Método de pesquisa

Web of Science (WOS) e Scopus foram usados para encontrar publicações relacionadas com base nas seguintes palavras-chave: previsão, previsão, COVID-19 e coronavírus. A classificação dos trabalhos publicados escolhidos com base na área temática é apresentada na Fig. 1. Os artigos atualizados do início de 2020 até agora foram filtrados do Scopus usando o operador booleano OR, tanto para tópicos quanto para títulos. Selecionamos 920 artigos de pesquisa técnica que contêm apenas descrições algorítmicas, artigos de revisão, artigos de conferências, estudos de caso e fornecem insights gerenciais, publicados em 10 de outubro de 2020 (Fig. 2). Além disso, este estudo se concentra mais nos artigos que foram indexados pela Web of Science.

3 Outros comentários

Mahalle e Kalamkar [5] categorizaram os modelos de previsão como modelos matemáticos e técnicas de aprendizado de máquina, usando a OMS e as comunicações de mídia social como conjuntos de dados. Parâmetros significativos, incluindo contagem de óbitos, parâmetros metrológicos, período de quarentena, recursos médicos e mobilidade também foram estudados [5].

Naude' [6] fez uma revisão da contribuição da inteligência artificial (IA) contra o COVID-19. Alguns campos da IA que têm contribuição contra o COVID-19 foram identificados como alertas e alertas precoces, rastreamento e previsão, painéis de dados, diagnóstico e prognóstico, tratamentos e curas e controle social [6].

4 Principais campos de pesquisa

Palavras-chave são críticas na identificação da literatura apropriada em um campo de pesquisa [7]. Conforme especificado por [8]: "palavras-chave representam a pesquisa central de um artigo." A palavras-chave

Fig. 1 Classificação dos trabalhos científicos por área temática


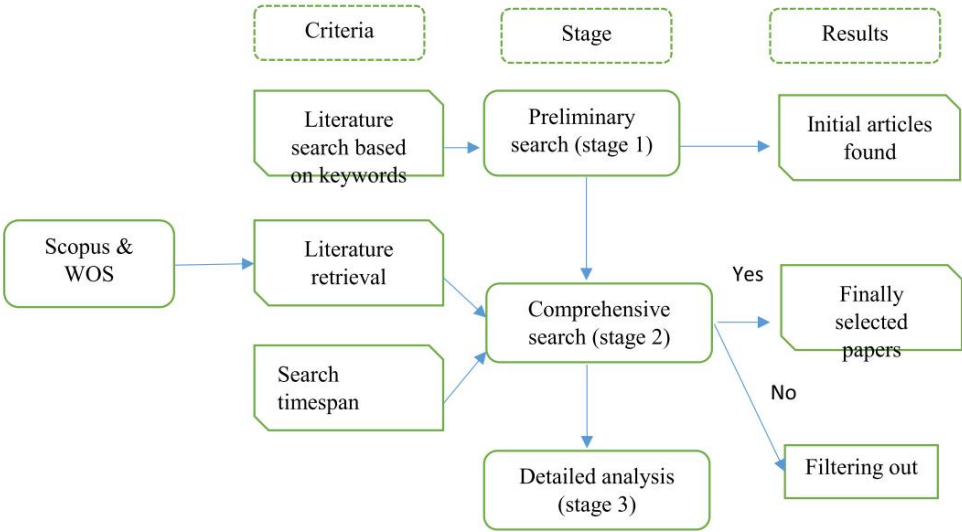


Fig. 2 Metodologia de pesquisa usado neste papel



rede oferece uma cópia de uma área de informação que fornece insights sobre os assuntos disponíveis e como esses tópicos são relacionados e ordenados [9]. Portanto, o VOSviewer 1.6.11 software foi aplicado para fornecer uma co-ocorrência de palavra-chave rede, e os dados bibliográficos foram derivados do Scopus. As palavras-chave dos autores foram usadas para gerar uma rede de palavras-chave. Uma soma de 1931 palavras-chave foi obtida de o conjunto de dados, em relação à contagem completa. A Tabela 1 apresenta as configurações de parâmetro para visualização de palavras-chave.

A rede resultante contém 500 nós e 4000 links, como mostrado na Fig. 3, que também apresenta os principais campos para previsão de coronavírus. Links mais fortes no visualização da rede são indicadas por linhas mais grossas [10]. Isto pode ser visto na Fig. 3 que Coronavírus, previsão, epidemia, humano e previsão têm links de conexão. Além disso, a Fig. 3 apresenta uma visualização de rede baseada em palavras-chave, onde Coronavírus, previsão, epidemia, humano, análise estatística, quarentena, hospitalização, mortalidade e clima estão entre as principais palavras-chave que os pesquisadores focaram. Na Fig. 3, o cluster é indicado pela cor, e o círculo maior representa a palavra-chave que é mais usado.

A Figura 4 apresenta a análise detalhada da soma de trabalhos citados e o número de registros versus afiliações. Os números filtrados de registros e trabalhos citados incluem uma mínimo de 1 e 18, respectivamente.

Tabela 1 Configurações de parâmetros

Parâmetro	Valor
Número mínimo de ocorrências	1
Critério atendido	1931 palavras-chave

5 Ilustrações genéricas

Vários modelos epidêmicos têm sido usados por pesquisadores para estimar o surto a curto e longo prazo [11–14]. Os modelos epidêmicos mais aplicados são os suscetíveis, modelo infectado e recuperado (SIR) e suscetível, expostos, infectados e recuperados (SEIR). O modelo SIR [15, 16] é descrito como mostrado na Fig. 5:

Em termos de modelagem matemática, o modelo SIR é mostrado abaixo [17]:

$$\frac{ds}{dt} = -\frac{1}{4} b i s$$
 01P

$$\frac{di}{dt} = \frac{1}{4} b i s - c i$$
 02P

$$\frac{dr}{dt} = c i$$
 03P

onde S é o número de indivíduos suscetíveis no tempo t; E é o número de indivíduos infectados no tempo t; R é o número de indivíduos recuperados no tempo t; e b e c são a taxa de transmissão e a taxa de recuperação (remoção), respectivamente. O modelo SEIR [18] é semelhante ao SIR modelo, exceto que a variável E é adicionada para a fração de indivíduos que foram infectados, mas são assintomáticos. O modelo SEIR e as equações relacionadas são apresentados em Fig. 6.

As equações do modelo SEIR são definidas abaixo:

$$\frac{dS}{dt} = -\frac{1}{4} b \frac{S i}{N}$$
 04P

$$\frac{dE}{dt} = \frac{1}{4} b \frac{S i}{N} - c E$$
 5<sup>a</sup>




Fig. 3 Redes entre os links (análise de palavras-chave)

$\frac{dI}{dt}$	$\frac{1}{4} cE - \delta I$	$\delta I$
$\frac{dQ}{dt}$	$\frac{1}{4} dI - kQ + jQ$	$\delta Q$
$\frac{dR}{dt}$	$\frac{1}{4} kQ$	$\delta R$
$\frac{dD}{dt}$	$\frac{1}{4} jQ$	$\delta D$
$\frac{dP}{dt}$	$\frac{1}{4} aS$	$\delta P$

onde  $a$  representa a taxa de proteção;  $b$  é a taxa de infecção;  $c$  é o inverso do tempo latente médio;  $d$  representa o inverso do tempo médio de quarentena;  $k_0$  e  $k_1$  são coeficientes usados na taxa de cura dependente do tempo; e  $j_0$  e  $j_1$  são coeficientes usados na taxa de mortalidade dependente do tempo [18].

6 Modelagem matemática

Ahmar e del Val [19] usaram o método SutteARIMA para prever casos confirmados de curto prazo de COVID-19 e Índice de Mercado de Espanha (IBEX 35). Comparativamente, o método SutteARIMA mostrou-se mais adequado para prevendo casos confirmados diários na Espanha do que o Média Móvel Integrada AutoRegressiva (ARIMA) com base no erro percentual médio absoluto (MAPE) valores. Al-qaness [20] sugeriu uma versão melhorada do o Sistema Adaptativo de Inferência Neuro-Fuzzy (ANFIS) baseado no Algoritmo de Polinização de Flores (FPA) usando o Algoritmo Salp Swarm para prever o número de casos confirmados de COVID-19 na China. A ideia é determinar os parâmetros do Adaptativo Neuro-Fuzzy Sistema de Inferência usando o híbrido dos Algoritmos de Polinização de Flores e Enxame de Salpas. O desempenho da FPA foi validado comparando-o com o existente modificado Modelos ANFIS, como o Particle Swarm Optimization (PSO), algoritmo genético (GA), Bayesiano aproximado



Department of Pathophysiology and Transplantation, University of Milan, Italy; Dipartimento di Anestesia, Rianimazione Ed Emergenza-Urgenza, Fondazione IRCCS Ca' Granda Ospedale Maggiore Policlinico, Milan, Italy; Dipartimento Anestesia e Terapie Intensive, Humanitas Rozzano, Milan, Italy	University of Texas at Austin, Austin, TX, United States; Institut Pasteur, Paris, France; Dalian Minzu University, Dalian, China; Dalian University of Technology, Dalian, China; University of Hong Kong, Hong Kong; Santa Fe Institute, Santa Fe, NM, United States	Big Data Research Center, University of Electronic Science and Technology of China, Chengdu, 611731, China; College of Computer Science, Sichuan University, Chengdu, 610065, China; Beijing AIQIYI Science & Technology Co.	Diagnostic and Interventional Ultrasound Unit, Valle del Serchio General Hospital, Lucca, Italy; Pulmonary Medicine Unit, Department of Cardiovascular and Thoracic Sciences, Fondazione Policlinico Universitario	Department of Population Health Sciences, School of Public Health, Georgia State University, Atlanta, GA, United States; Department of Mathematics, Center for Computational Science, Tulane University, New Orleans, LA,	Cited by 18 to 242 and Null values Number of Rec.. 1
	Singapore Health Service (SingHealth), Duke-NUS Medical School, Singapore, Singapore; Duke University, Durham, NC, United States; US National Academy of Medicine, Washington, DC, United States	Leverhulme Centre for Demographic Science, Nuffield College, University of Oxford, Oxford, OX1 3UQ, United Kingdom	Biozentrum, University of Basel, Switzerland / Swiss Institute of Bioinformatics, Basel, Switzerland; Department of	Department Infection Control and Infectious Disease, University of Regensburg, Regensburg, Germany;	
Department of Microbiology, Medical School, University of Athens, Athens, Greece; Consiglio Nazionale delle Ricerche, Science and Technology for Energy and Sustainable Mobility, Napoli,		School of Management, University of Bath, Bath, United Kingdom; Institute for the Future (IFF), University of Nicosia, Nicosia,		State Key Laboratory for Information Engineering in Surveying, Mapping and Remote Sensing,	

Fig. 4 Uma análise detalhada (soma dos trabalhos citados e número de registros vs. Afiliações)



Fig. 5 Modelo suscetível, infectado e recuperado (SIR)

computação (ABC) e FPA. Anastassopoulou e Russo [21] propuseram um método para prever o número de reprodução ( $R_0$ ) do modelo suscetível, infectado, recuperado e falecido (SIRD) e outros parâmetros-chave para prever a propagação da epidemia de COVID-19 na China.

Chakraborty e Ghosh [22] apresentaram uma previsão em tempo real de casos confirmados de COVID-19 para vários países como

bem como uma avaliação de risco do novo COVID-19 para alguns países profundamente afetados usando o algoritmo da árvore de regressão. Uma abordagem de média móvel simples foi usada por [23] para prever casos confirmados de COVID-19 no Paquistão. [24] usaram um modelo de crescimento logístico de cinco parâmetros para reconstruir e prever a epidemia de COVID-19 nos EUA; no entanto, os autores alegaram que a precisão de seu modelo depende de decisões políticas em nível federal e estadual. Cheng e Burcu [12] introduziram uma plataforma, [icumonitoring.ch](http://icumonitoring.ch), para fornecer projeções em nível hospitalar para ocupação de unidades de terapia intensiva (UTI) com base em modelos SEIR. A plataforma proposta pode ajudar os gerentes de UTI a estimar

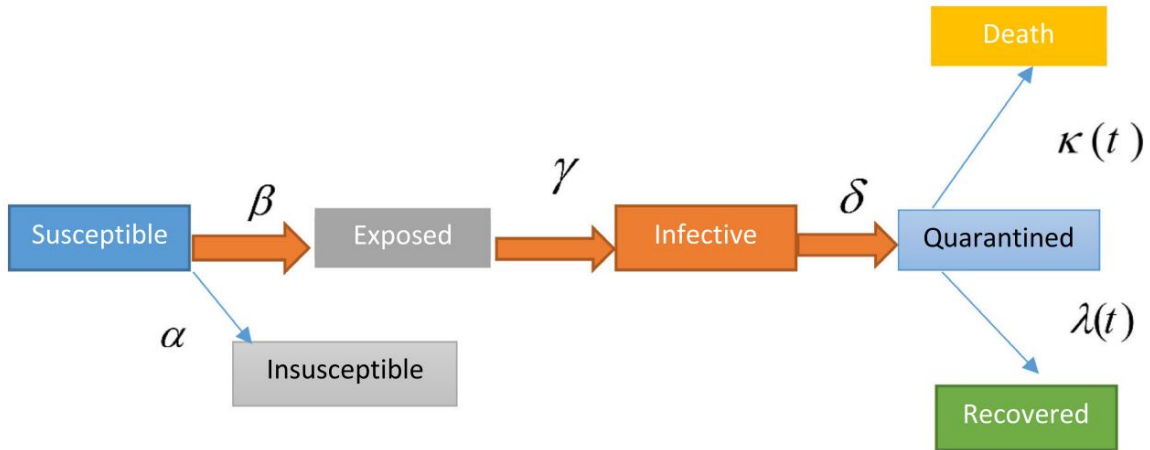


Fig. 6 O diagrama suscetível, exposto, infectado e recuperado (SEIR) [18]

a necessidade de recursos adicionais e é atualizado a cada 3–4 dias. Chimmula e Zhang [25] aplicaram redes de memória de longo prazo (LSTM) como uma técnica de aprendizado profundo para prever surtos de COVID-19 no Canadá. Sua abordagem identificou os principais recursos para estimar as tendências da pandemia no Canadá. Um modelo ARIMA simples foi proposto por [26] para estimar casos registrados e recuperados após um bloqueio na Itália.

Salgotra e Gandomi [4] estabeleceram dois modelos de previsão de COVID-19 baseados em programação genética na Índia. Seus resultados indicam que os modelos de programação evolutiva genética são altamente confiáveis para casos de COVID-19 na Índia. Dil e Dil [11] usaram o modelo SIR para prever casos confirmados de COVID-19 na região do Mediterrâneo Oriental, ou seja, Irã, Iraque, Arábia Saudita, Emirados Árabes Unidos, Líbano, Egito e Paquistão, com foco especial no Paquistão. Um modelo SIRD simples foi proposto por [14] para prever surtos de COVID-19 na China, Itália e França e estimar as necessidades das unidades de saúde, como unidades de ventilação.

## 7 Avaliação de critérios

Previsão de casos confirmados, avaliação de risco, bolsa de valores, leitos de UTI, casos registrados e recuperados são os principais critérios pelos quais os acadêmicos demonstram maior interesse.

## 8 Abordagens de solução

Várias abordagens foram abordadas por pesquisadores para prever o surto de COVID-19 [27, 28]. A Tabela 2 apresenta as abordagens de solução propostas pelos pesquisadores para a previsão do COVID-19, entre as quais SIR, SEIR, SIRD e Média Móvel são as abordagens mais populares. Além disso, alguns pesquisadores [29, 30] preferiram usar algoritmos híbridos para aumentar o poder dos algoritmos de previsão.

### 8.1 Modelo autorregressivo

O modelo autorregressivo de séries temporais é conhecido como uma ferramenta útil para modelar dados dependentes e tem sido aplicado a vários problemas do mundo real [49-53].

#### 8.1.1 Média móvel

Em estatística e economia, uma média móvel é uma maneira de calcular e analisar dados fornecendo uma série de médias de vários subconjuntos do conjunto de dados [54].

8.1.1.1 Média móvel simples Uma média móvel simples (SMA) é definida como a média não ponderada do

dados (em finanças) ou um número igual de dados em ambos os lados de um valor central (em ciência ou engenharia) [54]. Um exemplo de aplicação de uma média móvel simples no COVID-19 pode ser encontrado em [23].

8.1.1.2 Média móvel integrada autoregressiva (ARIMA) Um modelo de média móvel integrada autoregressiva é uma forma generalizada do modelo de média móvel autoregressiva. Como é bem conhecido pela previsão, alguns pesquisadores usaram o ARIMA para prever a propagação da nova pandemia [31, 55-58].

#### 8.1.2 Distribuições de duas peças com base na escala

Maleki M et al. [35] propuseram um modelo de série temporal autorregressivo baseado na distribuição normal de mistura de escala de duas peças para prever casos confirmados e recuperados de COVID-19. Comparado com o modelo de série temporal autorregressivo padrão, o algoritmo proposto supera outros na previsão de casos confirmados e recuperados de COVID-19 em todo o mundo.

## 8.2 Modelos exponenciais

Modelos exponenciais são adequados na modelagem de diversos fenômenos, como populações, taxas de juros e doenças infecciosas [59].

#### 8.2.1 Funções logísticas

Uma das famosas curvas em forma de S é uma função logística com aplicação em biologia, química, linguística, ciência política e estatística. [24, 37, 38] fornecem exemplos de aplicações de funções logísticas no COVID-19.

#### 8.2.2 Aprendizado profundo

O aprendizado profundo é um ramo famoso do aprendizado de máquina no qual o processo de aprendizado pode ser supervisionado, semi-supervisionado, não supervisionado [60-62]. A aplicação de diferentes formas de aprendizado profundo na previsão de casos de COVID-19 pode ser encontrada em redes de memória de longo prazo (LSTM) [25, 63], rede neural polinomial [39] e rede neural [31, 40].

#### 8.2.3 Métodos de regressão

Em estatística, os métodos de regressão são um conjunto de modelagem estatística para estimar a relação entre uma variável dependente e uma(s) variável(is) independente(s) [64, 65]. Como uma ferramenta poderosa para prever a pandemia, vários métodos de regressão foram abordados por pesquisadores contra o COVID-19 [42-44, 66, 67].

Tabela 2 Abordagens de solução propostas para a previsão do coronavírus 2019 (COVID-19)

Algoritmo							
Modelos epidêmicos		Modelos de séries temporais					Inspirado na natureza algoritmos
SENHOR	[11]	Autoregressivo modelo	Média móvel	Média móvel integrada	autorregressiva		Genético programação [30–34]
					[19, 22, 26, 30, 31]		
				Média móvel simples	[23]		
			Outros modelos	[35]			
POEMA	[12, 36]	Modelos exponenciais		Modelo de crescimento logístico	[24, 37, 38]		Flor polinização algoritmo [29]
SIRD	[13, 14]	Aprendizado profundo	Redes de memória de longo prazo (LSTM)	[25]			Polinomial Neural Rede [39]
			Rede neural	[31, 40]			Ecológico Modelos de nicho [41]
		Regressão métodos	[42–44]				
		Algoritmo do profeta					
Fenomenológico modelo	[46]	Outros modelos	Neuro adaptativo difuso inferência sistema [29]	Regressão árvore algoritmo [22]	Apoio, suporte vetor máquina [39, 47]	Iteração método [48]	Apoio, suporte vetor Kuhn Tucker [47]

8.2.4 Algoritmo do Profeta

O algoritmo Prophet é uma ferramenta de código aberto que funciona bem com dados de séries temporais que têm efeitos sazonais. o objetivo principal do algoritmo, desenvolvido pela Data do Facebook Equipe científica, é a previsão de negócios [68, 69]. o O algoritmo Profeta provou ser robusto ao lidar com dados ausentes [70].

8.2.5 Programação genética

A programação genética (GP) é um algoritmo inspirado na natureza, onde as chaves incluem a representação do programa (árvore estrutura), seleção, cruzamento e mutação [71]. Algum exemplos de GP no COVID-19 estão disponíveis em [32–34].

8.2.6 SIR

Um dos modelos epidêmicos mais aplicados é o modelo suscetível, infectado e recuperado (SIR) [15, 16]. As variáveis S, I e R são definidas nas Eqs. 1–3.

8.2.7 SEIR

O modelo SEIR [18] é uma versão estendida do SIR modelo, que considera um parâmetro adicional, E,

representando a fração de indivíduos que foram infectados, mas assintomáticos.

8.2.8 SIRD


O modelo SIRD diferencia entre os indivíduos recuperados indivíduos (aqueles que sobreviveram à doença e agora estão imunes) e indivíduos falecidos [13, 14].

9 Pontos fortes e fracos da previsão modelos

Conforme discutido anteriormente, muitos algoritmos de aprendizado de máquina têm sido usados para prever a nova pandemia em diferentes lugares do mundo. A Figura 7 apresenta a porcentagem de contribuição de diferentes abordagens de solução aplicadas em previsão de casos confirmados de COVID-19 (há 925 artigos indexados na Scopus em 10 de outubro de 2020). Como isso é claro da Fig. 7, aprendizado profundo, modelos compartimentais, e outros métodos têm as maiores contribuições, enquanto o Algoritmo Profeta, como um novo ramo de aprendizado de máquina, tem a menor contribuição.

Os algoritmos de aprendizado de máquina exibem muitos prós e contras, que são descritos na Tabela 3.

Fig. 7% de contribuição de diferentes abordagens de solução aplicadas na previsão de casos confirmados de COVID-19



10 Conclusão e discussão

No momento da redação deste artigo, o COVID-19 havia se espalhado para mais de 200 países em todo o mundo, com mais de 36 milhões de casos firmados. Vários trabalhos foram lançados em campo para a previsão de surtos globais. Este estudo teve como objetivo revisar os modelos de previsão mais importantes para o COVID-19 e fornecer uma breve análise da literatura publicada. Este artigo destacou as áreas temáticas mais importantes por palavras-chave

análise. Além disso, foram identificados vários critérios que podem auxiliar os pesquisadores para trabalhos futuros. Além disso, este artigo reconheceu os modelos mais úteis que os pesquisadores aplicaram para prever essa pandemia. Além disso, este artigo pode ajudar pesquisadores a identificar lacunas importantes na área de pesquisa e, posteriormente, desenvolver novos modelos de aprendizado de máquina para previsão de casos de COVID-19. Uma análise cienciométrica detalhada foi realizada como ferramenta influente para uso em análises e revisões bibliométricas. Para isso, são discutidas palavras-chave e áreas temáticas,

Tabela 3 Pontos fortes e fracos dos algoritmos de aprendizado de máquina propostos

Algoritmo	Força	Fraqueza
Rede neural artificial	Poderia acessar vários algoritmos de treinamento [72]	A natureza de ser uma caixa preta [72], overtraining [73]
Máquina de vetores de suporte	Pode evitar overfitting e definir um problema de otimização convexa [72]	Escolha do kernel, bem como velocidade e tamanho dos conjuntos de treinamento e teste [72]
Modelos compartimentais (SIR, SEIR, SIRD, etc.)	Preveja como a doença se espalha Apresentar os efeitos das intervenções de saúde pública no resultado da pandemia [74-78]	Os modelos propostos são em sua maioria determinísticos e funcionam com grandes populações [79]
Algoritmos inspirados na natureza (programação genética)	Pesquisa inteligente [80] Pode se integrar com certos algoritmos de decomposição [81]	Vários parâmetros devem ser definidos pela decisão fabricantes Os algoritmos são aproximados e geralmente não determinísticos [82]
Algoritmo do profeta	São robustos ao lidar com dados ausentes [70]	É difícil usar o algoritmo para Multiplicative modelos O formato predefinido é necessário para os dados antes de usar o algoritmo
ARIMA	Funciona para modelos sazonais e não sazonais Outliers podem ser bem tratados	Mudanças nas observações e mudanças na especificação do modelo tornam o modelo instável [83]
Aprendizado profundo	Resultados comparáveis ao desempenho de especialistas humanos [84, 85]	Requer grandes quantidades de dados O processo de treinamento é caro



a classificação de modelos de previsão, avaliação de critérios e comparação de métodos de solução são fornecidos na segunda seção do trabalho.

Este estudo descreve alguns argumentos-chave que são tua de mais discussão:

- Em termos de área temática, medicina, bioquímica e matemática são as áreas mais discutidas pelos acadêmicos.
- Em termos de análise de palavras-chave, as tendências mostram que os estudos sobre COVID-19 aumentarão nos próximos poucos meses. Além disso, Coronavírus, previsão, epidemia, humano, análise estatística, quarentena, hospitalização, mortalidade e instâncias meteorológicas são as palavras-chave mais interessantes para os acadêmicos. • Vários outros critérios têm sido usados por pesquisadores na previsão, incluindo:

– Casos confirmados, avaliação de risco, bolsa de valores, unidades de ventilação, leitos de UTI, estimativa de casos registrados e recuperados.

- Vários países, incluindo China, Paquistão, França, Itália, EUA, Reino Unido, Brasil, Nigéria, Irã, Alemanha e Índia, foram abordados como estudos de caso.
- Entre os modelos epidêmicos, deep learning, SIR e SEIR são os principais modelos usados pelos pesquisadores. • Os algoritmos híbridos são usados para aumentar o poder das abordagens de previsão. • A maioria dos estudos são abordagens determinísticas, embora haja uma necessidade urgente de fornecer abordagens robustas para lidar com situações incertas.

Para futuras direções de pesquisa, uma revisão abrangente em outros campos, como inteligência artificial (IA) e aprendizado profundo, é incentivada. Além disso, mais estudos abordando o desenvolvimento de abordagens novas e híbridas para prever a pandemia devem ser investigados. Além disso, no momento da redação deste artigo, tínhamos acesso a apenas um número limitado de artigos publicados pela Scopus e WOS.

No entanto, as partes mais importantes deste artigo são as palavras-chave e a análise cientométrica que considera toda a base de dados, das quais escolhemos alguns exemplos de artigos publicados para revisão. Portanto, sugere-se uma revisão mais abrangente na área de pesquisa.

Financiamento Os autores confirmam que não há fonte de financiamento para este estudo.

## Conformidade com os padrões éticos

Conflito de interesse Os autores declaram não ter conflito de interesse.

## Referências

- Putra S, Khozin Mutamar Z (2019) Estimativa de parâmetros no modelo epidêmico SIR usando otimização de enxame de partículas. *Am J Math Comput Model* 4(4):83–93
- Mbuvha RR, Marwala T (2020) Sobre gestão orientada por dados de o surto de COVID-19 na África do Sul. *medRxiv*
- Qi H et al (2020) A transmissão do COVID-19 na China continental está associada à temperatura e umidade: uma análise de série temporal, p 138778
- Salgotra R, Gandomi M, Gandomi AH (2020) Análise de séries temporais e previsão da pandemia de COVID-19 na Índia usando programação genética. *Chaos Solitons Fractals* 138:109945
- Mahalle P et al (2020) Modelos de previsão para coronavírus (covid-19): um levantamento do estado da arte. *TechRxiv*. <https://doi.org/10.36227/techrxiv.12101547.v1> (Pré-impressão)
- Naude W (2020) Inteligência artificial contra o COVID-19: uma revisão inicial. Documento de discussão da IZA nº 13110. <https://ssrn.com/abstract=3568314>
- Shrivastava R, Mahajan PJS, Bibliotecas T (2016) Pesquisa em inteligência artificial na Índia: uma análise cientométrica. *Sci Technol Libr* 35(2):136–151
- Su HN, Lee P-CJS (2010) Mapeando a estrutura do conhecimento por cocorrência de palavras-chave: um primeiro olhar sobre artigos de periódicos em previsão tecnológica. *Cienciometria* 85(1):65–79
- Van Eck NJ, Waltman L (2014) Visualizando redes bibliométricas. In: Ding Y, Rousseau R, Wolfram D (eds) *Medindo o impacto acadêmico*. Springer, Berlim, pp 285–320
- Van Eck NJ, Waltman L (2013) *VOSviewer manual*, vol 1. Univeriteit Leiden, Leiden, pp. 1–53
- Dil S, Dil N, Maken ZH (2020) Tendências e previsões da COVID-19 na região leste do Mediterrâneo, com foco particular no Paquistão. *Cureus* 12(6):8
- Cheng Z et al (2020) icumonitoring.ch: uma plataforma para previsão de curto prazo de ocupação de unidades de terapia intensiva durante a epidemia de COVID 19 na Suíça. *Swiss Med Weekly* 150:10
- Anastassopoulou C et al (2020) Análise, modelagem e previsão baseadas em dados do surto de COVID-19. *PLoS ONE* 15(3):21
- Fanelli D, Piazza F (2020) Análise e previsão da disseminação do COVID-19 na China, Itália e França. *Fractais de Solitões do Caos* 134:5
- Kermack WO, McKendrick AG (1932) Contribuições para a teoria matemática das epidemias. II: o problema da endemicidade. *Proc R Soc Lond Ser A* 138(834):55–83
- Capasso V, Serio G (1978) Uma generalização do modelo epidêmico determinístico de Kermack-McKendrick. *Math Biosci* 42(1–2):43–61
- Weiss HH (2013) O modelo SIR e os fundamentos do público saúde. *Mater Mat* 2013(3):1–17
- Peng L et al (2020) Análise epidêmica do COVID-19 na China por modelagem dinâmica. [arXiv:2002.06563](https://arxiv.org/abs/2002.06563)
- Ahmar AS, del Val EB (2020) SutteARIMA: método de previsão de curto prazo, um caso—Covid-19 e mercado de ações na Espanha. *Sci Total Environ* 729:138883
- Al-qaness MAA et al (2020) Método de otimização para previsão de casos confirmados de COVID-19 na China. *J Clin Med* 9(3):674
- Anastassopoulou C et al (2020) Análise, modelagem e previsão baseadas em dados do surto de COVID-19. *PLoS ONE* 15(3):e0230405
- Chakraborty T, Ghosh I (2020) Previsões em tempo real e avaliação de risco de novos casos de coronavírus (COVID-19): uma análise baseada em dados. *Chaos Solitons Fractals* 135:10
- Chaudhry RM et al (2020) Coronavirus disease 2019 (COVID 19): previsão de uma urgência emergente no Paquistão. *Cureus* 12(5):15

24. Chen DG, Chen XG, Chen JK (2020) Reconstruindo e prevendo a epidemia de COVID-19 nos Estados Unidos usando um modelo de crescimento logístico de 5 parâmetros. *Política de Res. Glob Health* 5(1):7
25. Chimmula VKR, Zhang L (2020) Previsão de séries temporais da transmissão de COVID-19 no Canadá usando redes LSTM. *Fractais de Solitons do Caos* 135:6
26. Chintalapudi N, Battineni G, Amenta F (2020) Previsão de surto de vírus COVID-19 de casos registrados e recuperados após o bloqueio de sessenta dias na Itália: uma abordagem de modelo orientada por dados. *J Microbiol Immunol Infect* 53(3):396-403
27. Kavadi DP, Patan R, Ramachandran M, Gandomi AH (2020) Previsão parcial de aprendizado de máquina pandêmico não linear global derivado parcial do COVID-19. *Fractais Chaos Solitons*. <https://doi.org/10.1016/j.chaos.2020.110056>
28. Mousavi M, Salgotra R, Holloway D, Gandomi AH (2020) COVID-19 previsão de séries temporais usando taxa de transmissão e parâmetros meteorológicos como recursos. *IEEE Comput Intell Mag* (no prelo). <https://doi.org/10.1109/mci.2020.3019895>
29. Al-qaness MAA et al (2020) Método de otimização para previsão de casos confirmados de COVID-19 na China. *J Clin Med* 9(3):15
30. Singh S et al (2020) Desenvolvimento de novo modelo híbrido de decomposição wavelet discreta e modelos de média móvel integrada autorregressiva (ARIMA) em aplicação para previsão de um mês dos casos de vítimas de COVID-19. *Fractais de Solitões do Caos* 135:8
31. Moftakhar L, Seif M, Safe MS (2020) Tendência exponencialmente crescente de pacientes infectados com COVID-19 no Irã: uma comparação de rede neural e modelos de previsão ARIMA. *Iran J Public Health* 49:92-100
32. Salgotra R et al (2020) Análise de séries temporais e previsão da pandemia de COVID-19 na Índia usando programação genética. *Chaos Solitons Fractais* 138:109945
33. Salgotra R, Gandomi M, Gandomi AH (2020) Modelagem evolutiva da pandemia de COVID-19 em quinze países mais afetados. *Fractais Chaos Solitons*. <https://doi.org/10.1016/j.chaos.2020.110118>
34. Salgotra R, Gandomi AH (no prelo) Análise de séries temporais da pandemia de COVID-19 na Austrália usando programação genética. In: Kose U et al (eds) *Data science for COVID 19*. Elsevier 35. Maleki M et al (2020) Modelagem de séries temporais para prever os casos confirmados e recuperados de COVID-19. *Travel Med Infect Dis* 37:101742
36. Reno C et al (2020) Previsão de interações hospitalares associadas ao COVID-19 sob diferentes níveis de distanciamento social na Lombardia e Emilia-Romagna, norte da Itália: resultados de um modelo compartimental SEIR estendido. *J Clin Med* 9(5):11
37. Li Q, Feng W, Quan YH (2020) Tendência e previsão do surto de COVID-19 na China. *J Infect* 80(4):472-474
38. Qeadan F et al (2020) Previsão ingênua para COVID-19 em Utah com base nos modelos da Coreia do Sul e Itália - a flutuação entre dois extremos. *Int J Environ Res Public Health* 17(8):14
39. Fong SJ et al (2020) Encontrando um modelo de previsão antecipado preciso a partir de um pequeno conjunto de dados: um caso de surto de novo coronavírus 2019-nCoV. *Int J Interact Multimed Artif Intell* 6(1):132-140
40. Tamang SK, Singh PD, Datta B (2020) Previsão de casos Covid-19 com base na previsão usando técnica de ajuste de curva de rede neural artificial. *Glob J Environ Sci Manag* 6:53-64
41. Ren HY et al (2020) Previsão antecipada das potenciais zonas de risco do COVID-19 nas megacidades da China. *Sci Total Environ* 729:8
42. Ji D et al (2020) Previsão de risco de progressão em pacientes com pneumonia por COVID-19: o CALL Score. *Clin Infect Dis* 71(6):1393-1399. <https://doi.org/10.1093/cid/ciaa414>
43. Ribeiro MHD et al (2020) Previsão de curto prazo de casos confirmados cumulativos de COVID-19: perspectivas para o Brasil. *Fractais Chaos Solitons* 135:109853
44. Sujath R et al (2020) Um modelo de previsão de aprendizado de máquina para a pandemia de COVID-19 na Índia. *Avaliação de risco Stochast Environ Res* 34:959-972
45. Abdulmajeed K, Adeleke M, Popoola LJD (2020) Previsão online de casos de Covid-19 na Nigéria usando dados limitados. *Resumo de dados* 30:105683
46. Roosa K et al (2020) Previsões em tempo real da epidemia de COVID-19 na China de 5 a 24 de fevereiro de 2020. *Infect Dis Model* 5:256-263
47. Parbat, DJC, Solitons and Fractals, um modelo de regressão vetorial de suporte baseado em Python para previsão de casos de Covid19 na Índia. 2020: pág. 109942
48. Perc M et al (2020) Previsão Covid-19. *Front Phys* 8:127
49. Maleki M, Arellano-Valle RB (2017) Estimativa máxima a posteriori de processos autorregressivos com base em misturas finitas de misturas de escala de distribuições assimétricas-normais. *J Stat Comput Simul* 87(6):1061-1083
50. Maleki M, Nematollahi AJ, Tecnologia TAS (2017) Modelos autoregressivos com mistura de misturas de escala de inovações gaussianas. *Iran J Sci Technol Trans A Sci* 41(4):1099-1107
51. Zarrin P et al (2019) Modelos de séries temporais baseados no processo skew-normal irrestrito. *J Stat Comput Simul* 89(1):38-51
52. Maleki M et al (2017) Uma abordagem Bayesiana para processos autoregressivos distorcidos robustos. *Calcutá Stat Assoc Bull* 69(2):165-182
53. Hajraji A, Maleki MJ (2019) Modelo autoregressivo semiparamétrico não linear com misturas finitas de misturas de escala de inovações normais inclinadas. *J Appl Stat* 46(11):2010-2029
54. Sprinthal RC, Fisk ST (1990) Análise estatística básica. *Aprendiz Hall*, Englewood Cliffs 55.
55. Roy S, Bhunia GS, Shit PK (2020) Previsão espacial da epidemia de COVID 19 usando técnicas ARIMA na Índia. *Modelo Earth Syst Environ*. <https://doi.org/10.1007/s40808-020-00890-y>
56. Alzahrani SI et al (2020) Previsão da propagação da pandemia de COVID-19 na Arábia Saudita usando o modelo de previsão ARIMA sob as atuais intervenções de saúde pública. *J Infectar Saúde Pública* 13:914-919
57. Kufel TJ (2020) Previsão baseada em ARIMA da dinâmica de casos confirmados de Covid-19 para países europeus selecionados. *Equilib QJ Econ Econ Policy* 15(2):181-204
58. Singh S et al (2020) Desenvolvimento de um novo modelo híbrido de decomposição wavelet discreta e modelos de média móvel integrada autorregressiva (ARIMA) em aplicação a um mês de previsão das vítimas casos de COVID-19. *Chaos Solitons Fractais* 135:109866
59. Smith BAJIDM (2020) Uma nova IDEIA: o impacto do intervalo serial em um modelo de decaimento de incidência modificada e ajuste exponencial (m-IDEA) para projeções de casos diários de COVID-19. *Infect Dis Model* 5:346-356
60. Bengio Y et al (2013) Aprendizagem de representação: uma revisão e novas perspectivas. *IEEE Trans Pattern Anal Mach Intell* 35(8):1798-1828
61. Schmidhuber JJ (2015) Aprendizado profundo em redes neurais: um Visão geral. *Rede Neural* 61:85-117
62. LeCun Y, Bengio Y, Hinton GJ (2015) Aprendizado profundo. *Natureza* 521(7553):436-444
63. Ayyoubzadeh SM et al (2020) Prevendo a incidência de COVID-19 por meio da análise de dados de tendências do Google no Irã: estudo piloto de mineração de dados e aprendizado profundo. *JMIR Public Health Surveill* 6(2):e18828
64. Freedman DA (2009) Modelos estatísticos: teoria e prática. Cambridge University Press, Cambridge 65. Cook RD, Weisberg SJ (1982) Crítica e análise de influência na regressão. *Sociol Methodol* 13:313-361
66. Vela'squez RMA, Lara JVMJC (2020) Previsão e avaliação da disseminação do COVID-19 nos EUA com regressão de processo gaussiana de espaço reduzido. *Chaos Solitons Fractais* 136:109924

67. Almeshal AM et al (2020) Prevendo a disseminação do COVID-19 no Kuwait usando modelos de regressão compartimental e logística. *Appl Sci* 10(10):3402
68. Taylor SJ, Letham B (2018) Previsão em escala. *Am Stat* 72(1):37–45
69. Taylor S, Letham B (2017) Profeta: procedimento de previsão automática. Versão do pacote R 0.1. <https://CRAN.R-project.org/package=prophet>
70. Ndiaye BM, Tendeng L, Seck D (2020) Análise da pandemia de COVID 19 pelo modelo SIR e técnicas de aprendizado de máquina para previsão. [arXiv:2004.01574](https://arxiv.org/abs/2004.01574)
71. Banzhaf W et al (1998) Programação genética. Springer, Berlim
72. Jalalkamali A et al (2015) Aplicação de vários modelos de inteligência artificial e modelo ARIMAX para previsão de seca usando o Índice de Precipitação Padronizado. *Int J Environ Sci Technol* 12(4):1201–1210
73. Wilamowski BMJIEEM (2009) Arquiteturas de redes neurais e algoritmos de aprendizagem. *IEEE Ind Electron Mag* 3(4):56–63
74. Hethcote HW (1989) Três modelos epidemiológicos básicos. In: Levin SA, Hallam TG, Gross LJ (eds) *Ecologia matemática aplicada*. Springer, Berlim, pp 119–144
75. Brauer F, Castillo-Chavez C (2012) *Modelos matemáticos em biologia populacional e epidemiologia*, vol 2. Springer, Berlim
76. Nunn C, Altizer S, Altizer SM (2006) *Doenças infecciosas em primatas: comportamento, ecologia e evolução*. Oxford University Press, Oxford
77. Gao S et al (2007) Análise de um modelo epidêmico SIR com vacinação de pulso e atraso de tempo distribuído. *J Biomed Biotechnol* 2007:64870. <https://doi.org/10.1155/2007/64870>
78. Rahimi I, Gandomi AH, Chen F et al (2020) Análise e previsão de COVID-19 usando SIR, SEIR e modelos de aprendizado de máquina: Casos da Austrália, Itália e Reino Unido, 13 de outubro de 2020, PRE PRINT (versão 1) ) disponível na Praça da Pesquisa. <https://doi.org/10.21203/rs.3.rs-85513/v1>
79. Bartlett MS (1957) Periodicidade do sarampo e tamanho da comunidade. *JR Stat Soc Ser A* 120(1):48–70
80. Glover F, Laguna M (1998) *Tabu search. Manual de otimização combinatória*. Springer, Boston, MA, pp 2093–2229
81. Poojari CA, Beasley JE (2009) Melhorando a decomposição de dobradores usando um algoritmo genético. *Eur J Oper Res* 199(1):89–97
82. Blum C, Roli AJ (2003) Metaheurísticas em otimização combinatória: visão geral e comparação conceitual. *Sobrevivência de Computação ACM* 35(3):268–308
83. Makridakis S, Hibon MJ (1997) modelos ARMA e a metodologia Box Jenkins. *J Forecast* 16(3):147–163
84. Ciregan D, Meier U, Schmidhuber J (2012) Redes neurais profundas de várias colunas para classificação de imagens. In: *Conferência IEEE 2012 sobre visão computacional e reconhecimento de padrões*. IEEE
85. Krizhevsky A, Sutskever I, Hinton GE (2017) Classificação de imagenet com redes neurais convolucionais profundas. *Commun ACM* 60(6):84–90. <https://doi.org/10.1145/3065386>

Nota do editor Springer Nature permanece neutro em relação a reivindicações jurisdicionais em mapas publicados e afiliações institucionais.