

Previsão de séries temporais relacionais

RYAN A. ROSSI

Adobe Research, 345 Park Avenue, San Jose, CA 95110; e-mail:
rrossi@adobe.com

Resumo

As redes codificam dependências entre entidades (pessoas, computadores, proteínas) e nos permitem estudar fenômenos em domínios sociais, tecnológicos e biológicos. Essas redes evoluem naturalmente ao longo do tempo pela adição, exclusão e alteração de links, nós e atributos. Apesar da importância de modelar essas dinâmicas, o trabalho existente em aprendizado de máquina relacional ignorou dados de séries temporais relacionais. O aprendizado de séries temporais relacionais está na interseção da análise tradicional de séries temporais e do aprendizado relacional estatístico e preenche a lacuna entre esses dois problemas fundamentalmente importantes.

Este artigo formula o problema de aprendizado de séries temporais relacionais e uma estrutura geral e taxonomia para tarefas de descoberta de representação de nós e links, incluindo a previsão de sua existência, rótulo e peso (importância), bem como a construção sistemática de recursos. Também reinterpretemos a tarefa de previsão levando à proposta de duas importantes tarefas de previsão de séries temporais relacionais que consistem em (i) classificação de séries temporais relacionais (prevê uma classe ou rótulo futuro de uma entidade) e (ii) regressão de séries temporais relacionais (prevê um atributo ou peso de valor real futuro). Os modelos de séries temporais relacionais são projetados para alavancar dependências relacionais e temporais para minimizar o erro de previsão para classificação e regressão de séries temporais relacionais. Por fim, discutimos desafios e problemas em aberto que ainda precisam ser abordados.

1. Introdução

1.1 Motivação

Nos últimos anos, os dados relacionais cresceram a uma taxa tremenda; está presente em domínios como Internet e World Wide Web (Albert et al., 1999; Faloutsos et al., 1999; Broder et al., 2000), citação científica e colaboração (Newman, 2001; McGovern et al., 2003), epidemiologia (Kleczkowski & Grenfell, 1999; Moore & Newman, 2000; May & Lloyd, 2001; Pastor-Satorras & Vespignani, 2001), análise da comunicação (Rossi & Neville, 2010), metabolismo (Jeong et al., 2000; Wagner & Fell, 2001), ecossistemas (Camacho et al., 2002; Dunne et al., 2002), bioinformática (Jeong et al., 2001; Maslov & Sneppen, 2002), fraude e análise terrorista (Krebs, 2002; Neville et al., 2005), e muitos outros. Os links nesses dados podem representar citações, amizades, associações, funções metabólicas, comunicações, colocações, mecanismos compartilhados ou muitos outros relacionamentos explícitos ou implícitos.

A maioria dessas redes relacionais do mundo real é naturalmente dinâmica – evoluindo ao longo do tempo com a adição, exclusão e alteração de nós, links e atributos. Apesar da importância fundamental dessas dinâmicas, a maioria dos trabalhos em aprendizagem relacional ignorou a dinâmica em dados relacionais (ou seja, dados de rede atribuídos). Em particular, os gráficos atribuídos dinâmicos têm três componentes principais que variam no tempo. Primeiro, os valores dos atributos (nos nós ou links) podem mudar ao longo do tempo (por exemplo, área de pesquisa de um autor). Em seguida, os links podem ser criados e excluídos ao longo do tempo (por exemplo, conexões de host são abertas e

fechado). Finalmente, os nós podem aparecer e desaparecer ao longo do tempo (por exemplo, através da atividade em uma rede social online). A Figura 1 fornece uma visão intuitiva dessas dinâmicas subjacentes.

Pesquisas anteriores em aprendizado de máquina (ML) pressupõem dados distribuídos de forma independente e idêntica (IID) (Anderson et al., 1986; Bishop et al., 2006); e ignorou dependências relacionais (e dependências temporais). Essa suposição de independência é frequentemente violada em dados relacionais, pois as dependências (relacionais) entre instâncias de dados são naturalmente codificadas. Mais especificamente, a autocorrelação relacional é uma correlação ou dependência estatística entre os valores do mesmo atributo entre instâncias vinculadas (Jensen et al., 2004) e é uma propriedade fundamental de muitos conjuntos de dados relacionais. Por exemplo, as pessoas são frequentemente vinculadas por associações comerciais, e as informações sobre uma pessoa podem ser altamente informativas para uma tarefa de previsão envolvendo um associado dessa pessoa. Recentemente, métodos de aprendizado relacional estatístico (SRL) (Getoor & Taskar, 2007) foram desenvolvidos para alavancar as dependências relacionais (ou seja, autocorrelação relacional (Rossi et al., 2012b), também conhecida como homofilia (McPherson et al., 2001); entre (Friedman et al., 1999; Macskassy & Provost, 2003; Neville et al., 2003; De Raedt & Kersting, 2008; McDowell et al., 2010). Em muitos casos, esses métodos de aprendizagem relacional melhoram o desempenho preditivo em relação aos tradicionais Técnicas de DII (Macskassy & Provost, 2003; Neville et al., 2003; McDowell et al., 2009).

Os métodos de aprendizado relacional demonstraram melhorar em relação ao ML tradicional ao modelar dependências relacionais, mas ignoraram informações temporais (ou seja, assumem explicitamente que os dados são independentes em relação ao tempo). Nesse mesmo espírito, nosso trabalho busca melhorar ainda mais o desempenho preditivo, incorporando informações temporais e projetando métodos para aprender, representar e modelar com precisão as dependências temporais e relacionais. A informação temporal é conhecida por ser significativamente importante para modelar, prever e compreender dados relacionais com precisão (Watts & Strogatz, 1998; Newman et al., 2006). De fato, o tempo desempenha um papel fundamental em muitas leis naturais e está no centro de nossa compreensão do universo, ou seja, a unificação do espaço e do tempo na física (Einstein, 1906) e como o tempo está relacionado ao espaço e vice-versa é fundamentalmente importante para nossa compreensão e interpretação do universo e suas leis (Einstein, 1906; Bock et al., 2008). Fazemos um argumento semelhante aqui, que ignorar o tempo em redes atribuídas só pode adicionar mais incerteza, pois o tempo coloca uma ordem natural nos componentes da rede, incluindo a mudança de valores de atributos, links e nós.

Este trabalho formula o problema de aprendizado de séries temporais relacionais e propõe um framework que consiste em dois componentes principais como mostrado na Figura 2. O primeiro componente aprende um




Figura 1 Dados de séries temporais relacionais




Figura 2 Visão geral do aprendizado de séries temporais relacionais

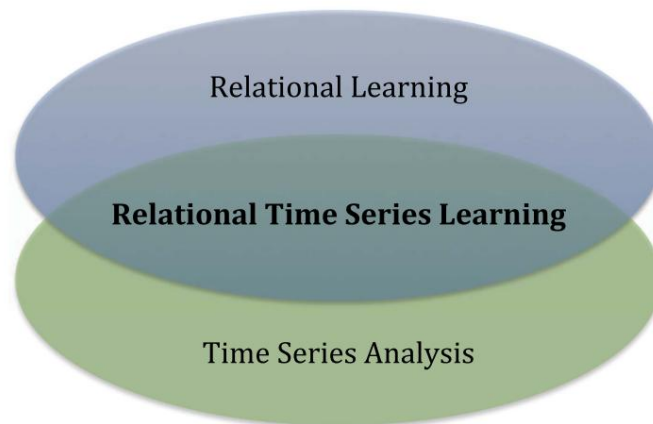


Figura 3 Para preencher a lacuna entre o aprendizado relacional e a análise de séries temporais. O foco deste trabalho está na interseção entre essas duas áreas que chamamos de Aprendizagem Relacional de Séries Temporais. O aprendizado relacional se concentrou principalmente em dados gráficos relacionais estáticos (gráficos + atributos), enquanto a literatura de análise de séries temporais evita dados gráficos e, em vez disso, concentra-se em séries temporais independentes (ou seja, modelando cada uma das séries temporais de forma disjunta) ou séries temporais que são consideradas completamente dependente (ou seja, clique).

representação de uma coleção de dados relacionais dinâmicos (isto é, uma série temporal de gráficos e atributos) dada como entrada que incorpora as dependências temporais fundamentais em dados de gráficos relacionais. Enquanto o segundo componente aproveita a representação baseada em recursos aprendida para previsão de séries temporais relacionais, que inclui modelos de classificação de séries temporais relacionais e regressão. Em outras palavras, este trabalho propõe técnicas para aprender uma representação adequada a partir de dados dinâmicos de grafos atribuídos com o objetivo de melhorar a precisão de uma determinada tarefa de aprendizagem relacional¹ (Getoor & Taskar, 2007) como classificação (Rossi et al., 2012b). Propomos uma taxonomia mostrada na Figura 4 para as tarefas fundamentais de representação para nós em redes dinâmicas atribuídas. Este trabalho se concentra nas três tarefas fundamentais de representação para redes de atribuição dinâmica, incluindo rotulagem dinâmica de nós, ponderação dinâmica de nós e predição dinâmica de nós.

Como um aparte, observemos que não nos concentramos nas tarefas de representação (simétrica) baseadas em links, pois elas receberam atenção considerável recentemente (em várias outras formas) (Hasan et al., 2006; Liben-Nowell & Kleinberg, 2007); Lassez et al., 2008; Acar et al., 2009; Koren et al., 2009; Xiang et al., 2010a; Al Hasan & Zaki, 2011; Menon & Elkan, 2011; Oyama et al., 2011; Schall, 2014) e, portanto, este trabalho se concentra nas novas tarefas de representação dinâmica para nós.

Em última análise, o objetivo deste trabalho é ajudar a preencher ainda mais a lacuna entre a aprendizagem relacional (Friedman et al., 1999; Macskassy & Provost, 2003; Neville et al., 2003; Getoor & Taskar, 2007; De Raedt & Kersting, 2008; McDowell et al., 2010; Rossi et al., 2012b) e análise tradicional de séries temporais (Pindyck & Rubinfeld, 1981; Clements & Hendry, 1998; Croushore & Stark, 2001; Brockwell & Davis, 2002; Marcellino et al., 2006; Ahmed et al., 2010; Box et al., 2013) (ver Figura 3). Essa lacuna entre esses problemas fundamentalmente importantes aparentemente surgiu devido ao fato de que a maioria das técnicas de aprendizado relacional da comunidade ML ignorou dados relacionais temporais ou dinâmicos (Chakrabarti et al., 1998; Friedman et al., 1999; Domingos & Richardson, 2001; Macskassy & Provost, 2003; Neville et al., 2003; Getoor & Taskar, 2007; De Raedt & Kersting, 2008; McDowell et al., 2010). (i) modelagem de séries temporais independentes ou (ii) séries temporais múltiplas que são consideradas completamente correlacionadas (Pindyck & Rubinfeld, 1981; Brockwell & Davis, 2002; Ahmed et al., 2010; Box et al., 2013). A interseção dessas duas áreas é o aprendizado relacional de séries temporais e difere significativamente do aprendizado relacional e da análise de séries temporais nos dados utilizados, modelos e suposições de dados e seus objetivos. Por exemplo, o objetivo de previsão do problema de aprendizado relacional é principalmente para tarefas de previsão dentro da rede ou através da rede e não prevê os futuros valores de atributo do nó. A aprendizagem relacional não utiliza ou modela informações temporais, enquanto a análise de séries temporais carece de informações relacionais. Há muitas outras diferenças discutidas posteriormente.

¹ Essa área de ML às vezes é chamada de SRL ou aprendizado de máquina relacional.

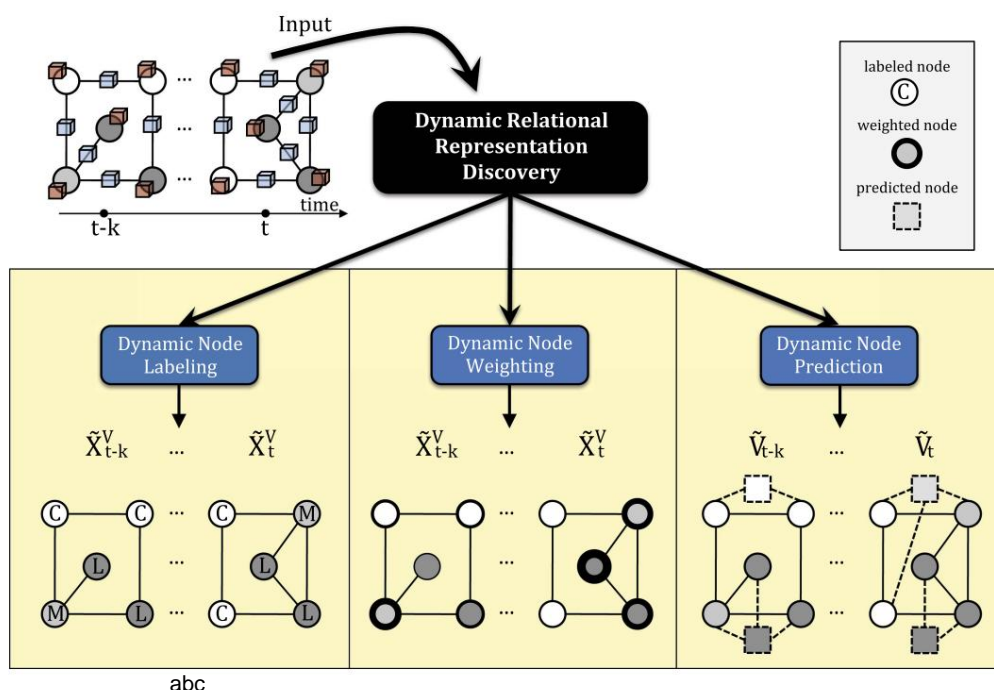


Figura 4 Taxonomia de tarefas de representação relacional dinâmica para nós. Para as tarefas de representação dinâmica de nós, introduzimos uma taxonomia de representação relacional dinâmica focada nas tarefas de representação de rotulagem dinâmica de nós, ponderação e previsão da existência de nós.

1.2 Escopo deste artigo

Este artigo enfoca o problema de previsão de séries temporais relacionais e técnicas para aprender representações relacionais dinâmicas de dados de grafos com timestamps. Não nos concentramos em análise e mineração de rede dinâmica. No entanto, sempre que possível, reinterpretamos técnicas que foram propostas para diferentes problemas e discutimos como elas poderiam ser usadas para aprendizado de representação de séries temporais relacionais para melhorar a previsão de séries temporais relacionais. Além disso, os métodos de previsão de séries temporais relacionais também podem ser úteis para outras aplicações (ou seja, além de prever atributos de nós), incluindo análise de rede dinâmica (Tang et al., 2010; Holme & Saramäki, 2012), detecção de anomalias (Bunke & Kraetzl, 2004; Chandola et al., 2009) em gráficos dinâmicos (Noble & Cook, 2003; Ide & Kashima, 2004; Tong & Lin, 2011; Rossi et al., 2013a), ranking dinâmico (O'Madadhain & Smyth, 2005; Das Sarma et al., 2008; Rossi & Gleich, 2012), entre muitas outras tarefas e aplicações de ML (Rossi et al., 2013b, 2013c; Rossi, 2014). No entanto, isso está fora do escopo deste artigo.

1.3 Visão geral

Este artigo está organizado da seguinte forma: a Seção 2 apresenta e define o problema de previsão de séries temporais relacionais, que consiste na classificação de séries temporais relacionais (Seção 2.1) e regressão (Seção 2.2). A seguir, a Seção 3 apresenta o aprendizado de representação de séries temporais relacionais para previsão de séries temporais relacionais. A Seção 4 examina e reinterpreta o trabalho existente para uso no problema de aprendizado e previsão de representação de séries temporais relacionais. A Seção 5 apresenta alguns importantes problemas abertos e desafiadores. Por fim, a Seção 6 conclui.

2 Previsão de séries temporais relacionais

Usando a representação aprendida, demonstramos a eficácia dessas técnicas para classificação de séries temporais relacionais e regressão de atributos de nós dinâmicos. Definimos classificação de séries temporais relacionais (Seção 2.1) e regressão (Seção 2.2) mais precisamente abaixo.

2.1 Classificação de séries temporais relacionais

PROBLEMA 1 (CLASSIFICAÇÃO DE SÉRIE TEMPORAL RELACIONAL). Dada uma série temporal 'conhecida' de dados gráficos atribuídos a um grafo onde o grafo é aprendido a partir de rótulos de classe $Y_t + h$ dos nós no

Como um aparte, se $h = 1$, então chamamos essa previsão de um passo à frente, enquanto a previsão de vários passos à frente se refere ao caso em que $h > 1$ e, portanto, a previsão é em vários intervalos de tempo. Nossos métodos de classificação de séries temporais relacionais também são flexíveis para problemas binários (ie $|L| = 2$) e multi-classe (ie $|L| > 2$), enquanto a classificação binária tem sido o foco principal dos métodos de aprendizado relacional anteriores para problemas estáticos. gráficos. Da mesma forma, também investigamos o problema de regressão de séries temporais relacionais.

2.2 Regressão de série temporal relacional

PROBLEMA 2 (REGRESSÃO DE SÉRIE TEMPORAL RELACIONAL). Dada uma série temporal de gráficos atribuídos a G_t , a tarefa é estimar a variável de valor real $Y_t + h$ no tempo $t+h$ para os nós no gráfico.

A tarefa de previsão investigada neste artigo também é fundamentalmente diferente dos problemas/suposições tradicionais de aprendizagem relacional. Mais especificamente, definimos dentro da rede (por exemplo, inferência) como a tarefa em que as instâncias de treinamento de um único grafo (estático) são conectadas diretamente a instâncias cujos rótulos de classificação devem ser previstos (McDowell et al., 2009; Xiang et al., 2010b). Por outro lado, a tarefa de inferência através da rede tenta aprender um modelo em uma rede (estática) e aplicar os modelos aprendidos em uma rede separada (Craven et al., 1998; Lu & Getoor, 2003). Por exemplo, podemos aprender um modelo de um gráfico estático e/ou agregado do Facebook e usar esse modelo aprendido para previsão em outra rede social, como Google+ ou Twitter. Embora ambos os problemas de previsão para aprendizagem relacional assumam uma rede estática, eles também diferem fundamentalmente em suas suposições e objetivos subjacentes. Por outro lado, focamos no uso de séries temporais passadas de grafos atribuídos onde os nós de treinamento podem ser conectados diretamente a nós cujos rótulos de classificação devem ser previstos e, da mesma forma, as observações de séries temporais passadas do atributo de previsão também podem ser usadas diretamente. A ideia fundamental é que tanto as dependências e informações temporais e relacionais passadas podem ser usadas para prever os valores de séries temporais futuras de um determinado atributo. Também observamos que podemos aprender um modelo usando alguns dados passados e usá-lo para prever o valor futuro em $t + h$ de uma série temporal de atributos, ou podemos usar uma técnica que faz 'aprendizagem preguiçosa' no sentido de que os dados passados são determinados no tempo de previsão e usados para prever $t + h$.

3 Aprendizagem de representação a partir de dados de séries temporais relacionais

Recentemente, as representações de dados relacionais tornaram-se um tópico cada vez mais importante devido à recente proliferação de dados de rede (por exemplo, redes sociais, biológicas, de informação) e um aumento correspondente na aplicação de algoritmos SRL a esses domínios. Em particular, as transformações apropriadas dos nós, links e/ou recursos dos dados podem afetar drasticamente os recursos e os resultados dos algoritmos SRL. Ver Rossi et al. (2012b) para uma pesquisa abrangente sobre descoberta de representação relacional (para dados de gráficos estáticos).

Esta seção discute primeiro os dados de séries temporais relacionais na Seção 3.1. As importantes dependências relacionais e temporais são discutidas e definidas na Seção 3.2, enquanto a Seção 3.3 define formalmente as principais tarefas de descoberta de representação para a previsão de séries temporais relacionais.

3.1 Dados de séries temporais relacionais

Os dados relacionais no mundo real são naturalmente dinâmicos, evoluindo ao longo do tempo com a adição, exclusão e alteração de nós, links e atributos. Exemplos de dados relacionais dinâmicos incluem gráficos sociais, biológicos, tecnológicos, Web, redes de informação, entre muitos outros tipos de redes. Em particular, os gráficos atribuídos dinâmicos têm três componentes principais que variam no tempo. Primeiro, os valores dos atributos (nos nós ou links) podem mudar ao longo do tempo (por exemplo, área de pesquisa de um autor). Em seguida, os links podem ser criados e excluídos ao longo do tempo (por exemplo, conexões de host são abertas e fechadas). Finalmente, os nós podem aparecer e

desaparecem com o tempo (por exemplo, através da atividade em uma rede social online). Uma ilustração intuitiva da dinâmica subjacente que governa os dados relacionais é mostrada na Figura 1.

DEFINIÇÃO 1 (SÉRIE TEMPORAL RELACIONAL). Seja $G = (V, E)$ denota uma série temporal relacional², e T denota o intervalo de tempo de interesse. Também definimos $G(t) = (V(t), E(t))$ como uma rede atribuída no tempo $t \in T$, e $V(t)$ é o conjunto de nós, $E(t)$ é o conjunto de arestas (possivelmente direcionadas), cada $x_i(t) \in V(t)$ é um vetor de atributo para o nó $v_i \in V(t)$, enquanto cada $x_{ij}(t) \in E(t)$ é um vetor de atributo para aresta $(i, j) \in E(t)$ no tempo $t \in T$. Além disso, $Y(t)$ é o atributo do nó de interesse para previsão onde $y_i(t)$ é o valor do atributo de previsão no tempo t para o nó $v_i \in V(t)$ e $y_i(p:t) = \{y_i(p), \dots, y_i(t)\}$ é o vetor de atributos da série temporal defasada para o nó $v_i \in V(t)$.

3.2 Dependências relacionais e temporais

Neste trabalho, utilizamos autocorrelação relacional e duas dependências temporais em redes atribuídas dinâmicas. Mais precisamente, observamos duas dependências temporais fundamentais de dados de redes relacionais dinâmicas, incluindo a noção de localidade temporal e recorrência temporal. Definimos essas dependências temporais informalmente abaixo, pois elas se aplicam geralmente a todo o espectro de informações relacionais temporais, incluindo atributos não relacionais, atributos de nós relacionais, atributos de arestas relacionais, bem como arestas e nós em um grafo.

IMÓVEL 1 (LOCALIDADE TEMPORAL). Os eventos recentes são mais influentes para o estado atual do que os distantes.

Essa dependência temporal implica que um valor de atributo de nó recente, valor de atributo de borda ou link é mais forte ou mais preditivo do futuro do que um mais distante. Em termos de valores de atributo em nós (ou arestas), isso implica que um valor de atributo observado recentemente (por exemplo, número de posts) em t é mais preditivo do que observações anteriores em $t-1$ e mais distante. Assim, se $x_i(t) = \tilde{y}$ é observado no tempo t , então no tempo $t+1$ é provável que $x_i(t+1) = \tilde{y}$. No caso de arestas, isso implica que uma aresta observada recentemente $(v_i, v_j) \in E(t)$ entre v_i e v_j no tempo t implica que há uma alta probabilidade de uma aresta futura $(v_i, v_j) \in E(t+1)$ em $t+1$ surgirá.

IMÓVEL 2 (RECORRÊNCIA TEMPORAL). Uma série regular de observações é mais provável que indique uma relacionamento mais forte do que um evento isolado.

A noção de recorrência temporal implica que uma sequência repetida de observações é mais influente ou tem maior probabilidade de reaparecer no futuro do que um evento isolado. Em outras palavras, uma sequência repetida ou regular de valores de atributo de nó (ou valores de atributo de borda) é mais provável de reaparecer no futuro do que um valor de atributo de nó isolado. Como exemplo, dada uma rede de comunicação e um atributo de nó representando o tópico de comunicação para cada nó da rede, se o nó v_i tiver uma sequência regular de tópicos, ou seja, $x_i(k) = \tilde{y}$, para $k = p, \dots, t$ em um conjunto recente de passos de tempo, então há uma probabilidade elevada de que $x_i(t+1) = \tilde{y}$. A recorrência temporal implica que uma série repetida ou recorrente de arestas $(v_i, v_j) \in E(k)$, para $k = p, \dots, t$ entre v_i e v_j implica uma maior probabilidade de uma aresta futura $(v_i, v_j) \in E(t+1)$ em $t+1$. Além disso, a recorrência temporal é mais provável em séries regulares ou recorrentes de observações semelhantes, enquanto a localidade temporal é mais provável em observações mais isoladas.

Aprender representações de séries temporais relacionais precisas para nós em redes atribuídas dinâmicas continua sendo um desafio. Assim como os métodos SRL foram projetados para explorar as dependências relacionais em dados de grafos, em vez disso, aproveitamos as dependências relacionais e as dependências temporais das arestas, vértices e atributos para aprender representações relacionais dinâmicas mais precisas.

3.3 Tarefas de representação

Neste artigo, formulamos o problema de descoberta de representação relacional dinâmica e propomos uma taxonomia para as tarefas de representação dinâmica mostradas na Figura 4. Mais especificamente, a dinâmica

² Uma série temporal de dados de gráfico atribuídos relacionais.

tarefas de representação para nós incluem (i) prever seu rótulo ou tipo, (ii) estimar seu peso ou importância e (iii) prever sua existência. Propomos métodos para cada uma das tarefas de representação de nós relacionais dinâmicas na Figura 4 que são definidas abaixo.

3.3.1 Rotulagem dinâmica de nós

Dada uma série temporal de dados de grafos atribuídos, definimos o problema de rotulagem dinâmica de nós como a tarefa de aprender uma série temporal de rótulos de nós X_p, \dots, X_t onde para cada passo de tempo um dado nó pode ser atribuído a um único nó rótulo (ou seja, rótulo de classe) ou vários rótulos (ou seja, vários tópicos ou funções). A série temporal de rótulos pode representar um rótulo de classe conhecido previamente observado ou uma variável latente como papéis, tópicos, entre muitos outros.

3.3.2 Ponderação dinâmica de nós

Dada uma série temporal de dados de grafos atribuídos, definimos a tarefa de representação de ponderação dinâmica de nós como o aprendizado de uma série temporal de pesos para os nós X_p, \dots, X_t que utilizam dependências relacionais e temporais na dinâmica relacional dados. A série temporal de pesos pode representar a importância ou influência de um nó na rede dinâmica atribuída ou pode simplesmente representar uma variável latente capturando as dependências fundamentais nos dados relacionais dinâmicos.

3.3.3 Previsão de nós dinâmicos

Dada uma série temporal de dados de grafos atribuídos, definimos a tarefa de representação de predição de nós dinâmicos como a previsão da existência de um nó em um passo de tempo futuro $t + 1$ onde o aprendizado aproveita dados relacionais temporais passados e mais especificamente incorpora dependências relacionais e temporais nos dados relacionais dinâmicos. O nó previsto pode representar um novo tipo de nó, ainda não descoberto, como uma função ou tópico de comunicação, ou pode ser um novo nó de um tipo de nó já existente, como um usuário ou grupo do Facebook. A maioria das técnicas também prevê a existência de arestas entre o nó previsto e o conjunto de nós no grafo.

4 Técnicas relacionadas à reinterpretação

Esta seção unifica por meio da reinterpretação de uma variedade de métodos relacionais e/ou temporais chave para uso no problema de aprendizado de séries temporais relacionais. Essas abordagens diferem drasticamente no tipo de dados temporais (e/ou relacionais) usados, suas características e suposições-chave tanto nos dados quanto no modelo, bem como na tarefa ou objetivo fundamental e subjacente otimizado por uma técnica específica.

4.1 Tarefas de representação de link temporal

Embora nossa taxonomia de descoberta de representação relacional dinâmica mostrada na Figura 4 se concentre na rotulagem, ponderação e previsão de nós, há também as tarefas de representação gráfica dinâmica simétrica para links que incluem rotulagem de link, ponderação de link e previsão de link. Nosso trabalho não está preocupado com as tarefas de representação dinâmica baseadas em links, pois elas foram investigadas em vários contextos (Hasan et al., 2006; Liben-Nowell & Kleinberg, 2007; Lassez et al., 2008; Acar et al., 2009). ; Koren et al., 2009; Xiang et al., 2010a; Al Hasan & Zaki, 2011; Menon & Elkan, 2011; Oyama et al., 2011; Schall, 2014; Nguyen et al., 2018). Por exemplo, a previsão e ponderação de links tem sido usada para melhorar os mecanismos de busca (Lassez et al., 2008), sistemas de recomendação (Koren, 2010) para ambos os produtos (Koren et al., 2009; Xiang et al., 2010a) e amigos (ou seja, recomendação social) (Ma et al., 2008), entre muitos outros (Chen et al., 2013; Liu et al., 2013; Li et al., 2014). Também notamos que outros trabalhos se concentraram na previsão de links em redes temporais usando fatorações tensoriais (Dunlavy et al., 2011) e na previsão de estrutura nessas redes usando subgrafos frequentes (Lahiri & Berger-Wolf, 2007).

4.2 Centralidade e análise temporal

Recentemente, tem havido muito trabalho na análise de gráficos dinâmicos ou temporais que se concentram apenas em arestas que mudam ao longo do tempo e ignoram e/ou descartam quaisquer atributos (dinâmicos ou estáticos)

(Bhadra & Ferreira, 2003; Xuan et al., 2003; Leskovec et al., 2007a, 2007b; Lahiri & Berger-Wolf, 2008; Tang et al., 2009; Tang et al., 2010; Kovanen et al., 2011; Redmond et al., 2012; Rossi et al., 2012a).

As medidas de centralidade também foram estendidas para redes temporais (Tang et al., 2010; Holme & Saramäki, 2012).

Enquanto a grande maioria deste trabalho se concentrou apenas em arestas dinâmicas (ou seja, gráficos dinâmicos/temporais/streaming), focamos em dados relacionais dinâmicos e incorporamos todo o espectro de dinâmicas, incluindo arestas, vértices e atributos (e suas contrapartes estáticas como Nós vamos).

4.3 Análise de séries temporais

A última seção discutiu a análise de gráficos temporais que careciam de dados de atributos, enquanto dados de séries temporais baseados em atributos não relacionais (Clements & Hendry, 1998; Croushore & Stark, 2001; Marcellino et al., 2006) são o foco desta seção. Em particular, os métodos tradicionais de séries temporais ignoram todos os dados do gráfico (Pindyck & Rubinfeld, 1981; Brockwell & Davis, 2002; Ahmed et al., 2010; Box et al., 2013), e se concentram apenas na modelagem de uma sequência dependente do tempo de dados de valor real, como temperaturas horárias ou dados econômicos, como preço de ações ou produto interno bruto (Clements & Hendry, 1998; Croushore & Stark, 2001; Marcellino et al., 2006). Em contraste, nossos métodos propostos naturalmente permitem a modelagem de séries temporais de atributos e gráficos (ou seja, dados de séries temporais relacionais) onde cada nó e borda podem ter uma série temporal multidimensional com conectividade ou dependência arbitrária entre eles, conforme mostrado na Figura 5.

Na intersecção da análise de séries temporais e ML, Ahmed et al. (2010) recentemente usaram métodos de ML como Redes Neurais (Hornik et al., 1989) e máquinas de vetor de suporte (Hearst et al., 1998) para previsão de séries temporais. Em particular, os autores descobriram que muitos desses métodos de ML ofereceram melhorias significativas em relação aos modelos tradicionais de séries temporais (Ahmed et al., 2010), como modelos auto-regressivos e outros (Brockwell & Davis, 2002). A principal contribuição do trabalho de Ahmed et al. (2010) houve uso de métodos tradicionais de ML para previsão de séries temporais, que recentemente atraiu numerosos estudos de acompanhamento (Agami et al., 2009; Ben Taieb et al., 2012; Esling & Agon, 2012). A partir dessa perspectiva, nosso trabalho faz uma contribuição semelhante à medida que formulamos o problema do aprendizado relacional de séries temporais para dados de gráficos relacionais dinâmicos e propomos técnicas para classificação e regressão de séries temporais relacionais, que se mostram melhores em relação ao aprendizado relacional tradicional e séries temporais métodos.

4.4 Aprendizagem relacional

A maioria das pesquisas em aprendizagem relacional se concentrou na modelagem de instantâneos estáticos ou dados agregados (Chakrabarti et al., 1998; Domingos & Richardson, 2001) e ignorou amplamente a utilidade de aprender e incorporar dinâmicas temporais em representações relacionais. Trabalhos anteriores em aprendizado relacional em gráficos atribuídos usam instantâneos de rede estática ou limitam significativamente a quantidade de informações temporais incorporadas aos modelos. Sharan e Neville (2008) assumem uma representação estrita que usa apenas estimativa de kernel para pesos de link, enquanto algoritmo genético aprimorado relacional variável no tempo




Figura 5 Modelo de dados para aprendizado relacional de séries temporais. Cada nó na rede pode ter um número arbitrário de atributos de série temporal, como pressão arterial, número de visualizações de página por hora, etc. Além disso, também assumimos que cada borda na rede também pode ter um número arbitrário de atributos de série temporal (não mostrado por simplicidade). Para cada aresta, também modelamos as dependências temporais, resultando na série temporal na aresta na ilustração acima. Como um aparte, se houver vários tipos de arestas entre nós, como arestas de amigos e arestas de e-mail representando amizade entre dois indivíduos e comunicações por e-mail, respectivamente, modelaríamos as dependências temporais para cada um dos tipos de arestas, resultando em aprendizado múltiplo séries temporais de forças de borda temporal de borda.

classificador (Güney et al., 2011) usa um algoritmo genético para aprender os pesos dos links. Árvores de probabilidades espaciais-relacionais (McGovern et al., 2008) incorporam informações temporais e espaciais nos atributos relacionais. No entanto, as abordagens acima focam apenas em um padrão temporal específico e não consideram diferentes granularidades temporais (ou seja, eles usam todos os instantâneos disponíveis e não têm a noção de uma série temporal defasada). Em contraste, exploramos um espaço maior de representações relacionais temporais em uma estrutura flexível que pode capturar dependências temporais sobre links, atributos e nós. Até onde sabemos, somos os primeiros a aproveitar todo o espectro de dados relacionais dinâmicos para melhorar as previsões.

Também somos os primeiros a propor e investigar métodos de conjunto temporal-relacional para classificação relacional variante no tempo. No entanto, tem havido trabalhos recentes sobre métodos de conjuntos relacionais (Preisach & Schmidt-Thieme, 2006, 2008; Eldardiry & Neville, 2011) e métodos de conjuntos não relacionais para fluxos em evolução (Bifet et al., 2009). Embora nenhum dos trabalhos anteriores proponha métodos de conjunto temporal-relacional para classificação, houve trabalhos recentes sobre métodos de conjunto relacional (Preisach & Schmidt-Thieme, 2006, 2008; Eldardiry & Neville, 2011). Em particular, Preisach e Schmidt-Thieme (2006) usam métodos de votação e empilhamento para combinar dados relacionais com múltiplas relações, enquanto Eldardiry e Neville (2011) incorporam a média de previsão no processo de inferência coletiva para reduzir a variância de aprendizado e inferência.

4.5 Aprendizado profundo

Nosso trabalho também está relacionado ao tópico ML de aprendizado profundo (LeCun et al., 1998; Hinton et al., 2006; Marc'Aurelio Ranzato et al., 2007; Bengio, 2009; Lee et al., 2009; Boureau et al. al., 2010; Deng & Li, 2013), que recentemente recebeu uma atenção considerável da indústria devido ao seu sucesso em uma variedade de aplicações e sistemas do mundo real (Salakhutdinov & Hinton, 2009; Lezama et al., 2011 ; Coupri et al., 2013). No entanto, quase todo esse trabalho se concentrou em imagens e outros tipos de dados semelhantes, enquanto nos concentramos em redes atribuídas dinâmicas. Em vista do nosso trabalho, deep learning para dados relacionais dinâmicos é informalmente qualquer método que construa uma representação com níveis variados de abstração ou granularidade com dependências entre as várias camadas. Por exemplo, o método Dynamic Role Mixed Membership Model (Rossi, 2015) para previsão de nós primeiro aprende um grande conjunto de recursos, depois descobrimos papéis desses recursos usando fatoração de matriz (ou seja, capturando a essência desse conjunto de recursos) e, finalmente, modelamos as transições de papéis ao longo do tempo. Essas representações formam uma hierarquia de camadas, cada uma capturando um nível diferente de granularidade nas redes atribuídas dinâmicas.

5 Desafios e problemas em aberto

Uma discussão de futuros desafios e direções são discutidas abaixo.

5.1 Caracterização do espaço e do tempo

Trabalhos futuros também devem investigar o tradeoff entre espaço e tempo. Caracterizar essas compensações é um desafio, por exemplo, métodos de aprendizado relacional de séries temporais podem aprender um modelo usando menos dados considerando apenas as observações mais recentes, enquanto abordagens de aprendizado relacional, que ignoram informações temporais, usam todos os dados disponíveis. Além disso, a modelagem de dependências temporais também pode levar a modelos mais simples/precisos e algoritmos de aprendizado e inferência mais eficientes. No entanto, os modelos de séries temporais relacionais geralmente exigem uma granularidade temporal e uma função de kernel apropriadas, e aprender ambos automaticamente pode ser caro.

5.2 Análise teórica

Ainda não existe uma análise teórica significativa dos modelos de previsão de séries temporais relacionais existentes, apesar da importância fundamental de entender as limitações teóricas desses modelos.

Além disso, trabalhos futuros devem propor modelos teóricos simples que auxiliem na caracterização teórica do trabalho existente.

5.3 Gráficos de séries temporais relacionais sintéticos

Ainda não existem modelos de gráficos sintéticos para gerar dados de gráficos de séries temporais relacionais. No entanto, esses modelos ajudariam a avaliar as abordagens existentes e caracterizar suas limitações.

5.4 Pacotes técnicos

Embora tenha havido algum trabalho em técnicas de conjunto para previsão de séries temporais relacionais (Rossi & Neville, 2012), ainda não houve nenhuma investigação sistemática sobre o desempenho dessas em uma variedade de redes dinâmicas. Mais trabalho é necessário para identificar quais tipos de redes dinâmicas apresentam melhor desempenho, entre outras características.

5.5 Aprendizado automático de funções do kernel

Trabalhos futuros devem investigar o problema relacionado de aprender a função do kernel automaticamente. Embora este trabalho tenha investigado uma variedade de funções do kernel e encontrado o exponencial para funcionar melhor na maioria das situações, esperamos que para certos dados de séries temporais relacionais, tal abordagem provavelmente resultará em um modelo preditivo significativamente melhor. Além disso, também facilita a aplicação do aprendizado relacional de séries temporais (para muitas tarefas do mundo real), sem exigir muito esforço por parte do usuário, em termos de conhecimento e suposições sobre os dados. No entanto, as técnicas propostas no futuro devem enfrentar os desafios associados ao custo computacional de tal abordagem e investigar cuidadosamente os benefícios (tanto teórica quanto empiricamente).

5.6 Robustez ao ruído

Outro problema importante é investigar a capacidade dos métodos de aprendizado de séries temporais relacionais de lidar com níveis variados de ruído tanto na informação relacional quanto na temporal? Além disso, a modelagem das dependências temporais reduz o impacto do ruído, especificamente, quando os dados relacionais são ruidosos (por exemplo, links ausentes ou errôneos)?

5.7 Seleção do modelo

A seleção do modelo de série temporal relacional apropriado é de fundamental importância. No entanto, existem apenas algumas técnicas e investigações sobre aprendizado de modelos e otimização de hiperparâmetros mais geralmente para modelos de séries temporais relacionais (Rossi, 2015). Assim, mais trabalho é necessário para entender as vantagens e desvantagens de cada abordagem, e novas técnicas desenvolvidas para superar problemas e/ou deficiências do trabalho existente.

6. Conclusão

Este artigo apresenta e examina trabalhos relacionados ao problema de previsão de séries temporais relacionais. Em particular, isso inclui as tarefas fundamentais de previsão de séries temporais relacionais: (i) prever rótulos de classes discretas (classificação) e (ii) prever um futuro peso contínuo com valor real (regressão). Para isso, introduzimos uma taxonomia unificadora que serve de base para estudar as principais tarefas de representação que surgem em dados de gráficos atribuídos dinâmicos (para melhorar a previsão de séries temporais relacionais). Isso inclui as tarefas de representação de rotulagem dinâmica de nó e link, ponderação, previsão de sua existência e descoberta de recursos importantes.

O trabalho existente é então pesquisado e reinterpretado para o problema de previsão de séries temporais relacionais.

Em particular, discutimos como essas técnicas, que foram originalmente propostas para outras tarefas de ML, podem ser reinterpretadas e usadas para melhorar a previsão de séries temporais relacionais. Este artigo serve como base para investigar o importante e desafiador problema da previsão de séries temporais relacionais.

Reconhecimentos

Os autores agradecem a todos os revisores por muitas sugestões e comentários úteis.

Referências

- Acar, E., Dunlavy, D. & Kolda, T. 2009. Predição de link em dados em evolução usando fatoração de matriz e tensor. In *Proceedings of the 9th IEEE International Conference on Data Mining Workshops*, 262–269.
- Agami, N., Atiya, A., Saleh, M. & El-Shishiny, H. 2009. Um modelo de previsão dinâmica baseado em rede neural para tendência análise de impacto. *Previsão Tecnológica e Mudança Social* 76(7), 952–962.
- Ahmed, N., Atiya, A., El Gayar, N. & El-Shishiny, H. 2010. Uma comparação empírica de modelos de aprendizado de máquina para previsão de séries temporais. *Revisões Econométricas* 29(5–6), 594–621.
- Albert, R., Jeong, H. & Barabási, A. 1999. Internet: diâmetro da rede mundial. *Natureza* 401 (6749), 130–131.
- Al Hasan, M. & Zaki, MJ 2011. Uma pesquisa de previsão de links em redes sociais. Na *Análise de Dados de Redes Sociais*, 243–275. Springer.
- Anderson, JR, Michalski, RS, Michalski, RS, Carbonell, JG & Mitchell, TM 1986. *Aprendizado de Máquina: Uma Abordagem de Inteligência Artificial*, 2. Morgan Kaufmann.
- Bengio, Y. 2009. Aprendendo arquiteturas profundas para IA. *Fundamentos e tendências em aprendizado de máquina* 2(1), 1–127.
- Ben Taieb, S., Bontempi, G., Atiya, AF & Sorjamaa, A. 2012. Uma revisão e comparação de estratégias para previsão de séries temporais multi-passo à frente com base na competição de previsão NN5. *Sistemas Especialistas com Aplicativos* 39(8), 7067–7083.
- Bhadra, S. & Ferreira, A. 2003. Complexidade de componentes conectados em grafos evolutivos e o cálculo de árvores multicast em redes dinâmicas. Em *Ad-Hoc, redes móveis e sem fio*, 259–270.
- Bifet, A., Holmes, G., Pfahringer, B., Kirkby, R. & Gavalda, R. 2009. Novos métodos de conjunto para evolução de fluxos de dados. In *Proceeding of the 15th ACM SIGKDD International Conference on Knowledge Discovery in Data Mining*, 139–148.
- Bishop, CM 2006. *Reconhecimento de Padrões e Aprendizado de Máquina*. Springer.
- Bock, J., Cooray, A., Hanany, S., Keating, B., Lee, A., Matsumura, T., Milligan, M., Ponthieu, N., Renbarger, T. & Tran, H. 2008 A sonda experimental de cosmologia inflacionária (EPIC): um estudo de conceito de missão para a sonda de inflação Einstein da NASA. *arXiv:0805.4207*.
- Boureau, Y.-L., Bach, F., LeCun, Y. & Ponce, J. 2010. Aprendendo recursos de nível médio para reconhecimento. Em *IEEE Conferência sobre Visão Computacional e Reconhecimento de Padrões*, 2559–2566.
- Box, GE, Jenkins, GM & Reinsel, GC 2013. *Análise de Séries Temporais: Previsão e Controle*. John Wiley & Filhos.
- Brockwell, PJ & Davis, RA 2002. *Introdução a Séries Temporais e Previsão*, 1. Taylor & Francis.
- Broder, A., Kumar, R., Maghoul, F., Raghavan, P., Rajagopalan, S., Stata, R., Tomkins, A. & Wiener, J. 2000. Gráfico estrutura na web. *Redes de Computadores* 33(1–6), 309–320.
- Bunke, H. & Kraetzl, M. 2004. Classificação e detecção de eventos anormais em séries temporais de gráficos. Em Mark Last, Abraham Kandel, Horst Bunke, *Data Mining in Time Series Databases*, Last, M., Kandel, A. & Bunke H (eds). World Scientific, 127–148.
- Camacho, J., Guimerà, R. & Nunes Amaral, L. 2002. Padrões robustos na estrutura da teia alimentar. *Cartas de Revisão Física* 88(22), 228102: 1–4.
- Chakrabarti, S., Dom, B. & Indyk, P. 1998. Categorização de hipertexto aprimorada usando hiperlinks. Em *Atos do ACM SIGMOD Conferência Internacional sobre Gestão de Dados*, 307–318.
- Chandola, V., Banerjee, A. & Kumar, V. 2009. Detecção de anomalias: uma pesquisa. *Pesquisas Computacionais ACM* 41(3), 15.
- Chen, C., Yin, H., Yao, J. & Cui, B. 2013. TeRec: um sistema de recomendação temporal sobre fluxo de tweets. *Processos de a VLDB Endowment* 6(12), 1254–1257.
- Clements, M. & Hendry, D. 1998. *Forecasting Economic Time Series*. Cambridge University Press.
- Coupré, C., Farabet, C. & LeCun, Y. 2013. Segmentação de vídeo baseada em grafos causais. *arXiv:1301.1671*.
- Coupré, C., Farabet, C., LeCun, Y., & Najman, L. 2013, setembro. Segmentação de vídeo baseada em gráfico causal. Dentro *Processamento de Imagem (ICIP)*, 2013 20th IEEE International Conference on (pp. 4249–4253). IEEE.
- Craven, M., DiPasquo, D., Freitag, D., McCallum, A., Mitchell, T., Nigam, K. & Slattery, S. 1998. Aprendendo a extrair conhecimento simbólico da World Wide Web. In *Proceedings of the 15th AAAI Conference on Artificial Intelligence*, 509–516.
- Croushore, D. & Stark, T. 2001. Um conjunto de dados em tempo real para macroeconomistas. *Journal of Econometrics* 105(1), 111–130.
- Das Sarma, A., Gollapudi, S. & Panigrahy, R. 2008. Estimando PageRank em fluxos de grafos. In *Proceedings of the ACM SIGMOD International Conference on Management of Data*, 69–78.
- Deng, L. & Li, X. 2013. Paradigmas de aprendizado de máquina para reconhecimento de fala: uma visão geral. *Transações em Processamento de Áudio, Fala e Linguagem* 21(5), 1060–1089.
- De Raedt, L. & Kersting, K. 2008. *Programação Lógica Indutiva Probabilística*. Springer-Verlag.
- Domingos, P. & Richardson, M. 2001. Mineração do valor da rede dos clientes. In *Proceeding of the 7th ACM SIGKDD International Conference on Knowledge Discovery in Data Mining*, 57–66.
- Dunlavy, DM, Kolda, TG & Acar, E. 2011. Predição de ligação temporal usando fatoração de matriz e tensor. *Transações na descoberta de conhecimento de dados* 5(2), 10:1–10:27.

- Dunne, J., Williams, R. & Martinez, N. 2002. Estrutura da teia alimentar e teoria da rede: o papel da conectividade e tamanho. *Proceedings of the National Academy of Sciences of the United States of America* 99(20), 12917.
- Einstein, A. 1906. Sobre a teoria do movimento browniano. *Annals of Physics* 324(2), 371-381.
- Eldardiry, H. & Neville, J. 2011. Classificação de conjuntos coletivos entre modelos. *Anais da 25ª AAAI Conferência sobre Inteligência Artificial*, 343-349.
- Esling, P. & Agon, C. 2012. Mineração de dados de séries temporais. *Pesquisas de Computação ACM* 45(1), 12.
- Faloutsos, M., Faloutsos, P. & Faloutsos, C. 1999. Sobre relações de poder-lei da topologia da internet. In *Proceedings of the ACM SIGCOMM International Conference on Applications, Technologies, Architectures and Protocols for Computer Communication*, 251–262.
- Friedman, N., Getoor, L., Koller, D. & Pfeffer, A. 1999. Aprendendo modelos relacionais probabilísticos. Em *Processos de a 16ª Conferência Conjunta Internacional sobre Inteligência Artificial*, 1300-1309. Springer-Verlag.
- Getoor, L. & Taskar, B. (eds) 2007. *Introdução à Aprendizagem Estatística Relacional*. Imprensa do MIT.
- Güneş, İ., Çataltepe, Z. & Öyüdücü, İ. G. 2011. GA-TVRC: um novo classificador relacional variável no tempo para extrair informações temporais usando algoritmos genéticos. Em *Aprendizado de Máquina e Mineração de Dados em Reconhecimento de Padrões*, 568–583. Springer.
- Hasan, MA, Chaoji, V., Salem, S. & Zaki, M. 2006. Previsão de links usando aprendizado supervisionado. Em *Atos do Workshop SDM sobre Análise de Links, Contraterrorismo e Segurança*.
- Hearst, MA, Dumais, S., Osman, E., Platt, J. & Scholkopf, B. 1998. Support vector machines. *Sistemas Inteligentes e seus pedidos* 13(4), 18–28.
- Hinton, GE, Osindero, S. & Teh, Y.-W. 2006. Um algoritmo de aprendizado rápido para redes de crenças profundas. *Computação Neural* 18(7), 1527-1554.
- Holme, P. & Saramäki, J. 2012. Redes temporais. *Relatórios de Física*.
- Hornik, K., Stinchcombe, M. & White, H. 1989. Redes feedforward multicamadas são aproximadores universais. *Redes Neurais* 2(5), 359–366.
- Ide, T. & Kashima, H. 2004. Detecção de anomalias baseadas em Eigenspace em sistemas de computador. Em *Atas do 10º ACM SIGKDD Conferência Internacional sobre Descoberta de Conhecimento e Mineração de Dados*, 440–449.
- Jensen, D., Neville, J. & Gallagher, B. 2004. Por que a inferência coletiva melhora a classificação relacional. In *Proceedings of the 10th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 593–598.
- Jeong, H., Mason, SP, Barabási, AL & Oltvai, ZN 2001. Letalidade e centralidade em redes de proteínas. *Natureza*, 411 (6833), 41.
- Jeong, H., Mason, S., Barabasi, A. & Oltvai, Z. 2001. Letalidade e centralidade em redes de proteínas. pré-impressão arXiv cond-mat/0105306.
- Jeong, H., Tombor, B., Albert, R., Oltvai, Z. & Barabási, A. 2000. A organização em larga escala de redes metabólicas. *Natureza* 407 (6804), 651-654.
- Kleczkowski, A. & Grenfell, B. 1999. Equações do tipo campo médio para propagação de epidemias: o modelo do mundo pequeno. *Physica A: Mecânica Estatística e suas Aplicações* 274(1–2), 355–360.
- Koren, Y. 2010. Filtragem colaborativa com dinâmica temporal. *Comunicações da ACM* 53(4), 89–97.
- Koren, Y., Bell, R. & Volinsky, C. 2009. Técnicas de fatoração matricial para sistemas de recomendação. *Computador IEEE* 42(8), 30-37.
- Kovane, L., Karsai, M., Kaski, K., Kertész, J. & Saramäki, J. 2011. Motivos temporais em redes dependentes do tempo. *Journal of Statistical Mechanics: Theory and Experiment* 2011(11), P11005.
- Krebs, V. 2002. Mapeamento de redes de células terroristas. *Conexões* 24(3), 43–52.
- Lahiri, M. & Berger-Wolf, T. 2008. Comportamento periódico de mineração em redes sociais dinâmicas. Nos *Anais do 8º IEEE International Conference on Data Mining*, 373–382.
- Lahiri, M. & Berger-Wolf, TY 2007. Predição de estrutura em redes temporais usando subgrafos frequentes. Em *IEEE Simpósio sobre Inteligência Computacional e Mineração de Dados*, 35–42.
- Lassez, J.-L., Rossi, R. & Jeev, K. 2008. Ranking de links na web: motores de busca e navegação. In *Proceedings of the IEA/AIE International Conference*, 199–208. Springer.
- LeCun, Y., Bottou, L., Bengio, Y. & Haffner, P. 1998. Aprendizagem baseada em gradiente aplicada ao reconhecimento de documentos. *Anais do IEEE* 86(11), 2278–2324.
- Lee, H., Grosse, R., Ranganath, R. & Ng, AY 2009. Redes de crenças profundas convolucionais para aprendizado não supervisionado escalável de representações hierárquicas. In *Proceedings of the 26th International Conference on Machine Learning*, 609-616.
- Leskovec, J., Adamic, L. & Huberman, B. 2007a. A dinâmica do marketing viral. *Transações na Web* 1(1), 1-39.
- Leskovec, J., Kleinberg, J. & Faloutsos, C. 2007b. Evolução do gráfico: diâmetros de densificação e retração. *Transações na descoberta de conhecimento dos dados* 1(1), 1–41. <https://dl.acm.org/citation.cfm?id=1217301>.
- Lezama, J., Alahari, K., Sivic, J. & Laptev, I. 2011. Trilha para o futuro: segmentação de vídeo espaço-temporal com longa pistas de movimento de alcance. Na *Conferência IEEE sobre Visão Computacional e Reconhecimento de Padrões*.

- Li, L., Zheng, L., Yang, F. & Li, T. 2014. Modelagem e ampliação do interesse temporal do usuário em notícias personalizadas recomendação. *Sistemas especialistas com aplicativos* 41(7), 3168–3177.
- Liben-Nowell, D. & Kleinberg, J. 2007. O problema de previsão de links para redes sociais. *jornal do americano Society for Information Science and Technology* 58(7), 1019–1031.
- Liu, NN, He, L. & Zhao, M. 2013. Ranking colaborativo temporal social para recomendação de filme sensível ao contexto. *Transações ACM em Sistemas Inteligentes e Tecnologia* 4(1), 15.
- Lu, Q. & Getoor, L. 2003. Classificação baseada em links. *Anais da 20ª Conferência Internacional sobre Máquinas Aprendizagem*, 496-503.
- Ma, H., Yang, H., Lyu, MR & King, I. 2008. SoRec: recomendação social usando fatoração matricial probabilística. In *Proceedings of the 17th ACM Conference on Information and Knowledge Management*, 931-940.
- Macskassy, S. & Provost, F. 2003. Um classificador relacional simples. Nos *Anais do 2º Workshop SIGKDD sobre Mineração de dados multi-relacional*, 64-76.
- Marc'Aurelio Ranzato, Y., Boureau, L. & LeCun, Y. 2007. Aprendizado de recursos esparsos para redes de crenças profundas. *Avanços em Sistemas de Processamento de Informação Neural* 20, 1185-1192.
- Marcellino, M., Stock, JH & Watson, MW 2006. Uma comparação de multipasso direto e iterado são métodos para previsão de séries temporais macroeconômicas. *Journal of Econometrics* 135(1), 499–526.
- Maslov, S. & Sneppen, K. 2002. Especificidade e estabilidade na topologia de redes de proteínas. *Ciência* 296 (5569), 910-913.
- Maio, R. & Lloyd, A. 2001. Dinâmica de infecção em redes sem escala. *Revisão Física E* 64(6), 66112.
- McDowell, L., Gupta, K. & Aha, D. 2010. Meta-previsão para classificação coletiva. In *Anais da 23ª Conferência Internacional FLAIRS*.
- McDowell, LK, Gupta, KM & Aha, DW 2009. Classificação coletiva cautelosa. *Journal of Machine Learning Research* 10, 2777–2836.
- McGovern, A., Collier, N., Matthew Gagne, I., Brown, D. & Rodger, A. 2008. Árvores de probabilidade relacional espaço-temporais: uma introdução. In *Proceedings of the 8th IEEE International Conference on Data Mining*, 935–940.
- McGovern, A., Friedland, L., Hay, M., Gallagher, B., Fast, A., Neville, J. & Jensen, D. 2003. Explorando a estrutura relacional para entender os padrões de publicação em física de alta energia. *Explorações SIGKDD* 5(2), 165–172.
- McPherson, M., Smith-Lovin, L. & Cook, JM 2001. Birds of a feather: homofilia nas redes sociais. *Anual Revisão de Sociologia* 27(1), 415-444.
- Menon, A. & Elkan, C. 2011. Predição de link via fatoração de matriz. Em *Anais da Conferência Europeia sobre Aprendizado de Máquina e Princípios e Práticas de Descoberta de Conhecimento em Bancos de Dados*, 437–452.
- Moore, C. & Newman, M. 2000. Epidemias e percolação em redes de pequeno mundo. *Revisão Física E* 61(5), 5678-5682.
- Neville, J., Jensen, D. & Gallagher, B. 2003. Estimadores simples para classificadores Bayesianos relacionais. Em *Atos do 3ª Conferência Internacional IEEE sobre Mineração de Dados*, 609-612.
- Neville, J., Simsek, O., Jensen, D., Komoroske, J., Palmer, K. & Goldberg, H. 2005. Usando a descoberta de conhecimento relacional para prevenir a fraude de valores mobiliários. In *Proceedings of the 11th ACM SIGKDD International Conference on Knowledge Discovery in Data Mining*, 449–458.
- Newman, M. 2001. A estrutura das redes de colaboração científica. *Proceedings of the National Academy of Sciences* 98(2), 404–409.
- Newman, M., Barabasi, A.-L. & Watts, DJ 2006. *A Estrutura e Dinâmica das Redes*. Universidade de Princeton Imprensa.
- Nguyen, GH, Lee, JB, Rossi, RA, Ahmed, NK, Koh, E. & Kim, S. 2018. Incorporações de rede dinâmicas em tempo contínuo. No *3º Workshop Internacional sobre Representações de Aprendizagem para Grandes Redes (WWW BigNet)*.
- Noble, C. & Cook, D. 2003. Detecção de anomalia baseada em gráfico. Nos *Anais do 9º ACM SIGKDD Internacional Conferência sobre Descoberta de Conhecimento e Mineração de Dados*, 631–636.
- O'Madadhain, J. & Smyth, P. 2005. EventRank: uma estrutura para classificar redes variantes no tempo. Em *Processos de o Workshop LinkKDD*, 9–16.
- Oyama, S., Hayashi, K. & Kashima, H. 2011. Previsão de ligação temporal cruzada. Em *Anais do XI Internacional Conferência sobre Mineração de Dados*, 1188-1193.
- Pastor-Satorras, R. & Vespignani, A. 2001. Epidemia se espalhando em redes sem escala. *Cartas de Revisão Física* 86(14), 3200-3203.
- Pindyck, RS & Rubinfeld, DL 1981. *Modelos Econométricos e Previsões Econômicas*, 2. McGraw-Hill New York.
- Preisach, C. & Schmidt-Thieme, L. 2006. Classificação de conjunto relacional. Em *Anais da VI Internacional Conferência sobre Mineração de Dados*, 499-509.
- Preisach, C. & Schmidt-Thieme, L. 2008. Conjuntos de classificadores relacionais. *Conhecimento e Sistemas de Informação* 14(3), 249-272.
- Redmond, U., Harrigan, M. & Cunningham, P. 2012. Identificando subgrafos que respeitam o tempo em redes temporais. In *Proceedings of the 3rd International Workshop on Mining Ubiquitous and Social Environments*, 51–63.
- Rossi, RA 2014. Decomposição rápida do núcleo do triângulo para mineração de gráficos grandes. Em *Avanços na Descoberta do Conhecimento e Mineração de Dados*, 8443, 310-322.

- Rossi, RA 2015. Melhorando o Aprendizado de Máquina Relacional por Modelagem de Dependências Temporais. Tese de Doutorado, Purdue Universidade.
- Rossi, RA, Gallagher, B., Neville, J. & Henderson, K. 2013a. Modelando o comportamento dinâmico em grandes grafos em evolução. In *Proceedings of the Sixth ACM International Conference on Web Search and Data Mining*, 667–676.
- Rossi, RA & Gleich, D. 2012. PageRank dinâmico usando teletransporte em evolução. *Algoritmos e Modelos para a Web Gráfico* 7323, 126–137.
- Rossi, RA, Gleich, D. & Gebremedhin, A. 2013b. Decomposição do núcleo triangular e cliques máximos. Em *SIAM Network Science Workshop*, 1–2.
- Rossi, RA, Gleich, DF, Gebremedhin, AH & Patwary, MA 2012a. E se a panelinha fosse rápida? Máximo de cliques em redes de informação e fortes componentes em redes temporais. *arXiv: 1210.5802*, 1–11.
- Rossi, RA, Gleich, DF, Gebremedhin, AH & Patwary, MA 2013c. Um algoritmo de clique máximo quase paralelo para grandes gráficos esparsos e componentes fortes temporais. *arXiv: 1302.6256*, 1–9.
- Rossi, RA, McDowell, LK, Aha, DW & Neville, J. 2012b. Transformando dados de gráfico para estatística relacional Aprendendo. *Journal of Artificial Intelligence Research* 45, 363–441.
- Rossi, RA & Neville, J. 2010. Modelagem da evolução dos tópicos de discussão e comunicação para melhorar a classificação relacional. In *Proceedings of the ACM SIGKDD 1st Workshop on Social Media Analytics*, 89–97.
- Rossi, RA & Neville, J. 2012. Classificação relacional evolutiva no tempo e métodos ensemble. Em *Avanços em Descoberta de Conhecimento e Mineração de Dados* 7301, 1–13. Springer.
- Salakhutdinov, R. & Hinton, GE 2009. Máquinas profundas de Boltzmann. Na *Conferência Internacional sobre Inteligência Artificial e Estatística*, 448–455.
- Schall, D. 2014. Previsão de links em redes sociais direcionadas. *Análise de Redes Sociais e Mineração* 4(1), 1–14.
- Sharan, U. & Neville, J. 2008. Classificadores temporais-relacionais para predição em domínios em evolução. Em *Processos de a 8ª Conferência Internacional IEEE sobre Mineração de Dados*, 540–549.
- Tang, J., Musolesi, M., Mascolo, C. & Latora, V. 2009. Métricas de distância temporal para análise de redes sociais. In *Proceedings of the 2nd ACM Workshop on Online Social Networks*, 31–36.
- Tang, J., Musolesi, M., Mascolo, C., Latora, V. & Nicosia, V. 2010. Analisar fluxos de informação e mediadores-chave através de métricas de centralidade temporal. In *Proceedings of the 3rd Workshop on Social Network Systems*, 1–6.
- Tong, H. & Lin, C. 2011. Fatoração matricial residual não negativa com aplicação à detecção de anomalias gráficas. In *Proceedings of the 7th SIAM International Conference on Data Mining*.
- Wagner, A. & Fell, D. 2001. O pequeno mundo dentro de grandes redes metabólicas. *Anais da Royal Society of Londres. Série B: Ciências Biológicas* 268 (1478), 1803–1810.
- Watts, DJ & Strogatz, SH 1998. Dinâmica coletiva de redes de 'pequeno mundo'. *Natureza* 393 (6684), 440–442.
- Xiang, L., Yuan, Q., Zhao, S., Chen, L., Zhang, X., Yang, Q. & Sun, J. 2010a. Recomendação temporal em gráficos via fusão de preferência de longo e curto prazo. In *Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 723–732.
- Xiang, R., Neville, J. & Rogati, M. 2010b. Modelagem da força de relacionamento em redes sociais online. Em *Procedimentos da 19ª Conferência Internacional da World Wide Web*, 981–990.
- Xuan, B., Ferreira, A. & Jarry, A. 2003. Computando jornadas mais curtas, rápidas e principais em redes dinâmicas. *International Journal of Foundations of Computer Science* 14(2), 267–285.